Probabilidade e Estatística: A Ciência da Incerteza

Michael J. Evans e Jeffrey S. Rosenthal

Aviso sobre esta tradução

Esta tradução foi feita inteiramente por inteligência artificial, a partir da segunda edição em inglês de *Probability and Statistics: The Science of Uncertainty*, de Michael J. Evans e Jeffrey S. Rosenthal, e é publicada com a autorização dos autores. Ela não passou pela revisão de um tradutor profissional e pode conter erros.

O trabalho foi conduzido por uma só pessoa. A inteligência artificial foi usada com o objetivo de democratizar o acesso ao conhecimento: levar um material de alta qualidade, que os autores oferecem gratuitamente, a quem não lê com facilidade o idioma do original.

A versão oficial, em inglês, está disponível gratuitamente em `https://utstat.utoronto.ca/mikevans/jeffrosenthal/`. Em caso de dúvida, ela é a referência.

Notice

This translation was produced entirely by artificial intelligence from the second English edition of *Probability and Statistics: The Science of Uncertainty*, by Michael J. Evans and Jeffrey S. Rosenthal, and is published with the authors' permission. It has not been reviewed by a professional translator and may contain errors.

The work was carried out by a single person. Artificial intelligence was used to democratize access to knowledge: to bring this high-quality material, which the authors make freely available, to readers who do not easily read the original language.

The official English version is freely available at `https://utstat.utoronto.ca/mikevans/jeffrosenthal/`. In case of doubt, it is the reference.

Sumário

Prefácio **x**

1 Modelos de Probabilidade **1**

1.1 Probabilidade: Uma Medida de Incerteza 1

1.1.1 Por Que Precisamos da Teoria da Probabilidade? 3

1.2 Modelos de Probabilidade 6

1.2.1 Diagramas de Venn e Subconjuntos 10

1.3 Propriedades dos Modelos de Probabilidade 14

1.4 Probabilidade Uniforme em Espaços Finitos 19

1.4.1 Princípios de Contagem 21

1.5 Probabilidade Condicional e Independência 29

1.5.1 Probabilidade Condicional 29

1.5.2 Independência de Eventos 34

1.6 Continuidade de P 41

1.7 Demonstrações Adicionais (Avançado) 45

2 Variáveis Aleatórias e Distribuições **47**

2.1 Variáveis Aleatórias 48

2.2 Distribuições de Variáveis Aleatórias 54

2.3 Distribuições Discretas 59

2.3.1 Distribuições Discretas Importantes 61

2.4 Distribuições Contínuas 76

2.4.1 Distribuições Absolutamente Contínuas Importantes . . . 79

2.5 Funções de Distribuição Acumulada 93
2.5.1 Propriedades das Funções de Distribuição 95
2.5.2 Fdas de Distribuições Discretas 96
2.5.3 Fdas de Distribuições Absolutamente Contínuas 97
2.5.4 Distribuições de Mistura 101
2.5.5 Distribuições Nem Discretas Nem Contínuas (Avançado) . 105
2.6 Mudança de Variável Unidimensional 111
2.6.1 O Caso Discreto 111
2.6.2 O Caso Contínuo 113
2.7 Distribuições Conjuntas 119
2.7.1 Funções de Distribuição Acumulada Conjuntas 120
2.7.2 Distribuições Marginais 122
2.7.3 Funções de Probabilidade Conjuntas 125
2.7.4 Funções Densidade Conjuntas 128
2.8 Condicionamento e Independência 141
2.8.1 Condicionamento em Variáveis Aleatórias Discretas . . . 141
2.8.2 Condicionamento em Variáveis Aleatórias Contínuas . . . 143
2.8.3 Independência de Variáveis Aleatórias 146
2.8.4 Estatísticas de Ordem 155
2.9 Mudança de Variável Multidimensional 162
2.9.1 O Caso Discreto 163
2.9.2 O Caso Contínuo (Avançado) 164
2.9.3 Convolução 167
2.10 Simulando Distribuições de Probabilidade 172
2.10.1 Simulando Distribuições Discretas 174
2.10.2 Simulando Distribuições Contínuas 177
2.11 Demonstrações Adicionais (Avançado) 186

3 Esperança **190**

3.1 O Caso Discreto 191

3.2 O Caso Absolutamente Contínuo 207

3.3 Variância, Covariância e Correlação 218

3.4 Funções Geradoras 237

3.4.1 Funções Características (Avançado) 248

3.5 Esperança Condicional 255

3.5.1 Caso Discreto 256

3.5.2 Caso Absolutamente Contínuo 260

3.5.3 Esperanças Duplas 262

3.5.4 Variância Condicional (Avançado) 265

3.6 Desigualdades 273

3.6.1 Desigualdade de Jensen (Avançado) 277

3.7 Esperanças Gerais (Avançado) 283

3.8 Demonstrações Adicionais (Avançado) 287

4 Distribuições Amostrais e Limites **292**

4.1 Distribuições Amostrais 293

4.2 Convergência em Probabilidade 298

4.2.1 A Lei Fraca dos Grandes Números 301

4.3 Convergência com Probabilidade 1 305

4.3.1 A Lei Forte dos Grandes Números 309

4.4 Convergência em Distribuição 312

4.4.1 O Teorema Central do Limite 316

4.4.2 O Teorema Central do Limite e a Avaliação do Erro 322

4.5 Aproximações de Monte Carlo 328

4.6 Teoria da Distribuição Normal 342

4.6.1 A Distribuição Qui-quadrado 344

4.6.2 A Distribuição t 348

4.6.3 A Distribuição F 350
4.7 Demonstrações Adicionais (Avançado) 357

5 Inferência Estatística 365
5.1 Por Que Precisamos da Estatística? 366
5.2 Inferência Usando um Modelo de Probabilidade 372
5.3 Modelos Estatísticos 378
5.4 Coleta de Dados 389
5.4.1 Populações Finitas 390
5.4.2 Amostragem Aleatória Simples 392
5.4.3 Histogramas 396
5.4.4 Amostragem por Levantamento 398
5.5 Algumas Inferências Básicas 407
5.5.1 Estatísticas Descritivas 408
5.5.2 Gráficos dos Dados 414
5.5.3 Tipos de Inferências 417

6 Inferência por Verossimilhança 427
6.1 A Função de Verossimilhança 427
6.1.1 Estatísticas Suficientes 434
6.2 Estimação por Máxima Verossimilhança 443
6.2.1 Cálculo do EMV 445
6.2.2 O Caso Multidimensional (Avançado) 453
6.3 Inferências Baseadas no EMV 460
6.3.1 Erros Padrão, Viés e Consistência 461
6.3.2 Intervalos de Confiança 469
6.3.3 Testes de Hipóteses e Valores-p 477
6.3.4 Inferências para a Variância 486
6.3.5 Cálculos de Tamanho da Amostra: Intervalos de Confiança 488
6.3.6 Cálculo do Tamanho da Amostra: Poder 490

6.4 Métodos Livres de Distribuição 501
6.4.1 Método dos Momentos 502
6.4.2 Bootstrap 504
6.4.3 A Estatística do Sinal e Inferências sobre Quantis 511
6.5 Assintótica do EMV (Avançado) 521

7 Inferência Bayesiana 533
7.1 As Distribuições a Priori e a Posteriori 534
7.2 Inferências Baseadas na Distribuição a Posteriori 548
7.2.1 Estimação 552
7.2.2 Intervalos de Credibilidade 558
7.2.3 Teste de Hipóteses e Fatores de Bayes 562
7.2.4 Predição 570
7.3 Cálculos Bayesianos 579
7.3.1 Normalidade Assintótica da Distribuição a Posteriori . . . 579
7.3.2 Amostragem da Distribuição a Posteriori 580
7.3.3 Amostragem da Distribuição a Posteriori via Amostragem de Gibbs (Avançado) 584
7.4 Escolha de Distribuições a Priori 598
7.4.1 Prioris Conjugadas 598
7.4.2 Elicitação 599
7.4.3 Bayes Empírico 600
7.4.4 Bayes Hierárquico 602
7.4.5 Prioris Impróprias e Não Informatividade 603
7.5 Demonstrações Adicionais (Avançado) 610

8 Inferências Ótimas 612
8.1 Estimação Não Viesada Ótima 613
8.1.1 O Teorema de Rao–Blackwell e a Rao–Blackwellização . . 614
8.1.2 Completude e o Teorema de Lehmann–Scheffé 620

8.1.3 A Desigualdade de Cramer–Rao (Avançado) 623
8.2 Testes de Hipóteses Ótimos 631
8.2.1 A Função Poder de um Teste 632
8.2.2 Erros Tipo I e Tipo II 633
8.2.3 Regiões de Rejeição e Funções de Teste 634
8.2.4 O Teorema de Neyman–Pearson 636
8.2.5 Testes da Razão de Verossimilhança (Avançado) 644
8.3 Inferências Bayesianas Ótimas 650
8.4 Teoria da Decisão (Avançado) 655
8.5 Demonstrações Adicionais (Avançado) 670

9 Verificação de Modelos 676
9.1 Verificação do Modelo Amostral 676
9.1.1 Gráficos de Resíduos e de Probabilidade 685
9.1.2 O Teste Qui-quadrado de Aderência 691
9.1.3 Predição e Validação Cruzada 698
9.1.4 O Que Fazemos Quando um Modelo Falha? 699
9.2 Verificação de Conflito entre a Priori e Dados 707
9.3 O Problema das Verificações Múltiplas 718

10 Relações entre Variáveis 721
10.1 Variáveis Relacionadas 722
10.1.1 A Definição de Relação 722
10.1.2 Relações de Causa e Efeito e Experimentos 728
10.1.3 Planejamento de Experimentos 733
10.2 Resposta e Preditores Categóricos 744
10.2.1 Preditor Aleatório 744
10.2.2 Preditor Determinístico 748
10.2.3 Formulação Bayesiana 752
10.3 Resposta e Preditores Quantitativos 759

10.3.1 O Método dos Mínimos Quadrados 759
10.3.2 O Modelo de Regressão Linear Simples 762
10.3.3 Modelo Linear Simples Bayesiano (Avançado) 781
10.3.4 O Modelo de Regressão Linear Múltipla (Avançado) 787
10.4 Resposta Quantitativa e Preditores Categóricos 812
10.4.1 Um Preditor Categórico (ANOVA com Um Fator) 812
10.4.2 Medidas Repetidas (Comparações Pareadas) 820
10.4.3 Dois Preditores Categóricos (ANOVA com Dois Fatores) . 823
10.4.4 Blocos Aleatorizados 832
10.4.5 Um Preditor Categórico e Um Preditor Quantitativo . . . 834
10.5 Resposta Categórica e Preditores Quantitativos 845
10.6 Demonstrações Adicionais (Avançado) 851

11 Tópico Avançado — Processos Estocásticos 859
11.1 Passeio Aleatório Simples 859
11.1.1 A Distribuição da Fortuna 861
11.1.2 O Problema da Ruína do Jogador 863
11.2 Cadeias de Markov 870
11.2.1 Exemplos de Cadeias de Markov 871
11.2.2 Cálculos com Cadeias de Markov 876
11.2.3 Distribuições Estacionárias 879
11.2.4 Teorema Limite para Cadeias de Markov 886
11.3 Monte Carlo via Cadeias de Markov 899
11.3.1 O Algoritmo de Metropolis–Hastings 902
11.3.2 O Amostrador de Gibbs 907
11.4 Martingais 911
11.4.1 Definição de Martingal 912
11.4.2 Valores Esperados 914
11.4.3 Tempos de Parada 915

11.5 Movimento Browniano 922
11.5.1 Passeios Aleatórios Cada Vez Mais Rápidos 923
11.5.2 O Movimento Browniano como Limite 925
11.5.3 Difusões e Preços de Ações 929
11.6 Processos de Poisson 935
11.7 Demonstrações Adicionais 939

A Fundamentos Matemáticos **948**
A.1 Derivadas 948
A.2 Integrais 949
A.3 Séries Infinitas 950
A.4 Multiplicação de Matrizes 951
A.5 Derivadas Parciais 952
A.6 Integrais Múltiplas 953

B Cálculos **956**
B.1 Usando o R 956
B.2 Usando o Minitab 977

C Distribuições Comuns **985**
C.1 Distribuições Discretas 985
C.2 Distribuições Absolutamente Contínuas 987

D Tabelas **990**
D.1 Números Aleatórios 990
D.2 Fda da Normal Padrão 993
D.3 Quantis da Distribuição Qui-Quadrado 995
D.4 Quantis da Distribuição t 997
D.5 Quantis da Distribuição F 999
D.6 Probabilidades da Distribuição Binomial 1008

E Respostas dos Exercícios Ímpares **1019**

Prefácio

Este livro é um texto introdutório de probabilidade e estatística, voltado para estudantes que cursaram um ano de cálculo na universidade e procuram uma introdução à probabilidade e à estatística com conteúdo matemático. Sempre que possível, apresentamos os detalhes matemáticos, e espera-se que os estudantes queiram adquirir algum domínio sobre eles, além de aprender a conduzir análises de dados. Todas as metodologias habituais de um curso introdutório típico são apresentadas, assim como parte da teoria que as justifica.

O texto pode ser usado com ou sem um pacote estatístico de computador. Na nossa opinião, os estudantes devem perceber a importância de várias técnicas computacionais nas aplicações, e o livro procura mostrar isso. Por isso, achamos que os aspectos computacionais do assunto, como o método de Monte Carlo, devem ser abordados, mesmo que não se use um pacote estatístico. Quase qualquer pacote estatístico serve. O apêndice **Cálculos** traz uma introdução à linguagem R. Ele cobre todos os aspectos da linguagem necessários para fazer as contas do texto. Além disso, fornecemos o código R de todas as contas mais complicadas. Os estudantes podem usar esses exemplos como modelo para problemas que envolvam esse tipo de conta, por exemplo, com amostragem de Gibbs[1]. Também fornecemos, numa seção à parte desse apêndice, código do Minitab para as contas um pouco mais trabalhosas, por exemplo, a amostragem de Gibbs. Não é preciso ter experiência com programação para resolver os problemas.

Organizamos os exercícios do livro em grupos, para ajudar quem o usa. Os **Exercícios** servem para todos os estudantes e oferecem prática na aplicação dos conceitos discutidos numa seção. Os **Problemas** exigem uma compreensão maior, e o estudante pode esperar passar mais tempo pensando neles. Se um problema estiver marcado com (MV), ele vai exigir alguma familiaridade com cálculo de várias variáveis além do primeiro curso de cálculo, embora esses problemas não sejam necessariamente difíceis. Os **Desafios** são problemas que a maioria dos estudantes vai achar difíceis; são só para os estudantes que não têm dificuldade com os **Exercícios** e os **Problemas**. Há também **Exercícios computacionais** e **Problemas computacionais**, nos quais se espera que os estudantes usem um pacote estatístico para chegar às soluções.

Incluímos vários **Tópicos para discussão**, pensados para estimular o pensamento crítico dos estudantes. Ao longo de todo o livro, procuramos levar

No original: *Gibbs sampling*[1].

os estudantes além do domínio das técnicas, para que pensem no assunto num quadro de referência mais amplo. É importante que os estudantes adquiram uma base matemática sólida nas técnicas básicas de probabilidade e estatística, e acreditamos que este livro os ajudará a conseguir isso. Em última análise, porém, essas disciplinas são aplicadas em contextos do mundo real, e por isso é igualmente importante que os estudantes entendam como aplicá-las e quais questões surgem. Muitas vezes, os **Tópicos para discussão** não têm resposta certa; o objetivo deles é fazer o estudante pensar sobre o assunto. Se fossem usados para avaliação, seriam respondidos em forma de dissertação e corrigidos pela maturidade que o estudante mostrasse em relação às questões envolvidas. Os Tópicos para discussão provavelmente são mais adequados a turmas menores, mas também vão beneficiar os estudantes que simplesmente os lerem e refletirem sobre a relevância deles.

Algumas seções do livro estão marcadas como Avançado. Esse material é voltado a estudantes com mais maturidade matemática (por exemplo, que estejam cursando, ou já tenham cursado, uma segunda disciplina de cálculo). Todo o material Avançado pode ser omitido, sem perda de continuidade, pelo professor que assim desejar. Em particular, o último capítulo do texto está marcado como Avançado e só seria dado num curso introdutório de nível alto, voltado a especialistas. Além disso, muitas demonstrações aparecem na última seção de muitos capítulos, intitulada Demonstrações Adicionais (Avançado). O professor pode escolher quais dessas demonstrações (se alguma) deseja apresentar aos seus alunos.

Assim, achamos que o material do texto é apresentado de forma flexível, o que permite ao professor encontrar um nível adequado para os estudantes a quem ensina. Um apêndice de **Fundamentos Matemáticos** revisa alguns conceitos matemáticos de um primeiro curso de cálculo, caso os estudantes precisem relembrá-los, e traz também breves introduções a derivadas parciais, integrais duplas etc.

O Capítulo 1 apresenta o modelo de probabilidade[2] e motiva o estudo da probabilidade. São desenvolvidas as propriedades básicas de uma medida de probabilidade[3].

O Capítulo 2 trata de distribuições discretas, contínuas e conjuntas, e dos efeitos de uma mudança de variável[4]. Também introduz o tema da simulação a partir de uma distribuição de probabilidade. A mudança de variável multivariada é desenvolvida numa seção Avançada.

No original: *probability model*[2], *probability measure*[3], *change of variable*[4].

O Capítulo 3 introduz a esperança[5]. São discutidos a função geradora[6] de probabilidade, os momentos e a função geradora de momentos[7] de uma variável aleatória[8]. Este capítulo desenvolve algumas das principais desigualdades usadas em probabilidade. Uma seção sobre funções características está incluída como tópico Avançado.

O Capítulo 4 trata de distribuições amostrais e limites. Convergência em probabilidade[9], convergência com probabilidade 1[10], as leis fraca e forte dos grandes números, convergência em distribuição[11] e o teorema central do limite[12] são todos apresentados, junto com diversas aplicações, como o método de Monte Carlo. A teoria da distribuição normal, necessária para muitas aplicações estatísticas, também é tratada aqui.

Como já dissemos, os Capítulos 1 a 4 incluem material sobre técnicas de Monte Carlo. A simulação é um aspecto fundamental da aplicação da teoria da probabilidade, e, na nossa visão, seu ensino deve estar integrado à teoria desde o começo. Isso revela o poder da probabilidade para resolver problemas do mundo real e ajuda a convencer os estudantes de que ela é muito mais do que apenas uma teoria matemática interessante. Nenhum profissional da área se afasta da teoria quando usa o computador para fazer contas, nem o contrário. Acreditamos que essa é uma forma mais moderna de ensinar o assunto. Esse material pode ser omitido, porém, se o professor pensar de outro modo ou achar que não há tempo suficiente para tratá-lo bem.

O Capítulo 5 é uma introdução à inferência estatística. Na maior parte, ele se ocupa de preparar o terreno para o desenvolvimento de uma metodologia mais formal nos capítulos seguintes. Por isso, questões práticas — como a coleta adequada de dados, a apresentação de dados por técnicas gráficas e métodos informais de inferência, como a estatística descritiva — são discutidas aqui.

O Capítulo 6 trata de muitos dos métodos padrão de inferência para problemas de uma amostra. A justificativa teórica desses métodos é desenvolvida principalmente por meio da função de verossimilhança[13], mas o tratamento[14] ainda é bastante informal. São apresentados métodos básicos de inferência, como o erro padrão[15] de uma estimativa[16], os intervalos de confiança e os valores-p. Há também uma seção dedicada a métodos livres de distribuição[17] (não paramétricos), como o bootstrap[18].

O Capítulo 7 aborda muitos dos mesmos problemas discutidos no Capítulo 6, mas agora de uma perspectiva bayesiana. O ponto de vista adotado aqui

---

No original: *expectation*[5], *generating function*[6], *moment-generating function*[7], *random variable*[8], *convergence in probability*[9], *convergence with probability 1*[10], *convergence in distribution*[11], *central limit theorem*[12], *likelihood function*[13], *treatment*[14], *standard error*[15], *estimate*[16], *distribution-free methods*[17], *bootstrapping*[18].

não é que os métodos bayesianos sejam melhores, nem, aliás, piores que os do Capítulo 6. Nossa visão é, antes, que os métodos bayesianos surgem naturalmente quando o estatístico acrescenta outro ingrediente — a distribuição a priori[19] — ao modelo. A adequação dela, ou do modelo amostral[20] para os dados, é resolvida pelos métodos de verificação de modelos[21] do Capítulo 9. Não é nossa intenção fazer os estudantes adotarem uma filosofia particular. Em vez disso, o texto apresenta aos estudantes um amplo espectro do pensamento estatístico.

Os capítulos seguintes tratam das abordagens frequentista e bayesiana dos diversos problemas discutidos. O material bayesiano está em seções claramente identificadas e pode ser omitido sem perda de continuidade, se assim se desejar. Nos últimos anos, porém, ficou claro que a metodologia bayesiana é amplamente usada nas aplicações. Por isso, achamos importante que os estudantes tenham contato com ela, assim como com as abordagens frequentistas, cedo na sua formação estatística.

O Capítulo 8 trata das justificativas tradicionais de otimalidade oferecidas para algumas inferências estatísticas. Em particular, são discutidos alguns aspectos da estimação[22] não viesada ótima e o teorema de Neyman–Pearson. Há também uma breve introdução à teoria da decisão[23]. Este capítulo é mais formal e matemático que os Capítulos 5, 6 e 7, e pode ser omitido, sem perda de continuidade, se o professor quiser dar ênfase a métodos e aplicações.

O Capítulo 9 trata da verificação de modelos. Pusemos a verificação de modelos num capítulo separado para ressaltar sua importância nas aplicações. Na prática, a verificação de modelos é o modo como os estatísticos justificam as escolhas que fazem ao selecionar os ingredientes de um problema estatístico. Embora essas escolhas sejam inerentemente subjetivas, os métodos deste capítulo fornecem verificações para garantir que as escolhas feitas sejam sensatas à luz dos dados observados objetivos.

O Capítulo 10 trata da análise estatística das relações entre variáveis. Ele inclui material sobre regressão linear simples e múltipla, ANOVA, planejamento de experimentos[24] e tabelas de contingência. A ênfase deste capítulo está nas aplicações.

O Capítulo 11 trata de processos estocásticos. Em particular, cadeias de Markov e Monte Carlo via cadeias de Markov são abordados neste capítulo, assim como o movimento browniano[25] e sua relevância em finanças. São apresentados

No original: *prior*[19], *sampling model*[20], *model checking*[21], *estimation*[22], *decision theory*[23], *design of experiments*[24], *Brownian motion*[25].

tópicos bastante sofisticados, mas o tratamento é inteiramente elementar. O Capítulo 11 depende apenas do material dos Capítulos 1 a 4.

Um curso semestral de probabilidade cobriria os Capítulos 1–4 e talvez parte do Capítulo 11. Um curso semestral de estatística, na sequência, cobriria os Capítulos 5–7 e 9–10. O Capítulo 8 não é necessário, mas algumas partes, como a teoria da estimação não viesada e os testes ótimos, são adequadas a um curso mais teórico.

Um curso básico de dois semestres de probabilidade e estatística cobriria os Capítulos 1–6 e 9–10. Um curso assim abrange todos os temas tradicionais, inclusive a teoria básica da probabilidade, os conceitos básicos de inferência estatística e os temas habituais de estatística aplicada introdutória. Cobrir o livro inteiro levaria três semestres, que poderiam ser organizados de várias maneiras.

As seções Avançadas podem ser omitidas ou incluídas, conforme o nível dos estudantes, sem perda de continuidade. O mesmo vale para os Capítulos 7, 8 e 11.

Estudantes que já fizeram um curso introdutório de estatística aplicada sem cálculo também vão tirar proveito de um curso baseado neste texto. Embora os temas sejam parecidos, aqui eles são apresentados com mais profundidade e rigor. Por exemplo, *Introduction to the Practice of Statistics*, 6ª ed., de D. Moore e G. McCabe (W. H. Freeman, 2009), é um excelente texto, e acreditamos que o nosso livro serviria de base sólida para um curso de continuação.

Há um Manual de Soluções do Professor (*Instructor's Solutions Manual*) disponível na editora.

A segunda edição contém muito mais exercícios básicos que a primeira. Além disso, reescrevemos várias seções, com o objetivo de deixar o material mais claro para os estudantes. Uma das metas da reescrita foi dividir o material em partes menores e mais fáceis de digerir, para que as ideias principais se destaquem com mais nitidez. Houve também uma reformulação tipográfica completa que, a nosso ver, também ajuda nisso. Nos apêndices, acrescentamos material sobre o pacote estatístico R, além das respostas dos exercícios ímpares, que os estudantes podem usar para conferir sua compreensão.

Muito obrigado aos revisores e usuários pelos seus comentários: Abbas Alhakim (Clarkson University), Michelle Baillargeon (McMaster University), Arne C. Bathke (University of Kentucky), Lisa A. Bloomer (Middle Tennessee State University), Christopher Brown (California Lutheran University), Jem N. Corcoran (University of Colorado), Guang Cheng (Purdue University), Yi Cheng (Indiana University South Bend), Eugene Demidenko (Dartmouth College),

Robert P. Dobrow (Carleton College), John Ferdinands (Calvin College), Soledad A. Fernandez (The Ohio State University), Paramjit Gill (University of British Columbia Okanagan), Marvin Glover (Milligan College), Ellen Gundlach (Purdue University), Paul Gustafson (University of British Columbia), Jan Hannig (Colorado State University), Solomon W. Harrar (The University of Montana), Susan Herring (Sonoma State University), George F. Hilton (Pacific Union College), Chun Jin (Central Connecticut State University), Paul Joyce (University of Idaho), Hubert Lilliefors (George Washington University), Andy R. Magid (University of Oklahoma), Phil McDonnough (University of Toronto), Julia Morton (Nipissing University), Jean D. Opsomer (Colorado State University), Randall H. Rieger (West Chester University), Robert L. Schaefer (Miami University), Osnat Stramer (University of Iowa), Tim B. Swartz (Simon Fraser University), Glen Takahara (Queen's University), Robert D. Thompson (Hunter College), David C. Vaughan (Wilfrid Laurier University), Joseph J. Walker (Georgia State University), Chad Westerland (University of Arizona), Dongfeng Wu (Mississippi State University), Yuehua Wu (York University), Nicholas Zaino (University of Rochester). Em particular, o professor Chris Andrews (State University of New York) forneceu muitas correções à primeira edição.

Os autores também agradecem a muitas pessoas que ajudaram no desenvolvimento deste projeto. Em particular, nossos colegas e alunos da University of Toronto nos apoiaram muito. Ping Gao, Aysha Hashim, Gun Ho Jang, Hadas Moshonov e Mahinda Samarakoon ajudaram de muitas formas. Vários dos conjuntos de dados do Capítulo 10 são usados há muitos anos em disciplinas da University of Toronto e foram, acreditamos, compilados pelo trabalho do falecido professor Daniel B. DeLury. O professor David Moore, da Purdue University, ajudou fornecendo várias das tabelas do fim do livro. Patrick Farace, Anne Scanlan-Rohrer, Chris Spavins, Danielle Swearengin, Brian Tedesco, Vivien Weiss e Katrina Wilhelm, da W. H. Freeman, deram muito apoio e incentivo. Nossas famílias nos ajudaram com sua paciência e carinho enquanto trabalhávamos no que às vezes parecia uma tarefa sem fim; muito obrigado a Rosemary e Heather Evans e a Margaret Fulford.

Michael Evans e Jeffrey Rosenthal
Toronto, 2009

Há vários anos deixamos o livro disponível gratuitamente na web. Esta versão corrige uma série de problemas apontados pelos usuários. Somos gratos a todos que nos chamaram a atenção para eles (veja a página antiga na web para os agradecimentos individuais) e continuaremos a fazer correções à medida que formos informados.

Michael Evans e Jeffrey Rosenthal
Toronto, 2023

CAPÍTULO 1

Modelos de Probabilidade

ESBOÇO DO CAPÍTULO

Seção 1 Probabilidade: Uma Medida de Incerteza
Seção 2 Modelos de Probabilidade
Seção 3 Propriedades dos Modelos de Probabilidade
Seção 4 Probabilidade Uniforme em Espaços Finitos
Seção 5 Probabilidade Condicional e Independência
Seção 6 Continuidade de P
Seção 7 Demonstrações Adicionais (Avançado)

Este capítulo apresenta o conceito básico de todo o curso, a saber, a probabilidade. Discutimos por que a probabilidade foi introduzida como um conceito científico e como ela foi formalizada matematicamente em termos de um modelo de probabilidade[1]. Em seguida, desenvolvemos alguns dos resultados matemáticos básicos associados ao modelo de probabilidade.

1.1 Probabilidade: Uma Medida de Incerteza

Muitas vezes, na vida, nos deparamos com a nossa própria ignorância. Seja quando pensamos no engarrafamento de hoje à noite, no tempo de amanhã, nos preços das ações na semana que vem, numa eleição que se aproxima ou em onde deixamos o chapéu, frequentemente não conhecemos um resultado com certeza. Em vez disso, somos obrigados a adivinhar, a estimar, a nos precaver em nossas apostas.

Probabilidade é a ciência da incerteza. Ela fornece regras matemáticas precisas para entender e analisar a nossa própria ignorância. Ela não nos diz como estará o tempo amanhã nem quais serão os preços das ações na semana que vem; em vez disso, nos dá uma estrutura para trabalhar com o nosso conhecimento limitado e para tomar decisões sensatas com base no que sabemos e no que não sabemos.

No original: *probability model*[1].

Dizer que há 40% de chance de chuva amanhã não é saber como estará o tempo amanhã. É, antes, saber o que não sabemos sobre o tempo de amanhã.

Neste texto, vamos desenvolver uma compreensão mais precisa do que significa dizer que há 40% de chance de chuva amanhã. Vamos aprender a trabalhar com ideias de aleatoriedade, probabilidade, valor esperado[2], previsão, estimação[3] etc., de maneiras que sejam sensatas e matematicamente claras.

Há também outras fontes de aleatoriedade além da incerteza. Por exemplo, os computadores costumam usar *números pseudoaleatórios*[4] para tornar os jogos divertidos, as simulações precisas e as buscas eficientes. Além disso, segundo a teoria moderna da mecânica quântica, a constituição da matéria atômica é, em certo sentido, *verdadeiramente* aleatória. Todas essas fontes de aleatoriedade podem ser estudadas com as técnicas deste texto.

Outra maneira de pensar sobre probabilidade é em termos de *frequência relativa*[5]. Por exemplo, dizer que uma moeda tem 50% de chance de dar cara pode ser interpretado como dizer que, se lançássemos a moeda muitas e muitas vezes, ela daria cara aproximadamente na metade das vezes. Essa interpretação tem algumas limitações. Em muitos casos (como o tempo de amanhã ou os preços das ações na semana que vem), é impossível repetir o experimento muitas e muitas vezes. Além disso, o que exatamente significa "aproximadamente" nesse caso? Apesar dessas limitações, porém, a interpretação por frequência relativa é uma maneira útil de pensar sobre probabilidades e de desenvolver intuição sobre elas.

A incerteza nos acompanha desde sempre, é claro, mas a teoria matemática da probabilidade surgiu no século XVII. Em 1654, o jogador parisiense Le Chevalier de Méré perguntou a Blaise Pascal sobre certas probabilidades que apareciam nos jogos de azar (por exemplo: se um jogo de azar é interrompido no meio, qual é a probabilidade de que cada jogador teria vencido caso o jogo continuasse?). Pascal ficou intrigado e se correspondeu com o grande matemático e advogado Pierre de Fermat sobre essas questões. Mais tarde, Pascal escreveu o livro *Traité du Triangle Arithmetique*, em que discute os coeficientes binomiais (o triângulo de Pascal) e a distribuição de probabilidade binomial.

No início do século XX, russos como Andrei Andreyevich Markov, Andrey Nikolayevich Kolmogorov e Pafnuty L. Chebychev (e o americano Norbert Wiener) desenvolveram uma teoria matemática da probabilidade mais formal. Na década de 1950, os americanos William Feller e Joe Doob escreveram livros

No original: *expected value*[2], *estimation*[3], *pseudorandom numbers*[4], *relative frequency*[5].

importantes sobre a matemática da teoria da probabilidade. Eles popularizaram o assunto no mundo ocidental, tanto como uma área importante da matemática pura quanto pelas suas aplicações importantes na física, na química e, mais tarde, na ciência da computação, na economia e nas finanças.

1.1.1 Por Que Precisamos da Teoria da Probabilidade?

A teoria da probabilidade aparece com muita frequência no nosso dia a dia. Apresentamos alguns exemplos aqui.

Suponha que você esteja pensando em comprar um bilhete da loteria "Lotto 6/49". Nessa loteria, você escolhe seis números inteiros distintos entre 1 e 49. Em seguida, outros seis inteiros distintos entre 1 e 49 são sorteados ao acaso pela empresa da loteria. Se os dois conjuntos de seis inteiros forem idênticos, você ganha o prêmio máximo.

Depois de dominar a Seção 1.4, você saberá calcular que a probabilidade de os dois conjuntos coincidirem é igual a uma chance em 13.983.816. Ou seja, é cerca de 14 milhões de vezes mais provável que você não ganhe o prêmio máximo do que ganhe. (Não são chances muito boas!)

Suponha que os bilhetes da loteria custem US$ 1 cada. Depois de dominar os valores esperados no Capítulo 3, você saberá que não deve nem sequer *cogitar* comprar um bilhete de loteria a menos que o prêmio máximo seja maior que US$ 14 milhões (o que normalmente não é). Além disso, se o prêmio máximo algum dia passar de US$ 14 milhões, é provável que muitas outras pessoas comprem bilhetes

naquela semana, o que aumenta a probabilidade de você ter de *dividir* o prêmio máximo com outros ganhadores mesmo que ganhe — portanto, provavelmente não vale a pena comprar um bilhete de loteria nem mesmo nesse caso.

Suponha, em vez disso, que um "amigo" lhe proponha uma aposta. Ele tem três cartas: uma vermelha dos dois lados, uma preta dos dois lados e uma vermelha de um lado e preta do outro. Ele mistura as três cartas num chapéu, tira uma ao acaso e a coloca deitada sobre a mesa, com apenas um lado à mostra. Suponha que esse lado seja vermelho. Ele então propõe apostar os US$ 4 dele contra os seus US$ 3 que o outro lado da carta também é vermelho.

À primeira vista, você pode achar que a probabilidade de o outro lado também ser vermelho é de 50%; logo, uma boa aposta. No entanto, depois de dominar a probabilidade condicional[6] (Seção 1.5), você saberá que, dado que um lado é

No original: *conditional probability*[6].

vermelho, a probabilidade condicional de o outro lado também ser vermelho é igual a 2/3. Assim, pela teoria dos valores esperados (Capítulo 3), você saberá que não deve aceitar a aposta do seu "amigo".

Por fim, suponha que ele sugira que você lance uma moeda mil vezes. Seu "amigo" diz que, se a moeda der cara pelo menos seiscentas vezes, ele lhe pagará US$ 100; caso contrário, você terá de pagar a ele apenas US$ 1.

À primeira vista, você pode achar que, embora 500 caras seja o mais provável, ainda há uma chance *razoável* de aparecerem 600 caras — pelo menos boa o bastante para justificar aceitar a aposta de US$ 100 contra US$ 1 do seu amigo. No entanto, depois de dominar as leis dos grandes números (Capítulo 4), você saberá que, à medida que o número de lançamentos da moeda cresce, torna-se cada vez mais provável que o número de caras fique muito próximo da metade do número total de lançamentos. De fato, neste caso, há menos de uma chance em dez bilhões de se obterem mais de 600 caras! Portanto, você também não deve aceitar essa aposta.

Como mostram esses exemplos, uma boa compreensão da teoria da probabilidade permitirá que você avalie corretamente as probabilidades em situações do dia a dia, o que, por sua vez, permitirá que você tome decisões mais sensatas. Pode até fazer você economizar dinheiro!

A teoria da probabilidade também desempenha um papel fundamental em muitas aplicações importantes da ciência e da tecnologia. Por exemplo, o projeto de um reator nuclear deve ser tal que o vazamento de radioatividade para o meio ambiente seja um evento extremamente raro. É claro que gostaríamos de dizer que é categoricamente impossível que isso aconteça algum dia, mas reatores são sistemas complicados, formados por muitos subsistemas interligados, e sabemos que cada um deles vai deixar de funcionar direito em algum momento. Além disso, nunca podemos afirmar com certeza que não pode ocorrer um evento natural, como um terremoto, que danifique o reator o suficiente para permitir uma emissão. O melhor que podemos fazer é tentar quantificar a nossa incerteza a respeito das falhas dos componentes do reator ou da ocorrência de eventos naturais que levariam a tal evento. É aí que a probabilidade entra em cena. Usando a probabilidade como ferramenta para lidar com as incertezas, o reator pode ser projetado para garantir que uma emissão inaceitável tenha uma probabilidade extremamente pequena — digamos, uma vez em um bilhão de anos — de ocorrer.

Os exemplos dos jogos de azar e do reator nuclear tratam essencialmente do conceito de *risco* — o risco de perder dinheiro, o risco de ser exposto a um nível nocivo de radioatividade etc. Na verdade, estamos expostos a riscos o tempo todo. Quando andamos de carro, viajamos de avião ou mesmo quando

caminhamos pela rua, estamos expostos a riscos. Sabemos que o risco de nos ferirmos nessas circunstâncias nunca é zero, e ainda assim continuamos a realizar essas atividades. Isso acontece porque percebemos intuitivamente que a probabilidade de ocorrer um acidente é extremamente baixa.

Assim, usamos a probabilidade todos os dias da nossa vida para avaliar riscos. À medida que os problemas que enfrentamos, individual ou coletivamente, ficam mais complicados, precisamos refinar e desenvolver as nossas ideias intuitivas e grosseiras sobre probabilidade para chegar a uma abordagem clara e precisa. É por isso que a teoria da probabilidade se desenvolveu como disciplina. Aliás, o setor de seguros se desenvolveu para nos ajudar a lidar com o risco. A probabilidade é a ferramenta usada para determinar quanto você paga para reduzir o seu risco ou para indenizar você ou a sua família em caso de lesão pessoal.

Resumo da Seção 1.1

- A teoria da probabilidade nos dá uma compreensão precisa da incerteza.
- Essa compreensão pode nos ajudar a fazer previsões, tomar decisões melhores, avaliar riscos e até ganhar dinheiro.

Tópicos para discussão

1.1.1 Você acha que o tempo de amanhã e os preços das ações na semana que vem são "realmente" aleatórios, ou essa é apenas uma maneira conveniente de discuti-los e analisá-los?

1.1.2 Você acha que é possível que as probabilidades dependam de quem as observa, ou de quando são observadas?

1.1.3 Você acha surpreendente que a teoria da probabilidade não tenha sido discutida como assunto matemático até o século XVII? Por quê?

1.1.4 De que maneiras a probabilidade é importante para áreas como a física, a ciência da computação e as finanças? Explique.

1.1.5 Quais são exemplos da sua própria vida em que pensar em probabilidades economizou — ou poderia ter economizado — dinheiro, ou ajudou você a tomar uma decisão melhor? (Liste tantos quantos puder.)

1.1.6 As probabilidades costumam ser retratadas em filmes e programas de televisão populares. Liste tantos exemplos quanto puder. Você acha que as probabilidades foram retratadas ali de maneira "razoável"?

1.2 Modelos de Probabilidade

Uma definição formal de probabilidade começa com um *espaço amostral*[7], geralmente denotado por S. Esse espaço amostral é qualquer conjunto que liste todos os *resultados* (ou *respostas*) possíveis de algum experimento ou situação desconhecida. Por exemplo, talvez

$$S = \{\text{chuva},\ \text{neve},\ \text{limpo}\}$$

ao prever o tempo de amanhã. Ou talvez S seja o conjunto de todos os números reais positivos, ao prever o preço de uma ação na próxima semana. O ponto é que S pode ser qualquer conjunto, até mesmo um conjunto infinito. Costumamos escrever s para um elemento de S, de modo que $s \in S$. Observe que S descreve apenas aquilo que nos interessa; se estamos estudando o tempo, então chuva e neve estão em S, mas os preços das ações de amanhã não estão.

Um modelo de probabilidade também exige uma coleção de *eventos*, que são subconjuntos de S aos quais se podem atribuir probabilidades. No exemplo do tempo acima, os subconjuntos $\{\text{chuva}\}$, $\{\text{neve}\}$, $\{\text{chuva}, \text{neve}\}$, $\{\text{chuva}, \text{limpo}\}$, $\{\text{chuva}, \text{neve}, \text{limpo}\}$ e até o conjunto vazio $\varnothing = \{\,\}$ são todos exemplos de subconjuntos de S que poderiam ser eventos. Observe que aqui a vírgula significa "ou"; assim, $\{\text{chuva}, \text{neve}\}$ é o evento de que vai chover *ou* nevar. Em geral, vamos supor que *todos* os subconjuntos de S são eventos. (Na verdade, em situações complicadas há algumas restrições técnicas sobre quais subconjuntos podem ou não ser eventos, de acordo com a área da matemática chamada teoria da medida[8]. Mas não vamos nos ocupar dessas tecnicalidades aqui.)

Por fim, e mais importante, um modelo de probabilidade exige uma *medida de probabilidade*[9], geralmente denotada por P. Essa medida de probabilidade deve atribuir a cada evento A uma probabilidade $P(A)$. Exigimos as seguintes propriedades:

1. $P(A)$ é sempre um número real não negativo[10], entre 0 e 1, inclusive.
2. $P(\varnothing) = 0$, isto é, se A é o conjunto vazio $\varnothing$, então $P(A) = 0$.
3. $P(S) = 1$, isto é, se A é o espaço amostral S inteiro, então $P(A) = 1$.
4. P é *(enumeravelmente) aditiva*, o que significa que, se $A_1, A_2, \ldots$ é uma sequência finita ou enumerável[11] de eventos disjuntos[12], então

$$P(A_1 \cup A_2 \cup \cdots) = P(A_1) + P(A_2) + \cdots . \tag{1.2.1}$$

No original: *sample space*[7], *measure theory*[8], *probability measure*[9], *nonnegative*[10], *countable*[11], *disjoint*[12].

A primeira dessas propriedades diz que vamos medir todas as probabilidades numa escala de 0 a 1, em que 0 significa impossível e 1 (ou 100%) significa certo. A segunda propriedade diz que a probabilidade de que *nada* aconteça é 0; em outras palavras, é impossível que *nenhum* resultado ocorra. A terceira propriedade diz que a probabilidade de que *algo* aconteça é 1; em outras palavras, é certo que *algum* resultado deve ocorrer.

A quarta propriedade é a mais sutil. Ela diz que podemos calcular probabilidades de eventos complicados somando as probabilidades de eventos menores, desde que esses eventos menores sejam *disjuntos* e, juntos, contenham o evento complicado inteiro. Observe que eventos são *disjuntos* se não têm nenhum resultado em comum. Por exemplo, $\{\text{chuva}\}$ e $\{\text{neve}, \text{limpo}\}$ são disjuntos, ao passo que $\{\text{chuva}\}$ e $\{\text{chuva}, \text{limpo}\}$ não são disjuntos. (Estamos supondo, por simplicidade, que não pode chover *e* nevar amanhã.) Assim, devemos ter $P(\{\text{chuva}\}) + P(\{\text{neve}, \text{limpo}\}) = P(\{\text{chuva}, \text{neve}, \text{limpo}\})$, mas *não* devemos esperar ter $P(\{\text{chuva}\}) + P(\{\text{chuva}, \text{limpo}\}) = P(\{\text{chuva}, \text{chuva}, \text{limpo}\})$ (este último sendo o mesmo que $P(\{\text{chuva}, \text{limpo}\})$).

Agora formalizamos a definição de modelo de probabilidade.

Definição 1.2.1

Um *modelo de probabilidade* consiste em um conjunto não vazio chamado espaço amostral S; uma coleção de eventos que são subconjuntos de S; e uma medida de probabilidade P que atribui uma probabilidade entre 0 e 1 a cada evento, com $P(\varnothing) = 0$ e $P(S) = 1$ e com P aditiva como em (1.2.1).

Exemplo 1.2.1

Considere de novo o exemplo do tempo, com $S = \{\text{chuva}, \text{neve}, \text{limpo}\}$. Suponha que a probabilidade de chuva seja 40%, a probabilidade de neve seja 15% e a probabilidade de um dia limpo seja 45%. Podemos expressar isso como $P(\{\text{chuva}\}) = 0{,}40$, $P(\{\text{neve}\}) = 0{,}15$ e $P(\{\text{limpo}\}) = 0{,}45$.

Neste exemplo, é claro que $P(\varnothing) = 0$, isto é, é impossível que *nada* aconteça amanhã. Além disso, $P(\{\text{chuva}, \text{neve}, \text{limpo}\}) = 1$, porque estamos supondo que exatamente *um* entre chuva, neve ou tempo limpo deve ocorrer amanhã. (Para ser mais realista, poderíamos dizer que estamos prevendo o tempo exatamente às 11h da manhã de amanhã.) Agora, qual é a probabilidade de que chova *ou* neve amanhã? Bem, pela propriedade de aditividade, vemos que

$$P(\{\text{chuva}, \text{neve}\}) = P(\{\text{chuva}\}) + P(\{\text{neve}\}) = 0{,}40 + 0{,}15 = 0{,}55.$$

Concluímos assim que, como esperado, há 55% de chance de chuva *ou* neve amanhã. ■

Exemplo 1.2.2

Suponha que seu candidato tenha 60% de chance de vencer uma eleição em andamento. Então $S = \{\text{vitória}, \text{derrota}\}$, com $P(\text{vitória}) = 0{,}6$ e $P(\text{derrota}) = 0{,}4$. Observe que $P(\text{vitória}) + P(\text{derrota}) = 1$. ■

Exemplo 1.2.3

Suponha que lançamos uma moeda honesta, que pode dar cara (H) ou coroa (T) com igual probabilidade. Então $S = \{H, T\}$, com $P(H) = P(T) = 0{,}5$. É claro que $P(H) + P(T) = 1$. ■

Exemplo 1.2.4

Suponha que lançamos três moedas honestas em sequência e registramos a sequência de caras e coroas resultante. Então

$$S = \{HHH, HHT, HTH, HTT, THH, THT, TTH, TTT\}.$$

Além disso, esses oito resultados são todos igualmente prováveis; assim, $P(HHH) = 1/8$, $P(TTT) = 1/8$ etc. Também, a probabilidade de que a primeira moeda dê cara *e* a segunda dê coroa, sendo a terceira qualquer uma, é igual à soma das probabilidades dos eventos HTH e HTT, isto é, $P(HTH) + P(HTT) = 1/8 + 1/8 = 1/4$. ■

Exemplo 1.2.5

Suponha que lançamos três moedas honestas em sequência, mas nos importamos apenas com o número de caras resultante. Então $S = \{0, 1, 2, 3\}$. No entanto, as probabilidades desses quatro resultados *não* são todas iguais; veremos mais adiante que, na verdade, $P(0) = P(3) = 1/8$, enquanto $P(1) = P(2) = 3/8$. ■

Observamos que também é possível definir modelos de probabilidade em espaços amostrais mais complicados (por exemplo, infinitos não enumeráveis).

Exemplo 1.2.6

Suponha que $S = [0, 1]$ seja o intervalo unitário. Podemos definir uma medida de probabilidade P em S dizendo que

$$P([a, b]) = b - a\,, \qquad \text{sempre que } 0 \le a \le b \le 1. \tag{1.2.2}$$

Em palavras, para qualquer* subintervalo $[a, b]$ de $[0, 1]$, a probabilidade do intervalo é simplesmente o *comprimento* desse intervalo. Este exemplo é chamado de *distribuição uniforme em* $[0, 1]$. A distribuição uniforme é apenas a primeira de muitas distribuições em espaços de estados não enumeráveis. Muitos outros exemplos serão dados no Capítulo 2. ■

*Para a distribuição uniforme em $[0, 1]$, acontece que nem todos os subconjuntos de $[0, 1]$ podem ser considerados *eventos* propriamente ditos neste modelo. No entanto, isso é apenas uma propriedade técnica, e qualquer subconjunto que consigamos escrever explicitamente será sempre um evento. Veja livros de probabilidade mais avançados, por exemplo, a página 3 de *A First Look at Rigorous Probability Theory*, segunda edição, de J. S. Rosenthal (World Scientific Publishing, Singapura, 2006).

1.2.1 Diagramas de Venn e Subconjuntos

Os *diagramas de Venn* oferecem um método gráfico muito útil para representar o espaço amostral S e seus subconjuntos. Por exemplo, na Figura 1.2.1 temos um diagrama de Venn[13] que mostra o subconjunto $A \subset S$ e o *complementar*[14]

$$A^c = \{s : s \notin A\}$$

de A. O retângulo representa o espaço amostral S inteiro. O círculo (e seu interior) representa o subconjunto A; a região fora do círculo, mas dentro de S, representa A^c.

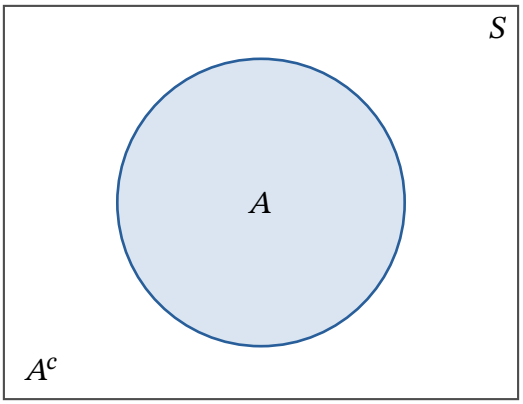


Figura 1.2.1: Diagrama de Venn dos subconjuntos A e A^c do espaço amostral S.

Dois subconjuntos $A \subset S$ e $B \subset S$ são representados por dois círculos, como na Figura 1.2.2 na próxima página. A *interseção*

$$A \cap B = \{s : s \in A \text{ e } s \in B\}$$

dos subconjuntos A e B é o conjunto dos elementos comuns aos dois conjuntos e é representada pela região onde os dois círculos se sobrepõem. O conjunto

$$A \setminus B = A \cap B^c = \{s : s \in A \text{ e } s \notin B\}$$

é chamado de *complementar de B em A* e é representado pela região dentro do círculo A, mas fora do círculo B. Esse é o conjunto dos elementos que estão em A mas não em B. Da mesma forma, temos o complementar de A em B, a saber, $A^c \cap B$. Observe que os conjuntos $A \cap B$, $A \cap B^c$ e $A^c \cap B$ são disjuntos dois a dois[15].

A *união*

$$A \cup B = \{s : s \in A \text{ ou } s \in B\}$$

No original: *Venn diagram*[13], *complement*[14], *mutually disjoint*[15].

dos conjuntos A e B é o conjunto dos elementos que estão em A ou em B. Na Figura 1.2.2, ela é representada pela região coberta pelos dois círculos. Observe que $A \cup B = (A \cap B^c) \cup (A \cap B) \cup (A^c \cap B)$.

Há mais uma região na Figura 1.2.2. É o complementar de $A \cup B$, a saber, o conjunto dos elementos que não estão nem em A nem em B. Assim, temos imediatamente

$$(A \cup B)^c = A^c \cap B^c.$$

Da mesma forma, podemos mostrar que

$$(A \cap B)^c = A^c \cup B^c,$$

isto é, o subconjunto dos elementos que não estão ao mesmo tempo em A e em B é dado pelo conjunto dos elementos que não estão em A ou não estão em B.

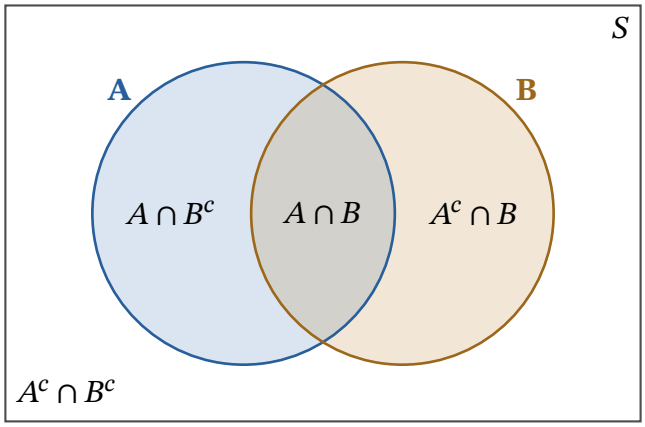


Figura 1.2.2: Diagrama de Venn que representa os subconjuntos A, B, $A \cap B$, $A \cap B^c$, $A^c \cap B$, $A^c \cap B^c$ e $A \cup B$.

Por fim, observamos que, se A e B são subconjuntos disjuntos, faz sentido representá-los como na Figura 1.2.3, isto é, como dois círculos que não se sobrepõem, já que eles não têm elementos em comum.

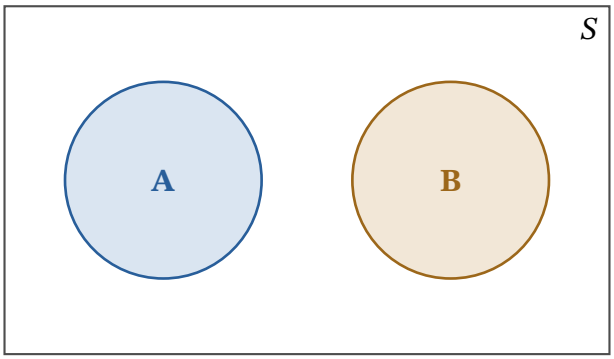


Figura 1.2.3: Diagrama de Venn dos subconjuntos disjuntos A e B.

Resumo da Seção 1.2

- Um modelo de probabilidade consiste em um espaço amostral S e uma medida de probabilidade P que atribui probabilidades a cada evento.
- Diferentes tipos de conjuntos podem surgir como espaços amostrais.
- Os diagramas de Venn oferecem um método conveniente para representar conjuntos e as relações entre eles.

Exercícios

1.2.1 Suponha que $S = \{1, 2, 3\}$, com $P(\{1\}) = 1/2$, $P(\{2\}) = 1/3$ e $P(\{3\}) = 1/6$.

(a) Quanto vale $P(\{1, 2\})$?

(b) Quanto vale $P(\{1, 2, 3\})$?

(c) Liste todos os eventos A tais que $P(A) = 1/2$.

1.2.2 Suponha que $S = \{1, 2, 3, 4, 5, 6, 7, 8\}$, com $P(\{s\}) = 1/8$ para $1 \leq s \leq 8$.

(a) Quanto vale $P(\{1, 2\})$?

(b) Quanto vale $P(\{1, 2, 3\})$?

(c) Quantos eventos A existem tais que $P(A) = 1/2$?

1.2.3 Suponha que $S = \{1, 2, 3\}$, com $P(\{1\}) = 1/2$ e $P(\{1, 2\}) = 2/3$. Quanto deve valer $P(\{2\})$?

1.2.4 Suponha que $S = \{1, 2, 3\}$ e que tentamos definir P por $P(\{1, 2, 3\}) = 1$, $P(\{1, 2\}) = 0{,}7$, $P(\{1, 3\}) = 0{,}5$, $P(\{2, 3\}) = 0{,}7$, $P(\{1\}) = 0{,}2$, $P(\{2\}) = 0{,}5$, $P(\{3\}) = 0{,}3$. P é uma medida de probabilidade válida? Por quê?

1.2.5 Considere a distribuição uniforme[16] em $[0, 1]$. Seja $s \in [0, 1]$ um resultado qualquer. Quanto vale $P(\{s\})$? Esse resultado surpreende você?

1.2.6 Rotule as sub-regiões do diagrama de Venn da Figura 1.2.4 usando os conjuntos A, B e C e seus complementares (assim como fizemos na Figura 1.2.2).

1.2.7 Num diagrama de Venn, represente o conjunto dos elementos que estão nos subconjuntos A ou B, mas *não* em ambos. Escreva também esse

No original: *uniform distribution*[16].

conjunto como um subconjunto envolvendo uniões e interseções de A, B e seus complementares.

1.2.8 Suponha que $S = \{1, 2, 3\}$, $P(\{1, 2\}) = 1/3$ e $P(\{2, 3\}) = 2/3$. Calcule $P(\{1\})$, $P(\{2\})$ e $P(\{3\})$.

1.2.9 Suponha que $S = \{1, 2, 3, 4\}$, $P(\{1\}) = 1/12$, $P(\{1, 2\}) = 1/6$ e $P(\{1, 2, 3\}) = 1/3$. Calcule $P(\{1\})$, $P(\{2\})$, $P(\{3\})$ e $P(\{4\})$.

1.2.10 Suponha que $S = \{1, 2, 3\}$ e $P(\{1\}) = P(\{3\}) = 2\,P(\{2\})$. Calcule $P(\{1\})$, $P(\{2\})$ e $P(\{3\})$.

1.2.11 Suponha que $S = \{1, 2, 3\}$, $P(\{1\}) = P(\{2\}) + 1/6$ e $P(\{3\}) = 2\,P(\{2\})$. Calcule $P(\{1\})$, $P(\{2\})$ e $P(\{3\})$.

1.2.12 Suponha que $S = \{1, 2, 3, 4\}$ e $P(\{1\}) - 1/8 = P(\{2\}) = 3\,P(\{3\}) = 4\,P(\{4\})$. Calcule $P(\{1\})$, $P(\{2\})$, $P(\{3\})$ e $P(\{4\})$.

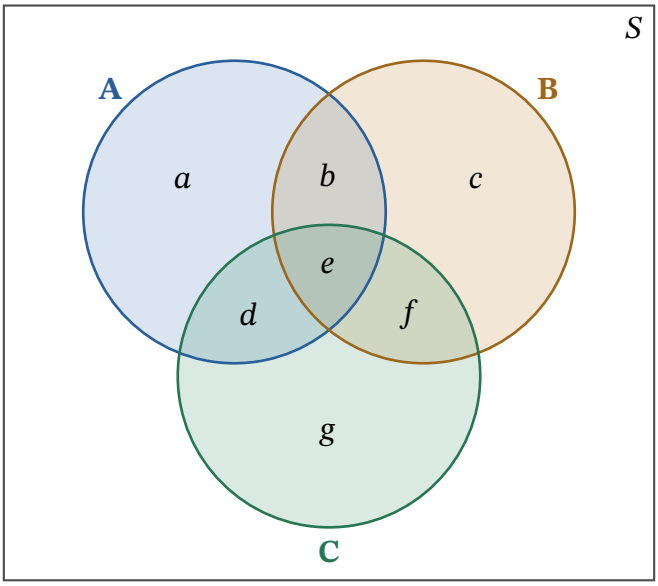


Figura 1.2.4: Diagrama de Venn dos subconjuntos A, B e C.

Problemas

1.2.13 Considere de novo a distribuição uniforme em $[0, 1]$. É verdade que

$$P([0,1]) = \sum_{s \in [0,1]} P(\{s\})\,?$$

Como isso se relaciona com a propriedade de aditividade das medidas de probabilidade?

1.2.14 Suponha que S seja um conjunto finito ou enumerável. É possível que $P(\{s\}) = 0$ para todo $s \in S$? Por quê?

1.2.15 Suponha que S seja um conjunto não enumerável[17]. É possível que $P(\{s\}) = 0$ para todo $s \in S$? Por quê?

Tópicos para discussão

1.2.16 A propriedade de aditividade faz sentido intuitivamente? Por quê?

1.2.17 É importante que tenhamos sempre $P(S) = 1$? Como a teoria da probabilidade mudaria se não fosse assim?

1.3 Propriedades dos Modelos de Probabilidade

A propriedade de aditividade das medidas de probabilidade implica automaticamente certas propriedades básicas. Elas valem para *qualquer* modelo de probabilidade.

Se A é um evento qualquer, escrevemos A^c (lê-se "complementar de A") para o evento em que A *não* ocorre. No exemplo do tempo, se $A = \{\text{chuva}\}$, então $A^c = \{\text{neve}, \text{limpo}\}$. Nos exemplos das moedas, se A é o evento em que a primeira moeda dá cara, então A^c é o evento em que a primeira moeda dá coroa.

Ora, A e A^c são sempre disjuntos. Além disso, sua união é sempre o espaço amostral inteiro: $A \cup A^c = S$. Logo, pela propriedade de aditividade, devemos ter $P(A) + P(A^c) = P(S)$. Mas sempre temos $P(S) = 1$. Assim, $P(A) + P(A^c) = 1$, ou

$$P(A^c) = 1 - P(A). \tag{1.3.1}$$

Em palavras, a probabilidade de um evento qualquer *não* ocorrer é igual a um menos a probabilidade de ele *ocorrer*. Esse é um fato muito útil, que usaremos com frequência.

Suponha agora que $A_1, A_2, \ldots$ sejam eventos que formam uma *partição* do espaço amostral S. Isso significa que $A_1, A_2, \ldots$ são disjuntos e, além disso, que sua união é igual a S, isto é, $A_1 \cup A_2 \cup \cdots = S$. Temos o seguinte teorema básico, que

No original: *uncountable*[17].

permite decompor o cálculo da probabilidade de B na soma das probabilidades dos conjuntos $A_i \cap B$. Muitas vezes, essas são mais fáceis de calcular.

Teorema 1.3.1 (*Lei da probabilidade total, versão não condicionada*)

Sejam $A_1, A_2, \ldots$ eventos que formam uma partição do espaço amostral S. Seja B um evento qualquer. Então

$$P(B) = P(A_1 \cap B) + P(A_2 \cap B) + \cdots.$$

Demonstração. Os eventos $(A_1 \cap B), (A_2 \cap B), \ldots$ são disjuntos, e sua união é B. Logo, o resultado segue imediatamente da propriedade de aditividade (1.2.1). ■

Uma versão um pouco mais útil da lei da probabilidade total[18], bem como aplicações de seu uso, é apresentada na Seção 1.5.

Suponha agora que A e B sejam dois eventos tais que A *contém* B (em símbolos, $A \supseteq B$). Em palavras, todos os resultados de B também estão em A. Intuitivamente, A é um evento "maior" que B, de modo que esperaríamos que sua probabilidade fosse maior. Temos o seguinte resultado.

Teorema 1.3.2

Sejam A e B dois eventos com $A \supseteq B$. Então

$$P(A) = P(B) + P(A \cap B^c). \tag{1.3.2}$$

Demonstração. Podemos escrever $A = B \cup (A \cap B^c)$, em que B e $A \cap B^c$ são disjuntos. Logo, $P(A) = P(B) + P(A \cap B^c)$ por aditividade. ■

Como sempre temos $P(A \cap B^c) \geq 0$, concluímos o seguinte.

Corolário 1.3.1 (*Monotonicidade*)

Sejam A e B dois eventos, com $A \supseteq B$. Então

$$P(A) \geq P(B).$$

Por outro lado, reorganizando (1.3.2), obtemos o seguinte.

No original: *law of total probability*[18].

Corolário 1.3.2

Sejam A e B dois eventos, com $A \supseteq B$. Então

$$P(A \cap B^c) = P(A) - P(B). \tag{1.3.3}$$

Mais geralmente, mesmo que não tenhamos $A \supseteq B$, vale a seguinte propriedade.

Teorema 1.3.3 (*Princípio da inclusão-exclusão, versão para dois eventos*)

Sejam A e B dois eventos. Então

$$P(A \cup B) = P(A) + P(B) - P(A \cap B). \tag{1.3.4}$$

Demonstração. Podemos escrever $A \cup B = (A \cap B^c) \cup (B \cap A^c) \cup (A \cap B)$, em que $A \cap B^c$, $B \cap A^c$ e $A \cap B$ são disjuntos. Por aditividade, temos

$$P(A \cup B) = P(A \cap B^c) + P(B \cap A^c) + P(A \cap B). \tag{1.3.5}$$

Por outro lado, usando o Corolário 1.3.2 (com B substituído por $A \cap B$), temos

$$P(A \cap B^c) = P(A \cap (A \cap B)^c) = P(A) - P(A \cap B) \tag{1.3.6}$$

e, de modo análogo,

$$P(B \cap A^c) = P(B) - P(A \cap B). \tag{1.3.7}$$

Substituindo (1.3.6) e (1.3.7) em (1.3.5), o resultado segue. ■

Uma versão mais geral do princípio da inclusão-exclusão[19] é desenvolvida no Desafio 1.3.10.

Às vezes não precisamos calcular a probabilidade de uma união; basta saber que ela é limitada superiormente pela soma das probabilidades dos eventos individuais. Isso se chama subaditividade[20].

Teorema 1.3.4 (*Subaditividade*)

Seja $A_1, A_2, \ldots$ uma sequência finita ou infinita enumerável de eventos, não necessariamente disjuntos. Então

$$P(A_1 \cup A_2 \cup \cdots) \leq P(A_1) + P(A_2) + \cdots.$$

No original: *inclusion–exclusion*[19], *subadditivity*[20].

Demonstração. Veja a Seção 1.7 para a demonstração deste resultado. ■

Observamos que algumas propriedades da definição de modelo de probabilidade na verdade decorrem de outras. Por exemplo, uma vez que sabemos que a probabilidade P é aditiva e que $P(S) = 1$, segue que *necessariamente* $P(\varnothing) = 0$. De fato, como S e $\varnothing$ são disjuntos, $P(S \cup \varnothing) = P(S) + P(\varnothing)$. Mas, é claro, $P(S \cup \varnothing) = P(S) = 1$, de modo que devemos ter $P(\varnothing) = 0$.

Do mesmo modo, uma vez que sabemos que P é aditiva em sequências infinitas enumeráveis de eventos disjuntos, segue que P também tem de ser aditiva em sequências finitas de eventos disjuntos. De fato, dada uma sequência finita disjunta $A_1, \ldots, A_n$, basta tomar $A_i = \varnothing$ para todo $i > n$ para obter uma sequência infinita enumerável disjunta com a mesma união e a mesma soma de probabilidades.

Resumo da Seção 1.3

- A probabilidade do complementar de um evento é igual a um menos a probabilidade do evento.
- As probabilidades sempre satisfazem as propriedades básicas de probabilidade total, subaditividade e monotonicidade.
- O princípio da inclusão-exclusão permite calcular $P(A \cup B)$ em termos de eventos mais simples.

Exercícios

1.3.1 Suponha que $S = \{1, 2, \ldots, 100\}$. Suponha, além disso, que $P(\{1\}) = 0{,}1$.

(a) Qual é a probabilidade $P(\{2, 3, 4, \ldots, 100\})$?

(b) Qual é o menor valor possível de $P(\{1, 2, 3\})$?

1.3.2 Suponha que Al assista ao telejornal das seis horas em 2/3 das vezes, ao telejornal das onze horas em 1/2 das vezes e a ambos, o das seis e o das onze, em 1/3 das vezes. Num dia escolhido ao acaso, qual é a probabilidade de que Al assista apenas ao telejornal das seis? Num dia escolhido ao acaso, qual é a probabilidade de que Al não assista a nenhum dos dois telejornais?

1.3.3 Suponha que um funcionário chegue atrasado em 10% das vezes, saia mais cedo em 20% das vezes, e chegue atrasado *e* saia mais cedo em 5% das vezes. Qual é a probabilidade de que, num dado dia, esse funcionário chegue atrasado *ou* saia mais cedo (ou ambos)?

1.3.4 Suponha que seu joelho direito doa em 15% do tempo e que seu joelho esquerdo doa em 10% do tempo. Qual é a maior porcentagem possível do tempo em que pelo menos um dos seus joelhos está dolorido? Qual é a menor porcentagem possível do tempo em que pelo menos um dos seus joelhos está dolorido?

1.3.5 Suponha que uma moeda honesta seja lançada cinco vezes seguidas.

(a) Qual é a probabilidade de obter cara em todos os cinco lançamentos?

(b) Qual é a probabilidade de obter pelo menos uma coroa?

1.3.6 Suponha que uma carta seja escolhida uniformemente ao acaso de um baralho comum de 52 cartas.

(a) Qual é a probabilidade de que a carta seja um valete?

(b) Qual é a probabilidade de que a carta seja de paus?

(c) Qual é a probabilidade de que a carta seja um valete e de paus?

(d) Qual é a probabilidade de que a carta seja um valete ou de paus (ou ambos)?

1.3.7 Suponha que seu time tenha 40% de chance de vencer ou empatar o jogo de hoje e 30% de chance de vencer o jogo de hoje. Qual é a probabilidade de que o jogo de hoje termine empatado?

1.3.8 Suponha que 55% dos estudantes sejam do sexo feminino, dos quais 4/5 (44%) têm cabelo comprido, e que 45% sejam do sexo masculino, dos quais 1/3 (15% de todos os estudantes) têm cabelo comprido. Qual é a probabilidade de que um estudante escolhido ao acaso seja do sexo feminino ou tenha cabelo comprido (ou ambos)?

Problemas

1.3.9 Suponha que escolhemos um inteiro positivo ao acaso, de acordo com alguma distribuição de probabilidade desconhecida. Suponha ainda que saibamos que $P(\{1,2,3,4,5\}) = 0{,}3$, que $P(\{4,5,6\}) = 0{,}4$ e que $P(\{1\}) = 0{,}1$. Quais são o maior e o menor valores possíveis de $P(\{2\})$?

Desafios

1.3.10 Generalize o princípio da inclusão-exclusão, da seguinte forma.

(a) Suponha que haja três eventos A, B e C. Prove que

$$P(A \cup B \cup C) = P(A) + P(B) + P(C) - P(A \cap B) - P(A \cap C) \\ - P(B \cap C) + P(A \cap B \cap C).$$

(b) Suponha que haja n eventos $A_1, A_2, \ldots, A_n$. Prove que

$$P(A_1 \cup \cdots \cup A_n) = \sum_{i=1}^{n} P(A_i) - \sum_{\substack{i,j=1 \\ i<j}}^{n} P(A_i \cap A_j) + \sum_{\substack{i,j,k=1 \\ i<j<k}}^{n} P(A_i \cap A_j \cap A_k) \\ - \cdots \pm P(A_1 \cap \cdots \cap A_n).$$

(Sugestão: use indução.)

Tópicos para discussão

1.3.11 Dos vários teoremas apresentados nesta seção, quais você considera os mais importantes? Quais você considera os menos importantes? Explique as razões das suas escolhas.

1.4 Probabilidade Uniforme em Espaços Finitos

Se o espaço amostral S é finito, uma medida de probabilidade possível em S é a medida de probabilidade *uniforme*, que atribui probabilidade $1/|S|$ a cada resultado. Aqui, $|S|$ é o número de elementos do espaço amostral S. Pela aditividade, segue então que, para qualquer evento A, temos

$$P(A) = \frac{|A|}{|S|}. \tag{1.4.1}$$

Exemplo 1.4.1

Suponha que lançamos um dado de seis faces. Os resultados possíveis são $S = \{1, 2, 3, 4, 5, 6\}$, de modo que $|S| = 6$. Se o dado é honesto, acreditamos que todos os resultados são igualmente prováveis. Assim, fazemos $P(\{i\}) = 1/6$ para cada $i \in S$, de modo que $P(\{3\}) = 1/6$, $P(\{4\}) = 1/6$ etc. Segue de (1.4.1) que, por exemplo, $P(\{3, 4\}) = 2/6 = 1/3$, $P(\{1, 5, 6\}) = 3/6 = 1/2$ etc. Este é um bom modelo para um único lançamento de um dado honesto de seis faces. ■

Exemplo 1.4.2

Como segundo exemplo, suponha que lançamos uma moeda honesta uma vez. Então $S = \{\text{cara}, \text{coroa}\}$, de modo que $|S| = 2$, e $P(\{\text{cara}\}) = P(\{\text{coroa}\}) = 1/2$. ■

Exemplo 1.4.3

Suponha agora que lançamos *três moedas honestas diferentes*. O resultado pode ser escrito como uma sequência de três letras, em que cada letra é H (para cara) ou T (para coroa). Assim,

$$S = \{HHH, HHT, HTH, HTT, THH, THT, TTH, TTT\}.$$

Aqui $|S| = 8$, e cada um dos eventos é igualmente provável. Logo, $P(\{HHH\}) = 1/8$, $P(\{HHH, TTT\}) = 2/8 = 1/4$ etc. Note também que, pela aditividade, temos, por exemplo, que $P(\text{exatamente duas caras}) = P(\{HHT, HTH, THH\}) = 1/8 + 1/8 + 1/8 = 3/8$ etc. ■

Exemplo 1.4.4

Como último exemplo, suponha que lançamos um dado honesto de seis faces *e* uma moeda honesta. Então podemos escrever

$$S = \{1H, 2H, 3H, 4H, 5H, 6H, 1T, 2T, 3T, 4T, 5T, 6T\}.$$

Logo, $|S| = 12$ neste caso, e $P(s) = 1/12$ para cada $s \in S$. ■

1.4.1 Princípios de Contagem

Por causa de (1.4.1), problemas que envolvem distribuições uniformes em espaços amostrais finitos muitas vezes se resumem a conseguir calcular os tamanhos $|A|$ e $|S|$ dos conjuntos envolvidos. Isto é, precisamos ser bons em *contar* o número de elementos de diversos conjuntos. A ciência da contagem se chama *análise combinatória*[21], e alguns de seus aspectos são muito sofisticados. No restante desta seção, consideramos algumas regras de contagem simples e sua aplicação na teoria da probabilidade quando a distribuição uniforme é apropriada.

No original: *combinatorics*[21].

Exemplo 1.4.5 — Contando sequências: o princípio multiplicativo

Suponha que lançamos três moedas honestas e dois dados honestos de seis faces. Qual é a probabilidade de que as três moedas deem cara e os dois dados deem 6? Cada moeda tem dois resultados possíveis (cara e coroa), e cada dado tem seis resultados possíveis $\{1, 2, 3, 4, 5, 6\}$. O número total de resultados possíveis das três moedas e dos dois dados é, então, obtido *multiplicando* três 2 e dois 6, isto é, $2 \times 2 \times 2 \times 6 \times 6 = 288$. Isso às vezes é chamado de *princípio multiplicativo*. Há, portanto, 288 resultados possíveis para o nosso experimento (por exemplo, $HHH66$, $HTH24$, $TTH15$ etc.). Desses resultados, apenas um (a saber, $HHH66$) conta como sucesso. Assim, a probabilidade de que as três moedas deem cara e os dois dados deem 6 é igual a 1/288.

Note que podemos obter esse resultado de outra maneira. A chance de que qualquer uma das moedas dê cara é 1/2, e a chance de que qualquer um dos dados dê 6 é 1/6. Além disso, esses eventos são todos *independentes* (veja a próxima seção). Sob independência, a probabilidade de que *todos* ocorram é dada pelo produto de suas probabilidades individuais, a saber,

$$(1/2)(1/2)(1/2)(1/6)(1/6) = 1/288.$$

De modo mais geral, suponha que temos k conjuntos finitos $S_1, \ldots, S_k$ e queremos contar o número de sequências de comprimento k em que o i-ésimo elemento vem de S_i, isto é, contar o número de elementos de

$$S = \{(s_1, \ldots, s_k) : s_i \in S_i\} = S_1 \times \cdots \times S_k.$$

O princípio multiplicativo diz que o número dessas sequências é obtido multiplicando os números de elementos de cada conjunto S_i, isto é,

$$|S| = |S_1| \cdots |S_k|.$$

■

Exemplo 1.4.6

Suponha que lançamos dois dados honestos de seis faces. Qual é a probabilidade de que a soma dos números obtidos seja igual a 10? Pelo princípio multiplicativo acima, o número total de resultados possíveis é igual a $6 \times 6 = 36$. Desses resultados, há três cuja soma é 10, a saber, $(4, 6)$, $(5, 5)$ e $(6, 4)$. Assim, a probabilidade de que a soma seja 10 é igual a 3/36, ou 1/12. ■

Exemplo 1.4.7 — Contando permutações

Suponha que quatro amigos vão a um restaurante e cada um deixa o casaco na chapelaria. No fim da refeição, os quatro casacos são devolvidos *aleatoriamente* às quatro pessoas. Qual é a probabilidade de que cada uma das quatro pessoas receba o próprio casaco? Aqui, o número total de maneiras diferentes de devolver os casacos é igual a $4 \times 3 \times 2 \times 1$, ou $4!$ (isto é, quatro fatorial). Isso porque o primeiro casaco pode ser devolvido a qualquer um dos quatro amigos, o segundo casaco a qualquer um dos três amigos restantes, e assim por diante. Apenas uma dessas atribuições é a correta. Logo, a probabilidade de que cada uma das quatro pessoas receba o próprio casaco é igual a $1/4!$, ou $1/24$.

Aqui estamos contando permutações, isto é, sequências de elementos de um conjunto em que nenhum elemento aparece mais de uma vez. Podemos usar o princípio multiplicativo para contar permutações de modo mais geral. Por exemplo, suponha que $|S| = n$ e queremos contar o número de permutações de comprimento $k \leq n$ obtidas de S, isto é, queremos contar o número de elementos do conjunto

$$\{(s_1, \ldots, s_k) : s_i \in S, s_i \neq s_j \text{ quando } i \neq j\}.$$

Então temos n escolhas para o primeiro elemento s_1, $n-1$ escolhas para o segundo elemento e, por fim, $n-(k-1) = n-k+1$ escolhas para o último elemento. Portanto, há $n(n-1)\cdots(n-k+1)$ permutações de comprimento k de um conjunto de n elementos. Isso também pode ser escrito como $n!/(n-k)!$. Note que, quando $k = n$, há

$$n! = n(n-1)\cdots 2 \cdot 1$$

permutações de comprimento n. ■

Exemplo 1.4.8 — Contando subconjuntos

Suponha que 10 moedas honestas são lançadas. Qual é a probabilidade de que exatamente sete delas deem cara? Aqui, cada sequência possível de 10 caras ou coroas (por exemplo, $HHHTTTHTTT$, $THTTTTHHHT$ etc.) é igualmente provável e, pelo princípio multiplicativo, o número total de resultados possíveis é igual a 2 multiplicado por si mesmo 10 vezes, ou $2^{10} = 1024$. Logo, a probabilidade de ocorrer uma sequência específica qualquer é $1/1024$. Mas, dessas sequências, quantas têm exatamente sete caras?

Para responder a isso, note que podemos especificar uma dessas sequências dando as posições das sete caras, o que envolve escolher um subconjunto de tamanho 7 do conjunto de índices possíveis $\{1, \dots, 10\}$. Há $10!/3! = 10 \cdot 9 \cdots 5 \cdot 4$ permutações diferentes de comprimento 7 de $\{1, \dots, 10\}$, e cada uma dessas permutações especifica uma sequência de sete caras e três coroas. Mas podemos permutar os índices que especificam onde ficam as caras de 7! maneiras diferentes sem alterar a sequência de caras e coroas. Assim, o número total de resultados com exatamente sete caras é igual a $10!/3!7! = 120$. A probabilidade de que exatamente sete das 10 moedas deem cara é, portanto, igual a $120/1024$, ou pouco menos de 12%.

Em geral, se temos um conjunto S de n elementos, então o número de subconjuntos diferentes de tamanho k que podemos construir escolhendo elementos de S é

$$\binom{n}{k} = \frac{n!}{k!\,(n-k)!},$$

que é chamado de *coeficiente binomial*. Isso decorre do mesmo argumento, a saber, há $n!/(n-k)!$ permutações de comprimento k obtidas do conjunto; cada uma dessas permutações, junto com as $k!$ permutações obtidas permutando-a, especifica um único subconjunto de S. ■

Segue, por exemplo, que a probabilidade de obter exatamente k caras ao lançar um total de n moedas honestas é dada por

$$\binom{n}{k} 2^{-n} = \frac{n!}{k!\,(n-k)!}\, 2^{-n}.$$

Isso porque há $\binom{n}{k}$ padrões diferentes de k caras e $n-k$ coroas, e um total de 2^n sequências diferentes de n caras e coroas.

De modo mais geral, se cada moeda tem probabilidade θ de dar cara (e probabilidade $1-\theta$ de dar coroa), em que $0 \leq \theta \leq 1$, então a probabilidade de

obter exatamente k caras ao lançar um total de n dessas moedas é dada por

$$\binom{n}{k}\theta^k(1-\theta)^{n-k} = \frac{n!}{k!\,(n-k)!}\,\theta^k(1-\theta)^{n-k}, \tag{1.4.2}$$

porque cada um dos $\binom{n}{k}$ padrões diferentes de k caras e $n-k$ coroas tem probabilidade $\theta^k(1-\theta)^{n-k}$ de ocorrer (isso decorre da discussão sobre independência na Seção 1.5.2). Se $\theta = 1/2$, isso se reduz à fórmula anterior.

Exemplo 1.4.9 — Contando sequências de subconjuntos e partições

Suponha que temos um conjunto S de n elementos e queremos contar o número de elementos de

$$\{(S_1, S_2, \dots, S_l) : S_i \subset S, |S_i| = k_i, S_i \cap S_j = \varnothing \text{ quando } i \neq j\},$$

ou seja, queremos contar o número de sequências de l subconjuntos de um conjunto em que dois subconjuntos quaisquer não têm elementos em comum e o i-ésimo subconjunto tem k_i elementos. Pelo princípio multiplicativo, isso é igual a

$$\begin{aligned}\binom{n}{k_1}\binom{n-k_1}{k_2}\cdots\binom{n-k_1-\cdots-k_{l-1}}{k_l} \\ = \frac{n!}{k_1!\cdots k_{l-1}!\,k_l!\,(n-k_1-\cdots-k_l)!},\end{aligned} \tag{1.4.3}$$

porque podemos escolher os elementos de S_1 de $\binom{n}{k_1}$ maneiras, escolher os elementos de S_2 de $\binom{n-k_1}{k_2}$ maneiras etc.

Quando, além de os conjuntos serem disjuntos dois a dois, temos $S = S_1 \cup S_2 \cup \cdots \cup S_l$, estamos contando o número de *partições ordenadas* de um conjunto de n elementos com k_1 elementos no primeiro conjunto, k_2 elementos no segundo conjunto etc. Nesse caso, (1.4.3) é igual a

$$\binom{n}{k_1\ k_2\ \dots\ k_l} = \frac{n!}{k_1!\,k_2!\cdots k_l!}, \tag{1.4.4}$$

que é chamado de *coeficiente multinomial*. ■

Por exemplo, quantas mãos de bridge diferentes existem? Com isso, queremos dizer de quantas maneiras diferentes um baralho de 52 cartas pode ser dividido em quatro mãos de 13 cartas cada, com as mãos identificadas como Norte, Leste, Sul e Oeste, respectivamente. Por (1.4.4), isso é igual a

$$\binom{52}{13\ 13\ 13\ 13} = \frac{52!}{13!\,13!\,13!\,13!} \approx 5{,}364474 \times 10^{28},$$

que é um número muito grande.

Resumo da Seção 1.4

- A distribuição de probabilidade uniforme em um espaço amostral finito S satisfaz $P(A) = |A|/|S|$.
- Calcular $P(A)$ nesse caso exige calcular os *tamanhos* dos conjuntos A e S. Isso pode exigir princípios de contagem, como o princípio multiplicativo, fatoriais e coeficientes binomiais/multinomiais.

Exercícios

1.4.1 Suponha que lançamos oito dados honestos de seis faces.

(a) Qual é a probabilidade de que os oito dados mostrem 6?

(b) Qual é a probabilidade de que os oito dados mostrem o mesmo número?

(c) Qual é a probabilidade de que a soma dos oito dados seja igual a 9?

1.4.2 Suponha que lançamos 10 dados honestos de seis faces. Qual é a probabilidade de que apareçam exatamente dois 2?

1.4.3 Suponha que lançamos 100 moedas honestas independentes. Qual é a probabilidade de que pelo menos três delas deem cara? (Dica: talvez seja útil usar (1.3.1).)

1.4.4 Suponha que recebemos cinco cartas de um baralho comum de 52 cartas. Qual é a probabilidade de que

(a) recebamos os quatro ases, mais o rei de espadas?

(b) as cinco cartas sejam de espadas?

(c) não recebamos nenhum par (isto é, as cinco cartas tenham valores diferentes)?

(d) recebamos um full house (isto é, três cartas de um mesmo valor, mais um par de outro valor)?

1.4.5 Suponha que distribuímos quatro mãos de bridge de 13 cartas a partir de um baralho comum de 52 cartas. Qual é a probabilidade de que

(a) as 13 cartas de espadas fiquem todas na mesma mão?

(b) os quatro ases fiquem todos na mesma mão?

1.4.6 Suponha que tiramos duas cartas ao acaso de um baralho comum de 52 cartas. Qual é a probabilidade de que a soma dos valores das duas cartas (em que valetes, damas e reis contam como 10, e ases contam como 1) seja pelo menos 4?

1.4.7 Suponha que continuamos distribuindo cartas de um baralho comum de 52 cartas até aparecer o primeiro valete. Qual é a probabilidade de que pelo menos 10 cartas passem *antes* do primeiro valete?

1.4.8 Em um baralho comum de 52 cartas bem embaralhado, qual é a probabilidade de que o ás de espadas e o ás de paus fiquem um ao lado do outro?

1.4.9 Suponha que lançamos repetidamente dois dados honestos de seis faces, considerando a cada vez a *soma* dos dois valores obtidos. Qual é a probabilidade de que a primeira vez em que a soma é exatamente 7 seja no terceiro lançamento?

1.4.10 Suponha que lançamos três dados honestos de seis faces. Qual é a probabilidade de que dois deles mostrem o mesmo valor, mas o terceiro não?

1.4.11 Considere duas urnas, identificadas como urna nº 1 e urna nº 2. Suponha que a urna nº 1 tem 5 bolas vermelhas e 7 azuis. Suponha que a urna nº 2 tem 6 bolas vermelhas e 12 azuis. Suponha que escolhemos três bolas uniformemente ao acaso de cada uma das duas urnas. Qual é a probabilidade de que as seis bolas escolhidas sejam todas da mesma cor?

1.4.12 Suponha que lançamos um dado honesto de seis faces e três moedas honestas. Qual é a probabilidade de que o número total de caras seja igual ao número mostrado pelo dado?

1.4.13 Suponha que lançamos duas moedas de 1 centavo, três de 5 centavos e quatro de 10 centavos. Qual é a probabilidade de que o valor total de todas as moedas que deram cara seja igual a US$ 0,31?

Problemas

1.4.14 Mostre que uma medida de probabilidade definida por (1.4.1) é sempre aditiva no sentido de (1.2.1).

1.4.15 Suponha que lançamos oito dados honestos de seis faces. Qual é a probabilidade de que a soma dos oito dados seja igual a 9? Qual é

a probabilidade de que a soma dos oito dados seja igual a 10? Qual é a probabilidade de que a soma dos oito dados seja igual a 11?

1.4.16 Suponha que lançamos um dado honesto de seis faces e seis moedas. Qual é a probabilidade de que o número de caras seja igual ao número mostrado pelo dado?

1.4.17 Suponha que lançamos 10 dados honestos de seis faces. Qual é a probabilidade de que apareçam exatamente dois 2 *e* exatamente três 3?

1.4.18 Suponha que distribuímos quatro mãos de bridge de 13 cartas a partir de um baralho comum de 52 cartas. Qual é a probabilidade de que as mãos Norte e Leste tenham exatamente o mesmo número de cartas de espadas?

1.4.19 Suponha que tiramos uma carta ao acaso de um baralho comum de 52 cartas e também lançamos 10 moedas honestas. Qual é a probabilidade de que o número de caras seja igual ao valor da carta (em que valetes, damas e reis contam como 10, e ases contam como 1)?

Desafios

1.4.20 Suponha que lançamos dois dados honestos de seis faces e 12 moedas. Qual é a probabilidade de que o número de caras seja igual à soma dos números mostrados pelos dois dados?

1.4.21 *(O problema do aniversário)* Suponha que há C pessoas e que o aniversário (apenas mês e dia) de cada uma tem a mesma probabilidade de cair em qualquer um dos 365 dias de um ano normal (isto é, não bissexto).

(a) Suponha que $C = 2$. Qual é a probabilidade de que as duas pessoas façam aniversário exatamente no mesmo dia?

(b) Suponha que $C \geq 2$. Qual é a probabilidade de que todas as C pessoas façam aniversário exatamente no mesmo dia?

(c) Suponha que $C \geq 2$. Qual é a probabilidade de que *algum par* entre as C pessoas faça aniversário exatamente no mesmo dia? (Dica: talvez seja útil usar (1.3.1).)

(d) Qual é o menor valor de C para o qual a probabilidade do item (c) é maior que 0,5? Esse resultado surpreende você?

1.5 Probabilidade Condicional e Independência

Considere novamente o exemplo das três moedas, como no Exemplo 1.4.3, em que lançamos três moedas honestas diferentes, e

$$S = \{HHH, HHT, HTH, HTT, THH, THT, TTH, TTT\},$$

com $P(s) = 1/8$ para cada $s \in S$. Qual é a probabilidade de a primeira moeda dar cara? Bem, é claro que deve ser $1/2$. Podemos ver isso de modo mais formal dizendo que $P(\text{primeira moeda cara}) = P(\{HHH, HHT, HTH, HTT\}) = 4/8 = 1/2$, como deveria ser.

Mas suponha agora que um informante nos diga que exatamente duas das três moedas deram cara. *Agora*, qual é a probabilidade de a primeira moeda ter dado cara?

A questão é que esse informante mudou a informação de que dispomos, isto é, mudou o nosso nível de ignorância. Segue-se que as probabilidades correspondentes também devem mudar. De fato, se sabemos que exatamente duas das moedas deram cara, então sabemos que o resultado foi um de HHT, HTH e THH. Como esses três resultados devem (neste caso) continuar igualmente prováveis, e como só os dois primeiros correspondem à primeira moeda dar cara, concluímos o seguinte: se sabemos que exatamente duas das três moedas deram cara, *então* a probabilidade de a primeira moeda ter dado cara é $2/3$.

Mais precisamente, calculamos uma *probabilidade condicional*. Isto é, determinamos que, *condicionada* ao conhecimento de que exatamente duas moedas deram cara, a *probabilidade condicional* de a primeira moeda ter dado cara é $2/3$. Escrevemos isso em notação matemática como

$$P(\text{primeira moeda cara} \mid \text{duas moedas cara}) = 2/3.$$

Aqui a barra vertical $\mid$ significa "condicionado a" ou "dado que".

1.5.1 Probabilidade Condicional

Em geral, dados dois eventos A e B com $P(B) > 0$, a *probabilidade condicional* de A dado B, escrita $P(A \mid B)$, representa a fração das vezes em que A ocorre uma vez que *sabemos* que B ocorre. Ela é calculada como a razão entre a probabilidade de A e B *ambos* ocorrerem e a probabilidade de B ocorrer, da seguinte forma.

Definição 1.5.1

Dados dois eventos A e B, com $P(B) > 0$, a probabilidade condicional de A dado B é igual a

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}. \tag{1.5.1}$$

A motivação para (1.5.1) é a seguinte. O evento B ocorrerá numa fração $P(B)$ das vezes. Além disso, A e B *ambos* ocorrerão numa fração $P(A \cap B)$ das vezes. A razão $P(A \cap B)/P(B)$ dá, portanto, a *proporção* das vezes em que B ocorre nas quais A *também* ocorre. Isto é, se *ignorarmos* todas as vezes em que B não ocorre e considerarmos só as vezes em que B ocorre, então a razão $P(A \cap B)/P(B)$ é igual à fração das vezes em que A também ocorrerá. É exatamente isso que se quer dizer com a probabilidade condicional de A dado B.

No exemplo que acabamos de calcular, A é o evento em que a primeira moeda dá cara, e B é o evento em que exatamente duas moedas dão cara. Assim, em termos matemáticos, $A = \{HHH, HHT, HTH, HTT\}$ e $B = \{HHT, HTH, THH\}$. Segue-se que $A \cap B = \{HHT, HTH\}$. Portanto,

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)} = \frac{P(\{HHT, HTH\})}{P(\{HHT, HTH, THH\})} = \frac{2/8}{3/8} = 2/3,$$

como já havíamos calculado.

Por outro lado, calculamos de modo análogo que

$$P(\text{primeira moeda coroa} \mid \text{duas moedas cara}) = 1/3.$$

Vemos, assim, que condicionar a algum evento (como "duas moedas cara") pode fazer as probabilidades aumentarem (como no caso do evento "primeira moeda cara") ou diminuírem (como no caso do evento "primeira moeda coroa").

A definição de $P(B \mid A)$ leva imediatamente à *fórmula da multiplicação*[22]

$$P(A \cap B) = P(A)P(B \mid A). \tag{1.5.2}$$

Ela nos permite calcular a probabilidade conjunta de A e B quando são dadas a probabilidade de A e a probabilidade condicional de B dado A.

A probabilidade condicional nos permite expressar o Teorema 1.3.1, a lei da probabilidade total, de um modo diferente e às vezes mais útil.

No original: *multiplication formula*[22].

Teorema 1.5.1 (*Lei da probabilidade total, versão condicional*)

Sejam $A_1, A_2, \ldots$ eventos que formam uma partição do espaço amostral S, cada um com probabilidade positiva. Seja B um evento qualquer. Então $P(B) = P(A_1)P(B \mid A_1) + P(A_2)P(B \mid A_2) + \cdots$.

Demonstração. A fórmula da multiplicação (1.5.2) dá $P(A_i \cap B) = P(A_i)P(B \mid A_i)$. O resultado segue então imediatamente do Teorema 1.3.1. ■

Exemplo 1.5.1

Suponha que uma turma tenha 60% de meninas e 40% de meninos. Suponha que 30% das meninas tenham cabelo comprido e que 20% dos meninos tenham cabelo comprido. Um aluno é escolhido uniformemente ao acaso na turma. Qual é a probabilidade de o aluno escolhido ter cabelo comprido?

Para responder, seja A_1 o conjunto das meninas e A_2 o conjunto dos meninos. Então $\{A_1, A_2\}$ é uma partição da turma. Seja ainda B o conjunto de todos os alunos de cabelo comprido.

Estamos interessados em $P(B)$. Calculamos esse valor pelo Teorema 1.5.1 como

$$P(B) = P(A_1)P(B \mid A_1) + P(A_2)P(B \mid A_2) = (0{,}6)(0{,}3) + (0{,}4)(0{,}2) = 0{,}26,$$

de modo que há 26% de chance de o aluno escolhido ao acaso ter cabelo comprido. ■

Suponha agora que A e B sejam dois eventos, cada um com probabilidade positiva. Em algumas aplicações, são dados os valores de $P(A)$, $P(B)$ e $P(B \mid A)$ e queremos calcular $P(A \mid B)$. O resultado a seguir estabelece uma relação simples entre essas quantidades.

Teorema 1.5.2 (*Teorema de Bayes*)

Sejam A e B dois eventos, cada um com probabilidade positiva. Então

$$P(A \mid B) = \frac{P(A)}{P(B)} P(B \mid A).$$

Demonstração. Calculamos que

$$\frac{P(A)}{P(B)} P(B \mid A) = \frac{P(A)}{P(B)} \frac{P(A \cap B)}{P(A)} = \frac{P(A \cap B)}{P(B)} = P(A \mid B).$$

Isso dá o resultado. ■

Aplicações típicas da fórmula da multiplicação, da lei da probabilidade total e do teorema de Bayes ocorrem em *sistemas em dois estágios*. A resposta de um sistema desse tipo pode ser pensada como algo que acontece em duas etapas, ou estágios. Em geral, são dadas as probabilidades do primeiro estágio e as probabilidades condicionais do segundo estágio. A fórmula da multiplicação é então usada para calcular probabilidades conjuntas do que acontece nos dois estágios; a lei da probabilidade total é usada para calcular as probabilidades do que acontece no segundo estágio; e o teorema de Bayes é usado para calcular as probabilidades condicionais do primeiro estágio, dado o que ocorreu no segundo estágio. Ilustramos isso com um exemplo.

Exemplo 1.5.2

Suponha que a urna nº 1 tenha 3 bolas vermelhas e 2 azuis, e que a urna nº 2 tenha 4 bolas vermelhas e 7 azuis. Suponha que uma das duas urnas seja escolhida, cada uma com probabilidade 1/2, e que então uma das bolas dessa urna seja retirada uniformemente ao acaso.

Qual é a probabilidade de a urna nº 2 ser escolhida no primeiro estágio (evento A) e de uma bola azul ser retirada no segundo estágio (evento B)? A fórmula da multiplicação dá o modo correto de calcular essa probabilidade:

$$P(A \cap B) = P(A)P(B \mid A) = \frac{1}{2}\frac{7}{11} = \frac{7}{22}.$$

Suponha, em vez disso, que queremos calcular a probabilidade de obter uma bola azul. Usando a lei da probabilidade total (Teorema 1.5.1), temos

$$P(B) = P(A)P(B \mid A) + P(A^c)P(B \mid A^c) = \frac{1}{2}\frac{7}{11} + \frac{1}{2}\frac{2}{5}.$$

Suponha agora que recebemos a informação de que a bola retirada é azul. Então, pelo teorema de Bayes, a probabilidade condicional de termos escolhido a urna nº 2 é dada por

$$\begin{aligned} P(A \mid B) &= \frac{P(A)}{P(B)}P(B \mid A) = \left(\frac{1/2}{(1/2)(2/5) + (1/2)(7/11)}\right)\frac{7}{11} \\ &= 35/57 = 0{,}614. \end{aligned}$$

Observe que, sem a informação de que saiu uma bola azul no segundo estágio, temos

$$P(\text{urna nº 2 escolhida}) = 1/2.$$

Vemos que saber que a bola era azul *aumenta* consideravelmente a probabilidade de a urna nº 2 ter sido escolhida. ■

Podemos representar um sistema em dois estágios por meio de uma árvore, como na Figura 1.5.1. Pode ser útil desenhar uma figura assim ao fazer cálculos de probabilidade para esses sistemas. Há dois resultados possíveis no primeiro estágio e três resultados possíveis no segundo estágio.

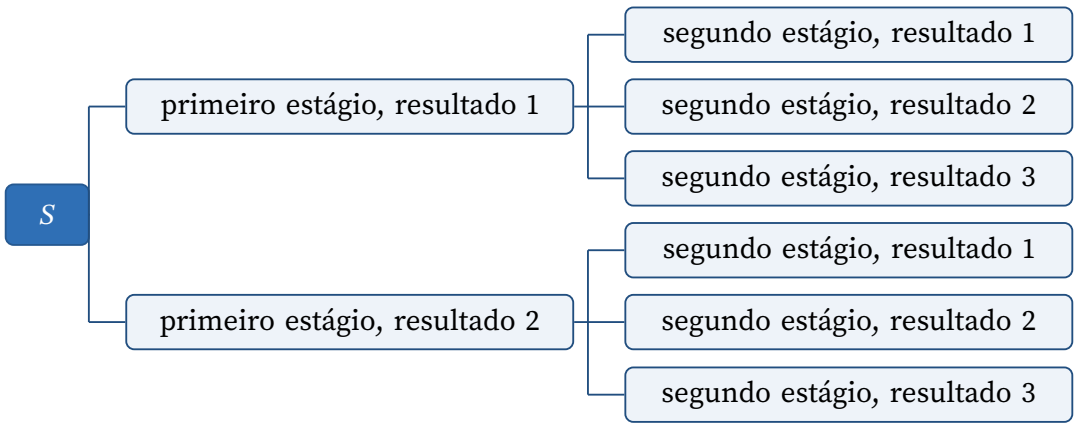


Figura 1.5.1: Uma árvore representando um sistema em dois estágios com dois resultados possíveis no primeiro estágio e três resultados possíveis no segundo estágio.

1.5.2 Independência de Eventos

Considere agora o Exemplo 1.4.4, em que lançamos um dado honesto e uma moeda honesta, de modo que

$$S = \{1H, 2H, 3H, 4H, 5H, 6H, 1T, 2T, 3T, 4T, 5T, 6T\}$$

e $P(\{s\}) = 1/12$ para cada $s \in S$. Aqui, a probabilidade de o dado dar 5 é igual a $P(\{5H, 5T\}) = 2/12 = 1/6$, como deveria ser.

Mas agora, qual é a probabilidade de o dado dar 5, *condicionada* ao conhecimento de que a moeda deu coroa? Bem, podemos calcular essa probabilidade como

$$\begin{aligned} P(\text{dado} = 5 \mid \text{moeda} = \text{coroa}) &= \frac{P(\text{dado} = 5 \text{ e moeda} = \text{coroa})}{P(\text{moeda} = \text{coroa})} \\ &= \frac{P(\{5T\})}{P(\{1T, 2T, 3T, 4T, 5T, 6T\})} \\ &= \frac{1/12}{6/12} = 1/6. \end{aligned}$$

Isso é o mesmo que a probabilidade incondicional[23], $P(\text{dado} = 5)$. Parece que saber que a moeda deu coroa não teve efeito algum sobre a probabilidade de o dado dar 5. Essa propriedade se chama *independência*. Dizemos que a moeda e o dado são *independentes* neste exemplo, para indicar que a ocorrência de um não tem nenhuma influência sobre a probabilidade de o outro ocorrer.

Mais formalmente, fazemos a definição a seguir.

No original: *unconditional probability*[23].

Definição 1.5.2

Dois eventos A e B são *independentes* se

$$P(A \cap B) = P(A)\,P(B).$$

Agora, como $P(A \mid B) = P(A \cap B)/P(B)$, vemos que A e B são independentes se e somente se $P(A \mid B) = P(A)$ ou $P(B \mid A) = P(B)$, desde que $P(A) > 0$ e $P(B) > 0$. A Definição 1.5.2 tem a vantagem de continuar válida mesmo que $P(B) = 0$ ou $P(A) = 0$, respectivamente. Intuitivamente, os eventos A e B são independentes se nenhum dos dois tem qualquer impacto sobre a probabilidade do outro.

Exemplo 1.5.3

No Exemplo 1.4.4, se A é o evento em que o dado deu 5 e B é o evento em que a moeda deu coroa, então $P(A) = P(\{5H, 5T\}) = 2/12 = 1/6$, e

$$P(B) = P(\{1T, 2T, 3T, 4T, 5T, 6T\}) = 6/12 = 1/2.$$

Além disso, $P(A \cap B) = P(\{5T\}) = 1/12$, que de fato é igual a $(1/6)(1/2)$. Logo, A e B são independentes neste caso. ■

Para vários eventos, a definição de independência é um pouco mais elaborada.

Definição 1.5.3

Uma coleção de eventos $A_1, A_2, A_3, \ldots$ é *independente* se

$$P(A_{i_1} \cap \cdots \cap A_{i_j}) = P(A_{i_1}) \cdots P(A_{i_j})$$

para *toda* subcoleção finita $A_{i_1}, \ldots, A_{i_j}$ de eventos distintos.

Exemplo 1.5.4

De acordo com a Definição 1.5.3, três eventos A, B e C são independentes se *todas* as equações a seguir valem:

$$\begin{aligned} P(A \cap B) &= P(A)P(B), \\ P(A \cap C) &= P(A)P(C), \\ P(B \cap C) &= P(B)P(C), \end{aligned} \tag{1.5.3}$$

e

$$P(A \cap B \cap C) = P(A)P(B)P(C). \tag{1.5.4}$$

Não basta verificar só *algumas* dessas condições para comprovar a independência. Por exemplo, suponha que $S = \{1, 2, 3, 4\}$, com $P(\{1\}) = P(\{2\}) = P(\{3\}) = P(\{4\}) = 1/4$. Sejam $A = \{1, 2\}$, $B = \{1, 3\}$ e $C = \{1, 4\}$. Então cada uma das três equações (1.5.3) vale, mas a equação (1.5.4) não vale. Aqui, os eventos A, B e C são chamados *independentes dois a dois*, mas não são independentes. ■

Resumo da Seção 1.5

- A probabilidade condicional mede a probabilidade de A ocorrer dado que B ocorre; ela é dada por $P(A \mid B) = P(A \cap B) / P(B)$.
- A probabilidade condicional satisfaz sua própria lei da probabilidade total.
- Eventos são independentes se não têm efeito sobre as probabilidades uns dos outros. Formalmente, isso significa que $P(A \cap B) = P(A)P(B)$.
- Se A e B são independentes, e $P(A) > 0$ e $P(B) > 0$, então $P(A \mid B) = P(A)$ e $P(B \mid A) = P(B)$.

Exercícios

1.5.1 Suponha que lançamos quatro dados honestos de seis faces.

(a) Qual é a probabilidade condicional de o primeiro dado mostrar 2, condicionada ao evento em que exatamente três dados mostram 2?

(b) Qual é a probabilidade condicional de o primeiro dado mostrar 2, condicionada ao evento em que *pelo menos* três dados mostram 2?

1.5.2 Suponha que lançamos duas moedas honestas e um dado honesto de seis faces.

(a) Qual é a probabilidade de o número de caras ser igual ao número que aparece no dado?

(b) Qual é a probabilidade condicional de o número de caras ser igual ao número que aparece no dado, condicionada ao conhecimento de que o dado mostrou 1?

(c) A resposta do item (b) é maior ou menor que a resposta do item (a)? Explique intuitivamente por que isso acontece.

1.5.3 Suponha que lançamos três moedas honestas.

(a) Qual é a probabilidade de as três moedas darem cara?

(b) Qual é a probabilidade condicional de as três moedas darem cara, condicionada ao conhecimento de que o número de caras é ímpar?

(c) Qual é a probabilidade condicional de as três moedas darem cara, dado que o número de caras é par?

1.5.4 Suponha que distribuímos cinco cartas de um baralho comum de 52 cartas. Qual é a probabilidade condicional de as cinco cartas serem de espadas, dado que pelo menos quatro delas são de espadas?

1.5.5 Suponha que distribuímos cinco cartas de um baralho comum de 52 cartas. Qual é a probabilidade condicional de a mão conter os quatro ases, dado que a mão contém pelo menos quatro ases?

1.5.6 Suponha que distribuímos cinco cartas de um baralho comum de 52 cartas. Qual é a probabilidade condicional de a mão não conter nenhum par, dado que ela não contém nenhuma carta de espadas?

1.5.7 Suponha que um arremessador de beisebol lance bolas rápidas em 80% das vezes e bolas curvas em 20% das vezes. Suponha que um rebatedor acerte um home run em 8% de todos os arremessos de bola rápida e em 5% de todos os arremessos de bola curva. Qual é a probabilidade de esse rebatedor acertar um home run no próximo arremesso desse arremessador?

1.5.8 Suponha que a probabilidade de nevar seja de 20% e que a probabilidade de um acidente de trânsito seja de 10%. Suponha ainda que a probabilidade *condicional* de um acidente, dado que neva, seja de 40%. Qual é a probabilidade condicional de nevar, dado que há um acidente?

1.5.9 Suponha que lançamos dois dados honestos de seis faces, um vermelho e um azul. Seja A o evento em que os dois dados mostram o mesmo valor. Seja

B o evento em que a soma dos dois dados é igual a 12. Seja C o evento em que o dado vermelho mostra 4. Seja D o evento em que o dado azul mostra 4.

(a) A e B são independentes?

(b) A e C são independentes?

(c) A e D são independentes?

(d) C e D são independentes?

(e) A, C e D são todos independentes?

1.5.10 Considere duas urnas, chamadas urna nº 1 e urna nº 2. Suponha, como no Exercício 1.4.11, que a urna nº 1 tenha 5 bolas vermelhas e 7 azuis, que a urna nº 2 tenha 6 bolas vermelhas e 12 azuis, e que retiramos três bolas uniformemente ao acaso de cada uma das duas urnas. Condicionada ao fato de as seis bolas escolhidas serem todas da mesma cor, qual é a probabilidade condicional de essa cor ser vermelha?

1.5.11 Suponha que lançamos um dado honesto de seis faces e depois lançamos um número de moedas honestas igual ao número que aparece no dado. (Por exemplo, se o dado mostra 4, então lançamos 4 moedas.)

(a) Qual é a probabilidade de o número de caras ser igual a 3?

(b) Condicionada ao conhecimento de que o número de caras é igual a 3, qual é a probabilidade condicional de o dado ter mostrado o número 5?

1.5.12 Suponha que lançamos um dado honesto de seis faces e depois tiramos de um baralho bem embaralhado um número de cartas igual ao número que aparece no dado. (Por exemplo, se o dado mostra 4, então tiramos 4 cartas.)

(a) Qual é a probabilidade de o número de valetes na nossa mão ser igual a 2?

(b) Condicionada ao conhecimento de que o número de valetes na nossa mão é igual a 2, qual é a probabilidade condicional de o dado ter mostrado o número 3?

Problemas

1.5.13 Considere três cartas, assim: uma é vermelha dos dois lados, uma é preta dos dois lados e uma é vermelha de um lado e preta do outro. Suponha que as cartas sejam colocadas num chapéu e que uma seja escolhida ao acaso. Suponha ainda que essa carta seja colocada deitada sobre a mesa, de modo que só conseguimos ver um dos lados.

(a) Qual é a probabilidade de esse lado ser vermelho?

(b) Condicionada a esse lado ser vermelho, qual é a probabilidade de a carta à mostra ser a que é vermelha dos dois lados? (Dica: a resposta é um tanto surpreendente.)

(c) Suponha que você quisesse verificar a resposta do item (b) por meio de um experimento físico real. Explique como poderia fazer isso.

1.5.14 Prove que A e B são independentes se e somente se A^C e B são independentes.

1.5.15 Sejam A e B eventos de probabilidade positiva. Prove que $P(A \mid B) > P(A)$ se e somente se $P(B \mid A) > P(B)$.

Desafios

1.5.16 Suponha que lançamos três dados honestos de seis faces. Calcule a probabilidade condicional de o primeiro dado mostrar 4, dado que a soma dos três números que aparecem é 12.

1.5.17 *(O jogo de craps)* O jogo de craps é jogado lançando-se dois dados honestos de seis faces. No primeiro lançamento, se a soma dos dois números que aparecem for igual a 2, 3 ou 12, o jogador perde imediatamente. Se a soma for igual a 7 ou 11, o jogador ganha imediatamente. Se a soma for igual a qualquer outro valor, esse valor passa a ser o "ponto" do jogador. O jogador então lança os dois dados repetidamente, até tirar de novo o valor do ponto (caso em que ganha) ou tirar um 7 (caso em que perde).

(a) Suponha que o ponto do jogador seja igual a 4. Condicionada a isso, qual é a probabilidade condicional de ele ganhar (isto é, de tirar outro 4 antes de tirar um 7)? (Dica: o último lançamento será um 4 ou um 7; qual é a probabilidade condicional de ser um 4?)

(b) Para $2 \leq i \leq 12$, seja p_i a probabilidade condicional de o jogador ganhar, condicionada a ter tirado i no primeiro lançamento. Calcule p_i para todo i com $2 \leq i \leq 12$. (Dica: você já fez isso para $i = 4$ no item (b). Além disso, os casos $i = 2, 3, 7, 11, 12$ são triviais. Os demais casos são parecidos com o caso $i = 4$.)

(c) Calcule a probabilidade total de um jogador ganhar no craps. (Dica: use o item (b) e o Teorema 1.5.1.)

1.5.18 *(O problema de Monty Hall)* Suponha que haja três portas, chamadas A, B e C. Um carro novo está atrás de uma das três portas, mas você não sabe de

qual. Você escolhe uma das portas, digamos a porta A. O apresentador então abre uma das portas B ou C, da seguinte maneira: se o carro está atrás de B, ele abre C; se o carro está atrás de C, ele abre B; se o carro está atrás de A, ele abre B ou C, cada uma com probabilidade 1/2. (Em qualquer caso, a porta aberta pelo apresentador *não* terá o carro atrás dela.) O apresentador então lhe dá a *opção* de ficar com a porta que você escolheu originalmente (isto é, A) ou de trocar para a porta restante ainda fechada (isto é, aquela entre B e C que o apresentador não abriu). Você então ganha (isto é, fica com o carro) se e somente se o carro estiver atrás da porta que você escolheu no final. (Fonte: *Parade Magazine*, coluna "Ask Marilyn", 9 de setembro de 1990.) Suponha, para fixar as ideias, que o apresentador abra a porta B.

(a) Se você ficar com a escolha original (isto é, a porta A), condicionada a o apresentador ter aberto a porta B, qual é a sua probabilidade de ganhar? (Dica: primeiro condicione à verdadeira posição do carro. Depois use o Teorema 1.5.2.)

(b) Se você trocar para a porta restante (isto é, a porta C), condicionada a o apresentador ter aberto a porta B, qual é a sua probabilidade de ganhar?

(c) Você acha surpreendente o resultado dos itens (a) e (b)? Como você poderia planejar um experimento físico para verificar o resultado?

(d) Suponha que mudemos as regras de modo que, se você escolheu originalmente A e o carro de fato estava atrás de A, o apresentador sempre abre a porta B. Como mudariam as respostas dos itens (a) e (b) nesse caso?

(e) Suponha que mudemos as regras de modo que, se você escolheu originalmente A, o apresentador sempre abre a porta B *não importa onde esteja o carro*. Então *condicionamos* ao fato de a porta B, por acaso, *não* ter um carro atrás dela. Como mudariam as respostas dos itens (a) e (b) nesse caso?

Tópicos para discussão

1.5.19 Suponha que duas pessoas lancem, cada uma, uma moeda honesta ao mesmo tempo. Os resultados dos dois lançamentos costumam ser independentes? Em que tipo de circunstância eles poderiam não ser independentes? (Liste tantas circunstâncias desse tipo quantas conseguir.)

1.5.20 Suponha que você consiga repetir um experimento muitas vezes e queira verificar se dois eventos são independentes ou não. Como você poderia fazer isso?

1.5.21 O problema de Monty Hall (Desafio 1.5.18) foi apresentado originalmente por Marilyn von Savant, que escrevia na coluna "Ask Marilyn" da *Parade Magazine*. Ela deu a resposta correta. No entanto, muitas pessoas (entre elas alguns matemáticos conhecidos, além de muitos leigos) escreveram para reclamar que a resposta dela estava errada. A controvérsia se arrastou por meses, com muitas cartas e linguagem muito dura dos dois lados (no fim, von Savant teve razão). Parte da confusão estava nas hipóteses que estavam sendo feitas; por exemplo, algumas pessoas interpretaram a pergunta dela como a da versão modificada do item (e) do Desafio 1.5.18. No entanto, boa parte da confusão se deveu simplesmente a erros matemáticos e mal-entendidos. (Fonte: *Parade Magazine*, coluna "Ask Marilyn", 9 de setembro de 1990; 2 de dezembro de 1990; 17 de fevereiro de 1991; 7 de julho de 1991.)

(a) Surpreende você que tanta gente, incluindo matemáticos conhecidos, tenha errado ao resolver este problema? Por quê?

(b) Surpreende você que tanta gente, incluindo muitos leigos, se importasse tanto com a resposta deste problema? Por quê?

1.6 Continuidade de P

Suponha que $A_1, A_2, \ldots$ seja uma sequência de eventos que estão ficando "mais próximos" (em algum sentido) de outro evento, A. Então poderíamos esperar que as probabilidades $P(A_1), P(A_2), \ldots$ estejam se aproximando de $P(A)$, isto é, que $\lim_{n\to\infty} P(A_n) = P(A)$. Mas podemos ter certeza disso?

Propriedades como essa, que dizem que $P(A_n)$ está próximo de $P(A)$ sempre que A_n está "próximo" de A, são chamadas de *propriedades de continuidade*. A pergunta acima pode, portanto, ser traduzida, grosso modo, como a pergunta sobre se as medidas de probabilidade P são ou não "contínuas". Acontece que P é, de fato, contínua em certo sentido.

Especificamente, vamos escrever $\{A_n\} \nearrow A$ e dizer que a sequência $\{A_n\}$ *cresce* para A se $A_1 \subseteq A_2 \subseteq A_3 \subseteq \cdots$ e, além disso, $\bigcup_{n=1}^{\infty} A_n = A$. Ou seja, a sequência de eventos é uma sequência *crescente* e, além disso, sua união é igual a A. Por exemplo, se $A_n = (1/n, n]$, então $A_1 \subseteq A_2 \subseteq \cdots$ e $\bigcup_{n=1}^{\infty} A_n = (0, \infty)$. Logo, $\{(1/n, n]\} \nearrow (0, \infty)$. A Figura 1.6.1 representa uma sequência crescente[24] de subconjuntos.

No original: *increasing sequence*[24].

Analogamente, vamos escrever $\{A_n\} \searrow A$ e dizer que a sequência $\{A_n\}$ *decresce* para A se $A_1 \supseteq A_2 \supseteq A_3 \supseteq \cdots$ e, além disso, $\bigcap_{n=1}^{\infty} A_n = A$. Ou seja, a sequência de eventos é uma sequência *decrescente* e, além disso, sua interseção é igual a A. Por exemplo, se $A_n = \left(-1/n, 1/n\right]$, então $A_1 \supseteq A_2 \supseteq \cdots$ e $\bigcap_{n=1}^{\infty} A_n = \{0\}$. Logo, $\left\{(-1/n, 1/n]\right\} \searrow \{0\}$. A Figura 1.6.2 representa uma sequência decrescente[25] de subconjuntos.

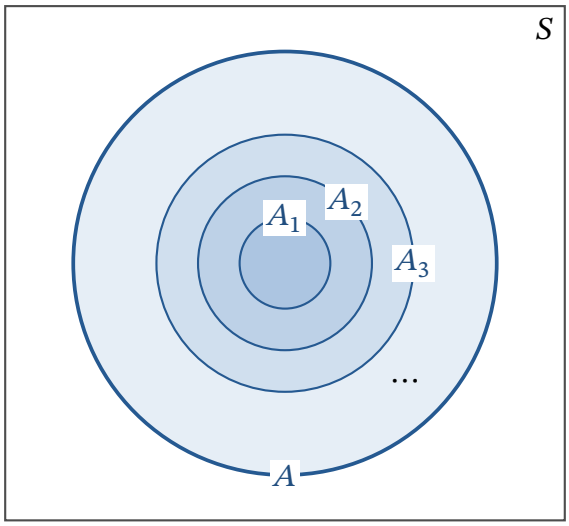


Figura 1.6.1: Uma sequência crescente de subconjuntos $A_1 \subseteq A_2 \subseteq A_3 \subseteq \ldots$.

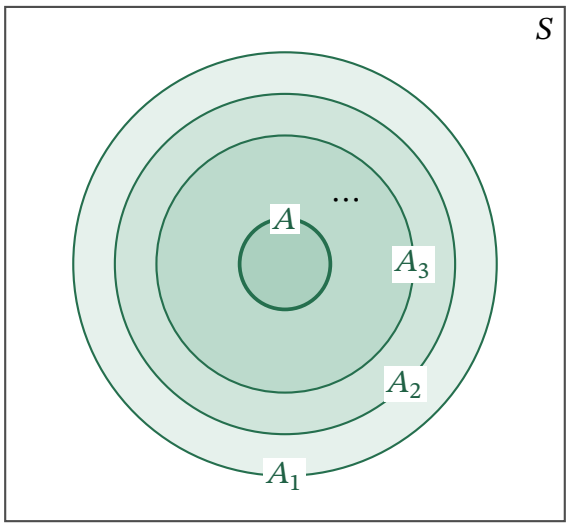


Figura 1.6.2: Uma sequência decrescente de subconjuntos $A_1 \supseteq A_2 \supseteq A_3 \supseteq \ldots$.

Consideraremos sequências de conjuntos como essas em vários pontos do texto. Para isso, precisamos do resultado a seguir.

No original: *decreasing sequence*[25].

Teorema 1.6.1

Sejam $A, A_1, A_2, \ldots$ eventos e suponha que $\{A_n\} \nearrow A$ ou $\{A_n\} \searrow A$. Então

$$\lim_{n\to\infty} P(A_n) = P(A).$$

Demonstração. Veja a Seção 1.7 para a demonstração deste teorema. ■

Exemplo 1.6.1

Suponha que S seja o conjunto de todos os inteiros positivos, com $P(s) = 2^{-s}$ para todo $s \in S$. Então, quanto vale $P(\{5, 6, 7, 8, \ldots\})$?

Começamos observando que os eventos $A_n = \{5, 6, 7, 8, \ldots, n\}$ crescem para $A = \{5, 6, 7, 8, \ldots\}$, isto é, $\{A_n\} \nearrow A$. Logo, usando a continuidade das probabilidades, devemos ter

$$\begin{aligned} P(\{5,6,7,8,\ldots\}) &= \lim_{n\to\infty} P(\{5,6,7,8,\ldots,n\}) \\ &= \lim_{n\to\infty} \big(P(5) + P(6) + \cdots + P(n)\big) \\ &= \lim_{n\to\infty} \left(2^{-5} + 2^{-6} + \cdots + 2^{-n}\right) = \lim_{n\to\infty} \left(\frac{2^{-5} - 2^{-n-1}}{1 - 2^{-1}}\right) \\ &= \lim_{n\to\infty} \left(2^{-4} - 2^{-n}\right) = 2^{-4} = 1/16. \end{aligned}$$

Alternativamente, poderíamos usar a aditividade enumerável diretamente para concluir que

$$P(\{5, 6, 7, 8, \ldots\}) = P(5) + P(6) + P(7) + \cdots,$$

o que dá no mesmo. ■

Exemplo 1.6.2

Seja P *alguma* medida de probabilidade no espaço $S = R^1$. Suponha que

$$P\big((3, 5 + 1/n)\big) \geq \delta$$

para todo n, em que $\delta > 0$. Seja $A_n = (3, 5 + 1/n)$. Então $\{A_n\} \searrow A$, em que $A = (3, 5]$. Logo, devemos ter também $P(A) = P((3, 5]) \geq \delta$.

Observe, no entanto, que ainda poderíamos ter $P((3, 5)) = 0$. Por exemplo, talvez $P(\{5\}) = \delta$, mas $P((3, 5)) = 0$. ■

Resumo da Seção 1.6

- Se $\{A_n\} \nearrow A$ ou $\{A_n\} \searrow A$, então $\lim_{n\to\infty} P(A_n) = P(A)$.
- Isso nos permite calcular ou limitar várias probabilidades que, de outra forma, não poderiam ser compreendidas.

Exercícios

1.6.1 Suponha que $S = \{1, 2, 3, \ldots\}$ seja o conjunto de todos os inteiros positivos e que $P(\{s\}) = 2^{-s}$ para todo $s \in S$. Calcule $P(A)$, em que $A = \{2, 4, 6, \ldots\}$ é o conjunto de todos os inteiros positivos *pares*. Faça isso de duas maneiras: usando a continuidade de P (junto com a aditividade finita[26]) e usando a aditividade enumerável.

1.6.2 Considere a distribuição uniforme em $[0, 1]$. Calcule (com demonstração)

$$\lim_{n\to\infty} P([1/4, 1 - e^{-n}]).$$

1.6.3 Suponha que $S = \{1, 2, 3, \ldots\}$ seja o conjunto de todos os inteiros positivos e que P seja *alguma* medida de probabilidade em S. Prove que devemos ter

$$\lim_{n\to\infty} P(\{1, 2, \ldots, n\}) = 1.$$

1.6.4 Suponha que $P([0, \frac{8}{4+n}]) = \frac{2+e^{-n}}{6}$ para todo $n = 1, 2, 3, \ldots$. Quanto deve valer $P(\{0\})$?

1.6.5 Suponha que $P([0, 1]) = 1$, mas $P([1/n, 1]) = 0$ para todo $n = 1, 2, 3, \ldots$. Quanto deve valer $P(\{0\})$?

1.6.6 Suponha que $P([1/n, 1/2]) \leq 1/3$ para todo $n = 1, 2, 3, \ldots$.

(a) Devemos ter $P((0, 1/2]) \leq 1/3$?

(b) Devemos ter $P([0, 1/2]) \leq 1/3$?

1.6.7 Suponha que $P([0, \infty)) = 1$. Prove que existe algum n tal que $P([0, n]) > 0{,}9$.

1.6.8 Suponha que $P((0, 1/2]) = 1/3$. Prove que há algum n tal que $P([1/n, 1/2]) > 1/4$.

No original: *finite additivity*[26].

1.6.9 Suponha que $P([0,1/2]) = 1/3$. Deve existir algum n tal que $P([1/n,1/2]) > 1/4$?

Problemas

1.6.10 Seja P *alguma* medida de probabilidade no espaço amostral $S = [0,1]$.

(a) Prove que devemos ter $\lim_{n\to\infty} P((0,1/n)) = 0$.

(b) Mostre, por meio de um exemplo, que podemos ter $\lim_{n\to\infty} P([0,1/n)) > 0$.

Desafios

1.6.11 Suponha que saibamos que P é *finitamente* aditiva, mas *não* saibamos se ela é *enumeravelmente* aditiva. Em outras palavras, sabemos que $P(A_1 \cup \cdots \cup A_n) = P(A_1) + \cdots + P(A_n)$ para qualquer coleção finita de eventos disjuntos $\{A_1, \ldots, A_n\}$, mas não sabemos nada sobre $P(A_1 \cup A_2 \cup \cdots)$ para coleções infinitas de eventos disjuntos. Suponha, além disso, que saibamos que P é contínua no sentido do Teorema 1.6.1. Usando isso, dê uma *demonstração* de que P deve ser enumeravelmente aditiva[27]. (Na prática, você está provando que a continuidade de P é *equivalente* à aditividade enumerável de P, pelo menos uma vez que se saiba que P é finitamente aditiva[28].)

1.7 Demonstrações Adicionais (Avançado)

Demonstração do Teorema 1.3.4

Queremos provar que, sempre que $A_1, A_2, \ldots$ for uma sequência finita ou infinita enumerável de eventos, não necessariamente disjuntos, então $P(A_1 \cup A_2 \cup \cdots) \leq P(A_1) + P(A_2) + \cdots$.

Seja $B_1 = A_1$ e, para $n \geq 2$, seja $B_n = A_n \cap (A_1 \cup \cdots \cup A_{n-1})^c$. Então $B_1, B_2, \ldots$ são disjuntos, $B_1 \cup B_2 \cup \cdots = A_1 \cup A_2 \cup \cdots$ e, pela aditividade,

$$P(A_1 \cup A_2 \cup \cdots) = P(B_1 \cup B_2 \cup \cdots) = P(B_1) + P(B_2) + \cdots . \tag{1.7.1}$$

No original: *countably additive*[27], *finitely additive*[28].

Além disso, $A_n \supseteq B_n$; logo, pela monotonicidade[29], temos $P(A_n) \geq P(B_n)$. Segue de (1.7.1) que

$$P(A_1 \cup A_2 \cup \cdots) = P(B_1) + P(B_2) + \cdots \leq P(A_1) + P(A_2) + \cdots$$

como afirmado. ■

Demonstração do Teorema 1.6.1

Queremos provar que, quando $A, A_1, A_2, \ldots$ são eventos e $\{A_n\} \nearrow A$ ou $\{A_n\} \searrow A$, então $\lim_{n\to\infty} P(A_n) = P(A)$.

Suponha primeiro que $\{A_n\} \nearrow A$. Então podemos escrever

$$A = A_1 \cup (A_2 \cap A_1^c) \cup (A_3 \cap A_2^c) \cup \cdots$$

em que a união é disjunta. Logo, pela aditividade,

$$P(A) = P(A_1) + P(A_2 \cap A_1^c) + P(A_3 \cap A_2^c) + \cdots .$$

Ora, por definição, escrever essa soma infinita é o mesmo que escrever

$$P(A) = \lim_{n\to\infty} \big(P(A_1) + P(A_2 \cap A_1^c) + \cdots + P(A_n \cap A_{n-1}^c)\big). \tag{1.7.2}$$

No entanto, novamente pela aditividade, vemos que

$$P(A_1) + P(A_2 \cap A_1^c) + P(A_3 \cap A_2^c) + \cdots + P(A_n \cap A_{n-1}^c) = P(A_n).$$

Substituindo essa informação em (1.7.2), obtemos $P(A) = \lim_{n\to\infty} P(A_n)$, que era o que queríamos provar.

Suponha agora que $\{A_n\} \searrow A$. Sejam $B_n = A_n^c$ e $B = A^c$. Então vemos que $\{B_n\} \nearrow B$ (por quê?). Logo, pelo que acabamos de provar, devemos ter $P(B) = \lim_{n\to\infty} P(B_n)$. Mas então, usando (1.3.1), temos

$$1 - P(A) = \lim_{n\to\infty} \{1 - P(A_n)\},$$

de onde segue que $P(A) = \lim_{n\to\infty} P(A_n)$. Isso completa a demonstração. ■

No original: *monotonicity*[29].

CAPÍTULO 2

Variáveis Aleatórias e Distribuições

ESBOÇO DO CAPÍTULO

Seção 1 Variáveis Aleatórias
Seção 2 Distribuições de Variáveis Aleatórias
Seção 3 Distribuições Discretas
Seção 4 Distribuições Contínuas
Seção 5 Funções de Distribuição Acumulada
Seção 6 Mudança de Variável Unidimensional
Seção 7 Distribuições Conjuntas
Seção 8 Condicionamento e Independência
Seção 9 Mudança de Variável Multidimensional
Seção 10 Simulação de Distribuições de Probabilidade
Seção 11 Demonstrações Adicionais (Avançado)

No Capítulo 1, discutimos o modelo de probabilidade[1] como o objeto central de estudo da teoria da probabilidade. Isso exigiu definir uma medida de probabilidade[2] P numa classe de subconjuntos do espaço amostral[3] S. Acontece que há maneiras mais simples de apresentar uma atribuição particular de probabilidades do que essa — maneiras com as quais é muito mais conveniente trabalhar do que com P. Este capítulo trata das definições de variáveis aleatórias, funções de distribuição, funções de probabilidade e funções densidade, e do desenvolvimento dos conceitos necessários para fazer cálculos num modelo de probabilidade usando essas entidades. Este capítulo também discute o conceito de distribuição condicional[4] de uma variável aleatória[5], dados os valores de outras. As distribuições condicionais de variáveis aleatórias fornecem a estrutura para discutir o que significa dizer que variáveis estão relacionadas, o que é importante em muitas aplicações da probabilidade e da estatística.

No original: *probability model*[1], *probability measure*[2], *sample space*[3], *conditional distribution*[4], *random variable*[5].

2.1 Variáveis Aleatórias

O capítulo anterior explicou como construir modelos de probabilidade, incluindo um espaço amostral S e uma medida de probabilidade P. Uma vez que temos um modelo de probabilidade, podemos definir *variáveis aleatórias* para esse modelo de probabilidade.

Intuitivamente, uma variável aleatória atribui um valor numérico a cada resultado possível do espaço amostral. Por exemplo, se o espaço amostral é {chuva, neve, limpo}, então poderíamos definir uma variável aleatória X tal que $X = 3$ se chover, $X = 6$ se nevar e $X = -2{,}7$ se o tempo estiver limpo.

Mais formalmente, temos a definição a seguir.

Definição 2.1.1

Uma *variável aleatória* é uma função do espaço amostral S no conjunto R^1 de todos os números reais.

A Figura 2.1.1 dá uma representação gráfica de uma variável aleatória X que leva um valor de resposta $s \in S$ num número real $X(s) \in R^1$.

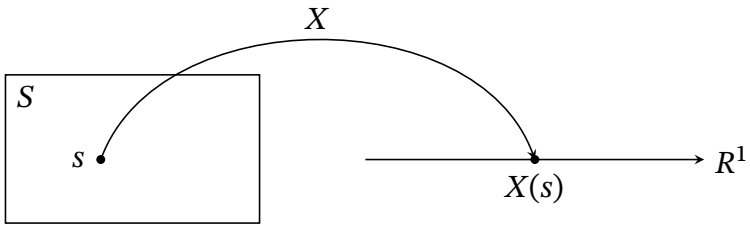


Figura 2.1.1: Uma variável aleatória X como função no espaço amostral S e assumindo valores em R^1.

Exemplo 2.1.1 — Uma Variável Aleatória Muito Simples

A variável aleatória descrita acima poderia ser escrita formalmente como $X : \{\text{chuva}, \text{neve}, \text{limpo}\} \to R^1$ dada por $X(\text{chuva}) = 3$, $X(\text{neve}) = 6$ e $X(\text{limpo}) = -2{,}7$. Voltaremos a este exemplo mais adiante. ■

Apresentamos agora mais alguns exemplos. A questão é que podemos definir variáveis aleatórias como quisermos, desde que sejam funções do espaço amostral em R^1.

Exemplo 2.1.2

Para o caso $S = \{\text{chuva}, \text{neve}, \text{limpo}\}$, poderíamos definir uma segunda variável aleatória Y dizendo que $Y = 0$ se chover, $Y = -1/2$ se nevar e $Y = 7/8$ se o tempo estiver limpo. Isto é, $Y(\text{chuva}) = 0$, $Y(\text{neve}) = 1/2$* e $Y(\text{limpo}) = 7/8$. ■

Exemplo 2.1.3

Se o espaço amostral corresponde a lançar três moedas diferentes, então poderíamos tomar X como o número total de caras obtidas, Y como o número total de coroas obtidas, $Z = 0$ se houver exatamente uma cara e, caso contrário, $Z = 17$ etc. ■

Exemplo 2.1.4

Se o espaço amostral corresponde a lançar dois dados honestos, então poderíamos tomar X como o quadrado do número obtido no primeiro dado, Y como o quadrado do número obtido no segundo dado, Z como a soma dos dois números obtidos, W como o quadrado da soma dos dois números obtidos, R como a soma dos quadrados dos dois números obtidos etc. ■

Exemplo 2.1.5 — Constantes como Variáveis Aleatórias

Como caso particular, todo valor *constante* c também é uma variável aleatória, se dissermos que $c(s) = c$ para todo $s \in S$. Assim, 5 é uma variável aleatória, assim como 3 ou $-21{,}6$. ■

*Nota do tradutor. O original traz $Y(\text{snow}) = 1/2$; pela frase anterior ($Y = -1/2$ se nevar), seria $Y(\text{neve}) = -1/2$.

Exemplo 2.1.6 — Funções Indicadoras

Vale a pena mencionar um tipo especial de variável aleatória. Se A é um evento qualquer, então podemos definir a *função indicadora* de A, denotada por I_A, como a variável aleatória

$$I_A(s) = \begin{cases} 1 & s \in A \\ 0 & s \notin A, \end{cases}$$

que é igual a 1 em A e igual a 0 em A^C. ■

Dadas variáveis aleatórias X e Y, podemos fazer com elas as operações aritméticas usuais. Assim, por exemplo, $Z = X^2$ é outra variável aleatória, definida por $Z(s) = X^2(s) = (X(s))^2 = X(s) \times X(s)$. Da mesma forma, se $W = XY^3$, então $W(s) = X(s) \times Y(s) \times Y(s) \times Y(s)$ etc. Além disso, se $Z = X + Y$, então $Z(s) = X(s) + Y(s)$ etc.

Exemplo 2.1.7

Considere o lançamento de um dado honesto de seis faces, de modo que $S = \{1, 2, 3, 4, 5, 6\}$. Seja X o número obtido, de modo que $X(s) = s$ para $s \in S$. Seja Y o número obtido mais três, de modo que $Y(s) = s + 3$. Seja $Z = X^2 + Y$. Então $Z(s) = X(s)^2 + Y(s) = s^2 + s + 3$. Assim, $Z(1) = 5$, $Z(2) = 9$ etc. ■

Escrevemos $X = Y$ para indicar que $X(s) = Y(s)$ para todo $s \in S$. Da mesma forma, escrevemos $X \leq Y$ para indicar que $X(s) \leq Y(s)$ para todo $s \in S$, e $X \geq Y$ para indicar que $X(s) \geq Y(s)$ para todo $s \in S$. Por exemplo, escrevemos $X \leq c$ para indicar que $X(s) \leq c$ para todo $s \in S$.

Exemplo 2.1.8

Considere de novo o lançamento de um dado honesto de seis faces, com $S = \{1, 2, 3, 4, 5, 6\}$. Para $s \in S$, seja $X(s) = s$ e seja $Y = X + I_{\{6\}}$. Isso significa que

$$Y(s) = X(s) + I_{\{6\}}(s) = \begin{cases} s & s \leq 5 \\ 7 & s = 6. \end{cases}$$

Logo, $Y(s) = X(s)$ para $1 \leq s \leq 5$. Mas não é verdade que $Y = X$, porque $Y(6) \neq X(6)$. Por outro lado, é verdade que $Y \geq X$. ■

Exemplo 2.1.9

Para a variável aleatória do Exemplo 2.1.1 acima, não é verdade que $X \geq 0$, nem é verdade que $X \leq 0$. No entanto, é verdade que $X \geq -2{,}7$ e que $X \leq 6$. Também é verdade que $X \geq -10$ e $X \leq 100$. ■

Se S é infinito, então uma variável aleatória X pode assumir infinitos valores diferentes.

Exemplo 2.1.10

Se $S = \{1, 2, 3, \ldots\}$, com $P\{s\} = 2^{-s}$ para todo $s \in S$, e se X é definida por $X(s) = s^2$, então sempre temos $X \geq 1$. Mas não existe um maior valor de $X(s)$, porque o valor $X(s)$ cresce sem limite quando $s \to \infty$. Chamaremos uma variável aleatória assim de variável aleatória *ilimitada*. ■

Por fim, suponha que X seja uma variável aleatória. Sabemos que estados s diferentes ocorrem com probabilidades diferentes. Segue-se que $X(s)$ também assume valores diferentes com probabilidades diferentes. Essas probabilidades são chamadas de *distribuição* de X; vamos tratar delas a seguir.

Resumo da Seção 2.1

- Uma variável aleatória é uma função do espaço de estados no conjunto dos números reais.
- A função pode ser constante, ou corresponder à contagem de alguma quantidade aleatória que surja, ou ser qualquer outro tipo de função.

Exercícios

2.1.1 Seja $S = \{1, 2, 3, \ldots\}$ e sejam $X(s) = s^2$ e $Y(s) = 1/s$ para $s \in S$. Para cada uma das quantidades a seguir, determine (com justificativa) se ela existe ou não. Se existir, dê o seu valor.

(a) $\min_{s \in S} X(s)$

(b) $\max_{s \in S} X(s)$

(c) $\min_{s \in S} Y(s)$

(d) $\max_{s \in S} Y(s)$

2.1.2 Seja $S = \{\text{alto}, \text{médio}, \text{baixo}\}$. Defina as variáveis aleatórias X, Y e Z por $X(\text{alto}) = -12$, $X(\text{médio}) = -2$, $X(\text{baixo}) = 3$, $Y(\text{alto}) = 0$, $Y(\text{médio}) = 0$, $Y(\text{baixo}) = 1$, $Z(\text{alto}) = 6$, $Z(\text{médio}) = 0$, $Z(\text{baixo}) = 4$. Determine se cada uma das relações a seguir é verdadeira ou falsa.

(a) $X < Y$

(b) $X \leq Y$

(c) $Y < Z$

(d) $Y \leq Z$

(e) $XY < Z$

(f) $XY \leq Z$

2.1.3 Seja $S = \{1, 2, 3, 4, 5\}$.

(a) Defina duas variáveis aleatórias não constantes diferentes (isto é, não iguais), X e Y, em S.

(b) Para as variáveis aleatórias X e Y que você escolheu, seja $Z = X + Y^2$. Calcule $Z(s)$ para todo $s \in S$.

2.1.4 Considere o lançamento de um dado honesto de seis faces, de modo que $S = \{1, 2, 3, 4, 5, 6\}$. Sejam $X(s) = s$ e $Y(s) = s^3 + 2$. Seja $Z = XY$. Calcule $Z(s)$ para todo $s \in S$.

2.1.5 Sejam A e B eventos e seja $X = I_A \cdot I_B$. X é uma função indicadora[6]? Se for, de que evento?

2.1.6 Sejam $S = \{1, 2, 3, 4\}$, $X = I_{\{1,2\}}$, $Y = I_{\{2,3\}}$ e $Z = I_{\{3,4\}}$. Seja $W = X + Y + Z$.

(a) Calcule $W(1)$.

(b) Calcule $W(2)$.

(c) Calcule $W(4)$.

(d) Determine se $W \geq Z$ ou não.

2.1.7 Sejam $S = \{1, 2, 3\}$, $X = I_{\{1\}}$, $Y = I_{\{2,3\}}$ e $Z = I_{\{1,2\}}$. Seja $W = X - Y + Z$.

(a) Calcule $W(1)$.

(b) Calcule $W(2)$.

(c) Calcule $W(3)$.

No original: *indicator function*[6].

(d) Determine se $W \geq Z$ ou não.

2.1.8 Sejam $S = \{1, 2, 3, 4, 5\}$, $X = I_{\{1,2,3\}}$, $Y = I_{\{2,3\}}$ e $Z = I_{\{3,4,5\}}$. Seja $W = X - Y + Z$.

(a) Calcule $W(1)$.

(b) Calcule $W(2)$.

(c) Calcule $W(5)$.

(d) Determine se $W \geq Z$ ou não.

2.1.9 Sejam $S = \{1, 2, 3, 4\}$, $X = I_{\{1,2\}}$ e $Y(s) = s^2 X(s)$.

(a) Calcule $Y(1)$.

(b) Calcule $Y(2)$.

(c) Calcule $Y(4)$.

Problemas

2.1.10 Seja X uma variável aleatória.

(a) É necessariamente verdade que $X \geq 0$?

(b) É necessariamente verdade que existe algum número real c tal que $X + c \geq 0$?

(c) Suponha que o espaço amostral S seja finito. Então é necessariamente verdade que existe algum número real c tal que $X + c \geq 0$?

2.1.11 Suponha que o espaço amostral S seja finito. É possível definir uma variável aleatória ilimitada[7] em S? Por quê?

2.1.12 Suponha que X seja uma variável aleatória que assume apenas os valores 0 ou 1. X tem de ser uma função indicadora? Explique.

2.1.13 Suponha que o espaço amostral S seja finito, de tamanho m. Quantas funções indicadoras diferentes podem ser definidas em S?

2.1.14 Suponha que X seja uma variável aleatória. Seja $Y = \sqrt{X}$. Y tem de ser uma variável aleatória? Explique.

No original: *unbounded*[7].

Tópicos para discussão

2.1.15 A teoria matemática da probabilidade foi apresentada ao mundo de língua inglesa em grande parte por dois matemáticos americanos, William Feller e Joe Doob, que escreviam no início dos anos 1950. Segundo o professor Doob, os dois tiveram uma discussão sobre se as variáveis aleatórias deveriam se chamar "random variables" (variáveis aleatórias) ou "chance variables" (variáveis de acaso). Eles decidiram jogando uma moeda — e "random variables" venceu. (Fonte: *Statistical Science* **12** (1997), n.º 4, página 307.) Qual nome *você* acha que teria sido uma escolha melhor?

2.2 Distribuições de Variáveis Aleatórias

Como as variáveis aleatórias são definidas como funções do resultado s, e como se supõe que o resultado s seja aleatório (isto é, que assuma valores diferentes com probabilidades diferentes), segue-se que o valor de uma variável aleatória também será aleatório (como o nome indica).

Mais especificamente, se X é uma variável aleatória, qual é a probabilidade de X ser igual a algum valor particular x? Bem, $X = x$ exatamente quando o resultado s escolhido é tal que $X(s) = x$.

Exemplo 2.2.1

Consideremos de novo a variável aleatória do Exemplo 2.1.1, em que $S = \{\text{chuva}, \text{neve}, \text{limpo}\}$ e X é definida por $X(\text{chuva}) = 3$, $X(\text{neve}) = 6$ e $X(\text{limpo}) = -2{,}7$. Suponha, além disso, que a medida de probabilidade P seja tal que $P(\text{chuva}) = 0{,}4$, $P(\text{neve}) = 0{,}15$ e $P(\text{limpo}) = 0{,}45$. Então, claramente, $X = 3$ só quando chove, $X = 6$ só quando neva e $X = -2{,}7$ só quando o tempo está limpo. Assim, $P(X = 3) = P(\text{chuva}) = 0{,}4$, $P(X = 6) = P(\text{neve}) = 0{,}15$ e $P(X = -2{,}7) = P(\text{limpo}) = 0{,}45$. Além disso, $P(X = 17) = 0$ e, de fato, $P(X = x) = P(\varnothing) = 0$ para todo $x \notin \{3, 6, -2{,}7\}$. Podemos também calcular que

$$P(X \in \{3, 6\}) = P(X = 3) + P(X = 6) = 0{,}4 + 0{,}15 = 0{,}55,$$

enquanto

$$P(X < 5) = P(X = 3) + P(X = -2{,}7) = 0{,}4 + 0{,}45 = 0{,}85,$$

etc. ■

Vemos por este exemplo que, se B é um subconjunto qualquer dos números reais, então $P(X \in B) = P(\{s \in S : X(s) \in B\})$. Além disso, entender bem X exige conhecer as probabilidades $P(X \in B)$ para diferentes subconjuntos B. Essa é a motivação da definição a seguir.

Definição 2.2.1

Se X é uma variável aleatória, então a *distribuição* de X é a coleção de probabilidades $P(X \in B)$ para todos os subconjuntos B dos números reais.

Em termos rigorosos, exige-se que B seja um subconjunto de Borel[8], o que é uma restrição técnica da teoria da medida[9] com a qual não precisamos nos preocupar aqui. Qualquer subconjunto que pudéssemos escrever é um subconjunto de Borel.

Na Figura 2.2.1, damos uma representação gráfica de como calculamos a distribuição de uma variável aleatória X. Para um conjunto B, precisamos encontrar os elementos $s \in S$ tais que $X(s) \in B$. Esses elementos são dados pelo conjunto $\{s \in S : X(s) \in B\}$. Em seguida, calculamos a probabilidade $P(\{s \in S : X(s) \in B\})$. Precisamos fazer isso para todo subconjunto $B \subset R^1$.

No original: *Borel subset*[8], *measure theory*[9].

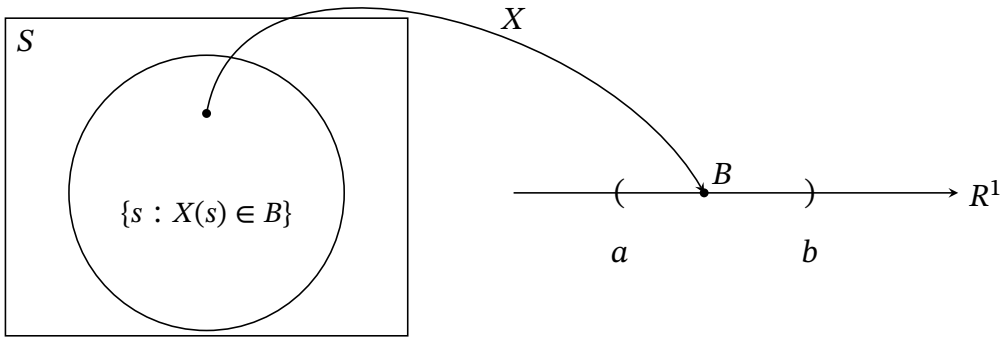


Figura 2.2.1: Se $B = (a, b) \subset R^1$, então $\{s \in S : X(s) \in B\}$ é o conjunto dos elementos tais que $a < X(s) < b$.

Exemplo 2.2.2 — Uma Distribuição Muito Simples

Considere mais uma vez a variável aleatória acima, em que $S = \{\text{chuva}, \text{neve}, \text{limpo}\}$ e X é definida por $X(\text{chuva}) = 3$, $X(\text{neve}) = 6$ e $X(\text{limpo}) = -2{,}7$, e $P(\text{chuva}) = 0{,}4$, $P(\text{neve}) = 0{,}15$ e $P(\text{limpo}) = 0{,}45$. Qual é a distribuição de X? Bem, se B é um subconjunto qualquer dos números reais, então $P(X \in B)$ deve contar 0,4 se $3 \in B$, mais 0,15 se $6 \in B$, mais 0,45 se $-2{,}7 \in B$. Podemos escrever formalmente toda essa informação de uma só vez dizendo que

$$P(X \in B) = 0{,}4\, I_B(3) + 0{,}15\, I_B(6) + 0{,}45\, I_B(-2{,}7),$$

em que, de novo, $I_B(x) = 1$ se $x \in B$, e $I_B(x) = 0$ se $x \notin B$. ■

Exemplo 2.2.3 — Uma Distribuição Quase Tão Simples

Considere mais uma vez a situação acima, com $S = \{\text{chuva}, \text{neve}, \text{limpo}\}$ e $P(\text{chuva}) = 0{,}4$, $P(\text{neve}) = 0{,}15$ e $P(\text{limpo}) = 0{,}45$. Considere uma variável aleatória Y definida por $Y(\text{chuva}) = 5$, $Y(\text{neve}) = 7$ e $Y(\text{limpo}) = 5$.

Qual é a distribuição de Y? Claramente, $Y = 7$ só quando neva, de modo que $P(Y = 7) = P(\text{neve}) = 0{,}15$. No entanto, aqui $Y = 5$ se chover *ou* se o tempo estiver limpo. Logo, $P(Y = 5) = P(\{\text{chuva}, \text{limpo}\}) = 0{,}4 + 0{,}45 = 0{,}85$. Portanto, se B é um subconjunto qualquer dos números reais, então

$$P(Y \in B) = 0{,}15\, I_B(7) + 0{,}85\, I_B(5).$$

■

Embora os exemplos acima mostrem que é possível acompanhar $P(X \in B)$ para todos os subconjuntos B dos números reais, eles também indicam que fazer isso é bastante trabalhoso. Felizmente, há funções mais simples disponíveis para nos ajudar a acompanhar distribuições de probabilidade, entre elas as funções de distribuição acumulada, as funções de probabilidade e as funções densidade. Vamos tratar delas a seguir.

Resumo da Seção 2.2

- A distribuição de uma variável aleatória X é a coleção de probabilidades $P(X \in B)$ de X pertencer a diversos conjuntos.
- A probabilidade $P(X \in B)$ é determinada calculando-se a probabilidade do conjunto dos valores de resposta s tais que $X(s) \in B$, isto é, $P(X \in B) = P(\{s \in S : X(s) \in B\})$.

Exercícios

2.2.1 Considere o lançamento de duas moedas honestas independentes. Seja X o número de caras que aparecem. Calcule $P(X = x)$ para todo número real x.

2.2.2 Suponha que lançamos três moedas honestas e seja X o número de caras obtidas.

(a) Calcule $P(X = x)$ para todo número real x.

(b) Escreva uma fórmula para $P(X \in B)$, para qualquer subconjunto B dos números reais.

2.2.3 Suponha que lançamos dois dados honestos de seis faces e seja Y a soma dos dois números obtidos.

(a) Calcule $P(Y = y)$ para todo número real y.

(b) Escreva uma fórmula para $P(Y \in B)$, para qualquer subconjunto B dos números reais.

2.2.4 Suponha que lançamos um dado honesto de seis faces e seja Z o número obtido. Sejam $W = Z^3 + 4$ e $V = \sqrt{Z}$.

(a) Calcule $P(W = w)$ para todo número real w.

(b) Calcule $P(V = v)$ para todo número real v.

(c) Calcule $P(ZW = x)$ para todo número real x.

(d) Calcule $P(VW = y)$ para todo número real y.

(e) Calcule $P(V + W = r)$ para todo número real r.

2.2.5 Suponha que uma tigela contenha 100 fichas: 30 marcadas com 1, 20 marcadas com 2 e 50 marcadas com 3. As fichas são bem misturadas, uma ficha é retirada e o número X da ficha é anotado.

(a) Calcule $P(X = x)$ para todo número real x.

(b) Suponha que a primeira ficha seja devolvida, uma segunda ficha seja retirada e o número Y da ficha seja anotado. Calcule $P(Y = y)$ para todo número real y.

(c) Calcule $P(W = w)$ para todo número real w quando $W = X + Y$.

2.2.6 Suponha que um baralho comum de 52 cartas seja bem embaralhado e que uma única carta seja retirada. Suponha que um ás valha 1, um valete valha 11, uma dama valha 12 e um rei valha 13.

(a) Calcule $P(X = x)$ para todo número real x, quando X é o valor da carta retirada.

(b) Suponha que $Y = 1, 2, 3$ ou 4 quando sai uma carta de ouros, copas, paus ou espadas, respectivamente. Calcule $P(Y = y)$ para todo número real y.

(c) Calcule $P(W = w)$ para todo número real w quando $W = X + Y$.

2.2.7 Suponha que uma universidade seja composta de 55% de alunas e 45% de alunos. Um estudante é selecionado para responder a um questionário. Há 25 perguntas no questionário aplicado a um aluno e 30 perguntas no questionário aplicado a uma aluna. Se X denota o número de perguntas respondidas por um estudante selecionado ao acaso, calcule $P(X = x)$ para todo número real x.

2.2.8 Suponha que uma tigela contenha 10 fichas, numeradas de 0 a 9, cada uma com um número diferente. As fichas são bem misturadas, uma é retirada e o número nela, X_1, é anotado. Essa ficha é então devolvida à tigela. Uma segunda ficha é retirada e o número nela, X_2, é anotado. Calcule $P(W = w)$ para todo número real w quando $W = X_1 + 10X_2$.

Problemas

2.2.9 Suponha que uma tigela contenha 10 fichas, numeradas de 0 a 9, cada uma com um número diferente. As fichas são bem misturadas, uma é retirada e o número nela, X_1, é anotado. Essa ficha *não* é devolvida à tigela. Uma segunda

ficha é retirada e o número nela, X_2, é anotado. Calcule $P(W = w)$ para todo número real w quando $W = X_1 + 10X_2$.

Desafios

2.2.10 Suponha que Alice lance três moedas honestas e seja X o número de caras obtidas. Suponha que Barbara lance cinco moedas honestas e seja Y o número de caras obtidas. Seja $Z = X - Y$. Calcule $P(Z = z)$ para todo número real z.

2.3 Distribuições Discretas

Para muitas variáveis aleatórias X, temos $P(X = x) > 0$ para certos valores de x. Isso significa que há probabilidade positiva de a variável ser igual a certos valores particulares.

Se

$$\sum_{x \in R^1} P(X = x) = 1,$$

então *toda* a probabilidade associada à variável aleatória X pode ser obtida a partir da probabilidade de X ser igual a certos valores particulares. Isso motiva a definição a seguir.

Definição 2.3.1

Uma variável aleatória X é *discreta* se

$$\sum_{x \in R^1} P(X = x) = 1. \tag{2.3.1}$$

À primeira vista, poderíamos esperar que (2.3.1) valesse para *qualquer* variável aleatória. No entanto, (2.3.1) não vale para a distribuição uniforme[10] em $[0, 1]$ nem para outras distribuições *contínuas*, como veremos na próxima seção.

Variáveis aleatórias que satisfazem (2.3.1) são simples, em certo sentido, porque podemos entendê-las completamente apenas entendendo suas probabilidades de serem iguais a valores particulares x. De fato, simplesmente listando todos

No original: *uniform distribution*[10].

os valores possíveis x tais que $P(X = x) > 0$, obtemos uma segunda definição, equivalente, como segue.

Definição 2.3.2

Uma variável aleatória X é *discreta* se existe uma sequência finita ou enumerável $x_1, x_2, \ldots$ de números reais distintos, e uma sequência correspondente $p_1, p_2, \ldots$ de números reais não negativos, tais que $P(X = x_i) = p_i$ para todo i, e $\sum_i p_i = 1$.

Essa segunda definição também sugere como registrar distribuições discretas. Ela motiva a definição a seguir.

Definição 2.3.3

Para uma variável aleatória discreta X, sua *função de probabilidade* é a função $p_X : R^1 \to [0, 1]$ definida por

$$p_X(x) = P(X = x).$$

Portanto, se $x_1, x_2, \ldots$ são os valores distintos tais que $P(X = x_i) = p_i$ para todo i, com $\sum_i p_i = 1$, então

$$p_X(x) = \begin{cases} p_i & x = x_i \text{ para algum } i \\ 0 & \text{caso contrário.} \end{cases}$$

Evidentemente, toda a informação sobre a distribuição de X está contida em sua função de probabilidade[11], mas só se *soubermos* que X é uma variável aleatória discreta.

Por fim, observamos que o Teorema 1.5.1 implica imediatamente o seguinte.

Teorema 2.3.1 (*Lei da probabilidade total, versão para variável aleatória discreta*)

Seja X uma variável aleatória discreta e seja A algum evento. Então

$$P(A) = \sum_{x \in R^1} P(X = x)\, P(A \mid X = x).$$

No original: *probability function*[11].

2.3.1 Distribuições Discretas Importantes

Certas distribuições discretas particulares são tão importantes que as listamos aqui.

Exemplo 2.3.1 — Distribuições Degeneradas

Seja c algum número real fixo. Então, como já discutido, c também é uma variável aleatória (na verdade, c é uma *variável aleatória constante*). Nesse caso, evidentemente c é discreta, com função de probabilidade p_c satisfazendo $p_c(c) = 1$ e $p_c(x) = 0$ para $x \neq c$. Como c é sempre igual a um valor particular (a saber, c) com probabilidade 1, a distribuição de c às vezes é chamada de *massa pontual*, *distribuição pontual* ou *distribuição degenerada*. ■

Exemplo 2.3.2 — A Distribuição de Bernoulli

Considere o lançamento de uma moeda que tem probabilidade θ de dar cara e probabilidade $1 - \theta$ de dar coroa, em que $0 < \theta < 1$. Seja $X = 1$ se a moeda der cara, e $X = 0$ se der coroa. Então $p_X(1) = P(X = 1) = \theta$, enquanto $p_X(0) = P(X = 0) = 1 - \theta$. Dizemos que a variável aleatória X tem distribuição Bernoulli(θ); escrevemos isso como $X \sim \text{Bernoulli}(\theta)$.

Distribuições de Bernoulli surgem sempre que temos uma variável resposta que assume só dois valores possíveis e rotulamos um desses resultados como 1 e o outro como 0. Por exemplo, 1 poderia corresponder ao sucesso e 0 ao fracasso em algum teste de qualidade aplicado a um item produzido num processo de fabricação. Nesse caso, θ é a proporção de itens fabricados que passarão no teste. Alternativamente, poderíamos selecionar ao acaso um indivíduo de uma população e registrar 1 quando o indivíduo for do sexo feminino e 0 se for do sexo masculino. Nesse caso, θ é a proporção de mulheres na população. ■

Exemplo 2.3.3 — A Distribuição Binomial

Considere o lançamento de n moedas, cada uma com probabilidade (independente) θ de dar cara e probabilidade $1-\theta$ de dar coroa. (Novamente, $0 < \theta < 1$.) Seja X o número total de caras obtidas. Por (1.4.2), vemos que, para $x = 0, 1, 2, \ldots, n$,

$$p_X(x) = P(X = x) = \binom{n}{x}\theta^x(1-\theta)^{n-x} = \frac{n!}{x!\,(n-x)!}\,\theta^x(1-\theta)^{n-x}.$$

Dizemos que a variável aleatória X tem distribuição Binomial(n, θ); escrevemos isso como $X \sim$ Binomial(n, θ). A distribuição Bernoulli(θ) corresponde ao caso particular da distribuição Binomial(n, θ) em que $n = 1$, a saber, Bernoulli(θ) = Binomial$(1, \theta)$. A Figura 2.3.1 traz os gráficos de várias funções de probabilidade Binomial$(20, \theta)$.

A distribuição binomial se aplica a qualquer situação que envolva n realizações independentes de um sistema aleatório; em cada realização, registramos se um evento particular ocorreu, o que se chama *sucesso*, ou não ocorreu, o que se chama *fracasso*. Se denotarmos o evento em questão por A e pusermos $\theta = P(A)$, temos que o número de sucessos nas n realizações tem distribuição Binomial(n, θ). Por exemplo, poderíamos estar testando lâmpadas produzidas por um fabricante, e θ é a probabilidade de uma lâmpada funcionar quando a testamos. Então o número de lâmpadas que funcionam num lote de n tem distribuição Binomial(n, θ). Se um jogador de beisebol tem probabilidade θ de rebater com sucesso quando está no bastão, então o número de rebatidas válidas obtidas em n vezes no bastão tem distribuição Binomial(n, θ).

Há outra maneira de expressar a distribuição binomial que às vezes é útil. Por exemplo, se $X_1, X_2, \ldots, X_n$ são escolhidas de forma independente e cada uma tem distribuição Bernoulli(θ), e $Y = X_1 + \cdots + X_n$, então Y terá distribuição Binomial(n, θ) (veja o Exemplo 3.4.10 para os detalhes). ■

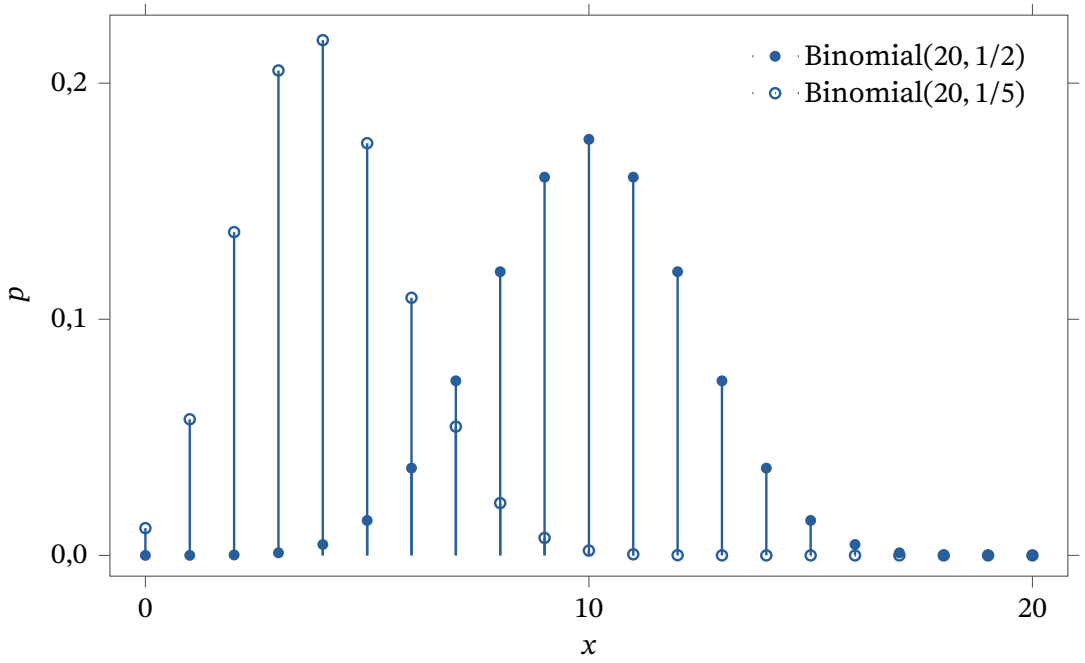


Figura 2.3.1: Gráfico das funções de probabilidade Binomial(20, 1/2) (• • •) e Binomial(20, 1/5) (∘ ∘ ∘).

Exemplo 2.3.4 — A Distribuição Geométrica

Considere lançar repetidamente uma moeda que tem probabilidade θ de dar cara e probabilidade $1 - \theta$ de dar coroa, em que, novamente, $0 < \theta < 1$. Seja X o número de coroas que aparecem antes da primeira cara. Então, para $k \geq 0$, $X = k$ se e somente se a moeda mostra exatamente k coroas seguidas de uma cara. A probabilidade disso é igual a $(1 - \theta)^k\theta$. (Em particular, a probabilidade de obter um número *infinito* de coroas antes da primeira cara é igual a $(1 - \theta)^\infty\theta = 0$, de modo que X nunca é igual a infinito.) Portanto, $p_X(k) = (1 - \theta)^k\theta$, para $k = 0, 1, 2, 3, \ldots$. Dizemos que a variável aleatória X tem distribuição Geométrica(θ); escrevemos isso como $X \sim$ Geométrica(θ). A Figura 2.3.2 traz os gráficos de várias funções de probabilidade Geométrica(θ).

A distribuição geométrica se aplica sempre que contamos o número de fracassos até o primeiro sucesso em realizações independentes de um sistema aleatório em que a ocorrência de algum evento é considerada um sucesso. Por exemplo, o número de lâmpadas testadas que funcionam até a primeira lâmpada que não funciona (uma lâmpada que funciona é considerada um "fracasso" para o teste) e o número de vezes no bastão sem rebatida válida até a primeira rebatida válida do jogador de beisebol seguem, ambos, a distribuição geométrica.

Observamos que alguns livros definem a distribuição geométrica, em vez disso, como o número de lançamentos da moeda até a primeira cara, *inclusive*, que é simplesmente igual a um mais a variável aleatória definida aqui. ■

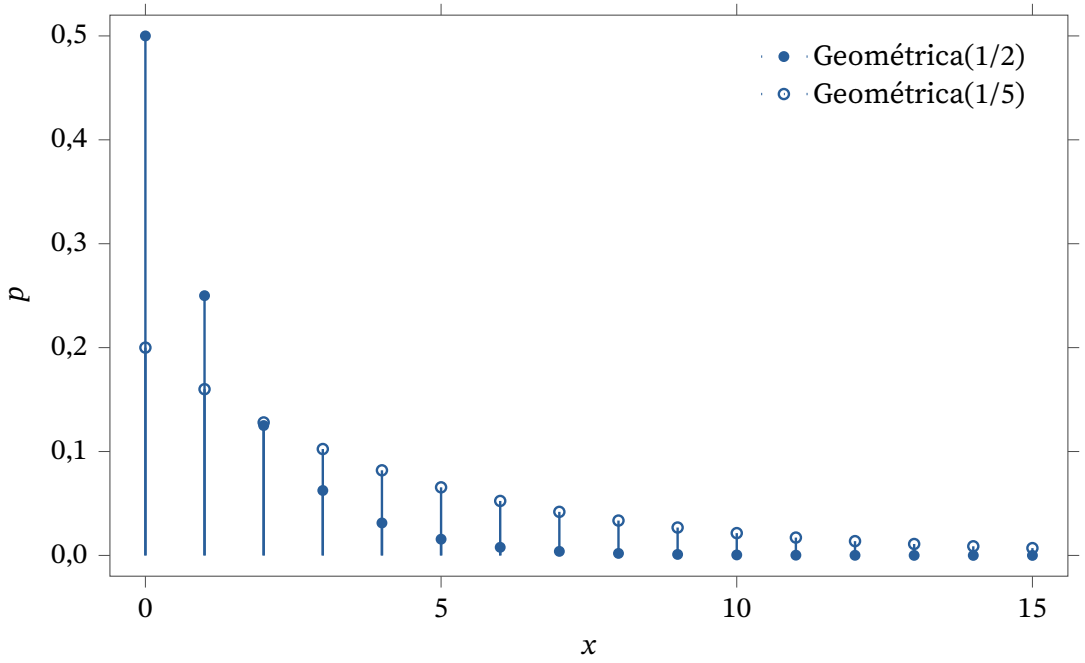


Figura 2.3.2: Gráfico das funções de probabilidade Geométrica(1/2) (• • •) e Geométrica(1/5) (∘ ∘ ∘) nos valores $0, 1, \ldots, 15$.

Exemplo 2.3.5 — A Distribuição Binomial Negativa

Generalizando o exemplo anterior, considere novamente lançar repetidamente uma moeda que tem probabilidade θ de dar cara e probabilidade $1-\theta$ de dar coroa. Seja r um inteiro positivo e seja Y o número de coroas que aparecem antes da r-ésima cara. Então, para $k \geq 0$, $Y = k$ se e somente se a moeda mostra exatamente $r-1$ caras (e k coroas) nos primeiros $r-1+k$ lançamentos e, depois, mostra cara no $(r+k)$-ésimo lançamento. A probabilidade disso é igual a

$$p_Y(k) = \binom{r-1+k}{r-1}\theta^{r-1}(1-\theta)^k\theta = \binom{r-1+k}{k}\theta^r(1-\theta)^k,$$

para $k = 0, 1, 2, 3, \ldots$.

Dizemos que a variável aleatória Y tem distribuição Binomial Negativa(r, θ); escrevemos isso como $Y \sim$ Binomial Negativa(r, θ). Naturalmente, o caso particular $r = 1$ corresponde à distribuição Geométrica(θ). Assim, na nossa notação, temos que Binomial Negativa$(1, \theta)$ = Geométrica(θ). A Figura 2.3.3 traz os gráficos de várias funções de probabilidade Binomial Negativa(r, θ).

A distribuição Binomial Negativa(r, θ) se aplica sempre que contamos o número de fracassos até o r-ésimo sucesso em realizações independentes de um sistema aleatório em que a ocorrência de algum evento é considerada um sucesso. Por exemplo, o número de lâmpadas testadas que funcionam até a terceira lâmpada que não funciona e o número de vezes no bastão sem rebatida válida até a quinta rebatida válida do jogador de beisebol seguem, ambos, a distribuição binomial negativa. ■

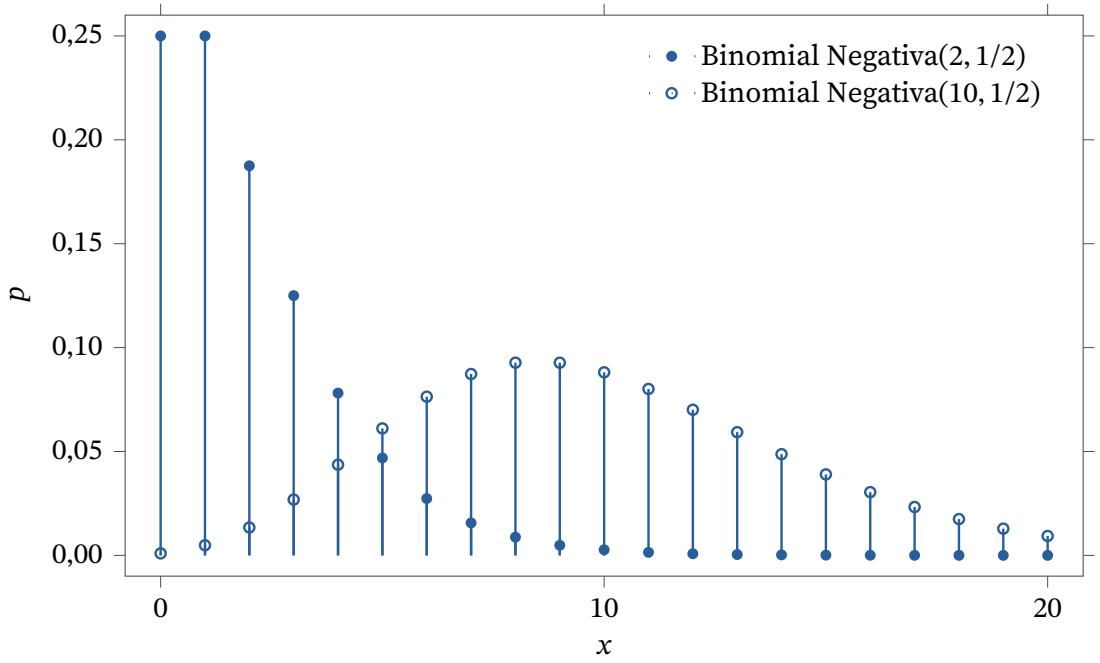


Figura 2.3.3: Gráfico da função de probabilidade Binomial Negativa(2, 1/2) (• • •) e da função de probabilidade Binomial Negativa(10, 1/2) (∘ ∘ ∘) nos valores 0, 1, ... , 20.

Exemplo 2.3.6 — A Distribuição de Poisson

Dizemos que uma variável aleatória Y tem distribuição Poisson(λ), e escrevemos $Y \sim \text{Poisson}(\lambda)$, se

$$p_Y(y) = P(Y = y) = \frac{\lambda^y}{y!} e^{-\lambda}$$

para $y = 0, 1, 2, 3, \ldots$. Observamos que, como (pelo cálculo) $\sum_{y=0}^{\infty} \lambda^y / y! = e^{\lambda}$, de fato vale (como tem de valer) que $\sum_{y=0}^{\infty} P(Y = y) = 1$. A Figura 2.3.4 traz os gráficos de várias funções de probabilidade Poisson(λ).

Motivamos a distribuição de Poisson da seguinte maneira. Suponha que $X \sim \text{Binomial}(n, \theta)$, isto é, que X tem distribuição Binomial(n, θ) como no Exemplo 2.3.3. Então, para $0 \leq x \leq n$,

$$P(X = x) = \binom{n}{x} \theta^x (1 - \theta)^{n-x}.$$

Se tomarmos $\theta = \lambda / n$ para algum $\lambda > 0$, isso se torna

$$\begin{aligned} P(X = x) &= \binom{n}{x} \left(\frac{\lambda}{n}\right)^x \left(1 - \frac{\lambda}{n}\right)^{n-x} \\ &= \frac{n(n-1)\cdots(n-x+1)}{x!} \left(\frac{\lambda}{n}\right)^x \left(1 - \frac{\lambda}{n}\right)^{n-x}. \end{aligned} \tag{2.3.2}$$

Vamos considerar agora o que acontece se fizermos $n \to \infty$ em (2.3.2), mantendo x fixo em algum inteiro não negativo. Nesse caso,*

$$\frac{n(n-1)(n-2)\cdots(n-x+1)}{n^x} = 1\left(1-\frac{1}{n}\right)\left(1-\frac{2}{n}\right)\cdots\left(1-\frac{x+1}{n}\right)$$

converge para 1, enquanto (como, pelo cálculo, $(1+(c/n))^n \to e^c$ para qualquer c)

$$\left(1-\frac{\lambda}{n}\right)^{n-x} = \left(1-\frac{\lambda}{n}\right)^{n}\left(1-\frac{\lambda}{n}\right)^{-x} \to e^{-\lambda}\cdot 1 = e^{-\lambda}.$$

Substituindo esses limites em (2.3.2), vemos que

$$\lim_{n\to\infty} P(X=x) = \frac{\lambda^x}{x!}e^{-\lambda}$$

para $x = 0, 1, 2, 3, \ldots$.

Intuitivamente, podemos enunciar esse resultado da seguinte forma. Se lançarmos um número *n muito grande* de moedas, e cada moeda tiver probabilidade *muito pequena* $\theta = \lambda/n$ de dar cara, então a probabilidade de o número total de caras ser x é dada aproximadamente por $\lambda^x e^{-\lambda}/x!$. A Figura 2.3.5 mostra a precisão dessa estimativa quando aproximamos a distribuição Binomial$(100, 1/10)$ pela distribuição Poisson(λ), em que $\lambda = n\theta = 100(1/10) = 10$.

A distribuição de Poisson é um bom modelo para contar ocorrências aleatórias de um evento quando há muitas ocorrências possíveis, mas cada ocorrência tem probabilidade muito pequena. Exemplos incluem o número de incêndios em residências numa cidade num dado dia, o número de eventos radioativos registrados por um contador Geiger, o número de chamadas telefônicas que chegam a uma central telefônica e o número de acessos a uma página popular da World Wide Web num dado dia etc. ■

*Nota do tradutor. o original traz o último fator como $\left(1-\frac{x+1}{n}\right)$; pela conta seria $\left(1-\frac{x-1}{n}\right)$, pois o último fator do numerador é $n-x+1 = n-(x-1)$.

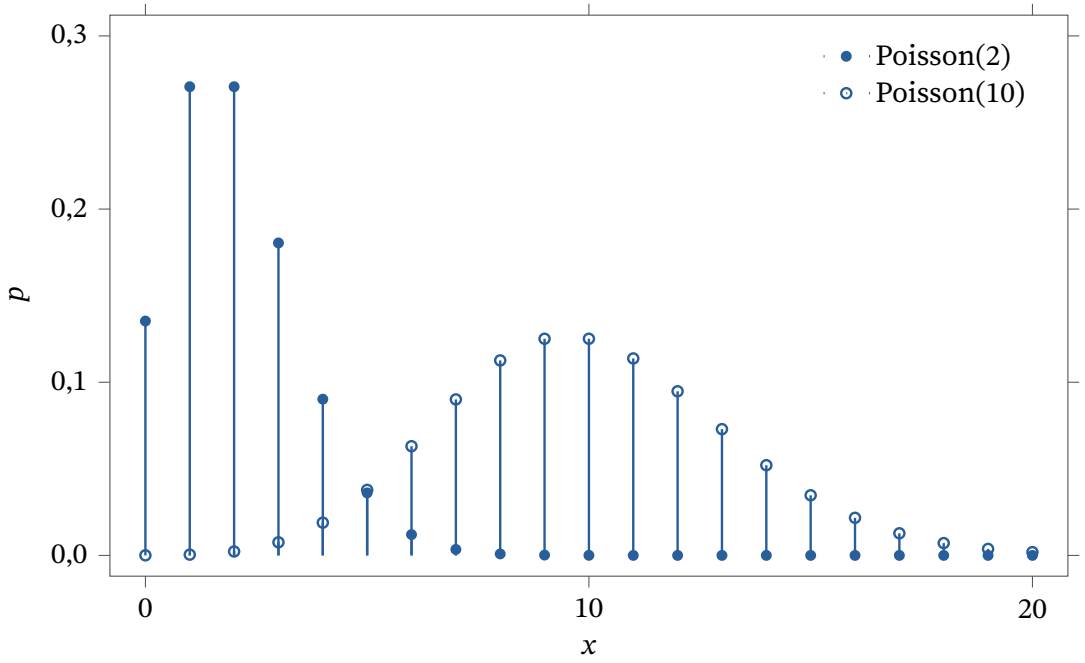


Figura 2.3.4: Gráfico das funções de probabilidade Poisson(2) (• • •) e Poisson(10) (∘ ∘ ∘) nos valores $0, 1, \ldots, 20$.

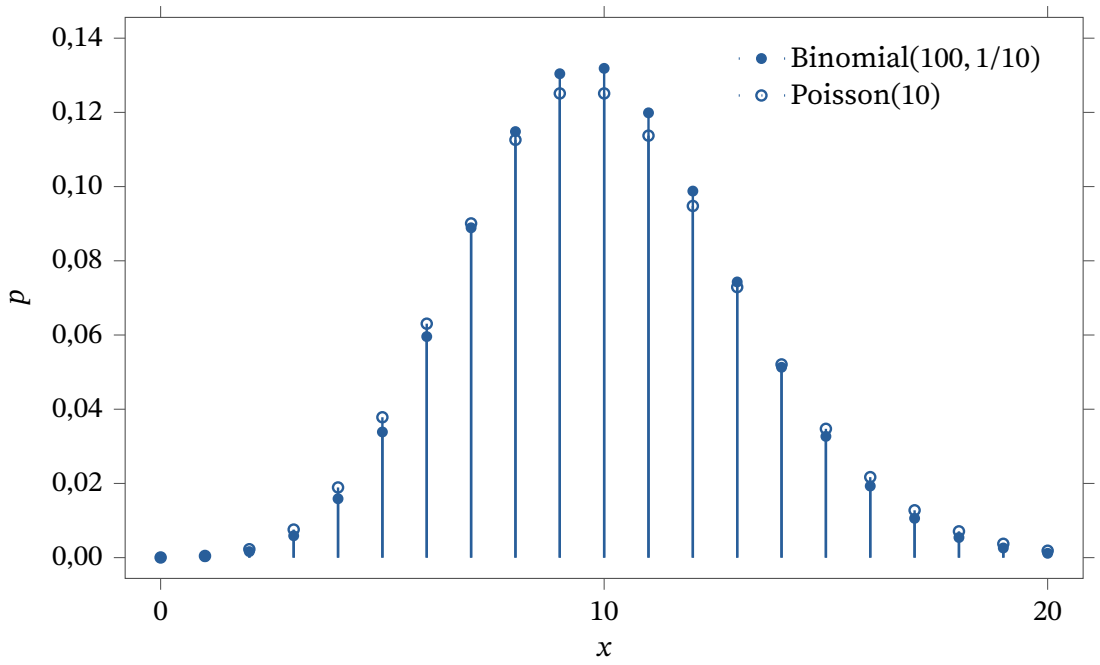


Figura 2.3.5: Gráfico das funções de probabilidade Binomial(100, 1/10) (• • •) e Poisson(10) (∘ ∘ ∘) nos valores $0, 1, \ldots, 20$.

Exemplo 2.3.7 — A Distribuição Hipergeométrica

Suponha que uma urna contenha M bolas brancas e $N - M$ bolas pretas. Suponha que retiramos $n \leq N$ bolas da urna de tal maneira que cada subconjunto de n bolas tenha a mesma probabilidade de ser retirado. Como há $\binom{N}{n}$ desses subconjuntos, essa probabilidade é $1/\binom{N}{n}$.

Uma maneira de fazer isso é misturar bem as bolas na urna e então retirar uma primeira bola. Assim, cada bola tem probabilidade $1/N$ de ser retirada. Em seguida, sem repor a primeira bola, misturamos bem as bolas na urna e retiramos uma segunda bola. Assim, cada bola na urna tem probabilidade $1/(N-1)$ de ser retirada. Temos então que quaisquer duas bolas, digamos a i-ésima e a j-ésima, têm probabilidade

$$\begin{aligned} &P(\text{bolas } i \text{ e } j \text{ são retiradas}) \\ &= P(\text{bola } i \text{ é a } 1^{\text{a}})\, P(\text{bola } j \text{ é a } 2^{\text{a}} \mid \text{bola } i \text{ é a } 1^{\text{a}}) \\ &\quad + P(\text{bola } j \text{ é a } 1^{\text{a}})\, P(\text{bola } i \text{ é a } 2^{\text{a}} \mid \text{bola } j \text{ é a } 1^{\text{a}}) \\ &= \frac{1}{N}\frac{1}{N-1} + \frac{1}{N}\frac{1}{N-1} = 1\Big/\binom{N}{2} \end{aligned}$$

de serem retiradas nas duas primeiras retiradas. Continuando dessa forma por n retiradas, obtemos que a probabilidade de qualquer conjunto particular de n bolas ser retirado é $1/\binom{N}{n}$. Esse tipo de amostragem é chamado de *amostragem sem reposição*.

Dado que tomamos uma amostra de tamanho n, seja X o número de bolas brancas obtidas. Note que devemos ter $X \geq 0$ e $X \geq n - (N - M)$, porque no máximo $N - M$ das bolas podem ser pretas. Portanto, $X \geq \max(0, n + M - N)$. Além disso, $X \leq n$ e $X \leq M$, porque há só M bolas brancas. Portanto, $X \leq \min(n, M)$.

Suponha então que $\max(0, n + M - N) \leq x \leq \min(n, M)$. Qual é a probabilidade de se obterem x bolas brancas? Em outras palavras, quanto vale $P(X = x)$? Para calcular isso, sabemos que precisamos contar o número de subconjuntos de n bolas que contêm x bolas brancas. Usando os princípios combinatórios da Seção 1.4.1, vemos que esse número é dado por $\binom{M}{x}\binom{N-M}{n-x}$. Portanto,

$$P(X = x) = \binom{M}{x}\binom{N-M}{n-x}\Big/\binom{N}{n}$$

para $\max(0, n + M - N) \leq x \leq \min(n, M)$. Dizemos que a variável aleatória X tem distribuição Hipergeométrica(N, M, n). Na Figura 2.3.6,

traçamos algumas funções de probabilidade hipergeométricas. A função de probabilidade Hipergeométrica$(20, 10, 10)$ é 0 para $x > 10$, enquanto a função de probabilidade Hipergeométrica$(20, 10, 5)$ é 0 para $x > 5$.

Evidentemente, a distribuição hipergeométrica se aplica a qualquer contexto em que estejamos fazendo *amostragem sem reposição* de um conjunto finito de N elementos e em que cada elemento do conjunto tem ou não tem uma característica. Por exemplo, se selecionamos pessoas ao acaso para participar de uma pesquisa de opinião de modo que cada conjunto de n indivíduos numa população de N tenha a mesma probabilidade de ser selecionado, então o número de pessoas que respondem sim a uma pergunta particular tem distribuição Hipergeométrica(N, M, n), em que M é o número de pessoas da população inteira que responderiam sim. Veremos a relevância disso para a estatística na Seção 5.4.2. ■

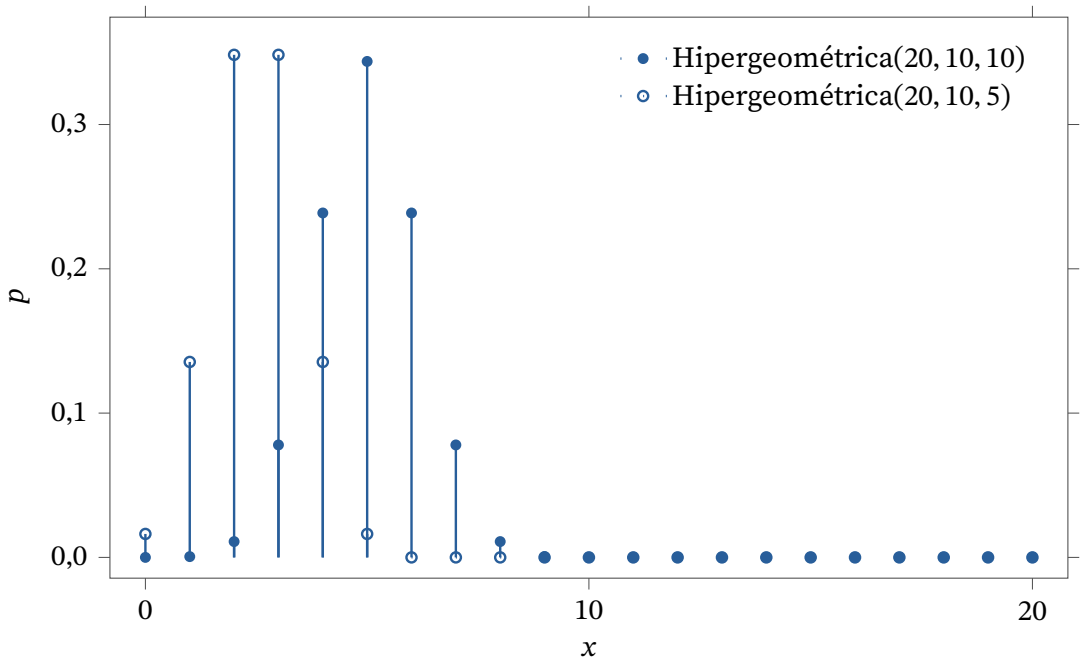


Figura 2.3.6: Gráfico das funções de probabilidade Hipergeométrica$(20, 10, 10)$ (• • •) e Hipergeométrica$(20, 10, 5)$ (∘ ∘ ∘).

Suponha que, no Exemplo 2.3.7, tivéssemos *reposto* a bola retirada antes de retirar a bola seguinte. Isso se chama *amostragem com reposição*[12]. Fica então claro, pelo Exemplo 2.3.3, que o número de bolas brancas observadas em n retiradas tem distribuição Binomial$(n, M/N)$.

No original: *sampling with replacement*[12].

Resumo da Seção 2.3

- Uma variável aleatória X é discreta se $\sum_x P(X = x) = 1$, isto é, se toda a sua probabilidade vem de ela ser igual a valores particulares.
- Uma variável aleatória discreta X assume só um número finito, ou enumerável, de valores distintos.
- Distribuições discretas importantes incluem as distribuições degenerada, de Bernoulli, binomial, geométrica, binomial negativa, de Poisson e hipergeométrica.

Exercícios

2.3.1 Considere o lançamento de dois dados honestos de seis faces. Seja Y a soma dos números obtidos. Qual é a função de probabilidade de Y?

2.3.2 Considere o lançamento de uma moeda honesta. Seja $Z = 1$ se a moeda der cara e $Z = 3$ se der coroa. Seja $W = Z^2 + Z$.

(a) Qual é a função de probabilidade de Z?

(b) Qual é a função de probabilidade de W?

2.3.3 Considere o lançamento de duas moedas honestas. Seja $X = 1$ se a primeira moeda der cara e $X = 0$ se a primeira moeda der coroa. Seja $Y = 1$ se a segunda moeda der cara e $Y = 5$ se a segunda moeda der coroa. Seja $Z = XY$. Qual é a função de probabilidade de Z?

2.3.4 Considere o lançamento de duas moedas honestas. Seja $X = 1$ se a primeira moeda der cara e $X = 0$ se a primeira moeda der coroa. Seja $Y = 1$ se as duas moedas mostrarem a *mesma* face (isto é, as duas cara ou as duas coroa), com $Y = 0$ caso contrário. Seja $Z = X + Y$ e $W = XY$.

(a) Qual é a função de probabilidade de Z?

(b) Qual é a função de probabilidade de W?

2.3.5 Considere o lançamento de dois dados honestos de seis faces. Seja W o produto dos números obtidos. Qual é a função de probabilidade de W?

2.3.6 Seja $Z \sim$ Geométrica(θ). Calcule $P(5 \leq Z \leq 9)$.

2.3.7 Seja $X \sim$ Binomial$(12, \theta)$. Para que valor de θ a probabilidade $P(X = 11)$ é máxima?

2.3.8 Seja $W \sim \text{Poisson}(\lambda)$. Para que valor de λ a probabilidade $P(W = 11)$ é máxima?

2.3.9 Seja $Z \sim$ Binomial Negativa$(3, 1/4)$. Calcule $P(Z \leq 2)$.

2.3.10 Seja $X \sim$ Geométrica$(1/5)$. Calcule $P(X^2 \leq 15)$.

2.3.11 Seja $Y \sim \text{Binomial}(10, \theta)$. Calcule $P(Y = 10)$.

2.3.12 Seja $X \sim \text{Poisson}(\lambda)$. Seja $Y = X - 7$. Qual é a função de probabilidade de Y?

2.3.13 Seja $X \sim$ Hipergeométrica$(20, 7, 8)$. Qual é a probabilidade de $X = 3$? Qual é a probabilidade de $X = 8$?

2.3.14 Suponha que um dado simétrico seja lançado 20 vezes de forma independente e que, a cada vez, registremos se o evento $\{2, 3, 5, 6\}$ ocorreu ou não.

(a) Qual é a distribuição do número de vezes que esse evento ocorre em 20 lançamentos?

(b) Calcule a probabilidade de o evento ocorrer cinco vezes.

2.3.15 Suponha que um jogador de basquete acerte a cesta, de certa posição da quadra, com probabilidade 0,35.

(a) Qual é a probabilidade de o jogador acertar três cestas em 10 arremessos independentes?

(b) Qual é a probabilidade de o jogador fazer sua primeira cesta na décima tentativa?

(c) Qual é a probabilidade de o jogador fazer sua segunda cesta na décima tentativa?

2.3.16 Uma urna contém 4 bolas pretas e 5 bolas brancas. Depois de uma boa mistura, uma bola é retirada da urna, sua cor é anotada e a bola é devolvida à urna.

(a) Qual é a probabilidade de se observarem 5 bolas pretas em 15 retiradas como essa?

(b) Qual é a probabilidade de serem necessárias 15 retiradas até que se observe a primeira bola preta?

(c) Qual é a probabilidade de se fazerem 15 retiradas com 5 bolas pretas observadas e de a quinta bola preta ser observada na 15ª retirada?

2.3.17 Uma urna contém 4 bolas pretas e 5 bolas brancas. Depois de uma boa mistura, uma bola é retirada da urna, sua cor é anotada e a bola é posta de lado. As bolas restantes são então misturadas e uma segunda bola é retirada.

(a) Qual é a distribuição de probabilidade do número de bolas pretas observadas?

(b) Qual é a distribuição de probabilidade do número de bolas brancas observadas?

2.3.18 (*Processos de Poisson e filas*) Considere uma situação que envolva um atendente, por exemplo, um caixa numa lanchonete de fast-food, um caixa eletrônico de banco, uma central telefônica etc. Em geral, as unidades chegam para atendimento de forma aleatória e formam uma fila quando o atendente está ocupado. Muitas vezes, o número de chegadas ao atendente, para alguma unidade de tempo específica t, pode ser modelado por uma distribuição Poisson(λt) e é tal que os números de chegadas em períodos que não se sobrepõem são independentes. No Capítulo 3, mostraremos que λt é o número médio de chegadas durante um período de tempo de duração t e, portanto, que λ é a taxa de chegadas por unidade de tempo.

Suponha que chamadas telefônicas cheguem a uma linha de atendimento à taxa de duas por minuto. Um processo de Poisson[13] fornece um bom modelo.

(a) Qual é a probabilidade de chegarem cinco chamadas nos próximos 2 minutos?

(b) Qual é a probabilidade de chegarem cinco chamadas nos próximos 2 minutos e, depois, mais cinco chamadas nos 2 minutos seguintes?

(c) Qual é a probabilidade de não chegar nenhuma chamada durante um período de 10 minutos?

2.3.19 Suponha que uma urna contenha 1000 bolas, uma delas preta e as outras 999 brancas. Suponha que 100 bolas sejam retiradas da urna ao acaso, com reposição. Use a distribuição de Poisson apropriada para aproximar a probabilidade de se observarem cinco bolas pretas.

2.3.20 Suponha que haja um laço num programa de computador e que o teste para sair do laço dependa do valor de uma variável aleatória X. O programa sai do laço sempre que $X \in A$, e isso ocorre com probabilidade 1/3. Se o laço é executado pelo menos uma vez, qual é a probabilidade de o laço ser executado cinco vezes antes de sair?

No original: *Poisson process*[13].

Exercícios computacionais

2.3.21 Tabule e faça o gráfico da função de probabilidade Hipergeométrica(20, 8, 10).

2.3.22 Tabule e faça o gráfico da função de probabilidade Binomial(30; 0,3). Tabule e faça o gráfico da função de probabilidade Binomial(30; 0,7). Explique por que a função de probabilidade Binomial(30; 0,3) em x coincide com a função de probabilidade Binomial(30; 0,7) em $n - x$.

Problemas

2.3.23 Seja X uma variável aleatória discreta com função de probabilidade $p_X(x) = 2^{-x}$ para $x = 1, 2, 3, \ldots$, com $p_X(x) = 0$ caso contrário.

(a) Seja $Y = X^2$. Qual é a função de probabilidade p_Y de Y?

(b) Seja $Z = X - 1$. Qual é a distribuição de Z? (Identifique a distribuição pelo nome e especifique os valores de todos os parâmetros.)

2.3.24 Sejam $X \sim$ Binomial(n_1, θ) e $Y \sim$ Binomial(n_2, θ), com X e Y escolhidas de forma independente. Seja $Z = X + Y$. Qual será a distribuição de Z? (Explique seu raciocínio.) (Sugestão: veja o fim do Exemplo 2.3.3.)

2.3.25 Sejam $X \sim$ Geométrica(θ) e $Y \sim$ Geométrica(θ), com X e Y escolhidas de forma independente. Seja $Z = X + Y$. Qual será a distribuição de Z? Generalize isso para r moedas. (Explique seu raciocínio.)

2.3.26 Sejam $X \sim$ Geométrica(θ_1) e $Y \sim$ Geométrica(θ_2), com X e Y escolhidas de forma independente. Calcule $P(X \leq Y)$. Explique o que essa probabilidade significa em termos de lançamentos de moedas.

2.3.27 Suponha que $X_n \sim$ Geométrica(λ/n). Calcule $\lim_{n\to\infty} P(X_n \leq n)$.

2.3.28 Sejam $X \sim$ Binomial Negativa(r, θ) e $Y \sim$ Binomial Negativa(s, θ), com X e Y escolhidas de forma independente. Seja $Z = X + Y$. Qual será a distribuição de Z? (Explique seu raciocínio.)

2.3.29 (*Distribuição hipergeométrica generalizada*) Suponha que um conjunto contenha N objetos, M_1 dos quais rotulados com 1, M_2 rotulados com 2 e os restantes rotulados com 3. Suponha que selecionamos uma amostra de $n \leq N$

objetos do conjunto usando amostragem sem reposição[14], como descrito no Exemplo 2.3.7. Determine a probabilidade de obtermos as contagens (f_1, f_2, f_3), em que f_i é o número de objetos rotulados com i na amostra.

2.3.30 Suponha que unidades cheguem a um atendente segundo um processo de Poisson com taxa λ (veja o Exercício 2.3.18). Seja T o tempo até a primeira chegada. Calcule $P(T > t)$.

2.4 Distribuições Contínuas

Na seção anterior, consideramos variáveis aleatórias discretas X para as quais $P(X = x) > 0$ para certos valores de x. No entanto, para algumas variáveis aleatórias X, como uma que tenha a distribuição uniforme, temos $P(X = x) = 0$ para todo x. Isso motiva a definição a seguir.

Definição 2.4.1

Uma variável aleatória X é *contínua* se

$$P(X = x) = 0, \tag{2.4.1}$$

para todo $x \in R^1$.

No original: *sampling without replacement*[14].

Exemplo 2.4.1 — A Distribuição Uniforme$[0,1]$

Considere uma variável aleatória cuja distribuição é a distribuição uniforme em $[0,1]$, como apresentada em (1.2.2). Isto é,

$$P(a \le X \le b) = b - a, \tag{2.4.2}$$

sempre que $0 \le a \le b \le 1$, com $P(X < 0) = P(X > 1) = 0$. Diz-se que a variável aleatória X tem a distribuição Uniforme$[0,1]$; escrevemos isso como $X \sim$ Uniforme$[0,1]$. Por exemplo,

$$P\left(\frac{1}{2} \le X \le \frac{3}{4}\right) = \frac{3}{4} - \frac{1}{2} = \frac{1}{4}.$$

Além disso,

$$P\left(X \ge \frac{2}{3}\right) = P\left(\frac{2}{3} \le X \le 1\right) + P(X > 1)) = \left(1 - \frac{2}{3}\right) + 0 = \frac{1}{3}.$$

* De fato, para qualquer $x \in [0,1]$,

$$P(X \le x) = P(X < 0) + P(0 \le X \le x) = 0 + (x - 0) = x.$$

Observe que, tomando $a = b = x$ em (2.4.2), vemos em particular que $P(X = x) = x - x = 0$ para todo $x \in R^1$. Assim, a distribuição uniforme é um exemplo de distribuição contínua. Na verdade, é um dos exemplos mais importantes! ■

A distribuição Uniforme$[0,1]$ é bastante fácil de manipular. No entanto, em geral, é muito difícil trabalhar com distribuições contínuas. Como $P(X = x) = 0$ para todo x, não podemos simplesmente somar probabilidades, como fazemos com variáveis aleatórias discretas. Então, como podemos controlar todas as probabilidades?

Uma solução possível é sugerida reescrevendo (2.4.2) da seguinte forma. Para $x \in R^1$, seja

$$f(x) = \begin{cases} 1 & 0 \le x \le 1 \\ 0 & \text{caso contrário.} \end{cases} \tag{2.4.3}$$

Então (2.4.2) pode ser reescrita como

$$P(a \le X \le b) = \int_a^b f(x)\,dx, \tag{2.4.4}$$

sempre que $a \le b$.

*Nota do tradutor. o original traz um parêntese a mais em "$P(X > 1))$"

Pode-se questionar se é sensato converter a equação simples (2.4.2) na complicada equação integral (2.4.4). No entanto, a vantagem de (2.4.4) é que, modificando a função f, podemos obter muitas outras distribuições contínuas além da distribuição uniforme. Para explorar isso, fazemos as definições a seguir.

Definição 2.4.2

Seja $f : R^1 \to R^1$ uma função. Então f é uma *função densidade* se $f(x) \geq 0$ para todo $x \in R^1$ e $\int_{-\infty}^{\infty} f(x)\,dx = 1$.

Definição 2.4.3

Uma variável aleatória X é *absolutamente contínua* se existe uma função densidade f tal que

$$P(a \leq X \leq b) = \int_a^b f(x)\,dx, \tag{2.4.5}$$

sempre que $a \leq b$, como em (2.4.4).

Em particular, se $b = a + \delta$, com δ um número positivo pequeno, e se f é contínua em a, então vemos que

$$P(a \leq X \leq a + \delta) = \int_a^{a+\delta} f(x)\,dx \approx \delta\, f(a).$$

Assim, uma função densidade[15] avaliada em a pode ser vista como uma medida da probabilidade de uma variável aleatória estar num pequeno intervalo em torno de a.

Para entender melhor as variáveis aleatórias absolutamente contínuas, observamos o teorema a seguir.

Teorema 2.4.1

Seja X uma variável aleatória absolutamente contínua. Então X é uma variável aleatória contínua, isto é, $P(X = a) = 0$ para todo $a \in R^1$.

Demonstração. Seja a um número real qualquer. Então $P(X = a) = P(a \leq X \leq a)$. Por outro lado, tomando $a = b$ em (2.4.5), vemos que $P(a \leq X \leq a) = \int_a^a f(x)\,dx = 0$. Portanto, $P(X = a) = 0$ para todo a, como queríamos. ■

No original: *density function*[15].

Acontece que a recíproca[16] do Teorema 2.4.1 é falsa. Isto é, nem toda distribuição contínua é absolutamente contínua[17].* No entanto, a maioria das distribuições contínuas que surgem em estatística é absolutamente contínua. Além disso, é muito mais fácil trabalhar com distribuições absolutamente contínuas do que com outros tipos de distribuições contínuas. Por isso, restringimos aqui nossa discussão às distribuições absolutamente contínuas. Na verdade, os estatísticos às vezes dizem que X é *contínua* como forma abreviada de dizer que X é absolutamente contínua.

2.4.1 Distribuições Absolutamente Contínuas Importantes

Certas distribuições absolutamente contínuas são tão importantes que as listamos aqui.

Exemplo 2.4.2 — A Distribuição Uniforme$[0, 1]$

Evidentemente, a distribuição uniforme é absolutamente contínua, com a função densidade dada por (2.4.3). Veremos, na Seção 2.10, que a distribuição Uniforme$[0, 1]$ tem uma relação importante com toda distribuição absolutamente contínua. ■

*Para exemplos disso, veja livros de probabilidade mais avançados, por exemplo, a página 143 de *A First Look at Rigorous Probability Theory*, segunda edição, de J. S. Rosenthal (World Scientific Publishing, Singapura, 2006).

No original: *converse*[16], *absolutely continuous*[17].

Exemplo 2.4.3 — A Distribuição Uniforme$[L, R]$

Sejam L e R dois números reais quaisquer com $L < R$. Considere uma variável aleatória X tal que

$$P(a \leq X \leq b) = \frac{b-a}{R-L} \tag{2.4.6}$$

sempre que $L \leq a \leq b \leq R$, com $P(X < L) = P(X > R) = 0$. Diz-se que a variável aleatória X tem a distribuição Uniforme$[L, R]$; escrevemos isso como $X \sim$ Uniforme$[L, R]$. (Se $L = 0$ e $R = 1$, essa definição coincide com a definição anterior da distribuição Uniforme$[0, 1]$.) Observe que $X \sim$ Uniforme$[L, R]$ tem a mesma probabilidade de estar em quaisquer dois subintervalos de $[L, R]$ que tenham o mesmo comprimento.

Observe que a distribuição Uniforme$[L, R]$ também é absolutamente contínua, com densidade dada por

$$f(x) = \begin{cases} \dfrac{1}{R-L} & L \leq x \leq R \\ 0 & \text{caso contrário.} \end{cases}$$

Na Figura 2.4.1, traçamos o gráfico de uma densidade Uniforme$[2, 4]$. ■

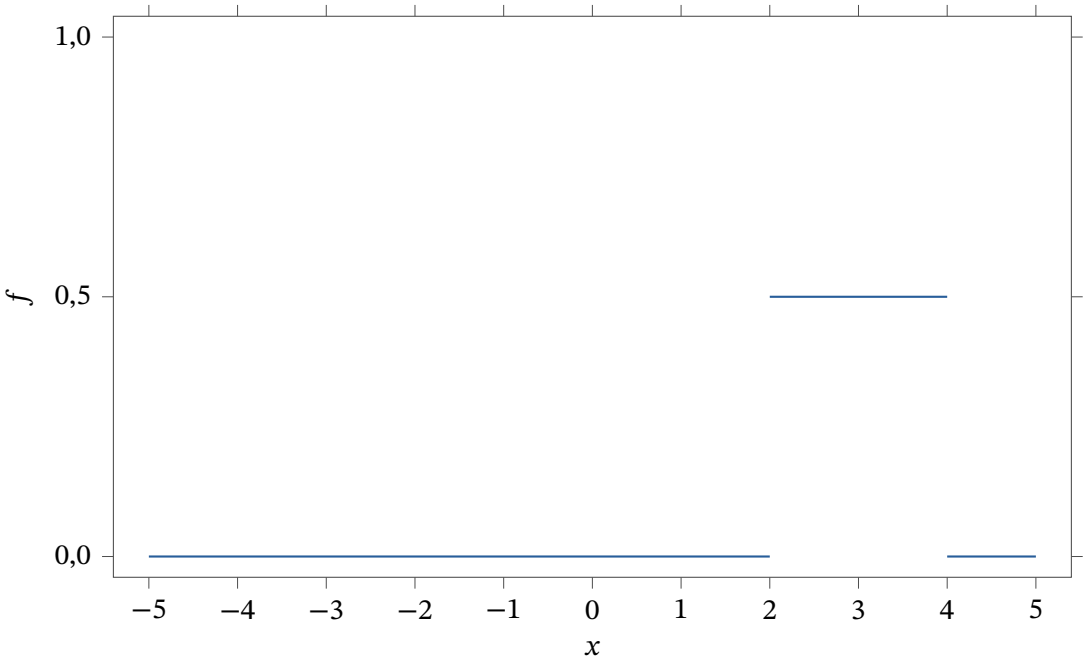


Figura 2.4.1: Uma função densidade Uniforme$[2, 4]$.

Exemplo 2.4.4 — A Distribuição Exponencial(1)

Defina uma função $f : R^1 \to R^1$ por

$$f(x) = \begin{cases} e^{-x} & x \geq 0 \\ 0 & x < 0. \end{cases}$$

Então, evidentemente, $f(x) \geq 0$ para todo x. Além disso,

$$\int_{-\infty}^{\infty} f(x)\,dx = \int_{0}^{\infty} e^{-x}\,dx = -e^{-x}\Big|_0^{\infty} = (-0) - (-1) = 1.$$

Portanto, f é uma função densidade. Veja a Figura 2.4.2 para um gráfico dessa densidade.

Considere agora uma variável aleatória X com essa função densidade f. Se $0 \leq a \leq b < \infty$, então

$$P(a \leq X \leq b) = \int_a^b f(x)\,dx = \int_a^b e^{-x}\,dx = (-e^{-b}) - (-e^{-a}) = e^{-a} - e^{-b}.$$

Diz-se que a variável aleatória X tem a distribuição Exponencial(1), o que escrevemos como $X \sim$ Exponencial(1). A distribuição exponencial tem muitas propriedades importantes, que exploraremos nas próximas seções. ■

Exemplo 2.4.5 — A Distribuição Exponencial(λ)

Seja $\lambda > 0$ uma constante fixa. Defina uma função $f : R^1 \to R^1$ por

$$f(x) = \begin{cases} \lambda\, e^{-\lambda x} & x \geq 0 \\ 0 & x < 0. \end{cases}$$

Então, evidentemente, $f(x) \geq 0$ para todo x. Além disso,

$$\int_{-\infty}^{\infty} f(x)\,dx = \int_{0}^{\infty} \lambda e^{-\lambda x}\,dx = -e^{-\lambda x}\Big|_0^{\infty} = (-0) - (-1) = 1.$$

Portanto, f é novamente uma função densidade. (Se $\lambda = 1$, isso corresponde à densidade Exponencial(1).)

Se X é uma variável aleatória com essa função densidade f, então

$$P(a \leq X \leq b) = \int_a^b \lambda\, e^{-\lambda x}\,dx = (-e^{-\lambda b}) - (-e^{-\lambda a}) = e^{-\lambda a} - e^{-\lambda b}$$

para $0 \leq a \leq b < \infty$. Diz-se que a variável aleatória X tem a distribuição Exponencial(λ); escrevemos isso como $X \sim$ Exponencial(λ). Observe que alguns livros e pacotes de software substituem λ por $1/\lambda$ na definição da distribuição Exponencial(λ) — sempre verifique isso ao usar outro livro ou um software.

Uma distribuição exponencial pode ser usada muitas vezes para modelar tempos de vida. Por exemplo, certo tipo de lâmpada produzido por um fabricante poderia seguir uma distribuição Exponencial(λ), para uma escolha adequada de λ. Com isso queremos dizer que o tempo de vida X de uma lâmpada selecionada ao acaso entre as produzidas por esse fabricante tem probabilidade

$$P(X \geq x) = \int_x^\infty \lambda e^{-\lambda z}\, dz = e^{-\lambda x}$$

de durar mais do que x, em quaisquer unidades de tempo que estejam sendo usadas. Veremos no Capítulo 3 que, numa aplicação específica, o valor $1/\lambda$ corresponde ao tempo de vida médio das lâmpadas.

Como outra aplicação dessa distribuição, considere uma situação que envolve um atendente, por exemplo, um caixa de uma lanchonete de fast-food, um caixa eletrônico, uma central telefônica etc. Unidades chegam para atendimento de forma aleatória e formam uma fila quando o atendente está ocupado. Muitas vezes o número de chegadas ao atendente, num intervalo de tempo específico t, pode ser modelado por uma distribuição Poisson(λt). Seja agora T_1 o tempo até a primeira chegada. Então temos

$$P(T_1 > t) = P(\text{nenhuma chegada em } (0, t]) = \frac{(\lambda t)^0}{0!} e^{-\lambda t} = e^{-\lambda t}$$

e T_1 tem densidade dada por

$$f(t) = -\frac{d}{dt} \int_t^\infty f(z)\, dz = -\frac{d}{dt} P(T_1 > t) = \lambda e^{-\lambda t}.$$

Logo, $T_1 \sim$ Exponencial(λ). ■

Exemplo 2.4.6 — A Distribuição Gama(α, λ)

A *função gama* é definida por

$$\Gamma(\alpha) = \int_0^\infty t^{\alpha-1} e^{-t}\, dt, \qquad \alpha > 0.$$

Acontece (veja o Problema 2.4.15) que

$$\Gamma(\alpha + 1) = \alpha\, \Gamma(\alpha) \tag{2.4.7}$$

e que, se n é um inteiro positivo, então $\Gamma(n) = (n-1)!$, enquanto $\Gamma(1/2) = \sqrt{\pi}$.

Podemos usar a função gama para definir a densidade da distribuição Gama(α, λ), da seguinte forma. Sejam $\alpha > 0$ e $\lambda > 0$, e defina uma função f por

$$f(x) = \frac{\lambda^\alpha x^{\alpha-1}}{\Gamma(\alpha)} e^{-\lambda x} \tag{2.4.8}$$

quando $x > 0$, com $f(x) = 0$ para $x \leq 0$. Então, evidentemente, $f \geq 0$. Além disso, não é difícil verificar (veja o Problema 2.4.17) que $\int_0^\infty f(x)\, dx = 1$. Portanto, f é uma função densidade.

Diz-se que uma variável aleatória X com função densidade f dada por (2.4.8) tem a distribuição Gama(α, λ); escrevemos isso como $X \sim$ Gama(α, λ). Observe que alguns livros e pacotes de software substituem λ por $1/\lambda$ na definição da distribuição Gama(α, λ) — sempre verifique isso ao usar outro livro ou um software.

O caso $\alpha = 1$ corresponde (porque $\Gamma(1) = 0! = 1$) à distribuição Exponencial(λ): Gama$(1, \lambda) =$ Exponencial(λ). Na Figura 2.4.2, traçamos os gráficos de várias funções densidade Gama(α, λ).

Uma distribuição gama também pode ser usada para modelar tempos de vida. Como mostra a Figura 2.4.2, a família gama oferece uma variedade de formas para escolher muito maior do que a família exponencial. ■

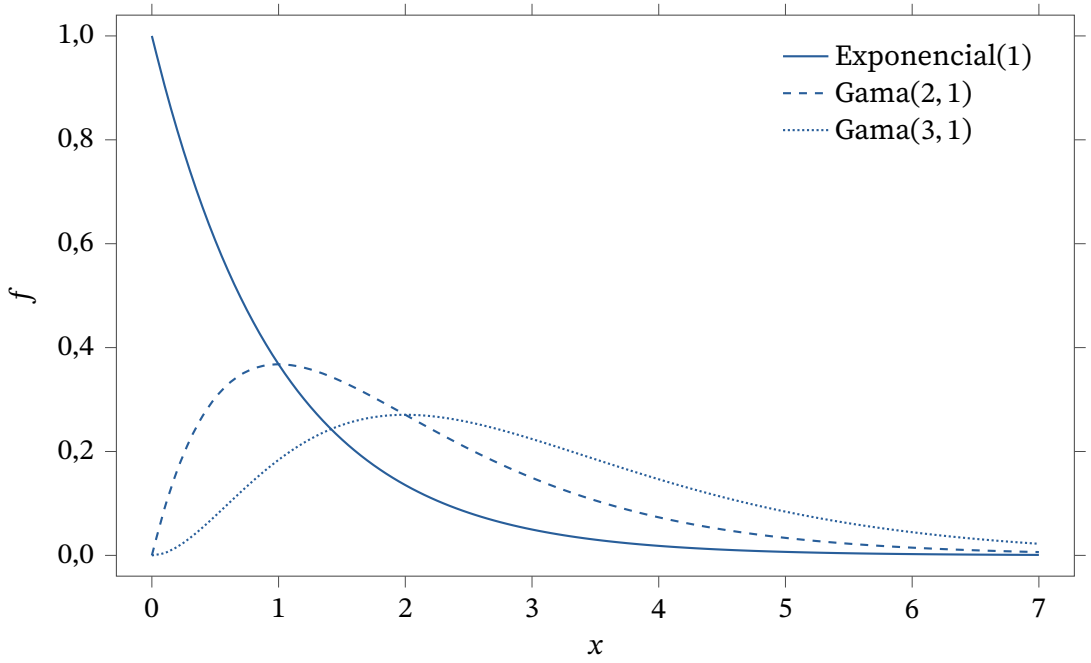


Figura 2.4.2: Gráfico de uma densidade Exponencial(1) (linha cheia), de uma Gama(2, 1) (linha tracejada) e de uma Gama(3, 1) (linha pontilhada).

Definimos agora uma função $\phi : R^1 \to R^1$ por

$$\phi(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}. \tag{2.4.9}$$

Essa função ϕ é a famosa "curva em forma de sino", pois seu gráfico tem a forma de um sino, como mostra a Figura 2.4.3.

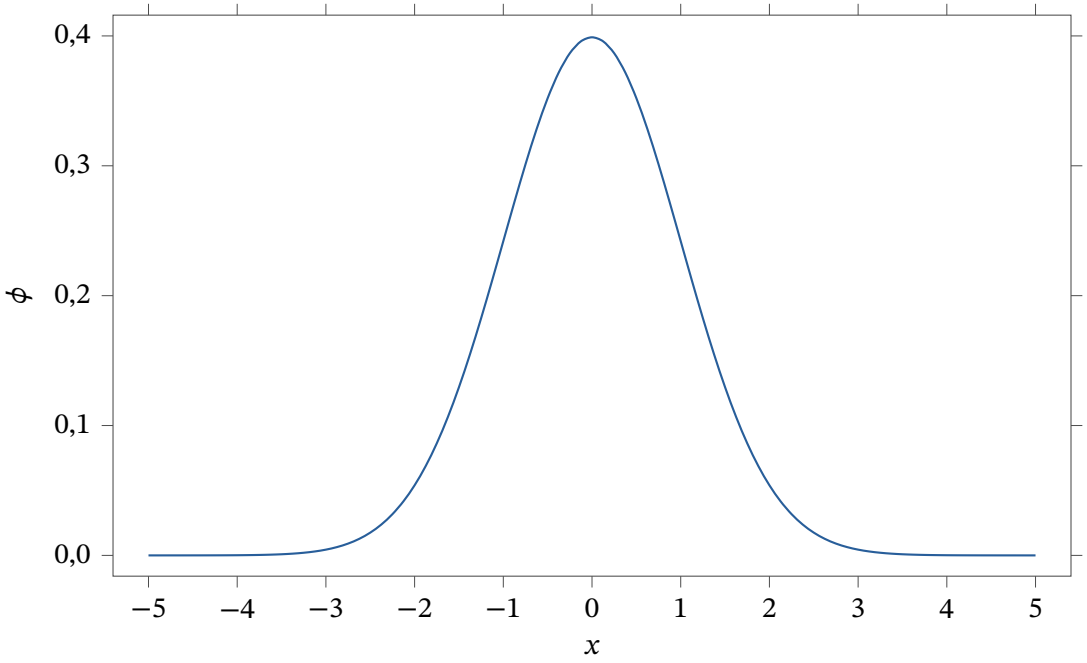


Figura 2.4.3: Gráfico da função ϕ em (2.4.9).

Temos o seguinte resultado para ϕ.

Teorema 2.4.2

A função ϕ dada por (2.4.9) é uma função densidade.

Demonstração. Veja a Seção 2.11 para a demonstração deste resultado. ■

Isso leva às seguintes distribuições importantes.

Exemplo 2.4.7 — A Distribuição $N(0,1)$

Seja X uma variável aleatória com a função densidade ϕ dada por (2.4.9). Isso significa que, para $-\infty < a \leq b < \infty$,

$$P(a \leq X \leq b) = \int_a^b \phi(x)\,dx = \int_a^b \frac{1}{\sqrt{2\pi}} e^{-x^2/2}\,dx.$$

Diz-se que a variável aleatória X tem a distribuição $N(0,1)$ (ou a *distribuição normal padrão*); escrevemos isso como $X \sim N(0,1)$. ■

Exemplo 2.4.8 — A Distribuição $N(\mu, \sigma^2)$

Sejam $\mu \in R^1$ e $\sigma > 0$. Seja f a função definida por

$$f(x) = \frac{1}{\sigma}\phi\left(\frac{x-\mu}{\sigma}\right) = \frac{1}{\sigma\sqrt{2\pi}}e^{-(x-\mu)^2/2\sigma^2}.$$

(Se $\mu = 0$ e $\sigma = 1$, isso corresponde ao exemplo anterior.) Evidentemente, $f \geq 0$. Além disso, fazendo $y = (x-\mu)/\sigma$, temos

$$\begin{aligned}\int_{-\infty}^{\infty} f(x)\,dx &= \int_{-\infty}^{\infty} \sigma^{-1}\phi((x-\mu)/\sigma)\,dx \\ &= \int_{-\infty}^{\infty} \sigma^{-1}\phi(y)\sigma\,dy = \int_{-\infty}^{\infty} \phi(y)\,dy = 1.\end{aligned}$$

Portanto, f é uma função densidade.

Seja X uma variável aleatória com essa função densidade f. Diz-se que a variável aleatória X tem a distribuição $N(\mu, \sigma^2)$; escrevemos isso como $X \sim N(\mu, \sigma^2)$. Na Figura 2.4.4, traçamos os gráficos das densidades $N(0, 1)$ e $N(1, 1)$. Observe que mudanças em μ simplesmente deslocam a densidade, sem mudar sua forma. Na Figura 2.4.5, traçamos os gráficos das densidades $N(0, 1)$ e $N(0, 4)$. Observe que as duas densidades estão centradas em 0, mas a densidade $N(0, 4)$ é muito mais espalhada. O valor de σ^2 controla o grau de dispersão.

A distribuição $N(\mu, \sigma^2)$, para alguma escolha de μ e σ^2, aparece com bastante frequência nas aplicações. Parte da razão para isso é um resultado importante conhecido como teorema central do limite, que discutiremos na Seção 4.4. Em particular, esse resultado leva ao uso de uma distribuição normal para aproximar outras distribuições, assim como usamos a distribuição de Poisson para aproximar a distribuição binomial no Exemplo 2.3.6.

Numa população humana grande, não é incomum que várias medidas corporais tenham distribuição normal (pelo menos com um grau razoável de aproximação). Por exemplo, suponhamos que as alturas (medidas em pés) dos estudantes de certa universidade tenham distribuição $N(\mu, \sigma^2)$ para alguma escolha de μ e σ^2. Então a probabilidade de que um estudante selecionado ao acaso tenha altura entre a e b pés, com $a < b$, é dada por

$$\int_a^b \frac{1}{\sigma\sqrt{2\pi}}e^{-(x-\mu)^2/2\sigma^2}\,dx.$$

Na Seção 2.5, discutiremos como calcular uma integral como essa. Mais adiante neste texto, discutiremos como escolher um valor adequado

para μ e σ^2 e como avaliar se alguma distribuição normal é adequada para modelar a distribuição de uma variável definida numa população específica. ■

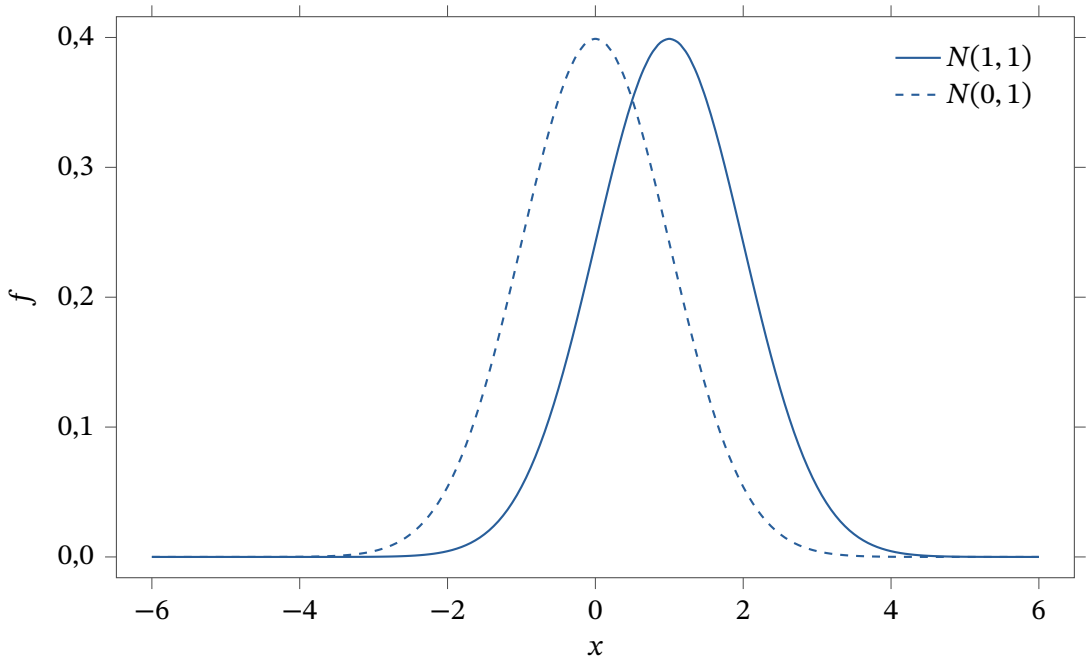


Figura 2.4.4: Gráfico da densidade $N(1,1)$ (linha cheia) e da densidade $N(0,1)$ (linha tracejada).

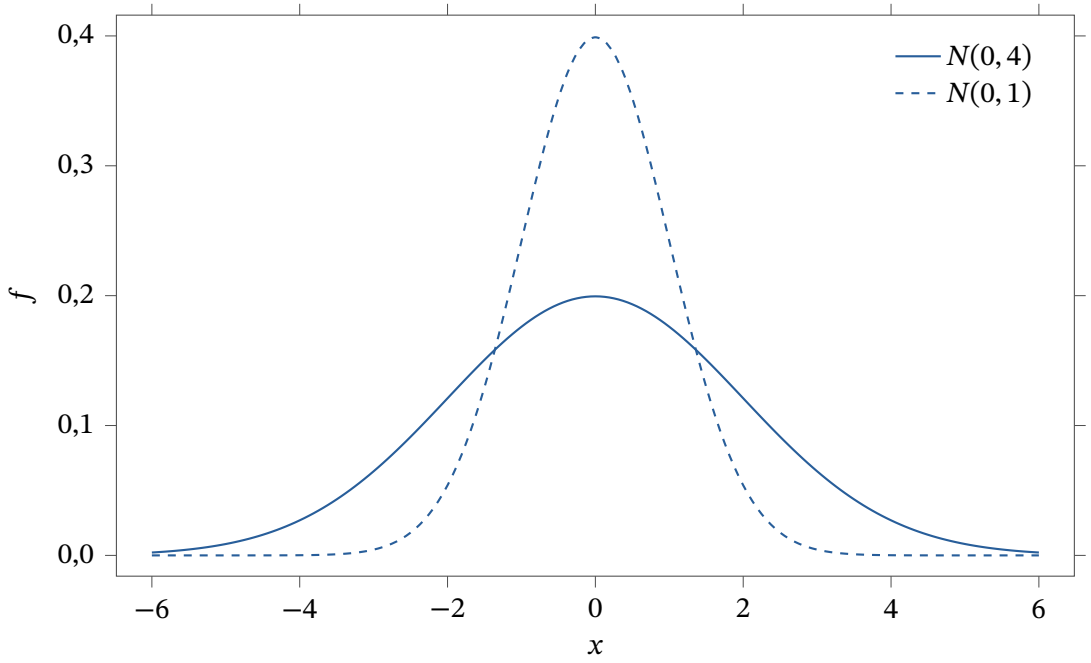


Figura 2.4.5: Gráfico de uma densidade $N(0,4)$ (linha cheia) e de uma densidade $N(0,1)$ (linha tracejada).

Dada uma variável aleatória absolutamente contínua X, escreveremos sua densidade como f_X, ou como f se não houver confusão. Variáveis aleatórias absolutamente contínuas serão usadas extensamente nos capítulos seguintes deste livro.

Observação 2.4.1 Por fim, observamos que funções densidade não são únicas. De fato, se f é uma função densidade e mudamos seu valor num número finito de pontos, então o valor de $\int_a^b f(x)\,dx$ continua inalterado. Portanto, a função modificada também serve como densidade correspondente à mesma distribuição. Por outro lado, muitas vezes uma escolha "melhor" particular de função densidade é clara. Por exemplo, se a função densidade pode ser escolhida contínua, ou mesmo contínua por partes[18], então essa escolha é preferível a alguma outra versão da função densidade.

Para dar um exemplo específico, para a distribuição Uniforme$[0,1]$, poderíamos substituir a densidade f de (2.4.3) por

$$g(x) = \begin{cases} 1 & 0 < x < 1 \\ 0 & \text{caso contrário,} \end{cases}$$

No original: *piecewise continuous*[18].

ou até por

$$h(x) = \begin{cases} 1 & 0 < x < 3/4 \\ 17 & x = 3/4 \\ 1 & 3/4 < x < 1 \\ 0 & \text{caso contrário.} \end{cases}$$

Qualquer uma dessas novas densidades definiria novamente a distribuição Uniforme$[0, 1]$, porque teríamos $\int_a^b f(x)\,dx = \int_a^b g(x)\,dx = \int_a^b h(x)\,dx$ para quaisquer $a < b$.

Por outro lado, as densidades f e g são ambas contínuas por partes e, portanto, são escolhas naturais para a função densidade, enquanto h é uma escolha desnecessariamente complicada. Por isso, ao lidar com funções densidade, sempre suporemos que elas são tão contínuas quanto possível, como f e g, em vez de terem descontinuidades removíveis como h. Isso será particularmente importante quando discutirmos os métodos de verossimilhança[19] no Capítulo 6. ■

Resumo da Seção 2.4

- Uma variável aleatória X é contínua se $P(X = x) = 0$ para todo x, isto é, se nenhuma parte de sua probabilidade vem de ser igual a valores particulares.
- X é absolutamente contínua se existe uma função densidade f_X com $P(a \leq X \leq b) = \int_a^b f_X(x)\,dx$ para todos $a < b$.
- Distribuições absolutamente contínuas importantes incluem a uniforme, a exponencial, a gama e a normal.

Exercícios

2.4.1 Seja $U \sim$ Uniforme$[0, 1]$. Calcule cada uma das probabilidades a seguir.

(a) $P(U \leq 0)$

(b) $P(U = 1/2)$

(c) $P(U < -1/3)$

(d) $P(U \leq 2/3)$

No original: *likelihood*[19].

(e) $P(U < 2/3)$

(f) $P(U < 1)$

(g) $P(U \leq 17)$

2.4.2 Seja $W \sim$ Uniforme$[1, 4]$. Calcule cada uma das probabilidades a seguir.

(a) $P(W \geq 5)$

(b) $P(W \geq 2)$

(c) $P(W^2 \leq 9)$ (Sugestão: se $W^2 \leq 9$, como W tem de ser?)

(d) $P(W^2 \leq 2)$

2.4.3 Seja $Z \sim$ Exponencial(4). Calcule cada uma das probabilidades a seguir.

(a) $P(Z \geq 5)$

(b) $P(Z \geq -5)$

(c) $P(Z^2 \geq 9)$

(d) $P(Z^4 - 17 \geq 9)$

2.4.4 Determine para quais constantes c as funções a seguir são densidades.

(a) $f(x) = cx$ em $(0, 1)$ e 0 caso contrário.

(b) $f(x) = cx^n$ em $(0, 1)$ e 0 caso contrário, para n um inteiro não negativo[20].

(c) $f(x) = cx^{1/2}$ em $(0, 2)$ e 0 caso contrário.

(d) $f(x) = c \sin x$ em $(0, \pi/2)$ e 0 caso contrário.

2.4.5 A função definida por $f(x) = x/3$ para $-1 < x < 2$ e 0 caso contrário é uma densidade? Por quê?

2.4.6 Seja $X \sim$ Exponencial(3). Calcule cada uma das probabilidades a seguir.

(a) $P(0 < X < 1)$

(b) $P(0 < X < 3)$

(c) $P(0 < X < 5)$

(d) $P(2 < X < 5)$

(e) $P(2 < X < 10)$

(f) $P(X > 2)$

No original: *nonnegative*[20].

2.4.7 Seja $M > 0$ e suponha que $f(x) = cx^2$ para $0 < x < M$, e $f(x) = 0$ caso contrário. Para que valor de c (dependendo de M) f é uma densidade?

2.4.8 Suponha que X tenha densidade f e que $f(x) \geq 2$ para $0{,}3 < x < 0{,}4$. Prove que $P(0{,}3 < X < 0{,}4) \geq 0{,}2$.

2.4.9 Suponha que X tenha densidade f e Y tenha densidade g. Suponha que $f(x) > g(x)$ para $1 < x < 2$. Prove que $P(1 < X < 2) > P(1 < Y < 2)$.

2.4.10 Suponha que X tenha densidade f e Y tenha densidade g. É possível que $f(x) > g(x)$ para todo x? Explique.

2.4.11 Suponha que X tenha densidade f e que $f(x) > f(y)$ sempre que $0 < x < 1 < y < 2$. Segue-se que $P(0 < X < 1) > P(1 < X < 2)$? Explique.

2.4.12 Suponha que X tenha densidade f e que $f(x) > f(y)$ sempre que $0 < x < 1 < y < 3$. Segue-se que $P(0 < X < 1) > P(1 < X < 3)$? Explique.

2.4.13 Suponha que $X \sim N(0,1)$ e $Y \sim N(1,1)$. Prove que $P(X < 3) > P(Y < 3)$.

Problemas

2.4.14 Seja $Y \sim$ Exponencial(λ) para algum $\lambda > 0$. Sejam $y, h \geq 0$. Prove que $P(Y - h \geq y \mid Y \geq h) = P(Y \geq y)$. Isto é, condicionalmente a saber que $Y \geq h$, a variável aleatória $Y - h$ tem a mesma distribuição que Y tinha originalmente. Essa é a chamada propriedade de *falta de memória* das distribuições exponenciais; ela diz que elas "esquecem" imediatamente seu comportamento passado.

2.4.15 Considere a função gama[21] $\Gamma(\alpha) = \int_0^\infty t^{\alpha-1}e^{-t}\,dt$, para $\alpha > 0$.

(a) Prove que $\Gamma(\alpha + 1) = \alpha\,\Gamma(\alpha)$. (Sugestão: use integração por partes[22].)

(b) Prove que $\Gamma(1) = 1$.

(c) Use os itens (a) e (b) para mostrar que $\Gamma(n) = (n-1)!$ se n é um inteiro positivo.

2.4.16 Use o fato de que $\Gamma(1/2) = \sqrt{\pi}$ para dar uma demonstração alternativa de que $\int_{-\infty}^{\infty} \phi(x)\,dx = 1$ (como no Teorema 2.4.2). (Sugestão: faça a substituição $t = x^2/2$.)

No original: *gamma function*[21], *integration by parts*[22].

2.4.17 Seja f a densidade da distribuição Gama(α, λ), como em (2.4.8). Prove que $\int_0^\infty f(x)\,dx = 1$. (Sugestão: tome $t = \lambda x$.)

2.4.18 (*Distribuição logística*[23]) Considere a função dada por $f(x) = e^{-x}(1 + e^{-x})^{-2}$ para $-\infty < x < \infty$. Prove que f é uma função densidade.

2.4.19 (*Distribuição Weibull*(α)) Considere, para $\alpha > 0$ fixo, a função dada por $f(x) = \alpha x^{\alpha-1} e^{-x^\alpha}$ para $0 < x < \infty$ e 0 caso contrário. Prove que f é uma função densidade.

2.4.20 (*Distribuição Pareto*(α)) Considere, para $\alpha > 0$ fixo, a função dada por $f(x) = \alpha(1 + x)^{-\alpha-1}$ para $0 < x < \infty$ e 0 caso contrário. Prove que f é uma função densidade.

2.4.21 (*Distribuição de Cauchy*[24]) Considere a função dada por

$$f(x) = \frac{1}{\pi}\frac{1}{1 + x^2}$$

para $-\infty < x < \infty$. Prove que f é uma função densidade. (Sugestão: lembre-se da derivada de $\arctan(x)$.)

2.4.22 (*Distribuição de Laplace*[25]) Considere a função dada por $f(x) = e^{-|x|}/2$ para $-\infty < x < \infty$ e 0 caso contrário. Prove que f é uma função densidade.

2.4.23 (*Distribuição de valor extremo*[26]) Considere a função dada por $f(x) = e^{-x}\exp\{-e^{-x}\}$ para $-\infty < x < \infty$ e 0 caso contrário. Prove que f é uma função densidade.

2.4.24 (*Distribuição Beta*(a, b)) A *função beta*[27] é a função $B : (0, \infty)^2 \to R^1$ dada por

$$B(a, b) = \int_0^1 x^{a-1}(1 - x)^{b-1}\,dx.$$

Pode-se provar (veja o Desafio 2.4.25) que

$$B(a, b) = \frac{\Gamma(a)\,\Gamma(b)}{\Gamma(a + b)} \tag{2.4.10}$$

(a) Prove que a função f dada por $f(x) = B^{-1}(a, b)\,x^{a-1}(1 - x)^{b-1}$, para $0 < x < 1$, e 0 caso contrário, é uma função densidade.

(b) Determine e trace o gráfico da densidade quando $a = 1$, $b = 1$. Você sabe o nome dessa distribuição?

No original: *logistic*[23], *Cauchy*[24], *Laplace distribution*[25], *extreme value*[26], *beta function*[27].

(c) Determine e trace o gráfico da densidade quando $a = 2$, $b = 1$.

(d) Determine e trace o gráfico da densidade quando $a = 1$, $b = 2$.

(e) Determine e trace o gráfico da densidade quando $a = 2$, $b = 2$.

Desafios

2.4.25 Prove (2.4.10). (Sugestão: use $\Gamma(a)\,\Gamma(b) = \int_0^\infty \int_0^\infty x^{a-1}y^{b-1}e^{-x-y}\,dx\,dy$ e faça a mudança de variável[28] $u = x + y$, $v = x/u$.)

Tópicos para discussão

2.4.26 Suponha que $X \sim N(0,1)$ e $Y \sim N(0,4)$. Qual você acha que é maior, $P(X > 2)$ ou $P(Y > 2)$? Por quê? (Sugestão: veja a Figura 2.4.5.)

2.5 Funções de Distribuição Acumulada

Se X é uma variável aleatória, então sua distribuição consiste nos valores de $P(X \in B)$ para todos os subconjuntos B dos números reais. No entanto, há certos subconjuntos especiais B com os quais é conveniente trabalhar. Especificamente, se $B = (-\infty, x]$ para algum número real x, então $P(X \in B) = P(X \leq x)$. Acontece (ver Teorema 2.5.1) que basta acompanhar $P(X \leq x)$ para todos os números reais x.

Isso motiva a definição a seguir.

Definição 2.5.1

Dada uma variável aleatória X, sua *função de distribuição acumulada* (ou *função de distribuição*, ou *fda*, para abreviar) é a função $F_X : R^1 \to [0,1]$ definida por $F_X(x) = P(X \leq x)$. (Quando não há risco de confusão, às vezes escrevemos $F(x)$ em vez de $F_X(x)$.)

A razão de chamar F_X de "função de distribuição" é que a distribuição completa de X pode ser determinada diretamente a partir de F_X. Mostramos isso para alguns eventos de importância especial.

No original: *change of variable*[28].

Primeiro, suponha que $B = (a, b]$ seja um intervalo aberto à esquerda. Usando (1.3.3),

$$P(X \in B) = P(a < X \leq b) = P(X \leq b) - P(X \leq a) = F_X(b) - F_X(a).$$

Agora, suponha que $B = [a, b]$ seja um intervalo fechado. Usando a continuidade da probabilidade (ver Teorema 1.6.1), temos

$$\begin{aligned} P(X \in B) = P(a \leq X \leq b) &= \lim_{n\to\infty} P(a - 1/n < X \leq b) \\ &= \lim_{n\to\infty} \big(F_X(b) - F_X(a - 1/n)\big) = F_X(b) - \lim_{n\to\infty} F_X(a - 1/n). \end{aligned}$$

Às vezes escrevemos $\lim_{n\to\infty} F_X(a - 1/n)$ como $F_X(a^-)$, de modo que $P(X \in [a, b]) = F_X(b) - F_X(a^-)$. No caso particular em que $a = b$, temos

$$P(X = a) = F_X(a) - F_X(a^-). \tag{2.5.1}$$

Da mesma forma, se $B = (a, b)$ é um intervalo aberto, então

$$P(X \in B) = P(a < X < b) = \lim_{n\to\infty} F_X(b - 1/n) - F_X(a) = F_X(b^-) - F_X(a).$$

Se $B = [a, b)$ é um intervalo aberto à direita, então

$$\begin{aligned} P(X \in B) = P(a \leq X < b) &= \lim_{n\to\infty} F_X(b - 1/n) - \lim_{n\to\infty} F_X(a - 1/n) \\ &= F_X(b^-) - F_X(a^-). \end{aligned}$$

Concluímos que podemos determinar $P(X \in B)$ a partir de F_X sempre que B for qualquer tipo de intervalo.

Agora, se B for, em vez disso, uma *união* de intervalos, então podemos usar a aditividade para, de novo, calcular $P(X \in B)$ a partir de F_X. Por exemplo, se

$$B = (a_1, b_1] \cup (a_2, b_2] \cup \cdots \cup (a_k, b_k],$$

com $a_1 < b_1 < a_2 < b_2 < \cdots < a_k < b_k$, então, pela aditividade,

$$\begin{aligned} P(X \in B) &= P(X \in (a_1, b_1]) + \cdots + P(X \in (a_k, b_k]) \\ &= F_X(b_1) - F_X(a_1) + \cdots + F_X(b_k) - F_X(a_k). \end{aligned}$$

Portanto, ainda podemos calcular $P(X \in B)$ apenas a partir dos valores de $F_X(x)$.

Teorema 2.5.1

Seja X uma variável aleatória qualquer, com função de distribuição acumulada F_X. Seja B um subconjunto qualquer dos números reais. Então $P(X \in B)$ pode ser determinada apenas a partir dos valores de $F_X(x)$.

Demonstração. (Esboço) Acontece que todos os subconjuntos B relevantes podem ser obtidos aplicando operações de limite a uniões de intervalos. Portanto, como F_X determina $P(X \in B)$ quando B é uma união de intervalos, segue que F_X determina $P(X \in B)$ para todos os subconjuntos B relevantes. ■

2.5.1 Propriedades das Funções de Distribuição

À luz do Teorema 2.5.1, vemos que as funções de distribuição acumulada F_X são muito úteis. Assim, registramos aqui algumas de suas propriedades básicas.

Teorema 2.5.2

Seja F_X a função de distribuição acumulada de uma variável aleatória X. Então

(a) $0 \leq F_X(x) \leq 1$ para todo x,

(b) $F_X(x) \leq F_X(y)$ sempre que $x \leq y$ (isto é, F_X é crescente),

(c) $\lim_{x \to +\infty} F_X(x) = 1$,

(d) $\lim_{x \to -\infty} F_X(x) = 0$.

Demonstração.

(a) Como $F_X(x) = P(X \leq x)$ é uma probabilidade, está entre 0 e 1.

(b) Sejam $A = \{X \leq x\}$ e $B = \{X \leq y\}$. Então, se $x \leq y$, temos $A \subseteq B$, de modo que $P(A) \leq P(B)$. Mas $P(A) = F_X(x)$ e $P(B) = F_X(y)$, e o resultado segue.

(c) Seja $A_n = \{X \leq n\}$. Como X tem de assumir *algum* valor e, portanto, $X \leq n$ para n suficientemente grande, vemos que $\{A_n\}$ cresce para S, isto é, $\{A_n\} \nearrow S$ (ver Seção 1.6). Portanto, pela continuidade de P (ver Teorema 1.6.1), $\lim_{n \to \infty} P(A_n) = P(S) = 1$. Mas $P(A_n) = P(X \leq n) = F_X(n)$, e o resultado segue.

(d) Seja $B_n = \{X \leq -n\}$. Como $X \geq -n$ para n suficientemente grande, $\{B_n\}$ decresce para o conjunto vazio, isto é, $\{B_n\} \searrow \varnothing$. Portanto, de novo pela continuidade de P, $\lim_{n \to \infty} P(B_n) = P(\varnothing) = 0$. Mas $P(B_n) = P(X \leq -n) = F_X(-n)$, e o resultado segue. ■

Se F_X é uma função de distribuição acumulada[29], então F_X também é *contínua à direita*[30]; ver Problema 2.5.17. Acontece que, se uma função $F : R^1 \to R^1$ satisfaz as propriedades (a) a (d) e é contínua à direita, então existe uma única medida de probabilidade P em R^1 tal que F é a fda de P. Não demonstraremos esse resultado aqui.*

2.5.2 Fdas de Distribuições Discretas

Podemos calcular a função de distribuição acumulada (fda) F_X de uma variável aleatória discreta a partir de sua função de probabilidade p_X, como segue.

Teorema 2.5.3

Seja X uma variável aleatória discreta com função de probabilidade p_X. Então sua função de distribuição acumulada F_X satisfaz $F_X(x) = \sum_{y \le x} p_X(y)$.

Demonstração. Sejam $x_1, x_2, \ldots$ os valores possíveis de X. Então $F_X(x) = P(X \le x) = \sum_{x_i \le x} P(X = x_i) = \sum_{y \le x} P(X = y) = \sum_{y \le x} p_X(y)$, como afirmado. ■

Portanto, se X é uma variável aleatória discreta, então, pelo Teorema 2.5.3, F_X é constante por partes[31], com um salto de tamanho $p_X(x_i)$ em cada valor x_i. O gráfico de uma distribuição assim tem a aparência do que está representado na Figura 2.5.1.

Vejamos um exemplo de função de distribuição de uma variável aleatória discreta.

*Por exemplo, ver a página 67 de *A First Look at Rigorous Probability Theory*, segunda edição, de J. S. Rosenthal (World Scientific Publishing, Singapura, 2006).

No original: *cumulative distribution function*[29], *right continuous*[30], *piecewise constant*[31].

Exemplo 2.5.1

Considere o lançamento de um dado honesto de seis faces, de modo que $S = \{1, 2, 3, 4, 5, 6\}$, com $P(s) = 1/6$ para cada $s \in S$. Seja X o número mostrado no dado dividido por 6, de modo que $X(s) = s/6$ para $s \in S$. Quanto vale $F_X(x)$? Como $X(s) \leq x$ se e somente se $s \leq 6x$, temos

$$F_X(x) = P(X \leq x) = \sum_{s \in S,\, s \leq 6x} P(s) = \sum_{s \in S,\, s \leq 6x} \frac{1}{6} = \frac{1}{6} |\{s \in S : s \leq 6x\}|.$$

Isto é, para calcular $F_X(x)$, contamos quantos elementos $s \in S$ satisfazem $s \leq 6x$ e multiplicamos esse número por 1/6. Portanto,

$$F_X(x) = \begin{cases} 0 & x < 1/6 \\ 1/6 & 1/6 \leq x < 2/6 \\ 2/6 & 2/6 \leq x < 3/6 \\ 3/6 & 3/6 \leq x < 4/6 \\ 4/6 & 4/6 \leq x < 5/6 \\ 5/6 & 5/6 \leq x < 1 \\ 6/6 & 1 \leq x. \end{cases}$$

Na Figura 2.5.1, apresentamos um gráfico da função F_X e observamos que se trata de uma função escada. Observe (ver Exercício 2.5.1) que as propriedades do Teorema 2.5.2 são de fato satisfeitas pela função F_X. ■

2.5.3 Fdas de Distribuições Absolutamente Contínuas

Uma vez conhecida a densidade f_X de X, é fácil calcular a função de distribuição acumulada de X, como segue.

Teorema 2.5.4

Seja X uma variável aleatória absolutamente contínua, com função densidade f_X. Então a função de distribuição acumulada F_X de X satisfaz

$$F_X(x) = \int_{-\infty}^{x} f_X(t)\, dt$$

para $x \in R^1$.

Demonstração. Isso segue de (2.4.5), tomando $b = x$ e fazendo $a \to -\infty$. ■

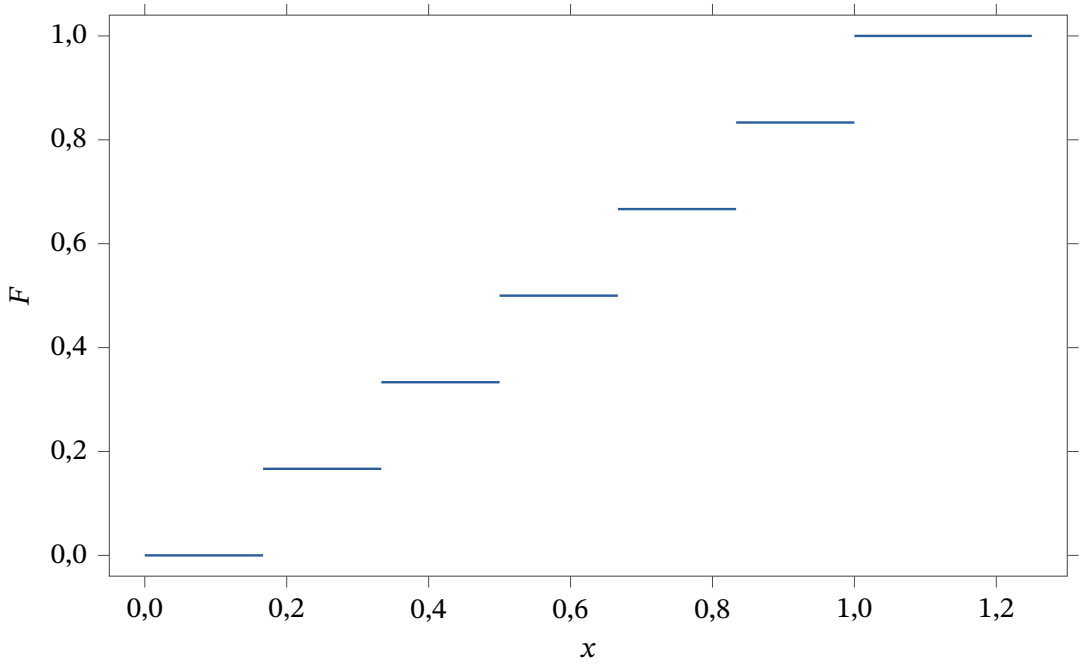


Figura 2.5.1: Gráfico da fda F_X do Exemplo 2.5.1.

Pelo teorema fundamental do cálculo, vemos que também é possível calcular uma densidade f_X uma vez conhecida a função de distribuição acumulada F_X.

Corolário 2.5.1

Seja X uma variável aleatória absolutamente contínua, com função de distribuição acumulada F_X. Seja

$$f_X(x) = \frac{d}{dx} F_X(x) = F_X'(x).$$

Então f_X é uma função densidade de X.

Observamos que F_X pode não ser diferenciável em todo ponto, de modo que a função f_X do corolário pode não estar definida em certos pontos isolados. A função densidade pode assumir qualquer valor nesses pontos.

Considere novamente a distribuição $N(0, 1)$, com densidade ϕ dada por (2.4.9). De acordo com o Teorema 2.5.4, a função de distribuição acumulada F dessa distribuição é dada por

$$F(x) = \int_{-\infty}^{x} \phi(t)\, dt = \int_{-\infty}^{x} \frac{1}{\sqrt{2\pi}} e^{-t^2/2}\, dt.$$

Acontece que é comprovadamente impossível calcular essa integral de forma exata, exceto para certos valores específicos de x (por exemplo, $x = -\infty$, $x = 0$

ou $x = \infty$). Ainda assim, a função de distribuição acumulada da distribuição $N(0,1)$ é tão importante que recebe um símbolo especial. Além disso, ela está tabelada na Tabela D.2 do Apêndice D para certos valores de x.

Definição 2.5.2

O símbolo Φ denota a função de distribuição acumulada de uma distribuição normal padrão, definida por

$$\Phi(x) = \int_{-\infty}^{x} \phi(t)\,dt = \int_{-\infty}^{x} \frac{1}{\sqrt{2\pi}} e^{-t^2/2}\,dt, \tag{2.5.2}$$

para $x \in R^1$.

Exemplo 2.5.2 — Cálculos de Probabilidades Normais

Suponha que $X \sim N(0,1)$ e que queremos calcular

$$P(-0{,}63 \le X \le 2{,}0) = P(X \le 2{,}0) - P(X \le -0{,}63).$$

Então $P(X \le 2) = \Phi(2)$, enquanto $P(X \le -0{,}63) = \Phi(-0{,}63)$. Infelizmente, $\Phi(2)$ e $\Phi(-0{,}63)$ não podem ser calculados de forma exata, mas podem ser aproximados usando um computador para calcular numericamente a integral (2.5.2). Praticamente todos os pacotes de software estatístico fornecem essas aproximações, mas também há muitas tabelas disponíveis, como a Tabela D.2. Usando essa tabela, obtemos $\Phi(2) = 0{,}9772$, enquanto $\Phi(-0{,}63) = 0{,}2643$. Isso implica que

$$P(-0{,}63 \le X \le 2{,}0) = \Phi(2{,}0) - \Phi(-0{,}63) = 0{,}9772 - 0{,}2643 = 0{,}7129.$$

Agora, suponha que $X \sim N(\mu, \sigma^2)$ e que queremos calcular $P(a \le X \le b)$. Denotando por f a densidade de X e seguindo o Exemplo 2.4.8, temos

$$P(a \le X \le b) = \int_a^b f(x)\,dx = \int_a^b \frac{1}{\sigma}\phi\left(\frac{x-\mu}{\sigma}\right)dx.$$

Então, novamente seguindo o Exemplo 2.4.8, fazemos a substituição $y = (x-\mu)/\sigma$ na integral acima e obtemos

$$P(a \le X \le b) = \int_{\frac{a-\mu}{\sigma}}^{\frac{b-\mu}{\sigma}} \phi(x)\,dx = \Phi\left(\frac{b-\mu}{\sigma}\right) - \Phi\left(\frac{a-\mu}{\sigma}\right).$$

Portanto, probabilidades normais em geral podem ser calculadas usando a função Φ.

Suponha agora que $a = -0{,}63$, $b = 2{,}0$, $\mu = 1{,}3$ e $\sigma^2 = 4$. Obtemos

$$\begin{aligned} P(-0{,}63 \leq X \leq 2{,}0) &= \Phi\left(\frac{2{,}0 - 1{,}3}{2}\right) - \Phi\left(\frac{-0{,}63 - 1{,}3}{2}\right) \\ &= \Phi(0{,}35) - \Phi(-0{,}965) = 0{,}6368 - 0{,}16725 \\ &= 0{,}46955 \end{aligned}$$

porque, pela Tabela D.2, $\Phi(0{,}35) = 0{,}6368$. Aproximamos $\Phi(-0{,}965)$ pela interpolação linear entre os valores $\Phi(-0{,}96) = 0{,}1685$ e $\Phi(-0{,}97) = 0{,}1660$, dada por

$$\begin{aligned} \Phi(-0{,}965) &\approx \Phi(-0{,}96) + \frac{\Phi(-0{,}97) - \Phi(-0{,}96)}{-0{,}97 - (-0{,}96)}\big(-0{,}965 - (-0{,}96)\big) \\ &= 0{,}1685 + \frac{0{,}1660 - 0{,}1685}{-0{,}97 - (-0{,}96)}\big(-0{,}965 - (-0{,}96)\big) = 0{,}16725. \end{aligned}$$

■

Exemplo 2.5.3

Seja X uma variável aleatória com função de distribuição acumulada dada por

$$F_X(x) = \begin{cases} 0 & x < 2 \\ (x-2)^4/16 & 2 \leq x < 4 \\ 1 & 4 \leq x. \end{cases}$$

Na Figura 2.5.2, apresentamos um gráfico de F_X.

Suponha que, para essa variável aleatória X, queremos calcular $P(X \leq 3)$, $P(X < 3)$, $P(X > 2{,}5)$ e $P(1{,}2 < X \leq 3{,}4)$. Podemos calcular todas essas probabilidades diretamente a partir de F_X. Temos

$$\begin{aligned} P(X \leq 3) &= F_X(3) = (3-2)^4/16 = 1/16, \\ P(X < 3) &= F_X(3^-) = \lim_{n\to\infty}(3 - (1/n) - 2)^4/16 = 1/16, \\ P(X > 2{,}5) &= 1 - P(X \leq 2{,}5) = 1 - F_X(2{,}5) \\ &= 1 - (2{,}5-2)^4/16 = 1 - 0{,}0625/16 = 0{,}996, \\ P(1{,}2 < X \leq 3{,}4) &= F_X(3{,}4) - F_X(1{,}2) = (3{,}4-2)^4/16 - 0 = 0{,}2401. \end{aligned}$$

■

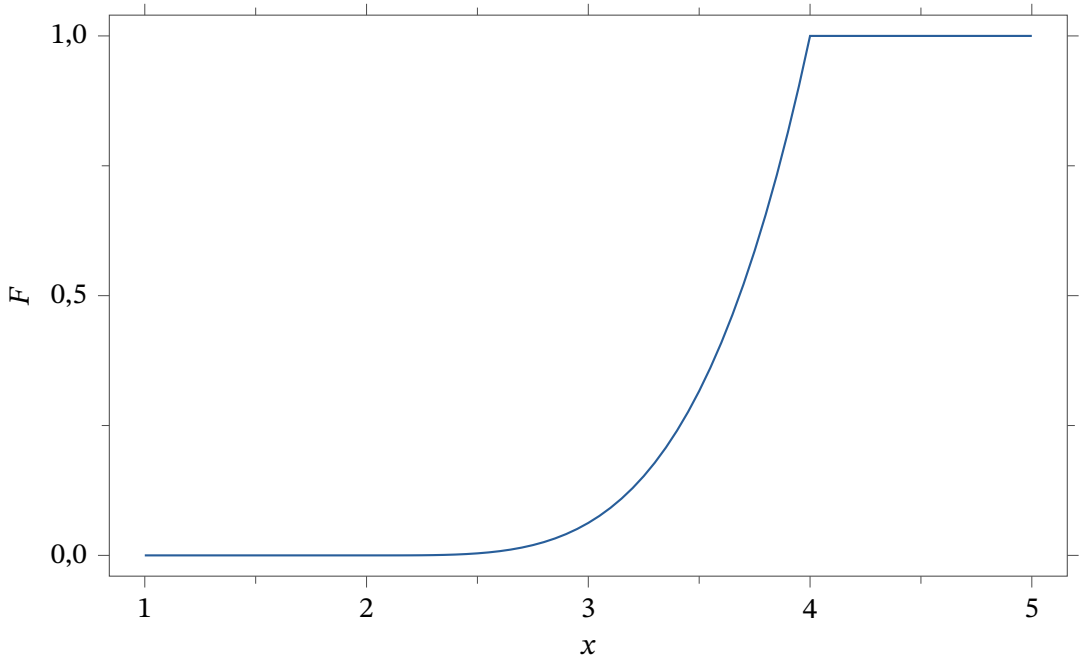


Figura 2.5.2: Gráfico da fda F_X do Exemplo 2.5.3.

2.5.4 Distribuições de Mistura

Suponha agora que $F_1, F_2, \ldots, F_k$ sejam funções de distribuição acumulada correspondentes a diversas distribuições. Sejam também $p_1, p_2, \ldots, p_k$ números reais positivos com $\sum_{i=1}^{k} p_i = 1$ (de modo que esses valores formam uma distribuição de probabilidade). Então podemos definir uma nova função G por

$$G(x) = p_1F_1(x) + p_2F_2(x) + \cdots + p_kF_k(x). \tag{2.5.3}$$

Verifica-se facilmente (ver Exercício 2.5.6) que a função G dada por (2.5.3) satisfaz as propriedades (a) a (d) do Teorema 2.5.2 e é contínua à direita. Portanto, G também é uma fda.

A distribuição cuja fda é dada por (2.5.3) é chamada de *distribuição de mistura*, porque ela *mistura* as várias distribuições com fdas $F_1, \ldots, F_k$ de acordo com a distribuição de probabilidade dada pelos $p_1, p_2, \ldots, p_k$.

Para ver como uma distribuição de mistura surge em aplicações, considere um sistema de dois estágios, como discutido na Seção 1.5.1. Seja Z uma variável aleatória que descreve o resultado do primeiro estágio, tal que $P(Z = i) = p_i$ para $i = 1, 2, \ldots, k$. Suponha que, no segundo estágio, observamos uma variável aleatória Y cuja distribuição depende do resultado do primeiro estágio, de modo que Y tem fda F_i quando $Z = i$. Na prática, F_i é a distribuição condicional

de Y, dado que $Z = i$ (ver Seção 2.8). Então, pela lei da probabilidade total[32] (ver Teorema 1.5.1), a função de distribuição de Y é dada por

$$P(Y \leq y) = \sum_{i=1}^{k} P(Y \leq y \mid Z = i)\, P(Z = i) = \sum_{i=1}^{k} p_i F_i(y) = G(y).$$

Portanto, a função de distribuição de Y é dada por uma mistura das F_i.

Considere o exemplo a seguir.

No original: *law of total probability*[32].

Exemplo 2.5.4

Suponha que temos duas tigelas contendo fichas. A tigela nº 1 contém uma ficha marcada com 0, duas fichas marcadas com 3 e uma ficha marcada com 5. A tigela nº 2 contém uma ficha marcada com 2, uma ficha marcada com 4 e uma ficha marcada com 5. Seja agora X_i a variável aleatória correspondente a retirar ao acaso uma ficha da tigela nº i. Portanto, $P(X_1 = 0) = 1/4$, $P(X_1 = 3) = 1/2$ e $P(X_1 = 5) = 1/4$, enquanto $P(X_2 = 2) = P(X_2 = 4) = P(X_2 = 5) = 1/3$. Então X_1 tem função de distribuição dada por

$$F_1(x) = \begin{cases} 0 & x < 0 \\ 1/4 & 0 \le x < 3 \\ 3/4 & 3 \le x < 5 \\ 1 & x \ge 5 \end{cases}$$

e X_2 tem função de distribuição dada por

$$F_2(x) = \begin{cases} 0 & x < 2 \\ 1/3 & 2 \le x < 4 \\ 2/3 & 4 \le x < 5 \\ 1 & x \ge 5. \end{cases}$$

Suponha agora que escolhemos uma tigela sorteando ao acaso uma carta de um baralho de cinco cartas, em que uma carta está marcada com 1 e quatro cartas estão marcadas com 2. Seja Z o valor da carta obtida, de modo que $P(Z = 1) = 1/5$ e $P(Z = 2) = 4/5$. Então, tendo obtido o valor $Z = i$, observamos Y retirando ao acaso uma ficha da tigela nº i. Vemos imediatamente que a fda de Y é dada por

$$G(x) = (1/5)\,F_1(x) + (4/5)\,F_2(x),$$

e esta é uma mistura das fdas F_1 e F_2. ■

Como ilustram os exemplos a seguir, também é possível ter misturas *infinitas* de distribuições.

Exemplo 2.5.5 — Misturas de Locação e de Escala

Suponha que F seja uma função de distribuição acumulada qualquer. Então, para qualquer número real y, a função F_y definida por $F_y(x) = F(x - y)$ também é uma função de distribuição acumulada. De fato, F_y é simplesmente uma versão "deslocada" de F. Um exemplo disso está representado na Figura 2.5.3.

Se $p_i \geq 0$ com $\sum_i p_i = 1$ (de modo que os p_i formam uma distribuição de probabilidade), e $y_1, y_2, \ldots$ são números reais, então podemos definir uma *mistura de locação discreta* por

$$H(x) = \sum_i p_i F_{y_i}(x) = \sum_i p_i F(x - y_i).$$

De fato, o próprio deslocamento $F_y(x) = F(x - y)$ corresponde a um caso particular de mistura de locação discreta, com $p_1 = 1$ e $y_1 = y$.

Além disso, se g é uma função não negativa com $\int_{-\infty}^{\infty} g(t)\,dt = 1$ (de modo que g é uma função densidade), então podemos definir

$$H(x) = \int_{-\infty}^{\infty} F_y(x)\, g(y)\, dy = \int_{-\infty}^{\infty} F(x - y)\, g(y)\, dy.$$

Então não é difícil ver que H também é uma função de distribuição acumulada, chamada de *mistura de locação contínua* de F. A ideia é que H corresponde a uma *mistura* de diferentes distribuições deslocadas F_y, com a densidade g dando a distribuição do coeficiente de mistura y.

Também podemos definir uma *mistura de escala discreta* por

$$K(x) = \sum_i p_i F(x/y_i)$$

sempre que $y_i > 0$, $p_i \geq 0$ e $\sum_i p_i = 1$. Da mesma forma, se $\int_0^{\infty} g(t)\,dt = 1$, então podemos escrever

$$K(x) = \int_0^{\infty} F(x/y)\, g(y)\, dy.$$

Então K também é uma função de distribuição acumulada, chamada de *mistura de escala contínua* de F. ■

Neste ponto, você pode se perguntar se uma distribuição de mistura é discreta ou contínua. A resposta depende das distribuições que estão sendo misturadas e da distribuição de mistura. Por exemplo, misturas de locação discretas

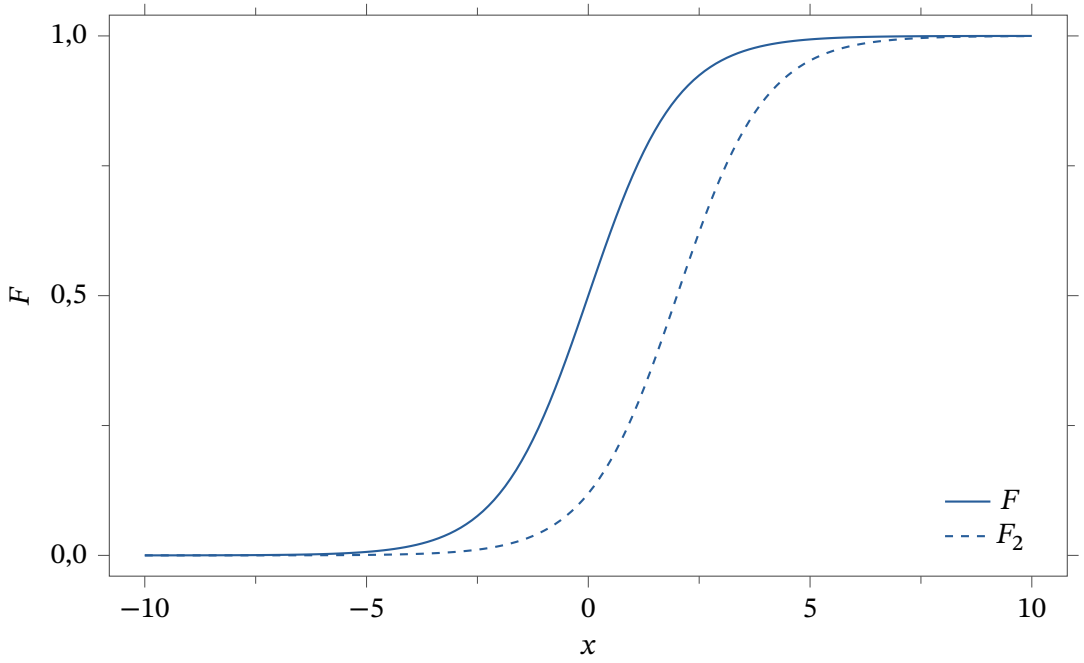


Figura 2.5.3: Gráfico das funções de distribuição F (linha contínua) e F_2 (linha tracejada) do Exemplo 2.5.5, em que $F(x) = e^x/(e^x + 1)$ para $x \in R^1$.

de distribuições discretas são discretas, e misturas de locação discretas de distribuições contínuas são contínuas.

Nada nos obriga, porém, a misturar apenas distribuições discretas ou apenas distribuições contínuas. Outros tipos de distribuição são considerados na seção a seguir.

2.5.5 Distribuições Nem Discretas Nem Contínuas (Avançado)

Há distribuições que não são nem discretas nem contínuas, como mostra o exemplo a seguir.

Exemplo 2.5.6

Suponha que $X_1 \sim$ Poisson(3) seja discreta com fda F_1, enquanto $X_2 \sim N(0,1)$ é contínua com fda F_2, e que Y tenha a distribuição de mistura dada por $F_Y(y) = (1/5)\,F_1(y) + (4/5)\,F_2(y)$. Usando (2.5.1), temos

$$\begin{aligned} P(Y = y) &= F_Y(y) - F_Y(y^-) \\ &= (1/5)F_1(y) + (4/5)\,F_2(y) - (1/5)F_1(y^-) - (4/5)F_2(y^-) \\ &= (1/5)\big(F_1(y) - F_1(y^-)\big) + (4/5)\big(F_2(y) - F_2(y^-)\big) \\ &= \frac{1}{5}P(X_1 = y) + \frac{4}{5}P(X_2 = y). \end{aligned}$$

Portanto,

$$P(Y = y) = \begin{cases} \frac{1}{5}\frac{3^y}{y!}e^{-3} & y \text{ inteiro não negativo} \\ 0 & \text{caso contrário.} \end{cases}$$

Como $P(Y = y) > 0$ para inteiros não negativos y, a variável aleatória Y não é contínua. Por outro lado, temos

$$\sum_y P(Y = y) = \sum_{y=0}^{\infty} \frac{1}{5}\frac{3^y}{y!}e^{-3} = \frac{1}{5} < 1.$$

Portanto, Y também não é discreta.

Na verdade, Y não é nem discreta nem contínua. Em vez disso, Y é uma mistura de uma distribuição discreta com uma contínua. ■

Na maior parte deste livro, trataremos separadamente as distribuições discretas e as contínuas. No entanto, é importante ter em mente que distribuições reais podem não ser nem discretas nem contínuas, mas sim uma mistura das duas.* Na maioria das aplicações, porém, as distribuições com que lidamos são contínuas ou discretas.

Lembre-se de que uma distribuição contínua não precisa ser absolutamente contínua, isto é, ter uma densidade. Portanto, uma distribuição que é mistura de uma distribuição discreta com uma contínua pode não ser uma mistura de uma distribuição discreta com uma absolutamente contínua.

*Na verdade, existem distribuições de probabilidade que não podem ser expressas nem mesmo como mistura de uma distribuição discreta com uma contínua, mas não precisamos nos preocupar com elas aqui.

Resumo da Seção 2.5

- A função de distribuição acumulada (fda) de X é $F_X(x) = P(X \leq x)$.
- Todas as probabilidades associadas a X podem ser determinadas a partir de F_X.
- À medida que x cresce de $-\infty$ a ∞, $F_X(x)$ cresce de 0 a 1.
- Se X é discreta, então $F_X(x) = \sum_{y \leq x} P(X = y)$.
- Se X é absolutamente contínua, então $F_X(x) = \int_{-\infty}^{x} f_X(t)\,dt$ e $f_X(x) = F_X'(x)$.
- Escrevemos $\Phi(x)$ para a fda da distribuição normal padrão calculada em x.
- Uma distribuição de mistura tem uma fda que é uma combinação linear de outras fdas. Dois casos particulares são as misturas de locação e de escala.
- Algumas distribuições de mistura não são nem discretas nem contínuas.

Exercícios

2.5.1 Verifique explicitamente que as propriedades (a) a (d) do Teorema 2.5.2 são de fato satisfeitas pela função F_X do Exemplo 2.5.1.

2.5.2 Considere o lançamento de um dado honesto de seis faces, de modo que $S = \{1, 2, 3, 4, 5, 6\}$ e $P(s) = 1/6$ para todo $s \in S$. Seja X o número mostrado no dado, de modo que $X(s) = s$ para $s \in S$. Seja $Y = X^2$. Calcule a função de distribuição acumulada $F_Y(y) = P(Y \leq y)$, para todo $y \in R^1$. Verifique explicitamente que as propriedades (a) a (d) do Teorema 2.5.2 são satisfeitas por essa função F_Y.

2.5.3 Para cada uma das funções F a seguir, determine se F é ou não uma função de distribuição acumulada válida, isto é, se F satisfaz ou não as propriedades (a) a (d) do Teorema 2.5.2.

(a) $F(x) = x$ para todo $x \in R^1$

(b)

$$F(x) = \begin{cases} 0 & x < 0 \\ x & 0 \leq x \leq 1 \\ 1 & x > 1 \end{cases}$$

(c)

$$F(x) = \begin{cases} 0 & x < 0 \\ x^2 & 0 \leq x \leq 1 \\ 1 & x > 1 \end{cases}$$

(d)

$$F(x) = \begin{cases} 0 & x < 0 \\ x^2 & 0 \leq x \leq 3 \\ 1 & x > 3 \end{cases}$$

(e)

$$F(x) = \begin{cases} 0 & x < 0 \\ x^2/9 & 0 \leq x \leq 3 \\ 1 & x > 3 \end{cases}$$

(f)

$$F(x) = \begin{cases} 0 & x < 1 \\ x^2/9 & 1 \leq x \leq 3 \\ 1 & x > 3 \end{cases}$$

(g)

$$F(x) = \begin{cases} 0 & x < -1 \\ x^2/9 & -1 \leq x \leq 3 \\ 1 & x > 3 \end{cases}$$

2.5.4 Seja $X \sim N(0, 1)$. Calcule cada um dos itens a seguir em termos da função Φ da Definição 2.5.2 e use a Tabela D.2 (ou um software) para calcular numericamente essas probabilidades.

(a) $P(X \leq -5)$

(b) $P(-2 \leq X \leq 7)$

(c) $P(X \geq 3)$

2.5.5 Seja $Y \sim N(-8, 4)$. Calcule cada um dos itens a seguir em termos da função Φ da Definição 2.5.2 e use a Tabela D.2 (ou um software) para calcular numericamente essas probabilidades.

(a) $P(Y \leq -5)$

(b) $P(-2 \leq Y \leq 7)$

(c) $P(Y \geq 3)$

2.5.6 Verifique que a função G dada por (2.5.3) satisfaz as propriedades (a) a (d) do Teorema 2.5.2.

2.5.7 Suponha que $F_X(x) = x^2$ para $0 \leq x \leq 1$. Calcule cada um dos itens a seguir.

(a) $P(X < 1/3)$

(b) $P(1/4 < X < 1/2)$

(c) $P(2/5 < X < 4/5)$

(d) $P(X < 0)$

(e) $P(X < 1)$

(f) $P(X < -1)$

(g) $P(X < 3)$

(h) $P(X = 3/7)$

2.5.8 Suponha que $F_Y(y) = y^3$ para $0 \leq y < 1/2$ e que $F_Y(y) = 1$ para $1/2 \leq y$. Calcule cada um dos itens a seguir.

(a) $P(1/3 < Y < 3/4)$

(b) $P(Y = 1/3)$

(c) $P(Y = 1/2)$

2.5.9 Seja $F(x) = x^2$ para $0 \leq x \leq 2$, com $F(x) = 0$ para $x < 0$ e $F(x) = 4$ para $x > 2$.

(a) Esboce um gráfico de F.

(b) F é uma função de distribuição acumulada válida? Por quê?

2.5.10 Seja $F(x) = 0$ para $x < 0$, com $F(x) = e^{-x}$ para $x \geq 0$.

(a) Esboce um gráfico de F.

(b) F é uma função de distribuição acumulada válida? Por quê?

2.5.11 Seja $F(x) = 0$ para $x < 0$, com $F(x) = 1 - e^{-x}$ para $x \geq 0$.

(a) Esboce um gráfico de F.

(b) F é uma função de distribuição acumulada válida? Por quê?

2.5.12 Seja $X \sim$ Exponencial(3). Calcule a função F_X.

2.5.13 Seja $F(x) = 0$ para $x < 0$, com $F(x) = 1/3$ para $0 \leq x < 2/5$, $F(x) = 3/4$ para $2/5 \leq x < 4/5$ e $F(x) = 1$ para $x \geq 4/5$.

(a) Esboce um gráfico de F.

(b) Demonstre que F é uma função de distribuição acumulada válida.

(c) Se X tem função de distribuição acumulada igual a F, calcule $P(X > 4/5)$, $P(-1 < X < 1/2)$, $P(X = 2/5)$ e $P(X = 4/5)$.

2.5.14 Seja $G(x) = 0$ para $x < 0$, com $G(x) = 1 - e^{-x^2}$ para $x \geq 0$.

(a) Demonstre que G é uma função de distribuição acumulada válida.

(b) Se Y tem função de distribuição acumulada igual a G, calcule $P(Y > 4)$, $P(-1 < Y < 2)$ e $P(Y = 0)$.

2.5.15 Sejam F e G como nos dois exercícios anteriores. Seja $H(x) = (1/3)F(x) + (2/3)G(x)$. Suponha que Z tenha função de distribuição acumulada igual a H. Calcule cada um dos itens a seguir.

(a) $P(Z > 4/5)$

(b) $P(-1 < Z < 1/2)$

(c) $P(Z = 2/5)$

(d) $P(Z = 4/5)$

(e) $P(Z = 0)$

(f) $P(Z = 1/2)$

Problemas

2.5.16 Seja F uma função de distribuição acumulada. Calcule (com justificativa) o valor de $\lim_{n\to\infty}[F(2n) - F(n)]$.

2.5.17 Seja F uma função de distribuição acumulada. Para $x \in R^1$, poderíamos definir $F(x^+)$ por $F(x^+) = \lim_{n\to\infty} F(x + \frac{1}{n})$. Demonstre que F é *contínua à direita*, o que significa que, para cada $x \in R^1$, temos $F(x^+) = F(x)$. (Sugestão: você precisará usar a continuidade de P (Teorema 1.6.1).)

2.5.18 Seja X uma variável aleatória, com função de distribuição acumulada F_X. Demonstre que $P(X = a) = 0$ se e somente se a função F_X é contínua em a. (Sugestão: use (2.5.1) e o problema anterior.)

2.5.19 Seja Φ como na Definição 2.5.2. Deduza uma fórmula para $\Phi(-x)$ em termos de $\Phi(x)$. (Sugestão: faça $s = -t$ em (2.5.2) e não se esqueça do Teorema 2.5.2.)

2.5.20 Determine a função de distribuição da distribuição logística do Problema 2.4.18.

2.5.21 Determine a função de distribuição da distribuição Weibull(α) do Problema 2.4.19.

2.5.22 Determine a função de distribuição da distribuição Pareto(α) do Problema 2.4.20.

2.5.23 Determine a função de distribuição da distribuição de Cauchy do Problema 2.4.21.

2.5.24 Determine a função de distribuição da distribuição de Laplace do Problema 2.4.22.

2.5.25 Determine a função de distribuição da distribuição de valor extremo do Problema 2.4.23.

2.5.26 Determine a função de distribuição das distribuições beta do Problema 2.4.24, nos itens (b) a (e).

Tópicos para discussão

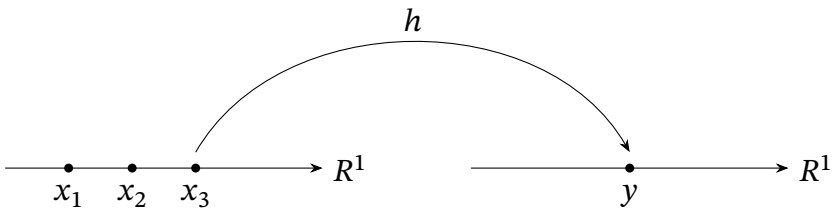
2.5.27 Você se surpreende com o fato de que toda a informação sobre a distribuição de uma variável aleatória X possa ser armazenada numa única função F_X? Por quê? Em que outros exemplos você consegue pensar em que muita informação diferente é armazenada numa única função?

2.6 Mudança de Variável Unidimensional

Seja X uma variável aleatória com distribuição conhecida. Suponha que $Y = h(X)$, em que $h : R^1 \to R^1$ é alguma função. (Lembre que isso significa, na verdade, que $Y(s) = h(X(s))$ para todo $s \in S$.) Qual é, então, a distribuição de Y?

2.6.1 O Caso Discreto

Se X é uma variável aleatória *discreta*, isso é bem direto. Para calcular a probabilidade de que $Y = y$, precisamos calcular a probabilidade do conjunto formado por todos os valores de x que satisfazem $h(x) = y$, isto é, calcular $P(X \in \{x : h(x) = y\})$. Isso está representado graficamente na Figura 2.6.1.



$$\{x : h(x) = y\} = \{x_1, x_2, x_3\}$$

Figura 2.6.1: Um exemplo em que o conjunto dos valores de x que satisfazem $h(x) = y$ é formado por três pontos, x_1, x_2 e x_3.

Estabelecemos agora o resultado básico.

Teorema 2.6.1

Seja X uma variável aleatória discreta, com função de probabilidade p_X. Seja $Y = h(X)$, em que $h : R^1 \to R^1$ é alguma função. Então Y também é discreta, e sua função de probabilidade p_Y satisfaz $p_Y(y) = \sum_{x \in h^{-1}\{y\}} p_X(x)$, em que $h^{-1}\{y\}$ é o conjunto de todos os números reais x com $h(x) = y$.

Demonstração. Calculamos que $p_Y(y) = P(h(X) = y) = \sum_{x \in h^{-1}\{y\}} P(X = x) = \sum_{x \in h^{-1}\{y\}} p_X(x)$, como afirmado. ■

Exemplo 2.6.1

Seja X o número de caras no lançamento de três moedas honestas. Seja $Y = 1$ se $X \geq 1$, com $Y = 0$ se $X = 0$. Então $Y = h(X)$, em que $h(0) = 0$ e $h(1) = h(2) = h(3) = 1$. Logo, $h^{-1}\{0\} = \{0\}$, de modo que $P(Y = 0) = P(X = 0) = 1/8$. Por outro lado, $h^{-1}\{1\} = \{1, 2, 3\}$, de modo que $P(Y = 1) = P(X = 1) + P(X = 2) + P(X = 3) = 3/8 + 3/8 + 1/8 = 7/8$. ■

Exemplo 2.6.2

Seja X o número que sai num dado honesto de seis faces, de modo que $P(X = x) = 1/6$ para $x = 1, 2, 3, 4, 5$ e 6. Seja $Y = X^2 - 3X + 2$. Então $Y = h(X)$, em que $h(x) = x^2 - 3x + 2$. Note que $h(x) = 0$ se e somente se $x = 1$ ou $x = 2$. Logo, $h^{-1}\{0\} = \{1, 2\}$ e

$$P(Y = 0) = p_X(1) + p_X(2) = \frac{1}{6} + \frac{1}{6} = \frac{1}{3}.$$

■

2.6.2 O Caso Contínuo

Se X é *contínua* e $Y = h(X)$, a situação é mais complicada. De fato, Y pode nem ser contínua, como mostra o exemplo a seguir.

Exemplo 2.6.3

Suponha que X tenha distribuição uniforme em $[0, 1]$, isto é, $X \sim$ Uniforme$[0, 1]$, como no Exemplo 2.4.2. Seja $Y = h(X)$, em que

$$h(x) = \begin{cases} 7 & x \leq 3/4 \\ 5 & x > 3/4. \end{cases}$$

Aqui, $Y = 7$ se e somente se $X \leq 3/4$ (o que acontece com probabilidade $3/4$), enquanto $Y = 5$ se e somente se $X > 3/4$ (o que acontece com probabilidade $1/4$). Logo, Y é discreta, com função de probabilidade p_Y satisfazendo $p_Y(7) = 3/4$, $p_Y(5) = 1/4$ e $p_Y(y) = 0$ quando $y \neq 5, 7$. ■

Por outro lado, se X é absolutamente contínua e a função h é *estritamente crescente*[33], a situação fica consideravelmente mais simples, como mostra o teorema a seguir.

No original: *strictly increasing*[33].

Teorema 2.6.2

Seja X uma variável aleatória absolutamente contínua, com função densidade f_X. Seja $Y = h(X)$, em que $h : R^1 \to R^1$ é uma função diferenciável e estritamente crescente. Então Y também é absolutamente contínua, e sua função densidade f_Y é dada por

$$f_Y(y) = f_X(h^{-1}(y)) \, / \, |h'(h^{-1}(y))|, \tag{2.6.1}$$

em que h' é a derivada de h e $h^{-1}(y)$ é o único número x tal que $h(x) = y$.

Demonstração. Veja a demonstração desse resultado na Seção 2.11. ■

Exemplo 2.6.4

Seja $X \sim \text{Uniforme}[0, 1]$ e seja $Y = 3X$. Qual é a distribuição de Y?

Aqui, X tem densidade f_X dada por $f_X(x) = 1$ se $0 \leq x \leq 1$, e $f_X(x) = 0$ caso contrário. Além disso, $Y = h(X)$, em que h é definida por $h(x) = 3x$. Note que h é estritamente crescente, porque, se $x < y$, então $3x < 3y$, isto é, $h(x) < h(y)$. Logo, podemos aplicar o Teorema 2.6.2.

Observamos primeiro que $h'(x) = 3$ e que $h^{-1}(y) = y/3$. Então, pelo Teorema 2.6.2, Y é absolutamente contínua, com densidade

$$\begin{aligned} f_Y(y) &= f_X(h^{-1}(y))/|h'(h^{-1}(y))| = \frac{1}{3} f_X(y/3) \\ &= \begin{cases} 1/3 & 0 \leq y/3 \leq 1 \\ 0 & \text{caso contrário} \end{cases} = \begin{cases} 1/3 & 0 \leq y \leq 3 \\ 0 & \text{caso contrário.} \end{cases} \end{aligned}$$

Comparando com o Exemplo 2.4.3, vemos que $Y \sim \text{Uniforme}[0, 3]$, isto é, que Y tem distribuição $\text{Uniforme}[L, R]$ com $L = 0$ e $R = 3$. ■

Exemplo 2.6.5

Seja $X \sim N(0,1)$ e seja $Y = 2X + 5$. Qual é a distribuição de Y?

Aqui, X tem densidade f_X dada por

$$f_X(x) = \phi(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}.$$

Além disso, $Y = h(X)$, em que h é definida por $h(x) = 2x + 5$. Note que, de novo, h é estritamente crescente, porque, se $x < y$, então $2x + 5 < 2y + 5$, isto é, $h(x) < h(y)$. Logo, podemos de novo aplicar o Teorema 2.6.2.

Observamos primeiro que $h'(x) = 2$ e que $h^{-1}(y) = (y - 5)/2$. Então, pelo Teorema 2.6.2, Y é absolutamente contínua, com densidade

$$f_Y(y) = f_X(h^{-1}(y))/|h'(h^{-1}(y))| = f_X((y-5)/2)/2 = \frac{1}{2\sqrt{2\pi}} e^{-(y-5)^2/8}.$$

Comparando com o Exemplo 2.4.8, vemos que $Y \sim N(5,4)$, isto é, que Y tem distribuição $N(\mu, \sigma^2)$ com $\mu = 5$ e $\sigma^2 = 4$. ■

Se, em vez disso, a função h for estritamente *decrescente*, vale um resultado semelhante.

Teorema 2.6.3

Seja X uma variável aleatória absolutamente contínua, com função densidade f_X. Seja $Y = h(X)$, em que $h : R^1 \to R^1$ é uma função diferenciável e estritamente decrescente. Então Y também é absolutamente contínua, e sua função densidade f_Y pode, de novo, ser definida por (2.6.1).

Demonstração. Veja a demonstração desse resultado na Seção 2.11. ■

Exemplo 2.6.6

Seja $X \sim \text{Uniforme}[0,1]$ e seja $Y = \ln(1/X)$. Qual é a distribuição de Y?

Aqui, X tem densidade f_X dada por $f_X(x) = 1$ para $0 \leq x \leq 1$, e $f_X(x) = 0$ caso contrário. Além disso, $Y = h(X)$, em que h é definida por $h(x) = \ln(1/x)$. Note que, aqui, h é estritamente decrescente, porque, se $x < y$, então $1/x > 1/y$, de modo que $\ln(1/x) > \ln(1/y)$, isto é, $h(x) > h(y)$. Logo, podemos aplicar o Teorema 2.6.3.

Observamos primeiro que $h'(x) = -1/x$ e que $h^{-1}(y) = e^{-y}$. Então, pelo Teorema 2.6.3, Y é absolutamente contínua, com densidade

$$\begin{aligned} f_Y(y) &= f_X(h^{-1}(y))/|h'(h^{-1}(y))| = e^{-y} f_X(e^{-y}) \\ &= \begin{cases} e^{-y} & 0 \leq e^{-y} \leq 1 \\ 0 & \text{caso contrário} \end{cases} = \begin{cases} e^{-y} & y \geq 0 \\ 0 & \text{caso contrário.} \end{cases} \end{aligned}$$

Comparando com o Exemplo 2.4.4, vemos que $Y \sim \text{Exponencial}(1)$, isto é, que Y tem distribuição Exponencial(1). ■

Por fim, observamos o seguinte.

Teorema 2.6.4

O Teorema 2.6.2 (e o 2.6.3) continua valendo supondo apenas que h seja estritamente crescente (ou decrescente) nos pontos em que $f_X(x) > 0$. Se $f_X(x) = 0$ num intervalo de valores de x, então não importa como a função h se comporta nesse intervalo (nem mesmo se ela está bem definida ali).

Exemplo 2.6.7

Se $X \sim \text{Exponencial}(\lambda)$, então $f_X(x) = 0$ para $x < 0$. Portanto, só se exige que h seja estritamente crescente (ou decrescente) para $x \geq 0$. Assim, funções como $h(x) = x^2$, $h(x) = x^8$ e $h(x) = \sqrt{x}$ ainda poderiam ser usadas com o Teorema 2.6.2, enquanto funções como $h(x) = -x^2$, $h(x) = -x^8$ e $h(x) = -\sqrt{x}$ ainda poderiam ser usadas com o Teorema 2.6.3, embora essas funções não sejam necessariamente estritamente crescentes (ou decrescentes) nem bem definidas em toda a reta real. ■

Resumo da Seção 2.6

- Se X é discreta e $Y = h(X)$, então $P(Y = y) = \sum_{x:\, h(x)=y} P(X = x)$.
- Se X é absolutamente contínua e $Y = h(X)$, com h estritamente crescente ou estritamente decrescente, então a densidade de Y é dada por $f_Y(y) = f_X(h^{-1}(y)) \,/\, |h'(h^{-1}(y))|$.
- Isso nos permite calcular a distribuição de uma função de uma variável aleatória.

Exercícios

2.6.1 Seja $X \sim \text{Uniforme}[L, R]$. Seja $Y = cX + d$, em que $c > 0$. Prove que $Y \sim \text{Uniforme}[cL + d, cR + d]$. (Isso generaliza o Exemplo 2.6.4.)

2.6.2 Seja $X \sim \text{Uniforme}[L, R]$. Seja $Y = cX + d$, em que $c < 0$. Prove que $Y \sim \text{Uniforme}[cR + d, cL + d]$. (Em particular, se $L = 0$, $R = 1$, $c = -1$ e $d = 1$, então $X \sim \text{Uniforme}[0, 1]$ e também $Y = 1 - X \sim \text{Uniforme}[0, 1]$.)

2.6.3 Seja $X \sim N(\mu, \sigma^2)$. Seja $Y = cX + d$, em que $c > 0$. Prove que $Y \sim N(c\mu + d, c^2\sigma^2)$. (Isso generaliza o Exemplo 2.6.5.)

2.6.4 Seja $X \sim \text{Exponencial}(\lambda)$. Seja $Y = cX$, em que $c > 0$. Prove que $Y \sim \text{Exponencial}(\lambda/c)$.

2.6.5 Seja $X \sim \text{Exponencial}(\lambda)$. Seja $Y = X^3$. Calcule a densidade f_Y de Y.

2.6.6 Seja $X \sim \text{Exponencial}(\lambda)$. Seja $Y = X^{1/4}$. Calcule a densidade f_Y de Y. (Sugestão: use o Teorema 2.6.4.)

2.6.7 Seja $X \sim \text{Uniforme}[0, 3]$. Seja $Y = X^2$. Calcule a função densidade f_Y de Y.

2.6.8 Suponha que X tenha uma densidade tal que $f_X(\mu + x) = f_X(\mu - x)$, isto é, simétrica em torno de μ. Seja $Y = 2\mu - X$. Mostre que a densidade de Y é dada por f_X. Use isso para determinar a distribuição de Y quando $X \sim N(\mu, \sigma^2)$.

2.6.9 Suponha que X tenha função densidade $f_X(x) = x^3/4$ para $0 < x < 2$, e $f_X(x) = 0$ caso contrário.

(a) Seja $Y = X^2$. Calcule a função densidade $f_Y(y)$ de Y.

(b) Seja $Z = \sqrt{X}$. Calcule a função densidade $f_Z(z)$ de Z.

2.6.10 Seja $X \sim \text{Uniforme}[0, \pi/2]$. Seja $Y = \sin(X)$. Calcule a função densidade $f_Y(y)$ de Y.

2.6.11 Suponha que X tenha função densidade $f_X(x) = (1/2)\sin(x)$ para $0 < x < \pi$, e $f_X(x) = 0$ caso contrário. Seja $Y = X^2$. Calcule a função densidade $f_Y(y)$ de Y.

2.6.12 Suponha que X tenha função densidade $f_X(x) = 1/x^2$ para $x > 1$, e $f_X(x) = 0$ caso contrário. Seja $Y = X^{1/3}$. Calcule a função densidade $f_Y(y)$ de Y.

2.6.13 Seja $X \sim \text{Normal}(0, 1)$. Seja $Y = X^3$. Calcule a função densidade $f_Y(y)$ de Y.

Problemas

2.6.14 Sejam $X \sim \text{Uniforme}[2, 7]$, $Y = X^3$ e $Z = \sqrt{Y}$. Calcule a densidade f_Z de Z de duas maneiras.

(a) Aplique o Teorema 2.6.2 para obter primeiro a densidade de Y e depois aplique o Teorema 2.6.2 *de novo* para obter a densidade de Z.

(b) Observe que $Z = \sqrt{Y} = \sqrt{X^3} = X^{3/2}$ e aplique o Teorema 2.6.2 uma *única* vez.

2.6.15 Seja $X \sim \text{Uniforme}[L, R]$ e seja $Y = h(X)$, em que $h(x) = (x - c)^6$. De acordo com o Teorema 2.6.4, sob que condições sobre L, R e c podemos aplicar o Teorema 2.6.2 ou o Teorema 2.6.3 a essa escolha de X e Y?

2.6.16 Seja $X \sim N(\mu, \sigma^2)$. Seja $Y = cX + d$, em que $c < 0$. Prove que, de novo, $Y \sim N(c\mu + d, c^2\sigma^2)$, exatamente como no Exercício 2.6.3.

2.6.17 (*Distribuição Log-normal*[34](τ)) Suponha que $X \sim N(0, \tau^2)$. Prove que $Y = e^X$ tem densidade

$$f_\tau(y) = \frac{1}{\sqrt{2\pi}\,\tau} \exp\left(-\frac{(\ln y)^2}{2\tau^2}\right)\frac{1}{y}$$

para $y > 0$, em que $\tau > 0$ é desconhecido. Dizemos que $Y \sim \text{Log-normal}(\tau)$.

2.6.18 Suponha que $X \sim \text{Weibull}(\alpha)$ (veja o Problema 2.4.19). Determine a distribuição de $Y = X^\beta$.

2.6.19 Suponha que $X \sim \text{Pareto}(\alpha)$ (veja o Problema 2.4.20). Determine a distribuição de $Y = (1 + X)^\beta - 1$.

No original: *Log-normal distribution*[34].

2.6.20 Suponha que X tenha a distribuição de valor extremo (veja o Problema 2.4.23). Determine a distribuição de $Y = e^{-X}$.

Desafios

2.6.21 Os Teoremas 2.6.2 e 2.6.3 exigem que h seja uma função crescente ou decrescente, pelo menos nos pontos em que a densidade de X é positiva (veja o Teorema 2.6.4). Suponha agora que $X \sim N(0,1)$ e $Y = h(X)$, em que $h(x) = x^2$. Então $f_X(x) > 0$ para todo x, enquanto h é crescente só para $x > 0$ e decrescente só para $x < 0$. Logo, os Teoremas 2.6.2 e 2.6.3 não se aplicam diretamente. Calcule $f_Y(y)$ mesmo assim. (Sugestão: $P(a \le Y \le b) = P(a \le Y \le b, X > 0) + P(a \le Y \le b, X < 0)$.)

2.7 Distribuições Conjuntas

Suponha que X e Y sejam duas variáveis aleatórias. Mesmo que conheçamos exatamente as distribuições de X e de Y, isso ainda não nos diz nada sobre a *relação* entre X e Y.

Exemplo 2.7.1

Seja $X \sim$ Bernoulli(1/2), de modo que $P(X = 0) = P(X = 1) = 1/2$. Seja $Y_1 = X$ e seja $Y_2 = 1 - X$. Então, claramente, temos também $Y_1 \sim$ Bernoulli(1/2) e $Y_2 \sim$ Bernoulli(1/2).

Por outro lado, a *relação* entre X e Y_1 é muito diferente da relação entre X e Y_2. Por exemplo, se sabemos que $X = 1$, então também devemos ter $Y_1 = 1$, mas $Y_2 = 0$. Logo, saber apenas que X, Y_1 e Y_2 têm todas a distribuição Bernoulli(1/2) não nos dá informação completa sobre as relações entre essas variáveis aleatórias. ■

Uma definição formal de distribuição conjunta[35] é a seguinte.

No original: *joint distribution*[35].

Definição 2.7.1

Se X e Y são variáveis aleatórias, então a *distribuição conjunta* de X e Y é a coleção das probabilidades $P((X, Y) \in B)$, para todos os subconjuntos $B \subseteq R^2$ de pares de números reais.

Distribuições conjuntas, como as outras distribuições, são tão complicadas que usamos várias funções para descrevê-las, entre elas as funções de distribuição acumulada conjuntas, as funções de probabilidade conjuntas e as funções densidade conjuntas, como discutimos a seguir.

2.7.1 Funções de Distribuição Acumulada Conjuntas

Definição 2.7.2

Sejam X e Y variáveis aleatórias. Então sua *função de distribuição acumulada conjunta* é a função $F_{X,Y} : R^2 \to [0, 1]$ definida por

$$F_{X,Y}(x, y) = P(X \leq x, Y \leq y).$$

(Lembre que a vírgula significa "e" aqui, de modo que $F_{X,Y}(x, y)$ é a probabilidade de que $X \leq x$ *e* $Y \leq y$.)

Exemplo 2.7.2 — Continuação do Exemplo 2.7.1

Novamente, seja $X \sim \text{Bernoulli}(1/2)$, $Y_1 = X$ e $Y_2 = 1 - X$. Então calculamos que

$$F_{X,Y_1}(x,y) = P(X \leq x, Y_1 \leq y) = \begin{cases} 0 & \min(x,y) < 0 \\ 1/2 & 0 \leq \min(x,y) < 1 \\ 1 & \min(x,y) \geq 1. \end{cases}$$

Por outro lado,

$$F_{X,Y_2}(x,y) = P(X \leq x, Y_2 \leq y) = \begin{cases} 0 & \min(x,y) < 0 \text{ ou } \max(x,y) < 1 \\ 1/2 & 0 \leq \min(x,y) < 1 \leq \max(x,y) \\ 1 & \min(x,y) \geq 1. \end{cases}$$

Vemos, assim, que F_{X,Y_1} é uma função bem diferente de F_{X,Y_2}. Isso reflete o fato de que, embora Y_1 e Y_2 tenham a mesma distribuição, a relação de cada uma com X é bem diferente. Por outro lado, as funções F_{X,Y_1} e F_{X,Y_2} são bastante incômodas e trabalhosas de manipular. ■

Vemos por esse exemplo que as funções de distribuição acumulada conjuntas (ou fdas conjuntas) de fato registram a relação entre X e Y. Na verdade, as fdas conjuntas nos dizem tudo sobre as probabilidades conjuntas de X e Y, como mostra o teorema a seguir (um análogo do Teorema 2.5.1).

Teorema 2.7.1

Sejam X e Y variáveis aleatórias quaisquer, com função de distribuição acumulada conjunta $F_{X,Y}$. Seja B um subconjunto de R^2. Então $P((X,Y) \in B)$ pode ser determinada apenas a partir dos valores de $F_{X,Y}(x,y)$.

Não daremos uma demonstração do Teorema 2.7.1, embora ela seja parecida com a demonstração do Teorema 2.5.1. No entanto, o teorema a seguir indica por que o Teorema 2.7.1 é verdadeiro e também fornece um fato útil para os cálculos.

Teorema 2.7.2

Sejam X e Y variáveis aleatórias quaisquer, com função de distribuição acumulada conjunta $F_{X,Y}$. Suponha que $a \leq b$ e $c \leq d$. Então

$$P(a < X \leq b, c < Y \leq d) = F_{X,Y}(b,d) - F_{X,Y}(a,d) - F_{X,Y}(b,c) + F_{X,Y}(a,c).$$

Demonstração. De acordo com (1.3.3),

$$\begin{aligned} &P(a < X \leq b, c < Y \leq d) \\ &\quad = P(X \leq b, Y \leq d) - P(X \leq b, Y \leq d, \text{e } X \leq a \text{ ou } Y \leq c). \end{aligned}$$

Mas, pelo princípio da inclusão-exclusão[36] (1.3.4),

$$\begin{aligned} &P(X \leq b, Y \leq d, \text{e } X \leq a \text{ ou } Y \leq c) \\ &\quad = P(X \leq b, Y \leq c) + P(X \leq a, Y \leq d) - P(X \leq a, Y \leq c). \end{aligned}$$

Combinando essas duas equações, vemos que

$$\begin{aligned} &P(a < X \leq b, c < Y \leq d) \\ &\quad = P(X \leq b, Y \leq d) - P(X \leq a, Y \leq d) - P(X \leq b, Y \leq c) + P(X \leq a, Y \leq c) \end{aligned}$$

e, daí, obtemos

$$P(a < X \leq b, c < Y \leq d) = F_{X,Y}(b,d) - F_{X,Y}(a,d) - F_{X,Y}(b,c) + F_{X,Y}(a,c),$$

como afirmado. ■

Não é fácil trabalhar com fdas conjuntas. Por isso, nesta seção vamos considerar também outras funções, que são mais convenientes para pares de variáveis aleatórias discretas ou absolutamente contínuas.

2.7.2 Distribuições Marginais

Vimos como uma função de distribuição acumulada conjunta $F_{X,Y}$ nos informa sobre a relação entre X e Y. No entanto, a função $F_{X,Y}$ também nos diz tudo sobre cada uma das variáveis X e Y separadamente, como mostra o teorema a seguir.

No original: *inclusion–exclusion*[36].

Teorema 2.7.3

Sejam X e Y duas variáveis aleatórias, com função de distribuição acumulada conjunta $F_{X,Y}$. Então a função de distribuição acumulada F_X de X satisfaz

$$F_X(x) = \lim_{y\to\infty} F_{X,Y}(x,y),$$

para todo $x \in R^1$. Analogamente, a função de distribuição acumulada F_Y de Y satisfaz

$$F_Y(y) = \lim_{x\to\infty} F_{X,Y}(x,y),$$

para todo $y \in R^1$.

Demonstração. Note que *sempre* temos $Y \leq \infty$. Logo, usando a continuidade de P, temos

$$\begin{aligned} F_X(x) &= P(X \leq x) \\ &= P(X \leq x, Y \leq \infty) \\ &= \lim_{y\to\infty} P(X \leq x, Y \leq y) \\ &= \lim_{y\to\infty} F_{X,Y}(x,y), \end{aligned}$$

como afirmado. Analogamente,

$$\begin{aligned} F_Y(y) &= P(Y \leq y) \\ &= P(X \leq \infty, Y \leq y) \\ &= \lim_{x\to\infty} P(X \leq x, Y \leq y) \\ &= \lim_{x\to\infty} F_{X,Y}(x,y), \end{aligned}$$

o que completa a demonstração. ■

No contexto do Teorema 2.7.3, F_X é chamada de *função de distribuição acumulada marginal* de X, e a distribuição de X é chamada de *distribuição marginal*[37] de X. (Analogamente, F_Y é chamada de função de distribuição acumulada marginal de Y, e a distribuição de Y é chamada de distribuição marginal de Y.) Intuitivamente, se pensamos em $F_{X,Y}$ como uma função de um par (x, y), então F_X e F_Y são funções de x e de y, respectivamente, que poderiam ser escritas nas "margens" de um gráfico de $F_{X,Y}$.

No original: *marginal distribution*[37].

Exemplo 2.7.3

Na Figura 2.7.1, fizemos o gráfico da função de distribuição conjunta

$$F_{X,Y}(x,y) = \begin{cases} 0 & x < 0 \text{ ou } y < 0 \\ xy^2 & 0 \le x \le 1, 0 \le y \le 1 \\ x & 0 \le x \le 1, y \ge 1 \\ y^2 & x \ge 1, 0 \le y \le 1 \\ 1 & x > 1 \text{ e } y > 1. \end{cases}$$

É fácil ver que

$$F_X(x) = F_{X,Y}(x,1) = x$$

para $0 \le x \le 1$ e que

$$F_Y(y) = F_{X,Y}(1,y) = y^2$$

para $0 \le y \le 1$. Os gráficos dessas funções são dados pelas bordas mais externas da superfície representada na Figura 2.7.1. ■

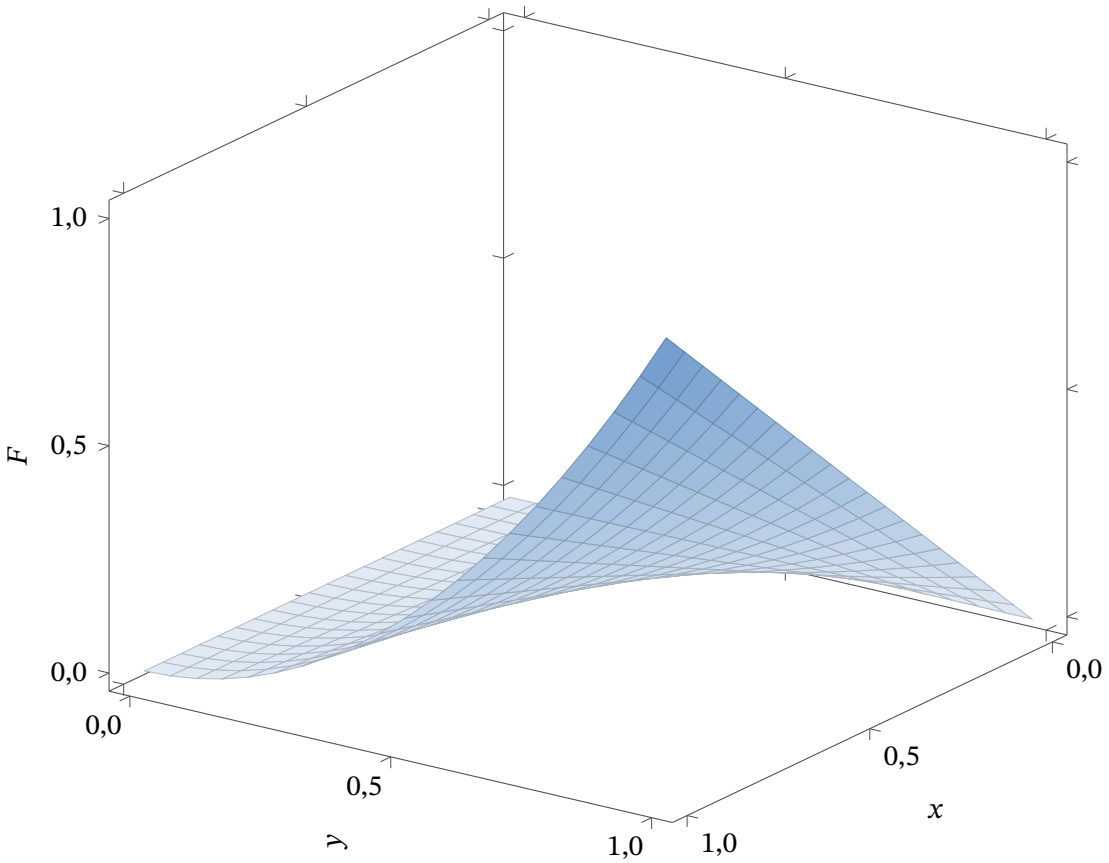


Figura 2.7.1: Gráfico da função de distribuição conjunta $F_{X,Y}(x,y) = xy^2$ para $0 \le x \le 1$ e $0 \le y \le 1$ no Exemplo 2.7.3.

Assim, o Teorema 2.7.3 nos diz que a fda conjunta[38] $F_{X,Y}$ é de fato muito útil. Ela não só nos informa sobre a relação entre X e Y, como também contém toda a informação sobre as distribuições marginais de X e de Y.

Veremos nas próximas subseções que as funções de probabilidade conjuntas e as funções densidade conjuntas também contêm informação tanto sobre a relação entre X e Y quanto sobre as distribuições marginais de X e Y.

2.7.3 Funções de Probabilidade Conjuntas

Suponha que X e Y sejam ambas variáveis aleatórias *discretas*. Então podemos definir uma função de probabilidade conjunta para X e Y, da seguinte forma.

Definição 2.7.3

Sejam X e Y variáveis aleatórias discretas. Então sua função de probabilidade conjunta, $p_{X,Y}$, é uma função de R^2 em R^1, definida por

$$p_{X,Y}(x, y) = P(X = x, Y = y).$$

Considere o exemplo a seguir.

No original: *joint cdf*[38].

Exemplo 2.7.4 — Continuação dos Exemplos 2.7.1 e 2.7.2

Novamente, seja $X \sim \text{Bernoulli}(1/2)$, $Y_1 = X$ e $Y_2 = 1 - X$. Então vemos que

$$p_{X,Y_1}(x,y) = P(X = x, Y_1 = y) = \begin{cases} 1/2 & x = y = 1 \\ 1/2 & x = y = 0 \\ 0 & \text{caso contrário.} \end{cases}$$

Por outro lado,

$$p_{X,Y_2}(x,y) = P(X = x, Y_2 = y) = \begin{cases} 1/2 & x = 1, y = 0 \\ 1/2 & x = 0, y = 1 \\ 0 & \text{caso contrário.} \end{cases}$$

Vemos, assim, que p_{X,Y_1} e p_{X,Y_2} são duas funções simples, fáceis de manipular, que descrevem claramente as relações entre X e Y_1 e entre X e Y_2. Logo, para pares de variáveis aleatórias discretas, as funções de probabilidade conjuntas costumam ser a melhor maneira de descrever suas relações. ■

Uma vez conhecida a função de probabilidade conjunta $p_{X,Y}$, as funções de probabilidade marginais de X e Y são obtidas facilmente.

Teorema 2.7.4

Sejam X e Y duas variáveis aleatórias discretas, com função de probabilidade conjunta $p_{X,Y}$. Então a função de probabilidade p_X de X pode ser calculada como

$$p_X(x) = \sum_y p_{X,Y}(x,y).$$

Analogamente, a função de probabilidade p_Y de Y pode ser calculada como

$$p_Y(y) = \sum_x p_{X,Y}(x,y).$$

Demonstração. Usando a aditividade de P, temos

$$p_X(x) = P(X = x) = \sum_y P(X = x, Y = y) = \sum_y p_{X,Y}(x,y),$$

como afirmado. Analogamente,

$$p_Y(y) = P(Y = y) = \sum_x P(X = x, Y = y) = \sum_x p_{X,Y}(x, y). \quad \blacksquare$$

Exemplo 2.7.5

Suponha que a função de probabilidade conjunta de X e Y seja dada por

$$p_{X,Y}(x, y) = \begin{cases} 1/7 & x = 5, y = 0 \\ 1/7 & x = 5, y = 3 \\ 1/7 & x = 5, y = 4 \\ 3/7 & x = 8, y = 0 \\ 1/7 & x = 8, y = 4 \\ 0 & \text{caso contrário.} \end{cases}$$

Então

$$\begin{aligned} p_X(5) &= \sum_y p_{X,Y}(5, y) = p_{X,Y}(5, 0) + p_{X,Y}(5, 3) + p_{X,Y}(5, 4) \\ &= \frac{1}{7} + \frac{1}{7} + \frac{1}{7} = \frac{3}{7}, \end{aligned}$$

enquanto

$$p_X(8) = \sum_y p_{X,Y}(8, y) = p_{X,Y}(8, 0) + p_{X,Y}(8, 4) = \frac{3}{7} + \frac{1}{7} = \frac{4}{7}.$$

Analogamente,

$$p_Y(4) = \sum_x p_{X,Y}(x, 4) = p_{X,Y}(5, 4) + p_{X,Y}(8, 4) = \frac{1}{7} + \frac{1}{7} = \frac{2}{7},$$

etc.

Note que, num contexto tão simples, é possível dispor a função de probabilidade conjunta numa tabela, como ilustrado a seguir para $p_{X,Y}$, p_X e p_Y deste exemplo.

	$Y = 0$	$Y = 3$	$Y = 4$	
$X = 5$	1/7	1/7	1/7	3/7
$X = 8$	3/7	0	1/7	4/7
	4/7	1/7	2/7	

Somar as linhas e as colunas e colocar os totais nas margens dá as distribuições marginais de X e Y. ■

2.7.4 Funções Densidade Conjuntas

Se X e Y são variáveis aleatórias *contínuas*, então, claramente, $p_{X,Y}(x, y) = 0$ para todo x e y. Logo, as funções de probabilidade conjuntas não são úteis nesse caso. Por outro lado, veremos aqui que, se X e Y são *conjuntamente absolutamente contínuas*[39], então a relação entre elas pode ser descrita de forma útil por uma função densidade conjunta[40].

Definição 2.7.4

Seja $f : R^2 \to R^1$ uma função. Então f é uma *função densidade conjunta* se $f(x, y) \geq 0$ para todo x e y, e $\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y)\, dx\, dy = 1$.

Definição 2.7.5

Sejam X e Y variáveis aleatórias. Então X e Y são *conjuntamente absolutamente contínuas* se existe uma função densidade conjunta f tal que

$$P(a \leq X \leq b, c \leq Y \leq d) = \int_c^d \int_a^b f(x, y)\, dx\, dy,$$

para todos $a \leq b, c \leq d$.

Considere o exemplo a seguir.

No original: *jointly absolutely continuous*[39], *joint density*[40].

Exemplo 2.7.6

Sejam X e Y conjuntamente absolutamente contínuas, com função densidade conjunta f dada por

$$f(x,y) = \begin{cases} 4x^2y + 2y^5 & 0 \le x \le 1, 0 \le y \le 1 \\ 0 & \text{caso contrário.} \end{cases}$$

Primeiro verificamos que f é de fato uma função densidade. Claramente, $f(x,y) \ge 0$ para todo x e y. Além disso,

$$\begin{aligned} \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} f(x,y)\,dx\,dy &= \int_0^1\int_0^1 (4x^2y + 2y^5)\,dx\,dy = \int_0^1 \left(\frac{4}{3}y + 2y^5\right)dy \\ &= \frac{4}{3}\frac{1}{2} + 2\frac{1}{6} = \frac{2}{3} + \frac{1}{3} = 1. \end{aligned}$$

Logo, f é uma função densidade conjunta. Na Figura 2.7.2, fizemos o gráfico da função f, que forma uma superfície sobre o quadrado unitário.

Em seguida, calculamos $P(0{,}5 \le X \le 0{,}7, 0{,}2 \le Y \le 0{,}9)$. De fato, temos

$$\begin{aligned} &P(0{,}5 \le X \le 0{,}7, 0{,}2 \le Y \le 0{,}9) \\ &= \int_{0{,}2}^{0{,}9}\int_{0{,}5}^{0{,}7} (4x^2y + 2y^5)\,dx\,dy \\ &= \int_{0{,}2}^{0{,}9} \left[\left(\frac{4}{3}((0{,}7)^3 - (0{,}5)^3)\right)y + 2y^5(0{,}7 - 0{,}5)\right]dy \\ &= \frac{4}{3}((0{,}7)^3 - (0{,}5)^3)\frac{1}{2}((0{,}9)^2 - (0{,}2)^2) + \frac{2}{6}((0{,}9)^6 - (0{,}2)^6)(0{,}7 - 0{,}5) \\ &= \frac{2}{3}((0{,}7)^3 - (0{,}5)^3)((0{,}9)^2 - (0{,}2)^2) + \frac{1}{3}((0{,}9)^6 - (0{,}2)^6)(0{,}7 - 0{,}5) \doteq 0{,}147. \end{aligned}$$

As outras probabilidades podem ser calculadas de modo análogo. ■

Uma vez conhecida uma densidade conjunta $f_{X,Y}$, calcular as densidades marginais de X e Y é muito fácil, como mostra o teorema a seguir.

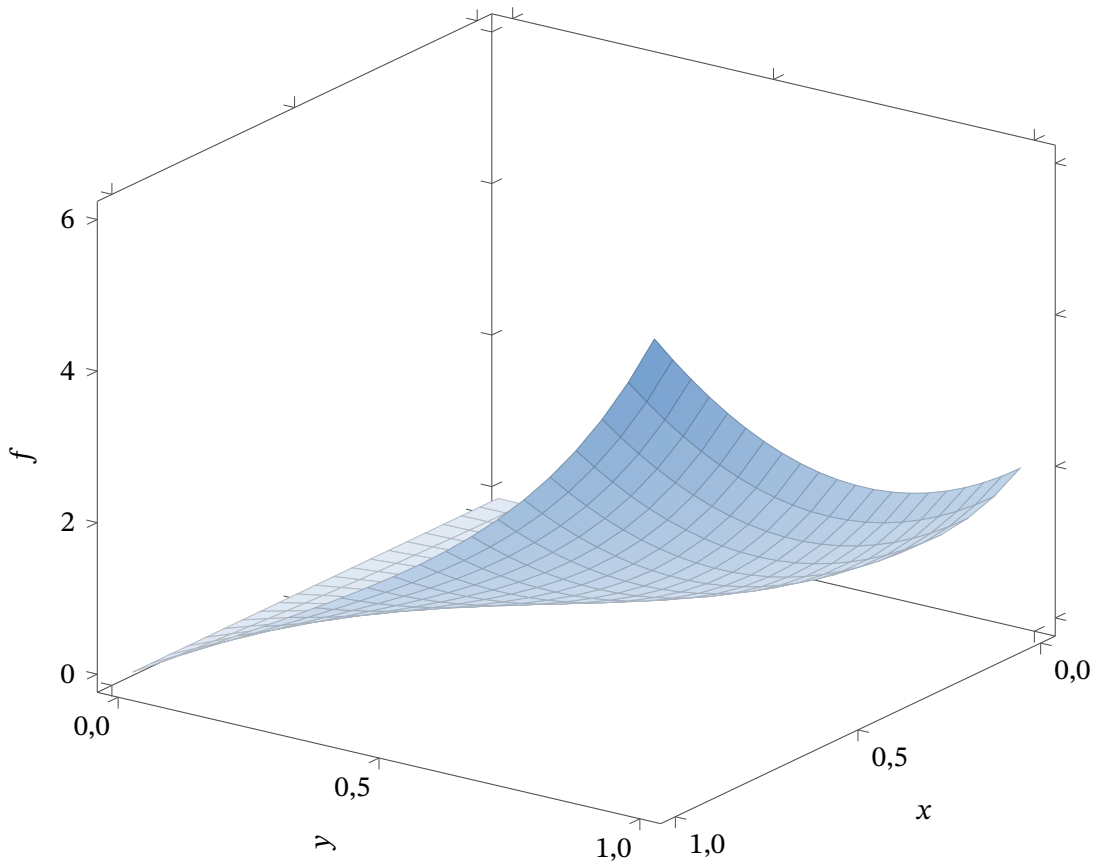


Figura 2.7.2: Gráfico da densidade f do Exemplo 2.7.6.

Teorema 2.7.5

Sejam X e Y variáveis aleatórias conjuntamente absolutamente contínuas, com função densidade conjunta $f_{X,Y}$. Então a densidade (marginal) f_X de X satisfaz

$$f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x,y)\,dy,$$

para todo $x \in R^1$. Analogamente, a densidade (marginal) f_Y de Y satisfaz

$$f_Y(y) = \int_{-\infty}^{\infty} f_{X,Y}(x,y)\,dx,$$

para todo $y \in R^1$.

Demonstração. Precisamos mostrar que, para $a \le b$, $P(a \le X \le b) = \int_a^b f_X(x)\,dx = \int_a^b \int_{-\infty}^{\infty} f_{X,Y}(x,y)\,dy\,dx$. Ora, sempre temos $-\infty < Y < \infty$. Logo, usando a continuidade de P, temos que $P(a \le X \le b) = P(a \le X \le b,\ -\infty < Y < \infty)$ e

$$\begin{aligned} &P(a \le X \le b,\ -\infty < Y < \infty) \\ &= \lim_{\substack{c \to -\infty \\ d \to \infty}} P(a \le X \le b, c \le Y \le d) = \lim_{\substack{c \to -\infty \\ d \to \infty}} \int_c^d \int_a^b f(x,y)\,dx\,dy \\ &= \lim_{\substack{c \to -\infty \\ d \to \infty}} \int_a^b \int_c^d f(x,y)\,dy\,dx = \int_a^b \int_{-\infty}^{\infty} f_{X,Y}(x,y)\,dy\,dx, \end{aligned}$$

como afirmado. O resultado para f_Y segue de modo análogo. ■

Exemplo 2.7.7 — Continuação do Exemplo 2.7.6

Sejam novamente X e Y com densidade conjunta

$$f_{X,Y}(x,y) = \begin{cases} 4x^2y + 2y^5 & 0 \le x \le 1, 0 \le y \le 1 \\ 0 & \text{caso contrário.} \end{cases}$$

Então, pelo Teorema 2.7.5, para $0 \le x \le 1$,

$$f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x,y)\,dy = \int_0^1 (4x^2y + 2y^5)\,dy = 2x^2 + (1/3),$$

enquanto, para $x < 0$ ou $x > 1$,

$$f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x,y)\,dy = \int_{-\infty}^{\infty} 0\,dy = 0.$$

Analogamente, para $0 \le y \le 1$,

$$f_Y(y) = \int_{-\infty}^{\infty} f_{X,Y}(x,y)\,dx = \int_0^1 (4x^2y + 2y^5)\,dx = \frac{4}{3}y + 2y^5,$$

enquanto, para $y < 0$ ou $y > 1$, $f_Y(y) = 0$. ■

Exemplo 2.7.8

Suponha que X e Y sejam conjuntamente absolutamente contínuas, com densidade conjunta

$$f_{X,Y}(x,y) = \begin{cases} 120x^3y & x \geq 0, y \geq 0, x+y \leq 1 \\ 0 & \text{caso contrário.} \end{cases}$$

Então a região em que $f_{X,Y}(x,y) > 0$ é um *triângulo*, como representado na Figura 2.7.3.

Verificamos que

$$\begin{aligned} \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} f_{X,Y}(x,y)\,dx\,dy &= \int_0^1\int_0^{1-x} 120x^3y\,dy\,dx = \int_0^1 120x^3\frac{(1-x)^2}{2}\,dx \\ &= \int_0^1 60(x^3-2x^4+x^5)\,dx = 60\left(\frac{1}{4}-2\frac{1}{5}+\frac{1}{6}\right) \\ &= 15-2(12)+10 = 1, \end{aligned}$$

de modo que $f_{X,Y}$ é de fato uma função densidade conjunta. Calculamos então, por exemplo, que

$$f_X(x) = \int_0^{1-x} 120x^3y\,dy = 120x^3\frac{(1-x)^2}{2} = 60(x^3-2x^4+x^5)$$

para $0 \leq x \leq 1$ (com $f_X(x) = 0$ para $x < 0$ ou $x > 1$). ■

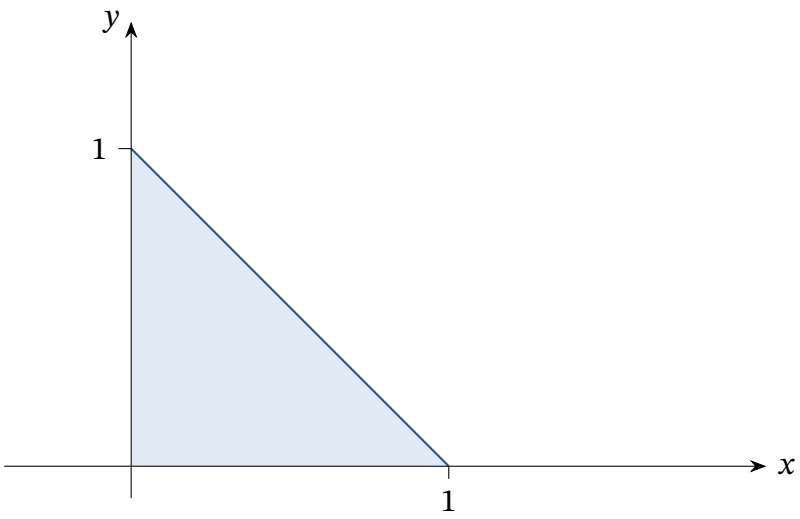


Figura 2.7.3: Região do plano em que a densidade $f_{X,Y}$ do Exemplo 2.7.8 é positiva.

Exemplo 2.7.9 — Distribuição Normal Bivariada$(\mu_1, \mu_2, \sigma_1, \sigma_2, \rho)$

Sejam μ_1, μ_2, σ_1, σ_2 e ρ números reais, com $\sigma_1, \sigma_2 > 0$ e $-1 \leq \rho \leq 1$. Sejam X e Y com densidade conjunta dada por

$$f_{X,Y}(x,y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left\{-\frac{1}{2(1-\rho^2)}\left[\left(\frac{x-\mu_1}{\sigma_1}\right)^2 + \left(\frac{y-\mu_2}{\sigma_2}\right)^2 - 2\rho\left(\frac{x-\mu_1}{\sigma_1}\right)\left(\frac{y-\mu_2}{\sigma_2}\right)\right]\right\}$$

para $x \in R^1$, $y \in R^1$. Dizemos que X e Y têm a *distribuição Normal Bivariada*$(\mu_1, \mu_2, \sigma_1, \sigma_2, \rho)$.

Pode-se mostrar (ver Problema 2.7.13) que $X \sim N(\mu_1, \sigma_1^2)$ e $Y \sim N(\mu_2, \sigma_2^2)$. Logo, X e Y têm, cada uma, distribuição normal. O parâmetro ρ mede o grau da *relação* que existe entre X e Y (ver Problema 3.3.17) e é chamado de *correlação*. Em particular, X e Y são independentes (ver Seção 2.8.3), e portanto não relacionadas, se e somente se $\rho = 0$ (ver Problema 2.8.21).

A Figura 2.7.4 é um gráfico da densidade *normal bivariada padrão*, obtida fazendo $\mu_1 = 0$, $\mu_2 = 0$, $\sigma_1 = 1$, $\sigma_2 = 1$ e $\rho = 0$. Trata-se de uma superfície em forma de sino em R^3, com o pico no ponto $(0, 0)$ do plano xy. O gráfico da distribuição Normal Bivariada$(\mu_1, \mu_2, \sigma_1, \sigma_2, \rho)$ geral também é uma superfície em forma de sino, mas o pico fica no ponto (μ_1, μ_2) do plano xy, e a forma do sino é controlada por σ_1, σ_2 e ρ.

Pode-se mostrar (ver Problema 2.9.16) que, quando Z_1, Z_2 são variáveis aleatórias independentes, ambas com distribuição $N(0, 1)$, e tomamos

$$X = \mu_1 + \sigma_1 Z_1, \qquad Y = \mu_2 + \sigma_2\left(\rho Z_1 + (1-\rho^2)^{1/2} Z_2\right), \tag{2.7.1}$$

então $(X, Y) \sim$ Normal Bivariada$(\mu_1, \mu_2, \sigma_1, \sigma_2, \rho)$. Essa relação pode ser bastante útil para estabelecer várias propriedades dessa distribuição. Também podemos escrever uma versão análoga $Y = \mu_2 + \sigma_2 Z_1$, $X = \mu_1 + \sigma_1\left(\rho Z_1 + (1-\rho^2)^{1/2} Z_2\right)$ e obter o mesmo resultado sobre a distribuição.

A distribuição normal bivariada é uma das distribuições bivariadas mais usadas nas aplicações. Por exemplo, se selecionamos ao acaso um indivíduo de uma população e medimos seu peso X e sua altura Y, então uma distribuição normal bivariada muitas vezes fornece uma descrição razoável da distribuição conjunta dessas variáveis. ■

As densidades conjuntas também podem ser usadas para calcular probabili-

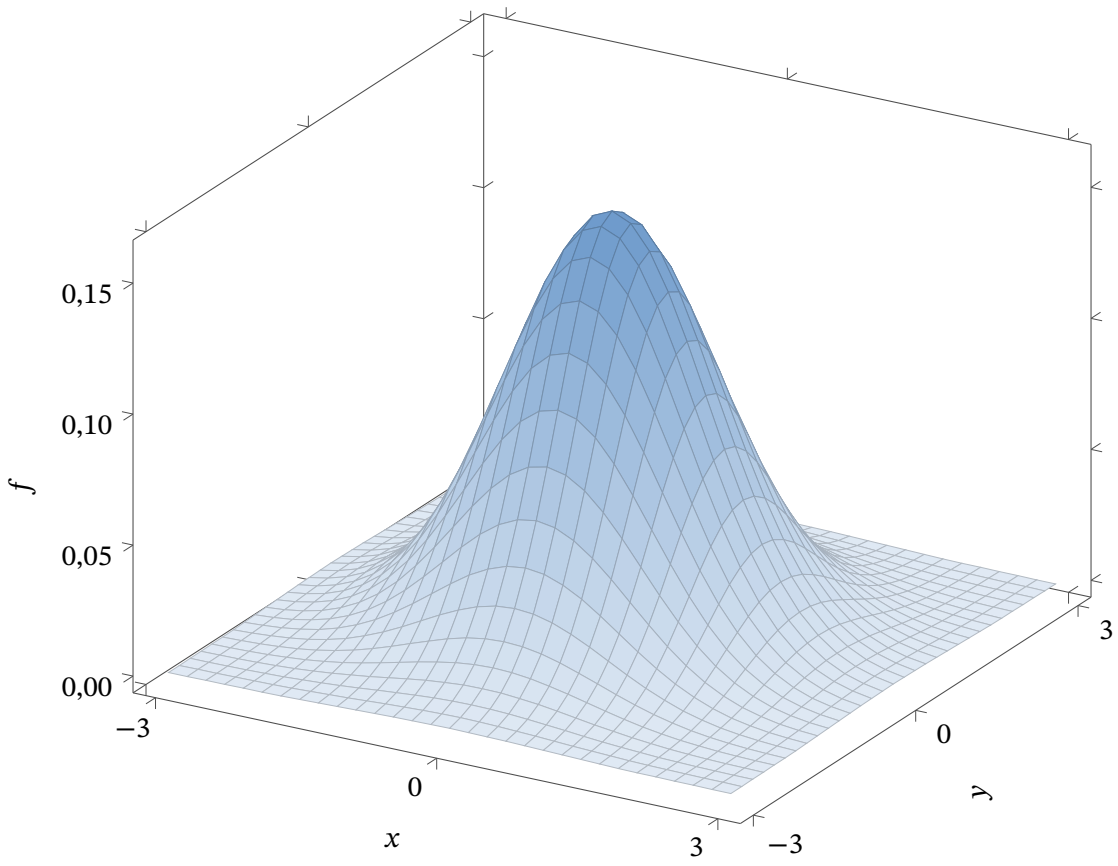


Figura 2.7.4: Gráfico da função densidade normal bivariada padrão.

dades de regiões mais gerais, como mostra o resultado a seguir. (Omitimos a demonstração. O caso particular $B = [a, b] \times [c, d]$ corresponde diretamente à definição de $f_{X,Y}$.)

Teorema 2.7.6

Sejam X e Y variáveis aleatórias conjuntamente absolutamente contínuas, com densidade conjunta $f_{X,Y}$, e seja $B \subseteq R^2$ uma região qualquer. Então

$$P\big((X, Y) \in B\big) = \int\int_B f(x, y)\, dx\, dy.$$

A discussão anterior girou em torno de apenas *duas* variáveis aleatórias, X e Y. De modo mais geral, podemos considerar n variáveis aleatórias $X_1, \ldots, X_n$. Se as variáveis aleatórias são todas discretas, então podemos definir também uma função de probabilidade conjunta $p_{X_1,\ldots,X_n} : R^n \to [0, 1]$ por $p_{X_1,\ldots,X_n}(x_1, \ldots, x_n) = P(X_1 = x_1, \ldots, X_n = x_n)$. Se as variáveis aleatórias são conjuntamente absolutamente contínuas, então podemos definir uma função densidade conjunta $f_{X_1,\ldots,X_n} : R^n \to [0, 1]^*$ de modo que

$$\begin{aligned} &P(a_1 \le X_1 \le b_1, \ldots, a_n \le X_n \le b_n) \\ &\quad = \int_{a_n}^{b_n} \cdots \int_{a_1}^{b_1} f_{X_1,\ldots,X_n}(x_1, \ldots, x_n)\, dx_1 \cdots dx_n, \end{aligned}$$

sempre que $a_i \le b_i$ para todo i.

Resumo da Seção 2.7

- Muitas vezes é importante registrar as probabilidades conjuntas de duas variáveis aleatórias, X e Y.
- Sua função de distribuição acumulada conjunta é dada por $F_{X,Y}(x, y) = P(X \le x, Y \le y)$.
- Se X e Y são discretas, então sua função de probabilidade conjunta é dada por $p_{X,Y}(x, y) = P(X = x, Y = y)$.
- Se X e Y são absolutamente contínuas, então sua função densidade conjunta $f_{X,Y}(x, y)$ é tal que $P(a \le X \le b, c \le Y \le d) = \int_c^d \int_a^b f_{X,Y}(x, y)\, dx\, dy$.
- A densidade marginal de X e de Y pode ser calculada a partir de qualquer uma das funções $F_{X,Y}$, $p_{X,Y}$ ou $f_{X,Y}$.

*Nota do tradutor. O original traz $[0, 1]$ como contradomínio da densidade conjunta; uma densidade pode passar de 1 (a do Exemplo 2.7.6 chega a 6), então seria $[0, \infty)$.

- Um exemplo importante de distribuição conjunta é a distribuição normal bivariada.

Exercícios

2.7.1 Seja $X \sim \text{Bernoulli}(1/3)$ e seja $Y = 4X - 2$. Calcule a fda conjunta $F_{X,Y}$.

2.7.2 Seja $X \sim \text{Bernoulli}(1/4)$ e seja $Y = -7X$. Calcule a fda conjunta $F_{X,Y}$.

2.7.3 Suponha que

$$p_{X,Y}(x,y) = \begin{cases} 1/5 & x = 2, y = 3 \\ 1/5 & x = 3, y = 2 \\ 1/5 & x = -3, y = -2 \\ 1/5 & x = -2, y = -3 \\ 1/5 & x = 17, y = 19 \\ 0 & \text{caso contrário.} \end{cases}$$

(a) Calcule p_X.

(b) Calcule p_Y.

(c) Calcule $P(Y > X)$.

(d) Calcule $P(Y = X)$.

(e) Calcule $P(XY < 0)$.

2.7.4 Para cada uma das funções densidade conjuntas $f_{X,Y}$ a seguir, encontre o valor de C e calcule $f_X(x)$, $f_Y(y)$ e $P(X \leq 0{,}8, Y \leq 0{,}6)$.

(a)

$$f_{X,Y}(x,y) = \begin{cases} 2x^2y + Cy^5 & 0 \leq x \leq 1, 0 \leq y \leq 1 \\ 0 & \text{caso contrário.} \end{cases}$$

(b)

$$f_{X,Y}(x,y) = \begin{cases} C(xy + x^5y^5) & 0 \leq x \leq 1, 0 \leq y \leq 1 \\ 0 & \text{caso contrário.} \end{cases}$$

(c)

$$f_{X,Y}(x,y) = \begin{cases} C(xy + x^5y^5) & 0 \leq x \leq 4, 0 \leq y \leq 10 \\ 0 & \text{caso contrário.} \end{cases}$$

(d)

$$f_{X,Y}(x,y) = \begin{cases} Cx^5y^5 & 0 \le x \le 4, 0 \le y \le 10 \\ 0 & \text{caso contrário.} \end{cases}$$

2.7.5 Prove que $F_{X,Y}(x,y) \le \min(F_X(x), F_Y(y))$.

2.7.6 Suponha que $P(X = x, Y = y) = 1/8$ para $x = 3, 5$ e $y = 1, 2, 4, 7$; caso contrário, $P(X = x, Y = y) = 0$. Calcule cada um dos itens a seguir.

(a) $F_{X,Y}(x,y)$ para todo $x, y \in R^1$

(b) $p_{X,Y}(x,y)$ para todo $x, y \in R^1$

(c) $p_X(x)$ para todo $x \in R^1$

(d) $p_Y(y)$ para todo $x \in R^1$*

(e) A fda marginal $F_X(x)$ para todo $x \in R^1$

(f) A fda marginal $F_Y(y)$ para todo $y \in R^1$

2.7.7 Sejam X e Y com densidade conjunta $f_{X,Y}(x,y) = c\sin(xy)$ para $0 < x < 1$ e $0 < y < 2$, e $f_{X,Y}(x,y) = 0$ caso contrário, para uma constante apropriada $c > 0$ (que não pode ser calculada explicitamente). Em termos de c, calcule cada um dos itens a seguir.

(a) A densidade marginal[41] $f_X(x)$ para todo $x \in R^1$

(b) A densidade marginal $f_Y(y)$ para todo $y \in R^1$

2.7.8 Sejam X e Y com densidade conjunta $f_{X,Y}(x,y) = (x^2 + y)/36$ para $-2 < x < 1$ e $0 < y < 4$, e $f_{X,Y}(x,y) = 0$ caso contrário. Calcule cada um dos itens a seguir.

(a) A densidade marginal $f_X(x)$ para todo $x \in R^1$

(b) A densidade marginal $f_Y(y)$ para todo $y \in R^1$

(c) $P(Y < 1)$

(d) A fda conjunta $F_{X,Y}(x,y)$ para todo $x, y \in R^1$

2.7.9 Sejam X e Y com densidade conjunta $f_{X,Y}(x,y) = (x^2 + y)/4$ para $0 < x < y < 2$, e $f_{X,Y}(x,y) = 0$ caso contrário. Calcule cada um dos itens a seguir.

*Nota do tradutor. O original traz "para todo $x \in R^1$"; pelo contexto seria $y \in R^1$.

No original: *marginal density*[41].

(a) A densidade marginal $f_X(x)$ para todo $x \in R^1$

(b) A densidade marginal $f_Y(y)$ para todo $y \in R^1$

(c) $P(Y < 1)$

2.7.10 Sejam X e Y com distribuição Normal Bivariada$(3, 5, 2, 4, 1/2)$.

(a) Especifique a distribuição marginal de X.

(b) Especifique a distribuição marginal de Y.

(c) X e Y são independentes? Por quê?

Problemas

2.7.11 Seja $X \sim$ Exponencial(λ) e seja $Y = X^3$. Calcule a fda conjunta, $F_{X,Y}(x, y)$.

2.7.12 Seja $F_{X,Y}$ uma fda conjunta. Prove que, para todo $y \in R^1$, $\lim_{x \to -\infty} F_{X,Y}(x, y) = 0$.

2.7.13 Sejam X e Y com distribuição Normal Bivariada$(\mu_1, \mu_2, \sigma_1, \sigma_2, \rho)$, como no Exemplo 2.7.9. Prove que $X \sim N(\mu_1, \sigma_1^2)$, provando que

$$\int_{-\infty}^{\infty} f_{X,Y}(x, y)\, dy = \frac{1}{\sigma_1 \sqrt{2\pi}} \exp\left\{-\frac{(x - \mu_1)^2}{2\sigma_1^2}\right\}.$$

2.7.14 Suponha que a densidade conjunta $f_{X,Y}$ seja dada por $f_{X,Y}(x, y) = Cye^{-xy}$ para $0 < x < 1$, $0 < y < 1$, e seja 0 caso contrário.

(a) Determine C de modo que $f_{X,Y}$ seja uma densidade.

(b) Calcule $P(1/2 < X < 1, 1/2 < Y < 1)$.

(c) Calcule as densidades marginais de X e de Y.

2.7.15 Suponha que a densidade conjunta $f_{X,Y}$ seja dada por $f_{X,Y}(x, y) = Cye^{-xy}$ para $0 < x < y < 1$, e seja 0 caso contrário.

(a) Determine C de modo que $f_{X,Y}$ seja uma densidade.

(b) Calcule $P(1/2 < X < 1, 1/2 < Y < 1)$.

(c) Calcule as densidades marginais de X e de Y.

2.7.16 Suponha que a densidade conjunta $f_{X,Y}$ seja dada por $f_{X,Y}(x, y) = Ce^{-(x+y)}$ para $0 < x < y < \infty$, e seja 0 caso contrário.

(a) Determine C de modo que $f_{X,Y}$ seja uma densidade.

(b) Calcule as densidades marginais de X e de Y.

2.7.17 (*Distribuição Dirichlet*[42]$(\alpha_1, \alpha_2, \alpha_3)$) Suponha que (X_1, X_2) tenha a densidade conjunta

$$f_{X_1,X_2}(x_1, x_2) = \frac{\Gamma(\alpha_1 + \alpha_2 + \alpha_3)}{\Gamma(\alpha_1)\,\Gamma(\alpha_2)\,\Gamma(\alpha_3)}\, x_1^{\alpha_1 - 1} x_2^{\alpha_2 - 1} (1 - x_1 - x_2)^{\alpha_3 - 1}$$

para $x_1 \geq 0$, $x_2 \geq 0$ e $0 \leq x_1 + x_2 \leq 1$. Uma distribuição Dirichlet muitas vezes se aplica quando X_1, X_2 e $1 - X_1 - X_2$ correspondem a proporções aleatórias.

(a) Prove que f_{X_1,X_2} é uma densidade. (Sugestão: esboce a região em que f_{X_1,X_2} é não negativa, integre primeiro em x_1 fazendo a transformação $u = x_1/(1 - x_2)$ nessa integral e use (2.4.10) do Problema 2.4.24.)

(b) Prove que $X_1 \sim \text{Beta}(\alpha_1, \alpha_2 + \alpha_3)$ e $X_2 \sim \text{Beta}(\alpha_2, \alpha_1 + \alpha_3)$.

2.7.18 (*Distribuição Dirichlet*$(\alpha_1, \ldots, \alpha_{k+1})$) Suponha que $(X_1, \ldots, X_k)$ tenha a densidade conjunta

$$\begin{aligned} &f_{X_1,\ldots,X_k}(x_1, \ldots, x_k) \\ &\quad = \frac{\Gamma(\alpha_1 + \cdots + \alpha_{k+1})}{\Gamma(\alpha_1) \cdots \Gamma(\alpha_{k+1})}\, x_1^{\alpha_1 - 1} \cdots x_k^{\alpha_k - 1} (1 - x_1 - \cdots - x_k)^{\alpha_{k+1} - 1} \end{aligned}$$

para $x_i \geq 0$, $i = 1, \ldots, k$, e $0 \leq x_1 + \cdots + x_k \leq 1$. Prove que $f_{X_1,\ldots,X_k}$ é uma densidade. (Sugestão: Problema 2.7.17.)

Desafios

2.7.19 Encontre um exemplo de duas variáveis aleatórias X e Y e de uma função $h : R^1 \to R^1$ tais que $F_X(x) > 0$ e $F_Y(x) > 0$ para todo $x \in R^1$, mas $\lim_{x\to\infty} F_{X,Y}(x, h(x)) = 0$.

Tópicos para discussão

2.7.20 Quais são exemplos de pares de quantidades aleatórias da vida real que têm relações interessantes? (Liste tantos quantos puder e descreva cada relação da melhor forma que puder.)

No original: *Dirichlet distribution*[42].

2.8 Condicionamento e Independência

Sejam X e Y duas variáveis aleatórias. Suponha que sabemos que $X = 5$. O que isso nos diz sobre Y? Dependendo da relação entre X e Y, isso pode nos dizer tudo sobre Y (por exemplo, se $Y = X$) ou nada sobre Y. Em geral, a resposta ficará entre esses dois extremos, e saber que $X = 5$ mudará um pouco as probabilidades de Y.

2.8.1 Condicionamento em Variáveis Aleatórias Discretas

Suponha que X é uma variável aleatória discreta, com $P(X = 5) > 0$. Seja $a < b$, e suponha que estamos interessados na probabilidade condicional[43] $P(a < Y \leq b \mid X = 5)$. Bem, já sabemos calcular probabilidades condicionais como essa. De fato, por (1.5.1),

$$P(a < Y \leq b \mid X = 5) = \frac{P(a < Y \leq b, X = 5)}{P(X = 5)},$$

desde que $P(X = 5) > 0$. Isso motiva a definição a seguir.

Definição 2.8.1

Sejam X e Y variáveis aleatórias, e suponha que $P(X = x) > 0$. A *distribuição condicional* de Y, dado que $X = x$, é a distribuição de probabilidade que atribui a probabilidade

$$\frac{P(Y \in B, X = x)}{P(X = x)}$$

a cada evento $Y \in B$. Em particular, ela atribui a probabilidade

$$\frac{P(a < Y \leq b, X = x)}{P(X = x)}$$

ao evento $a < Y \leq b$.

No original: *conditional probability*[43].

Exemplo 2.8.1

Suponha, como no Exemplo 2.7.5, que X e Y têm função de probabilidade conjunta

$$p_{X,Y}(x,y) = \begin{cases} 1/7 & x = 5, y = 0 \\ 1/7 & x = 5, y = 3 \\ 1/7 & x = 5, y = 4 \\ 3/7 & x = 8, y = 0 \\ 1/7 & x = 8, y = 4 \\ 0 & \text{caso contrário.} \end{cases}$$

Calculamos $P(Y = 4 \mid X = 8)$ como

$$P(Y = 4 \mid X = 8) = \frac{P(Y = 4, X = 8)}{P(X = 8)} = \frac{1/7}{(3/7) + (1/7)} = \frac{1/7}{4/7} = 1/4.$$

Por outro lado,

$$P(Y = 4 \mid X = 5) = \frac{P(Y = 4, X = 5)}{P(X = 5)} = \frac{1/7}{(1/7) + (1/7) + (1/7)} = \frac{1/7}{3/7} = 1/3.$$

Assim, dependendo do valor de X, obtemos probabilidades diferentes para Y. ■

Generalizando o exemplo acima, vemos que, se X e Y são discretas, então

$$P(Y = y \mid X = x) = \frac{P(Y = y, X = x)}{P(X = x)} = \frac{p_{X,Y}(x,y)}{p_X(x)} = \frac{p_{X,Y}(x,y)}{\sum_z p_{X,Y}(x,z)}.$$

Isso motiva a definição a seguir.

Definição 2.8.2

Suponha que X e Y são duas variáveis aleatórias discretas. Então a *função de probabilidade condicional* de Y, dado X, é a função $p_{Y|X}$ definida por

$$p_{Y|X}(y \mid x) = \frac{p_{X,Y}(x,y)}{\sum_z p_{X,Y}(x,z)} = \frac{p_{X,Y}(x,y)}{p_X(x)},$$

definida para todo $y \in R^1$ e todo x com $p_X(x) > 0$.

2.8.2 Condicionamento em Variáveis Aleatórias Contínuas

Se X é contínua, então teremos $P(X = x) = 0$. Nesse caso, as Definições 2.8.1 e 2.8.2 não podem ser usadas, porque não podemos dividir por 0. Então, como podemos condicionar em $X = x$ nesse caso?

Uma abordagem é sugerida por condicionar, em vez disso, em $x - \epsilon < X \leq x + \epsilon$, em que $\epsilon > 0$ é um número muito pequeno. Mesmo que X seja contínua, ainda podemos ter $P(x - \epsilon \leq X \leq x + \epsilon) > 0$. Por outro lado, se ϵ é muito pequeno e $x - \epsilon \leq X \leq x + \epsilon$, então X tem de estar muito próximo de x.

De fato, suponha que X e Y são conjuntamente absolutamente contínuas, com função densidade conjunta $f_{X,Y}$. Então

$$\begin{aligned} P(a \leq Y \leq b \mid x - \epsilon \leq X \leq x + \epsilon) &= \frac{P(a \leq Y \leq b, x - \epsilon \leq X \leq x + \epsilon)}{P(x - \epsilon \leq X \leq x + \epsilon)} \\ &= \frac{\int_a^b \int_{x-\epsilon}^{x+\epsilon} f_{X,Y}(t, y)\, dt\, dy}{\int_{-\infty}^{\infty} \int_{x-\epsilon}^{x+\epsilon} f_{X,Y}(t, y)\, dt\, dy}. \end{aligned}$$

Na Figura 2.8.1, representamos a região $\{(x, y) : a \leq y \leq b, x - \epsilon < x \leq x + \epsilon\}$ para (X, Y).

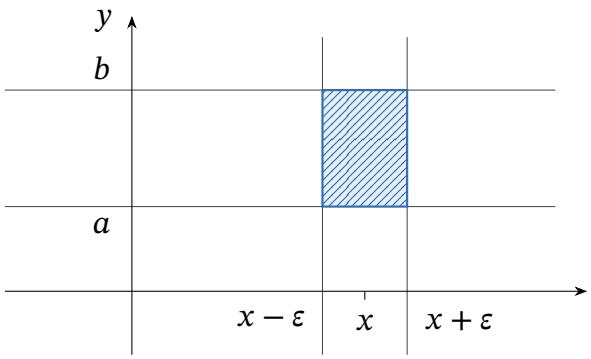


Figura 2.8.1: A região sombreada é o conjunto $\{(x, y) : a \leq y \leq b, x - \epsilon \leq x \leq x + \epsilon\}$.

Agora, se ϵ é muito pequeno, então nas integrais acima teremos sempre t muito próximo de x. Se $f_{X,Y}$ é uma função contínua, isso implica que $f_{X,Y}(t, y)$ estará

muito próximo de $f_{X,Y}(x,y)$. Concluímos que, se ϵ é muito pequeno, então

$$\begin{aligned} P(a \leq Y \leq b \mid x-\epsilon \leq X \leq x+\epsilon) &\approx \frac{\int_a^b \int_{x-\epsilon}^{x+\epsilon} f_{X,Y}(x,y)\,dt\,dy}{\int_{-\infty}^{\infty} \int_{x-\epsilon}^{x+\epsilon} f_{X,Y}(x,y)\,dt\,dy} \\ &= \frac{\int_a^b 2\epsilon\, f_{X,Y}(x,y)\,dy}{\int_{-\infty}^{\infty} 2\epsilon\, f_{X,Y}(x,y)\,dy} \\ &= \int_a^b \frac{f_{X,Y}(x,y)}{\int_{-\infty}^{\infty} f_{X,Y}(x,z)\,dz}\,dy. \end{aligned}$$

Isso sugere que a quantidade

$$\frac{f_{X,Y}(x,y)}{\int_{-\infty}^{\infty} f_{X,Y}(x,z)\,dz} = \frac{f_{X,Y}(x,y)}{f_X(x)}$$

faz o papel de uma densidade para a distribuição condicional de Y, dado que $X = x$. Isso motiva as definições a seguir.

Definição 2.8.3

Sejam X e Y conjuntamente absolutamente contínuas, com função densidade conjunta $f_{X,Y}$. A *densidade condicional* de Y, dado $X = x$, é a função $f_{Y|X}(y \mid x)$, definida por

$$f_{Y|X}(y \mid x) = \frac{f_{X,Y}(x,y)}{f_X(x)},$$

válida para todo $y \in R^1$ e para todo x tal que $f_X(x) > 0$.

Definição 2.8.4

Sejam X e Y conjuntamente absolutamente contínuas, com função densidade conjunta $f_{X,Y}$. A *distribuição condicional* de Y, dado $X = x$, é definida estabelecendo que

$$P(a \leq Y \leq b \mid X = x) = \int_a^b f_{Y|X}(y \mid x)\,dy,$$

quando $a \leq b$, com $f_{Y|X}$ como na Definição 2.8.3, válida para todo x tal que $f_X(x) > 0$.

Exemplo 2.8.2

Sejam X e Y com densidade conjunta

$$f_{X,Y}(x,y) = \begin{cases} 4x^2y + 2y^5 & 0 \le x \le 1, 0 \le y \le 1 \\ 0 & \text{caso contrário,} \end{cases}$$

como nos Exemplos 2.7.6 e 2.7.7.

Sabemos, pelo Exemplo 2.7.7, que

$$f_X(x) = \begin{cases} 2x^2 + (1/3) & 0 \le x \le 1 \\ 0 & \text{caso contrário,} \end{cases}$$

enquanto

$$f_Y(y) = \begin{cases} \frac{4}{3}y + 2y^5 & 0 \le y \le 1 \\ 0 & \text{caso contrário.} \end{cases}$$

Vamos agora calcular $P(0{,}2 \le Y \le 0{,}3 \mid X = 0{,}8)$. Usando as Definições 2.8.4 e 2.8.3, temos

$$\begin{aligned} &P(0{,}2 \le Y \le 0{,}3 \mid X = 0{,}8) \\ &= \int_{0{,}2}^{0{,}3} f_{Y|X}(y \mid 0{,}8)\, dy = \frac{\int_{0{,}2}^{0{,}3} f_{X,Y}(0{,}8; y)\, dy}{f_X(0{,}8)} = \frac{\int_{0{,}2}^{0{,}3} \left(4\,(0{,}8)^2\, y + 2y^5\right) dy}{2\,(0{,}8)^2 + \frac{1}{3}} \\ &= \frac{\frac{4}{2}\,(0{,}8)^2\left((0{,}3)^2 - (0{,}2)^2\right) + \frac{2}{6}\left((0{,}3)^6 - (0{,}2)^6\right)}{2\,(0{,}8)^2 + \frac{1}{3}} = 0{,}0398. \end{aligned}$$

Em contraste, se calculamos a probabilidade *não condicionada* (isto é, a usual) de que $0{,}2 \le Y \le 0{,}3$, vemos que

$$\begin{aligned} P(0{,}2 \le Y \le 0{,}3) &= \int_{0{,}2}^{0{,}3} f_Y(y)\, dy = \int_{0{,}2}^{0{,}3} \left(\frac{4}{3}y + 2y^5\right) dy \\ &= \frac{4}{3}\frac{1}{2}\left((0{,}3)^2 - (0{,}2)^2\right) + \frac{2}{6}\left((0{,}3)^6 - (0{,}2)^6\right) = 0{,}0336. \end{aligned}$$

Vemos, assim, que condicionar em $X = 0{,}8$ aumenta a probabilidade de que $0{,}2 \le Y \le 0{,}3$, de cerca de 0,0336 para cerca de 0,0398. ■

Por analogia com o Teorema 1.3.1, temos o seguinte.

Teorema 2.8.1 (Lei da probabilidade total, versão para variáveis aleatórias absolutamente contínuas)

Sejam X e Y variáveis aleatórias conjuntamente absolutamente contínuas, e sejam $a \leq b$ e $c \leq d$. Então

$$P(a \leq X \leq b, c \leq Y \leq d) = \int_c^d \int_a^b f_X(x)\, f_{Y|X}(y \mid x)\, dx\, dy.$$

Mais geralmente, se $B \subseteq R^2$ é uma região qualquer, então

$$P\big((X, Y) \in B\big) = \iint_B f_X(x)\, f_{Y|X}(y \mid x)\, dx\, dy.$$

Demonstração. Pela Definição 2.8.3,

$$f_X(x)\, f_{Y|X}(y \mid x) = f_{X,Y}(x, y).$$

Portanto, o resultado segue imediatamente da Definição 2.7.4 e do Teorema 2.7.6. ■

2.8.3 Independência de Variáveis Aleatórias

Lembre-se da Definição 1.5.2: dois eventos A e B são *independentes* se $P(A \cap B) = P(A)\, P(B)$. Queremos ter uma definição correspondente de independência para variáveis aleatórias X e Y. Intuitivamente, a independência de X e Y significa que X e Y não exercem nenhuma influência uma sobre a outra, isto é, que os valores de X não alteram em nada as probabilidades de Y (e vice-versa).

A ideia da definição formal é que X e Y dão origem a eventos da forma "$a < X \leq b$" ou "$Y \in B$", e queremos que todos esses eventos envolvendo X sejam independentes de todos esses eventos envolvendo Y. Mais precisamente, nossa definição é a seguinte.

Definição 2.8.5

Sejam X e Y duas variáveis aleatórias. Então X e Y são *independentes* se, para todos os subconjuntos B_1 e B_2 dos números reais,

$$P(X \in B_1, Y \in B_2) = P(X \in B_1)\, P(Y \in B_2).$$

Isto é, os eventos "$X \in B_1$" e "$Y \in B_2$" são eventos independentes.

Intuitivamente, X e Y são independentes se não exercem nenhuma influência uma sobre a outra, como veremos.

Ora, é muito difícil trabalhar com a Definição 2.8.5. Felizmente, existe uma caracterização da independência muito mais simples.

Teorema 2.8.2

Sejam X e Y duas variáveis aleatórias. Então X e Y são independentes se e somente se

$$P(a \leq X \leq b, c \leq Y \leq d) = P(a \leq X \leq b)\, P(c \leq Y \leq d) \tag{2.8.1}$$

sempre que $a \leq b$ e $c \leq d$.

Isto é, X e Y são independentes se e somente se os eventos "$a \leq X \leq b$" e "$c \leq Y \leq d$" são eventos independentes sempre que $a \leq b$ e $c \leq d$.

Não demonstraremos o Teorema 2.8.2 aqui, embora a demonstração seja semelhante, em espírito, à do Teorema 2.5.1. No entanto, às vezes usaremos (2.8.1) para verificar a independência de X e Y.

Ainda assim, nem mesmo (2.8.1) é tão fácil de verificar diretamente. Para distribuições discretas e para distribuições absolutamente contínuas, há condições mais fáceis, como segue.

Teorema 2.8.3

Sejam X e Y duas variáveis aleatórias.

(a) Se X e Y são discretas, então X e Y são independentes se e somente se sua função de probabilidade conjunta $p_{X,Y}$ satisfaz

$$p_{X,Y}(x,y) = p_X(x)\, p_Y(y)$$

para todo $x, y \in R^1$.

(b) Se X e Y são conjuntamente absolutamente contínuas, então X e Y são independentes se e somente se sua função densidade conjunta $f_{X,Y}$ pode ser escolhida de modo a satisfazer

$$f_{X,Y}(x,y) = f_X(x)\, f_Y(y)$$

para todo $x, y \in R^1$.

Demonstração. (a) Se X e Y são independentes, então, fazendo $a = b = x$ e $c = d = y$ em (2.8.1), vemos que $P(X = x, Y = y) = P(X = x)\,P(Y = y)$. Portanto, $p_{X,Y}(x,y) = p_X(x)\, p_Y(y)$.

Reciprocamente, se $p_{X,Y}(x,y) = p_X(x)\, p_Y(y)$ para todo x e y, então

$$\begin{aligned} &P(a \le X \le b, c \le Y \le d) \\ &\quad = \sum_{a\le x\le b} \sum_{c\le y\le d} p_{X,Y}(x,y) = \sum_{a\le x\le b} \sum_{c\le y\le d} p_X(x)\, p_Y(y) \\ &\quad = \left(\sum_{a\le x\le b} p_X(x)\right)\left(\sum_{c\le y\le d} p_Y(y)\right) = P(a \le X \le b)\, P(c \le Y \le d). \end{aligned}$$

Isso completa a demonstração de (a).

(b) Se $f_{X,Y}(x,y) = f_X(x)\, f_Y(y)$ para todo x e y, então

$$\begin{aligned} &P(a \le X \le b, c \le Y \le d) \\ &\quad = \int_a^b \int_c^d f_{X,Y}(x,y)\, dy\, dx = \int_a^b \int_c^d f_X(x)\, f_Y(y)\, dy\, dx \\ &\quad = \left(\int_a^b f_X(x)\, dx\right)\left(\int_c^d f_Y(y)\, dy\right) = P(a \le X \le b)\, P(c \le Y \le d). \end{aligned}$$

Isso completa a demonstração da parte "se" de (b). A demonstração da parte "somente se" de (b) é mais técnica, e não a incluímos aqui. ■

Exemplo 2.8.3

Sejam X e Y com densidade conjunta, como no Exemplo 2.7.6,

$$f_{X,Y}(x,y) = \begin{cases} 4x^2y + 2y^5 & 0 \le x \le 1, 0 \le y \le 1 \\ 0 & \text{caso contrário} \end{cases}$$

e, portanto, como obtido no Exemplo 2.7.7, densidades marginais

$$f_X(x) = \begin{cases} 2x^2 + (1/3) & 0 \le x \le 1 \\ 0 & \text{caso contrário} \end{cases}$$

e

$$f_Y(y) = \begin{cases} \frac{4}{3}y + 2y^5 & 0 \le y \le 1 \\ 0 & \text{caso contrário.} \end{cases}$$

Calculamos, então, que

$$f_X(x)\, f_Y(y) = \begin{cases} \left(2x^2 + (1/3)\right)\left(\frac{4}{3}y + 2y^5\right) & 0 \le x \le 1, 0 \le y \le 1 \\ 0 & \text{caso contrário.} \end{cases}$$

Vemos, assim, que $f_X(x)\, f_Y(y) \neq f_{X,Y}(x,y)$. Portanto, X e Y *não* são independentes. ■

Exemplo 2.8.4

Sejam X e Y com densidade conjunta

$$f_{X,Y}(x,y) = \begin{cases} \frac{1}{8080}(12xy^2 + 6x + 4y^2 + 2) & 0 \le x \le 6, 3 \le y \le 5 \\ 0 & \text{caso contrário.} \end{cases}$$

Calculamos as densidades marginais como

$$f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x,y)\,dy = \begin{cases} \frac{1}{60} + \frac{1}{20}x & 0 \le x \le 6 \\ 0 & \text{caso contrário,} \end{cases}$$

e

$$f_Y(y) = \int_{-\infty}^{\infty} f_{X,Y}(x,y)\,dx = \begin{cases} \frac{3}{202} + \frac{3}{101}y^2 & 3 \le y \le 5 \\ 0 & \text{caso contrário.} \end{cases}$$

Calculamos, então, que

$$f_X(x)\,f_Y(y) = \begin{cases} (\frac{1}{60} + \frac{1}{20}x)(\frac{3}{202} + \frac{3}{101}y^2) & 0 \le x \le 6, 3 \le y \le 5 \\ 0 & \text{caso contrário.} \end{cases}$$

Fazendo a multiplicação, vemos que $f_X(x)\,f_Y(y) = f_{X,Y}(x,y)$. Portanto, neste caso, X e Y *são* independentes. ■

Combinando o Teorema 2.8.3 com as Definições 2.8.2 e 2.8.3, obtemos imediatamente o resultado a seguir sobre independência. Ele diz que a independência de variáveis aleatórias equivale a dizer que condicionar em uma delas não tem efeito sobre a outra, o que corresponde a uma noção intuitiva de independência.

Teorema 2.8.4

Sejam X e Y duas variáveis aleatórias.

(a) Se X e Y são discretas, então X e Y são independentes se e somente se $p_{Y|X}(y \mid x) = p_Y(y)$ para todo $x, y \in R^1$.

(b) Se X e Y são conjuntamente absolutamente contínuas, então X e Y são independentes se e somente se $f_{Y|X}(y \mid x) = f_Y(y)$ para todo $x, y \in R^1$.

Embora seja bem difícil trabalhar com a Definição 2.8.5, ela fornece o modo mais fácil de demonstrar uma propriedade muito importante da independência, como segue.

Teorema 2.8.5

Sejam X e Y variáveis aleatórias independentes. Sejam $f, g : R^1 \to R^1$ duas funções quaisquer. Então as variáveis aleatórias $f(X)$ e $g(Y)$ também são independentes.

Demonstração. Usando a Definição 2.8.5, calculamos que

$$\begin{aligned} P\big(f(X) \in B_1, g(Y) \in B_2\big) &= P\big(X \in f^{-1}(B_1), Y \in g^{-1}(B_2)\big) \\ &= P\big(X \in f^{-1}(B_1)\big)\, P\big(Y \in g^{-1}(B_2)\big) \\ &= P\big(f(X) \in B_1\big)\, P\big(g(Y) \in B_2\big). \end{aligned}$$

(Aqui, $f^{-1}(B_1) = \{x \in R^1 : f(x) \in B_1\}$ e $g^{-1}(B_2) = \{y \in R^1 : g(y) \in B_2\}$.) Como isso vale para quaisquer B_1 e B_2, vemos que $f(X)$ e $g(Y)$ são independentes. ■

Suponha agora que temos n variáveis aleatórias $X_1, \ldots, X_n$. As variáveis aleatórias são *independentes* se e somente se a coleção de eventos $\{a_i \le X_i \le b_i\}$ é independente, sempre que $a_i \le b_i$, para todo $i = 1, 2, \ldots, n$. Generalizando o Teorema 2.8.3, temos o resultado a seguir.

Teorema 2.8.6

Seja $X_1, \ldots, X_n$ uma coleção de variáveis aleatórias.

(a) Se $X_1, \ldots, X_n$ são discretas, então $X_1, \ldots, X_n$ são independentes se e somente se sua função de probabilidade conjunta $p_{X_1,\ldots,X_n}$ satisfaz

$$p_{X_1,\ldots,X_n}(x_1, \ldots, x_n) = p_{X_1}(x_1) \cdots p_{X_n}(x_n)$$

para todo $x_1, \ldots, x_n \in R^1$.

(b) Se $X_1, \ldots, X_n$ são conjuntamente absolutamente contínuas, então $X_1, \ldots, X_n$ são independentes se e somente se sua função densidade conjunta $f_{X_1,\ldots,X_n}$ pode ser escolhida de modo a satisfazer

$$f_{X_1,\ldots,X_n}(x, y) = f_{X_1}(x_1) \cdots f_{X_n}(x_n)$$

* para todo $x_1, \ldots, x_n \in R^1$.

Um caso particularmente comum em estatística é o seguinte.

*Nota do tradutor. o original traz $f_{X_1,\ldots,X_n}(x, y)$; pelo contexto seria $f_{X_1,\ldots,X_n}(x_1, \ldots, x_n)$

Definição 2.8.6

Uma coleção $X_1, \ldots, X_n$ de variáveis aleatórias é *independente e identicamente distribuída* (ou *i.i.d.*) se a coleção é independente e se, além disso, cada uma das n variáveis tem a mesma distribuição. A sequência i.i.d. $X_1, \ldots, X_n$ também é chamada de *amostra* da distribuição comum.

Em particular, se uma coleção $X_1, \ldots, X_n$ de variáveis aleatórias é i.i.d. e *discreta*, então as funções de probabilidade p_{X_i} são todas iguais, de modo que $p_{X_1}(x) = p_{X_2}(x) = \cdots = p_{X_n}(x) \equiv p(x)$, para todo $x \in R^1$. Além disso, pelo Teorema 2.8.6(a), segue que

$$p_{X_1,\ldots,X_n}(x_1, \ldots, x_n) = p_{X_1}(x_1)\, p_{X_2}(x_2) \cdots p_{X_n}(x_n) = p(x_1)\, p(x_2) \cdots p(x_n)$$

para todo $x_1, \ldots, x_n \in R^1$.

Da mesma forma, se uma coleção $X_1, \ldots, X_n$ de variáveis aleatórias é i.i.d. e *conjuntamente absolutamente contínua*, então as funções densidade f_{X_i} são todas iguais, de modo que $f_{X_1}(x) = f_{X_2}(x) = \cdots = f_{X_n}(x) \equiv f(x)$, para todo $x \in R^1$. Além disso, pelo Teorema 2.8.6(b), segue que

$$f_{X_1,\ldots,X_n}(x_1, \ldots, x_n) = f_{X_1}(x_1)\, f_{X_2}(x_2) \cdots f_{X_n}(x_n) = f(x_1)\, f(x_2) \cdots f(x_n)$$

para todo $x_1, \ldots, x_n \in R^1$.

Consideramos agora uma família importante de distribuições discretas que surgem por meio de amostragem.

Exemplo 2.8.5 — Distribuições Multinomiais

Suponha que temos uma resposta s que pode assumir três valores possíveis — por conveniência, rotulados 1, 2 e 3 — com a distribuição de probabilidade

$$P(s = 1) = \theta_1, \quad P(s = 2) = \theta_2, \quad P(s = 3) = \theta_3,$$

de modo que cada $\theta_i \geq 0$ e $\theta_1 + \theta_2 + \theta_3 = 1$. Como exemplo simples, considere uma tigela de fichas na qual uma proporção θ_i das fichas está rotulada com i (para $i = 1, 2, 3$). Se retiramos ao acaso uma ficha da tigela e observamos seu rótulo s, então $P(s = i) = \theta_i$. Alternativamente, considere uma população de estudantes de uma universidade, da qual uma proporção θ_1 mora no campus (indicado por $s = 1$), uma proporção θ_2 mora fora do campus com os pais (indicado por $s = 2$) e uma proporção θ_3 mora fora do campus por conta própria (indicado por $s = 3$). Se sorteamos um estudante dessa população e determinamos s para esse estudante,

então $P(s = i) = \theta_i$.

Também podemos escrever

$$P(s = i) = \theta_1^{I_{\{1\}}(i)}\, \theta_2^{I_{\{2\}}(i)}\, \theta_3^{I_{\{3\}}(i)}$$

para $i \in \{1, 2, 3\}$, em que $I_{\{j\}}$ é a função indicadora de $\{j\}$. Portanto, se $(s_1, \ldots, s_n)$ é uma amostra da distribuição em $\{1, 2, 3\}$ dada pelos θ_i, o Teorema 2.8.6(a) implica que a função de probabilidade conjunta da amostra é igual a

$$P(s_1 = k_1, \ldots, s_n = k_n) = \prod_{j=1}^{n} \theta_1^{I_{\{1\}}(k_j)}\, \theta_2^{I_{\{2\}}(k_j)}\, \theta_3^{I_{\{3\}}(k_j)} = \theta_1^{x_1} \theta_2^{x_2} \theta_3^{x_3}, \qquad (2.8.2)$$

em que $x_i = \sum_{j=1}^{n} I_{\{i\}}(k_j)$ é igual ao número de i's em $(k_1, \ldots, k_n)$.

Agora, com base na amostra $(s_1, \ldots, s_n)$, defina as variáveis aleatórias

$$X_i = \sum_{j=1}^{n} I_{\{i\}}(s_j)$$

para $i = 1$, 2 e 3. Claramente, X_i é o número de i's observados na amostra, e sempre temos $X_i \in \{0, 1, \ldots, n\}$ e $X_1 + X_2 + X_3 = n$. Chamamos os X_i de *contagens* formadas a partir da amostra.

Para (x_1, x_2, x_3) satisfazendo $x_i \in \{0, 1, \ldots, n\}$ e $x_1 + x_2 + x_3 = n$, (2.8.2) implica que a função de probabilidade conjunta de (X_1, X_2, X_3) é dada por

$$\begin{aligned} p_{(X_1,X_2,X_3)}(x_1, x_2, x_3) &= P(X_1 = x_1, X_2 = x_2, X_3 = x_3) \\ &= C(x_1, x_2, x_3)\, \theta_1^{x_1} \theta_2^{x_2} \theta_3^{x_3}, \end{aligned}$$

em que $C(x_1, x_2, x_3)$ é igual ao número de amostras $(s_1, \ldots, s_n)$ com x_1 de seus elementos iguais a 1, x_2 de seus elementos iguais a 2 e x_3 de seus elementos iguais a 3. Para calcular $C(x_1, x_2, x_3)$, notamos que há $\binom{n}{x_1}$ escolhas para as posições dos 1's na sequência amostral, $\binom{n-x_1}{x_2}$ escolhas para as posições dos 2's na sequência e, por fim, $\binom{n-x_1-x_2}{x_3} = 1$ escolha para as posições dos 3's na sequência (lembre-se do coeficiente multinomial definido em (1.4.4)). Portanto, a função de probabilidade das contagens (X_1, X_2, X_3) é igual a

$$\begin{aligned} p_{(X_1,X_2,X_3)}(x_1, x_2, x_3) &= \binom{n}{x_1}\binom{n - x_1}{x_2}\binom{n - x_1 - x_2}{x_3} \theta_1^{x_1} \theta_2^{x_2} \theta_3^{x_3} \\ &= \binom{n}{x_1\ x_2\ x_3} \theta_1^{x_1} \theta_2^{x_2} \theta_3^{x_3}. \end{aligned}$$

Dizemos que

$$(X_1, X_2, X_3) \sim \text{Multinomial}(n, \theta_1, \theta_2, \theta_3).$$

Note que a distribuição Multinomial$(n, \theta_1, \theta_2, \theta_3)$ generaliza a distribuição Binomial(n, θ), já que agora contamos o número de valores da resposta em três categorias possíveis, e não em duas. Além disso, é imediato que

$$X_i \sim \text{Binomial}(n, \theta_i),$$

porque X_i é igual ao número de ocorrências de i nos n valores independentes da resposta, e i ocorre em uma resposta individual com probabilidade igual a θ_i (veja também o Problema 2.8.18). *

Como exemplo simples, suponha que temos uma urna contendo 10 bolas vermelhas, 20 bolas brancas e 30 bolas pretas. Se retiramos ao acaso 10 bolas da urna, com reposição, qual é a probabilidade de obtermos 3 bolas vermelhas, 4 brancas e 3 pretas? Como as retiradas são com reposição, elas são i.i.d., e então as contagens têm distribuição Multinomial$(10, 10/60, 20/60, 30/60)$. A probabilidade procurada é igual a

$$\binom{10}{3\,4\,3}\left(\frac{10}{60}\right)^3\left(\frac{20}{60}\right)^4\left(\frac{30}{60}\right)^3 = 3{,}0007 \times 10^{-2}.$$

Note que, se as retiradas fossem sem reposição, elas não seriam i.i.d., e as contagens, portanto, não seguiriam uma distribuição multinomial, mas sim uma generalização da distribuição hipergeométrica, como discutido no Problema 2.3.29.

Suponha agora que temos uma resposta s que assume k valores possíveis — por conveniência, rotulados $1, 2, \ldots, k$ — com a distribuição de probabilidade dada por $P(s = i) = \theta_i$. Para uma amostra $(s_1, \ldots, s_n)$, defina as contagens $X_i = \sum_{j=1}^{n} I_{\{i\}}(s_j)$ para $i = 1, \ldots k$. Então, argumentando como acima e lembrando a dedução de (1.4.4), temos

$$p_{(X_1,\ldots,X_k)}(x_1, \ldots, x_k) = \binom{n}{x_1 \;\ldots\; x_k}\theta_1^{x_1} \cdots \theta_k^{x_k}$$

sempre que cada $x_i \in \{0, \ldots, n\}$ e $x_1 + \cdots + x_k = n$. Nesse caso, escrevemos

$$(X_1, \ldots, X_k) \sim \text{Multinomial}(n, \theta_1, \ldots, \theta_k).$$

■

*Nota do tradutor. o original remete ao Problema 2.8.18; pelo conteúdo seria o 2.8.22

2.8.4 Estatísticas de Ordem

Suponha agora que $(X_1, \ldots, X_n)$ é uma amostra. Em muitas aplicações da estatística, teremos n valores de dados para os quais faz sentido supor que eles surgem como uma sequência i.i.d. É frequentemente de interesse, então, ordená-los do menor para o maior, obtendo as *estatísticas de ordem*[44]

$$X_{(1)}, \ldots, X_{(n)}.$$

Aqui, $X_{(i)}$ é igual ao i-ésimo menor valor da amostra $X_1, \ldots, X_n$. Assim, por exemplo, se $n = 5$ e

$$X_1 = 2{,}3; \quad X_2 = 4{,}5; \quad X_3 = -1{,}2; \quad X_4 = 2{,}2; \quad X_5 = 4{,}3,$$

então

$$X_{(1)} = -1{,}2; \quad X_{(2)} = 2{,}2; \quad X_{(3)} = 2{,}3; \quad X_{(4)} = 4{,}3; \quad X_{(5)} = 4{,}5.$$

Em muitas situações, as distribuições das estatísticas de ordem são de considerável interesse. Considere os exemplos a seguir.

Exemplo 2.8.6 — Distribuição do Máximo Amostral

Suponha que $X_1, X_2, \ldots, X_n$ são i.i.d., de modo que $F_{X_1}(x) = F_{X_2}(x) = \cdots = F_{X_n}(x)$. Então a *estatística de maior ordem* $X_{(n)} = \max(X_1, X_2, \ldots, X_n)$ é o *máximo* dessas n variáveis aleatórias.

Ora, $X_{(n)}$ é outra variável aleatória. Qual é a sua função de distribuição acumulada? Vemos que $X_{(n)} \leq x$ se e somente se $X_i \leq x$ para todo i. Portanto,

$$\begin{aligned} F_{X_{(n)}}(x) &= P(X_{(n)} \leq x) = P(X_1 \leq x, X_2 \leq x, \ \ldots, X_n \leq x) \\ &= P(X_1 \leq x)\, P(X_2 \leq x) \cdots P(X_n \leq x) = F_{X_1}(x)\, F_{X_2}(x) \cdots F_{X_n}(x) \\ &= \big(F_{X_1}(x)\big)^n. \end{aligned}$$

Se F_{X_1} corresponde a uma distribuição absolutamente contínua, então podemos derivar essa expressão para obter a densidade de $X_{(n)}$. ■

No original: *order statistics*[44].

Exemplo 2.8.7

Como caso particular do Exemplo 2.8.6, suponha que $X_1, X_2, \ldots, X_n$ são identicamente e independentemente distribuídas Uniforme$[0,1]$. Pelo que vimos acima, para $0 \leq x \leq 1$, temos $F_{X_{(n)}}(x) = \big(F_{X_1}(x)\big)^n = x^n$. Segue então do Corolário 2.5.1 que a densidade $f_{X_{(n)}}$ de $X_{(n)}$ é igual a $f_{X_{(n)}}(x) = F'_{X_{(n)}}(x) = nx^{n-1}$ para $0 \leq x \leq 1$, com (naturalmente) $f_{X_{(n)}}(x) = 0$ para $x < 0$ e $x > 1$. Note que, pelo Problema 2.4.24, podemos escrever $X_{(n)} \sim \text{Beta}(n, 1)$. ■

Exemplo 2.8.8 — Distribuição do Mínimo Amostral

Seguindo o Exemplo 2.8.6, também podemos obter a função de distribuição do mínimo amostral, ou *estatística de menor ordem*, $X_{(1)} = \min(X_1, X_2, \ldots, X_n)$. Temos

$$\begin{aligned} F_{X_{(1)}}(x) &= P(X_{(1)} \leq x) \\ &= 1 - P(X_{(1)} > x) \\ &= 1 - P(X_1 > x, X_2 > x, \ldots, X_n > x) \\ &= 1 - P(X_1 > x)\,P(X_2 > x) \cdots P(X_n > x) \\ &= 1 - \big(1 - F_{X_1}(x)\big)\big(1 - F_{X_2}(x)\big) \cdots \big(1 - F_{X_n}(x)\big) \\ &= 1 - \big(1 - F_{X_1}(x)\big)^n. \end{aligned}$$

Novamente, se F_{X_1} corresponde a uma distribuição absolutamente contínua, podemos derivar essa expressão para obter a densidade de $X_{(1)}$. ■

Exemplo 2.8.9

Sejam $X_1, \ldots, X_n$ i.i.d. Uniforme$[0,1]$. Então, para $0 \leq x \leq 1$,

$$F_{X_{(1)}}(x) = P(X_{(1)} \leq x) = 1 - P(X_{(1)} > x) = 1 - (1-x)^n.$$

Segue então do Corolário 2.5.1 que a densidade $f_{X_{(1)}}$ de $X_{(1)}$ satisfaz $f_{X_{(1)}}(x) = F'_{X_{(1)}}(x) = n(1-x)^{n-1}$ para $0 \leq x \leq 1$, com (naturalmente) $f_{X_{(1)}}(x) = 0$ para $x < 0$ e $x > 1$. Note que, pelo Problema 2.4.24, podemos escrever $X_{(1)} \sim \text{Beta}(1, n)$. ■

A mediana amostral[45] e os quartis amostrais[46] são definidos em termos das estatísticas de ordem e usados em aplicações estatísticas. Essas quantidades, e seus usos, são discutidos na Seção 5.5.

Resumo da Seção 2.8

- Se X e Y são discretas, então a função de probabilidade condicional de Y, dado X, é igual a $p_{Y|X}(y \mid x) = p_{X,Y}(x, y)/p_X(x)$.
- Se X e Y são absolutamente contínuas, então a função densidade condicional de Y, dado X, é igual a $f_{Y|X}(y \mid x) = f_{X,Y}(x, y)/f_X(x)$.
- X e Y são independentes se $P(X \in B_1, Y \in B_2) = P(X \in B_1)\, P(Y \in B_2)$ para todos $B_1, B_2 \subseteq R^1$.
- X e Y discretas são independentes se e somente se $p_{X,Y}(x, y) = p_X(x)\, p_Y(y)$ para todo $x, y \in R^1$ ou, equivalentemente, $p_{Y|X}(y \mid x) = p_Y(y)$.
- X e Y absolutamente contínuas são independentes se e somente se $f_{X,Y}(x, y) = f_X(x)\, f_Y(y)$ para todo $x, y \in R^1$ ou, equivalentemente, $f_{Y|X}(y \mid x) = f_Y(y)$.
- Uma sequência $X_1, X_2, \ldots, X_n$ é i.i.d. se as variáveis aleatórias são independentes e cada X_i tem a mesma distribuição.

Exercícios

2.8.1 Suponha que X e Y têm função de probabilidade conjunta

$$p_{X,Y}(x, y) = \begin{cases} 1/6 & x = -2, y = 3 \\ 1/12 & x = -2, y = 5 \\ 1/6 & x = 9, y = 3 \\ 1/12 & x = 9, y = 5 \\ 1/3 & x = 13, y = 3 \\ 1/6 & x = 13, y = 5 \\ 0 & \text{caso contrário.} \end{cases}$$

(a) Calcule $p_X(x)$ para todo $x \in R^1$.

(b) Calcule $p_Y(y)$ para todo $y \in R^1$.

No original: *sample median*[45], *sample quartiles*[46].

(c) Determine se X e Y são ou não independentes.

2.8.2 Suponha que X e Y têm função de probabilidade conjunta

$$p_{X,Y}(x,y) = \begin{cases} 1/16 & x = -2, y = 3 \\ 1/4 & x = -2, y = 5 \\ 1/2 & x = 9, y = 3 \\ 1/16 & x = 9, y = 5 \\ 1/16 & x = 13, y = 3 \\ 1/16 & x = 13, y = 5 \\ 0 & \text{caso contrário.} \end{cases}$$

(a) Calcule $p_X(x)$ para todo $x \in R^1$.

(b) Calcule $p_Y(y)$ para todo $y \in R^1$.

(c) Determine se X e Y são ou não independentes.

2.8.3 Suponha que X e Y têm função densidade conjunta

$$f_{X,Y}(x,y) = \begin{cases} \frac{12}{49}\left(2 + x + xy + 4y^2\right) & 0 \le x \le 1, 0 \le y \le 1 \\ 0 & \text{caso contrário.} \end{cases}$$

(a) Calcule $f_X(x)$ para todo $x \in R^1$.

(b) Calcule $f_Y(y)$ para todo $y \in R^1$.

(c) Determine se X e Y são ou não independentes.

2.8.4 Suponha que X e Y têm função densidade conjunta

$$f_{X,Y}(x,y) = \begin{cases} \frac{2}{5(2+e)}\left(3 + e^x + 3y + 3ye^y + ye^x + ye^{x+y}\right) & 0 \le x \le 1, 0 \le y \le 1 \\ 0 & \text{caso contrário.} \end{cases}$$

(a) Calcule $f_X(x)$ para todo $x \in R^1$.

(b) Calcule $f_Y(y)$ para todo $y \in R^1$.

(c) Determine se X e Y são ou não independentes.

2.8.5 Suponha que X e Y têm função de probabilidade conjunta

$$p_{X,Y}(x,y) = \begin{cases} 1/9 & x = -4, y = -2 \\ 2/9 & x = 5, y = -2 \\ 3/9 & x = 9, y = -2 \\ 2/9 & x = 9, y = 0 \\ 1/9 & x = 9, y = 4 \\ 0 & \text{caso contrário.} \end{cases}$$

(a) Calcule $P(Y = 4 \mid X = 9)$.

(b) Calcule $P(Y = -2 \mid X = 9)$.

(c) Calcule $P(Y = 0 \mid X = -4)$.

(d) Calcule $P(Y = -2 \mid X = 5)$.

(e) Calcule $P(X = 5 \mid Y = -2)$.

2.8.6 Sejam $X \sim \text{Bernoulli}(\theta)$ e $Y \sim \text{Geométrica}(\theta)$, com X e Y independentes. Seja $Z = X + Y$. Qual é a função de probabilidade de Z?

2.8.7 Para cada uma das funções densidade conjunta $f_{X,Y}$ a seguir (tiradas do Exercício 2.7.4), calcule a densidade condicional[47] $f_{Y|X}(y \mid x)$ e determine se X e Y são ou não independentes.

(a)
$$f_{X,Y}(x,y) = \begin{cases} 2x^2y + Cy^5 & 0 \le x \le 1, 0 \le y \le 1 \\ 0 & \text{caso contrário.} \end{cases}$$

(b)
$$f_{X,Y}(x,y) = \begin{cases} C(xy + x^5y^5) & 0 \le x \le 1, 0 \le y \le 1 \\ 0 & \text{caso contrário.} \end{cases}$$

(c)
$$f_{X,Y}(x,y) = \begin{cases} C(xy + x^5y^5) & 0 \le x \le 4, 0 \le y \le 10 \\ 0 & \text{caso contrário.} \end{cases}$$

(d)
$$f_{X,Y}(x,y) = \begin{cases} Cx^5y^5 & 0 \le x \le 4, 0 \le y \le 10 \\ 0 & \text{caso contrário.} \end{cases}$$

No original: *conditional density*[47].

2.8.8 Sejam X e Y variáveis aleatórias conjuntamente absolutamente contínuas. Suponha que $X \sim$ Exponencial(2) e que $P(Y > 5 \mid X = x) = e^{-3x}$. Calcule $P(Y > 5)$.

2.8.9 Dê um exemplo de duas variáveis aleatórias X e Y, cada uma assumindo valores no conjunto $\{1, 2, 3\}$, tais que $P(X = 1, Y = 1) = P(X = 1)\,P(Y = 1)$, mas X e Y *não* sejam independentes.

2.8.10 Sejam $X \sim$ Bernoulli(θ) e $Y \sim$ Bernoulli(ψ), em que $0 < \theta < 1$ e $0 < \psi < 1$. Suponha que $P(X = 1, Y = 1) = P(X = 1)\,P(Y = 1)$. Prove que X e Y têm de ser independentes.

2.8.11 Suponha que X é uma variável aleatória *constante* e que Y é uma variável aleatória qualquer. Prove que X e Y têm de ser independentes.

2.8.12 Suponha que $X \sim$ Bernoulli(1/3) e $Y \sim$ Poisson(λ), com X e Y independentes e com $\lambda > 0$. Calcule $P(X = 1 \mid Y = 5)$.

2.8.13 Suponha que $P(X = x, Y = y) = 1/8$ para $x = 3, 5$ e $y = 1, 2, 4, 7$; caso contrário, $P(X = x, Y = y) = 0$.

(a) Calcule a função de probabilidade condicional[48] $p_{Y|X}(y \mid x)$ para todo $x, y \in R^1$ com $p_X(x) > 0$.

(b) Calcule a função de probabilidade condicional $p_{X|Y}(x \mid y)$ para todo $x, y \in R^1$ com $p_Y(y) > 0$.

(c) X e Y são independentes? Por quê?

2.8.14 Sejam X e Y com densidade conjunta $f_{X,Y}(x, y) = (x^2 + y)/36$ para $-2 < x < 1$ e $0 < y < 4$; caso contrário, $f_{X,Y}(x, y) = 0$.

(a) Calcule a densidade condicional $f_{Y|X}(y \mid x)$ para todo $x, y \in R^1$ com $f_X(x) > 0$.

(b) Calcule a densidade condicional $f_{X|Y}(x \mid y)$ para todo $x, y \in R^1$ com $f_Y(y) > 0$.

(c) X e Y são independentes? Por quê?

2.8.15 Sejam X e Y com densidade conjunta $f_{X,Y}(x, y) = (x^2 + y)/4$ para $0 < x < y < 2$; caso contrário, $f_{X,Y}(x, y) = 0$. Calcule cada um dos itens a seguir.

(a) A densidade condicional $f_{Y|X}(y \mid x)$ para todo $x, y \in R^1$ com $f_X(x) > 0$

(b) A densidade condicional $f_{X|Y}(x \mid y)$ para todo $x, y \in R^1$ com $f_Y(y) > 0$

No original: *conditional probability function*[48].

(c) X e Y são independentes? Por quê?

2.8.16 Suponha que obtemos a seguinte amostra de tamanho $n = 6$: $X_1 = 12$, $X_2 = 8$, $X_3 = X_4 = 9$, $X_5 = 7$ e $X_6 = 11$. Especifique as estatísticas de ordem $X_{(i)}$ para $1 \leq i \leq 6$.

Problemas

2.8.17 Sejam X e Y variáveis aleatórias conjuntamente absolutamente contínuas, com densidade conjunta da forma

$$f_{X,Y}(x,y) = \begin{cases} C_1(2x^2y + C_2y^5) & 0 \leq x \leq 1, 0 \leq y \leq 1 \\ 0 & \text{caso contrário.} \end{cases}$$

Determine valores de C_1 e C_2 tais que $f_{X,Y}$ seja uma função densidade conjunta válida e X e Y sejam independentes.

2.8.18 Sejam X e Y variáveis aleatórias discretas. Suponha que $p_{X,Y}(x,y) = g(x)\,h(y)$, para certas funções g e h. Prove que X e Y são independentes. (Sugestão: use o Teorema 2.8.3(a) e o Teorema 2.7.4.)

2.8.19 Sejam X e Y variáveis aleatórias conjuntamente absolutamente contínuas. Suponha que $f_{X,Y}(x,y) = g(x)\,h(y)$, para certas funções g e h. Prove que X e Y são independentes. (Sugestão: use o Teorema 2.8.3(b) e o Teorema 2.7.5.)

2.8.20 Sejam X e Y variáveis aleatórias discretas, com $P(X = 1) > 0$ e $P(X = 2) > 0$. Suponha que $P(Y = 1 \mid X = 1) = 3/4$ e $P(Y = 2 \mid X = 2) = 3/4$. Prove que X e Y não podem ser independentes.

2.8.21 Sejam X e Y com distribuição normal bivariada, como no Exemplo 2.7.9. Prove que X e Y são independentes se e somente se $\rho = 0$.

2.8.22 Suponha que $(X_1, X_2, X_3) \sim \text{Multinomial}(n, \theta_1, \theta_2, \theta_3)$. Prove, somando a função de probabilidade conjunta, que $X_1 \sim \text{Binomial}(n, \theta_1)$.

2.8.23 Suponha que $(X_1, X_2, X_3) \sim \text{Multinomial}(n, \theta_1, \theta_2, \theta_3)$. Encontre a distribuição condicional de X_2 dado que $X_1 = x_1$.

2.8.24 Suponha que $X_1, \ldots, X_n$ é uma amostra da distribuição Exponencial(λ). Encontre as densidades $f_{X_{(1)}}$ e $f_{X_{(n)}}$.

2.8.25 Suponha que $X_1, \ldots, X_n$ é uma amostra de uma distribuição com fda F. Prove que

$$F_{X_{(i)}}(x) = \sum_{j=i}^{n} \binom{n}{j} F^j(x) \big(1 - F(x)\big)^{n-j}.$$

(Sugestão: note que $X_{(i)} \leq x$ se e somente se pelo menos i dentre $X_1, \ldots, X_n$ são menores ou iguais a x.)

2.8.26 Suponha que $X_1, \ldots, X_5$ é uma amostra da distribuição Uniforme$[0, 1]$. Se definimos a mediana amostral como $X_{(3)}$, encontre a densidade da mediana amostral. Você consegue identificar essa distribuição? (Sugestão: use o Problema 2.8.25.)

2.8.27 Suponha que $(X, Y) \sim$ Normal Bivariada$(\mu_1, \mu_2, \sigma_1, \sigma_2, \rho)$. Prove que Y, dado $X = x$, tem distribuição $N\big(\mu_2 + \rho\sigma_2 (x - \mu_1)/\sigma_1, (1 - \rho^2)\sigma_2^2\big)$. Estabeleça o resultado análogo para a distribuição condicional de X dado $Y = y$. (Sugestão: use (2.7.1) para Y dado $X = x$ e sua análoga para X dado $Y = y$.)

Desafios

2.8.28 Sejam X e Y variáveis aleatórias.

(a) Suponha que X e Y são ambas discretas. Prove que X e Y são independentes se e somente se $P(Y = y \mid X = x) = P(Y = y)$ para todo x e y tais que $P(X = x) > 0$.

(b) Suponha que X e Y são conjuntamente absolutamente contínuas. Prove que X e Y são independentes se e somente se $P(a \leq Y \leq b \mid X = x) = P(a \leq Y \leq b)$ para todo x e y tais que $f_X(x) > 0$.

2.9 Mudança de Variável Multidimensional

Sejam X e Y variáveis aleatórias com distribuição conjunta conhecida. Suponha que $Z = h_1(X, Y)$ e $W = h_2(X, Y)$, em que $h_1, h_2 : R^2 \to R^1$ são duas funções. Qual é a distribuição conjunta de Z e W?

Esse problema é parecido com o que consideramos na Seção 2.6, exceto que passamos de um contexto unidimensional para um bidimensional. O contexto bidimensional é mais complicado; no entanto, os resultados continuam essencialmente os mesmos, como veremos.

2.9.1 O Caso Discreto

Se X e Y são variáveis aleatórias *discretas*, a distribuição de Z e W é essencialmente direta.

Teorema 2.9.1

Sejam X e Y variáveis aleatórias discretas, com função de probabilidade conjunta $p_{X,Y}$. Sejam $Z = h_1(X, Y)$ e $W = h_2(X, Y)$, em que $h_1, h_2 : R^2 \to R^1$ são funções quaisquer. Então Z e W também são discretas, e sua função de probabilidade conjunta $p_{Z,W}$ satisfaz

$$p_{Z,W}(z, w) = \sum_{\substack{x,y:\ h_1(x,y)=z \\ h_2(x,y)=w}} p_{X,Y}(x, y).$$

Aqui, a soma é feita sobre todos os pares (x, y) tais que $h_1(x, y) = z$ e $h_2(x, y) = w$.

Demonstração. Calculamos que $p_{Z,W}(z, w) = P(Z = z, W = w) = P(h_1(X, Y) = z, h_2(X, Y) = w)$. Isso é igual a

$$\sum_{\substack{x,y:\ h_1(x,y)=z \\ h_2(x,y)=w}} P(X = x, Y = y) = \sum_{\substack{x,y:\ h_1(x,y)=z \\ h_2(x,y)=w}} p_{X,Y}(x, y),$$

como afirmado. ■

Como caso particular, observamos o seguinte.

Corolário 2.9.1

Suponha, no contexto do Teorema 2.9.1, que a função conjunta $h = (h_1, h_2) : R^2 \to R^2$, definida por $h(x, y) = \big(h_1(x, y), h_2(x, y)\big)$, seja injetora, isto é, que, se $h_1(x_1, y_1) = h_1(x_2, y_2)$ e $h_2(x_1, y_1) = h_2(x_2, y_2)$, então $x_1 = x_2$ e $y_1 = y_2$. Então

$$p_{Z,W}(z, w) = p_{X,Y}(h^{-1}(z, w)),$$

em que $h^{-1}(z, w)$ é o único par (x, y) tal que $h(x, y) = (z, w)$.

Exemplo 2.9.1

Suponha que X e Y tenham função densidade conjunta*

$$p_{X,Y}(x,y) = \begin{cases} 1/6 & x = 2, y = 6 \\ 1/12 & x = -2, y = -6 \\ 1/4 & x = -3, y = 11 \\ 1/2 & x = 3, y = -8 \\ 0 & \text{caso contrário.} \end{cases}$$

Sejam $Z = X + Y$ e $W = Y - X^2$. Então $p_{Z,W}(8,2) = P(Z = 8, W = 2) = P(X = 2, Y = 6) + P(X = -3, Y = 11) = 1/6 + 1/4 = 5/12$. Por outro lado, $p_{Z,W}(-5,-17) = P(Z = -5, W = -17) = P(X = 3, Y = -8) = \frac{1}{2}$. ■

2.9.2 O Caso Contínuo (Avançado)

Se X e Y são *contínuas* e a função $h = (h_1, h_2)$ é *injetora*[49], então de novo é possível calcular uma fórmula para a densidade conjunta de Z e W, como mostra o teorema a seguir. Para enunciá-lo, lembre, do cálculo de várias variáveis, que, se $h = (h_1, h_2) : R^2 \to R^2$ é uma função diferenciável, então seu *jacobiano*[50] J é definido por

$$J(x,y) = \det \begin{pmatrix} \frac{\partial h_1}{\partial x} & \frac{\partial h_2}{\partial x} \\ \frac{\partial h_1}{\partial y} & \frac{\partial h_2}{\partial y} \end{pmatrix} = \frac{\partial h_1}{\partial x}\frac{\partial h_2}{\partial y} - \frac{\partial h_2}{\partial x}\frac{\partial h_1}{\partial y}.$$

*Nota do tradutor. o original diz "joint density function", mas a função dada é uma função de probabilidade conjunta (caso discreto)

No original: *one-to-one*[49], *Jacobian*[50].

Teorema 2.9.2

Sejam X e Y conjuntamente absolutamente contínuas, com função densidade conjunta $f_{X,Y}$. Sejam $Z = h_1(X,Y)$ e $W = h_2(X,Y)$, em que $h_1, h_2 : R^2 \to R^1$ são funções diferenciáveis. Defina a função conjunta $h = (h_1, h_2) : R^2 \to R^2$ por

$$h(x,y) = (h_1(x,y), h_2(x,y)).$$

Suponha que h seja injetora, pelo menos na região $\{(x,y) : f(x,y) > 0\}$, isto é, que, se $h_1(x_1,y_1) = h_1(x_2,y_2)$ e $h_2(x_1,y_1) = h_2(x_2,y_2)$, então $x_1 = x_2$ e $y_1 = y_2$. Então Z e W também são conjuntamente absolutamente contínuas, com função densidade conjunta $f_{Z,W}$ dada por

$$f_{Z,W}(z,w) = f_{X,Y}(h^{-1}(z,w)) \,/\, |J(h^{-1}(z,w))|,$$

em que J é o jacobiano de h e $h^{-1}(z,w)$ é o único par (x,y) tal que $h(x,y) = (z,w)$.

Demonstração. Veja a Seção 2.11 para a demonstração deste resultado. ■

Exemplo 2.9.2

Sejam X e Y conjuntamente absolutamente contínuas, com função densidade conjunta $f_{X,Y}$ dada por

$$f_{X,Y}(x,y) = \begin{cases} 4x^2y + 2y^5 & 0 \le x \le 1, 0 \le y \le 1 \\ 0 & \text{caso contrário,} \end{cases}$$

como no Exemplo 2.7.6. Sejam $Z = X + Y^2$ e $W = X - Y^2$. Qual é a densidade conjunta de Z e W?

Observamos primeiro que $Z = h_1(X,Y)$ e $W = h_2(X,Y)$, em que $h_1(x,y) = x + y^2$ e $h_2(x,y) = x - y^2$. Logo,

$$J(x,y) = \frac{\partial h_1}{\partial x}\frac{\partial h_2}{\partial y} - \frac{\partial h_2}{\partial x}\frac{\partial h_1}{\partial y} = (1)(-2y) - (1)(2y) = -4y.$$

Podemos *inverter* a relação h resolvendo para X e Y, e obtemos

$$X = \frac{1}{2}(Z + W) \quad \text{e} \quad Y = \sqrt{\frac{Z - W}{2}}.$$

Isso significa que $h = (h_1, h_2)$ é inversível, com

$$h^{-1}(z,w) = \left(\frac{1}{2}(z+w), \sqrt{\frac{z-w}{2}}\right).$$

Logo, usando o Teorema 2.9.2, vemos que

$$
\begin{aligned}
& f_{Z,W}(z,w) \\
&= f_{X,Y}(h^{-1}(z,w)) \,/\, |J(h^{-1}(z,w))| \\
&= f_{X,Y}\left(\frac{1}{2}(z+w), \sqrt{\frac{z-w}{2}}\right) \Big/ |J(h^{-1}(z,w))| \\
&= \begin{cases} \left\{4\left(\frac{1}{2}(z+w)\right)^2 \sqrt{\frac{z-w}{2}} + 2\left(\sqrt{\frac{z-w}{2}}\right)^5\right\} \Big/ 4\sqrt{\frac{z-w}{2}} & 0 \le \frac{1}{2}(z+w) \le 1, \\ & 0 \le \sqrt{\frac{z-w}{2}} \le 1 \\ 0 & \text{caso contrário} \end{cases} \\
&= \begin{cases} \left(\frac{z+w}{2}\right)^2 + \frac{1}{2}\left(\frac{z-w}{2}\right)^2 & 0 \le z+w \le 2, 0 \le z-w \le 2 \\ 0 & \text{caso contrário.} \end{cases}
\end{aligned}
$$

Obtivemos assim a função densidade conjunta de Z e W. ■

Exemplo 2.9.3

Sejam U_1 e U_2 independentes, cada uma com distribuição Uniforme$[0,1]$. (Poderíamos escrever isso como: U_1, U_2 são i.i.d. Uniforme$[0,1]$.) Assim,

$$
f_{U_1,U_2}(u_1,u_2) = \begin{cases} 1 & 0 \le u_1 \le 1, 0 \le u_2 \le 1 \\ 0 & \text{caso contrário.} \end{cases}
$$

Defina então X e Y por

$$
X = \sqrt{2\log(1/U_1)}\,\cos(2\pi U_2), \qquad Y = \sqrt{2\log(1/U_1)}\,\sin(2\pi U_2).
$$

Qual é a densidade conjunta de X e Y?

Vemos que, aqui, $X = h_1(U_1,U_2)$ e $Y = h_2(U_1,U_2)$, em que

$$
\begin{aligned}
h_1(u_1,u_2) &= \sqrt{2\log(1/u_1)}\,\cos(2\pi u_2), \\
h_2(u_1,u_2) &= \sqrt{2\log(1/u_1)}\,\sin(2\pi u_2).
\end{aligned}
$$

Portanto,

$$
\begin{aligned}
\frac{\partial h_1}{\partial u_1}(u_1,u_2) = \frac{1}{2}\,&(2\log(1/u_1))^{-1/2} \\
&\times \left(2u_1\left(-1/u_1^2\right)\right)\cos(2\pi u_2).
\end{aligned}
$$

Continuando dessa forma, acabamos calculando (veja o Exercício 2.9.1) que

$$
J(u_1,u_2) = \frac{\partial h_1}{\partial u_1}\frac{\partial h_2}{\partial u_2} - \frac{\partial h_2}{\partial u_1}\frac{\partial h_1}{\partial u_2} = -\frac{2\pi}{u_1}\left(\cos^2(2\pi u_2) + \sin^2(2\pi u_2)\right) = -\frac{2\pi}{u_1}.
$$

Em seguida, tomamos $R = \sqrt{X^2 + Y^2}$, de modo que $R^2 = X^2 + Y^2 = 2\log(1/U_1)$. Então, invertendo a relação h, calculamos que

$$U_1(X,Y) = e^{-R^2/2},$$
$$\cos(2\pi U_2(X,Y)) = X/R, \qquad \sin(2\pi U_2(X,Y)) = Y/R.$$

Aqui, $U_1(X,Y) \in [0,1]$ é definido diretamente, enquanto $U_2(X,Y) \in [0,1]$ é definido implicitamente, de modo que $2\pi U_2(X,Y) \in [0,2\pi)$ seja o único ângulo que satisfaz as relações acima. Então, pelo Teorema 2.9.2, para qualquer $(x,y) \in R^2$,

$$\begin{aligned} f_{X,Y}(x,y) &= f_{U_1,U_2}(h^{-1}(x,y)) \left|J(h^{-1}(x,y))\right|^{-1} \\ &= f_{U_1,U_2}(U_1(x,y), U_2(x,y)) \left|J(U_1(x,y), U_2(x,y))\right|^{-1} \\ &= (1)\left|-\frac{2\pi}{U_1(x,y)}\right|^{-1} = \left|-\frac{2\pi}{e^{-R^2(x,y)/2}}\right|^{-1} \\ &= \left|-\frac{2\pi}{e^{-(x^2+y^2)/2}}\right|^{-1} = \frac{1}{2\pi}\, e^{-(x^2+y^2)/2}. \end{aligned}$$

Concluímos que

$$f_{X,Y}(x,y) = \left(\frac{1}{\sqrt{2\pi}} e^{-x^2/2}\right)\left(\frac{1}{\sqrt{2\pi}} e^{-y^2/2}\right).$$

Reconhecemos isso como o produto de duas densidades normais padrão. Concluímos, assim, que $X \sim N(0,1)$ e $Y \sim N(0,1)$ e que, além disso, X e Y são independentes. ■

2.9.3 Convolução

Suponha agora que X e Y sejam independentes, com distribuições conhecidas, e que $Z = X + Y$. Qual é a distribuição de Z? Nesse caso, a distribuição de Z é chamada de *convolução*[51] das distribuições de X e de Y. Felizmente, a convolução costuma ser razoavelmente simples de calcular.

No original: *convolution*[51].

Teorema 2.9.3

Sejam X e Y independentes e seja $Z = X + Y$.

(a) Se X e Y são ambas discretas, com funções de probabilidade p_X e p_Y, então Z também é discreta, com função de probabilidade p_Z dada por

$$p_Z(z) = \sum_w p_X(z - w)\, p_Y(w).$$

(b) Se X e Y são conjuntamente absolutamente contínuas, com funções densidade f_X e f_Y, então Z também é absolutamente contínua, com função densidade f_Z dada por

$$f_Z(z) = \int_{-\infty}^{\infty} f_X(z - w)\, f_Y(w)\, dw.$$

Demonstração. (a) Tomamos $W = Y$ e consideramos a transformação bidimensional de (X, Y) em $(Z, W) = (X + Y, Y)$.

No caso discreto, pelo Corolário 2.9.1, $p_{Z,W}(z, w) = p_{X,Y}(z - w, w)$. Então, pelo Teorema 2.7.4, $p_Z(z) = \sum_w p_{Z,W}(z, w) = \sum_w p_{X,Y}(z - w, w)$. Mas, como X e Y são independentes, $p_{X,Y}(x, y) = p_X(x)\, p_Y(y)$, de modo que $p_{X,Y}(z - w, w) = p_X(z - w)\, p_Y(w)$. Isso prova a parte (a).

(b) No caso contínuo, precisamos calcular o jacobiano $J(x, y)$ da transformação de (X, Y) em $(Z, W) = (X + Y, Y)$. Felizmente, isso é muito fácil, pois obtemos

$$J(x, y) = \frac{\partial(x + y)}{\partial x}\frac{\partial y}{\partial y} - \frac{\partial y}{\partial x}\frac{\partial(x + y)}{\partial y} = (1)(1) - (0)(1) = 1.$$

Logo, pelo Teorema 2.9.2, $f_{Z,W}(z, w) = f_{X,Y}(z - w, w)/|1| = f_{X,Y}(z - w, w)$ e, pelo Teorema 2.7.5,

$$f_Z(z) = \int_{-\infty}^{\infty} f_{Z,W}(z, w)\, dw = \int_{-\infty}^{\infty} f_{X,Y}(z - w, w)\, dw.$$

Mas, como X e Y são independentes, podemos tomar $f_{X,Y}(x, y) = f_X(x)\, f_Y(y)$, de modo que $f_{X,Y}(z - w, w) = f_X(z - w)\, f_Y(w)$. Isso prova a parte (b). ■

Exemplo 2.9.4

Sejam $X \sim \text{Binomial}(4, 1/5)$ e $Y \sim \text{Bernoulli}(1/4)$, com X e Y independentes. Seja $Z = X + Y$. Então

$$\begin{aligned} p_Z(3) &= P(X+Y=3) = P(X=3, Y=0) + P(X=2, Y=1) \\ &= \binom{4}{3}(1/5)^3(4/5)^1\,(3/4) + \binom{4}{2}(1/5)^2(4/5)^2\,(1/4) \\ &= 4(1/5)^3(4/5)^1\,(3/4) + 6(1/5)^2(4/5)^2\,(1/4) \doteq 0{,}0576. \end{aligned}$$

■

Exemplo 2.9.5

Sejam $X \sim \text{Uniforme}[3, 7]$ e $Y \sim \text{Exponencial}(6)$, com X e Y independentes. Seja $Z = X + Y$. Então

$$\begin{aligned} f_Z(5) &= \int_{-\infty}^{\infty} f_X(x)\, f_Y(5-x)\, dx = \int_3^5 (1/4)\, 6\, e^{-6(5-x)}\, dx \\ &= -(1/4)e^{-6(5-x)}\Big|_{x=3}^{x=5} = -(1/4)e^{-12} + (1/4)e^0 \doteq 0{,}2499985. \end{aligned}$$

Observe que, aqui, os limites de integração vão só de 3 a 5, porque $f_X(x) = 0$ para $x < 3$, enquanto $f_Y(5-x) = 0$ para $x > 5$. ■

Resumo da Seção 2.9

- Se X e Y são discretas, e $Z = h_1(X, Y)$ e $W = h_2(X, Y)$, então

$$p_{Z,W}(z, w) = \sum_{\{(x,y):\ h_1(x,y)=z,\ h_2(x,y)=w\}} p_{X,Y}(x, y).$$

- Se X e Y são absolutamente contínuas, se $Z = h_1(X, Y)$ e $W = h_2(X, Y)$, e se $h = (h_1, h_2) : R^2 \to R^2$ é injetora com jacobiano $J(x, y)$, então $f_{Z,W}(z, w) = f_{X,Y}(h^{-1}(z, w))/|J(h^{-1}(z, w))|$.
- Isso nos permite calcular a distribuição conjunta de funções de pares de variáveis aleatórias.

Exercícios

2.9.1 Verifique explicitamente, no Exemplo 2.9.3, que $J(u_1, u_2) = -2\pi/u_1$.

2.9.2 Sejam $X \sim$ Exponencial(3) e $Y \sim$ Uniforme$[1, 4]$, com X e Y independentes. Sejam $Z = X + Y$ e $W = X - Y$.

(a) Escreva a densidade conjunta $f_{X,Y}(x, y)$ de X e Y. (Não deixe de considerar os intervalos de valores válidos de x e y.)

(b) Encontre uma função bidimensional h tal que $(Z, W) = h(X, Y)$.

(c) Encontre uma função bidimensional h^{-1} tal que $(X, Y) = h^{-1}(Z, W)$.

(d) Calcule a densidade conjunta $f_{Z,W}(z, w)$ de Z e W. (De novo, não deixe de considerar os intervalos de valores válidos de z e w.)

2.9.3 Repita as partes (b) a (d) do Exercício 2.9.2, para as mesmas variáveis aleatórias X e Y, se, em vez disso, $Z = X^2 + Y^2$ e $W = X^2 - Y^2$.

2.9.4 Repita as partes (b) a (d) do Exercício 2.9.2, para as mesmas variáveis aleatórias X e Y, se, em vez disso, $Z = X + 4$ e $W = Y - 3$.

2.9.5 Repita as partes (b) a (d) do Exercício 2.9.2, para as mesmas variáveis aleatórias X e Y, se, em vez disso, $Z = Y^4$ e $W = X^4$.

2.9.6 Suponha que a função de probabilidade conjunta de X e Y seja dada por

$$p_{X,Y}(x, y) = \begin{cases} 1/7 & x = 5, y = 0 \\ 1/7 & x = 5, y = 3 \\ 1/7 & x = 5, y = 4 \\ 3/7 & x = 8, y = 0 \\ 1/7 & x = 8, y = 4 \\ 0 & \text{caso contrário.} \end{cases}$$

Sejam $Z = X + Y$, $W = X - Y$, $A = X^2 + Y^2$ e $B = 2X - 3Y^2$.

(a) Calcule a função de probabilidade conjunta $p_{Z,W}(z, w)$.

(b) Calcule a função de probabilidade conjunta $p_{A,B}(a, b)$.

(c) Calcule a função de probabilidade conjunta $p_{Z,A}(z, a)$.

(d) Calcule a função de probabilidade conjunta $p_{W,B}(w, b)$.

2.9.7 Seja X com função de probabilidade

$$p_X(x) = \begin{cases} 1/3 & x = 0 \\ 1/2 & x = 2 \\ 1/6 & x = 3 \\ 0 & \text{caso contrário,} \end{cases}$$

e seja Y com função de probabilidade

$$p_Y(y) = \begin{cases} 1/6 & y = 2 \\ 1/12 & y = 5 \\ 3/4 & y = 9 \\ 0 & \text{caso contrário.} \end{cases}$$

Suponha que X e Y sejam independentes. Seja $Z = X + Y$. Calcule $p_Z(z)$ para todo $z \in R^1$.

2.9.8 Seja $X \sim$ Geométrica$(1/4)$ e seja Y com função de probabilidade

$$p_Y(y) = \begin{cases} 1/6 & y = 2 \\ 1/12 & y = 5 \\ 3/4 & y = 9 \\ 0 & \text{caso contrário.} \end{cases}$$

Seja $W = X + Y$. Suponha que X e Y sejam independentes. Calcule $p_W(w)$ para todo $w \in R^1$.

2.9.9 Suponha que X e Y sejam discretas, com $P(X = 1, Y = 1) = P(X = 1, Y = 2) = P(X = 1, Y = 3) = P(X = 2, Y = 2) = P(X = 2, Y = 3) = 1/5$ e, caso contrário, $P(X = x, Y = y) = 0$. Sejam $Z = X - Y^2$ e $W = X^2 + 5Y$.

(a) Calcule a função de probabilidade conjunta $p_{Z,W}(z, w)$ para todo $z, w \in R^1$.

(b) Calcule a função de probabilidade marginal $p_Z(z)$ de Z.

(c) Calcule a função de probabilidade marginal $p_W(w)$ de W.

2.9.10 Suponha que X tenha densidade $f_X(x) = x^3/4$ para $0 < x < 2$, e $f_X(x) = 0$ caso contrário, e que Y tenha densidade $f_Y(y) = 5y^4/32$ para $0 < y < 2$, e $f_Y(y) = 0$ caso contrário. Suponha que X e Y sejam independentes e seja $Z = X + Y$.

(a) Calcule a densidade conjunta $f_{X,Y}(x, y)$ para todo $x, y \in R^1$.

(b) Calcule a densidade $f_Z(z)$ de Z.

Problemas

2.9.11 Suponha de novo que X tenha densidade $f_X(x) = x^3/4$ para $0 < x < 2$, e $f_X(x) = 0$ caso contrário, que Y tenha densidade $f_Y(y) = 5y^4/32$ para $0 < y < 2$, e $f_Y(y) = 0$ caso contrário, e que X e Y sejam independentes. Sejam $Z = X - Y$ e $W = 4X + 3Y$.

(a) Calcule a densidade conjunta $f_{Z,W}(z, w)$ para todo $z, w \in R^1$.

(b) Calcule a densidade marginal $f_Z(z)$ de Z.

(c) Calcule a densidade marginal $f_W(w)$ de W.

2.9.12 Seja $X \sim$ Binomial(n_1, θ) independente de $Y \sim$ Binomial(n_2, θ). Seja $Z = X + Y$. Use o Teorema 2.9.3(a) para provar que $Z \sim$ Binomial$(n_1 + n_2, \theta)$.

2.9.13 Sejam X e Y independentes, com $X \sim$ Binomial Negativa(r_1, θ) e $Y \sim$ Binomial Negativa(r_2, θ). Seja $Z = X + Y$. Use o Teorema 2.9.3(a) para provar que $Z \sim$ Binomial Negativa$(r_1 + r_2, \theta)$.

2.9.14 Sejam X e Y independentes, com $X \sim N(\mu_1, \sigma_1^2)$ e $Y \sim N(\mu_2, \sigma_2^2)$. Seja $Z = X + Y$. Use o Teorema 2.9.3(b) para provar que $Z \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$.

2.9.15 Sejam X e Y independentes, com $X \sim$ Gama(α_1, λ) e $Y \sim$ Gama(α_2, λ). Seja $Z = X + Y$. Use o Teorema 2.9.3(b) para provar que $Z \sim$ Gama$(\alpha_1 + \alpha_2, \lambda)$.

2.9.16 (MV) Mostre que, quando Z_1, Z_2 são i.i.d. $N(0, 1)$ e X, Y são dados por (2.7.1), então $(X, Y) \sim$ Normal Bivariada$(\mu_1, \mu_2, \sigma_1, \sigma_2, \rho)$.

2.10 Simulando Distribuições de Probabilidade

Até aqui, nos ocupamos principalmente da teoria matemática e de manipulações de probabilidades e variáveis aleatórias. No entanto, os computadores modernos de alta velocidade podem ser usados para simular probabilidades e variáveis aleatórias *numericamente*. Essas simulações têm muitas aplicações, entre elas:

- Aproximar quantidades difíceis demais de calcular matematicamente
- Simular graficamente sistemas físicos ou biológicos complicados

- Extrair amostras aleatórias de grandes conjuntos de dados para procurar erros ou atividades ilegais etc.
- Implementar algoritmos complicados para dar nitidez a imagens, reconhecer fala etc.
- Simular comportamento inteligente
- Criptografar dados ou gerar senhas
- Resolver quebra-cabeças ou decifrar códigos testando muitas soluções aleatórias
- Gerar escolhas aleatórias para questionários on-line, jogos de computador etc.

De fato, à medida que os computadores ficam mais rápidos e mais difundidos, as simulações probabilísticas se tornam cada vez mais comuns em aplicativos de software, pesquisa científica, controle de qualidade, marketing, atividade policial etc.

Na maioria das aplicações de simulação probabilística, o primeiro passo é simular variáveis aleatórias com certas distribuições. Isto é, uma certa distribuição de probabilidade é especificada, e queremos gerar uma ou mais variáveis aleatórias com essa distribuição.

Ora, quase todas as linguagens de programação modernas vêm com um *gerador de números pseudoaleatórios*[52], um dispositivo para gerar uma sequência $U_1, U_2, \ldots$ de valores aleatórios que são aproximadamente independentes e têm aproximadamente a distribuição uniforme em $[0, 1]$. Na verdade, os U_i costumam ser gerados por algum tipo de procedimento iterativo determinístico, projetado para "parecer" aleatório. Assim, os U_i não são, de fato, aleatórios, mas sim *pseudoaleatórios*.

Mesmo assim, vamos ignorar qualquer preocupação com a pseudoaleatoriedade e simplesmente supor que

$$U_1, U_2, U_3, \ldots \sim \text{Uniforme}[0, 1], \tag{2.10.1}$$

isto é, que os U_i são i.i.d. Uniforme$[0, 1]$.

Portanto, se tudo de que precisássemos fossem variáveis aleatórias Uniforme$[0, 1]$, então, de acordo com (2.10.1), estaríamos resolvidos. Na maioria

No original: *pseudorandom number generator*[52].

das aplicações, porém, outros tipos de aleatoriedade também são necessários. Por isso, vamos considerar como usar as variáveis aleatórias uniformes de (2.10.1) para gerar variáveis aleatórias com outras distribuições.

Exemplo 2.10.1 — A Distribuição Uniforme$[L, R]$

Suponha que queremos gerar $X \sim \text{Uniforme}[L, R]$. De acordo com o Exercício 2.6.1, basta tomar

$$X = (R - L)U_1 + L,$$

para garantir que $X \sim \text{Uniforme}[L, R]$. ■

2.10.1 Simulando Distribuições Discretas

Consideramos agora a questão de como simular distribuições discretas.

Exemplo 2.10.2 — A Distribuição Bernoulli(θ)

Suponha que queremos gerar $X \sim \text{Bernoulli}(\theta)$, em que $0 < \theta < 1$. Basta tomar

$$X = \begin{cases} 1 & U_1 \leq \theta \\ 0 & U_1 > \theta. \end{cases}$$

Então, claramente, sempre temos $X = 0$ ou $X = 1$. Além disso, $P(X = 1) = P(U_1 \leq \theta) = \theta$, porque $U_1 \sim \text{Uniforme}[0, 1]$. Logo, vemos que $X \sim \text{Bernoulli}(\theta)$. ■

Exemplo 2.10.3 — A Distribuição Binomial(n, θ)

Suponha que queremos gerar $Y \sim \text{Binomial}(n, \theta)$, em que $0 < \theta < 1$ e $n \geq 1$. Há dois métodos naturais para isso.

Primeiro, podemos simplesmente definir Y da seguinte forma:

$$Y = \min\left\{j : \sum_{k=0}^{j} \binom{n}{k}\theta^k(1-\theta)^{n-k} \geq U_1\right\}.$$

Isto é, tomamos Y como o maior valor de j tal que a soma das probabilidades binomiais até $j-1$ ainda não passa de U_1. Nesse caso,

$$\begin{aligned}
P(Y = y) &= P\left(\begin{array}{c} \sum_{k=0}^{y-1}\binom{n}{k}\theta^k(1-\theta)^{n-k} < U_1 \\ \text{e } \sum_{k=0}^{y}\binom{n}{k}\theta^k(1-\theta)^{n-k} \geq U_1 \end{array}\right) \\
&= P\left(\sum_{k=0}^{y-1}\binom{n}{k}\theta^k(1-\theta)^{n-k} < U_1 \leq \sum_{k=0}^{y}\binom{n}{k}\theta^k(1-\theta)^{n-k}\right) \\
&= \sum_{k=0}^{y}\binom{n}{k}\theta^k(1-\theta)^{n-k} - \sum_{k=0}^{y-1}\binom{n}{k}\theta^k(1-\theta)^{n-k} \\
&= \binom{n}{y}\theta^y(1-\theta)^{n-y}.
\end{aligned}$$

Logo, temos $Y \sim \text{Binomial}(n, \theta)$, como queríamos.

Como alternativa, podemos tomar

$$X_i = \begin{cases} 1 & U_i \leq \theta \\ 0 & U_i > \theta \end{cases}$$

para $i = 1, 2, 3, \ldots$. Então, pelo Exemplo 2.10.2, temos $X_i \sim \text{Bernoulli}(\theta)$ para cada i, com os $\{X_i\}$ independentes porque os $\{U_i\}$ são independentes. Logo, pela observação no fim do Exemplo 2.3.3, se tomarmos $Y = X_1 + \cdots + X_n$, teremos de novo $Y \sim \text{Binomial}(n, \theta)$. ■

No Exemplo 2.10.3, o segundo método é mais elegante e também mais simples do ponto de vista computacional (pois não exige calcular nenhum coeficiente binomial[53]). Por outro lado, o primeiro método do Exemplo 2.10.3 é mais geral, como mostra o teorema a seguir.

No original: *binomial coefficient*[53].

Teorema 2.10.1

Seja p uma função de probabilidade de uma distribuição de probabilidade discreta. Sejam $x_1 < x_2 < x_3 < \cdots$ todos os valores para os quais $p(x_i) > 0$. Seja $U_1 \sim \text{Uniforme}[0,1]$. Defina Y por

$$Y = \min\left\{x_j : \sum_{k=1}^{j} p(x_k) \geq U_1\right\}.$$

Então Y é uma variável aleatória discreta, com função de probabilidade p.

Demonstração. Temos

$$\begin{aligned} P(Y = x_i) &= P\left(\sum_{k=1}^{i-1} p(x_k) < U_1, \text{ e } \sum_{k=1}^{i} p(x_k) \geq U_1\right) \\ &= P\left(\sum_{k=1}^{i-1} p(x_k) < U_1 \leq \sum_{k=1}^{i} p(x_k)\right) \\ &= \sum_{k=1}^{i} p(x_k) - \sum_{k=1}^{i-1} p(x_k) = p(x_i). \end{aligned}$$

Além disso, claramente $P(Y = y) = 0$ se $y \notin \{x_1, x_2, \ldots\}$. Logo, para todo $y \in R^1$, temos $P(Y = y) = p(y)$, como queríamos. ■

Exemplo 2.10.4 — A Distribuição Geométrica(θ)

Para simular $Y \sim$ Geométrica(θ), de novo temos duas opções. Usando o Teorema 2.10.1, podemos tomar $U_1 \sim$ Uniforme$[0,1]$ e então fazer

$$Y = \min\left\{j : \sum_{k=0}^{j} \theta(1-\theta)^k \geq U_1\right\} = \min\{j : 1-(1-\theta)^{j+1} \geq U_1\}$$
$$= \min\left\{j : j \geq \frac{\log(1-U_1)}{\log(1-\theta)} - 1\right\} = \left\lfloor \frac{\log(1-U_1)}{\log(1-\theta)} \right\rfloor,$$

em que $\lfloor r \rfloor$ significa arredondar r para baixo até o inteiro seguinte, isto é, $\lfloor r \rfloor$ é o *maior inteiro* que não excede r (às vezes chamado de *piso* de r).

Como alternativa, usando a definição de Geométrica(θ) do Exemplo 2.3.4, podemos tomar

$$X_i = \begin{cases} 1 & U_i \leq \theta \\ 0 & U_i > \theta \end{cases}$$

para $i = 1, 2, 3, \ldots$ (em que $U_i \sim$ Uniforme$[0,1]$) e então fazer $Y = \min\{i : X_i = 1\}$. De qualquer forma, temos $Y \sim$ Geométrica(θ), como queríamos. ■

2.10.2 Simulando Distribuições Contínuas

Passamos agora à simulação de distribuições absolutamente contínuas. Em geral, esse não é um problema fácil. No entanto, para certas distribuições contínuas particulares, não é difícil, como mostramos a seguir.

Exemplo 2.10.5 — A Distribuição Uniforme$[L, R]$

Já vimos no Exemplo 2.10.1 que, se $U_1 \sim$ Uniforme$[0,1]$ e tomarmos

$$X = (R-L)U_1 + L,$$

então $X \sim$ Uniforme$[L, R]$. Assim, simular qualquer distribuição uniforme é imediato. ■

Exemplo 2.10.6 — A Distribuição Exponencial(λ)

Também vimos, no Exemplo 2.6.6, que, se $U_1 \sim \text{Uniforme}[0,1]$ e tomarmos

$$Y = \ln(1/U_1),$$

então $Y \sim \text{Exponencial}(1)$. Assim, simular a distribuição Exponencial(1) é imediato.

Além disso, sabemos pelo Exercício 2.6.4 que, se $Y \sim \text{Exponencial}(1)$, então, se $\lambda > 0$ e tomarmos

$$Z = Y/\lambda = \ln(1/U_1)/\lambda,$$

teremos $Z \sim \text{Exponencial}(\lambda)$. Assim, simular qualquer distribuição Exponencial(λ) também é imediato. ■

Exemplo 2.10.7 — A Distribuição $N(\mu, \sigma^2)$

Simular a distribuição normal padrão, $N(0,1)$, pode parecer mais difícil. No entanto, pelo Exemplo 2.9.3, se $U_1 \sim \text{Uniforme}[0,1]$ e $U_2 \sim \text{Uniforme}[0,1]$, com U_1 e U_2 independentes, e tomarmos

$$X = \sqrt{2\log(1/U_1)}\cos(2\pi U_2), \qquad Y = \sqrt{2\log(1/U_1)}\sin(2\pi U_2), \tag{2.10.2}$$

então $X \sim N(0,1)$ e $Y \sim N(0,1)$ (e, além disso, X e Y são independentes). Assim, com esse truque, a distribuição normal padrão também pode ser simulada com facilidade.

Segue então do Exercício 2.6.3 que, uma vez que temos $X \sim N(0,1)$, se tomarmos $Z = \sigma X + \mu$, então $Z \sim N(\mu, \sigma^2)$. Logo, é imediato obter amostras de qualquer distribuição normal. ■

Esses exemplos ilustram que, para certas distribuições contínuas especiais, obter amostras delas é imediato. Para dar um método *geral* de obter amostras de uma distribuição contínua, primeiro enunciamos a definição a seguir.

Definição 2.10.1

Seja X uma variável aleatória com função de distribuição acumulada F. Então a *fda inversa* (ou *função quantil*) de X é a função F^{-1} definida por

$$F^{-1}(t) = \min\{x : F(x) \geq t\},$$

para $0 < t < 1$.

Na Figura 2.10.1, apresentamos um gráfico da fda inversa de uma distribuição $N(0,1)$. Observe que essa função vai para $-\infty$ quando o argumento vai para 0 e vai para ∞ quando o argumento vai para 1.

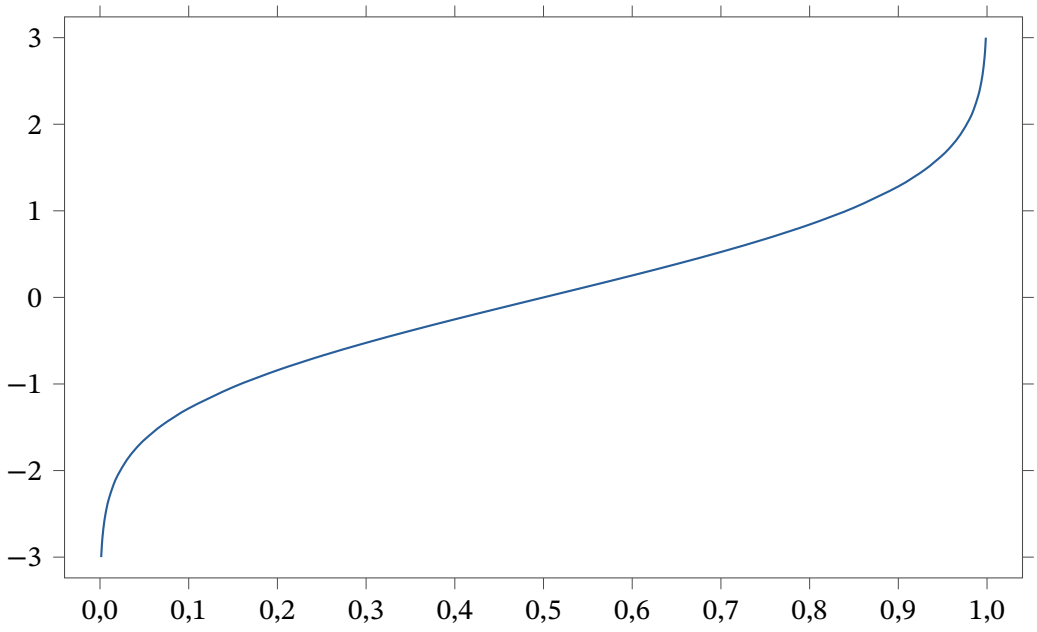


Figura 2.10.1: A fda inversa da distribuição $N(0,1)$.

Usando a fda inversa, obtemos um método geral de obter amostras de uma distribuição contínua, como segue.

Teorema 2.10.2 (Método da inversão para gerar variáveis aleatórias)

Seja F uma função de distribuição acumulada qualquer, e seja $U \sim \text{Uniforme}[0,1]$. Defina uma variável aleatória Y por $Y = F^{-1}(U)$. Então $P(Y \leq y) = F(y)$, isto é, Y tem função de distribuição acumulada dada por F.

Demonstração. Começamos observando que $P(Y \leq y) = P(F^{-1}(U) \leq y)$. Mas $F^{-1}(U)$ é o menor valor x tal que $F(x) \geq U$. Logo, $F^{-1}(U) \leq y$ se e somente se

$F(y) \geq U$, isto é, $U \leq F(y)$. Portanto,

$$P(Y \leq y) = P(F^{-1}(U) \leq y) = P(U \leq F(y)).$$

Mas $0 \leq F(y) \leq 1$ e $U \sim$ Uniforme$[0,1]$, de modo que $P(U \leq F(y)) = F(y)$. Assim,

$$P(Y \leq y) = P(U \leq F(y)) = F(y).$$

Segue que F é a fda de Y, como afirmado. ■

Observamos que o Teorema 2.10.2 vale para *qualquer* função de distribuição acumulada, quer ela corresponda a uma distribuição contínua, a uma distribuição discreta ou a uma mistura das duas (como na Seção 2.5.4). De fato, isso foi provado para distribuições discretas no Teorema 2.10.1.

Exemplo 2.10.8 — Gerando a Partir de uma Distribuição Exponencial

Seja F a fda de uma variável aleatória Exponencial(1). Então

$$F(x) = \int_0^x e^{-t}\, dt = 1 - e^{-x}.$$

Segue então que

$$\begin{aligned} F^{-1}(t) &= \min\{x : F(x) \geq t\} = \min\{x : 1 - e^{-x} \geq t\} \\ &= \min\{x : x \geq -\ln(1-t)\} = -\ln(1-t) = \ln(1/(1-t)). \end{aligned}$$

Portanto, pelo Teorema 2.10.2, se $U \sim$ Uniforme$[0,1]$ e tomarmos

$$Y = F^{-1}(U) = \ln(1/(1-U)), \tag{2.10.3}$$

então $Y \sim$ Exponencial(1).

Ora, já vimos pelo Exemplo 2.6.6 que, se $U \sim$ Uniforme$[0,1]$ e tomarmos $Y = \ln(1/U)$, então $Y \sim$ Exponencial(1). Isso é essencialmente o mesmo que (2.10.3), exceto que substituímos U por $1 - U$. Por outro lado, isso não surpreende, porque já sabemos, pelo Exercício 2.6.2, que, se $U \sim$ Uniforme$[0,1]$, então também $1 - U \sim$ Uniforme$[0,1]$. ■

Exemplo 2.10.9 — Gerando a Partir da Distribuição Normal Padrão

Seja Φ a fda de uma variável aleatória $N(0,1)$, como na Definição 2.5.2. Então

$$\Phi^{-1}(t) = \min\{x : \Phi(x) \geq t\},$$

e não há fórmula mais simples para $\Phi^{-1}(t)$. Pelo Teorema 2.10.2, se $U \sim$ Uniforme$[0,1]$ e tomarmos

$$Y = \Phi^{-1}(U), \tag{2.10.4}$$

então $Y \sim N(0,1)$.

Por outro lado, por causa das dificuldades de calcular com Φ e Φ^{-1}, o método de (2.10.4) não é muito prático. É bem melhor usar o método de (2.10.2) para simular uma variável aleatória normal. ■

Para distribuições complicadas demais para obter amostras pelo método da inversão[54] do Teorema 2.10.2, e para as quais não há nenhum truque simples disponível, ainda pode ser possível obter amostras usando *métodos de cadeias de Markov*, que discutiremos em capítulos posteriores, ou por *amostragem por rejeição*[55] (ver Desafio 2.10.21).

Resumo da Seção 2.10

- É importante saber simular distribuições de probabilidade.
- Se X é discreta, assumindo o valor x_i com probabilidade p_i, em que $x_1 < x_2 < \cdots$, e $U \sim$ Uniforme$[0,1]$ e $Y = \min\{x_j : \sum_{k=1}^{j} p_k \geq U\}$, então Y tem a mesma distribuição que X. Esse método pode ser usado para simular praticamente qualquer distribuição discreta.
- Se F é uma distribuição acumulada qualquer com fda inversa F^{-1}, $U \sim$ Uniforme$[0,1]$ e $Y = F^{-1}(U)$, então Y tem função de distribuição acumulada F. Isso nos permite simular praticamente qualquer distribuição contínua.
- Há métodos simples para simular muitas distribuições usuais, entre elas a binomial, a uniforme, a exponencial e a normal.

No original: *inversion method*[54], *rejection sampling*[55].

Exercícios

2.10.1 Seja Y uma variável aleatória discreta com $P(Y = -7) = 1/2$, $P(Y = -2) = 1/3$ e $P(Y = 5) = 1/6$. Encontre uma fórmula para Z em função de U tal que, se $U \sim \text{Uniforme}[0, 1]$, então Z tenha a mesma distribuição que Y.

2.10.2 Para cada uma das funções de distribuição acumulada F a seguir, encontre uma fórmula para X em função de U tal que, se $U \sim \text{Uniforme}[0, 1]$, então X tenha função de distribuição acumulada F.

(a)
$$F(x) = \begin{cases} 0 & x < 0 \\ x & 0 \le x \le 1 \\ 1 & x > 1 \end{cases}$$

(b)
$$F(x) = \begin{cases} 0 & x < 0 \\ x^2 & 0 \le x \le 1 \\ 1 & x > 1 \end{cases}$$

(c)
$$F(x) = \begin{cases} 0 & x < 0 \\ x^2/9 & 0 \le x \le 3 \\ 1 & x > 3 \end{cases}$$

(d)
$$F(x) = \begin{cases} 0 & x < 1 \\ x^2/9 & 1 \le x \le 3 \\ 1 & x > 3 \end{cases}$$

(e)
$$F(x) = \begin{cases} 0 & x < 0 \\ x^5/32 & 0 \le x \le 2 \\ 1 & x > 2 \end{cases}$$

(f)
$$F(x) = \begin{cases} 0 & x < 0 \\ 1/3 & 0 \le x < 7 \\ 3/4 & 7 \le x < 11 \\ 1 & x \ge 11 \end{cases}$$

2.10.3 Suponha que $U \sim \text{Uniforme}[0,1]$ e $Y = \ln(1/U)/3$. Qual é a distribuição de Y?

2.10.4 Generalizando a questão anterior, suponha que $U \sim \text{Uniforme}[0,1]$ e $W = \ln(1/U)/\lambda$ para algum $\lambda > 0$ fixo.

(a) Qual é a distribuição de W?

(b) Isso fornece um modo de simular uma certa distribuição bem conhecida? Explique.

2.10.5 Sejam $U_1 \sim \text{Uniforme}[0,1]$ e $U_2 \sim \text{Uniforme}[0,1]$ independentes, e seja $X = c_1\sqrt{\log(1/U_1)}\cos(2\pi U_2) + c_2$. Encontre valores de c_1 e c_2 tais que $X \sim N(5,9)$.

2.10.6 Seja $U \sim \text{Uniforme}[0,1]$. Encontre uma fórmula para Y em função de U tal que $P(Y = 3) = P(Y = 4) = 2/5$ e $P(Y = 7) = 1/5$, e $P(Y = y) = 0$ caso contrário.

2.10.7 Suponha que $P(X = 1) = 1/3$, $P(X = 2) = 1/6$, $P(X = 4) = 1/2$ e $P(X = x) = 0$ caso contrário.

(a) Calcule a fda $F_X(x)$ para todo $x \in R^1$.

(b) Calcule a fda inversa $F_X^{-1}(t)$ para todo $t \in R^1$.

(c) Seja $U \sim \text{Uniforme}[0,1]$. Encontre uma fórmula para Y em função de U tal que Y tenha fda F_X.

2.10.8 Seja X com função densidade $f_X(x) = 3\sqrt{x}/2$ para $0 < x < 1$, e $f_X(x) = 0$ caso contrário.

(a) Calcule a fda $F_X(x)$ para todo $x \in R^1$.

(b) Calcule a fda inversa $F_X^{-1}(t)$ para todo $t \in R^1$.

(c) Seja $U \sim \text{Uniforme}[0,1]$. Encontre uma fórmula para Y em função de U tal que Y tenha densidade f.

2.10.9 Seja $U \sim \text{Uniforme}[0,1]$. Encontre uma fórmula para Z em função de U tal que Z tenha densidade $f_Z(z) = 4z^3$ para $0 < z < 1$, e $f_Z(z) = 0$ caso contrário.

Exercícios computacionais

2.10.10 Para cada uma das distribuições a seguir, use o computador (você pode usar quaisquer algoritmos disponíveis num pacote de software) para

simular $X_1, X_2, \ldots, X_N$ i.i.d. com a distribuição dada. (Tome no mínimo $N = 1000$, com $N = 10.000$ ou $N = 100.000$ se possível.) Depois, calcule $\bar{X} = (1/N)\sum_{i=1}^{N} X_i$ e $(1/N)\sum_{i=1}^{N}(X_i - \bar{X})^2$.

(a) Uniforme$[0, 1]$

(b) Uniforme$[5, 8]$

(c) Bernoulli$(1/3)$

(d) Binomial$(12, 1/3)$

(e) Geométrica$(1/5)$

(f) Exponencial(1)

(g) Exponencial(13)

(h) $N(0, 1)$

(i) $N(5, 9)$

Problemas

2.10.11 Seja $G(x) = p_1F_1(x) + p_2F_2(x) + \cdots + p_kF_k(x)$, em que $p_i \geq 0$, $\sum_i p_i = 1$ e as F_i são fdas, como em (2.5.3). Suponha que sabemos gerar X_i com fda F_i, para $i = 1, 2, \ldots, k$. Descreva um procedimento para gerar uma variável aleatória Y com fda G.

2.10.12 Seja X uma variável aleatória absolutamente contínua, com densidade dada por $f_X(x) = x^{-2}$ para $x \geq 1$, e $f_X(x) = 0$ caso contrário. Encontre uma fórmula para Z em função de U tal que, se $U \sim$ Uniforme$[0, 1]$, então Z tenha a mesma distribuição que X.

2.10.13 Encontre a fda inversa da distribuição logística do Problema 2.4.18. (Sugestão: veja o Problema 2.5.20.)

2.10.14 Encontre a fda inversa da distribuição Weibull(α) do Problema 2.4.19. (Sugestão: veja o Problema 2.5.21.)

2.10.15 Encontre a fda inversa da distribuição Pareto(α) do Problema 2.4.20. (Sugestão: veja o Problema 2.5.22.)

2.10.16 Encontre a fda inversa da distribuição de Cauchy do Problema 2.4.21. (Sugestão: veja o Problema 2.5.23.)

2.10.17 Encontre a fda inversa da distribuição de Laplace do Problema 2.4.22. (Sugestão: veja o Problema 2.5.24.)

2.10.18 Encontre a fda inversa da distribuição de valor extremo do Problema 2.4.23. (Sugestão: veja o Problema 2.5.25.)

2.10.19 Encontre as fdas inversas das distribuições beta do Problema 2.4.24(b) a (d). (Sugestão: veja o Problema 2.5.26.)

2.10.20 (*Método da composição*[56]) Se geramos $X \sim f_X$, obtendo x, e depois geramos Y a partir de $f_{Y|X}(\cdot \mid x)$, prove que $Y \sim f_Y$.

Desafios

2.10.21 (*Amostragem por rejeição*) Suponha que f seja uma função densidade complicada. Suponha que g seja uma função densidade da qual é fácil obter amostras (por exemplo, a densidade de uma distribuição uniforme, exponencial ou normal). Suponha que conhecemos um valor de c tal que $f(x) \leq cg(x)$ para todo $x \in R^1$. O que segue fornece um método, chamado amostragem por rejeição, para obter amostras de uma densidade complicada f usando uma densidade mais simples g, desde que conheçamos $f(x) \leq cg(x)$ para todo $x \in R^1$.

(a) Suponha que Y tenha densidade g. Seja $U \sim \text{Uniforme}[0, c]$, com U e Y independentes. Prove que

$$P(a \leq Y \leq b \mid f(Y) \geq Ucg(Y)) = \int_a^b f(x)\,dx.$$

(Sugestão: use o Teorema 2.8.1 para mostrar que $P(a \leq Y \leq b,\ f(Y) \geq cUg(Y)) = \int_a^b g(y)P(f(Y) \geq cUg(Y) \mid Y = y)\,dy$.)

(b) Suponha que $Y_1, Y_2, \ldots$ sejam i.i.d., cada uma com densidade g, e, independentemente, que $U_1, U_2, \ldots$ sejam i.i.d. Uniforme$[0, c]$. Seja $i_0 = 0$ e, para $n \geq 1$, seja $i_n = \min\{j > i_{n-1} : U_j f(Y_j) \geq cg(Y_j)\}$. Prove que $X_{i_1}, X_{i_2}, \ldots$ são i.i.d., cada uma com densidade f. * (Sugestão: prove isso para X_{i_1}, X_{i_2}.)

*Nota do tradutor. o original escreve $X_{i_1}, X_{i_2}, \ldots$; pelo contexto seriam $Y_{i_1}, Y_{i_2}, \ldots$

No original: *method of composition*[56].

2.11 Demonstrações Adicionais (Avançado)

Demonstração do Teorema 2.4.2

Queremos provar que a função ϕ dada por (2.4.9) é uma função densidade.

Claramente, $\phi(x) \geq 0$ para todo x. Para prosseguir, tomamos $I = \int_{-\infty}^{\infty} \phi(x)\,dx$. Então, usando cálculo de várias variáveis,

$$\begin{aligned} I^2 &= \left(\int_{-\infty}^{\infty} \phi(x)\,dx\right)^2 = \left(\int_{-\infty}^{\infty} \phi(x)\,dx\right)\left(\int_{-\infty}^{\infty} \phi(y)\,dy\right) \\ &= \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} \phi(x)\,\phi(y)\,dx\,dy = \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} \frac{1}{2\pi}\, e^{-(x^2+y^2)/2}\,dx\,dy. \end{aligned}$$

Passamos agora para coordenadas polares (r, θ), de modo que $x = r\cos\theta$ e $y = r\sin\theta$, com $r > 0$ e $0 \leq \theta \leq 2\pi$. Então $x^2 + y^2 = r^2$ e, pelo teorema de mudança de variável do cálculo de várias variáveis, $dx\,dy = r\,dr\,d\theta$. Logo,

$$\begin{aligned} I^2 &= \int_0^{2\pi}\int_0^{\infty} \frac{1}{2\pi}\, e^{-r^2/2}\, r\,dr\,d\theta = \int_0^{\infty} e^{-r^2/2}\, r\,dr \\ &= -e^{-r^2/2}\Big|_{r=0}^{r=\infty} = (-0) - (-1) = 1, \end{aligned}$$

e temos $I^2 = 1$. Mas claramente $I \geq 0$ (porque $\phi \geq 0$); então devemos ter $I = 1$, como afirmado. ■

Demonstração do Teorema 2.6.2

Queremos provar que, quando X é uma variável aleatória absolutamente contínua, com função densidade f_X, e $Y = h(X)$, em que $h : R^1 \to R^1$ é uma função diferenciável e estritamente crescente, então Y também é absolutamente contínua, e sua função densidade f_Y é dada por

$$f_Y(y) = f_X(h^{-1}(y)) \,/\, |h'(h^{-1}(y))|, \tag{2.11.1}$$

em que h' é a derivada de h e $h^{-1}(y)$ é o único número x tal que $h(x) = y$.

Devemos mostrar que, sempre que $a \leq b$, temos

$$P(a \leq Y \leq b) = \int_a^b f_Y(y)\,dy,$$

em que f_Y é dada por (2.11.1). Para isso, observamos que, como h é estritamente crescente, h^{-1} também é. Logo, aplicar h^{-1} preserva as desigualdades, de modo

que

$$P(a \leq Y \leq b) = P(h^{-1}(a) \leq h^{-1}(Y) \leq h^{-1}(b)) = P(h^{-1}(a) \leq X \leq h^{-1}(b))$$
$$= \int_{h^{-1}(a)}^{h^{-1}(b)} f_X(x)\,dx.$$

Fazemos então a substituição $y = h(x)$, de modo que $x = h^{-1}(y)$, e

$$dx = \left|\frac{d}{dy}h^{-1}(y)\right| dy.$$

Mas, pelo teorema da função inversa[57] do cálculo, $\frac{d}{dy}h^{-1}(y) = 1/h'(h^{-1}(y))$. Além disso, quando x vai de $h^{-1}(a)$ a $h^{-1}(b)$, vemos que $y = h(x)$ vai de a a b. Concluímos que

$$P(a \leq Y \leq b) = \int_{h^{-1}(a)}^{h^{-1}(b)} f_X(x)\,dx = \int_a^b f_X(h^{-1}(y))(1/|h'(h^{-1}(y))|)\,dy$$
$$= \int_a^b f_Y(y)\,dy,$$

como queríamos. ■

Demonstração do Teorema 2.6.3

Queremos provar que, quando X é uma variável aleatória absolutamente contínua, com função densidade f_X, e $Y = h(X)$, em que $h : R^1 \to R^1$ é uma função diferenciável e estritamente decrescente, então Y também é absolutamente contínua, e sua função densidade f_Y pode, mais uma vez, ser definida por (2.11.1).

Observamos que, como h é estritamente decrescente, h^{-1} também é. Logo, aplicar h^{-1} inverte as desigualdades, de modo que

$$P(a \leq Y \leq b) = P(h^{-1}(b) \leq h^{-1}(Y) \leq h^{-1}(a)) = P(h^{-1}(b) \leq X \leq h^{-1}(a))$$
$$= \int_{h^{-1}(b)}^{h^{-1}(a)} f_X(x)\,dx.$$

Fazemos então a substituição $y = h(x)$, de modo que $x = h^{-1}(y)$, e

$$dx = \left|\frac{d}{dy}h^{-1}(y)\right| dy.$$

No original: *inverse function theorem*[57].

Mas, pelo teorema da função inversa do cálculo,

$$\frac{d}{dy}h^{-1}(y) = \frac{1}{h'(h^{-1}(y))}.$$

Além disso, quando x vai de $h^{-1}(b)$ a $h^{-1}(a)$, vemos que $y = h(x)$ vai de a a b. Concluímos que

$$\begin{aligned} P(a \le Y \le b) &= \int_{h^{-1}(b)}^{h^{-1}(a)} f_X(x)\,dx = \int_a^b f_X(h^{-1}(y))\,(1/|h'(h^{-1}(y))|)\,dy \\ &= \int_a^b f_Y(y)\,dy, \end{aligned}$$

como queríamos. ■

Demonstração do Teorema 2.9.2

Queremos provar o seguinte resultado. Sejam X e Y conjuntamente absolutamente contínuas, com função densidade conjunta $f_{X,Y}$. Sejam $Z = h_1(X,Y)$ e $W = h_2(X,Y)$, em que $h_1, h_2 : R^2 \to R^1$ são funções diferenciáveis. Defina a função conjunta $h = (h_1, h_2) : R^2 \to R^2$ por

$$h(x,y) = (h_1(x,y), h_2(x,y)).$$

Suponha que h seja injetora, pelo menos na região $\{(x,y) : f(x,y) > 0\}$, isto é, se $h_1(x_1,y_1) = h_1(x_2,y_2)$ e $h_2(x_1,y_1) = h_2(x_2,y_2)$, então $x_1 = x_2$ e $y_1 = y_2$. Então Z e W também são conjuntamente absolutamente contínuas, com função densidade conjunta $f_{Z,W}$ dada por

$$f_{Z,W}(z,w) = f_{X,Y}(h^{-1}(z,w)) \,/\, |J(h^{-1}(z,w))|,$$

em que J é o jacobiano de h e $h^{-1}(z,w)$ é o único par (x,y) tal que $h(x,y) = (z,w)$.

Devemos mostrar que, sempre que $a \le b$ e $c \le d$, temos*

$$P(a \le Z \le b, c \le W \le d) = \int_c^d \int_a^b f_{Z,W}(z,w)\,dw\,dz.$$

Se chamarmos de $S = [a,b] \times [c,d]$ o retângulo bidimensional, podemos reescrever[58] isso como

$$P((Z,W) \in S) = \int\int_S f_{Z,W}(z,w)\,dz\,dw.$$

*Nota do tradutor. O original traz $dw\,dz$; pelos limites (z de a a b na integral de dentro, w de c a d na de fora) seria $dz\,dw$.

No original: *plausibility*[58].

Agora, usando a teoria do cálculo de várias variáveis e fazendo a substituição $(x, y) = h^{-1}(z, w)$ (o que é permitido porque h é injetora), temos

$$\begin{aligned}
&\iint_S f_{Z,W}(z, w)\, dz\, dw \\
&= \iint_S \Big(f_{X,Y}(h^{-1}(z, w)) \,/\, |J(h^{-1}(z, w))| \Big)\, dz\, dw \\
&= \iint_{h^{-1}(S)} \big(f_{X,Y}(x, y) \,/\, |J(x, y)| \big)\, |J(x, y)|\, dx\, dy \\
&= \iint_{h^{-1}(S)} f_{X,Y}(x, y)\, dx\, dy = P((X, Y) \in h^{-1}(S)) \\
&= P(h^{-1}(Z, W) \in h^{-1}(S)) = P((Z, W) \in S),
\end{aligned}$$

como queríamos. ■

CAPÍTULO 3

Esperança

ESBOÇO DO CAPÍTULO

Seção 1 O Caso Discreto
Seção 2 O Caso Absolutamente Contínuo
Seção 3 Variância, Covariância e Correlação
Seção 4 Funções Geradoras
Seção 5 Esperança Condicional
Seção 6 Desigualdades
Seção 7 Esperanças Gerais (Avançado)
Seção 8 Demonstrações Adicionais (Avançado)

Nos dois primeiros capítulos, estudamos modelos de probabilidade, variáveis aleatórias e distribuições. Há mais um conceito que é fundamental para toda a teoria da probabilidade: o de valor esperado[1].

Intuitivamente, o valor esperado de uma variável aleatória[2] é o valor médio[3] que a variável aleatória assume. Por exemplo, se metade das vezes $X = 0$ e a outra metade das vezes $X = 10$, então o valor médio de X é 5. Escreveremos isso como $E(X) = 5$. Da mesma forma, se em um terço das vezes $Y = 6$ e em dois terços das vezes $Y = 15$, então $E(Y) = 12$.

Outra interpretação do valor esperado é em termos de apostas justas. Suponha que alguém lhe ofereça um bilhete (por exemplo, um bilhete de loteria) que vale uma certa quantia aleatória X. Quanto você estaria disposto a pagar para comprar o bilhete? Parece razoável que você esteja disposto a pagar o valor esperado $E(X)$ do bilhete, e não mais que isso. No entanto, essa interpretação tem certas limitações; veja o Exemplo 3.1.12.

Para entender o valor esperado com mais precisão, consideramos separadamente as variáveis aleatórias discretas e as absolutamente contínuas.

No original: *expected value*[1], *random variable*[2], *mean value*[3].

3.1 O Caso Discreto

Começamos com uma definição.

Definição 3.1.1

Seja X uma variável aleatória discreta. Então o *valor esperado* (ou *valor médio*, ou *média*) de X, denotado por $E(X)$ (ou μ_X), é definido por

$$E(X) = \sum_{x \in R^1} x\, P(X = x) = \sum_{x \in R^1} x\, p_X(x).$$

Teremos $P(X = x) = 0$ exceto para os valores x que são valores possíveis de X. Portanto, uma definição equivalente é a seguinte.

Definição 3.1.2

Seja X uma variável aleatória discreta que assume os valores distintos $x_1, x_2, \ldots$, com $p_i = P(X = x_i)$. Então o *valor esperado* de X é dado por

$$E(X) = \sum_i x_i\, p_i.$$

A definição (em qualquer das duas formas) é mais bem compreendida por meio de exemplos.

Exemplo 3.1.1

Suponha, como acima, que $P(X = 0) = P(X = 10) = 1/2$. Então

$$E(X) = (0)(1/2) + (10)(1/2) = 5,$$

como previsto. ■

Exemplo 3.1.2

Suponha, como acima, que $P(Y = 6) = 1/3$ e $P(Y = 15) = 2/3$. Então

$$E(Y) = (6)(1/3) + (15)(2/3) = 2 + 10 = 12,$$

de novo como previsto. ■

Exemplo 3.1.3

Suponha que $P(Z = -3) = 0{,}2$, $P(Z = 11) = 0{,}7$ e $P(Z = 31) = 0{,}1$. Então

$$E(Z) = (-3)(0{,}2) + (11)(0{,}7) + (31)(0{,}1) = -0{,}6 + 7{,}7 + 3{,}1 = 10{,}2.$$

■

Exemplo 3.1.4

Suponha que $P(W = -3) = 0{,}2$, $P(W = -11) = 0{,}7$ e $P(W = 31) = 0{,}1$. Então

$$E(W) = (-3)(0{,}2) + (-11)(0{,}7) + (31)(0{,}1) = -0{,}6 - 7{,}7 + 3{,}1 = -5{,}2.$$

Nesse caso, o valor esperado de W é *negativo*. ■

Vemos assim que, para uma variável aleatória discreta X, uma vez conhecidas as probabilidades de que $X = x$ (ou, de modo equivalente, uma vez conhecida a função de probabilidade[4] p_X), é simples (pelo menos nos casos simples) calcular o valor esperado de X.

Consideramos agora algumas das distribuições discretas comuns apresentadas na Seção 2.3.

Exemplo 3.1.5 — Distribuições Degeneradas

Se $X \equiv c$ é uma constante, então $P(X = c) = 1$, e assim

$$E(X) = (c)(1) = c,$$

como deveria ser. ■

No original: *probability function*[4].

Exemplo 3.1.6 — A Distribuição Bernoulli(θ) e Funções Indicadoras

Se $X \sim$ Bernoulli(θ), então $P(X = 1) = \theta$ e $P(X = 0) = 1 - \theta$, e assim

$$E(X) = (1)(\theta) + (0)(1 - \theta) = \theta.$$

Como aplicação particular disso, suponha que temos uma resposta s que assume valores numa amostra S, e que $A \subset S$. Tomando $X(s) = I_A(s)$, temos que X é a função indicadora do conjunto A e, portanto, assume os valores 0 e 1. Então temos que $P(X = 1) = P(A)$, e assim $X \sim$ Bernoulli($P(A)$). Isso implica que

$$E(X) = E(I_A) = P(A).$$

Portanto, mostramos que a esperança da função indicadora do conjunto A é igual à probabilidade de A. ■

Exemplo 3.1.7 — A Distribuição Binomial(n, θ)

Se $Y \sim \text{Binomial}(n, \theta)$, então

$$P(Y = k) = \binom{n}{k}\theta^k(1-\theta)^{n-k}$$

para $k = 0, 1, \ldots, n$. Portanto,

$$\begin{aligned} E(Y) &= \sum_{k=0}^{n} k\,P(Y=k) = \sum_{k=0}^{n} k\binom{n}{k}\theta^k(1-\theta)^{n-k} \\ &= \sum_{k=0}^{n} k\,\frac{n!}{k!\,(n-k)!}\theta^k(1-\theta)^{n-k} = \sum_{k=1}^{n}\frac{n!}{(k-1)!\,(n-k)!}\theta^k(1-\theta)^{n-k} \\ &= \sum_{k=1}^{n}\frac{n\,(n-1)!}{(k-1)!\,(n-k)!}\theta^k(1-\theta)^{n-k} = \sum_{k=1}^{n} n\binom{n-1}{k-1}\theta^k(1-\theta)^{n-k}. \end{aligned}$$

Ora, o *teorema binomial* diz que, para quaisquer a e b e qualquer inteiro positivo m,

$$(a+b)^m = \sum_{j=0}^{m}\binom{m}{j}a^j b^{m-j}.$$

Usando isso, e fazendo $j = k-1$, vemos que

$$\begin{aligned} E(Y) &= \sum_{k=1}^{n} n\binom{n-1}{k-1}\theta^k(1-\theta)^{n-k} = \sum_{j=0}^{n-1} n\binom{n-1}{j}\theta^{j+1}(1-\theta)^{n-j-1} \\ &= n\theta\sum_{j=0}^{n-1}\binom{n-1}{j}\theta^j(1-\theta)^{n-j-1} = n\theta\left((\theta+1-\theta)^{n-1}\right) = n\theta. \end{aligned}$$

Portanto, o valor esperado de Y é $n\theta$. Note que isso é exatamente n vezes o valor esperado de X, onde $X \sim \text{Bernoulli}(\theta)$ como no Exemplo 3.1.6. Veremos no Exemplo 3.1.15 que isso não é coincidência. ■

Exemplo 3.1.8 — A Distribuição Geométrica(θ)

Se $Z \sim$ Geométrica(θ), então $P(Z = k) = (1-\theta)^k\theta$ para $k = 0, 1, 2, \ldots$. Portanto,

$$E(Z) = \sum_{k=0}^{\infty} k(1-\theta)^k\theta. \tag{3.1.1}$$

Logo, podemos escrever

$$(1-\theta)E(Z) = \sum_{\ell=0}^{\infty} \ell(1-\theta)^{\ell+1}\theta.$$

Usando a substituição $k = \ell + 1$, calculamos que

$$(1-\theta)E(Z) = \sum_{k=1}^{\infty} (k-1)\,(1-\theta)^k\theta. \tag{3.1.2}$$

Subtraindo (3.1.2) de (3.1.1), vemos que

$$\theta E(Z) = (E(Z)) - ((1-\theta)E(Z)) = \sum_{k=1}^{\infty} (k-(k-1))\,(1-\theta)^k\theta$$
$$= \sum_{k=1}^{\infty} (1-\theta)^k\theta = \frac{1-\theta}{1-(1-\theta)}\,\theta = 1-\theta.$$

Portanto, $\theta E(Z) = 1-\theta$, e obtemos $E(Z) = (1-\theta)/\theta$. ■

Exemplo 3.1.9 — A Distribuição Poisson(λ)

Se $X \sim$ Poisson(λ), então $P(X = k) = e^{-\lambda}\lambda^k/k!$ para $k = 0, 1, 2, \ldots$. Portanto, fazendo $\ell = k - 1$,

$$E(X) = \sum_{k=0}^{\infty} ke^{-\lambda}\frac{\lambda^k}{k!} = \sum_{k=1}^{\infty} e^{-\lambda}\frac{\lambda^k}{(k-1)!} = \lambda e^{-\lambda}\sum_{k=1}^{\infty}\frac{\lambda^{k-1}}{(k-1)!}$$
$$= \lambda\, e^{-\lambda}\sum_{\ell=0}^{\infty}\frac{\lambda^{\ell}}{\ell!} = \lambda\, e^{-\lambda}e^{\lambda} = \lambda,$$

e concluímos que $E(X) = \lambda$. ■

Deve-se observar que os valores esperados podem às vezes ser infinitos, como mostra o exemplo a seguir.

Exemplo 3.1.10

Seja X uma variável aleatória discreta, com função de probabilidade p_X dada por

$$p_X(2^k) = 2^{-k}$$

para $k = 1, 2, 3, \ldots$, com $p_X(x) = 0$ para os outros valores de x. Isto é, $p_X(2) = 1/2$, $p_X(4) = 1/4$, $p_X(8) = 1/8$ etc., enquanto $p_X(1) = p_X(3) = p_X(5) = p_X(6) = \cdots = 0$.

Então é fácil verificar que p_X é de fato uma função de probabilidade válida (isto é, $p_X(x) \geq 0$ para todo x, com $\sum_x p_X(x) = 1$). Por outro lado, calculamos que

$$E(X) = \sum_{k=1}^{\infty} (2^k)(2^{-k}) = \sum_{k=1}^{\infty} (1) = \infty.$$

Dizemos, portanto, que $E(X) = \infty$, isto é, que o valor esperado de X é infinito. ■

Às vezes o valor esperado simplesmente não existe, como no exemplo a seguir.

Exemplo 3.1.11

Seja Y uma variável aleatória discreta, com função de probabilidade p_Y dada por

$$p_Y(y) = \begin{cases} 1/2y & y = 2, 4, 8, 16, \ldots \\ 1/2|y| & y = -2, -4, -8, -16, \ldots \\ 0 & \text{caso contrário.} \end{cases}$$

Isto é, $p_Y(2) = p_Y(-2) = 1/4$, $p_Y(4) = p_Y(-4) = 1/8$, $p_Y(8) = p_Y(-8) = 1/16$ etc. Então é fácil verificar que p_Y é de fato uma função de probabilidade válida (isto é, $p_Y(y) \geq 0$ para todo y, com $\sum_y p_Y(y) = 1$).

Por outro lado, calculamos que

$$\begin{aligned} E(Y) = \sum_y y\, p_Y(y) &= \sum_{k=1}^{\infty} (2^k)(1/2\,2^k) + \sum_{k=1}^{\infty} (-2^k)(1/2\,2^k) \\ &= \sum_{k=1}^{\infty} (1/2) - \sum_{k=1}^{\infty} (1/2) = \infty - \infty, \end{aligned}$$

o que é *indefinido*. Dizemos, portanto, que $E(Y)$ não existe, isto é, que o valor esperado de Y é *indefinido* nesse caso. ■

Exemplo 3.1.12 — O Paradoxo de São Petersburgo

Suponha que alguém lhe proponha o seguinte acordo. Você vai lançar repetidamente uma moeda honesta e receberá um prêmio de 2^Z centavos, onde Z é o número de coroas que aparecem antes da primeira cara. Quanto você estaria disposto a pagar por esse acordo?

Bem, a probabilidade de o prêmio ser de 2^z centavos é igual à probabilidade de você obter z coroas e depois uma cara, que é igual a $1/2^{z+1}$. Portanto, o valor esperado do prêmio (em centavos) é igual a

$$\sum_{z=0}^{\infty}(2^z)(1/2^{z+1}) = \sum_{z=0}^{\infty} 1/2 = \infty.$$

Em palavras, o valor médio do prêmio é infinito!

Portanto, de acordo com a interpretação do valor esperado como "aposta justa", discutida no início deste capítulo, parece que você deveria estar disposto a pagar uma quantia infinita (ou, pelo menos, qualquer quantia finita, por maior que seja) para obter o prêmio prometido por esse acordo! Quanto você acha que *realmente* deveria estar disposto a pagar por ele?* ■

*Quando um dos autores ouviu falar desse acordo pela primeira vez, decidiu experimentá-lo e aceitou pagar US$ 1. Na verdade, ele obteve quatro coroas antes da primeira cara, de modo que seu prêmio foi de 16 centavos, mas ainda assim perdeu 84 centavos no total.

Exemplo 3.1.13 — O Paradoxo de São Petersburgo, Truncado

Suponha que, no paradoxo de São Petersburgo (Exemplo 3.1.12), fique combinado que o prêmio será truncado em 2^{30} centavos (o que é pouco mais de US$ 10 milhões!). Isto é, o prêmio será o mesmo do acordo original, exceto que ele será congelado quando ultrapassar 2^{30} centavos. Formalmente, o prêmio agora é igual a $2^{\min(30,Z)}$ centavos, onde Z é como antes.

Quanto você estaria disposto a pagar por esse novo prêmio? Bem, o valor esperado do novo prêmio (em centavos) é igual a

$$\sum_{z=1}^{\infty}(2^{\min(30,z)})(1/2^{z+1}) = \sum_{z=1}^{30}(2^z)(1/2^{z+1}) + \sum_{z=31}^{\infty}(2^{30})(1/2^{z+1})$$
$$= \sum_{z=1}^{30}(1/2) + (2^{30})(1/2^{31}) = 31/2 = 15{,}5.$$

Isto é, truncar o prêmio em pouco mais de US$ 10 milhões muda enormemente o seu valor esperado: de infinito para menos de 16 centavos! *

Na *teoria da utilidade*, costuma-se supor que cada pessoa tem uma função utilidade U tal que, se ela ganha x centavos, sua quantidade de "utilidade" (isto é, benefício, alegria ou prazer) é igual a $U(x)$. Nesse contexto, o truncamento do Exemplo 3.1.13 pode ser visto não como uma mudança nas regras do jogo, mas como correspondente a uma função utilidade da forma $U(x) = \min(x, 2^{30})$. Em palavras, isso diz que sua utilidade é igual à quantia de dinheiro que você recebe, até chegar a 2^{30} centavos (aproximadamente US$ 10 milhões); a partir daí, você não se importa mais com dinheiro.† O resultado do Exemplo 3.1.13 diz então que, com essa função utilidade, o paradoxo de São Petersburgo vale só 15,5 centavos para você — mesmo que seu valor esperado seja infinito.

Muitas vezes precisamos calcular valores esperados de *funções* de variáveis aleatórias. Felizmente, isso não é muito difícil, como mostra o teorema a seguir.

*Nota do tradutor. O original soma a partir de $z = 1$, mas Z pode valer 0 (como no Exemplo 3.1.12); com o termo $z = 0$ o valor esperado seria $32/2 = 16$.

†Ou, talvez, você ache improvável que vá conseguir *receber* o dinheiro!

Teorema 3.1.1

(a) Seja X uma variável aleatória discreta, e seja $g : R^1 \to R^1$ uma função tal que a esperança da variável aleatória $g(X)$ existe. Então

$$E(g(X)) = \sum_x g(x)\, P(X = x).$$

(b) Sejam X e Y variáveis aleatórias discretas, e seja $h : R^2 \to R^1$ uma função tal que a esperança da variável aleatória $h(X, Y)$ existe. Então

$$E(h(X, Y)) = \sum_{x,y} h(x, y) P(X = x, Y = y).$$

Demonstração. Demonstramos aqui a parte (b). A parte (a) segue então simplesmente tomando $h(x, y) = g(x)$ e observando que

$$\sum_{x,y} g(x)\, P(X = x, Y = y) = \sum_x g(x)\, P(X = x).$$

Seja $Z = h(X, Y)$. Temos que

$$\begin{aligned} E(Z) &= \sum_z z\, P(Z = z) = \sum_z z\, P(h(X, Y) = z) \\ &= \sum_z z \sum_{\substack{x,y \\ h(x,y)=z}} P(X = x, Y = y) = \sum_{x,y} \sum_{z=h(x,y)} z\, P(X = x, Y = y) \\ &= \sum_{x,y} h(x, y)\, P(X = x, Y = y), \end{aligned}$$

como afirmado. ■

Uma das propriedades mais importantes do valor esperado é que ele é *linear*, como enunciado a seguir.

Teorema 3.1.2 (Linearidade dos valores esperados)

Sejam X e Y variáveis aleatórias discretas, sejam a e b números reais, e tome $Z = aX + bY$. Então $E(Z) = aE(X) + bE(Y)$.

Demonstração. Seja $p_{X,Y}$ a função de probabilidade conjunta de X e Y. Então, usando o Teorema 3.1.1,

$$\begin{aligned} E(Z) &= \sum_{x,y} (ax + by)\, p_{X,Y}(x, y) = a \sum_{x,y} x\, p_{X,Y}(x, y) + b \sum_{x,y} y\, p_{X,Y}(x, y) \\ &= a \sum_x x \sum_y p_{X,Y}(x, y) + b \sum_y y \sum_x p_{X,Y}(x, y). \end{aligned}$$

Como $\sum_y p_{X,Y}(x,y) = p_X(x)$ e $\sum_x p_{X,Y}(x,y) = p_Y(y)$, temos que

$$E(Z) = a\sum_x x\, p_X(x) + b\sum_y y\, p_Y(y) = aE(X) + bE(Y),$$

como afirmado. ■

Exemplo 3.1.14

Sejam $X \sim \text{Binomial}(n, \theta_1)$ e $Y \sim \text{Geométrica}(\theta_2)$. Quanto vale $E(3X - 2Y)$?

Já sabemos (Exemplos 3.1.6 e 3.1.7) que $E(X) = n\,\theta_1$ e $E(Y) = (1 - \theta_2)/\theta_2$. Portanto, pelo Teorema 3.1.2, $E(3X - 2Y) = 3E(X) - 2E(Y) = 3n\theta_1 - 2(1 - \theta_2)/\theta_2$. ■

Exemplo 3.1.15

Seja $Y \sim \text{Binomial}(n, \theta)$. Então sabemos (cf. Exemplo 2.3.3) que podemos pensar em $Y = X_1 + \cdots + X_n$, onde cada $X_i \sim \text{Bernoulli}(\theta)$ (de fato, $X_i = 1$ se a i-ésima moeda der cara, e $X_i = 0$ caso contrário). Como $E(X_i) = \theta$ para cada i, segue imediatamente do Teorema 3.1.2 que

$$E(Y) = E(X_1) + \cdots + E(X_n) = \theta + \cdots + \theta = n\theta.$$

Isso dá a mesma resposta do Exemplo 3.1.7, mas com muito menos trabalho. ■

Suponha que X seja uma variável aleatória e que $Y = c$ seja uma constante. Então, pelo Teorema 3.1.2, temos que $E(X + c) = E(X) + c$. Disso vemos que o valor médio μ_X de X é uma medida da *locação* da distribuição de probabilidade de X. Por exemplo, se X assume o valor x com probabilidade p e o valor y com probabilidade $1 - p$, então a média de X é $\mu_X = px + (1 - p)y$, que é um valor entre x e y. Para uma constante c, a distribuição de probabilidade de $X + c$ está concentrada nos pontos $x + c$ e $y + c$, com probabilidades p e $1 - p$, respectivamente. A média de $X + c$ é $\mu_X + c$, que está entre os pontos $x + c$ e $y + c$, isto é, a média se desloca junto com a distribuição de probabilidade. Também é verdade que, se X está concentrada no conjunto finito de pontos $x_1 < x_2 < \cdots < x_k$, então $x_1 \leq \mu_X \leq x_k$, e a média se desloca exatamente como deslocamos a distribuição. Isso está ilustrado na Figura 3.1.1 para uma distribuição concentrada em $k = 4$ pontos. Usando os resultados da Seção 2.6.1, temos que $p_{X+c}(x) = p_X(x - c)$.

O Teorema 3.1.2 diz, em particular, que $E(X + Y) = E(X) + E(Y)$, isto é, que a

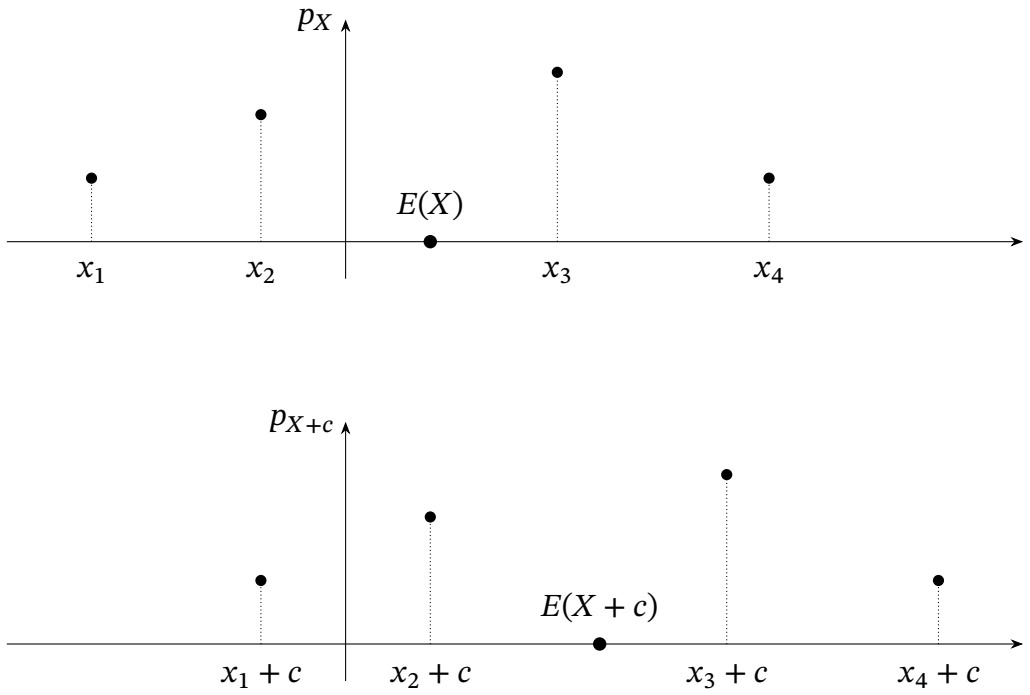


Figura 3.1.1: As funções de probabilidade e as médias das variáveis aleatórias discretas X e $X+c$.

esperança[5] preserva somas. É razoável perguntar se a mesma propriedade vale para produtos. Isto é, temos necessariamente $E(XY) = E(X)E(Y)$? Em geral, a resposta é não, como mostra o exemplo a seguir.

No original: *expectation*[5].

Exemplo 3.1.16

Sejam X e Y variáveis aleatórias discretas, com função de probabilidade conjunta dada por

$$p_{X,Y}(x,y) = \begin{cases} 1/2 & x = 3, y = 5 \\ 1/6 & x = 3, y = 9 \\ 1/6 & x = 6, y = 5 \\ 1/6 & x = 6, y = 9 \\ 0 & \text{caso contrário.} \end{cases}$$

Então

$$E(X) = \sum_x x\, P(X = x) = (3)(1/2 + 1/6) + (6)(1/6 + 1/6) = 4$$

e

$$E(Y) = \sum_y y\, P(Y = y) = (5)(1/2 + 1/6) + (9)(1/6 + 1/6) = 19/3,$$

enquanto

$$\begin{aligned} E(XY) &= \sum_z z\, P(XY = z) \\ &= (3)(5)(1/2) + (3)(9)(1/6) + (6)(5)(1/6) + (6)(9)(1/6) \\ &= 26. \end{aligned}$$

Como $(4)(19/3) \neq 26$, vemos que $E(X)\,E(Y) \neq E(XY)$ nesse caso. ■

Por outro lado, se X e Y são *independentes*, então de fato temos $E(X)E(Y) = E(XY)$.

Teorema 3.1.3

Sejam X e Y variáveis aleatórias discretas independentes. Então $E(XY) = E(X)E(Y)$.

Demonstração. A independência implica (ver Teorema 2.8.3) que $P(X = x, Y = y) = P(X = x)\,P(Y = y)$. Usando isso, calculamos, pelo Teorema 3.1.1, que

$$\begin{aligned} E(XY) &= \sum_{x,y} xy\, P(X = x, Y = y) = \sum_{x,y} xy\, P(X = x)\, P(Y = y) \\ &= \left(\sum_x x\, P(X = x)\right)\left(\sum_y y\, P(Y = y)\right) = E(X)\, E(Y), \end{aligned}$$

como afirmado. ■

O Teorema 3.1.3 será usado com frequência nos capítulos seguintes, assim como a importante propriedade a seguir.

Teorema 3.1.4 (Monotonicidade)

Sejam X e Y variáveis aleatórias discretas, e suponha que $X \leq Y$. (Lembre que isso significa $X(s) \leq Y(s)$ para todo $s \in S$.) Então $E(X) \leq E(Y)$.

Demonstração. Seja $Z = Y - X$. Então Z também é discreta. Além disso, como $X \leq Y$, temos $Z \geq 0$, de modo que todos os valores possíveis de Z são não negativos. Portanto, se listarmos os valores possíveis de Z como $z_1, z_2, \ldots$, então $z_i \geq 0$ para todo i, de modo que

$$E(Z) = \sum_i z_i P(Z = z_i) \geq 0.$$

Mas, pelo Teorema 3.1.2, $E(Z) = E(Y) - E(X)$. Portanto, $E(Y) - E(X) \geq 0$, de modo que $E(Y) \geq E(X)$. ■

Resumo da Seção 3.1

- O valor esperado $E(X)$ de uma variável aleatória X representa o valor médio que ela assume a longo prazo.
- Se X é discreta, então $E(X) = \sum_x x P(X = x)$.
- Foram calculados os valores esperados das distribuições de Bernoulli, binomial, geométrica e de Poisson.
- O valor esperado tem uma interpretação em termos de apostas justas, mas essas interpretações exigem a teoria da utilidade para refletir com precisão o comportamento humano.
- Valores esperados de funções de uma ou duas variáveis aleatórias também podem ser calculados somando os valores da função multiplicados pelas probabilidades.
- A esperança é linear e monótona.
- Se X e Y são independentes, então $E(XY) = E(X)E(Y)$. Mas, sem independência, essa propriedade pode falhar.

Exercícios

3.1.1 Calcule $E(X)$ quando a função de probabilidade de X é dada por cada uma das seguintes.

(a)
$$p_X(x) = \begin{cases} 1/7 & x = -4 \\ 2/7 & x = 0 \\ 4/7 & x = 3 \\ 0 & \text{caso contrário} \end{cases}$$

(b)
$$p_X(x) = \begin{cases} 2^{-x-1} & x = 0, 1, 2, \ldots \\ 0 & \text{caso contrário} \end{cases}$$

(c)
$$p_X(x) = \begin{cases} 2^{-x+6} & x = 7, 8, 9, \ldots \\ 0 & \text{caso contrário} \end{cases}$$

3.1.2 Sejam X e Y com função de probabilidade conjunta dada por

$$p_{X,Y}(x, y) = \begin{cases} 1/7 & x = 5, y = 0 \\ 1/7 & x = 5, y = 3 \\ 1/7 & x = 5, y = 4 \\ 3/7 & x = 8, y = 0 \\ 1/7 & x = 8, y = 4 \\ 0 & \text{caso contrário,} \end{cases}$$

como no Exemplo 2.7.5. Calcule cada um dos seguintes.

(a) $E(X)$

(b) $E(Y)$

(c) $E(3X + 7Y)$

(d) $E(X^2)$

(e) $E(Y^2)$

(f) $E(XY)$

(g) $E(XY + 14)$

3.1.3 Sejam X e Y com função de probabilidade conjunta dada por

$$p_{X,Y}(x,y) = \begin{cases} 1/2 & x = 2, y = 10 \\ 1/6 & x = -7, y = 10 \\ 1/12 & x = 2, y = 12 \\ 1/12 & x = -7, y = 12 \\ 1/12 & x = 2, y = 14 \\ 1/12 & x = -7, y = 14 \\ 0 & \text{caso contrário.} \end{cases}$$

Calcule cada um dos seguintes.

(a) $E(X)$

(b) $E(Y)$

(c) $E(X^2)$

(d) $E(Y^2)$

(e) $E(X^2 + Y^2)$

(f) $E(XY - 4Y)$

3.1.4 Sejam $X \sim \text{Bernoulli}(\theta_1)$ e $Y \sim \text{Binomial}(n, \theta_2)$. Calcule $E(4X - 3Y)$.

3.1.5 Sejam $X \sim \text{Geométrica}(\theta)$ e $Y \sim \text{Poisson}(\lambda)$. Calcule $E(8X - Y + 12)$.

3.1.6 Sejam $Y \sim \text{Binomial}(100;\ 0{,}3)$ e $Z \sim \text{Poisson}(7)$. Calcule $E(Y + Z)$.

3.1.7 Sejam $X \sim \text{Binomial}(80, 1/4)$ e $Y \sim \text{Poisson}(3/2)$. Suponha que X e Y sejam independentes. Calcule $E(XY)$.

3.1.8 Começando com uma moeda de 1 centavo, suponha que você lance um dado honesto de seis faces e receba um número adicional de moedas de 1 centavo igual a três vezes o número que aparece no dado. Seja X o número total de moedas que você tem no fim. Calcule $E(X)$.

3.1.9 Suponha que você comece com oito moedas de 1 centavo e lance uma moeda honesta. Se a moeda der cara, você fica com todas as suas moedas de 1 centavo; se der coroa, você tem que devolver metade delas. Seja X o número total de moedas de 1 centavo que você tem no fim. Calcule $E(X)$.

3.1.10 Suponha que você lance duas moedas honestas. Seja $Y = 3$ se as duas moedas mostrarem o mesmo resultado; caso contrário, seja $Y = 5$. Calcule $E(Y)$.

3.1.11 Suponha que você lance dois dados honestos de seis faces.

(a) Seja Z a soma dos dois números obtidos. Calcule $E(Z)$.

(b) Seja W o produto dos dois números obtidos. Calcule $E(W)$.

3.1.12 Suponha que você lance uma moeda honesta e um dado honesto de seis faces. Seja X o produto do número de caras (isto é, 0 ou 1) pelo número que aparece no dado. Calcule $E(X)$. (Sugestão: não se esqueça do Teorema 3.1.3.)

3.1.13 Suponha que você lance um dado honesto de seis faces e depois lance tantas moedas quanto o número que aparece no dado. (Por exemplo, se o dado mostrar 4, você lança quatro moedas.) Seja Y o número de caras obtidas. Calcule $E(Y)$.

3.1.14 Suponha que você lance três moedas honestas, e seja X o *cubo* do número de caras obtidas. Calcule $E(X)$.

Problemas

3.1.15 Suponha que você comece com uma moeda de 1 centavo e lance repetidamente uma moeda honesta. Cada vez que der cara, *antes* da primeira coroa, você ganha mais duas moedas de 1 centavo. Seja X o número total de moedas de 1 centavo que você tem no fim. Calcule $E(X)$.

3.1.16 Suponha que você comece com uma moeda de 1 centavo e lance repetidamente uma moeda honesta. Cada vez que der cara, *antes* da primeira coroa, seu número de moedas de 1 centavo é *dobrado*. Seja X o número total de moedas de 1 centavo que você tem no fim. Calcule $E(X)$.

3.1.17 Sejam $X \sim \text{Geométrica}(\theta)$ e $Y = \min(X, 100)$.

(a) Calcule $E(Y)$.

(b) Calcule $E(Y - X)$.

3.1.18 Dê um exemplo de variável aleatória X tal que $E\big(\min(X, 100)\big) = E(X)$.

3.1.19 Dê um exemplo de variável aleatória X tal que $E(\min(X, 100)) = E(X)/2$.

3.1.20 Dê um exemplo de função de probabilidade conjunta $p_{X,Y}$ para variáveis aleatórias X e Y tal que $X \sim \text{Bernoulli}(1/4)$ e $Y \sim \text{Bernoulli}(1/2)$, mas $E(XY) \neq 1/8$.

3.1.21 Para $X \sim \text{Hipergeométrica}(N, M, n)$, prove que $E(X) = nM/N$.

3.1.22 Para $X \sim$ Binomial Negativa(r, θ), prove que $E(X) = r(1-\theta)/\theta$. (Sugestão: argumente que, se $X_1, \ldots, X_r$ são independentes e identicamente distribuídas[6] Geométrica(θ), então $X = X_1 + \cdots + X_r \sim$ Binomial Negativa(r, θ).)

3.1.23 Suponha que $(X_1, X_2, X_3) \sim$ Multinomial$(n, \theta_1, \theta_2, \theta_3)$. Prove que $E(X_i) = n\theta_i$.

Desafios

3.1.24 Seja $X \sim$ Geométrica(θ). Calcule $E(X^2)$.

3.1.25 Suponha que X seja uma variável aleatória discreta tal que $E(\min(X, M)) = E(X)$. Prove que $P(X > M) = 0$.

Tópicos para discussão

3.1.26 Quanto *você* estaria disposto a pagar pelo acordo correspondente ao paradoxo de São Petersburgo (ver Exemplo 3.1.12)? Justifique sua resposta.

3.1.27 Que função utilidade U (como no texto que segue o Exemplo 3.1.13) descreve melhor a sua atitude pessoal em relação ao dinheiro? Por quê?

3.2 O Caso Absolutamente Contínuo

Suponha agora que X seja absolutamente contínua[7], com função densidade[8] f_X. Como podemos calcular $E(X)$ nesse caso? Por analogia com o caso discreto, poderíamos tentar calcular $\sum_x x\,P(X = x)$, mas, como $P(X = x)$ é sempre zero, essa soma também é sempre zero.

Por outro lado, se ϵ é um número positivo pequeno, poderíamos tentar aproximar $E(X)$ por

$$E(X) \approx \sum_i i\epsilon\, P(i\epsilon \le X < (i+1)\epsilon),$$

em que a soma é sobre todos os inteiros i. Isso faz sentido porque, se ϵ é pequeno e $i\epsilon \le X < (i+1)\epsilon$, então $X \approx i\epsilon$.

No original: *independent and identically distributed*[6], *absolutely continuous*[7], *density function*[8].

Ora, sabemos que

$$P(i\epsilon \leq X < (i+1)\epsilon) = \int_{i\epsilon}^{(i+1)\epsilon} f_X(x)\,dx.$$

Isso nos diz que

$$E(X) \approx \sum_i \int_{i\epsilon}^{(i+1)\epsilon} i\epsilon\, f_X(x)\,dx.$$

Além disso, nessa integral, $i\epsilon \leq x < (i+1)\epsilon$. Logo, $i\epsilon \approx x$. Vemos, portanto, que

$$E(X) \approx \sum_i \int_{i\epsilon}^{(i+1)\epsilon} x\, f_X(x)\,dx = \int_{-\infty}^{\infty} x\, f_X(x)\,dx.$$

Isso motiva a definição a seguir.

Definição 3.2.1

Seja X uma variável aleatória absolutamente contínua, com função densidade f_X. Então o *valor esperado* de X é dado por

$$E(X) = \int_{-\infty}^{\infty} x\, f_X(x)\,dx.$$

A partir dessa definição, não é muito difícil calcular os valores esperados de muitas das distribuições absolutamente contínuas usuais.

Exemplo 3.2.1 — A Distribuição Uniforme$[0,1]$

Seja $X \sim \text{Uniforme}[0,1]$, de modo que a densidade de X é dada por

$$f_X(x) = \begin{cases} 1 & 0 \leq x \leq 1 \\ 0 & \text{caso contrário.} \end{cases}$$

Logo,

$$E(X) = \int_{-\infty}^{\infty} x\, f_X(x)\,dx = \int_0^1 x\,dx = \frac{x^2}{2}\Big|_{x=0}^{x=1} = 1/2,$$

como era de esperar. ■

Exemplo 3.2.2 — A Distribuição Uniforme$[L, R]$

Seja $X \sim \text{Uniforme}[L, R]$, de modo que a densidade de X é dada por

$$f_X(x) = \begin{cases} 1/(R-L) & L \le x \le R \\ 0 & \text{caso contrário.} \end{cases}$$

Logo,

$$E(X) = \int_{-\infty}^{\infty} x\, f_X(x)\, dx = \int_L^R x\, \frac{1}{R-L}\, dx = \frac{x^2}{2(R-L)}\Big|_{x=L}^{x=R}$$
$$= \frac{R^2 - L^2}{2(R-L)} = \frac{(R-L)(R+L)}{2(R-L)} = \frac{R+L}{2},$$

novamente como era de esperar. ■

Exemplo 3.2.3 — A Distribuição Exponencial(λ)

Seja $Y \sim \text{Exponencial}(\lambda)$, de modo que a densidade de Y é dada por

$$f_Y(y) = \begin{cases} \lambda e^{-\lambda y} & y \ge 0 \\ 0 & y < 0. \end{cases}$$

Logo, a integração por partes, com $u = y$ e $dv = \lambda e^{-\lambda y}$ (de modo que $du = dy$, $v = -e^{-\lambda y}$), leva a

$$E(Y) = \int_{-\infty}^{\infty} y\, f_Y(y)\, dy = \int_0^{\infty} y\, \lambda e^{-\lambda y}\, dy = -y e^{-\lambda y}\Big|_0^{\infty} + \int_0^{\infty} e^{-\lambda y}\, dy$$
$$= \int_0^{\infty} e^{-\lambda y}\, dy = -\frac{e^{-\lambda y}}{\lambda}\Big|_0^{\infty} = -\frac{0-1}{\lambda} = \frac{1}{\lambda}.$$

Em particular, se $\lambda = 1$, então $Y \sim \text{Exponencial}(1)$ e $E(Y) = 1$. ■

Exemplo 3.2.4 — A Distribuição $N(0,1)$

Seja $Z \sim N(0,1)$, de modo que a densidade de Z é dada por

$$f_Z(z) = \phi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}.$$

Logo,

$$\begin{aligned} E(Z) &= \int_{-\infty}^{\infty} z\, f_Z(z)\, dz \\ &= \int_{-\infty}^{\infty} z \frac{1}{\sqrt{2\pi}} e^{-z^2/2}\, dz \\ &= \int_{-\infty}^{0} z \frac{1}{\sqrt{2\pi}} e^{-z^2/2}\, dz + \int_{0}^{\infty} z \frac{1}{\sqrt{2\pi}} e^{-z^2/2}\, dz. \end{aligned} \tag{3.2.1}$$

Mas, usando a substituição $w = -z$, vemos que

$$\int_{-\infty}^{0} z \frac{1}{\sqrt{2\pi}} e^{-z^2/2}\, dz = \int_{0}^{\infty} (-w) \frac{1}{\sqrt{2\pi}} e^{-w^2/2}\, dw.$$

Então as duas integrais em (3.2.1) se cancelam, e ficamos com $E(Z) = 0$. ■

Assim como no caso de variáveis discretas, as médias de variáveis aleatórias absolutamente contínuas também podem ser infinitas ou indefinidas.

Exemplo 3.2.5

Seja X com função densidade dada por

$$f_X(x) = \begin{cases} 1/x^2 & x \geq 1 \\ 0 & \text{caso contrário.} \end{cases}$$

Então

$$E(X) = \int_{-\infty}^{\infty} x\, f_X(x)\, dx = \int_{1}^{\infty} x\,(1/x^2)\, dx = \int_{1}^{\infty} (1/x)\, dx = \log x \Big|_{x=1}^{x=\infty} = \infty.$$

Logo, o valor esperado de X é infinito. ■

Exemplo 3.2.6

Seja Y com função densidade dada por

$$f_Y(y) = \begin{cases} 1/2y^2 & y \geq 1 \\ 1/2y^2 & y \leq -1 \\ 0 & \text{caso contrário.} \end{cases}$$

Então

$$E(Y) = \int_{-\infty}^{\infty} y\, f_Y(y)\, dy = \int_{-\infty}^{-1} y(1/y^2)\, dy + \int_{1}^{\infty} y(1/y^2)\, dy$$
$$= -\int_{1}^{\infty} (1/y)\, dy + \int_{1}^{\infty} (1/y)\, dy = -\infty + \infty,$$

que é indefinido.* Logo, o valor esperado de Y é indefinido (isto é, não existe) nesse caso. ■

O Teorema 3.1.1 continua valendo no caso contínuo, da seguinte forma.

Teorema 3.2.1

(a) Seja X uma variável aleatória absolutamente contínua, com função densidade f_X, e seja $g : R^1 \to R^1$ uma função qualquer. Então, quando a esperança de $g(X)$ existe,

$$E\,(g(X)) = \int_{-\infty}^{\infty} g(x)\, f_X(x)\, dx.$$

(b) Sejam X e Y variáveis aleatórias conjuntamente absolutamente contínuas, com função densidade conjunta $f_{X,Y}$, e seja $h : R^2 \to R^1$ uma função qualquer. Então, quando a esperança de $h(X, Y)$ existe,

$$E\,(h(X, Y)) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} h(x, y)\, f_{X,Y}(x, y)\, dx\, dy.$$

Não demonstraremos o Teorema 3.2.1 aqui; no entanto, vamos usá-lo com frequência. Como primeira aplicação desse resultado, demonstramos que os valores esperados de variáveis aleatórias absolutamente contínuas continuam sendo lineares.

*Nota do tradutor. o original define $f_Y(y) = 1/2y^2$, mas integra $y(1/y^2)$; pela densidade seria $y/(2y^2)$, o que não muda a conclusão

Teorema 3.2.2 (Linearidade dos valores esperados)

Sejam X e Y variáveis aleatórias conjuntamente absolutamente contínuas, e sejam a e b números reais. Então $E(aX + bY) = aE(X) + bE(Y)$.

Demonstração. Seja $f_{X,Y}$ a função densidade conjunta[9] de X e Y. Então, usando o Teorema 3.2.1, calculamos*

$$\begin{aligned} E(Z) &= \int_{-\infty}^{\infty}\int_{-\infty}^{\infty}(ax+by)\,f_{X,Y}(x,y)\,dx\,dy \\ &= a\int_{-\infty}^{\infty}\int_{-\infty}^{\infty}x f_{X,Y}(x,y)\,dx\,dy + b\int_{-\infty}^{\infty}\int_{-\infty}^{\infty}y f_{X,Y}(x,y)\,dx\,dy \\ &= a\int_{-\infty}^{\infty}x\left(\int_{-\infty}^{\infty}f_{X,Y}(x,y)\,dy\right)dx \\ &\quad + b\int_{-\infty}^{\infty}y\left(\int_{-\infty}^{\infty}f_{X,Y}(x,y)\,dx\right)dy. \end{aligned}$$

Mas $\int_{-\infty}^{\infty} f_{X,Y}(x,y)\,dy = f_X(x)$ e $\int_{-\infty}^{\infty} f_{X,Y}(x,y)\,dx = f_Y(y)$, de modo que

$$E(Z) = a\int_{-\infty}^{\infty}x f_X(x)\,dx + b\int_{-\infty}^{\infty}y f_Y(y)\,dy = aE(X) + bE(Y),$$

como afirmado. ■

Assim como no caso discreto, temos $E(X + c) = E(X) + c$ para uma variável aleatória absolutamente contínua X. Observe, no entanto, que isso não decorre do Teorema 3.2.2, porque a constante c é uma variável aleatória discreta, e não absolutamente contínua. Na verdade, precisamos de um tratamento[10] mais geral da esperança para obter esse resultado (ver a Seção 3.7). De qualquer forma, o resultado é verdadeiro, e novamente temos que a média de uma variável aleatória serve como medida da locação da distribuição de probabilidade de X. Na Figura 3.2.1, traçamos as densidades e as médias das variáveis aleatórias absolutamente contínuas X e $X + c$. Os resultados de mudança de variável[11] da Seção 2.6.2 dão $f_{X+c}(x) = f_X(x - c)$.

*Nota do tradutor. o original escreve $E(Z)$ sem definir Z; pelo enunciado, $Z = aX + bY$

No original: *joint density*[9], *treatment*[10], *change of variable*[11].

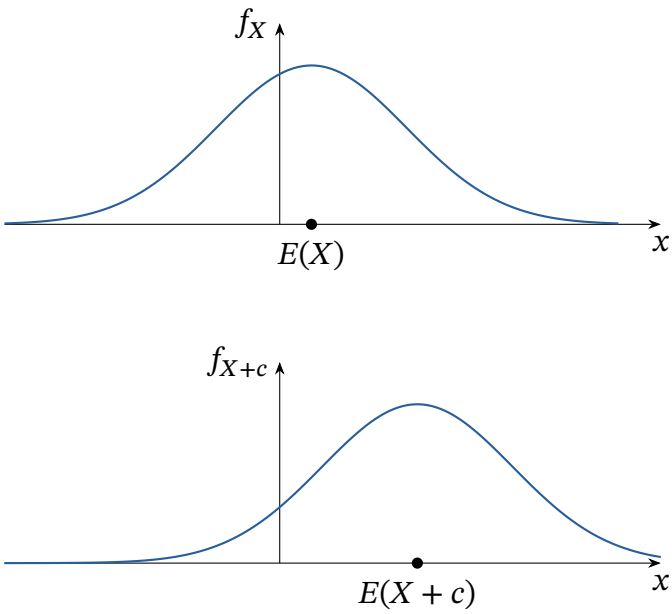


Figura 3.2.1: As densidades e as médias das variáveis aleatórias absolutamente contínuas X e $X + c$.

Exemplo 3.2.7 — A Distribuição $N(\mu, \sigma^2)$

Seja $X \sim N(\mu, \sigma^2)$. Então sabemos (cf. Exercício 2.6.3) que, se $Z = (X - \mu)/\sigma$, então $Z \sim N(0, 1)$. Logo, podemos escrever $X = \mu + \sigma Z$, em que $Z \sim N(0, 1)$. Mas sabemos (ver o Exemplo 3.2.4) que $E(Z) = 0$ e (ver o Exemplo 3.1.5) que $E(\mu) = \mu$. Logo, usando o Teorema 3.2.2, $E(X) = E(\mu + \sigma Z) = E(\mu) + \sigma E(Z) = \mu + \sigma(0) = \mu$. ■

Se X e Y são *independentes*, então os resultados a seguir mostram que novamente temos $E(XY) = E(X)\,E(Y)$.

Teorema 3.2.3

Sejam X e Y variáveis aleatórias conjuntamente absolutamente contínuas e independentes. Então $E(XY) = E(X)E(Y)$.

Demonstração. A independência implica (Teorema 2.8.3) que $f_{X,Y}(x, y) = f_X(x)\,f_Y(y)$. Usando isso, junto com o Teorema 3.2.1, calculamos

$$E(XY) = \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} xy\, f_{X,Y}(x,y)\,dx\,dy = \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} xy\, f_X(x) f_Y(y)\,dx\,dy$$
$$= \left(\int_{-\infty}^{\infty} x\, f_X(x)\,dx\right)\left(\int_{-\infty}^{\infty} y\, f_Y(y)\,dy\right) = E(X)E(Y),$$

como afirmado. ■

A propriedade de monotonicidade[12] (Teorema 3.1.4) também continua valendo.

Teorema 3.2.4 (Monotonicidade)

Sejam X e Y variáveis aleatórias conjuntamente contínuas, e suponha que $X \leq Y$. Então $E(X) \leq E(Y)$.

Demonstração. Seja $f_{X,Y}$ a função densidade conjunta de X e Y. Como $X \leq Y$, a densidade $f_{X,Y}$ pode ser escolhida de modo que $f_{X,Y}(x,y) = 0$ sempre que $x > y$. Agora, seja $Z = Y - X$. Então, pelo Teorema 3.2.1(b),

$$E(Z) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (y - x)\, f_{X,Y}(x,y)\, dx\, dy.$$

Como $f_{X,Y}(x,y) = 0$ sempre que $x > y$, isso implica que $E(Z) \geq 0$. Mas, pelo Teorema 3.2.2, $E(Z) = E(Y) - E(X)$. Logo, $E(Y) - E(X) \geq 0$, de modo que $E(Y) \geq E(X)$. ■

Resumo da Seção 3.2

- Se X é absolutamente contínua, então $E(X) = \int x\, f_X(x)\, dx$.
- Foram calculados os valores esperados das distribuições uniforme, exponencial e normal.
- A esperança de variáveis aleatórias absolutamente contínuas é linear e monótona.
- Se X e Y são independentes, então continuamos tendo $E(XY) = E(X)\,E(Y)$.

Exercícios

3.2.1 Calcule C e $E(X)$ quando a função densidade de X é dada por cada uma das expressões a seguir.

(a)
$$f_X(x) = \begin{cases} C & 5 \leq x \leq 9 \\ 0 & \text{caso contrário} \end{cases}$$

No original: *monotonicity*[12].

(b)
$$f_X(x) = \begin{cases} C(x+1) & 6 \le x \le 8 \\ 0 & \text{caso contrário} \end{cases}$$

(c)
$$f_X(x) = \begin{cases} Cx^4 & -5 \le x \le -2 \\ 0 & \text{caso contrário} \end{cases}$$

3.2.2 Sejam X e Y com densidade conjunta

$$f_{X,Y}(x,y) = \begin{cases} 4x^2y + 2y^5 & 0 \le x \le 1, 0 \le y \le 1 \\ 0 & \text{caso contrário,} \end{cases}$$

como nos Exemplos 2.7.6 e 2.7.7. Calcule cada um dos itens a seguir.

(a) $E(X)$

(b) $E(Y)$

(c) $E(3X + 7Y)$

(d) $E(X^2)$

(e) $E(Y^2)$

(f) $E(XY)$

(g) $E(XY + 14)$

3.2.3 Sejam X e Y com densidade conjunta

$$f_{X,Y}(x,y) = \begin{cases} (4xy + 3x^2y^2)/18 & 0 \le x \le 1, 0 \le y \le 3 \\ 0 & \text{caso contrário.} \end{cases}$$

Calcule cada um dos itens a seguir.

(a) $E(X)$

(b) $E(Y)$

(c) $E(X^2)$

(d) $E(Y^2)$

(e) $E(Y^4)$

(f) $E(X^2Y^3)$

3.2.4 Sejam X e Y com densidade conjunta

$$f_{X,Y}(x,y) = \begin{cases} 6xy + (9/2)x^2y^2 & 0 \le y \le x \le 1 \\ 0 & \text{caso contrário.} \end{cases}$$

Calcule cada um dos itens a seguir.

(a) $E(X)$

(b) $E(Y)$

(c) $E(X^2)$

(d) $E(Y^2)$

(e) $E(Y^4)$

(f) $E(X^2Y^3)$

3.2.5 Sejam $X \sim \text{Uniforme}[3,7]$ e $Y \sim \text{Exponencial}(9)$. Calcule $E(-5X - 6Y)$.

3.2.6 Sejam $X \sim \text{Uniforme}[-12,-9]$ e $Y \sim N(-8,9)$. Calcule $E(11X + 14Y + 3)$.

3.2.7 Sejam $Y \sim \text{Exponencial}(9)$ e $Z \sim \text{Exponencial}(8)$. Calcule $E(Y + Z)$.

3.2.8 Sejam $Y \sim \text{Exponencial}(9)$ e $Z \sim \text{Gama}(5,4)$. Calcule $E(Y + Z)$. (Você pode usar o Problema 3.2.16 abaixo.)

3.2.9 Suponha que X tenha função densidade $f(x) = 3/20(x^2 + x^3)$ para $0 < x < 2$ e, caso contrário, $f(x) = 0$. Calcule $E(X)$, $E(X^2)$ e $E(X^3)$ e ordene-os do maior para o menor.

3.2.10 Suponha que X tenha função densidade $f(x) = 12/7(x^2 + x^3)$ para $0 < x < 1$ e, caso contrário, $f(x) = 0$. Calcule $E(X)$, $E(X^2)$ e $E(X^3)$ e ordene-os do maior para o menor.

3.2.11 Suponha que as alturas dos homens (em centímetros) sigam a distribuição $N(174, 20^2)$, enquanto as das mulheres seguem a distribuição $N(160, 15^2)$. Calcule a média da altura total de um casal formado por um homem e uma mulher.

3.2.12 Suponha que X e Y sejam independentes, com $E(X) = 5$ e $E(Y) = 6$. Para cada uma das variáveis Z a seguir, calcule $E(Z)$ ou explique por que não é possível determinar $E(Z)$ com as informações disponíveis.

(a) $Z = X + Y$

(b) $Z = XY$

(c) $Z = 2X - 4Y$

(d) $Z = 2X(3 + 4Y)$

(e) $Z = (2 + X)(3 + 4Y)$

(f) $Z = (2 + X)(3X + 4Y)$

3.2.13 Suponha que dardos sejam lançados aleatoriamente contra uma parede. Seja X a distância (em centímetros) da borda esquerda da ponta do dardo até a extremidade esquerda da parede, e seja Y a distância da borda direita da ponta do dardo até a extremidade esquerda da parede. Suponha que a ponta do dardo tenha 0,1 centímetro de espessura e que $E(X) = 214$. Calcule $E(Y)$.

3.2.14 Seja X a altura média de todos os cidadãos, medida até o alto da cabeça, e seja Y a altura média de todos os cidadãos, medida até o alto da cabeça ou do chapéu (o que for mais alto). Temos necessariamente $E(Y) \geq E(X)$? Por quê?

3.2.15 Suponha que os times de basquete A e B tenham cinco jogadores cada e que cada integrante do time A seja "marcado" por um único integrante do time B. Suponha que se observe que cada integrante do time A é mais alto que o marcador correspondente do time B. Decorre necessariamente que a altura média do time A é maior que a altura média do time B? Por quê?

Problemas

3.2.16 Sejam $\alpha > 0$ e $\lambda > 0$, e seja $X \sim \text{Gama}(\alpha, \lambda)$. Prove que $E(X) = \alpha/\lambda$. (Sugestão: as contas são um tanto parecidas com as do Problema 2.4.15. Você também vai precisar da propriedade (2.4.7) da função gama[13].)

3.2.17 Suponha que X siga a distribuição logística[14] (ver o Problema 2.4.18). Prove que $E(X) = 0$.

3.2.18 Suponha que X siga a distribuição Weibull(α) (ver o Problema 2.4.19). Prove que $E(X) = \Gamma\left(\alpha^{-1} + 1\right)$.

3.2.19 Suponha que X siga a distribuição Pareto(α) (ver o Problema 2.4.20) para $\alpha > 1$. Prove que $E(X) = 1/(\alpha - 1)$. Quanto vale $E(X)$ quando $0 < \alpha \leq 1$?

3.2.20 Suponha que X siga a distribuição de Cauchy[15] (ver o Problema 2.4.21). Argumente que $E(X)$ não existe. (Sugestão: calcule a integral em duas partes, onde o integrando é positivo e onde o integrando é negativo.)

No original: *gamma function*[13], *logistic*[14], *Cauchy*[15].

3.2.21 Suponha que X siga a distribuição de Laplace[16] (ver o Problema 2.4.22). Prove que $E(X) = 0$.

3.2.22 Suponha que X siga a distribuição Beta(a, b) (ver o Problema 2.4.24). Prove que $E(X) = a/(a + b)$.

3.2.23 Suponha que $(X_1, X_2) \sim$ Dirichlet$(\alpha_1, \alpha_2, \alpha_3)$ (ver o Problema 2.7.17). Prove que $E(X_i) = \alpha_i/(\alpha_1 + \alpha_2 + \alpha_3)$.

3.3 Variância, Covariância e Correlação

Agora que entendemos o valor esperado, podemos usá-lo para definir várias outras quantidades de interesse. Os valores numéricos dessas quantidades dão informação sobre a distribuição de variáveis aleatórias.

Dada uma variável aleatória X, sabemos que o valor médio de X será $E(X)$. Mas isso não nos diz nada sobre o quanto X tende a se afastar de $E(X)$. Para isso, temos a definição a seguir.

Definição 3.3.1

A *variância* de uma variável aleatória X é a quantidade

$$\sigma_X^2 = \text{Var}(X) = E\Big((X - \mu_X)^2\Big), \tag{3.3.1}$$

em que $\mu_X = E(X)$ é a média de X.

Notamos que também é possível escrever (3.3.1) como $\text{Var}(X) = E\big((X - E(X))^2\big)$; mas os vários usos de "E" podem confundir. Além disso, como $(X - \mu_X)^2$ é sempre não negativa, sua esperança está sempre definida, de modo que a variância[17] de X está sempre definida.

Intuitivamente, a variância $\text{Var}(X)$ é uma medida de quão *espalhada* é a distribuição de X, ou de quão *aleatória* X é, ou de quanto X *varia*, como ilustra o exemplo a seguir.

No original: *Laplace distribution*[16], *variance*[17].

Exemplo 3.3.1

Sejam X e Y duas variáveis aleatórias discretas, com funções de probabilidade

$$p_X(x) = \begin{cases} 1 & x = 10 \\ 0 & \text{caso contrário} \end{cases}$$

e

$$p_Y(y) = \begin{cases} 1/2 & y = 5 \\ 1/2 & y = 15 \\ 0 & \text{caso contrário,} \end{cases}$$

respectivamente.

Então $E(X) = E(Y) = 10$. Porém,

$$\text{Var}(X) = (10 - 10)^2(1) = 0,$$

enquanto

$$\text{Var}(Y) = (5 - 10)^2(1/2) + (15 - 10)^2(1/2) = 25.$$

Vemos assim que, embora X e Y tenham o mesmo valor esperado, a variância de Y é muito maior que a de X. Isso corresponde ao fato de que Y é mais aleatória que X; isto é, ela varia mais do que X. ■

Exemplo 3.3.2

Seja X com função de probabilidade dada por

$$p_X(x) = \begin{cases} 1/2 & x = 2 \\ 1/6 & x = 3 \\ 1/6 & x = 4 \\ 1/6 & x = 5 \\ 0 & \text{caso contrário.} \end{cases}$$

Então $E(X) = (2)(1/2) + (3)(1/6) + (4)(1/6) + (5)(1/6) = 3$. Logo,

$$\text{Var}(X) = ((2 - 3)^2)\frac{1}{2} + ((3 - 3)^2)\frac{1}{6} + ((4 - 3)^2)\frac{1}{6} + ((5 - 3)^2)\frac{1}{6} = 4/3.$$

■

Exemplo 3.3.3

Seja $Y \sim \text{Bernoulli}(\theta)$. Então $E(Y) = \theta$. Logo,

$$\begin{aligned}\text{Var}(Y) = E((Y-\theta)^2) &= ((1-\theta)^2)(\theta) + ((0-\theta)^2)(1-\theta) \\ &= \theta - 2\theta^2 + \theta^3 + \theta^2 - \theta^3 = \theta - \theta^2 = \theta(1-\theta).\end{aligned}$$

■

O quadrado em (3.3.1) faz com que a "escala" de $\text{Var}(X)$ seja diferente da escala de X. Por exemplo, se X estivesse medindo uma distância em metros (m), então $\text{Var}(X)$ estaria medindo em metros quadrados (m^2). Se passássemos então de metros para pés, teríamos de multiplicar X por cerca de 3,28084, mas teríamos de multiplicar $\text{Var}(X)$ por cerca de $(3{,}28084)^2$.

Para corrigir esse problema de "escala", basta tirar a raiz quadrada, como a seguir.

Definição 3.3.2

O *desvio padrão* de uma variável aleatória X é a quantidade

$$\sigma_X = \text{Sd}(X) = \sqrt{\text{Var}(X)} = \sqrt{E((X-\mu_X)^2)}.$$

É razoável perguntar por que, em (3.3.1), precisamos do quadrado. Ora, se simplesmente *omitíssemos* o quadrado e considerássemos $E((X-\mu_X))$, obteríamos sempre zero (porque $\mu_X = E(X)$), o que é inútil. Por outro lado, poderíamos usar $E(|X-\mu_X|)$. Isso seria, como (3.3.1), uma medida válida da distância média entre X e μ_X. Além disso, não teria o "problema de escala" que $\text{Var}(X)$ tem. Porém, veremos que $\text{Var}(X)$ tem muitas propriedades convenientes. Já $E(|X-\mu_X|)$ é muito difícil de manipular. Assim, é puramente por *conveniência* que definimos a variância por $E((X-\mu_X)^2)$ em vez de $E(|X-\mu_X|)$.

A variância será muito importante em todo o restante deste livro. Por isso, fazemos uma pausa para apresentar algumas propriedades importantes de Var.

Teorema 3.3.1

Seja X uma variável aleatória qualquer, com valor esperado $\mu_X = E(X)$ e variância $\text{Var}(X)$. Então valem as seguintes afirmações:

(a) $\text{Var}(X) \geq 0$.

(b) Se a e b são números reais, $\text{Var}(aX + b) = a^2 \text{Var}(X)$.

(c) $\text{Var}(X) = E(X^2) - (\mu_X)^2 = E(X^2) - E(X)^2$. (Isto é, a variância é igual ao segundo momento menos o quadrado do primeiro momento.)

(d) $\text{Var}(X) \leq E(X^2)$.

Demonstração. (a) Isso é imediato, porque sempre temos $(X - \mu_X)^2 \geq 0$.

(b) Notamos que $\mu_{aX+b} = E(aX + b) = aE(X) + b = a\mu_X + b$, por linearidade[18]. Logo, usando de novo a linearidade,

$$\begin{aligned}\text{Var}(aX + b) &= E\Big((aX + b - \mu_{aX+b})^2\Big) = E\Big((aX + b - a\mu_X - b)^2\Big) \\ &= a^2 E\Big((X - \mu_X)^2\Big) = a^2 \text{Var}(X).\end{aligned}$$

(c) Novamente, usando a linearidade,

$$\begin{aligned}\text{Var}(X) &= E\Big((X - \mu_X)^2\Big) = E\Big(X^2 - 2X\mu_X + (\mu_X)^2\Big) \\ &= E(X^2) - 2E(X)\mu_X + (\mu_X)^2 = E(X^2) - 2(\mu_X)^2 + (\mu_X)^2 \\ &= E(X^2) - (\mu_X)^2.\end{aligned}$$

(d) Isso segue imediatamente da parte (c), porque temos $-(\mu_X)^2 \leq 0$. ■

O Teorema 3.3.1 muitas vezes oferece maneiras mais fáceis de calcular a variância, como nos exemplos a seguir.

No original: *linearity*[18].

Exemplo 3.3.4 — Variância da Distribuição Exponencial(λ)

Seja $W \sim$ Exponencial(λ), de modo que $f_W(w) = \lambda e^{-\lambda w}$. Então $E(W) = 1/\lambda$. Além disso, usando integração por partes,

$$E(W^2) = \int_0^\infty w^2 \lambda e^{-\lambda w}\, dw = \int_0^\infty 2we^{-\lambda w}\, dw$$
$$= (2/\lambda) \int_0^\infty w\lambda e^{-\lambda w}\, dw = (2/\lambda)E(W) = 2/\lambda^2.$$

Logo, pela parte (c) do Teorema 3.3.1,

$$\text{Var}(W) = E(W^2) - (E(W))^2 = (2/\lambda^2) - (1/\lambda)^2 = 1/\lambda^2.$$

■

Exemplo 3.3.5

Seja $W \sim$ Exponencial(λ) e seja $Y = 5W + 3$. Então, pelo exemplo anterior, $\text{Var}(W) = 1/\lambda^2$. Então, usando a parte (b) do Teorema 3.3.1,

$$\text{Var}(Y) = \text{Var}(5W + 3) = 25\,\text{Var}(W) = 25/\lambda^2.$$

■

Como $\sqrt{a^2} = |a|$, a parte (b) do Teorema 3.3.1 implica imediatamente um fato correspondente sobre o desvio padrão[19].

Corolário 3.3.1

Seja X uma variável aleatória qualquer, com desvio padrão $\text{Sd}(X)$, e seja a um número real qualquer. Então $\text{Sd}(aX) = |a|\,\text{Sd}(X)$.

Exemplo 3.3.6

Seja $W \sim$ Exponencial(λ) e seja $Y \sim 5W + 3$. * Então, usando os exemplos acima, vemos que $\text{Sd}(W) = (\text{Var}(W))^{1/2} = \left(1/\lambda^2\right)^{1/2} = 1/\lambda$. Além disso, $\text{Sd}(Y) = (\text{Var}(Y))^{1/2} = \left(25/\lambda^2\right)^{1/2} = 5/\lambda$. Isso está de acordo com o Corolário 3.3.1, pois $\text{Sd}(Y) = |5|\,\text{Sd}(W)$. ■

No original: *standard deviation*[19].

Exemplo 3.3.7 — Variância e Desvio Padrão da Distribuição $N(\mu, \sigma^2)$

Suponha que $X \sim N(\mu, \sigma^2)$. No Exemplo 3.2.7 estabelecemos que $E(X) = \mu$. Agora calculamos $\text{Var}(X)$.

Considere primeiro $Z \sim N(0, 1)$. Então, pelo Teorema 3.3.1(c), temos que

$$\text{Var}(Z) = E(Z^2) = \int_{-\infty}^{\infty} z^2 \frac{1}{\sqrt{2\pi}} \exp\left\{-\frac{z^2}{2}\right\} dz.$$

Então, tomando $u = z$, $dv = z \exp\{-z^2/2\}$ (de modo que $du = 1$, $v = -\exp\{-z^2/2\}$) e usando integração por partes, obtemos

$$\text{Var}(Z) = -\frac{1}{\sqrt{2\pi}} z \exp\left\{-\frac{z^2}{2}\right\}\Big|_{-\infty}^{\infty} + \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} \exp\left\{-\frac{z^2}{2}\right\} dz = 1$$

e $\text{Sd}(Z) = 1$.

Agora, para $\sigma > 0$, tome $X = \mu + \sigma Z$. Temos então $X \sim N(\mu, \sigma^2)$. Pelo Teorema 3.3.1(b), temos que

$$\text{Var}(X) = \text{Var}(\mu + \sigma Z) = \sigma^2 \text{Var}(Z) = \sigma^2$$

e $\text{Sd}(X) = \sigma$. Isso estabelece que a variância da distribuição $N(\mu, \sigma^2)$ é σ^2 e que o desvio padrão é σ.

Na Figura 3.3.1, traçamos os gráficos de três distribuições normais, todas com média 0, mas com variâncias diferentes.

O efeito da variância sobre o grau de espalhamento da distribuição em torno da média fica bem claro nesses gráficos. À medida que σ^2 aumenta, a distribuição se torna mais difusa; à medida que diminui, ela se torna mais concentrada em torno da média 0. ■

*Nota do tradutor. o original traz $Y \sim 5W + 3$; pelo Exemplo 3.3.5 seria $Y = 5W + 3$

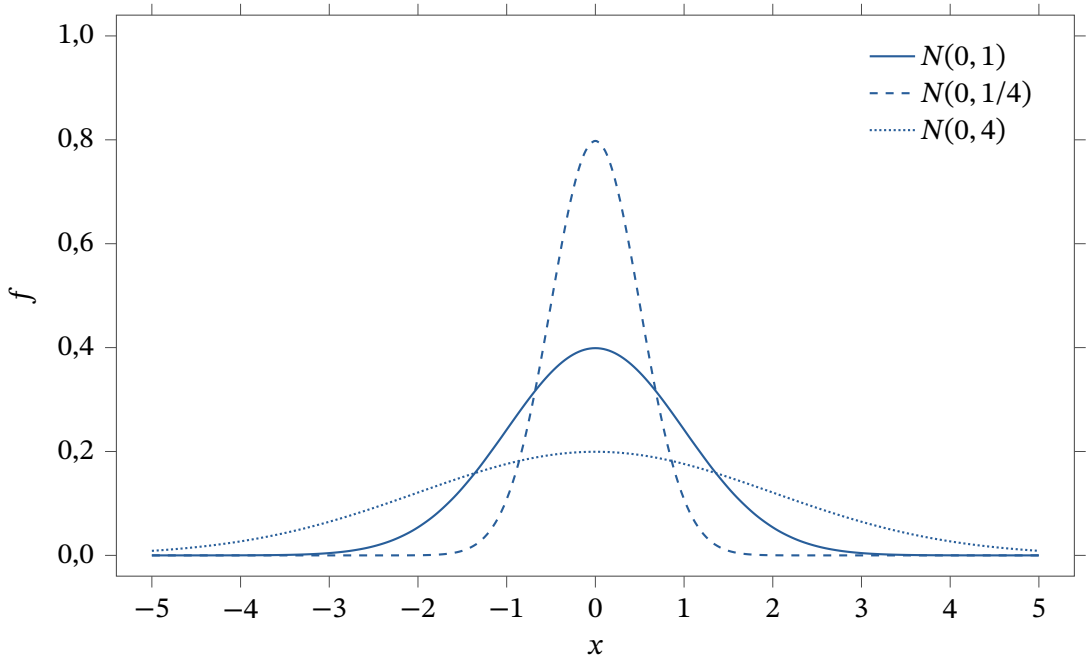


Figura 3.3.1: Gráficos das funções densidade $N(0,1)$ (linha cheia), $N(0,1/4)$ (linha tracejada) e $N(0,4)$ (linha pontilhada).

Até aqui consideramos a variância de uma variável aleatória de cada vez. Mas o conceito relacionado de covariância[20] mede a *relação* entre duas variáveis aleatórias.

Definição 3.3.3

A *covariância* de duas variáveis aleatórias X e Y é dada por

$$\mathrm{Cov}(X,Y) = E\left((X-\mu_X)(Y-\mu_Y)\right),$$

em que $\mu_X = E(X)$ e $\mu_Y = E(Y)$.

No original: *covariance*[20].

Exemplo 3.3.8

Sejam X e Y variáveis aleatórias discretas, com função de probabilidade conjunta $p_{X,Y}$ dada por

$$p_{X,Y}(x,y) = \begin{cases} 1/2 & x = 3, y = 4 \\ 1/3 & x = 3, y = 6 \\ 1/6 & x = 5, y = 6 \\ 0 & \text{caso contrário.} \end{cases}$$

Então $E(X) = (3)(1/2) + (3)(1/3) + (5)(1/6) = 10/3$ e $E(Y) = (4)(1/2) + (6)(1/3) + (6)(1/6) = 5$. Logo,

$$\begin{aligned} \operatorname{Cov}(X,Y) &= E((X - 10/3)(Y - 5)) \\ &= (3 - 10/3)(4 - 5)/2 + (3 - 10/3)(6 - 5)/3 + (5 - 10/3)(6 - 5)/6 \\ &= 1/3. \end{aligned}$$

■

Exemplo 3.3.9

Seja X uma variável aleatória qualquer com $\operatorname{Var}(X) > 0$. Seja $Y = 3X$ e seja $Z = -4X$. Então $\mu_Y = 3\mu_X$ e $\mu_Z = -4\mu_X$. Logo,

$$\begin{aligned} \operatorname{Cov}(X,Y) &= E((X - \mu_X)(Y - \mu_Y)) = E((X - \mu_X)(3X - 3\mu_X)) \\ &= 3\,E((X - \mu_X)^2) = 3\operatorname{Var}(X), \end{aligned}$$

enquanto

$$\begin{aligned} \operatorname{Cov}(X,Z) &= E((X - \mu_X)(Z - \mu_Z)) = E((X - \mu_X)((-4)X - (-4)\mu_X)) \\ &= (-4)E((X - \mu_X)^2) = -4\operatorname{Var}(X). \end{aligned}$$

Note, em particular, que $\operatorname{Cov}(X,Y) > 0$, enquanto $\operatorname{Cov}(X,Z) < 0$. Intuitivamente, isso diz que Y aumenta quando X aumenta, ao passo que Z diminui quando X aumenta. ■

Começamos com alguns fatos simples sobre a covariância. Obviamente, sempre temos $\operatorname{Cov}(X,Y) = \operatorname{Cov}(Y,X)$. Temos também o resultado a seguir.

Teorema 3.3.2 (Linearidade da covariância)

Sejam X, Y e Z três variáveis aleatórias. Sejam a e b números reais. Então

$$\operatorname{Cov}(aX + bY, Z) = a\operatorname{Cov}(X, Z) + b\operatorname{Cov}(Y, Z).$$

Demonstração. Note que, por linearidade, $\mu_{aX+bY} \equiv E(aX + bY) = aE(X) + bE(Y) \equiv a\mu_X + b\mu_Y$. Logo,

$$\begin{aligned}
\operatorname{Cov}(aX + bY, Z) &= E\big((aX + bY - \mu_{aX+bY})(Z - \mu_Z)\big) \\
&= E\left((aX + bY - a\mu_X - b\mu_Y)(Z - \mu_Z)\right) \\
&= E\left((aX - a\mu_X + bY - b\mu_Y)(Z - \mu_Z)\right) \\
&= aE\left((X - \mu_X)(Z - \mu_Z)\right) + bE\left((Y - \mu_Y)(Z - \mu_Z)\right) \\
&= a\operatorname{Cov}(X, Z) + b\operatorname{Cov}(Y, Z),
\end{aligned}$$

e o resultado está estabelecido. ■

Temos também a identidade a seguir, que é semelhante ao Teorema 3.3.1(c).

Teorema 3.3.3

Sejam X e Y duas variáveis aleatórias. Então

$$\operatorname{Cov}(X, Y) = E(XY) - E(X)E(Y).$$

Demonstração. Usando a linearidade, temos

$$\begin{aligned}
\operatorname{Cov}(X, Y) &= E\left((X - \mu_X)(Y - \mu_Y)\right) = E\left(XY - \mu_X Y - X\mu_Y + \mu_X\mu_Y\right) \\
&= E(XY) - \mu_X E(Y) - E(X)\mu_Y + \mu_X\mu_Y \\
&= E(XY) - \mu_X\mu_Y - \mu_X\mu_Y + \mu_X\mu_Y = E(XY) - \mu_X\mu_Y.
\end{aligned}$$

■

Corolário 3.3.2

Se X e Y são independentes, então $\operatorname{Cov}(X, Y) = 0$.

Demonstração. Como X e Y são independentes, sabemos (Teoremas 3.1.3 e 3.2.3) que $E(XY) = E(X)\,E(Y)$. Logo, o resultado segue imediatamente do Teorema 3.3.3. ■

Notamos que a recíproca[21] do Corolário 3.3.2 é falsa, como mostra o exemplo a seguir.

Exemplo 3.3.10 — Covariância 0 Não Implica Independência

Sejam X e Y variáveis aleatórias discretas, com função de probabilidade conjunta $p_{X,Y}$ dada por

$$p_{X,Y}(x,y) = \begin{cases} 1/4 & x = 3, y = 5 \\ 1/4 & x = 4, y = 9 \\ 1/4 & x = 7, y = 5 \\ 1/4 & x = 6, y = 9 \\ 0 & \text{caso contrário.} \end{cases}$$

Então $E(X) = (3)(1/4) + (4)(1/4) + (7)(1/4) + (6)(1/4) = 5$, $E(Y) = (5)(1/4) + (9)(1/4) + (5)(1/4) + (9)(1/4) = 7$ e $E(XY) = (3)(5)(1/4) + (4)(9)(1/4) + (7)(5)(1/4) + (6)(9)(1/4) = 35$. Obtemos $\text{Cov}(X,Y) = E(XY) - E(X)\,E(Y) = 35 - (5)(7) = 0$.

Por outro lado, X e Y claramente não são independentes. Por exemplo, $P(X = 4) > 0$ e $P(Y = 5) > 0$, mas $P(X = 4, Y = 5) = 0$, de modo que $P(X = 4, Y = 5) \neq P(X = 4)\,P(Y = 5)$. ■

Há também uma relação importante entre variância e covariância.

Teorema 3.3.4

(a) Para quaisquer variáveis aleatórias X e Y,

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\,\text{Cov}(X,Y).$$

(b) Mais geralmente, para quaisquer variáveis aleatórias $X_1, \ldots, X_n$,

$$\text{Var}\left(\sum_i X_i\right) = \sum_i \text{Var}(X_i) + 2\sum_{i<j} \text{Cov}(X_i, X_j).$$

Demonstração. Demonstramos aqui a parte (b); a parte (a) segue então como o caso particular $n = 2$.

No original: *converse*[21].

Note que, por linearidade,

$$\mu_{\sum_i X_i} \equiv E\left(\sum_i X_i\right) = \sum_i E(X_i) \equiv \sum_i \mu_{X_i}.$$

Portanto, temos que

$$\begin{aligned}
&\operatorname{Var}\left(\sum_i X_i\right) \\
&= E\left(\left(\sum_i X_i - \mu_{\sum_i X_i}\right)^2\right) = E\left(\left(\sum_i X_i - \sum_i \mu_i\right)^2\right) \\
&= E\left(\left(\sum_i (X_i - \mu_i)\right)^2\right) = E\left(\left(\sum_i (X_i - \mu_i)\right)\left(\sum_j (X_j - \mu_j)\right)\right) \\
&= E\left(\sum_{i,j} (X_i - \mu_i)(X_j - \mu_j)\right) = \sum_{i,j} E((X_i - \mu_i)(X_j - \mu_j)) \\
&= \sum_{i=j} E((X_i - \mu_i)(X_j - \mu_j)) + 2\sum_{i<j} E((X_i - \mu_i)(X_j - \mu_j)) \\
&= \sum_i \operatorname{Var}(X_i) + 2\sum_{i<j} \operatorname{Cov}(X_i, X_j).
\end{aligned}$$

■

Combinando o Teorema 3.3.4 com o Corolário 3.3.2, obtemos o seguinte.

Corolário 3.3.3

(a) Se X e Y são independentes, então $\operatorname{Var}(X+Y) = \operatorname{Var}(X) + \operatorname{Var}(Y)$.

(b) Se $X_1, \ldots, X_n$ são independentes, então $\operatorname{Var}\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n \operatorname{Var}(X_i)$.

Um uso do Corolário 3.3.3 é o seguinte.

Exemplo 3.3.11

Seja $Y \sim \text{Binomial}(n, \theta)$. Quanto vale $\text{Var}(Y)$? Lembre que podemos escrever

$$Y = X_1 + X_2 + \cdots + X_n,$$

em que os X_i são independentes, com $X_i \sim \text{Bernoulli}(\theta)$. Já vimos que $\text{Var}(X_i) = \theta(1-\theta)$. Logo, pelo Corolário 3.3.3,

$$\begin{aligned}\text{Var}(Y) &= \text{Var}(X_1) + \text{Var}(X_2) + \cdots + \text{Var}(X_n) \\ &= \theta(1-\theta) + \theta(1-\theta) + \cdots + \theta(1-\theta) = n\theta(1-\theta).\end{aligned}$$

■

Outro conceito muito ligado à covariância é a correlação[22].

Definição 3.3.4

A *correlação* de duas variáveis aleatórias X e Y é dada por

$$\text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\text{Sd}(X)\,\text{Sd}(Y)} = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\,\text{Var}(Y)}},$$

desde que $0 < \text{Var}(X) < \infty$ e $0 < \text{Var}(Y) < \infty$.

No original: *correlation*[22].

Exemplo 3.3.12

Como no Exemplo 3.3.2, * seja X uma variável aleatória qualquer com $\text{Var}(X) > 0$, seja $Y = 3X$ e seja $Z = -4X$. Então $\text{Cov}(X, Y) = 3\,\text{Var}(X)$ e $\text{Cov}(X, Z) = -4\,\text{Var}(X)$. Mas, pelo Corolário 3.3.1, $\text{Sd}(Y) = 3\,\text{Sd}(X)$ e $\text{Sd}(Z) = 4\,\text{Sd}(X)$. Logo,

$$\text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\text{Sd}(X)\,\text{Sd}(Y)} = \frac{3\,\text{Var}(X)}{\text{Sd}(X)3\,\text{Sd}(X)} = \frac{\text{Var}(X)}{\text{Sd}(X)^2} = 1,$$

porque $\text{Sd}(X)^2 = \text{Var}(X)$. Temos também que

$$\text{Corr}(X, Z) = \frac{\text{Cov}(X, Z)}{\text{Sd}(X)\,\text{Sd}(Z)} = \frac{-4\,\text{Var}(X)}{\text{Sd}(X)4\,\text{Sd}(X)} = -\frac{\text{Var}(X)}{\text{Sd}(X)^2} = -1.$$

Intuitivamente, isso diz de novo que Y aumenta quando X aumenta, ao passo que Z diminui quando X aumenta. Note, porém, que os fatores de escala 3 e -4 se cancelaram; só os seus sinais importaram. ■

Veremos mais adiante, na Seção 3.6, que sempre temos $-1 \leq \text{Corr}(X, Y) \leq 1$, para quaisquer variáveis aleatórias X e Y. Logo, no Exemplo 3.3.12, Y tem a maior correlação possível com X (o que faz sentido, porque Y aumenta sempre que X aumenta, sem exceção), enquanto Z tem a menor correlação possível com X (o que faz sentido, porque Z diminui sempre que X aumenta). Veremos também que $\text{Corr}(X, Y)$ é uma medida de até que ponto existe uma relação linear entre X e Y.

*Nota do tradutor. o original traz “Exemplo 3.3.2”; pelo conteúdo, seria o Exemplo 3.3.9

Exemplo 3.3.13 — A Distribuição Normal Bivariada$(\mu_1, \mu_2, \sigma_1, \sigma_2, \rho)$

Definimos essa distribuição no Exemplo 2.7.9. Acontece que, quando (X, Y) segue essa distribuição conjunta, então (pelo Problema 2.7.13) $X \sim N(\mu_1, \sigma_1^2)$ e $Y \sim N(\mu_2, \sigma_2^2)$. Além disso, temos que (ver Problema 3.3.17) $\text{Corr}(X, Y) = \rho$. Nos gráficos a seguir, traçamos amostras de $n = 1000$ valores de (X, Y) de distribuições normais bivariadas com $\mu_1 = \mu_2 = 0$, $\sigma_1^2 = \sigma_2^2 = 1$ e vários valores de ρ. Note que usamos (2.7.1) para gerar essas amostras.

Por esses gráficos, podemos ver o efeito de ρ sobre a distribuição conjunta. A Figura 3.3.2 mostra que, quando $\rho = 0$, a nuvem de pontos é aproximadamente circular. Ela se torna elíptica na Figura 3.3.3, com $\rho = 0{,}5$, e mais concentrada em torno de uma reta na Figura 3.3.4, com $\rho = 0{,}9$. Como veremos na Seção 3.6, os pontos ficam exatamente sobre uma reta quando $\rho = 1$.

A Figura 3.3.5 mostra o efeito de uma correlação negativa. Com correlações positivas, o valor de Y tende a aumentar com X, o que se reflete na inclinação ascendente da nuvem de pontos. Com correlações negativas, Y tende a diminuir com X, o que se reflete na inclinação negativa da nuvem de pontos. ■

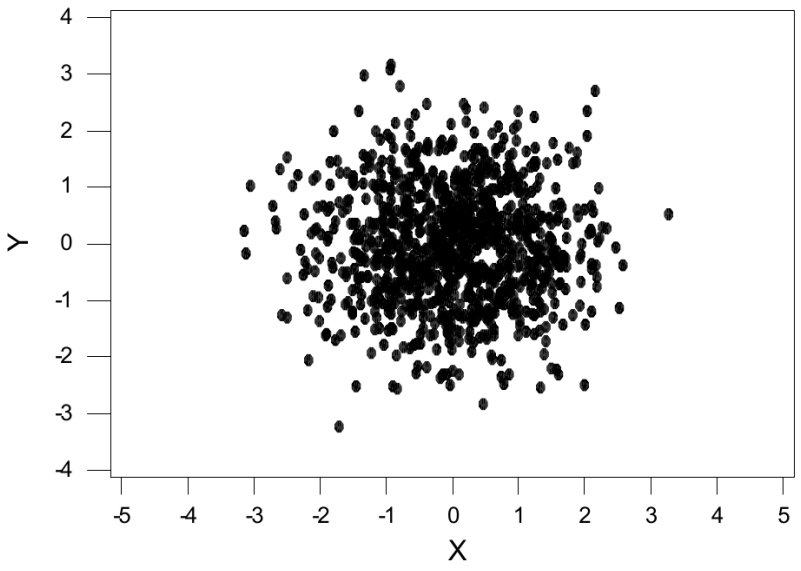


Figura 3.3.2: Uma amostra de $n = 1000$ valores (X, Y) da distribuição Normal Bivariada $(0, 0, 1, 1, 0)$.

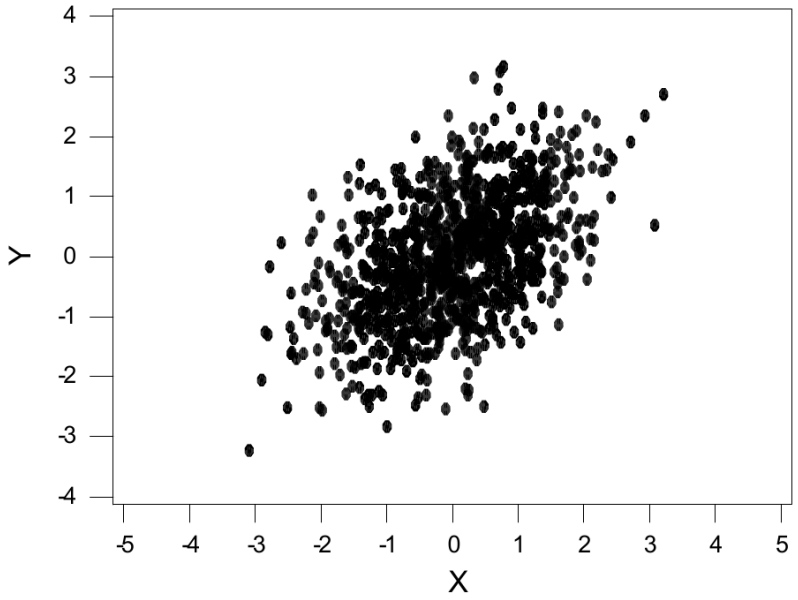


Figura 3.3.3: Uma amostra de $n = 1000$ valores (X, Y) da distribuição Normal Bivariada $(0; 0; 1; 1; 0{,}5)$.

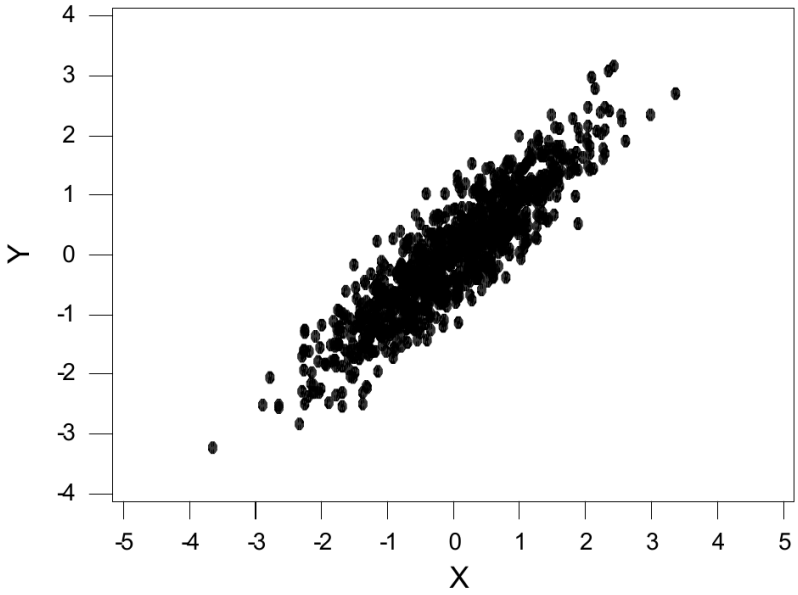


Figura 3.3.4: Uma amostra de $n = 1000$ valores (X, Y) da distribuição Normal Bivariada $(0; 0; 1; 1; 0{,}9)$.

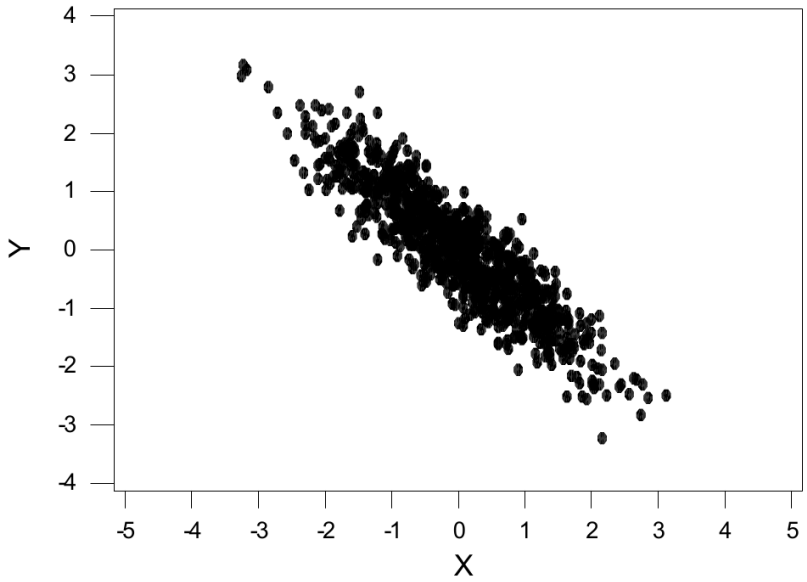


Figura 3.3.5: Uma amostra de $n = 1000$ valores (X, Y) da distribuição Normal Bivariada $(0; 0; 1; 1; -0{,}9)$.

Resumo da Seção 3.3

- A variância de uma variável aleatória X mede o quanto ela tende a se afastar de sua média e é dada por $\text{Var}(X) = E((X - \mu_X)^2) = E(X^2) - (E(X))^2$.
- Calculamos as variâncias de muitas distribuições usuais.
- O desvio padrão de X é igual a $\text{Sd}(X) = \sqrt{\text{Var}(X)}$.
- $\text{Var}(X) \geq 0$ e $\text{Var}(aX + b) = a^2 \text{Var}(X)$; também $\text{Sd}(aX + b) = |a| \text{Sd}(X)$.
- A covariância das variáveis aleatórias X e Y mede como elas se relacionam e é dada por $\text{Cov}(X, Y) = E((X - \mu_X)(Y - \mu_y)) = E(XY) - E(X)E(Y)$. *
- Se X e Y são independentes, então $\text{Cov}(X, Y) = 0$.
- $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\,\text{Cov}(X, Y)$. Se X e Y são independentes, isso é igual a $\text{Var}(X) + \text{Var}(Y)$.
- A correlação de X e Y é $\text{Corr}(X, Y) = \text{Cov}(X, Y)/(\text{Sd}(X)\,\text{Sd}(Y))$.

*Nota do tradutor. o original traz o índice minúsculo μ_y; seria μ_Y

Exercícios

3.3.1 Suponha que a função de probabilidade conjunta de X e Y seja dada por

$$p_{X,Y}(x,y) = \begin{cases} 1/2 & x = 3, y = 5 \\ 1/6 & x = 3, y = 9 \\ 1/6 & x = 6, y = 5 \\ 1/6 & x = 6, y = 9 \\ 0 & \text{caso contrário,} \end{cases}$$

com $E(X) = 4$, $E(Y) = 19/3$ e $E(XY) = 26$, como no Exemplo 3.1.16.

(a) Calcule $\text{Cov}(X, Y)$.

(b) Calcule $\text{Var}(X)$ e $\text{Var}(Y)$.

(c) Calcule $\text{Corr}(X, Y)$.

3.3.2 Suponha que a função de probabilidade conjunta de X e Y seja dada por

$$p_{X,Y}(x,y) = \begin{cases} 1/7 & x = 5, y = 0 \\ 1/7 & x = 5, y = 3 \\ 1/7 & x = 5, y = 4 \\ 3/7 & x = 8, y = 0 \\ 1/7 & x = 8, y = 4 \\ 0 & \text{caso contrário,} \end{cases}$$

como no Exemplo 2.7.5.

(a) Calcule $E(X)$ e $E(Y)$.

(b) Calcule $\text{Cov}(X, Y)$.

(c) Calcule $\text{Var}(X)$ e $\text{Var}(Y)$.

(d) Calcule $\text{Corr}(X, Y)$.

3.3.3 Sejam X e Y com densidade conjunta

$$f_{X,Y}(x,y) = \begin{cases} 4x^2y + 2y^5 & 0 \le x \le 1, 0 \le y \le 1 \\ 0 & \text{caso contrário,} \end{cases}$$

como no Exercício 3.2.2. Calcule $\text{Corr}(X, Y)$.

3.3.4 Sejam X e Y com densidade conjunta

$$f_{X,Y}(x,y) = \begin{cases} 15x^3y^4 + 6x^2y^7 & 0 \leq x \leq 1, 0 \leq y \leq 1 \\ 0 & \text{caso contrário.} \end{cases}$$

Calcule $E(X)$, $E(Y)$, $\text{Var}(X)$, $\text{Var}(Y)$, $\text{Cov}(X,Y)$ e $\text{Corr}(X,Y)$.

3.3.5 Sejam Y e Z duas variáveis aleatórias independentes, cada uma com variância positiva. Prove que $\text{Corr}(Y,Z) = 0$.

3.3.6 Sejam X, Y e Z três variáveis aleatórias e suponha que X e Z sejam independentes. Prove que $\text{Cov}(X+Y,Z) = \text{Cov}(Y,Z)$.

3.3.7 Seja $X \sim \text{Exponencial}(3)$ e $Y \sim \text{Poisson}(5)$. Suponha que X e Y sejam independentes. Seja $Z = X + Y$.

(a) Calcule $\text{Cov}(X,Z)$.

(b) Calcule $\text{Corr}(X,Z)$.

3.3.8 Prove que a variância da distribuição Uniforme[23] $[L,R]$ é dada pela expressão $(R-L)^2/12$.

3.3.9 Prove que $\text{Var}(X) = E(X(X-1)) - E(X)E(X-1)$. Use isso para calcular diretamente pela função de probabilidade que, quando $X \sim \text{Binomial}(n,\theta)$, então $\text{Var}(X) = n\theta(1-\theta)$.

3.3.10 Suponha que você lance três moedas honestas. Seja X o número de caras obtidas e seja $Y = X^2$. Calcule $E(X)$, $E(Y)$, $\text{Var}(X)$, $\text{Var}(Y)$, $\text{Cov}(X,Y)$ e $\text{Corr}(X,Y)$.

3.3.11 Suponha que você lance dois dados honestos de seis faces. Seja X o número obtido no primeiro dado e seja Y a soma dos números obtidos nos dois dados. Calcule $E(X)$, $E(Y)$, $E(XY)$ e $\text{Cov}(X,Y)$.

3.3.12 Suponha que você lance quatro moedas honestas. Seja X o número de caras obtidas e seja Y o número de coroas obtidas. Calcule $\text{Cov}(X,Y)$ e $\text{Corr}(X,Y)$.

3.3.13 Sejam X e Y independentes, com $X \sim \text{Bernoulli}(1/2)$ e $Y \sim \text{Bernoulli}(1/3)$. Seja $Z = X + Y$ e $W = X - Y$. Calcule $\text{Cov}(Z,W)$ e $\text{Corr}(Z,W)$.

3.3.14 Sejam X e Y independentes, com $X \sim \text{Bernoulli}(1/2)$ e $Y \sim N(0,1)$. Seja $Z = X + Y$ e $W = X - Y$. Calcule $\text{Var}(Z)$, $\text{Var}(W)$, $\text{Cov}(Z,W)$ e $\text{Corr}(Z,W)$.

No original: *uniform distribution*[23].

3.3.15 Suponha que você lance um dado honesto de seis faces e depois lance tantas moedas quanto o número obtido no dado. (Por exemplo, se o dado mostrar 4, você lança quatro moedas.) Seja X o número obtido no dado e Y o número de caras obtidas. Calcule $\text{Cov}(X, Y)$.

Problemas

3.3.16 Seja $X \sim N(0, 1)$ e seja $Y = cX$.

(a) Calcule $\lim_{c \searrow 0} \text{Cov}(X, Y)$.

(b) Calcule $\lim_{c \nearrow 0} \text{Cov}(X, Y)$.

(c) Calcule $\lim_{c \searrow 0} \text{Corr}(X, Y)$.

(d) Calcule $\lim_{c \nearrow 0} \text{Corr}(X, Y)$.

(e) Explique por que as respostas das partes (c) e (d) não são iguais.

3.3.17 Sejam X e Y com distribuição normal bivariada, como no Exemplo 2.7.9. Prove que $\text{Corr}(X, Y) = \rho$. (Sugestão: use (2.7.1).)

3.3.18 Prove que a variância da distribuição Geométrica(θ) é dada por $(1 - \theta)/\theta^2$. (Sugestão: use o Exercício 3.3.9 e $\left((1 - \theta)^x\right)'' = x(x - 1)(1 - \theta)^{x-2}$.)

3.3.19 Prove que a variância da distribuição Binomial Negativa(r, θ) é dada por $r(1 - \theta)/\theta^2$. (Sugestão: use o Problema 3.3.18.)

3.3.20 Sejam $\alpha > 0$ e $\lambda > 0$, e seja $X \sim \text{Gama}(\alpha, \lambda)$. Prove que $\text{Var}(X) = \alpha/\lambda^2$. (Sugestão: lembre o Problema 3.2.16.)

3.3.21 Suponha que $X \sim \text{Weibull}(\alpha)$ (ver Problema 2.4.19). Prove que $\text{Var}(X) = \Gamma(2/\alpha + 1) - \Gamma^2(1/\alpha + 1)$. (Sugestão: lembre o Problema 3.2.18.)

3.3.22 Suponha que $X \sim \text{Pareto}(\alpha)$ (ver Problema 2.4.20) para $\alpha > 2$. Prove que $\text{Var}(X) = \alpha/((\alpha - 1)^2(\alpha - 2))$. (Sugestão: lembre o Problema 3.2.19.)

3.3.23 Suponha que X siga a distribuição de Laplace (ver Problema 2.4.22). Prove que $\text{Var}(X) = 2$. (Sugestão: lembre o Problema 3.2.21.)

3.3.24 Suponha que $X \sim \text{Beta}(a, b)$ (ver Problema 2.4.24). Prove que $\text{Var}(X) = ab/((a + b)^2(a + b + 1))$. (Sugestão: lembre o Problema 3.2.22.)

3.3.25 Suponha que $(X_1, X_2, X_3) \sim \text{Multinomial}(n, \theta_1, \theta_2, \theta_3)$. Prove que

$$\text{Var}(X_i) = n\theta_i(1 - \theta_i), \quad \text{Cov}(X_i, X_j) = -n\theta_i\theta_j, \quad \text{quando } i \neq j.$$

(Sugestão: lembre o Problema 3.1.23.)

3.3.26 Suponha que $(X_1, X_2) \sim \text{Dirichlet}(\alpha_1, \alpha_2, \alpha_3)$ (ver Problema 2.7.17). Prove que

$$\text{Var}(X_i) = \frac{\alpha_i(\alpha_1 + \alpha_2 + \alpha_3 - \alpha_i)}{(\alpha_1 + \alpha_2 + \alpha_3)^2(\alpha_1 + \alpha_2 + \alpha_3 + 1)},$$
$$\text{Cov}(X_1, X_2) = \frac{-\alpha_1\alpha_2}{(\alpha_1 + \alpha_2 + \alpha_3)^2(\alpha_1 + \alpha_2 + \alpha_3 + 1)}.$$

(Sugestão: lembre o Problema 3.2.23.)

3.3.27 Suponha que $X \sim \text{Hipergeométrica}(N, M, n)$. Prove que

$$\text{Var}(X) = n\frac{M}{N}\left(1 - \frac{M}{N}\right)\frac{N-n}{N-1}.$$

(Sugestão: lembre o Problema 3.1.21 e use o Exercício 3.3.9.)

3.3.28 Suponha que você lance um dado honesto de seis faces e depois lance tantas moedas quanto o número obtido no dado. (Por exemplo, se o dado mostrar 4, você lança quatro moedas.) Seja X o número obtido no dado e Y o número de caras obtidas. Calcule $\text{Corr}(X, Y)$.

Desafios

3.3.29 Seja Y uma variável aleatória não negativa. Prove que $E(Y) = 0$ se e somente se $P(Y = 0) = 1$. (Você pode supor, para simplificar, que Y é discreta, mas o resultado vale para qualquer Y.)

3.3.30 Prove que $\text{Var}(X) = 0$ se e somente se existe um número real c com $P(X = c) = 1$. (Você pode usar o resultado do Desafio 3.3.29.)

3.3.31 Dê um exemplo de uma variável aleatória X tal que $E(X) = 5$ e $\text{Var}(X) = \infty$.

3.4 Funções Geradoras

Seja X uma variável aleatória. Lembre que a função de distribuição acumulada[24] de X, definida por $F_X(x) = P(X \leq x)$, contém toda a informação

No original: *cumulative distribution function*[24].

sobre a distribuição de X (veja o Teorema 2.5.1). Acontece que há outras funções — a função geradora[25] de probabilidade e a função geradora de momentos[26] — que também fornecem informação (às vezes, toda a informação) sobre X e seus valores esperados.

Definição 3.4.1

Seja X uma variável aleatória (em geral, discreta). Definimos então sua *função geradora de probabilidade*, r_X, por $r_X(t) = E(t^X)$ para $t \in R^1$.

Considere os exemplos de funções geradoras de probabilidade a seguir.

Exemplo 3.4.1 — A Distribuição Binomial(n, θ)

Se $X \sim \text{Binomial}(n, \theta)$, então

$$\begin{aligned} r_X(t) = E(t^X) &= \sum_{i=0}^{n} P(X = i)\, t^i \\ &= \sum_{i=0}^{n} \binom{n}{i} \theta^i (1-\theta)^{n-i} t^i \\ &= \sum_{i=0}^{n} \binom{n}{i} (t\theta)^i (1-\theta)^{n-i} = (t\theta + 1 - \theta)^n, \end{aligned}$$

pelo teorema binomial. ■

Exemplo 3.4.2 — A Distribuição Poisson(λ)

Se $Y \sim \text{Poisson}(\lambda)$, então

$$\begin{aligned} r_Y(t) = E(t^Y) &= \sum_{i=0}^{\infty} P(Y = i)\, t^i = \sum_{i=0}^{\infty} e^{-\lambda} \frac{\lambda^i}{i!} t^i \\ &= \sum_{i=0}^{\infty} e^{-\lambda} \frac{(\lambda t)^i}{i!} = e^{-\lambda} e^{\lambda t} = e^{\lambda(t-1)}. \end{aligned}$$

■

O teorema a seguir nos diz que, uma vez conhecida a função geradora de probabilidade $r_X(t)$, podemos calcular todas as probabilidades $P(X = 0)$, $P(X = 1)$, $P(X = 2)$ etc.

No original: *generating function*[25], *moment-generating function*[26].

Teorema 3.4.1

Seja X uma variável aleatória discreta cujos valores possíveis são todos inteiros não negativos. Suponha que $r_X(t_0) < \infty$ para algum $t_0 > 0$. Então

$$r_X(0) = P(X = 0),$$
$$r'_X(0) = P(X = 1),$$
$$r''_X(0) = 2\,P(X = 2),$$

etc. Em geral,

$$r_X^{(k)}(0) = k!\,P(X = k),$$

onde $r_X^{(k)}$ é a k-ésima derivada de r_X.

Demonstração. Como os valores possíveis são todos inteiros não negativos da forma $i = 0, 1, 2, \ldots$, temos

$$\begin{aligned} r_X(t) = E(t^X) &= \sum_x t^x P(X = x) = \sum_{i=0}^{\infty} t^i P(X = i) \\ &= t^0 P(X = 0) + t^1 P(X = 1) + t^2 P(X = 2) + t^3 P(X = 3) + \cdots, \end{aligned}$$

de modo que

$$r_X(t) = 1P(X = 0) + t^1 P(X = 1) + t^2 P(X = 2) + t^3 P(X = 3) + \cdots. \tag{3.4.1}$$

Substituindo $t = 0$ em (3.4.1), todos os termos se anulam, exceto o primeiro, e obtemos $r_X(0) = P(X = 0)$. Derivando os dois lados de (3.4.1), obtemos

$$r'_X(t) = 1P(X = 1) + 2t^1 P(X = 2) + 3t^2 P(X = 3) + \cdots,$$

e tomar $t = 0$ dá $r'_X(0) = P(X = 1)$. Derivando mais uma vez os dois lados, obtemos

$$r''_X(t) = 2P(X = 2) + 3 \cdot 2\,t^1 P(X = 3) + \cdots$$

e tomar $t = 0$ dá $r''_X(0) = 2\,P(X = 2)$. Continuando dessa forma, obtemos a fórmula geral. ■

Aplicamos agora o Teorema 3.4.1 às distribuições binomial e de Poisson.

Exemplo 3.4.3 — A Distribuição Binomial(n, θ)

Pelo Exemplo 3.4.1, temos que

$$\begin{aligned} r_X(0) &= (1-\theta)^n \\ r'_X(0) &= n(t\theta + 1 - \theta)^{n-1}(\theta)\Big|_{t=0} = n(1-\theta)^{n-1}\theta \\ r''_X(0) &= n(n-1)(t\theta + 1 - \theta)^{n-2}(\theta)(\theta)\Big|_{t=0} = n(n-1)(1-\theta)^{n-2}\theta^2, \end{aligned}$$

etc. Verifica-se assim diretamente que

$$\begin{aligned} P(X=0) &= r_X(0) \\ P(X=1) &= r'_X(0) \\ 2\,P(X=2) &= r''_X(0), \end{aligned}$$

etc. ■

Exemplo 3.4.4 — A Distribuição Poisson(λ)

Pelo Exemplo 3.4.2, temos que

$$\begin{aligned} r_X(0) &= e^{-\lambda} \\ r'_X(0) &= \lambda e^{-\lambda} \\ r''_X(0) &= \lambda^2 e^{-\lambda}, \end{aligned}$$

etc. Verifica-se novamente que

$$\begin{aligned} P(X=0) &= r_X(0) \\ P(X=1) &= r'_X(0) \\ 2\,P(X=2) &= r''_X(0), \end{aligned}$$

etc. ■

Pelo Teorema 3.4.1, vemos por que r_X é chamada de função geradora de probabilidade. De fato, ao menos no caso discreto com a distribuição concentrada nos inteiros não negativos, podemos realmente gerar as probabilidades de X a partir de r_X. Vemos então imediatamente que, para uma variável aleatória X que assume valores apenas em $\{0, 1, 2, \ldots\}$, r_X é única. Com isso queremos dizer que, se X e Y estão concentradas em $\{0, 1, 2, \ldots\}$ e $r_X = r_Y$, então X e Y têm a mesma distribuição. Essa propriedade de unicidade da função geradora de probabilidade pode ser muito útil quando se tenta determinar a distribuição de uma variável aleatória que assume valores apenas

em $\{0, 1, 2, \ldots\}$.

Está claro que a função geradora de probabilidade nos diz muito — na verdade, tudo — sobre a distribuição de variáveis aleatórias concentradas nos inteiros não negativos. Mas e quanto a outras variáveis aleatórias? Acontece que há outras quantidades, chamadas momentos, associadas a variáveis aleatórias, que são bastante informativas sobre suas distribuições.

Definição 3.4.2

Seja X uma variável aleatória e seja k um inteiro positivo. Então o k-ésimo *momento* de X é a quantidade $E(X^k)$, desde que essa esperança exista.

Note que, se $E(X^k)$ existe e é finita, pode-se mostrar que $E(X^l)$ existe e é finita quando $0 \leq l < k$.

O primeiro momento é simplesmente a média da variável aleatória. Ele pode ser tomado como uma medida de onde fica, na reta real, a massa central de probabilidade de X, ao menos quando essa distribuição é unimodal (tem um único pico) e não é muito assimétrica. O segundo momento $E(X^2)$, junto com o primeiro, nos dá a variância por meio de $\text{Var}(X) = E(X^2) - (E(X))^2$. Portanto, os dois primeiros momentos da distribuição nos informam a localização da distribuição e a dispersão, ou grau de concentração, dessa distribuição em torno da média. Na verdade, os momentos de ordem mais alta também fornecem informação sobre a distribuição.

Muitas das distribuições mais importantes da probabilidade e da estatística têm todos os seus momentos finitos; na verdade, elas têm o que se chama de função geradora de momentos.

Definição 3.4.3

Seja X uma variável aleatória qualquer. Sua *função geradora de momentos* m_X é definida por $m_X(s) = E(e^{sX})$ em $s \in R^1$.

O exemplo a seguir calcula a função geradora de momentos de uma distribuição bem conhecida.

Exemplo 3.4.5 — A Distribuição Exponencial(λ)

Seja $X \sim$ Exponencial(λ). Então, para $s < \lambda$,

$$\begin{aligned} m_X(s) = E(e^{sX}) &= \int_{-\infty}^{\infty} e^{sx} f_X(x)\,dx = \int_0^{\infty} e^{sx}\lambda e^{-\lambda x}\,dx \\ &= \int_0^{\infty} \lambda\, e^{(s-\lambda)x}\,dx = \frac{\lambda\, e^{(s-\lambda)x}}{s-\lambda}\Big|_{x=0}^{x=\infty} = -\frac{\lambda e^{(s-\lambda)0}}{s-\lambda} \\ &= -\frac{\lambda}{s-\lambda} = \lambda(\lambda - s)^{-1}. \end{aligned}$$

■

Uma comparação das Definições 3.4.1 e 3.4.3 dá imediatamente o seguinte.

Teorema 3.4.2

Seja X uma variável aleatória qualquer. Então $m_X(s) = r_X(e^s)$.

Esse resultado obviamente pode nos ajudar a calcular algumas funções geradoras de momentos quando já temos r_X.

Exemplo 3.4.6

Seja $Y \sim$ Binomial(n, θ). Então sabemos que $r_Y(t) = (t\theta + 1 - \theta)^n$. Logo, $m_Y(s) = r_Y(e^s) = (e^s\theta + 1 - \theta)^n$. ■

Exemplo 3.4.7

Seja $Z \sim$ Poisson(λ). Então sabemos que $r_Z(t) = e^{\lambda(t-1)}$. Logo, $m_Z(s) = r_Z(e^s) = e^{\lambda(e^s-1)}$. ■

O teorema a seguir nos diz que, uma vez conhecida a função geradora de momentos $m_X(t)$, podemos calcular todos os momentos $E(X)$, $E(X^2)$, $E(X^3)$ etc.

Teorema 3.4.3

Seja X uma variável aleatória qualquer. Suponha que, para algum $s_0 > 0$, valha $m_X(s) < \infty$ sempre que $s \in (-s_0, s_0)$. Então

$$m_X(0) = 1$$
$$m'_X(0) = E(X)$$
$$m''_X(0) = E(X^2),$$

etc. Em geral,

$$m_X^{(k)}(0) = E(X^k),$$

onde $m_X^{(k)}$ é a k-ésima derivada de m_X.

Demonstração. Sabemos que $m_X(s) = E(e^{sX})$. Temos

$$m_X(0) = E(e^{0X}) = E(e^0) = E(1) = 1.$$

Além disso, derivando, vemos* que $m'_X(s) = E(Xe^{sX})$, de modo que

$$m'_X(0) = E(Xe^{0X}) = E(Xe^0) = E(X).$$

Derivando de novo, vemos que $m''_X(s) = E(X^2e^{sX})$, de modo que

$$m''_X(0) = E(X^2e^{0X}) = E(X^2e^0) = E(X^2).$$

Continuando dessa forma, obtemos a fórmula geral. ■

Consideramos agora uma aplicação do Teorema 3.4.3.

*A rigor, a troca da ordem entre derivada e esperança é justificada pela teoria das funções analíticas e exige que $m_X(s) < \infty$ sempre que $|s| < s_0$.

Exemplo 3.4.8 — A Média e a Variância da Distribuição Exponencial(λ)

Usando a função geradora de momentos calculada no Exemplo 3.4.5, temos

$$m'_X(s) = (-1)\lambda(\lambda - s)^{-2}(-1) = \lambda(\lambda - s)^{-2}.$$

Portanto,

$$E(X) = m'_X(0) = \lambda(\lambda - 0)^{-2} = \lambda/\lambda^2 = 1/\lambda,$$

como deveria ser. Além disso,

$$E(X^2) = m''_X(0) = (-2)\lambda(\lambda - 0)^{-3}(-1) = 2\lambda/\lambda^3 = 2/\lambda^2,$$

de modo que temos

$$\text{Var}(X) = E(X^2) - (E(X))^2 = (2/\lambda^2) - (1/\lambda)^2 = 1/\lambda^2.$$

Isso fornece uma maneira fácil de calcular a variância de X. ■

Exemplo 3.4.9 — A Média e a Variância da Distribuição Poisson(λ)

No Exemplo 3.4.7, obtivemos $m_Z(s) = \exp(\lambda(e^s - 1))$. Assim, temos*

$$E(X) = m'_X(0) = \lambda e^0 \exp\Big(\lambda(e^0 - 1)\Big) = \lambda$$

$$E(X^2) = m''_X(0) = \lambda e^0 \exp\Big(\lambda(e^0 - 1)\Big) + \Big(\lambda e^0\Big)^2 \exp\Big(\lambda(e^0 - 1)\Big) = \lambda + \lambda^2.$$

Portanto, $\text{Var}(X) = E(X^2) - (E(X))^2 = \lambda + \lambda^2 - \lambda^2 = \lambda$. ■

Calcular a função geradora de momentos de uma distribuição normal também é importante, mas é um pouco mais difícil.

Teorema 3.4.4

Se $X \sim N(0, 1)$, então $m_X(s) = e^{s^2/2}$.

*Nota do tradutor. o original passa de m_Z para $E(X) = m'_X(0)$; pelo contexto, X aqui é a $Z \sim \text{Poisson}(\lambda)$ do Exemplo 3.4.7

Demonstração. Como X tem densidade $\phi(x) = (2\pi)^{-1/2} e^{-x^2/2}$, temos que

$$\begin{aligned} m_X(s) = E(e^{sX}) &= \int_{-\infty}^{\infty} e^{sx}\phi(x)\,dx = \int_{-\infty}^{\infty} e^{sx}\frac{1}{\sqrt{2\pi}}e^{-x^2/2}\,dx \\ &= \frac{1}{\sqrt{2\pi}}\int_{-\infty}^{\infty} e^{sx-(x^2/2)}\,dx = \frac{1}{\sqrt{2\pi}}\int_{-\infty}^{\infty} e^{-(x-s)^2/2+(s^2/2)}\,dx \\ &= e^{s^2/2}\frac{1}{\sqrt{2\pi}}\int_{-\infty}^{\infty} e^{-(x-s)^2/2}\,dx. \end{aligned}$$

Fazendo $y = x - s$ (de modo que $dy = dx$), isso se torna (usando o Teorema 2.4.2)

$$m_X(s) = e^{s^2/2}\frac{1}{\sqrt{2\pi}}\int_{-\infty}^{\infty} e^{-y^2/2}\,dy = e^{s^2/2}\int_{-\infty}^{\infty}\phi(y)\,dy = e^{s^2/2},$$

como afirmado. ■

Uma propriedade útil tanto das funções geradoras de probabilidade quanto das funções geradoras de momentos é a seguinte.

Teorema 3.4.5

Sejam X e Y variáveis aleatórias independentes. Então temos

(a) $r_{X+Y}(t) = r_X(t)\,r_Y(t)$, e

(b) $m_{X+Y}(t) = m_X(t)\,m_Y(t)$.

Demonstração. Como X e Y são independentes, t^X e t^Y também são (pelo Teorema 2.8.5). Logo, sabemos (pelos Teoremas 3.1.3 e 3.2.3) que $E(t^X t^Y) = E(t^X)\,E(t^Y)$. Usando isso, temos

$$r_{X+Y}(t) = E\left(t^{X+Y}\right) = E\left(t^X t^Y\right) = E(t^X)E(t^Y) = r_X(t)r_Y(t).$$

Analogamente,

$$m_{X+Y}(t) = E\left(e^{t(X+Y)}\right) = E\left(e^{tX}e^{tY}\right) = E(e^{tX})\,E(e^{tY}) = m_X(t)m_Y(t).$$

■

Exemplo 3.4.10

Seja $Y \sim \text{Binomial}(n, \theta)$. Então, como no Exemplo 3.1.15, podemos escrever

$$Y = X_1 + \cdots + X_n,$$

onde as $\{X_i\}$ são i.i.d. com $X_i \sim \text{Bernoulli}(\theta)$. Logo, o Teorema 3.4.5 diz que devemos ter $r_Y(t) = r_{X_1}(t)\, r_{X_2}(t) \cdots r_{X_n}(t)$. Mas, para qualquer i,

$$r_{X_i}(t) = \sum_x t^x P(X = x) = t^1\theta + t^0(1-\theta) = \theta t + 1 - \theta.$$

Logo, devemos ter

$$r_Y(t) = (\theta t + 1 - \theta)(\theta t + 1 - \theta) \cdots (\theta t + 1 - \theta) = (\theta t + 1 - \theta)^n,$$

como já verificado no Exemplo 3.4.1. ■

As funções geradoras de momentos, quando definidas numa vizinhança de 0, definem completamente uma distribuição, no sentido a seguir. (Omitimos a demonstração, que é avançada.)

Teorema 3.4.6 (Teorema da unicidade)

Seja X uma variável aleatória tal que, para algum $s_0 > 0$, temos $m_X(s) < \infty$ sempre que $s \in (-s_0, s_0)$. Então, se Y é alguma outra variável aleatória com $m_Y(s) = m_X(s)$ sempre que $s \in (-s_0, s_0)$, X e Y têm a mesma distribuição.

Os Teoremas 3.4.1 e 3.4.6 fornecem uma técnica poderosa para identificar distribuições. Por exemplo, se determinamos que a função geradora de momentos de X é $m_X(t) = \exp(s^2/2)$,* então sabemos, pelos Teoremas 3.4.4 e 3.4.6, que $X \sim N(0, 1)$. Podemos usar essa abordagem para determinar as distribuições de algumas variáveis aleatórias complicadas.

*Nota do tradutor. o original traz $m_X(t)$ à esquerda e s à direita; seria $m_X(s) = \exp(s^2/2)$

Exemplo 3.4.11

Suponha que $X_i \sim N(\mu_i, \sigma_i^2)$ para $i = 1, \ldots, n$ e que essas variáveis aleatórias sejam independentes. Considere a distribuição de $Y = \sum_{i=1}^{n} X_i$.

Quando $n = 1$, temos (pelo Problema 3.4.15)

$$m_Y(s) = \exp\left\{\mu_1 s + \frac{\sigma_1^2 s^2}{2}\right\}.$$

Então, usando o Teorema 3.4.5, temos que

$$\begin{aligned} m_Y(s) &= \prod_{i=1}^{n} m_{X_i}(s) = \prod_{i=1}^{n} \exp\left\{\mu_i s + \frac{\sigma_i^2 s^2}{2}\right\} \\ &= \exp\left\{\left(\sum_{i=1}^{n} \mu_i\right) s + \frac{\left(\sum_{i=1}^{n} \sigma_i^2\right) s^2}{2}\right\}. \end{aligned}$$

Pelo Problema 3.4.15, e aplicando o Teorema 3.4.6, temos que

$$Y \sim N\left(\sum_{i=1}^{n} \mu_i, \sum_{i=1}^{n} \sigma_i^2\right).$$

As funções geradoras também podem nos ajudar com distribuições compostas, que são definidas a seguir.

Definição 3.4.4

Sejam $X_1, X_2, \ldots$ i.i.d., e seja N uma variável aleatória não negativa, com valores inteiros, independente das $\{X_i\}$. Seja

$$S = \sum_{i=1}^{N} X_i. \tag{3.4.2}$$

Diz-se então que S tem uma *distribuição composta*.

Uma distribuição composta[27] é obtida a partir de uma soma de variáveis aleatórias i.i.d., em que o número de termos da soma é distribuído aleatoriamente, independentemente dos termos da soma. Note que $S = 0$ quando $N = 0$. Essas distribuições têm aplicações em áreas como seguros, em que $X_1, X_2, \ldots$ são

No original: *compound distribution*[27].

sinistros e N é o número de sinistros apresentados a uma seguradora durante um período. Portanto, S representa o valor total reclamado à seguradora durante o período. Obviamente, a seguradora quer estudar a distribuição de S, pois isso ajudará a determinar quanto ela precisa cobrar pelo seguro para garantir lucro.

O teorema a seguir é importante no estudo de distribuições compostas.

Teorema 3.4.7

Se S tem uma distribuição composta como em (3.4.2), então

(a) $E(S) = E(X_1)E(N)$.

(b) $m_S(s) = r_N(m_{X_1}(s))$.

Demonstração. Veja a Seção 3.8 para a demonstração desse resultado. ■

3.4.1 Funções Características (Avançado)

Um problema das funções geradoras de momentos é que elas podem ser *infinitas* em qualquer intervalo aberto em torno de $s = 0$. Considere o exemplo a seguir.

Exemplo 3.4.12

Seja X uma variável aleatória com densidade

$$f_X(x) = \begin{cases} 1/x^2 & x \geq 1 \\ 0 & \text{caso contrário.} \end{cases}$$

Então

$$m_X(s) = E(e^{sX}) = \int_1^\infty e^{sx}(1/x^2)\,dx.$$

Para qualquer $s > 0$, sabemos que e^{sx} cresce mais rápido que x^2, de modo que $\lim_{x\to\infty} e^{sx}/x^2 = \infty$. Logo, $m_X(s) = \infty$ sempre que $s > 0$.

X tem algum momento finito? Temos que

$$E(X) = \int_1^\infty x(1/x^2)\,dx = \int_1^\infty (1/x)\,dx = \ln x\,|_{x=1}^{x=\infty} = \infty,$$

de modo que, na verdade, o primeiro momento não existe. Daí concluímos que X não tem nenhum momento. ■

A variável aleatória X do exemplo acima *não* satisfaz a condição do Teorema 3.4.3 de que $m_X(s) < \infty$ sempre que $|s| < s_0$, para algum $s_0 > 0$. Logo, o Teorema 3.4.3 (como a maioria dos outros teoremas que usam funções geradoras de momentos) não se aplica. Há, no entanto, uma função definida de modo parecido que não sofre desse defeito, dada pela definição a seguir.

Definição 3.4.5

Seja X uma variável aleatória qualquer. Definimos então sua *função característica*, c_X, por

$$c_X(s) = E(e^{isX}) \tag{3.4.3}$$

para $s \in R^1$.

Assim, a definição de c_X é igual à de m_X, exceto pela introdução do número imaginário $i = \sqrt{-1}$. Usando propriedades dos números complexos, vemos que (3.4.3) também pode ser escrita como $c_X(s) = E(\cos(sX)) + i\,E(\sin(sX))$ para $s \in R^1$.

Considere os exemplos a seguir.

Exemplo 3.4.13 — A Distribuição Bernoulli

Seja $X \sim \text{Bernoulli}(\theta)$. Então

$$\begin{aligned} c_X(s) &= E(e^{isX}) = (e^{is0})(1-\theta) + (e^{is1})(\theta) \\ &= (1)(1-\theta) + e^{is}(\theta) = 1 - \theta + \theta e^{is} \\ &= 1 - \theta + \theta \cos s + i\theta \sin s. \end{aligned}$$

■

Exemplo 3.4.14

Seja X com função de probabilidade dada por

$$p_X(x) = \begin{cases} 1/6 & x = 2 \\ 1/3 & x = 3 \\ 1/2 & x = 4 \\ 0 & \text{caso contrário.} \end{cases}$$

Então

$$\begin{aligned} c_X(s) &= E(e^{isX}) = (e^{is2})(1/6) + (e^{is3})(1/3) + (e^{is4})(1/2) \\ &= (1/6)\cos 2s + (1/3)\cos 3s + (1/2)\cos 4s \\ &\quad + (1/6)i \sin 2s + (1/3)i \sin 3s + i(1/2)\sin 4s. \end{aligned}$$

■

Exemplo 3.4.15

Seja Z com função de probabilidade dada por

$$p_Z(z) = \begin{cases} 1/2 & z = 1 \\ 1/2 & z = -1 \\ 0 & \text{caso contrário.} \end{cases}$$

Então

$$\begin{aligned} c_Z(s) &= E(e^{isZ}) = (e^{is})(1/2) + (e^{-is})(1/2) \\ &= (1/2)\cos(s) + (1/2)\cos(-s) + (1/2)\sin(s) + (1/2)\sin(-s) \\ &= (1/2)\cos s + (1/2)\cos s + (1/2)\sin s - (1/2)\sin s = \cos s. \end{aligned}$$

Logo, neste caso, $c_Z(s)$ é um número real (não complexo) para todo $s \in R^1$. ■

Uma vez superado nosso "medo" dos números imaginários e complexos, podemos ver que a função característica[28] é, em alguns aspectos, muito melhor que a função geradora de momentos. A principal vantagem é que, como $e^{isX} = \cos(sX) + i\sin(sX)$ e $|e^{isX}| = 1$, a função característica[29] (ao contrário da função geradora de momentos) é sempre finita (embora possa ser um número complexo).

Teorema 3.4.8

Seja X uma variável aleatória qualquer e seja s um número real qualquer. Então $c_X(s)$ é finita.

A função característica tem muitas propriedades parecidas com as da função geradora de momentos. Em particular, temos o seguinte. (A demonstração é igual à do Teorema 3.4.3.)

Teorema 3.4.9

Seja X uma variável aleatória qualquer com seus k primeiros momentos finitos. Então $c_X(0) = 1$, $c'_X(0) = i\,E(X)$, $c''_X(0) = i^2E(X^2) = -E(X^2)$ etc. Em geral, $c_X^{(k)}(0) = i^kE(X^k)$, onde $i = \sqrt{-1}$ e $c_X^{(k)}$ é a k-ésima derivada de c_X.

Temos também o seguinte. (A demonstração é igual à do Teorema 3.4.5.)

No original: *characteristic function*[28], *characteristic function*[29].

Teorema 3.4.10

Sejam X e Y variáveis aleatórias *independentes*. Então $c_{X+Y}(s) = c_X(s)\,c_Y(s)$.

Por simplicidade, em geral não usaremos funções características neste livro. No entanto, vale a pena ter em mente que, sempre que fazemos algo com funções geradoras de momentos, em geral poderíamos fazer o mesmo com mais generalidade usando funções características.

Resumo da Seção 3.4

- A função geradora de probabilidade de uma variável aleatória X é $r_X(t) = E(t^X)$.
- Se X é discreta, então as derivadas de r_X satisfazem $r_X^{(k)}(0) = k!\,P(X = k)$.
- O k-ésimo momento de uma variável aleatória X é $E(X^k)$.
- A função geradora de momentos de uma variável aleatória X é $m_X(s) = E(e^{sX}) = r_X(e^s)$.
- As derivadas de m_X satisfazem $m_X^{(k)}(0) = E(X^k)$, para $k = 0, 1, 2, \ldots$.
- Se X e Y são independentes, então $r_{X+Y}(t) = r_X(t)\,r_Y(y)^*$ e $m_{X+Y}(s) = m_X(s)\,m_Y(s)$.
- Se $m_X(s)$ é finita numa vizinhança de $s = 0$, então ela caracteriza de modo único a distribuição de X.
- A função característica $c_X(s) = E(e^{isX})$ pode ser usada no lugar de $m_X(s)$ para evitar infinitos.

Exercícios

3.4.1 Seja Z uma variável aleatória discreta com $P(Z = z) = 1/2^z$ para $z = 1, 2, 3, \ldots$.

(a) Calcule $r_Z(t)$. Verifique que $r_Z'(0) = P(Z = 1)$ e $r_Z''(0) = 2\,P(Z = 2)$.

(b) Calcule $m_Z(t)$. Verifique que $m_Z'(0) = E(Z)$ e $m_Z''(0) = E(Z^2)$.

3.4.2 Seja $X \sim \text{Binomial}(n, \theta)$. Use m_X para provar que $\text{Var}(X) = n\theta(1 - \theta)$.

3.4.3 Seja $Y \sim \text{Poisson}(\lambda)$. Use m_Y para calcular a média e a variância de Y.

*Nota do tradutor. o original traz $r_Y(y)$; seria $r_Y(t)$

3.4.4 Seja $Y = 3X + 4$. Calcule $r_Y(t)$ em termos de r_X.

3.4.5 Seja $Y = 3X + 4$. Calcule $m_Y(s)$ em termos de m_X.

3.4.6 Seja $X \sim \text{Binomial}(n, \theta)$. Calcule $E(X^3)$, o terceiro momento de X.

3.4.7 Seja $Y \sim \text{Poisson}(\lambda)$. Calcule $E(Y^3)$, o terceiro momento de Y.

3.4.8 Suponha que $P(X = 2) = 1/2$, $P(X = 5) = 1/3$ e $P(X = 7) = 1/6$.

(a) Calcule $r_X(t)$ para $t \in R^1$.

(b) Verifique que $r'_X(0) = P(X = 1)$ e $r''_X(0) = 2P(X = 2)$.

(c) Calcule $m_X(s)$ para $s \in R^1$.

(d) Verifique que $m'_X(0) = E(X)$ e $m''_X(0) = E(X^2)$.

Problemas

3.4.9 Suponha que $f_X(x) = 1/10$ para $0 < x < 10$, com $f_X(x) = 0$ caso contrário.

(a) Calcule $m_X(s)$ para $s \in R^1$.

(b) Verifique que $m'_X(0) = E(X)$. (Sugestão: regra de L'Hôpital.)

3.4.10 Seja $X \sim \text{Geométrica}(\theta)$. Calcule $r_X(t)$ e $r''_X(0)/2$.

3.4.11 Seja $X \sim \text{Binomial Negativa}(r, \theta)$. Calcule $r_X(t)$ e $r''_X(0)/2$.

3.4.12 Seja $X \sim \text{Geométrica}(\theta)$.

(a) Calcule $m_X(s)$.

(b) Use m_X para calcular a média de X.

(c) Use m_X para calcular a variância de X.

3.4.13 Seja $X \sim \text{Binomial Negativa}(r, \theta)$.

(a) Calcule $m_X(s)$.

(b) Use m_X para calcular a média de X.

(c) Use m_X para calcular a variância de X.

3.4.14 Se $Y = a + bX$, onde a e b são constantes, mostre que $r_Y(t) = t^a r_X(t^b)$ e $m_Y(t) = e^{at} m_X(bt)$.

3.4.15 Seja $Z \sim N(\mu, \sigma^2)$. Mostre que

$$m_Z(s) = \exp\left\{\mu s + \frac{\sigma^2 s^2}{2}\right\}.$$

(Sugestão: escreva $Z = \mu + \sigma X$, onde $X \sim N(0,1)$, e use o Teorema 3.4.4.)

3.4.16 Seja Y distribuída segundo a distribuição de Laplace (veja o Problema 2.4.22).

(a) Calcule $m_Y(s)$. (Sugestão: divida a integral em duas partes.)

(b) Use m_Y para calcular a média de Y.

(c) Use m_Y para calcular a variância de Y.

3.4.17 Calcule o k-ésimo momento da distribuição Weibull(α) em termos de Γ (veja o Problema 2.4.19).

3.4.18 Calcule o k-ésimo momento da distribuição Pareto(α) (veja o Problema 2.4.20). (Sugestão: faça a transformação $u = (1+x)^{-1}$ e lembre-se da distribuição beta.)

3.4.19 Calcule o k-ésimo momento da distribuição Log-normal[30](τ) (veja o Problema 2.6.17). (Sugestão: faça a transformação $z = \ln x$ e use o Problema 3.4.15.)

3.4.20 Prove que a função geradora de momentos da distribuição Gama(α, λ) é dada por $\lambda^\alpha/(\lambda - t)^\alpha$ quando $t < \lambda$.

3.4.21 Suponha que $X_i \sim$ Poisson(λ_i) e que $X_1, \ldots, X_n$ sejam independentes. Usando funções geradoras de momentos, determine a distribuição de $Y = \sum_{i=1}^n X_i$.

3.4.22 Suponha que $X_i \sim$ Binomial Negativa(r_i, θ) e que $X_1, \ldots, X_n$ sejam independentes. Usando funções geradoras de momentos, determine a distribuição de $Y = \sum_{i=1}^n X_i$.

3.4.23 Suponha que $X_i \sim$ Gama(α_i, λ) e que $X_1, \ldots, X_n$ sejam independentes. Usando funções geradoras de momentos, determine a distribuição de $Y = \sum_{i=1}^n X_i$.

3.4.24 Suponha que $X_1, X_2, \ldots$ sejam i.i.d. Exponencial(λ) e $N \sim$ Poisson(λ), independente das $\{X_i\}$. Determine a função geradora de momentos de S_N. Determine o primeiro momento dessa distribuição derivando essa função.

No original: *Log-normal distribution*[30].

3.4.25 Suponha que $X_1, X_2, \ldots$ sejam variáveis aleatórias i.i.d. Exponencial(λ) e $N \sim$ Geométrica(θ), independente das $\{X_i\}$. Determine a função geradora de momentos de S_N. Determine o primeiro momento dessa distribuição derivando essa função.

3.4.26 Seja $X \sim$ Bernoulli(θ). Use $c_X(s)$ para calcular a média de X.

3.4.27 Seja $Y \sim$ Binomial(n, θ).

(a) Calcule a função característica $c_Y(s)$. (Sugestão: use $c_X(s)$ do Problema 3.4.26.)

(b) Use $c_Y(s)$ para calcular a média de Y.

3.4.28 A função característica da distribuição de Cauchy (veja o Problema 2.4.21) é dada por $c(t) = e^{-|t|}$. Use isso para determinar a função característica da média amostral

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$$

baseada numa amostra de tamanho n da distribuição de Cauchy. Explique por que isso implica que a média amostral também tem distribuição de Cauchy. O que você acha surpreendente nesse resultado?

3.4.29 O *k-ésimo cumulante* (quando existe) de uma variável aleatória X é obtido calculando a k-ésima derivada de $\ln c_X(s)$ em relação a s, avaliando-a em $s = 0$ e dividindo por i^k. Calcule $c_X(s)$ e todos os cumulantes da distribuição $N(\mu, \sigma^2)$.

3.5 Esperança Condicional

Vimos nas Seções 1.5 e 2.8 que o *condicionamento* em algum evento, ou em alguma variável aleatória, pode mudar diversas probabilidades. Ora, como as esperanças são definidas em termos de probabilidades, parece razoável que as esperanças também mudem quando condicionamos em algum evento ou variável aleatória. Essas esperanças modificadas são chamadas *esperanças condicionais*, como discutimos agora.

3.5.1 Caso Discreto

O caso mais simples é aquele em que X é uma variável aleatória discreta e A é algum evento de probabilidade positiva. Temos o seguinte.

Definição 3.5.1

Seja X uma variável aleatória discreta, e seja A algum evento com $P(A) > 0$. Então a *esperança condicional* de X, dado A, é igual a

$$E(X \mid A) = \sum_{x \in R^1} x\, P(X = x \mid A) = \sum_{x \in R^1} x \frac{P(X = x, A)}{P(A)}.$$

Exemplo 3.5.1

Considere o lançamento de um dado honesto de seis faces, de modo que $S = \{1, 2, 3, 4, 5, 6\}$. Seja X o número que aparece no dado, de modo que $X(s) = s$ para $s \in S$. Seja $A = \{3, 5, 6\}$ o evento de que o dado mostra 3, 5 ou 6. Quanto vale $E(X \mid A)$?

Aqui sabemos que

$$P(X = 3 \mid A) = P(X = 3 \mid X = 3, 5 \text{ ou } 6) = 1/3$$

e que, de forma análoga, $P(X = 5 \mid A) = P(X = 6 \mid A) = 1/3$. Logo,

$$\begin{aligned} E(X \mid A) &= \sum_{x \in R^1} x\, P(X = x \mid A) \\ &= 3\, P(X = 3 \mid A) + 5\, P(X = 5 \mid A) + 6\, P(X = 6 \mid A) \\ &= 3(1/3) + 5(1/3) + 6(1/3) = 14/3. \end{aligned}$$

■

Muitas vezes queremos condicionar no valor de alguma outra variável aleatória. Se essa outra variável aleatória também é discreta, e se o valor em que condicionamos tem probabilidade positiva, isso funciona como acima.

Definição 3.5.2

Sejam X e Y variáveis aleatórias discretas, com $P(Y = y) > 0$. Então a *esperança condicional* de X, dado $Y = y$, é igual a

$$E(X \mid Y = y) = \sum_{x \in R^1} x\, P(X = x \mid Y = y) = \sum_{x \in R^1} x \frac{p_{X,Y}(x, y)}{p_Y(y)}.$$

Exemplo 3.5.2

Suponha que a função de probabilidade conjunta de X e Y seja dada por

$$p_{X,Y}(x,y) = \begin{cases} 1/7 & x = 5, y = 0 \\ 1/7 & x = 5, y = 3 \\ 1/7 & x = 5, y = 4 \\ 3/7 & x = 8, y = 0 \\ 1/7 & x = 8, y = 4 \\ 0 & \text{caso contrário.} \end{cases}$$

Então

$$\begin{aligned} E(X \mid Y = 0) &= \sum_{x \in R^1} x\, P(X = x \mid Y = 0) \\ &= 5P(X = 5 \mid Y = 0) + 8P(X = 8 \mid Y = 0) \\ &= 5\,\frac{P(X = 5, Y = 0)}{P(Y = 0)} + 8\,\frac{P(X = 8, Y = 0)}{P(Y = 0)} \\ &= 5\,\frac{1/7}{1/7 + 3/7} + 8\,\frac{3/7}{1/7 + 3/7} = \frac{29}{4}. \end{aligned}$$

De forma análoga,

$$\begin{aligned} E(X \mid Y = 4) &= \sum_{x \in R^1} x\, P(X = x \mid Y = 4) \\ &= 5P(X = 5 \mid Y = 4) + 8P(X = 8 \mid Y = 4) \\ &= 5\,\frac{1/7}{1/7 + 1/7} + 8\,\frac{1/7}{1/7 + 1/7} = 13/2. \end{aligned}$$

Além disso,

$$\begin{aligned} E(X \mid Y = 3) &= \sum_{x \in R^1} x\, P(X = x \mid Y = 3) = 5P(X = 5 \mid Y = 3) \\ &= 5\,\frac{1/7}{1/7} = 5. \end{aligned}$$

■

Às vezes queremos condicionar numa variável aleatória Y sem especificar de antemão em qual valor de Y estamos condicionando. Nesse caso, a esperança condicional[31] $E(X \mid Y)$ é ela própria uma variável aleatória, isto é, ela depende do valor (aleatório) de Y que ocorrer.

No original: *conditional expectation*[31].

Definição 3.5.3

Sejam X e Y variáveis aleatórias discretas. Então a *esperança condicional* de X, dado Y, é a variável aleatória $E(X \mid Y)$, que é igual a $E(X \mid Y = y)$ quando $Y = y$. Em particular, $E(X \mid Y)$ é uma variável aleatória que depende do valor aleatório de Y.

Exemplo 3.5.3

Suponha novamente que a função de probabilidade conjunta de X e Y seja dada por

$$p_{X,Y}(x,y) = \begin{cases} 1/7 & x = 5, y = 0 \\ 1/7 & x = 5, y = 3 \\ 1/7 & x = 5, y = 4 \\ 3/7 & x = 8, y = 0 \\ 1/7 & x = 8, y = 4 \\ 0 & \text{caso contrário.} \end{cases}$$

Já calculamos que $E(X \mid Y = 0) = 29/4$, $E(X \mid Y = 4) = 13/2$ e $E(X \mid Y = 3) = 5$. Podemos expressar esses resultados juntos dizendo que

$$E(X \mid Y) = \begin{cases} 29/4 & Y = 0 \\ 5 & Y = 3 \\ 13/2 & Y = 4. \end{cases}$$

Isto é, $E(X \mid Y)$ é uma variável aleatória, que depende do valor de Y. Note que, como $P(Y = y) = 0$ para $y \neq 0, 3, 4$, a variável aleatória $E(X \mid Y)$ fica *indefinida* nesse caso; mas isso não é um problema, porque esse caso nunca ocorrerá. ■

Por fim, observamos que, assim como a esperança comum, a esperança condicional é linear.

Teorema 3.5.1

Sejam X_1, X_2 e Y variáveis aleatórias; seja A um evento; sejam a, b e y números reais; e seja $Z = aX_1 + bX_2$. Então

(a) $E(Z \mid A) = aE(X_1 \mid A) + bE(X_2 \mid A)$.

(b) $E(Z \mid Y = y) = aE(X_1 \mid Y = y) + bE(X_2 \mid Y = y)$.

(c) $E(Z \mid Y) = aE(X_1 \mid Y) + bE(X_2 \mid Y)$.

3.5.2 Caso Absolutamente Contínuo

Suponha agora que X e Y são conjuntamente absolutamente contínuas[32]. Então condicionar em $Y = y$, para algum valor particular de y, parece problemático, porque $P(Y = y) = 0$. Porém, já vimos na Seção 2.8.2 que podemos definir uma *densidade condicional*[33] $f_{X|Y}(x \mid y)$ que nos dá uma função densidade para X, condicionada a $Y = y$. E, assim como funções densidade dão origem a esperanças, funções densidade condicionais dão origem a esperanças condicionais, como segue.

Definição 3.5.4

Sejam X e Y variáveis aleatórias conjuntamente absolutamente contínuas, com função densidade conjunta $f_{X,Y}(x, y)$. Então a *esperança condicional* de X, dado $Y = y$, é igual a

$$E(X \mid Y = y) = \int_{x \in R^1} x\, f_{X|Y}(x \mid y)\, dx = \int_{x \in R^1} x\, \frac{f_{X,Y}(x, y)}{f_Y(y)}\, dx.$$

No original: *jointly absolutely continuous*[32], *conditional density*[33].

Exemplo 3.5.4

Sejam X e Y conjuntamente absolutamente contínuas, com função densidade conjunta $f_{X,Y}$ dada por

$$f_{X,Y}(x,y) = \begin{cases} 4x^2y + 2y^5 & 0 \le x \le 1, 0 \le y \le 1 \\ 0 & \text{caso contrário.} \end{cases}$$

Então, para $0 < y < 1$,

$$f_Y(y) = \int_{-\infty}^{\infty} f_{X,Y}(x,y)\,dx = \int_0^1 (4x^2y + 2y^5)\,dx = 4y/3 + 2y^5.$$

Logo,

$$\begin{aligned} E(X \mid Y = y) &= \int_{x \in R^1} x \frac{f_{X,Y}(x,y)}{f_Y(y)}\,dx = \int_0^1 x \frac{4x^2y + 2y^5}{4y/3 + 2y^5}\,dx \\ &= \frac{y + y^5}{4y/3 + 2y^5} = \frac{1 + y^4}{4/3 + 2y^4}. \end{aligned}$$

■

Como no caso discreto, muitas vezes queremos condicionar numa variável aleatória sem especificar de antemão o valor dessa variável. Assim, $E(X \mid Y)$ é novamente uma variável aleatória, que depende do valor aleatório de Y.

Definição 3.5.5

Sejam X e Y variáveis aleatórias conjuntamente absolutamente contínuas. Então a *esperança condicional* de X, dado Y, é a variável aleatória $E(X \mid Y)$, que é igual a $E(X \mid Y = y)$ quando $Y = y$. Assim, $E(X \mid Y)$ é uma variável aleatória que depende do valor aleatório de Y.

Exemplo 3.5.5

Sejam X e Y novamente com densidade conjunta

$$f_{X,Y}(x,y) = \begin{cases} 4x^2y + 2y^5 & 0 \leq x \leq 1, 0 \leq y \leq 1 \\ 0 & \text{caso contrário.} \end{cases}$$

Já sabemos que $E(X \mid Y = y) = \big(1 + y^4\big)/\big(4/3 + 2y^4\big)$. Essa fórmula vale para qualquer y entre 0 e 1, de modo que concluímos que $E(X \mid Y) = \big(1 + Y^4\big)/\big(4/3 + 2Y^4\big)$. Note que, nessa última fórmula, Y é uma variável aleatória, de modo que $E(X \mid Y)$ também é uma variável aleatória. ■

Por fim, observamos que, no caso absolutamente contínuo, a esperança condicional continua linear, isto é, o Teorema 3.5.1 continua valendo.

3.5.3 Esperanças Duplas

Como a esperança condicional $E(X \mid Y)$ é ela própria uma variável aleatória (como função de Y), faz sentido tomar a sua esperança, $E\big(E(X \mid Y)\big)$. Essa é uma *esperança dupla*. Um dos resultados fundamentais sobre a esperança condicional é que essa esperança dupla é sempre igual a $E(X)$.

Teorema 3.5.2 (Teorema da esperança total)

Se X e Y são variáveis aleatórias, então $E\big(E(X \mid Y)\big) = E(X)$.

Esse teorema decorre como caso particular do Teorema 3.5.3, na próxima página. Mas ele também faz sentido intuitivamente. De fato, condicionar em Y muda o valor condicional de X de várias maneiras, às vezes tornando-o menor e às vezes maior, dependendo do valor de Y. Porém, se depois tomamos a média sobre todos os valores possíveis de Y, esses vários efeitos se cancelam, e ficamos apenas com $E(X)$.

Exemplo 3.5.6

Suponha novamente que X e Y têm função de probabilidade conjunta

$$p_{X,Y}(x,y) = \begin{cases} 1/7 & x = 5, y = 0 \\ 1/7 & x = 5, y = 3 \\ 1/7 & x = 5, y = 4 \\ 3/7 & x = 8, y = 0 \\ 1/7 & x = 8, y = 4 \\ 0 & \text{caso contrário.} \end{cases}$$

Então sabemos que

$$E(X \mid Y = y) = \begin{cases} 29/4 & y = 0 \\ 5 & y = 3 \\ 13/2 & y = 4. \end{cases}$$

Além disso, $P(Y = 0) = 1/7 + 3/7 = 4/7$, $P(Y = 3) = 1/7$ e $P(Y = 4) = 1/7 + 1/7 = 2/7$. Logo,

$$\begin{aligned} &E\big(E(X \mid Y)\big) \\ &= \sum_{y \in R^1} E(X \mid Y = y)\, P(Y = y) \\ &= E(X \mid Y = 0)\, P(Y = 0) + E(X \mid Y = 3)\, P(Y = 3) + E(X \mid Y = 4)\, P(Y = 4) \\ &= (29/4)(4/7) + (5)(1/7) + (13/2)(2/7) = 47/7. \end{aligned}$$

Por outro lado, calculamos diretamente que $E(X) = 5P(X = 5) + 8P(X = 8) = 5(3/7) + 8(4/7) = 47/7$. Logo, $E\big(E(X \mid Y)\big) = E(X)$, como afirmado. ■

Exemplo 3.5.7

Sejam X e Y novamente com densidade conjunta

$$f_{X,Y}(x,y) = \begin{cases} 4x^2y + 2y^5 & 0 \le x \le 1, 0 \le y \le 1 \\ 0 & \text{caso contrário.} \end{cases}$$

Já sabemos que

$$E(X \mid Y) = \big(1 + Y^4\big)/\big(4/3 + 2Y^4\big)$$

e que $f_Y(y) = 4y/3 + 2y^5$ para $0 \le y \le 1$. Logo,

$$\begin{aligned} &E\big(E(X \mid Y)\big) \\ &= E\left(\frac{1+Y^4}{4/3+2Y^4}\right) = \int_{-\infty}^{\infty} E(X \mid Y = y)\, f_Y(y)\, dy \\ &= \int_0^1 \frac{1+y^4}{4/3+2y^4}\,(4y/3 + 2y^5)\, dy = \int_0^1 (y + y^5)\, dy = 1/2 + 1/6 = 2/3. \end{aligned}$$

Por outro lado,

$$\begin{aligned} E(X) &= \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} x\, f_{X,Y}(x,y)\, dy\, dx = \int_0^1\int_0^1 x\,(4x^2y + 2y^5)\, dy\, dx \\ &= \int_0^1 x\,(2x^2 + 2/6)\, dx = \int_0^1 (2x^3 + x/3)\, dx = 2/4 + 1/6 = 2/3. \end{aligned}$$

Logo, $E\big(E(X \mid Y)\big) = E(X)$, como afirmado. ■

O Teorema 3.5.2 é um caso particular (com $g(y) \equiv 1$) do resultado mais geral a seguir, que de fato *caracteriza* a esperança condicional.

Teorema 3.5.3

Sejam X e Y variáveis aleatórias, e seja $g : R^1 \to R^1$ uma função qualquer. Então $E\big(g(Y)E(X \mid Y)\big) = E\big(g(Y)X\big)$.

Demonstração. Veja a demonstração desse resultado na Seção 3.8. ■

Observamos também o seguinte resultado relacionado. Ele diz que, ao condicionar em Y, qualquer função de Y pode ser posta em evidência, já que ela é, na prática, uma constante.

Teorema 3.5.4

Sejam X e Y variáveis aleatórias, e seja $g : R^1 \to R^1$ uma função qualquer. Então $E\big(g(Y)X \mid Y\big) = g(Y)E(X \mid Y)$.

Demonstração. Veja a demonstração desse resultado na Seção 3.8. ■

Por fim, como condicionar *duas vezes* em Y é o mesmo que condicionar uma única vez em Y, temos imediatamente o seguinte.

Teorema 3.5.5

Sejam X e Y variáveis aleatórias. Então $E\big(E(X \mid Y) \mid Y\big) = E(X \mid Y)$.

3.5.4 Variância Condicional (Avançado)

Além de definir a esperança condicional, podemos definir a variância condicional[34]. Como de costume, ela envolve a distância quadrática esperada de uma variável aleatória até a sua média. Neste caso, porém, a esperança é uma esperança condicional. Além disso, a média é uma média condicional.

Definição 3.5.6

Se X é uma variável aleatória e A é um evento com $P(A) > 0$, então a *variância condicional* de X, dado A, é igual a

$$\operatorname{Var}(X \mid A) = E\big((X - E(X \mid A))^2 \mid A\big) = E(X^2 \mid A) - \big(E(X \mid A)\big)^2.$$

De forma análoga, se Y é outra variável aleatória, então

$$\begin{aligned}\operatorname{Var}(X \mid Y = y) &= E\big((X - E(X \mid Y = y))^2 \mid Y = y\big) \\ &= E(X^2 \mid Y = y) - \big(E(X \mid Y = y)\big)^2,\end{aligned}$$

e

$$\operatorname{Var}(X \mid Y) = E\big((X - E(X \mid Y))^2 \mid Y\big) = E(X^2 \mid Y) - \big(E(X \mid Y)\big)^2.$$

No original: *conditional variance*[34].

Exemplo 3.5.8

Considere novamente o lançamento de um dado honesto de seis faces, de modo que $S = \{1, 2, 3, 4, 5, 6\}$, com $P(s) = 1/6$ e $X(s) = s$ para $s \in S$, e com $A = \{3, 5, 6\}$. Já calculamos que $P(X = s \mid A) = 1/3$ para $s \in A$ e que $E(X \mid A) = 14/3$. Logo,

$$\begin{aligned}
&\operatorname{Var}(X \mid A) = E\big((X - E(X \mid A))^2 \mid A\big) \\
&= E\Big((X - 14/3)^2 \,\Big|\, A\Big) = \sum_{s \in S} (s - 14/3)^2 \, P(X = s \mid A) \\
&= (3 - 14/3)^2(1/3) + (5 - 14/3)^2(1/3) + (6 - 14/3)^2(1/3) = 14/9 \doteq 1{,}56.
\end{aligned}$$

Em contraste, como $E(X) = 7/2$, temos

$$\operatorname{Var}(X) = E\Big(\big(X - E(X)\big)^2\Big) = \sum_{x=1}^{6} (x - 7/2)^2(1/6) = 35/12 \doteq 2{,}92.$$

Logo, vemos que a variância condicional $\operatorname{Var}(X \mid A)$ é bem menor que a variância incondicional $\operatorname{Var}(X)$. Isso indica que, neste exemplo, uma vez que sabemos que o evento A ocorreu, sabemos mais sobre o valor de X do que sabíamos originalmente. ■

Exemplo 3.5.9

Suponha que X e Y têm função densidade conjunta

$$f_{X,Y}(x, y) = \begin{cases} 8xy & 0 < x < y < 1 \\ 0 & \text{caso contrário.} \end{cases}$$

Temos $f_Y(y) = 4y^3$, $f_{X|Y}(x \mid y) = 8xy/4y^3 = 2x/y^2$ para $0 < x < y$, e assim

$$E(X \mid Y = y) = \int_0^y x \, \frac{2x}{y^2} \, dx = \int_0^y \frac{2x^2}{y^2} \, dx = \frac{2y^3}{3y^2} = \frac{2y}{3}.$$

Portanto,

$$\begin{aligned}
\operatorname{Var}(X \mid Y = y) &= E\Big(\big(X - E(X \mid Y = y)\big)^2 \,\Big|\, Y = y\Big) \\
&= \int_0^y \left(x - \frac{2y}{3}\right)^2 \frac{2x}{y^2} \, dx = \frac{1}{2y^2} - \frac{8}{9y} + \frac{4}{9}.
\end{aligned}$$

* ■

Por fim, observamos que a esperança condicional e a variância condicional satisfazem a seguinte identidade útil.

Teorema 3.5.6

Para variáveis aleatórias X e Y,

$$\operatorname{Var}(X) = \operatorname{Var}\big(E(X \mid Y)\big) + E\big(\operatorname{Var}(X \mid Y)\big).$$

Demonstração. Veja a demonstração desse resultado na Seção 3.8. ■

Resumo da Seção 3.5

- Se X é discreta, então a esperança condicional de X, dado um evento A, é igual a $E(X \mid A) = \sum_{x \in R^1} x\, P(X = x \mid A)$.
- Se X e Y são variáveis aleatórias discretas, então $E(X \mid Y)$ é ela própria uma variável aleatória, com $E(X \mid Y)$ igual a $E(X \mid Y = y)$ quando $Y = y$.
- Se X e Y são conjuntamente absolutamente contínuas, então $E(X \mid Y)$ é ela própria uma variável aleatória, com $E(X \mid Y)$ igual a $E(X \mid Y = y)$ quando $Y = y$, em que $E(X \mid Y = y) = \int x\, f_{X|Y}(x \mid y)\, dx$.
- A esperança condicional é linear.
- Sempre temos $E\big(g(Y)\, E(X \mid Y)\big) = E\big(g(Y)\, X\big)$ e $E\big(E(X \mid Y) \mid Y\big) = E(X \mid Y)$.
- A variância condicional é dada por $\operatorname{Var}(X \mid Y) = E(X^2 \mid Y) - \big(E(X \mid Y)\big)^2$.

Exercícios

3.5.1 Suponha que X e Y são discretas, com

$$p_{X,Y}(x,y) = \begin{cases} 1/5 & x = 2, y = 3 \\ 1/5 & x = 3, y = 2 \\ 1/5 & x = 3, y = 3 \\ 1/5 & x = 2, y = 2 \\ 1/5 & x = 3, y = 17 \\ 0 & \text{caso contrário.} \end{cases}$$

*Nota do tradutor. o original traz $\frac{1}{2y^2} - \frac{8}{9y} + \frac{4}{9}$; pela conta, a integral vale $y^2/18$

(a) Calcule $E(X \mid Y = 3)$.

(b) Calcule $E(Y \mid X = 3)$.

(c) Calcule $E(X \mid Y)$.

(d) Calcule $E(Y \mid X)$.

3.5.2 Suponha que X e Y são conjuntamente absolutamente contínuas, com

$$f_{X,Y}(x,y) = \begin{cases} 9(xy + x^5y^5)/16.000.900 & 0 \le x \le 4, 0 \le y \le 5 \\ 0 & \text{caso contrário.} \end{cases}$$

(a) Calcule $f_X(x)$.

(b) Calcule $f_Y(y)$.

(c) Calcule $E(X \mid Y)$.

(d) Calcule $E(Y \mid X)$.

(e) Calcule $E\big(E(X \mid Y)\big)$ e verifique que é igual a $E(X)$.

3.5.3 Suponha que X e Y são discretas, com

$$p_{X,Y}(x,y) = \begin{cases} 1/11 & x = -4, y = 2 \\ 2/11 & x = -4, y = 3 \\ 4/11 & x = -4, y = 7 \\ 1/11 & x = 6, y = 2 \\ 1/11 & x = 6, y = 3 \\ 1/11 & x = 6, y = 7 \\ 1/11 & x = 6, y = 13 \\ 0 & \text{caso contrário.} \end{cases}$$

(a) Calcule $E(Y \mid X = 6)$.

(b) Calcule $E(Y \mid X = -4)$.

(c) Calcule $E(Y \mid X)$.

3.5.4 Seja $p_{X,Y}$ como no exercício anterior.

(a) Calcule $E(X \mid Y = 2)$.

(b) Calcule $E(X \mid Y = 3)$.

(c) Calcule $E(X \mid Y = 7)$.

(d) Calcule $E(X \mid Y = 13)$.

(e) Calcule $E(X \mid Y)$.

3.5.5 Suponha que um estudante precisa escolher uma entre duas ofertas de emprego de verão. Se não for necessário fazer um curso de verão, então um emprego de garçom renderá ganhos (arredondados para o múltiplo de US$ 1.000 mais próximo) com a seguinte distribuição de probabilidade.

US$ 1.000	US$ 2.000	US$ 3.000	US$ 4.000
0,1	0,3	0,4	0,2

Se for necessário fazer um curso de verão, então um emprego de meio período num hotel renderá ganhos (arredondados para o múltiplo de US$ 1.000 mais próximo) com a seguinte distribuição de probabilidade.

US$ 1.000	US$ 2.000	US$ 3.000	US$ 4.000
0,3	0,4	0,2	0,1

Se a probabilidade de o estudante ter de fazer o curso de verão é 0,6, determine os ganhos esperados do estudante no verão.

3.5.6 Suponha que você lança dois dados honestos de seis faces. Seja X o número que aparece no primeiro dado, e seja Z a soma dos dois números que aparecem.

(a) Calcule $E(X)$.

(b) Calcule $E(Z \mid X = 1)$.

(c) Calcule $E(Z \mid X = 6)$.

(d) Calcule $E(X \mid Z = 2)$.

(e) Calcule $E(X \mid Z = 4)$.

(f) Calcule $E(X \mid Z = 6)$.

(g) Calcule $E(X \mid Z = 7)$.

(h) Calcule $E(X \mid Z = 11)$.

3.5.7 Suponha que você lança dois dados honestos de seis faces. Seja Z a soma dos dois números que aparecem, e seja W o produto dos dois números que aparecem.

(a) Calcule $E(Z \mid W = 4)$.

(b) Calcule $E(W \mid Z = 4)$.

3.5.8 Suponha que você lança um dado honesto de seis faces e depois lança tantas moedas quanto o número que aparece no dado. (Por exemplo, se o dado mostra 4, você lança quatro moedas.) Seja X o número que aparece no dado, e seja Y o número de caras obtidas.

(a) Calcule $E(Y \mid X = 5)$.

(b) Calcule $E(X \mid Y = 0)$.

(c) Calcule $E(X \mid Y = 2)$.

3.5.9 Suponha que você lança três moedas honestas. Seja X o número de caras obtidas, e seja $Y = 1$ se a primeira moeda dá cara; caso contrário, $Y = 0$.

(a) Calcule $E(X \mid Y = 0)$.

(b) Calcule $E(X \mid Y = 1)$.

(c) Calcule $E(Y \mid X = 0)$.

(d) Calcule $E(Y \mid X = 1)$.

(e) Calcule $E(Y \mid X = 2)$.

(f) Calcule $E(Y \mid X = 3)$.

(g) Calcule $E(Y \mid X)$.

(h) Verifique diretamente que $E[E(Y \mid X)] = E(Y)$.

3.5.10 Suponha que você lança uma moeda honesta e um dado honesto de seis faces. Seja X o número que aparece no dado, e seja $Y = 1$ se a moeda dá cara, com $Y = 0$ se a moeda dá coroa. Seja $Z = XY$.

(a) Calcule $E(Z)$.

(b) Calcule $E(Z \mid X = 4)$.

(c) Calcule $E(Y \mid X = 4)$.

(d) Calcule $E(Y \mid Z = 4)$.

(e) Calcule $E(X \mid Z = 4)$.

3.5.11 Suponha que X e Y são conjuntamente absolutamente contínuas, com função densidade conjunta $f_{X,Y}(x, y) = (6/19)(x^2 + y^3)$ para $0 < x < 2$ e $0 < y < 1$; caso contrário, $f_{X,Y}(x, y) = 0$.

(a) Calcule $E(X)$.

(b) Calcule $E(Y)$.

(c) Calcule $E(X \mid Y)$.

(d) Calcule $E(Y \mid X)$.

(e) Verifique diretamente que $E[E(X \mid Y)] = E(X)$.

(f) Verifique diretamente que $E[E(Y \mid X)] = E(Y)$.

Problemas

3.5.12 Suponha que há duas urnas. A urna nº 1 contém 100 fichas: 30 marcadas com 1, 40 marcadas com 2 e 30 marcadas com 3. A urna nº 2 contém 100 fichas: 20 marcadas com 1, 50 marcadas com 2 e 30 marcadas com 3. Uma moeda é lançada e, se sair cara, uma ficha é retirada ao acaso da urna nº 1; caso contrário, uma ficha é retirada ao acaso da urna nº 2. O valor Y da ficha é registrado. Se a ocorrência de cara na moeda é indicada por $X = 1$, a de coroa por $X = 0$, e $X \sim$ Bernoulli(3/4), determine $E(X \mid Y)$, $E(Y \mid X)$, $E(Y)$ e $E(X)$.

3.5.13 Suponha que cinco moedas são lançadas, cada uma até que se obtenha a primeira cara naquela moeda, e que cada moeda tem probabilidade θ de dar cara. Se você é informado de que o número total de coroas observadas é $Y = 10$, determine o número esperado de coroas observadas na primeira moeda.

3.5.14 *(Paradoxo de Simpson[35])* Suponha que as distribuições condicionais de Y, dado X, são as da tabela a seguir. Por exemplo, $p_{Y|X}(1 \mid i)$ poderia corresponder à probabilidade de que um paciente cardíaco escolhido ao acaso no hospital i tenha um tratamento bem-sucedido.

$p_{Y\|X}(0 \mid 1)$ 0,030	$p_{Y\|X}(1 \mid 1)$ 0,970
$p_{Y\|X}(0 \mid 2)$ 0,020	$p_{Y\|X}(1 \mid 2)$ 0,980

(a) Calcule $E(Y \mid X)$.

(b) Suponha agora que os pacientes são classificados também como em estado grave ($Z = 1$) ou não em estado grave ($Z = 0$). As distribuições condicionais de Y, dado (X, Z), são as das tabelas a seguir. Calcule $E(Y \mid X, Z)$.

$p_{Y\|X,Z}(0 \mid 1, 0)$ 0,010	$p_{Y\|X,Z}(1 \mid 1, 0)$ 0,990
$p_{Y\|X,Z}(0 \mid 2, 0)$ 0,013	$p_{Y\|X,Z}(1 \mid 2, 0)$ 0,987

No original: *Simpson's paradox*[35].

$p_{Y\|X,Z}(0 \mid 1,1)$ 0,038	$p_{Y\|X,Z}(1 \mid 1,1)$ 0,962
$p_{Y\|X,Z}(0 \mid 2,1)$ 0,040	$p_{Y\|X,Z}(1 \mid 2,1)$ 0,960

(c) Explique por que as distribuições condicionais do item (a) indicam que o hospital 2 é o melhor hospital para um paciente que precisa passar por esse tratamento, mas todas as distribuições condicionais do item (b) indicam que o hospital 1 é o melhor hospital. Esse fenômeno é conhecido como paradoxo de Simpson.

(d) Prove que, em geral, $p_{Y|X}(y \mid x) = \sum_z p_{Y|X,Z}(y \mid x,z)\, p_{Z|X}(z \mid x)$ e $E(Y \mid X) = E\big(E(Y \mid X,Z) \mid X\big)$.

(e) Se as distribuições condicionais $p_{Z|X}(\cdot \mid x)$ correspondentes ao exemplo discutido nos itens (a) a (c) são as da tabela a seguir, verifique numericamente o resultado do item (d) e explique como isso resolve o paradoxo de Simpson.

$p_{Z\|X}(0 \mid 1)$ 0,286	$p_{Z\|X}(1 \mid 1)$ 0,714
$p_{Z\|X}(0 \mid 2)$ 0,750	$p_{Z\|X}(1 \mid 2)$ 0,250

3.5.15 Apresente um exemplo de uma variável aleatória X e de um evento A com $P(A) > 0$ tais que $\text{Var}(X \mid A) > \text{Var}(X)$. (Sugestão: suponha que $S = \{1,2,3\}$ com $X(s) = s$, e $A = \{1,3\}$.)

3.5.16 Suponha que X, dado $Y = y$, tem distribuição Gama(α, y) e que a distribuição marginal[36] de Y é dada por $1/Y \sim$ Exponencial(λ). Determine $E(X)$.

3.5.17 Suponha que $(X,Y) \sim$ Normal Bivariada$(\mu_1, \mu_2, \sigma_1, \sigma_2, \rho)$. Use (2.7.1) (quando dado $Y = y$) e sua análoga (quando dado $X = x$) para determinar $E(X \mid Y)$, $E(Y \mid X)$, $\text{Var}(X \mid Y)$ e $\text{Var}(Y \mid X)$.

3.5.18 Suponha que $(X_1, X_2, X_3) \sim$ Multinomial$(n, \theta_1, \theta_2, \theta_3)$. Determine $E(X_1 \mid X_2)$ e $\text{Var}(X_1 \mid X_2)$. (Sugestão: mostre que X_1, dado $X_2 = x_2$, tem distribuição binomial.)

3.5.19 Suponha que $(X_1, X_2) \sim$ Dirichlet$(\alpha_1, \alpha_2, \alpha_3)$. Determine $E(X_1 \mid X_2)$ e $\text{Var}(X_1 \mid X_2)$. (Sugestão: primeiro mostre que $X_1/(1 - x_2)$, dado $X_2 = x_2$, tem distribuição beta e depois use o Problema 3.3.24.)

No original: *marginal distribution*[36].

3.5.20 Seja $f_{X,Y}$ como no Exercício 3.5.2.

(a) Calcule $\text{Var}(X)$.

(b) Calcule $\text{Var}\big(E(X \mid Y)\big)$.

(c) Calcule $\text{Var}(X \mid Y)$.

(d) Verifique que $\text{Var}(X) = \text{Var}\big(E(X \mid Y)\big) + E\big(\text{Var}(X \mid Y)\big)$.

3.5.21 Suponha que temos três variáveis aleatórias discretas X, Y e Z. Dizemos que X e Y são *condicionalmente independentes*[37], dado Z, se

$$p_{X,Y|Z}(x, y \mid z) = p_{X|Z}(x \mid z)\, p_{Y|Z}(y \mid z)$$

para todos x, y e z tais que $P(Z = z) > 0$. Prove que, quando X e Y são condicionalmente independentes, dado Z, então

$$E\big(g(X)h(Y) \mid Z\big) = E\big(g(X) \mid Z\big)\, E\big(h(Y) \mid Z\big).$$

3.6 Desigualdades

A esperança e a variância estão intimamente relacionadas às distribuições das variáveis aleatórias. Essa relação nos permite provar certas desigualdades que costumam ser muito úteis. Começamos com um resultado clássico, a desigualdade de Markov[38], que é muito simples, mas também muito útil e poderosa.

Teorema 3.6.1 (Desigualdade de Markov)

Se X é uma variável aleatória não negativa, então, para todo $a > 0$,

$$P(X \geq a) \leq \frac{E(X)}{a}.$$

Isto é, a probabilidade de que X ultrapasse um valor dado qualquer a não é maior que a média de X dividida por a.

Demonstração. Defina uma nova variável aleatória Z por

$$Z = \begin{cases} a & X \geq a \\ 0 & X < a. \end{cases}$$

No original: *conditionally independent*[37], *Markov's*[38].

Então, evidentemente, $Z \leq X$, de modo que $E(Z) \leq E(X)$ pela monotonicidade. Por outro lado,

$$E(Z) = a\,P(Z = a) + 0\,P(Z = 0) = a\,P(Z = a) = a\,P(X \geq a).$$

Assim, $E(X) \geq E(Z) = a\,P(X \geq a)$. Reorganizando, $P(X \geq a) \leq E(X)/a$, como afirmado. ■

Intuitivamente, a desigualdade de Markov diz que, se o valor esperado de X é pequeno, então é improvável que X seja grande demais. Vejamos agora algumas aplicações do Teorema 3.6.1.

Exemplo 3.6.1

Suponha que $P(X = 3) = 1/2$, $P(X = 4) = 1/3$ e $P(X = 7) = 1/6$. Então $E(X) = 3(1/2) + 4(1/3) + 7(1/6) = 4$. Portanto, tomando $a = 6$, a desigualdade de Markov diz que $P(X \geq 6) \leq 4/6 = 2/3$. Na verdade, $P(X \geq 6) = 1/6 < 2/3$. ■

Exemplo 3.6.2

Suponha que $P(X = 2) = P(X = 8) = 1/2$. Então $E(X) = 2(1/2) + 8(1/2) = 5$. Portanto, tomando $a = 8$, a desigualdade de Markov diz que $P(X \geq 8) \leq 5/8$. Na verdade, $P(X \geq 8) = 1/2 < 5/8$. ■

Exemplo 3.6.3

Suponha que $P(X = 0) = P(X = 2) = 1/2$. Então $E(X) = 0(1/2) + 2(1/2) = 1$. Portanto, tomando $a = 2$, a desigualdade de Markov diz que $P(X \geq 2) \leq 1/2$. Na verdade, $P(X \geq 2) = 1/2$, de modo que a desigualdade de Markov é uma *igualdade* neste caso. ■

A desigualdade de Markov também é usada para provar a desigualdade de Chebychev[39], talvez a desigualdade mais importante de toda a teoria da probabilidade.

No original: *Chebychev's*[39].

Teorema 3.6.2 (Desigualdade de Chebychev)

Seja Y uma variável aleatória qualquer, com média finita μ_Y. Então, para todo $a > 0$,

$$P(|Y - \mu_Y| \geq a) \leq \frac{\text{Var}(Y)}{a^2}.$$

Demonstração. Tome $X = (Y - \mu_Y)^2$. Então X é uma variável aleatória não negativa. Assim, usando o Teorema 3.6.1, temos $P(|Y - \mu_Y| \geq a) = P\left(X \geq a^2\right) \leq E(X)/a^2 = \text{Var}(Y)/a^2$, e isso estabelece o resultado. ■

Intuitivamente, a desigualdade de Chebychev diz que, se a variância de Y é pequena, então é improvável que Y fique longe demais de seu valor médio μ_Y. Vejamos agora alguns exemplos.

Exemplo 3.6.4

Suponha de novo que $P(X = 3) = 1/2$, $P(X = 4) = 1/3$ e $P(X = 7) = 1/6$. Então $E(X) = 4$, como acima. Além disso, $E(X^2) = 9(1/2) + 16(1/3) + 49(1/6) = 18$, de modo que $\text{Var}(X) = 18 - 4^2 = 2$. Portanto, tomando $a = 1$, a desigualdade de Chebychev diz que $P(|X - 4| \geq 1) \leq 2/1^2 = 2$, o que não nos diz nada, porque sempre temos $P(|X - 4| \geq 1) \leq 1$. Por outro lado, tomando $a = 3$, obtemos $P(|X - 4| \geq 3) \leq 2/3^2 = 2/9$, o que é verdade, pois, de fato, $P(|X - 4| \geq 3) = P(X = 7) = 1/6 < 2/9$. ■

Exemplo 3.6.5

Sejam $X \sim \text{Exponencial}(3)$ e $a = 5$. Então $E(X) = 1/3$ e $\text{Var}(X) = 1/9$. Portanto, pela desigualdade de Chebychev com $a = 1/2$, $P(|X - 1/3| \geq 1/2) \leq (1/9)/(1/2)^2 = 4/9$. Por outro lado, como $X \geq 0$, $P(|X - 1/3| \geq 1/2) = P(X \geq 5/6)$ e, pela desigualdade de Markov, $P(X \geq 5/6) \leq (1/3)/(5/6) = 2/5$. Como $2/5 < 4/9$, neste caso obtemos, na verdade, uma cota melhor pela desigualdade de Markov do que pela desigualdade de Chebychev. ■

Exemplo 3.6.6

Sejam $Z \sim N(0, 1)$ e $a = 5$. Então, pela desigualdade de Chebychev, $P(|Z| \geq 5) \leq 1/5$. ■

Exemplo 3.6.7

Seja X uma variável aleatória com variância *muito pequena*. Então a desigualdade de Chebychev diz que $P(|X - \mu_X| \geq a)$ é pequena sempre que a não for pequeno demais. Em outras palavras, em geral $|X - \mu_X|$ é muito pequeno, isto é, $X \approx \mu_X$. Isso faz sentido, porque, se a variância de X é muito pequena, então em geral X fica muito perto de seu valor médio μ_X. ■

As desigualdades também são úteis para covariâncias, como segue.

Teorema 3.6.3 (Desigualdade de Cauchy–Schwartz)

Sejam X e Y variáveis aleatórias quaisquer, cada uma com variância finita e não nula. Então

$$|\mathrm{Cov}(X, Y)| \leq \sqrt{\mathrm{Var}(X)\,\mathrm{Var}(Y)}.$$

Além disso, se $\mathrm{Var}(Y) > 0$, então a igualdade vale se e somente se $X - \mu_X = \lambda(Y - \mu_Y)$, em que $\lambda = \mathrm{Cov}(X, Y)/\,\mathrm{Var}(Y)$.

Demonstração. Veja a Seção 3.8 para a demonstração. ■

A desigualdade de Cauchy–Schwartz[40] diz que, se a variância de X ou de Y é pequena, então a covariância de X e Y também tem de ser pequena.

Exemplo 3.6.8

Suponha que $X = C$ seja uma constante. Então $\mathrm{Var}(X) = 0$. Segue da desigualdade de Cauchy–Schwartz que, para *qualquer* variável aleatória Y, temos de ter $\mathrm{Cov}(X, Y) \leq (\mathrm{Var}(X)\,\mathrm{Var}(Y))^{1/2} = (0\,\mathrm{Var}(Y))^{1/2} = 0$, de modo que $\mathrm{Cov}(X, Y) = 0$. ■

Lembrando que a *correlação* de X e Y é definida por

$$\mathrm{Corr}(X, Y) = \frac{\mathrm{Cov}(X, Y)}{\sqrt{\mathrm{Var}(X)\,\mathrm{Var}(Y)}},$$

obtemos imediatamente o seguinte resultado importante (ao qual já nos referimos quando a correlação foi introduzida).

No original: *Cauchy–Schwartz inequality*[40].

Corolário 3.6.1

Sejam X e Y variáveis aleatórias quaisquer, com médias finitas e variâncias finitas e não nulas. Então $|\text{Corr}(X, Y)| \leq 1$. Além disso, $|\text{Corr}(X, Y)| = 1$ se e somente se

$$X - \mu_X = \frac{\text{Cov}(X, Y)}{\text{Var}(Y)}(Y - \mu_Y).$$

Assim, a correlação entre duas variáveis aleatórias está sempre entre -1 e 1. Vemos também que X e Y são linearmente relacionadas se e somente se $|\text{Corr}(X, Y)| = 1$, e que essa relação é crescente (inclinação positiva) quando $\text{Corr}(X, Y) = 1$ e decrescente (inclinação negativa) quando $\text{Corr}(X, Y) = -1$.

3.6.1 Desigualdade de Jensen (Avançado)

Por fim, desenvolvemos uma desigualdade mais avançada, que às vezes é muito útil. Uma função f é chamada *convexa* se, para todo $x < y$, o segmento de reta de $(x, f(x))$ a $(y, f(y))$ fica inteiramente *acima* do gráfico de f, como mostra a Figura 3.6.1.

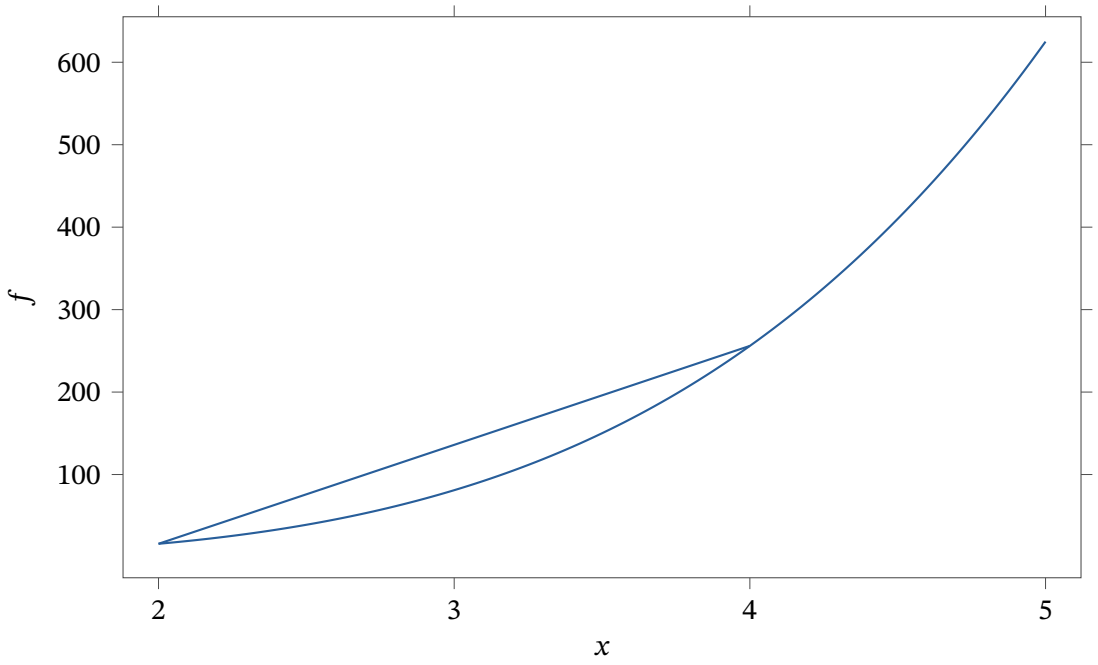


Figura 3.6.1: Gráfico da função convexa $f(x) = x^4$ e do segmento de reta que liga $(2, f(2))$ a $(4, f(4))$.

Em símbolos, exigimos que, para todo $x < y$ e todo $0 < \lambda < 1$, se tenha $\lambda f(x) + (1 - \lambda)f(y) \geq f(\lambda x + (1 - \lambda)y)$. Exemplos de funções convexas incluem

$f(x) = x^2$, $f(x) = x^4$ e $f(x) = \max(x, C)$ para qualquer número real C. Temos o seguinte resultado.

Teorema 3.6.4 (Desigualdade de Jensen)

Seja X uma variável aleatória qualquer e seja $f : R^1 \to R^1$ uma função convexa tal que $E(f(X))$ seja finita. Então $f(E(X)) \leq E(f(X))$. A igualdade ocorre se e somente se $f(X) = a + bX$ para certos a e b.

Demonstração. Como f é convexa, podemos encontrar uma função linear $g(x) = ax + b$ tal que $g(E(X)) = f(E(X))$ e $g(x) \leq f(x)$ para todo $x \in R^1$ (veja, por exemplo, a Figura 3.6.2).

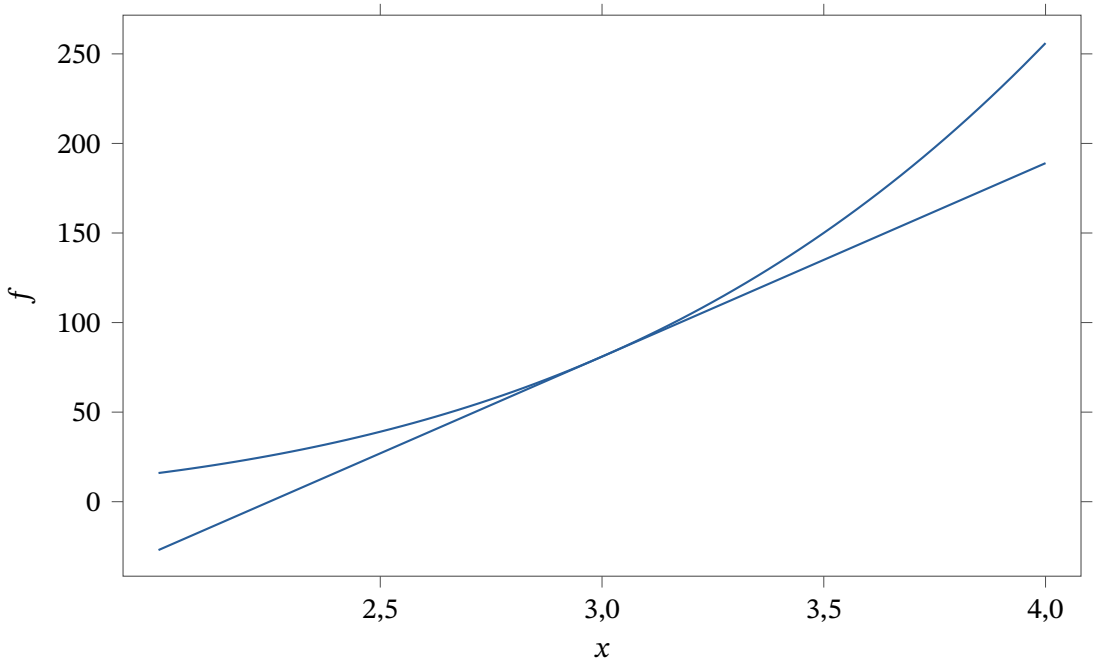


Figura 3.6.2: Gráfico da função convexa $f(x) = x^4$ e da função $g(x) = 81 + 108(x - 3)$, que satisfaz $g(x) \leq f(x)$ no intervalo $(2, 4)$.

Mas então, usando a monotonicidade e a linearidade, temos $E(f(X)) \geq E(g(X)) = E(aX + b) = aE(X) + b = g(E(X)) = f(E(X))$, como afirmado.

Temos igualdade se e somente se $0 = E(f(X) - g(X))$. Como $f(X) - g(X) \geq 0$, isso ocorre (usando o Desafio 3.3.29) se e somente se $f(X) = g(X) = aX + b$ com probabilidade 1. ■

Exemplo 3.6.9

Seja X uma variável aleatória com variância finita. Então, tomando $f(x) = x^2$, a desigualdade de Jensen diz que $E(X^2) \geq (E(X))^2$. É claro que já sabíamos disso, porque $E(X^2) - (E(X))^2 = \text{Var}(X) \geq 0$. ■

Exemplo 3.6.10

Seja X uma variável aleatória com quarto momento finito. Então, tomando $f(x) = x^4$, a desigualdade de Jensen diz que $E(X^4) \geq (E(X))^4$. ■

Exemplo 3.6.11

Seja X uma variável aleatória com média finita e seja $M \in R^1$. Então, tomando $f(x) = \max(x, M)$, temos que $E(\max(X, M)) \geq \max(E(X), M)$ pela desigualdade de Jensen. Na verdade, também poderíamos ter deduzido isso da propriedade de monotonicidade da esperança, usando as duas desigualdades $\max(X, M) \geq X$ e $\max(X, M) \geq M$. ■

Resumo da Seção 3.6

- Para X não negativa, a desigualdade de Markov diz que $P(X \geq a) \leq E(X)/a$.
- A desigualdade de Chebychev diz que $P(|Y - \mu_Y| \geq a) \leq \text{Var}(Y)/a^2$.
- A desigualdade de Cauchy–Schwartz diz que $|\text{Cov}(X, Y)| \leq (\text{Var}(X)\,\text{Var}(Y))^{1/2}$, de modo que $|\text{Corr}(X, Y)| \leq 1$.
- A desigualdade de Jensen diz que $f(E(X)) \leq E(f(X))$ sempre que f é *convexa*.

Exercícios

3.6.1 Seja $Z \sim \text{Poisson}(3)$. Use a desigualdade de Markov para obter uma cota superior[41] para $P(Z \geq 7)$.

3.6.2 Seja $X \sim \text{Exponencial}(5)$. Use a desigualdade de Markov para obter uma cota superior para $P(X \geq 3)$ e compare-a com o valor exato.

No original: *upper bound*[41].

3.6.3 Seja $X \sim$ Geométrica$(1/2)$.

(a) Use a desigualdade de Markov para obter uma cota superior para $P(X \geq 9)$.

(b) Use a desigualdade de Markov para obter uma cota superior para $P(X \geq 2)$.

(c) Use a desigualdade de Chebychev para obter uma cota superior para $P(|X - 1| \geq 1)$.

(d) Compare as respostas obtidas nas partes (b) e (c).

3.6.4 Seja $Z \sim N(5, 9)$. Use a desigualdade de Chebychev para obter uma cota superior para $P(|Z - 5| \geq 30)$.

3.6.5 Seja $W \sim$ Binomial$(100, 1/2)$, como o número de caras ao lançar 100 moedas honestas. Use a desigualdade de Chebychev para obter uma cota superior para $P(|W - 50| \geq 10)$.

3.6.6 Sejam $Y \sim N(0, 100)$ e $Z \sim$ Binomial$(80, 1/4)$. Determine (com justificativa) o maior e o menor valor possível de $\text{Cov}(Y, Z)$.

3.6.7 Seja $X \sim$ Geométrica$(1/11)$. Use a desigualdade de Jensen[42] para determinar uma cota inferior[43] para $E(X^4)$, de duas maneiras diferentes.

(a) Aplique a desigualdade de Jensen a X com $f(x) = x^4$.

(b) Aplique a desigualdade de Jensen a X^2 com $f(x) = x^2$.

3.6.8 Seja X o número mostrado em um dado honesto de seis faces. Que cota a desigualdade de Chebychev dá para $P(X \geq 5 \text{ ou } X \leq 2)$?

3.6.9 Suponha que você lance quatro moedas honestas. Seja Y o número de caras obtidas.

(a) Que cota a desigualdade de Chebychev dá para $P(Y \geq 3 \text{ ou } Y \leq 1)$?

(b) Que cota a desigualdade de Chebychev dá para $P(Y \geq 4 \text{ ou } Y \leq 0)$?

3.6.10 Suponha que W tenha função densidade $f(w) = 3w^2$ para $0 < w < 1$ e $f(w) = 0$ caso contrário.

(a) Calcule $E(W)$.

(b) Que cota a desigualdade de Chebychev dá para $P(|W - E(W)| \geq 1/4)$?

No original: *Jensen's*[42], *lower bound*[43].

3.6.11 Suponha que Z tenha função densidade $f(z) = z^3/4$ para $0 < z < 2$ e $f(z) = 0$ caso contrário.

(a) Calcule $E(Z)$.

(b) Que cota a desigualdade de Chebychev dá para $P(|Z - E(Z)| \geq 1/2)$?

3.6.12 Suponha que $\text{Var}(X) = 4$ e $\text{Var}(Y) = 9$.

(a) Qual é o maior valor possível de $\text{Cov}(X, Y)$?

(b) Qual é o menor valor possível de $\text{Cov}(X, Y)$?

(c) Suponha que $Z = 3X/2$. Calcule $\text{Var}(Z)$ e $\text{Cov}(X, Z)$ e compare sua resposta com a da parte (a).

(d) Suponha que $W = -3X/2$. Calcule $\text{Var}(W)$ e $\text{Cov}(X, W)$ e compare sua resposta com a da parte (b).

3.6.13 Suponha que uma espécie de besouro tenha, em média, 35 milímetros de comprimento. Encontre uma cota superior para a probabilidade de que um besouro dessa espécie escolhido ao acaso tenha mais de 80 milímetros de comprimento.

Problemas

3.6.14 Prove que, para quaisquer $\epsilon > 0$ e $\delta > 0$, existe um inteiro positivo M tal que, se X é o número de caras ao lançar M moedas honestas, então $P(|(X/M) - (1/2)| \geq \delta) \leq \epsilon$.

3.6.15 Prove que, para quaisquer μ e $\sigma^2 > 0$, existem $a > 0$ e uma variável aleatória X com $E(X) = \mu$ e $\text{Var}(X) = \sigma^2$ tais que a desigualdade de Chebychev vale com igualdade, isto é, tais que $P(|X - \mu| \geq a) = \sigma^2/a^2$.

3.6.16 Suponha que (X, Y) seja uniforme no conjunto $\{(x_1, y_1), \ldots, (x_n, y_n)\}$, em que $x_1, \ldots, x_n$ são valores distintos e $y_1, \ldots, y_n$ são valores distintos.

(a) Prove que X é uniformemente distribuída em $x_1, \ldots, x_n$, com média dada por $\bar{x} = n^{-1} \sum_{i=1}^n x_i$ e variância dada por $\hat{s}_X^2 = n^{-1} \sum_{i=1}^n (x_i - \bar{x})^2$.

(b) Prove que o coeficiente de correlação entre X e Y é dado por

$$r_{XY} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} = \frac{\hat{s}_{XY}}{\hat{s}_X \hat{s}_Y},$$

em que $\hat{s}_{XY} = n^{-1}\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})$. O valor $\hat{s}_{XY}$ é chamado de *covariância amostral*[44] e r_{XY} é chamado de *coeficiente de correlação amostral*[45] quando os valores $(x_1, y_1), \ldots, (x_n, y_n)$ são uma amostra observada de alguma distribuição bivariada.

(c) Argumente que r_{XY} também é o coeficiente de correlação entre X e Y quando abandonamos a hipótese de que os x_i e os y_i são distintos.

(d) Prove que $-1 \leq r_{XY} \leq 1$ e enuncie as condições sob as quais $r_{XY} = \pm 1$.

3.6.17 Suponha que X seja uniformemente distribuída em $\{x_1, \ldots, x_n\}$ e, portanto, tenha média $\bar{x} = n^{-1}\sum_{i=1}^{n} x_i$ e variância $\hat{s}_X^2 = n^{-1}\sum_{i=1}^{n}(x_i - \bar{x})^2$ (veja o Problema 3.6.16(a)). Qual é a maior proporção dos valores x_i que pode ficar fora de $(\bar{x} - 2\hat{s}_X, \bar{x} + 2\hat{s}_X)$?

3.6.18 Suponha que X tenha distribuição com densidade dada por $f_X(x) = 2/x^3$ para $x > 1$ e 0 caso contrário.

(a) Prove que f_X é uma densidade.

(b) Calcule a média de X.

(c) Calcule $P(X \geq k)$ e compare com a cota superior para essa quantidade dada pela desigualdade de Markov.

(d) O que a desigualdade de Chebyshev diz neste caso?

3.6.19 Seja $g(x) = \max(-x, -10)$.

(a) Verifique que g é uma função convexa[46].

(b) Suponha que $Z \sim$ Exponencial(5). Use a desigualdade de Jensen para obter uma cota inferior para $E(g(Z))$.

3.6.20 Pode-se mostrar que uma função f, com segunda derivada contínua, é convexa em (a, b) se $f''(x) > 0$ para todo $x \in (a, b)$.

(a) Use o fato acima para mostrar que $f(x) = x^p$ é convexa em $(0, \infty)$ sempre que $p \geq 1$.

(b) Use a parte (a) para provar que $(E(|X|^p))^{1/p} \geq |E(X)|$ sempre que $p \geq 1$.

(c) Prove que $\text{Var}(X) = 0$ se e somente se X é degenerada em uma constante c.

No original: *sample covariance*[44], *sample correlation coefficient*[45], *convex function*[46].

Desafios

3.6.21 Determine (com demonstração) todas as funções que são convexas e cujas *opostas* também são convexas. (Isto é, encontre todas as funções f tais que f é convexa e $-f$ também é convexa.)

3.7 Esperanças Gerais (Avançado)

Até aqui, consideramos valores esperados separadamente, apenas para variáveis aleatórias discretas e absolutamente contínuas. No entanto, essa separação em dois "casos" diferentes pode parecer artificial. Além disso, sabemos que algumas variáveis aleatórias não são nem discretas nem contínuas — por exemplo, misturas de distribuições discretas e contínuas.

Por isso, parece desejável ter uma definição mais geral de valor esperado. Essa generalidade costuma ser tratada no contexto da teoria da medida[47] geral, um assunto matemático avançado. No entanto, também é possível dar uma definição geral em termos elementares, como segue.

Definição 3.7.1

Seja X uma variável aleatória qualquer (talvez nem discreta nem contínua). Então o *valor esperado* de X é dado por

$$E(X) = \int_0^\infty P(X > t)\,dt - \int_{-\infty}^0 P(X < t)\,dt,$$

desde que $\int_0^\infty P(X > t)\,dt < \infty$ ou $\int_{-\infty}^0 P(X < t)\,dt < \infty$.

Essa definição parece contradizer as nossas definições anteriores de $E(X)$. Na verdade, porém, não há contradição, como mostra o teorema a seguir.

No original: *measure theory*[47].

Teorema 3.7.1

(a) Seja X uma variável aleatória discreta com valores possíveis distintos $x_1, x_2, \ldots$, e tome $p_i = P(X = x_i)$. Então a Definição 3.7.1 coincide com a definição anterior de $E(X)$. Isto é,

$$\int_0^\infty P(X > t)\,dt - \int_{-\infty}^0 P(X < t)\,dt = \sum_i x_i\, p_i.$$

(b) Seja X uma variável aleatória absolutamente contínua com densidade f_X. Então a Definição 3.7.1 coincide com a definição anterior de $E(X)$. Isto é,

$$\int_0^\infty P(X > t)\,dt - \int_{-\infty}^0 P(X < t)\,dt = \int_{-\infty}^\infty x\, f_X(x)\,dx.$$

Demonstração. O ponto-chave da demonstração é trocar a ordem da integração/soma.

(a) Temos

$$\int_0^\infty P(X > t)\,dt = \int_0^\infty \sum_{i,\, x_i > t} p_i\,dt = \sum_i p_i \int_0^{x_i} dt = \sum_i p_i\, x_i,$$

como afirmado.

(b) Temos

$$\begin{aligned}\int_0^\infty P(X > t)\,dt &= \int_0^\infty \left(\int_t^\infty f_X(x)\,dx\right) dt = \int_0^\infty \left(\int_0^x f_X(x)\,dt\right) dx \\ &= \int_0^\infty x\, f_X(x)\,dx.\end{aligned}$$

Analogamente,

$$\begin{aligned}\int_{-\infty}^0 P(X < t)\,dt &= \int_{-\infty}^0 \left(\int_{-\infty}^t f_X(x)\,dx\right) dt = \int_{-\infty}^0 \left(\int_x^0 f_X(x)\,dt\right) dx \\ &= \int_{-\infty}^0 (-x)\, f_X(x)\,dx.\end{aligned}$$

Logo,

$$\begin{aligned}\int_0^\infty P(X > t)\,dt - \int_{-\infty}^0 P(X < t)\,dt &= \int_0^\infty x\, f_X(x)\,dx - \int_{-\infty}^0 (-x)\, f_X(x)\,dx \\ &= \int_{-\infty}^\infty x\, f_X(x)\,dx,\end{aligned}$$

como afirmado. ■

Em outras palavras, o Teorema 3.7.1 diz que a Definição 3.7.1 inclui as nossas definições anteriores de valor esperado, tanto para variáveis aleatórias discretas quanto para absolutamente contínuas, e ao mesmo tempo funciona para *qualquer* variável aleatória. (Observe que, para aplicar a Definição 3.7.1, tomamos uma *integral*, e não uma *soma*, seja X discreta ou contínua!)

Além disso, a Definição 3.7.1 preserva as propriedades fundamentais do valor esperado, como mostra o teorema a seguir. (Omitimos a demonstração aqui, mas veja o Desafio 3.7.10 para uma demonstração da parte (c).)

Teorema 3.7.2

Sejam X e Y variáveis aleatórias quaisquer, talvez nem discretas nem contínuas, com valores esperados definidos pela Definição 3.7.1.

(a) (*Linearidade*) Se a e b são números reais quaisquer, então $E(aX + bY) = a\,E(X) + b\,E(Y)$.

(b) Se X e Y são independentes, então $E(XY) = E(X)\,E(Y)$.

(c) (*Monotonicidade*) Se $X \leq Y$, então $E(X) \leq E(Y)$.

A Definição 3.7.1 também nos diz algo sobre valores esperados de distribuições de mistura, como segue.

Teorema 3.7.3

Para $1 \leq i \leq k$, seja Y_i uma variável aleatória com fda F_i. Seja X uma variável aleatória cuja fda corresponde a uma mistura finita (como na Seção 2.5.4) das fdas das Y_i, de modo que $F_X(x) = \sum_i p_i F_i(x)$, em que $p_i \geq 0$ e $\sum_i p_i = 1$. Então $E(X) = \sum_i p_i E(Y_i)$.

Demonstração. Calculamos que

$$\begin{aligned} P(X > t) &= 1 - F_X(t) = 1 - \sum_i p_i F_i(t) \\ &= \sum_i p_i (1 - F_i(t)) = \sum_i p_i P(Y_i > t). \end{aligned}$$

Analogamente,

$$P(X < t) = F_X(t^-) = \sum_i p_i F_i(t^-) = \sum_i p_i P(Y_i < t).$$

Logo, pela Definição 3.7.1,

$$\begin{aligned} E(X) &= \int_0^\infty P(X > t)\,dt - \int_{-\infty}^0 P(X < t)\,dt \\ &= \int_0^\infty \sum_i p_i P(Y_i > t)\,dt - \int_{-\infty}^0 \sum_i p_i P(Y_i < t)\,dt \\ &= \sum_i p_i \left(\int_0^\infty P(Y_i > t)\,dt - \int_{-\infty}^0 P(Y_i < t)\,dt \right) \\ &= \sum_i p_i E(Y_i), \end{aligned}$$

como afirmado. ■

Resumo da Seção 3.7

- Para variáveis aleatórias gerais, podemos definir um valor esperado geral por $E(X) = \int_0^\infty P(X > t)\,dt - \int_{-\infty}^0 P(X < t)\,dt$.
- Essa definição coincide com a anterior para variáveis aleatórias discretas ou absolutamente contínuas.
- A esperança geral continua linear e monótona.

Exercícios

3.7.1 Sejam X_1, X_2 e Y como no Exemplo 2.5.6, de modo que Y é uma mistura de X_1 e X_2. Calcule $E(X_1)$, $E(X_2)$ e $E(Y)$.

3.7.2 Suponha que lançamos um dado honesto de seis faces. Se sair 1, lançamos o mesmo dado de novo e tomamos X como o valor obtido. Se sair qualquer coisa diferente de 1, lançamos em vez disso um dado honesto de oito faces (com as faces numeradas de 1 a 8) e tomamos X como o valor obtido no dado de oito faces. Calcule o valor esperado de X.

3.7.3 Seja X uma variável aleatória constante positiva, de modo que $X = C$ para alguma constante $C > 0$. Prove diretamente a partir da Definição 3.7.1 que $E(X) = C$.

3.7.4 Seja Z uma variável aleatória geral (talvez nem discreta nem contínua) e suponha que $P(Z \leq 100) = 1$. Prove diretamente a partir da Definição 3.7.1 que $E(Z) \leq 100$.

3.7.5 Suponha que só nos digam que $P(X > x) = 1/x^2$ para $x \geq 1$ e $P(X > x) = 1$ para $x < 1$, mas não nos digam se X é discreta, contínua ou nenhuma das duas. Calcule $E(X)$.

3.7.6 Suponha que $P(Z > z) = 1$ para $z \leq 5$, $P(Z > z) = (8 - z)/3$ para $5 < z < 8$ e $P(Z > z) = 0$ para $z \geq 8$. Calcule $E(Z)$.

3.7.7 Suponha que $P(W > w) = e^{-5w}$ para $w \geq 0$ e $P(W > w) = 1$ para $w < 0$. Calcule $E(W)$.

3.7.8 Suponha que $P(Y > y) = e^{-y^2/2}$ para $y \geq 0$ e $P(Y > y) = 1$ para $y < 0$. Calcule $E(Y)$. (Sugestão: a densidade de uma normal padrão pode ajudar a resolver a integral.)

3.7.9 Suponha que a fda de W seja dada por $F_W(w) = 0$ para $w < 10$, $F_W(w) = w - 10$ para $10 \leq w \leq 11$ e $F_W(w) = 1$ para $w > 11$. Calcule $E(W)$. (Sugestão: lembre que $F_W(w) = P(W \leq w) = 1 - P(W > w)$.)

Desafios

3.7.10 Prove a parte (c) do Teorema 3.7.2. (Sugestão: se $X \leq Y$, como o evento $\{X > t\}$ se compara com o evento $\{Y > t\}$? Logo, como $P(X > t)$ se compara com $P(Y > t)$? E quanto a $\{X < t\}$ e $\{Y < t\}$?)

3.8 Demonstrações Adicionais (Avançado)

Demonstração do Teorema 3.4.7

Queremos provar que, se S tem uma distribuição composta como em (3.4.2), então (a) $E(S) = E(X_1)\,E(N)$ e (b) $m_S(s) = r_N(m_{X_1}(s))$.

Como as $\{X_i\}$ são i.i.d., temos $E(X_i) = E(X_1)$ para todo i. Defina I_i por $I_i = I_{\{1,\ldots,N\}}(i)$. Então podemos escrever $S = \sum_{i=1}^{\infty} X_i I_i$. Observe também que $\sum_{i=1}^{\infty} I_i = N$.

Como N é independente de X_i, I_i também é, e temos

$$\begin{aligned} E(S) &= E\left(\sum_{i=1}^{\infty} X_i I_i\right) = \sum_{i=1}^{\infty} E(X_i I_i) \\ &= \sum_{i=1}^{\infty} E(X_i)\,E(I_i) = \sum_{i=1}^{\infty} E(X_1)\,E(I_i) \\ &= E(X_1)\sum_{i=1}^{\infty} E(I_i) = E(X_1)\,E\left(\sum_{i=1}^{\infty} I_i\right) \\ &= E(X_1)\,E(N). \end{aligned}$$

Isso prova a parte (a).

Agora, usando uma versão para esperanças da lei da probabilidade total[48] (ver Teorema 3.5.3) e lembrando que $E\big(\exp\big(\sum_{i=1}^{n} sX_i\big)\big) = m_{X_1}(s)^n$, porque as $\{X_i\}$ são i.i.d., calculamos que

$$\begin{aligned} &m_S(s) \\ &= E\left(\exp\left(\sum_{i=1}^{n} sX_i\right)\right) = \sum_{n=0}^{\infty} P(N=n)\,E\left(\exp\left(\sum_{i=1}^{n} sX_i\right) \,\middle|\, N=n\right) \\ &= \sum_{n=0}^{\infty} P(N=n)\,E\left(\exp\left(\sum_{i=1}^{n} sX_i\right)\right) = \sum_{n=0}^{\infty} P(N=n)\,m_{X_1}(s)^n \\ &= E\big(m_{X_1}(s)^N\big) = r_N(m_{X_1}(s)), \end{aligned}$$

o que prova a parte (b).* ■

Demonstração do Teorema 3.5.3

Queremos mostrar que, quando X e Y são variáveis aleatórias e $g : R^1 \to R^1$ é uma função qualquer, então $E(g(Y)\,E(X \mid Y)) = E(g(Y)\,X)$.

*Nota do tradutor. na primeira linha da conta de $m_S(s)$, o original traz o limite superior n na soma dentro de exp; pela definição de S, seria N.

No original: *law of total probability*[48].

Se X e Y são discretas, então

$$\begin{aligned} E(g(Y)\,E(X \mid Y)) &= \sum_{y\in R^1} g(y)\,E(X \mid Y=y)\,P(Y=y) \\ &= \sum_{y\in R^1} g(y)\left(\sum_{x\in R^1} x\,P(X=x \mid Y=y)\right)P(Y=y) \\ &= \sum_{y\in R^1} g(y)\left(\sum_{x\in R^1} x\,\frac{P(X=x, Y=y)}{P(Y=y)}\right)P(Y=y) \\ &= \sum_{x\in R^1}\sum_{y\in R^1} g(y)\,x\,P(X=x, Y=y) = E(g(Y)X), \end{aligned}$$

como afirmado.

Analogamente, se X e Y são conjuntamente absolutamente contínuas, então

$$\begin{aligned} E(g(Y)\,E(X \mid Y)) &= \int_{-\infty}^{\infty} g(y)\,E(X \mid Y=y)\,f_Y(y)\,dy \\ &= \int_{-\infty}^{\infty} g(y)\left(\int_{-\infty}^{\infty} x\,f_{X|Y}(x \mid y)\,dx\right)f_Y(y)\,dy \\ &= \int_{-\infty}^{\infty} g(y)\left(\int_{-\infty}^{\infty} x\,\frac{f_{X,Y}(x,y)}{f_Y(y)}\,dx\right)f_Y(y)\,dy \\ &= \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} g(y)\,x\,f_{X,Y}(x,y)\,dx\,dy = E(g(Y)X), \end{aligned}$$

como afirmado. ■

Demonstração do Teorema 3.5.4

Queremos provar que, quando X e Y são variáveis aleatórias e $g : R^1 \to R^1$ é uma função qualquer, então $E(g(Y)X \mid Y) = g(Y)\,E(X \mid Y)$.

Para simplificar, supomos que X e Y são discretas; o caso conjuntamente absolutamente contínuo é análogo. Então, para qualquer y com $P(Y=y) > 0$,

$$\begin{aligned} E(g(Y)X \mid Y=y) &= \sum_{x\in R^1}\sum_{z\in R^1} g(z)\,x\,P(X=x, Y=z \mid Y=y) \\ &= \sum_{x\in R^1} g(y)\,x\,P(X=x \mid Y=y) \\ &= g(y)\sum_{x\in R^1} x\,P(X=x \mid Y=y) = g(y)\,E(X \mid Y=y). \end{aligned}$$

Como isso vale para qualquer y, devemos ter $E(g(Y)X \mid Y) = g(Y)\,E(X \mid Y)$, como afirmado. ■

Demonstração do Teorema 3.5.6

Precisamos mostrar que, para variáveis aleatórias X e Y, $\operatorname{Var}(X) = \operatorname{Var}(E(X \mid Y)) + E(\operatorname{Var}(X \mid Y))$.

Usando o Teorema 3.5.2, temos que

$$\operatorname{Var}(X) = E((X - \mu_X)^2) = E(E((X - \mu_X)^2 \mid Y)). \tag{3.8.1}$$

Agora,

$$\begin{aligned}(X - \mu_X)^2 &= (X - E(X \mid Y) + E(X \mid Y) - \mu_X)^2 \\ &= (X - E(X \mid Y))^2 + (E(X \mid Y) - \mu_X)^2 \\ &\quad + 2\,(X - E(X \mid Y))\,(E(X \mid Y) - \mu_X).\end{aligned} \tag{3.8.2}$$

Mas $E\big((X - E(X \mid Y))^2 \mid Y\big) = \operatorname{Var}(X \mid Y)$.

Além disso, usando de novo o Teorema 3.5.2,

$$E(E((E(X \mid Y) - \mu_X)^2 \mid Y)) = E((E(X \mid Y) - \mu_X)^2) = \operatorname{Var}(E(X \mid Y)).$$

Por fim, usando o Teorema 3.5.4 e a linearidade (Teorema 3.5.1), vemos que

$$\begin{aligned}&E((X - E(X \mid Y))\,(E(X \mid Y) - \mu_X) \mid Y) \\ &= (E(X \mid Y) - \mu_X)\,E(X - E(X \mid Y) \mid Y) \\ &= (E(X \mid Y) - \mu_X)\,(E(X \mid Y) - E(E(X \mid Y) \mid Y)) \\ &= (E(X \mid Y) - \mu_X)\,(E(X \mid Y) - E(X \mid Y)) = 0.\end{aligned}$$

De (3.8.1), (3.8.2) e da linearidade, temos que $\operatorname{Var}(X) = E(\operatorname{Var}(X \mid Y)) + \operatorname{Var}(E(X \mid Y)) + 0$, o que completa a demonstração. ■

Demonstração do Teorema 3.6.3 (Desigualdade de Cauchy–Schwartz)

Vamos provar que, sempre que X e Y são variáveis aleatórias quaisquer, cada uma com variância finita e não nula, então

$$|\operatorname{Cov}(X, Y)| \leq \sqrt{\operatorname{Var}(X)\operatorname{Var}(Y)}.$$

Além disso, se $\operatorname{Var}(Y) > 0$, então a igualdade vale se e somente se $X - \mu_X = \lambda(Y - \mu_Y)$, em que $\lambda = \operatorname{Cov}(X, Y)/\operatorname{Var}(Y)$.

Se $\operatorname{Var}(Y) = 0$, então o Desafio 3.3.30 implica que $Y = \mu_Y$ com probabilidade 1 (porque $\operatorname{Var}(Y) = E((Y - \mu_Y)^2) \geq 0$). Isso implica que

$$\operatorname{Cov}(X, Y) = E((X - \mu_X)(\mu_Y - \mu_Y)) = 0 = \sqrt{\operatorname{Var}(X)\operatorname{Var}(Y)},$$

e a desigualdade de Cauchy–Schwartz vale.

Se $\operatorname{Var}(Y) \neq 0$, sejam $Z = X - \mu_X$ e $W = Y - \mu_Y$. Então, para qualquer número real λ, calculamos, usando a linearidade, que

$$\begin{aligned} E\big((Z - \lambda W)^2\big) &= E(Z^2) - 2\lambda E(ZW) + \lambda^2 E(W^2) \\ &= \operatorname{Var}(X) - 2\lambda \operatorname{Cov}(X, Y) + \lambda^2 \operatorname{Var}(Y) \\ &= a\lambda^2 + b\lambda + c, \end{aligned}$$

em que $a = \operatorname{Var}(Y) > 0$, $b = -2\operatorname{Cov}(X, Y)$ e $c = \operatorname{Var}(X)$. Por outro lado, claramente $E\big((Z - \lambda W)^2\big) \geq 0$ para todo λ. Logo, temos uma equação do segundo grau que é sempre não negativa e, portanto, tem no máximo uma raiz real.

Pela fórmula de Bhaskara[49], toda equação do segundo grau tem *duas* raízes reais desde que o discriminante seja $b^2 - 4ac > 0$. Como esse não é o caso aqui, devemos ter $b^2 - 4ac \leq 0$, isto é,

$$4\operatorname{Cov}(X, Y)^2 - 4\operatorname{Var}(Y)\operatorname{Var}(X) \leq 0.$$

Dividindo por 4, rearranjando e tirando raízes quadradas, vemos que

$$|\operatorname{Cov}(X, Y)| \leq (\operatorname{Var}(X)\operatorname{Var}(Y))^{1/2},$$

como afirmado.

Por fim, $|\operatorname{Cov}(X, Y)| = (\operatorname{Var}(X)\operatorname{Var}(Y))^{1/2}$ se e somente se $b^2 - 4ac = 0$, o que significa que a equação do segundo grau tem uma única raiz real. Assim, existe algum número real λ tal que $E((Z - \lambda W)^2) = 0$. Como $(Z - \lambda W)^2 \geq 0$, segue do Desafio 3.3.29 que isso acontece se e somente se $Z - \lambda W = 0$ com probabilidade 1, como afirmado. Quando é esse o caso,

$$\operatorname{Cov}(X, Y) = E(ZW) = E(\lambda W^2) = \lambda E(W^2) = \lambda \operatorname{Var}(Y)$$

e, portanto, $\lambda = \operatorname{Cov}(X, Y)/\operatorname{Var}(Y)$ quando $\operatorname{Var}(Y) \neq 0$. ■

No original: *quadratic formula*[49].

CAPÍTULO 4

Distribuições Amostrais e Limites

ESBOÇO DO CAPÍTULO

Seção 1 Distribuições Amostrais
Seção 2 Convergência em Probabilidade
Seção 3 Convergência com Probabilidade 1
Seção 4 Convergência em Distribuição
Seção 5 Aproximações de Monte Carlo
Seção 6 Teoria da Distribuição Normal
Seção 7 Demonstrações Adicionais (Avançado)

Em muitas aplicações da teoria da probabilidade, deparamo-nos com o seguinte problema. Suponha que $X_1, X_2, \ldots, X_n$ seja uma sequência independente e identicamente distribuída (i.i.d.), isto é, que $X_1, X_2, \ldots, X_n$ seja uma amostra de alguma distribuição, e que estejamos interessados na distribuição de uma nova variável aleatória[1] $Y = h(X_1, X_2, \ldots, X_n)$ para alguma função h. Em particular, podemos querer calcular a função de distribuição de Y, ou talvez sua média e sua variância[2]. A distribuição de Y às vezes é chamada de sua *distribuição amostral*[3], já que Y se baseia numa amostra de alguma distribuição subjacente.

Veremos que alguns dos métodos desenvolvidos nos capítulos anteriores são úteis para resolver problemas desse tipo, sobretudo quando é possível calcular uma solução exata, por exemplo, obter uma expressão exata para a função de probabilidade[4] ou para a função densidade[5] de Y. A Seção 4.6 contém vários resultados exatos sobre a distribuição de diversas funções de variáveis aleatórias normais. Eles têm aplicações importantes em estatística.

Muitas vezes, porém, é impossível obter resultados exatos, porque o problema é simplesmente complexo demais. Nesses casos, precisamos desenvolver uma aproximação para a distribuição de Y.

Em muitos problemas importantes, define-se uma versão de Y para cada tamanho de amostra n (por exemplo, uma média amostral ou uma variância amostral), de modo que podemos considerar uma sequência de variáveis

No original: *random variable*[1], *variance*[2], *sampling distribution*[3], *probability function*[4], *density function*[5].

aleatórias $Y_1, Y_2, \ldots$ etc. Isso nos leva a considerar a distribuição limite[6] de uma sequência desse tipo para que, quando n for grande, possamos aproximar a distribuição de Y_n pelo limite, que muitas vezes é bem mais simples. Essa abordagem leva a um resultado famoso, conhecido como teorema central do limite[7], discutido na Seção 4.4.

Às vezes não conseguimos desenvolver nem mesmo aproximações úteis para n grande, seja pela dificuldade do problema, seja porque n é simplesmente pequeno demais numa aplicação específica. Felizmente, porém, podemos então usar a abordagem de Monte Carlo, na qual o poder do computador entra em cena. Isso é discutido na Seção 4.5.

No Capítulo 5, veremos que, em aplicações estatísticas, em geral não sabemos muito sobre a distribuição subjacente dos X_i dos quais estamos amostrando. Coletamos então uma amostra e um valor, como Y, que servirá de estimativa[8] de uma característica da distribuição subjacente; por exemplo, a média amostral $\bar{X}$ servirá de estimativa da média da distribuição dos X_i. Queremos então saber o que acontece com essas estimativas à medida que n cresce. Se tivermos escolhido bem as estimativas, elas convergirão para as quantidades que estamos estimando à medida que n aumenta. Uma estimativa assim é chamada de *consistente*. Nas Seções 4.2 e 4.3, discutiremos os teoremas de consistência mais importantes, a saber, as leis fraca e forte dos grandes números.

4.1 Distribuições Amostrais

Consideremos um exemplo bem simples.

Exemplo 4.1.1

Suponha que obtemos uma amostra X_1, X_2 de tamanho $n = 2$ da distribuição discreta com função de probabilidade dada por

$$p_X(x) = \begin{cases} 1/2 & x = 1 \\ 1/4 & x = 2 \\ 1/4 & x = 3 \\ 0 & \text{caso contrário.} \end{cases}$$

No original: *limiting distribution*[6], *central limit theorem*[7], *estimate*[8].

Tomemos $Y_2 = (X_1X_2)^{1/2}$. Essa é a *média geométrica* dos valores da amostra (a média geométrica de n números positivos $x_1, \ldots, x_n$ é definida como $(x_1 \cdots x_n)^{1/n}$).

Para determinar a distribuição de Y_2, primeiro listamos os valores possíveis de Y_2, as amostras que dão origem a esses valores e suas probabilidades de ocorrência. Os valores dessas probabilidades especificam a distribuição amostral de Y. Temos a tabela a seguir.*

y	Amostra	$p_{Y_2}(y)$
1	$\{(1,1)\}$	$(1/2)(1/2) = 1/4$
$\sqrt{2}$	$\{(1,2),(2,1)\}$	$(1/2)(1/4) + (1/4)(1/2) = 1/4$
$\sqrt{3}$	$\{(1,3),(1,3)\}$	$(1/2)(1/4) + (1/4)(1/2) = 1/4$
2	$\{(2,2)\}$	$(1/4)(1/4) = 1/16$
$\sqrt{6}$	$\{(2,3),(3,2)\}$	$(1/4)(1/4) + (1/4)(1/4) = 1/8$
3	$\{(3,3)\}$	$(1/4)(1/4) = 1/16$

Suponha agora que temos, em vez disso, uma amostra $X_1, \ldots, X_{20}$ de tamanho $n = 20$ e queremos encontrar a distribuição de $Y_{20} = (X_1 \cdots X_{20})^{1/20}$. É claro que podemos proceder como acima, mas desta vez as contas são muito mais complicadas, já que agora há $3^{20} = 3.486.784.401$ amostras possíveis, contra as $3^2 = 9$ amostras usadas para montar a tabela anterior. Calcular $p_{Y_{20}}$ diretamente, como fizemos para p_{Y_2}, seria custoso, mesmo para um computador! Então, o que podemos fazer aqui?

Uma possibilidade é olhar para a distribuição de $Y_n = (X_1 \cdots X_n)^{1/n}$ quando n é grande e ver se conseguimos aproximá-la de alguma forma. Os resultados da Seção 4.4.1 mostram que

$$\ln Y_n = \frac{1}{n}\sum_{i=1}^{n} \ln X_i$$

tem distribuição aproximadamente normal quando n é grande. De fato, a distribuição normal que aproxima quando $n = 20$ acaba sendo uma distribuição $N(0{,}447940; 0{,}105167)$.† Traçamos o gráfico dessa densidade na Figura 4.1.1.

Outra abordagem é usar os métodos da Seção 2.10 para gerar N amostras de tamanho $n = 20$ a partir de p_X, calcular $\ln Y_{20}$ para cada uma (ln é uma transformação injetora, e transformamos para evitar os valores potencialmente grandes assumidos por Y_{20}) e então usar esses N valores para aproximar a distribuição de $\ln Y_{20}$. Por exemplo, na Figura 4.1.2 apresentamos o gráfico de um histograma de densidade (veja a Seção 5.4.3

para mais discussão sobre histogramas) de $N = 10^4$ valores de $\ln Y_{20}$ calculados a partir de $N = 10^4$ amostras de tamanho $n = 20$ geradas (com o computador) a partir de p_X. A área de cada retângulo corresponde à proporção de valores de $\ln Y_{20}$ que caíram no intervalo dado pela base do retângulo. Como veremos nas Seções 4.2, 4.3 e 4.4, essas áreas aproximam as probabilidades reais de $\ln Y_{20}$ cair nesses intervalos. Essas aproximações melhoram à medida que aumentamos N.

Repare na semelhança entre as formas das Figuras 4.1.1 e 4.1.2. A Figura 4.1.2, porém, não é simétrica em relação ao seu centro, pois é um pouco assimétrica. Isso é um indício de que a aproximação normal não é inteiramente adequada quando $n = 20$. ■

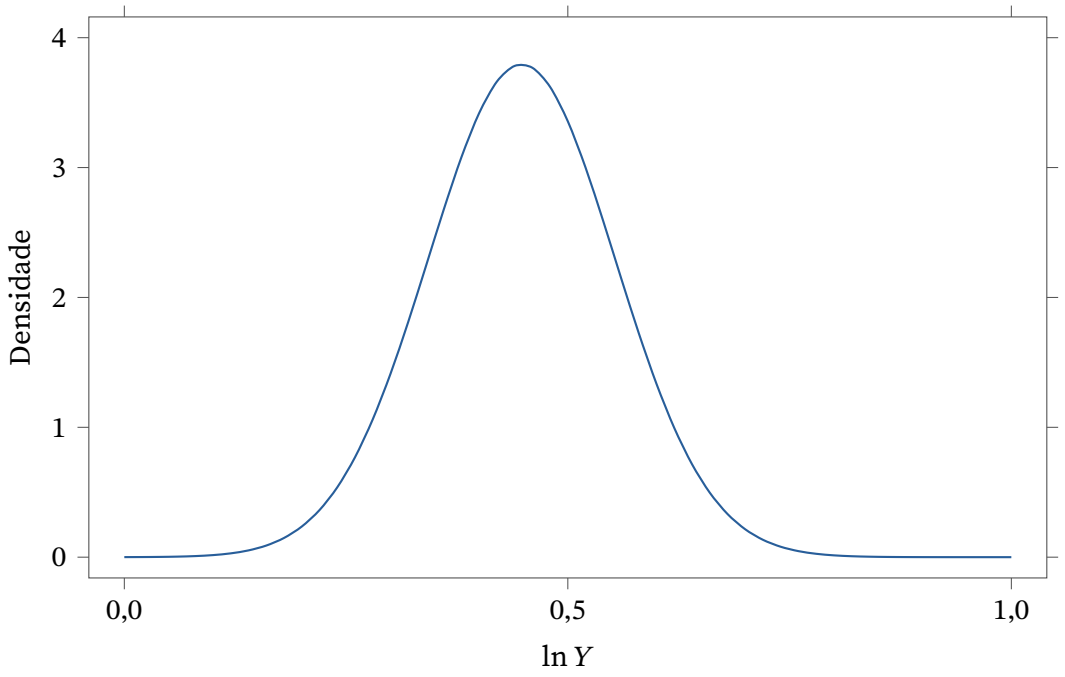


Figura 4.1.1: Gráfico da densidade $N(0{,}447940; 0{,}105167)$ que aproxima a distribuição de $\ln Y_{20}$ no Exemplo 4.1.1.

*Nota do tradutor. o original traz $\{(1,3),(1,3)\}$ na linha de $\sqrt{3}$; pela conta seria $\{(1,3),(3,1)\}$

†Nota do tradutor. na notação $N(\mu,\sigma^2)$ do livro, o segundo parâmetro deveria ser a variância, 0,011060, e 0,105167 é o desvio padrão de $\ln Y_{20}$, e é com ele que a Figura 4.1.1 foi desenhada

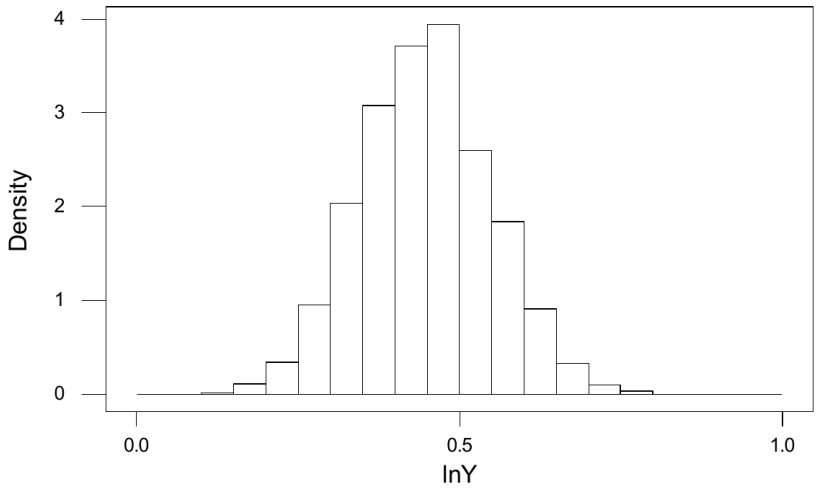


Figura 4.1.2: Gráfico de $N = 10^4$ valores de $\ln Y_{20}$ obtidos gerando $N = 10^4$ amostras a partir de p_X no Exemplo 4.1.1.

Às vezes temos sorte e conseguimos obter a distribuição amostral de

$$Y = h(X_1, X_2, \dots, X_n)$$

exatamente, numa forma útil para calcular probabilidades e esperanças de Y. Em geral, porém, quando queremos calcular $P(Y \in B) = P_Y(B)$, temos de determinar o conjunto de amostras $(X_1, X_2, \dots, X_n)$ tais que $Y \in B$, dado por

$$h^{-1}B = \{(x_1, x_2, \dots, x_n) \,:\, h(x_1, x_2, \dots, x_n) \in B\},$$

e então calcular $P((X_1, X_2, \dots, X_n) \in h^{-1}B)$. Em geral, esse é um problema intratável, e aproximações ou métodos de simulação (Monte Carlo) serão essenciais. Técnicas para obter essas aproximações serão discutidas nas seções seguintes deste capítulo. Em particular, desenvolveremos uma aproximação importante para a distribuição amostral da média amostral

$$\bar{X} = h(X_1, X_2, \dots, X_n) = \frac{1}{n}\sum_{i=1}^{n} X_i.$$

Resumo da Seção 4.1

- Uma distribuição amostral é a distribuição de uma variável aleatória correspondente a uma função de alguma sequência i.i.d.
- As distribuições amostrais às vezes podem ser obtidas por cálculo direto ou por aproximações, como o teorema central do limite.

Exercícios

4.1.1 Suponha que X_1, X_2, X_3 sejam i.i.d. com função de probabilidade p_X do Exemplo 4.1.1. Determine a distribuição exata de $Y_3 = (X_1 X_2 X_3)^{1/3}$.

4.1.2 Suponha que um dado honesto de seis faces seja lançado $n = 2$ vezes, de forma independente. Calcule a distribuição exata da média amostral.

4.1.3 Suponha que uma urna contenha uma proporção p de fichas marcadas com 0 e uma proporção $1 - p$ de fichas marcadas com 1. Para uma amostra de $n = 2$, retirada com reposição, determine a distribuição da média amostral.

4.1.4 Suponha que uma urna contenha N fichas marcadas com 0 e M fichas marcadas com 1. Para uma amostra de $n = 2$, retirada sem reposição, determine a distribuição da média amostral.

4.1.5 Suponha que um dado simétrico seja lançado $n = 20$ vezes, de forma independente. Obtenha a distribuição amostral exata do máximo dessa amostra.

4.1.6 Suponha que três dados honestos sejam lançados, e seja Y o número de faces 6 obtidas. Calcule a distribuição exata de Y.

4.1.7 Suponha que dois dados honestos sejam lançados, e seja W o *produto* dos dois números obtidos. Calcule a distribuição exata de W.

4.1.8 Suponha que dois dados honestos sejam lançados, e seja Z a *diferença* entre os dois números obtidos (isto é, o primeiro número *menos* o segundo). Calcule a distribuição exata de Z.

4.1.9 Suponha que quatro moedas honestas sejam lançadas, e seja Y o número de pares de moedas que caem do mesmo jeito (isto é, o número de pares em que as duas dão cara ou as duas dão coroa). Calcule a distribuição exata de Y.

Exercícios computacionais

4.1.10 Gere uma amostra de $N = 10^3$ valores de Y_{50} do Exemplo 4.1.1. Calcule a média e o desvio padrão[9] dessa amostra.

No original: *standard deviation*[9].

4.1.11 Suponha que $X_1, X_2, \ldots, X_{10}$ seja uma sequência i.i.d. de uma distribuição $N(0,1)$. Gere uma amostra de $N = 10^3$ valores da distribuição de $\max(X_1, X_2, \ldots, X_{10})$. Calcule a média e o desvio padrão[10] dessa amostra.

Problemas

4.1.12 Suponha que $X_1, X_2, \ldots, X_n$ seja uma amostra da distribuição Poisson(λ). Determine a distribuição amostral exata de $Y = X_1 + X_2 + \cdots + X_n$. (Sugestão: determine a função geradora de momentos[11] de Y e use o teorema da unicidade[12].)

4.1.13 Suponha que X_1, X_2 seja uma amostra da distribuição Uniforme[13]$[0,1]$. Determine a distribuição amostral exata de $Y = X_1 + X_2$. (Sugestão: determine a densidade de Y.)

4.1.14 Suponha que X_1, X_2 seja uma amostra da distribuição Uniforme$[0,1]$. Determine a distribuição amostral exata de $Y = (X_1 X_2)^{1/2}$. (Sugestão: determine a densidade de $\ln Y$ e depois transforme.)

4.2 Convergência em Probabilidade

Noções de *convergência* são fundamentais em boa parte da matemática. Por exemplo, se $a_n = 1 - 1/n$, então $a_1 = 0$, $a_2 = 1/2$, $a_3 = 2/3$, $a_4 = 3/4$ etc. Vemos que os valores de a_n estão ficando "cada vez mais próximos" de 1 e, de fato, sabemos do cálculo que $\lim_{n\to\infty} a_n = 1$ neste caso.

Para variáveis aleatórias, as noções de convergência são mais complicadas. Se os próprios valores são aleatórios, como podem "convergir" para alguma coisa? Por outro lado, podemos considerar várias *probabilidades* associadas às variáveis aleatórias e ver se *elas* convergem em algum sentido.

A noção mais simples de convergência de variáveis aleatórias é a convergência em probabilidade[14], definida a seguir. (Outras noções de convergência serão desenvolvidas nas seções seguintes.)

No original: *standard deviation*[10], *moment-generating function*[11], *uniqueness theorem*[12], *uniform distribution*[13], *convergence in probability*[14].

Definição 4.2.1

Sejam $X_1, X_2, \ldots$ uma sequência infinita de variáveis aleatórias e Y outra variável aleatória. A sequência $\{X_n\}$ *converge em probabilidade* para Y se, para todo $\epsilon > 0$, $\lim_{n\to\infty} P(|X_n - Y| \geq \epsilon) = 0$, e escrevemos $X_n \xrightarrow{P} Y$.

Na Figura 4.2.1, representamos as diferenças $X_n - Y$, para valores selecionados de n, em 10 sequências geradas $\{X_n - Y\}$, numa situação típica em que as variáveis aleatórias X_n convergem em probabilidade para uma variável aleatória Y. Também traçamos as retas horizontais em $\pm\epsilon$ para $\epsilon = 0{,}25$. Com isso, vemos a concentração crescente da distribuição de $X_n - Y$ em torno de 0 à medida que n cresce, como exige a Definição 4.2.1. De fato, os 10 valores observados de $X_{100} - Y$ satisfazem todos a desigualdade $|X_{100} - Y| < 0{,}25$.

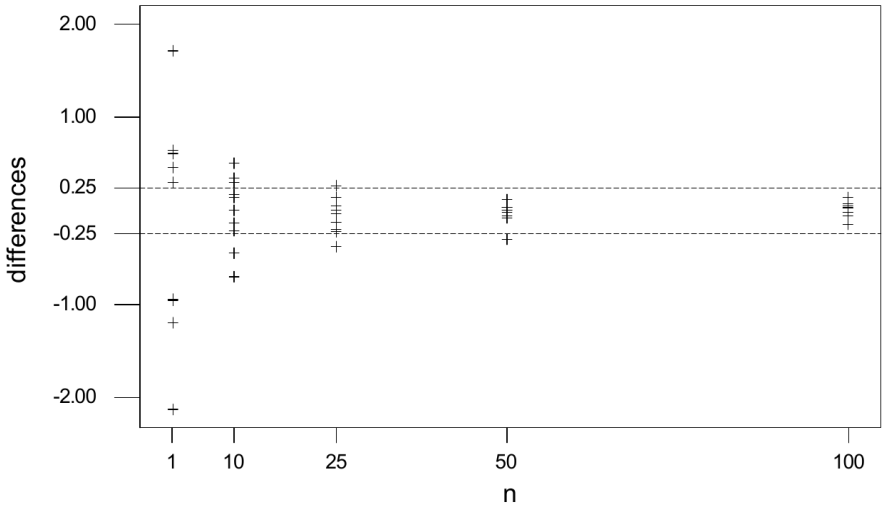


Figura 4.2.1: Gráfico de 10 replicações de $\{X_n - Y\}$ ilustrando a convergência em probabilidade de X_n para Y.

Vejamos algumas aplicações dessa definição.

Exemplo 4.2.1

Seja Y uma variável aleatória qualquer e sejam $X_1 = X_2 = X_3 = \cdots = Y$. (Isto é, as variáveis aleatórias são todas *idênticas* entre si.) Nesse caso, $|X_n - Y| = 0$ e, portanto, evidentemente,

$$\lim_{n\to\infty} P(|X_n - Y| \geq \epsilon) = 0$$

para todo $\epsilon > 0$. Logo, $X_n \xrightarrow{P} Y$. ■

Exemplo 4.2.2

Suponha que $P(X_n = 1 - 1/n) = 1$ e $P(Y = 1) = 1$. Então $P(|X_n - Y| \geq \epsilon) = 0$ sempre que $n > 1/\epsilon$. Logo, $P(|X_n - Y| \geq \epsilon) \to 0$ quando $n \to \infty$, para todo $\epsilon > 0$. Portanto, a sequência $\{X_n\}$ converge em probabilidade para Y. (Aqui, as distribuições de X_n e de Y são todas *degeneradas*.) ■

Exemplo 4.2.3

Seja $U \sim \text{Uniforme}[0, 1]$. Defina X_n por

$$X_n = \begin{cases} 3 & U \leq \frac{2}{3} - \frac{1}{n} \\ 8 & \text{caso contrário,} \end{cases}$$

e defina Y por

$$Y = \begin{cases} 3 & U \leq \frac{2}{3} \\ 8 & \text{caso contrário.} \end{cases}$$

Então

$$P(|X_n - Y| \geq \epsilon) \leq P(X_n \neq Y) = P\left(\frac{2}{3} - \frac{1}{n} < U \leq \frac{2}{3}\right) = \frac{1}{n}.$$

Logo, $P(|X_n - Y| \geq \epsilon) \to 0$ quando $n \to \infty$, para todo $\epsilon > 0$, e a sequência $\{X_n\}$ converge em probabilidade para Y. (Desta vez, as distribuições de X_n e de Y *não* são degeneradas.) ■

Um caso comum é aquele em que as distribuições dos X_n não são degeneradas, mas Y é apenas uma constante, como no exemplo a seguir.

Exemplo 4.2.4

Suponha que $Z_n \sim \text{Exponencial}(n)$ e seja $Y = 0$. Então

$$P(|Z_n - Y| \geq \epsilon) = P(Z_n \geq \epsilon) = \int_{\epsilon}^{\infty} ne^{-nx}\, dx = e^{-n\epsilon}.$$

Logo, novamente, $P(|Z_n - Y| \geq \epsilon) \to 0$ quando $n \to \infty$, para todo $\epsilon > 0$, de modo que a sequência $\{Z_n\}$ converge em probabilidade para Y. ■

4.2.1 A Lei Fraca dos Grandes Números

Uma das aplicações mais importantes da convergência em probabilidade é a lei fraca dos grandes números[15]. Suponha que $X_1, X_2, \ldots$ seja uma sequência de variáveis aleatórias independentes, todas com a mesma média μ. Para n grande, o que podemos dizer sobre a média delas,

$$M_n = \frac{1}{n}(X_1 + \cdots + X_n)?$$

Chamamos M_n de *média da amostra*, ou *média amostral*, de $X_1, \ldots, X_n$. Quando o tamanho da amostra[16] n está fixo, usaremos muitas vezes $\bar{X}$ como notação da média amostral em vez de M_n.

Por exemplo, se lançamos uma sequência de moedas honestas e tomamos $X_i = 1$ ou $X_i = 0$ conforme a i-ésima moeda dê cara ou coroa, então M_n representa a *fração* das n primeiras moedas que deram cara. Seria de esperar que, para n grande, essa fração fique próxima de $1/2$, isto é, do valor esperado[17] dos X_i.

A lei fraca dos grandes números dá um sentido preciso em que as médias M_n tendem a se aproximar de $E(X_i)$, para n grande.

Teorema 4.2.1 (Lei fraca dos grandes números)

Seja $X_1, X_2, \ldots$ uma sequência de variáveis aleatórias independentes, todas com a mesma média μ e com variância menor ou igual a $v < \infty$. Então, para todo $\epsilon > 0$, $\lim_{n\to\infty} P(|M_n - \mu| \geq \epsilon) = 0$. Isto é, as médias convergem em probabilidade para a média comum μ, ou $M_n \xrightarrow{P} \mu$.

Demonstração. Pela linearidade[18] dos valores esperados, vemos que $E(M_n) = \mu$. Além disso, pela independência, temos

$$\begin{aligned}\operatorname{Var}(M_n) &= \frac{1}{n^2}\big(\operatorname{Var}(X_1) + \operatorname{Var}(X_2) + \cdots + \operatorname{Var}(X_n)\big) \\ &\leq \frac{1}{n^2}(v + v + \cdots + v) = \frac{1}{n^2}(nv) = v/n.\end{aligned}$$

Logo, pela desigualdade de Chebychev[19] (Teorema 3.6.2), temos

$$P(|M_n - \mu| \geq \epsilon) \leq \operatorname{Var}(M_n)/\epsilon^2 \leq v/\epsilon^2 n.$$

Isso converge para 0 quando $n \to \infty$, o que prova o teorema. ■

No original: *weak law of large numbers*[15], *sample size*[16], *expected value*[17], *linearity*[18], *Chebychev's*[19].

É fato que, no Teorema 4.2.1, se exigirmos que as variáveis X_i sejam i.i.d. em vez de apenas independentes, nem sequer precisamos que os X_i tenham variância finita. Mas não discutiremos esse resultado aqui. Vejamos algumas aplicações da lei fraca dos grandes números.

Exemplo 4.2.5

Considere o lançamento de uma sequência de moedas honestas idênticas. Seja M_n a fração das n primeiras moedas que dão cara. Então $M_n = (X_1 + \cdots + X_n)/n$, em que $X_i = 1$ se a i-ésima moeda dá cara e, caso contrário, $X_i = 0$. Logo, pela lei fraca dos grandes números, temos

$$\begin{aligned}\lim_{n\to\infty} P(M_n < 0{,}49) &= \lim_{n\to\infty} P(M_n - 0{,}5 < -0{,}01) \\ &\leq \lim_{n\to\infty} P(M_n - 0{,}5 < -0{,}01 \text{ ou } M_n - 0{,}5 > 0{,}01) \\ &= \lim_{n\to\infty} P(|M_n - 0{,}5| > 0{,}01) = 0\end{aligned}$$

e, analogamente, $\lim_{n\to\infty} P(M_n > 0{,}51) = 0$. Isso ilustra que, para n grande, é muito provável que M_n esteja muito próximo de 0,5. ■

Exemplo 4.2.6

Considere o lançamento de uma sequência de moedas idênticas, cada uma com probabilidade p de dar cara. Seja M_n, novamente, a fração das n primeiras moedas que dão cara. Então, pela lei fraca dos grandes números, para todo $\epsilon > 0$, $\lim_{n\to\infty} P(p - \epsilon < M_n < p + \epsilon) = 1$. Vemos, assim, que, para n grande, é muito provável que M_n esteja muito próximo de p. (O exemplo anterior corresponde ao caso particular $p = 1/2$.) ■

Exemplo 4.2.7

Sejam $X_1, X_2, \ldots$ i.i.d. com distribuição $N(3, 5)$. Então $E(M_n) = 3$ e, pela lei fraca dos grandes números, $P(3 - \epsilon < M_n < 3 + \epsilon) \to 1$ quando $n \to \infty$. Logo, para n grande, a média M_n está muito próxima de 3. ■

Exemplo 4.2.8

Sejam $W_1, W_2, \ldots$ i.i.d. com distribuição Exponencial(6). Então $E(M_n) = 1/6$ e, pela lei fraca dos grandes números, $P(1/6 - \epsilon < M_n < 1/6 + \epsilon) \to 1$ quando $n \to \infty$. Logo, para n grande, a média M_n está muito próxima de 1/6. ■

Resumo da Seção 4.2

- Uma sequência $\{X_n\}$ de variáveis aleatórias converge em probabilidade para Y se
$$\lim_{n\to\infty} P(|X_n - Y| \geq \epsilon) = 0.$$
- A lei fraca dos grandes números diz que, se $\{X_n\}$ é i.i.d. (ou é independente, com média constante e variância limitada), então as médias $M_n = (X_1 + \cdots + X_n)/n$ convergem em probabilidade para $E(X_i)$.

Exercícios

4.2.1 Sejam $U \sim$ Uniforme$[5, 10]$, $Z = I_{U\in[5,7)}$ e $Z_n = I_{U\in[5,7+1/n^2)}$. Prove que $Z_n \to Z$ em probabilidade.

4.2.2 Sejam $Y \sim$ Uniforme$[0, 1]$ e $X_n = Y^n$. Prove que $X_n \to 0$ em probabilidade.

4.2.3 Sejam $W_1, W_2, \ldots$ i.i.d. com distribuição Exponencial(3). Prove que, para algum n, temos $P(W_1 + W_2 + \cdots + W_n < n/2) > 0{,}999$.

4.2.4 Sejam $Y_1, Y_2, \ldots$ i.i.d. com distribuição $N(2, 5)$. Prove que, para algum n, temos $P(Y_1 + Y_2 + \cdots + Y_n > n) > 0{,}999$.

4.2.5 Sejam $X_1, X_2, \ldots$ i.i.d. com distribuição Poisson(8). Prove que, para algum n, temos $P(X_1 + X_2 + \cdots + X_n > 9n) < 0{,}001$.

4.2.6 Suponha que $X \sim$ Uniforme$[0, 1]$ e seja $Y_n = \frac{n-1}{n}X$. Prove que $Y_n \xrightarrow{P} X$.

4.2.7 Sejam H_n o número de caras no lançamento de n moedas honestas, $X_n = e^{-H_n}$ e $Y = 0$. Prove que $X_n \xrightarrow{P} Y$.

4.2.8 Sejam $Z_n \sim$ Uniforme$[0, n]$, $W_n = 5Z_n/(Z_n + 1)$ e $W = 5$. Prove que $W_n \xrightarrow{P} W$.

4.2.9 Considere o lançamento de n moedas honestas. Sejam H_n o número total de caras e F_n o número de caras nas moedas de 1 a $n-1$ (isto é, omitindo a n-ésima moeda). Sejam $X_n = H_n/(H_n+1)$, $Y_n = F_n/(H_n+1)$ e $Z = 0$. Prove que $X_n - Y_n \xrightarrow{P} Z$.

4.2.10 Seja Z_n a soma dos *quadrados* dos números obtidos ao lançarmos n dados honestos. Encontre (com demonstração) um número m tal que $\frac{1}{n}Z_n \xrightarrow{P} m$. (Sugestão: use a lei fraca dos grandes números.)

4.2.11 Considere o lançamento de n moedas honestas de 5 centavos e n moedas honestas de 10 centavos. Seja X_n igual a 4 vezes o número de moedas de 5 centavos que dão cara mais 5 vezes o número de moedas de 10 centavos que dão cara. Encontre (com demonstração) um número r tal que $\frac{1}{n}X_n \xrightarrow{P} r$.

Exercícios computacionais

4.2.12 Gere $X_1, \ldots, X_n$ i.i.d. com distribuição Exponencial(5) e calcule M_n para $n = 20$. Repita isso N vezes, com N grande (se possível, tome $N = 10^5$; caso contrário, tão grande quanto for viável), e calcule a proporção dos valores de M_n que ficam entre 0,19 e 0,21. Repita com $n = 50$. Que propriedade da convergência em probabilidade seus resultados ilustram?

4.2.13 Gere $X_1, \ldots, X_n$ i.i.d. com distribuição Poisson(7) e calcule M_n para $n = 20$. Repita isso N vezes, com N grande (se possível, tome $N = 10^5$; caso contrário, tão grande quanto for viável), e calcule a proporção dos valores de M_n que ficam entre 6,99 e 7,01. Repita com $n = 100$. Que propriedade da convergência em probabilidade seus resultados ilustram?

Problemas

4.2.14 Dê um exemplo de variáveis aleatórias $X_1, X_2, \ldots$ tais que $\{X_n\}$ converge para 0 em probabilidade, mas $E(X_n) = 1$ para todo n. (Sugestão: suponha que $P(X_n = n) = 1/n$ e $P(X_n = 0) = 1 - 1/n$.)

4.2.15 Prove que $X_n \xrightarrow{P} 0$ se e somente se $|X_n| \xrightarrow{P} 0$.

4.2.16 Prove ou refute: $X_n \xrightarrow{P} 5$ se e somente se $|X_n| \xrightarrow{P} 5$.

4.2.17 Suponha que $X_n \xrightarrow{P} X$ e $Y_n \xrightarrow{P} Y$. Sejam $Z_n = X_n + Y_n$ e $Z = X + Y$. Prove que $Z_n \xrightarrow{P} Z$.

Desafios

4.2.18 Suponha que $X_n \xrightarrow{P} X$ e que f seja uma função contínua. Prove que $f(X_n) \xrightarrow{P} f(X)$.

4.3 Convergência com Probabilidade 1

Uma noção de convergência para variáveis aleatórias que está intimamente associada à convergência de uma sequência de números reais é dada pelo conceito de convergência com probabilidade 1[20]. Essa propriedade é apresentada na definição a seguir.

Definição 4.3.1

Seja $X_1, X_2, \ldots$ uma sequência infinita de variáveis aleatórias. Diremos que a sequência $\{X_i\}$ *converge com probabilidade 1* (ou *converge quase certamente (q.c.)*) para uma variável aleatória Y se $P\left(\lim_{n\to\infty} X_n = Y\right) = 1$, e escrevemos $X_n \xrightarrow{\text{q.c.}} Y$.

Na Figura 4.3.1, ilustramos essa convergência com o gráfico da sequência de diferenças $\{X_n - Y\}$ numa situação típica em que as variáveis aleatórias X_n convergem com probabilidade 1 para uma variável aleatória Y. Também traçamos as retas horizontais em $\pm\epsilon$ para $\epsilon = 0{,}1$. Note que, inevitavelmente, todos os valores $X_n - Y$ ficam no intervalo $(-0{,}1; 0{,}1)$ ou, em outras palavras, os valores de X_n ficam a menos de 0,1 dos valores de Y.

A Definição 4.3.1 indica que, para qualquer $\epsilon > 0$ dado, existirá um valor N_ϵ tal que $|X_n - Y| < \epsilon$ para todo $n \geq N_\epsilon$. O valor de N_ϵ varia conforme o valor observado da sequência $\{X_n - Y\}$, mas ele sempre existe. Compare isso com a situação mostrada na Figura 4.2.1, que diz apenas que a distribuição de probabilidade de $X_n - Y$ se concentra em torno de 0 à medida que n cresce, e não que os valores individuais de $X_n - Y$ estarão necessariamente todos perto de 0 (veja também o Exemplo 4.3.2).

Vejamos um exemplo disso.

No original: *convergence with probability 1*[20].

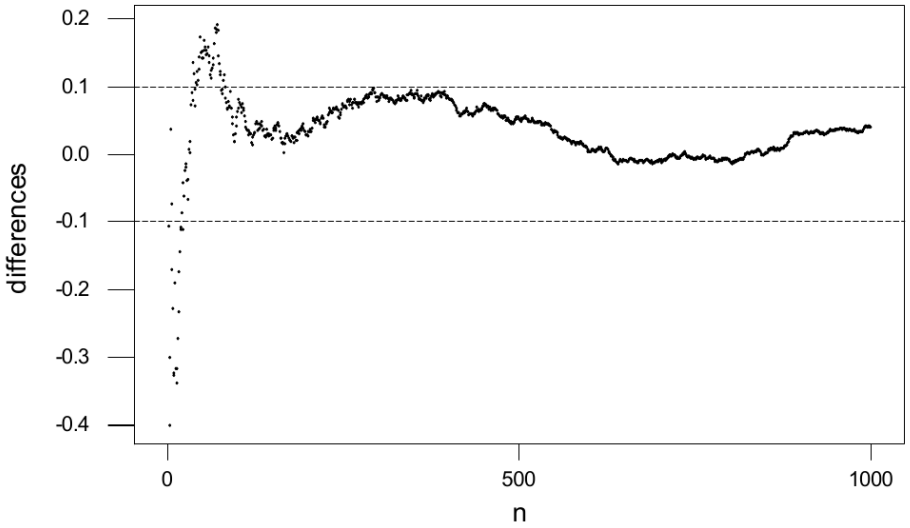


Figura 4.3.1: Gráfico de uma única replicação $\{X_n - Y\}$ ilustrando a convergência com probabilidade 1 de X_n para Y.

Exemplo 4.3.1

Considere novamente a situação do Exemplo 4.2.3, em que $U \sim$ Uniforme$[0,1]$,

$$X_n = \begin{cases} 3 & U \leq \frac{2}{3} - \frac{1}{n} \\ 8 & \text{caso contrário} \end{cases}$$

e

$$Y = \begin{cases} 3 & U \leq \frac{2}{3} \\ 8 & \text{caso contrário.} \end{cases}$$

Se $U > 2/3$, então $Y = 8$ e também $X_n = 8$ para todo n, de modo que, claramente, $X_n \to Y$. Se $U < 2/3$, então, para n grande o suficiente, teremos também

$$U \leq \frac{2}{3} - \frac{1}{n},$$

e então, de novo, $X_n \to Y$. Por outro lado, se $U = 2/3$, teremos sempre $X_n = 8$, embora $Y = 3$. Portanto, $X_n \to Y$ exceto quando $U = 2/3$. Como $P(U = 2/3) = 0$, temos de fato $X_n \to Y$ com probabilidade 1. ■

Pode-se perguntar qual é a relação entre a convergência em probabilidade e a convergência com probabilidade 1. O teorema a seguir dá uma resposta.

Teorema 4.3.1

Sejam $Z, Z_1, Z_2, \ldots$ variáveis aleatórias. Suponha que $Z_n \to Z$ com probabilidade 1. Então $Z_n \to Z$ em probabilidade. Isto é, se uma sequência de variáveis aleatórias converge quase certamente, então ela converge em probabilidade para o mesmo limite.

Demonstração. Veja a Seção 4.7 para a demonstração deste resultado. ■

Por outro lado, a recíproca[21] do Teorema 4.3.1 é falsa, como mostra o exemplo a seguir.

No original: *converse*[21].

Exemplo 4.3.2

Seja U com distribuição uniforme em $[0, 1]$. Construímos uma sequência infinita de variáveis aleatórias $\{X_n\}$ fazendo

$$
\begin{aligned}
&X_1 = I_{[0,1/2)}(U), X_2 = I_{[1/2,1]}(U),\\
&X_3 = I_{[0,1/4)}(U), X_4 = I_{[1/4,1/2)}(U), X_5 = I_{[1/2,3/4)}(U), X_6 = I_{[3/4,1]}(U),\\
&X_7 = I_{[0,1/8)}(U), X_8 = I_{[1/8,1/4)}(U), \ldots\\
&\quad\vdots
\end{aligned}
$$

em que I_A é a *função indicadora* do evento A, isto é, $I_A(s) = 1$ se $s \in A$ e $I_A(s) = 0$ se $s \notin A$.

Note que primeiro subdividimos $[0, 1]$ em dois subintervalos de mesmo comprimento e definimos X_1 e X_2 como as funções indicadoras desses dois subintervalos. Em seguida, subdividimos $[0, 1]$ em quatro subintervalos de mesmo comprimento e definimos X_3, X_4, X_5 e X_6 como as funções indicadoras dos quatro subintervalos. Continuamos esse processo dividindo $[0, 1]$ em oito subintervalos de mesmo comprimento, depois em 16 subintervalos de mesmo comprimento etc., para obter uma sequência infinita de variáveis aleatórias.

Cada uma dessas variáveis aleatórias X_n assume apenas os valores 0 e 1 e, portanto, tem de seguir uma distribuição de Bernoulli. Em particular, $X_1 \sim \text{Bernoulli}(1/2)$, $X_2 \sim \text{Bernoulli}(1/2)$, $X_3 \sim \text{Bernoulli}(1/4)$ etc.

Então, para $0 < \epsilon < 1$, temos $P(|X_n - 0| \geq \epsilon) = P(X_n = 1)$. Como os intervalos de U que tornam $X_n \neq 0$ ficam cada vez menores, vemos que $P(X_n = 1)$ converge para 0. Portanto, X_n converge para 0 em probabilidade.

Por outro lado, X_n *não* converge para 0 quase certamente. De fato, seja qual for o valor que U assuma, sempre haverá infinitos valores diferentes de n para os quais $X_n = 1$. Portanto, teremos $X_n = 1$ infinitas vezes, de modo que *não* teremos X_n convergindo para 0 para nenhum valor particular de U. Assim, $P(\lim_{n\to\infty} X_n \to 0) = 0$, e X_n *não* converge para 0 com probabilidade 1. ■

O Teorema 4.3.1 e o Exemplo 4.3.2 mostram, juntos, que a convergência com probabilidade 1 é uma noção *mais forte* que a convergência em probabilidade.

Ora, a lei fraca dos grandes números (Seção 4.2.1) conclui apenas que as médias M_n convergem em probabilidade para $E(X_i)$. Uma versão mais forte desse resultado concluiria, em vez disso, a convergência com probabilidade 1. É o que consideramos agora.

4.3.1 A Lei Forte dos Grandes Números

O resultado a seguir é um fortalecimento da lei fraca dos grandes números, porque conclui a convergência com probabilidade 1, e não apenas a convergência em probabilidade.

Teorema 4.3.2 (Lei forte dos grandes números)

Seja $X_1, X_2, \ldots$ uma sequência de variáveis aleatórias i.i.d., cada uma com média finita μ. Então

$$P\left(\lim_{n\to\infty} M_n = \mu\right) = 1.$$

Isto é, as médias convergem com probabilidade 1 para a média comum μ, ou $M_n \xrightarrow{\text{q.c.}} \mu$.

Demonstração. Veja *A First Look at Rigorous Probability Theory, Second Edition*, de J. S. Rosenthal (World Scientific Publishing Co., 2006), para uma demonstração deste resultado. ■

Esse resultado diz que as médias amostrais convergem com probabilidade 1 para μ.

Assim como o Teorema 4.2.1, ele diz que, para n grande, as médias M_n costumam ficar perto de $\mu = E(X_i)$. Mas diz, além disso, que, se esperarmos o bastante (isto é, se n for grande o suficiente), então, a partir de algum momento, as médias ficarão *todas* perto de μ, para *todo* n suficientemente grande. Em outras palavras, a média amostral é consistente para μ.

Resumo da Seção 4.3

- Uma sequência $\{X_n\}$ de variáveis aleatórias converge com probabilidade 1 (ou converge quase certamente) para Y se $P(\lim_{n\to\infty} X_n = Y) = 1$.
- A convergência com probabilidade 1 implica a convergência em probabilidade.
- A lei forte dos grandes números diz que, se $\{X_n\}$ é i.i.d., então as médias $M_n = (X_1 + \cdots + X_n)/n$ convergem com probabilidade 1 para $E(X_i)$.

Exercícios

4.3.1 Seja $U \sim$ Uniforme$[5, 10]$, e sejam $Z = I_{[5,7)}(U)$ (isto é, Z é a função indicadora[22] de $[5, 7)$) e $Z_n = I_{[5,7+1/n^2)}(U)$. Prove que $Z_n \to Z$ com probabilidade 1.

4.3.2 Seja $Y \sim$ Uniforme$[0, 1]$, e seja $X_n = Y^n$. Prove que $X_n \to 0$ com probabilidade 1.

4.3.3 Sejam $W_1, W_2, \ldots$ i.i.d. com distribuição Exponencial(3). Prove que, com probabilidade 1, para algum n, temos $W_1 + W_2 + \cdots + W_n < n/2$.

4.3.4 Sejam $Y_1, Y_2, \ldots$ i.i.d. com distribuição $N(2, 5)$. Prove que, com probabilidade 1, para algum n, temos $Y_1 + Y_2 + \cdots + Y_n > n$.

4.3.5 Suponha que $X_n \to X$ com probabilidade 1 e também que $Y_n \to Y$ com probabilidade 1. Prove que $P(X_n \to X \text{ e } Y_n \to Y) = 1$.

4.3.6 Suponha que $Z_1, Z_2, \ldots$ sejam i.i.d. com média finita μ. Seja $M_n = (Z_1 + \cdots + Z_n)/n$. Determine (com justificativa) se as afirmações a seguir são verdadeiras ou falsas.

(a) Com probabilidade 1, $M_n = \mu$ para algum n.

(b) Com probabilidade 1, $\mu - 0{,}01 < M_n < \mu + 0{,}01$ para algum n.

(c) Com probabilidade 1, $\mu - 0{,}01 < M_n < \mu + 0{,}01$ para todo n, exceto um número finito deles.

(d) Para qualquer $x \in R^1$, com probabilidade 1, $x - 0{,}01 < M_n < x + 0{,}01$ para algum n.

4.3.7 Seja $\{X_n\}$ i.i.d., com $X_n \sim$ Uniforme$[3, 7]$. Seja $Y_n = (X_1 + X_2 + \cdots + X_n)/n$. Encontre (com demonstração) um número m tal que $Y_n \xrightarrow{\text{q.c.}} m$. (Sugestão: use a lei forte dos grandes números[23].)

4.3.8 Seja Z_n a soma dos quadrados dos números obtidos quando lançamos n dados honestos. Encontre (com demonstração) um número m tal que $\frac{1}{n} Z_n \xrightarrow{\text{q.c.}} m$.

4.3.9 Considere o lançamento de n moedas honestas de 5 centavos e de n moedas honestas de 10 centavos. Seja X_n igual a 4 vezes o número de moedas de

No original: *indicator function*[22], *strong law of large numbers*[23].

5 centavos que dão cara mais 5 vezes o número de moedas de 10 centavos que dão cara. Encontre (com demonstração) um número r tal que $\frac{1}{n}X_n \xrightarrow{\text{q.c.}} r$.

4.3.10 Suponha que $Y_n \xrightarrow{\text{q.c.}} Y$. Isso implica que $P(|Y_5 - Y| > |Y_4 - Y|) = 0$? Explique.

4.3.11 Considere lançar repetidamente uma moeda honesta. Seja H_n o número de caras nos n primeiros lançamentos, e seja $Z_n = H_n/n$.

(a) Prove que, com probabilidade 1, existe algum m tal que $|Z_n - 1/2| < 0{,}001$ para todo $n \geq m$.

(b) Seja r o menor inteiro positivo que satisfaz $|Z_r - 1/2| < 0{,}001$. É necessariamente verdade que $|Z_n - 1/2| < 0{,}001$ para todo $n \geq r$? Por quê?

4.3.12 Suponha que $P(X = 0) = P(X = 1) = 1/2$, e seja $X_n = X$ para $n = 1, 2, 3, \ldots$. (Isto é, as variáveis aleatórias X_n são todas *idênticas*.) Seja $Y_n = (X_1 + X_2 + \cdots + X_n)/n$.

(a) Prove que $P(\lim_{n\to\infty} Y_n = 0) = P(\lim_{n\to\infty} Y_n = 1) = 1/2$.

(b) Prove que não existe um número m tal que $P(\lim_{n\to\infty} Y_n = m) = 1$.

(c) Por que a parte (b) não contradiz a lei dos grandes números[24]?

Exercícios computacionais

4.3.13 Gere $X_1, \ldots, X_n$ i.i.d. com distribuição Exponencial(5), com n grande (tome $n = 10^5$, se possível). Faça o gráfico dos valores $M_1, M_2, \ldots, M_n$. Para que valor eles estão convergindo? Com que rapidez?

4.3.14 Gere $X_1, \ldots, X_n$ i.i.d. com distribuição Poisson(7), com n grande (tome $n = 10^5$, se possível). Faça o gráfico dos valores $M_1, M_2, \ldots, M_n$. Para que valor eles estão convergindo? Com que rapidez?

4.3.15 Gere $X_1, X_2, \ldots, X_n$ i.i.d. com distribuição $N(-4, 3)$, com n grande (tome $n = 10^5$, se possível). Faça o gráfico dos valores $M_1, M_2, \ldots, M_n$. Para que valor eles estão convergindo? Com que rapidez?

No original: *law of large numbers*[24].

Problemas

4.3.16 Suponha que, para cada inteiro positivo k, existam variáveis aleatórias $W_k, X_{k,1}, X_{k,2}, \ldots$ tais que $P(\lim_{n\to\infty} X_{k,n} = W_k) = 1$. Prove que $P(\lim_{n\to\infty} X_{k,n} = W_k \text{ para todo } k) = 1$.

4.3.17 Prove que $X_n \xrightarrow{\text{q.c.}} 0$ se e somente se $|X_n| \xrightarrow{\text{q.c.}} 0$.

4.3.18 Prove ou refute: $X_n \xrightarrow{\text{q.c.}} 5$ se e somente se $|X_n| \xrightarrow{\text{q.c.}} 5$.

4.3.19 Suponha que $X_n \xrightarrow{\text{q.c.}} X$ e $Y_n \xrightarrow{\text{q.c.}} Y$. Sejam $Z_n = X_n + Y_n$ e $Z = X + Y$. Prove que $Z_n \xrightarrow{\text{q.c.}} Z$.

Desafios

4.3.20 Suponha que, para cada número real $r \in [0,1]$, existam variáveis aleatórias $W_r, X_{r,1}, X_{r,2}, \ldots$ tais que $P(\lim_{n\to\infty} X_{r,n} = W_r) = 1$. Prove ou refute que devemos ter $P(\lim_{n\to\infty} X_{n,r} = W_r \text{ para todo } r \in [0,1]) = 1$. *

4.3.21 Dê um exemplo de variáveis aleatórias $X_1, X_2, \ldots$ tais que $\{X_n\}$ converge para 0 com probabilidade 1, mas $E(X_n) = 1$ para todo n.

4.3.22 Suponha que $X_n \xrightarrow{\text{q.c.}} X$ e que f seja uma função contínua. Prove que $f(X_n) \xrightarrow{\text{q.c.}} f(X)$.

4.4 Convergência em Distribuição

Há ainda outra noção de convergência de uma sequência de variáveis aleatórias que é importante nas aplicações da probabilidade e da estatística.

Definição 4.4.1

Sejam $X, X_1, X_2, \ldots$ variáveis aleatórias. Dizemos que a sequência $\{X_n\}$ *converge em distribuição* para X se, para todo $x \in R^1$ tal que $P(X = x) = 0$, tivermos $\lim_{n\to\infty} P(X_n \le x) = P(X \le x)$, e escrevemos $X_n \xrightarrow{D} X$.

*Nota do tradutor. o original traz $X_{n,r}$ nesta última fórmula; pela notação do enunciado seria $X_{r,n}$

Intuitivamente, $\{X_n\}$ converge em distribuição para X se, para n grande, a distribuição de X_n está próxima da de X. A importância disso, como veremos, é que muitas vezes é difícil trabalhar com a distribuição de X_n, enquanto a de X é muito mais simples. Com X_n convergindo em distribuição para X, porém, podemos aproximar a distribuição de X_n pela de X.

Exemplo 4.4.1

Suponha que $P(X_n = 1) = 1/n$ e $P(X_n = 0) = 1 - 1/n$. Seja $X = 0$, de modo que $P(X = 0) = 1$. Então

$$P(X_n \leq x) = \begin{cases} 0 & x < 0 \\ 1 - 1/n & 0 \leq x < 1 \\ 1 & 1 \leq x \end{cases} \rightarrow P(X \leq x) = \begin{cases} 0 & x < 0 \\ 1 & 0 \leq x \end{cases}$$

quando $n \rightarrow \infty$. Como $P(X_n \leq x) \rightarrow P(X \leq x)$ para todo x, e em particular em todo x em que $P(X = x) = 0$, temos que $\{X_n\}$ converge em distribuição para X. Intuitivamente, quando $n \rightarrow \infty$, fica cada vez mais provável que X_n seja igual a 0. ■

Exemplo 4.4.2

Suponha que $P(X_n = 1) = 1/2 + 1/n$ e $P(X_n = 0) = 1/2 - 1/n$. Suponha, além disso, que $P(X = 0) = P(X = 1) = 1/2$. Então $\{X_n\}$ converge em distribuição para X, porque $P(X_n = 1) \rightarrow 1/2$ e $P(X_n = 0) \rightarrow 1/2$ quando $n \rightarrow \infty$. ■

Exemplo 4.4.3

Seja $X \sim$ Uniforme$[0, 1]$ e seja $P(X_n = i/n) = 1/n$ para $i = 1, 2, \ldots, n$. Então X é absolutamente contínua, enquanto X_n é discreta. Por outro lado, para qualquer $0 \leq x \leq 1$, temos $P(X \leq x) = x$ e, denotando por $\lfloor x \rfloor$ o maior inteiro menor ou igual a x, temos

$$P(X_n \leq x) = \frac{\lfloor nx \rfloor}{n}.$$

Logo, $|P(X_n \leq x) - P(X \leq x)| \leq 1/n$ para todo n. Como $\lim_{n \rightarrow \infty} 1/n = 0$, temos de fato $X_n \rightarrow X$ em distribuição. ■

Exemplo 4.4.4

Suponha que $X_1, X_2, \ldots$ sejam i.i.d. com média finita μ e que $M_n = (X_1 + \cdots + X_n)/n$. Então a lei fraca dos grandes números diz que, para qualquer $\epsilon > 0$, temos

$$P(M_n \leq \mu - \epsilon) \to 0 \quad \text{e} \quad P(M_n \leq \mu + \epsilon) \to 1$$

quando $n \to \infty$. Segue que $\lim_{n\to\infty} P(M_n \leq x) = P(M \leq x)$ para qualquer $x \neq \mu$, em que M é a variável aleatória constante $M = \mu$. Logo, $M_n \to M$ em distribuição. Observe que *não* é necessariamente verdade que $P(M_n \leq \mu) \to P(M \leq \mu) = 1$. Isso, porém, não contradiz a definição de convergência em distribuição, porque $P(M = \mu) \neq 0$, de modo que não precisamos nos preocupar com o caso $x = \mu$. ■

Exemplo 4.4.5 — Aproximação de Poisson para a Binomial

Suponha que $X_n \sim \text{Binomial}(n, \lambda/n)$ e $X \sim \text{Poisson}(\lambda)$. Vimos no Exemplo 2.3.6 que

$$P(X_n = j) = \binom{n}{j}\left(\frac{\lambda}{n}\right)^j \left(1 - \frac{\lambda}{n}\right)^{n-j} \to e^{-\lambda}\frac{\lambda^j}{j!}$$

quando $n \to \infty$. Isso implica que $F_{X_n}(x) \to F_X(x)$ em todo ponto $x \notin \{0, 1, 2, \ldots\}$, e esses são exatamente os pontos em que $P(X = x) = 0$. Portanto, $\{X_n\}$ converge em distribuição para X. (Na verdade, foi essa a nossa motivação original para a distribuição de Poisson.) ■

Muitos outros exemplos de convergência em distribuição[25] são dados pelo teorema central do limite, discutido na próxima seção. Antes, paramos para considerar a relação entre a convergência em distribuição[26] e as noções de convergência anteriores.

Teorema 4.4.1

Se $X_n \xrightarrow{P} X$, então $X_n \xrightarrow{D} X$.

Demonstração. Veja a Seção 4.7 para a demonstração deste resultado. ■

No original: *convergence in distribution*[25], *convergence in distribution*[26].

A recíproca do Teorema 4.4.1 é falsa. De fato, o fato de X_n convergir em distribuição para X não diz nada sobre a *relação* subjacente entre X_n e X; diz apenas algo sobre as distribuições delas. O exemplo a seguir ilustra isso.

Exemplo 4.4.6

Suponha que $X, X_1, X_2, \ldots$ sejam i.i.d., cada uma igual a ± 1 com probabilidade $1/2$ cada. Neste caso, $P(X_n \leq x) = P(X \leq x)$ para todo n e todo $x \in R^1$, de modo que, é claro, X_n converge em distribuição para X. Por outro lado, como X e X_n são independentes,

$$P(|X - X_n| \geq 2) = \frac{1}{2}$$

para todo n, o que *não* tende a 0 quando $n \to \infty$. Logo, X_n *não* converge para X em probabilidade (nem com probabilidade 1). Assim, podemos ter convergência em distribuição sem convergência em probabilidade nem convergência com probabilidade 1. ■

O resultado a seguir, enunciado sem demonstração, indica como as funções geradoras de momentos podem ser usadas para verificar a convergência em distribuição. (Ele generaliza o Teorema 3.4.6.)

Teorema 4.4.2

Seja X uma variável aleatória tal que, para algum $s_0 > 0$, temos $m_X(s) < \infty$ sempre que $s \in (-s_0, s_0)$. Se $Z_1, Z_2, \ldots$ é uma sequência de variáveis aleatórias com $m_{Z_n}(s) < \infty$ e $\lim_{n\to\infty} m_{Z_n}(s) = m_X(s)$ para todo $s \in (-s_0, s_0)$, então $\{Z_n\}$ converge para X em distribuição.

Usaremos esse resultado para provar um dos teoremas mais famosos da probabilidade: o teorema central do limite.

Por fim, observamos que combinar o Teorema 4.4.1 com o Teorema 4.3.1 revela o seguinte.

Corolário 4.4.1

Se $X_n \to X$ com probabilidade 1, então $X_n \xrightarrow{D} X$.

4.4.1 O Teorema Central do Limite

Apresentamos agora o teorema central do limite, um dos resultados mais importantes de toda a teoria da probabilidade. Intuitivamente, ele diz que uma soma grande de variáveis aleatórias i.i.d., normalizada de forma adequada, terá sempre distribuição aproximadamente *normal*. Isso mostra que a distribuição normal é extremamente fundamental em probabilidade e estatística, embora sua função densidade seja complicada e sua função de distribuição acumulada[27] seja intratável.

Suponha que $X_1, X_2, \ldots$ seja uma sequência i.i.d. de variáveis aleatórias, cada uma com média finita μ e variância finita σ^2. Seja $S_n = X_1 + \cdots + X_n$ a soma amostral[28] e $M_n = S_n/n$ a média amostral. O teorema central do limite trata da distribuição da variável aleatória

$$Z_n = \frac{S_n - n\mu}{\sqrt{n}\,\sigma} = \frac{M_n - \mu}{\sigma/\sqrt{n}} = \sqrt{n}\left(\frac{M_n - \mu}{\sigma}\right),$$

em que $\sigma = \sqrt{\sigma^2}$. Sabemos que $E(M_n) = \mu$ e $\mathrm{Var}(M_n) = \sigma^2/n$, o que implica $E(Z_n) = 0$ e $\mathrm{Var}(Z_n) = 1$. A variável Z_n é obtida, portanto, da média amostral (ou da soma amostral) subtraindo sua média e dividindo pelo seu desvio padrão. Essa transformação é chamada de *padronização* de uma variável aleatória, para que ela tenha média 0 e variância 1. Portanto, Z_n é a versão padronizada[29] da média amostral (da soma amostral).

Observe que a distribuição de Z_n tem duas características em comum com a distribuição $N(0,1)$: média 0 e variância 1. O teorema central do limite mostra que há uma relação ainda mais forte.

Teorema 4.4.3 (O teorema central do limite)

Sejam $X_1, X_2, \ldots$ i.i.d. com média finita μ e variância finita σ^2. Seja $Z \sim N(0,1)$. Então, quando $n \to \infty$, a sequência $\{Z_n\}$ converge em distribuição para Z, isto é, $Z_n \xrightarrow{D} Z$.

Demonstração. Veja a Seção 4.7 para a demonstração deste resultado. ■

O teorema central do limite é tão importante que vamos reenunciar suas conclusões de várias maneiras diferentes.

No original: *cumulative distribution function*[27], *sample sum*[28], *standardized version*[29].

Corolário 4.4.2

Para cada $x \in R^1$ fixo, $\lim_{n\to\infty} P(Z_n \leq x) = \Phi(x)$, em que Φ é a função de distribuição acumulada da distribuição normal padrão.

Podemos escrever isso da seguinte forma.

Corolário 4.4.3

Para cada $x \in R^1$ fixo,

$$\lim_{n\to\infty} P(S_n \leq n\mu + x\sqrt{n}\,\sigma) = \Phi(x) \quad \text{e}$$
$$\lim_{n\to\infty} P(M_n \leq \mu + x\sigma/\sqrt{n}) = \Phi(x).$$

Em particular, S_n é aproximadamente igual a $n\mu$, com desvios desse valor da ordem de $\sqrt{n}$, e M_n é aproximadamente igual a μ, com desvios desse valor da ordem de $1/\sqrt{n}$.

Observamos que não é essencial, no teorema central do limite, dividir por σ; nesse caso, o teorema afirma, em vez disso, que $(S_n - n\mu)/\sqrt{n}$ (ou $\sqrt{n}\,(M_n - \mu)$) converge em distribuição para a distribuição $N(0, \sigma^2)$. Isto é, a distribuição limite ainda será normal, mas terá variância σ^2 em vez de variância 1.

Da mesma forma, em vez de dividir exatamente por σ, basta dividir por qualquer quantidade σ_n, desde que $\sigma_n \xrightarrow{\text{q.c.}} \sigma$. Uma modificação simples da demonstração do Teorema 4.4.2 leva ao resultado a seguir.

Corolário 4.4.4

Se

$$Z_n^* = \frac{S_n - n\mu}{\sqrt{n}\,\sigma_n} = \frac{M_n - \mu}{\sigma_n/\sqrt{n}} = \sqrt{n}\left(\frac{M_n - \mu}{\sigma_n}\right)$$

e $\lim_{n\to\infty} \sigma_n \xrightarrow{\text{q.c.}} \sigma$, então $Z_n^* \xrightarrow{D} Z$ quando $n \to \infty$.

Para ilustrar o teorema central do limite, consideramos um experimento de simulação.

Exemplo 4.4.7 — O Teorema Central do Limite Ilustrado numa Simulação

Suponha que geramos uma amostra $X_1, \ldots, X_n$ da densidade Uniforme$[0, 1]$. Observe que a densidade Uniforme$[0, 1]$ é completamente diferente

de uma densidade normal. Uma conta fácil mostra que, quando $X \sim \text{Uniforme}[0,1]$, então $E(X) = 1/2$ e $\text{Var}(X) = 1/12$.

Suponha agora que estamos interessados na distribuição da média amostral $M_n = S_n/n = (X_1 + \cdots + X_n)/n$ para várias escolhas de n. O teorema central do limite nos diz que

$$Z_n = \frac{S_n - n/2}{\sqrt{n/12}} = \sqrt{n}\left(\frac{M_n - 1/2}{\sqrt{1/12}}\right)$$

converge em distribuição para uma distribuição $N(0,1)$. Mas quão grande n precisa ser para que essa aproximação seja precisa?

Para avaliar isso, fizemos um experimento de simulação de Monte Carlo. Na Figura 4.4.1, traçamos um histograma de densidade de $N = 10^5$ valores da distribuição $N(0,1)$, com base em 800 subintervalos de $(-4,4)$, cada um de comprimento $l = 0{,}01$. Os histogramas de densidade são discutidos mais a fundo na Seção 5.4.3, mas, por ora, observamos que, acima de cada intervalo, traçamos a proporção dos valores amostrados que caíram no intervalo, dividida pelo comprimento do intervalo. À medida que aumentamos N e diminuímos l, esses histogramas se parecem cada vez mais com a densidade da distribuição da qual estamos amostrando. De fato, a Figura 4.4.1 se parece muito com uma densidade $N(0,1)$, como deveria.

Na Figura 4.4.2, traçamos um histograma de densidade (usando os mesmos valores de N e l) de Z_1. Observe que $Z_1 \sim \text{Uniforme}[-\sqrt{12}/2, \sqrt{12}/2]$ e, de fato, o histograma se parece com uma densidade uniforme. A Figura 4.4.3 apresenta um histograma de densidade de Z_2, que ainda parece muito pouco normal; mas observe que o histograma de Z_3, na Figura 4.4.4, já começa a se parecer mais com uma distribuição normal. O histograma de Z_{10}, na Figura 4.4.5, parece muito normal. Na verdade, a proporção de valores de Z_{10} em $(-\infty; 1{,}96]$, nesse histograma, é igual a 0,9759, enquanto a proporção exata para uma distribuição $N(0,1)$ é 0,9750.

Assim, neste exemplo, o teorema central do limite fez efeito muito rapidamente, mesmo estando nós amostrando de uma distribuição muito diferente da normal. Acontece que são principalmente as caudas de uma distribuição que determinam quão grande n precisa ser para que a aproximação do teorema central do limite seja precisa. Quando uma distribuição tem caudas que não são mais pesadas que as de uma distribuição normal, podemos esperar que a aproximação seja bastante precisa para tamanhos amostrais relativamente pequenos. ■

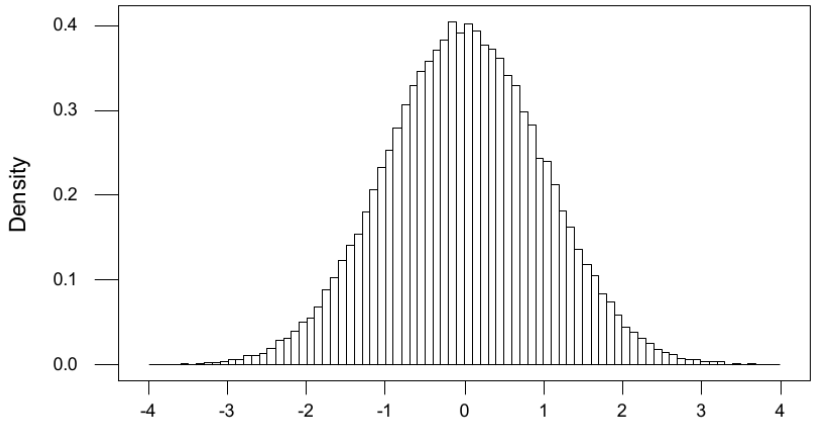


Figura 4.4.1: Histograma de densidade de 10^5 valores normais padrão.

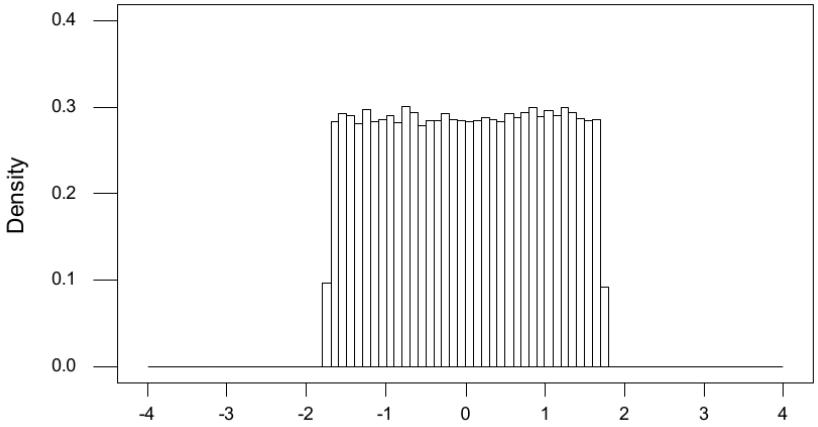


Figura 4.4.2: Histograma de densidade de 10^5 valores de Z_1 no Exemplo 4.4.7.

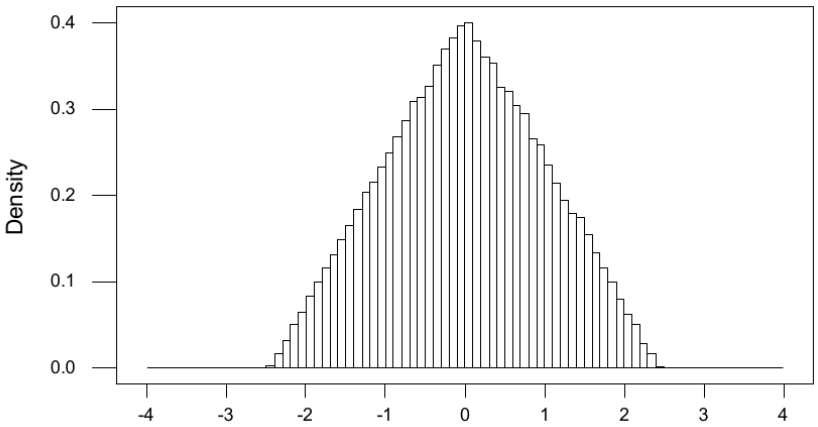


Figura 4.4.3: Histograma de densidade de 10^5 valores de Z_2 no Exemplo 4.4.7.

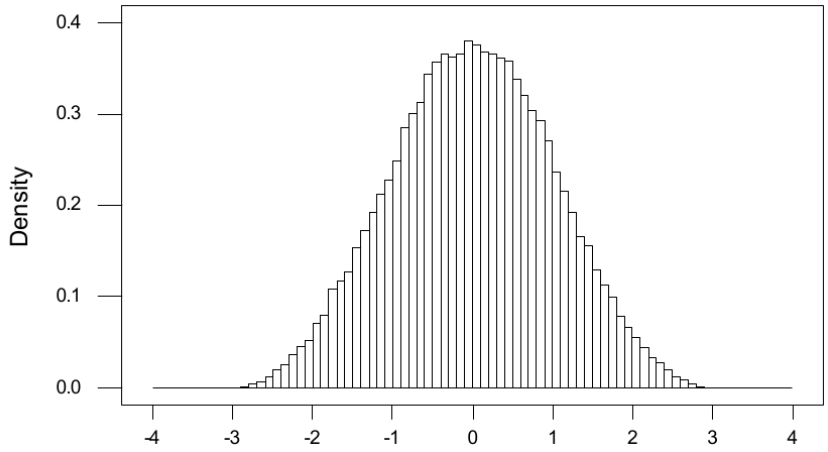


Figura 4.4.4: Histograma de densidade de 10^5 valores de Z_3 no Exemplo 4.4.7.

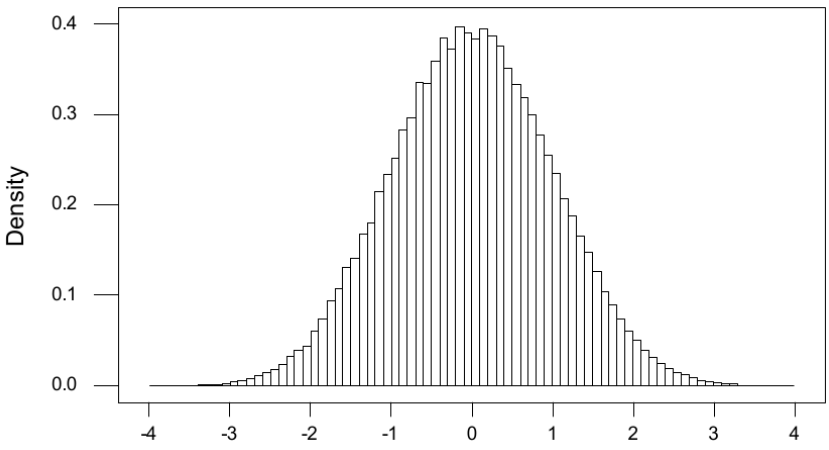


Figura 4.4.5: Histograma de densidade de 10^5 valores de Z_{10} no Exemplo 4.4.7.

Consideramos algumas outras aplicações do teorema central do limite.

Exemplo 4.4.8

Por exemplo, suponha que $X_1, X_2, \ldots$ sejam variáveis aleatórias i.i.d., cada uma com distribuição Poisson(5). Lembre que isso implica $\mu = E(X_i) = 5$ e $\sigma^2 = \text{Var}(X_i) = 5$. Logo, para cada $x \in R^1$ fixo, temos

$$P\left(S_n \leq 5n + x\sqrt{5n}\right) \to \Phi(x)$$

quando $n \to \infty$. ■

Exemplo 4.4.9 — Aproximação Normal para a Distribuição Binomial

Suponha que $X_1, X_2, \ldots$ sejam variáveis aleatórias i.i.d., cada uma com distribuição Bernoulli(θ). Lembre que isso implica $E(X_i) = \theta$ e $v = \text{Var}(X_i) = \theta(1-\theta)$. Logo, para cada $x \in R^1$ fixo, temos

$$P\left(S_n \leq n\theta + x\sqrt{n\theta(1-\theta)}\right) \to \Phi(x), \tag{4.4.1}$$

quando $n \to \infty$.

Mas observe agora que já mostramos que $Y_n = S_n \sim \text{Binomial}(n, \theta)$. Então (4.4.1) implica que, sempre que tivermos uma variável aleatória $Y_n \sim \text{Binomial}(n, \theta)$,

$$\begin{aligned} P(Y_n \leq y) &= P\left(\frac{Y_n - n\theta}{\sqrt{n\theta(1-\theta)}} \leq \frac{y - n\theta}{\sqrt{n\theta(1-\theta)}}\right) \\ &\approx \Phi\left(\frac{y - n\theta}{\sqrt{n\theta(1-\theta)}}\right) \end{aligned} \tag{4.4.2}$$

para n grande.

Observe que aqui estamos aproximando uma distribuição discreta por uma distribuição contínua. Por causa disso, muitas vezes se faz uma pequena melhoria em (4.4.2) quando y é um inteiro não negativo. Em vez dela, usamos

$$P(Y_n \leq y) \approx \Phi\left(\frac{y + 0{,}5 - n\theta}{\sqrt{n\theta(1-\theta)}}\right).$$

Somar 0,5 a y é chamado de *correção de continuidade*. Na prática, isso atribui toda a probabilidade normal relevante do intervalo $(y - 0{,}5; y + 0{,}5)$ ao inteiro não negativo y. Já se mostrou que isso melhora a aproximação (4.4.2). ■

Exemplo 4.4.10 — Aproximação de Probabilidades Usando o Teorema Central do Limite

Embora existam tabelas para a distribuição binomial (Tabela D.6), muitas vezes precisamos calcular probabilidades binomiais em situações que as tabelas não cobrem. Sempre podemos usar um software estatístico para isso; na verdade, esses softwares usam a aproximação normal que deduzimos do teorema central do limite.

Por exemplo, suponha que temos uma moeda viciada, em que a probabilidade de obter cara num único lançamento é $\theta = 0{,}6$. Vamos lançar a moeda $n = 1000$ vezes e então calcular a probabilidade de obter pelo menos 550 caras e no máximo 625 caras. Se Y denota o número de caras obtidas nos 1000 lançamentos, temos $Y \sim \text{Binomial}(1000; 0{,}6)$, de modo que

$$\begin{aligned} E(Y) &= 1000\,(0{,}6) = 600, \\ \text{Var}(Y) &= 1000\,(0{,}6)\,(0{,}4) = 240. \end{aligned}$$

Portanto, usando a correção de continuidade e a Tabela D.2,

$$\begin{aligned} P(550 \le Y \le 625) &= P(550 - 0{,}5 \le Y \le 625 + 0{,}5) \\ &= P\left(\frac{549{,}5 - 600}{\sqrt{240}} \le \frac{Y - 600}{\sqrt{240}} \le \frac{625{,}5 - 600}{\sqrt{240}}\right) \\ &= P\left(-3{,}2598 \le \frac{Y - 600}{\sqrt{240}} \le 1{,}646\right) \\ &\approx \Phi(1{,}65) - \Phi(-3{,}26) = 0{,}9505 - 0{,}0006 = 0{,}9499. \end{aligned}$$

Observe que seria impossível calcular essa probabilidade usando as fórmulas da distribuição binomial. ■

Um dos usos mais importantes do teorema central do limite é que ele leva a um método para avaliar o erro de uma média quando ela está estimando ou aproximando alguma quantidade de interesse.

4.4.2 O Teorema Central do Limite e a Avaliação do Erro

Suponha que $X_1, X_2, \ldots$ seja uma sequência i.i.d. de variáveis aleatórias, cada uma com média finita μ e variância finita σ^2, e que estejamos usando a média amostral M_n para aproximar a média μ. Essa situação surge com frequência em muitos problemas computacionais (ver a Seção 4.5) e estatísticos (ver o

Capítulo 6). Nesse contexto, podemos gerar os X_i, mas não conhecemos o valor de μ.

Se aproximamos μ por M_n, uma pergunta natural é: quanto erro há na aproximação? O teorema central do limite nos diz que

$$\begin{aligned}\Phi(3) - \Phi(-3) &= \lim_{n\to\infty} P\left(-3 < \frac{M_n - \mu}{\sigma/\sqrt{n}} < 3\right) \\ &= \lim_{n\to\infty} P\left(M_n - 3\frac{\sigma}{\sqrt{n}} < \mu < M_n + 3\frac{\sigma}{\sqrt{n}}\right).\end{aligned}$$

Usando a Tabela D.2 (ou um software estatístico), temos $\Phi(3) - \Phi(-3) = 0{,}9987 - (1 - 0{,}9987) = 0{,}9974$. Assim, para n grande, temos que o intervalo

$$\left(M_n - 3\sigma/\sqrt{n}, M_n + 3\sigma/\sqrt{n}\right)$$

contém o valor desconhecido de μ praticamente com certeza[30] (na verdade, com probabilidade de cerca de 0,9974). Portanto, o semicomprimento[31] $3\sigma/\sqrt{n}$ desse intervalo nos dá uma avaliação do erro da aproximação M_n. Observe que $\text{Var}(M_n) = \sigma^2/n$, de modo que o semicomprimento do intervalo é igual a 3 desvios padrão da estimativa M_n.

Como não conhecemos μ, é extremamente improvável que conheçamos σ (já que sua definição usa μ). Mas, se conseguirmos encontrar uma estimativa consistente[32] σ_n de σ, então podemos usar o Corolário 4.4.4 para construir esse intervalo.

Acontece que a escolha correta de σ_n depende do que sabemos sobre a distribuição da qual estamos amostrando (ver o Capítulo 6 para mais discussão sobre isso). Por exemplo, se $X_1 \sim \text{Bernoulli}(\theta)$, então $\mu = \theta$ e $\sigma^2 = \text{Var}(X_1) = \theta(1-\theta)$. Pela lei forte dos grandes números (Teorema 4.3.2), $M_n \xrightarrow{\text{q.c.}} \mu = \theta$ e, assim,

$$\sigma_n = \sqrt{M_n(1-M_n)} \xrightarrow{\text{q.c.}} \sqrt{\theta(1-\theta)} = \sigma.$$

Então, usando o mesmo argumento de antes, temos que, para n grande, o intervalo

$$\left(M_n - 3\sqrt{M_n(1-M_n)/n}, M_n + 3\sqrt{M_n(1-M_n)/n}\right) \tag{4.4.3}$$

contém o verdadeiro valor de θ praticamente com certeza (de novo, com probabilidade de cerca de 0,9974). O semicomprimento de (4.4.3) é uma medida da precisão da estimativa M_n; observe que ele pode ser calculado a partir dos

No original: *with virtual certainty*[30], *half-length*[31], *consistent estimate*[32].

valores $X_1, \ldots, X_n$. Chamamos a quantidade $(M_n(1 - M_n)/n)^{1/2}$ de *erro padrão*[33] da estimativa M_n.

Para uma variável aleatória X_1 geral, seja

$$\sigma_n^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - M_n)^2 = \frac{1}{n-1}\left(\sum_{i=1}^{n} X_i^2 - 2M_n\sum_{i=1}^{n} X_i + nM_n^2\right)$$
$$= \frac{n}{n-1}\left(\frac{1}{n}\sum_{i=1}^{n} X_i^2 - 2M_n^2 + M_n^2\right) = \frac{n}{n-1}\left(\frac{1}{n}\sum_{i=1}^{n} X_i^2 - M_n^2\right).$$

Pela lei forte dos grandes números, temos $M_n \xrightarrow{\text{q.c.}} \mu$ e

$$\frac{1}{n}\sum_{i=1}^{n} X_i^2 \xrightarrow{\text{q.c.}} E\left(X_1^2\right) = \sigma^2 + \mu^2.$$

Como $n/(n-1) \to 1$ e também $M_n^2 \xrightarrow{\text{q.c.}} \mu^2$, concluímos que $\sigma_n^2 \xrightarrow{\text{q.c.}} \sigma^2$. Isso implica que $\sigma_n \xrightarrow{\text{q.c.}} \sigma$; logo, σ_n é consistente para σ. É comum chamar σ_n^2 de *variância amostral* da amostra $X_1, \ldots, X_n$. Quando o tamanho da amostra n está fixo, muitas vezes denotaremos essa estimativa da variância por S^2.

De novo, usando o argumento acima, temos que, para n grande, o intervalo

$$\left(M_n - 3\sigma_n/\sqrt{n}, M_n + 3\sigma_n/\sqrt{n}\right) = \left(M_n - 3S/\sqrt{n}, M_n + 3S/\sqrt{n}\right) \tag{4.4.4}$$

contém o verdadeiro valor de μ praticamente com certeza (também com probabilidade de cerca de 0,9974). Portanto, o semicomprimento é uma medida da precisão da estimativa M_n; observe que ele pode ser calculado a partir dos valores $X_1, \ldots, X_n$. A quantidade $S/\sqrt{n}$ é chamada de *erro padrão* da estimativa M_n.

Usaremos essas estimativas do erro das aproximações na próxima seção.

Resumo da Seção 4.4

- Uma sequência $\{X_n\}$ de variáveis aleatórias converge em distribuição para Y se, para todo $y \in R^1$ com $P(Y = y) = 0$, temos $\lim_{n\to\infty} F_{X_n}(y) = F_Y(y)$, isto é, $\lim_{n\to\infty} P(X_n \leq y) = P(Y \leq y)$.
- Se $\{X_n\}$ converge para Y em probabilidade (ou com probabilidade 1), então $\{X_n\}$ converge para Y em distribuição.

No original: *standard error*[33].

- O importantíssimo teorema central do limite diz que, se as $\{X_n\}$ são i.i.d. com média μ e variância σ^2 finitas, então as variáveis aleatórias $Z_n = (S_n - n\mu)/\sqrt{n}\,\sigma$ convergem em distribuição para uma distribuição normal padrão.
- O teorema central do limite nos permite aproximar diversas distribuições por distribuições normais, o que é útil em experimentos de simulação e em muitos outros contextos. A Tabela D.2 (ou qualquer pacote de software estatístico) fornece valores da função de distribuição acumulada de uma normal padrão.

Exercícios

4.4.1 Suponha que $P(X_n = i) = (n+i)/(3n+6)$ para $i = 1, 2, 3$. Suponha também que $P(X = i) = 1/3$ para $i = 1, 2, 3$. Prove que $\{X_n\}$ converge em distribuição para X.

4.4.2 Suponha que $P(Y_n = k) = (1 - 2^{-n-1})^{-1}/2^{k+1}$ para $k = 0, 1, \ldots, n$. Seja $Y \sim$ Geométrica(1/2). Prove que $\{Y_n\}$ converge em distribuição para Y.

4.4.3 Seja Z_n com densidade $(n+1)x^n$ para $0 < x < 1$, e 0 caso contrário. Seja $Z = 1$. Prove que $\{Z_n\}$ converge em distribuição para Z.

4.4.4 Seja W_n com densidade

$$\frac{1 + x/n}{1 + 1/2n}$$

para $0 < x < 1$, e 0 caso contrário. Seja $W \sim$ Uniforme$[0, 1]$. Prove que $\{W_n\}$ converge em distribuição para W.

4.4.5 Sejam $Y_1, Y_2, \ldots$ i.i.d. com distribuição Exponencial(3). Use o teorema central do limite e a Tabela D.2 (ou um software) para estimar a probabilidade $P(\sum_{i=1}^{1600} Y_i \leq 540)$.

4.4.6 Sejam $Z_1, Z_2, \ldots$ i.i.d. com distribuição Uniforme$[-20, 10]$. Use o teorema central do limite e a Tabela D.2 (ou um software) para estimar a probabilidade $P(\sum_{i=1}^{900} Z_i \geq -4470)$.

4.4.7 Sejam $X_1, X_2, \ldots$ i.i.d. com distribuição Geométrica(1/4). Use o teorema central do limite e a Tabela D.2 (ou um software) para estimar a probabilidade $P(\sum_{i=1}^{800} X_i \geq 2450)$.

4.4.8 Suponha que $X_n \sim N(0, 1/n)$, isto é, X_n tem distribuição normal com média 0 e variância $1/n$. A sequência $\{X_n\}$ converge em distribuição para alguma variável aleatória? Se sim, qual é a distribuição dessa variável aleatória?

4.4.9 Suponha que $P(X_n = i/n) = 2i/n(n+1)$ para $i = 1, 2, 3, \ldots, n$. Seja Z com função densidade dada por $f(z) = 2z$ para $0 < z < 1$ e, caso contrário, $f(z) = 0$.

(a) Calcule $P(Z \leq y)$ para $0 < y < 1$.

(b) Calcule $P(X_n \leq m/n)$ para algum inteiro $1 \leq m \leq n$. (Sugestão: lembre que $\sum_{i=1}^{m} i = m(m+1)/2$.)

(c) Calcule $P(X_n \leq y)$ para $0 < y < 1$.

(d) Prove que $X_n \xrightarrow{D} Z$.

4.4.10 Suponha que $P(Y_n \leq y) = 1 - e^{-2ny/(n+1)}$ para todo $y > 0$. Prove que $Y_n \xrightarrow{D} Y$, em que $Y \sim$ Exponencial(λ) para algum $\lambda > 0$, e calcule λ.

4.4.11 Suponha que $P(Z_n \leq z) = 1 - (1 - \frac{3z}{n})^n$ para todo $0 < z < n/3$. Prove que $Z_n \xrightarrow{D} Z$, em que $Z \sim$ Exponencial(λ) para algum $\lambda > 0$, e calcule λ. (Sugestão: lembre, do cálculo, que $\lim_{n\to\infty}(1 + \frac{c}{n})^n = e^c$ para qualquer número real c.)

4.4.12 Suponha que o tempo de atendimento, em minutos, num banco tenha distribuição Exponencial com $\lambda = 1/2$. Use o teorema central do limite para estimar a probabilidade de que o tempo médio de atendimento dos primeiros n clientes seja menor que 2,5 minutos, quando:

(a) $n = 16$.

(b) $n = 36$.

(c) $n = 100$.

4.4.13 Suponha que o número de quilogramas de uma liga metálica produzidos por uma fábrica a cada semana seja uniformemente distribuído entre 20 e 30. Use o teorema central do limite para estimar a probabilidade de que a produção do próximo ano seja menor que 1280 quilogramas. (Suponha que um ano tenha exatamente 52 semanas.)

4.4.14 Suponha que o tempo, em dias, até a falha de um componente tenha distribuição Gama com $\alpha = 5$ e $\lambda = 1/10$. Quando um componente falha, ele é imediatamente substituído por um componente novo. Use o teorema central do limite para estimar a probabilidade de que 40 componentes, juntos, sejam suficientes para durar pelo menos 6 anos. (Suponha que um ano tenha exatamente 365,25 dias.)

Exercícios computacionais

4.4.15 Gere N amostras $X_1, X_2, \ldots, X_{20} \sim$ Exponencial(3) para N grande ($N = 10^4$, se possível). Use essas amostras para estimar a probabilidade $P(1/6 \leq M_{20} \leq 1/2)$. Como sua resposta se compara com a aproximação dada pelo teorema central do limite?

4.4.16 Gere N amostras $X_1, X_2, \ldots, X_{30} \sim$ Uniforme$[-20, 10]$ para N grande ($N = 10^4$, se possível). Use essas amostras para estimar a probabilidade $P(M_{30} \leq -5)$. Como sua resposta se compara com a aproximação dada pelo teorema central do limite?

4.4.17 Gere N amostras $X_1, X_2, \ldots, X_{20} \sim$ Geométrica$(1/4)$ para N grande ($N = 10^4$, se possível). Use essas amostras para estimar a probabilidade $P(2{,}5 \leq M_{20} \leq 3{,}3)$. Como sua resposta se compara com a aproximação dada pelo teorema central do limite?

4.4.18 Gere N amostras $X_1, X_2, \ldots, X_{20}$ da distribuição de $\log Z$, em que $Z \sim$ Gama$(4, 1)$, para N grande ($N = 10^4$, se possível). Use essas amostras para construir um histograma de densidade dos valores de M_{20}. Comente a forma desse gráfico.

4.4.19 Gere N amostras $X_1, X_2, \ldots, X_{20}$ da distribuição Binomial$(10; 0{,}01)$ para N grande ($N = 10^4$, se possível). Use essas amostras para construir um histograma de densidade dos valores de M_{20}. Comente a forma desse gráfico.

Problemas

4.4.20 Seja $a_1, a_2, \ldots$ uma sequência qualquer de números reais não negativos com $\sum_i a_i = 1$. Suponha que $P(X = i) = a_i$ para todo inteiro positivo i. Construa uma sequência $\{X_n\}$ de variáveis aleatórias *absolutamente contínuas* tal que $X_n \to X$ em distribuição.

4.4.21 Seja $f : [0, 1] \to (0, \infty)$ uma função contínua positiva tal que $\int_0^1 f(x)\,dx = 1$. Considere variáveis aleatórias X e $\{X_n\}$ tais que $P(a \leq X \leq b) = \int_a^b f(x)\,dx$ para $a \leq b$ e

$$P\left(X_n = \frac{i}{n}\right) = \frac{f(i/n)}{\sum_{j=1}^{n} f(j/n)}$$

para $i = 1, 2, 3, \ldots, n$. Prove que $X_n \to X$ em distribuição.

4.4.22 Suponha que $Y_i = X_i^3$ e que $X_1, \ldots, X_n$ seja uma amostra de uma distribuição $N(0,1)$. Indique como você aproximaria a probabilidade $P(M_n \leq m)$, em que $M_n = (Y_1 + \cdots + Y_n)/n$.

4.4.23 Suponha que $Y_i = \cos(2\pi U_i)$ e que $U_1, \ldots, U_n$ seja uma amostra da distribuição Uniforme$[0,1]$. Indique como você aproximaria a probabilidade $P(M_n \leq m)$, em que $M_n = (Y_1 + \cdots + Y_n)/n$.

Problemas computacionais

4.4.24 Suponha que $Y = X^3$ e $X \sim N(0,1)$. Gerando uma amostra grande ($n = 10^4$, se possível) da distribuição de Y, aproxime a probabilidade $P(Y \leq 1)$ e avalie o erro da sua aproximação. Calcule essa probabilidade exatamente e compare-a com a sua aproximação.

4.4.25 Suponha que $Y = X^3$ e $X \sim N(0,1)$. Gerando uma amostra grande ($n = 10^4$, se possível) da distribuição de Y, aproxime a esperança[34] $E(\cos(X^3))$ e avalie o erro da sua aproximação.

Desafios

4.4.26 Suponha que $X_n \to C$ em distribuição, em que C é uma constante. Prove que $X_n \to C$ em probabilidade. (Isso prova que, se X é *constante*, então a recíproca do Teorema 4.4.1 *vale*, embora não valha para X geral.)

4.5 Aproximações de Monte Carlo

As leis dos grandes números dizem que, se $X_1, X_2, \ldots$ é uma sequência i.i.d. de variáveis aleatórias com média μ e

$$M_n = \frac{X_1 + \cdots + X_n}{n},$$

então, para n grande, teremos $M_n \approx \mu$.

Suponha agora que μ seja *desconhecida*. Então, como discutido na Seção 4.4.2, é possível mudar de perspectiva e usar M_n (para n grande) como um *estimador*, ou aproximação, de μ. Sempre que aproximamos ou estimamos uma quantidade,

No original: *expectation*[34].

também precisamos dizer algo sobre o tamanho do erro da estimativa. É claro que não podemos dizer exatamente qual é esse erro, pois isso exigiria conhecer o valor exato de μ. Na Seção 4.4.2, porém, mostramos como o teorema central do limite leva a uma abordagem muito natural para avaliar esse erro, usando três vezes o erro padrão da estimativa. Vejamos alguns exemplos.

Exemplo 4.5.1

Considere lançar uma sequência de moedas idênticas, cada uma com probabilidade θ de dar cara, mas com θ desconhecido. Seja M_n, novamente, a fração das n primeiras moedas que dão cara. Sabemos então que, para n grande, é muito provável que M_n esteja muito próximo de θ. Portanto, podemos usar M_n para *estimar* θ. Além disso, a discussão da Seção 4.4.2 indica que (4.4.3) é o intervalo relevante a apresentar quando se avalia a precisão da estimativa M_n. ■

Exemplo 4.5.2

Suponha que acreditamos que certo remédio baixa a pressão arterial, mas não sabemos quanto. Gostaríamos de conhecer a quantidade média μ pela qual esse remédio baixa a pressão arterial.

Suponha que observamos n pacientes (escolhidos ao acaso, de modo que sejam i.i.d.), em que o paciente i tem pressão arterial B_i antes de tomar o remédio e pressão arterial A_i depois. Seja $X_i = B_i - A_i$. Então

$$M_n = \frac{1}{n}\sum_{i=1}^{n}(B_i - A_i)$$

é a redução média da pressão arterial. (Note que $B_i - A_i$ pode ser negativo para alguns pacientes, e é importante incluir também esses termos negativos na soma.) Então, para n grande, o valor de M_n é uma boa *estimativa* de $E(X_i) = \mu$. Além disso, a discussão da Seção 4.4.2 indica que (4.4.4) é o intervalo relevante a apresentar quando se avalia a precisão da estimativa M_n. ■

Estimadores como esses também podem ser usados para estimar quantidades puramente matemáticas, que não envolvem nenhum dado experimental (como moedas ou pacientes), mas que são difíceis demais de calcular diretamente. Nesse caso, esses estimadores são chamados de *aproximações de Monte Carlo* (nome tirado do cassino do principado de Mônaco, porque elas introduzem aleatoriedade para resolver problemas que não são aleatórios).

Exemplo 4.5.3

Suponha que queremos calcular

$$I = \int_0^1 \cos(x^2)\,\sin(x^4)\,dx.$$

Essa integral não é fácil de resolver exatamente. Mas ela pode ser calculada aproximadamente por uma aproximação de Monte Carlo, como segue. Note que

$$I = E(\cos(U^2)\ \sin(U^4)),$$

em que $U \sim$ Uniforme$[0,1]$. Portanto, para n grande, a integral I é aproximadamente igual a $M_n = (T_1 + \cdots + T_n)/n$, em que $T_i = \cos(U_i^2)\,\sin(U_i^4)$ e em que $U_1, U_2, \ldots$ são i.i.d. Uniforme$[0,1]$.

Juntando tudo isso, obtemos o seguinte algoritmo para aproximar a integral I:

1. Escolha um inteiro positivo grande n.
2. Obtenha $U_i \sim$ Uniforme$[0,1]$, independentemente para $i = 1, 2, \ldots, n$.
3. Faça $T_i = \cos(U_i^2)\ \sin(U_i^4)$, para $i = 1, 2, \ldots, n$.
4. Estime I por $M_n = (T_1 + \cdots + T_n)/n$.

Para n suficientemente grande, esse algoritmo dará uma boa estimativa da integral I.

Por exemplo, a tabela a seguir registra as estimativas M_n e os intervalos (4.4.4) baseados em amostras de variáveis Uniforme$[0,1]$ para várias escolhas de n.

n	M_n	$M_n - 3S/\sqrt{n}$	$M_n + 3S/\sqrt{n}$
10^3	0,145294	0,130071	0,160518
10^4	0,138850	0,134105	0,143595
10^5	0,139484	0,137974	0,140993

Daí vemos que o valor de I é aproximadamente 0,139484 e que o valor verdadeiro está quase certamente no intervalo (0,137974; 0,140993). Note como os comprimentos dos intervalos diminuem à medida que aumentamos n. Na verdade, é possível mostrar que o valor exato é $I = 0{,}139567$, de modo que nossa aproximação é excelente. ■

Exemplo 4.5.4

Suponha que queremos calcular a integral

$$I = \int_0^\infty 25x^2 \cos(x^2) e^{-25x}\, dx.$$

Essa integral não é fácil de resolver exatamente, mas também pode ser calculada aproximadamente por uma aproximação de Monte Carlo, como segue.

Note, primeiro, que $I = E(X^2 \cos(X^2))$, em que $X \sim$ Exponencial(25). Portanto, para n grande, a integral I é aproximadamente igual a $M_n = (T_1 + \cdots + T_n)/n$, em que $T_i = X_i^2 \cos(X_i^2)$, com $X_1, X_2, \ldots$ i.i.d. Exponencial(25).

Ora, sabemos da Seção 2.10 que podemos simular $X \sim$ Exponencial(25) fazendo $X = -\ln(U)/25$, em que $U \sim$ Uniforme$[0, 1]$. Portanto, juntando tudo isso, obtemos o seguinte algoritmo para aproximar a integral I:

1. Escolha um inteiro positivo grande n.
2. Obtenha $U_i \sim$ Uniforme$[0, 1]$, independentemente para $i = 1, 2, \ldots, n$.
3. Faça $X_i = -\ln(U_i)/25$, para $i = 1, 2, \ldots, n$.
4. Faça $T_i = X_i^2 \cos(X_i^2)$, para $i = 1, 2, \ldots, n$.
5. Estime I por $M_n = (T_1 + \cdots + T_n)/n$.

Para n suficientemente grande, esse algoritmo dará uma boa estimativa da integral I.

Por exemplo, a tabela a seguir registra as estimativas M_n e os intervalos (4.4.4) baseados em amostras de variáveis Exponencial(25) para várias escolhas de n.

n	M_n	$M_n - 3S/\sqrt{n}$	$M_n + 3S/\sqrt{n}$
10^3	$3{,}33846 \times 10^{-3}$	$2{,}63370 \times 10^{-3}$	$4{,}04321 \times 10^{-3}$
10^4	$3{,}29933 \times 10^{-3}$	$3{,}06646 \times 10^{-3}$	$3{,}53220 \times 10^{-3}$
10^5	$3{,}20629 \times 10^{-3}$	$3{,}13759 \times 10^{-3}$	$3{,}27499 \times 10^{-3}$

Daí vemos que o valor de I é aproximadamente $3{,}20629 \times 10^{-3}$ e que o valor verdadeiro está quase certamente no intervalo $(3{,}13759 \times 10^{-3}; 3{,}27499 \times 10^{-3})$. ■

Exemplo 4.5.5

Suponha que queremos calcular a soma

$$S = \sum_{j=0}^{\infty} (j^2 + 3)^{-7} 5^{-j}.$$

Embora seja muito difícil calculá-la diretamente, ela pode ser calculada aproximadamente por uma aproximação de Monte Carlo.

Vamos reescrever a soma como

$$S = \left(\frac{5}{4}\right) \sum_{j=0}^{\infty} (j^2 + 3)^{-7} \left(\frac{4}{5}\right) \left(1 - \frac{4}{5}\right)^j.$$

Vemos então que $S = (5/4)\, E((X^2 + 3)^{-7})$, em que $X \sim$ Geométrica(4/5).

Ora, sabemos da Seção 2.10 que podemos simular $X \sim$ Geométrica(4/5) fazendo $X = \lfloor \ln(1 - U)/\ln(1 - 4/5) \rfloor$ ou, de forma equivalente, $X = \lfloor \ln(U)/\ln(1 - 4/5) \rfloor$, em que $U \sim$ Uniforme$[0, 1]$ e em que $\lfloor \cdot \rfloor$ significa arredondar para baixo, até o inteiro seguinte. Portanto, obtemos o seguinte algoritmo para aproximar a soma S:

1. Escolha um inteiro positivo grande n.
2. Obtenha $U_i \sim$ Uniforme$[0, 1]$, independentemente para $i = 1, 2, \ldots, n$.
3. Faça $X_i = \lfloor \ln(U_i)/\ln(1 - 4/5) \rfloor$, para $i = 1, 2, \ldots, n$.
4. Faça $T_i = (X_i^2 + 3)^{-7}$, para $i = 1, 2, \ldots, n$.
5. Estime S por $M_n = (5/4)(T_1 + \cdots + T_n)/n$.

Para n suficientemente grande, esse algoritmo dará uma boa estimativa da soma S.

Por exemplo, a tabela a seguir registra as estimativas M_n e os intervalos (4.4.4) baseados em amostras de variáveis Geométrica(4/5) para várias escolhas de n.

n	M_n	$M_n - 3S/\sqrt{n}$	$M_n + 3S/\sqrt{n}$
10^3	$4{,}66773 \times 10^{-4}$	$4{,}47078 \times 10^{-4}$	$4{,}86468 \times 10^{-4}$
10^4	$4{,}73538 \times 10^{-4}$	$4{,}67490 \times 10^{-4}$	$4{,}79586 \times 10^{-4}$
10^5	$4{,}69377 \times 10^{-4}$	$4{,}67436 \times 10^{-4}$	$4{,}71318 \times 10^{-4}$

Daí vemos que o valor de S é aproximadamente $4{,}69377 \times 10^{-4}$ e que o valor verdadeiro está quase certamente no intervalo $(4{,}67436 \times 10^{-4}; 4{,}71318 \times 10^{-4})$. ■

Note que, ao usar uma aproximação de Monte Carlo[35], não é necessário que o domínio de uma integral ou de uma soma seja todo o conjunto de valores da variável aleatória correspondente, como mostra o exemplo a seguir.

Exemplo 4.5.6

Suponha que queremos calcular a integral

$$J = \int_0^\infty \operatorname{sin}(x) e^{-x^2/2}\, dx.$$

Novamente, é extremamente difícil calculá-la exatamente.

Aqui,

$$J = \sqrt{2\pi}\, E(\operatorname{sin}(X) I_{\{X>0\}}),$$

em que $X \sim N(0,1)$ e $I_{\{X>0\}}$ é a função indicadora do evento $\{X > 0\}$. Sabemos da Seção 2.10 que podemos simular $X \sim N(0,1)$ fazendo

$$X = \sqrt{2\log(1/U)}\, \cos(2\pi V),$$

em que U e V são i.i.d. Uniforme$[0,1]$. Portanto, obtemos o seguinte algoritmo para aproximar a integral J:

1. Escolha um inteiro positivo grande n.
2. Obtenha $U_i, V_i \sim$ Uniforme$[0,1]$, independentemente para $i = 1, 2, \ldots, n$.
3. Faça $X_i = \sqrt{2\log(1/U_i)}\, \cos(2\pi V_i)$, para $i = 1, 2, \ldots, n$.
4. Faça $T_i = \operatorname{sin}(X_i) I_{\{X_i>0\}}$, para $i = 1, 2, \ldots, n$. (Isto é, faça $T_i = \operatorname{sin}(X_i)$ se $X_i > 0$; caso contrário, faça $T_i = 0$.)
5. Estime J por $M_n = \sqrt{2\pi}\,(T_1 + \cdots + T_n)/n$.

Para n suficientemente grande, esse algoritmo dará novamente uma boa estimativa da integral I.*

Por exemplo, a tabela a seguir registra as estimativas M_n e os intervalos (4.4.4) baseados em amostras de variáveis $N(0,1)$ para várias escolhas de n.

No original: *Monte Carlo approximation*[35].

n	M_n	$M_n - 3S/\sqrt{n}$	$M_n + 3S/\sqrt{n}$
10^3	0,744037	0,657294	0,830779
10^4	0,733945	0,706658	0,761233
10^5	0,722753	0,714108	0,731398

Daí vemos que o valor de J é aproximadamente 0,722753 e que o valor verdadeiro está quase certamente no intervalo (0,714108; 0,731398). ■

Consideramos agora um problema importante para as aplicações estatísticas da teoria da probabilidade.

Exemplo 4.5.7 — Aproximação de Distribuições Amostrais por Monte Carlo

Suponha que $X_1, X_2, \ldots, X_n$ é uma sequência i.i.d. da medida de probabilidade P. Queremos encontrar a distribuição de uma nova variável aleatória $Y = h(X_1, X_2, \ldots, X_n)$, para alguma função h. Desde que consigamos gerar valores de P, os métodos de Monte Carlo nos dão uma maneira de aproximar essa distribuição.

Denotando por F_Y a função de distribuição acumulada de Y, temos

$$F_Y(y) = P((-\infty, y]) = E_{P_Y}(I_{(-\infty,y]}(Y)) = E(I_{(-\infty,y]}(h(X_1, X_2, \ldots, X_n))).$$

Assim, $F_Y(y)$ pode ser expressa como a esperança da variável aleatória

$$I_{(-\infty,y]}(h(X_1, X_2, \ldots, X_n))$$

com base em amostragem de P.

Para estimar isso, geramos N amostras de tamanho n

$$(X_{i1}, X_{i2}, \ldots, X_{in}),$$

para $i = 1, \ldots, N$, de P (note que N é o tamanho da amostra de Monte Carlo e pode variar, enquanto o tamanho da amostra n é fixo aqui) e então calculamos a proporção de valores $h(X_{i1}, X_{i2}, \ldots, X_{in}) \in (-\infty, y]$. A estimativa M_N é então dada por

$$\hat{F}_Y(y) = \frac{1}{N} \sum_{i=1}^{N} I_{(-\infty,y]}(h(X_{i1}, X_{i2}, \ldots, X_{in})).$$

Pelas leis dos grandes números, isso converge para $F_Y(y)$ quando $N \to \infty$. Para avaliar o erro dessa aproximação, usamos (4.4.3), que agora toma a

*Nota do tradutor. O original traz I; a integral deste exemplo é J.

forma*

$$\left(\hat{F}_Y(y) - 3\sqrt{\hat{F}_Y(y)(1-\hat{F}_Y(y))/n},\, \hat{F}_Y(y) + 3\sqrt{\hat{F}_Y(y)(1-\hat{F}_Y(y))/n}\right).$$

Apresentamos uma aplicação disso no Exemplo 4.4.7. Note que, se a base de um retângulo do histograma da Figura 4.4.2 é dada por $(a, b]$, então a altura desse retângulo é igual à proporção de valores que caíram em $(a, b]$ vezes $1/(b-a)$. Isso pode ser expresso como $(\hat{F}_Y(b) - \hat{F}_Y(a))/(b-a)$, que converge para $(F_Y(b) - F_Y(a))/(b-a)$ quando $N \to \infty$. Isso prova que as áreas dos retângulos do histograma convergem para $F_Y(b) - F_Y(a)$ quando $N \to \infty$.

De modo mais geral, podemos aproximar uma esperança $E(g(Y))$ pela média

$$\frac{1}{N}\sum_{i=1}^{N} g(h(X_{i1}, X_{i2}, \ldots, X_{in})).$$

Pelas leis dos grandes números, essa média converge para $E(g(Y))$ quando $N \to \infty$. ■

Em geral, há mais de um algoritmo de Monte Carlo possível para estimar uma quantidade de interesse. Por exemplo, suponha que queremos aproximar a integral $\int_a^b g(x)\,dx$, em que supomos que essa integral é finita. Seja f uma densidade no intervalo (a, b) tal que $f(x) > 0$ para todo $x \in (a, b)$, e suponha que temos um algoritmo conveniente para gerar $X_1, X_2, \ldots$ i.i.d. com distribuição dada por f. Temos que

$$\int_a^b g(x)\,dx = \int_a^b \frac{g(x)}{f(x)} f(x)\,dx = E\left(\frac{g(X)}{f(X)}\right)$$

quando X tem distribuição com densidade f. Então podemos estimar $\int_a^b g(x)\,dx$ por

$$M_n = \frac{1}{n}\sum_{i=1}^{n} \frac{g(X_i)}{f(X_i)} = \frac{1}{n}\sum_{i=1}^{n} T_i,$$

em que $T_i = g(X_i)/f(X_i)$. Na prática, foi isso que fizemos no Exemplo 4.5.3 (f é a densidade Uniforme$[0, 1]$), no Exemplo 4.5.4 (f é a densidade Exponencial(25)) e no Exemplo 4.5.6 (f é a densidade $N(0, 1)$). Mas note que há muitas outras escolhas possíveis. No Exemplo 4.5.3, poderíamos ter tomado como f qualquer densidade beta. No Exemplo 4.5.4, poderíamos ter tomado como f qualquer densidade gama, e o mesmo vale para o Exemplo 4.5.6. A maioria dos

*Nota do tradutor. O original traz $/n$ dentro das raízes; como a média é de N indicadoras, seria $/N$.

pacotes estatísticos de computador tem comandos para gerar valores dessas distribuições. Num problema dado, qual é o melhor algoritmo a usar?

Nesse caso, naturalmente usaríamos o algoritmo mais *eficiente*. Para os algoritmos que discutimos aqui, isso significa que, se, com base numa amostra de tamanho n, o algoritmo 1 leva a uma estimativa com erro padrão $\sigma_1/\sqrt{n}$ e o algoritmo 2 leva a uma estimativa com erro padrão $\sigma_2/\sqrt{n}$, então o algoritmo 1 é mais eficiente que o algoritmo 2 sempre que $\sigma_1 < \sigma_2$. Naturalmente, preferiríamos o algoritmo 1, porque os intervalos (4.4.3) ou (4.4.4) tenderão a ser mais curtos para o algoritmo 1 com o mesmo tamanho de amostra. Na verdade, uma comparação mais refinada da eficiência levaria em conta também o tempo total de computador usado por cada algoritmo, mas vamos ignorar esse aspecto do problema aqui. Veja o Problema 4.5.21 para mais discussão sobre a eficiência e a escolha do algoritmo no contexto do problema de integração.

Resumo da Seção 4.5

- Uma quantidade desconhecida pode ser calculada aproximadamente por uma aproximação de Monte Carlo, em que se toma a média de repetições independentes de um experimento aleatório (em geral, num computador) para estimar a quantidade.
- Aproximações de Monte Carlo podem ser usadas para aproximar somas, integrais e distribuições amostrais complicadas, bastando escolher o experimento aleatório de modo apropriado.

Exercícios

4.5.1 Descreva uma aproximação de Monte Carlo de $\int_{-\infty}^{\infty} \cos^2(x) e^{-x^2/2}\, dx$.

4.5.2 Descreva uma aproximação de Monte Carlo de $\sum_{j=0}^{m} j^6 \binom{m}{j} 2^j 3^{-m}$. (Sugestão: lembre a distribuição Binomial$(m, 2/3)$.)

4.5.3 Descreva uma aproximação de Monte Carlo de $\int_0^{\infty} e^{-5x-14x^2}\, dx$. (Sugestão: lembre a distribuição Exponencial(5).)

4.5.4 Suponha que $X_1, X_2, \ldots$ são i.i.d. com distribuição Poisson(λ), em que λ é desconhecido. Considere $M_n = (X_1 + X_2 + \cdots + X_n)/n$ como uma estimativa de λ. Suponha que sabemos que $\lambda \leq 10$. Quão grande n precisa ser para garantir que M_n esteja a menos de 0,1 do valor verdadeiro de λ praticamente com certeza, isto é, quando 3 desvios padrão são menores que 0,1?

4.5.5 Descreva uma aproximação de Monte Carlo de $\sum_{j=0}^{\infty} \operatorname{sin}(j^2)5^j/j!$. Suponha que você dispõe de um algoritmo para gerar valores da distribuição Poisson(5).

4.5.6 Descreva uma aproximação de Monte Carlo de $\int_0^{10} e^{-x^4}\,dx$. (Sugestão: lembre a distribuição Uniforme$[0, 10]$.)

4.5.7 Suponha que repetimos certo experimento 2000 vezes e obtemos uma média amostral de -5 e um erro padrão de 17. Em termos disso, especifique um intervalo que contenha praticamente com certeza a média verdadeira (desconhecida) μ do experimento.

4.5.8 Suponha que repetimos certo experimento 400 vezes e obtemos valores de resposta i.i.d. $X_1, X_2, \ldots, X_{400}$. Suponha que calculamos que a média amostral é $M_{400} = 6$ e, além disso, que $\sum_{i=1}^{400}(X_i)^2 = 15.400$. Em termos disso:

(a) Calcule o erro padrão σ_n.

(b) Especifique um intervalo que contenha praticamente com certeza a média verdadeira (desconhecida) μ dos X_i.

4.5.9 Suponha que certo experimento tem probabilidade θ de sucesso, em que $0 < \theta < 1$, mas θ é desconhecido. Suponha que repetimos o experimento 1000 vezes, com 400 sucessos e 600 fracassos. Calcule um intervalo de valores que contenha θ praticamente com certeza.

4.5.10 Suponha que certo experimento tem probabilidade θ de sucesso, em que $0 < \theta < 1$, mas θ é desconhecido. Suponha que repetimos o experimento n vezes, e seja Y a fração de sucessos.

(a) Em termos de θ, quanto vale $\operatorname{Var}(Y)$?

(b) Para que valor de θ a $\operatorname{Var}(Y)$ é máxima?

(c) Qual é esse maior valor possível de $\operatorname{Var}(Y)$?

(d) Calcule o menor inteiro n tal que possamos ter certeza de que $\operatorname{Var}(Y) < 0{,}01$, seja qual for o valor de θ.

4.5.11 Suponha que X e Y são variáveis aleatórias com densidade conjunta[36] dada por $f_{X,Y}(x, y) = C\,g(x, y)$ para $0 \leq x, y \leq 1$ (com $f_{X,Y}(x, y) = 0$ para os demais x, y), para uma constante C apropriada, em que

$$g(x, y) = x^2y^3 \operatorname{sin}(xy) \operatorname{cos}(\sqrt{xy}\,) \exp(x^2 + y).$$

No original: *joint density*[36].

(a) Explique por que

$$E(X) = \int_0^1 \int_0^1 x\, f_{X,Y}(x,y)\, dx\, dy = \frac{\int_0^1 \int_0^1 x\, g(x,y)\, dx\, dy}{\int_0^1 \int_0^1 g(x,y)\, dx\, dy}.$$

(b) Descreva um algoritmo de Monte Carlo para calcular aproximadamente $E(X)$.

4.5.12 Seja $g(x,y) = \cos(\sqrt{xy}\,)$, e considere a integral $I = \int_0^5 \int_0^4 g(x,y)\, dy\, dx$.

(a) Prove que $I = 20\, E[g(X,Y)]$, em que $X \sim$ Uniforme$[0,5]$ e $Y \sim$ Uniforme$[0,4]$.

(b) Use o item (a) para descrever um algoritmo de Monte Carlo para calcular aproximadamente I.

4.5.13 Considere a integral $J = \int_0^1 \int_0^\infty h(x,y)\, dy\, dx$, em que

$$h(x,y) = e^{-y^2} \cos(\sqrt{xy}\,).$$

(a) Prove que $J = E[e^Y h(X,Y)]$, em que $X \sim$ Uniforme$[0,1]$ e $Y \sim$ Exponencial(1).

(b) Use o item (a) para descrever um algoritmo de Monte Carlo para calcular aproximadamente J.

(c) Se $X \sim$ Uniforme$[0,1]$ e $Y \sim$ Exponencial(5), prove que

$$J = (1/5)\, E[e^{5Y} h(X,Y)].$$

(d) Use o item (c) para descrever um algoritmo de Monte Carlo para calcular aproximadamente J.

(e) Explique como você poderia usar um computador para determinar qual é melhor: o algoritmo do item (b) ou o algoritmo do item (d).

Exercícios computacionais

4.5.14 Use um algoritmo de Monte Carlo para aproximar $\int_0^1 \cos(x^3)\sin(x^4)\, dx$ com base numa amostra grande (tome $n = 10^5$, se possível). Avalie o erro da aproximação.

4.5.15 Use um algoritmo de Monte Carlo para aproximar $\int_0^\infty 25\cos(x^4)e^{-25x}\, dx$ com base numa amostra grande (tome $n = 10^5$, se possível). Avalie o erro da aproximação.

4.5.16 Use um algoritmo de Monte Carlo para aproximar $\sum_{j=0}^{\infty}(j^2+3)^{-5}5^{-j}$ com base numa amostra grande (tome $n = 10^5$, se possível). Avalie o erro da aproximação.

4.5.17 Suponha que $X \sim N(0,1)$. Use um algoritmo de Monte Carlo para aproximar $P(X^2 - 3X + 2 \geq 0)$ com base numa amostra grande (tome $n = 10^5$, se possível). Avalie o erro da aproximação.

Problemas

4.5.18 Suponha que $X_1, X_2, \ldots$ são i.i.d. Bernoulli(θ), em que θ é desconhecido. Determine uma cota inferior[37] para n tal que a probabilidade de a estimativa M_n estar a menos de δ do valor desconhecido de θ seja de cerca de 0,9974. Isso nos permite fazer simulações com alta confiança de que o erro da aproximação apresentada é menor que algum valor δ prescrito. (Sugestão: use o fato de que $x(1-x) \leq 1/4$ para todo $x \in [0,1]$.)

4.5.19 Suponha que $X_1, X_2, \ldots$ são i.i.d. com média μ desconhecida e variância σ^2 desconhecida. Suponha, porém, que sabemos que $\sigma^2 \leq \sigma_0^2$, em que σ_0^2 é um valor conhecido. Determine uma cota inferior para n tal que a probabilidade de a estimativa M_n estar a menos de δ do valor desconhecido de μ seja de cerca de 0,9974. Isso nos permite fazer simulações com alta confiança de que o erro da aproximação apresentada é menor que algum valor δ prescrito.

4.5.20 Suponha que $X_1, X_2, \ldots$ são i.i.d. com distribuição Uniforme$[0,\theta]$, em que θ é desconhecido, e considere $Z_n = n^{-1}(n+1)X_{(n)}$ como uma estimativa de θ (veja a Seção 2.8.4 sobre estatísticas de ordem[38]).

(a) Prove que $E(Z_n) = \theta$ e calcule $\mathrm{Var}(Z_n)$.

(b) Use a desigualdade de Chebyshev para mostrar que Z_n converge em probabilidade para θ.

(c) Mostre que $E(2M_n) = \theta$ e compare M_n e Z_n quanto à sua eficiência como estimadores de θ. Qual deles você usaria para estimar θ, e por quê?

4.5.21 (*Amostragem por importância*[39]) Suponha que queremos aproximar a integral $\int_a^b g(x)\,dx$, em que supomos que essa integral é finita. Seja f uma densidade no intervalo (a,b) tal que $f(x) > 0$ para todo $x \in (a,b)$ e tal que temos um algoritmo conveniente para gerar $X_1, X_2, \ldots$ i.i.d. com distribuição dada por f.

No original: *lower bound*[37], *order statistics*[38], *importance sampling*[39].

(a) Prove que

$$M_n(f) = \frac{1}{n}\sum_{i=1}^{n} \frac{g(X_i)}{f(X_i)} \xrightarrow{\text{q.c.}} \int_a^b g(x)\,dx.$$

(Chamamos f de *amostrador por importância*[40] e notamos que isso mostra que toda f que satisfaz as condições acima fornece um estimador consistente[41] $M_n(f)$ de $\int_a^b g(x)\,dx$.)

(b) Prove que

$$\text{Var}(M_n(f)) = \frac{1}{n}\left\{\int_a^b \frac{g^2(x)}{f(x)}\,dx - \left(\int_a^b g(x)\,dx\right)^2\right\}.$$

(c) Suponha que $g(x) = h(x)f(x)$, em que f é como descrita acima. Mostre que a amostragem por importância com relação a f leva ao estimador

$$M_n(f) = \frac{1}{n}\sum_{i=1}^{n} h(X_i).$$

(d) Mostre que, se existe c tal que $|g(x)| \leq cf(x)$ para todo $x \in (a, b)$, então $\text{Var}(M_n(f)) < \infty$.

(e) Determine o erro padrão de $M_n(f)$ e indique como você o usaria para avaliar o erro da aproximação $M_n(f)$ quando $\text{Var}(M_n(f)) < \infty$.

Problemas computacionais

4.5.22 Use um algoritmo de Monte Carlo para aproximar $P(X^3 + Y^3 \leq 3)$, em que $X \sim N(1, 2)$ é independente de $Y \sim \text{Gama}(1, 1)$, com base numa amostra grande (tome $n = 10^5$, se possível). Avalie o erro da aproximação. Quão grande n precisa ser para garantir que a estimativa esteja a menos de 0,01 do valor verdadeiro praticamente com certeza? (Sugestão: Problema 4.5.18.)

4.5.23 Use um algoritmo de Monte Carlo para aproximar $E(X^3 + Y^3)$, em que $X \sim N(1, 2)$ é independente de $Y \sim \text{Gama}(1, 1)$, com base numa amostra grande (tome $n = 10^5$, se possível). Avalie o erro da aproximação.

4.5.24 Para a integral do Exercício 4.5.3, compare a eficiência do algoritmo baseado na geração de valores de uma distribuição Exponencial(5) com a do algoritmo baseado na geração de valores de uma distribuição $N(0, 1/7)$.

No original: *importance sampler*[40], *consistent estimator*[41].

Desafios

4.5.25 (*Agulha de Buffon*) Suponha que você deixa cair uma agulha ao acaso sobre uma grande folha de papel pautado. Suponha que a distância entre as linhas é exatamente igual ao comprimento da agulha.

(a) Prove que a probabilidade de a agulha cair tocando uma linha é igual a $2/\pi$. (Sugestão: seja D a distância da extremidade mais alta da agulha até a linha logo abaixo dela, e seja A o ângulo que a agulha forma com essa linha. Quais são, então, as distribuições de D e de A? Sob que condições sobre D e A a agulha estará tocando uma linha?)

(b) Explique como esse experimento poderia ser usado para obter uma aproximação de Monte Carlo do valor de π.

4.5.26 (*Amostragem por importância ótima*) Considere a amostragem por importância como descrita no Problema 4.5.21.

(a) Prove que $\mathrm{Var}(M_n(f))$ é minimizada tomando

$$f(x) = |g(x)| \Big/ \int_a^b |g(x)|\,dx.$$

Calcule a variância mínima e mostre que ela é 0 quando $g(x) \geq 0$ para todo $x \in (a, b)$.

(b) Por que esse amostrador por importância ótimo em geral não é viável? (O amostrador por importância ótimo indica, porém, que, na busca por um amostrador por importância eficiente, procuramos uma f que seja grande quando $|g|$ é grande e pequena quando $|g|$ é pequeno.)

Tópicos para discussão

4.5.27 Uma integral como $\int_0^\infty x^2 \cos(x^2) e^{-x}\,dx$ pode ser calculada aproximadamente com um pacote de computador de integração numérica (por exemplo, usando a regra de Simpson). Quais são algumas vantagens e desvantagens de usar uma aproximação de Monte Carlo em vez de um pacote de integração numérica?

4.5.28 Realize o experimento de Monte Carlo da agulha de Buffon, descrito no Desafio 4.5.25, repetindo o experimento pelo menos 20 vezes. Apresente a estimativa de π assim obtida. Quão próxima ela está do valor verdadeiro de π? O que poderia ser feito para tornar a estimativa mais precisa?

4.6 Teoria da Distribuição Normal

Por causa do teorema central do limite (Teorema 4.4.3), a distribuição normal tem um papel extremamente importante na teoria estatística. Por isso, vamos considerar várias propriedades e distribuições importantes relacionadas à distribuição normal. Essas propriedades e distribuições serão muito importantes para a teoria estatística dos capítulos seguintes deste livro.

Já sabemos que, se $X_1 \sim N(\mu_1, \sigma_1^2)$ é independente de $X_2 \sim N(\mu_2, \sigma_2^2)$, então $cX_1 + d \sim N(c\mu_1 + d, c^2\sigma^2)$ (veja o Exercício 2.6.3)* e $X_1 + X_2 \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$ (veja o Problema 2.9.14). Combinando esses fatos e usando indução, obtemos o resultado a seguir.

Teorema 4.6.1

Suponha que $X_i \sim N(\mu_i, \sigma_i^2)$ para $i = 1, 2, \ldots, n$ e que essas variáveis aleatórias sejam independentes. Seja $Y = (\sum_i a_i X_i) + b$ para certas constantes $\{a_i\}$ e b. Então

$$Y \sim N\Big((\sum_i a_i\mu_i) + b,\ \sum_i a_i^2\sigma_i^2\Big).$$

Isso implica imediatamente o seguinte.

Corolário 4.6.1

Suponha que $X_i \sim N(\mu, \sigma^2)$ para $i = 1, 2, \ldots, n$ e que essas variáveis aleatórias sejam independentes. Se $\bar{X} = (X_1 + \cdots + X_n)/n$, então $\bar{X} \sim N(\mu, \sigma^2/n)$.

Uma propriedade mais sutil das distribuições normais é a seguinte.

Teorema 4.6.2

Suponha que $X_i \sim N(\mu_i, \sigma_i^2)$ para $i = 1, 2, \ldots, n$ e também que as $\{X_i\}$ sejam *independentes*. Sejam $U = \sum_{i=1}^n a_i X_i$ e $V = \sum_{i=1}^n b_i X_i$ para certas constantes $\{a_i\}$ e $\{b_i\}$. Então $\mathrm{Cov}(U, V) = \sum_i a_i b_i \sigma_i^2$. Além disso, $\mathrm{Cov}(U, V) = 0$ se e somente se U e V são independentes.

Demonstração. A fórmula de $\mathrm{Cov}(U, V)$ decorre imediatamente da linearidade

*Nota do tradutor. O original traz $c^2\sigma^2$; pela notação do trecho seria $c^2\sigma_1^2$.

da covariância[42] (Teorema 3.3.2), pois temos

$$\begin{aligned}\operatorname{Cov}(U,V) &= \operatorname{Cov}\Big(\sum_{i=1}^{n} a_i X_i,\ \sum_{j=1}^{n} b_j X_j\Big) = \sum_{i=1}^{n}\sum_{j=1}^{n} a_i b_j \operatorname{Cov}(X_i, X_j) \\ &= \sum_{i=1}^{n} a_i b_i \operatorname{Cov}(X_i, X_i) = \sum_{i=1}^{n} a_i b_i \operatorname{Var}(X_i) = \sum_{i=1}^{n} a_i b_i \sigma_i^2\end{aligned}$$

(observe que $\operatorname{Cov}(X_i, X_j) = 0$ para $i \neq j$, pela independência). Além disso, se U e V são independentes, então necessariamente $\operatorname{Cov}(U,V) = 0$, pelo Corolário 3.3.2.

Resta provar que, se $\operatorname{Cov}(U,V) = 0$, então U e V são independentes. Isso envolve uma mudança de variável[43] bidimensional, como discutido na Seção 2.9.2 (avançada); por isso, remetemos o leitor à Seção 4.7 para esta parte da demonstração. ■

O Teorema 4.6.2 diz que, no caso particular de combinações lineares de distribuições normais independentes, se $\operatorname{Cov}(U,V) = 0$, então U e V são independentes. No entanto, é importante lembrar que essa propriedade *não* vale em geral: existem variáveis aleatórias X e Y tais que $\operatorname{Cov}(X,Y) = 0$ mesmo que X e Y não sejam independentes (veja o Exemplo 3.3.10). Além disso, essa propriedade não vale nem mesmo para distribuições *normais* em geral (veja o Problema 4.6.13).

Observe que, usando álgebra linear, podemos escrever as equações $U = \sum_{i=1}^{n} a_i X_i$ e $V = \sum_{i=1}^{n} b_i X_i$ do Teorema 4.6.2 na forma matricial

$$\begin{pmatrix} U \\ V \end{pmatrix} = A \begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_n \end{pmatrix}, \tag{4.6.1}$$

em que

$$A = \begin{pmatrix} a_1 & a_2 & \dots & a_n \\ b_1 & b_2 & \dots & b_n \end{pmatrix}.$$

Além disso, as linhas de A são *ortogonais* se e somente se $\sum_i a_i b_i = 0$. Ora, no caso em que $\sigma_i = 1$ para todo i, temos $\operatorname{Cov}(U,V) = \sum_i a_i b_i$. Portanto, se $\sigma_i = 1$ para todo i, o Teorema 4.6.2 pode ser interpretado assim: se U e V são dados por (4.6.1), então U e V são independentes se e somente se as linhas de A são ortogonais. A álgebra linear é muito usada em tratamentos mais avançados dessas ideias.

No original: *covariance*[42], *change of variable*[43].

4.6.1 A Distribuição Qui-quadrado

Apresentamos agora outra distribuição, relacionada à distribuição normal.

Definição 4.6.1

A *distribuição qui-quadrado* com n graus de liberdade (ou qui-quadrado(n), ou $\chi^2(n)$) é a distribuição da variável aleatória

$$Z = X_1^2 + X_2^2 + \cdots + X_n^2,$$

em que $X_1, \ldots, X_n$ são i.i.d., cada uma com a distribuição normal padrão $N(0,1)$.

A maioria dos pacotes estatísticos tem rotinas prontas para calcular probabilidades da qui-quadrado (veja também a Tabela D.3 do Apêndice D).

Uma propriedade da distribuição qui-quadrado[44] é fácil.

Teorema 4.6.3

Se $Z \sim \chi^2(n)$, então $E(Z) = n$.

Demonstração. Escreva $Z = X_1^2 + X_2^2 + \cdots + X_n^2$, em que as $\{X_i\}$ são i.i.d. $\sim N(0,1)$. Então $E((X_i)^2) = 1$. Segue, pela linearidade, que $E(Z) = 1 + \cdots + 1 = n$. ■

A função densidade da distribuição qui-quadrado é um pouco mais difícil de obter. Começamos pelo caso $n = 1$.

Teorema 4.6.4

Seja $Z \sim \chi^2(1)$. Então

$$f_Z(z) = \frac{1}{\sqrt{2\pi z}} e^{-z/2} = \frac{(1/2)^{1/2}}{\Gamma(1/2)} z^{-1/2} e^{-z/2}$$

para $z > 0$, com $f_Z(z) = 0$ para $z < 0$. Isto é, $Z \sim \text{Gama}(1/2, 1/2)$ (usando $\Gamma(1/2) = \sqrt{\pi}$).

Demonstração. Como $Z \sim \chi^2(1)$, podemos escrever $Z = X^2$, em que $X \sim N(0,1)$.

No original: *chi-squared distribution*[44].

Calculamos então que, para $z > 0$,

$$\int_{-\infty}^{z} f_Z(s)\,ds = P(Z \le z) = P(X^2 \le z) = P(-\sqrt{z} \le X \le \sqrt{z}).$$

Mas, como $X \sim N(0,1)$ com função densidade $\phi(s) = (2\pi)^{-1/2} e^{-s^2/2}$, podemos reescrever[45] isso como

$$\int_{-\infty}^{z} f_Z(s)\,ds = \int_{-\sqrt{z}}^{\sqrt{z}} \phi(s)\,ds = \int_{-\infty}^{\sqrt{z}} \phi(s)\,ds - \int_{-\infty}^{-\sqrt{z}} \phi(s)\,ds.$$

Como isso vale para todo $z > 0$, podemos derivar em relação a z (usando o teorema fundamental do cálculo e a regra da cadeia) e obter

$$f_Z(z) = \frac{1}{2\sqrt{z}}\,\phi(\sqrt{z}) - \frac{-1}{2\sqrt{z}}\,\phi(-\sqrt{z}) = \frac{1}{\sqrt{z}}\,\phi(\sqrt{z}) = \frac{1}{\sqrt{2\pi z}}\,e^{-z/2},$$

como afirmado. ■

Na Figura 4.6.1, traçamos o gráfico da densidade $\chi^2(1)$. Observe que a densidade se torna infinita em 0.

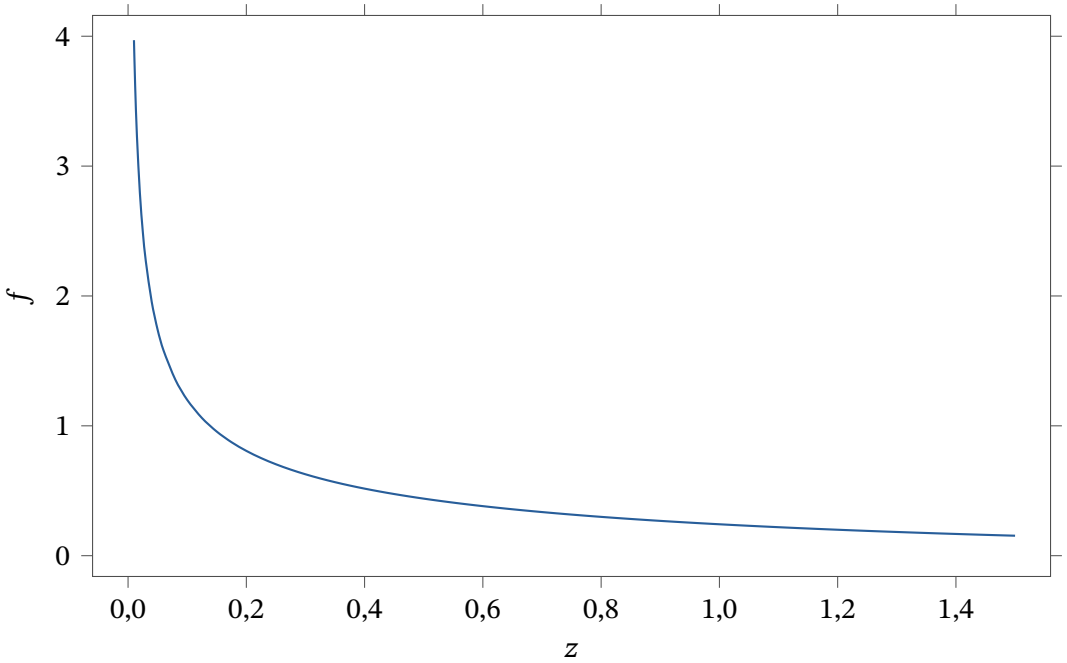


Figura 4.6.1: Gráfico da densidade $\chi^2(1)$.

No original: *plausibility*[45].

Teorema 4.6.5

Seja $Z \sim \chi^2(n)$. Então $Z \sim \text{Gama}(n/2, 1/2)$. Isto é,

$$f_Z(z) = \frac{1}{2^{n/2}\Gamma(n/2)} z^{(n/2)-1} e^{-z/2}$$

para $z > 0$, com $f_Z(z) = 0$ para $z < 0$.

Demonstração. Como $Z \sim \chi^2(n)$, podemos escrever $Z = X_1^2 + X_2^2 + \cdots + X_n^2$, em que as X_i são i.i.d. $N(0, 1)$. Mas isso significa que as X_i^2 são i.i.d. $\chi^2(1)$. Logo, pelo Teorema 4.6.4, as X_i^2 são i.i.d. Gama$(1/2, 1/2)$ para $i = 1, 2, \ldots, n$. Portanto, Z é a soma de n variáveis aleatórias independentes, cada uma com distribuição Gama$(1/2, 1/2)$.

Ora, pelo Apêndice C (veja o Problema 3.4.20), a função geradora de momentos de uma variável aleatória Gama(α, β) é dada por $m(s) = \beta^\alpha(\beta - s)^{-\alpha}$ para $s < \beta$. Tomando $\alpha = 1/2$ e $\beta = 1/2$ e aplicando o Teorema 3.4.5, a variável $Y = X_1^2 + X_2^2 + \cdots + X_n^2$ tem função geradora de momentos dada por

$$m_Y(s) = \prod_{i=1}^{n} m_{X_i^2}(s) = \prod_{i=1}^{n} \left(\frac{1}{2}\right)^{1/2} \left(\frac{1}{2} - s\right)^{-1/2} = \left(\frac{1}{2}\right)^{n/2} \left(\frac{1}{2} - s\right)^{-n/2}$$

para $s < 1/2$. Reconhecemos aí a função geradora de momentos da distribuição Gama$(n/2, 1/2)$. Portanto, pelo Teorema 3.4.6, temos $X_1^2 + X_2^2 + \cdots + X_n^2 \sim$ Gama$(n/2, 1/2)$, como afirmado.

Esse resultado também pode ser obtido usando o Problema 2.9.15 e indução. ■

Observe que a densidade $\chi^2(2)$ é igual à densidade Exponencial(2).* Na Figura 4.6.2, traçamos os gráficos de várias densidades χ^2. Observe que as χ^2 são assimétricas, com cauda longa à direita. À medida que os graus de liberdade[46] aumentam, a massa central de probabilidade se desloca para a direita.

Uma aplicação da distribuição qui-quadrado é a seguinte.

*Nota do tradutor. Com a parametrização do livro (densidade $\lambda e^{-\lambda x}$, Exemplo 2.4.5), a densidade $\chi^2(2)$, que é $\frac{1}{2}e^{-z/2}$, seria a Exponencial(1/2).

No original: *degrees of freedom*[46].

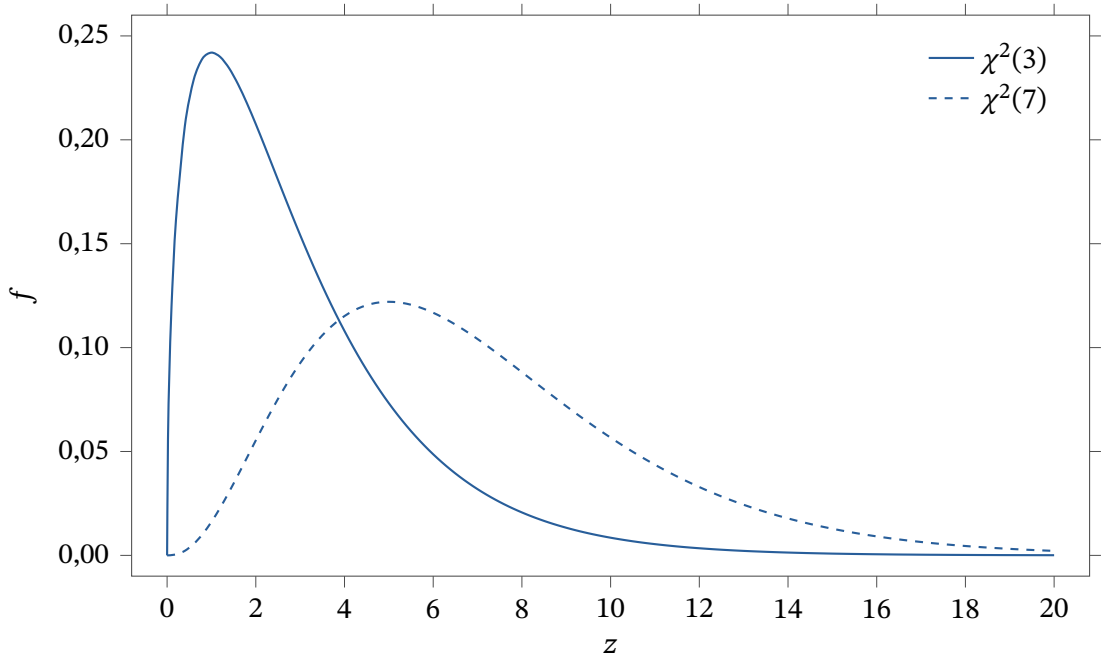


Figura 4.6.2: Gráfico das funções densidade $\chi^2(3)$ (linha cheia) e $\chi^2(7)$ (linha tracejada).

Teorema 4.6.6

Sejam $X_1, \ldots, X_n$ i.i.d. $N(\mu, \sigma^2)$. Tome

$$\bar{X} = \frac{1}{n}(X_1 + \cdots + X_n) \quad \text{e} \quad S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^2.$$

Então $(n-1)S^2/\sigma^2 \sim \chi^2(n-1)$ e, além disso, S^2 e $\bar{X}$ são independentes.

Demonstração. Veja a demonstração deste resultado na Seção 4.7. ■

Como a distribuição $\chi^2(n-1)$ tem média $n-1$, obtemos o seguinte.

Corolário 4.6.2

$E(S^2) = \sigma^2$.

Demonstração. Os Teoremas 4.6.6 e 4.6.3 implicam que $E((n-1)S^2/\sigma^2) = n-1$ e que $E(S^2) = \sigma^2$. ■

O Teorema 4.6.6 será muito usado no Capítulo 6. Por exemplo, esse resultado, junto com o Corolário 4.6.1, nos dá a distribuição amostral conjunta da média amostral $\bar{X}$ e da variância amostral S^2 quando amostramos de uma distribuição $N(\mu, \sigma^2)$. Se não conhecemos μ, então $\bar{X}$ é um estimador natural

dessa quantidade e, do mesmo modo, S^2 é um estimador natural de σ^2 quando ela é desconhecida. Curiosamente, dividimos por $n-1$ em S^2, e não por n, justamente porque queremos que $E(S^2) = \sigma^2$, como no Corolário 4.6.2. Na verdade, essa propriedade não depende de amostrarmos de uma distribuição normal. Pode-se mostrar que, sempre que $X_1, \ldots, X_n$ é uma amostra de uma distribuição com variância σ^2, temos $E(S^2) = \sigma^2$.

4.6.2 A Distribuição t

A distribuição t também tem muitas aplicações estatísticas.

Definição 4.6.2

A *distribuição* t com n graus de liberdade (ou Student(n), ou $t(n)$) é a distribuição da variável aleatória

$$Z = \frac{X}{\sqrt{(X_1^2 + X_2^2 + \cdots + X_n^2)/n}},$$

em que $X, X_1, \ldots, X_n$ são i.i.d., cada uma com a distribuição normal padrão $N(0,1)$. (De modo equivalente, $Z = X/\sqrt{Y/n}$, em que $Y \sim \chi^2(n)$.)

A maioria dos pacotes estatísticos tem rotinas prontas para calcular probabilidades da $t(n)$ (veja também a Tabela D.4 do Apêndice D).

A densidade da distribuição $t(n)$ é dada pelo resultado a seguir.

Teorema 4.6.7

Seja $U \sim t(n)$. Então

$$f_U(u) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{\pi}\,\Gamma\left(\frac{n}{2}\right)}\left(1 + \frac{u^2}{n}\right)^{-(n+1)/2}\frac{1}{\sqrt{n}}$$

para todo $u \in R^1$.

Demonstração. Para a demonstração deste resultado, veja a Seção 4.7. ■

O resultado a seguir mostra que, quando n é grande, a distribuição $t(n)$ é muito parecida com a distribuição $N(0,1)$.

Teorema 4.6.8

Quando $n \to \infty$, a distribuição $t(n)$ converge em distribuição para uma distribuição normal padrão.

Demonstração. Sejam $Z_1, \ldots, Z_n, Z$ i.i.d. $N(0,1)$. Quando $n \to \infty$, pela lei forte dos grandes números, $(Z_1^2 + \cdots + Z_n^2)/n$ converge com probabilidade 1 para a constante 1. Portanto, a distribuição de

$$\frac{Z}{\sqrt{(Z_1^2 + \cdots + Z_n^2)/n}} \tag{4.6.2}$$

converge para a distribuição de Z, que é a distribuição normal padrão[47]. Pela Definição 4.6.2, (4.6.2) tem distribuição $t(n)$. ■

Na Figura 4.6.3, traçamos os gráficos de várias densidades t. Observe que as densidades das distribuições t são simétricas em torno de 0 e parecidas com a densidade normal padrão.

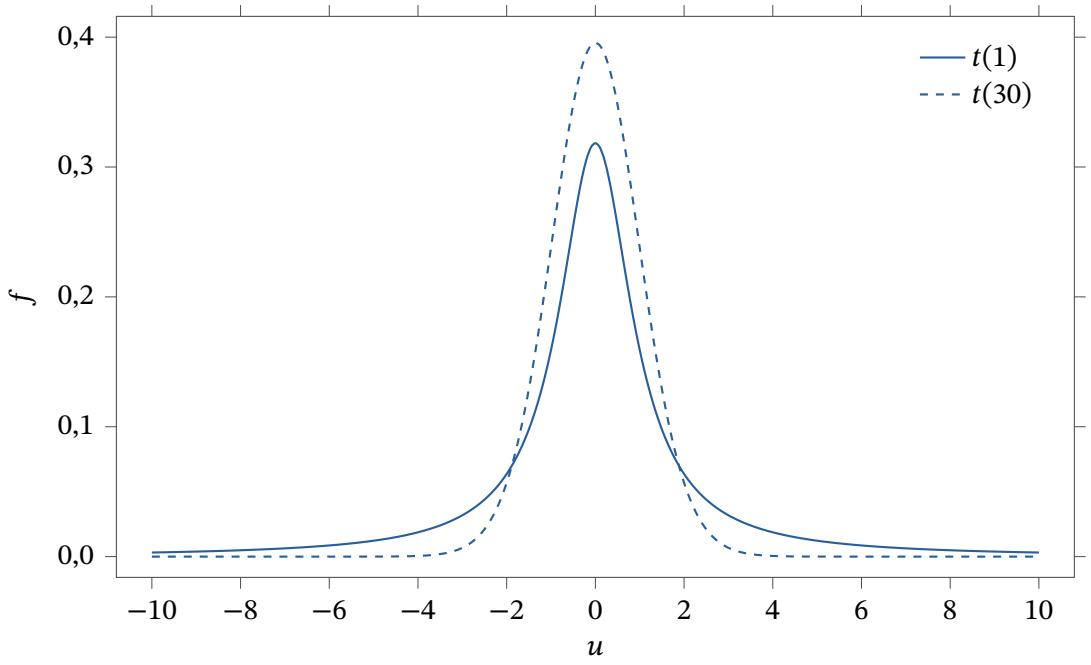


Figura 4.6.3: Gráfico das funções densidade $t(1)$ (linha cheia) e $t(30)$ (linha tracejada).

A distribuição $t(n)$ tem caudas mais longas que a distribuição $N(0,1)$. Por exemplo, a distribuição $t(1)$ (também conhecida como *distribuição de Cauchy*[48]) tem 0,9366 de sua probabilidade no intervalo $(-10, 10)$, ao passo que a

No original: *standard normal distribution*[47], *Cauchy*[48].

distribuição $N(0,1)$ tem ali toda a sua probabilidade (pelo menos até a quarta casa decimal). As densidades $t(30)$ e $N(0,1)$ são muito parecidas.

4.6.3 A Distribuição F

Por fim, consideramos a distribuição F.

Definição 4.6.3

A *distribuição* F com m e n graus de liberdade (ou $F(m,n)$) é a distribuição da variável aleatória

$$Z = \frac{(X_1^2 + X_2^2 + \cdots + X_m^2)/m}{(Y_1^2 + Y_2^2 + \cdots + Y_n^2)/n},$$

em que $X_1, \ldots, X_m, Y_1, \ldots, Y_n$ são i.i.d., cada uma com a distribuição normal padrão. (De modo equivalente, $Z = (X/m)/(Y/n)$, em que $X \sim \chi^2(m)$ e $Y \sim \chi^2(n)$.)

A maioria dos pacotes estatísticos tem rotinas prontas para calcular probabilidades da $F(m,n)$ (veja também a Tabela D.5 do Apêndice D).

A densidade da distribuição $F(m,n)$ é dada pelo resultado a seguir.

Teorema 4.6.9

Seja $U \sim F(m,n)$. Então

$$f_U(u) = \frac{\Gamma\left(\frac{m+n}{2}\right)}{\Gamma\left(\frac{m}{2}\right)\Gamma\left(\frac{n}{2}\right)}\left(\frac{m}{n}u\right)^{(m/2)-1}\left(1+\frac{m}{n}u\right)^{-(m+n)/2}\frac{m}{n}$$

para $u > 0$, com $f_U(u) = 0$ para $u < 0$.

Demonstração. Para a demonstração deste resultado, veja a Seção 4.7. ■

Na Figura 4.6.4, traçamos os gráficos de várias densidades $F(m,n)$. Observe que essas densidades são assimétricas, com cauda longa à direita.

Os resultados a seguir são úteis quando é preciso fazer contas com a distribuição $F(m,n)$.

*Nota do tradutor. No original, a linha cheia começa em cerca de 0,22 em $u = 0$ e fica cerca de cinco vezes abaixo da fórmula do Teorema 4.6.9, que para $m = 2$, $n = 1$ dá $f_U(u) = (1+2u)^{-3/2}$ (igual a 1 em $u = 0$). O gráfico aqui foi calculado pela fórmula.

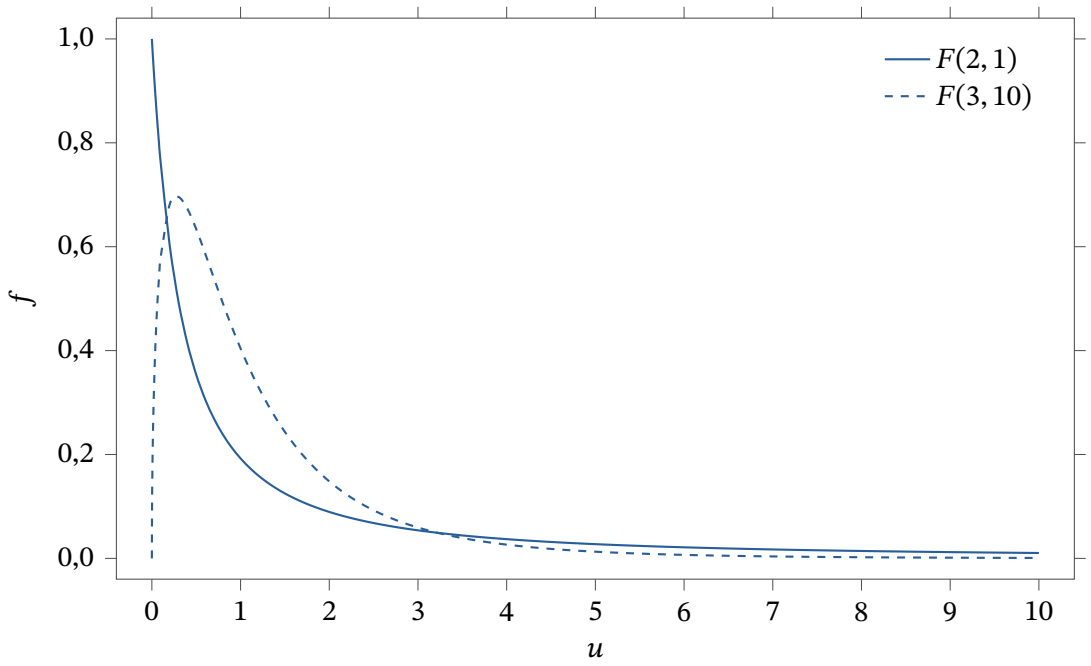


Figura 4.6.4: Gráfico das funções densidade $F(2,1)$ (linha cheia) e $F(3,10)$ (linha tracejada).*

Teorema 4.6.10

Se $Z \sim F(m,n)$, então $1/Z \sim F(n,m)$.

Demonstração. Usando a Definição 4.6.3, temos

$$\frac{1}{Z} = \frac{(Y_1^2 + Y_2^2 + \cdots + Y_n^2)/n}{(X_1^2 + X_2^2 + \cdots + X_m^2)/m},$$

e o resultado é imediato pela definição. ■

Portanto, se $Z \sim F(m,n)$, então $P(Z \leq z) = P(1/Z \geq 1/z) = 1 - P(1/Z \leq 1/z)$, e $P(1/Z \leq 1/z)$ é a fda da distribuição $F(n,m)$ calculada em $1/z$.

Em muitas aplicações estatísticas, n pode ser muito grande. O resultado a seguir dá, então, uma aproximação útil para esse caso.

Teorema 4.6.11

Se $Z_n \sim F(m,n)$, então mZ_n converge em distribuição para uma distribuição $\chi^2(m)$ quando $n \to \infty$.

Demonstração. Usando a Definição 4.6.3, temos

$$mZ = \frac{X_1^2 + X_2^2 + \cdots + X_m^2}{(Y_1^2 + Y_2^2 + \cdots + Y_n^2)/n}.$$

Pela Definição 4.6.1, $X_1^2 + \cdots + X_m^2 \sim \chi^2(m)$. Pelo Teorema 4.6.3, $E(Y_i^2) = 1$, de modo que a lei forte dos grandes números implica que $(Y_1^2 + Y_2^2 + \cdots + Y_n^2)/n$ converge quase certamente[49] para 1. Isso estabelece o resultado. ■

Por fim, as Definições 4.6.2 e 4.6.3 dão imediatamente o resultado a seguir.

Teorema 4.6.12

Se $Z \sim t(n)$, então $Z^2 \sim F(1, n)$.

Resumo da Seção 4.6

- Combinações lineares de variáveis aleatórias normais independentes também são normais, com média e variância apropriadas.
- Duas combinações lineares da *mesma* coleção de variáveis aleatórias normais independentes são independentes se e somente se sua covariância é igual a 0.
- A distribuição qui-quadrado com n graus de liberdade é a distribuição correspondente a uma soma de quadrados de n variáveis aleatórias normais padrão i.i.d. Ela tem média n e é igual à distribuição Gama$(n/2, 1/2)$.
- A distribuição t com n graus de liberdade é a distribuição correspondente a uma variável aleatória normal padrão dividida pela raiz quadrada de $1/n$ vezes uma variável aleatória qui-quadrado independente com n graus de liberdade. Sua função densidade foi apresentada. Quando $n \to \infty$, ela converge em distribuição para uma distribuição normal padrão.
- A distribuição F com m e n graus de liberdade é a distribuição correspondente a m/n vezes uma distribuição qui-quadrado com m graus de liberdade, dividida por uma distribuição qui-quadrado independente com n graus de liberdade. Sua função densidade foi apresentada. Se t tem distribuição $t(n)$, então t^2 tem distribuição $F(1, n)$.

No original: *almost surely*[49].

Exercícios

4.6.1 Sejam $X_1 \sim N(3, 2^2)$ e $X_2 \sim N(-8, 5^2)$ independentes. Sejam $U = X_1 - 5X_2$ e $V = -6X_1 + CX_2$, em que C é uma constante.

(a) Quais são as distribuições de U e V?

(b) Que valor de C torna U e V independentes?

4.6.2 Sejam $X \sim N(3, 5)$ e $Y \sim N(-7, 2)$ independentes.

(a) Qual é a distribuição de $Z = 4X - Y/3$?

(b) Qual é a covariância de X e Z?

4.6.3 Sejam $X \sim N(3, 5)$ e $Y \sim N(-7, 2)$ independentes. Encontre valores de $C_1 \neq 0$, C_2, $C_3 \neq 0$, C_4, C_5 tais que $C_1(X + C_2)^2 + C_3(Y + C_4)^2 \sim \chi^2(C_5)$.

4.6.4 Sejam $X \sim \chi^2(n)$ e $Y \sim N(0, 1)$ independentes. Prove que $X + Y^2 \sim \chi^2(n + 1)$.

4.6.5 Sejam $X \sim \chi^2(n)$ e $Y \sim \chi^2(m)$ independentes. Prove que $X + Y \sim \chi^2(n + m)$.

4.6.6 Sejam $X_1, X_2, \ldots, X_{4n}$ i.i.d. com distribuição $N(0, 1)$. Encontre um valor de C tal que

$$C \frac{X_1^2 + X_2^2 + \cdots + X_n^2}{X_{n+1}^2 + X_{n+2}^2 + \cdots + X_{4n}^2} \sim F(n, 3n).$$

4.6.7 Sejam $X_1, X_2, \ldots, X_{n+1}$ i.i.d. com distribuição $N(0, 1)$. Encontre um valor de C tal que

$$C \frac{X_1}{\sqrt{X_2^2 + \cdots + X_n^2 + X_{n+1}^2}} \sim t(n).$$

4.6.8 Sejam $X \sim N(3, 5)$ e $Y \sim N(-7, 2)$ independentes. Encontre valores de C_1, C_2, C_3, C_4, C_5, C_6 tais que

$$\frac{C_1(X + C_2)^{C_3}}{((Y + C_4)^2)^{C_5}} \sim t(C_6).$$

4.6.9 Sejam $X \sim N(3, 5)$ e $Y \sim N(-7, 2)$ independentes. Encontre valores de C_1, C_2, C_3, C_4, C_5, C_6, C_7 tais que

$$\frac{C_1(X + C_2)^{C_3}}{(Y + C_4)^{C_5}} \sim F(C_6, C_7).$$

4.6.10 Sejam $X_1, X_2, \ldots, X_{100}$ independentes, cada uma com a distribuição normal padrão.

(a) Calcule a distribuição de X_1^2.

(b) Calcule a distribuição de $X_3^2 + X_5^2$.

(c) Calcule a distribuição de $X_{10}\Big/\sqrt{[X_{20}^2 + X_{30}^2 + X_{40}^2]/3}$.

(d) Calcule a distribuição de $3X_{10}^2\big/[X_{20}^2 + X_{30}^2 + X_{40}^2]$.

(e) Calcule a distribuição de

$$\frac{30}{70}\,\frac{X_1^2 + X_2^2 + \cdots + X_{70}^2}{X_{71}^2 + X_{72}^2 + \cdots + X_{100}^2}.$$

4.6.11 Sejam $X_1, X_2, \ldots, X_{61}$ independentes, cada uma com distribuição $N(\mu, \sigma^2)$. Tome $\bar{X} = (1/61)(X_1 + X_2 + \cdots + X_{61})$ e

$$S^2 = \frac{1}{60}\Big[(X_1 - \bar{X})^2 + (X_2 - \bar{X})^2 + \cdots + (X_{61} - \bar{X})^2\Big]$$

como de costume.

(a) Para que valores de K e m a quantidade $Y \equiv K(\bar{X} - \mu)/\sqrt{S^2}$ tem distribuição t com m graus de liberdade?

(b) Com K como no item (a), encontre y tal que $P(Y \geq y) = 0{,}05$.

(c) Para que valores de a, b e c a quantidade $W \equiv a(\bar{X} - \mu)^2/S^2$ tem distribuição F com b e c graus de liberdade?

(d) Para esses valores de a, b e c, encontre uma quantidade w tal que $P(W \geq w) = 0{,}05$.

4.6.12 Suponha que a temperatura interna (em graus Celsius, sob uso intenso) do mais recente computador de mesa da Dell tenha distribuição normal com média 40 e desvio padrão 5, enquanto a do mais recente Compaq tem distribuição normal com média 45 e desvio padrão 8. Suponha que medimos a temperatura do Dell 20 vezes (em dias diferentes) e obtemos as medidas $D_1, D_2, \ldots, D_{20}$, e que medimos também a temperatura do Compaq 30 vezes e obtemos as medidas $C_1, C_2, \ldots, C_{30}$.

(a) Calcule a distribuição de $\bar{D} \equiv (D_1 + \cdots + D_{20})/20$.

(b) Calcule a distribuição de $\bar{C} \equiv (C_1 + \cdots + C_{30})/30$.

(c) Calcule a distribuição de $Z \equiv \bar{C} - \bar{D}$.

(d) Calcule $P(\bar{C} < \bar{D})$.

(e) Seja $U = (D_1 - \bar{D})^2 + (D_2 - \bar{D})^2 + \cdots + (D_{20} - \bar{D})^2$. Quanto vale $P(U > 633{,}25)$?

Problemas

4.6.13 Seja $X \sim N(0,1)$ e seja $P(Y = 1) = P(Y = -1) = 1/2$. Suponha que X e Y sejam independentes. Seja $Z = XY$.

(a) Prove que $Z \sim N(0,1)$.

(b) Prove que $\text{Cov}(X, Z) = 0$.

(c) Prove diretamente que X e Z *não* são independentes.

(d) Por que isso não contradiz o Teorema 4.6.2?

4.6.14 Seja $Z \sim t(n)$. Prove que $P(Z < -x) = P(Z > x)$ para $x \in R^1$, isto é, prove que a distribuição $t(n)$ é simétrica em torno de 0.

4.6.15 Seja $X_n \sim F(n, 2n)$ para $n = 1, 2, 3, \ldots$. Prove que $X_n \to 1$ em probabilidade e com probabilidade 1.

4.6.16 (*A distribuição qui-quadrado geral*) Prove que, para $\alpha > 0$, a função

$$f(z) = \frac{1}{2^{\alpha/2}\Gamma(\alpha/2)} z^{(\alpha/2)-1} e^{-z/2}$$

define uma distribuição de probabilidade em $(0, \infty)$. Essa distribuição é conhecida como distribuição $\chi^2(\alpha)$, isto é, ela generaliza a distribuição da Seção 4.6.2* ao permitir que o número de graus de liberdade seja um número real positivo qualquer. (Sugestão: a distribuição $\chi^2(\alpha)$ é igual a uma distribuição Gama$(\alpha/2, 1/2)$.)

4.6.17 (MV) (*A distribuição t geral*) Prove que, para $\alpha > 0$, a função

$$f(u) = \frac{\Gamma\left(\frac{\alpha+1}{2}\right)}{\sqrt{\pi}\,\Gamma\left(\frac{\alpha}{2}\right)} \left(1 + \frac{u^2}{\alpha}\right)^{-(\alpha+1)/2} \frac{1}{\sqrt{\alpha}}$$

define uma distribuição de probabilidade em $(-\infty, \infty)$, mostrando que a variável aleatória

$$U = \frac{X}{\sqrt{Y/\alpha}}$$

tem essa densidade quando $X \sim N(0,1)$ é independente de $Y \sim \chi^2(\alpha)$, como no Problema 4.6.16. Essa distribuição é conhecida como distribuição $t(\alpha)$, isto é, ela generaliza a distribuição da Seção 4.6.3† ao permitir que o número de graus de

*Nota do tradutor. A distribuição qui-quadrado é a da Seção 4.6.1; a 4.6.2 é a da distribuição t.

†Nota do tradutor. A distribuição t é a da Seção 4.6.2; a 4.6.3 é a da distribuição F.

liberdade seja um número real positivo qualquer. (Sugestão: a demonstração é praticamente idêntica à do Teorema 4.6.7.)

4.6.18 (MV) (*A distribuição F geral*) Prove que, para $\alpha > 0$, $\beta > 0$, a função

$$f(u) = \frac{\Gamma\left(\frac{\alpha+\beta}{2}\right)}{\Gamma\left(\frac{\alpha}{2}\right)\Gamma\left(\frac{\beta}{2}\right)}\left(\frac{\alpha}{\beta}u\right)^{(\alpha/2)-1}\left(1+\frac{\alpha}{\beta}u\right)^{-(\alpha+\beta)/2}\frac{\alpha}{\beta}$$

define uma distribuição de probabilidade em $(0, \infty)$, mostrando que a variável aleatória

$$U = \frac{X/\alpha}{Y/\beta}$$

tem essa densidade sempre que $X \sim \chi^2(\alpha)$ é independente de $Y \sim \chi^2(\beta)$, como no Problema 4.6.16. Essa distribuição é conhecida como distribuição $F(\alpha, \beta)$, isto é, ela generaliza a distribuição da Seção 4.6.4* ao permitir que os graus de liberdade do numerador e do denominador sejam números reais positivos quaisquer. (Sugestão: a demonstração é praticamente idêntica à do Teorema 4.6.9.)

4.6.19 Prove que, quando $X \sim t(\alpha)$, como definida no Problema 4.6.17, e $\alpha > 1$, então $E(X) = 0$. Prove ainda que, quando $\alpha > 2$, $\text{Var}(X) = \alpha/(\alpha - 2)$. Você pode supor que essas integrais existem — veja o Desafio 4.6.21. (Sugestão: para calcular o segundo momento, use $Y = X^2 \sim F(1, \alpha)$, como definida no Problema 4.6.18.)

4.6.20 Prove que, quando $X \sim F(\alpha, \beta)$, então $E(X) = \beta/(\beta - 2)$ quando $\beta > 2$ e $\text{Var}(X) = 2\beta^2(\alpha + \beta - 2)/\alpha(\beta - 2)^2(\beta - 4)$ quando $\beta > 4$.

Desafios

4.6.21 Seguindo o Problema 4.6.19, prove que a média de X não existe sempre que $0 < \alpha \leq 1$. Prove ainda que a variância de X não existe sempre que $0 < \alpha \leq 1$ e é infinita quando $1 < \alpha \leq 2$.

4.6.22 Prove a identidade (4.7.1) da Seção 4.7, que aparece como parte da demonstração do Teorema 4.6.6.

*Nota do tradutor. A distribuição F é a da Seção 4.6.3; não há Seção 4.6.4.

4.7 Demonstrações Adicionais (Avançado)

Demonstração do Teorema 4.3.1

Queremos provar o seguinte resultado. Sejam $Z, Z_1, Z_2, \ldots$ variáveis aleatórias. Suponha que $Z_n \to Z$ com probabilidade 1. Então $Z_n \to Z$ em probabilidade. Isto é, se uma sequência de variáveis aleatórias converge quase certamente, então ela converge em probabilidade para o mesmo limite.

Suponha que $P(Z_n \to Z) = 1$. Fixe $\epsilon > 0$ e seja $A_n = \{s : |Z_m - Z| \geq \epsilon \text{ para algum } m \geq n\}$. Então $\{A_n\}$ é uma sequência decrescente[50] de eventos. Além disso, se $s \in \bigcap_{n=1}^{\infty} A_n$, então $Z_n(s) \nrightarrow Z(s)$ quando $n \to \infty$. Logo,

$$P\left(\bigcap_{n=1}^{\infty} A_n\right) \leq P(Z_n \nrightarrow Z) = 0.$$

Pela continuidade das probabilidades, temos $\lim_{n\to\infty} P(A_n) = P\left(\bigcap_{n=1}^{\infty} A_n\right) = 0$. Logo, $P(|Z_n - Z| \geq \epsilon) \leq P(A_n) \to 0$ quando $n \to \infty$. Como isso vale para qualquer $\epsilon > 0$, vemos que $Z_n \to Z$ em probabilidade. ■

Demonstração do Teorema 4.4.1

Mostramos que, se $X_n \xrightarrow{P} X$, então $X_n \xrightarrow{D} X$.

Suponha que $X_n \to X$ em probabilidade e que $P(X = x) = 0$. Queremos mostrar que $\lim_{n\to\infty} P(X_n \leq x) = P(X \leq x)$.

Escolha qualquer $\epsilon > 0$. Ora, se $X_n \leq x$, então devemos ter $X \leq x + \epsilon$ ou $|X - X_n| \geq \epsilon$. Logo, pela subaditividade[51],

$$P(X_n \leq x) \leq P(X \leq x + \epsilon) + P(|X - X_n| \geq \epsilon).$$

Substituindo x por $x - \epsilon$ nessa equação, vemos também que

$$P(X \leq x - \epsilon) \leq P(X_n \leq x) + P(|X - X_n| \geq \epsilon).$$

Reorganizando e combinando essas duas desigualdades, temos

$$P(X \leq x - \epsilon) - P(|X - X_n| \geq \epsilon) \leq P(X_n \leq x) \leq P(X \leq x + \epsilon) + P(|X - X_n| \geq \epsilon).$$

Essa é a chave.

No original: *decreasing sequence*[50], *subadditivity*[51].

Em seguida, fazemos $n \to \infty$. Como $X_n \to X$ em probabilidade, sabemos que

$$\lim_{n\to\infty} P(|X - X_n| \geq \epsilon) = 0.$$

Isso significa que $\lim_{n\to\infty} P(X_n \leq x)$ fica "espremido" entre $P(X \leq x - \epsilon)$ e $P(X \leq x + \epsilon)$.

Fazemos então $\epsilon \searrow 0$. Pela continuidade das probabilidades,

$$\lim_{\epsilon\searrow 0} P(X \leq x + \epsilon) = P(X \leq x) \quad \text{e} \quad \lim_{\epsilon\searrow 0} P(X \leq x - \epsilon) = P(X < x).$$

Isso significa que $\lim_{n\to\infty} P(X_n \leq x)$ fica "espremido" entre $P(X < x)$ e $P(X \leq x)$.

Mas, como $P(X = x) = 0$, devemos ter $P(X < x) = P(X \leq x)$. Logo, $\lim_{n\to\infty} P(X_n \leq x) = P(X \leq x)$, como queríamos. ■

Demonstração do Teorema 4.4.3 (O teorema central do limite)

Precisamos provar o seguinte. Sejam $X_1, X_2, \ldots$ i.i.d. com média finita μ e variância finita σ^2. Seja $Z \sim N(0,1)$. Defina $S_n = X_1 + \cdots + X_n$ e

$$Z_n = \frac{S_n - n\mu}{\sqrt{n\sigma^2}}.$$

Então, quando $n \to \infty$, a sequência $\{Z_n\}$ converge em distribuição para a Z, isto é, $Z_n \xrightarrow{D} Z$.

Lembre que a distribuição normal padrão tem função geradora de momentos dada por $m_Z(s) = \exp(s^2/2)$.

Vamos agora *supor* que $m_{Z_n}(s)$ é finita para $|s| < s_0$, para algum $s_0 > 0$. (Essa suposição pode ser eliminada usando *funções características* em vez de funções geradoras de momentos.) Supondo isso, vamos provar que, para cada número real s, temos $\lim_{n\to\infty} m_{Z_n}(s) = m_Z(s)$, em que $m_{Z_n}(s)$ é a função geradora de momentos de Z_n. Segue então do Teorema 4.4.2 que Z_n converge para Z em distribuição.

Para prosseguir, seja $Y_i = (X_i - \mu)/\sigma$. Então $E(Y_i) = 0$ e $E(Y_i^2) = \text{Var}(Y_i) = 1$. Além disso, temos

$$Z_n = \frac{1}{\sqrt{n}}(Y_1 + \cdots + Y_n).$$

Seja $m_Y(s) = E(e^{sY_i})$ a função geradora de momentos de Y_i (que é a mesma para

todo i, já que elas são i.i.d.). Então, usando a independência, calculamos que

$$\begin{aligned}\lim_{n\to\infty} m_{Z_n}(s) &= \lim_{n\to\infty} E\left(e^{sZ_n}\right) = \lim_{n\to\infty} E\left(e^{s(Y_1+\cdots+Y_n)/\sqrt{n}}\right)\\ &= \lim_{n\to\infty} E\left(e^{sY_1/\sqrt{n}}\, e^{sY_2/\sqrt{n}} \cdots e^{sY_n/\sqrt{n}}\right)\\ &= \lim_{n\to\infty} E\left(e^{sY_1/\sqrt{n}}\right) E\left(e^{sY_2/\sqrt{n}}\right) \cdots E\left(e^{sY_n/\sqrt{n}}\right)\\ &= \lim_{n\to\infty} m_Y(s/\sqrt{n})\, m_Y(s/\sqrt{n}) \cdots m_Y(s/\sqrt{n})\\ &= \lim_{n\to\infty} m_Y(s/\sqrt{n})^n.\end{aligned}$$

Ora, sabemos do Teorema 3.5.3 que $m_Y(0) = E(e^0) = 1$.* Além disso, $m'_Y(0) = E(Y_i) = 0$ e $m''_Y(0) = E(Y_i^2) = 1$. Mas então, expandindo $m_Y(s)$ em série de Taylor[52] em torno de $s = 0$, vemos que

$$m_Y(s) = 1 + 0s + \frac{1}{2!}s^2 + o(s^2) = 1 + s^2/2 + o(s^2),$$

em que $o(s^2)$ representa uma quantidade que, quando $s \to 0$, vai a 0 mais depressa do que s^2 — isto é, $o(s^2)/s \to 0$ quando $s \to 0$.† Isso significa que

$$m_Y(s/\sqrt{n}) = 1 + (s/\sqrt{n})^2/2 + o\big((s/\sqrt{n})^2\big) = 1 + s^2/2n + o(1/n),$$

em que agora $o(1/n)$ representa uma quantidade que, quando $n \to \infty$, vai a 0 mais depressa do que $1/n$.

Por fim, lembramos do cálculo que, para qualquer número real c, $\lim_{n\to\infty}(1 + c/n)^n = e^c$. Segue disso e do que foi visto acima que‡

$$\lim_{n\to\infty}\big(m_Y(s/2\sqrt{n})\big)^n = \lim_{n\to\infty}(1 + s^2/2n)^n = e^{s^2/2}.$$

Isto é, $\lim_{n\to\infty} m_{Z_n}(s) = e^{s^2/2}$, como afirmado. ■

Demonstração do Teorema 4.6.2

Provamos o seguinte. Suponha que $X_i \sim N(\mu_i, \sigma_i^2)$ para $i = 1, 2, \ldots, n$ e também que as $\{X_i\}$ são independentes. Sejam $U = \sum_{i=1}^n a_i X_i$ e $V = \sum_{i=1}^n b_i X_i$, para

*Nota do tradutor. o original cita o Teorema 3.5.3 (sobre $E(g(Y)E(X \mid Y))$); pelo conteúdo, seria o Teorema 3.4.3, que dá $m_X(0) = 1$, $m'_X(0) = E(X)$ e $m''_X(0) = E(X^2)$.

†Nota do tradutor. o original traz $o(s^2)/s \to 0$; pela definição dada na própria frase, seria $o(s^2)/s^2 \to 0$.

‡Nota do tradutor. o original traz $m_Y(s/2\sqrt{n})$; pela conta anterior, seria $m_Y(s/\sqrt{n})$.

No original: *Taylor series*[52].

constantes $\{a_i\}$ e $\{b_i\}$ quaisquer. Então $\text{Cov}(U, V) = \sum_i a_i b_i \sigma_i^2$. Além disso, $\text{Cov}(U, V) = 0$ se e somente se U e V são independentes.

Foi provado na Seção 4.6 que $\text{Cov}(U, V) = \sum_i a_i b_i \sigma_i^2$ e que $\text{Cov}(U, V) = 0$ se U e V são independentes. Resta provar que, se $\text{Cov}(U, V) = 0$, então U e V são independentes. Por simplicidade, tomamos $n = 2$, $\mu_1 = \mu_2 = 0$ e $\sigma_1^2 = \sigma_2^2 = 1$; o caso geral é parecido, mas mais trabalhoso. Temos, portanto,

$$U = a_1 X_1 + a_2 X_2 \quad \text{e} \quad V = b_1 X_1 + b_2 X_2.$$

O jacobiano[53] dessa transformação é

$$J(x_1, x_2) = \frac{\partial U}{\partial X_1}\frac{\partial V}{\partial X_2} - \frac{\partial V}{\partial X_1}\frac{\partial U}{\partial X_2} = a_1 b_2 - b_1 a_2.$$

Invertendo a transformação, obtemos

$$X_1 = \frac{b_2 U - a_2 V}{a_1 b_2 - b_1 a_2} \quad \text{e} \quad X_2 = \frac{a_1 V - b_1 U}{a_1 b_2 - b_1 a_2}.$$

Além disso,

$$f_{X_1, X_2}(x_1, x_2) = \frac{1}{2\pi} e^{-\left(x_1^2 + x_2^2\right)/2}.$$

Logo, pelo teorema da mudança de variável multidimensional (Teorema 2.9.2), temos

$$\begin{aligned} f_{U,V}(u, v) &= f_{X_1, X_2}(x_1, x_2)\left(\frac{b_2 u - a_2 v}{a_1 b_2 - b_1 a_2}, \frac{a_1 v - b_1 u}{a_1 b_2 - b_1 a_2}\right) |J(x_1, x_2)|^{-1} \\ &= \frac{1}{2\pi} \frac{\exp\{-((b_2 u - a_2 v)^2 + (a_1 v - b_1 u)^2) \,/\, 2(a_1 b_2 - b_1 a_2)^2\}}{|a_1 b_2 - b_1 a_2|}. \end{aligned}$$

Mas

$$(b_2 u - a_2 v)^2 + (a_1 v - b_1 u)^2 = (b_1^2 + b_2^2) u^2 + (a_1^2 + a_2^2) v^2 - 2(a_1 b_1 + a_2 b_2) uv$$

e $\text{Cov}(U, V) = a_1 b_1 + a_2 b_2$. Logo, se $\text{Cov}(U, V) = 0$, então

$$(b_2 u - a_2 v)^2 + (a_1 v - b_1 u)^2 = (b_1^2 + b_2^2) u^2 + (a_1^2 + a_2^2) v^2$$

e

$$\begin{aligned} f_{U,V}(u, v) &= \frac{\exp\{-((b_1^2 + b_2^2) u^2 + (a_1^2 + a_2^2) v^2)/2(a_1 b_2 - b_1 a_2)^2\}}{2\pi\, |a_1 b_2 - b_1 a_2|} \\ &= \frac{\exp\{-(b_1^2 + b_2^2) u^2 / 2(a_1 b_2 - b_1 a_2)^2\} \exp\{-(a_1^2 + a_2^2) v^2 / 2(a_1 b_2 - b_1 a_2)^2\}}{2\pi\, |a_1 b_2 - b_1 a_2|}. \end{aligned}$$

No original: *Jacobian*[53].

Segue que podemos *fatorar* $f_{U,V}(u,v)$ como uma função de u vezes uma função de v. Mas isso implica (ver Problema 2.8.19) que U e V são independentes. ■

Demonstração do Teorema 4.6.6

Queremos provar que, quando $X_1, \ldots, X_n$ são i.i.d. $N(\mu, \sigma^2)$ e

$$\bar{X} = \frac{1}{n}(X_1 + \cdots + X_n) \quad \text{e} \quad S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^2,$$

então $(n-1)S^2/\sigma^2 \sim \chi^2(n-1)$ e, além disso, S^2 e $\bar{X}$ são independentes.

Temos

$$\frac{n-1}{\sigma^2}S^2 = \sum_{i=1}^{n}\left(\frac{X_i - \bar{X}}{\sigma}\right)^2.$$

Reescrevemos essa expressão como (ver Desafio 4.6.22)

$$\frac{n-1}{\sigma^2}S^2 = \left(\frac{X_1 - X_2}{\sigma\sqrt{2}}\right)^2 + \left(\frac{X_1 + X_2 - 2X_3}{\sigma\sqrt{2\cdot 3}}\right)^2 + \left(\frac{X_1 + X_2 + X_3 - 3X_4}{\sigma\sqrt{3\cdot 4}}\right)^2 + \cdots + \left(\frac{X_1 + X_2 + \cdots + X_{n-1} - (n-1)X_n}{\sigma\sqrt{(n-1)n}}\right)^2. \quad (4.7.1)$$

Ora, pelo Teorema 4.6.1, cada uma das $n-1$ expressões entre parênteses em (4.7.1) tem distribuição normal padrão. Além disso, pelo Teorema 4.6.2, as expressões entre parênteses em (4.7.1) são todas *independentes* umas das outras e também são todas independentes de $\bar{X}$.

Segue que $(n-1)S^2/\sigma^2$ é independente de $\bar{X}$. Segue também, pela definição da distribuição qui-quadrado, que $(n-1)S^2/\sigma^2 \sim \chi^2(n-1)$. ■

Demonstração do Teorema 4.6.7

Queremos mostrar que, quando $U \sim t(n)$, então

$$f_U(u) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{\pi}\,\Gamma\left(\frac{n}{2}\right)}\left(1 + \frac{u^2}{n}\right)^{-(n+1)/2}\frac{1}{\sqrt{n}}$$

para todo $u \in R^1$.

Como $U \sim t(n)$, podemos escrever $U = X/\sqrt{Y/n}$, em que X e Y são independentes, com $X \sim N(0,1)$ e $Y \sim \chi^2(n)$. Segue que X e Y têm densidade conjunta dada por

$$f_{X,Y}(x,y) = \frac{e^{-x^2/2}\,y^{(n/2)-1}e^{-y/2}}{\sqrt{2\pi}\,2^{n/2}\,\Gamma\left(\frac{n}{2}\right)}$$

quando $y > 0$ (com $f_{X,Y}(x,y) = 0$ para $y < 0$).

Seja $V = Y$. Vamos usar a fórmula de mudança de variável multivariada (Teorema 2.9.2) para calcular a densidade conjunta $f_{U,V}(u,v)$ de U e V. Como $U = X/\sqrt{Y/n}$ e $V = Y$, segue que $X = U\sqrt{V/n}$ e $Y = V$. Calculamos o termo jacobiano como*

$$J(x,y) = \det\begin{pmatrix} \frac{\partial u}{\partial x} & \frac{\partial v}{\partial x} \\ \frac{\partial u}{\partial y} & \frac{\partial v}{\partial y} \end{pmatrix} = \det\begin{pmatrix} \frac{1}{\sqrt{y/n}} & 0 \\ \frac{-x\sqrt{n}}{y^{3/2}} & 1 \end{pmatrix} = \frac{1}{\sqrt{y/n}}.$$

Logo,

$$\begin{aligned} f_{U,V}(u,v) &= f_{X,Y}\left(u\sqrt{\frac{v}{n}}, v\right) J^{-1}\left(u\sqrt{\frac{v}{n}}, v\right) \\ &= \frac{e^{-(u^2v)/2n}\, v^{(n/2)-1} e^{-v/2}}{\sqrt{2\pi}\, 2^{n/2}\, \Gamma\left(\frac{n}{2}\right)} \sqrt{\frac{v}{n}} \\ &= \frac{1}{\sqrt{\pi}\,\Gamma(n/2)} \frac{1}{2^{(n+1)/2}} \frac{1}{\sqrt{n}}\, v^{(n+1)/2-1} e^{-(v/2)(1+u^2/n)} \end{aligned}$$

para $v > 0$ (com $f_{U,V}(u,v) = 0$ para $v < 0$).

Por fim, calculamos a densidade marginal[54] de U:

$$\begin{aligned} f_U(u) &= \int_{-\infty}^{\infty} f_{U,V}(u,v)\, dv \\ &= \frac{1}{\sqrt{\pi}\,\Gamma(n/2)} \frac{1}{2^{(n+1)/2}} \frac{1}{\sqrt{n}} \int_0^{\infty} v^{(n+1)/2-1} e^{-(v/2)(1+u^2/n)}\, dv \\ &= \frac{1}{\sqrt{\pi}\,\Gamma(n/2)} \left(1 + \frac{u^2}{n}\right)^{-(n+1)/2} \frac{1}{\sqrt{n}} \int_0^{\infty} w^{(n+1)/2-1} e^{-w/2}\, dw \\ &= \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{\pi}\,\Gamma(n/2)} \left(1 + \frac{u^2}{n}\right)^{-(n+1)/2} \frac{1}{\sqrt{n}}, \end{aligned}$$

em que fizemos a substituição $w = \left(1 + u^2/n\right) v/2$ para obter a terceira igualdade e depois usamos a definição da função gama[55] para obter o resultado.† ■

*Nota do tradutor. o original traz $-x\sqrt{n}/y^{3/2}$; pela derivada de $x/\sqrt{y/n}$ em y, seria $-x\sqrt{n}/(2y^{3/2})$. O determinante não muda.

†Nota do tradutor. na terceira linha o original traz $e^{-w/2}$; com a substituição $w = (1 + u^2/n)v/2$, seria e^{-w}, o que dá o resultado final.

No original: *marginal density*[54], *gamma function*[55].

Demonstração do Teorema 4.6.9

Queremos mostrar que, quando $U \sim F(m, n)$, então

$$f_U(u) = \frac{\Gamma\left(\frac{m+n}{2}\right)}{\Gamma\left(\frac{m}{2}\right)\Gamma\left(\frac{n}{2}\right)} \left(\frac{m}{n}u\right)^{(m/2)-1} \left(1 + \frac{m}{n}u\right)^{-(m+n)/2} \frac{m}{n}$$

para $u > 0$, com $f_U(u) = 0$ para $u < 0$.

Como $U \sim F(n, m)$, podemos escrever $U = (X/m)/(Y/n)$, em que X e Y são independentes, com $X \sim \chi^2(m)$ e $Y \sim \chi^2(n)$.* Segue que X e Y têm densidade conjunta dada por

$$f_{X,Y}(x, y) = \frac{x^{(m/2)-1} e^{-x/2}\, y^{(n/2)-1} e^{-y/2}}{2^{m/2}\,\Gamma\left(\frac{m}{2}\right) 2^{n/2}\,\Gamma\left(\frac{n}{2}\right)}$$

quando $x, y > 0$ (com $f_{X,Y}(x, y) = 0$ para $x < 0$ ou $y < 0$).

Seja $V = Y$, e usemos a fórmula de mudança de variável multivariada (Teorema 2.9.2) para calcular a densidade conjunta $f_{U,V}(u, v)$ de U e V. Como $U = (X/m)/(Y/n)$ e $V = Y$, segue que $X = (m/n)UV$ e $Y = V$. Calculamos o termo jacobiano como

$$J(x, y) = \det\begin{pmatrix} \frac{\partial u}{\partial x} & \frac{\partial v}{\partial x} \\ \frac{\partial u}{\partial y} & \frac{\partial v}{\partial y} \end{pmatrix} = \det\begin{pmatrix} \frac{n}{my} & 0 \\ \frac{-nX}{mY^2} & 1 \end{pmatrix} = \frac{n}{my}.$$

Logo,

$$\begin{aligned} f_{U,V}(u, v) &= f_{X,Y}\big((m/n)uv, v\big) J^{-1}\big((m/n)uv, v\big) \\ &= \frac{\left(\frac{m}{n}uv\right)^{(m/2)-1} e^{-(m/n)(uv/2)}\, v^{(n/2)-1} e^{-(v/2)}}{2^{m/2}\,\Gamma\left(\frac{m}{2}\right) 2^{n/2}\,\Gamma\left(\frac{n}{2}\right)} \frac{m}{n} v \\ &= \frac{1}{\Gamma\left(\frac{m}{2}\right)\Gamma\left(\frac{n}{2}\right)} \left(\frac{m}{n}u\right)^{(m/2)-1} \frac{m}{n} \frac{1}{2^{(m+n)/2}}\, v^{(m+n)/2-1} e^{-(v/2)(1+mu/n)} \end{aligned}$$

para $u, v > 0$ (com $f_{U,V}(u, v) = 0$ para $u < 0$ ou $v < 0$).

*Nota do tradutor. o original traz $U \sim F(n, m)$; pelo enunciado e pela representação $U = (X/m)/(Y/n)$, seria $F(m, n)$.

Por fim, calculamos a densidade marginal de U como

$$\begin{aligned}
&f_U(u) \\
&= \int_{-\infty}^{\infty} f_{U,V}(u,v)\,dv \\
&= \frac{1}{\Gamma\left(\frac{m}{2}\right)\Gamma\left(\frac{n}{2}\right)}\left(\frac{m}{n}u\right)^{(m/2)-1}\frac{m}{n}\,\frac{1}{2^{(m+n)/2}}\int_0^{\infty} v^{(m+n)/2-1}e^{-(v/2)(1+mu/n)}\,dv \\
&= \frac{1}{\Gamma\left(\frac{m}{2}\right)\Gamma\left(\frac{n}{2}\right)}\left(\frac{m}{n}u\right)^{(m/2)-1}\left(1+\frac{m}{n}u\right)^{-(n+m)/2}\frac{m}{n}\int_0^{\infty} w^{(m+n)/2-1}e^{-w}\,dw \\
&= \frac{\Gamma\left(\frac{m+n}{2}\right)}{\Gamma\left(\frac{m}{2}\right)\Gamma\left(\frac{n}{2}\right)}\left(\frac{m}{n}u\right)^{(m/2)-1}\left(1+\frac{m}{n}u\right)^{-(n+m)/2}\frac{m}{n},
\end{aligned}$$

em que usamos a substituição $w = (1 + mu/n)\,v/2$ para obter a terceira igualdade, e o resultado final segue da definição da função gama. ■

CAPÍTULO 5

Inferência Estatística

ESBOÇO DO CAPÍTULO

Seção 1 Por Que Precisamos da Estatística?
Seção 2 Inferência Usando um Modelo de Probabilidade
Seção 3 Modelos Estatísticos
Seção 4 Coleta de Dados
Seção 5 Algumas Inferências Básicas

Neste capítulo, começamos nossa discussão da inferência estatística. A teoria da probabilidade se ocupa principalmente de calcular diversas quantidades associadas a um modelo de probabilidade[1]. Isso exige que *saibamos* qual é o modelo de probabilidade correto. Nas aplicações, muitas vezes não é esse o caso, e o melhor que podemos dizer é que a medida de probabilidade[2] correta a ser usada está num conjunto de medidas de probabilidade possíveis. Chamamos essa coleção de *modelo estatístico*. Assim, num certo sentido, nossa incerteza aumentou: não temos apenas a incerteza associada a um resultado ou resposta, tal como descrita por uma medida de probabilidade, mas agora também estamos incertos sobre qual é a medida de probabilidade.

A inferência estatística se ocupa de fazer afirmações, ou inferências, sobre características da verdadeira medida de probabilidade subjacente. É claro que essas inferências precisam se basear em algum tipo de informação; o modelo estatístico constitui parte dela. Outra parte importante da informação será dada por um resultado ou resposta observada, que chamamos de *dados*. As inferências tomam então a forma de diversas afirmações sobre a verdadeira medida de probabilidade subjacente da qual os dados foram obtidos. Elas assumem formas variadas, que chamamos de *tipos de inferência*.

O papel deste capítulo é apresentar os conceitos e as ideias básicas da inferência estatística. As abordagens mais importantes da inferência são discutidas nos Capítulos 6, 7 e 8. Os métodos de verossimilhança[3], como descrito no Capítulo 6, são os que exigem menos estrutura. Os métodos bayesianos, discutidos no Capítulo 7, exigem alguns ingredientes adicionais. Os

No original: *probability model*[1], *probability measure*[2], *likelihood*[3].

métodos de inferência baseados em medidas de desempenho e em funções de perda são descritos no Capítulo 8.

5.1 Por Que Precisamos da Estatística?

Embora passemos boa parte do nosso tempo discutindo a teoria da estatística, devemos sempre lembrar que a estatística é uma disciplina aplicada. Com isso queremos dizer que, em última análise, a teoria estatística será aplicada a situações do mundo real para responder a perguntas de importância prática.

O que caracteriza os contextos em que os métodos estatísticos são úteis? Talvez a melhor maneira de responder a isso seja considerar um exemplo prático em que a metodologia estatística desempenha um papel importante.

Exemplo 5.1.1 — Estudo de Transplante Cardíaco de Stanford

No artigo de Turnbull, Brown e Hu intitulado "Survivorship of Heart Transplant Data" (*Journal of the American Statistical Association*, março de 1974, volume 69, 74–80), é feita uma análise para determinar se um programa de transplante cardíaco, instituído na Universidade Stanford, está de fato produzindo o resultado pretendido. Neste caso, o resultado pretendido é um aumento do tempo de vida, isto é, um paciente que recebe um coração novo deveria viver mais do que se não tivesse recebido um coração novo.

É evidentemente importante garantir que um tratamento médico proposto para uma doença leve a uma melhora do quadro. Claramente, não gostaríamos que ele levasse a uma piora do quadro. Além disso, se produzisse apenas uma pequena melhora, talvez não valesse a pena aplicá-lo, caso fosse muito caro ou causasse sofrimento adicional.

Nunca podemos saber se um determinado paciente que recebeu um coração novo viveu mais *por causa* do transplante. Assim, nossa única esperança de determinar se o tratamento está funcionando é comparar os tempos de vida dos pacientes que receberam corações novos com os tempos de vida dos pacientes que não receberam. Há muitos fatores que influenciam o tempo de vida de um paciente, e muitos deles não terão nada a ver com o estado do coração do paciente. Por exemplo, o estilo de vida e a existência de outras doenças, que variam muito de paciente para paciente, terão grande influência. Então, como podemos fazer essa comparação?

Uma abordagem para esse problema é imaginar que existem distribuições de probabilidade que descrevem os tempos de vida dos dois grupos. Sejam elas dadas pelas densidades f_T e f_C, em que T indica transplante e C indica ausência de transplante. Aqui usamos C como rótulo porque esse grupo serve como *controle* no estudo, fornecendo uma comparação com o tratamento (um transplante cardíaco). Consideramos então o tempo de vida de um paciente que recebeu um transplante como uma observação aleatória de f_T, e o tempo de vida de um paciente que não recebeu um transplante como uma observação aleatória de f_C. Queremos comparar f_T e f_C, de alguma maneira, para determinar se o tratamento com transplante está funcionando. Por exemplo, poderíamos calcular o tempo de vida médio de cada distribuição e compará-los. Se o tempo de vida médio de f_T for maior que o de f_C, podemos afirmar que o tratamento está funcionando. É claro que ainda teríamos de julgar se o tamanho da melhora basta para justificar o gasto adicional e o sofrimento dos pacientes.

Se pudéssemos tomar um número arbitrariamente grande de observações de f_T e de f_C, sabemos, pelos resultados dos capítulos anteriores, que poderíamos determinar essas distribuições com bastante precisão. Na prática, porém, ficamos restritos a um número relativamente pequeno de observações. Por exemplo, no estudo citado havia 30 pacientes no grupo de controle (os que não receberam transplante) e 52 pacientes no grupo de tratamento (os que receberam transplante).

Para cada paciente do grupo de controle, registrou-se o valor de X — o número de dias em que ele esteve vivo desde a data em que foi considerado candidato a um transplante cardíaco até a data de encerramento do estudo. Por diversos motivos, esses pacientes não receberam corações novos; por exemplo, morreram antes que se pudesse encontrar um coração novo para eles. Esses dados, junto com um indicador da situação do paciente na data de encerramento do estudo, são apresentados na Tabela 5.1. O valor do indicador $S = a$ indica que o paciente estava vivo no fim do estudo, e $S = d$ indica que o paciente estava morto.

Para cada paciente do grupo de tratamento, registraram-se o valor de Y, o número de dias que ele esperou pelo transplante desde a data em que foi considerado candidato a um transplante cardíaco, e o valor de Z, o número de dias em que esteve vivo desde a data em que recebeu o transplante cardíaco até a data de encerramento do estudo. Os tempos de sobrevivência do grupo de tratamento são então dados pelos valores de

$Y + Z$. Esses dados, junto com um indicador da situação do paciente na data de encerramento do estudo, são apresentados na Tabela 5.2.

Não podemos comparar f_T e f_C diretamente, porque não conhecemos essas distribuições. Mas temos alguma informação sobre elas, porque obtivemos valores de cada uma, como apresentado nas Tabelas 5.1 e 5.2. Então, como usamos esses dados para comparar f_T e f_C e responder à questão de importância central, isto é, se o tratamento é eficaz? Esse é o domínio da estatística e da teoria estatística, a saber, fornecer métodos para fazer inferências sobre distribuições de probabilidade desconhecidas com base em observações (amostras) obtidas delas.

Observamos que simplificamos um pouco este exemplo, embora nossa discussão apresente a essência do problema. A complexidade adicional vem do fato de que, em geral, os estatísticos terão à disposição dados adicionais sobre cada paciente, como idade, sexo e histórico de doenças. Como um exemplo particular disso, na Tabela 5.2 temos os valores tanto de Y quanto de Z para cada paciente do grupo de tratamento. Acontece que essa informação adicional, conhecida como covariáveis, pode ser usada para tornar nossas comparações mais precisas. Isso será discutido no Capítulo 10. ■

P	X	S	P	X	S	P	X	S
1	49	d	11	1400	a	21	2	d
2	5	d	12	5	d	22	148	d
3	17	d	13	34	d	23	1	d
4	2	d	14	15	d	24	68	d
5	39	d	15	11	d	25	31	d
6	84	d	16	2	d	26	1	d
7	7	d	17	1	d	27	20	d
8	0	d	18	39	d	28	118	a
9	35	d	19	8	d	29	91	a
10	36	d	20	101	d	30	427	a

Tabela 5.1: Tempos de sobrevivência (X) em dias e situação (S) no fim do estudo de cada paciente (P) do grupo de controle.

P	Y	Z	S	P	Y	Z	S	P	Y	Z	S
1	0	15	d	19	50	1140	a	37	77	442	a
2	35	3	d	20	22	1153	a	38	2	65	d
3	50	624	d	21	45	54	d	39	26	419	a
4	11	46	d	22	18	47	d	40	32	362	a
5	25	127	d	23	4	0	d	41	13	64	d
6	16	61	d	24	1	43	d	42	56	228	d
7	36	1350	d	25	40	971	a	43	2	65	d
8	27	312	d	26	57	868	a	44	9	264	a
9	19	24	d	27	0	44	d	45	4	25	d
10	17	10	d	28	1	780	a	46	30	193	a
11	7	1024	d	29	20	51	d	47	3	196	a
12	11	39	d	30	35	710	a	48	26	63	d
13	2	730	d	31	82	663	a	49	4	12	d
14	82	136	d	32	31	253	d	50	45	103	a
15	24	1379	a	33	40	147	d	51	25	60	a
16	70	1	d	34	9	51	d	52	5	43	a
17	15	836	d	35	66	479	a				
18	16	60	d	36	20	322	d				

Tabela 5.2: Número de dias até o transplante (Y), tempos de sobrevivência em dias após o transplante (Z) e situação (S) no fim do estudo de cada paciente (P) do grupo de tratamento.

O exemplo anterior fornece alguma evidência de que questões de grande importância prática exigem o uso do pensamento e da metodologia estatísticos. Há muitas situações nas ciências físicas e sociais em que a estatística desempenha um papel fundamental, e os motivos são exatamente como os encontrados no Exemplo 5.1.1. O ingrediente central em todas elas é que nos deparamos com incerteza. Essa incerteza é causada tanto pela variação, que pode ser modelada por meio da probabilidade, quanto pelo fato de não podermos coletar observações suficientes para conhecer com precisão os modelos de probabilidade corretos. Os quatro primeiros capítulos trataram da construção e do uso de um modelo matemático para lidar com a primeira fonte de incerteza. Neste capítulo, começamos a discutir métodos para lidar com a segunda fonte de incerteza.

Resumo da Seção 5.1

- A estatística é aplicada a situações em que temos perguntas que não podem ser respondidas de forma definitiva, em geral por causa da variação nos dados.
- A probabilidade é usada para modelar a variação observada nos dados. A inferência estatística se ocupa de usar os dados observados para ajudar a identificar a verdadeira distribuição de probabilidade (ou as verdadeiras distribuições) que produz essa variação e, assim, compreender melhor as respostas às perguntas de interesse.

Exercícios

5.1.1 Calcule os tempos médios de sobrevivência do grupo de controle e do grupo de tratamento[4] no Exemplo 5.1.1. O que você conclui a partir desses números? Você acha válido basear suas conclusões sobre a eficácia do tratamento nesses números? Explique por quê.

5.1.2 Há observações atípicas nos dados apresentados no Exemplo 5.1.1? Em caso afirmativo, que efeito você acha que essas observações têm sobre os tempos médios de sobrevivência calculados no Exercício 5.1.1?

5.1.3 No Exemplo 5.1.1, podemos usar a variável de situação S como covariável. Qual é o significado prático dessa variável?

5.1.4 Um estudante está incerto sobre a nota que vai receber numa disciplina de estatística. O professor da disciplina disponibilizou um banco de dados com as notas da disciplina ao longo de vários anos. Você consegue identificar uma distribuição de probabilidade que possa ser relevante para quantificar a incerteza do estudante? Que covariáveis poderiam ser relevantes nessa situação?

5.1.5 Os dados a seguir foram gerados por um estudante a partir de uma distribuição $N(\mu, 1)$. Infelizmente, o estudante esqueceu qual valor de μ foi usado, de modo que estamos incertos sobre a distribuição de probabilidade correta a ser usada para descrever a variação nos dados.

0,2	−0,7	0,0	−1,9	0,7	−0,3	0,3	0,4
0,3	−0,8	1,5	0,1	0,3	−0,7	−1,8	0,2

No original: *treatment*[4].

Você consegue sugerir um valor plausível para μ? Explique seu raciocínio.

5.1.6 Suponha que você queira determinar a idade média de todos os alunos do sexo masculino de uma determinada faculdade. A secretaria acadêmica da faculdade lhe dá acesso a um banco de dados que lista a idade de cada aluno da faculdade. Descreva como você poderia responder à sua pergunta. Esse é um problema estatístico, no sentido de que você está incerto sobre alguma coisa e, portanto, precisará usar metodologia estatística?

5.1.7 Suponha que lhe digam que uma característica X segue uma distribuição $N(\mu_1, 1)$ e uma característica Y segue uma distribuição $N(\mu_2, 1)$, em que μ_1 e μ_2 são desconhecidos. Além disso, você recebe os resultados $x_1, \dots, x_m$ de m medições independentes de X e $y_1, \dots, y_n$ de n medições independentes de Y. Sugira um método para determinar se μ_1 e μ_2 são iguais. Você consegue pensar em algum problema na sua abordagem?

5.1.8 Suponha que saibamos que uma característica X segue uma distribuição Exponencial(λ) e que lhe peçam para determinar λ com base em observações i.i.d. $x_1, \dots, x_n$ dessa distribuição. Sugira um método para fazer isso. Você consegue pensar em algum problema na sua abordagem?

Problemas

5.1.9 Você consegue identificar algum problema potencial no método que discutimos no Exemplo 5.1.1 para determinar se o programa de transplante cardíaco é eficaz em prolongar a vida?

5.1.10 Suponha que você consiga gerar amostras de qualquer tamanho de uma distribuição de probabilidade P para a qual é muito difícil calcular $P(C)$ para algum conjunto C. Explique como você poderia estimar $P(C)$ com base numa amostra. Que papel o tamanho da amostra[5] desempenha na sua incerteza sobre a qualidade da sua aproximação? O tamanho de $P(C)$ tem algum papel nisso?

Problemas computacionais

5.1.11 Suponha que queiramos obter a distribuição da quantidade $Y = X^4 + 2X^3 - 3$ quando $X \sim N(0, 1)$. Aqui nos deparamos com uma forma de

No original: *sample size*[5].

incerteza matemática, porque é muito difícil determinar a distribuição de Y por métodos matemáticos. Proponha um método computacional para aproximar a função de distribuição de Y e estimar $P(Y \in (1, 2))$. Qual é a relevância da metodologia estatística para a sua abordagem?

Tópicos para discussão

5.1.12 Às vezes se afirma que todas as incertezas podem e devem ser modeladas por meio da probabilidade. Discuta essa questão no contexto do Exemplo 5.1.1, isto é, indique todas as coisas sobre as quais você está incerto neste exemplo e como você poderia propor distribuições de probabilidade para quantificar essas incertezas.

5.2 Inferência Usando um Modelo de Probabilidade

Nos quatro primeiros capítulos, discutimos a teoria da probabilidade, e boa parte dessa discussão envolveu a matemática da teoria da probabilidade. É ela que nos diz como fazer os vários cálculos associados à aplicação da teoria. É importante ter em mente, porém, os motivos pelos quais introduzimos a probabilidade em primeiro lugar. Como discutimos na Seção 1.1, a probabilidade trata de medir ou quantificar a incerteza.

É claro que temos incerteza sobre muitas coisas, e não podemos afirmar que a probabilidade se aplica a todas essas situações. Vamos supor, porém, que estamos numa situação em que achamos que a probabilidade se aplica e que temos uma medida de probabilidade P definida numa coleção de subconjuntos de um espaço amostral[6] S para uma resposta s.

Numa aplicação da probabilidade, supomos que conhecemos P e temos incerteza sobre um valor de resposta $s \in S$ futuro, ou oculto. Nesse contexto, podemos precisar, ou querer, fazer uma *inferência* sobre o valor desconhecido de s. Isso pode tomar a forma de uma *predição*[7] ou *estimativa*[8] de um valor plausível para s; por exemplo, sob condições adequadas, poderíamos tomar o valor esperado[9] de s como nossa predição. Em outros contextos, podem nos pedir que construamos um subconjunto que tenha alta probabilidade de conter

No original: *sample space*[6], *prediction*[7], *estimate*[8], *expected value*[9].

s e que seja, em algum sentido, pequeno; por exemplo, encontrar a região que contém pelo menos 95% da probabilidade e que tem o menor tamanho entre todas essas regiões. Ou então podem nos pedir que avaliemos se um valor dado s_0 é ou não um valor implausível segundo a P conhecida; por exemplo, avaliar se s_0 está ou não numa região a que P atribui baixa probabilidade e, portanto, é implausível. Esses são exemplos de inferências relevantes para as aplicações da teoria da probabilidade.

Exemplo 5.2.1

Como aplicação específica, considere o tempo de vida X, em anos, de uma máquina, em que se sabe que $X \sim$ Exponencial(1) (ver Figura 5.2.1). Então, para uma máquina nova, poderíamos predizer seu tempo de vida por $E(X) = 1$ ano. Além disso, pelo gráfico da densidade Exponencial(1), fica claro que o menor intervalo que contém 95% da probabilidade para X é $(0, c)$, em que c satisfaz

$$0{,}95 = \int_0^c e^{-x}\,dx = 1 - e^{-c}$$

ou $c = -\ln(0{,}05) = 2{,}9957$. Esse intervalo nos dá uma faixa razoável de tempos de vida prováveis para a máquina nova. Por fim, se quiséssemos avaliar se $x_0 = 5$ é ou não um tempo de vida plausível para uma máquina recém-comprada, poderíamos calcular a probabilidade de cauda

$$P(X > 5) = \int_5^\infty e^{-x}\,dx = e^{-5} = 0{,}0067,$$

que, neste caso, é muito pequena e, portanto, indica que $x_0 = 5$ está bem longe na cauda. A cauda direita dessa densidade é uma região de baixa probabilidade para essa distribuição, de modo que $x_0 = 5$ pode ser considerado implausível. Assim, é pouco provável que uma máquina dure 5 anos, e um comprador teria de planejar substituir a máquina antes do fim desse período. ■

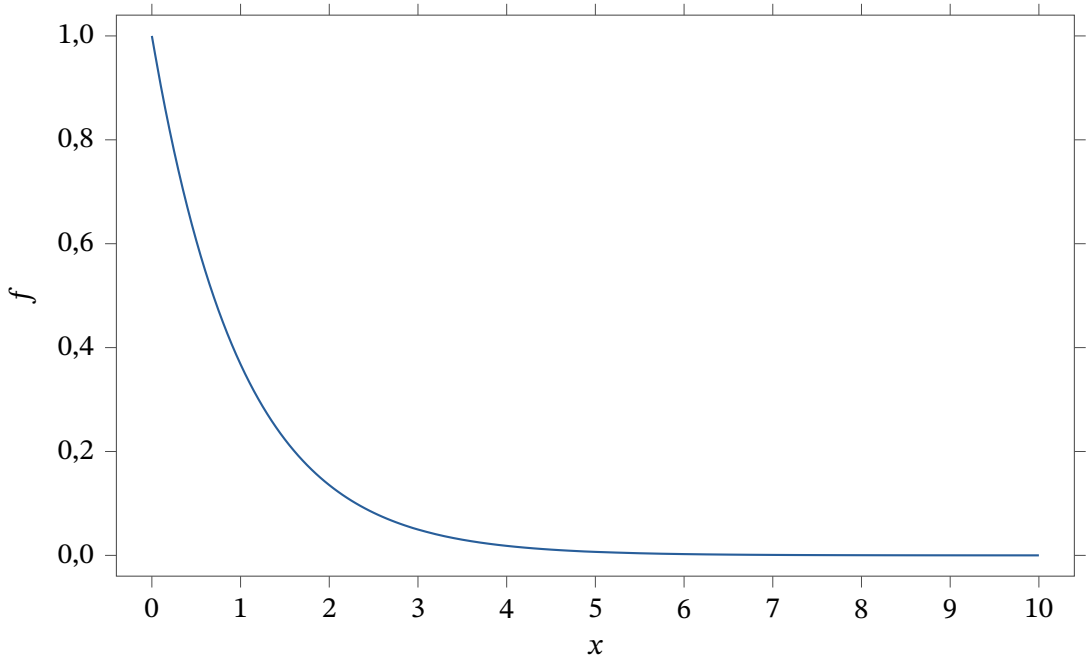


Figura 5.2.1: Gráfico da densidade Exponencial(1) f.

Em algumas aplicações, recebemos alguma informação parcial sobre o s desconhecido, na forma $s \in C \subset S$. Nesse caso, substituímos P pela medida de probabilidade condicional[10] $P(\cdot \mid C)$ ao derivar nossas inferências. São muitos os motivos para fazer isso e, em geral, podemos dizer que a maioria dos estatísticos concorda que essa é a coisa certa a fazer. É importante reconhecer, porém, que esse passo não decorre de um teorema matemático; ele pode, antes, ser visto como um axioma ou princípio básico de inferência. Vamos nos referir a ele como o *princípio da probabilidade condicional*, que terá papel fundamental em alguns desenvolvimentos posteriores.

No original: *conditional probability*[10].

Exemplo 5.2.2

Suponha que temos uma máquina cujo tempo de vida tem a distribuição do Exemplo 5.2.1 e que a máquina já está funcionando há um ano. Então as inferências sobre o tempo de vida da máquina se baseiam na distribuição condicional, dado que $X > 1$. A densidade dessa distribuição condicional é dada por $e^{-(x-1)}$ para $x > 1$. O tempo de vida predito passa a ser

$$E(X \mid X > 1) = \int_1^\infty x e^{-(x-1)}\, dx$$
$$= -x e^{-(x-1)}\Big|_1^\infty + \int_1^\infty e^{-(x-1)}\, dx = 2.$$

O fato de o tempo de vida adicional ser igual ao tempo de vida predito antes de a máquina começar a funcionar é uma característica especial da distribuição Exponencial. Isso não vale em geral (ver Exercício 5.2.4).

A probabilidade de cauda que mede quão plausível é o valor $x_0 = 5$ é dada por

$$P(X > 5 \mid X > 1) = \int_5^\infty e^{-(x-1)}\, dx = e^{-4} = 0{,}0183,$$

o que indica que $x_0 = 5$ é um pouco mais plausível diante do fato de a máquina já ter sobrevivido um ano. O menor intervalo que contém 0,95 da probabilidade condicional passa a ser da forma $(1, c)$, em que c é a solução de

$$0{,}95 = \int_1^c e^{-(x-1)}\, dx = e(e^{-1} - e^{-c}),$$

o que implica $c = -\ln\left(e^{-1} - 0{,}95e^{-1}\right) = 3{,}9957$. ■

Nosso ponto principal nesta seção é simplesmente que já temos alguma familiaridade com conceitos inferenciais. Além disso, por meio do princípio da probabilidade condicional, temos uma regra ou axioma básico que governa como fazemos inferências no contexto em que a medida de probabilidade P é conhecida e s não é conhecido.

Resumo da Seção 5.2

- Modelos de probabilidade são usados para modelar a incerteza sobre respostas futuras.
- Podemos usar a distribuição de probabilidade para predizer uma resposta futura ou para avaliar se um dado valor faz sentido ou não como um possível valor futuro da distribuição.

Exercícios

5.2.1 Às vezes, a *moda de uma densidade* (o ponto em que a densidade assume seu valor máximo) é escolhida como preditor[11] de um valor futuro de uma resposta. Determine esse preditor nos Exemplos 5.2.1 e 5.2.2 e comente sua adequação como preditor.

5.2.2 Suponha que se tenha decidido usar a média de uma distribuição para predizer uma resposta futura. No Exemplo 5.2.1, calcule o erro quadrático médio[12] (o valor esperado do quadrado do erro entre um valor futuro e seu preditor) desse preditor, antes de observar o valor. A que característica da distribuição do tempo de vida[13] isso corresponde?

5.2.3 Faça o gráfico da densidade da distribuição obtida como mistura de uma distribuição normal com média 4 e variância[14] 1 e uma distribuição normal com média -4 e variância 1, em que a probabilidade de mistura é 0,5. Explique por que nem a média nem a moda é um preditor adequado neste caso. (Sugestão: Seção 2.5.4.)

5.2.4 Repita os cálculos dos Exemplos 5.2.1 e 5.2.2 quando se sabe que o tempo de vida de uma máquina tem a distribuição de $Y = 10X$, em que $X \sim \text{Uniforme}[0, 1]$.

5.2.5 Suponha que $X \sim N(10, 2)$. Que valor você registraria como predição de um valor futuro de X? Como você justificaria sua escolha?

5.2.6 Suponha que $X \sim N(10, 2)$. Registre o menor intervalo que contém 0,95 da probabilidade para uma resposta futura. (Sugestão: considere um gráfico da densidade.)

5.2.7 Suponha que $X \sim \text{Gama}(3, 6)$. Que valor você registraria como predição de um valor futuro de X? Como você justificaria sua escolha?

5.2.8 Suponha que $X \sim \text{Poisson}(5)$. Que valor você registraria como predição de um valor futuro de X? Como você justificaria sua escolha?

5.2.9 Suponha que $X \sim$ Geométrica$(1/3)$. Que valor você registraria como predição de um valor futuro de X?

5.2.10 Suponha que X tenha a seguinte distribuição de probabilidade.

No original: *predictor*[11], *mean-squared error*[12], *lifelength*[13], *variance*[14].

x	1	2	3	4
$P(X = x)$	1/2	1/4	1/8	1/8

(a) Registre uma predição de um valor futuro de X.

(b) Suponha que, em seguida, lhe digam que $X \geq 2$. Registre uma predição de um valor futuro de X que use essa informação.

Problemas

5.2.11 Suponha que uma moeda honesta seja lançada 10 vezes e que a resposta X medida seja o número de vezes que observamos cara.

(a) Se você usar o valor esperado da resposta como preditor, qual é a predição de uma resposta futura X?

(b) Usando a Tabela D.6 (ou um pacote estatístico), calcule um menor intervalo que contenha pelo menos 0,95 da probabilidade para X. Observe que pode ajudar fazer antes o gráfico da função de probabilidade[15] de X.

(c) Que região você usaria para avaliar se um valor s_0 é ou não um valor futuro possível? (Sugestão: quais são as regiões de baixa probabilidade da distribuição?) Avalie se $x = 8$ é ou não plausível.

5.2.12 No Exemplo 5.2.1, explique (intuitivamente) por que o intervalo $(0; 2{,}9957)$ é o menor intervalo que contém 0,95 da probabilidade para o tempo de vida.

5.2.13 (Continuação do Problema 5.2.11) Suponha que nos digam que o número de caras observado é par. Repita as partes (a), (b) e (c).

5.2.14 Suponha que uma resposta X tenha distribuição Beta(a, b) com $a, b > 1$ fixos (ver Problema 2.4.16). Determine a média e a moda (ponto em que a densidade assume seu máximo) dessa distribuição e avalie qual é o preditor mais preciso de um X futuro quando se usa o erro quadrático médio, isto é, a distância quadrática esperada entre X e a predição.

5.2.15 Suponha que uma resposta X tenha distribuição $N(0, 1)$ e que decidimos predizer um valor futuro usando a média da distribuição.

(a) Determine a predição de um X futuro.

No original: *probability function*[15].

(b) Determine a predição de um $Y = X^2$ futuro.

(c) Comente a relação (ou a falta dela) entre as respostas das partes (a) e (b).

5.2.16 Suponha que $X \sim$ Geométrica(1/3). Determine o menor intervalo que contém 0,95 da probabilidade para um X futuro. (Sugestão: faça o gráfico da função de probabilidade e registre a função de distribuição.)

5.2.17 Suponha que $X \sim$ Geométrica(1/3) e que nos digam que $X > 5$. Que valor você registraria como predição de um valor futuro de X? Determine o menor intervalo que contém 0,95 da probabilidade para um X futuro. (Sugestão: faça o gráfico da função de probabilidade e registre a função de distribuição.)

Tópicos para discussão

5.2.18 Você acha realista que um profissional proceda como se conhecesse a verdadeira distribuição de probabilidade de uma resposta num problema?

5.3 Modelos Estatísticos

Em um problema estatístico, enfrentamos uma incerteza de natureza diferente daquela que surge na Seção 5.2. Em um contexto estatístico, observamos os *dados* s, mas não temos certeza sobre P. Numa situação assim, queremos construir inferências sobre P com base em s. Essa é a situação inversa da discutida na Seção 5.2.

Como devemos proceder para fazer essas *inferências estatísticas* provavelmente não é nada óbvio. Na verdade, há várias abordagens possíveis, que discutiremos nos capítulos seguintes. Neste capítulo, vamos desenvolver os ingredientes básicos de todas as abordagens.

Comum a praticamente todas as abordagens da inferência estatística é o conceito de *modelo estatístico* para os dados s. Ele toma a forma de um conjunto $\{P_\theta : \theta \in \mathbf{\Omega}\}$ de medidas de probabilidade, uma das quais corresponde à verdadeira medida de probabilidade desconhecida P que produziu os dados s. Em outras palavras, estamos afirmando que *existe* um mecanismo aleatório gerando s, e *sabemos* que a medida de probabilidade correspondente P é uma das medidas de probabilidade em $\{P_\theta : \theta \in \mathbf{\Omega}\}$.

O modelo estatístico $\{P_\theta : \theta \in \mathbf{\Omega}\}$ corresponde à informação que um estatístico traz para a aplicação sobre qual é a verdadeira medida de probabilidade,

ou pelo menos sobre o que ele está disposto a supor sobre ela. A variável θ é chamada de *parâmetro* do modelo, e o conjunto $\mathbf{\Omega}$ é chamado de *espaço paramétrico*[16]. Em geral, usamos modelos em que $\theta \in \mathbf{\Omega}$ indexa as medidas de probabilidade do modelo, isto é, $P_{\theta_1} = P_{\theta_2}$ se e somente se $\theta_1 = \theta_2$. Se todas as medidas de probabilidade P_θ puderem ser apresentadas por meio de funções de probabilidade ou de funções densidade f_θ (por conveniência, não vamos distinguir na notação entre o caso discreto e o contínuo), então é comum escrever o modelo estatístico como $\{f_\theta : \theta \in \mathbf{\Omega}\}$.

Pela definição de modelo estatístico, vemos que existe um único valor $\theta \in \mathbf{\Omega}$ tal que P_θ é a verdadeira medida de probabilidade. Chamamos esse valor de *valor verdadeiro do parâmetro*. Evidentemente, é equivalente falar em fazer inferências sobre o valor verdadeiro do parâmetro em vez de sobre a verdadeira medida de probabilidade, isto é, uma inferência sobre o valor verdadeiro de θ é, ao mesmo tempo, uma inferência sobre a verdadeira distribuição de probabilidade. Assim, por exemplo, podemos querer estimar o valor verdadeiro de θ, construir pequenas regiões em $\mathbf{\Omega}$ que provavelmente contêm o valor verdadeiro, ou avaliar se os dados estão ou não de acordo com algum valor particular θ_0, sugerido como o valor verdadeiro. Esses são tipos de inferência exatamente como os que discutimos na Seção 5.2, mas aqui a situação é bem diferente.

No original: *parameter space*[16].

Exemplo 5.3.1

Suponha que temos uma urna com 100 fichas, cada uma preta B ou branca W. Suponha ainda que nos dizem que há 50 ou 60 fichas pretas na urna. As fichas são bem misturadas e, em seguida, duas fichas são retiradas sem reposição. O objetivo é fazer uma inferência sobre o verdadeiro número de fichas pretas na urna, tendo observado os dados $s = (s_1, s_2)$, em que s_i é a cor da i-ésima ficha retirada.

Nesse caso, podemos tomar o modelo estatístico como $\{P_\theta : \theta \in \mathbf{\Omega}\}$, em que θ é o número de fichas pretas na urna, de modo que $\mathbf{\Omega} = \{50, 60\}$, e P_θ é a medida de probabilidade em

$$S = \{(B, B), (B, W), (W, B), (W, W)\}$$

correspondente a θ. Portanto, P_{50} atribui a probabilidade $50 \cdot 49/(100 \cdot 99)$ a cada uma das sequências (B, B) e (W, W) e a probabilidade $50 \cdot 50/(100 \cdot 99)$ a cada uma das sequências (B, W) e (W, B), e P_{60} atribui a probabilidade $60 \cdot 59/(100 \cdot 99)$ à sequência (B, B), a probabilidade $40 \cdot 39/(100 \cdot 99)$ à sequência (W, W) e a probabilidade $60 \cdot 40/(100 \cdot 99)$ a cada uma das sequências (B, W) e (W, B).

A escolha do parâmetro é um tanto arbitrária, pois poderíamos facilmente ter rotulado as medidas de probabilidade possíveis como P_1 e P_2, respectivamente. O parâmetro é, em essência, apenas um rótulo que nos permite distinguir entre os possíveis candidatos à verdadeira medida de probabilidade. É comum, no entanto, escolher esse rótulo de forma conveniente, para que ele signifique algo no problema em discussão. ■

Registramos aqui mais alguma terminologia de uso comum. Se um único valor observado de uma resposta X tem o modelo estatístico $\{f_\theta : \theta \in \mathbf{\Omega}\}$, então uma amostra $(X_1, \ldots, X_n)$ (lembre que, aqui, amostra significa que as X_i são independentes e identicamente distribuídas[17]; veja a Definição 2.8.6) tem densidade conjunta[18] dada por $f_\theta(x_1) f_\theta(x_2) \cdots f_\theta(x_n)$ para algum $\theta \in \mathbf{\Omega}$. Isso especifica o modelo estatístico para a resposta $(X_1, \ldots, X_n)$. Chamamos isso de *modelo estatístico para uma amostra*. Naturalmente, o valor verdadeiro de θ no modelo estatístico para uma amostra é o mesmo que para uma única observação. Às vezes, em vez de falar do modelo estatístico para uma amostra, falamos de uma amostra do modelo estatístico $\{f_\theta : \theta \in \mathbf{\Omega}\}$.

Observe que, sempre que possível, usaremos letras maiúsculas para denotar

No original: *independent and identically distributed*[17], *joint density*[18].

um valor não observado de uma variável aleatória[19] X e letras minúsculas para denotar o valor observado. Assim, uma amostra observada $(X_1, \dots, X_n)$ será denotada por $(x_1, \dots, x_n)$.

Exemplo 5.3.2

Suponha que há duas fábricas de máquinas. Sabe-se que as máquinas construídas pela primeira fábrica têm tempos de vida com distribuição Exponencial(1), enquanto as máquinas fabricadas pela segunda fábrica têm tempos de vida com distribuição Exponencial(2/3). As densidades dessas distribuições estão representadas na Figura 5.3.1.*

Você comprou cinco dessas máquinas sabendo que todas as cinco vieram da mesma fábrica, mas não sabe de qual. Em seguida, você observa os tempos de vida dessas máquinas, obtendo a amostra $(x_1, \dots, x_5)$, e quer fazer inferências sobre a verdadeira P.

Nesse caso, o modelo estatístico para uma única observação é formado por duas medidas de probabilidade $\{P_1, P_2\}$, em que P_1 é a medida de probabilidade Exponencial(1) e P_2 é a medida de probabilidade Exponencial(2/3). Aqui, tomamos o parâmetro como $\theta \in \mathbf{\Omega} = \{1, 2\}$.

Claramente, tempos de vida observados mais longos favorecem $\theta = 2$. Por exemplo, se

$$(x_1, \dots, x_5) = (5{,}0;\ 3{,}5;\ 3{,}3;\ 4{,}1;\ 2{,}8),$$

então intuitivamente temos mais certeza de que $\theta = 2$ do que se

$$(x_1, \dots, x_5) = (2{,}0;\ 2{,}5;\ 3{,}0;\ 3{,}1;\ 1{,}8).$$

O objeto da inferência estatística é tornar mais precisas afirmações como essa e quantificar nossa incerteza quanto à validade dessas afirmações.

Observamos de novo que a quantidade θ serve apenas como rótulo para as distribuições do modelo. O valor de θ não tem outra interpretação além de rótulo, e poderíamos muito bem ter usado outros valores como rótulos. Em muitas aplicações, no entanto, o parâmetro θ é tomado como alguma característica da distribuição que assume um valor único para cada distribuição do modelo. Aqui, poderíamos ter tomado θ como a média, e então o espaço paramétrico seria $\mathbf{\Omega} = \{1;\ 1{,}5\}$. Note que poderíamos igualmente ter usado o primeiro quartil, ou, aliás, qualquer outro quantil, para rotular as distribuições, desde que cada distribuição da família forneça um valor único para a característica escolhida. De modo

No original: *random variable*[19].

geral, qualquer transformação injetora de um parâmetro é aceitável como parametrização de um modelo estatístico. Quando trocamos os rótulos, dizemos que fizemos uma *reparametrização* do modelo estatístico. ■

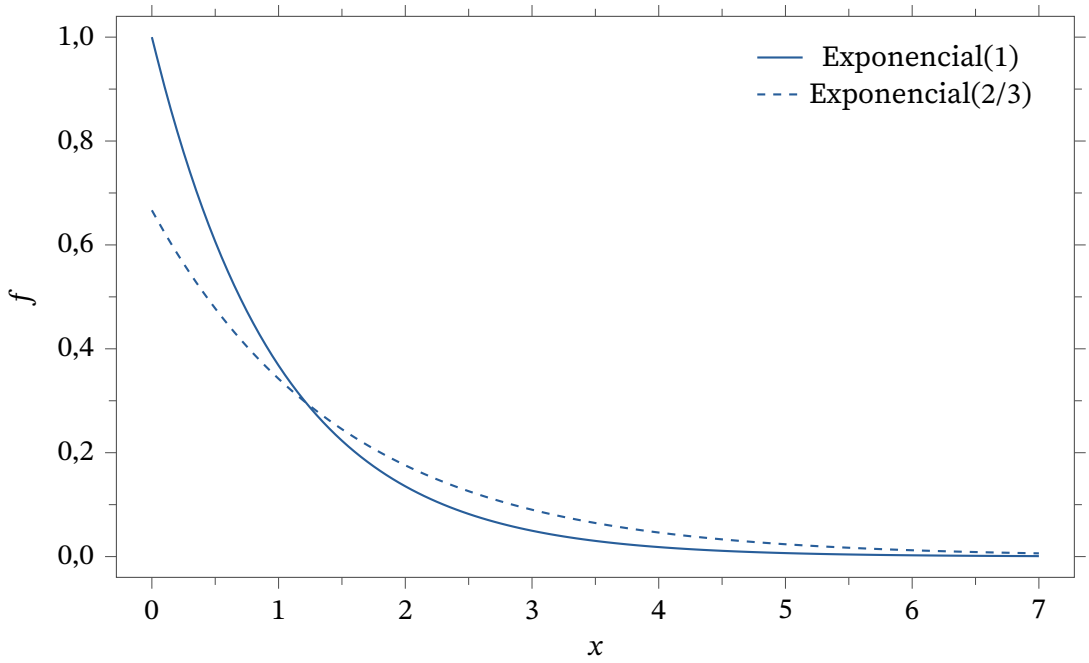


Figura 5.3.1: Gráfico das densidades Exponencial(1) (linha contínua) e Exponencial(1,5) (linha tracejada).

Consideramos agora dois exemplos importantes de modelos estatísticos. Eles são importantes porque aparecem com frequência nas aplicações.

*Nota do tradutor. Na legenda da Figura 5.3.1, o original traz Exponencial(1,5), mas o texto e a curva impressa (que começa em $f(0) \approx 0{,}67$) correspondem à Exponencial(2/3), cuja média é 1,5; a curva foi desenhada pela Exponencial(2/3).

Exemplo 5.3.3 — Modelo de Bernoulli

Suponha que $(x_1, \ldots, x_n)$ seja uma amostra de uma distribuição Bernoulli(θ) com $\theta \in [0, 1]$ desconhecido. Poderíamos estar observando os resultados de lançamentos de uma moeda e registrando X_i igual a 1 sempre que sai cara no i-ésimo lançamento e igual a 0 caso contrário. Ou então poderíamos estar observando itens produzidos num processo industrial e registrando X_i igual a 1 sempre que o i-ésimo item é defeituoso e 0 caso contrário. Numa aplicação biomédica, a resposta $X_i = 1$ poderia indicar que um tratamento num paciente teve sucesso, enquanto $X_i = 0$ indica um fracasso. Em todos esses casos, queremos conhecer o valor verdadeiro de θ, pois ele nos diz algo importante sobre a moeda que estamos lançando, sobre o processo industrial ou sobre o tratamento médico, respectivamente.

Suponha agora que não temos nenhuma informação sobre a verdadeira probabilidade θ. Por isso, tomamos o espaço paramétrico como $\mathbf{\Omega} = [0, 1]$, o conjunto de todos os valores possíveis de θ. A função de probabilidade do i-ésimo item da amostra é dada por

$$f_\theta(x_i) = \theta^{x_i}(1-\theta)^{1-x_i},$$

e a função de probabilidade da amostra é dada por

$$\prod_{i=1}^{n} f_\theta(x_i) = \prod_{i=1}^{n} \theta^{x_i}(1-\theta)^{1-x_i} = \theta^{n\bar{x}}(1-\theta)^{n(1-\bar{x})}.$$

Isso especifica o modelo para uma amostra.

Note que poderíamos parametrizar esse modelo por qualquer função injetora de θ. Por exemplo, $\alpha = \theta^2$ serviria (pois é injetora em $\mathbf{\Omega}$), assim como $\psi = \ln\{\theta/(1-\theta)\}$. ■

Exemplo 5.3.4 — Modelo Normal de Locação e Escala

Suponha que $(x_1, \ldots, x_n)$ seja uma amostra de uma distribuição $N(\mu, \sigma^2)$ com $\theta = (\mu, \sigma^2) \in R^1 \times R^+$ desconhecido, em que $R^+ = (0, \infty)$. Por exemplo, podemos ter observações das alturas, em centímetros, de indivíduos de uma população e achar razoável supor que a distribuição das alturas na população é normal, com média e desvio padrão desconhecidos.

A densidade da amostra é então dada por

$$\begin{aligned}\prod_{i=1}^{n} f_{(\mu,\sigma^2)}(x_i) &= \left(2\pi\sigma^2\right)^{-n/2} \exp\left\{-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2\right\} \\ &= \left(2\pi\sigma^2\right)^{-n/2} \exp\left\{-\frac{n}{2\sigma^2}(\bar{x}-\mu)^2 - \frac{n-1}{2\sigma^2}s^2\right\},\end{aligned}$$

pois (Problema 5.3.13)

$$\sum_{i=1}^{n}(x_i-\mu)^2 = n(\bar{x}-\mu)^2 + \sum_{i=1}^{n}(x_i-\bar{x})^2, \tag{5.3.1}$$

em que

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

é a *média amostral* e

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i-\bar{x})^2$$

é a *variância amostral*.

Parametrizações alternativas desse modelo são de uso comum. Por exemplo, em vez de usar (μ, σ^2), às vezes (μ, σ^{-2}), ou (μ, σ), ou $(\mu, \ln\sigma)$ é uma escolha conveniente. Note que $\ln\sigma$ percorre R^1 quando σ varia em R^+. ■

Na verdade, podemos nos perguntar quão adequado é o modelo do Exemplo 5.3.4 para a distribuição das alturas numa população, já que, em qualquer população finita, a verdadeira distribuição é discreta (há apenas uma quantidade finita de estudantes). É claro que uma distribuição normal pode dar uma boa aproximação de uma distribuição discreta, como no Exemplo 4.4.9. Assim, no Exemplo 5.3.4, estamos supondo também que uma distribuição de probabilidade contínua pode dar uma aproximação próxima da verdadeira distribuição discreta. Acontece que essas aproximações podem levar a grandes simplificações na obtenção das inferências, e por isso as usamos sempre que possível. Uma aproximação assim, é claro, não se aplica ao Exemplo 5.3.3.

Note também que as alturas serão sempre expressas em alguma unidade específica, por exemplo, centímetros; com base nisso, sabemos que a média populacional tem de estar numa certa faixa de valores, por exemplo, $\mu \in (0, 300)$, mas o modelo estatístico permite qualquer valor de μ. Assim, muitas vezes temos de fato informação adicional sobre o valor verdadeiro do parâmetro de um modelo, mas ela é um tanto imprecisa; por exemplo, provavelmente também temos $\mu \in (100, 300)$. No Capítulo 7, discutiremos maneiras de incorporar essa informação à nossa análise.

De onde vem, numa aplicação, a informação do modelo $\{P_\theta : \theta \in \mathbf{\Omega}\}$? Por exemplo, como poderíamos saber que as alturas têm distribuição aproximadamente normal no Exemplo 5.3.4? Às vezes essa informação se baseia na experiência anterior com aplicações relacionadas, mas muitas vezes ela é uma *suposição* que precisa ser verificada antes que os procedimentos de inferência possam ser usados. Os procedimentos concebidos para verificar essas suposições são chamados de procedimentos de *verificação de modelos*[20], que serão discutidos no Capítulo 9. Na prática, os procedimentos de verificação de modelos são indispensáveis; do contrário, as inferências tiradas dos dados e do modelo estatístico podem estar erradas se o modelo estiver errado.

Resumo da Seção 5.3

- Numa aplicação estatística, não conhecemos a distribuição de uma resposta, mas sabemos (ou estamos dispostos a supor) que a verdadeira distribuição de probabilidade é uma de um conjunto de distribuições possíveis $\{f_\theta : \theta \in \mathbf{\Omega}\}$, em que f_θ é a densidade ou a função de probabilidade (a que for pertinente) da resposta. O conjunto das distribuições possíveis é chamado de *modelo estatístico*.
- O conjunto $\mathbf{\Omega}$ é chamado de *espaço paramétrico*, e a variável θ é chamada de *parâmetro* do modelo. Como cada valor de θ corresponde a uma distribuição de probabilidade distinta no modelo, podemos falar do *valor verdadeiro* de θ, já que ele dá a verdadeira distribuição por meio de f_θ.

Exercícios

5.3.1 Suponha que há três moedas: sabe-se que uma é honesta, outra tem probabilidade 1/3 de dar cara num único lançamento e a outra tem probabilidade 2/3 de dar cara num único lançamento. Uma moeda é escolhida

No original: *model checking*[20].

(não aleatoriamente) e lançada cinco vezes. O objetivo é fazer uma inferência, com base na amostra, sobre qual das moedas está sendo lançada. Descreva completamente um modelo estatístico para uma única resposta e para a amostra.

5.3.2 Suponha que uma face de um dado simétrico de seis faces está duplicada, mas não sabemos qual. Sabemos que, se o 1 está duplicado, então o 2 não aparece; caso contrário, o 1 não aparece. Descreva o modelo estatístico para um único lançamento.

5.3.3 Suponha que temos duas populações (I e II) e que se sabe que a variável X tem distribuição $N(10, 2)$ na população I e distribuição $N(8, 3)$ na população II. Uma amostra $(X_1, \ldots, X_n)$ é gerada a partir de uma das populações; não lhe dizem de qual população a amostra veio, mas pedem que você tire inferências sobre a verdadeira distribuição com base na amostra. Descreva o modelo estatístico para esse problema. Você poderia parametrizar esse modelo pela média populacional? E pela variância populacional? Às vezes, problemas como esse são chamados de *problemas de classificação*, porque fazer inferências sobre a verdadeira distribuição equivale a classificar a amostra como pertencente a uma das populações.

5.3.4 Suponha a mesma situação do Exercício 5.3.3, mas agora a distribuição da população I é $N(10, 2)$ e a da população II é $N(10, 3)$. Você poderia parametrizar o modelo pela média populacional? E pela variância populacional? Justifique sua resposta.

5.3.5 Suponha que um processo de fabricação produz baterias cujos tempos de vida sabidamente têm distribuição exponencial, mas com a média da distribuição completamente desconhecida. Descreva o modelo estatístico para uma única observação. É possível parametrizar esse modelo pela média? É possível parametrizar esse modelo pela variância? É possível parametrizar esse modelo pelo *coeficiente de variação* (o coeficiente de variação de uma distribuição é igual ao desvio padrão[21] dividido pela média)?

5.3.6 Suponha que se sabe que uma resposta X tem distribuição Uniforme$[0, \beta]$, em que $\beta > 0$ é desconhecido. É possível parametrizar esse modelo pelo primeiro quartil da distribuição? (O primeiro quartil da distribuição de uma variável aleatória X é o ponto c que satisfaz $P(X \leq c) = 0{,}25$.) Explique por quê.

5.3.7 Suponha que se sabe que uma variável aleatória X segue uma das

No original: *standard deviation*[21].

seguintes distribuições.

θ	$P_\theta(X=1)$	$P_\theta(X=2)$	$P_\theta(X=3)$
A	1/2	1/2	0
B	0	1/2	1/2

(a) Qual é o espaço paramétrico $\mathbf{\Omega}$?

(b) Suponha que observamos o valor $X = 1$. Qual é o valor verdadeiro do parâmetro? Qual é a verdadeira distribuição de X?

(c) O que você poderia dizer sobre o valor verdadeiro do parâmetro se tivesse observado $X = 2$?

5.3.8 Suponha que temos um modelo estatístico $\{P_1, P_2\}$, em que P_1 e P_2 são medidas de probabilidade num espaço amostral S. Suponha ainda que existe um subconjunto $C \subset S$ tal que $P_1(C) = 1$, enquanto $P_2(C^c) = 1$. Discuta como você faria uma inferência sobre a verdadeira distribuição de uma resposta s depois de ter observado uma única observação.

5.3.9 Suponha que você sabe que a distribuição de probabilidade de uma variável X é P_1 ou P_2. Se você observa $X = 1$ e $P_1(X = 1) = 0{,}75$, enquanto $P_2(X = 1) = 0{,}001$, qual você diria que é a verdadeira distribuição de X? Justifique essa conclusão.

5.3.10 Suponha que lhe dizem que a turma nº 1 tem 35 homens e 65 mulheres, enquanto a turma nº 2 tem 45 homens e 55 mulheres. Dizem-lhe também que uma determinada pessoa de uma dessas turmas é mulher, mas não lhe dizem de qual turma ela veio.

(a) Construa um modelo estatístico para esse problema, identificando o parâmetro, o espaço paramétrico e a família de distribuições. Identifique também os dados.

(b) Com base nos dados, você acha que é possível fazer uma inferência confiável sobre o valor verdadeiro do parâmetro? Explique por quê.

(c) Se você tivesse de arriscar de qual distribuição vieram os dados, que escolha faria? Explique por quê.

Problemas

5.3.11 Suponha que, no Exemplo 5.3.3, parametrizamos o modelo por $\psi = \ln\{\theta/(1-\theta)\}$. Escreva o modelo estatístico com essa parametrização, isto

é, escreva a função de probabilidade usando ψ como parâmetro e escreva o espaço paramétrico correspondente.

5.3.12 Suponha que, no Exemplo 5.3.4, parametrizamos o modelo por $(\mu, \ln \sigma) = (\mu, \psi)$. Escreva o modelo estatístico com essa parametrização, isto é, escreva a função densidade[22] usando (μ, ψ) como parâmetro e escreva o espaço paramétrico correspondente.

5.3.13 Prove a identidade (5.3.1).

5.3.14 Uma amostra $(X_1, \ldots, X_n)$ é gerada a partir de uma distribuição Bernoulli(θ) com $\theta \in [0, 1]$ desconhecido, mas o estatístico observa apenas $T = \sum_{i=1}^{n} X_i$. Descreva o modelo estatístico para os dados observados.

5.3.15 Suponha que se sabe que uma resposta X tem distribuição $N(\mu, \sigma^2)$, em que $\theta = (\mu, \sigma^2) \in R^1 \times R^+$ e θ é completamente desconhecido. Mostre como calcular o primeiro quartil de cada distribuição desse modelo a partir dos valores (μ, σ^2). É possível parametrizar o modelo pelo primeiro quartil? Justifique sua resposta.

5.3.16 Suponha que se sabe que a resposta X tem distribuição $N(Y, \sigma^2)$, em que $Y \sim N(0, \delta^2)$ e $\sigma^2, \delta^2 > 0$ são completamente desconhecidos. Descreva o modelo estatístico para uma observação (X, Y). Se Y não é observada, descreva o modelo estatístico para X.

5.3.17 Suponha que temos um modelo estatístico $\{P_1, P_2\}$, em que P_1 é uma distribuição $N(10, 1)$, enquanto P_2 é uma distribuição $N(0, 1)$.

(a) É possível fazer algum tipo de inferência confiável sobre a verdadeira distribuição com base numa única observação? Por quê?

(b) Repita a parte (a), mas agora suponha que P_1 é uma distribuição $N(1, 1)$.

5.3.18 Suponha que temos um modelo estatístico $\{P_1, P_2\}$, em que P_1 é uma distribuição $N(1, 1)$, enquanto P_2 é uma distribuição $N(0, 1)$. Suponha ainda que temos uma amostra $x_1, \ldots, x_{100}$ da verdadeira distribuição. Discuta como você poderia fazer uma inferência sobre a verdadeira distribuição com base na amostra.

No original: *density function*[22].

Tópicos para discussão

5.3.19 Explique por que você acha importante que os estatísticos digam com toda a clareza o que estão supondo sempre que fazem uma análise estatística.

5.3.20 Considere o modelo estatístico dado pela coleção das distribuições $N(\mu, \sigma_0^2)$, em que $\mu \in R^1$ é considerado completamente desconhecido, mas σ_0^2 é suposto conhecido. Você acha que esse é um modelo razoável para usar numa aplicação? Justifique sua resposta.

5.4 Coleta de Dados

Os desenvolvimentos das Seções 5.2 e 5.3 se baseiam no fato de a resposta observada s ser uma realização de uma medida de probabilidade P. Na verdade, em muitas aplicações, isso é uma suposição. Muitas vezes recebemos dados que poderiam ter sido produzidos dessa forma, mas nem sempre podemos ter certeza.

Quando não podemos ter certeza de que os dados foram produzidos por um mecanismo aleatório, a análise estatística dos dados é chamada de *estudo observacional*[23]. Num estudo observacional, o estatístico apenas observa os dados, em vez de intervir diretamente na geração deles para garantir que a suposição de aleatoriedade valha. Por exemplo, suponha que um professor coleta dados de seus alunos para um estudo que examina a relação entre as notas e o emprego de meio período. É razoável considerar que os dados coletados vieram de uma distribuição de probabilidade? Se sim, como justificaríamos isso?

É importante que o estatístico distinga com cuidado entre as situações que são estudos observacionais e as que não são. Como ilustra a discussão a seguir, há ressalvas que precisam ser feitas à análise de um estudo observacional. Embora as análises estatísticas de estudos observacionais sejam válidas e, de fato, importantes, precisamos estar cientes de suas limitações ao interpretar os resultados.

No original: *observational study*[23].

5.4.1 Populações Finitas

Suponha que temos um conjunto finito Π de objetos, chamado de *população*, e uma função real X (às vezes chamada de *medição*) definida em Π. Assim, para cada $\pi \in \Pi$, temos uma quantidade real $X(\pi)$ que mede algum aspecto ou característica de π.

Por exemplo, Π poderia ser o conjunto de todos os alunos atualmente matriculados em tempo integral numa certa universidade, com $X(\pi)$ a altura do aluno π em centímetros. Ou, para o mesmo Π, poderíamos tomar $X(\pi)$ como o gênero do aluno π, em que $X(\pi) = 1$ indica feminino e $X(\pi) = 2$ indica masculino. Aqui, a altura é uma *variável quantitativa*, porque seus valores significam algo numa escala numérica, e podemos fazer contas com esses valores, por exemplo, calcular uma média. Já o gênero é um exemplo de *variável categórica*, porque seus valores servem apenas para classificar, e qualquer outra escolha de números reais distintos teria servido tão bem quanto a que fizemos. O primeiro passo de uma análise estatística é determinar os tipos de variáveis com que estamos trabalhando, porque as técnicas de análise estatística adequadas dependem disso.

A população e a medição, juntas, produzem uma *distribuição populacional* sobre a população. Ela é especificada pela *função de distribuição acumulada*[24] *populacional* $F_X : R^1 \to [0, 1]$, em que

$$F_X(x) = \frac{|\{\pi : X(\pi) \leq x\}|}{N},$$

sendo $|A|$ o número de elementos do conjunto A e $N = |\Pi|$. Portanto, $F_X(x)$ é a proporção de elementos de Π cuja medição é menor ou igual a x.

Considere o exemplo simples a seguir, em que podemos calcular F_X exatamente.

No original: *cumulative distribution function*[24].

Exemplo 5.4.1

Suponha que Π é uma população de $N = 20$ lotes de terra do mesmo tamanho. Suponha ainda que $X(\pi)$ é uma medida da fertilidade do lote π numa escala de 10 pontos e que foram obtidas as seguintes medições.

4	8	6	7	8	3	7	5	4	6
9	5	7	5	8	3	4	7	8	3

Temos então

$$F_X(x) = \begin{cases} 0 & x < 3 \\ 3/20 & 3 \leq x < 4 \\ 6/20 & 4 \leq x < 5 \\ 9/20 & 5 \leq x < 6 \\ 11/20 & 6 \leq x < 7 \\ 15/20 & 7 \leq x < 8 \\ 19/20 & 8 \leq x < 9 \\ 1 & 9 \leq x \end{cases}$$

porque, por exemplo, 6 dos 20 lotes têm medição de fertilidade menor ou igual a 4. ■

O objetivo do estatístico nesse contexto é conhecer a função F_X com a maior precisão possível. Se conhecemos F_X exatamente, então identificamos a distribuição de X sobre Π. Uma forma de conhecer a distribuição exatamente é fazer um *censo*, em que o estatístico sai a campo, observa $X(\pi)$ para todo $\pi \in \Pi$ e então calcula F_X. Às vezes isso é viável, mas muitas vezes não é possível nem mesmo desejável, por causa dos custos de reunir com exatidão todas as medições — pense em como seria difícil coletar as alturas de todos os alunos da sua escola.

Embora às vezes um censo seja necessário, e até exigido por lei, muitas vezes é possível obter uma aproximação muito precisa de F_X selecionando um subconjunto

$$\{\pi_1, \ldots, \pi_n\} \subset \Pi$$

para algum $n < N$. Aproximamos então $F_X(x)$ pela *função de distribuição*

empírica[25], definida por

$$\hat{F}_X(x) = \frac{|\{\pi_i : X(\pi_i) \leq x, i = 1, \ldots, n\}|}{n}$$
$$= \frac{1}{n}\sum_{i=1}^{n} I_{(-\infty,x]}(X(\pi_i)).$$

Poderíamos também medir mais de um aspecto de π para produzir uma *medição multivariada* $X : \Pi \to R^k$ para algum k. Por exemplo, se Π é de novo a população de alunos, poderíamos ter $X(\pi) = (X_1(\pi), X_2(\pi))$, em que $X_1(\pi)$ é a altura em centímetros do aluno π e $X_2(\pi)$ é o peso do aluno π em quilogramas. Discutiremos medições multivariadas no Capítulo 10, em que nosso interesse está nas relações entre variáveis, mas aqui nos concentramos em medições univariadas.

Há duas perguntas que precisamos responder agora — a saber, como devemos selecionar o subconjunto $\{\pi_1, \ldots, \pi_n\}$ e quão grande deve ser n?

5.4.2 Amostragem Aleatória Simples

Vamos tratar primeiro da questão de selecionar $\{\pi_1, \ldots, \pi_n\}$. Suponha que selecionamos esse subconjunto de acordo com alguma regra dada, baseada no rótulo único que cada $\pi \in \Pi$ possui. Por exemplo, se o rótulo é um número, poderíamos ordenar os números e tomar os n elementos de menores rótulos. Ou poderíamos ordenar os números e tomar um elemento sim, um não, até ter um subconjunto de n elementos, e assim por diante.

Há muitas regras desse tipo que poderíamos aplicar, e todas elas têm um problema básico. Se queremos que $\hat{F}_X$ aproxime F_X para a população inteira, então, ao usarmos uma regra, corremos o risco de selecionar $\{\pi_1, \ldots, \pi_n\}$ apenas de uma subpopulação. Por exemplo, se usamos os números de matrícula para identificar cada elemento de uma população de alunos, e os alunos mais antigos têm números de matrícula menores, então, quando n é muito menor que N e selecionamos os alunos de menores números de matrícula, $\hat{F}_X$, na melhor das hipóteses, está apenas aproximando a distribuição de X na população dos alunos mais antigos. Essa distribuição pode ser muito diferente de F_X. Da mesma forma, para qualquer outra regra que usemos, mesmo que não consigamos imaginar qual poderia ser a subpopulação, pode haver um *efeito de seleção*, ou *viés*, induzido que torna a estimativa inválida.

No original: *empirical distribution function*[25].

Essa é a ressalva que precisamos fazer ao analisar os resultados de estudos observacionais. Num estudo observacional, os dados são gerados por alguma regra, em geral desconhecida do estatístico; isso significa que quaisquer conclusões tiradas com base nos dados $X(\pi_1), \ldots, X(\pi_n)$ podem não valer para a população inteira.

Parece haver apenas uma forma de garantir que os efeitos de seleção sejam evitados: o conjunto $\{\pi_1, \ldots, \pi_n\}$ precisa ser selecionado usando aleatoriedade. Na *amostragem aleatória simples*[26], isso significa que um mecanismo aleatório é usado para selecionar os π_i de modo que cada subconjunto de n elementos tenha probabilidade $1/\binom{N}{n}$ de ser escolhido. Por exemplo, poderíamos colocar N fichas numa tigela, cada uma com um rótulo único correspondente a um elemento da população, e então retirar ao acaso n fichas da tigela, sem reposição. Os rótulos das fichas retiradas identificam os indivíduos que foram selecionados de Π. Como alternativa, para a aleatorização, poderíamos usar uma tabela de números aleatórios, como a Tabela D.1 do Apêndice D (veja a Tabela D.1 para uma descrição de como ela é usada), ou gerar valores aleatórios com um algoritmo de computador (veja a Seção 2.10).

Note que, com a amostragem aleatória simples, $(X(\pi_1), \ldots, X(\pi_n))$ é aleatório. Em particular, quando $n = 1$, temos então

$$P(X(\pi_1) \leq x) = F_X(x),$$

isto é, a distribuição de probabilidade da variável aleatória $X(\pi_1)$ é a mesma que a distribuição populacional.

Exemplo 5.4.2

Considere o contexto do Exemplo 5.4.1. Quando selecionamos ao acaso o primeiro lote de Π, é claro que cada lote tem probabilidade $1/20$ de ser selecionado. Temos então

$$P(X(\pi_1) \leq x) = \frac{|\{\pi : X(\pi) \leq x\}|}{20} = F_X(x)$$

para todo $x \in R^1$. ■

Antes de observar a amostra, temos também $P(X(\pi_2) \leq x) = F_X(x)$. Considere, porém, a distribuição de $X(\pi_2)$ dado que $X(\pi_1) = x_1$. Como removemos um membro da população, com valor de medição x_1, então $NF_X(x) - 1$ é o número

No original: *simple random sampling*[26].

de indivíduos que restam em Π com $X(\pi) \leq x_1$. Portanto,

$$P(X(\pi_2) \leq x \mid X(\pi_1) = x_1) = \begin{cases} \dfrac{NF_X(x) - 1}{N - 1} & x \geq x_1 \\ \dfrac{NF_X(x)}{N - 1} & x < x_1. \end{cases}$$

Note que isso não é igual a $F_X(x)$.

Assim, com a amostragem aleatória simples, $X(\pi_1)$ e $X(\pi_2)$ não são independentes. Observe, porém, que, quando N é grande,

$$P(X(\pi_2) \leq x \mid X(\pi_1) = x_1) \approx F_X(x),$$

de modo que $X(\pi_1)$ e $X(\pi_2)$ são aproximadamente independentes e identicamente distribuídas (i.i.d.). Contas semelhantes levam à conclusão de que, quando N é grande e n é pequeno em relação a N, então, com a amostragem aleatória simples da população, as variáveis aleatórias

$$X(\pi_1), \ldots, X(\pi_n)$$

são aproximadamente i.i.d. e com distribuição dada por F_X. Assim, trataremos os valores observados $(x_1, \ldots, x_n)$ de $(X(\pi_1), \ldots, X(\pi_n))$ como uma amostra (no sentido da Definição 2.8.6) de F_X. Neste texto, salvo indicação em contrário, sempre suporemos que n é pequeno em relação a N, de modo que essa aproximação faça sentido.

Sob a suposição i.i.d., a lei fraca dos grandes números[27] (Teorema 4.2.1) implica que a função de distribuição empírica $\hat{F}_X$ satisfaz

$$\hat{F}_X(x) = \frac{1}{n} \sum_{i=1}^{n} I_{(-\infty, x]}(X(\pi_i)) \xrightarrow{P} F_X(x)$$

quando $n \to \infty$. Vemos então que $\hat{F}_X$ pode ser considerada uma estimativa da função de distribuição acumulada (fda) populacional F_X.

Sempre que os dados tiverem sido coletados por amostragem aleatória simples, chamaremos a investigação estatística de *estudo amostral*. É um princípio básico da boa prática estatística que estudos amostrais são sempre preferíveis a estudos observacionais, sempre que forem viáveis. Isso porque podemos ter certeza de que, com um estudo amostral, quaisquer conclusões que tiremos com base na amostra $\pi_1, \ldots, \pi_n$ valerão para a população de interesse Π. Com estudos observacionais, nunca podemos ter certeza de que os dados amostrais

No original: *weak law of large numbers*[27].

não foram, na verdade, selecionados de algum subconjunto próprio de Π. Por exemplo, se lhe pedissem para fazer inferências sobre a distribuição das alturas dos alunos da sua escola, mas você selecionasse alguns dos seus amigos como amostra, então é claro que a fda estimada poderia ser muito diferente da fda verdadeira (possivelmente, mais amigos seus são de um gênero do que do outro).

Muitas vezes, porém, não temos escolha senão usar dados observacionais numa análise estatística. Amostrar diretamente da população de interesse pode ser extremamente difícil ou até impossível. Ainda podemos tratar os resultados de tais análises como uma forma de evidência, mas precisamos ter cautela com possíveis efeitos de seleção e reconhecer essa possibilidade. Estudos amostrais constituem um nível mais alto de evidência estatística do que estudos observacionais, já que evitam a possibilidade de efeitos de seleção.

No Capítulo 10, discutiremos *experimentos*, que constituem o nível mais alto de evidência estatística. Experimentos são apropriados quando estamos investigando a possibilidade de existirem relações de causa e efeito entre variáveis definidas em populações.

A segunda pergunta que precisamos tratar diz respeito à escolha do tamanho da amostra n. Parece natural que queiramos escolher uma amostra tão grande quanto possível. Por outro lado, há sempre custos associados à amostragem, e às vezes cada valor amostral é muito caro de obter. Além disso, muitas vezes, quanto mais dados coletamos, mais difícil é garantir que os dados não sejam corrompidos por diversos erros que podem surgir no processo de coleta. Assim, nossa resposta sobre quão grande n precisa ser é que queremos escolhê-lo grande o suficiente para obter a precisão necessária, mas não maior que isso. Por conseguinte, o estatístico precisa especificar qual precisão é exigida e, então, n é determinado.

Veremos nos capítulos seguintes que há vários métodos para especificar a precisão exigida num problema e, então, determinar um valor apropriado para n. Determinar n é um componente-chave da implementação de um estudo amostral e costuma ser chamado de *cálculo do tamanho da amostra*.

Se definimos

$$f_X(x) = \frac{|\{\pi : X(\pi) = x\}|}{N} = \frac{1}{N} \sum_{\pi \in \Pi} I_{\{x\}}(X(\pi)),$$

isto é, $f_X(x)$ é a proporção de membros da população que satisfazem $X(\pi) = x$, então vemos que f_X faz o papel da função de probabilidade, porque

$$F_X(x) = \sum_{z \leq x} f_X(z).$$

Chamamos f_X de *função de frequência relativa*[28] *populacional*. Agora, $f_X(x)$ pode ser estimada, com base na amostra $\{\pi_1, \dots, \pi_n\}$, por

$$\hat{f}_X(x) = \frac{|\{\pi_i : X(\pi_i) = x, i = 1, \dots, n\}|}{n} = \frac{1}{n}\sum_{i=1}^{n} I_{\{x\}}(X(\pi_i)),$$

isto é, a proporção de membros π da amostra que satisfazem $X(\pi) = x$.

Com variáveis categóricas, $\hat{f}_X(x)$ estima a proporção populacional $f_X(x)$ na categoria especificada por x. Com algumas variáveis quantitativas, porém, f_X não é uma quantidade apropriada a estimar, e é preciso considerar uma função alternativa.

5.4.3 Histogramas

Variáveis quantitativas podem ainda ser classificadas como variáveis discretas ou contínuas. Variáveis contínuas são aquelas que podemos medir com precisão arbitrária à medida que aumentamos a exatidão de um instrumento de medição. Por exemplo, a altura de um indivíduo poderia ser considerada uma variável contínua, enquanto o número de anos de estudo de um indivíduo seria considerado uma variável quantitativa discreta. Para variáveis quantitativas discretas, f_X é uma quantidade apropriada para descrever uma distribuição populacional, mas procedemos de outro modo com variáveis quantitativas contínuas.

Suponha que X é uma variável quantitativa contínua. Nesse caso, faz mais sentido *agrupar* os valores em intervalos, dados por

$$(h_1, h_2], (h_2, h_3], \dots, (h_{m-1}, h_m],$$

em que os h_i são escolhidos de modo que $h_1 < h_2 < \cdots < h_m$, com (h_1, h_m) cobrindo, na prática, o intervalo de valores possíveis de X. Definimos então

$$h_X(x) = \begin{cases} \dfrac{|\{\pi : X(\pi) \in (h_i, h_{i+1}]\}|}{N(h_{i+1} - h_i)} & x \in (h_i, h_{i+1}] \\ 0 & \text{caso contrário} \end{cases}$$

e chamamos h_X de *função histograma de densidade*. Aqui, $h_X(x)$ é a proporção de elementos π da população cuja medição $X(\pi)$ está no intervalo $(h_i, h_{i+1}]$ que contém x, dividida pelo comprimento do intervalo.

No original: *relative frequency*[28].

Na Figura 5.4.1, traçamos um histograma de densidade baseado numa amostra de 10.000 da distribuição $N(0,1)$ (estamos tratando essa amostra como a população inteira), usando os valores $h_1 = -5, h_2 = -4, \ldots, h_{11} = 5$. Note que as linhas verticais são apenas artefatos do programa de gráficos e não representam valores de h_X, que são dados pelas linhas horizontais.

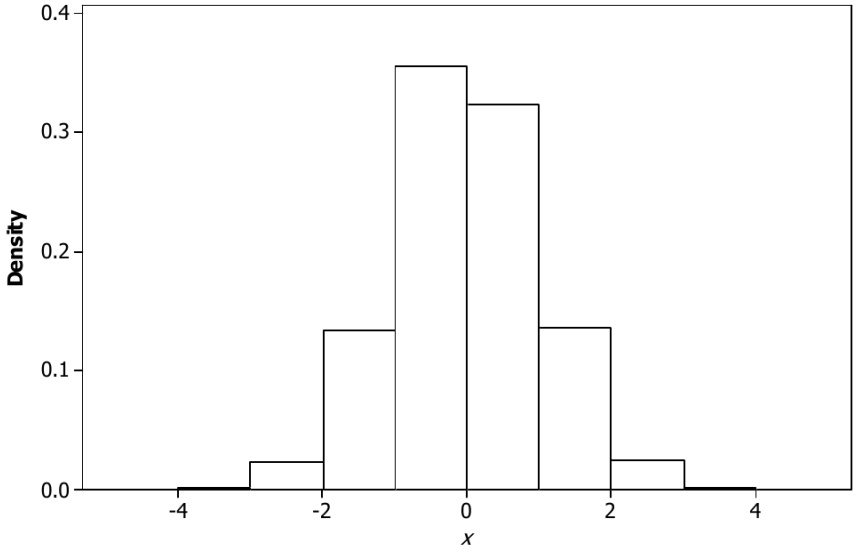


Figura 5.4.1: Função histograma de densidade de uma amostra de 10.000 da distribuição $N(0,1)$, usando os valores $h_1 = -5, h_2 = -4, \ldots, h_{11} = 5$.

Se $x \in (h_i, h_{i+1}]$, então $h_X(x)(h_{i+1} - h_i)$ dá a proporção de indivíduos da população cuja medição $X(\pi)$ está em $(h_i, h_{i+1}]$. Além disso, temos

$$F_X(h_j) = \int_{-\infty}^{h_j} h_X(x)\,dx$$

para cada extremo de intervalo e

$$F_X(h_j) - F_X(h_i) = \int_{h_i}^{h_j} h_X(x)\,dx$$

quando $h_i \leq h_j$. Se os intervalos $(h_i, h_{i+1}]$ são pequenos, esperamos que

$$F_X(b) - F_X(a) \approx \int_a^b h_X(x)\,dx$$

para qualquer escolha de $a < b$.

Suponha agora que os comprimentos $h_{i+1} - h_i$ são pequenos e que N é muito grande. Então faz sentido imaginar uma função suave e contínua f_X, por

exemplo, talvez uma função densidade normal ou gama, que aproxima h_X no sentido de que

$$\int_a^b f_X(x)\,dx \approx \int_a^b h_X(x)\,dx$$

para todo $a < b$. Então teremos também

$$\int_a^b f_X(x)\,dx \approx F_X(b) - F_X(a)$$

para todo $a < b$. Chamaremos tal f_X de função densidade da distribuição populacional.

Em essência, é assim que muitas distribuições contínuas surgem na prática. Na Figura 5.4.2, traçamos um histograma de densidade para os mesmos valores usados na Figura 5.4.1, mas desta vez usamos os extremos de intervalo $h_1 = -5, h_2 = -4{,}75, \ldots, h_{41} = 5$. Notamos que a Figura 5.4.2 se parece muito mais com uma função contínua do que a Figura 5.4.1.

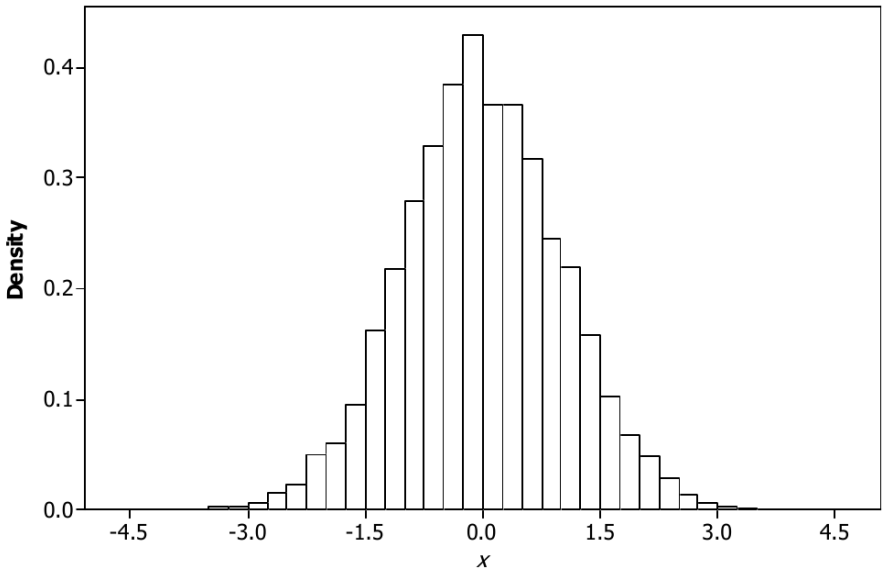


Figura 5.4.2: Função histograma de densidade de uma amostra de 10.000 da distribuição $N(0, 1)$, usando os valores $h_1 = -5, h_2 = -4{,}75, \ldots, h_{41} = 5$.

5.4.4 Amostragem por Levantamento

A amostragem de populações finitas fornece a formulação de uma aplicação muito importante da estatística, a saber, a *amostragem por levantamento*[29] ou

No original: *survey sampling*[29].

pesquisa de opinião. Em geral, um levantamento consiste num conjunto de perguntas feitas a uma amostra $\{\pi_1, \dots, \pi_n\}$ de uma população Π. Cada pergunta corresponde a uma medição, de modo que, se há m perguntas, a resposta de um respondente π é o vetor m-dimensional $(X_1(\pi), X_2(\pi), \dots, X_m(\pi))$. Um exemplo muito importante de amostragem por levantamento são as pesquisas eleitorais feitas para prever o resultado de uma votação. Além disso, muitas empresas de bens de consumo realizam extensas pesquisas de mercado para tentar descobrir o que os consumidores querem e, assim, obter informações que possam levar a vendas maiores.

Em geral, a análise dos resultados se interessa não só pelas distribuições populacionais de cada X_i sobre a população, mas também pelas distribuições populacionais conjuntas. Por exemplo, a função de distribuição acumulada conjunta de (X_1, X_2) é dada por

$$F_{(X_1,X_2)}(x_1, x_2) = \frac{|\{\pi : X_1(\pi) \leq x_1, X_2(\pi) \leq x_2\}|}{N},$$

isto é, $F_{(X_1,X_2)}(x_1, x_2)$ é a proporção dos indivíduos da população cuja medição X_1 não passa de x_1 e cuja medição X_2 não passa de x_2. É claro que podemos também definir as distribuições conjuntas de três ou mais medições. Essas distribuições conjuntas são o que usamos para responder a perguntas como: há relação entre X_1 e X_2 e, se houver, que forma ela assume? Esse tema será discutido extensamente no Capítulo 10. Podemos também definir $f_{(X_1,X_2)}$ para a distribuição conjunta[30], e histogramas de densidade conjuntos são de novo úteis quando X_1 e X_2 são ambas variáveis quantitativas contínuas.

No original: *joint distribution*[30].

Exemplo 5.4.3

Suponha que há quatro candidatos concorrendo a prefeito de certa cidade. Uma amostra aleatória de 1000 eleitores é selecionada; cada um deles é perguntado se vai votar e, em caso afirmativo, em qual dos quatro candidatos vai votar. Além disso, pergunta-se a idade dos respondentes. Denotamos a resposta à pergunta sobre se vão ou não votar por X_1, com $X_1(\pi) = 1$ significando sim e $X_1(\pi) = 0$ significando não. Para os que vão votar, denotamos por X_2 a resposta sobre o candidato em quem vão votar, com $X_2(\pi) = i$ indicando o candidato i. Por fim, a idade do respondente, em anos, é denotada por X_3. Além das distribuições de X_1 e X_2, o pesquisador também se interessa pelas distribuições conjuntas de (X_1, X_3) e (X_2, X_3), pois elas nos informam sobre a relação entre a participação dos eleitores e a idade, no primeiro caso, e entre a escolha de candidato e a idade, no segundo. ■

Há muitos aspectos interessantes e importantes da amostragem por levantamento que vão bem além deste livro. Por exemplo, muitas vezes acontece, em populações humanas, que uma pessoa selecionada ao acaso não responda a um levantamento. Isso se chama *erro de não resposta*[31], e é um efeito de seleção sério. Quem faz a amostragem precisa planejar o estudo com cuidado para tentar atenuar os efeitos do erro de não resposta. Além disso, há variantes da amostragem aleatória simples (veja o Desafio 5.4.20) que podem ser preferíveis em certos contextos, pois aumentam a precisão dos resultados. O desenho do questionário usado também é muito importante, pois precisamos garantir que as respostas tratem das questões pretendidas sem enviesar os resultados.

Resumo da Seção 5.4

- A amostragem aleatória simples de uma população Π significa que selecionamos ao acaso um subconjunto de tamanho n de Π de modo que cada subconjunto de n elementos tenha a mesma probabilidade — a saber, $1/\binom{|\Pi|}{n}$ — de ser selecionado.
- Os dados que surgem de um estudo amostral são gerados pela distribuição da medição de interesse X sobre a população Π inteira, e não sobre alguma subpopulação. É por isso que estudos amostrais são preferíveis a estudos observacionais.

No original: *nonresponse error*[31].

- Quando o tamanho da amostra n é pequeno em relação a $|\Pi|$, podemos tratar os valores observados de X como uma amostra da distribuição de X sobre a população.

Exercícios

5.4.1 Suponha que temos uma população $\Pi = \{\pi_1, \ldots, \pi_{10}\}$ e a medição quantitativa X dada por:

i	1	2	3	4	5	6	7	8	9	10
$X(\pi_i)$	1	1	2	1	2	3	3	1	2	4

Calcule F_X, f_X, μ_X e σ_X^2.

5.4.2 Suponha que você toma uma amostra de $n = 3$ (sem reposição) da população do Exercício 5.4.1.

(a) Você pode considerar isso uma amostra aproximadamente i.i.d. da distribuição populacional? Por quê?

(b) Explique como você faria fisicamente a amostragem da população nesse caso. (Sugestão: Tabela D.1.)

(c) Usando o método que você descreveu na parte (b), gere três amostras de tamanho $n = 3$ e calcule $\bar{X}$ para cada amostra.

5.4.3 Suponha que você toma uma amostra de $n = 4$ (com reposição) da população do Exercício 5.4.1.

(a) Você pode considerar isso uma amostra aproximadamente i.i.d. da distribuição populacional? Por quê?

(b) Explique como você faria fisicamente a amostragem nesse caso.

(c) Usando o método que você descreveu na parte (b), gere três amostras de tamanho $n = 3$* e calcule $\bar{X}$ para cada amostra.

5.4.4 Suponha que temos uma população finita Π e uma medição $X : \Pi \to \{0, 1\}$, em que $|\Pi| = N$ e $|\{\pi : X(\pi) = 0\}| = a$.

(a) Determine $f_X(0)$ e $f_X(1)$. Você consegue identificar essa distribuição populacional?

(b) Para uma amostra aleatória simples de tamanho n, determine a probabilidade de que $n\hat{f}_X(0) = x$.

*Nota do tradutor. o original traz $n = 3$; pelo enunciado (amostra de $n = 4$) seria $n = 4$

(c) Sob a suposição de amostragem i.i.d., determine a probabilidade de que $n\hat{f}_X(0) = x$.

5.4.5 Suponha que a seguinte amostra de tamanho $n = 20$ é obtida de um processo industrial.

3,9	7,2	6,9	4,5	5,8	3,7	4,4	4,5	5,6	2,5
4,8	8,5	4,3	1,2	2,3	3,1	3,4	4,8	1,8	3,7

(a) Construa um histograma de densidade para esse conjunto de dados usando os intervalos $(1; 4{,}5]$, $(4{,}5; 5{,}5]$, $(5{,}5; 6{,}5]$, $(6{,}5; 10]$.

(b) Construa um histograma de densidade para esse conjunto de dados usando os intervalos $(1; 3{,}5]$, $(3{,}5; 4{,}5]$, $(4{,}5; 6{,}5]$, $(6{,}5; 10]$.

(c) Com base nos resultados das partes (a) e (b), o que você conclui sobre histogramas?

5.4.6 Suponha que se sabe que, numa população de 1000 alunos, 350 alunos vão votar no partido A, 550 alunos vão votar no partido B e os alunos restantes vão votar no partido C.

(a) Explique como tal informação pode ser obtida.

(b) Se tomamos $X : \Pi \to \{A, B, C\}$ tal que $X(\pi)$ é o partido em que π vai votar, explique por que não podemos representar a distribuição populacional de X por F_X.

(c) Calcule f_X.

(d) Explique como se poderia estimar f_X antes da eleição.

(e) O que há de irrealista na distribuição populacional especificada por f_X? (Sugestão: isso parece realista, com base no que você sabe sobre o comportamento dos eleitores?)

5.4.7 Considere a população Π como os arquivos armazenados num computador num certo momento. Suponha que $X(\pi)$ é o tipo do arquivo, conforme indicado por sua extensão, por exemplo, .mp3. X é uma variável categórica ou quantitativa?

5.4.8 Suponha que lhe pedem para estimar a proporção de alunos de uma faculdade de 15.000 alunos que pretendem trabalhar durante as férias de verão.

(a) Identifique a população Π, a variável X e f_X. Que tipo de variável é X?

(b) Como você poderia determinar f_X exatamente?

(c) Por que você poderia não conseguir determinar f_X exatamente? Proponha um procedimento para estimar f_X nessa situação.

(d) Suponha que lhe pediram também para estimar a proporção de alunos que pretendiam trabalhar mas não conseguiram encontrar emprego. Repita as partes (a), (b) e (c) para essa situação.

5.4.9 Às vezes, os participantes de uma pesquisa de opinião não respondem com sinceridade a uma pergunta. Por exemplo, alunos a quem se pergunta "Você já baixou música ilegalmente?" podem não responder com sinceridade, mesmo que tenham a garantia de que suas respostas são confidenciais. Suponha que uma amostra aleatória simples de alunos foi escolhida numa faculdade e que essa pergunta foi feita aos alunos.

(a) Se a pergunta foi feita aos alunos por uma pessoa, comente como você acha que os resultados do estudo amostral seriam afetados.

(b) Se os alunos puderam responder anonimamente, talvez enviando um questionário pelo correio, comente como você acha que os resultados seriam afetados.

(c) Uma técnica para lidar com o viés do respondente induzido por tais perguntas é fazer os alunos responderem com sinceridade apenas quando ocorre certo evento aleatório. Por exemplo, poderíamos pedir a um aluno que lance uma moeda honesta três vezes e minta sempre que obtiver duas caras. Qual é a probabilidade de que um aluno diga a verdade? Depois de concluir o estudo e registrar a proporção de alunos que disseram ter trapaceado, que proporção você registraria como sua estimativa da proporção de alunos que de fato trapacearam?

5.4.10 Uma empresa de pesquisa de mercado é contratada para determinar quão satisfeitos os proprietários estão com a compra de um carro novo nos últimos 6 meses. A satisfação deve ser medida pelos respondentes escolhendo um ponto numa escala de sete pontos $\{1, 2, 3, 4, 5, 6, 7\}$, em que 1 indica completamente insatisfeito e 7 indica completamente satisfeito (tal escala é comumente chamada de *escala Likert*).

(a) Identifique Π, a variável X e f_X.

(b) É comum tratar uma variável como X como uma variável quantitativa. Você acha que isso está correto? Seria correto tratar X como uma variável categórica?

(c) Uma crítica comum ao uso de tal escala é que a interpretação de uma afirmação como $3 =$ "estou um pouco insatisfeito" varia de uma pessoa para outra. Comente como isso afeta a validade do estudo.

Exercícios computacionais

5.4.11 Gere uma amostra de 1000 da distribuição $N(3, 2)$.

(a) Calcule $\hat{F}_X$ para essa amostra.

(b) Trace um histograma de densidade baseado nesses dados usando os intervalos de comprimento 1 na faixa $(-5, 10)$.

(c) Trace um histograma de densidade baseado nesses dados usando os intervalos de comprimento 0,1 na faixa $(-5, 10)$.

(d) Comente a diferença na aparência dos histogramas das partes (b) e (c). A que você atribui isso?

(e) O que limita o tamanho dos intervalos que usamos para agrupar as observações quando traçamos histogramas?

5.4.12 Suponha que temos uma população de 10.000 elementos, cada um com um rótulo único do conjunto $\{1, 2, 3, \dots, 10.000\}$.

(a) Gere uma amostra de 500 rótulos dessa população usando amostragem aleatória simples.

(b) Gere uma amostra de 500 rótulos dessa população usando amostragem i.i.d.

Problemas

5.4.13 Suponha que temos uma população finita Π e uma medição $X : \Pi \to \{0, 1, 2\}$, em que $|\Pi| = N$, $|\{\pi : X(\pi) = 0\}| = a$ e $|\{\pi : X(\pi) = 1\}| = b$. Este problema generaliza o Exercício 5.4.4.

(a) Determine $f_X(0)$, $f_X(1)$ e $f_X(2)$.

(b) Para uma amostra aleatória simples de tamanho n, determine a probabilidade de que $\hat{f}_X(0) = f_0$, $\hat{f}_X(1) = f_1$ e $\hat{f}_X(2) = f_2$.

(c) Sob a suposição de amostragem i.i.d., determine a probabilidade de que $\hat{f}_X(0) = f_0$, $\hat{f}_X(1) = f_1$ e $\hat{f}_X(2) = f_2$.

5.4.14 Suponha que X é uma medição quantitativa definida numa população finita.

(a) Prove que a média populacional é igual a $\mu_X = \sum_x x f_X(x)$, isto é, que a média de $X(\pi)$ sobre todos os elementos π da população é igual a μ_X.

(b) Prove que a variância populacional é dada por $\sigma_X^2 = \sum_x (x - \mu_X)^2 f_X(x)$, isto é, que a média de $(X(\pi) - \mu_X)^2$ sobre todos os elementos π da população é igual a σ_X^2.

5.4.15 Suponha que temos a situação descrita no Exercício 5.4.4 e que tomamos uma amostra aleatória simples de tamanho n de Π, em que $|\Pi| = N$.

(a) Prove que a média de $\hat{f}_X(0)$ é dada por $f_X(0)$. (Sugestão: note que podemos escrever $\hat{f}_X(0) = n^{-1} \sum_{i=1}^n I_{\{0\}}(X(\pi_i))$ e $I_{\{0\}}(X(\pi_i)) \sim$ Bernoulli$(f_X(0))$.)

(b) Prove que a variância de $\hat{f}_X(0)$ é dada por

$$\frac{f_X(0)(1 - f_X(0))}{n} \frac{N - n}{N - 1}. \tag{5.4.1}$$

(Sugestão: use a sugestão da parte (a), mas note que os $I_{\{0\}}(X(\pi_i))$ não são independentes. Use o Teorema 3.3.4(b) e calcule $\mathrm{Cov}\big(I_{\{0\}}(X(\pi_i)), I_{\{0\}}(X(\pi_i))\big)$* em termos de $f_X(0)$.)

(c) Repita as contas das partes (a) e (b), mas desta vez suponha que você toma uma amostra de n com reposição. (Sugestão: use o Exercício 5.4.4(c).)

(d) Explique por que o fator $(N - n)/(N - 1)$ em (5.4.1) é chamado de *fator de correção para população finita*[32].

5.4.16 Suponha que temos uma população finita Π e que não conhecemos $|\Pi| = N$. Além disso, suponha que temos uma variável de medição $X : \Pi \to \{0, 1\}$ e que sabemos que $N f_X(0) = a$, em que a é conhecido. Com base numa amostra aleatória simples de n elementos de Π, determine um estimador de N. (Sugestão: use uma função de $\hat{f}_X(0)$.)

5.4.17 Suponha que X é uma variável quantitativa definida numa população Π e que tomamos uma amostra aleatória simples de tamanho n de Π.

(a) Se estimamos a média populacional μ_X pela média amostral $\bar{X} = \frac{1}{n} \sum_{i=1}^n X(\pi_i)$, prove que $E(\bar{X}) = \mu_X$, em que μ_X é definida no Problema 5.4.14(a). (Sugestão: qual é a distribuição de cada $X(\pi_i)$?)

(b) Sob a suposição de que a amostragem i.i.d. faz sentido, mostre que a variância de $\bar{X}$ é igual a σ_X^2/n, em que σ_X^2 é definida no Problema 5.4.14(b).

*__Nota do tradutor.__ o original traz π_i nos dois argumentos; pelo contexto seria π_i e π_j, com $i \neq j$

No original: *finite population correction factor*[32].

5.4.18 Suponha que temos uma população finita Π e que não conhecemos $|\Pi| = N$. Além disso, suponha que temos uma variável de medição $X : \Pi \to R^1$ e que conhecemos $T = \sum_\pi X(\pi)$. Com base numa amostra aleatória simples de n elementos de Π, determine um estimador de N. (Sugestão: use uma função de $\bar{X}$.)

5.4.19 Sob amostragem i.i.d., prove que $\hat{f}_X(x) \xrightarrow{D} f_X(x)$ quando $n \to \infty$. (Sugestão: $\hat{f}_X(x) = n^{-1} \sum_{i=1}^n I_{\{x\}}(X(\pi_i))$.)

Desafios

5.4.20 (*Amostragem estratificada*[33]) Suponha que X é uma variável quantitativa definida numa população Π e que podemos particionar Π em duas subpopulações Π_1 e Π_2, de modo que uma proporção p da população inteira esteja em Π_1. Seja f_{iX} a distribuição populacional condicional de X em Π_i.

(a) Prove que $f_X(x) = pf_{1X}(x) + (1-p)f_{2X}(x)$.

(b) Estabeleça que $\mu_X = p\mu_{1X} + (1-p)\mu_{2X}$, em que μ_{iX} é a média de X em Π_i.

(c) Estabeleça que $\sigma_X^2 = p\sigma_{1X}^2 + (1-p)\sigma_{2X}^2 + p(1-p)(\mu_{1X} - \mu_{2X})^2$.

(d) Suponha que faz sentido supor amostragem i.i.d. sempre que tomamos uma amostra da população inteira ou de qualquer uma das subpopulações, isto é, sempre que os tamanhos de amostra que estamos considerando são pequenos em relação aos tamanhos dessas populações. Implementamos a amostragem estratificada tomando uma amostra aleatória simples de tamanho n_i da subpopulação Π_i. Estimamos então μ_X por $p\bar{X}_1 + (1-p)\bar{X}_2$, em que $\bar{X}_i$ é a média amostral baseada na amostra de Π_i. Prove que $E(p\bar{X}_1 + (1-p)\bar{X}_2) = \mu_X$ e

$$\mathrm{Var}\big(p\bar{X}_1 + (1-p)\bar{X}_2\big) = p^2\frac{\sigma_{1X}^2}{n_1} + (1-p)^2\frac{\sigma_{2X}^2}{n_2}.$$

(e) Sob as suposições da parte (d), prove que

$$\mathrm{Var}\big(p\bar{X}_1 + (1-p)\bar{X}_2\big) \leq \mathrm{Var}\big(\bar{X}\big)$$

quando $\bar{X}$ se baseia numa amostra aleatória simples de tamanho n da população inteira e $n_1 = pn$, $n_2 = (1-p)n$. Isso se chama *amostragem estratificada proporcional*.

No original: *stratified sampling*[33].

(f) Em que condições não há benefício na amostragem estratificada proporcional? O que você conclui sobre as situações em que a amostragem estratificada será mais benéfica?

Tópicos para discussão

5.4.21 Às vezes, argumenta-se que um profissional habilidoso consegue escolher, de forma determinística, uma amostra representativa de uma população mais precisa do que empregando a amostragem aleatória simples. Esse argumento se baseia, em parte, no argumento de que, com a amostragem aleatória simples, é sempre possível obter, por puro acaso, uma amostra muito pouco representativa, e que isso pode ser evitado por um especialista. Comente essa afirmação.

5.4.22 Suponha que se afirma que uma medição quantitativa X definida numa população finita Π tem distribuição aproximadamente normal, com média desconhecida e variância desconhecida. Explique detalhadamente o que essa afirmação significa.

5.5 Algumas Inferências Básicas

Suponha agora que estamos numa situação que envolve uma medição X, cuja distribuição é desconhecida, e que obtivemos os dados $(x_1, x_2, \dots, x_n)$, isto é, observamos n valores de X. Espera-se que esses dados tenham resultado de uma amostragem aleatória simples, mas talvez eles tenham sido coletados como parte de um estudo observacional. Denote por f_X a função de frequência relativa populacional desconhecida associada, ou uma densidade que a aproxime, e por F_X a função de distribuição populacional.

O que fazemos agora com os dados depende de duas coisas. Primeiro, temos de determinar o que queremos saber sobre a distribuição populacional subjacente. Tipicamente, nosso interesse está em apenas algumas características dessa distribuição — a média e a variância. Segundo, temos de usar a teoria estatística para combinar os dados com o modelo estatístico e fazer inferências sobre as características de interesse.

Discutimos agora algumas características de interesse típicas e apresentamos alguns métodos informais de estimação[34] dessas características, conhecidos

No original: *estimation*[34].

como *estatísticas descritivas*. Elas costumam ser usadas como um passo preliminar antes de se tirarem inferências mais formais e se justificam por razões intuitivas simples. São chamadas de descritivas porque estimam quantidades que *descrevem* aspectos da distribuição subjacente.

5.5.1 Estatísticas Descritivas

Os estatísticos muitas vezes se concentram em várias características das distribuições. Apresentamos algumas delas nos exemplos a seguir.

Exemplo 5.5.1 — Estimando Proporções e Proporções Acumuladas

Muitas vezes queremos fazer inferências sobre o valor $f_X(x)$ ou o valor $F_X(x)$ para um x específico. Lembre que $f_X(x)$ é a proporção de membros da população cuja medição X é igual a x. Em geral, $F_X(x)$ é a proporção de membros da população cuja medição X é menor ou igual a x.

Suponha agora que temos uma amostra $(x_1, x_2, \ldots, x_n)$ de f_X. Uma estimativa natural de $f_X(x)$ é dada por $\hat{f}_X(x)$, a proporção de valores amostrais iguais a x. Uma estimativa natural de $F_X(x)$ é dada por $\hat{F}_X(x) = n^{-1}\sum_{i=1}^{n} I_{(-\infty,x]}(x_i)$, a proporção de valores amostrais menores ou iguais a x, também conhecida como a função de distribuição empírica avaliada em x.

Suponha que obtivemos a seguinte amostra de $n = 10$ valores.

1,2	2,1	0,4	3,3	−2,1	4,0	−0,3	2,2	1,5	5,0

Nesse caso, $\hat{f}_X(x) = 0{,}1$ sempre que x é um valor dos dados, e vale 0 caso contrário. Para calcular $\hat{F}_X(x)$, basta contar quantos valores amostrais são menores ou iguais a x e dividir por $n = 10$. Por exemplo, $\hat{F}_X(-3) = 0/10 = 0$, $\hat{F}_X(0) = 2/10 = 0{,}2$ e $\hat{F}_X(4) = 9/10 = 0{,}9$. ■

Uma classe importante de características da distribuição de uma variável quantitativa X é dada pela definição a seguir.

Definição 5.5.1

Para $p \in [0, 1]$, o *p-ésimo quantil* (ou $100p$*-ésimo percentil*) x_p da distribuição com fda F_X é definido como o menor número x_p que satisfaz $p \leq F_X(x_p)$.

Por exemplo, se a sua nota numa prova o colocou no 90º percentil, então sua

nota é igual a $x_{0,9}$ e 90% dos colegas que fizeram a prova tiraram a sua nota ou menos. Observe que, pela definição da função de distribuição acumulada inversa (Definição 2.10.1), podemos escrever $x_p = F_X^{-1}(p) = \min\{x : p \leq F_X(x)\}$.

Quando F_X é estritamente crescente[35] e contínua, $F_X^{-1}(p)$ é o único valor x_p que satisfaz

$$F_X(x_p) = p. \tag{5.5.1}$$

A Figura 5.5.1 ilustra a situação em que há uma única solução de (5.5.1). Quando F_X não é estritamente crescente ou não é contínua (como quando X é discreta), pode haver mais de uma solução de (5.5.1), ou nenhuma. A Figura 5.5.2 ilustra a situação em que não há solução de (5.5.1).

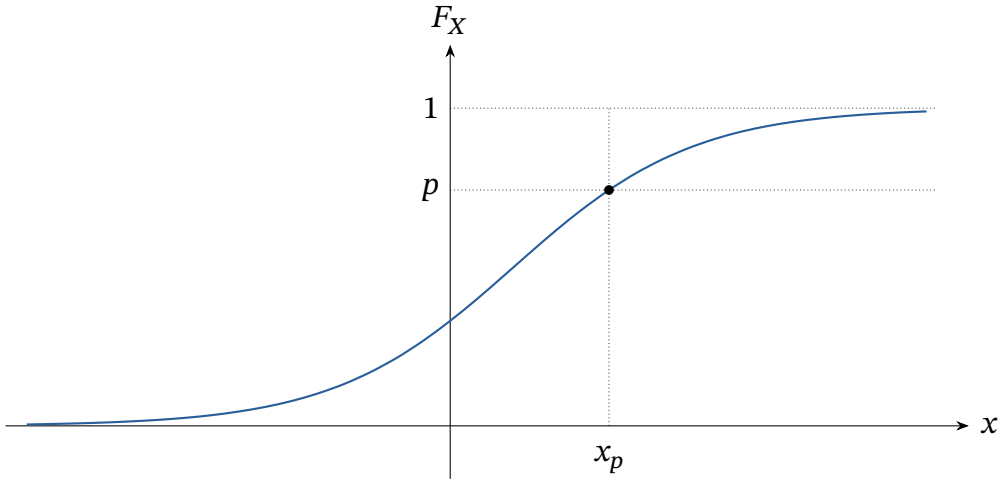


Figura 5.5.1: O p-ésimo quantil x_p quando há uma única solução de (5.5.1).

Assim, quando X é uma medição contínua, uma proporção p da população tem sua medição X menor ou igual a x_p. Como casos particulares, $x_{0,5} = F_X^{-1}(0{,}5)$ é a *mediana*, enquanto $x_{0,25} = F_X^{-1}(0{,}25)$ e $x_{0,75} = F_X^{-1}(0{,}75)$ são, respectivamente, o primeiro e o terceiro *quartis* da distribuição.

Exemplo 5.5.2 — Estimando Quantis

Uma estimativa natural de um quantil populacional $x_p = F_X^{-1}(p)$ é usar $\hat{x}_p = \hat{F}_X^{-1}(p)$. Observe, porém, que $\hat{F}_X$ não é contínua, de modo que pode não haver solução de (5.5.1) usando $\hat{F}_X$.

Aplicar a Definição 5.5.1, porém, leva à estimativa a seguir. Primeiro, ordene os valores amostrais observados $(x_1, \ldots, x_n)$ para obter as *estatísticas de ordem* $x_{(1)} < \cdots < x_{(n)}$ (ver Seção 2.8.4). Depois, observe que $x_{(i)}$ é o

No original: *strictly increasing*[35].

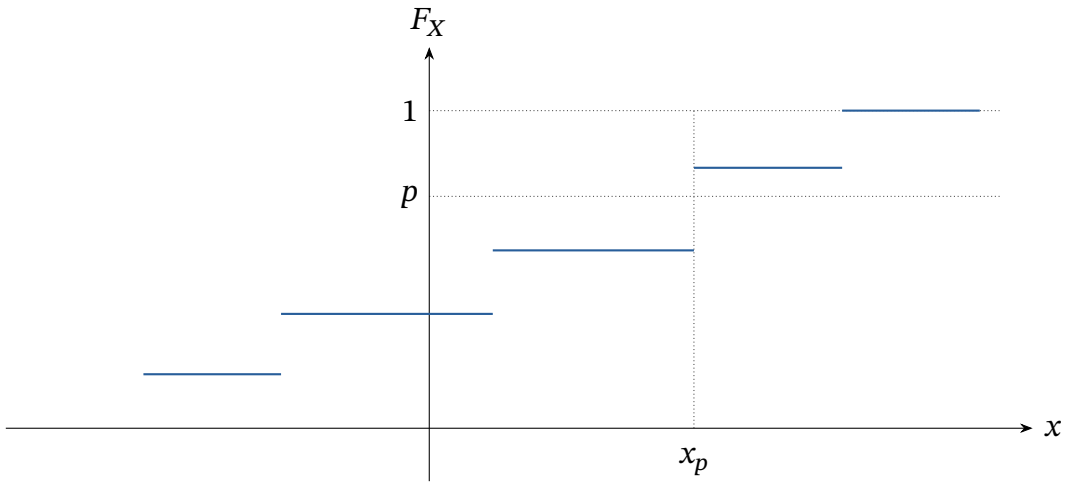


Figura 5.5.2: O p-ésimo quantil x_p determinado por uma fda F_X quando não há solução de (5.5.1).

(i/n)-ésimo quantil da distribuição empírica, porque

$$\hat{F}_X(x_{(i)}) = \frac{i}{n}$$

e $\hat{F}_X(x) < i/n$ sempre que $x < x_{(i)}$. Em geral, temos que o *p-ésimo quantil amostral* é $\hat{x}_p = x_{(i)}$ sempre que

$$\frac{i-1}{n} < p \leq \frac{i}{n}. \tag{5.5.2}$$

Algumas modificações dessa estimativa são usadas às vezes. Por exemplo, se encontrarmos i tal que (5.5.2) seja satisfeita e pusermos

$$\tilde{x}_p = x_{(i-1)} + n\big(x_{(i)} - x_{(i-1)}\big)\left(p - \frac{i-1}{n}\right), \tag{5.5.3}$$

então $\tilde{x}_p$ é a interpolação linear entre $x_{(i-1)}$ e $x_{(i)}$. Quando n é par, essa definição dá a *mediana amostral* como $\tilde{x}_{0,5} = x_{(n/2)}$; uma fórmula parecida vale quando n é ímpar (Problema 5.5.21). Veja também o Problema 5.5.22 para mais discussão sobre (5.5.3).

Com bastante frequência, a mediana amostral é definida como

$$\check{x}_{0,5} = \begin{cases} x_{((n+1)/2)} & n \text{ ímpar} \\ \frac{1}{2}\big(x_{(n/2)} + x_{(n/2+1)}\big) & n \text{ par,} \end{cases} \tag{5.5.4}$$

isto é, o valor do meio quando n é ímpar e a média dos dois valores do meio quando n é par. Para n grande o bastante, todas essas definições dão respostas parecidas. Qualquer uma delas pode ser usada numa aplicação.

Considere os dados do Exemplo 5.5.1. Ordenando os dados do menor para o maior, as estatísticas de ordem são dadas pela tabela a seguir.

$x_{(1)} = -2{,}1$	$x_{(2)} = -0{,}3$	$x_{(3)} = 0{,}4$	$x_{(4)} = 1{,}2$	$x_{(5)} = 1{,}5$
$x_{(6)} = 2{,}1$	$x_{(7)} = 2{,}2$	$x_{(8)} = 3{,}3$	$x_{(9)} = 4{,}0$	$x_{(10)} = 5{,}0$

Então, usando (5.5.3), a mediana amostral é dada por $\tilde{x}_{0,5} = x_{(5)} = 1{,}5$, enquanto os quartis amostrais são dados por

$$\begin{aligned}\tilde{x}_{0,25} &= x_{(2)} + 10\big(x_{(3)} - x_{(2)}\big)(0{,}25 - 0{,}2) \\ &= -0{,}3 + 10\,(0{,}4 - (-0{,}3))\,(0{,}25 - 0{,}2) = 0{,}05\end{aligned}$$

e

$$\begin{aligned}\tilde{x}_{0,75} &= x_{(7)} + 10\big(x_{(8)} - x_{(7)}\big)(0{,}75 - 0{,}7) \\ &= 2{,}2 + 10\,(3{,}3 - 2{,}2)\,(0{,}75 - 0{,}7) = 2{,}75.\end{aligned}$$

Assim, nesse caso, estimamos que 25% da população em estudo tem medição X menor que 0,05 etc. ■

Exemplo 5.5.3 — Medindo a Locação e a Escala de uma Distribuição Populacional

Muitas vezes nos pedem para fazer inferências sobre o valor da *média populacional*

$$\mu_X = \frac{1}{|\Pi|}\sum_{\pi\in\Pi} X(\pi)$$

e da *variância populacional*

$$\sigma_X^2 = \frac{1}{|\Pi|}\sum_{\pi\in\Pi}\big(X(\pi) - \mu_X\big)^2,$$

em que Π é uma população finita e X é uma medição a valores reais definida sobre ela. Elas são, respectivamente, medidas da posição e da dispersão da distribuição populacional em torno da média. Observe que calcular uma média ou uma variância só faz sentido quando X é uma variável quantitativa.

Quando X é discreta, podemos também escrever

$$\mu_X = \sum_x x f_X(x)$$

porque $|\Pi| f_X(x)$ é igual ao número de elementos $\pi \in \Pi$ com $X(\pi) = x$. No caso contínuo, usando uma densidade aproximada f_X, podemos escrever

$$\mu_X \approx \int_{-\infty}^{\infty} x f_X(x)\, dx.$$

Existem fórmulas parecidas para a variância populacional de X (ver Problema 5.4.14).

Provavelmente lhe ocorrerá que uma estimativa natural da média populacional μ_X é dada pela média amostral

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i.$$

Do mesmo modo, uma estimativa natural da variância populacional σ_X^2 é dada pela *variância amostral*

$$s^2 = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{x})^2. \tag{5.5.5}$$

Mais adiante explicaremos por que dividimos por $n - 1$ em (5.5.5), e não por n. Na verdade, faz pouca diferença qual usamos, mesmo para valores modestos de n. O *desvio padrão amostral* é dado por s, a raiz quadrada positiva de s^2. Para os dados do Exemplo 5.1.1, obtemos $\bar{x} = 1{,}73$ e $s = 2{,}097$.*

A média populacional μ_X e o desvio padrão populacional σ_X funcionam como um par, em que μ_X mede onde a distribuição está localizada na reta real e σ_X mede quanta dispersão há na distribuição em torno de μ_X. Claramente, quanto maior o valor de σ_X, mais variabilidade há na distribuição.

Alternativamente, poderíamos usar a mediana populacional $x_{0,5}$ como medida de posição da distribuição e a *amplitude interquartil populacional* $x_{0,75} - x_{0,25}$ como medida da quantidade de variabilidade na distribuição em torno da mediana. A mediana e a amplitude interquartil são a escolha preferida para medir esses aspectos da distribuição sempre que a distribuição é *assimétrica*, isto é, não simétrica. Isso porque a mediana é insensível a valores muito extremos, enquanto a média não é. Por exemplo, sabe-se bem que os preços dos imóveis numa região apresentam uma distribuição assimétrica à direita. Umas poucas casas vendidas por preços muito altos não mudam o preço mediano, mas podem provocar uma grande mudança no preço médio.

Quando temos uma distribuição simétrica, a média e a mediana coincidem (desde que a média exista). Quanto maior a assimetria de uma distribuição, porém, maior será a discrepância entre sua média e sua mediana. Por exemplo, na Figura 5.5.3 traçamos o gráfico da densidade de uma distribuição $\chi^2(4)$. Essa distribuição é assimétrica à direita, e a média é 4, enquanto a mediana é 3,3567.

Estimamos a amplitude interquartil populacional pela *amplitude interquartil amostral* (IQR), dada por $I\hat{Q}R = \tilde{x}_{0,75} - \tilde{x}_{0,25}$. Para os dados do Exemplo 5.5.1, obtemos a mediana amostral $\tilde{x}_{0,5} = 1{,}5$, enquanto $I\hat{Q}R = 2{,}75 - 0{,}05 = 2{,}70$.

Se mudarmos o maior valor da amostra de $x_{(10)} = 5{,}0$ para $x_{(10)} = 500{,}0$, a mediana amostral continua $\tilde{x}_{0,5} = 1{,}5$, mas observe que a média amostral vai de 1,73 para 51,23! ■

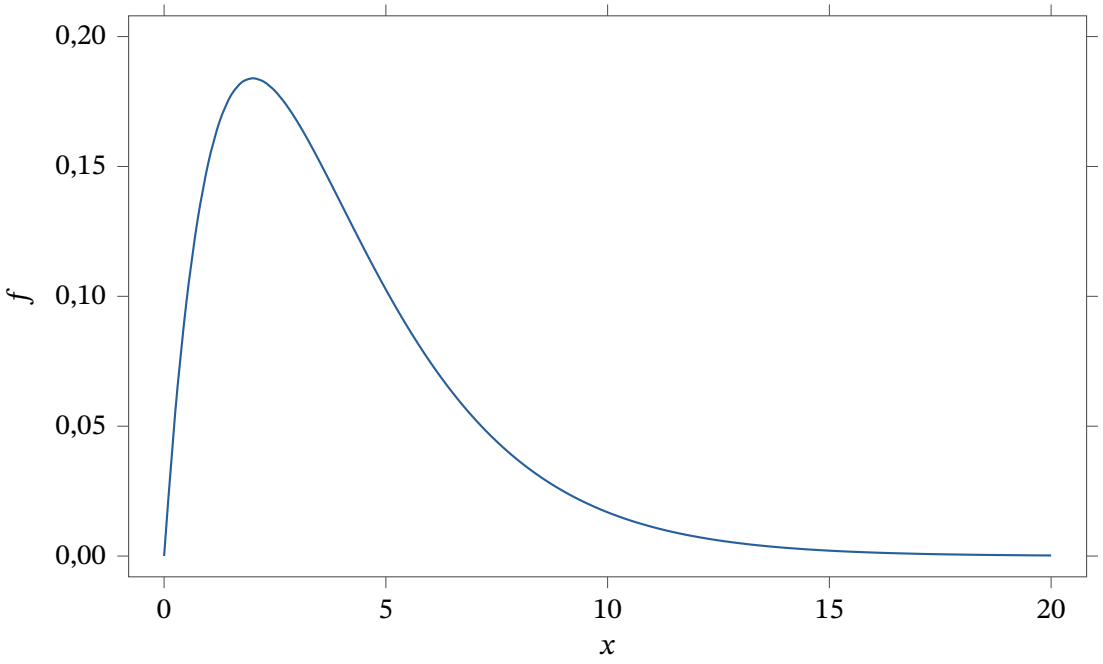


Figura 5.5.3: A densidade f de uma distribuição $\chi^2(4)$.*

*Nota do tradutor. o original traz "Exemplo 5.1.1"; os valores $\bar{x} = 1{,}73$ e $s = 2{,}097$ são os dos dados do Exemplo 5.5.1

*Nota do tradutor. No original, o eixo vertical vai até 0,03 e o pico da curva fica perto de 0,03; a densidade $\chi^2(4)$, $f(x) = xe^{-x/2}/4$, tem máximo $f(2) = 2e^{-1}/4 \approx 0{,}184$. O gráfico foi traçado pela fórmula, com o eixo ampliado até 0,20.

5.5.2 Gráficos dos Dados

É sempre uma boa ideia fazer o gráfico dos dados. Para variáveis quantitativas discretas, podemos fazer o gráfico de $\hat{f}_X$, isto é, das proporções amostrais (frequências relativas). Para variáveis quantitativas contínuas, apresentamos o histograma de densidade na Seção 5.4.3. Esses gráficos nos dão alguma ideia da forma da distribuição da qual estamos amostrando. Por exemplo, podemos ver se há algum indício de que a distribuição seja fortemente assimétrica.

Consideramos agora outro gráfico muito útil para variáveis quantitativas.

Exemplo 5.5.4 — Boxplots e Valores Atípicos

Outro gráfico útil para variáveis quantitativas é conhecido como *boxplot*. Por exemplo, a Figura 5.5.4 mostra um boxplot dos dados do Exemplo 5.5.1. A linha no centro da caixa é a mediana. A linha abaixo da mediana é o primeiro quartil, e a linha acima da mediana é o terceiro quartil.

As linhas verticais que saem dos quartis são chamadas de *bigodes* e vão dos quartis até os *valores adjacentes*. Os valores adjacentes são dados pelo maior valor menor ou igual ao *limite superior* (o terceiro quartil mais 1,5 vez o $I\hat{Q}R$) e pelo menor valor maior ou igual ao *limite inferior* (o primeiro quartil menos 1,5 vez o $I\hat{Q}R$). Valores além dos valores adjacentes, quando existem, são marcados com um $*$; neste caso, não há nenhum. Se mudarmos $x_{(10)} = 5{,}0$ para $x_{(10)} = 15{,}0$, porém, vemos esse valor extremo marcado com um $*$, como mostra a Figura 5.5.5.

Os pontos fora dos limites superior e inferior, e portanto marcados com $*$, costumam ser chamados de *valores atípicos*. Um valor atípico é um valor extremo em relação ao resto das observações. Às vezes, os valores atípicos ocorrem porque se cometeu um erro ao coletar ou registrar os dados, mas eles também ocorrem simplesmente porque estamos amostrando de uma distribuição de cauda longa. Muitas vezes é difícil saber qual é o caso numa aplicação específica, mas cada uma dessas observações deve ser registrada. Vimos no Exemplo 5.5.3 que valores atípicos podem ter um grande impacto nas análises estatísticas. Seus efeitos devem ser registrados ao relatar os resultados de uma análise estatística. ■

Para variáveis categóricas, é comum fazer o gráfico dos dados num gráfico de barras, como descrito no próximo exemplo.

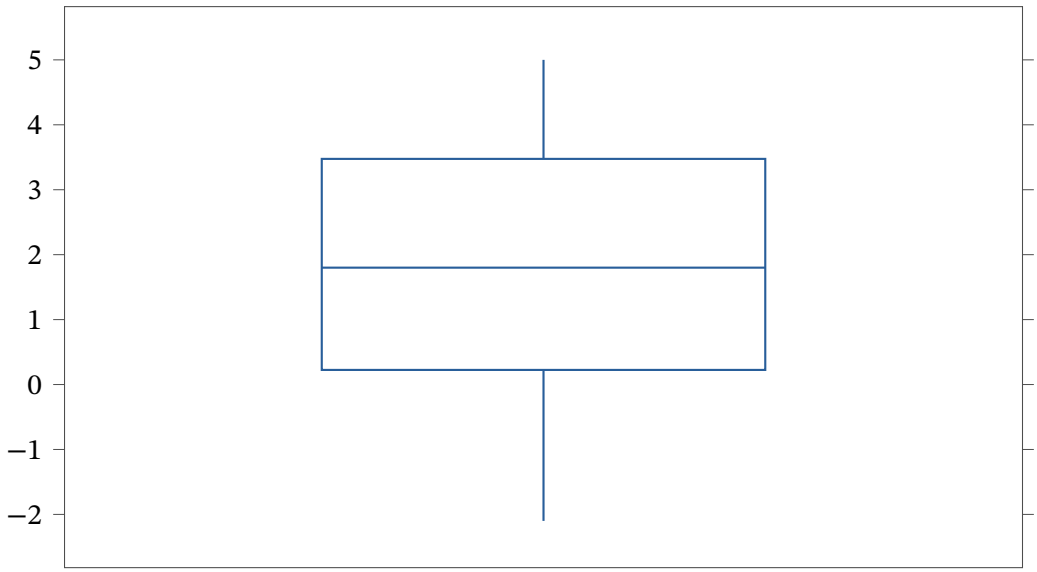


Figura 5.5.4: Um boxplot dos dados do Exemplo 5.5.1.

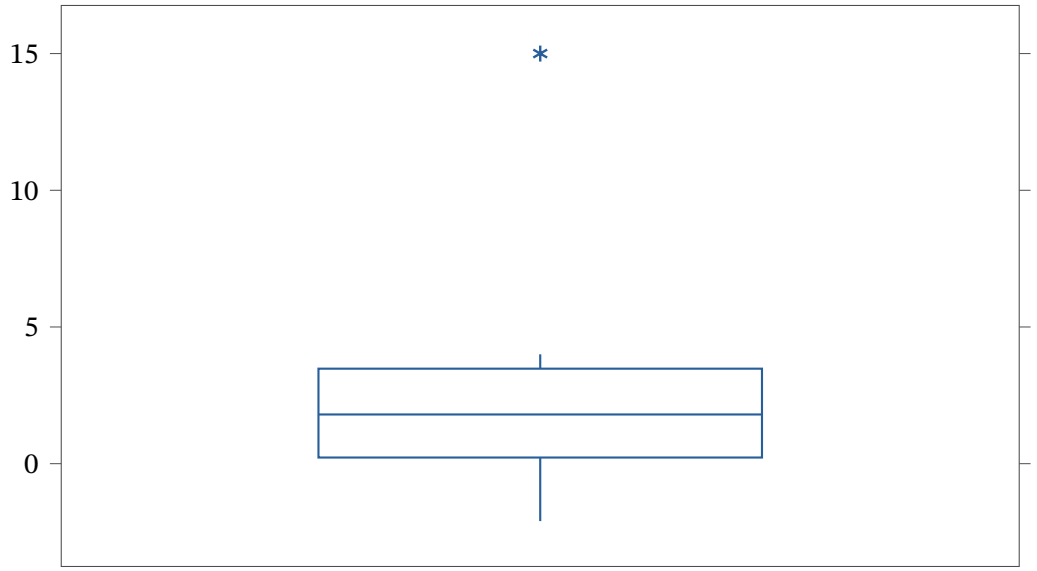


Figura 5.5.5: Um boxplot dos dados do Exemplo 5.5.1, trocando $x_{(10)} = 5{,}0$ por $x_{(10)} = 15{,}0$.

Exemplo 5.5.5 — Gráficos de Barras

Para variáveis categóricas, codificamos os valores da variável como números igualmente espaçados e então desenhamos retângulos de largura constante (as barras) sobre esses valores, de modo que a altura do retângulo sobre um valor seja igual à proporção de vezes que esse valor ocorre. Um gráfico assim é chamado de *gráfico de barras*. Observe que os valores ao longo do eixo x são apenas rótulos e não devem ser tratados como números com os quais podemos fazer contas etc.

Por exemplo, suponha que tomamos uma amostra aleatória simples de 100 estudantes e registramos o sabor de sorvete favorito de cada um (entre quatro possibilidades), obtendo os resultados dados na tabela a seguir.

Sabor	Contagem	Proporção
Chocolate	42	0,42
Baunilha	28	0,28
Caramelo	22	0,22
Morango	8	0,08

Codificando Chocolate como 1, Baunilha como 2, Caramelo como 3 e Morango como 4, a Figura 5.5.6 apresenta um gráfico de barras desses dados. É comum que as barras desses gráficos não se toquem. ■

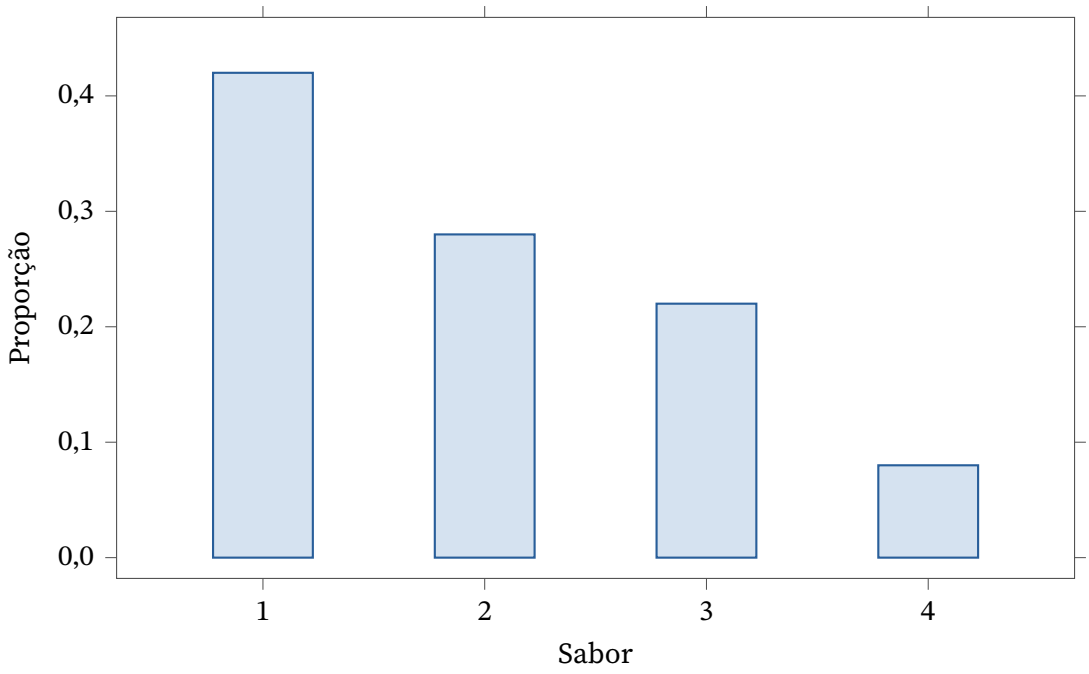


Figura 5.5.6: Um gráfico de barras dos dados do Exemplo 5.5.5.

5.5.3 Tipos de Inferências

Certamente, apresentar estatísticas descritivas e fazer gráficos dos dados são métodos que um estatístico usa para tentar aprender algo sobre a distribuição populacional subjacente. Essa abordagem tem dificuldades, porém, pois acabamos de escolher esses métodos com base na intuição. Muitas vezes não está claro quais estatísticas descritivas devemos usar. Além disso, esses resumos dos dados não fazem uso nenhum da informação que temos sobre a verdadeira distribuição populacional, expressa pelo modelo estatístico, a saber, $f_X \in \{f_\theta : \theta \in \mathbf{\Omega}\}$. Levar essa informação em conta nos leva a desenvolver uma teoria da inferência estatística, isto é, a especificar como devemos combinar a informação do modelo com os dados para fazer inferências sobre quantidades populacionais. Faremos isso nos Capítulos 6, 7 e 8, mas antes discutimos os tipos de inferência mais usados nas aplicações.

Na Seção 5.2, discutimos três tipos de inferência no contexto de um modelo de probabilidade conhecido, especificado por alguma função densidade ou função de probabilidade f. Observamos que poderíamos querer fazer qualquer uma das seguintes coisas a respeito de um valor de resposta s não observado.

(i) Predizer um valor de resposta s desconhecido por meio de uma predição t.

(ii) Construir um subconjunto C do espaço amostral S que tenha alta probabilidade de conter um valor de resposta s desconhecido.

(iii) Avaliar se $s_0 \in S$ é ou não um valor plausível da distribuição de probabilidade especificada por f.

Chamamos (i), (ii) e (iii) de *inferências* sobre o s não observado. Os exemplos da Seção 5.2 mostram que esses são conceitos intuitivamente razoáveis.

Numa aplicação, não conhecemos f; sabemos apenas que $f \in \{f_\theta : \theta \in \mathbf{\Omega}\}$, e observamos os dados s. Não temos certeza de qual candidata f_θ é a correta ou, de modo equivalente, de qual dos valores possíveis de θ é o correto.

Como mencionado na Seção 5.5.1, nosso objetivo principal pode ser determinar não a verdadeira f_θ, mas alguma característica da verdadeira distribuição, como sua média, sua mediana ou o valor da verdadeira função de distribuição F num valor especificado. Vamos denotar essa característica de interesse por $\psi(\theta)$. Por exemplo, quando a característica de interesse é a média da verdadeira distribuição de uma variável aleatória contínua, então

$$\psi(\theta) = \int_{-\infty}^{\infty} x f_\theta(x)\, dx.$$

Alternativamente, poderíamos estar interessados em $\psi(\theta) = F_\theta^{-1}(0{,}5)$, a mediana da distribuição de uma variável aleatória com função de distribuição dada por F_θ.

Valores diferentes de θ levam a valores possivelmente diferentes da característica $\psi(\theta)$. Depois de observar os dados s, queremos fazer inferências sobre qual é o valor correto. Vamos considerar os três tipos de inferência para $\psi(\theta)$.

(i) Escolher uma estimativa $T(s)$ de $\psi(\theta)$, o que chamamos de *problema de estimação*.

(ii) Construir um subconjunto $C(s)$ do conjunto de valores possíveis de $\psi(\theta)$ que acreditamos conter o valor verdadeiro, o que chamamos de problema de construção de uma *região de credibilidade*[36] ou de uma *região de confiança*[37].

(iii) Avaliar se ψ_0 é ou não um valor plausível para $\psi(\theta)$ depois de observar s, o que chamamos de problema de *avaliação de hipóteses*[38].

Assim, estimativas, regiões de credibilidade ou de confiança e avaliação de hipóteses são exemplos de tipos de inferência. Em particular, queremos construir estimativas $T(s)$ de $\psi(\theta)$, construir regiões de credibilidade ou de confiança $C(s)$ para $\psi(\theta)$ e avaliar quão plausível é um valor hipotético ψ_0 para $\psi(\theta)$.

O *problema da inferência estatística* consiste em determinar como devemos combinar a informação do modelo $\{f_\theta : \theta \in \mathbf{\Omega}\}$ com os dados s para realizar essas inferências sobre $\psi(\theta)$.

Um modelo estatístico muito importante nas aplicações é o modelo normal de locação e escala[39], apresentado no Exemplo 5.3.4. Ilustramos algumas das ideias discutidas nesta seção por meio desse modelo.

Exemplo 5.5.6 — Aplicação do Modelo Normal de Locação e Escala

Suponha que foi coletada a seguinte amostra aleatória simples das alturas (em polegadas) de 30 estudantes.

64,9	61,4	66,3	64,3	65,1	64,4	59,8	63,6	66,5	65,0
64,9	64,3	62,5	63,1	65,0	65,8	63,4	61,9	66,6	60,9
61,6	64,0	61,5	64,2	66,8	66,4	65,8	71,4	67,8	66,3

No original: *credible region*[36], *confidence region*[37], *hypothesis assessment*[38], *location-scale normal model*[39].

A estatística que analisa os dados acredita que a distribuição das alturas na população pode ser bem aproximada por uma distribuição normal com alguma média e alguma variância desconhecidas, e ela não está disposta a fazer nenhuma suposição adicional sobre a verdadeira distribuição. Assim, o modelo estatístico é dado pela família das distribuições $N(\mu, \sigma^2)$, em que $\theta = (\mu, \sigma^2) \in \mathbf{\Omega} = R^1 \times R^+$ é desconhecido.

Esse modelo estatístico faz sentido, isto é, a suposição de normalidade é adequada para essa situação? O histograma de densidade (baseado em 12 intervalos de mesmo comprimento, de 59,5 a 71,5) da Figura 5.5.7 parece normal, de modo bem grosseiro, mas a observação extrema na cauda direita pode ser algum motivo de preocupação. De todo modo, seguimos como se essa suposição fosse razoável. No Capítulo 9, discutiremos métodos mais refinados para avaliar essa suposição.

Suponha que estejamos interessados em fazer inferências sobre a altura média da população, isto é, a característica de interesse é $\psi(\mu, \sigma^2) = \mu$. Alternativamente, poderíamos querer fazer inferências sobre o 90º percentil dessa distribuição, isto é, $\psi(\mu, \sigma^2) = x_{0,90} = \mu + \sigma z_{0,90}$, em que $z_{0,90}$ é o 90º percentil da distribuição $N(0, 1)$ (quando $X \sim N(\mu, \sigma^2)$, então $P(X \leq \mu + \sigma z_{0,90}) = P((X - \mu)/\sigma \leq z_{0,90}) = \Phi(z_{0,90}) = 0{,}90$). Assim, 90% da população em estudo tem altura menor que $x_{0,90}$, um valor que desconhecemos porque não sabemos o valor de (μ, σ^2). Obviamente, há muitas outras características da verdadeira distribuição sobre as quais poderíamos querer fazer inferências.

Usando apenas a intuição, $T(x_1, \ldots, x_n) = \bar{x}$ parece uma estimativa sensata de μ, e $T(x_1, \ldots, x_n) = \bar{x} + s z_{0,90}$ parece uma estimativa sensata de $\mu + \sigma z_{0,90}$. Para justificar a escolha dessas estimativas, vamos precisar das teorias desenvolvidas nos capítulos seguintes. Neste caso, obtemos $\bar{x} = 64{,}517$ e, por (5.5.5), calculamos $s = 2{,}379$. Da Tabela D.2, obtemos $z_{0,90} = 1{,}2816$, de modo que

$$\bar{x} + s z_{0,90} = 64{,}517 + 2{,}379\,(1{,}2816) = 67{,}566.$$

Quão precisa é a estimativa $\bar{x}$ de μ? Uma abordagem natural para responder a essa pergunta é construir um intervalo de credibilidade, baseado na estimativa, que acreditamos ter alta probabilidade de conter o verdadeiro valor de μ e que seja o mais curto possível. Por exemplo, a teoria do Capítulo 6 leva a usar intervalos de confiança para μ da forma

$$[\bar{x} - sc, \bar{x} + sc]$$

para alguma escolha da constante c. Observe que $\bar{x}$ está no centro do

intervalo. A teoria do Capítulo 6 vai mostrar que, neste caso, escolher $c = 0{,}3734$ leva ao que se conhece como intervalo de confiança 0,95 para μ. Tomamos então o semicomprimento desse intervalo, a saber,

$$sc = 2{,}379\,(0{,}3734) = 0{,}888,$$

como medida da precisão da estimativa $\bar{x} = 64{,}517$ de μ. Neste caso, temos informação suficiente para dizer que conhecemos o verdadeiro valor de μ com margem de uma polegada, pelo menos com "confiança" igual a 0,95.

Por fim, suponha que temos um valor hipotético μ_0 para a altura média da população. Por exemplo, podemos acreditar que a altura média da população de indivíduos em estudo é igual à altura média de outra população, para a qual se sabe que essa quantidade é igual a $\mu_0 = 65$. Então, com base na amostra de alturas observada, queremos avaliar se o valor $\mu_0 = 65$ faz sentido ou não. Se a altura média amostral $\bar{x}$ estiver longe de μ_0, isso parece ser evidência contra o valor hipotético. No Capítulo 6, vamos mostrar que podemos basear nossa avaliação no valor de

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}} = \frac{64{,}517 - 65}{2{,}379/\sqrt{30}} = -1{,}112.$$

Se o valor de $|t|$ for muito grande, concluiremos que temos evidência contra o valor hipotético $\mu_0 = 65$. Precisamos especificar o que queremos dizer com *grande* aqui, e faremos isso no Capítulo 6. Acontece que $t = -1{,}112$ é um valor plausível para t quando o verdadeiro valor de μ é igual a 65, de modo que não temos evidência contra a hipótese. ■

Resumo da Seção 5.5

- Estatísticas descritivas são métodos estatísticos informais usados para fazer inferências sobre a distribuição de uma variável X de interesse, com base numa amostra observada dessa distribuição. Essas quantidades resumem características da amostra observada e podem ser vistas como estimativas das quantidades populacionais desconhecidas correspondentes. São necessários métodos mais formais para avaliar o erro dessas estimativas, ou mesmo para substituí-las por estimativas de maior precisão.
- É importante fazer gráficos dos dados usando gráficos relevantes. Eles nos dão alguma ideia da forma da distribuição populacional da qual estamos amostrando.

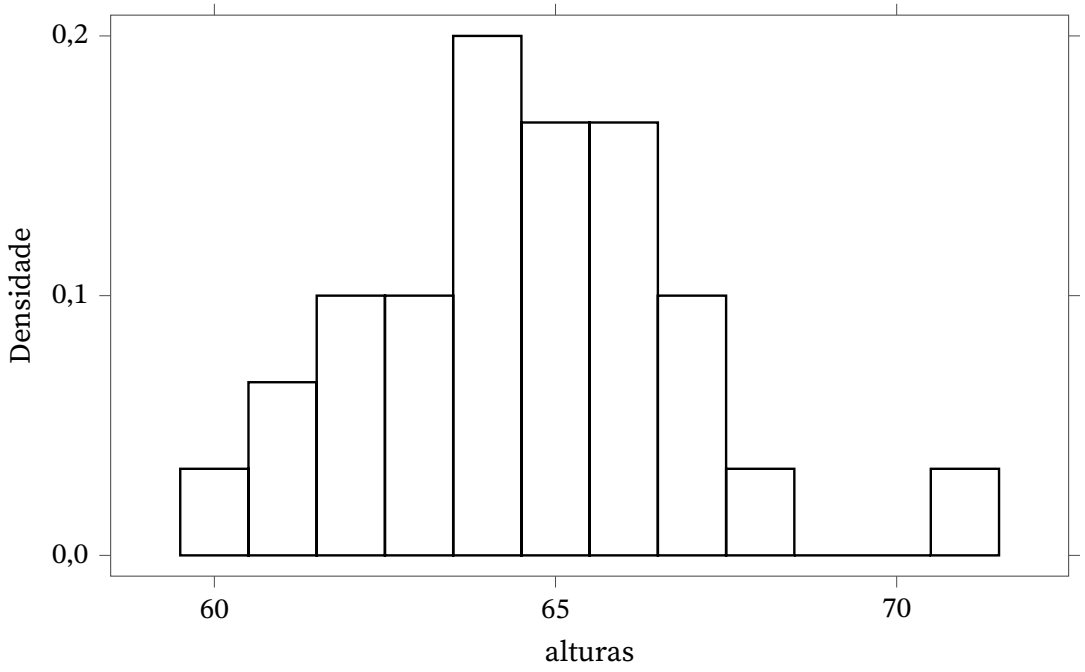


Figura 5.5.7: Histograma de densidade das alturas do Exemplo 5.5.6.

- Há três tipos principais de inferência: estimativas, intervalos de credibilidade ou de confiança e avaliação de hipóteses.

Exercícios

5.5.1 Suponha que os dados a seguir foram obtidos registrando-se X, o número de clientes que chegam a um caixa eletrônico durante 15 intervalos sucessivos de um minuto.

2	1	3	2	0	1	4	2
0	2	3	1	0	0	4	

(a) Registre estimativas de $f_X(0)$, $f_X(1)$, $f_X(2)$, $f_X(3)$ e $f_X(4)$.

(b) Registre estimativas de $F_X(0)$, $F_X(1)$, $F_X(2)$, $F_X(3)$ e $F_X(4)$.

(c) Faça o gráfico de $\hat{f}_X$.

(d) Registre a média e a variância.

(e) Registre a mediana e a IQR e faça um boxplot. Usando a regra estabelecida no Exemplo 5.5.4, decida se há valores atípicos.

5.5.2 Suponha que a amostra de tempos de espera (em minutos) a seguir foi obtida para clientes numa fila de um caixa eletrônico.

15	10	2	3	1	0	4	5
5	3	3	4	2	1	4	5

(a) Registre a função de distribuição empírica.

(b) Faça o gráfico de $\hat{f}_X$.

(c) Registre a média e a variância.

(d) Registre a mediana e a IQR e faça um boxplot. Usando a regra dada no Exemplo 5.5.4, decida se há valores atípicos.

5.5.3 Suponha que foi feito um experimento para ver se os mosquitos são atraídos de maneira diferente por cores diferentes. Foram usadas três cores diferentes de tecido, e o número de mosquitos que pousaram em cada pedaço foi registrado durante um intervalo de 15 minutos. Foram obtidos os dados a seguir.

	Número de pousos
Cor 1	25
Cor 2	35
Cor 3	22

(a) Registre estimativas de $f_X(1)$, $f_X(2)$ e $f_X(3)$, em que usamos i para a cor i.

(b) Faz sentido estimar $F_X(i)$? Explique por quê.

(c) Faça um gráfico de barras desses dados.

5.5.4 Um estudante fica sabendo que sua nota numa prova ficou no 90º percentil da população de todos os estudantes que fizeram a prova. Explique exatamente o que isso significa.

5.5.5 Determine a função de distribuição empírica com base na amostra dada abaixo.

1,0	−1,2	0,4	1,3	−0,3
−1,4	0,4	−0,5	−0,2	−1,3
0,0	−1,0	−1,3	2,0	1,0
0,9	0,4	2,1	0,0	−1,3

Faça o gráfico dessa função. Determine a mediana amostral[40], o primeiro e o terceiro quartis e a amplitude interquartil[41]. Qual é a sua estimativa de $F(1)$?

No original: *sample median*[40], *interquartile range*[41].

5.5.6 Considere o histograma de densidade da Figura 5.5.8. Se lhe pedissem para registrar medidas de posição[42] e de dispersão para os dados correspondentes a esse gráfico, o que você escolheria? Justifique sua resposta.

5.5.7 Suponha que um modelo estatístico é dado pela família das distribuições $N(\mu, \sigma_0^2)$, em que $\theta = \mu \in R^1$ é desconhecido, enquanto σ_0^2 é conhecido. Se nosso interesse é fazer inferências sobre o primeiro quartil da verdadeira distribuição, determine $\psi(\mu)$.

5.5.8 Suponha que um modelo estatístico é dado pela família das distribuições $N(\mu, \sigma_0^2)$, em que $\theta = \mu \in R^1$ é desconhecido, enquanto σ_0^2 é conhecido. Se nosso interesse é fazer inferências sobre o terceiro momento da distribuição, determine $\psi(\mu)$.

5.5.9 Suponha que um modelo estatístico é dado pela família das distribuições $N(\mu, \sigma_0^2)$, em que $\theta = \mu \in R^1$ é desconhecido, enquanto σ_0^2 é conhecido. Se nosso interesse é fazer inferências sobre a função de distribuição avaliada em 3, determine $\psi(\mu)$.

5.5.10 Suponha que um modelo estatístico é dado pela família das distribuições $N(\mu, \sigma^2)$, em que $\theta = (\mu, \sigma^2) \in R^1 \times R^+$ é desconhecido. Se nosso interesse é fazer inferências sobre o primeiro quartil da verdadeira distribuição, determine $\psi(\mu, \sigma^2)$.

5.5.11 Suponha que um modelo estatístico é dado pela família das distribuições $N(\mu, \sigma^2)$, em que $\theta = (\mu, \sigma^2) \in R^1 \times R^+$ é desconhecido. Se nosso interesse é fazer inferências sobre a função de distribuição avaliada em 3, determine $\psi(\mu, \sigma^2)$.

5.5.12 Suponha que um modelo estatístico é dado pela família das distribuições Bernoulli(θ), em que $\theta \in \mathbf{\Omega} = [0, 1]$. Se nosso interesse é fazer inferências sobre a probabilidade de que duas observações independentes desse modelo sejam iguais, determine $\psi(\theta)$.

5.5.13 Suponha que um modelo estatístico é dado pela família das distribuições Bernoulli(θ), em que $\theta \in \mathbf{\Omega} = [0, 1]$. Se nosso interesse é fazer inferências sobre a probabilidade de obtermos um 0 e um 1 em duas observações independentes desse modelo, determine $\psi(\theta)$.

5.5.14 Suponha que um modelo estatístico é dado pela família das distribuições Uniforme$[0, \theta]$, em que $\theta \in \mathbf{\Omega} = (0, \infty)$. Se nosso interesse é fazer

No original: *measures of location*[42].

inferências sobre o coeficiente de variação (veja o Exercício 5.3.5) da verdadeira distribuição, determine $\psi(\theta)$. O que você observa sobre essa característica?

5.5.15 Suponha que um modelo estatístico é dado pela família das distribuições Gama(α_0, β), em que $\theta = \beta \in \mathbf{\Omega} = (0, \infty)$. Se nosso interesse é fazer inferências sobre a variância da verdadeira distribuição, determine $\psi(\theta)$.

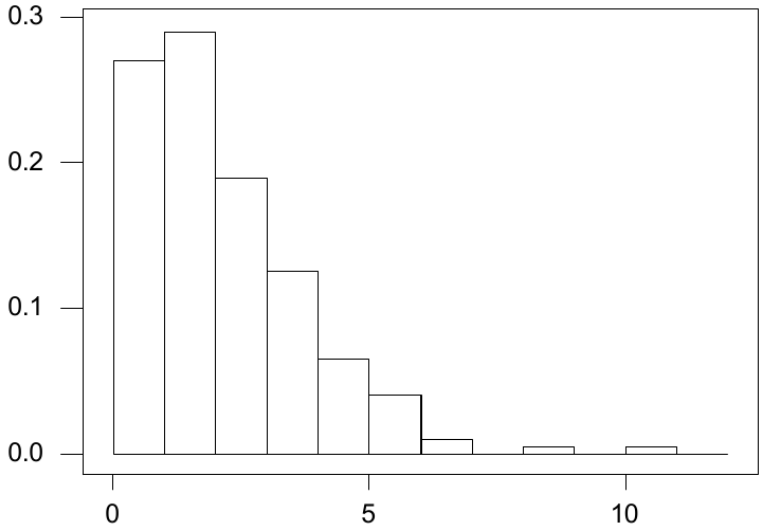


Figura 5.5.8: Histograma de densidade do Exercício 5.5.6.

Exercícios computacionais

5.5.16 Faça o seguinte com base nos dados do Exercício 5.4.5.

(a) Calcule as estatísticas de ordem[43] desses dados.

(b) Calcule a função de distribuição empírica nos pontos dos dados.

(c) Calcule a média amostral e o desvio padrão[44] amostral.

(d) Obtenha a mediana amostral e a amplitude interquartil amostral.

(e) Com base nos histogramas obtidos no Exercício 5.4.5, que conjunto de estatísticas descritivas você acha adequado para medir a posição e a dispersão?

(f) Suponha que o primeiro valor dos dados foi registrado incorretamente como 13,9 em vez de 3,9. Repita os itens (c) e (d) usando esse conjunto de dados e compare suas respostas com as obtidas antes. Você consegue

No original: *order statistics*[43], *standard deviation*[44].

tirar alguma conclusão geral sobre essas medidas? Justifique seu raciocínio.

5.5.17 Faça o seguinte com base nos dados do Exemplo 5.5.6.

(a) Calcule as estatísticas de ordem desses dados.

(b) Faça o gráfico da função de distribuição empírica (só nos pontos da amostra).

(c) Calcule a mediana amostral e a amplitude interquartil amostral e faça um boxplot. Há valores atípicos?

(d) Com base no boxplot, que conjunto de estatísticas descritivas você acha adequado para medir a posição e a dispersão?

(e) Suponha que o primeiro valor dos dados foi registrado incorretamente como 84,9 em vez de 64,9. Repita os itens (c) e (d) usando esse conjunto de dados e veja se alguma observação é classificada como valor atípico[45].

5.5.18 Gere uma amostra de 30 de uma distribuição $N(10, 2)$ e uma amostra de 1 de uma distribuição $N(30, 2)$. Junte-as para formar uma única amostra de 31.

(a) Faça um boxplot desses dados.

(b) O que você observa nesse gráfico?

(c) Com base no boxplot, que característica você acha que seria adequada para medir a posição e a dispersão da distribuição? Explique por quê.

5.5.19 Gere uma amostra de 50 de uma distribuição $\chi^2(1)$.

(a) Faça um boxplot desses dados.

(b) O que você observa nesse gráfico?

(c) Com base no boxplot, que característica você acha que seria adequada para medir a posição e a dispersão da distribuição? Explique por quê.

5.5.20 Gere uma amostra de 50 de uma distribuição $N(4, 1)$. Suponha que seu interesse seja estimar o 90º percentil $x_{0,9}$ dessa distribuição e que fingimos que $\mu = 4$ e $\sigma = 1$ são desconhecidos.

(a) Calcule uma estimativa de $x_{0,9}$ com base na estatística de ordem adequada.

No original: *outlier*[45].

(b) Calcule uma estimativa com base no fato de que $x_{0,9} = \mu + \sigma z_{0,9}$, em que $z_{0,9}$ é o 90º percentil da distribuição $N(0, 1)$.

(c) Se você soubesse, ou pelo menos estivesse disposto a supor, que a amostra veio de uma distribuição normal, qual das estimativas dos itens (a) ou (b) você preferiria? Explique por quê.

Problemas

5.5.21 Determine uma fórmula para a mediana amostral baseada em interpolação (isto é, usando (5.5.3)) quando n é ímpar. (Sugestão: use a *função menor inteiro*, ou *teto*, $\lceil x \rceil$ = menor inteiro maior ou igual a x.)

5.5.22 Uma alternativa à função de distribuição empírica é definir uma função de distribuição $\tilde{F}$ por $\tilde{F}(x) = 0$ se $x < x_{(1)}$, $\tilde{F}(x) = 1$ se $x \geq x_{(n)}$, $\tilde{F}(x) = \hat{F}(x_{(i)})$ se $x = x_{(i)}$, e

$$\tilde{F}(x) = \hat{F}(x_{(i)}) + \frac{\hat{F}(x_{(i+1)}) - \hat{F}(x_{(i)})}{x_{(i+1)} - x_{(i)}}\left(x - x_{(i)}\right)$$

se $x_{(i)} \leq x \leq x_{(i+1)}$, para $i = 1, \ldots, n$.

(a) Mostre que $\tilde{F}(x_{(i)}) = \hat{F}(x_{(i)})$ para $i = 1, \ldots, n$ e que $\tilde{F}$ é crescente de 0 a 1.

(b) Prove que $\tilde{F}$ é contínua em $\left(x_{(1)}, \infty\right)$ e contínua à direita[46] em toda parte.

(c) Mostre que, para $p \in [1/n, 1)$, o valor $\tilde{x}_p$ definido em (5.5.3) é a solução de $\tilde{F}(\tilde{x}_p) = p$.

Tópicos para discussão

5.5.23 Às vezes se argumenta que a estatística não precisa de uma teoria formal para prescrever inferências. Em vez disso, seria melhor deixar a prática estatística a cargo do profissional experiente, que decide qual é a abordagem sensata em cada problema. Comente essas afirmações.

5.5.24 Quão razoável você acha que é um pesquisador supor que uma variável aleatória tem distribuição normal? Discuta o papel das suposições na modelagem científica.

No original: *right continuous*[46].

CAPÍTULO 6

Inferência por Verossimilhança

ESBOÇO DO CAPÍTULO

Seção 1 A Função de Verossimilhança
Seção 2 Estimação por Máxima Verossimilhança
Seção 3 Inferências Baseadas no EMV
Seção 4 Métodos Livres de Distribuição
Seção 5 Comportamento do EMV em Grandes Amostras (Avançado)

Neste capítulo, discutimos algumas das abordagens mais básicas da inferência. Em essência, queremos que nossas inferências dependam apenas do modelo $\{P_\theta : \theta \in \mathbf{\Omega}\}$ e dos dados s. Esses métodos são muito mínimos, no sentido de que exigem poucas suposições. Embora tenham sucesso em certos problemas, parece que a estrutura adicional do Capítulo 7 ou do Capítulo 8 é necessária em situações mais complexas.

A função de verossimilhança[1] é um dos conceitos mais básicos da inferência estatística. Teorias inteiras de inferência foram construídas com base nela. Discutimos os métodos de verossimilhança[2] nas Seções 6.1, 6.2, 6.3 e 6.5. Na Seção 6.4, apresentamos alguns métodos de inferência livres de distribuição. Eles não são exatamente exemplos de métodos de verossimilhança, mas seguem a mesma ideia básica de fazer as inferências dependerem do menor número possível de suposições.

6.1 A Função de Verossimilhança

As inferências por verossimilhança se baseiam apenas nos dados s e no modelo $\{P_\theta : \theta \in \mathbf{\Omega}\}$ — o conjunto das medidas de probabilidade possíveis para o sistema sob investigação. A partir desses ingredientes, obtemos a entidade básica da inferência por verossimilhança, a saber, a função de verossimilhança.

Para motivar a definição da função de verossimilhança, suponha que temos um modelo estatístico em que cada P_θ é discreta, dada pela função de

No original: *likelihood function*[1], *likelihood*[2].

probabilidade[3] f_θ. Tendo observado s, considere a função $L(\cdot \mid s)$ definida no espaço paramétrico[4] $\mathbf{\Omega}$ e com valores em R^1, dada por

$$L(\theta \mid s) = f_\theta(s).$$

Chamamos $L(\cdot \mid s)$ de *função de verossimilhança* determinada pelo modelo e pelos dados. O valor $L(\theta \mid s)$ é chamado de *verossimilhança* de θ. Observe que, na função de verossimilhança, estamos fixando os dados e variando o valor do parâmetro.

Vemos que $f_\theta(s)$ é simplesmente a probabilidade de obter os dados s quando o verdadeiro valor do parâmetro é θ. Isso impõe uma ordenação de crença em $\mathbf{\Omega}$, a saber: acreditamos em θ_1 como o verdadeiro valor de θ mais do que em θ_2 sempre que $f_{\theta_1}(s) > f_{\theta_2}(s)$. Isso porque a desigualdade diz que os dados são mais prováveis sob θ_1 do que sob θ_2. Somos indiferentes entre θ_1 e θ_2 sempre que $f_{\theta_1}(s) = f_{\theta_2}(s)$. A inferência por verossimilhança sobre θ se baseia nessa ordenação.

É importante lembrar a interpretação correta de $L(\theta \mid s)$. O valor $L(\theta \mid s)$ é a probabilidade de s dado que θ é o verdadeiro valor — *não* é a probabilidade de θ dado que observamos s. Além disso, é possível que o valor de $L(\theta \mid s)$ seja muito pequeno para todo valor de θ. Portanto, não é o valor efetivo da verossimilhança que nos diz quanto suporte dar a um θ específico, e sim o seu valor em relação às verossimilhanças de outros valores possíveis do parâmetro.

Exemplo 6.1.1

Suponha que $S = \{1, 2, \ldots\}$ e que o modelo estatístico é $\{P_\theta : \theta \in \{1, 2\}\}$, em que P_1 é a distribuição uniforme nos inteiros $\{1, \ldots, 10^3\}$ e P_2 é a distribuição uniforme em $\{1, \ldots, 10^6\}$. Suponha ainda que observamos $s = 10$. Então $L(1 \mid 10) = 1/10^3$ e $L(2 \mid 10) = 1/10^6$. Os dois valores são bem pequenos, mas observe que a verossimilhança dá a $\theta = 1$ um suporte mil vezes maior que o que dá a $\theta = 2$. ■

Por isso, estamos interessados apenas nas *razões de verossimilhança*

$$\frac{L(\theta_1 \mid s)}{L(\theta_2 \mid s)}$$

para $\theta_1, \theta_2 \in \mathbf{\Omega}$ quando se trata de determinar inferências para θ com base na função de verossimilhança. Isso implica que qualquer função que seja um múltiplo positivo de $L(\cdot \mid s)$, isto é, $L^*(\cdot \mid s) = cL(\cdot \mid s)$ para algum $c > 0$ fixo,

No original: *probability function*[3], *parameter space*[4].

serve igualmente bem como função de verossimilhança. Dizemos que duas verossimilhanças são equivalentes se forem proporcionais dessa maneira. Em geral, chamamos qualquer múltiplo positivo de $L(\cdot \mid s)$ de função de verossimilhança.

Exemplo 6.1.2

Suponha que uma moeda é lançada $n = 10$ vezes e que se observam $s = 4$ caras. Sem conhecimento algum sobre a probabilidade de obter cara num único lançamento, o modelo estatístico adequado para os dados é o modelo Binomial$(10, \theta)$, com $\theta \in \mathbf{\Omega} = [0, 1]$. A função de verossimilhança é dada por

$$L(\theta \mid 4) = \binom{10}{4}\theta^4(1-\theta)^6, \tag{6.1.1}$$

cujo gráfico está na Figura 6.1.1.

Essa verossimilhança atinge o pico em $\theta = 0{,}4$ e vale 0,2508 nesse ponto. Vamos examinar usos da verossimilhança para estimar o θ desconhecido e avaliar a precisão da estimativa. Grosso modo, porém, isso se baseia em onde a verossimilhança atinge o máximo e em quão dispersa ela é em torno do pico. ■

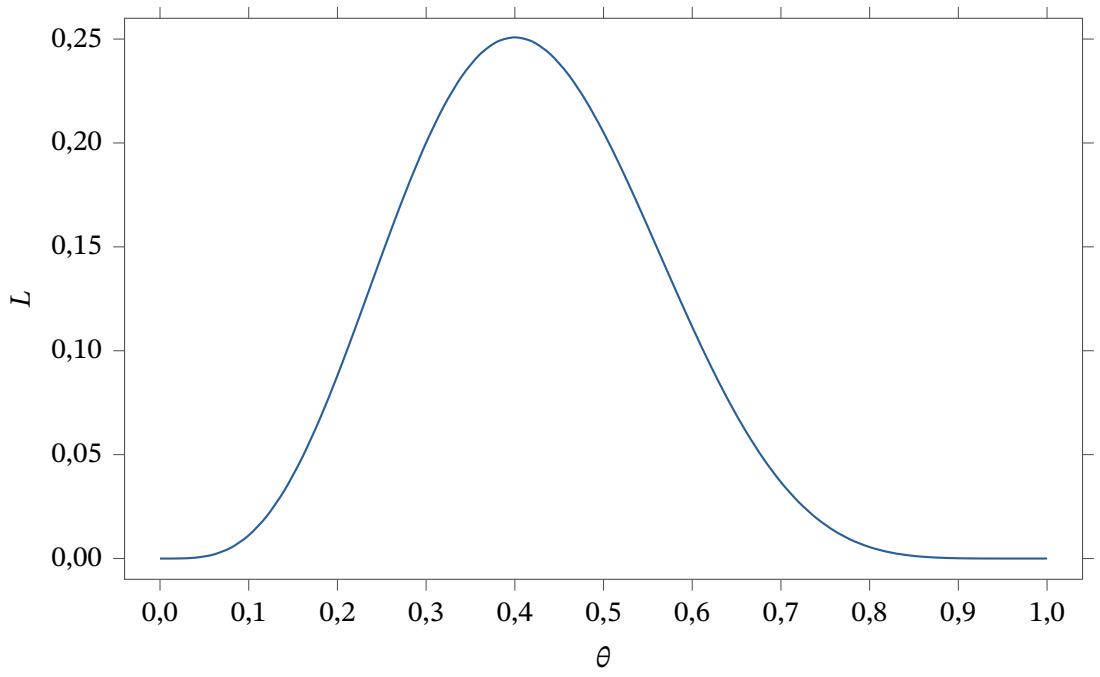


Figura 6.1.1: Função de verossimilhança do modelo Binomial$(10, \theta)$ quando se observa $s = 4$.

Há uma gama de abordagens para obter inferências por meio da função de

verossimilhança. Num extremo está o princípio da verossimilhança[5].

> *Princípio da verossimilhança*: se duas combinações de modelo e dados produzem funções de verossimilhança equivalentes, então as inferências sobre o parâmetro desconhecido devem ser as mesmas.

Esse princípio determina que tudo o que quisermos dizer sobre o valor desconhecido de θ tem de se basear apenas em $L(\cdot \mid s)$. Para muitos estatísticos, isso é visto como uma restrição severa demais. Considere o exemplo a seguir.

Exemplo 6.1.3

Suponha que uma moeda é lançada em lançamentos independentes até que se obtenham quatro caras, e que o número de coroas observadas até a quarta cara é $s = 6$. Então s tem distribuição Binomial Negativa$(4, \theta)$, e a verossimilhança especificada pelos dados observados é

$$L(\theta \mid 6) = \binom{9}{6}\theta^4(1-\theta)^6.$$

Observe que essa função de verossimilhança é um múltiplo positivo de (6.1.1).

Assim, o princípio da verossimilhança afirma que essas duas combinações de modelo e dados devem produzir as mesmas inferências sobre o θ desconhecido. Na prática, o princípio da verossimilhança diz que devemos ignorar o fato de que os dados foram obtidos de maneiras totalmente diferentes. Se, porém, levarmos em conta características adicionais do modelo, além da função de verossimilhança, verifica-se que podemos derivar inferências diferentes para as duas situações. Em particular, a avaliação de um valor hipotético $\theta = \theta_0$ pode ser feita de maneiras diferentes quando se leva em conta o método de amostragem. Muitos estatísticos acreditam que essa informação adicional deve ser usada ao derivar inferências. ■

Como exemplo de inferência derivada de uma função de verossimilhança, considere um conjunto da forma

$$C(s) = \{\theta : L(\theta \mid s) \geq c\},$$

para algum $c \geq 0$. O conjunto $C(s)$ é chamado de *região de verossimilhança*. Ele contém todos os valores de θ cuja verossimilhança é pelo menos c. Uma região

No original: *likelihood principle*[5].

de verossimilhança, para algum c, parece um conjunto sensato a indicar como possivelmente contendo o verdadeiro valor de θ. Afinal, se $\theta^* \notin C(s)$, então $L(\theta^* \mid s) < L(\theta \mid s)$ para todo $\theta \in C(s)$ e, portanto, θ^* não é tão bem sustentado pelos dados observados quanto qualquer valor de $C(s)$. O tamanho de $C(s)$ pode então ser tomado como uma medida de quão incertos estamos sobre o verdadeiro valor de θ.

Resta-nos, porém, o problema de escolher um valor adequado para c e, como o Exemplo 6.1.1 parece indicar, a própria verossimilhança não sugere uma maneira natural de fazer isso. Na Seção 6.3.2, discutiremos um método de escolha de c que se baseia em propriedades adicionais do modelo, além da função de verossimilhança.

Até aqui, nesta seção, supusemos que nossos modelos estatísticos são compostos de distribuições discretas. A definição da verossimilhança é bastante natural, pois $L(\theta \mid s)$ é simplesmente a probabilidade de s ocorrer quando θ é o verdadeiro valor. Essa interpretação claramente não está disponível de forma direta, porém, quando temos um modelo contínuo, porque todo ponto dos dados tem probabilidade 0 de ocorrer. Imagine, no entanto, que $f_{\theta_1}(s) > f_{\theta_2}(s)$ e que $s \in R^1$. Então, supondo a continuidade de toda f_θ em s, temos*

$$P_{\theta_1}(V) = \int_a^b f_{\theta_1}(s)\,dx > P_{\theta_2}(V) = \int_a^b f_{\theta_2}(s)\,dx$$

para todo intervalo $V = (a, b)$ que contenha s e seja suficientemente pequeno. Interpretamos isso como significando que a probabilidade de s ocorrer quando θ_1 é verdadeiro é maior que a probabilidade de s ocorrer quando θ_2 é verdadeiro. Assim, os dados s sustentam θ_1 mais do que θ_2. Uma interpretação semelhante vale quando $s \in R^n$ para $n > 1$ e V é uma região que contém s.

Portanto, no caso contínuo, definimos novamente a função de verossimilhança por $L(\theta \mid s) = f_\theta(s)$ e interpretamos a ordenação que ela impõe aos valores de θ exatamente como fazemos no caso discreto.† Novamente, duas verossimilhanças serão consideradas equivalentes se uma for um múltiplo positivo da outra.

Considere agora um exemplo muito importante.

*Nota do tradutor. No original, os integrandos estão escritos como $f_{\theta_1}(s)\,dx$ e $f_{\theta_2}(s)\,dx$, com s no lugar da variável de integração x; reproduzido como impresso.

†Observe, porém, que sempre que estivermos numa situação em que $f_{\theta_1}(s) = f_{\theta_2}(s)$, ainda poderíamos ter $P_{\theta_1}(V) > P_{\theta_2}(V)$ para todo V que contenha s e seja suficientemente pequeno. Isso implica que θ_1 é mais sustentado que θ_2, em vez de esses dois valores terem igual suporte, como indica a verossimilhança. Esse fenômeno não ocorre nos exemplos que discutimos, de modo que o ignoraremos aqui.

Exemplo 6.1.4 — Modelo Normal de Locação

Suponha que $(x_1, \ldots, x_n)$ é uma amostra observada independente e identicamente distribuída (i.i.d.) de uma distribuição $N(\theta, \sigma_0^2)$, em que $\theta \in \mathbf{\Omega} = R^1$ é desconhecido e $\sigma_0^2 > 0$ é conhecido. A função de verossimilhança é dada por

$$L(\theta \mid x_1, \ldots, x_n) = \prod_{i=1}^{n} f_\theta(x_i) = \prod_{i=1}^{n} \left(2\pi\sigma_0^2\right)^{-1/2} \exp\left(-\frac{1}{2\sigma_0^2}(x_i - \theta)^2\right)$$

e, claramente, isso se simplifica para

$$\begin{aligned} L(\theta \mid x_1, \ldots, x_n) &= \left(2\pi\sigma_0^2\right)^{-n/2} \exp\left(-\frac{1}{2\sigma_0^2}\sum_{i=1}^{n}(x_i - \theta)^2\right) \\ &= \left(2\pi\sigma_0^2\right)^{-n/2} \exp\left(-\frac{n}{2\sigma_0^2}(\bar{x} - \theta)^2\right) \exp\left(-\frac{n-1}{2\sigma_0^2}s^2\right). \end{aligned}$$

Uma versão equivalente e mais simples da função de verossimilhança é então dada por

$$L(\theta \mid x_1, \ldots, x_n) = \exp\left(-\frac{n}{2\sigma_0^2}(\bar{x} - \theta)^2\right),$$

e usaremos essa versão.

Por exemplo, suponha que $n = 25$, $\sigma_0^2 = 1$ e que observamos $\bar{x} = 3{,}3$. O gráfico dessa função está na Figura 6.1.2.

A verossimilhança atinge o pico em $\theta = \bar{x} = 3{,}3$, e a função do gráfico vale 1 nesse ponto. O intervalo de verossimilhança

$$C(x) = \{\theta : L(\theta \mid x_1, \ldots, x_n) \geq 0{,}5\} = (3{,}0645;\ 3{,}53548)$$

contém todos os valores de θ cuja verossimilhança é pelo menos 0,5 do valor da verossimilhança no pico.

O modelo normal de locação é pouco prático em muitas aplicações, pois supõe que a variância é conhecida, enquanto a média é desconhecida. Por exemplo, se estamos interessados na distribuição das alturas numa população, parece pouco provável que conheçamos a variância populacional sem conhecer a média populacional. Ainda assim, é um modelo estatístico importante, pois é um contexto em que os métodos de inferência podem ser desenvolvidos com bastante facilidade. A metodologia desenvolvida para essa situação costuma ser usada como paradigma para métodos de inferência em modelos muito mais complicados. ■

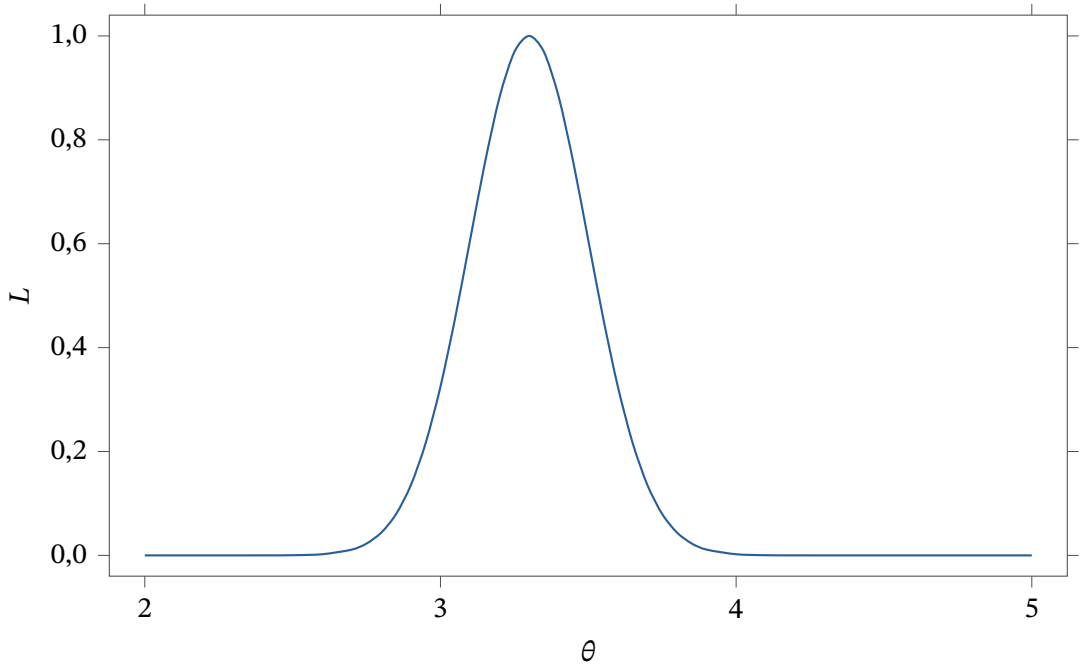


Figura 6.1.2: Verossimilhança de um modelo normal de locação baseada numa amostra de 25 com $\bar{x} = 3{,}3$.

O parâmetro θ não precisa ser unidimensional. A interpretação da verossimilhança continua a mesma, mas não é possível fazer o seu gráfico — pelo menos não quando a dimensão de θ é maior que 2.

Exemplo 6.1.5 — Modelos Multinomiais

No Exemplo 2.8.5, apresentamos as distribuições multinomiais. Elas surgem em aplicações quando temos uma variável resposta categórica s que pode assumir um número finito k de valores, digamos $\{1, \dots, k\}$, e $P(s = i) = \theta_i$.

Suponha, então, que $k = 3$ e que não conhecemos o valor de $(\theta_1, \theta_2, \theta_3)$. Nesse caso, o espaço paramétrico é dado por

$$\mathbf{\Omega} = \{(\theta_1, \theta_2, \theta_3) : \theta_i \geq 0, \text{ para } i = 1, 2, 3, \text{ e } \theta_1 + \theta_2 + \theta_3 = 1\}.$$

Observe que ele é, na verdade, apenas bidimensional, porque, assim que conhecemos o valor de dois quaisquer dos θ_i, digamos θ_1 e θ_2, conhecemos imediatamente o valor do parâmetro restante, pois $\theta_3 = 1 - \theta_1 - \theta_2$. Esse fato deve ser sempre lembrado quando lidamos com modelos multinomiais.

Suponha agora que observamos uma amostra de n dessa distribuição, digamos $(s_1, \dots, s_n)$. A função de verossimilhança dessa amostra é dada por

$$L(\theta_1, \theta_2, \theta_3 \mid s_1, \dots, s_n) = \theta_1^{x_1}\theta_2^{x_2}\theta_3^{x_3}, \tag{6.1.2}$$

em que x_i é o número de valores i na amostra.

Usando o fato de que podemos tratar múltiplos positivos da verossimilhança como equivalentes, vemos que a verossimilhança baseada nas contagens observadas (x_1, x_2, x_3) (já que elas provêm de uma distribuição Multinomial$(n, \theta_1, \theta_2, \theta_3)$) é dada por

$$L(\theta_1, \theta_2, \theta_3 \mid x_1, x_2, x_3) = \theta_1^{x_1}\theta_2^{x_2}\theta_3^{x_3}.$$

Ela é idêntica à verossimilhança (como funções de θ_1, θ_2 e θ_3) da amostra original. Certamente é mais simples lidar com as contagens do que com a amostra original. Esse é um fenômeno muito importante em estatística e é caracterizado pelo conceito de suficiência, discutido na próxima seção. ■

6.1.1 Estatísticas Suficientes

A equivalência, para fins de inferência, entre múltiplos positivos da função de verossimilhança leva a uma equivalência útil entre os valores possíveis dos dados provenientes do mesmo modelo. Por exemplo, suponha que os valores dos dados s_1 e s_2 são tais que $L(\cdot \mid s_1) = cL(\cdot \mid s_2)$ para algum $c > 0$. Do ponto de

vista da verossimilhança, é indiferente para nós termos obtido os dados s_1 ou os dados s_2, pois eles levam às mesmas razões de verossimilhança.

Isso leva à definição de estatística suficiente[6].

Definição 6.1.1

Uma função T definida no espaço amostral S é chamada de *estatística suficiente* para o modelo se, sempre que $T(s_1) = T(s_2)$, então

$$L(\cdot \mid s_1) = c(s_1, s_2)\, L(\cdot \mid s_2)$$

para alguma constante $c(s_1, s_2) > 0$.

A terminologia se justifica pelo fato de que precisamos observar apenas o valor t da função T, já que podemos escolher qualquer valor

$$s \in T^{-1}\{t\} = \{s : T(s) = t\}$$

e usar a verossimilhança baseada em s. Todas essas escolhas dão as mesmas razões de verossimilhança. Tipicamente, $T(s)$ terá dimensão menor que s, de modo que podemos considerar substituir s por $T(s)$ como uma *redução dos dados*, que simplifica um pouco a análise.

Ilustramos o cálculo de uma estatística suficiente num contexto simples.

Exemplo 6.1.6

Suponha que $S = \{1, 2, 3, 4\}$, $\mathbf{\Omega} = \{a, b\}$ e que as duas distribuições de probabilidade são dadas pela tabela a seguir.

	$s = 1$	$s = 2$	$s = 3$	$s = 4$
$\theta = a$	1/2	1/6	1/6	1/6
$\theta = b$	1/4	1/4	1/4	1/4

Então $L(\cdot \mid 2) = L(\cdot \mid 3) = L(\cdot \mid 4)$ (por exemplo, $L(a \mid 2) = 1/6$ e $L(b \mid 2) = 1/4$), de modo que os valores dos dados em $\{2, 3, 4\}$ dão todos as mesmas razões de verossimilhança. Portanto, $T : S \longrightarrow \{0, 1\}$ dada por $T(1) = 0$ e $T(2) = T(3) = T(4) = 1$ é uma estatística suficiente. O modelo ficou um pouco mais simples, pois agora o espaço amostral de T tem apenas dois elementos, em vez dos quatro do modelo original. ■

O resultado a seguir ajuda a identificar estatísticas suficientes.

No original: *sufficient statistic*[6].

Teorema 6.1.1 (Teorema da fatoração)

Se a densidade (ou a função de probabilidade) de um modelo se fatora como $f_\theta(s) = h(s)g_\theta(T(s))$, em que g_θ e h são não negativas, então T é uma estatística suficiente.

Demonstração. Por hipótese, é claro que, quando $T(s_1) = T(s_2)$, temos

$$L(\cdot \mid s_1) = h(s_1)g_\theta(T(s_1)) = \frac{h(s_1)g_\theta(T(s_1))}{h(s_2)g_\theta(T(s_2))} h(s_2)g_\theta(T(s_2))$$
$$= \frac{h(s_1)}{h(s_2)} h(s_2)g_\theta(T(s_2)) = c(s_1, s_2)\, L(\cdot \mid s_2)$$

porque $g_\theta(T(s_1)) = g_\theta(T(s_2))$. ■

Observe que o nome desse resultado vem do fato de termos fatorado f_θ como o produto de duas funções. O ponto importante sobre uma estatística suficiente T é que somos indiferentes, pelo menos quando consideramos inferências sobre θ, entre observar os dados completos s ou o valor de $T(s)$. Veremos no Capítulo 9 que há informação nos dados, além do valor de $T(s)$, que é útil quando queremos verificar suposições.

Estatísticas Suficientes Minimais

Dado que uma estatística suficiente faz uma redução dos dados sem perder informação relevante neles para as inferências sobre θ, procuramos uma estatística suficiente que faça a maior redução. Tal estatística é chamada de estatística suficiente minimal[7].

Definição 6.1.2

Uma estatística suficiente T de um modelo é uma *estatística suficiente minimal* sempre que o valor de $T(s)$ puder ser calculado assim que conhecermos a função de verossimilhança $L(\cdot \mid s)$.

Assim, uma função de verossimilhança relevante sempre pode ser obtida a partir do valor de qualquer estatística suficiente T, mas, se T também for suficiente minimal, então também podemos obter o valor de T a partir de qualquer função de verossimilhança. Pode-se mostrar que uma estatística suficiente minimal dá a maior redução dos dados no sentido de que, se T é

No original: *minimal sufficient statistic*[7].

suficiente minimal e U é suficiente, então existe uma função h tal que $T = h(U)$. Observe que as definições de estatística suficiente e de estatística suficiente minimal dependem do modelo, isto é, modelos diferentes podem dar origem a estatísticas suficientes e suficientes minimais diferentes.

Embora a ideia de estatística suficiente minimal seja um pouco sutil, em geral é bem simples encontrar uma, como ilustram os exemplos a seguir.

Exemplo 6.1.7 — Modelo Normal de Locação

Pelo teorema da fatoração, vemos imediatamente, a partir da discussão do Exemplo 6.1.4, que $\bar{x}$ é uma estatística suficiente. Ora, qualquer função de verossimilhança desse modelo é um múltiplo positivo de

$$\exp\left(-\frac{n}{2\sigma_0^2}(\bar{x}-\theta)^2\right).$$

Observe que qualquer função de θ desse tipo fica completamente especificada pelo ponto em que atinge o máximo, a saber, em $\theta = \bar{x}$. Assim, $\bar{x}$ pode ser obtido de qualquer função de verossimilhança desse modelo e, portanto, é uma estatística suficiente minimal. ■

Exemplo 6.1.8 — Modelo Normal de Locação e Escala

Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição $N(\mu, \sigma^2)$ em que $\mu \in R^1$ e $\sigma > 0$ são desconhecidos. Lembre a discussão e a aplicação desse modelo nos Exemplos 5.3.4 e 5.5.6.

O parâmetro desse modelo é bidimensional e é dado por $\theta = (\mu, \sigma^2) \in \mathbf{\Omega} = R^1 \times (0, \infty)$. Portanto, a função de verossimilhança é dada por

$$\begin{aligned} L(\theta \mid x_1, \ldots, x_n) &= \left(2\pi\sigma^2\right)^{-n/2} \exp\left(-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2\right) \\ &= \left(2\pi\sigma^2\right)^{-n/2} \exp\left(-\frac{n}{2\sigma^2}(\bar{x}-\mu)^2\right) \exp\left(-\frac{n-1}{2\sigma^2}s^2\right). \end{aligned}$$

Vemos imediatamente, pelo teorema da fatoração, que $(\bar{x}, s^2)$ é uma estatística suficiente.

Agora, fixando σ^2, qualquer múltiplo positivo de $L(\cdot \mid x_1, \ldots, x_n)$ é maximizado, como função de μ, em $\mu = \bar{x}$. Isso não depende de σ^2. Fixando μ em $\bar{x}$, temos que

$$L\left((\bar{x}, \sigma^2) \mid x_1, \ldots, x_n\right) = \left(2\pi\sigma^2\right)^{-n/2} \exp\left(-\frac{n-1}{2\sigma^2}s^2\right)$$

é maximizada, como função de σ^2, no mesmo ponto que $\ln L((\bar{x}, \sigma^2) \mid x_1, \ldots, x_n)$, porque ln é uma função estritamente crescente. Agora,

$$\begin{aligned}\frac{\partial \ln L\left((\bar{x}, \sigma^2) \mid x\right)}{\partial \sigma^2} &= \frac{\partial}{\partial \sigma^2}\left(-\frac{n}{2}\ln \sigma^2 - \frac{n-1}{2\sigma^2}s^2\right) \\ &= -\frac{n}{2\sigma^2} + \frac{n-1}{2\sigma^4}s^2.\end{aligned}$$

Igualando isso a 0, obtemos a solução

$$\hat{\sigma}^2 = \frac{n-1}{n}s^2,$$

que é uma função injetora de s^2. Assim, dada qualquer função de verossimilhança desse modelo, podemos calcular $(\bar{x}, s^2)$, o que estabelece que $(\bar{x}, s^2)$ é uma estatística suficiente minimal do modelo. De fato, a verossimilhança é maximizada em $(\bar{x}, \hat{\sigma}^2)$ (Problema 6.1.22). ■

Exemplo 6.1.9 — Modelos Multinomiais

Vimos no Exemplo 6.1.5 que a função de verossimilhança de uma amostra é dada por (6.1.2). Isso deixa claro que, se duas amostras diferentes têm as mesmas contagens, então elas têm a mesma verossimilhança, de modo que as contagens (x_1, x_2, x_3) constituem uma estatística suficiente.

Ocorre que essa função de verossimilhança é maximizada tomando

$$(\theta_1, \theta_2, \theta_3) = \left(\frac{x_1}{n}, \frac{x_2}{n}, \frac{x_3}{n}\right).$$

Assim, dada a verossimilhança, podemos calcular as contagens (supõe-se conhecido o tamanho da amostra n). Portanto, (x_1, x_2, x_3) é uma estatística suficiente minimal. ■

Resumo da Seção 6.1

- A função de verossimilhança de um modelo e de dados mostra como os dados sustentam os diversos valores possíveis do parâmetro. O que importa não é o valor efetivo da verossimilhança, e sim as razões entre os valores da verossimilhança em diferentes valores do parâmetro.
- Uma estatística suficiente T de um modelo é qualquer função dos dados s tal que, assim que conhecemos o valor de $T(s)$, podemos determinar a função de verossimilhança $L(\cdot \mid s)$ (a menos de um múltiplo constante positivo).

- Uma estatística suficiente minimal T de um modelo é qualquer estatística suficiente tal que, assim que conhecemos uma função de verossimilhança $L(\cdot \mid s)$ do modelo e dos dados, podemos determinar $T(s)$.

Exercícios

6.1.1 Suponha que uma amostra de n indivíduos está sendo testada quanto à presença de um anticorpo no sangue e que se registra o número de indivíduos com o anticorpo presente. Registre um modelo estatístico adequado para essa situação, supondo que as respostas dos indivíduos são independentes. Se tivermos uma amostra de 10 e registrarmos 3 positivos, faça o gráfico de uma função de verossimilhança representativa.

6.1.2 Suponha que suicídios ocorrem numa população a uma taxa p por pessoa-ano e que p é considerado completamente desconhecido. Se modelarmos o número de suicídios observados numa população com um total de N pessoas-ano como Poisson(Np), registre uma função de verossimilhança representativa para p quando observamos 22 suicídios com $N = 30.345$.

6.1.3 Suponha que os tempos de vida (em milhares de horas) de lâmpadas têm distribuição Exponencial(θ), em que $\theta > 0$ é desconhecido. Se observarmos $\bar{x} = 5{,}2$ numa amostra de 20 lâmpadas, registre uma função de verossimilhança representativa. Por que precisamos observar apenas a média amostral para obter uma verossimilhança representativa?

6.1.4 Suponha que tomamos uma amostra de $n = 100$ estudantes de uma universidade com mais de 50.000 estudantes matriculados. Classificamos esses estudantes como morando no campus, morando fora do campus com os pais ou morando fora do campus por conta própria. Suponha que observamos as contagens $(x_1, x_2, x_3) = (34, 44, 22)$. Determine a forma da função de verossimilhança para as proporções desconhecidas de estudantes da população que estão nessas categorias.

6.1.5 Determine a constante que torna iguais as funções de verossimilhança dos Exemplos 6.1.2 e 6.1.3.

6.1.6 Suponha que $(x_1, \ldots, x_n)$ é uma amostra da distribuição Bernoulli(θ), em que $\theta \in [0, 1]$ é desconhecido. Determine a função de verossimilhança e uma estatística suficiente minimal para esse modelo. (Sugestão: use o teorema da fatoração[8] e maximize o logaritmo da função de verossimilhança.)

No original: *factorization theorem*[8].

6.1.7 Suponha que $(x_1, \ldots, x_n)$ é uma amostra da distribuição Poisson(θ), em que $\theta > 0$ é desconhecido. Determine a função de verossimilhança e uma estatística suficiente minimal para esse modelo. (Sugestão: o teorema da fatoração e a maximização do logaritmo da função de verossimilhança.)

6.1.8 Suponha que um modelo estatístico é composto de duas distribuições, dadas pela tabela a seguir:

	$s = 1$	$s = 2$	$s = 3$
$f_1(s)$	0,3	0,1	0,6
$f_2(s)$	0,1	0,7	0,2

(a) Faça o gráfico da função de verossimilhança para cada valor possível s dos dados.

(b) Encontre uma estatística suficiente que faça uma redução dos dados.

6.1.9 Suponha que um modelo estatístico é dado por $\{f_1, f_2\}$, em que f_i é uma distribuição $N(i, 1)$. Calcule a razão de verossimilhança[9] $L(1 \mid 0)/L(2 \mid 0)$ e explique como você interpreta esse número.

6.1.10 Explique por que uma função de verossimilhança nunca pode assumir valores negativos. Uma função de verossimilhança pode ser igual a 0 num valor do parâmetro?

6.1.11 Suponha que temos um modelo estatístico $\{f_\theta : \theta \in [0, 1]\}$ e observamos x_0. É verdade que $\int_0^1 L(\theta \mid x_0)\, d\theta = 1$? Explique por quê.

6.1.12 Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição Geométrica(θ), em que $\theta \in [0, 1]$ é desconhecido. Determine a função de verossimilhança e uma estatística suficiente minimal para esse modelo. (Sugestão: use o teorema da fatoração e maximize o logaritmo da verossimilhança.)

6.1.13 Suponha que lhe dizem que a verossimilhança de um certo valor do parâmetro é 10^9. É possível interpretar esse número de alguma maneira significativa? Explique por quê.

6.1.14 Suponha que um estatístico registra uma função de verossimilhança como θ^2 para $\theta \in [0, 1]$, enquanto outro estatístico registra uma função de verossimilhança como $100\theta^2$ para $\theta \in [0, 1]$. Explique por que essas funções de verossimilhança são, na prática, a mesma.

No original: *likelihood ratio*[9].

Problemas

6.1.15 Mostre que a T definida no Exemplo 6.1.6 é uma estatística suficiente minimal. (Sugestão: mostre que, assim que você conhece a função de verossimilhança, pode determinar qual dos dois valores possíveis de T ocorreu.)

6.1.16 Suponha que $S = \{1, 2, 3, 4\}$, $\mathbf{\Omega} = \{a, b, c\}$, em que as três distribuições de probabilidade são dadas pela tabela a seguir.

	$s = 1$	$s = 2$	$s = 3$	$s = 4$
$\theta = a$	1/2	1/6	1/6	1/6
$\theta = b$	1/4	1/4	1/4	1/4
$\theta = c$	1/2	1/4	1/4	0

Determine uma estatística suficiente minimal para esse modelo. A estatística suficiente minimal do Exemplo 6.1.6 é suficiente para esse modelo?

6.1.17 Suponha que $(x_1, \ldots, x_n)$ é uma amostra da distribuição $N(\mu, \sigma_0^2)$, em que $\mu \in R^1$ é desconhecido. Determine a forma dos intervalos de verossimilhança para esse modelo.

6.1.18 Suponha que $(x_1, \ldots, x_n) \in R^n$ é uma amostra de f_θ, em que $\theta \in \mathbf{\Omega}$ é desconhecido. Mostre que as estatísticas de ordem[10] $(x_{(1)}, \ldots, x_{(n)})$ constituem uma estatística suficiente para o modelo.

6.1.19 Determine uma estatística suficiente minimal para uma amostra de n do modelo gama de taxa, isto é,

$$f_\theta(x) = \frac{\theta^{\alpha_0}}{\Gamma(\alpha_0)} x^{\alpha_0 - 1} \exp\{-\theta x\}$$

para $x > 0$, $\theta > 0$, e em que $\alpha_0 > 0$ é fixo.

6.1.20 Determine a forma de uma estatística suficiente minimal para uma amostra de tamanho n do modelo Uniforme$[0, \theta]$, em que $\theta > 0$.

6.1.21 Determine a forma de uma estatística suficiente minimal para uma amostra de tamanho n do modelo Uniforme$[\theta_1, \theta_2]$, em que $\theta_1 < \theta_2$.

6.1.22 Para o modelo normal de locação e escala[11], estabeleça que o ponto em que a verossimilhança é maximizada é dado por $(\bar{x}, \hat{\sigma}^2)$, como definido no

No original: *order statistics*[10], *location-scale normal model*[11].

Exemplo 6.1.8. (Sugestão: mostre que a segunda derivada de $\ln L((\bar{x}, \sigma^2) \mid x)$, em relação a σ^2, é negativa em $\hat{\sigma}^2$ e depois argumente que $(\bar{x}, \hat{\sigma}^2)$ é o máximo.)

6.1.23 Suponha que temos uma amostra de n de uma distribuição Bernoulli(θ), em que $\theta \in [0;\ 0{,}5]$. Determine uma estatística suficiente minimal para esse modelo. (Sugestão: é fácil estabelecer a suficiência de $\bar{x}$, mas esse ponto não maximiza a verossimilhança quando $\bar{x} > 0{,}5$, de modo que $\bar{x}$ não pode ser obtido da verossimilhança por maximização, como no Exercício 6.1.6. Em geral, considere a segunda derivada do logaritmo da verossimilhança em qualquer ponto $\theta \in (0;\ 0{,}5)$ e observe que conhecer a verossimilhança significa que podemos calcular qualquer uma de suas derivadas em quaisquer valores em que elas existam.)

6.1.24 Suponha que temos uma amostra de n da distribuição Multinomial$(1, \theta, 2\theta, 1 - 3\theta)$, em que $\theta \in [0, 1/3]$ é desconhecido. Determine a forma da função de verossimilhança e mostre que $x_1 + x_2$ é uma estatística suficiente minimal, em que x_i é o número de valores amostrais correspondentes a uma observação na i-ésima categoria. (Sugestão: Problema 6.1.23.)

6.1.25 Suponha que observamos s de um modelo estatístico com duas densidades, f_1 e f_2. Mostre que a razão de verossimilhança $T(s) = f_1(s)/f_2(s)$ é uma estatística suficiente minimal. (Sugestão: use diretamente a definição de suficiência.)

Desafios

6.1.26 Considere o modelo gama de locação e escala, isto é,

$$f_{(\mu,\sigma)}(x) = \frac{1}{\Gamma(\alpha_0)} \left(\frac{x-\mu}{\sigma}\right)^{\alpha_0 - 1} \exp\left\{-\frac{x-\mu}{\sigma}\right\} \frac{1}{\sigma}$$

para $x > \mu \in R^1$, $\sigma > 0$, e em que $\alpha_0 > 0$ é fixo.

(a) Determine a estatística suficiente minimal para uma amostra de n quando $\alpha_0 = 1$. (Sugestão: determine onde a verossimilhança é positiva e calcule a derivada parcial do logaritmo da verossimilhança em relação a μ.)

(b) Determine a estatística suficiente minimal para uma amostra de n quando $\alpha_0 \neq 1$. (Sugestão: use o Problema 6.1.18, a derivada parcial do logaritmo da verossimilhança em relação a μ, e determine onde ela é infinita.)

Tópicos para discussão

6.1.27 Qual a importância, na sua opinião, de um estatístico tentar quantificar quanto erro há numa inferência feita? Por exemplo, se uma estimativa[12] está sendo indicada para alguma quantidade desconhecida, é importante que o estatístico dê alguma indicação de quão precisa (ou imprecisa) é essa inferência?

6.2 Estimação por Máxima Verossimilhança

Na Seção 6.1, apresentamos a função de verossimilhança $L(\cdot \mid s)$ como base para fazer inferências sobre o valor verdadeiro desconhecido $\theta \in \mathbf{\Omega}$. Começamos agora a considerar os tipos específicos de inferência discutidos na Seção 5.5.3, começando pela estimação[13].

Quando nos interessa uma estimativa pontual de θ, um valor $\hat{\theta}(s)$ que maximiza $L(\theta \mid s)$ é uma escolha sensata, pois esse é o valor mais bem sustentado pelos dados, isto é,

$$L(\hat{\theta}(s) \mid s) \geq L(\theta \mid s) \tag{6.2.1}$$

para todo $\theta \in \mathbf{\Omega}$.

Definição 6.2.1

Chamamos $\hat{\theta} : S \to \mathbf{\Omega}$ que satisfaz (6.2.1) para todo $\theta \in \mathbf{\Omega}$ de *estimador de máxima verossimilhança*, e o valor $\hat{\theta}(s)$ é chamado de *estimativa de máxima verossimilhança* ou, abreviadamente, *EMV*.

Observe que, se usarmos $cL(\cdot \mid s)$ como função de verossimilhança, para $c > 0$ fixo, então $\hat{\theta}(s)$ também é um EMV para essa versão da verossimilhança. Assim, podemos usar qualquer versão da verossimilhança para calcular um EMV.

No original: *estimate*[12], *estimation*[13].

Exemplo 6.2.1

Suponha que o espaço amostral seja $S = \{1, 2, 3\}$, que o espaço paramétrico seja $\boldsymbol{\Omega} = \{1, 2\}$ e que o modelo seja dado pela tabela a seguir.

	$s = 1$	$s = 2$	$s = 3$
$f_1(s)$	0,3	0,4	0,3
$f_2(s)$	0,1	0,7	0,2

Suponha, além disso, que observamos $s = 1$. Assim, por exemplo, poderíamos ter recebido uma de duas tigelas de fichas contendo essas proporções de fichas marcadas com 1, 2 e 3. Retiramos uma ficha, observamos que ela está marcada com 1 e agora queremos fazer inferências sobre qual tigela recebemos.

Nesse caso, o EMV é dado por $\hat{\theta}(1) = 1$, pois $0{,}3 = L(1 \mid 1) > 0{,}1 = L(2 \mid 1)$. Se tivéssemos observado $s = 2$, então $\hat{\theta}(2) = 2$; se tivéssemos observado $s = 3$, então $\hat{\theta}(3) = 1$. ■

Note que um EMV não precisa ser único. Por exemplo, no Exemplo 6.2.1, se f_2 fosse definida por $f_2(1) = 0$, $f_2(2) = 0{,}7$ e $f_2(3) = 0{,}3$, então um EMV seria o dado ali, mas tomar $\hat{\theta}(3) = 2$ também daria um EMV.

O EMV tem uma propriedade de invariância muito importante. Suponha que *reparametrizamos* um modelo por meio de uma função injetora[14] Ψ definida em $\boldsymbol{\Omega}$. Com isso queremos dizer que, em vez de rotular as distribuições individuais do modelo com $\theta \in \boldsymbol{\Omega}$, usamos $\psi \in \mathrm{Y} = \{\Psi(\theta) : \theta \in \boldsymbol{\Omega}\}$. Por exemplo, no Exemplo 6.2.1, poderíamos tomar $\Psi(1) = a$ e $\Psi(2) = b$, de modo que $\mathrm{Y} = \{a, b\}$. Assim, o modelo passa a ser dado por $\{g_\psi : \psi \in \mathrm{Y}\}$, em que $g_\psi = f_\theta$ para o único valor θ tal que $\Psi(\theta) = \psi$. Temos um novo parâmetro ψ e um novo espaço paramétrico Y. Nada mudou nas distribuições de probabilidade do modelo estatístico; mudou apenas a maneira como elas são rotuladas. Temos, então, o resultado a seguir.

Teorema 6.2.1

Se $\hat{\theta}(s)$ é um EMV para a parametrização original e se Ψ é uma função injetora definida em $\boldsymbol{\Omega}$, então $\hat{\psi}(s) = \Psi(\hat{\theta}(s))$ é um EMV na nova parametrização.

Demonstração. Se escolhermos como função de verossimilhança da nova

No original: *one-to-one*[14].

parametrização $L^*(\psi \mid s) = g_\psi(s)$, e como verossimilhança da parametrização original $L(\theta \mid s) = f_\theta(s)$, então teremos

$$L^*(\hat{\psi}(s) \mid s) = g_{\Psi(\hat{\theta}(s))}(s) = f_{\hat{\theta}(s)}(s) = L(\hat{\theta}(s) \mid s) \geq L(\theta \mid s) = L^*(\Psi(\theta) \mid s)$$

para todo $\theta \in \mathbf{\Omega}$. Isso implica que $L^*(\hat{\psi}(s) \mid s) \geq L^*(\psi \mid s)$ para todo $\psi \in \mathrm{Y}$ e estabelece o resultado. ■

O Teorema 6.2.1 mostra que, não importa como parametrizamos o modelo, o EMV se comporta de maneira coerente sob a reparametrização. Essa é uma propriedade importante, e nem todos os procedimentos de estimação a satisfazem.

6.2.1 Cálculo do EMV

Uma questão importante é o cálculo dos EMVs. No Exemplo 6.2.1, conseguimos fazê-lo simplesmente examinando a tabela que dá as distribuições. Com modelos mais complicados, essa abordagem não é possível. Em muitas situações, porém, podemos usar os métodos do cálculo para calcular $\hat{\theta}(s)$. Para isso, exigimos que $f_\theta(s)$ seja uma função continuamente diferenciável de θ, para podermos usar os métodos de otimização do cálculo.

Em vez de usar a função de verossimilhança, muitas vezes é conveniente usar a função de log-verossimilhança[15].

Definição 6.2.2

Para a função de verossimilhança $L(\cdot \mid s)$, a *função de log-verossimilhança* $l(\cdot \mid s)$, definida em $\mathbf{\Omega}$, é dada por $l(\cdot \mid s) = \ln L(\cdot \mid s)$.

Note que $\ln(x)$ é uma função injetora e crescente de $x > 0$, e isso implica que $L(\hat{\theta}(s) \mid s) \geq L(\theta \mid s)$ para todo $\theta \in \mathbf{\Omega}$ se e somente se $l(\hat{\theta}(s) \mid s) \geq l(\theta \mid s)$ para todo $\theta \in \mathbf{\Omega}$. Assim, ao calcular um EMV, podemos maximizar $l(\cdot \mid s)$ em vez de $L(\cdot \mid s)$. A conveniência da log-verossimilhança vem do fato de que, para uma amostra $(s_1, \ldots, s_n)$ de $\{f_\theta : \theta \in \mathbf{\Omega}\}$, a função de verossimilhança é dada por

$$L(\theta \mid s_1, \ldots, s_n) = \prod_{i=1}^{n} f_\theta(s_i),$$

enquanto a log-verossimilhança é dada por

$$l(\theta \mid s_1, \ldots, s_n) = \sum_{i=1}^{n} \ln f_\theta(s_i).$$

No original: *log-likelihood*[15].

Em geral, é muito mais fácil derivar uma soma do que um produto.

Como vamos derivar a log-verossimilhança, é conveniente dar um nome a essa derivada. Definimos a *função escore*[16] $S(\theta \mid s)$ de um modelo como a derivada de sua função de log-verossimilhança, sempre que ela existir. Assim, quando θ é um parâmetro real unidimensional,

$$S(\theta \mid s) = \frac{\partial l(\theta \mid s)}{\partial \theta},$$

desde que essa derivada parcial exista (ver o Apêndice A.5 para a definição de derivada parcial). Restringimos agora nossa atenção à situação em que θ é unidimensional.

Para obter o EMV, precisamos então resolver a *equação escore*[17]

$$S(\theta \mid s) = 0 \tag{6.2.2}$$

em θ. É claro que uma solução de (6.2.2) não é necessariamente um EMV, porque esse ponto pode ser um mínimo local, ou apenas um máximo local em vez de um máximo global. Para garantir que uma solução $\hat{\theta}(s)$ seja pelo menos um máximo local, precisamos também verificar que

$$\left.\frac{\partial S(\theta \mid s)}{\partial \theta}\right|_{\theta=\hat{\theta}(s)} = \left.\frac{\partial^2 l(\theta \mid s)}{\partial \theta^2}\right|_{\theta=\hat{\theta}(s)} < 0. \tag{6.2.3}$$

Depois, precisamos calcular $l(\cdot \mid s)$ em cada máximo local para determinar o máximo global.

Vamos calcular alguns EMVs usando cálculo.

No original: *score function*[16], *score equation*[17].

Exemplo 6.2.2 — Modelo Normal de Locação

Considere a função de verossimilhança

$$L(\theta \mid x_1, \ldots, x_n) = \exp\left(-\frac{n}{2\sigma_0^2}(\bar{x} - \theta)^2\right),$$

obtida no Exemplo 6.1.4 para uma amostra $(x_1, \ldots, x_n)$ do modelo $N(\theta, \sigma_0^2)$, em que $\theta \in R^1$ é desconhecido e σ_0^2 é conhecido. A função de log-verossimilhança é, então,

$$l(\theta \mid x_1, \ldots, x_n) = -\frac{n}{2\sigma_0^2}(\bar{x} - \theta)^2,$$

e a função escore é

$$S(\theta \mid x_1, \ldots, x_n) = \frac{n}{\sigma_0^2}(\bar{x} - \theta).$$

A equação escore é dada por

$$\frac{n}{\sigma_0^2}(\bar{x} - \theta) = 0.$$

Resolvendo-a em θ, obtemos a solução única $\hat{\theta}(x_1, \ldots, x_n) = \bar{x}$. Para verificar que ela é um máximo local, calculamos

$$\left.\frac{\partial S(\theta \mid x_1, \ldots, x_n)}{\partial \theta}\right|_{\theta=\bar{x}} = -\frac{n}{\sigma_0^2},$$

que é negativo e, portanto, indica que $\bar{x}$ é um máximo local. Como temos apenas um máximo local, ele também é o máximo global, e de fato obtivemos o EMV. ■

Exemplo 6.2.3 — Modelo Exponencial

Suponha que se saiba que um tempo de vida tem distribuição Exponencial$(1/\theta)$, em que $\theta > 0$ é desconhecido. Então, com base numa amostra $(x_1, \dots, x_n)$, a verossimilhança é dada por

$$L(\theta \mid x_1, \dots, x_n) = \frac{1}{\theta^n} \exp\left(-\frac{n\bar{x}}{\theta}\right),$$

a log-verossimilhança é dada por

$$l(\theta \mid x_1, \dots, x_n) = -n \ln \theta - \frac{n\bar{x}}{\theta},$$

e a função escore é dada por

$$S(\theta \mid x_1, \dots, x_n) = -\frac{n}{\theta} + \frac{n\bar{x}}{\theta^2}.$$

Resolvendo a equação escore, obtemos $\hat{\theta}(x_1, \dots, x_n) = \bar{x}$ e, como $\bar{x} > 0$,

$$\frac{\partial S(\theta \mid x_1, \dots, x_n)}{\partial \theta}\bigg|_{\theta=\bar{x}} = \frac{n}{\theta^2} - 2\frac{n\bar{x}}{\theta^3}\bigg|_{\theta=\bar{x}} = -\frac{n}{\bar{x}^2} < 0,$$

de modo que $\bar{x}$ é de fato o EMV. ■

Nos dois exemplos que acabamos de ver, conseguimos deduzir fórmulas simples para o EMV. Isso nem sempre é possível. Considere o exemplo a seguir.

Exemplo 6.2.4

Considere uma população em que os indivíduos são classificados em um de três tipos, rotulados 1, 2 e 3, respectivamente. Suponha, além disso, que se saiba que as proporções de indivíduos que caem nessas categorias seguem a lei $p_1 = \theta$, $p_2 = \theta^2$, $p_3 = 1 - \theta - \theta^2$, em que

$$\theta \in [0, (\sqrt{5} - 1)/2] = [0; 0{,}61803]$$

é desconhecido. Aqui, p_i denota a proporção de indivíduos na i-ésima classe. Note que a exigência $0 \leq \theta + \theta^2 \leq 1$ impõe a cota superior para θ, e a cota exata é obtida resolvendo $\theta + \theta^2 - 1 = 0$ em θ pela fórmula de Bhaskara. Relações como essa, entre as proporções da distribuição de uma variável categórica, surgem com frequência em genética. Por exemplo, a variável categórica pode servir para classificar indivíduos em diferentes genótipos.

Para uma amostra de tamanho n (em que n é pequeno em relação ao

tamanho da população, de modo que podemos supor que as observações são i.i.d.), a função de verossimilhança é dada por

$$L(\theta \mid x_1, \ldots, x_n) = \theta^{x_1}\theta^{2x_2}(1-\theta-\theta^2)^{x_3},$$

em que x_i denota a contagem amostral na i-ésima classe. A função de log-verossimilhança é, então,*

$$l(\theta \mid s_1, \ldots, s_n) = (x_1 + 2x_2)\ln\theta + x_3 \ln(1-\theta-\theta^2),$$

e a função escore é

$$S(\theta \mid s_1, \ldots, s_n) = \frac{(x_1+2x_2)}{\theta} - \frac{x_3(1+2\theta)}{1-\theta-\theta^2}.$$

A equação escore leva então a uma solução $\hat{\theta}$ que é raiz da quadrática

$$\begin{aligned}&(x_1+2x_2)(1-\theta-\theta^2) - x_3(\theta+2\theta^2)\\ &\quad = -(x_1+2x_2+2x_3)\theta^2 - (x_1+2x_2+x_3)\theta + (x_1+2x_2).\end{aligned}$$

Usando a fórmula de Bhaskara, obtemos

$$\begin{aligned}\hat{\theta} = &\frac{1}{2(x_1+2x_2+2x_3)}\\ &\times\left(-x_1-2x_2-x_3 \pm \sqrt{5x_1^2+20x_1x_2+10x_1x_3+20x_2^2+20x_2x_3+x_3^2}\right).\end{aligned}$$

Note que a fórmula das raízes não determina o EMV de maneira clara. Na verdade, não conseguimos nem dizer se alguma das raízes está em $[0,1]$! Assim, há quatro valores possíveis para o EMV neste ponto: qualquer uma das raízes ou os pontos de fronteira 0 e 0,61803.

Podemos resolver isso facilmente numa aplicação, simplesmente calculando numericamente a verossimilhança nos quatro pontos. Por exemplo, se $x_1 = 70$, $x_2 = 5$ e $x_3 = 25$, então as raízes são $-1{,}28616$ e $0{,}47847$, de modo que é imediato que o EMV é $\hat{\theta}(x_1, \ldots, x_n) = 0{,}47847$. Podemos ver isso graficamente no gráfico da log-verossimilhança apresentado na Figura 6.2.1. ■

Em geral, a equação escore (6.2.2) precisa ser resolvida numericamente, com uma rotina iterativa como a de Newton–Raphson. O Exemplo 6.2.4 mostra que devemos ter muito cuidado para não aceitar simplesmente como EMV uma

*Nota do tradutor. O original passa a escrever $s_1, \ldots, s_n$ em vez de $x_1, \ldots, x_n$ nesta fórmula e na seguinte; mantido como impresso.

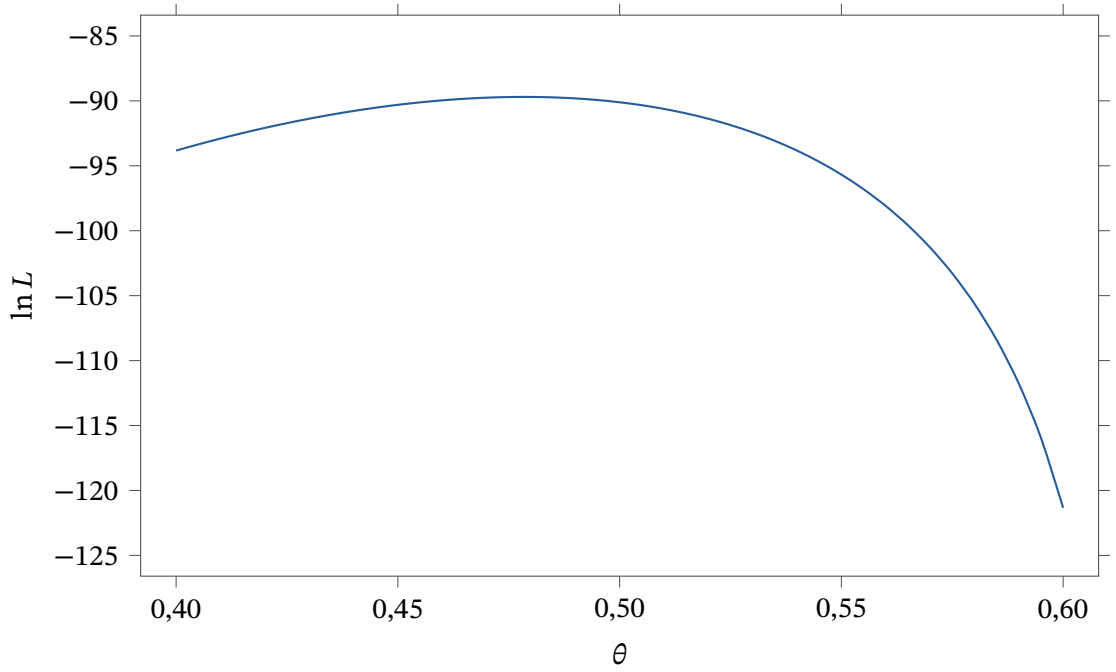


Figura 6.2.1: A função de log-verossimilhança do Exemplo 6.2.4 quando $x_1 = 70$, $x_2 = 5$ e $x_3 = 25$.

solução dada por esse tipo de procedimento, e sim verificar que a propriedade fundamental que o define, (6.2.1), está satisfeita. Também precisamos ter cuidado para que as condições de suavidade necessárias estejam satisfeitas, de modo que o cálculo possa ser usado. Considere o exemplo a seguir.

Exemplo 6.2.5 — Modelo Uniforme$[0, \theta]$

Suponha que $(x_1, \ldots, x_n)$ seja uma amostra do modelo Uniforme$[0, \theta]$, em que $\theta > 0$ é desconhecido. Então, a função de verossimilhança é dada por

$$L(\theta \mid x_1, \ldots, x_n) = \begin{cases} \theta^{-n} & x_i \leq \theta \text{ para } i = 1, \ldots, n \\ 0 & x_i > \theta \text{ para algum } i \end{cases}$$
$$= \theta^{-n} I_{[x_{(n)}, \infty)}(\theta),$$

em que $x_{(n)}$ é a maior estatística de ordem da amostra. Na Figura 6.2.2, fizemos o gráfico dessa função quando $n = 10$ e $x_{(n)} = 1{,}916$. Note que o máximo ocorre claramente em $x_{(n)}$; não conseguimos obter esse valor por derivação, pois $L(\cdot \mid x_1, \ldots, x_n)$ não é diferenciável nesse ponto. ■

A lição dos Exemplos 6.2.4 e 6.2.5 é que precisamos ter cuidado ao calcular EMVs. Vejamos agora um exemplo de problema bidimensional em que o EMV pode ser obtido com métodos unidimensionais.

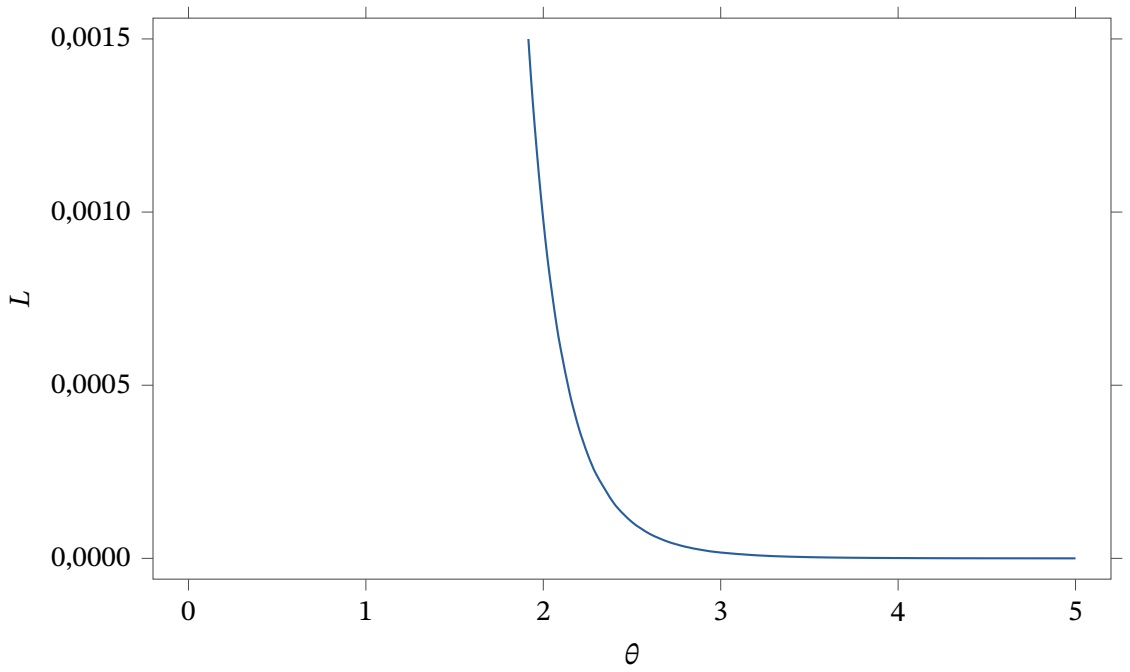


Figura 6.2.2: Gráfico da função de verossimilhança do Exemplo 6.2.5 quando $n = 10$ e $x_{(10)} = 1{,}916$.

Exemplo 6.2.6 — Modelo Normal de Locação e Escala

Suponha que $(x_1, \ldots, x_n)$ seja uma amostra de uma distribuição $N(\mu, \sigma^2)$, em que $\mu \in R^1$ e $\sigma > 0$ são desconhecidos. O parâmetro desse modelo é bidimensional, dado por $\theta = (\mu, \sigma^2) \in \mathbf{\Omega} = R^1 \times (0, \infty)$. A função de verossimilhança é, então, dada por

$$L(\mu, \sigma^2 \mid x_1, \ldots, x_n) = (2\pi\sigma^2)^{-n/2} \exp\left(-\frac{n}{2\sigma^2}(\bar{x} - \mu)^2\right) \exp\left(-\frac{n-1}{2\sigma^2}s^2\right),$$

como mostrado no Exemplo 6.1.8. A função de log-verossimilhança é dada por

$$l(\mu, \sigma^2 \mid x_1, \ldots, x_n) = -\frac{n}{2}\ln 2\pi - \frac{n}{2}\ln\sigma^2 - \frac{n}{2\sigma^2}(\bar{x} - \mu)^2 - \frac{n-1}{2\sigma^2}s^2. \quad (6.2.4)$$

Como discutido no Exemplo 6.1.8, é claro que, para σ^2 fixo, (6.2.4) é maximizada, como função de μ, por $\hat{\mu} = \bar{x}$. Note que isso não envolve σ^2; logo, essa tem de ser a primeira coordenada do EMV.

Substituindo $\mu = \bar{x}$ em (6.2.4), obtemos

$$-\frac{n}{2}\ln 2\pi - \frac{n}{2}\ln\sigma^2 - \frac{n-1}{2\sigma^2}s^2, \quad (6.2.5)$$

e a segunda coordenada do EMV tem de ser o valor de σ^2 que maximiza

(6.2.5). Derivando (6.2.5) em relação a σ^2 e igualando a 0, obtemos

$$-\frac{n}{2\sigma^2} + \frac{n-1}{2(\sigma^2)^2}s^2 = 0. \tag{6.2.6}$$

Resolvendo (6.2.6) em σ^2, chegamos à solução

$$\hat{\sigma}^2 = \frac{n-1}{n}s^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2.$$

Derivando (6.2.6) em relação a σ^2 e substituindo $\hat{\sigma}^2$, vemos que a derivada segunda é negativa; logo, $\hat{\sigma}^2$ é um ponto em que o máximo é atingido.

Portanto, mostramos que o EMV de (μ, σ^2) é dado por

$$\left(\bar{x}, \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2\right).$$

Na próxima seção, mostraremos que esse resultado também pode ser obtido com o cálculo em várias variáveis. ■

Até aqui falamos apenas da estimação do parâmetro completo θ de um modelo. E quanto à estimação de uma característica de interesse geral $\psi(\theta)$, para alguma função ψ definida no espaço paramétrico $\mathbf{\Omega}$? Talvez a resposta óbvia aqui seja usar a estimativa $\hat{\psi}(s) = \psi(\hat{\theta}(s))$, em que $\hat{\theta}(s)$ é um EMV de θ. Isso às vezes é chamado de *EMV plug-in* de ψ. Note, porém, que o EMV plug-in não é necessariamente um EMV verdadeiro, no sentido de termos uma função de verossimilhança para um modelo indexado por ψ que atinja seu valor máximo em $\hat{\psi}(s)$. Se ψ é uma função injetora definida em $\mathbf{\Omega}$, então o Teorema 6.2.1 estabelece que $\hat{\psi}(s)$ é um EMV verdadeiro, mas não nos outros casos.

Se ψ não é injetora, muitas vezes podemos encontrar uma *função complementar*[18] λ definida em $\mathbf{\Omega}$ tal que (ψ, λ) seja uma função injetora de θ. Então, pelo Teorema 6.2.1,

$$(\hat{\psi}(s), \hat{\lambda}(s)) = (\psi(\hat{\theta}(s)), \lambda(\hat{\theta}(s)))$$

é o EMV conjunto, mas $\hat{\psi}(s)$ ainda não é formalmente um EMV. Às vezes, um EMV plug-in pode ter um desempenho ruim, pois ignora a informação contida em $\lambda(\hat{\theta}(s))$ sobre o valor verdadeiro de ψ. Um exemplo ilustra esse fenômeno.

No original: *complement*[18].

Exemplo 6.2.7 — Soma dos Quadrados das Médias

Suponha que $X_i \sim N(\mu_i, 1)$ para $i = 1, \dots, n$ e que essas variáveis sejam independentes, com as μ_i completamente desconhecidas. Aqui, $\theta = (\mu_1, \dots, \mu_n)$ e $\boldsymbol{\Omega} = R^n$. Suponha que queremos estimar $\psi(\theta) = \mu_1^2 + \cdots + \mu_n^2$.

A função de log-verossimilhança é dada por

$$l(\theta \mid x_1, \dots, x_n) = -\frac{1}{2}\sum_{i=1}^{n}(x_i - \mu_i)^2.$$

É claro que ela é maximizada por $\hat{\theta}(x_1, \dots, x_n) = (x_1, \dots, x_n)$. Assim, o EMV plug-in de ψ é dado por $\hat{\psi} = \sum_{i=1}^{n} x_i^2$.

Observe agora que

$$E_\theta\left(\sum_{i=1}^{n} X_i^2\right) = \sum_{i=1}^{n} E_\theta(X_i^2) = \sum_{i=1}^{n}(\mathrm{Var}_\theta(X_i) + \mu_i^2) = n + \psi(\theta),$$

em que $E_\theta(g)$ se refere à esperança de $g(s)$ quando $s \sim f_\theta$. Assim, quando n é grande, é provável que $\hat{\psi}$ esteja longe do valor verdadeiro. Uma melhoria imediata desse estimador é usar, em vez dele, $\sum_{i=1}^{n} x_i^2 - n$. ■

Houve várias tentativas de corrigir problemas como o ilustrado no Exemplo 6.2.7. Em geral, elas envolvem modificar a verossimilhança de alguma maneira. Não seguiremos com essa questão neste texto, mas recomendamos cautela ao usar EMVs plug-in. Às vezes, como no Exemplo 6.2.6, em que estimamos μ por $\bar{x}$ e σ^2 por s^2, eles parecem adequados; outras vezes, como no Exemplo 6.2.7, não.

6.2.2 O Caso Multidimensional (Avançado)

Consideramos agora a situação em que $\theta = (\theta_1, \dots, \theta_k) \in R^k$ é multidimensional, isto é, $k > 1$. A verossimilhança e a log-verossimilhança são definidas exatamente como antes, mas a função escore passa a ser dada por

$$S(\theta \mid s) = \begin{pmatrix} \dfrac{\partial l(\theta \mid s)}{\partial \theta_1} \\ \dfrac{\partial l(\theta \mid s)}{\partial \theta_2} \\ \vdots \\ \dfrac{\partial l(\theta \mid s)}{\partial \theta_k} \end{pmatrix},$$

desde que todas essas derivadas parciais existam. Para a equação escore, obtemos

$$\begin{pmatrix} \frac{\partial l(\theta \mid s)}{\partial \theta_1} \\ \frac{\partial l(\theta \mid s)}{\partial \theta_2} \\ \vdots \\ \frac{\partial l(\theta \mid s)}{\partial \theta_k} \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{pmatrix},$$

e precisamos resolver essa equação k-dimensional em $(\theta_1, \ldots, \theta_k)$. Isso costuma ser muito mais difícil do que no caso unidimensional, e em geral temos de recorrer a métodos numéricos.

Uma condição necessária e suficiente para que $(\hat{\theta}_1, \ldots, \hat{\theta}_k)$ seja um máximo local, quando a log-verossimilhança tem derivadas parciais segundas contínuas, é que a matriz das derivadas parciais segundas da log-verossimilhança, calculada em $(\hat{\theta}_1, \ldots, \hat{\theta}_k)$, seja definida negativa (equivalentemente, todos os seus autovalores devem ser negativos). Depois, precisamos calcular a verossimilhança em cada um dos máximos locais obtidos para determinar o máximo global, ou EMV.

Não seguiremos aqui com o cálculo numérico de EMVs no caso multidimensional; restringimos nossa atenção a uma situação em que fazemos as contas em forma fechada.

Exemplo 6.2.8 — Modelo Normal de Locação e Escala

Determinamos a função de log-verossimilhança desse modelo em (6.2.4). A função escore é, então,*

$$S(\mu, \sigma^2 \mid x_1, \dots, x_n) = \begin{pmatrix} \dfrac{\partial S(\theta \mid x_1, \dots, x_n)}{\partial \mu} \\ \dfrac{\partial S(\theta \mid x_1, \dots, x_n)}{\partial \sigma^2} \end{pmatrix} = \begin{pmatrix} \dfrac{n}{\sigma^2}(\bar{x} - \mu) \\ -\dfrac{n}{2\sigma^2} + \dfrac{n}{2\sigma^4}(\bar{x} - \mu)^2 + -\dfrac{n-1}{2\sigma^4}s^2 \end{pmatrix}.$$

A equação escore é

$$\begin{pmatrix} \dfrac{n}{\sigma^2}(\bar{x} - \mu) \\ -\dfrac{n}{2\sigma^2} + \dfrac{n}{2\sigma^4}(\bar{x} - \mu)^2 + \dfrac{n-1}{2\sigma^4}s^2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix},$$

e a primeira dessas equações implica imediatamente que $\hat{\mu} = \bar{x}$. Substituindo esse valor de μ na segunda equação e resolvendo em σ^2, chegamos à solução

$$\hat{\sigma}^2 = \frac{n-1}{n}s^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2.$$

Pelo Exemplo 6.2.6, sabemos que essa solução de fato dá o EMV. ■

Resumo da Seção 6.2

- Um EMV (estimador de máxima verossimilhança) é um valor do parâmetro θ que maximiza a função de verossimilhança. É o valor de θ mais bem sustentado pelo modelo e pelos dados.
- Muitas vezes podemos calcular um EMV pelos métodos do cálculo. Quando aplicável, isso leva a resolver a equação escore em θ, explicitamente ou por meio de algoritmos numéricos. Verifique sempre, com cuidado, se esses métodos se aplicam ao problema específico em questão. Além disso, verifique sempre se uma solução da

*Nota do tradutor. O original traz $\partial S(\theta \mid x_1, \dots, x_n)$ nas derivadas da primeira linha; pela definição da função escore seria ∂l. Na segunda linha, o original traz "$+ - \frac{n-1}{2\sigma^4}s^2$"; pela conta (e como na equação escore logo abaixo), seria $+\frac{n-1}{2\sigma^4}s^2$. Mantido como impresso.

equação escore é um máximo e, de fato, um máximo absoluto.

Exercícios

6.2.1 Suponha que $S = \{1, 2, 3, 4\}$ e $\mathbf{\Omega} = \{a, b\}$, em que as duas distribuições de probabilidade são dadas pela tabela a seguir.

	$s = 1$	$s = 2$	$s = 3$	$s = 4$
$\theta = a$	1/2	1/6	1/6	1/6
$\theta = b$	1/3	1/3	1/3	0

Determine o EMV de θ para cada valor possível dos dados.

6.2.2 Se $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição Bernoulli(θ), em que $\theta \in [0, 1]$ é desconhecido, determine o EMV de θ.

6.2.3 Se $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição Bernoulli(θ), em que $\theta \in [0, 1]$ é desconhecido, determine o EMV de θ^2.

6.2.4 Se $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição Poisson(θ), em que $\theta \in (0, \infty)$ é desconhecido, determine o EMV de θ.

6.2.5 Se $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição Gama(α_0, θ), em que $\alpha_0 > 0$ e $\theta \in (0, \infty)$ é desconhecido, determine o EMV de θ.

6.2.6 Suponha que $(x_1, \ldots, x_n)$ seja o resultado de lançamentos independentes de uma moeda, em que lançamos até sair a primeira cara e em que a probabilidade de cara num único lançamento é $\theta \in (0, 1]$. Determine o EMV de θ.

6.2.7 Se $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição Beta(α, 1) (ver o Problema 2.4.24), em que $\alpha > 0$ é desconhecido, determine o EMV de α. (Sugestão: suponha que $\Gamma(\alpha)$ seja uma função diferenciável de α.)

6.2.8 Se $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição Weibull(β) (ver o Problema 2.4.19), em que $\beta > 0$ é desconhecido, determine a equação escore para o EMV de β.

6.2.9 Se $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição Pareto(α) (ver o Problema 2.4.20), em que $\alpha > 0$ é desconhecido, determine o EMV de α.

6.2.10 Se $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição Log-normal[19](τ) (ver o Problema 2.6.17), em que $\tau > 0$ é desconhecido, determine o EMV de τ.

6.2.11 Suponha que você esteja medindo o volume de uma caixa cúbica, em centímetros, fazendo medições independentes repetidas de um dos lados. Suponha que seja razoável supor que uma única medição segue uma distribuição $N(\mu, \sigma_0^2)$, em que μ é desconhecido e σ_0^2 é conhecido. Com base numa amostra de medições, você obtém o EMV de μ igual a 3,2 cm. Qual é a sua estimativa do volume da caixa? Como você justifica isso em termos da função de verossimilhança?

6.2.12 Se $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição $N(\mu_0, \sigma^2)$, em que $\sigma^2 > 0$ é desconhecido e μ_0 é conhecido, determine o EMV de σ^2. Em que esse EMV difere do EMV plug-in de σ^2 calculado com o modelo normal de locação e escala?

6.2.13 Explique por que não é possível que a função $\theta^3 \exp(-(\theta - 5{,}3)^2)$, para $\theta \in R^1$, seja uma função de verossimilhança.

6.2.14 Suponha que lhe digam que uma função de verossimilhança tem máximos locais nos pontos $-2{,}2$, 4,6 e 9,2, determinados com o cálculo. Explique como você determinaria o EMV.

6.2.15 Se duas funções de θ são versões equivalentes da verossimilhança quando uma é um múltiplo positivo da outra, quando duas funções de log-verossimilhança são equivalentes?

6.2.16 Suponha que lhe digam que a verossimilhança de θ em $\theta = 2$ é dada por 1/4. Essa é a probabilidade de que $\theta = 2$? Explique por quê.

Exercícios computacionais

6.2.17 Uma função de verossimilhança é dada por $\exp(-(\theta - 1)^2/2) + 3\exp(-(\theta - 2)^2/2)$ para $\theta \in R^1$. Aproxime numericamente o EMV calculando essa função em 1000 pontos igualmente espaçados em $(-10, 10]$. Faça também o gráfico da função de verossimilhança.

6.2.18 Uma função de verossimilhança é dada por $\exp(-(\theta - 1)^2/2) + 3\exp(-(\theta - 5)^2/2)$ para $\theta \in R^1$. Aproxime numericamente o EMV calculando essa função em 1000 pontos igualmente espaçados em $(-10, 10]$. Faça também

No original: *Log-normal distribution*[19].

o gráfico da função de verossimilhança. Comente a forma dos intervalos de verossimilhança.

Problemas

6.2.19 (*Lei de Hardy–Weinberg*) A lei de Hardy–Weinberg, em genética, diz que as proporções dos genótipos AA, Aa e aa são θ^2, $2\theta(1-\theta)$ e $(1-\theta)^2$, respectivamente, em que $\theta \in [0,1]$. Suponha que, numa amostra de tamanho n da população (pequena em relação ao tamanho da população), observamos x_1 indivíduos do tipo AA, x_2 indivíduos do tipo Aa e x_3 indivíduos do tipo aa.

(a) Que distribuição as contagens (X_1, X_2, X_3) seguem?

(b) Registre a função de verossimilhança, a função de log-verossimilhança e a função escore para θ.

(c) Registre a forma do EMV de θ.

6.2.20 Se $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição $N(\mu, 1)$, em que $\mu \in R^1$ é desconhecido, determine o EMV da probabilidade do intervalo $(-\infty, 1)$. Justifique sua resposta.

6.2.21 Se $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição $N(\mu, 1)$, em que $\mu \geq 0$ é desconhecido, determine o EMV de μ.

6.2.22 Prove que, se $\hat{\theta}(s)$ é o EMV para um modelo da resposta s e se T é uma estatística suficiente para o modelo, então $\hat{\theta}(s)$ também é o EMV para o modelo de $T(s)$.

6.2.23 Suponha que $(X_1, X_2, X_3) \sim$ Multinomial$(n, \theta_1, \theta_2, \theta_3)$ (ver o Exemplo 6.1.5), em que

$$\mathbf{\Omega} = \{(\theta_1, \theta_2, \theta_3) : 0 \leq \theta_i \leq 1, \theta_1 + \theta_2 + \theta_3 = 1\}$$

e observamos $(X_1, X_2, X_3) = (x_1, x_2, x_3)$.

(a) Determine o EMV de $(\theta_1, \theta_2, \theta_3)$.

(b) Qual é o EMV plug-in de $\theta_1 + \theta_2^2 - \theta_3^2$?

6.2.24 Se $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição Uniforme$[\theta_1, \theta_2]$ com

$$\mathbf{\Omega} = \{(\theta_1, \theta_2) \in R^2 : \theta_1 < \theta_2\},$$

determine o EMV de (θ_1, θ_2). (Sugestão: não é possível usar o cálculo. Em vez disso, determine diretamente o máximo em θ_1 com θ_2 fixo e depois varie θ_2.)

Problemas computacionais

6.2.25 Suponha que a proporção de canhotos numa população seja θ. Com base numa amostra aleatória simples de tamanho 20, você observa quatro canhotos.

(a) Supondo que o tamanho da amostra[20] seja pequeno em relação ao tamanho da população, faça o gráfico da função de log-verossimilhança e determine o EMV.

(b) Se, em vez disso, o tamanho da população for de apenas 50, faça o gráfico da função de log-verossimilhança e determine o EMV. (Sugestão: lembre que o número de canhotos segue uma distribuição hipergeométrica. Isso obriga θ a ser da forma $i/50$ para algum inteiro i entre 4 e 34. A partir de uma tabela da log-verossimilhança, você pode obter o EMV.)

Desafios

6.2.26 Se $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição com densidade

$$f_\theta(x) = (1/2)\exp(-|x-\theta|)$$

para $x \in R^1$ e em que $\theta \in R^1$ é desconhecido, determine o EMV de θ. (Sugestão: não é possível usar o cálculo. Em vez disso, maximize a log-verossimilhança em cada um dos intervalos $(-\infty, x_{(1)})$, $[x_{(1)} \leq \theta < x_{(2)})$ etc.)

Tópicos para discussão

6.2.27 Uma abordagem para quantificar a incerteza de um EMV $\hat{\theta}(s)$ é apresentar o EMV junto com um intervalo de verossimilhança[21] $\{\theta : L(\theta \mid s) \geq cL(\hat{\theta}(s) \mid s)\}$ para alguma constante $c \in (0,1)$. Que problemas você vê nessa abordagem? Em particular, como você escolheria c?

No original: *sample size*[20], *likelihood interval*[21].

6.3 Inferências Baseadas no EMV

Na Tabela 6.3.1, registramos $n = 66$ medições da velocidade da luz (tempo de passagem, registrado como desvios em relação a 24.800 nanossegundos, entre dois espelhos a 7.400 metros de distância) feitas por A. A. Michelson e S. Newcomb em 1882.

Tabela 6.3.1: Medições da velocidade da luz.

28	26	33	24	34	−44	27	16	40	−2	29
22	24	21	25	30	23	29	31	19	24	20
36	32	36	28	25	21	28	29	37	25	28
26	30	32	36	26	30	22	36	23	27	27
28	27	31	27	26	33	26	32	32	24	39
28	24	25	32	25	29	27	28	29	16	23

A Figura 6.3.1 é um boxplot desses dados, com a variável identificada como x. Observe que há dois valores atípicos, em $x = -2$ e $x = -44$. Vamos presumir que há algo muito especial nessas observações e descartá-las no restante da nossa discussão.

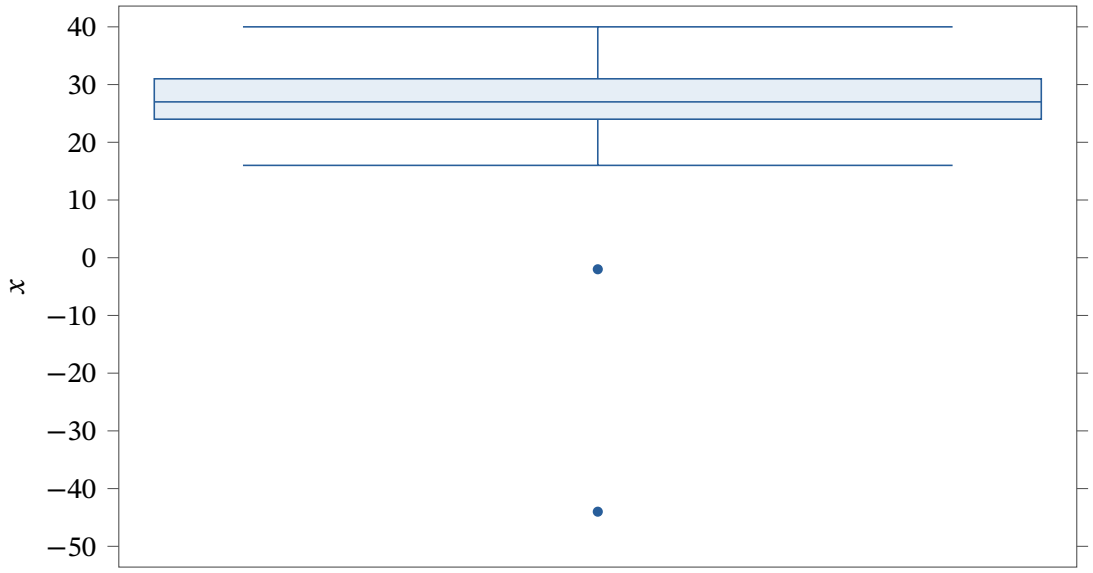


Figura 6.3.1: Boxplot dos valores dos dados da Tabela 6.3.1.

A Figura 6.3.2 apresenta um histograma desses dados sem os dois valores identificados como atípicos. Observe que o histograma parece razoavelmente simétrico; assim, parece plausível supor que esses dados venham de uma distribuição $N(\mu, \sigma^2)$ para alguns valores de μ e σ^2. Por conseguinte, um modelo estatístico razoável para esses dados parece ser o modelo normal de locação

e escala. No Capítulo 9, discutiremos mais a fundo como avaliar a validade da suposição de normalidade.

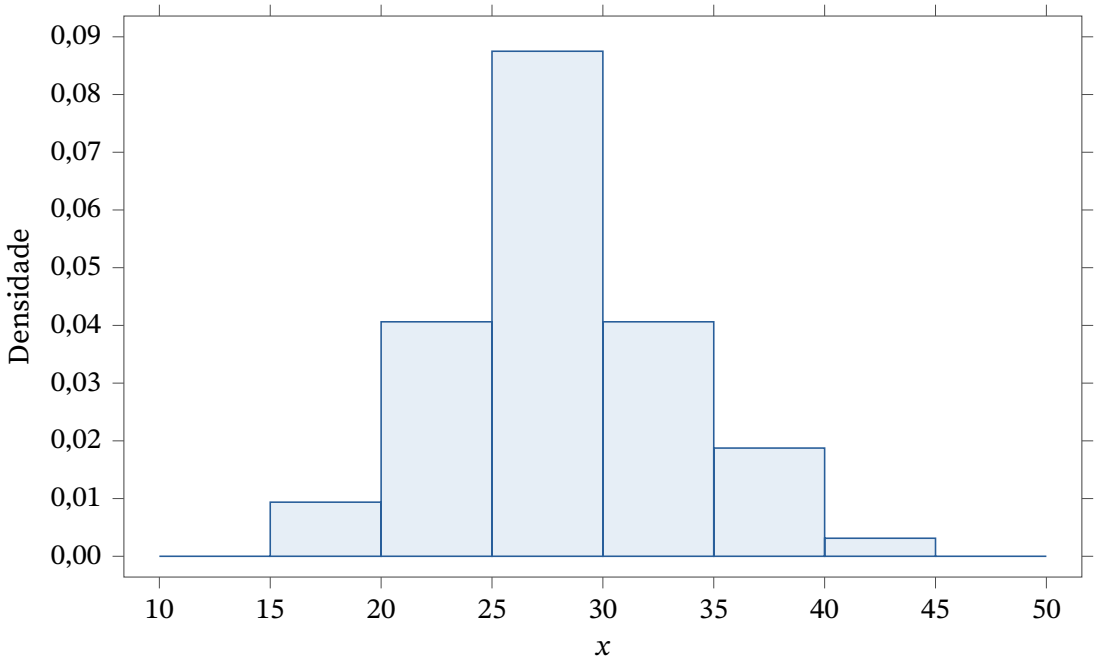


Figura 6.3.2: Histograma de densidade dos dados da Tabela 6.3.1 sem os valores atípicos.

Se aceitarmos que o modelo normal de locação e escala faz sentido, surge a questão de como fazer inferências sobre os parâmetros desconhecidos μ e σ^2. O objetivo desta seção é desenvolver métodos para tratar problemas como esse. Os métodos desenvolvidos nesta seção dependem de características especiais do EMV num contexto dado. Na Seção 6.5, desenvolvemos uma abordagem mais geral baseada no EMV.

6.3.1 Erros Padrão, Viés e Consistência

Com base na justificativa da verossimilhança, o EMV $\hat{\theta}(s)$ parece uma estimativa natural do verdadeiro valor de θ. Suponhamos que vamos então usar a estimativa EMV plug-in $\hat{\psi}(s) = \psi(\hat{\theta}(s))$ para uma característica de interesse $\psi(\theta)$ (por exemplo, $\psi(\theta)$ pode ser o primeiro quartil ou a variância[22]).

Numa aplicação, queremos saber quão confiável é a estimativa $\hat{\psi}(s)$. Em outras palavras, podemos esperar que $\hat{\psi}(s)$ esteja perto do verdadeiro valor de $\psi(\theta)$, ou há uma chance razoável de que $\hat{\psi}(s)$ esteja longe do verdadeiro valor?

No original: *variance*[22].

Isso nos leva a considerar a distribuição amostral[23] de $\hat{\psi}(s)$, pois ela nos diz quanta variabilidade haverá em $\hat{\psi}(s)$ sob amostragem repetida da verdadeira distribuição f_θ. Como não sabemos qual é o verdadeiro valor de θ, temos de olhar a distribuição amostral de $\hat{\psi}(s)$ para todo $\theta \in \mathbf{\Omega}$.

Para simplificar, substituímos isso por uma medida numérica de quão concentradas essas distribuições amostrais estão em torno de $\psi(\theta)$. Talvez a medida mais usada da precisão de um estimador geral $T(s)$ de $\psi(\theta)$ (isto é, não nos restringimos aos EMVs plug-in) seja o erro quadrático médio[24].

Definição 6.3.1

O *erro quadrático médio (MSE)* do estimador T de $\psi(\theta) \in R^1$ é dado por $\text{MSE}_\theta(T) = E_\theta((T - \psi(\theta))^2)$ para cada $\theta \in \mathbf{\Omega}$.

É claro que, quanto menor for $\text{MSE}_\theta(T)$, mais concentrada estará a distribuição amostral de $T(s)$ em torno do valor $\psi(\theta)$.

Olhar $\text{MSE}_\theta(T)$ como função de θ nos dá alguma ideia de quão confiável $T(s)$ é como estimativa do verdadeiro valor de $\psi(\theta)$. Como não conhecemos o verdadeiro valor de θ e, portanto, o verdadeiro valor de $\text{MSE}_\theta(T)$, os estatísticos registram uma estimativa do erro quadrático médio no verdadeiro valor. Muitas vezes,

$$\text{MSE}_{\hat{\theta}(s)}(T)$$

é usado para isso. Em outras palavras, avaliamos $\text{MSE}_\theta(T)$ em $\theta = \hat{\theta}(s)$ como medida da precisão da estimativa $T(s)$.

O resultado a seguir dá uma identidade importante para o MSE.

Teorema 6.3.1

Se $\psi(\theta) \in R^1$ e T é uma função real definida em S tal que $E_\theta(T)$ existe, então

$$\text{MSE}_\theta(T) = \text{Var}_\theta(T) + (E_\theta(T) - \psi(\theta))^2. \tag{6.3.1}$$

No original: *sampling distribution*[23], *mean-squared error*[24].

Demonstração. Temos*

$$\begin{aligned} E_\theta((T-\psi(\theta)))^2 &= E_\theta((T-E_\theta(T)+E_\theta(T)-\psi(\theta))^2) \\ &= E_\theta((T-E_\theta(T))^2) \\ &\quad + 2E_\theta((T-E_\theta(T))(E_\theta(T)-\psi(\theta))) + (E_\theta(T)-\psi(\theta))^2 \\ &= \mathrm{Var}_\theta(T) + (E_\theta(T)-\psi(\theta))^2 \end{aligned}$$

porque

$$\begin{aligned} E_\theta((T-E_\theta(T))(E_\theta(T)-\psi(\theta))) &= (E_\theta(T-E_\theta(T)))(E_\theta(T)-\psi(\theta)) \\ &= 0. \end{aligned}$$

■

O segundo termo em (6.3.1) é o quadrado do viés do estimador T.

Definição 6.3.2

O *viés* do estimador T de $\psi(\theta)$ é dado por $E_\theta(T)-\psi(\theta)$ sempre que $E_\theta(T)$ existe. Quando o viés de um estimador T é 0 para todo θ, dizemos que T é um *estimador não viesado* de ψ, isto é, T é não viesado sempre que $E_\theta(T)=\psi(\theta)$ para todo $\theta \in \mathbf{\Omega}$.

Note que, quando o viés de um estimador é 0, o MSE é simplesmente a variância.

A ausência de viés nos diz que, em certo sentido, a distribuição amostral do estimador está centrada no verdadeiro valor. Para estimadores não viesados,

$$\mathrm{MSE}_{\hat{\theta}(s)}(T) = \mathrm{Var}_{\hat{\theta}(s)}(T)$$

e

$$\mathrm{Sd}_{\hat{\theta}(s)}(T) = \sqrt{\mathrm{Var}_{\hat{\theta}(s)}(T)}$$

é uma estimativa do desvio padrão[25] de T e é chamado de *erro padrão*[26] *da estimativa* $T(s)$. Como princípio de boa prática estatística, sempre que informamos uma estimativa de uma quantidade, devemos também informar seu erro padrão — pelo menos quando temos um estimador não viesado[27] —, pois isso nos diz algo sobre a precisão da estimativa.

Consideramos alguns exemplos.

*Nota do tradutor. O original abre os parênteses assim no primeiro membro; pelo resto da conta seria $E_\theta((T-\psi(\theta))^2)$.

No original: *standard deviation*[25], *standard error*[26], *unbiased*[27].

Exemplo 6.3.1 — Modelo Normal de Locação

Considere a função de verossimilhança

$$L(\mu \mid x_1, \ldots, x_n) = \exp\left(-\frac{n}{2\sigma_0^2}(\bar{x} - \mu)^2\right),$$

obtida no Exemplo 6.1.4 para uma amostra $(x_1, \ldots, x_n)$ do modelo $N(\mu, \sigma_0^2)$, em que $\mu \in R^1$ é desconhecido e $\sigma_0^2 > 0$ é conhecido. Suponha que queremos estimar μ. O EMV de μ foi calculado no Exemplo 6.2.2: é $\bar{x}$.

Neste caso, podemos determinar a distribuição amostral do EMV exatamente, a partir dos resultados da Seção 4.6. Temos $\bar{X} \sim N(\mu, \sigma_0^2/n)$; logo, $\bar{X}$ é não viesado, e

$$\mathrm{MSE}_\mu(\bar{X}) = \mathrm{Var}_\mu(\bar{X}) = \frac{\sigma_0^2}{n},$$

que não depende de μ. Assim, neste caso não precisamos estimar o MSE. O erro padrão da estimativa é dado por

$$\mathrm{Sd}_\mu(\bar{X}) = \frac{\sigma_0}{\sqrt{n}}.$$

Note que o erro padrão diminui à medida que a variância populacional σ_0^2 diminui e à medida que o tamanho da amostra n aumenta. ■

Exemplo 6.3.2 — Modelo de Bernoulli

Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição Bernoulli(θ), em que $\theta \in [0, 1]$ é desconhecido. Suponha que queremos estimar θ. A função de verossimilhança é dada por

$$L(\theta \mid x_1, \ldots, x_n) = \theta^{n\bar{x}}(1-\theta)^{n(1-\bar{x})},$$

e o EMV de θ é $\bar{x}$ (Exercício 6.2.2), a proporção de sucessos nas n realizações. Temos $E_\theta(\bar{X}) = \theta$ para todo $\theta \in [0, 1]$; logo, o EMV é um estimador não viesado de θ.

Portanto,

$$\mathrm{MSE}_\theta(\bar{X}) = \mathrm{Var}_\theta(\bar{X}) = \frac{\theta(1-\theta)}{n},$$

e o MSE estimado é

$$\mathrm{MSE}_{\hat{\theta}}(\bar{X}) = \frac{\bar{x}(1-\bar{x})}{n}.$$

O erro padrão da estimativa $\bar{x}$ é então dado por

$$\mathrm{Sd}_{\hat{\theta}}(\bar{X}) = \sqrt{\frac{\bar{x}(1-\bar{x})}{n}}.$$

Note como esse erro padrão é bem diferente do erro padrão de $\bar{x}$ no Exemplo 6.3.1. ■

Exemplo 6.3.3 — Aplicação do Modelo de Bernoulli

Pede-se a um instituto de pesquisa que estime a proporção de domicílios da população de um determinado distrito que vão participar de um programa de reciclagem proposto, separando o lixo em vários componentes. Os pesquisadores decidiram tomar uma amostra de $n = 1000$ da população de aproximadamente 1,5 milhão de domicílios (falaremos mais adiante sobre como escolher esse número).

Cada entrevistado vai responder sim ou não a uma pergunta sobre sua participação. Como o tamanho da amostra é pequeno em relação ao tamanho da população, podemos supor que estamos amostrando de um modelo Bernoulli(θ), em que $\theta \in [0, 1]$ é a proporção de indivíduos da população que vão responder sim.

Feita a amostragem, houve 790 entrevistados que responderam sim e 210 que responderam não. Portanto, o EMV de θ é

$$\hat{\theta} = \bar{x} = \frac{790}{1000} = 0{,}79$$

e o erro padrão da estimativa é

$$\sqrt{\frac{\bar{x}(1-\bar{x})}{1000}} = \sqrt{\frac{0{,}79\,(1-0{,}79)}{1000}} = 0{,}01288.$$

Observe que não está totalmente claro como devemos interpretar o valor 0,01288. Ele significa que nossa estimativa 0,79 é muito precisa, razoavelmente precisa ou nada precisa? Discutiremos isso mais a fundo na Seção 6.3.2. ■

Exemplo 6.3.4 — Modelo Normal de Locação e Escala

Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição $N(\mu, \sigma^2)$, em que $\mu \in R^1$ e $\sigma^2 > 0$ são desconhecidos. O parâmetro desse modelo é dado por $\theta = (\mu, \sigma^2) \in \mathbf{\Omega} = R^1 \times (0, \infty)$. Suponha que queremos estimar $\mu = \psi(\mu, \sigma^2)$, isto é, só a primeira coordenada do parâmetro completo do modelo.

No Exemplo 6.1.8, determinamos que a função de verossimilhança é dada por

$$L(\mu, \sigma^2 \mid x_1, \ldots, x_n) = (2\pi\sigma^2)^{-n/2} \exp\left(-\frac{n}{2\sigma^2}(\bar{x} - \mu)^2\right) \exp\left(-\frac{n-1}{2\sigma^2}s^2\right).$$

No Exemplo 6.2.6, mostramos que o EMV de θ é

$$\left(\bar{x}, \frac{n-1}{n}s^2\right).$$

Além disso, pelo Teorema 4.6.6, a distribuição amostral do EMV é dada por $\bar{X} \sim N(\mu, \sigma^2/n)$, independente de $(n-1)S^2/\sigma^2 \sim \chi^2(n-1)$.

O EMV plug-in de μ é $\bar{x}$. Esse estimador é não viesado e tem

$$\mathrm{MSE}_\theta(\bar{X}) = \mathrm{Var}_\theta(\bar{X}) = \frac{\sigma^2}{n}.$$

Como σ^2 é desconhecido, estimamos $\mathrm{MSE}_\theta(\bar{X})$ por*

$$\mathrm{MSE}_\theta(\bar{X}) = \frac{\frac{n-1}{n}s^2}{n} = \frac{n-1}{n^2}s^2 \approx \frac{s^2}{n}.$$

O valor s^2/n é muito usado no lugar de $\mathrm{MSE}_{\hat{\theta}}(\bar{X})$ porque (Corolário 4.6.2)

$$E_\theta(S^2) = \sigma^2,$$

isto é, S^2 é um estimador não viesado de σ^2. A quantidade $s/\sqrt{n}$ é chamada de *erro padrão* da estimativa $\bar{x}$. ■

*Nota do tradutor. O original traz MSE_θ no primeiro membro; pelo texto, seria a estimativa $\mathrm{MSE}_{\hat{\theta}}(\bar{X})$.

Exemplo 6.3.5 — Aplicação do Modelo Normal de Locação e Escala

No Exemplo 5.5.6, temos uma amostra de $n = 30$ alturas (em polegadas) de estudantes. Calculamos $\bar{x} = 64{,}517$ como nossa estimativa da altura média populacional μ. Além disso, obtivemos a estimativa $s = 2{,}379$ de σ. Portanto, o erro padrão da estimativa $\bar{x} = 64{,}517$ é $s/\sqrt{30} = 2{,}379/\sqrt{30} = 0{,}43434$. Como no Exemplo 6.3.3, ficamos diante da questão de interpretar exatamente o que esse número significa em termos da precisão da estimativa. ■

Consistência de Estimadores

Talvez a propriedade mais importante que um estimador T de uma característica $\psi(\theta)$ pode ter é ser consistente. Em linhas gerais, isso significa que, à medida que aumentamos a quantidade de dados coletados, a sequência de estimativas deve convergir para o verdadeiro valor de $\psi(\theta)$. Para ver por que essa é uma propriedade necessária de qualquer procedimento de estimação, considere o contexto de amostragem de população finita discutido na Seção 5.4.1. Quando o tamanho da amostra é igual ao tamanho da população, é claro que temos a informação completa e podemos calcular exatamente qualquer característica da distribuição de qualquer medição definida na população. Assim, seria um erro usar, para uma característica de interesse, um procedimento de estimação que não convergisse para o verdadeiro valor da característica à medida que aumentamos o tamanho da amostra.

Felizmente, já desenvolvemos no Capítulo 4 a matemática necessária para definir com precisão o que entendemos por consistência.

Definição 6.3.3

Diz-se que uma sequência de estimativas $T_1, T_2, \ldots$ é *consistente* (em probabilidade) para $\psi(\theta)$ se $T_n \xrightarrow{P_\theta} \psi(\theta)$ quando $n \to \infty$, para todo $\theta \in \mathbf{\Omega}$. Diz-se que uma sequência de estimativas $T_1, T_2, \ldots$ é *consistente* (quase certamente) para $\psi(\theta)$ se $T_n \xrightarrow{\text{q.c.}} \psi(\theta)$ quando $n \to \infty$, para todo $\theta \in \mathbf{\Omega}$.

Observe que o Teorema 4.3.1 diz que, se a sequência é consistente quase certamente[28], então ela também é consistente em probabilidade.

Considere agora uma amostra $(x_1, \ldots, x_n)$ de um modelo $\{f_\theta : \theta \in \mathbf{\Omega}\}$ e seja

No original: *almost surely*[28].

$T_n = n^{-1} \sum_{i=1}^{n} x_i$ a n-ésima média amostral, como estimador de $\psi(\theta) = E_\theta(X)$, que supomos existir. As leis fraca e forte dos grandes números nos dão imediatamente a consistência da sequência $T_1, T_2, \ldots$ para $\psi(\theta)$. Vemos de imediato que isso dá a consistência de alguns dos estimadores discutidos nesta seção. Na verdade, o Teorema 6.5.2 dá a consistência do EMV em circunstâncias muito gerais. Além disso, o EMV plug-in também será consistente sob restrições fracas sobre ψ. Assim, podemos pensar na estimação por máxima verossimilhança como algo que faz a coisa certa num problema, pelo menos do ponto de vista da consistência.

De modo mais geral, devemos sempre restringir nossa atenção a procedimentos estatísticos que funcionam corretamente à medida que a quantidade de dados aumenta. Aumentar a quantidade de dados significa que estamos adquirindo mais informação e, portanto, reduzindo nossa incerteza, de modo que, no limite, sabemos tudo. Um procedimento estatístico inconsistente poderia induzir a erro.

6.3.2 Intervalos de Confiança

Embora o erro padrão pareça uma quantidade razoável para medir a precisão de uma estimativa de $\psi(\theta)$, sua interpretação ainda não está totalmente clara neste ponto. Acontece que ela está intrinsecamente ligada à ideia de *intervalo de confiança*[29].

Considere a construção de um intervalo

$$C(s) = (l(s), u(s)),$$

baseado nos dados s, que acreditamos ter alta probabilidade de conter o verdadeiro valor de $\psi(\theta)$. Para isso, temos de especificar o extremo inferior $l(s)$ e o extremo superior $u(s)$ para cada valor s dos dados. Como devemos fazer isso?

Uma abordagem é especificar uma probabilidade $\gamma \in [0, 1]$ e então exigir que o intervalo aleatório C tenha a *propriedade de confiança*, especificada na definição a seguir.

No original: *confidence interval*[29].

Definição 6.3.4

Um intervalo $C(s) = (l(s), u(s))$ é um *intervalo de confiança* γ para $\psi(\theta)$ se $P_\theta(\psi(\theta) \in C(s)) = P_\theta(l(s) \leq \psi(\theta) \leq u(s)) \geq \gamma$ para todo $\theta \in \mathbf{\Omega}$. Dizemos que γ é o *nível de confiança* do intervalo.

Assim, C é um intervalo de confiança γ para $\psi(\theta)$ se, sempre que amostramos de P_θ, a probabilidade de que $\psi(\theta)$ esteja no intervalo é pelo menos igual a γ. Para um conjunto de dados dado, um intervalo assim ou cobre $\psi(\theta)$ ou não cobre. Note, portanto, que não é correto dizer que uma realização particular de uma região de confiança[30] γ tem probabilidade γ de conter o verdadeiro valor de $\psi(\theta)$.

Se escolhermos γ como um valor próximo de 1, teremos alta confiança de que o verdadeiro valor de $\psi(\theta)$ está em $C(s)$. É claro que sempre podemos tomar $C(s) = R^1$ (um intervalo bem grande!), e então temos 100% de confiança de que o intervalo contém o verdadeiro valor. Mas isso não nos diz nada que já não soubéssemos. Assim, a ideia é tentar usar a informação dos dados para construir um intervalo tal que tenhamos alta confiança, digamos $\gamma = 0{,}95$ ou $\gamma = 0{,}99$, de que ele contém o verdadeiro valor e que não seja mais longo que o necessário. Interpretamos então o comprimento do intervalo como medida de quão precisamente os dados nos permitem conhecer o verdadeiro valor de $\psi(\theta)$.

Intervalos de Confiança z

Considere o exemplo a seguir, que apresenta uma abordagem para a construção de intervalos de confiança.

Exemplo 6.3.6 — Modelo Normal de Locação e Intervalos de Confiança z

Suponha que temos uma amostra $(x_1, \ldots, x_n)$ do modelo $N(\mu, \sigma_0^2)$, em que $\mu \in R^1$ é desconhecido e $\sigma_0^2 > 0$ é conhecido. A função de verossimilhança é a especificada no Exemplo 6.3.1. Suponha que queremos um intervalo de confiança para μ.

O raciocínio que fundamenta a função de verossimilhança leva naturalmente à seguinte restrição para uma região como essa: se $\mu_1 \in C(x_1, \ldots, x_n)$ e

$$L(\mu_2 \mid x_1, \ldots, x_n) \geq L(\mu_1 \mid x_1, \ldots, x_n),$$

No original: *confidence region*[30].

então devemos ter também $\mu_2 \in C(x_1, \ldots, x_n)$. Essa restrição decorre da verossimilhança, porque o modelo e os dados apoiam μ_2 pelo menos tanto quanto μ_1. Assim, se concluímos que μ_1 é um valor plausível, μ_2 também é.

Portanto, $C(x_1, \ldots, x_n)$ é da forma

$$C(x_1, \ldots, x_n) = \{\mu : L(\mu \mid x_1, \ldots, x_n) \geq k(x_1, \ldots, x_n)\}$$

para algum $k(x_1, \ldots, x_n)$, isto é, $C(x_1, \ldots, x_n)$ é um intervalo de verossimilhança para μ. Então

$$\begin{aligned} C(x_1, \ldots, x_n) &= \left\{\mu : \exp\left(-\frac{n}{2\sigma_0^2}(\bar{x} - \mu)^2\right) \geq k(x_1, \ldots, x_n)\right\} \\ &= \left\{\mu : -\frac{n}{2\sigma_0^2}(\bar{x} - \mu)^2 \geq \ln k(x_1, \ldots, x_n)\right\} \\ &= \left\{\mu : (\bar{x} - \mu)^2 \leq -\frac{2\sigma_0^2}{n} \ln k(x_1, \ldots, x_n)\right\} \\ &= \left[\bar{x} - k^*(x_1, \ldots, x_n)\frac{\sigma_0}{\sqrt{n}}, \bar{x} + k^*(x_1, \ldots, x_n)\frac{\sigma_0}{\sqrt{n}}\right], \end{aligned}$$

em que $k^*(x_1, \ldots, x_n) = \sqrt{-2 \ln k(x_1, \ldots, x_n)}$.

Resta-nos escolher k, ou, equivalentemente, k^*, de modo que o intervalo C seja um intervalo de confiança γ para μ. Talvez a escolha mais simples seja tentar escolher k^* de modo que $k^*(x_1, \ldots, x_n)$ seja constante e que o intervalo seja o mais curto possível. Como

$$Z = \frac{\bar{X} - \mu}{\sigma_0/\sqrt{n}} \sim N(0, 1), \tag{6.3.2}$$

temos*

$$\begin{aligned} \gamma \leq P_\mu(\mu \in C(x_1, \ldots, x_n)) &= P_\mu\left(\bar{X} - k^*\frac{\sigma_0}{\sqrt{n}} \leq \mu \leq \bar{X} + k^*\frac{\sigma_0}{\sqrt{n}}\right) \\ &= P_\mu\left(-k^* \leq \frac{\bar{X} - \mu}{\sigma_0/\sqrt{n}} \leq c\right) = P_\mu\left(\left|\frac{\bar{X} - \mu}{\sigma_0/\sqrt{n}}\right| \leq k^*\right) \\ &= 1 - 2(1 - \Phi(k^*)) \end{aligned} \tag{6.3.3}$$

para todo $\mu \in R^1$, em que Φ é a função de distribuição acumulada da $N(0, 1)$. Temos igualdade em (6.3.3) sempre que

$$\Phi(k^*) = \frac{1 + \gamma}{2},$$

e assim $k^* = z_{(1+\gamma)/2}$, em que z_α denota o α-ésimo quantil da distribuição $N(0, 1)$. Essa é a menor constante k^* que satisfaz (6.3.3).

Mostramos que o intervalo de verossimilhança dado por

$$\left[\bar{x} - z_{(1+\gamma)/2}\frac{\sigma_0}{\sqrt{n}}, \bar{x} + z_{(1+\gamma)/2}\frac{\sigma_0}{\sqrt{n}}\right] \tag{6.3.4}$$

é um intervalo de confiança γ exato para μ. Como esses intervalos se baseiam na *estatística z*, dada por (6.3.2), eles são chamados de *intervalos de confiança z*. Por exemplo, se tomarmos $\gamma = 0{,}95$, então $(1+\gamma)/2 = 0{,}975$ e, de um pacote estatístico (ou da Tabela D.2 do Apêndice D), obtemos $z_{0{,}975} = 1{,}96$. Portanto, em amostragem repetida, 95% dos intervalos da forma

$$\left[\bar{x} - 1{,}96\,\frac{\sigma_0}{\sqrt{n}}, \bar{x} + 1{,}96\,\frac{\sigma_0}{\sqrt{n}}\right]$$

vão conter o verdadeiro valor de μ.

Isso está ilustrado na Figura 6.3.3. Nela, traçamos os extremos superior e inferior dos intervalos de confiança 0,95 para μ em cada uma de $N = 25$ amostras de tamanho $n = 10$ geradas de uma distribuição $N(0,1)$. A teoria diz que, quando N é grande, aproximadamente 95% desses intervalos vão conter o verdadeiro valor $\mu = 0$. No gráfico, cobertura significa que o extremo inferior (indicado por $\bullet$) tem de estar abaixo da reta horizontal em 0 e que o extremo superior (indicado por $\circ$) tem de estar acima dessa reta horizontal. Vemos que só o quarto e o vigésimo terceiro intervalos de confiança não contêm 0; assim, $23/25 = 92\%$ dos intervalos contêm 0. Quando $N \to \infty$, essa proporção vai convergir para 0,95.

Observe que o intervalo (6.3.4) é simétrico em torno de $\bar{x}$. Por isso, o semicomprimento desse intervalo,

$$z_{(1+\gamma)/2}\frac{\sigma_0}{\sqrt{n}},$$

é uma medida da precisão da estimativa $\bar{x}$. O semicomprimento costuma ser chamado de *margem de erro*.

A partir da margem de erro, vemos agora como interpretar o erro padrão: o erro padrão controla os comprimentos dos intervalos de confiança para o μ desconhecido. Por exemplo, sabemos que, com probabilidade aproximadamente igual a 1 (na verdade, $\gamma = 0{,}9974$), o intervalo $[\bar{x} \pm 3\sigma_0/\sqrt{n}]$ contém o verdadeiro valor de μ. ■

O Exemplo 6.3.6 serve de exemplo-padrão de como os intervalos de confiança

*Nota do tradutor. O original traz c como limite superior no segundo membro da segunda linha; pela conta seria k^*.

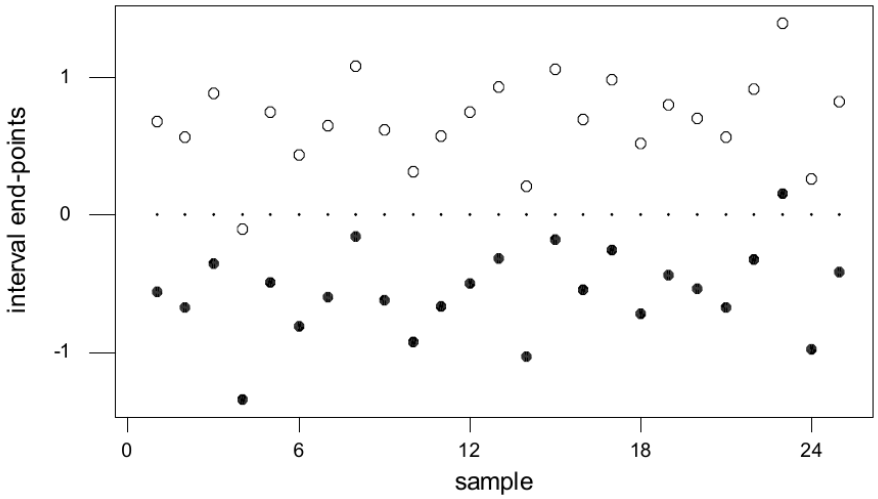


Figura 6.3.3: Gráfico de intervalos de confiança 0,95 para $\mu = 0$ (extremo inferior = •, extremo superior = ∘) para $N = 25$ amostras de tamanho $n = 10$ de uma distribuição $N(0, 1)$.

costumam ser construídos em estatística. Basicamente, a ideia é tomar uma estimativa e então olhar os intervalos formados tomando intervalos simétricos em torno da estimativa, por meio de múltiplos do seu erro padrão. Ilustramos isso com mais alguns exemplos.

Exemplo 6.3.7 — Modelo de Bernoulli

Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição Bernoulli(θ), em que $\theta \in [0, 1]$ é desconhecido, e que queremos um intervalo de confiança γ para θ. Seguindo o Exemplo 6.3.2, temos que o EMV é $\bar{x}$ (ver Exercício 6.2.2) e que o erro padrão dessa estimativa é

$$\sqrt{\frac{\bar{x}(1-\bar{x})}{n}}.$$

Para esse modelo, os intervalos de verossimilhança têm a forma

$$C(x_1, \ldots, x_n) = \{\theta : \theta^{n\bar{x}}(1-\theta)^{n(1-\bar{x})} \geq k(x_1, \ldots, x_n)\}$$

para algum $k(x_1, \ldots, x_n)$. Restringindo-nos de novo a k constante, vemos que, para determinar esses intervalos, temos de encontrar as raízes de equações da forma

$$\theta^{n\bar{x}}(1-\theta)^{n(1-\bar{x})} = k(x_1, \ldots, x_n).$$

Embora métodos numéricos de busca de raízes deem conta disso com bastante facilidade, essa abordagem não é muito tratável quando

queremos encontrar o valor adequado de $k(x_1, \ldots, x_n)$ que dê um intervalo de confiança γ.

Para evitar essas complicações computacionais, é comum usar uma verossimilhança e um intervalo de confiança aproximados, baseados no teorema central do limite. O teorema central do limite (ver Exemplo 4.4.9) implica que

$$\frac{\sqrt{n}\,(\bar{X} - \theta)}{\sqrt{\theta(1-\theta)}} \xrightarrow{D} N(0,1)$$

quando $n \to \infty$. Além disso, uma generalização do teorema central do limite (ver Seção 4.4.2) mostra que

$$Z = \frac{\sqrt{n}\,(\bar{X} - \theta)}{\sqrt{\bar{X}(1-\bar{X})}} \xrightarrow{D} N(0,1).$$

Portanto, temos

$$\begin{aligned}\gamma &= \lim_{n\to\infty} P_\theta\left(-z_{(1+\gamma)/2} \le \frac{\sqrt{n}\,(\bar{X} - \theta)}{\sqrt{\bar{X}(1-\bar{X})}} \le z_{(1+\gamma)/2}\right) \\ &= \lim_{n\to\infty} P_\theta\left(\bar{X} - z_{(1+\gamma)/2}\sqrt{\frac{\bar{X}(1-\bar{X})}{n}} \le \theta \le \bar{X} + z_{(1+\gamma)/2}\sqrt{\frac{\bar{X}(1-\bar{X})}{n}}\right),\end{aligned}$$

e

$$\left[\bar{x} - z_{(1+\gamma)/2}\sqrt{\frac{\bar{x}(1-\bar{x})}{n}},\ \bar{x} + z_{(1+\gamma)/2}\sqrt{\frac{\bar{x}(1-\bar{x})}{n}}\right] \tag{6.3.5}$$

é um intervalo de confiança γ aproximado para θ. Observe que ele tem a mesma forma do intervalo do Exemplo 6.3.6, exceto que o erro padrão mudou.

Por exemplo, se queremos um intervalo de confiança 0,95 aproximado para θ no Exemplo 6.3.3, então, com base no valor observado $\bar{x} = 0{,}79$, obtemos

$$\left[0{,}79 \pm 1{,}96\sqrt{\frac{0{,}79\,(1-0{,}79)}{1000}}\right] = [0{,}76475;\, 0{,}81525].$$

A margem de erro, neste caso, é igual a 0,025245; assim, podemos concluir que conhecemos a verdadeira proporção com precisão razoável com base na nossa amostra. Na verdade, pode ser que essa precisão não seja suficiente, ou mesmo que seja boa demais. Discutiremos métodos para garantir que se atinja a precisão adequada na Seção 6.3.5.

O intervalo de confiança γ obtido aqui para θ é um dos muitos que você verá recomendados na literatura. Lembre que (6.3.5) é só um intervalo

de confiança γ aproximado para θ, e n pode precisar ser grande para que a aproximação seja precisa. Em outras palavras, o verdadeiro nível de confiança de (6.3.5) não será igual a γ e pode ficar longe desse valor se n for pequeno demais. Em particular, se o verdadeiro θ estiver perto de 0 ou de 1, n pode precisar ser muito grande. Numa aplicação real, costumamos ter alguma ideia de uma pequena faixa de valores possíveis que a proporção populacional θ pode assumir. Por isso, é aconselhável fazer alguns estudos de simulação para avaliar se (6.3.5) vai ou não fornecer uma aproximação aceitável para θ nessa faixa (ver Exercício Computacional 6.3.21). ■

Intervalos de Confiança t

Consideramos agora intervalos de confiança para μ num modelo $N(\mu, \sigma^2)$, quando abandonamos a suposição irrealista de que conhecemos a variância populacional.

Exemplo 6.3.8 — Modelo Normal de Locação e Escala e Intervalos de Confiança t

Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição $N(\mu, \sigma^2)$, em que $\mu \in R^1$ e $\sigma > 0$ são desconhecidos. O parâmetro desse modelo é dado por $\theta = (\mu, \sigma^2) \in \mathbf{\Omega} = R^1 \times (0, \infty)$. Suponha que queremos formar intervalos de confiança para $\mu = \psi(\mu, \sigma^2)$.

A função de verossimilhança, neste caso, é uma função de duas variáveis, μ e σ^2, e por isso o raciocínio que usamos no Exemplo 6.3.6 para determinar a forma do intervalo de confiança não se aplica diretamente. No Exemplo 6.3.4, obtivemos $s/\sqrt{n}$ como o erro padrão da estimativa $\bar{x}$ de μ. Assim, restringimos nossa atenção a intervalos de confiança da forma

$$C(x_1, \ldots, x_n) = \left[\bar{x} - k\frac{s}{\sqrt{n}}, \bar{x} + k\frac{s}{\sqrt{n}}\right]$$

para alguma constante k.

Temos então

$$P_{(\mu,\sigma^2)}\left(\bar{X} - k\frac{S}{\sqrt{n}} \leq \mu \leq \bar{X} + k\frac{S}{\sqrt{n}}\right) = P_{(\mu,\sigma^2)}\left(-k \leq \frac{\bar{X} - \mu}{S/\sqrt{n}} \leq k\right)$$
$$= P_{(\mu,\sigma^2)}\left(\left|\frac{\bar{X} - \mu}{S/\sqrt{n}}\right| \leq k\right) = 1 - 2(1 - G(k\,;\, n-1)),$$

em que $G(\cdot\,; n-1)$ é a função de distribuição de

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}}. \tag{6.3.6}$$

Ora, pelo Teorema 4.6.6,

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0,1),$$

independente de $(n-1)S^2/\sigma^2 \sim \chi^2(n-1)$. Portanto, pela Definição 4.6.2,

$$T = \left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}}\right) \Bigg/ \sqrt{\frac{(n-1)S^2}{\sigma^2}} = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1).$$

Assim, se tomarmos

$$k = t_{(1+\gamma)/2}(n-1),$$

em que $t_\alpha(\lambda)$ é o α-ésimo quantil da distribuição $t(\lambda)$, então

$$\left[\bar{x} - t_{(1+\gamma)/2}(n-1)\frac{s}{\sqrt{n}}, \bar{x} + t_{(1+\gamma)/2}(n-1)\frac{s}{\sqrt{n}}\right]$$

é um intervalo de confiança γ exato para μ. Os quantis das distribuições t podem ser obtidos num pacote estatístico (ou na Tabela D.4 do Apêndice D). Como esses intervalos se baseiam na *estatística t*, dada por (6.3.6), eles são chamados de *intervalos de confiança t*.

Esses intervalos de confiança para μ tendem a ser mais longos que os obtidos no Exemplo 6.3.6, e isso reflete a incerteza maior por σ ser desconhecido. Quando $n = 5$, pode-se mostrar que $\bar{x} \pm 3s/\sqrt{n}$ é um intervalo de confiança 0,97. Quando substituímos s pelo verdadeiro valor de σ, $\bar{x} \pm 3\sigma/\sqrt{n}$ é um intervalo de confiança 0,9974.

Como já observado, os intervalos $\bar{x} \pm ks/\sqrt{n}$ não são intervalos de verossimilhança para μ. Assim, a justificativa para usá-los tem de ser um pouco diferente da dada no Exemplo 6.3.6. Na verdade, a verossimilhança é definida para o parâmetro completo $\theta = (\mu, \sigma^2)$, e não está totalmente claro como extrair inferências dela quando nosso interesse está num parâmetro marginal como μ. Há várias tentativas diferentes de resolver essa questão. Aqui, porém, nos apoiamos no caráter intuitivamente razoável desses intervalos. No Capítulo 7, veremos que esses intervalos também surgem de outra abordagem da inferência, o que reforça nossa convicção de que o uso desses intervalos é apropriado.

No Exemplo 6.3.5, temos uma amostra de $n = 30$ alturas (em polegadas) de estudantes. Calculamos $\bar{x} = 64{,}517$ como nossa estimativa de μ, com

erro padrão $s/\sqrt{30} = 0{,}43434$. Usando software (ou a Tabela D.4), obtemos $t_{0{,}975}(29) = 2{,}0452$. Assim, um intervalo de confiança 0,95 para μ é dado por

$$[64{,}517 \pm 2{,}0452\,(0{,}43434)] = [63{,}629; 65{,}405].$$

A margem de erro é 0,888; assim, temos bastante confiança de que a estimativa $\bar{x} = 64{,}517$ está a menos de uma polegada da verdadeira altura média. ■

6.3.3 Testes de Hipóteses e Valores-p

Como discutido na Seção 5.5.3, outra classe de procedimentos de inferência trata do que chamamos de *avaliação de hipóteses*[31]. Suponha que exista uma teoria, conjectura ou hipótese que especifica um valor para uma característica de interesse $\psi(\theta)$, digamos $\psi(\theta) = \psi_0$. Muitas vezes essa hipótese é escrita como $H_0 : \psi(\theta) = \psi_0$ e é chamada de *hipótese nula*[32].

A palavra *nula* é usada porque, como veremos no Capítulo 10, o valor especificado em H_0 costuma estar associado a um tratamento[33] que não tem efeito. Por exemplo, se queremos avaliar se um novo medicamento proposto trata uma determinada condição melhor ou não do que um tratamento padrão, a hipótese nula muitas vezes equivalerá a dizer que o novo medicamento não traz melhora nenhuma. Claro, precisamos mostrar como isso pode ser expresso em termos de alguma característica $\psi(\theta)$ de uma distribuição desconhecida, e faremos isso no Capítulo 10.

O estatístico fica então encarregado de avaliar se o s observado está ou não de acordo com essa hipótese. Assim, queremos avaliar a evidência que há em s de que $\psi(\theta) = \psi_0$ seja verdadeira. Um procedimento estatístico que faz isso pode ser chamado de avaliação de hipóteses, *teste de significância* ou *teste de hipóteses*[34]. Um procedimento desses envolve medir quão surpreendente é o s observado quando supomos que H_0 é verdadeira. Está claro que s é surpreendente sempre que s está numa região de baixa probabilidade para cada uma das distribuições especificadas pela hipótese nula, isto é, para cada uma das distribuições do modelo para as quais $\psi(\theta) = \psi_0$ é verdadeira. Se decidimos que os dados são surpreendentes sob H_0, então isso é evidência contra H_0. Essa avaliação é feita calculando uma probabilidade, chamada de *valor-p*, de modo que valores pequenos do valor-p indicam que s é surpreendente.

No original: *hypothesis assessment*[31], *null hypothesis*[32], *treatment*[33], *hypothesis testing*[34].

É importante lembrar sempre que, embora um valor-p seja uma probabilidade, essa probabilidade é uma medida de surpresa. Valores pequenos do valor-p nos indicam que ocorreu um evento surpreendente *se* a hipótese nula H_0 era verdadeira. Um valor-p grande não é evidência de que a hipótese nula seja verdadeira. Além disso, um valor-p não é a probabilidade de a hipótese nula ser verdadeira. O poder de um método de avaliação de hipóteses (ver Seção 6.3.6) também influi no modo como interpretamos um valor-p.

Testes z

Agora ilustramos o cálculo e o uso de valores-p por meio de vários exemplos.

Exemplo 6.3.9 — Modelo Normal de Locação e o Teste z

Suponha que temos uma amostra $(x_1, \ldots, x_n)$ do modelo $N(\mu, \sigma_0^2)$, em que $\mu \in R^1$ é desconhecido e $\sigma_0^2 > 0$ é conhecido, e que temos uma teoria que especifica um valor para a média desconhecida, digamos, $H_0 : \mu = \mu_0$. Note que, pelo Corolário 4.6.1, quando H_0 é verdadeira, a distribuição amostral do EMV é dada por $\bar{X} \sim N(\mu_0, \sigma_0^2/n)$.

Assim, um método para avaliar se a hipótese H_0 faz sentido ou não é comparar o valor observado $\bar{x}$ com essa distribuição. Se $\bar{x}$ está numa região de baixa probabilidade para a distribuição $N(\mu_0, \sigma_0^2/n)$, então isso é evidência de que H_0 é falsa. Como a densidade da distribuição $N(\mu_0, \sigma_0^2/n)$ é unimodal, as regiões de baixa probabilidade dessa distribuição ficam nas suas caudas. Quanto mais longe nas caudas estiver $\bar{x}$, mais surpreendente isso será quando H_0 for verdadeira e, portanto, mais evidência teremos contra H_0.

Na Figura 6.3.4, traçamos uma densidade do EMV junto com um valor observado $\bar{x}$ que fica bem longe na cauda direita da distribuição. Esse seria claramente um valor surpreendente para essa distribuição.

Assim, queremos medir quão longe nas caudas da distribuição $N(\mu_0, \sigma_0^2/n)$ está o valor $\bar{x}$. Podemos fazer isso calculando a probabilidade de observar um valor de $\bar{x}$ tão longe quanto $\bar{x}$, ou mais longe ainda, do centro da distribuição sob H_0. O centro dessa distribuição é dado por μ_0. Como

$$Z = \frac{\bar{X} - \mu_0}{\sigma_0/\sqrt{n}} \sim N(0, 1) \tag{6.3.7}$$

sob H_0, o valor-p é então dado por

$$P_{\mu_0}\left(|\bar{X}-\mu_0| \geq |\bar{x}-\mu_0|\right) = P_{\mu_0}\left(\left|\frac{\bar{X}-\mu_0}{\sigma_0/\sqrt{n}}\right| \geq \left|\frac{\bar{x}-\mu_0}{\sigma_0/\sqrt{n}}\right|\right)$$
$$= 2\left[1-\Phi\left(\left|\frac{\bar{x}-\mu_0}{\sigma_0/\sqrt{n}}\right|\right)\right],$$

em que Φ denota a função de distribuição da $N(0,1)$. Se o valor-p é pequeno, então temos evidência de que $\bar{x}$ é um valor surpreendente, porque isso nos diz que $\bar{x}$ está numa cauda da distribuição $N(\mu_0, \sigma_0^2/n)$. Como esse valor-p se baseia na estatística Z definida em (6.3.7), esse procedimento é chamado de *teste z*. ■

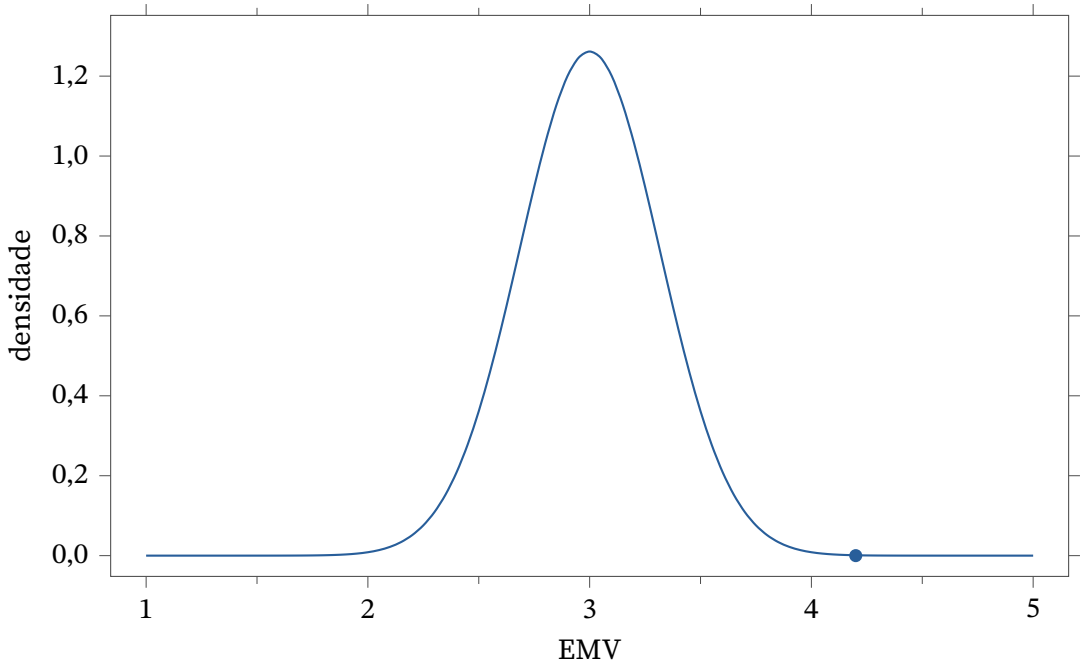


Figura 6.3.4: Gráfico da densidade do EMV no Exemplo 6.3.9 quando $\mu_0 = 3$, $\sigma_0^2 = 1$ e $n = 10$, junto com o valor observado $\bar{x} = 4{,}2$ (•).

Exemplo 6.3.10 — Aplicação do Teste z

Geramos a seguinte amostra de $n = 10$ de uma distribuição $N(26, 4)$.

29,0651	27,3980	23,4346	26,3665	23,4994
28,6592	25,5546	29,4477	28,0979	25,2850

Embora conheçamos o verdadeiro valor de μ, vamos supor que não o conhecemos e testar a hipótese $H_0 : \mu = 25$. Para avaliá-la, calculamos (usando um pacote estatístico para avaliar Φ) o valor-p

$$2\left[1 - \Phi\left(\frac{|\bar{x} - \mu_0|}{\sigma_0/\sqrt{n}}\right)\right] = 2\left[1 - \Phi\left(\frac{|26{,}6808 - 25|}{2/\sqrt{10}}\right)\right]$$
$$= 2\,(1 - \Phi(2{,}6576)) = 0{,}0078,$$

que é bem pequeno. Por exemplo, se a hipótese H_0 está correta, então, em amostragens repetidas, veríamos dados que dão um valor de $\bar{x}$ pelo menos tão surpreendente quanto o que observamos apenas 0,78% das vezes. Assim, concluímos que temos evidência contra H_0 ser verdadeira, o que, claro, é adequado neste caso.

Se você não usar um pacote estatístico para avaliar $\Phi(2{,}6576)$, então terá de usar a Tabela D.2 do Apêndice D para obter uma aproximação. Por exemplo, arredondando 2,6576 para 2,66, a Tabela D.2 dá $\Phi(2{,}66) = 0{,}9961$, e o valor-p aproximado é $2\,(1 - 0{,}9961) = 0{,}0078$. Neste caso, a aproximação é exata até a quarta casa decimal. ■

Exemplo 6.3.11 — Modelo de Bernoulli

Suponha que $(x_1, \ldots, x_n)$ seja uma amostra de uma distribuição Bernoulli(θ), em que $\theta \in [0,1]$ é desconhecido, e que queremos testar $H_0 : \theta = \theta_0$. Como no Exemplo 6.3.7, quando H_0 é verdadeira, temos

$$Z = \frac{\sqrt{n}\left(\bar{X} - \theta_0\right)}{\sqrt{\theta_0\left(1-\theta_0\right)}} \xrightarrow{D} N(0,1)$$

quando $n \to \infty$. Assim, podemos testar essa hipótese calculando o valor-p aproximado

$$P\left(|Z| \geq \left|\frac{\sqrt{n}\left(\bar{x} - \theta_0\right)}{\sqrt{\theta_0\left(1-\theta_0\right)}}\right|\right) \approx 2\left[1 - \Phi\left(\left|\frac{\sqrt{n}\left(\bar{x} - \theta_0\right)}{\sqrt{\theta_0\left(1-\theta_0\right)}}\right|\right)\right]$$

quando n é grande.

Como exemplo específico, suponha que um vidente afirme ter a capacidade de prever o resultado do lançamento aleatório de uma moeda honesta. Para testar isso, uma moeda foi lançada 100 vezes, e os palpites do vidente foram registrados como sucessos ou fracassos. Foi observado um total de 54 sucessos.

Se o vidente não tem capacidade de previsão, então esperaríamos que os sucessos ocorressem ao acaso, assim como as caras ocorrem quando lançamos a moeda. Portanto, queremos testar a hipótese nula de que a probabilidade θ de ocorrer um sucesso é igual a $\theta_0 = 1/2$. Isso equivale a dizer que o vidente não tem capacidade de previsão. O EMV é 0,54, e o valor-p aproximado é dado por

$$2\left[1 - \Phi\left(\left|\frac{\sqrt{100}\left(0{,}54 - 0{,}5\right)}{\sqrt{0{,}5\left(1-0{,}5\right)}}\right|\right)\right] = 2\left(1 - \Phi(0{,}8)\right) = 2\left(1 - 0{,}7881\right) = 0{,}4238,$$

e parece que não temos evidência de que H_0 seja falsa, isto é, nenhum motivo para duvidar de que o vidente não tem capacidade de previsão. ■

Muitas vezes, valores de corte como 0,05 ou 0,01 são usados para determinar se os resultados de um teste são significativos ou não. Por exemplo, se o valor-p é menor que 0,05, então se diz que os resultados são *estatisticamente significativos* ao nível de 5%. Não há nada de sagrado no nível de 0,05, porém, e valores diferentes podem ser usados conforme a aplicação. Por exemplo, se a consequência de concluir que temos evidência contra H_0 é que algo muito caro ou importante vai acontecer, então naturalmente podemos exigir que o valor de corte seja bem menor que 0,05.

Quando a Significância Estatística É Significativa na Prática?

Também é importante apontar aqui a diferença entre significância estatística e *significância prática*. Considere a situação do Exemplo 6.3.9 em que o verdadeiro valor de μ é $\mu_1 \neq \mu_0$, mas μ_1 está tão perto de μ_0 que, na prática, os dois são indistinguíveis. Pela lei forte dos grandes números[35], temos que $\bar{X} \xrightarrow{\text{q.c.}} \mu_1$ quando $n \to \infty$ e, portanto,

$$\left|\frac{\bar{X} - \mu_0}{\sigma_0/\sqrt{n}}\right| \xrightarrow{\text{q.c.}} \infty.$$

Isso implica que

$$2\left[1 - \Phi\left(\left|\frac{\bar{X} - \mu_0}{\sigma_0/\sqrt{n}}\right|\right)\right] \xrightarrow{\text{q.c.}} 0.$$

Concluímos que, se tomarmos um tamanho da amostra n grande o bastante, vamos inevitavelmente concluir que $\mu \neq \mu_0$, porque o valor-p do teste z tende a 0. Claro, isso está correto, porque a hipótese é falsa.

Apesar disso, não queremos concluir que, só porque temos significância estatística, a diferença entre o verdadeiro valor e μ_0 tem alguma importância prática. Se examinarmos a diferença absoluta observada $|\bar{x} - \mu_0|$ como estimativa de $|\mu - \mu_0|$, porém, não cometeremos esse erro. Se essa diferença absoluta for menor que algum limiar δ que consideramos representar uma diferença significativa na prática, então, mesmo que o valor-p nos leve a concluir que essa diferença existe, podemos concluir que não existe diferença de importância alguma. Claro, o valor de δ depende da aplicação. Por exemplo, no lançamento de moedas, em que estamos testando $\theta = 1/2$, talvez não nos importemos se a moeda for ligeiramente desonesta, digamos, $|\theta - \theta_0| \leq 0{,}01$. Ao testar as capacidades de um vidente, como no Exemplo 6.3.11, porém, poderíamos tomar δ bem menor, já que qualquer evidência de poderes paranormais seria uma descoberta espantosa. A questão da significância prática é algo de que devemos estar sempre cientes ao realizar um teste de significância.

Avaliação de Hipóteses por Meio de Intervalos de Confiança

Outra abordagem para testar hipóteses é por meio de intervalos de confiança. Por exemplo, se temos um intervalo de confiança γ $C(s)$ para $\psi(\theta)$ e $\psi_0 \notin C(s)$, então isso parece uma evidência clara contra $H_0 : \psi(\theta) = \psi_0$, pelo menos quando γ está perto de 1. Acontece que, em muitos problemas, a abordagem de testar por meio de intervalos de confiança é equivalente a usar valores-p

No original: *strong law of large numbers*[35].

com um valor de corte específico para o valor-p para determinar a significância estatística. Ilustramos essa equivalência usando o teste z e os intervalos de confiança z.

Exemplo 6.3.12 — Uma Equivalência entre Testes z e Intervalos de Confiança z

Desenvolvemos essa equivalência mostrando que obter um valor-p menor que $1-\gamma$ para $H_0 : \mu = \mu_0$ é equivalente a μ_0 não estar num intervalo de confiança γ para μ. Observe que

$$1-\gamma \leq 2\left[1-\Phi\left(\left|\frac{\bar{x}-\mu_0}{\sigma_0/\sqrt{n}}\right|\right)\right]$$

se e somente se

$$\Phi\left(\left|\frac{\bar{x}-\mu_0}{\sigma_0/\sqrt{n}}\right|\right) \leq \frac{1+\gamma}{2}.$$

Isso é verdade se e somente se

$$\frac{|\bar{x}-\mu_0|}{\sigma_0/\sqrt{n}} \leq z_{(1+\gamma)/2},$$

o que vale se e somente se

$$\mu_0 \in \left[\bar{x}-z_{(1+\gamma)/2}\frac{\sigma_0}{\sqrt{n}}, \bar{x}+z_{(1+\gamma)/2}\frac{\sigma_0}{\sqrt{n}}\right].$$

Isso implica que o intervalo de confiança γ para μ é formado pelos valores μ_0 para os quais o valor-p da hipótese $H_0 : \mu = \mu_0$ é maior que $1-\gamma$.

Portanto, o valor-p baseado na estatística z para a hipótese nula $H_0 : \mu = \mu_0$ será menor que $1-\gamma$ se e somente se μ_0 não estiver no intervalo de confiança γ para μ obtido no Exemplo 6.3.6. Por exemplo, se decidirmos declarar os resultados estatisticamente significativos para quaisquer valores-p menores que $1-\gamma = 0{,}05$, então sabemos que os resultados serão significativos sempre que o intervalo de confiança 0,95 para μ não contiver μ_0. Para os dados do Exemplo 6.3.10, um intervalo de confiança 0,95 é dado por $[25{,}441; 27{,}920]$. Como esse intervalo não contém $\mu_0 = 25$, temos evidência contra a hipótese nula ao nível de 0,05.

Podemos aplicar o mesmo raciocínio a testes sobre θ quando amostramos de um modelo Bernoulli(θ). Para os dados do Exemplo 6.3.11, obtemos o intervalo de confiança 0,95

$$\bar{x} \pm z_{0{,}975}\sqrt{\frac{\bar{x}(1-\bar{x})}{n}} = 0{,}54 \pm 1{,}96\sqrt{\frac{0{,}54(1-0{,}54)}{100}} = [0{,}44231; 0{,}63769],$$

que inclui o valor $\theta_0 = 0{,}5$. Assim, não temos evidência contra a hipótese nula de que o vidente não tem capacidade de previsão ao nível de 0,05. ■

Testes t

Agora consideramos um exemplo relativo ao importante modelo normal de locação e escala.

Exemplo 6.3.13 — Modelo Normal de Locação e Escala e Testes t

Suponha que $(x_1, \ldots, x_n)$ seja uma amostra de uma distribuição $N(\mu, \sigma^2)$, em que $\mu \in R^1$ e $\sigma > 0$ são desconhecidos, e suponha que queremos testar a hipótese nula $H_0 : \mu = \mu_0$. No Exemplo 6.3.8, obtivemos um intervalo de confiança γ para μ. Ele se baseava na estatística t dada por (6.3.6). Assim, baseamos nosso teste também nessa estatística. Na verdade, pode-se mostrar que o teste que deduzimos aqui é equivalente a usar os intervalos de confiança para avaliar a hipótese, como descrito no Exemplo 6.3.12.

Como no Exemplo 6.3.8, podemos provar que, quando a hipótese nula é verdadeira,

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \tag{6.3.8}$$

tem distribuição $t(n-1)$. As distribuições t são unimodais, com moda em 0, e as regiões de baixa probabilidade são dadas pelas caudas. Assim, testamos, ou avaliamos, essa hipótese calculando a probabilidade de observar um valor tão longe de 0 quanto (6.3.8), ou mais longe ainda. Portanto, o valor-p é dado por

$$P_{(\mu_0,\sigma^2)}\left(|T| \geq \left|\frac{\bar{x} - \mu_0}{s/\sqrt{n}}\right|\right) = 2\left[1 - G\left(\left|\frac{\bar{x} - \mu_0}{s/\sqrt{n}}\right|; n-1\right)\right],$$

em que $G(\cdot\,; n-1)$ é a função de distribuição da distribuição $t(n-1)$. Temos então evidência contra H_0 sempre que essa probabilidade é pequena. Esse procedimento é chamado de *teste t*. Mais uma vez, é uma boa ideia olhar para a diferença $|\bar{x} - \mu_0|$, quando concluímos que H_0 é falsa, para determinar se a diferença detectada tem ou não importância prática.

Considere agora os dados do Exemplo 6.3.10 e vamos fingir que não conhecemos μ nem σ^2. Então temos $\bar{x} = 26{,}6808$ e $s = \sqrt{4{,}8620} = 2{,}2050$; assim, para testar $H_0 : \mu = 25$, o valor da estatística t é

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}} = \frac{26{,}6808 - 25}{2{,}2050/\sqrt{10}} = 2{,}4105.$$

Com um pacote estatístico (ou pela Tabela D.4), obtemos $t_{0{,}975}(9) = 2{,}2622$; assim, temos um resultado estatisticamente significativo ao nível de 5% e concluímos que temos evidência contra $H_0 : \mu = 25$. Usando um pacote estatístico, podemos determinar o valor exato do valor-p, que neste caso é 0,039. ■

Testes Unilaterais

Todos os testes que discutimos até agora nesta seção para uma característica de interesse $\psi(\theta)$ foram *testes bilaterais*. Isso significa que a hipótese nula especificava que $\psi(\theta)$ é um único valor ψ_0. Às vezes, porém, queremos testar uma hipótese nula da forma $H_0 : \psi(\theta) \leq \psi_0$ ou $H_0 : \psi(\theta) \geq \psi_0$. Para realizar esses testes, usamos as mesmas estatísticas de teste que desenvolvemos nos vários exemplos aqui, mas calculamos o valor-p de um modo que reflita a natureza unilateral[36] da hipótese nula. Eles são conhecidos como *testes unilaterais*. Ilustramos um teste unilateral usando o modelo normal de locação[37].

Exemplo 6.3.14 — Testes Unilaterais

Suponha que temos uma amostra $(x_1, \ldots, x_n)$ do modelo $N(\mu, \sigma_0^2)$, em que $\mu \in R^1$ é desconhecido e $\sigma_0^2 > 0$ é conhecido. Suponha ainda que se levanta a hipótese de que $H_0 : \mu \leq \mu_0$ é verdadeira, e queremos avaliar isso depois de observar os dados.

Vamos basear nosso teste na estatística z

$$Z = \frac{\bar{X} - \mu_0}{\sigma_0/\sqrt{n}} = \frac{\bar{X} - \mu + \mu - \mu_0}{\sigma_0/\sqrt{n}} = \frac{\bar{X} - \mu}{\sigma_0/\sqrt{n}} + \frac{\mu - \mu_0}{\sigma_0/\sqrt{n}}.$$

Assim, Z é a soma de uma variável aleatória com distribuição $N(0, 1)$ e da constante $\sqrt{n}(\mu - \mu_0)/\sigma_0$, o que implica que

$$Z \sim N\left(\frac{\mu - \mu_0}{\sigma_0/\sqrt{n}}, 1\right).$$

Note que

$$\frac{\mu - \mu_0}{\sigma_0/\sqrt{n}} \leq 0$$

se e somente se H_0 é verdadeira.

Isso implica que, quando a hipótese nula é falsa, tenderemos a ver valores de Z na cauda direita da distribuição $N(0, 1)$; quando a hipótese nula é verdadeira, tenderemos a ver valores de Z razoáveis para a distribuição $N(0, 1)$ ou na cauda esquerda dessa distribuição. Assim, para testar H_0, calculamos o valor-p

$$P\left(Z \geq \frac{\bar{x} - \mu_0}{\sigma_0/\sqrt{n}}\right) = 1 - \Phi\left(\frac{\bar{x} - \mu_0}{\sigma_0/\sqrt{n}}\right),$$

No original: *one-sided*[36], *location normal model*[37].

com $Z \sim N(0,1)$, e concluímos que temos evidência contra H_0 quando ele é pequeno. Pelo mesmo raciocínio, o valor-p para a hipótese nula $H_0 : \mu \geq \mu_0$ é igual a

$$P\left(Z \leq \frac{\bar{x} - \mu_0}{\sigma_0/\sqrt{n}}\right) = \Phi\left(\frac{\bar{x} - \mu_0}{\sigma_0/\sqrt{n}}\right).$$

Para mais discussão sobre testes unilaterais e intervalos de confiança, veja os Problemas 6.3.25 a 6.3.32. ■

6.3.4 Inferências para a Variância

Nas Seções 6.3.1, 6.3.2 e 6.3.3, nos concentramos em inferências para a média desconhecida de uma distribuição, por exemplo, quando amostramos de uma distribuição $N(\mu, \sigma^2)$ ou de uma distribuição Bernoulli(θ) e nosso interesse está em μ ou em θ, respectivamente. Em geral, os parâmetros de locação tendem a ter um papel muito mais importante numa análise estatística do que outras características de uma distribuição. Há razões lógicas para isso, discutidas no Capítulo 10, quando consideramos os modelos de regressão. Às vezes nos referimos a um parâmetro como σ^2 como um *parâmetro de perturbação*[38], porque nosso interesse está em μ. Note que a variância de uma distribuição Bernoulli(θ) é $\theta(1-\theta)$, de modo que as inferências sobre θ são logicamente também inferências sobre a variância, isto é, não há parâmetros de perturbação.

Mas às vezes estamos interessados principalmente em fazer inferências sobre σ^2 na distribuição $N(\mu, \sigma^2)$ quando ela é desconhecida. Por exemplo, suponha que a experiência anterior com um sistema em estudo indique que o verdadeiro valor da variância é bem aproximado por σ_0^2, isto é, que o verdadeiro valor não difere de σ_0^2 por uma quantidade que tenha alguma significância prática. Agora, com base na nova amostra, podemos querer avaliar a hipótese $H_0 : \sigma^2 = \sigma_0^2$, isto é, queremos saber se a variabilidade básica do processo mudou ou não.

A discussão da Seção 6.3.1 levou a considerar o erro padrão $s/\sqrt{n}$ como estimativa do desvio padrão[39] $\sigma/\sqrt{n}$ de $\bar{x}$. Em muitos aspectos, s^2 parece um estimador muito natural de σ^2, mesmo quando não estamos amostrando de uma distribuição normal.

O exemplo a seguir desenvolve intervalos de confiança e valores-p para σ^2.

No original: *nuisance parameter*[38], *standard deviation*[39].

Exemplo 6.3.15 — Modelo Normal de Locação e Escala e Inferências para a Variância

Suponha que $(x_1, \ldots, x_n)$ seja uma amostra de uma distribuição $N(\mu, \sigma^2)$, em que $\mu \in R^1$ e $\sigma > 0$ são desconhecidos, e que queremos fazer inferências sobre a variância populacional σ^2. O EMV plug-in é dado por $(n-1)\,s^2/n$, que é a média dos quadrados dos desvios dos valores dos dados em relação a $\bar{x}$. Muitas vezes s^2 é recomendado como estimativa porque tem a propriedade de ser não viesado, e vamos usá-lo aqui. Pode-se obter uma expressão para o erro padrão dessa estimativa, mas, como ela é um tanto complicada, não vamos levar isso adiante aqui.

Podemos formar um intervalo de confiança γ para σ^2 usando $(n-1)\,S^2/\sigma^2 \sim \chi^2(n-1)$ (Teorema 4.6.6). Há várias possibilidades para esse intervalo, mas uma delas é notar que, denotando por $\chi^2_\alpha(\lambda)$ o quantil α da distribuição $\chi^2(\lambda)$,

$$\begin{aligned}\gamma &= P_{(\mu,\sigma^2)}\left(\chi^2_{(1-\gamma)/2}(n-1) \leq \frac{(n-1)\,S^2}{\sigma^2} \leq \chi^2_{(1+\gamma)/2}(n-1)\right) \\ &= P_{(\mu,\sigma^2)}\left(\frac{(n-1)\,S^2}{\chi^2_{(1+\gamma)/2}(n-1)} \leq \sigma^2 \leq \frac{(n-1)\,S^2}{\chi^2_{(1-\gamma)/2}(n-1)}\right)\end{aligned}$$

para todo $(\mu, \sigma^2) \in R^1 \times (0, \infty)$. Assim,

$$\left[\frac{(n-1)\,s^2}{\chi^2_{(1+\gamma)/2}(n-1)}, \frac{(n-1)\,s^2}{\chi^2_{(1-\gamma)/2}(n-1)}\right]$$

é um intervalo de confiança γ exato para σ^2. Para testar uma hipótese como $H_0 : \sigma = \sigma_0$ ao nível $1-\gamma$, basta ver se σ_0^2 está ou não no intervalo. O menor valor de γ tal que σ_0^2 esteja no intervalo é o valor-p desse procedimento de avaliação de hipóteses.

Para os dados do Exemplo 6.3.10, vamos fingir que não sabemos que $\sigma^2 = 4$. Aqui, $n = 10$ e $s^2 = 4{,}8620$. Com um pacote estatístico (ou pela Tabela D.3 do Apêndice D), obtemos $\chi^2_{0{,}025}(9) = 2{,}700$ e $\chi^2_{0{,}975}(9) = 19{,}023$. Assim, um intervalo de confiança 0,95 para σ^2 é dado por

$$\begin{aligned}\left[\frac{(n-1)\,s^2}{\chi^2_{(1+\gamma)/2}(n-1)}, \frac{(n-1)\,s^2}{\chi^2_{(1-\gamma)/2}(n-1)}\right] &= \left[\frac{9\,(4{,}8620)}{19{,}023}; \frac{9\,(4{,}8620)}{2{,}700}\right] \\ &= [2{,}3003; 16{,}207].\end{aligned}$$

O comprimento do intervalo indica que há um grau razoável de incerteza sobre o verdadeiro valor de σ^2. Vemos, porém, que um teste de $H_0 : \sigma^2 = 4$ não rejeitaria essa hipótese ao nível de 5%, porque o valor 4 está no intervalo de confiança 0,95. ■

6.3.5 Cálculos de Tamanho da Amostra: Intervalos de Confiança

Com bastante frequência, pede-se a um estatístico que determine o tamanho da amostra n que garanta que, com probabilidade muito alta, os resultados de uma análise estatística sejam conclusivos. Por exemplo, suponha que vamos tomar uma amostra de tamanho n de uma população Π e queremos estimar a média populacional μ de modo que a estimativa fique a menos de 0,5 da verdadeira média com probabilidade de pelo menos 0,95. Isso significa que queremos que o semicomprimento[40], ou margem de erro, do intervalo de confiança 0,95 para a média tenha a garantia de ser menor que 0,5.

Consideramos problemas assim nos exemplos a seguir. Note que, em geral, os *cálculos de tamanho da amostra* são do domínio do planejamento de experimentos[41], que discutiremos com mais detalhe no Capítulo 10.

Primeiro, consideramos o problema de escolher o tamanho da amostra para garantir que um intervalo de confiança seja mais curto que algum valor prescrito.

Exemplo 6.3.16 — O Comprimento de um Intervalo de Confiança para uma Média

Suponha que estamos na situação descrita no Exemplo 6.3.6, em que temos uma amostra $(x_1, \ldots, x_n)$ do modelo $N(\mu, \sigma_0^2)$, com $\mu \in R^1$ desconhecido e $\sigma_0^2 > 0$ conhecido. Suponha ainda que se pede ao estatístico que determine n de modo que a margem de erro de um intervalo de confiança γ para a média populacional μ não seja maior que um valor prescrito $\delta > 0$. Isso exige que n seja escolhido de modo que

$$z_{(1+\gamma)/2}\frac{\sigma_0}{\sqrt{n}} \leq \delta$$

ou, de modo equivalente, que

$$n \geq \sigma_0^2\left(\frac{z_{(1+\gamma)/2}}{\delta}\right)^2.$$

Por exemplo, se $\sigma_0^2 = 10$, $\gamma = 0{,}95$ e $\delta = 0{,}5$, então o menor valor possível de n é 154.

Considere agora a situação descrita no Exemplo 6.3.8, em que temos uma amostra $(x_1, \ldots, x_n)$ do modelo $N(\mu, \sigma^2)$ com $\mu \in R^1$ e $\sigma^2 > 0$ ambos

No original: *half-length*[40], *design of experiments*[41].

desconhecidos. Neste caso, queremos n tal que

$$t_{(1+\gamma)/2}(n-1)\,\frac{s}{\sqrt{n}} \leq \delta,$$

o que exige

$$n \geq s^2\left(\frac{t_{(1+\gamma)/2}(n-1)}{\delta}\right)^2.$$

Mas note que isso também depende do valor não observado de s, de modo que não podemos determinar um valor adequado de n.

Muitas vezes, porém, conseguimos determinar uma cota superior para o desvio padrão populacional, digamos, $\sigma \leq b$. Por exemplo, suponha que estamos medindo alturas de pessoas em centímetros. Então temos uma ideia bem boa das cotas superior e inferior das alturas que de fato poderemos obter. Portanto, com a suposição de normalidade, o intervalo dado pela média populacional mais ou menos três desvios padrão tem de estar contido no intervalo dado pelas cotas superior e inferior. Assim, dividir o comprimento desse intervalo por 6 dá uma cota superior plausível b para o valor de σ. De qualquer modo, quando temos uma cota superior assim, podemos esperar que $s \leq b$, pelo menos se escolhermos b de forma conservadora. Portanto, tomamos n satisfazendo

$$n \geq b^2\left(\frac{t_{(1+\gamma)/2}(n-1)}{\delta}\right)^2.$$

Note que também precisamos avaliar $t_{(1+\gamma)/2}(n-1)$ para cada n. É prudente ser bastante conservador na escolha de n neste caso, isto é, não escolher o menor valor possível. ■

Exemplo 6.3.17 — O Comprimento de um Intervalo de Confiança para uma Proporção

Suponha que estamos na situação descrita no Exemplo 6.3.2, em que temos uma amostra $(x_1, \ldots, x_n)$ do modelo Bernoulli(θ) e $\theta \in [0,1]$ é desconhecido. Exige-se que o estatístico especifique o tamanho da amostra n de modo que a margem de erro de um intervalo de confiança γ para θ não seja maior que um valor prescrito δ. Assim, pelo Exemplo 6.3.7, queremos que n satisfaça

$$z_{(1+\gamma)/2}\sqrt{\frac{\bar{x}(1-\bar{x})}{n}} \leq \delta, \tag{6.3.9}$$

e isso exige

$$n \geq \bar{x}(1-\bar{x})\left(\frac{z_{(1+\gamma)/2}}{\delta}\right)^2.$$

Como isso também depende do $\bar{x}$ não observado, não podemos determinar n. Note, porém, que $0 \leq \bar{x}(1-\bar{x}) \leq 1/4$ para todo $\bar{x}$ (trace o gráfico dessa função) e que essa cota superior é atingida quando $\bar{x} = 1/2$. Portanto, se determinarmos n de modo que

$$n \geq \frac{1}{4}\left(\frac{z_{(1+\gamma)/2}}{\delta}\right)^2,$$

então sabemos que (6.3.9) é satisfeita. Por exemplo, se $\gamma = 0{,}95$ e $\delta = 0{,}1$, o menor valor possível de n é 97; se $\gamma = 0{,}95$ e $\delta = 0{,}01$, o menor valor possível de n é 9604. ■

6.3.6 Cálculo do Tamanho da Amostra: Poder

Suponha que o propósito de um estudo seja avaliar uma hipótese específica $H_0 : \psi(\theta) = \psi_0$ e que tenha sido decidido que os resultados serão declarados estatisticamente significativos sempre que o valor-p for menor que α. Suponha que se peça ao estatístico que escolha n de modo que o valor-p obtido seja menor que α, com probabilidade de pelo menos β_0, em algum θ_1 específico tal que $\psi(\theta_1) \neq \psi_0$. A probabilidade de o valor-p ser menor que α para um valor específico de θ é chamada de *poder* do teste em θ. Vamos denotá-la por $\beta(\theta)$ e chamar β de *função poder*[42] do teste. A notação β não é de fato completa, pois omite a dependência de β em relação a ψ, ψ_0, α, n e ao procedimento de teste, mas vamos supor que esses elementos estejam claros em cada contexto

No original: *power function*[42].

particular. O problema apresentado ao estatístico pode então ser enunciado assim: encontre n tal que $\beta(\theta_1) \geq \beta_0$.

A função poder de um teste é uma medida da sensibilidade do teste para detectar afastamentos da hipótese nula. Escolhemos α pequeno ($\alpha = 0{,}05$, 0,01 etc.) para não declararmos erroneamente que temos evidência contra a hipótese nula quando ela é de fato verdadeira. Quando $\psi(\theta) \neq \psi_0$, $\beta(\theta)$ é a probabilidade de o teste fazer a coisa certa e detectar que H_0 é falsa.

Para qualquer procedimento de teste, é uma boa ideia examinar sua função poder, talvez para várias escolhas de α, para ver quão bom o teste é em detectar afastamentos. Pois pode acontecer de não encontrarmos nenhuma evidência contra uma hipótese nula quando ela é falsa porque o tamanho da amostra é pequeno demais. Nesse caso, o poder será pequeno nos valores de θ que representam afastamentos de H_0 significativos na prática. Para evitar esse problema, devemos sempre escolher um valor ψ_1 que represente um afastamento de ψ_0 significativo na prática[43] e então determinar n de modo que rejeitemos H_0 com alta probabilidade quando $\psi(\theta) = \psi_1$.

Consideramos o cálculo e o uso da função poder em vários exemplos.

Exemplo 6.3.18 — A Função Poder no Modelo Normal de Locação

Para o teste z bilateral do Exemplo 6.3.9, temos

$$\begin{aligned}
\beta(\mu) &= P_\mu\left(2\left[1-\Phi\left(\left|\frac{\bar{X}-\mu_0}{\sigma_0/\sqrt{n}}\right|\right)\right] < \alpha\right) \\
&= P_\mu\left(\Phi\left(\left|\frac{\bar{X}-\mu_0}{\sigma_0/\sqrt{n}}\right|\right) > 1-\frac{\alpha}{2}\right) = P_\mu\left(\left|\frac{\bar{X}-\mu_0}{\sigma_0/\sqrt{n}}\right| > z_{(1-\alpha/2)}\right) \\
&= P_\mu\left(\frac{\bar{X}-\mu_0}{\sigma_0/\sqrt{n}} > z_{(1-\alpha/2)}\right) + P_\mu\left(\frac{\bar{X}-\mu_0}{\sigma_0/\sqrt{n}} < -z_{(1-\alpha/2)}\right) \\
&= P_\mu\left(\frac{\bar{X}-\mu}{\sigma_0/\sqrt{n}} > \frac{\mu_0-\mu}{\sigma_0/\sqrt{n}} + z_{(1-\alpha/2)}\right) + P_\mu\left(\frac{\bar{X}-\mu}{\sigma_0/\sqrt{n}} < \frac{\mu_0-\mu}{\sigma_0/\sqrt{n}} - z_{(1-\alpha/2)}\right) \\
&= 1-\Phi\left(\frac{\mu_0-\mu}{\sigma_0/\sqrt{n}} + z_{(1-\alpha/2)}\right) + \Phi\left(\frac{\mu_0-\mu}{\sigma_0/\sqrt{n}} - z_{(1-\alpha/2)}\right). \qquad (6.3.10)
\end{aligned}$$

Note que

$$\beta(\mu) = \beta(\mu_0 + (\mu-\mu_0)) = \beta(\mu_0 - (\mu-\mu_0)),$$

de modo que β é simétrica em torno de μ_0 (ponha $\delta = \mu - \mu_0$ e $\mu = \mu_0 + \delta$ na expressão de $\beta(\mu)$ e obtemos o mesmo valor).

No original: *practically significant*[43].

Derivando (6.3.10) em relação a $\sqrt{n}$, obtemos

$$\left[\varphi\left(\frac{\mu_0-\mu}{\sigma_0/\sqrt{n}}-z_{(1-\alpha/2)}\right)-\varphi\left(\frac{\mu_0-\mu}{\sigma_0/\sqrt{n}}+z_{(1-\alpha/2)}\right)\right]\frac{\mu_0-\mu}{\sigma_0} \tag{6.3.11}$$

em que φ é a densidade da distribuição $N(0,1)$. Podemos provar que (6.3.11) é sempre não negativa (ver Desafio 6.3.34). Isso implica que $\beta(\mu)$ é crescente em n, de modo que basta resolver $\beta(\mu_1)=\beta_0$ em n (a solução pode não ser um inteiro) para determinar um tamanho da amostra adequado (todos os valores maiores de n darão um poder maior).

Por exemplo, quando $\sigma_0=1$, $\alpha=0{,}05$, $\beta_0=0{,}99$ e $\mu_1=\mu_0\pm 0{,}1$, precisamos encontrar n que satisfaça

$$1-\Phi(\sqrt{n}(0{,}1)+1{,}96)+\Phi(\sqrt{n}(0{,}1)-1{,}96)=0{,}99. \tag{6.3.12}$$

(Note que a simetria de β em torno de μ_0 significa que obteremos a mesma resposta se usarmos aqui $\mu_0-0{,}1$ em vez de $\mu_0+0{,}1$.) Tabelando (6.3.12) como função de n com um pacote estatístico, determina-se que $n=785$ é o menor valor que atinge a cota exigida.*

Observe também que a derivada de (6.3.10) em relação a μ é dada por

$$\left[\varphi\left(\frac{\mu_0-\mu}{\sigma_0/\sqrt{n}}+z_{(1-\alpha/2)}\right)-\varphi\left(\frac{\mu_0-\mu}{\sigma_0/\sqrt{n}}-z_{(1-\alpha/2)}\right)\right]\frac{\sqrt{n}}{\sigma_0}. \tag{6.3.13}$$

Ela é positiva quando $\mu>\mu_0$, negativa quando $\mu<\mu_0$ e vale 0 quando $\mu=\mu_0$ (ver Desafio 6.3.35). De (6.3.10), temos que $\beta(\mu)\to 1$ quando $\mu\to\pm\infty$. Esses fatos mostram que β assume seu valor mínimo em μ_0 e que é crescente à medida que nos afastamos de μ_0. Portanto, uma vez determinado n de modo que o poder seja pelo menos β_0 em algum μ_1, sabemos que o poder é pelo menos β_0 para todos os valores de μ que satisfazem $|\mu_0-\mu|\geq|\mu_0-\mu_1|$.

Como exemplo disso, considere a Figura 6.3.5, em que traçamos o gráfico da função poder quando $n=10$, $\mu_0=0$, $\sigma_0=1$ e $\alpha=0{,}05$, de modo que

$$\beta(\mu)=1-\Phi(\sqrt{10}\,\mu+1{,}96)+\Phi(\sqrt{10}\,\mu-1{,}96).$$

Note a simetria em torno de $\mu_0=0$ e o fato de que $\beta(\mu)$ cresce à medida que μ se afasta de 0. Obtemos $\beta(1{,}2)=0{,}967$, de modo que, quando $\mu=\pm 1{,}2$, a probabilidade de o valor-p para testar $H_0:\mu=0$ ser menor que 0,05 é 0,967. É claro que, à medida que aumentamos n, esse gráfico sobe ainda mais rapidamente para 1 conforme nos afastamos de 0.

Muitos pacotes estatísticos trazem a função poder como função embutida para vários testes. Isso é muito conveniente para examinar a sensibilidade do teste e determinar tamanhos da amostra. ■

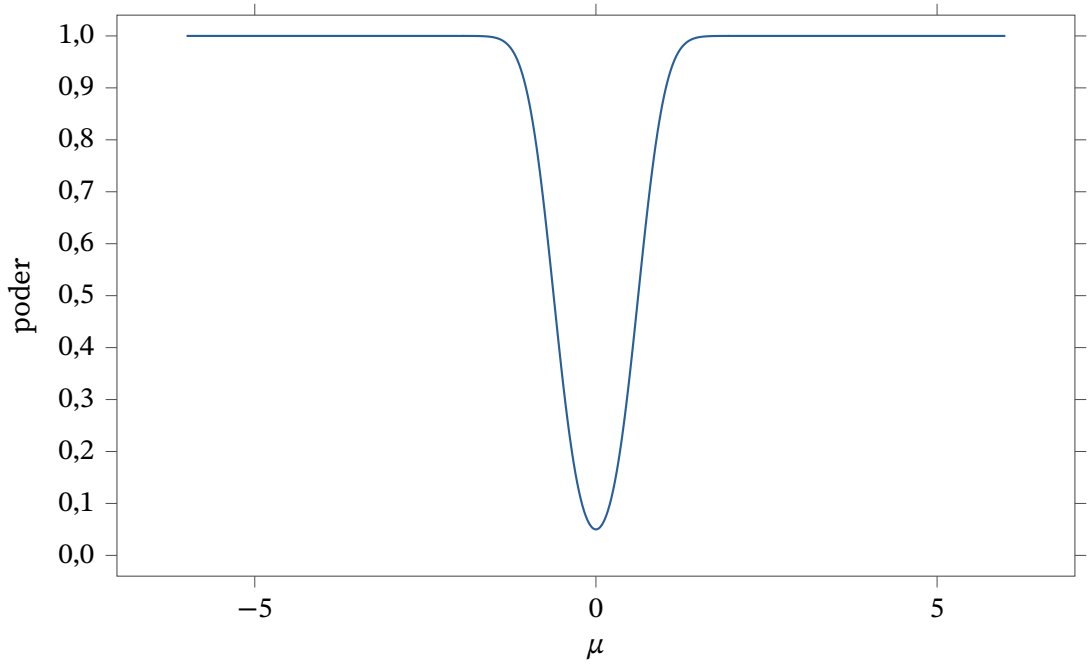


Figura 6.3.5: Gráfico da função poder $\beta(\mu)$ do Exemplo 6.3.18 quando $\alpha = 0{,}05$, $\mu_0 = 0$ e $\sigma_0 = 1$ é suposto conhecido.

Exemplo 6.3.19 — A Função Poder para θ no Modelo de Bernoulli

Para o teste bilateral do Exemplo 6.3.11, temos que a função poder é dada por*

$$\beta(\theta) = P_\theta\left(2\left[1 - \Phi\left(\left|\frac{\sqrt{n}\,(\bar{X} - \theta_0)}{\sqrt{\theta_0(1-\theta_0)}}\right|\right) < \alpha\right]\right).$$

Supondo que escolhemos n grande o bastante para que $\bar{X}$ tenha aproximadamente distribuição $N(\theta, \theta(1-\theta)/n)$, o cálculo aproximado dessa função poder pode ser feito como no Exemplo 6.3.18, quando pomos $\sigma_0 = \theta(1-\theta)$.† Não prosseguimos com esse cálculo aqui, mas observamos que muitos pacotes estatísticos calculam β como função embutida. ■

*Nota do tradutor. com $n = 785$ o lado esquerdo de (6.3.12) vale cerca de 0,80; para chegar a 0,99 seria preciso $n = 1838$. O valor 785 corresponde a $\beta_0 = 0{,}80$.

*Nota do tradutor. assim no original: o "$< \alpha$" aparece dentro dos colchetes; pelo Exemplo 6.3.18 seria $P_\theta(2[1 - \Phi(|\cdot|)] < \alpha)$.

†Nota do tradutor. assim no original; como σ_0 é desvio padrão no Exemplo 6.3.18, seria $\sigma_0 = \sqrt{\theta(1-\theta)}$.

Exemplo 6.3.20 — A Função Poder no Modelo Normal de Locação e Escala

Para o teste t bilateral do Exemplo 6.3.13, temos

$$\begin{aligned}\beta_n(\mu,\sigma^2) &= P_{(\mu,\sigma^2)}\left(2\left[1-G\left(\left|\frac{\bar{X}-\mu_0}{S/\sqrt{n}}\right|;\, n-1\right)\right]<\alpha\right)\\ &= P_{(\mu,\sigma^2)}\left(\left|\frac{\bar{X}-\mu_0}{S/\sqrt{n}}\right|>t_{(1-\alpha/2)}(n-1)\right),\end{aligned}$$

em que $G(\cdot\,;\, n-1)$ é a função de distribuição acumulada da distribuição $t(n-1)$. Note que ela é função tanto de μ quanto de σ^2. Em particular, temos de especificar tanto μ quanto σ^2 e então determinar n de modo que $\beta_n(\mu,\sigma^2) \geq \beta_0$. Muitos pacotes estatísticos trazem o cálculo dessa função poder embutido, de modo que um n adequado pode ser determinado com ele. Alternativamente, podemos usar métodos de Monte Carlo para aproximar a função de distribuição de

$$\left|\frac{\bar{X}-\mu_0}{S/\sqrt{n}}\right|$$

na amostragem da $N(\mu,\sigma^2)$, para vários valores de n, a fim de determinar um valor apropriado. ■

Resumo da Seção 6.3

- O EMV $\hat{\theta}$ é o valor do parâmetro θ mais apoiado pelo modelo e pelos dados. Assim, faz sentido basear no EMV a obtenção de inferências sobre alguma característica $\psi(\theta)$. Essas inferências incluem estimativas e seus erros padrão, intervalos de confiança e a avaliação de hipóteses por meio de valores-p.
- Um aspecto importante do planejamento de um estudo amostral é decidir o tamanho n da amostra para garantir que o estudo produza resultados suficientemente precisos. Prescrever os semicomprimentos dos intervalos de confiança (margens de erro) ou o poder de um teste são duas técnicas para fazer isso.

Exercícios

6.3.1 Suponha que medições (em centímetros) são feitas com um instrumento. Há erro no processo de medição, e supõe-se que uma medição tenha distribuição $N(\mu, \sigma_0^2)$, em que μ é a medida exata e $\sigma_0^2 = 0{,}5$. Se foram obtidas as ($n = 10$) medições 4,7; 5,5; 4,4; 3,3; 4,6; 5,3; 5,2; 4,8; 5,7; 5,3, avalie a hipótese $H_0 : \mu = 5$ calculando o valor-p relevante. Calcule também um intervalo de confiança 0,95 para o μ desconhecido.

6.3.2 Suponha que, no Exercício 6.3.1, abandonemos a hipótese de que $\sigma_0^2 = 0{,}5$. Avalie então a hipótese $H_0 : \mu = 5$ e calcule um intervalo de confiança 0,95 para μ.

6.3.3 Supõe-se que as notas numa prova de um curso de estatística tenham distribuição normal com média desconhecida, mas com variância igual a 5. Uma amostra de quatro estudantes é selecionada, e suas notas são 52, 63, 64, 84. Avalie a hipótese $H_0 : \mu = 60$ calculando o valor-p relevante e calcule um intervalo de confiança 0,95 para o μ desconhecido.

6.3.4 Suponha que, no Exercício 6.3.3, abandonemos a hipótese de que a variância populacional é 5. Avalie a hipótese $H_0 : \mu = 60$ calculando o valor-p relevante e calcule um intervalo de confiança 0,95 para o μ desconhecido.

6.3.5 Suponha que, no Exercício 6.3.3, tivéssemos observado uma única nota e que ela fosse 52. Avalie a hipótese $H_0 : \mu = 60$ calculando o valor-p relevante e calcule um intervalo de confiança 0,95 para o μ desconhecido. É possível calcular um valor-p e construir um intervalo de confiança 0,95 para μ sem a hipótese de que conhecemos a variância populacional? Explique sua resposta e, se ela for negativa, determine o tamanho mínimo da amostra n para o qual a inferência é possível sem a hipótese de que a variância populacional é conhecida.

6.3.6 Suponha que os dados da velocidade da luz da Tabela 6.3.1 sejam uma amostra de uma distribuição $N(\mu, \sigma^2)$ para valores desconhecidos de μ e σ^2. Determine um intervalo de confiança 0,99 para μ. Avalie a hipótese nula $H_0 : \mu = 24$.

6.3.7 Um fabricante quer avaliar se as hastes estão sendo produzidas de forma adequada ou não; o diâmetro das hastes deve ser 1,0 cm, e sabe-se que a variação nos diâmetros tem distribuição $N(\mu, 0{,}1)$. O fabricante está disposto a tolerar um desvio da média populacional em relação a esse valor de no máximo 0,1 cm, isto é, se a média populacional estiver no intervalo $1{,}0 \pm 0{,}1$ cm, então o processo de fabricação está funcionando corretamente. Toma-se uma amostra

de $n = 500$ hastes, e o diâmetro médio delas é $\bar{x} = 1{,}05$ cm, com $s^2 = 0{,}083$ cm^2. Esses resultados são estatisticamente significativos? São significativos na prática? Justifique suas respostas.

6.3.8 Um instituto de pesquisa faz uma pesquisa para determinar que proporção θ dos eleitores de uma dada população vai votar numa eleição próxima. Uma amostra aleatória de $n = 250$ foi tirada da população, e a proporção que respondeu sim foi 0,62. Avalie a hipótese $H_0 : \theta = 0{,}65$ e construa um intervalo de confiança 0,90 aproximado para θ.

6.3.9 Uma moeda foi lançada $n = 1000$ vezes, e a proporção de caras observada foi 0,51. Temos evidência para concluir que a moeda não é honesta?

6.3.10 Quantas vezes devemos lançar uma moeda para garantir que um intervalo de confiança 0,95 para a probabilidade de cara num único lançamento tenha comprimento menor que 0,1, 0,05 e 0,01, respectivamente?

6.3.11 Suponha que um dado possivelmente viciado é lançado 30 vezes e que a face com dois pontos sai 10 vezes. Temos evidência para concluir que o dado é viciado?

6.3.12 Suponha que se supõe que uma medição numa população tenha distribuição $N(\mu, 2)$, em que $\mu \in R^1$ é desconhecido, e que o tamanho da população é muito grande. Um pesquisador quer determinar um intervalo de confiança 0,95 para μ cujo comprimento não passe de 1. Qual é o tamanho mínimo da amostra que garante isso?

6.3.13 Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma Bernoulli(θ) com $\theta \in [0, 1]$ desconhecido.

(a) Mostre que $\sum_{i=1}^{n}(x_i - \bar{x})^2 = n\bar{x}(1 - \bar{x})$. (Sugestão: $x_i^2 = x_i$.)

(b) Se $X \sim$ Bernoulli(θ), então $\sigma^2 = \text{Var}(X) = \theta(1 - \theta)$. Registre a relação entre a estimativa plug-in de σ^2 e a estimativa dada por s^2 em (5.5.5).

(c) Como s^2 é um estimador não viesado de σ^2 (ver Problema 6.3.23), use os resultados do item (b) para determinar o viés da estimativa plug-in. O que acontece com esse viés quando $n \to \infty$?

6.3.14 Suponha que lhe digam que, com base em certos dados, um intervalo de confiança 0,95 para uma característica $\psi(\theta)$ é dado por $(1{,}23; 2{,}45)$. Perguntam-lhe então se há alguma evidência contra a hipótese $H_0 : \psi(\theta) = 2$. Enuncie sua conclusão e justifique seu raciocínio.

6.3.15 Suponha que x_1 é um valor de uma Bernoulli(θ) com $\theta \in [0, 1]$ desconhecido.

(a) x_1 é um estimador não viesado de θ?

(b) x_1^2 é um estimador não viesado de θ^2?

6.3.16 Suponha que um EMV plug-in de uma característica $\psi(\theta)$ seja dado por 5,3. Além disso, um valor-p foi calculado para avaliar a hipótese $H_0 : \psi(\theta) = 5$, e o valor foi 0,000132. Se lhe disserem que diferenças entre valores de $\psi(\theta)$ menores que 0,5 não têm importância no que diz respeito à aplicação, o que você conclui desses resultados? Suponha, em vez disso, que lhe dissessem que diferenças entre valores de $\psi(\theta)$ menores que 0,25 não têm importância no que diz respeito à aplicação; o que você conclui desses resultados?

6.3.17 Um valor-p foi calculado para avaliar a hipótese $H_0 : \psi(\theta) = 0$, e obteve-se o valor 0,22. O pesquisador diz que isso é forte evidência de que a hipótese é correta. Como você responde?

6.3.18 Um valor-p foi calculado para avaliar a hipótese $H_0 : \psi(\theta) = 1$, e obteve-se o valor 0,55. Dizem-lhe que diferenças em $\psi(\theta)$ maiores que 0,5 são consideradas significativas na prática, e as outras não. O pesquisador quer saber se foram coletados dados suficientes para detectar de forma confiável uma diferença desse tamanho ou maior. Como você responderia?

Exercícios computacionais

6.3.19 Suponha que se possa supor que uma medição numa população segue a distribuição $N(\mu, \sigma^2)$, em que $(\mu, \sigma^2) \in R^1 \times (0, \infty)$ é desconhecido e o tamanho da população é muito grande. Uma cota superior[44] bem conservadora para σ é dada por 5. Um pesquisador quer determinar um intervalo de confiança 0,95 para μ cujo comprimento não passe de 1. Determine um tamanho da amostra que garanta isso. (Sugestão: comece com uma aproximação para amostra grande.)

6.3.20 Suponha que se supõe que uma medição numa população tenha distribuição $N(\mu, 2)$, em que $\mu \in R^1$ é desconhecido, e que o tamanho da população é muito grande. Um pesquisador quer avaliar uma hipótese nula $H_0 : \mu = \mu_0$ e garantir que a probabilidade de o valor-p ser menor que 0,05 seja de pelo menos 0,80 quando $\mu = \mu_0 \pm 0{,}5$. Qual é o tamanho mínimo da amostra que garante isso? (Sugestão: tabele o poder como função do tamanho da amostra n.)

No original: *upper bound*[44].

6.3.21 Gere 10^3 amostras de tamanho $n = 5$ da distribuição Bernoulli(0,5). Para cada uma dessas amostras, calcule (6.3.5) com $\gamma = 0{,}95$ e registre a proporção de intervalos que contêm o valor verdadeiro. O que você nota? Repita essa simulação com $n = 20$. O que você nota?

6.3.22 Gere 10^4 amostras de tamanho $n = 5$ da distribuição $N(0, 1)$. Para cada uma dessas amostras, calcule o intervalo $(\bar{x} - s/\sqrt{5}, \bar{x} + s/\sqrt{5})$, em que s é o desvio padrão amostral, e calcule a proporção de vezes que esse intervalo contém μ. Repita essa simulação com $n = 10$ e 100 e compare seus resultados.

Problemas

6.3.23 Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição com média μ e variância σ^2.

(a) Prove que s^2 dado por (5.5.5) é um estimador não viesado de σ^2.

(b) Se, em vez disso, estimarmos σ^2 por $(n-1)s^2/n$, determine o viés dessa estimativa e o que acontece com ele quando $n \to \infty$.

6.3.24 Suponha que temos dois estimadores não viesados T_1 e T_2 de $\psi(\theta) \in R^1$.

(a) Mostre que $\alpha T_1 + (1-\alpha)T_2$ também é um estimador não viesado de $\psi(\theta)$ sempre que $\alpha \in [0, 1]$.

(b) Se T_1 e T_2 forem também independentes, por exemplo, determinados a partir de amostras independentes, calcule $\mathrm{Var}_\theta(\alpha T_1 + (1-\alpha)T_2)$ em termos de $\mathrm{Var}_\theta(T_1)$ e $\mathrm{Var}_\theta(T_2)$.

(c) Na situação do item (b), determine a melhor escolha de α, no sentido de que, para essa escolha, $\mathrm{Var}_\theta(\alpha T_1 + (1-\alpha)T_2)$ seja a menor possível. Qual é o efeito, sobre esse estimador combinado, de T_1 ter uma variância muito grande em relação a T_2?

(d) Repita os itens (b) e (c), mas agora sem supor que T_1 e T_2 são independentes, de modo que $\mathrm{Var}_\theta(\alpha T_1 + (1-\alpha)T_2)$ também envolverá $\mathrm{Cov}_\theta(T_1, T_2)$.

6.3.25 (*Intervalos de confiança unilaterais para médias*) Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição $N(\mu, \sigma_0^2)$, em que $\mu \in R^1$ é desconhecido e σ_0^2 é conhecido. Suponha que queremos fazer inferências sobre o intervalo $\psi(\mu) = (-\infty, \mu)$. Considere o problema de encontrar um intervalo $C(x_1, \ldots, x_n) = (-\infty, u(x_1, \ldots, x_n))$ que cubra o intervalo $(-\infty, \mu)$ com probabilidade de pelo menos γ. Assim, queremos u tal que, para todo μ,

$$P_\mu(\mu \le u(X_1, \ldots, X_n)) \ge \gamma.$$

Note que $(-\infty, \mu) \subset (-\infty, u(x_1, \ldots, x_n))$ se e somente se $\mu \leq u(x_1, \ldots, x_n)$, de modo que $C(x_1, \ldots, x_n)$ é chamado de intervalo de confiança γ unilateral à esquerda para μ. Obtenha um intervalo de confiança γ unilateral à esquerda exato para μ usando $u(x_1, \ldots, x_n) = \bar{x} + k(\sigma_0/\sqrt{n})$, isto é, encontre o k que dá essa propriedade.

6.3.26 (*Hipóteses unilaterais para médias*) Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição $N(\mu, \sigma_0^2)$, em que μ é desconhecido e σ_0^2 é conhecido. Suponha que queremos avaliar a hipótese $H_0 : \mu \leq \mu_0$. Nessas circunstâncias, dizemos que o valor observado $\bar{x}$ é surpreendente se $\bar{x}$ ocorre numa região de baixa probabilidade para toda distribuição em H_0. Portanto, um valor-p sensato para este problema é $\max_{\mu \in H_0} P_\mu(\bar{X} > \bar{x})$. Mostre que isso leva ao valor-p $1 - \Phi((\bar{x} - \mu_0)/(\sigma_0/\sqrt{n}))$.

6.3.27 Determine a forma da função poder associada ao procedimento de avaliação de hipóteses do Problema 6.3.26, quando declaramos o resultado de um teste estatisticamente significativo[45] sempre que o valor-p é menor que α.

6.3.28 Repita os Problemas 6.3.25 e 6.3.26, mas desta vez obtenha um intervalo de confiança γ unilateral à direita para μ e avalie a hipótese $H_0 : \mu \geq \mu_0$.

6.3.29 Repita os Problemas 6.3.25 e 6.3.26, mas desta vez não suponha que a variância populacional é conhecida. Em particular, determine k de modo que $u(x_1, \ldots, x_n) = \bar{x} + k\,(s/\sqrt{n})$ dê um intervalo de confiança γ unilateral à esquerda exato para μ e mostre que o valor-p para testar $H_0 : \mu \leq \mu_0$ é dado por*

$$1 - G\left(\frac{\bar{x} - \mu_0}{\sigma_0/\sqrt{n}};\, n - 1\right).$$

6.3.30 (*Intervalos de confiança unilaterais para variâncias*) Suponha que $(x_1, \ldots, x_n)$ é uma amostra da distribuição $N(\mu, \sigma^2)$, em que $(\mu, \sigma^2) \in R^1 \times (0, \infty)$ é desconhecido, e que queremos um intervalo de confiança γ da forma

$$C(x_1, \ldots, x_n) = (0, u(x_1, \ldots, x_n))$$

para σ^2. Se $u(x_1, \ldots, x_n) = ks^2$, determine k de modo que esse intervalo seja um intervalo de confiança γ exato.

*__Nota do tradutor.__ assim no original; como a variância é desconhecida, seria $s/\sqrt{n}$ no lugar de $\sigma_0/\sqrt{n}$.

No original: *statistically significant*[45].

6.3.31 (*Hipóteses unilaterais para variâncias*) Suponha que $(x_1, \ldots, x_n)$ é uma amostra da distribuição $N(\mu, \sigma^2)$, em que $(\mu, \sigma^2) \in R^1 \times (0, \infty)$ é desconhecido, e que queremos avaliar a hipótese $H_0 : \sigma^2 \leq \sigma_0^2$. Argumente que a variância amostral s^2 é surpreendente se s^2 for grande e que, portanto, um valor-p sensato para este problema é calcular $\max_{(\mu,\sigma^2)\in H_0} P_\mu(S^2 > s^2)$. Mostre que isso leva ao valor-p

$$1 - H\left(\frac{(n-1)s^2}{\sigma_0^2}; n-1\right),$$

em que $H(\cdot\,; n-1)$ é a função de distribuição da distribuição $\chi^2(n-1)$.

6.3.32 Determine a forma da função poder associada ao procedimento de avaliação de hipóteses do Problema 6.3.31, para calcular a probabilidade de o valor-p ser menor que α.

6.3.33 Repita o Exercício 6.3.7, mas desta vez não suponha que a variância populacional é conhecida. Nesse caso, o fabricante considera o processo sob controle se o desvio padrão populacional for menor ou igual a 0,1 e a média populacional estiver no intervalo $1{,}0 \pm 0{,}1$ cm. Use o Problema 6.3.31 para o teste sobre a variância populacional.

Desafios

6.3.34 Prove que (6.3.11) é sempre não negativa. (Sugestão: use os fatos de que φ é simétrica em torno de 0, crescente à esquerda de 0 e decrescente à direita de 0.)

6.3.35 Prove que (6.3.13) é positiva quando $\mu > \mu_0$, negativa quando $\mu < \mu_0$ e vale 0 quando $\mu = \mu_0$.

Tópicos para discussão

6.3.36 Discuta a seguinte afirmação: a precisão dos resultados de uma análise estatística é tão importante que devemos sempre tomar o maior tamanho da amostra possível.

6.3.37 Suponha que temos uma sequência de estimadores $T_1, T_2, \ldots$ para $\psi(\theta)$ e que $T_n \xrightarrow{P} \psi(\theta) + \epsilon(\theta)$ quando $n \to \infty$, para cada $\theta \in \mathbf{\Omega}$. Discuta em que circunstâncias você poderia considerar T_n um estimador útil de $\psi(\theta)$.

6.4 Métodos Livres de Distribuição

Os métodos de verossimilhança que vimos discutindo dependem todos da suposição de que a verdadeira distribuição está em $\{P_\theta : \theta \in \mathbf{\Omega}\}$. Em geral, nada garante que a suposição $\{P_\theta : \theta \in \mathbf{\Omega}\}$ esteja correta. Se a distribuição da qual estamos amostrando for muito diferente de qualquer uma das distribuições em $\{P_\theta : \theta \in \mathbf{\Omega}\}$, então os métodos de inferência que dependem dessa suposição, como os métodos de verossimilhança, podem ser muito enganosos. Por isso, em qualquer aplicação, é importante verificar se as nossas suposições fazem sentido. Discutiremos o tema da verificação de modelos[46] no Capítulo 9.

Outra abordagem para esse problema é tomar o modelo $\{P_\theta : \theta \in \mathbf{\Omega}\}$ tão grande quanto possível, refletindo o fato de que podemos ter pouquíssima informação sobre como é a verdadeira distribuição. Por exemplo, inferências baseadas no modelo Bernoulli(θ) com $\theta \in \mathbf{\Omega} = [0, 1]$ na verdade não especificam informação nenhuma sobre a verdadeira distribuição, porque esse modelo inclui todas as distribuições possíveis no espaço amostral[47] $S = \{0, 1\}$. Os métodos de inferência adequados quando $\{P_\theta : \theta \in \mathbf{\Omega}\}$ é muito grande são às vezes chamados de *livres de distribuição*, para refletir o fato de que muito pouca informação sobre a verdadeira distribuição é especificada no modelo.

Para espaços amostrais finitos, é simples adotar a abordagem livre de distribuição, como no modelo Bernoulli que acabamos de citar, mas, quando o espaço amostral é infinito, as coisas se complicam. Na verdade, às vezes é muito difícil determinar inferências sobre características de interesse quando o modelo é muito grande. Além disso, se temos

$$\{P_\theta : \theta \in \mathbf{\Omega}_1\} \subset \{P_\theta : \theta \in \mathbf{\Omega}\},$$

então, quando o modelo menor contém a verdadeira distribuição, os métodos baseados no modelo menor farão melhor uso da informação dos dados sobre o verdadeiro valor em $\mathbf{\Omega}_1$ do que os métodos que usam o modelo maior $\{P_\theta : \theta \in \mathbf{\Omega}\}$. Há, portanto, um compromisso entre tomar um modelo grande demais e tomar um modelo preciso demais. Essa é uma questão que um estatístico sempre precisa enfrentar.

Consideramos agora alguns exemplos de inferências livres de distribuição. Em alguns casos, as inferências têm propriedades amostrais aproximadas, enquanto em outros elas têm propriedades amostrais exatas para modelos muito grandes.

No original: *model checking*[46], *sample space*[47].

6.4.1 Método dos Momentos

Suponha que tomamos $\{P_\theta : \theta \in \mathbf{\Omega}\}$ como o conjunto de todas as distribuições em R^1 que têm os seus l primeiros momentos, e que queremos fazer inferências sobre os momentos

$$\mu_i = E_\theta(X^i),$$

para $i = 1, \ldots, l$, com base numa amostra $(x_1, \ldots, x_n)$. O análogo amostral natural do momento populacional μ_i é o *i-ésimo momento amostral*

$$m_i = \frac{1}{n}\sum_{j=1}^{n} x_j^i,$$

que parece ser um estimador sensato.

Em particular, temos $E_\theta(M_i) = \mu_i$ para todo $\theta \in \mathbf{\Omega}$, de modo que m_i é não viesado, e as leis fraca e forte dos grandes números estabelecem que m_i converge para μ_i quando n cresce. Além disso, o teorema central do limite[48] estabelece que

$$\frac{M_i - \mu_i}{\sqrt{\mathrm{Var}_\theta(M_i)}} \xrightarrow{D} N(0,1)$$

quando $n \to \infty$, desde que $\mathrm{Var}_\theta(M_i) < \infty$. Agora, como $X_1, \ldots, X_n$ são i.i.d., temos

$$\begin{aligned}\mathrm{Var}_\theta(M_i) &= \frac{1}{n^2}\sum_{j=1}^{n}\mathrm{Var}_\theta(X_j^i) = \frac{1}{n}\mathrm{Var}_\theta(X_1^i) = \frac{1}{n}E_\theta\big((X_1^i - \mu_i)^2\big)\\ &= \frac{1}{n}E_\theta(X_1^{2i} - 2\mu_i X_1^i + \mu_i^2) = \frac{1}{n}(\mu_{2i} - \mu_i^2),\end{aligned}$$

de modo que $\mathrm{Var}_\theta(M_i) < \infty$ desde que $i \leq l/2$. Nesse caso, podemos estimar $\mu_{2i} - \mu_i^2$ por

$$s_i^2 = \frac{1}{n-1}\sum_{j=1}^{n}(x_j^i - m_i)^2,$$

pois podemos simplesmente tratar $(x_1^i, \ldots, x_n^i)$ como uma amostra de uma distribuição com média μ_i e variância $\mu_{2i} - \mu_i^2$. O Problema 6.3.23 estabelece que s_i^2 é uma estimativa não viesada de $\mathrm{Var}_\theta(M_i)$. Assim, como nas inferências para a média populacional baseadas na estatística z, temos que

$$m_i \pm z_{(1+\gamma)/2}\frac{s_i}{\sqrt{n}}$$

No original: *central limit theorem*[48].

é um intervalo de confiança γ aproximado para μ_i sempre que $i \leq l/2$ e n é grande. Além disso, podemos testar a hipótese $H_0 : \mu_i = \mu_{i0}$ exatamente do mesmo modo como fizemos para a média populacional usando a estatística z.

Observe que o modelo $\{P_\theta : \theta \in \mathbf{\Omega}\}$ é muito grande (todas as distribuições em R^1 cujos $l/2$ primeiros momentos são finitos) e que essas inferências aproximadas são adequadas para toda distribuição do modelo. Uma ressalva: a estimação dos momentos fica mais difícil à medida que a ordem dos momentos aumenta. São necessários tamanhos de amostra muito grandes para estimar com precisão momentos de ordem alta.

O *princípio do método dos momentos*[49], em sua forma geral, nos permite fazer inferências sobre características que são funções dos momentos. Ele tem a seguinte forma:

> *Princípio do método dos momentos:* uma função $\psi(\mu_1, \ldots, \mu_k)$ dos $k \leq l$ primeiros momentos é estimada por $\psi(m_1, \ldots, m_k)$.

Quando ψ é continuamente diferenciável e não nula em $(\mu_1, \ldots, \mu_k)$, e $k \leq l/2$, pode-se provar que $\psi(M_1, \ldots, M_k)$ converge em distribuição para uma normal com média dada por $\psi(\mu_1, \ldots, \mu_k)$ e variância dada por uma expressão que envolve as variâncias e covariâncias de $M_1, \ldots, M_k$ e as derivadas parciais de ψ. Não vamos aprofundar esse tema aqui, mas observamos que, no caso $k = 1$ e $l = 2$, essas condições levam ao chamado *teorema delta*[50], segundo o qual

$$\frac{\sqrt{n}\left(\psi(\bar{X}) - \psi(\mu_1)\right)}{|\psi'(\bar{X})|\, s} \xrightarrow{D} N(0, 1) \tag{6.4.1}$$

quando $n \to \infty$, desde que ψ seja continuamente diferenciável em μ_1 e $\psi'(\mu_1) \neq 0$; veja *Approximation Theorems of Mathematical Statistics*, de R. J. Serfling (John Wiley & Sons, Nova York, 1980), para uma demonstração desse resultado. Esse resultado fornece intervalos de confiança e testes aproximados para $\psi(\mu_1)$.

No original: *method of moments*[49], *delta theorem*[50].

Exemplo 6.4.1 — Inferência sobre uma Característica Usando o Método dos Momentos

Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição com média μ e variância σ^2 desconhecidas, e que queremos construir um intervalo de confiança γ para $\psi(\mu) = 1/\mu^2$. Então $\psi'(\mu) = -2/\mu^3$, e o teorema delta diz que

$$\frac{\sqrt{n}\left(1/\bar{X}^2 - 1/\mu^2\right)}{2s/\bar{X}^3} \xrightarrow{D} N(0,1)$$

quando $n \to \infty$. Portanto,

$$\left(\frac{1}{\bar{x}}\right)^2 \pm 2\frac{s}{\sqrt{n}\,\bar{x}^3} z_{(1+\gamma)/2}$$

é um intervalo de confiança γ aproximado para $\psi(\mu) = 1/\mu^2$.

Observe que, se $\mu = 0$, esse intervalo de confiança não é válido, porque ψ não é continuamente diferenciável em 0. Assim, se você acha que a média populacional pode ser 0, ou mesmo próxima de 0, essa não seria uma escolha adequada de intervalo de confiança para ψ. ■

6.4.2 Bootstrap

Suponha que $\{P_\theta : \theta \in \mathbf{\Omega}\}$ é o conjunto de todas as distribuições em R^1 e que $(x_1, \ldots, x_n)$ é uma amostra de alguma distribuição desconhecida com fda F_θ. Então a função de distribuição empírica[51]

$$\hat{F}(x) = \frac{1}{n}\sum_{i=1}^{n} I_{(-\infty,x]}(x_i),$$

apresentada na Seção 5.4.1, é um estimador natural da fda $F(x)$.

Temos

$$E_\theta\left(\hat{F}(x)\right) = \frac{1}{n}\sum_{i=1}^{n} E_\theta\left(I_{(-\infty,x]}(X_i)\right) = \frac{1}{n}\sum_{i=1}^{n} F_\theta(x) = F_\theta(x)$$

para todo $\theta \in \mathbf{\Omega}$, de modo que $\hat{F}$ é não viesado para F_θ. As leis fraca e forte dos grandes números estabelecem então a consistência de $\hat{F}(x)$ para $F_\theta(x)$ quando $n \to \infty$. Observando que os $I_{(-\infty,x]}(x_i)$ constituem uma amostra da distribuição

No original: *empirical distribution function*[51].

Bernoulli($F_\theta(x)$), temos que o erro padrão de $\hat{F}(x)$ é dado por

$$\sqrt{\frac{\hat{F}(x)\big(1-\hat{F}(x)\big)}{n}}.$$

Esses fatos podem ser usados para construir intervalos de confiança aproximados e testar hipóteses para $F_\theta(x)$, exatamente como nos Exemplos 6.3.7 e 6.3.11.

Observe que $\hat{F}(x)$ determina uma distribuição no conjunto $\{x_1, \ldots, x_n\}$; por exemplo, se os valores da amostra são distintos, essa distribuição de probabilidade põe massa $1/n$ em cada x_i. Note que é fácil amostrar um valor de $\hat{F}$, pois basta escolher um valor de $\{x_1, \ldots, x_n\}$ em que cada ponto tem probabilidade $1/n$ de ocorrer. Quando os x_i não são distintos, isso muda de modo óbvio: x_i tem probabilidade f_i/n, em que f_i é o número de vezes que x_i ocorre em $x_1, \ldots, x_n$.

Suponha que queremos estimar $\psi(\theta) = T(F_\theta)$, em que T é uma função da distribuição F_θ. Usamos essa notação para enfatizar que $\psi(\theta)$ corresponde a alguma característica da distribuição, em vez de ser apenas uma função matemática arbitrária de θ. Por exemplo, $T(F_\theta)$ poderia ser um momento de F_θ, um quantil de F_θ etc.

Suponha agora que temos um estimador $\hat{\psi}(x_1, \ldots, x_n)$ proposto para fazer inferências sobre $\psi(\theta)$. Naturalmente, estamos interessados na precisão de $\hat{\psi}$, e poderíamos escolher medi-la por

$$\mathrm{MSE}_\theta(\hat{\psi}) = \Big(E_\theta(\hat{\psi}) - \psi(\theta)\Big)^2 + \mathrm{Var}_\theta(\hat{\psi}). \tag{6.4.2}$$

Então, para avaliar a precisão da nossa estimativa $\hat{\psi}(x_1, \ldots, x_n)$, precisamos estimar (6.4.2).

Quando n é grande, esperamos que $\hat{F}$ esteja próxima de F_θ, de modo que uma estimativa natural de $\psi(\theta)$ é $T(\hat{F})$, isto é, simplesmente calculamos a mesma característica para a distribuição empírica. Essa é a abordagem adotada no Capítulo 5, quando discutimos estatísticas descritivas. Então estimamos o quadrado do viés de $\hat{\psi}$ por

$$\big(\hat{\psi} - T(\hat{F})\big)^2. \tag{6.4.3}$$

Para estimar a variância de $\hat{\psi}$, usamos

$$\begin{aligned}\operatorname{Var}_{\hat{F}}(\hat{\psi}) &= E_{\hat{F}}(\hat{\psi}^2) - E^2_{\hat{F}}(\hat{\psi}) \\ &= \frac{1}{n^n}\sum_{i_1=1}^{n}\cdots\sum_{i_n=1}^{n}\hat{\psi}^2(x_{i_1},\ldots,x_{i_n}) \\ &\quad -\left(\frac{1}{n^n}\sum_{i_1=1}^{n}\cdots\sum_{i_n=1}^{n}\hat{\psi}(x_{i_1},\ldots,x_{i_n})\right)^2,\end{aligned} \tag{6.4.4}$$

isto é, tratamos $x_1,\ldots,x_n$ como valores aleatórios i.i.d. com fda dada por $\hat{F}$. Assim, para calcular uma estimativa de (6.4.2), basta calcular $\operatorname{Var}_{\hat{F}}(\hat{\psi})$. Isso raramente é viável, porém, porque as somas em (6.4.4) envolvem n^n termos. Mesmo para tamanhos de amostra bem modestos, como $n = 10$, essa conta não pode ser feita, nem mesmo num computador.

A solução para esse problema é aproximar (6.4.4) extraindo m amostras independentes de tamanho n de $\hat{F}$, calculando $\hat{\psi}$ para cada uma delas, o que dá $\hat{\psi}_1,\ldots,\hat{\psi}_m$, e então usando como estimativa a variância amostral

$$\widehat{\operatorname{Var}}_{\hat{F}}(\hat{\psi}) = \frac{1}{m-1}\left\{\sum_{i=1}^{m}\hat{\psi}_i^2 - \left(\frac{1}{m}\sum_{i=1}^{m}\hat{\psi}_i\right)^2\right\}. \tag{6.4.5}$$

As m amostras de $\hat{F}$ são chamadas de *amostras bootstrap*[52] ou *reamostras*, e essa técnica é chamada de *bootstrap* ou *reamostragem*. Combinando (6.4.3) e (6.4.5), obtemos uma estimativa de $\operatorname{MSE}_\theta(\hat{\psi})$. Além disso, $m^{-1}\sum_{i=1}^{m}\hat{\psi}_i$ é chamada de *média bootstrap*, e

$$\sqrt{\widehat{\operatorname{Var}}_{\hat{F}}(\hat{\psi})}$$

é o *erro padrão bootstrap*. Note que o erro padrão bootstrap é uma estimativa válida do erro em $\hat{\psi}$ sempre que $\hat{\psi}$ tem viés pequeno ou nulo.

Considere o exemplo a seguir.

Exemplo 6.4.2 — A Mediana Amostral como Estimador da Média Populacional

Suponha que queremos estimar a posição de uma distribuição unimodal e simétrica. Embora a média amostral possa parecer a escolha óbvia para isso, acontece que, para algumas distribuições, há estimadores melhores. Isso porque a distribuição da qual estamos amostrando pode ter caudas longas, isto é, pode produzir valores extremos, distantes do centro da distribuição. Isso faz com que a própria média amostral possa

No original: *bootstrapping*[52].

ser fortemente influenciada por umas poucas observações extremas e seja, assim, uma estimativa ruim da verdadeira média.

Nem todos os estimadores sofrem desse defeito. Por exemplo, se estamos amostrando de uma distribuição simétrica, então tanto a média amostral quanto a mediana amostral podem servir de estimador da média populacional. Mas, como já discutimos, a mediana amostral não é influenciada por valores extremos, isto é, ela não muda quando afastamos os menores (ou os maiores) valores do resto dos dados, e isso não acontece com a média amostral.

Um problema de trabalhar com a mediana amostral $\hat{x}_{0,5}$, em vez da média amostral $\bar{x}$, é que a distribuição amostral de $\hat{x}_{0,5}$ costuma ser mais difícil de estudar do que a de $\bar{x}$. Nessa situação, o bootstrap se torna útil. Se estamos estimando a média populacional $T(F_\theta)$ pela mediana amostral (o que é adequado quando sabemos que a distribuição da qual amostramos é simétrica), então a estimativa do quadrado do viés da mediana amostral é dada por

$$\left(\hat{\psi} - T(\hat{F})\right)^2 = \left(\hat{x}_{0,5} - \bar{x}\right)^2,$$

pois $\hat{\psi} = \hat{x}_{0,5}$ e $T(\hat{F}) = \bar{x}$ (a média da distribuição empírica é $\bar{x}$). Esse valor deve ser próximo de 0; caso contrário, nossa suposição de uma distribuição simétrica pareceria incorreta. Para calcular (6.4.5), precisamos gerar m amostras de tamanho n de $\{x_1, \ldots, x_n\}$ (com reposição) e calcular $\hat{x}_{0,5}$ para cada amostra.

Para ilustrar, suponha que temos uma amostra de tamanho $n = 15$, dada pela tabela a seguir.

−2,0	−0,2	−5,2	−3,5	−3,9
−0,6	−4,3	−1,7	−9,5	1,6
−2,9	0,9	−1,0	−2,0	3,0

Então, usando a definição de $\hat{x}_{0,5}$ dada por (5.5.4) (lá denotada por $\check{x}_{0,5}$), temos $\hat{\psi} = -2{,}000$ e $\bar{x} = -2{,}087$. A estimativa do quadrado do viés (6.4.3) é igual a $(-2{,}000 + 2{,}087)^2 = 7{,}569 \times 10^{-3}$, o que é adequadamente pequeno. Usando um pacote estatístico, geramos $m = 10^3$ amostras de tamanho $n = 15$ da distribuição que tem probabilidade 1/15 em cada um dos pontos da amostra e obtivemos

$$\widehat{\mathrm{Var}}_{\hat{F}}(\hat{\psi}) = 0{,}770866.$$

Com base em $m = 10^4$ amostras, obtivemos

$$\widehat{\mathrm{Var}}_{\hat{F}}(\hat{\psi}) = 0{,}718612,$$

e com base em $m = 10^5$ amostras obtivemos

$$\widehat{\text{Var}}_{\hat{F}}(\hat{\psi}) = 0{,}704928.$$

Como essas estimativas parecem estar se estabilizando, tomamos esta última como nossa estimativa. Assim, nesse caso, a estimativa bootstrap do MSE da mediana amostral no verdadeiro valor de θ é dada por

$$\widehat{\text{MSE}}_{\theta}(\hat{\psi}) = 0{,}007569 + 0{,}704928 = 0{,}71250.$$

Note que o MSE estimado da média amostral é dado por $s^2 = 0{,}62410$, de modo que a média amostral e a mediana amostral parecem ter precisão parecida neste problema. Na Figura 6.4.1, traçamos um histograma de densidade das medianas amostrais obtidas das $m = 10^5$ amostras bootstrap. Note que o histograma é muito assimétrico. Veja o Apêndice B para mais detalhes sobre como essas contas foram feitas.

Mesmo com o tamanho de amostra muito pequeno deste caso, foi necessário usar o computador para fazer as contas. Calcular (6.4.4) exatamente exigiria calcular a mediana de 15^{15} (aproximadamente $4{,}4 \times 10^{17}$) amostras, o que é claramente impossível mesmo com um computador. Assim, o bootstrap é um recurso muito útil. ■

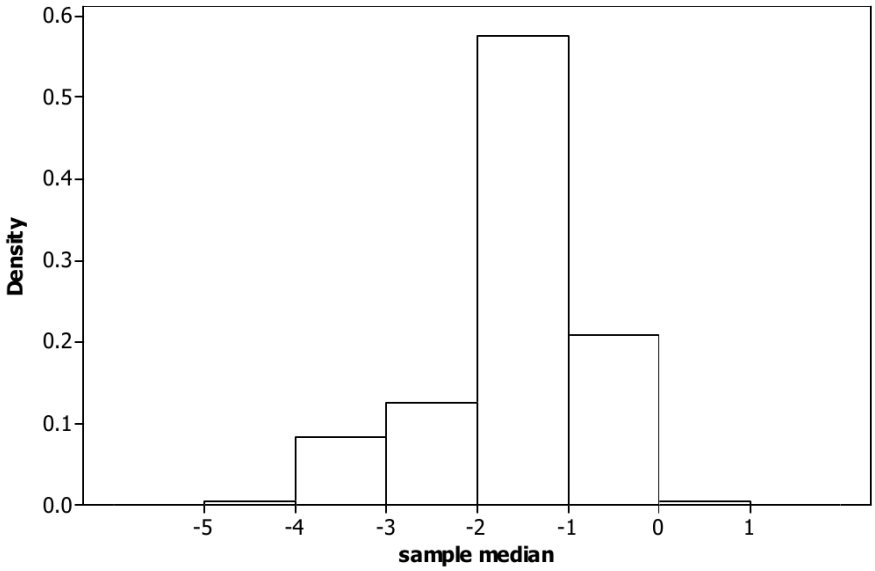


Figura 6.4.1: Um histograma de densidade de $m = 10^5$ medianas amostrais, cada uma obtida de uma amostra bootstrap de tamanho $n = 15$ dos dados do Exemplo 6.4.2.

A validade da técnica bootstrap depende de $\hat{\psi}$ ter os seus dois primeiros momentos. Assim, a família $\{P_\theta : \theta \in \mathbf{\Omega}\}$ precisa ser restringida de modo

apropriado, mas vemos que a técnica é muito geral.

De modo geral, não está claro como escolher m. Talvez o método mais direto seja aplicar o bootstrap com valores sucessivamente maiores de m e parar quando virmos que os resultados se estabilizam para vários valores. Foi o que fizemos no Exemplo 6.4.2, mas é preciso reconhecer que essa abordagem não é infalível, pois poderíamos ter uma amostra $(x_1, \ldots, x_n)$ para a qual a estimativa (6.4.5) converge muito lentamente.

Intervalos de Confiança Bootstrap

Também foram criados métodos bootstrap para obter intervalos de confiança γ aproximados para características como $\psi(\theta) = T(F_\theta)$. Um método muito simples é simplesmente construir o *intervalo t bootstrap de confiança* γ

$$\hat{\psi} \pm t_{(1+\gamma)/2}(n-1)\sqrt{\widehat{\mathrm{Var}}_{\hat{F}}(\hat{\psi})},$$

em que $t_{(1+\gamma)/2}(n-1)$ é o quantil $(1+\gamma)/2$ da distribuição $t(n-1)$. Outra possibilidade é calcular um *intervalo de confiança bootstrap percentil*[53], dado por

$$(\hat{\psi}_{(1-\gamma)/2}, \hat{\psi}_{(1+\gamma)/2}),$$

em que $\hat{\psi}_p$ denota o p-ésimo quantil empírico de $\hat{\psi}$ na amostra bootstrap[54] de tamanho m.

Note que, para serem aplicáveis, esses intervalos exigem que algumas condições sejam satisfeitas. Em particular, $\hat{\psi}$ deve ser pelo menos aproximadamente não viesado para $\psi(\theta)$, e a distribuição bootstrap deve ser aproximadamente normal. Olhando o gráfico da distribuição bootstrap na Figura 6.4.1, vemos que a mediana não tem uma distribuição bootstrap aproximadamente normal; portanto, esses intervalos não são aplicáveis à mediana.

Considere o exemplo a seguir.

Exemplo 6.4.3 — A Média 0,25-Aparada como Estimador da Média Populacional

Uma das virtudes da mediana amostral como estimador da média populacional é que ela não é afetada por valores extremos na amostra. Por outro lado, a mediana amostral descarta todos os valores dos dados, menos um ou dois, e assim parece estar descartando muita informação. Os estimadores conhecidos como médias aparadas podem ser vistos como

No original: *bootstrap percentile confidence interval*[53], *bootstrap sample*[54].

uma tentativa de manter as virtudes da mediana sem, ao mesmo tempo, descartar informação demais. Seja $\lfloor x \rfloor$ o maior inteiro menor ou igual a $x \in R^1$.

Definição 6.4.1

Para $\alpha \in [0, 1]$, uma *média α-aparada amostral* é dada por

$$\bar{x}_\alpha = \frac{1}{n - 2\lfloor \alpha n \rfloor} \sum_{i=\lfloor \alpha n \rfloor + 1}^{n - \lfloor \alpha n \rfloor} x_{(i)},$$

em que $x_{(i)}$ é a i-ésima estatística de ordem.

Assim, para uma média α-aparada amostral, descartamos (aproximadamente) αn dos menores valores dos dados e αn dos maiores, e calculamos a média dos $n - 2\alpha n$ valores que restam. Precisamos da função maior inteiro porque, em geral, αn não será um inteiro. Note que a média amostral corresponde a $\alpha = 0$ e a mediana amostral, a $\alpha = 0{,}5$.

Para os dados do Exemplo 6.4.1 e $\alpha = 0{,}25$, temos $(0{,}25)15 = 3{,}75$,* então descartamos as três menores e as três maiores observações, o que deixa os nove valores $-3{,}9; -3{,}5; -2{,}9; -2{,}0; -2{,}0; -1{,}7; -1{,}0; -0{,}6; -0{,}2$. A média desses nove valores dá $\hat{\psi} = \bar{x}_{0{,}25} = -1{,}97778$, que, notamos, é próxima tanto da mediana amostral quanto da média amostral.

Suponha agora que usamos uma média 0,25-aparada como estimador $\hat{\psi}$ de uma média populacional, quando acreditamos que a distribuição populacional é simétrica. Considere os dados do Exemplo 6.4.1 e suponha que geramos $m = 10^4$ amostras bootstrap. Traçamos um histograma dos 10^4 valores de $\hat{\psi}$ na Figura 6.4.2. Note que ele tem aparência bem normal; por isso, nos sentimos justificados em usar os intervalos de confiança associados ao bootstrap. Nesse caso, obtivemos

$$\sqrt{\widehat{\text{Var}}_{\hat{F}}(\hat{\psi})} = 0{,}7380,$$

de modo que o intervalo t bootstrap de confiança 0,95 para a média é dado por $-1{,}97778 + (2{,}14479)(0{,}7380) \simeq (-3{,}6; -0{,}4)$.† Ordenando a amostra bootstrap, obtemos o intervalo de confiança bootstrap percentil 0,95 $(-3{,}36667; -0{,}488889) \simeq (-3{,}4; -0{,}5)$, o que mostra que os dois intervalos são muito parecidos. ■

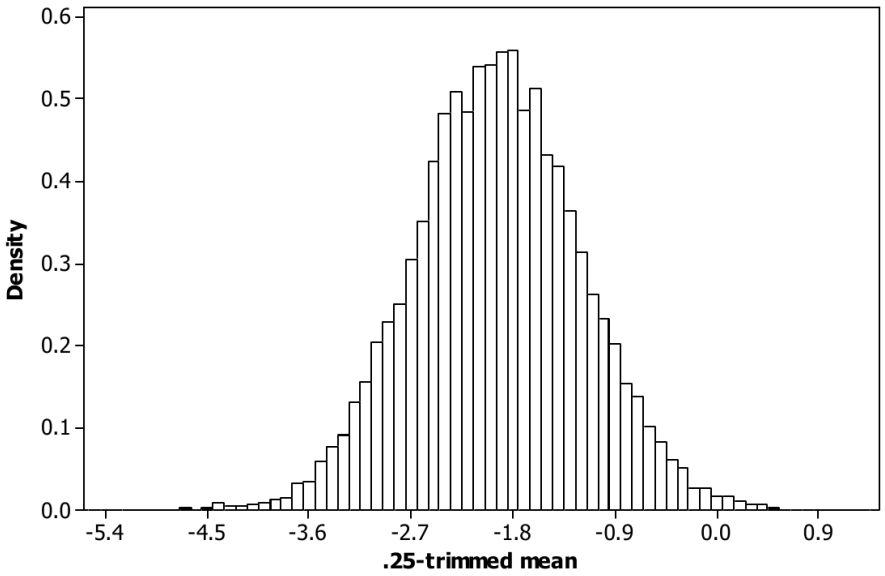


Figura 6.4.2: Um histograma de densidade de $m = 10^4$ médias 0,25-aparadas amostrais, cada uma obtida de uma amostra bootstrap de tamanho $n = 15$ dos dados do Exemplo 6.4.3

Mais detalhes sobre o bootstrap podem ser encontrados em *An Introduction to the Bootstrap*, de B. Efron e R. J. Tibshirani (Chapman and Hall, Nova York, 1993).

6.4.3 A Estatística do Sinal e Inferências sobre Quantis

Suponha que $\{P_\theta : \theta \in \mathbf{\Omega}\}$ seja o conjunto de todas as distribuições em R^1 cujas funções de distribuição associadas são contínuas. Suponha que queremos fazer inferências sobre um p-ésimo quantil de P_θ. Denotamos esse quantil por $x_p(\theta)$, de modo que, quando a função de distribuição associada a P_θ é denotada por F_θ, temos $p = F_\theta(x_p(\theta))$. Note que a continuidade implica que sempre existe uma solução em x de $p = F_\theta(x)$ e que $x_p(\theta)$ é a menor solução.

Lembre as definições e a discussão sobre a estimação dessas quantidades no Exemplo 5.5.2, com base numa amostra $(x_1, \ldots, x_n)$. Para simplificar, vamos nos restringir aos casos em que $p = i/n$ para algum $i \in \{1, \ldots, n\}$. Nesse caso, $\hat{x}_p = x_{(i)}$ é a estimativa natural de x_p.

Considere agora avaliar a evidência nos dados a respeito da hipótese $H_0 : x_p(\theta) = x_0$. Para testar essa hipótese, podemos usar a *estatística do teste do*

*Nota do tradutor. o original diz "Exemplo 6.4.1" aqui e no parágrafo seguinte, mas os dados ($n = 15$) são os do Exemplo 6.4.2.

†Nota do tradutor. o original traz "+"; pelo intervalo obtido, seria "±".

sinal[55], dada por $S = \sum_{i=1}^{n} I_{(-\infty,x_0]}(x_i)$. Assim, S é o número de valores amostrais menores ou iguais a x_0.

Note que, quando H_0 é verdadeira, $I_{(-\infty,x_0]}(x_1), \ldots, I_{(-\infty,x_0]}(x_n)$ é uma amostra da distribuição Bernoulli(p). Isso implica que, quando H_0 é verdadeira, $S \sim \text{Binomial}(n, p)$.

Portanto, podemos testar H_0 calculando o valor observado de S, denotado por S_o, e verificando se esse valor está numa região de baixa probabilidade da distribuição Binomial(n, p). Como a distribuição binomial é unimodal, as regiões de baixa probabilidade correspondem às caudas esquerda e direita dessa distribuição. Veja, por exemplo, a Figura 6.4.3, em que fizemos o gráfico da função de probabilidade de uma distribuição Binomial(20; 0,7).

O valor-p é então obtido calculando a probabilidade do conjunto

$$\left\{ i : \binom{n}{i} p^i (1-p)^{n-i} \leq \binom{n}{S_o} p^{S_o} (1-p)^{n-S_o} \right\} \tag{6.4.6}$$

com a distribuição de probabilidade Binomial(n, p). Essa é uma medida de quão longe, nas caudas, está o valor observado S_o (veja a Figura 6.4.3). Note que esse valor-p é completamente independente de θ e, portanto, é válido para o modelo inteiro. Tabelas de probabilidades binomiais (Tabela D.6 do Apêndice D), ou funções prontas disponíveis na maioria dos pacotes estatísticos, podem ser usadas para calcular esse valor-p.

Quando n é grande, temos, sob H_0,

$$Z = \frac{S - np}{\sqrt{np(1-p)}} \xrightarrow{D} N(0,1)$$

quando $n \to \infty$. Portanto, um valor-p aproximado é dado por

$$2\left\{1 - \Phi\left(\left|\frac{S_o - 0{,}5 - np}{\sqrt{np(1-p)}}\right|\right)\right\}$$

(como no Exemplo 6.3.11), em que substituímos S_o por $S_o - 0{,}5$ como correção de continuidade[56] (veja no Exemplo 4.4.9 a discussão sobre a correção de continuidade).

Um caso especial surge quando $p = 1/2$, isto é, quando fazemos inferências sobre uma mediana populacional desconhecida $x_{0,5}(\theta)$. Nesse caso, a distribuição de S sob H_0 é Binomial(n, 1/2). Como a Binomial(n, 1/2) é unimodal e simétrica em torno de $n/2$, (6.4.6) se torna

$$\{i : |S_o - n/2| \leq |i - n/2|\}.$$

No original: *sign test*[55], *correction for continuity*[56].

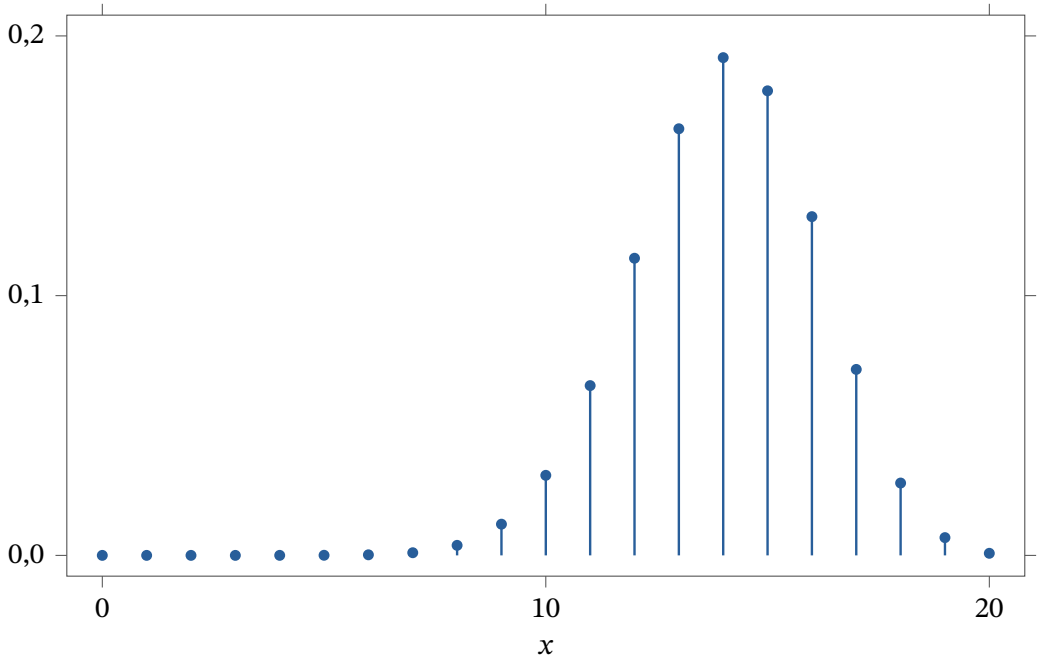


Figura 6.4.3: Gráfico da função de probabilidade da Binomial(20; 0,7).

Se quisermos um intervalo de confiança γ para $x_{0,5}(\theta)$, podemos usar a equivalência entre testes, nos quais sempre rejeitamos quando o valor-p é menor ou igual a $1-\gamma$, e intervalos de confiança γ (veja o Exemplo 6.3.12). Para isso, seja j o menor inteiro maior que $n/2$ que satisfaz

$$P(\{i : |i - n/2| \geq j - n/2\}) \leq 1 - \gamma, \tag{6.4.7}$$

em que P é a distribuição Binomial$(n, 1/2)$. Se $S \in \{i : |i - n/2| \geq j - n/2\}$, rejeitaremos $H_0 : x_{0,5}(\theta) = x_0$ ao nível $1-\gamma$, e não rejeitaremos em caso contrário. Isso leva ao intervalo de confiança γ, isto é, o conjunto de todos os valores $x_{0,5}$ tais que a hipótese nula $H_0 : x_{0,5}(\theta) = x_{0,5}$ não é rejeitada ao nível $1-\gamma$, que é igual a

$$\begin{aligned} C(x_1, \ldots, x_n) &= \left\{ x_0 : \left| \sum_{i=1}^{n} I_{(-\infty, x_0]}(x_i) - n/2 \right| < j - n/2 \right\} \\ &= \left\{ x_0 : n - j < \sum_{i=1}^{n} I_{(-\infty, x_0]}(x_i) < j \right\} = [x_{(n-j+1)}, x_{(j)}), \end{aligned} \tag{6.4.8}$$

porque, por exemplo, $n - j < \sum_{i=1}^{n} I_{(-\infty, x_0]}(x_i)$ se e somente se $x_0 \geq x_{(n-j+1)}$.

Exemplo 6.4.4 — Aplicação do Teste do Sinal

Suponha que temos a seguinte amostra de tamanho $n = 10$ de uma variável aleatória contínua X e queremos testar a hipótese $H_0 : x_{0,5}(\theta) = 0$.

0,44	−0,06	0,43	−0,16	−2,13
1,15	1,08	5,67	−4,97	0,11

O boxplot da Figura 6.4.4 indica que é muito improvável que essa amostra tenha vindo de uma distribuição normal, pois há duas observações extremas. Assim, é apropriado medir a posição da distribuição de X pela mediana.

Nesse caso, a mediana amostral (usando (5.5.4)) é dada por $(0{,}11 + 0{,}43)/2 = 0{,}27$. A estatística do sinal para a hipótese nula é dada por

$$S = \sum_{i=1}^{10} I_{(-\infty,0]}(x_i) = 4.$$

O valor-p é dado por

$$P(\{i : |4-5| \le |i-5|\}) = P(\{i : |i-5| \ge 1\}) = 1 - P(\{i : |i-5| < 1\})$$
$$= 1 - P(\{5\}) = 1 - \binom{10}{5}\left(\frac{1}{2}\right)^{10} = 1 - 0{,}24609 = 0{,}75391,$$

e não temos motivo para rejeitar a hipótese nula.

Suponha agora que queremos um intervalo de confiança 0,95 para a mediana. Usando um software (ou a Tabela D.6), calculamos

$$\binom{10}{5}\left(\frac{1}{2}\right)^{10} = 0{,}24609 \qquad \binom{10}{4}\left(\frac{1}{2}\right)^{10} = 0{,}20508$$
$$\binom{10}{3}\left(\frac{1}{2}\right)^{10} = 0{,}11719 \qquad \binom{10}{2}\left(\frac{1}{2}\right)^{10} = 4{,}3945 \times 10^{-2}$$
$$\binom{10}{1}\left(\frac{1}{2}\right)^{10} = 9{,}7656 \times 10^{-3} \quad \binom{10}{0}\left(\frac{1}{2}\right)^{10} = 9{,}7656 \times 10^{-4}.$$

Usaremos esses valores para calcular o valor de j em (6.4.7).

Podemos usar a simetria da distribuição Binomial$(10, 1/2)$ em torno de $n/2$ para calcular os valores de $P(\{i : |i - n/2| \ge j - n/2\})$ da seguinte maneira. Para $j = 10$, temos que (6.4.7) é igual a

$$P(\{i : |i-5| \ge 5\}) = P(\{0, 10\}) = 2\binom{10}{0}\left(\frac{1}{2}\right)^{10} = 1{,}9531 \times 10^{-3},$$

e note que $1{,}9531 \times 10^{-3} < 1 - 0{,}95 = 0{,}05$. Para $j = 9$, temos que (6.4.7) é igual a

$$P(\{i : |i-5| \ge 4\}) = P(\{0, 1, 9, 10\}) = 2\binom{10}{0}\left(\frac{1}{2}\right)^{10} + 2\binom{10}{1}\left(\frac{1}{2}\right)^{10}$$
$$= 2{,}1484 \times 10^{-2},$$

que também é menor que 0,05. Para $j = 8$, temos que (6.4.7) é igual a

$$\begin{aligned} P(\{i : |i-5| \geq 3\}) &= P(\{0,1,2,8,9,10\}) \\ &= 2\binom{10}{0}\left(\frac{1}{2}\right)^{10} + 2\binom{10}{1}\left(\frac{1}{2}\right)^{10} + 2\binom{10}{2}\left(\frac{1}{2}\right)^{10} \\ &= 0{,}10938, \end{aligned}$$

e esse valor é maior que 0,05. Portanto, o valor apropriado é $j = 9$, e um intervalo de confiança 0,95 para a mediana é dado por $[x_{(2)}, x_{(9)}) = [-0{,}16; 1{,}15)$.*

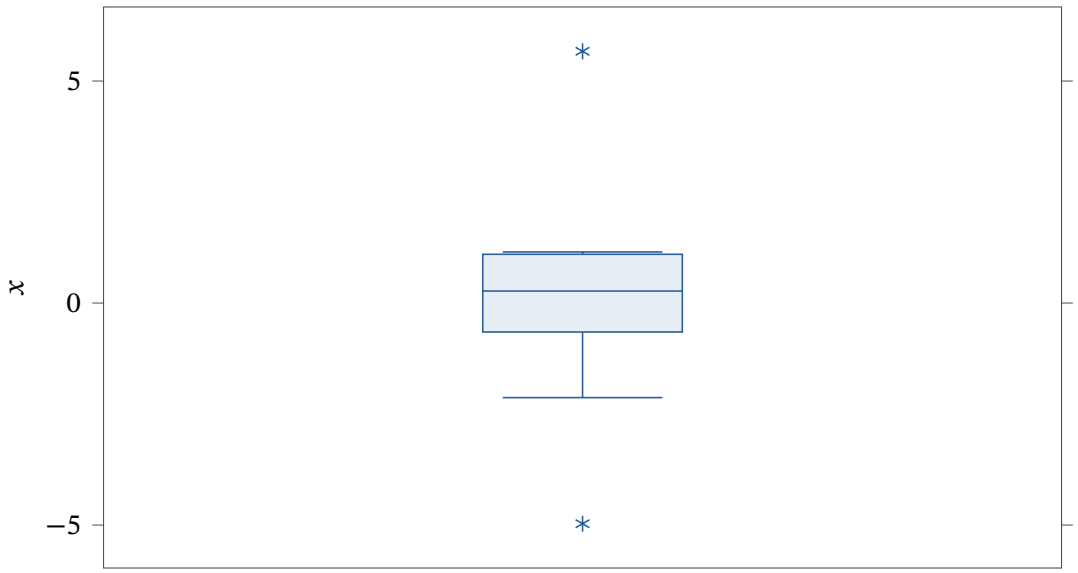


Figura 6.4.4: Boxplot dos dados do Exemplo 6.4.4.

Há muitos outros métodos livres de distribuição[57] para uma variedade de situações estatísticas. Embora alguns deles sejam discutidos nos problemas, deixamos um estudo aprofundado desses métodos para cursos mais avançados de estatística.

*Nota do tradutor. o original traz $[-0{,}16;\ 1{,}15)$; pelos dados ordenados, $x_{(2)} = -2{,}13$ ($-0{,}16$ é $x_{(3)}$), e o intervalo seria $[-2{,}13;\ 1{,}15)$.

No original: *distribution-free methods*[57].

Resumo da Seção 6.4

- Métodos de inferência estatística livres de distribuição são métodos apropriados quando sentimos que só podemos fazer suposições muito mínimas sobre a distribuição da qual estamos amostrando.
- O método dos momentos, o bootstrap e os métodos de inferência baseados na estatística do sinal são três métodos livres de distribuição aplicáveis em circunstâncias diferentes.

Exercícios

6.4.1 Suponha que obtivemos a amostra a seguir de uma distribuição da qual sabemos que tem os seis primeiros momentos. Determine um intervalo de confiança 0,95 aproximado para μ_3.

3,27	−1,24	3,97	2,25	3,47	−0,09	7,45	6,20	3,74	4,12
1,42	2,75	−1,48	4,97	8,00	3,26	0,15	−3,64	4,88	4,55

6.4.2 Determine o estimador pelo método dos momentos da variância populacional. Esse estimador é não viesado para a variância populacional? Justifique sua resposta.

6.4.3 (*Coeficiente de variação*) O coeficiente de variação de uma medição populacional com média não nula é dado por σ/μ, em que μ é a média populacional e σ é o desvio padrão populacional. Qual é a estimativa pelo método dos momentos do coeficiente de variação? Prove que o coeficiente de variação é invariante por mudanças de escala da distribuição, isto é, por transformações da forma $T(x) = cx$ com $c > 0$ constante. É essa invariância que faz do coeficiente de variação uma medida apropriada da variabilidade amostral em certos problemas, já que ele não depende das unidades que usamos para a medição.

6.4.4 No contexto descrito no Exercício 6.4.1, determine um intervalo de confiança 0,95 aproximado para $\exp(\mu_1)$.

6.4.5 Verifique que o terceiro momento de uma distribuição $N(\mu, \sigma^2)$ é dado por $\mu_3 = \mu^3 + 3\mu\sigma^2$. Como a distribuição normal é especificada pelos seus dois primeiros momentos, qualquer característica da distribuição normal pode ser estimada simplesmente substituindo as estimativas de máxima verossimilhança de μ e σ^2. Compare o estimador pelo método dos momentos de μ_3 com esse EMV plug-in, isto é, determine se eles são iguais ou não.

6.4.6 Suponha que temos os dados amostrais 1,48; 4,10; 2,02; 56,59; 2,98; 1,51; 76,49; 50,25; 43,52; 2,96. Considere-os uma amostra de uma distribuição normal com média e variância desconhecidas e avalie a hipótese de que a mediana populacional (que, nesse caso, é igual à média) é 3. Faça também um teste do sinal de que a mediana populacional é 3 e compare os resultados. Faça um boxplot desses dados. Ele apoia a suposição de que estamos amostrando de uma distribuição normal? Qual teste você acha mais apropriado? Justifique sua resposta.

6.4.7 Determine a função de distribuição empírica com base na amostra dada a seguir.

1,06	−1,28	0,40	1,36	−0,35
−1,42	0,44	−0,58	−0,24	−1,34
0,00	−1,02	−1,35	2,05	1,06
0,98	0,38	2,13	−0,03	−1,29

Usando a fda empírica, determine a mediana amostral[58], o primeiro e o terceiro quartis e a amplitude interquartil[59]. Qual é a sua estimativa de $F(2)$?

6.4.8 Suponha que você obtém a amostra de $n = 3$ valores distintos dada por 1, 2 e 3.

(a) Escreva todas as amostras bootstrap possíveis.

(b) Se você está aplicando o bootstrap à mediana amostral, quais são os valores possíveis da mediana amostral numa amostra bootstrap?

(c) Se você está aplicando o bootstrap à média amostral, quais são os valores possíveis da média amostral numa amostra bootstrap?

(d) O que você conclui sobre a distribuição bootstrap da mediana amostral em comparação com a distribuição bootstrap da média amostral?

6.4.9 Explique por que o teorema central do limite justifica dizer que a distribuição bootstrap da média amostral é aproximadamente normal quando n e m são grandes. Que resultado justifica a normalidade aproximada da distribuição bootstrap de uma função da média amostral sob certas condições?

6.4.10 Para os dados do Exercício 6.4.1, determine um intervalo de confiança 0,95 aproximado para a mediana populacional, supondo que a distribuição da qual estamos amostrando é simétrica, com primeiro e segundo momentos finitos. (Sugestão: use resultados para grandes amostras.)

No original: *sample median*[58], *interquartile range*[59].

6.4.11 Suponha que você tem uma amostra de n valores distintos e está interessado na distribuição bootstrap da *amplitude amostral*, dada por $x_{(n)} - x_{(1)}$. Qual é o número máximo de valores que essa estatística pode assumir no conjunto de todas as amostras bootstrap? Quais são o maior e o menor valor que a amplitude amostral pode assumir numa amostra bootstrap? Você acha que a distribuição bootstrap da amplitude amostral será aproximadamente normal? Justifique sua resposta.

6.4.12 Suponha que você obtém os dados 1,1; −1,0; 1,1; 3,1; 2,2 e 3,1. Quantas amostras bootstrap distintas existem?

Exercícios computacionais

6.4.13 Para os dados do Exercício 6.4.7, avalie a hipótese de que a mediana populacional é 0. Dê um intervalo de confiança 0,95 para a mediana populacional. Qual é a probabilidade de cobertura exata desse intervalo?

6.4.14 Para os dados do Exercício 6.4.7, avalie a hipótese de que o primeiro quartil da distribuição da qual estamos amostrando é −1,0.

6.4.15 Com um tamanho de amostra bootstrap $m = 1000$, use o bootstrap para estimar o MSE do EMV plug-in de μ_3 para a distribuição normal, usando os dados amostrais do Exercício 6.4.1. Determine se $m = 1000$ é uma amostra grande o bastante para resultados precisos.

6.4.16 Para os dados do Exercício 6.4.1, use o EMV plug-in para estimar o primeiro quartil de uma distribuição $N(\mu, \sigma^2)$. Use o bootstrap para estimar o MSE dessa estimativa para $m = 10^3$ e $m = 10^4$ (use (5.5.3) para calcular o primeiro quartil da distribuição empírica).

6.4.17 Para os dados do Exercício 6.4.1, use o EMV plug-in para estimar $F(3)$ para uma distribuição $N(\mu, \sigma^2)$. Use o bootstrap para estimar o MSE dessa estimativa para $m = 10^3$ e $m = 10^4$.

6.4.18 Para os dados do Exercício 6.4.1, construa um intervalo de confiança 0,95 para μ supondo que essa é uma amostra de uma distribuição $N(\mu, \sigma^2)$. Calcule também um intervalo de confiança 0,95 para μ baseado na estatística do sinal[60], um intervalo de confiança 0,95 bootstrap t e um intervalo de confiança 0,95 bootstrap percentil, usando $m = 10^3$ no bootstrap. Compare os quatro intervalos.

No original: *sign statistic*[60].

6.4.19 Para os dados do Exercício 6.4.1, use o EMV plug-in para estimar o primeiro *quintil*, isto é, $x_{0,2}$, de uma distribuição $N(\mu, \sigma^2)$. Faça um histograma de densidade como estimativa da distribuição bootstrap desse estimador para $m = 10^3$ e calcule um intervalo de confiança 0,95 bootstrap t para $x_{0,2}$, se você achar apropriado.

6.4.20 Para os dados do Exercício 6.4.1, use o EMV plug-in para estimar μ_3 de uma distribuição $N(\mu, \sigma^2)$. Faça um histograma de densidade como estimativa da distribuição bootstrap desse estimador para $m = 10^3$ e calcule um intervalo de confiança 0,95 bootstrap percentil para μ_3, se você achar apropriado.

Problemas

6.4.21 Prove que, quando $(x_1, \ldots, x_n)$ é uma amostra de valores distintos de uma distribuição em R^1, o i-ésimo momento da distribuição empírica em R^1 (isto é, a distribuição com fda dada por $\hat{F}$) é m_i.

6.4.22 Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição em R^1. Determine a forma geral do i-ésimo momento de $\hat{F}$, isto é, ao contrário do Problema 6.4.21, agora permitimos que vários dos valores dos dados sejam iguais.

6.4.23 (*Transformações estabilizadoras da variância*) Pelo teorema delta, temos que $\psi(M_1)$ é assintoticamente normal com média $\psi(\mu_1)$ e variância $(\psi'(\mu_1))^2\sigma^2/n$ quando ψ é continuamente diferenciável, $\psi'(\mu_1) \neq 0$ e M_1 é assintoticamente normal com média μ_1 e variância σ^2/n. Em algumas aplicações, é importante escolher a transformação ψ de modo que a variância assintótica não dependa da média μ_1, isto é, que $(\psi'(\mu_1))^2\sigma^2$ seja constante quando μ_1 varia (note que σ^2 pode mudar quando μ_1 muda). Essas transformações são conhecidas como transformações estabilizadoras da variância.

(a) Se estamos amostrando de uma distribuição Poisson(λ), mostre que $\psi(x) = \sqrt{x}$ é estabilizadora da variância.

(b) Se estamos amostrando de uma distribuição Bernoulli(θ), mostre que $\psi(x) = \arcsin\sqrt{x}$ é estabilizadora da variância.

(c) Se estamos amostrando de uma distribuição em $(0, \infty)$ cuja variância é proporcional ao quadrado da sua média (como a distribuição Gama(α, β)), mostre que $\psi(x) = \ln(x)$ é estabilizadora da variância.

Desafios

6.4.24 Suponha que X tem uma distribuição absolutamente contínua[61] em R^1 com densidade f simétrica em torno da sua mediana. Supondo que a mediana é 0, prove que $|X|$ e

$$\operatorname{sgn}(X) = \begin{cases} -1 & x < 0 \\ 0 & x = 0 \\ 1 & x > 0 \end{cases}$$

são independentes, com $|X|$ tendo densidade $2f$ e $\operatorname{sgn}(X)$ uniformemente distribuída em $\{-1, 1\}$.

6.4.25 (*Estatística dos desvios com sinal de Fisher*) Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição absolutamente contínua em R^1 com densidade simétrica em torno da sua mediana. Suponha que queremos avaliar a hipótese $H_0 : x_{0,5}(\theta) = x_0$.

Uma possibilidade para isso é usar o teste dos desvios com sinal de Fisher, baseado na estatística S^+. O valor observado de S^+ é dado por $S_o^+ = \sum_{i=1}^n |x_i - x_0| \operatorname{sgn}(x_i - x_0)$. Avaliamos então H_0 comparando S_o^+ com a distribuição condicional[62] de S^+ dados os desvios absolutos $|x_1 - x_0|, \ldots, |x_n - x_0|$. Se um valor S_o^+ ocorre perto do menor ou do maior valor possível de S^+ sob essa distribuição condicional, afirmamos que temos evidência contra H_0. Medimos isso calculando o valor-p dado pela probabilidade condicional[63] de obter um valor tão longe do centro da distribuição condicional de S^+, ou mais longe, usando a média condicional como centro. Este é um exemplo de *teste de aleatorização*, já que a distribuição da estatística de teste é determinada modificando aleatoriamente os dados observados (neste caso, trocando aleatoriamente os sinais dos desvios dos x_i em relação a x_0).

(a) Prove que $S_o^+ = n(\bar{x} - x_0)$.

(b) Prove que o valor-p descrito acima não depende de qual distribuição do modelo é aquela da qual estamos amostrando. Prove que a média condicional de S^+ é 0 e que a distribuição condicional de S^+ é simétrica em torno desse valor.

(c) Use a estatística do teste dos desvios com sinal de Fisher para avaliar a hipótese $H_0 : x_{0,5}(\theta) = 2$ quando os dados são 2,2; 1,5; 3,4; 0,4; 5,3; 4,3; 2,1, declarando os resultados estatisticamente significativos se o valor-p

No original: *absolutely continuous*[61], *conditional distribution*[62], *conditional probability*[63].

for menor ou igual a 0,05. (Sugestão: com base nos resultados obtidos no item (b), basta calcular probabilidades para os valores extremos de S^+.)

(d) Mostre que usar a estatística do teste dos desvios com sinal de Fisher para avaliar a hipótese $H_0 : x_{0,5}(\theta) = x_0$ é equivalente ao seguinte procedimento aleatorizado de avaliação de hipóteses baseado na estatística do teste t. Para isso, calculamos a distribuição condicional de

$$T = \frac{(\bar{X} - x_0)}{S/\sqrt{n}}$$

quando os $|X_i - x_0| = |x_i - x_0|$ estão fixados e os $\text{sgn}(X_i - x_0)$ são i.i.d. uniformes em $\{-1, 1\}$. Compare o valor observado da estatística t com essa distribuição, como fizemos para a estatística do teste dos desvios com sinal de Fisher. (Sugestão: mostre que $\sum_{i=1}^{n}(x_i - \bar{x})^2 = \sum_{i=1}^{n}(x_i - x_0)^2 - n(\bar{x} - x_0)^2$ e que valores absolutos grandes de T correspondem a valores absolutos grandes de S^+.)

6.5 Assintótica do EMV (Avançado)

Como vimos nos Exemplos 6.3.7 e 6.3.11, implementar procedimentos amostrais exatos baseados no EMV pode ser difícil. Naqueles exemplos, como o EMV era a média amostral e podíamos usar o teorema central do limite, a teoria de grandes amostras nos permitiu obter procedimentos aproximados. Na verdade, existe uma teoria geral de grandes amostras para o EMV que nos permite obter inferências amostrais aproximadas. Esse é o conteúdo desta seção. Os resultados que desenvolvemos são todos para o caso em que θ é unidimensional. Resultados semelhantes existem para os problemas de dimensão maior, mas os deixamos para um curso posterior.

Na Seção 6.3, a questão básica era a necessidade de medir a precisão do EMV. Uma abordagem é traçar o gráfico da verossimilhança e examinar quão concentrada ela está em torno do seu pico, com uma verossimilhança mais concentrada indicando maior precisão do EMV. Há vários problemas com isso. Em particular, a aparência da verossimilhança depende muito de como escolhemos as escalas dos eixos. Com escolhas apropriadas, podemos fazer uma verossimilhança parecer tão concentrada ou tão difusa quanto quisermos. Além disso, quando θ tem mais de duas dimensões, não conseguimos nem traçar o gráfico da verossimilhança. Uma solução, quando a verossimilhança é uma função suave de θ, é calcular uma medida numérica de quão concentrada

a log-verossimilhança está no seu pico. A quantidade normalmente usada para isso é chamada de informação de Fisher observada[64].

Definição 6.5.1

A *informação de Fisher observada* é dada por

$$\hat{I}(s) = -\left.\frac{\partial^2 l(\theta \mid s)}{\partial \theta^2}\right|_{\theta=\hat{\theta}(s)}, \tag{6.5.1}$$

em que $\hat{\theta}(s)$ é o EMV.

Quanto maior for a informação de Fisher observada, mais pontiaguda é a função de verossimilhança no seu valor máximo. Vamos mostrar que a informação de Fisher observada estima uma quantidade de importância considerável na inferência estatística.

Suponha que a resposta X seja real, que θ seja real e que o modelo $\{f_\theta : \theta \in \mathbf{\Omega}\}$ satisfaça as seguintes condições de regularidade:

$$\frac{\partial^2 \ln f_\theta(x)}{\partial \theta^2} \text{ existe para cada } x, \tag{6.5.2}$$

$$E_\theta(S(\theta \mid X)) = \int_{-\infty}^{\infty} \frac{\partial \ln f_\theta(x)}{\partial \theta} f_\theta(x)\, dx = 0, \tag{6.5.3}$$

$$\int_{-\infty}^{\infty} \frac{\partial}{\partial \theta}\left\{\frac{\partial \ln f_\theta(x)}{\partial \theta} f_\theta(x)\right\} dx = 0, \tag{6.5.4}$$

e

$$\int_{-\infty}^{\infty} \left|\frac{\partial^2 \ln f_\theta(x)}{\partial \theta^2}\right| f_\theta(x)\, dx < \infty. \tag{6.5.5}$$

Observe que temos

$$\frac{\partial f_\theta(x)}{\partial \theta} = \frac{\partial \ln f_\theta(x)}{\partial \theta} f_\theta(x),$$

de modo que podemos escrever (6.5.3), de forma equivalente, como

$$\int_{-\infty}^{\infty} \frac{\partial f_\theta(x)}{\partial \theta}\, dx = 0.$$

No original: *observed Fisher information*[64].

Observe também que (6.5.4) pode ser escrita como*

$$\begin{aligned} 0 &= \int_{-\infty}^{\infty} \frac{\partial}{\partial\theta}\left\{\frac{\partial l(\theta \mid x)}{\partial\theta} f_\theta(x)\right\} dx \\ &= \int_{-\infty}^{\infty} \left\{\frac{\partial^2 l(\theta \mid x)}{\partial\theta^2} + \left(\frac{\partial l(\theta \mid x)}{\partial\theta}\right)^2\right\} f_\theta(x)\, dx \\ &= \int_{-\infty}^{\infty} \left\{\frac{\partial^2 l(\theta \mid x)}{\partial\theta^2} + S^2(\theta \mid x)\right\} f_\theta(x)\, dx = E_\theta\left(\frac{\partial^2 l(\theta \mid x)}{\partial\theta^2} + S^2(\theta \mid X)\right). \end{aligned}$$

Isso, junto com (6.5.3) e (6.5.5), implica que podemos escrever (6.5.4), de forma equivalente, como

$$\mathrm{Var}_\theta(S(\theta \mid X)) = E_\theta(S^2(\theta \mid X)) = E_\theta\left(-\frac{\partial^2}{\partial\theta^2} l(\theta \mid X)\right).$$

Damos um nome à quantidade da esquerda.

Definição 6.5.2

A função $I(\theta) = \mathrm{Var}_\theta(S(\theta \mid X))$ é chamada de *informação de Fisher* do modelo.

O que desenvolvemos acima demonstrou o seguinte resultado.

Teorema 6.5.1

Se (6.5.2) e (6.5.3) forem satisfeitas, então $E_\theta(S(\theta \mid X)) = 0$. Se, além disso, (6.5.4) e (6.5.5) forem satisfeitas, então

$$I(\theta) = \mathrm{Var}_\theta(S(\theta \mid X)) = E_\theta\left(-\frac{\partial^2 l(\theta \mid X)}{\partial\theta^2}\right).$$

Agora vemos por que $\hat{I}$ é chamada de informação de Fisher observada: ela é uma estimativa natural da informação de Fisher[65] no valor verdadeiro θ. Observamos que há outra estimativa natural da informação de Fisher no valor verdadeiro, dada por $I(\hat{\theta})$. Chamamos essa estimativa de *informação de Fisher plug-in*.

Quando temos uma amostra $(x_1, \ldots, x_n)$ de f_θ, então

$$S(\theta \mid x_1, \ldots, x_n) = \frac{\partial}{\partial\theta} \ln \prod_{i=1}^{n} f_\theta(x_i) = \sum_{i=1}^{n} \frac{\partial \ln f_\theta(x_i)}{\partial\theta} = \sum_{i=1}^{n} S(\theta \mid x_i).$$

*Nota do tradutor. Na última linha, o original traz $l(\theta \mid x)$ com x minúsculo dentro de E_θ; pela conta seria $l(\theta \mid X)$.

No original: *Fisher information*[65].

Assim, se (6.5.3) vale para o modelo básico, então $E_\theta(S(\theta \mid X_1, \ldots, X_n)) = 0$ e (6.5.3) também vale para o modelo amostral[66]. Além disso, se (6.5.4) vale para o modelo básico, então

$$\begin{aligned} 0 &= \sum_{i=1}^{n} E_\theta\left(\frac{\partial^2}{\partial\theta^2} \ln f_\theta(X_i)\right) + \sum_{i=1}^{n} E_\theta(S^2(\theta \mid X_i)) \\ &= E_\theta\left(\frac{\partial^2}{\partial\theta^2} l(\theta \mid X_1, \ldots, X_n)\right) + \mathrm{Var}_\theta(S(\theta \mid X_1, \ldots, X_n)), \end{aligned}$$

o que implica

$$\mathrm{Var}_\theta(S(\theta \mid X_1, \ldots, X_n)) = -E_\theta\left(\frac{\partial^2}{\partial\theta^2} l(\theta \mid X_1, \ldots, X_n)\right) = nI(\theta),$$

porque $l(\theta \mid x_1, \ldots, x_n) = \sum_{i=1}^{n} \ln f_\theta(x_i)$. Portanto, (6.5.4) também vale para o modelo amostral, e a informação de Fisher do modelo amostral é dada pelo tamanho da amostra vezes a informação de Fisher do modelo básico. Estabelecemos o seguinte resultado.

Corolário 6.5.1

Sob amostragem i.i.d. de um modelo com informação de Fisher $I(\theta)$, a informação de Fisher para uma amostra de tamanho n é dada por $nI(\theta)$.

As condições necessárias para que o Teorema 6.5.1 se aplique não valem em geral e precisam ser verificadas em cada exemplo. Há, porém, muitos modelos em que essas condições valem.

Exemplo 6.5.1 — Inexistência da Informação de Fisher

Se $X \sim U[0, \theta]$, então $f_\theta(x) = \theta^{-1} I_{[0,\theta]}(x)$, que não é derivável em $\theta = x$ para nenhum x. De fato, se ignorássemos a falta de derivabilidade em $\theta = x$ e escrevêssemos

$$\frac{\partial f_\theta(x)}{\partial\theta} = -\frac{1}{\theta^2} I_{[0,\theta]}(x),$$

então

$$\int_{-\infty}^{\infty} \frac{\partial f_\theta(x)}{\partial\theta}\, dx = -\int_{-\infty}^{\infty} \frac{1}{\theta^2} I_{[0,\theta]}(x)\, dx = -\frac{1}{\theta} \neq 0.$$

Portanto, não podemos definir a informação de Fisher para esse modelo. ■

No original: *sampling model*[66].

Exemplo 6.5.2 — Normal de Locação

Suponha que temos uma amostra $(x_1, \dots, x_n)$ de uma distribuição $N(\theta, \sigma_0^2)$, em que $\theta \in R^1$ é desconhecido e σ_0^2 é conhecido. Vimos no Exemplo 6.2.2 que

$$S(\theta \mid x_1, \dots, x_n) = \frac{n}{\sigma_0^2}(\bar{x} - \theta)$$

e, portanto,

$$\frac{\partial^2}{\partial \theta^2} l(\theta \mid x_1, \dots, x_n) = -\frac{n}{\sigma_0^2},$$
$$nI(\theta) = E_\theta\left(-\frac{\partial^2}{\partial \theta^2} l(\theta \mid X_1, \dots, X_n)\right) = \frac{n}{\sigma_0^2}.$$

Também determinamos no Exemplo 6.2.2 que o EMV é dado por $\hat{\theta}(x_1, \dots, x_n) = \bar{x}$. Então a informação de Fisher plug-in é

$$nI(\bar{x}) = \frac{n}{\sigma_0^2},$$

enquanto a informação de Fisher observada é

$$\hat{I}(x_1, \dots, x_n) = -\left.\frac{\partial^2 l(\theta \mid x_1, \dots, x_n)}{\partial \theta^2}\right|_{\theta=\bar{x}} = \frac{n}{\sigma_0^2}.$$

Nesse caso, não há necessidade de estimar a informação de Fisher, mas é reconfortante que nossas duas estimativas deem o valor exato. ■

Enunciamos agora, sem demonstração, alguns teoremas sobre o comportamento do EMV em grandes amostras, sob amostragem repetida do modelo. Primeiro, temos um resultado sobre a consistência do EMV como estimador do valor verdadeiro de θ.

Teorema 6.5.2

Sob condições de regularidade (como as especificadas acima) para o modelo $\{f_\theta : \theta \in \mathbf{\Omega}\}$, o EMV $\hat{\theta}$ existe quase certamente e $\hat{\theta} \xrightarrow{\text{q.c.}} \theta$ quando $n \to \infty$.

Demonstração. Veja *Approximation Theorems of Mathematical Statistics*, de R. J. Serfling (John Wiley & Sons, Nova York, 1980), para a demonstração deste resultado. ■

Vemos que o Teorema 6.5.2 funciona como uma espécie de lei forte para o EMV. Acontece também que, quando o tamanho da amostra é grande, a distribuição

amostral do EMV é aproximadamente normal.

Teorema 6.5.3

Sob condições de regularidade (como as especificadas acima) para o modelo $\{f_\theta : \theta \in \mathbf{\Omega}\}$, temos $(nI(\theta))^{1/2}(\hat{\theta} - \theta) \xrightarrow{D} N(0,1)$ quando $n \to \infty$.

Demonstração. Veja *Approximation Theorems of Mathematical Statistics*, de R. J. Serfling (John Wiley & Sons, Nova York, 1980), para a demonstração deste resultado. ■

Vemos que o Teorema 6.5.3 funciona como uma espécie de teorema central do limite para o EMV. Para tornar esse resultado plenamente útil para a inferência, precisamos do seguinte corolário desse teorema.

Corolário 6.5.2

Quando I é uma função contínua de θ, então

$$(nI(\hat{\theta}))^{1/2}(\hat{\theta} - \theta) \xrightarrow{D} N(0,1).$$

No Corolário 6.5.2, estimamos a informação de Fisher $I(\theta)$ pela estimativa de Fisher plug-in $I(\hat{\theta})$. Muitas vezes, é muito difícil calcular a função I. Nesse caso, estimamos $nI(\theta)$ pela informação de Fisher observada $\hat{I}(x_1, \ldots, x_n)$. Um resultado como o Corolário 6.5.2 continua valendo nesse caso.

A partir do Corolário 6.5.2, podemos construir métodos de inferência aproximados para grandes amostras baseados no EMV. Por exemplo, o erro padrão aproximado do EMV é

$$(nI(\hat{\theta}))^{-1/2}.$$

Um intervalo de confiança γ aproximado é dado por

$$\hat{\theta} \pm (nI(\hat{\theta}))^{-1/2} z_{(1+\gamma)/2}.$$

Por fim, se quisermos avaliar a hipótese $H_0 : \theta = \theta_0$, podemos fazê-lo calculando o valor-p aproximado

$$2\left\{1 - \Phi\left((nI(\theta_0))^{1/2} |\hat{\theta} - \theta_0|\right)\right\}.$$

Observe que estamos usando o Teorema 6.5.3 para o valor-p, e não o Corolário 6.5.2, pois, quando H_0 é verdadeira, sabemos que a variância assintótica do EMV é $(nI(\theta_0))^{-1}$. Assim, não precisamos estimar essa quantidade.

Quando calcular I é difícil, podemos substituir $nI(\hat{\theta})$ por $\hat{I}(x_1, \ldots, x_n)$ nas expressões acima do intervalo de confiança e do valor-p. Agora vemos com muita clareza a importância da informação observada. Naturalmente, à medida que passamos de $nI(\theta)$ para $nI(\hat{\theta})$ e depois para $\hat{I}(x_1, \ldots, x_n)$, esperamos precisar de tamanhos de amostra n maiores para que a aproximação normal seja precisa.

Consideramos alguns exemplos.

Exemplo 6.5.3 — Modelo Normal de Locação

Usando a informação de Fisher obtida no Exemplo 6.5.2, o intervalo de confiança γ aproximado baseado no EMV é

$$\hat{\theta} \pm (nI(\hat{\theta}))^{-1/2} z_{(1+\gamma)/2} = \bar{x} \pm (\sigma_0/\sqrt{n})\, z_{(1+\gamma)/2}.$$

Esse é exatamente o intervalo de confiança z obtido no Exemplo 6.3.6. Em vez de ser um intervalo de confiança γ aproximado, a cobertura é exata nesse caso. Da mesma forma, o valor-p aproximado corresponde ao teste z, e o valor-p é exato. ■

Exemplo 6.5.4 — Modelo Bernoulli

Suponha que $(x_1, \ldots, x_n)$ seja uma amostra de uma distribuição Bernoulli(θ), em que $\theta \in [0, 1]$ é desconhecido. A função de verossimilhança é dada por

$$L(\theta \mid x_1, \ldots, x_n) = \theta^{n\bar{x}} (1 - \theta)^{n(1-\bar{x})},$$

e o EMV de θ é $\bar{x}$. A log-verossimilhança é

$$l(\theta \mid x_1, \ldots, x_n) = n\bar{x} \ln \theta + n(1 - \bar{x}) \ln(1 - \theta),$$

a função escore é dada por

$$S(\theta \mid x_1, \ldots, x_n) = \frac{n\bar{x}}{\theta} - \frac{n(1 - \bar{x})}{1 - \theta},$$

e

$$\frac{\partial}{\partial \theta} S(\theta \mid x_1, \ldots, x_n) = -\frac{n\bar{x}}{\theta^2} - \frac{n(1 - \bar{x})}{(1 - \theta)^2}.$$

Portanto, a informação de Fisher para a amostra é

$$\begin{aligned} nI(\theta) &= E_\theta \left(-\frac{\partial}{\partial \theta} S(\theta \mid X_1, \ldots, X_n) \right) \\ &= E_\theta \left(\frac{n\bar{X}}{\theta^2} + \frac{n(1 - \bar{X})}{(1 - \theta)^2} \right) = \frac{n}{\theta(1 - \theta)}, \end{aligned}$$

e a informação de Fisher plug-in é

$$nI(\bar{x}) = \frac{n}{\bar{x}(1-\bar{x})}.$$

Observe que, nesse caso, a informação de Fisher plug-in é igual à informação de Fisher observada.

Assim, um intervalo de confiança γ aproximado é dado por

$$\hat{\theta} \pm (nI(\hat{\theta}))^{-1/2} z_{(1+\gamma)/2} = \bar{x} \pm z_{(1+\gamma)/2} \sqrt{\bar{x}(1-\bar{x})/n},$$

que é exatamente o intervalo obtido no Exemplo 6.3.7 usando considerações de grandes amostras baseadas no teorema central do limite. Da mesma forma, obtemos o mesmo valor-p do Exemplo 6.3.11 ao testar $H_0 : \theta = \theta_0$. ■

Exemplo 6.5.5 — Modelo Poisson

Suponha que $(x_1, \ldots, x_n)$ seja uma amostra de uma distribuição Poisson(λ), em que $\lambda > 0$ é desconhecido. A função de verossimilhança é dada por

$$L(\lambda \mid x_1, \ldots, x_n) = \lambda^{n\bar{x}} e^{-n\lambda}.$$

A log-verossimilhança é

$$l(\lambda \mid x_1, \ldots, x_n) = n\bar{x} \ln \lambda - n\lambda,$$

a função escore é dada por

$$S(\lambda \mid x_1, \ldots, x_n) = \frac{n\bar{x}}{\lambda} - n,$$

e

$$\frac{\partial}{\partial \lambda} S(\lambda \mid x_1, \ldots, x_n) = -\frac{n\bar{x}}{\lambda^2}.$$

Daí deduzimos que o EMV de λ é $\hat{\lambda} = \bar{x}$.

Portanto, a informação de Fisher para a amostra é

$$nI(\lambda) = E_\lambda\left(-\frac{\partial}{\partial \lambda} S(\lambda \mid X_1, \ldots, X_n)\right) = E_\lambda\left(\frac{n\bar{X}}{\lambda^2}\right) = \frac{n}{\lambda},$$

e a informação de Fisher plug-in é

$$nI(\bar{x}) = \frac{n}{\bar{x}}.$$

Observe que, nesse caso, a informação de Fisher plug-in é igual à informação de Fisher observada.

Assim, um intervalo de confiança γ aproximado é dado por

$$\hat{\lambda} \pm (nI(\hat{\lambda}))^{-1/2} z_{(1+\gamma)/2} = \bar{x} \pm z_{(1+\gamma)/2} \sqrt{\bar{x}/n}.$$

Da mesma forma, o valor-p aproximado para testar $H_0 : \lambda = \lambda_0$ é dado por

$$2\left\{1 - \Phi\left((nI(\lambda_0))^{1/2} |\hat{\lambda} - \lambda_0|\right)\right\} = 2\left\{1 - \Phi\left((n/\lambda_0)^{1/2} |\bar{x} - \lambda_0|\right)\right\}.$$

Observe que usamos a informação de Fisher avaliada em λ_0 para esse teste. ■

Resumo da Seção 6.5

- Sob condições de regularidade sobre o modelo estatístico com parâmetro θ, podemos definir a informação de Fisher $I(\theta)$ do modelo.
- Sob condições de regularidade sobre o modelo estatístico, pode-se provar que, quando θ é o valor verdadeiro do parâmetro, o EMV é consistente para θ e tem distribuição aproximadamente normal, com média dada por θ e variância dada por $(nI(\theta))^{-1}$.
- A informação de Fisher $I(\theta)$ pode ser estimada substituindo-se o EMV (plug-in) ou usando a informação de Fisher observada. Essas estimativas levam a inferências sobre θ úteis na prática em muitos problemas.

Exercícios

6.5.1 Se $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição $N(\mu_0, \sigma^2)$, em que μ_0 é conhecido e $\sigma^2 \in (0, \infty)$ é desconhecido, determine a informação de Fisher.

6.5.2 Se $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição Gama(α_0, θ), em que α_0 é conhecido e $\theta \in (0, \infty)$ é desconhecido, determine a informação de Fisher.

6.5.3 Se $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição Pareto(α) (veja o Exercício 6.2.9), em que $\alpha > 0$ é desconhecido, determine a informação de Fisher.

6.5.4 Suponha que o número de chamadas que chegam a uma central de atendimento telefônico durante uma certa hora do dia seja Poisson(λ), em que

$\lambda \in (0, \infty)$ é desconhecido. O número de chamadas efetivamente recebidas nessa hora foi registrado durante 20 dias, e foram obtidos os seguintes dados.

9	10	8	12	11	12	5	13	9	9
7	5	16	13	9	5	13	8	9	10

Construa um intervalo de confiança 0,95 aproximado para λ. Avalie a hipótese de que essa é uma amostra de uma distribuição Poisson(11). Se você vai decidir que a hipótese é falsa quando o valor-p for menor que 0,05, calcule um poder aproximado para esse procedimento quando $\lambda = 10$.

6.5.5 Suponha que se saiba que os tempos de vida, em horas, das lâmpadas de um processo de fabricação têm distribuição Gama$(2, \theta)$, em que $\theta \in (0, \infty)$ é desconhecido. Foi retirada uma amostra aleatória de 27 lâmpadas, e seus tempos de vida foram medidos, obtendo-se os seguintes dados.

336,87	2750,71	2199,44	292,99	1835,55	1385,36	2690,52
710,64	2162,01	1856,47	2225,68	3524,23	2618,51	361,68
979,54	2159,18	1908,94	1397,96	914,41	1548,48	1801,84
1016,16	1666,71	1196,42	1225,68	2422,53	753,24	

Determine um intervalo de confiança 0,90 aproximado para θ.

6.5.6 Repita a análise do Exercício 6.5.5, mas agora suponha que os tempos de vida têm distribuição Gama$(1, \theta)$. Comente as diferenças entre as duas análises.

6.5.7 Suponha que, para uma determinada população, as rendas (medidas em milhares de dólares) acima de US$ 20 mil possam ser supostas com distribuição Pareto(α), em que $\alpha > 0$ é desconhecido. Uma amostra de tamanho 20 é retirada da população, e os seguintes dados são obtidos.

21,265	20,857	21,090	20,047	20,019	32,509	21,622	20,693
20,109	23,182	21,199	20,035	20,084	20,038	22,054	20,190
20,488	20,456	20,066	20,302				

Construa um intervalo de confiança 0,95 aproximado para α. Avalie a hipótese de que a renda média nessa população é US$ 25 mil.

6.5.8 Suponha que $(x_1, \ldots, x_n)$ seja uma amostra de uma distribuição Exponencial(θ). Construa um intervalo de confiança γ unilateral à esquerda aproximado para θ. (Veja o Problema 6.3.25.)

6.5.9 Suponha que $(x_1, \ldots, x_n)$ seja uma amostra de uma distribuição Geométrica(θ). Construa um intervalo de confiança γ unilateral à esquerda aproximado para θ. (Veja o Problema 6.3.25.)

6.5.10 Suponha que $(x_1, \ldots, x_n)$ seja uma amostra de uma distribuição Binomial Negativa(r, θ). Construa um intervalo de confiança γ unilateral à esquerda aproximado para θ. (Veja o Problema 6.3.25.)

Problemas

6.5.11 No Exercício 6.5.1, verifique que (6.5.2), (6.5.3), (6.5.4) e (6.5.5) são satisfeitas.

6.5.12 No Exercício 6.5.2, verifique que (6.5.2), (6.5.3), (6.5.4) e (6.5.5) são satisfeitas.

6.5.13 No Exercício 6.5.3, verifique que (6.5.2), (6.5.3), (6.5.4) e (6.5.5) são satisfeitas.

6.5.14 Suponha que a amostragem do modelo $\{f_\theta : \theta \in \mathbf{\Omega}\}$ satisfaça (6.5.2), (6.5.3), (6.5.4) e (6.5.5). Prove que $n^{-1}\hat{I} \xrightarrow{\text{q.c.}} I(\theta)$ quando $n \to \infty$.

6.5.15 (MV) Quando $\theta = (\theta_1, \theta_2)$, então, sob condições de regularidade apropriadas para o modelo $\{f_\theta : \theta \in \mathbf{\Omega}\}$, a *matriz de informação de Fisher* é definida por

$$I(\theta) = \begin{pmatrix} E_\theta\left(-\frac{\partial^2}{\partial\theta_1^2} l(\theta \mid X)\right) & E_\theta\left(-\frac{\partial^2}{\partial\theta_1\partial\theta_2} l(\theta \mid X)\right) \\ E_\theta\left(-\frac{\partial^2}{\partial\theta_1\partial\theta_2} l(\theta \mid X)\right) & E_\theta\left(-\frac{\partial^2}{\partial\theta_2^2} l(\theta \mid X)\right) \end{pmatrix}.$$

Se $(X_1, X_2, X_3) \sim$ Multinomial$(1, \theta_1, \theta_2, \theta_3)$ (Exemplo 6.1.5), determine a informação de Fisher para esse modelo. Lembre que $\theta_3 = 1 - \theta_1 - \theta_2$ e, portanto, é determinado por (θ_1, θ_2).

6.5.16 (MV) Generalize o Problema 6.5.15 para o caso em que

$$(X_1, \ldots, X_k) \sim \text{Multinomial}(1, \theta_1, \ldots, \theta_k).$$

6.5.17 (MV) Usando a definição da matriz de informação de Fisher do Exercício 6.5.15, determine a informação de Fisher para o modelo Normal Bivariada$(\mu_1, \mu_2, 1, 1, 0)$, em que $\mu_1, \mu_2 \in R^1$ são desconhecidos.

6.5.18 (MV) Estendendo a definição do Exercício 6.5.15 para o caso tridimensional, determine a informação de Fisher para o modelo Normal Bivariada$(\mu_1, \mu_2, \sigma^2, \sigma^2, 0)$, em que $\mu_1, \mu_2 \in R^1$ e $\sigma^2 > 0$ são desconhecidos.

Desafios

6.5.19 Suponha que o modelo $\{f_\theta : \theta \in \mathbf{\Omega}\}$ satisfaça (6.5.2), (6.5.3), (6.5.4) e (6.5.5) e tenha informação de Fisher $I(\theta)$. Se $\Psi : \mathbf{\Omega} \to R^1$ é injetora e Ψ e Ψ^{-1} são continuamente deriváveis, então, tomando $\Upsilon = \{\Psi(\theta) : \theta \in \mathbf{\Omega}\}$, prove que o modelo dado por $\{g_\psi : \psi \in \Upsilon\}$ satisfaz as condições de regularidade e que sua informação de Fisher em ψ é dada por $I(\Psi^{-1}(\psi))((\Psi^{-1})'(\psi))^2$.

Tópicos para discussão

6.5.20 Os métodos de inferência pelo método dos momentos discutidos na Seção 6.4.1 são, essencialmente, métodos de grandes amostras baseados no teorema central do limite. Os métodos de grandes amostras da Seção 6.5 se baseiam na forma da função de verossimilhança. Quais métodos você acha que têm mais chance de estar corretos quando sabemos muito pouco sobre a forma da distribuição da qual estamos amostrando? Em que sentido sua escolha será "mais correta"?

CAPÍTULO 7

Inferência Bayesiana

ESBOÇO DO CAPÍTULO

Seção 1 As Distribuições a Priori e a Posteriori
Seção 2 Inferências Baseadas na Distribuição a Posteriori
Seção 3 Cálculos Bayesianos
Seção 4 Escolha de Distribuições a Priori
Seção 5 Demonstrações Adicionais (Avançado)

No Capítulo 5, apresentamos os conceitos básicos da inferência. No centro da teoria da inferência está o conceito de modelo estatístico $\{f_\theta : \theta \in \mathbf{\Omega}\}$, que descreve a incerteza do estatístico sobre como os dados observados foram produzidos. O Capítulo 6 tratou da análise dessa incerteza com base apenas no modelo e nos dados. Em alguns casos, isso pareceu ter bastante sucesso, mas observamos que lá tratamos apenas de alguns dos contextos mais simples.

Se aceitarmos o princípio de que, para poderem ser analisadas, todas as incertezas precisam ser descritas por probabilidades, então a especificação de um modelo, sozinha, é incompleta, pois ela não nos diz como fazer afirmações probabilísticas sobre o verdadeiro valor desconhecido de θ. Neste capítulo, completamos a descrição de modo que todas as incertezas sejam descritas por probabilidades. Isso leva a uma distribuição de probabilidade para θ e, em essência, estamos na situação da Seção 5.2, com o parâmetro fazendo agora o papel da resposta não observada. Essa é a abordagem bayesiana da inferência.

Muitos estatísticos preferem desenvolver a teoria estatística sem os ingredientes adicionais necessários a uma descrição probabilística completa das incógnitas. Em parte, isso se deve ao desejo de evitar a especificação dos ingredientes adicionais do modelo necessários à formulação bayesiana. É claro que preferiríamos que nossa análise estatística se baseasse nas hipóteses de modelo menos numerosas e mais fracas possíveis. Por exemplo, na Seção 6.4, apresentamos métodos livres de distribuição[1]. Paga-se um preço por esse enfraquecimento, porém, e ele costuma se manifestar em ambiguidades sobre

No original: *distribution-free methods*[1].

como a inferência deve prosseguir. A formulação bayesiana, em essência, elimina a ambiguidade, mas ao preço de um modelo mais elaborado.

A abordagem bayesiana da inferência é às vezes apresentada como antagônica aos métodos baseados em propriedades de amostragem repetida (muitas vezes chamados de *métodos frequentistas*), como os discutidos, por exemplo, no Capítulo 6. A abordagem adotada neste texto, porém, é a de que o modelo bayesiano surge naturalmente quando o estatístico supõe mais ingredientes para o modelo. Cabe ao estatístico decidir que ingredientes podem ser justificados e, então, usar métodos apropriados. Devemos desconfiar de *todas* as hipóteses do modelo, pois usar hipóteses inadequadas pode invalidar nossas inferências. A verificação do modelo[2] será tratada no Capítulo 9.

7.1 As Distribuições a Priori e a Posteriori

O *modelo bayesiano* de inferência contém o modelo estatístico $\{f_\theta : \theta \in \mathbf{\Omega}\}$ para os dados $s \in S$ e acrescenta a ele a *medida de probabilidade*[3] *a priori*[4] Π para θ. A distribuição a priori[5] descreve as crenças do estatístico sobre o verdadeiro valor do parâmetro θ *a priori*, isto é, antes de observar os dados. Por exemplo, se $\mathbf{\Omega} = [0, 1]$ e θ é a probabilidade de obter cara no lançamento de uma moeda, então a densidade a priori π representada na Figura 7.1.1 indica que o estatístico tem alguma crença de que o verdadeiro valor de θ está em torno de 0,5. Mas essa informação não é muito precisa.

Por outro lado, a densidade a priori π representada na Figura 7.1.2 indica que o estatístico tem uma informação muito precisa sobre o verdadeiro valor de θ. Na verdade, se o estatístico não sabe nada sobre o verdadeiro valor de θ, então usar a distribuição uniforme[6] em $[0, 1]$ pode ser apropriado.

É importante lembrar que as probabilidades especificadas pela distribuição a priori representam crenças. Em geral, elas não correspondem a frequências de longo prazo, embora possam corresponder em certas circunstâncias. Uma pergunta natural é: de onde vêm essas crenças numa aplicação? Uma resposta fácil é dizer que elas vêm da experiência anterior com o sistema aleatório sob investigação ou, talvez, com sistemas relacionados. Para ser honesto, porém, raramente é esse o caso, e é preciso admitir que a distribuição a priori, assim como o modelo estatístico, é muitas vezes uma construção um tanto arbitrária, usada para conduzir as investigações do estatístico. Isso levanta a

No original: *model checking*[2], *probability measure*[3], *prior*[4], *prior*[5], *uniform distribution*[6].

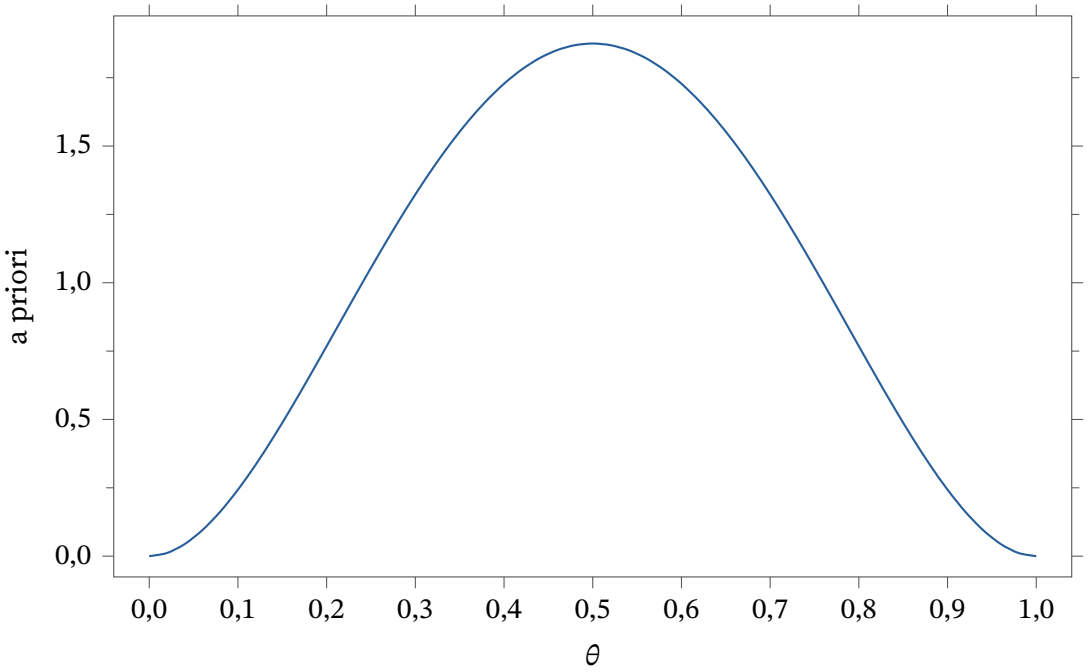


Figura 7.1.1: Uma distribuição a priori bastante difusa em $[0, 1]$.

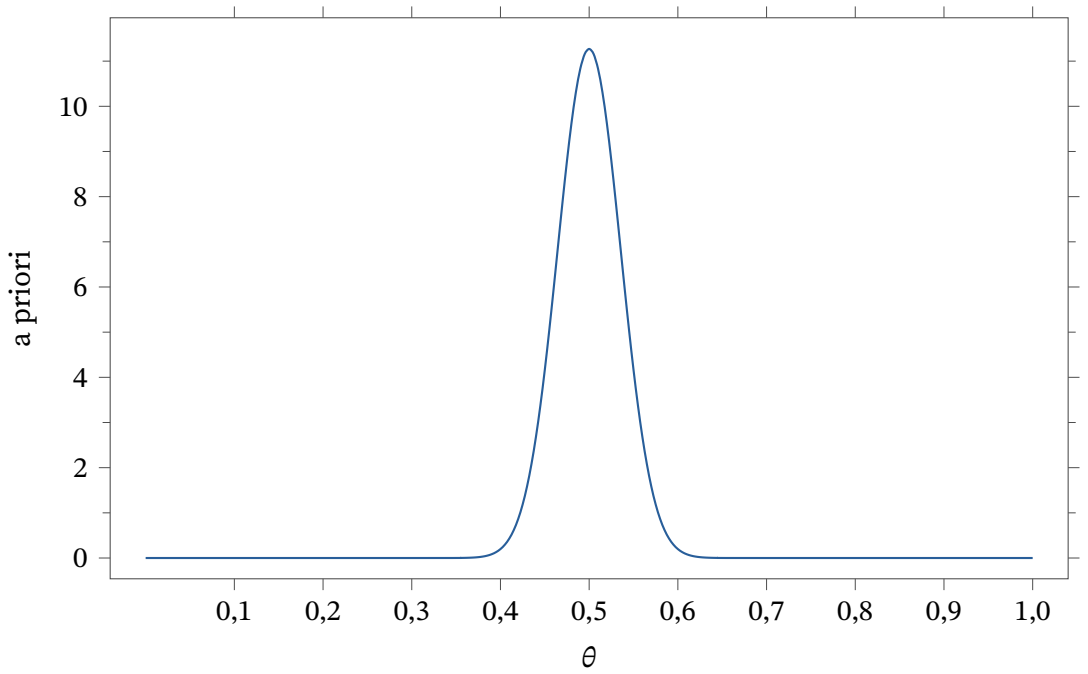


Figura 7.1.2: Uma distribuição a priori bastante precisa em $[0, 1]$.

questão de saber se as inferências obtidas têm ou não alguma relevância para o contexto prático, caso os ingredientes do modelo sofram dessa arbitrariedade. É aqui que entra em cena o conceito de verificação do modelo, um tópico que discutiremos no Capítulo 9. Por ora, vamos supor que todos os ingredientes fazem sentido, mas lembre que, numa aplicação, eles precisam ser verificados para que as inferências obtidas tenham significado prático.

Observamos que os ingredientes da formulação bayesiana da inferência especificam uma distribuição marginal[7] para θ, a saber, a distribuição a priori Π, e um conjunto de distribuições condicionais para os dados s dado θ, a saber, $\{f_\theta : \theta \in \mathbf{\Omega}\}$. Pela lei da probabilidade total[8] (Teoremas 2.3.1 e 2.8.1), esses ingredientes especificam uma distribuição conjunta[9] para (s, θ), a saber,

$$\pi(\theta) f_\theta(s),$$

em que π denota a função de probabilidade[10] ou a função densidade[11] associada a Π. Quando a distribuição a priori é absolutamente contínua[12], a distribuição marginal de s é dada por

$$m(s) = \int_{\mathbf{\Omega}} \pi(\theta) f_\theta(s)\, d\theta$$

e é chamada de *distribuição preditiva a priori*[13] dos dados. Quando a distribuição a priori de θ é discreta, substituímos (como de costume) a integral por uma soma.

Se não observássemos nenhum dado, a distribuição preditiva a priori seria a distribuição pertinente para fazer afirmações probabilísticas sobre o valor desconhecido de s. Do mesmo modo, a distribuição a priori π é a distribuição pertinente a usar para fazer afirmações probabilísticas sobre θ antes de observarmos s. A inferência sobre essas quantidades não observadas procede então como descrito na Seção 5.2.

Lembre agora o princípio da probabilidade condicional[14], a saber, $P(A)$ é substituída por $P(A \mid C)$ depois que nos dizem que C é verdadeiro. Portanto, depois de observar os dados, a distribuição pertinente a usar para fazer afirmações probabilísticas sobre θ é a distribuição condicional[15] de θ dado s. Denotamos essa medida de probabilidade condicional por $\Pi(\cdot \mid s)$ e a chamamos de distribuição a posteriori[16] de θ. Observe que a densidade (ou função de probabilidade) da distribuição a posteriori[17] se obtém imediatamente tomando a densidade conjunta[18] $\pi(\theta) f_\theta(s)$ de (s, θ) e dividindo-a pela marginal $m(s)$ de s.

No original: *marginal distribution*[7], *law of total probability*[8], *joint distribution*[9], *probability function*[10], *density function*[11], *absolutely continuous*[12], *prior predictive*[13], *conditional probability*[14], *conditional distribution*[15], *posterior*[16], *posterior*[17], *joint density*[18].

Definição 7.1.1

A *distribuição a posteriori* de θ é a distribuição condicional de θ, dado s. A *densidade a posteriori*, ou *função de probabilidade a posteriori* (a que for pertinente), é dada por

$$\pi(\theta \mid s) = \frac{\pi(\theta) f_\theta(s)}{m(s)}. \tag{7.1.1}$$

Às vezes, esse uso da probabilidade condicional é chamado de aplicação do teorema de Bayes (Teorema 1.5.2). Isso porque podemos pensar num valor de θ sendo escolhido primeiro de acordo com π e, depois, em s sendo gerado a partir de f_θ. Queremos então fazer afirmações probabilísticas sobre o primeiro estágio, tendo observado o resultado do segundo estágio. É importante lembrar, porém, que escolher usar a distribuição a posteriori para fazer afirmações probabilísticas sobre θ é um axioma, ou princípio, e não um teorema.

Observamos que, em (7.1.1), a preditiva a priori dos dados s faz o papel da *constante normalizadora inversa* da densidade a posteriori. Com isso queremos dizer que a densidade a posteriori de θ é proporcional a $\pi(\theta) f_\theta(s)$, como função de θ; para convertê-la numa função densidade propriamente dita, basta dividir por $m(s)$. Em muitos exemplos, não precisamos calcular a constante normalizadora inversa. Isso porque reconhecemos, na expressão $\pi(\theta) f_\theta(s)$, a forma funcional da distribuição a posteriori como função de θ e, assim, deduzimos imediatamente a distribuição de probabilidade a posteriori de θ. Além disso, há métodos de Monte Carlo, como os discutidos no Capítulo 4, que nos permitem amostrar de $\pi(\theta \mid s)$ sem conhecer $m(s)$ (ver também a Seção 7.3).

Consideremos algumas aplicações da inferência bayesiana.

Exemplo 7.1.1 — Modelo de Bernoulli

Suponha que observamos uma amostra $(x_1, \ldots, x_n)$ da distribuição Bernoulli(θ), com $\theta \in [0, 1]$ desconhecido. Para a distribuição a priori, tomamos π igual a uma densidade Beta(α, β) (ver o Problema 2.4.16). Então a densidade a posteriori de θ é proporcional à verossimilhança

$$\prod_{i=1}^{n} \theta^{x_i}(1-\theta)^{1-x_i} = \theta^{n\bar{x}}(1-\theta)^{n(1-\bar{x})}$$

vezes a densidade a priori

$$B^{-1}(\alpha, \beta)\, \theta^{\alpha-1}(1-\theta)^{\beta-1}.$$

Esse produto é proporcional a

$$\theta^{n\bar{x}+\alpha-1}(1-\theta)^{n(1-\bar{x})+\beta-1}.$$

Reconhecemos aí a densidade não normalizada de uma distribuição Beta($n\bar{x} + \alpha, n(1-\bar{x}) + \beta$). Assim, neste exemplo, não precisamos calcular $m(x_1, \ldots, x_n)$ para obter a distribuição a posteriori.

Como caso particular, suponha que observamos $n\bar{x} = 10$ numa amostra de $n = 40$ e que $\alpha = \beta = 1$, isto é, temos uma distribuição a priori uniforme para θ. Então a distribuição a posteriori de θ é a distribuição Beta(11, 31). Representamos a densidade a posteriori na Figura 7.1.3, junto com a densidade a priori.

A dispersão da distribuição a posteriori nos dá alguma ideia da precisão de quaisquer afirmações probabilísticas que façamos sobre θ. Observe quanta informação os dados acrescentaram, como se vê nos gráficos das densidades a priori e a posteriori. ■

Exemplo 7.1.2 — Modelo Normal de Locação

Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição $N(\mu, \sigma_0^2)$, em que $\mu \in R^1$ é desconhecido e σ_0^2 é conhecido. A função de verossimilhança é então dada por

$$L(\mu \mid x_1, \ldots, x_n) = \exp\left(-\frac{n}{2\sigma_0^2}(\bar{x} - \mu)^2\right).$$

Suponha que tomamos como distribuição a priori de μ uma $N(\mu_0, \tau_0^2)$, para alguma escolha especificada de μ_0 e τ_0^2. A densidade a posteriori de μ é

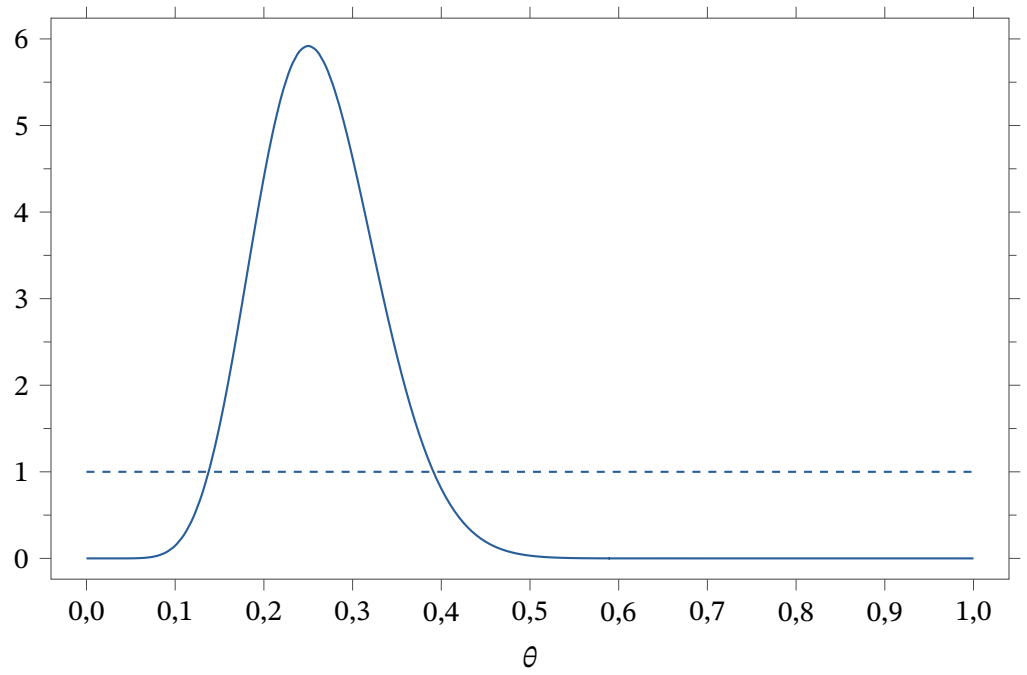


Figura 7.1.3: Densidades a priori (linha tracejada) e a posteriori (linha contínua) no Exemplo 7.1.1.

então proporcional a

$$
\begin{aligned}
&\exp\left\{-\frac{1}{2\tau_0^2}(\mu-\mu_0)^2\right\}\exp\left\{-\frac{n}{2\sigma_0^2}(\bar{x}-\mu)^2\right\}\\
&=\exp\left\{-\frac{1}{2\tau_0^2}\left(\mu^2-2\mu\mu_0+\mu_0^2\right)-\frac{n}{2\sigma_0^2}\left(\bar{x}^2-2\mu\bar{x}+\mu^2\right)\right\}\\
&=\exp\left\{-\frac{1}{2}\left(\frac{1}{\tau_0^2}+\frac{n}{\sigma_0^2}\right)\left[\mu^2-2\left(\frac{1}{\tau_0^2}+\frac{n}{\sigma_0^2}\right)^{-1}\left(\frac{\mu_0}{\tau_0^2}+\frac{n}{\sigma_0^2}\bar{x}\right)\mu\right]\right\}\\
&\quad\times\exp\left\{-\frac{\mu_0^2}{2\tau_0^2}-\frac{n\bar{x}^2}{2\sigma_0^2}\right\}\\
&=\exp\left\{-\frac{1}{2}\left(\frac{1}{\tau_0^2}+\frac{n}{\sigma_0^2}\right)\left(\mu-\left(\frac{1}{\tau_0^2}+\frac{n}{\sigma_0^2}\right)^{-1}\left(\frac{\mu_0}{\tau_0^2}+\frac{n}{\sigma_0^2}\bar{x}\right)\right)^2\right\}\\
&\quad\times\exp\left\{\frac{1}{2}\left(\frac{1}{\tau_0^2}+\frac{n}{\sigma_0^2}\right)^{-1}\left(\frac{\mu_0}{\tau_0^2}+\frac{n}{\sigma_0^2}\bar{x}\right)^2\right\}\\
&\quad\times\exp\left\{-\frac{1}{2}\left(\frac{\mu_0^2}{\tau_0^2}+\frac{n\bar{x}^2}{\sigma_0^2}\right)\right\}. \qquad (7.1.2)
\end{aligned}
$$

Reconhecemos imediatamente essa expressão, como função de μ, como

proporcional à densidade de uma distribuição

$$N\left(\left(\frac{1}{\tau_0^2}+\frac{n}{\sigma_0^2}\right)^{-1}\left(\frac{\mu_0}{\tau_0^2}+\frac{n}{\sigma_0^2}\bar{x}\right),\left(\frac{1}{\tau_0^2}+\frac{n}{\sigma_0^2}\right)^{-1}\right).$$

Observe que a média a posteriori é uma média ponderada da média a priori μ_0 e da média amostral $\bar{x}$, com pesos

$$\left(\frac{1}{\tau_0^2}+\frac{n}{\sigma_0^2}\right)^{-1}\frac{1}{\tau_0^2} \quad \text{e} \quad \left(\frac{1}{\tau_0^2}+\frac{n}{\sigma_0^2}\right)^{-1}\frac{n}{\sigma_0^2},$$

respectivamente. Isso implica que a média a posteriori fica entre a média a priori e a média amostral.

Além disso, a variância a posteriori é menor que a variância da média amostral. Assim, se a informação expressa pela distribuição a priori for precisa, as inferências sobre μ baseadas na distribuição a posteriori serão mais precisas que as baseadas apenas na média amostral. Observe que, quanto mais difusa for a distribuição a priori — isto é, quanto maior for τ_0^2 —, menor será a influência dela. Por exemplo, quando $n = 20$ e $\sigma_0^2 = 1$, $\tau_0^2 = 1$, a razão entre a variância a posteriori e a variância da média amostral é $20/21 \approx 0{,}95$. Houve, portanto, uma melhora de 5% devida ao uso da informação a priori.

Por exemplo, suponha que $\sigma_0^2 = 1$, $\mu_0 = 0$, $\tau_0^2 = 2$ e que, para $n = 10$, observamos $\bar{x} = 1{,}2$. Então a distribuição a priori é uma $N(0, 2)$, enquanto a distribuição a posteriori é uma distribuição

$$N\left(\left(\frac{1}{2}+\frac{10}{1}\right)^{-1}\left(\frac{0}{2}+\frac{10}{1}1{,}2\right),\left(\frac{1}{2}+\frac{10}{1}\right)^{-1}\right) = N(1{,}1429; 9{,}5238\times 10^{-2}).$$

Essas densidades estão representadas na Figura 7.1.4. Observe que a distribuição a posteriori é bem concentrada em comparação com a distribuição a priori; portanto, aprendemos muito com os dados. ■

Exemplo 7.1.3 — Modelo Multinomial

Suponha que temos uma resposta categórica s que assume k valores possíveis, digamos, $s \in S = \{1, \ldots, k\}$. Por exemplo, suponha que temos uma tigela com fichas marcadas com um dos números $1, \ldots, k$. Uma proporção θ_i das fichas está marcada com i, e retiramos uma ficha ao acaso, observando o seu número.

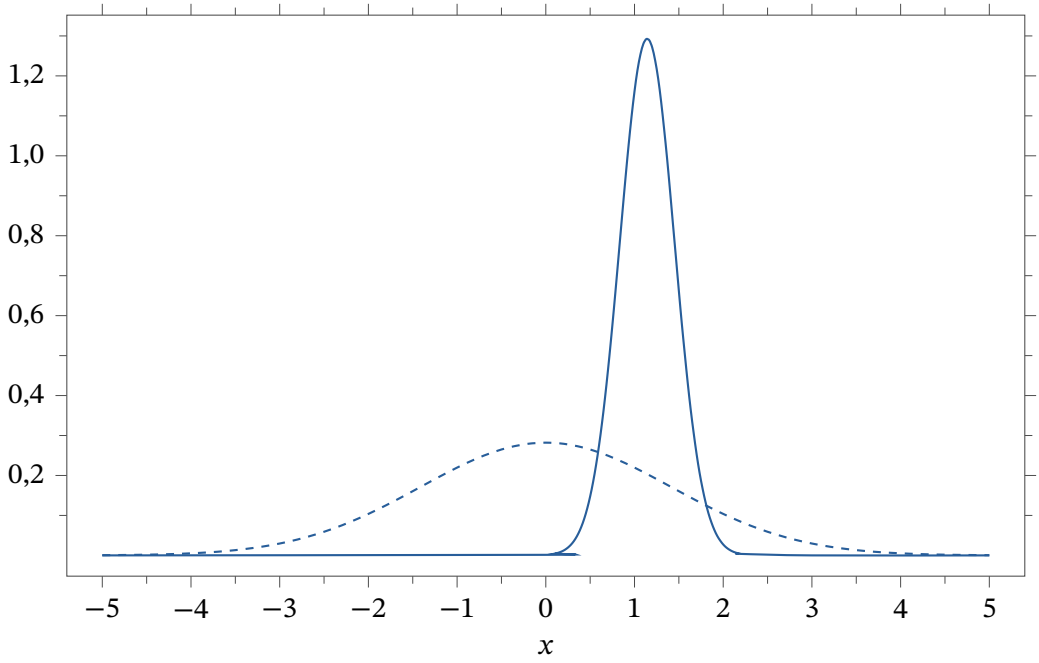


Figura 7.1.4: Gráfico da densidade a priori $N(0, 2)$ (linha tracejada) e da densidade a posteriori $N(1{,}1429; 9{,}5238 \times 10^{-2})$ (linha contínua) no Exemplo 7.1.2.

Quando os θ_i são desconhecidos, o modelo estatístico é dado por

$$\{p_{(\theta_1,\ldots,\theta_k)} : (\theta_1, \ldots, \theta_k) \in \mathbf{\Omega}\},$$

em que $p_{(\theta_1,\ldots,\theta_k)}(i) = P(s = i) = \theta_i$ e

$$\mathbf{\Omega} = \{(\theta_1, \ldots, \theta_k) : 0 \leq \theta_i \leq 1, i = 1, \ldots, k \text{ e } \theta_1 + \cdots + \theta_k = 1\}.$$

Observe que o espaço paramétrico tem, na verdade, apenas $(k - 1)$ dimensões porque, por exemplo, $\theta_k = 1 - \theta_1 - \cdots - \theta_{k-1}$, isto é, uma vez determinados $k - 1$ dos θ_i, o valor restante fica especificado.

Suponha agora que observamos uma amostra $(s_1, \ldots, s_n)$ desse modelo. Denote por x_i a frequência (contagem) da i-ésima categoria na amostra. Então, pelo Exemplo 2.8.5, vemos que a verossimilhança é dada por

$$L(\theta_1, \ldots, \theta_k \mid (s_1, \ldots, s_n)) = \theta_1^{x_1}\theta_2^{x_2} \cdots \theta_k^{x_k}.$$

Para a distribuição a priori, supomos que $(\theta_1, \ldots, \theta_{k-1}) \sim$ Dirichlet$(\alpha_1, \alpha_2, \ldots, \alpha_k)$, com densidade (ver o Problema 2.7.13) dada por

$$\frac{\Gamma(\alpha_1 + \cdots + \alpha_k)}{\Gamma(\alpha_1) \cdots \Gamma(\alpha_k)} \theta_1^{\alpha_1 - 1}\theta_2^{\alpha_2 - 1} \ldots \theta_k^{\alpha_k - 1} \tag{7.1.3}$$

para $(\theta_1, \ldots, \theta_k) \in \boldsymbol{\Omega}$ (lembre que $\theta_k = 1 - \theta_1 - \cdots - \theta_{k-1}$). Os α_i são constantes não negativas escolhidas pelo estatístico para refletir as suas crenças sobre o valor desconhecido de $(\theta_1, \ldots, \theta_k)$. A escolha $\alpha_1 = \alpha_2 = \cdots = \alpha_k = 1$ corresponde a uma distribuição uniforme, pois então (7.1.3) é constante em $\boldsymbol{\Omega}$.

A densidade a posteriori de $(\theta_1, \ldots, \theta_{k-1})$ é então proporcional a

$$\theta_1^{x_1+\alpha_1-1}\theta_2^{x_2+\alpha_2-1}\cdots\theta_k^{x_k+\alpha_k-1}$$

para $(\theta_1, \ldots, \theta_k) \in \boldsymbol{\Omega}$. A partir de (7.1.3), deduzimos imediatamente que a distribuição a posteriori de $(\theta_1, \ldots, \theta_{k-1})$ é Dirichlet$(x_1 + \alpha_1, x_2 + \alpha_2, \ldots, x_k + \alpha_k)$. ■

Exemplo 7.1.4 — Modelo Normal de Locação e Escala

Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição $N(\mu, \sigma^2)$, em que $\mu \in R^1$ e $\sigma > 0$ são desconhecidos. A função de verossimilhança é então dada por

$$L(\mu, \sigma^2 \mid x_1, \ldots, x_n) = (2\pi\sigma^2)^{-n/2} \exp\left(-\frac{n}{2\sigma^2}(\bar{x} - \mu)^2\right) \exp\left(-\frac{n-1}{2\sigma^2}s^2\right).$$

Suponha que colocamos a seguinte distribuição a priori em (μ, σ^2). Primeiro, especificamos que

$$\mu \mid \sigma^2 \sim N(\mu_0, \tau_0^2\sigma^2),$$

isto é, a distribuição a priori condicional de μ dado σ^2 é normal, com média μ_0 e variância $\tau_0^2\sigma^2$. Em seguida, especificamos a distribuição a priori marginal de σ^2 como

$$\frac{1}{\sigma^2} \sim \text{Gama}(\alpha_0, \beta_0). \tag{7.1.4}$$

Às vezes, (7.1.4) é expressa dizendo-se que σ^2 tem distribuição *Gama inversa*. Os valores μ_0, τ_0^2, α_0 e β_0 são escolhidos pelo estatístico para refletir as suas crenças a priori.

A partir disso, podemos deduzir (ver a Seção 7.5 para a dedução completa) que a distribuição a posteriori de (μ, σ^2) é dada por

$$\mu \mid \sigma^2, x_1, \ldots, x_n \sim N\left(\mu_x, \left(n + \frac{1}{\tau_0^2}\right)^{-1}\sigma^2\right) \tag{7.1.5}$$

e

$$\frac{1}{\sigma^2} \Big| x_1, \ldots, x_n \sim \text{Gama}(\alpha_0 + n/2, \beta_x), \tag{7.1.6}$$

em que

$$\mu_x = \left(n + \frac{1}{\tau_0^2}\right)^{-1} \left(\frac{\mu_0}{\tau_0^2} + n\bar{x}\right) \tag{7.1.7}$$

e

$$\beta_x = \beta_0 + \frac{n-1}{2}s^2 + \frac{1}{2}\frac{n(\bar{x} - \mu_0)^2}{1 + n\tau_0^2}. \tag{7.1.8}$$

Para gerar um valor (μ, σ^2) da distribuição a posteriori, podemos usar o método da composição (ver o Problema 2.10.13), gerando primeiro σ^2 por (7.1.6) e depois usando (7.1.5) para gerar μ. Discutiremos isso mais a fundo na Seção 7.3.

Observe que, quando $\tau_0 \to \infty$, isto é, quando a distribuição a priori de μ se torna cada vez mais difusa, a distribuição a posteriori condicional de μ dado σ^2 converge em distribuição para uma distribuição $N(\bar{x}, \sigma^2/n)$, pois

$$\mu_x \to \bar{x} \tag{7.1.9}$$

e

$$\left(n + \frac{1}{\tau_0^2}\right)^{-1} \to \frac{1}{n}. \tag{7.1.10}$$

Além disso, quando $\tau_0 \to \infty$ e $\beta_0 \to 0$, a distribuição a posteriori marginal de $1/\sigma^2$ converge em distribuição para uma distribuição $\text{Gama}\big(\alpha_0 + n/2, (n-1)s^2/2\big)$, pois

$$\beta_x \to (n-1)s^2/2. \tag{7.1.11}$$

Na verdade, não parece fazer muito sentido fazer $\tau_0 \to \infty$ e $\beta_0 \to 0$ na distribuição a priori de (μ, σ^2), já que a distribuição a priori não converge para uma distribuição de probabilidade própria. A ideia aqui, porém, é que pensamos em tomar τ_0 grande e β_0 pequeno, de modo que as inferências a posteriori sejam aproximadamente as obtidas a partir da distribuição a posteriori limite. Ainda assim, é preciso escolher α_0, mesmo no caso difuso, já que as inferências limite dependem dessa quantidade. ■

Resumo da Seção 7.1

- A inferência bayesiana acrescenta ao modelo amostral dos dados a distribuição de probabilidade a priori, como um ingrediente adicional a ser usado na determinação das inferências sobre o valor desconhecido do parâmetro.
- Observados os dados, o princípio da probabilidade condicional leva à distribuição a posteriori do parâmetro como base para a inferência.
- A inferência sobre parâmetros marginais é feita marginalizando a distribuição a posteriori completa.

Exercícios

7.1.1 Suponha que $S = \{1, 2\}$, $\mathbf{\Omega} = \{1, 2, 3\}$ e que a classe de distribuições de probabilidade da resposta s é dada pela tabela a seguir.

	$s = 1$	$s = 2$
$f_1(s)$	1/2	1/2
$f_2(s)$	1/3	2/3
$f_3(s)$	3/4	1/4

Se usarmos a distribuição a priori $\pi(\theta)$ dada pela tabela

	$\theta = 1$	$\theta = 2$	$\theta = 3$
$\pi(\theta)$	1/5	2/5	2/5

,

determine a distribuição a posteriori de θ para cada amostra possível de tamanho 2.

7.1.2 No Exemplo 7.1.1, determine a média e a variância[19] a posteriori de θ.

7.1.3 No Exemplo 7.1.2, qual é a probabilidade a posteriori de que μ seja positivo, dado que $n = 10$, $\bar{x} = 1$, quando $\sigma_0^2 = 1$, $\mu_0 = 0$ e $\tau_0^2 = 10$? Compare-a com a probabilidade a priori desse evento.

7.1.4 Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição Poisson(λ), com $\lambda \geq 0$ desconhecido. Se usarmos para λ a distribuição a priori dada pela distribuição Gama(α, β), determine a distribuição a posteriori de λ.

No original: *variance*[19].

7.1.5 Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição Uniforme$[0, \theta]$, com $\theta > 0$ desconhecido. Se a distribuição a priori de θ for Gama(α, β), obtenha a forma da densidade a posteriori de θ.

7.1.6 Encontre a média e a variância a posteriori de θ_i no Exemplo 7.1.3 quando $k = 3$. (Sugestão: veja os Problemas 3.2.16 e 3.3.20.)

7.1.7 Suponha que temos a amostra

6,56	6,39	3,30	3,03	5,31	5,62	5,10	2,45	8,24	3,71
4,14	2,80	7,43	6,82	4,75	4,09	7,95	5,84	8,44	9,36

de uma distribuição $N(\mu, \sigma^2)$ e determinamos que uma distribuição a priori especificada por $\mu \mid \sigma^2 \sim N(3, 4\sigma^2)$, $\sigma^{-2} \sim$ Gama$(1, 1)$ é apropriada. Determine a distribuição a posteriori de $(\mu, 1/\sigma^2)$.

7.1.8 Suponha que a probabilidade a priori de θ estar num conjunto $A \subset \mathbf{\Omega}$ é 0,25 e que a probabilidade a posteriori de θ estar em A é 0,80.

(a) Explique que efeito os dados tiveram sobre as suas crenças a respeito de o verdadeiro valor de θ estar em A.

(b) Explique por que é mais pertinente relatar uma probabilidade a posteriori do que uma probabilidade a priori.

7.1.9 Suponha que você lança uma moeda e põe uma distribuição a priori Uniforme$[0{,}4; 0{,}6]$ em θ, a probabilidade de obter cara num único lançamento.

(a) Se você lançar a moeda n vezes e obtiver n caras, determine a densidade a posteriori de θ.

(b) Suponha que o verdadeiro valor de θ seja, na verdade, 0,99. A distribuição a posteriori de θ vai alguma vez pôr massa de probabilidade em torno de $\theta = 0{,}99$, para alguma amostra de tamanho n?

(c) O que você conclui do item (b) sobre como deve escolher uma distribuição a priori?

7.1.10 Suponha que, para o modelo estatístico $\{f_\theta : \theta \in R^1\}$, atribuímos a densidade a priori π. Suponha agora que reparametrizamos o modelo por meio da função $\psi = \Psi(\theta)$, em que $\Psi : R^1 \to R^1$ é diferenciável e estritamente crescente[20].

(a) Determine a densidade a priori de ψ.

No original: *strictly increasing*[20].

(b) Mostre que $m(x)$ é a mesma, quer parametrizemos o modelo por θ, quer por ψ.

7.1.11 Suponha que, para o modelo estatístico $\{f_\theta : \theta \in \mathbf{\Omega}\}$, em que $\mathbf{\Omega} = \{-2, -1, 0, 1, 2, 3\}$, atribuímos a função de probabilidade a priori π, que é uniforme em $\mathbf{\Omega}$. Suponha agora que estamos interessados principalmente em fazer inferências sobre $|\theta|$.

(a) Determine a distribuição de probabilidade a priori de $|\theta|$. Essa distribuição é uniforme?

(b) Uma distribuição a priori uniforme é às vezes usada para expressar ignorância completa sobre o valor de um parâmetro. A ignorância completa sobre o valor de um parâmetro implica ignorância completa sobre uma função de um parâmetro? Explique.

7.1.12 Suponha que, para o modelo estatístico $\{f_\theta : \theta \in [0, 1]\}$, atribuímos a densidade a priori π, que é uniforme em $\mathbf{\Omega} = [0, 1]$. Suponha agora que estamos interessados principalmente em fazer inferências sobre θ^2.

(a) Determine a densidade a priori de θ^2. Essa distribuição é uniforme?

(b) Uma distribuição a priori uniforme é às vezes usada para expressar ignorância completa sobre o valor de um parâmetro. A ignorância completa sobre o valor de um parâmetro implica ignorância completa sobre uma função de um parâmetro? Explique.

Exercícios computacionais

7.1.13 No Exemplo 7.1.2, quando $\mu_0 = 2$, $\tau_0^2 = 1$, $\sigma_0^2 = 1$, $n = 20$ e $\bar{x} = 8{,}2$, gere uma amostra de 10^4 (ou tão grande quanto possível) da distribuição a posteriori de μ e estime a probabilidade a posteriori de que o coeficiente de variação seja maior que 0,125, isto é, a probabilidade a posteriori de que $\sigma_0/\mu > 0{,}125$. Estime o erro da sua aproximação.

7.1.14 No Exemplo 7.1.2, quando $\mu_0 = 2$, $\tau_0^2 = 1$, $\sigma_0^2 = 1$, $n = 20$ e $\bar{x} = 8{,}2$, gere uma amostra de 10^4 (ou tão grande quanto possível) da distribuição a posteriori de μ e estime a esperança[21] a posteriori do coeficiente de variação σ_0/μ. Estime o erro da sua aproximação.

7.1.15 No Exemplo 7.1.1, represente as densidades a priori e a posteriori no mesmo gráfico e compare-as quando $n = 30$, $\bar{x} = 0{,}73$, $\alpha = 3$ e $\beta = 3$. (Sugestão:

No original: *expectation*[21].

calcule o logaritmo da densidade a posteriori e depois tome a exponencial do resultado. Você vai precisar da *função log-gama*, definida por $\ln \Gamma(\alpha)$ para $\alpha > 0$.)

Problemas

7.1.16 Suponha que a distribuição a priori de um parâmetro real θ é dada pela distribuição $N(\theta_0, \tau^2)$. Mostre que essa distribuição não converge para uma distribuição de probabilidade quando $\tau \to \infty$. (Sugestão: considere os limites das funções de distribuição.)

7.1.17 Suponha que $(x_1, \ldots, x_n)$ é uma amostra de $\{f_\theta : \theta \in \Omega\}$ e que temos uma distribuição a priori π. Mostre que, se observarmos uma amostra adicional $(x_{n+1}, \ldots, x_{n+m})$, então a distribuição a posteriori que se obtém usando a posteriori $\pi(\cdot \mid x_1, \ldots, x_n)$ como distribuição a priori e condicionando em seguida a $(x_{n+1}, \ldots, x_{n+m})$ é a mesma que a distribuição a posteriori obtida usando a distribuição a priori π e condicionando a $(x_1, \ldots, x_n, x_{n+1}, \ldots, x_{n+m})$. Essa é a propriedade de *atualização bayesiana*.

7.1.18 No Exemplo 7.1.1, determine $m(x)$. Se lhe pedissem para gerar um valor dessa distribuição, como você faria? (Sugestão: para a parte da geração, use o teorema da probabilidade total.)

7.1.19 Prove que a distribuição a posteriori depende dos dados somente por meio do valor de uma estatística suficiente[22].

Problemas computacionais

7.1.20 Para os dados do Exercício 7.1.7, represente as densidades a priori e a posteriori de σ^2 em $(0, 10)$ no mesmo gráfico e compare-as. (Sugestão: calcule primeiro os logaritmos das densidades e depois represente a exponencial desses valores.)

7.1.21 No Exemplo 7.1.4, quando $\mu_0 = 0$, $\tau_0^2 = 1$, $\alpha_0 = 2$, $\beta_0 = 1$, $n = 20$, $\bar{x} = 8{,}2$ e $s^2 = 2{,}1$, gere uma amostra de 10^4 (ou tão grande quanto for viável) da distribuição a posteriori de σ^2 e estime a probabilidade a posteriori de que $\sigma > 2$. Estime o erro da sua aproximação.

7.1.22 No Exemplo 7.1.4, quando $\mu_0 = 0$, $\tau_0^2 = 1$, $\alpha_0 = 2$, $\beta_0 = 1$, $n = 20$, $\bar{x} = 8{,}2$ e $s^2 = 2{,}1$, gere uma amostra de 10^4 (ou tão grande quanto for viável)

No original: *sufficient statistic*[22].

da distribuição a posteriori de (μ, σ^2) e estime a esperança a posteriori de σ. Estime o erro da sua aproximação.

Tópicos para discussão

7.1.23 Uma das objeções levantadas contra a metodologia da inferência bayesiana é que ela tem natureza subjetiva. Comente isso e o papel da subjetividade nas investigações científicas.

7.1.24 Dois estatísticos são solicitados a analisar um conjunto de dados x produzido por um sistema em estudo. O Estatístico I escolhe usar um modelo amostral[23] $\{f_\theta : \theta \in \mathbf{\Omega}\}$ e a distribuição a priori π_I, enquanto o Estatístico II escolhe usar um modelo amostral $\{g_\psi : \psi \in \Psi\}$ e a distribuição a priori π_{II}. Comente o fato de que esses ingredientes podem ser completamente diferentes e, portanto, as análises subsequentes também. Qual é a relevância disso para o papel da subjetividade nas análises científicas de dados?

7.2 Inferências Baseadas na Distribuição a Posteriori

Na Seção 7.1, determinamos a distribuição a posteriori de θ como um objeto fundamental da inferência bayesiana. Em essência, o princípio da probabilidade condicional afirma que a distribuição a posteriori $\pi(\theta \mid s)$ contém toda a informação relevante do modelo amostral $\{f_\theta : \theta \in \mathbf{\Omega}\}$, da priori π e dos dados s sobre o verdadeiro valor desconhecido de θ. Embora esse seja um grande passo adiante, ele não nos diz completamente como fazer os tipos de inferência que discutimos na Seção 5.5.3.

Em particular, precisamos especificar como calcular estimativas e regiões de credibilidade e como fazer a avaliação de hipóteses[24] — que é o que faremos nesta seção. Acontece que muitas vezes há várias maneiras plausíveis de proceder, mas todas têm em comum o fato de se basearem na distribuição a posteriori.

Em geral, nosso interesse é especificar inferências sobre uma característica de interesse $\psi(\theta)$ a valores reais. Uma das grandes vantagens da abordagem bayesiana é que as inferências sobre ψ são determinadas da mesma maneira

No original: *sampling model*[23], *hypothesis assessment*[24].

que as inferências sobre o parâmetro completo θ, mas com a distribuição a posteriori marginal de ψ no lugar da distribuição a posteriori completa. Essa situação pode ser comparada com os métodos de verossimilhança[25] do Capítulo 6, em que nem sempre fica inteiramente claro como devemos proceder para determinar inferências sobre ψ com base na verossimilhança. Ainda assim, pagamos um preço por isso ao exigir o acréscimo de mais um ingrediente ao modelo, a saber, a priori.

Assim, precisamos determinar a distribuição a posteriori de ψ. Em geral, essa pode ser uma tarefa difícil, mesmo quando temos uma expressão em forma fechada para $\pi(\theta \mid s)$. Quando a distribuição a posteriori de θ é discreta, a função de probabilidade a posteriori de ψ é dada por

$$\omega(\psi_0 \mid s) = \sum_{\{\theta : \psi(\theta) = \psi_0\}} \pi(\theta \mid s).$$

Quando a distribuição a posteriori de θ é absolutamente contínua, muitas vezes conseguimos encontrar uma função complementar[26] $\lambda(\theta)$ tal que $h(\theta) = (\psi(\theta), \lambda(\theta))$ seja injetora[27] e tal que os métodos da Seção 2.9.2 possam ser aplicados. Então, denotando a inversa dessa transformação por $\theta = h^{-1}(\psi, \lambda)$, os métodos da Seção 2.9.2 mostram que a distribuição a posteriori marginal de ψ tem densidade dada por

$$\omega(\psi_0 \mid s) = \int \pi(h^{-1}(\psi_0, \lambda) \mid s) |J(h^{-1}(\psi_0, \lambda))|^{-1} \, d\lambda, \tag{7.2.1}$$

em que J denota o jacobiano[28] dessa transformação (veja o Problema 7.2.35). Calcular (7.2.1) pode ser difícil, e em geral evitaremos fazê-lo aqui. Um exemplo ilustra como às vezes podemos evitar a implementação direta de (7.2.1) e ainda assim obter a distribuição a posteriori marginal de ψ.

Exemplo 7.2.1 — Modelo Normal de Locação e Escala

Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição $N(\mu, \sigma^2)$, em que $\mu \in R^1$ e $\sigma > 0$ são desconhecidos, e que usamos a priori dada no Exemplo 7.1.4. A distribuição a posteriori de (μ, σ^2) é então dada por (7.1.5) e (7.1.6).

Suponha que nosso interesse principal está em $\psi(\mu, \sigma^2) = \sigma^2$. Vemos imediatamente que a distribuição a posteriori marginal de σ^2 é dada por (7.1.6) e, portanto, não temos mais trabalho a fazer, a menos que

No original: *likelihood*[25], *complement*[26], *one-to-one*[27], *Jacobian*[28].

queiramos uma fórmula para a densidade a posteriori marginal de σ^2. Para isso, podemos usar os métodos da Seção 2.6 (veja o Exercício 7.2.4).

Se quisermos a distribuição a posteriori marginal de $\psi(\mu, \sigma^2) = \mu$, as coisas não são tão simples, porque (7.1.5) só especifica a distribuição a posteriori condicional de μ dado σ^2. Podemos, porém, evitar a necessidade de implementar (7.2.1). Note que (7.1.5) implica que

$$Z = \frac{\mu - \mu_x}{\left(n + 1/\tau_0^2\right)^{-1/2} \sigma} \Big| \sigma^2, x_1, \ldots, x_n \sim N(0, 1),$$

em que μ_x é dado em (7.1.7). Como essa distribuição não envolve σ^2, a distribuição a posteriori de Z é independente da distribuição a posteriori de σ. Agora, se $X \sim \text{Gama}(\alpha, \beta)$, então $Y = 2\beta X \sim \text{Gama}(\alpha, 1/2) = \chi^2(2\alpha)$ (veja o Problema 4.6.16 para a definição da distribuição qui-quadrado geral) e, assim, por (7.1.6),

$$2\frac{\beta_x}{\sigma^2} \Big| x_1, \ldots, x_n \sim \chi^2(2\alpha_0 + n),$$

em que β_x é dado em (7.1.8). Portanto (usando o Problema 4.6.14), como estamos dividindo uma variável $N(0, 1)$ pela raiz quadrada de uma variável aleatória $\chi^2(2\alpha_0 + n)$ independente dividida por seus graus de liberdade, concluímos que a distribuição a posteriori de

$$T = \frac{Z}{\sqrt{\left(2\frac{\beta_x}{\sigma^2}\right)/(2\alpha_0 + n)}} = \frac{\mu - \mu_x}{\sqrt{\frac{2\beta_x}{(2\alpha_0 + n)\left(n + 1/\tau_0^2\right)}}}$$

é $t(2\alpha_0 + n)$. De modo equivalente, podemos dizer que a distribuição a posteriori de μ é a mesma de

$$\mu_x + \sqrt{\frac{1}{2\alpha_0 + n}}\sqrt{\frac{2\beta_x}{n + 1/\tau_0^2}}\, T,$$

em que $T \sim t(2\alpha_0 + n)$. Por (7.1.9), (7.1.10) e (7.1.11), temos que a distribuição a posteriori de μ converge para a distribuição de

$$\bar{x} + \sqrt{\frac{n-1}{(2\alpha_0 + n)}}\frac{s}{\sqrt{n}}\, T$$

quando $\tau_0 \to \infty$ e $\beta_0 \to 0$.

Em outros casos, não podemos evitar o uso de (7.2.1) se quisermos a densidade a posteriori marginal de ψ. Por exemplo, suponha que nosso

interesse está na distribuição a posteriori do coeficiente de variação (excluímos do espaço paramétrico a reta dada por $\mu = 0$)

$$\psi = \psi(\mu, \sigma^{-2}) = \frac{\sigma}{\mu} = \frac{1}{\mu}\left(\frac{1}{\sigma^2}\right)^{-1/2}.$$

Então, uma função complementar a ψ é dada por

$$\lambda = \lambda(\mu, \sigma^{-2}) = \frac{1}{\sigma^2},$$

e pode-se mostrar (veja a Seção 7.5) que

$$J(\theta(\psi, \lambda)) = \psi^{-2}\lambda^{-1/2}.$$

Se $\pi(\cdot \mid \lambda^{-1}, x_1, \ldots, x_n)$ e $\rho(\cdot \mid x_1, \ldots, x_n)$ denotam, respectivamente, a densidade a posteriori de μ dado λ e a densidade a posteriori de λ, então, por (7.2.1), a densidade marginal de ψ é dada por

$$\psi^{-2} \int_0^\infty \pi(\psi^{-1}\lambda^{-1/2} \mid \lambda^{-1}, x_1, \ldots, x_n)\rho(\lambda \mid x_1, \ldots, x_n)\, \lambda^{-1/2}\, d\lambda. \tag{7.2.2}$$

Sem escrever isso por extenso (veja o Problema 7.2.22), notamos que ficamos com uma integral bastante complicada para calcular. ■

Em alguns casos, integrais como (7.2.2) podem ser calculadas em forma fechada; em outros, não. Embora seja conveniente ter uma forma fechada para uma densidade, muitas vezes isso não é necessário, pois podemos usar métodos de Monte Carlo para aproximar as probabilidades e esperanças a posteriori de interesse. Voltaremos a isso na Seção 7.3. Devemos sempre lembrar que nosso objetivo, ao implementar métodos de inferência bayesiana, não é encontrar as densidades a posteriori marginais das quantidades de interesse, mas sim ter um algoritmo computacional que nos permita implementar nossas inferências.

Sob condições bastante fracas, pode-se mostrar que a distribuição a posteriori de θ converge, à medida que o tamanho da amostra[29] aumenta, para uma distribuição degenerada[30] no verdadeiro valor. Isso é muito satisfatório, pois indica que os métodos de inferência bayesiana são consistentes.

No original: *sample size*[29], *degenerate distribution*[30].

7.2.1 Estimação

Suponha agora que queremos calcular uma estimativa[31] de uma característica de interesse $\psi(\theta)$. Baseamos essa estimativa na distribuição a posteriori dessa quantidade. Há várias abordagens diferentes para esse problema.

Talvez a estimativa mais natural seja obter a densidade a posteriori (ou a função de probabilidade, quando for o caso) de ψ e usar a *moda a posteriori* $\hat{\psi}$, isto é, o ponto em que a função de probabilidade ou a densidade a posteriori de ψ assume seu máximo. No caso discreto, é o valor de ψ com a maior probabilidade a posteriori; no caso contínuo, é o valor que tem a maior quantidade de probabilidade a posteriori em intervalos curtos que o contêm.

Para calcular a moda a posteriori, precisamos maximizar $\omega(\psi \mid s)$ como função de ψ. Note que isso equivale a maximizar $m(s)\omega(\psi \mid s)$, de modo que não precisamos calcular a constante de normalização inversa para fazê-lo. Na verdade, podemos convenientemente escolher maximizar qualquer função que seja uma função crescente e injetora de $\omega(\cdot \mid s)$ e obter a mesma resposta. Em geral, $\omega(\cdot \mid s)$ pode não ter uma única moda, mas tipicamente há apenas uma.

Uma estimativa alternativa é muito usada e tem uma interpretação natural. Ela é dada pela média a posteriori

$$E(\psi(\theta) \mid s),$$

sempre que esta existir. Quando a distribuição a posteriori de ψ é simétrica em torno de sua moda e a esperança existe, a esperança a posteriori é igual à moda a posteriori; caso contrário, essas estimativas serão diferentes. Se quisermos que a estimativa reflita onde está a massa central de probabilidade, então, nos casos em que $\omega(\cdot \mid s)$ é muito assimétrica, talvez a moda seja uma escolha melhor que a média. Veremos no Capítulo 8, porém, que há outras maneiras de justificar a média a posteriori como estimativa.

Consideramos agora alguns exemplos.

Exemplo 7.2.2 — Modelo de Bernoulli

Suponha que observamos uma amostra $(x_1, \ldots, x_n)$ da distribuição Bernoulli(θ), com $\theta \in [0, 1]$ desconhecido, e que atribuímos a θ uma priori Beta(α, β). No Exemplo 7.1.1, determinamos que a distribuição a posteriori de θ é Beta$(n\bar{x} + \alpha, n(1 - \bar{x}) + \beta)$. Suponhamos que a característica de interesse é $\psi(\theta) = \theta$.

No original: *estimate*[31].

A esperança a posteriori de θ é dada por

$$\begin{aligned}
&E(\theta \mid x_1, \ldots, x_n) \\
&= \int_0^1 \theta \, \frac{\Gamma(n+\alpha+\beta)}{\Gamma(n\bar{x}+\alpha)\Gamma(n(1-\bar{x})+\beta)} \, \theta^{n\bar{x}+\alpha-1}(1-\theta)^{n(1-\bar{x})+\beta-1} \, d\theta \\
&= \frac{\Gamma(n+\alpha+\beta)}{\Gamma(n\bar{x}+\alpha)\Gamma(n(1-\bar{x})+\beta)} \int_0^1 \theta^{n\bar{x}+\alpha}(1-\theta)^{n(1-\bar{x})+\beta-1} \, d\theta \\
&= \frac{\Gamma(n+\alpha+\beta)}{\Gamma(n\bar{x}+\alpha)\Gamma(n(1-\bar{x})+\beta)} \, \frac{\Gamma(n\bar{x}+\alpha+1)\Gamma(n(1-\bar{x})+\beta)}{\Gamma(n+\alpha+\beta+1)} \\
&= \frac{n\bar{x}+\alpha}{n+\alpha+\beta}.
\end{aligned}$$

Quando temos uma priori uniforme, isto é, $\alpha = \beta = 1$, a esperança a posteriori é dada por

$$E(\theta \mid x) = \frac{n\bar{x}+1}{n+2}.$$

Para determinar a moda a posteriori, precisamos maximizar

$$\begin{aligned}
&\ln \theta^{n\bar{x}+\alpha-1}(1-\theta)^{n(1-\bar{x})+\beta-1} \\
&\qquad = (n\bar{x}+\alpha-1)\ln\theta + (n(1-\bar{x})+\beta-1)\ln(1-\theta).
\end{aligned}$$

Essa função tem derivada primeira

$$\frac{n\bar{x}+\alpha-1}{\theta} - \frac{n(1-\bar{x})+\beta-1}{1-\theta}$$

e derivada segunda

$$-\frac{n\bar{x}+\alpha-1}{\theta^2} - \frac{n(1-\bar{x})+\beta-1}{(1-\theta)^2}.$$

Igualando a derivada primeira a 0 e resolvendo, obtemos a solução

$$\hat{\theta} = \frac{n\bar{x}+\alpha-1}{n+\alpha+\beta-2}.$$

Agora, se $\alpha \geq 1$, $\beta \geq 1$, vemos que a derivada segunda é sempre negativa e, portanto, $\hat{\theta}$ é a única moda a posteriori. A restrição na escolha de $\alpha \geq 1$, $\beta \geq 1$ implica que a priori tem uma moda em $(0, 1)$, e não em 0 ou 1. Note que, quando $\alpha = 1$, $\beta = 1$, isto é, quando atribuímos a θ uma priori uniforme, a moda a posteriori é $\hat{\theta} = \bar{x}$. Essa é a mesma que a estimativa de máxima verossimilhança (EMV).

A distribuição a posteriori é muito assimétrica sempre que $n\bar{x} + \alpha$ e $n(1-\bar{x}) + \beta$ estão muito distantes (trace gráficos de densidades Beta

para ver isso). Assim, num caso desses, poderíamos considerar a moda a posteriori uma estimativa mais sensata de θ. Note que, quando n é grande, a moda e a média estarão muito próximas uma da outra e, de fato, muito próximas da EMV $\bar{x}$. ■

Exemplo 7.2.3 — Modelo Normal de Locação

Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição $N(\mu, \sigma_0^2)$, em que $\mu \in R^1$ é desconhecido e σ_0^2 é conhecido, e que tomamos como distribuição a priori de μ a $N(\mu, \tau_0^2)$.* Suponhamos que a característica de interesse é $\psi(\mu) = \mu$.

No Exemplo 7.1.2, mostramos que a distribuição a posteriori de μ é a distribuição

$$N\left(\left(\frac{1}{\tau_0^2} + \frac{n}{\sigma_0^2}\right)^{-1}\left(\frac{\mu_0}{\tau_0^2} + \frac{n}{\sigma_0^2}\bar{x}\right), \left(\frac{1}{\tau_0^2} + \frac{n}{\sigma_0^2}\right)^{-1}\right).$$

Como essa distribuição é simétrica em torno de sua moda e a média existe, a moda e a média a posteriori coincidem e são iguais a

$$\left(\frac{1}{\tau_0^2} + \frac{n}{\sigma_0^2}\right)^{-1}\left(\frac{\mu_0}{\tau_0^2} + \frac{n}{\sigma_0^2}\bar{x}\right).$$

Essa é uma média ponderada da média a priori e da média amostral, e fica entre esses dois valores.

Quando n é grande, vemos que esse estimador é aproximadamente igual à média amostral $\bar{x}$, que sabemos também ser o EMV nessa situação. Além disso, quando tomamos a priori muito difusa, isto é, quando τ_0^2 é muito grande, esse estimador também fica próximo da média amostral.

Observe também que a razão entre a variância amostral de $\bar{x}$ e a variância a posteriori de μ é

$$\frac{\sigma_0^2}{n}\left(\frac{1}{\tau_0^2} + \frac{n}{\sigma_0^2}\right) = 1 + \frac{\sigma_0^2}{n\tau_0^2},$$

que é sempre maior que 1. Quanto mais perto de 0 estiver τ_0^2, maior será essa razão. Além disso, quando $\tau_0^2 \to 0$, a estimativa bayesiana converge para μ_0.

Se estivermos bastante confiantes de que a média populacional μ está próxima da média a priori μ_0, tomaremos τ_0^2 pequeno, de modo que o viés da estimativa bayesiana seja pequeno e sua variância seja muito menor que a variância amostral de $\bar{x}$. Nessa situação, o estimador bayesiano é

mais preciso que a média amostral. É claro que, se não estivermos muito confiantes de que μ está próxima da média a priori μ_0, escolhemos um valor grande para τ_0^2, e o estimador bayesiano é basicamente o EMV. ■

Exemplo 7.2.4 — Modelo Multinomial

Suponha que temos uma amostra $(s_1, \ldots, s_n)$ do modelo discutido no Exemplo 7.1.3 e que atribuímos a $(\theta_1, \ldots, \theta_{k-1})$ uma distribuição Dirichlet$(\alpha_1, \alpha_2, \ldots, \alpha_k)$. A distribuição a posteriori de $(\theta_1, \ldots, \theta_{k-1})$ é então

$$\text{Dirichlet}(x_1 + \alpha_1, x_2 + \alpha_2, \ldots, x_k + \alpha_k),$$

em que x_i é o número de respostas na i-ésima categoria.

Suponha agora que nosso interesse está em estimar $\psi(\theta) = \theta_1$, a probabilidade de uma resposta estar na primeira categoria. Pode-se mostrar (veja o Problema 7.2.25) que, se $(\theta_1, \ldots, \theta_{k-1})$ tem distribuição Dirichlet$(\alpha_1, \alpha_2, \ldots, \alpha_k)$, então θ_i tem distribuição

$$\text{Dirichlet}(\alpha_i, \alpha_{-i}) = \text{Beta}(\alpha_i, \alpha_{-i}),$$

em que $\alpha_{-i} = \alpha_1 + \alpha_2 + \cdots + \alpha_k - \alpha_i$. Esse resultado implica que a distribuição a posteriori marginal de θ_1 é

$$\text{Beta}(x_1 + \alpha_1, x_2 + \cdots + x_k + \alpha_2 + \cdots + \alpha_k).$$

Então, supondo que cada $\alpha_i \geq 1$ e usando o argumento do Exemplo 7.2.2 e $x_1 + \cdots + x_k = n$, a moda a posteriori marginal de θ_1 é

$$\hat{\theta}_1 = \frac{x_1 + \alpha_1 - 1}{n - 2 + \alpha_1 + \cdots + \alpha_k}.$$

Quando a priori é a uniforme, isto é, $\alpha_1 = \cdots = \alpha_k = 1$, então

$$\hat{\theta}_1 = \frac{x_1}{n + k - 2}.$$

Como no Exemplo 7.2.2, calculamos que a esperança a posteriori é

$$E(\theta_1 \mid x) = \frac{x_1 + \alpha_1}{n + \alpha_1 + \cdots + \alpha_k}.$$

A distribuição a posteriori é muito assimétrica sempre que $x_1 + \alpha_1$ e $x_2 + \cdots + x_k + \alpha_2 + \cdots + \alpha_k$ estão muito distantes.

*Nota do tradutor. O original traz $N(\mu, \tau_0^2)$; pelo Exemplo 7.1.2 e pelo resto do exemplo, seria $N(\mu_0, \tau_0^2)$.

Pelo Problema 7.2.26, temos que o EMV plug-in de θ_1 é x_1/n. Quando n é grande, as estimativas bayesianas ficam próximas desse valor, de modo que não há conflito entre as estimativas. Note, porém, que, quando a priori é uniforme, $\alpha_1 + \cdots + \alpha_k = k$ e, portanto, o EMV plug-in e as estimativas bayesianas serão bem diferentes quando k for grande em relação a n. Na verdade, a moda a posteriori será sempre menor que o EMV plug-in quando $k > 2$ e $x_1 > 0$. Essa é uma situação em que as abordagens bayesiana e frequentista da inferência diferem.

Neste ponto, a decisão sobre qual estimativa usar fica a cargo de quem aplica o método, pois a teoria não parece dar uma resposta clara. Podemos nos consolar com o fato de que as estimativas não diferirão muito em muitos contextos de importância prática. ■

Exemplo 7.2.5 — Modelo Normal de Locação e Escala

Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição $N(\mu, \sigma^2)$, em que $\mu \in R^1$ e $\sigma > 0$ são desconhecidos, e que usamos a priori dada no Exemplo 7.1.4. Suponhamos que a característica de interesse é $\psi(\mu, \sigma^2) = \mu$.

No Exemplo 7.2.1, deduzimos que a distribuição a posteriori marginal de μ é a mesma distribuição de

$$\mu_x + \sqrt{\frac{1}{2\alpha_0 + n}}\sqrt{\frac{2\beta_x}{n + 1/\tau_0^2}}\, T,$$

em que $T \sim t(n + 2\alpha_0)$. Essa é uma distribuição $t(n + 2\alpha_0)$ deslocada para ter sua moda em μ_x e reescalada pelo fator

$$\sqrt{\frac{1}{2\alpha_0 + n}}\sqrt{\frac{2\beta_x}{n + 1/\tau_0^2}}.$$

Assim, a moda a posteriori marginal de μ é

$$\mu_x = \left(n + \frac{1}{\tau_0^2}\right)^{-1}\left(\frac{\mu_0}{\tau_0^2} + n\bar{x}\right).$$

Como uma distribuição t é simétrica em torno de sua moda, essa é também a média a posteriori de μ, desde que $n + 2\alpha_0 > 1$, pois uma distribuição $t(\lambda)$ só tem média quando $\lambda > 1$ (veja o Problema 4.6.16). Isso sempre acontecerá, já que o tamanho da amostra é $n \geq 1$. Novamente, μ_x é uma média ponderada da média a priori μ_0 e da média amostral $\bar{x}$.

A moda e a esperança a posteriori marginais também podem ser obtidas para $\psi(\mu, \sigma^2) = \sigma^2$. Essas contas ficam para o leitor (veja o Exercício 7.2.4). ■

Uma questão que ainda não abordamos é como avaliar a precisão das estimativas bayesianas. Naturalmente, essa avaliação se baseia na distribuição a posteriori e em quão concentrada ela está em torno da estimativa usada. No caso da média a posteriori, isso significa que calculamos a variância a posteriori como medida de dispersão da distribuição a posteriori de ψ em torno de sua média. Para a moda a posteriori, discutiremos essa questão mais a fundo na Seção 7.2.3.

Exemplo 7.2.6 — Variâncias a Posteriori

No Exemplo 7.2.2, a variância a posteriori de θ é dada por (veja o Exercício 7.2.6)

$$\frac{(n\bar{x}+\alpha)(n(1-\bar{x})+\beta)}{(n+\alpha+\beta)^2(n+\alpha+\beta+1)}.$$

Note que a variância a posteriori converge para 0 quando $n \to \infty$.

No Exemplo 7.2.3, a variância a posteriori é dada por $\left(1/\tau_0^2 + n/\sigma_0^2\right)^{-1}$. Note que a variância a posteriori converge para 0 quando $\tau_0^2 \to 0$ e converge para σ_0^2/n, a variância amostral de $\bar{x}$, quando $\tau_0^2 \to \infty$.

No Exemplo 7.2.4, a variância a posteriori de θ_1 é dada por (veja o Exercício 7.2.7)

$$\frac{(x_1+\alpha_1)(x_2+\cdots+x_k+\alpha_2+\cdots+\alpha_k)}{(n+\alpha_1+\cdots+\alpha_k)^2(n+\alpha_1+\cdots+\alpha_k+1)}.$$

Note que a variância a posteriori converge para 0 quando $n \to \infty$.

No Exemplo 7.2.5, a variância a posteriori de μ é dada por (veja o Problema 7.2.28)

$$\begin{aligned}&\left(\frac{1}{n+2\alpha_0}\right)\left(\frac{2\beta_x}{n+1/\tau_0^2}\right)\left(\frac{n+2\alpha_0}{n+2\alpha_0-2}\right)\\ &\quad=\left(\frac{2\beta_x}{n+1/\tau_0^2}\right)\left(\frac{1}{n+2\alpha_0-2}\right),\end{aligned}$$

desde que $n+2\alpha_0 > 2$, pois a variância de uma distribuição $t(\lambda)$ é $\lambda/(\lambda-2)$ quando $\lambda > 2$ (veja o Problema 4.6.16). Note que a variância a posteriori tende a 0 quando $n \to \infty$. ■

7.2.2 Intervalos de Credibilidade

Um *intervalo de credibilidade*[32] para um parâmetro $\psi(\theta)$ a valores reais é um intervalo $C(s) = [l(s), u(s)]$ que acreditamos que conterá o verdadeiro valor de ψ. Como na abordagem da teoria amostral, especificamos uma probabilidade γ e então encontramos um intervalo $C(s)$ que satisfaça

$$\Pi(\psi(\theta) \in C(s) \,|\, s) = \Pi(\{\theta : l(s) \le \psi(\theta) \le u(s)\} \,|\, s) \ge \gamma. \tag{7.2.3}$$

Chamamos então $C(s)$ de intervalo de credibilidade γ para ψ.

No original: *credible interval*[32].

Naturalmente, procuramos um intervalo de credibilidade γ, $C(s)$, tal que $\Pi(\psi(\theta) \in C(s) \mid s)$ seja o mais próximo possível de γ e tal que $C(s)$ seja o mais curto possível. Isso leva a considerar os *intervalos de maior densidade a posteriori*[33] *(HPD)*, que são da forma

$$C(s) = \{\psi : \omega(\psi \mid s) \geq c\},$$

em que $\omega(\cdot \mid s)$ é a densidade a posteriori marginal de ψ e c é escolhido o maior possível de modo que (7.2.3) seja satisfeita. Na Figura 7.2.1, traçamos um exemplo de intervalo HPD para um dado valor de c.

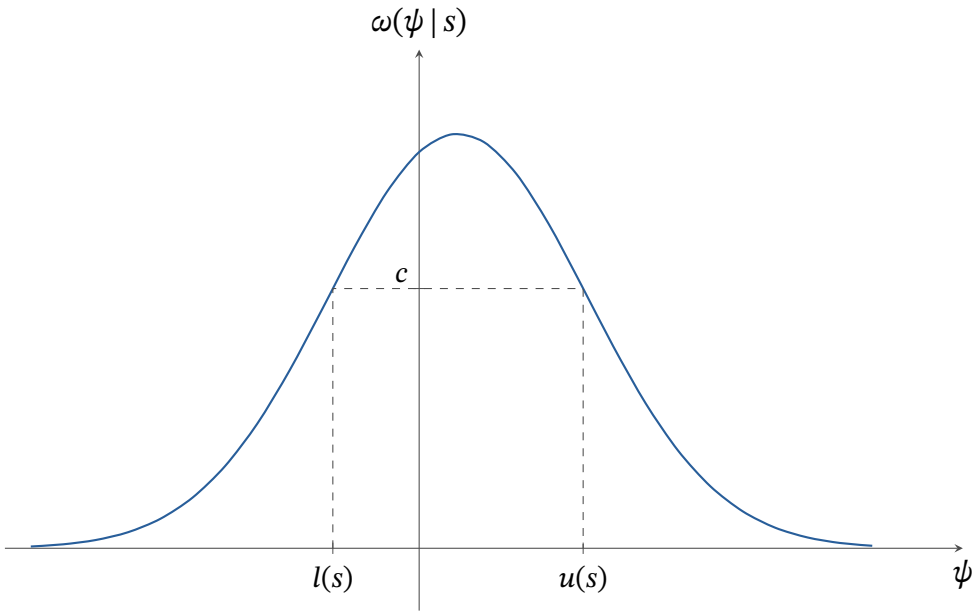


Figura 7.2.1: Um intervalo HPD $C(s) = [l(s), u(s)] = \{\psi : \omega(\psi \mid s) \geq c\}$.

É claro que $C(s)$ contém a moda sempre que $c \leq \max_\psi \omega(\psi \mid s)$. Podemos tomar o comprimento de um intervalo HPD como medida da precisão da moda de $\omega(\cdot \mid s)$ como estimador de $\psi(\theta)$. O comprimento de um intervalo de credibilidade 0,95 para ψ servirá ao mesmo propósito que a margem de erro nos intervalos de confiança.

Considere agora algumas aplicações do conceito de intervalo de credibilidade.

Exemplo 7.2.7 — Modelo Normal de Locação

Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição $N(\mu, \sigma_0^2)$, em que $\mu \in R^1$ é desconhecido e σ_0^2 é conhecido, e que tomamos como distribuição a priori de μ a $N(\mu_0, \tau_0^2)$. No Exemplo 7.1.2, mostramos que a

No original: *highest posterior density*[33].

distribuição a posteriori de μ é a distribuição

$$N\left(\left(\frac{1}{\tau_0^2}+\frac{n}{\sigma_0^2}\right)^{-1}\left(\frac{\mu_0}{\tau_0^2}+\frac{n}{\sigma_0^2}\bar{x}\right),\left(\frac{1}{\tau_0^2}+\frac{n}{\sigma_0^2}\right)^{-1}\right).$$

Como essa distribuição é simétrica em torno de sua moda (que é também a média) $\hat{\mu}$, um intervalo γ-HPD mais curto é da forma

$$\hat{\mu} \pm \left(\frac{1}{\tau_0^2}+\frac{n}{\sigma_0^2}\right)^{-1/2} c,$$

em que c é tal que

$$\begin{aligned}\gamma &= \Pi\left(\mu \in \left[\hat{\mu} \pm \left(\frac{1}{\tau_0^2}+\frac{n}{\sigma_0^2}\right)^{-1/2} c\right] \middle| x_1, \ldots, x_n\right) \\ &= \Pi\left(-c \leq \left(\frac{1}{\tau_0^2}+\frac{n}{\sigma_0^2}\right)^{1/2} (\mu-\hat{\mu}) \leq c \middle| x_1, \ldots, x_n\right).\end{aligned}$$

Como

$$\left(\frac{1}{\tau_0^2}+\frac{n}{\sigma_0^2}\right)^{1/2} (\mu-\hat{\mu}) \mid x_1, \ldots, x_n \sim N(0,1),$$

temos $\gamma = \Phi(c) - \Phi(-c)$, em que Φ é a função de distribuição acumulada (fda) normal padrão. Isso implica imediatamente que $c = z_{(1+\gamma)/2}$ e que o intervalo γ-HPD é dado por

$$\left(\frac{1}{\tau_0^2}+\frac{n}{\sigma_0^2}\right)^{-1}\left(\frac{\mu_0}{\tau_0^2}+\frac{n}{\sigma_0^2}\bar{x}\right) \pm \left(\frac{1}{\tau_0^2}+\frac{n}{\sigma_0^2}\right)^{-1/2} z_{(1+\gamma)/2}.$$

Note que, quando $\tau_0^2 \to \infty$, isto é, à medida que a priori se torna cada vez mais difusa, esse intervalo converge para o intervalo

$$\bar{x} \pm \frac{\sigma_0}{\sqrt{n}} z_{(1+\gamma)/2},$$

que é também o intervalo de confiança γ deduzido no Capítulo 6 para esse problema. Assim, sob uma priori normal difusa, as abordagens bayesiana e frequentista concordam. ■

Exemplo 7.2.8 — Modelo Normal de Locação e Escala

Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição $N(\mu, \sigma^2)$, em que $\mu \in R^1$ e $\sigma \geq 0$ são desconhecidos, e que usamos a priori dada no Exemplo 7.1.4. No Exemplo 7.2.1, deduzimos que a distribuição a posteriori marginal de μ é a mesma distribuição de

$$\mu_x + \sqrt{\frac{1}{2\alpha_0 + n}}\sqrt{\frac{2\beta_x}{n + 1/\tau_0^2}}\, T,$$

em que $T \sim t(2\alpha_0 + n)$. Como essa distribuição é simétrica em torno de sua moda μ_x, um intervalo γ-HPD é da forma

$$\mu_x \pm \sqrt{\frac{1}{2\alpha_0 + n}}\sqrt{\frac{2\beta_x}{n + 1/\tau_0^2}}\, c,$$

em que c satisfaz*

$$\begin{aligned}\gamma &= \Pi\left(\mu \in \left[\mu_x \pm \sqrt{\frac{1}{2\alpha_0 + n}}\sqrt{\frac{2\beta_x}{n + 1/\tau_0^2}}\, c\right] \middle| x_1, \ldots, x_n\right) \\ &= \Pi\left(-c \leq \left(\frac{2\beta_x}{(2\alpha_0 + n)\left(n + 1/\tau_0^2\right)}\right)^{-1/2} (\mu - \hat{\mu}) \leq c \middle| x_1, \ldots, x_n\right) \\ &= G_{2\alpha_0+n}(c) - G_{2\alpha_0+n}(-c).\end{aligned}$$

Aqui, $G_{2\alpha_0+n}$ é a fda da $t(2\alpha_0 + n)$ e, portanto, $c = t_{(1+\gamma)/2}(2\alpha_0 + n)$.

Usando (7.1.9), (7.1.10) e (7.1.11), temos que esse intervalo converge para o intervalo†

$$\bar{x} \pm \sqrt{\frac{n-1}{(2\alpha_0 + n)}}\frac{s}{\sqrt{n}}\, t(n + 2\alpha_0)$$

quando $\tau_0 \to \infty$ e $\beta_0 \to 0$. Note que esse intervalo é um pouco diferente do intervalo de confiança γ que obtivemos para μ no Exemplo 6.3.8, mas, quando α_0/n é pequeno, eles são praticamente idênticos. ■

Nos exemplos que consideramos até aqui, conseguimos obter expressões em forma fechada para os intervalos HPD. Em geral, isso não acontece. Nessas situações, temos de recorrer a métodos numéricos para obter os intervalos HPD, mas não vamos nos aprofundar nesse tema aqui.

*Nota do tradutor. Na segunda linha, o original traz $(\mu - \hat{\mu})$; neste exemplo a moda é μ_x, e seria $(\mu - \mu_x)$.

†Nota do tradutor. O original traz $t(n + 2\alpha_0)$ sem o índice do quantil; pela conta acima, seria $t_{(1+\gamma)/2}(n + 2\alpha_0)$.

Há outros métodos de obter intervalos de credibilidade. Por exemplo, um método comum de obter um intervalo de credibilidade γ para ψ é tomar o intervalo $[\psi_l, \psi_r]$, em que ψ_l é um quantil $(1-\gamma)/2$ da distribuição a posteriori de ψ e ψ_r é um quantil $1-(1-\gamma)/2$ dessa distribuição. Alternativamente, poderíamos formar intervalos unilaterais. Esses intervalos de credibilidade evitam as contas mais extensas que podem ser necessárias para os intervalos HPD.

7.2.3 Teste de Hipóteses e Fatores de Bayes

Suponha agora que queremos avaliar a evidência que os dados observados trazem a respeito da hipótese $H_0 : \psi(\theta) = \psi_0$. Parece claro como devemos fazer essa avaliação, a saber, calculando a probabilidade a posteriori

$$\Pi(\psi(\theta) = \psi_0 \,|\, s). \tag{7.2.4}$$

Se ela for pequena, concluímos que temos evidência contra H_0. Veremos outras justificativas para essa abordagem no Capítulo 8.

Exemplo 7.2.9

Suponha que queremos avaliar a evidência a respeito de $\theta \in A$ ou não. Se tomarmos $\psi = I_A$, estamos avaliando a hipótese $H_0 : \psi(\theta) = 1$ e

$$\Pi(\psi(\theta) = 1 \,|\, s) = \Pi(A \,|\, s).$$

Assim, nesse caso, simplesmente calculamos a probabilidade a posteriori de que $\theta \in A$. ■

Pode haver um problema, porém, no uso de (7.2.4) para avaliar uma hipótese. Pois, quando a distribuição a priori de ψ é absolutamente contínua, então $\Pi(\psi(\theta) = \psi_0 \,|\, s) = 0$ para quaisquer dados s. Portanto, sempre encontraríamos evidência contra H_0, não importa o que fosse observado, o que não faz sentido. Em geral, se o valor ψ_0 recebe probabilidade a priori pequena, pode acontecer de esse valor ter também probabilidade a posteriori pequena, não importa quais dados sejam observados.

Para evitar esse problema, às vezes se usa uma abordagem alternativa para a avaliação de hipóteses. Lembre que, se ψ_0 é um valor surpreendente para a distribuição a posteriori de ψ, isso é evidência de que H_0 é falsa. O valor ψ_0 é surpreendente sempre que está numa região de baixa probabilidade da distribuição a posteriori de ψ. Uma região de baixa probabilidade corresponde

a uma região onde a densidade a posteriori $\omega(\cdot \mid s)$ é relativamente baixa. Assim, um método possível para fazer essa avaliação é calcular o *valor-p (bayesiano)*

$$\Pi(\{\theta : \omega(\psi(\theta) \mid s) \leq \omega(\psi_0 \mid s)\} \mid s). \tag{7.2.5}$$

Note que, quando $\omega(\cdot \mid s)$ é unimodal, (7.2.5) corresponde a calcular uma probabilidade de cauda. Se a probabilidade (7.2.5) for pequena, então ψ_0 é surpreendente, pelo menos em relação às nossas crenças a posteriori. Quando decidimos rejeitar H_0 sempre que o valor-p for menor que $1-\gamma$, essa abordagem equivale a calcular uma região HPD γ para ψ e rejeitar H_0 sempre que ψ_0 não estiver na região.

Exemplo 7.2.10 — continuação do Exemplo 7.2.9

Aplicando a abordagem do valor-p a esse problema, vemos que $\psi(\theta) = I_A(\theta)$ tem distribuição a posteriori Bernoulli($\Pi(A \mid s)$). Portanto, $\omega(\cdot \mid s)$ é definida por $\omega(0 \mid s) = 1 - \Pi(A \mid s) = \Pi(A^c \mid s)$ e $\omega(1 \mid s) = \Pi(A \mid s)$.

Agora $\psi_0 = 1$, então

$$\begin{aligned}\{\theta : \omega(\psi(\theta) \mid s) \leq \omega(1 \mid s)\} &= \{\theta : \omega(I_A(\theta) \mid s) \leq \Pi(A \mid s)\} \\ &= \begin{cases} \boldsymbol{\Omega} & \Pi(A \mid s) \geq \Pi(A^c \mid s) \\ A & \Pi(A \mid s) < \Pi(A^c \mid s). \end{cases}\end{aligned}$$

Portanto, (7.2.5) fica

$$\Pi(\{\theta : \omega(\psi(\theta) \mid s) \leq \omega(1 \mid s)\} \mid s) = \begin{cases} 1 & \Pi(A \mid s) \geq \Pi(A^c \mid s) \\ \Pi(A \mid s) & \Pi(A \mid s) < \Pi(A^c \mid s), \end{cases}$$

de modo que, de novo, temos evidência contra H_0 sempre que $\Pi(A \mid s)$ é pequena. ■

Vemos pelos Exemplos 7.2.9 e 7.2.10 que calcular o valor-p (7.2.5) equivale essencialmente a usar (7.2.4) sempre que o parâmetro marginal ψ assume apenas dois valores. Isso não acontece, porém, quando ψ assume mais de dois valores, e o estatístico tem de decidir qual método é mais apropriado nesse contexto.

Como já observado, quando a distribuição a priori de ψ é absolutamente contínua, (7.2.4) é sempre 0, não importa quais dados sejam observados. Como o exemplo a seguir ilustra, também há uma dificuldade no uso de (7.2.5) nessa situação.

Exemplo 7.2.11

Suponha que a distribuição a posteriori de θ seja Beta$(2, 1)$, isto é, $\omega(\theta \mid s) = 2\theta$ quando $0 \leq \theta \leq 1$, e que queremos avaliar $H_0 : \theta = 3/4$. Então $\omega(\theta \mid s) \leq \omega(3/4 \mid s)$ se e somente se $\theta \leq 3/4$, e (7.2.5) é dado por

$$\int_0^{3/4} 2\theta \, d\theta = 9/16.$$

Por outro lado, suponha que fazemos uma transformação 1–1 para $\rho = \theta^2$, de modo que a hipótese passa a ser $H_0 : \rho = 9/16$. A distribuição a posteriori de ρ é Beta$(1, 1)$. Como a densidade a posteriori de ρ é constante, a densidade a posteriori em todo valor possível é menor ou igual à densidade a posteriori calculada em $9/16$. Portanto, (7.2.5) é igual a 1, e nunca encontraríamos evidência contra H_0 usando essa parametrização.

Esse exemplo mostra que nossa avaliação de H_0 via (7.2.5) depende da parametrização usada, o que não parece apropriado. ■

A dificuldade no uso de (7.2.5), demonstrada no Exemplo 7.2.11, só ocorre com distribuições a posteriori contínuas. Assim, para evitar esse problema, recomenda-se muitas vezes que a hipótese a ser testada receba sempre uma probabilidade a priori positiva. Como demonstrado no Exemplo 7.2.10, a abordagem via (7.2.5) passa então a ser essencialmente equivalente a usar (7.2.4) para avaliar H_0.

Em problemas em que parece natural usar distribuições a priori contínuas, isso se consegue tomando a distribuição a priori Π como uma mistura de distribuições de probabilidade, como discutido na Seção 2.5.4, a saber, a distribuição a priori é igual a

$$\Pi = p\Pi_1 + (1 - p)\,\Pi_2,$$

onde $\Pi_1(\psi(\theta) = \psi_0) = 1$ e $\Pi_2(\psi(\theta) = \psi_0) = 0$, isto é, Π_1 é degenerada em ψ_0 e Π_2 é contínua em ψ_0. Então

$$\Pi(\psi(\theta) = \psi_0) = p\Pi_1(\psi(\theta) = \psi_0) + (1 - p)\,\Pi_2(\psi(\theta) = \psi_0) = p > 0$$

é a probabilidade a priori de que H_0 seja verdadeira.

A preditiva a priori para os dados s é então dada por

$$m(s) = pm_1(s) + (1 - p)m_2(s),$$

onde m_i é a preditiva a priori obtida com a distribuição a priori Π_i (ver Problema 7.2.34). Isso implica (ver Problema 7.2.34) que a medida de probabilidade a posteriori para θ, quando se usa a distribuição a priori Π, é

$$\Pi(A \mid s) = \frac{pm_1(s)}{pm_1(s) + (1-p)m_2(s)} \Pi_1(A \mid s) + \frac{(1-p)\, m_2(s)}{pm_1(s) + (1-p)m_2(s)} \Pi_2(A \mid s) \tag{7.2.6}$$

onde $\Pi_i(\cdot \mid s)$ é a medida a posteriori obtida com a distribuição a priori Π_i. Note que isso é uma mistura das medidas de probabilidade a posteriori $\Pi_1(\cdot \mid s)$ e $\Pi_2(\cdot \mid s)$, com probabilidades de mistura

$$\frac{pm_1(s)}{pm_1(s) + (1-p)m_2(s)} \quad \text{e} \quad \frac{(1-p)\, m_2(s)}{pm_1(s) + (1-p)m_2(s)}.$$

Agora, $\Pi_1(\cdot \mid s)$ é degenerada em ψ_0 (se a distribuição a priori é degenerada num ponto, a distribuição a posteriori também tem de ser degenerada nesse ponto) e $\Pi_2(\cdot \mid s)$ é contínua em ψ_0. Portanto,

$$\Pi(\psi(\theta) = \psi_0 \mid s) = \frac{pm_1(s)}{pm_1(s) + (1-p)m_2(s)}, \tag{7.2.7}$$

e usamos essa probabilidade para avaliar H_0.

O exemplo a seguir ilustra essa abordagem.

Exemplo 7.2.12 — Modelo Normal de Locação

Suponha que $(x_1, \ldots, x_n)$ seja uma amostra de uma distribuição $N(\mu, \sigma_0^2)$, em que $\mu \in R^1$ é desconhecido e σ_0^2 é conhecido, e que queremos avaliar a hipótese $H_0 : \mu = \mu_0$. Como no Exemplo 7.1.2, vamos tomar como distribuição a priori de μ uma distribuição $N(\mu_0, \tau_0^2)$. Como estamos avaliando se $\mu = \mu_0$ ou não, parece razoável pôr a moda da distribuição a priori no valor da hipótese. A escolha do hiperparâmetro τ_0^2 reflete então o grau da nossa crença a priori de que H_0 é verdadeira. Denotamos essa medida de probabilidade a priori por Π_2, isto é, Π_2 é a medida de probabilidade $N(\mu_0, \sigma_0^2)$.*

Se usarmos Π_2 como distribuição a priori, então, como mostrado no Exemplo 7.1.2, a distribuição a posteriori de μ é absolutamente contínua. Isso implica que (7.2.4) é 0. Assim, seguindo a discussão anterior, consideramos em vez disso a distribuição a priori $\Pi = p\Pi_1 + (1 - p)\Pi_2$, obtida misturando Π_2 com uma medida de probabilidade Π_1 degenerada em μ_0. Então $\Pi_1(\{\mu_0\}) = 1$ e, assim, $\Pi(\{\mu_0\}) = p$. Como mostrado no Exemplo 7.1.2, sob Π_2 a distribuição a posteriori de μ é

$$N\left(\left(\frac{1}{\tau_0^2} + \frac{n}{\sigma_0^2}\right)^{-1}\left(\frac{\mu_0}{\tau_0^2} + \frac{n}{\sigma_0^2}\bar{x}\right), \left(\frac{1}{\tau_0^2} + \frac{n}{\sigma_0^2}\right)^{-1}\right),$$

enquanto a distribuição a posteriori sob Π_1 é a distribuição degenerada em μ_0. Precisamos agora calcular (7.2.7), e faremos isso no Exemplo 7.2.13. ■

Fatores de Bayes

Os fatores de Bayes formam outro método de avaliação de hipóteses e são definidos em termos de chances.

Definição 7.2.1

Num modelo de probabilidade com espaço amostral S e medida de probabilidade P, a *chance a favor* do evento $A \subset S$ é definida como $P(A)/P(A^c)$, isto é, a razão entre a probabilidade de A e a probabilidade de A^c.

Obviamente, valores grandes da chance a favor de A indicam uma crença forte de que A é verdadeiro. As chances são outra maneira de apresentar probabilidades, conveniente em certos contextos, por exemplo, nas corridas de

*Nota do tradutor. o original traz $N(\mu_0, \sigma_0^2)$; pela definição de Π_2 acima, seria $N(\mu_0, \tau_0^2)$.

cavalos. Os fatores de Bayes comparam a chance a posteriori[34] com a chance a priori[35].

Definição 7.2.2

O *fator de Bayes* BF_{H_0} *a favor da hipótese* $H_0 : \psi(\theta) = \psi_0$ é definido, sempre que a probabilidade a priori de H_0 não for 0 nem 1, como a razão entre a *chance a posteriori* a favor de H_0 e a *chance a priori* a favor de H_0, ou seja,

$$BF_{H_0} = \left\{ \frac{\Pi(\psi(\theta) = \psi_0 \mid s)}{1 - \Pi(\psi(\theta) = \psi_0 \mid s)} \right\} \Big/ \left\{ \frac{\Pi(\psi(\theta) = \psi_0)}{1 - \Pi(\psi(\theta) = \psi_0)} \right\}. \tag{7.2.8}$$

Assim, o fator de Bayes[36] a favor de H_0 mede o quanto os dados mudaram a chance a favor da hipótese. Se BF_{H_0} é pequeno, os dados fornecem evidência contra H_0, e evidência a favor de H_0 quando BF_{H_0} é grande.

Há uma relação entre a probabilidade a posteriori de H_0 ser verdadeira e BF_{H_0}. De (7.2.8), obtemos

$$\Pi(\psi(\theta) = \psi_0 \mid s) = \frac{rBF_{H_0}}{1 + rBF_{H_0}}, \tag{7.2.9}$$

onde

$$r = \frac{\Pi(\psi(\theta) = \psi_0)}{1 - \Pi(\psi(\theta) = \psi_0)}$$

é a chance a priori a favor de H_0. Assim, quando BF_{H_0} é pequeno, $\Pi(\psi(\theta) = \psi_0 \mid s)$ é pequena, e vice-versa.

Uma razão para usar fatores de Bayes na avaliação de hipóteses é o resultado a seguir, que estabelece uma ligação com as razões de verossimilhança.

Teorema 7.2.1

Se a distribuição a priori Π é uma mistura $\Pi = p\Pi_1 + (1 - p)\Pi_2$, em que $\Pi_1(A) = 1$, $\Pi_2(A^C) = 1$, e queremos avaliar a hipótese $H_0 : \theta \in A$, então

$$BF_{H_0} = m_1(s)/m_2(s),$$

onde m_i é a preditiva a priori dos dados sob Π_i.

Demonstração. Lembre que, se uma distribuição a priori concentra toda a sua probabilidade num conjunto, então a distribuição a posteriori também

No original: *posterior odds*[34], *prior odds*[35], *Bayes factor*[36].

concentra toda a sua probabilidade nesse conjunto. Então, usando (7.2.6), temos

$$BF_{H_0} = \frac{\Pi(A \mid s)}{1 - \Pi(A \mid s)} \Big/ \frac{\Pi(A)}{1 - \Pi(A)} = \frac{p m_1(s)}{(1-p)\, m_2(s)} \Big/ \frac{p}{1-p} = \frac{m_1(s)}{m_2(s)}. \qquad \blacksquare$$

Curiosamente, o Teorema 7.2.1 indica que o fator de Bayes não depende de p. Observamos, porém, que não é imediatamente claro como interpretar o valor de BF_{H_0}. Em particular, quão grande BF_{H_0} precisa ser para fornecer evidência forte a favor de H_0? Uma abordagem para esse problema é usar (7.2.9), já que ela dá a probabilidade a posteriori de H_0, que é diretamente interpretável. Assim, podemos calibrar o fator de Bayes. Note, porém, que isso exige especificar p.

Exemplo 7.2.13 — Modelo Normal de Locação (continuação do Exemplo 7.2.12)

Calculamos agora a preditiva a priori sob Π_2. Temos que a densidade conjunta de $(x_1, \ldots, x_n)$ dado μ é igual a

$$(2\pi\sigma_0^2)^{-n/2} \exp\left(-\frac{n-1}{2\sigma_0^2}\, s^2\right) \exp\left(-\frac{n}{2\sigma_0^2}\,(\bar{x}-\mu)^2\right)$$

e, assim,

$$\begin{aligned}
&m_2(x_1, \ldots, x_n) \\
&= \int_{-\infty}^{\infty} \left\{ \begin{array}{c} (2\pi\sigma_0^2)^{-n/2} \exp\left(-\frac{n-1}{2\sigma_0^2}\, s^2\right) \exp\left(-\frac{n}{2\sigma_0^2}\,(\bar{x}-\mu)^2\right) \\ \times (2\pi\tau_0^2)^{-1/2} \exp\left(-\frac{1}{2\tau_0^2}\,(\mu-\mu_0)^2\right) \end{array} \right\} d\mu \\
&= (2\pi\sigma_0^2)^{-n/2} \exp\left(-\frac{n-1}{2\sigma_0^2}\, s^2\right) \\
&\quad \times \tau_0^{-1}(2\pi)^{-1/2} \int_{-\infty}^{\infty} \exp\left(-\frac{n}{2\sigma_0^2}\,(\bar{x}-\mu)^2\right) \exp\left(-\frac{1}{2\tau_0^2}\,(\mu-\mu_0)^2\right) d\mu.
\end{aligned}$$

Então, usando (7.1.2), temos

$$\begin{aligned}
&\tau_0^{-1}(2\pi)^{-1/2} \int_{-\infty}^{\infty} \exp\left(-\frac{n}{2\sigma_0^2}\,(\bar{x}-\mu)^2\right) \exp\left(-\frac{1}{2\tau_0^2}\,(\mu-\mu_0)^2\right) d\mu \\
&= \tau_0^{-1} \exp\left(\frac{1}{2}\left(\frac{1}{\tau_0^2} + \frac{n}{\sigma_0^2}\right)^{-1} \left(\frac{\mu_0}{\tau_0^2} + \frac{n}{\sigma_0^2}\,\bar{x}\right)^2\right) \\
&\quad \times \exp\left(-\frac{1}{2}\left(\frac{\mu_0^2}{\tau_0^2} + \frac{n\bar{x}^2}{\sigma_0^2}\right)\right) \left(\frac{n}{\sigma_0^2} + \frac{1}{\tau_0^2}\right)^{-1/2}. \qquad (7.2.10)
\end{aligned}$$

Portanto,

$$\begin{aligned} & m_2(x_1, \ldots, x_n) \\ &= (2\pi\sigma_0^2)^{-n/2} \exp\left(-\frac{n-1}{2\sigma_0^2} s^2\right) \tau_0^{-1} \exp\left(\frac{1}{2}\left(\frac{1}{\tau_0^2} + \frac{n}{\sigma_0^2}\right)^{-1} \left(\frac{\mu_0}{\tau_0^2} + \frac{n}{\sigma_0^2}\bar{x}\right)^2\right) \\ &\quad \times \exp\left(-\frac{1}{2}\left(\frac{\mu_0^2}{\tau_0^2} + \frac{n\bar{x}^2}{\sigma_0^2}\right)\right)\left(\frac{n}{\sigma_0^2} + \frac{1}{\tau_0^2}\right)^{-1/2}. \end{aligned}$$

Como Π_1 é degenerada em μ_0, é imediato que a preditiva a priori sob Π_1 é dada por

$$m_1(x_1, \ldots, x_n) = (2\pi\sigma_0^2)^{-n/2} \exp\left(-\frac{n-1}{2\sigma_0^2} s^2\right) \exp\left(-\frac{n}{2\sigma_0^2}(\bar{x} - \mu_0)^2\right).$$

Portanto, BF_{H_0} é igual a

$$\exp\left(-\frac{n}{2\sigma_0^2}(\bar{x} - \mu_0)^2\right)$$

dividido por (7.2.10).

Por exemplo, suponha que $\mu_0 = 0$, $\tau_0^2 = 2$, $\sigma_0^2 = 1$, $n = 10$ e $\bar{x} = 0{,}2$. Então

$$\exp\left(-\frac{n}{2\sigma_0^2}(\bar{x} - \mu_0)^2\right) = \exp\left(-\frac{10}{2}(0{,}2)^2\right) = 0{,}81873,$$

enquanto (7.2.10) é igual a

$$\begin{aligned} & \frac{1}{\sqrt{2}} \exp\left(\frac{1}{2}\left(\frac{1}{2} + 10\right)^{-1} (10\,(0{,}2))^2\right) \exp\left(-\frac{10\,(0{,}2)^2}{2}\right)\left(10 + \frac{1}{2}\right)^{-1/2} \\ &= 0{,}21615. \end{aligned}$$

Assim,

$$BF_{H_0} = \frac{0{,}81873}{0{,}21615} = 3{,}7878,$$

o que dá alguma evidência a favor de $H_0 : \mu = \mu_0$. Se supusermos que $p = 1/2$, de modo que somos completamente indiferentes entre H_0 ser verdadeira ou não, então $r = 1$, e (7.2.9) dá

$$\Pi(\mu = 0 \mid x_1, \ldots, x_n) = \frac{3{,}7878}{1 + 3{,}7878} = 0{,}79114,$$

o que indica um grau alto de apoio a H_0. ■

7.2.4 Predição

Problemas de predição[37] surgem quando temos um valor de resposta não observado t num espaço amostral[38] T e uma resposta observada $s \in S$. Além disso, temos o modelo estatístico $\{P_\theta : \theta \in \mathbf{\Omega}\}$ para s e o modelo estatístico condicional $\{Q_\theta(\cdot \mid s) : \theta \in \mathbf{\Omega}\}$ para t dado s. Supomos que os dois modelos têm o mesmo valor verdadeiro de $\theta \in \mathbf{\Omega}$. O objetivo é construir uma *predição* $\tilde{t}(s) \in T$ do valor não observado t, com base nos dados observados s. O valor de t pode ser desconhecido simplesmente porque representa um resultado futuro.

Se denotarmos a densidade condicional[39] ou a função de probabilidade condicional[40] (a que for pertinente) de t por $q_\theta(\cdot \mid s)$, a distribuição conjunta de (θ, s, t) é dada por

$$q_\theta(t \mid s) f_\theta(s) \pi(\theta).$$

Então, depois de observar s (suponha aqui que as distribuições de θ e de t são absolutamente contínuas; se não forem, trocamos as integrais por somas), a densidade condicional de (t, θ), dado s, é

$$\frac{q_\theta(t \mid s) f_\theta(s) \pi(\theta)}{\int_{\mathbf{\Omega}} \int_T q_\theta(t \mid s) f_\theta(s) \pi(\theta)\, dt\, d\theta} = \frac{q_\theta(t \mid s) f_\theta(s) \pi(\theta)}{\int_{\mathbf{\Omega}} f_\theta(s) \pi(\theta)\, d\theta} = \frac{q_\theta(t \mid s) f_\theta(s) \pi(\theta)}{m(s)}.$$

Então, a distribuição a posteriori marginal de t, conhecida como a *preditiva a posteriori*[41] de t, é

$$q(t \mid s) = \int_{\mathbf{\Omega}} \frac{q_\theta(t \mid s) f_\theta(s) \pi(\theta)}{m(s)}\, d\theta = \int_{\mathbf{\Omega}} q_\theta(t \mid s) \pi(\theta \mid s)\, d\theta.$$

Note que a preditiva a posteriori de t é obtida tomando a média da densidade condicional de t, dado (θ, s), em relação à distribuição a posteriori de θ.

Agora que obtivemos a distribuição preditiva a posteriori de t, podemos usá-la para escolher uma estimativa do valor não observado. De novo, poderíamos escolher como nossa predição a moda a posteriori $\hat{t}$ ou a esperança a posteriori $E(t \mid x) = \int_T t\, q(t \mid s)\, dt$, a que for considerada mais pertinente.*

*Nota do tradutor. o original traz $E(t \mid x)$; pela notação da seção, seria $E(t \mid s)$.

No original: *prediction*[37], *sample space*[38], *conditional density*[39], *conditional probability function*[40], *posterior predictive*[41].

Exemplo 7.2.14 — Modelo de Bernoulli

Suponha que queremos predizer o próximo resultado independente X_{n+1}, tendo observado uma amostra $(x_1, \dots, x_n)$ da Bernoulli(θ) e $\theta \sim \text{Beta}(\alpha, \beta)$. Aqui, a observação futura é independente dos dados observados. A função de probabilidade preditiva a posteriori de X_{n+1} em t é então dada por

$$
\begin{aligned}
&q(t \mid x_1, \dots, x_n) \\
&= \int_0^1 \theta^t (1-\theta)^{1-t} \frac{\Gamma(n+\alpha+\beta)}{\Gamma(n\bar{x}+\alpha)\Gamma(n(1-\bar{x})+\beta)} \theta^{n\bar{x}+\alpha-1}(1-\theta)^{n(1-\bar{x})+\beta-1}\, d\theta \\
&= \frac{\Gamma(n+\alpha+\beta)}{\Gamma(n\bar{x}+\alpha)\Gamma(n(1-\bar{x})+\beta)} \int_0^1 \theta^{n\bar{x}+\alpha+t-1}(1-\theta)^{n(1-\bar{x})+\beta+(1-t)-1}\, d\theta \\
&= \frac{\Gamma(n+\alpha+\beta)}{\Gamma(n\bar{x}+\alpha)\Gamma(n(1-\bar{x})+\beta)} \frac{\Gamma(n\bar{x}+\alpha+t)\Gamma(n(1-\bar{x})+\beta+1-t)}{\Gamma(n+\alpha+\beta+1)} \\
&= \begin{cases} \dfrac{n\bar{x}+\alpha}{n+\alpha+\beta} & t = 1 \\ \dfrac{n(1-\bar{x})+\beta}{n+\alpha+\beta} & t = 0, \end{cases}
\end{aligned}
$$

que é a função de probabilidade de uma distribuição Bernoulli($(n\bar{x}+\alpha)/(n+\alpha+\beta)$).

Usar a moda a posteriori como preditor, isto é, maximizar $q(t \mid x_1, \dots, x_n)$ em t, leva à predição

$$
\hat{t} = \begin{cases} 1 & \text{se } \dfrac{n\bar{x}+\alpha}{n+\alpha+\beta} \geq \dfrac{n(1-\bar{x})+\beta}{n+\alpha+\beta}, \\ 0 & \text{caso contrário.} \end{cases}
$$

O preditor esperança a posteriori é dado por

$$
E(t \mid x_1, \dots, x_n) = \frac{n\bar{x}+\alpha}{n+\alpha+\beta}.
$$

Note que a moda a posteriori assume um valor em $\{0, 1\}$, e o X_{n+1} futuro também estará nesse conjunto. A média a posteriori pode ser qualquer valor em $[0, 1]$. ■

Exemplo 7.2.15 — Modelo Normal de Locação

Suponha que $(x_1, \ldots, x_n)$ seja uma amostra de uma distribuição $N(\mu, \sigma_0^2)$, em que $\mu \in R^1$ é desconhecido e σ_0^2 é conhecido, e que usamos a distribuição a priori dada no Exemplo 7.1.2. Suponha que queremos predizer uma observação futura X_{n+1}, mas que desta vez X_{n+1} vem da distribuição

$$N\left(\bar{x}, \left(\frac{1}{\tau_0^2} + \frac{n}{\sigma_0^2}\right)^{-1} \sigma_0^2\right). \tag{7.2.11}$$

Assim, nesse caso, a observação futura não é independente dos dados observados, mas é independente do parâmetro. Uma conta simples (ver Exercício 7.2.9) mostra que (7.2.11) é a distribuição preditiva a posteriori de t, e assim prediríamos t por $\bar{x}$, já que esse valor é ao mesmo tempo a moda e a média a posteriori. ■

Podemos também construir uma *região de predição* γ, $C(s)$, para um valor futuro t a partir do modelo $\{q_\theta(\cdot \mid s) : \theta \in \mathbf{\Omega}\}$. Uma região de predição γ para t satisfaz $Q(C(s) \mid s \geq \gamma)$, onde $Q(\cdot \mid s)$ é a medida preditiva a posteriori para t.* Uma abordagem para construir $C(s)$ é aplicar o conceito de HPD a $q(t \mid s)$. Ilustramos isso com vários exemplos.

Exemplo 7.2.16 — Modelo de Bernoulli (continuação do Exemplo 7.2.14)

Suponha que queremos uma região de predição γ para um valor futuro X_{n+1}. No Exemplo 7.2.14, deduzimos que a distribuição preditiva a posteriori de X_{n+1} é

$$\text{Bernoulli}\left(\frac{n\bar{x} + \alpha}{n + \alpha + \beta}\right).$$

Assim, uma região de predição γ para t, obtida pelo conceito de HPD, é dada por

$$C(x_1, \ldots, x_n) = \begin{cases} \{0, 1\} & \text{se } \max\left\{\frac{n\bar{x}+\alpha}{n+\alpha+\beta}, \frac{n(1-\bar{x})+\beta}{n+\alpha+\beta}\right\} \leq \gamma, \\ \{1\} & \text{se } \gamma \leq \max\left\{\frac{n\bar{x}+\alpha}{n+\alpha+\beta}, \frac{n(1-\bar{x})+\beta}{n+\alpha+\beta}\right\} = \frac{n\bar{x}+\alpha}{n+\alpha+\beta}, \\ \{0\} & \text{se } \gamma \leq \max\left\{\frac{n\bar{x}+\alpha}{n+\alpha+\beta}, \frac{n(1-\bar{x})+\beta}{n+\alpha+\beta}\right\} = \frac{n(1-\bar{x})+\beta}{n+\alpha+\beta}. \end{cases}$$

Vemos que essa região preditiva contém só a moda ou abrange todos os valores possíveis de X_{n+1}. Neste último caso, não é uma inferência informativa. ■

*Nota do tradutor. o original traz $Q(C(s) \mid s \geq \gamma)$; o sentido é $Q(C(s) \mid s) \geq \gamma$.

Exemplo 7.2.17 — Modelo Normal de Locação (continuação do Exemplo 7.2.15)

Suponha que queremos um intervalo de predição γ para uma observação futura X_{n+1} de uma distribuição

$$N\left(\bar{x}, \left(\frac{1}{\tau_0^2} + \frac{n}{\sigma_0^2}\right)^{-1} \sigma_0^2\right).$$

Como essa é também a distribuição preditiva a posteriori de X_{n+1} e é simétrica em torno de $\bar{x}$, um intervalo de predição γ para X_{n+1}, obtido pelo conceito de HPD, é dado por

$$\bar{x} \pm \left(\frac{1}{\tau_0^2} + \frac{n}{\sigma_0^2}\right)^{-1/2} \sigma_0 \, z_{(1+\gamma)/2}.$$

■

Resumo da Seção 7.2

- Com base na distribuição a posteriori de um parâmetro, podemos obter estimativas do parâmetro (modas ou médias a posteriori), construir intervalos de credibilidade para o parâmetro (intervalos HPD) e avaliar hipóteses sobre o parâmetro (probabilidade a posteriori da hipótese, valores-p bayesianos, fatores de Bayes).
- Um novo tipo de inferência foi discutido nesta seção, a saber, os problemas de predição, em que nos interessa predizer um valor não observado a partir de um modelo amostral.

Exercícios

7.2.1 Para o modelo discutido no Exemplo 7.1.1, deduza a média a posteriori de $\psi = \theta^m$, em que $m > 0$.

7.2.2 Para o modelo discutido no Exemplo 7.1.2, determine a distribuição a posteriori do terceiro quartil $\psi = \mu + \sigma_0 z_{0,75}$. Determine a moda a posteriori e a esperança a posteriori de ψ.

7.2.3 No Exemplo 7.2.1, determine a esperança a posteriori e a moda de $1/\sigma^2$.

7.2.4 No Exemplo 7.2.1, determine a esperança a posteriori e a moda de σ^2. (Sugestão: você vai precisar da densidade a posteriori de σ^2 para determinar a moda.)

7.2.5 Faça as contas para verificar a moda a posteriori e a esperança a posteriori de θ_1 no Exemplo 7.2.4.

7.2.6 Mostre que a variância do θ no Exemplo 7.2.2 é como dada no Exemplo 7.2.6. Prove que ela tende a 0 quando $n \to \infty$.

7.2.7 Mostre que a variância de θ_1 no Exemplo 7.2.4 é como dada no Exemplo 7.2.6. Prove que ela tende a 0 quando $n \to \infty$.

7.2.8 No Exemplo 7.2.14, qual dos dois preditores obtidos ali você acha mais sensato? Por quê?

7.2.9 No Exemplo 7.2.15, prove que a distribuição preditiva a posteriori de X_{n+1} é a enunciada. (Sugestão: escreva a densidade da distribuição preditiva a posteriori como uma esperança.)

7.2.10 Suponha que $(x_1, \ldots, x_n)$ seja uma amostra da distribuição Exponencial(λ), em que $\lambda > 0$ é desconhecido e $\lambda \sim$ Gama(α_0, β_0). Determine a moda da distribuição a posteriori de λ. Determine também a esperança a posteriori e a variância a posteriori de λ.

7.2.11 Suponha que $(x_1, \ldots, x_n)$ seja uma amostra da distribuição Exponencial(λ), em que $\lambda > 0$ é desconhecido e $\lambda \sim$ Gama(α_0, β_0). Determine a moda da distribuição a posteriori de uma observação futura independente X_{n+1}. Determine também a esperança a posteriori de X_{n+1} e a variância a posteriori de X_{n+1}. (Sugestão: Problemas 3.2.16 e 3.3.20.)

7.2.12 Suponha que, numa população de estudantes de uma disciplina com muitos inscritos, a nota, de 0 a 100, numa prova final tenha distribuição aproximadamente $N(\mu, 9)$. O professor põe a distribuição a priori $\mu \sim N(65, 1)$ no parâmetro desconhecido. Obtém-se a amostra de 10 notas dada abaixo.

46	68	34	86	75	56	77	73	53	64

(a) Determine a moda a posteriori e um intervalo de credibilidade 0,95 para μ. O que esse intervalo diz sobre a precisão da estimativa?

(b) Use o intervalo de credibilidade 0,95 para μ para testar a hipótese $H_0 : \mu = 65$.

(c) Suponha que atribuímos probabilidade a priori 0,5 a $\mu = 65$. Usando a distribuição a priori de mistura $\Pi = 0{,}5\Pi_1 + 0{,}5\Pi_2$, em que Π_1 é degenerada em $\mu = 65$ e Π_2 é a distribuição $N(65, 1)$, calcule a probabilidade a posteriori da hipótese nula[42].

No original: *null hypothesis*[42].

(d) Calcule o fator de Bayes a favor de $H_0 : \mu = 65$ quando se usa a distribuição a priori de mistura.

7.2.13 Um fabricante acredita que uma máquina produz hastes com comprimentos, em centímetros, com distribuição $N(\mu_0, \sigma^2)$, em que μ_0 é conhecido e $\sigma^2 > 0$ é desconhecido, e que a distribuição a priori $1/\sigma^2 \sim \text{Gama}(\alpha_0, \beta_0)$ é apropriada.

(a) Determine a distribuição a posteriori de σ^2 com base numa amostra $(x_1, \ldots, x_n)$.

(b) Determine a média a posteriori de σ^2.

(c) Indique como você avaliaria a hipótese $H_0 : \sigma^2 \leq \sigma_0^2$.

7.2.14 Considere o modelo amostral e a distribuição a priori do Exercício 7.1.1.

(a) Suponha que queremos estimar θ tendo observado $s = 1$. Determine a moda a posteriori e a média a posteriori. Qual você preferiria nessa situação? Explique por quê.

(b) Determine uma região HPD 0,8 para θ tendo observado $s = 1$.

(c) Suponha que, em vez disso, o interesse estivesse em $\psi(\theta) = I_{\{1,2\}}(\theta)$. Identifique a distribuição a priori de ψ. Identifique a distribuição a posteriori de ψ tendo observado $s = 1$. Determine uma região HPD 0,5 para ψ.

7.2.15 Para um evento A, temos que $P(A^c) = 1 - P(A)$.

(a) Qual é a relação entre a chance a favor de A e a chance a favor de A^c?

(b) Quando A é um subconjunto do espaço paramétrico[43], qual é a relação entre o fator de Bayes a favor de A e o fator de Bayes a favor de A^c?

7.2.16 Suponha que lhe digam que a chance a favor de um subconjunto A é de 3 para 1. Qual é a probabilidade de A? Se o fator de Bayes a favor de A é 10 e a probabilidade a priori de A é 1/2, determine a probabilidade a posteriori de A.

7.2.17 Suponha que foram obtidos os dados s. Dois estatísticos analisam esses dados usando o mesmo modelo amostral, mas distribuições a priori diferentes, e lhes pedem que avaliem uma hipótese H_0. Os dois estatísticos relatam um fator de Bayes a favor de H_0 igual a 100. O estatístico I atribuiu probabilidade a priori 1/2 a H_0, enquanto o estatístico II atribuiu probabilidade a priori 1/4 a H_0. Qual estatístico tem o maior grau de crença a posteriori de que H_0 é verdadeira?

No original: *parameter space*[43].

7.2.18 Dizem-lhe que um intervalo de credibilidade 0,95, determinado pelo critério HPD, para uma quantidade $\psi(\theta)$ é dado por $(-3{,}3; 2{,}6)$. Se lhe pedirem para avaliar a hipótese $H_0 : \psi(\theta) = 0$, o que você pode dizer sobre o valor-p bayesiano? Explique sua resposta.

7.2.19 Qual é o intervalo de valores possíveis de um fator de Bayes a favor de $A \subset \boldsymbol{\Omega}$? Em que condições um fator de Bayes a favor de $A \subset \boldsymbol{\Omega}$ assume seu menor valor?

Problemas

7.2.20 Suponha que $(x_1, \ldots, x_n)$ seja uma amostra da distribuição Uniforme$[0, \theta]$, em que $\theta > 0$ é desconhecido, e que temos $\theta \sim \text{Gama}(\alpha_0, \beta_0)$. Determine a moda da distribuição a posteriori de θ. (Sugestão: a densidade a posteriori não é diferenciável em $\theta = x_{(n)}$.)

7.2.21 Suponha que $(x_1, \ldots, x_n)$ seja uma amostra da distribuição Uniforme$[0, \theta]$, em que $\theta \in (0, 1)$ é desconhecido, e que temos $\theta \sim \text{Uniforme}[0, 1]$. Determine a forma do intervalo de credibilidade γ para θ com base no conceito de HPD.

7.2.22 No Exemplo 7.2.1, escreva por extenso a integral dada em (7.2.2).

7.2.23 (MV) No Exemplo 7.2.1, escreva por extenso a integral que você precisaria calcular se quisesse obter a densidade a posteriori do terceiro quartil da distribuição populacional, isto é, $\psi = \mu + \sigma z_{0,75}$.

7.2.24 Considere o modelo normal de locação[44] discutido no Exemplo 7.1.2 e o coeficiente de variação populacional $\psi = \sigma_0/\mu$.

(a) Mostre que a esperança a posteriori de ψ não existe. (Sugestão: mostre que podemos escrever a esperança a posteriori como

$$\int_{-\infty}^{\infty} \frac{\sigma_0}{a + bz} \frac{1}{\sqrt{2\pi}} e^{-z^2/2}\, dz,$$

em que $b > 0$, e mostre que essa integral não existe considerando o comportamento do integrando em $z = -a/b$.)

(b) Determine a densidade a posteriori de ψ.

(c) Mostre que você pode determinar a moda a posteriori de ψ calculando a densidade a posteriori em dois pontos específicos. (Sugestão: proceda

No original: *location normal model*[44].

maximizando o logaritmo da densidade a posteriori pelos métodos do cálculo.)

7.2.25 (MV) Suponha que $(\theta_1, \ldots, \theta_{k-1}) \sim \text{Dirichlet}(\alpha_1, \alpha_2, \ldots, \alpha_k)$.

(a) Prove que $(\theta_1, \ldots, \theta_{k-2}) \sim \text{Dirichlet}(\alpha_1, \alpha_2, \ldots, \alpha_{k-1} + \alpha_k)$. (Sugestão: na integral para eliminar θ_{k-1} por integração, faça a transformação $\theta_{k-1} \to \theta_{k-1}/(1 - \theta_1 - \cdots - \theta_{k-2})$.)

(b) Prove que $\theta_1 \sim \text{Beta}(\alpha_1, \alpha_2 + \cdots + \alpha_k)$. (Sugestão: use a parte (a).)

(c) Suponha que $(i_1, \ldots, i_k)$ seja uma permutação[45] de $(1, \ldots, k)$. Prove que $(\theta_{i_1}, \ldots, \theta_{i_{k-1}}) \sim \text{Dirichlet}(\alpha_{i_1}, \alpha_{i_2}, \ldots, \alpha_{i_k})$. (Sugestão: qual é o jacobiano dessa transformação?)

(d) Prove que $\theta_i \sim \text{Beta}(\alpha_i, \alpha_{-i})$. (Sugestão: use as partes (b) e (c).)

7.2.26 (MV) No Exemplo 7.2.4, mostre que o EMV plug-in de θ_1 é dado por x_1/n, isto é, encontre o EMV de $(\theta_1, \ldots, \theta_k)$ e determine a primeira coordenada. (Sugestão: mostre que há uma única solução das equações de escore e depois use os fatos de que a log-verossimilhança[46] é limitada superiormente e tende a $-\infty$ sempre que $\theta_i \to 0$.)

7.2.27 Compare os resultados obtidos nos Exercícios 7.2.3 e 7.2.4. O que você conclui sobre as propriedades de invariância desses procedimentos de estimação[47]? (Sugestão: considere o Teorema 6.2.1.)

7.2.28 No Exemplo 7.2.5, mostre que a variância a posteriori de μ é como enunciada no Exemplo 7.2.6. (Sugestão: Problema 4.6.16.)

7.2.29 Num problema de predição, como descrito na Seção 7.2.4, deduza a forma da densidade preditiva a priori de t quando a densidade conjunta de (θ, s, t) é $q_\theta(t \mid s) f_\theta(s) \pi(\theta)$ (suponha que s e θ assumem valores reais).

7.2.30 No Exemplo 7.2.16, deduza a função de probabilidade preditiva a posteriori de (X_{n+1}, X_{n+2}), tendo observado $x_1, \ldots, x_n$, quando $X_1, \ldots, X_n, X_{n+1}, X_{n+2}$ são independentes e identicamente distribuídas[48] (i.i.d.) Bernoulli(θ).

7.2.31 No Exemplo 7.2.15, deduza a distribuição preditiva a posteriori de X_{n+1}, tendo observado $x_1, \ldots, x_n$, quando $X_1, \ldots, X_n, X_{n+1}$ são i.i.d. $N(\mu, \sigma_0^2)$. (Sugestão: podemos escrever $X_{n+1} = \mu + \sigma_0 Z$, em que $Z \sim N(0, 1)$ é independente da distribuição a posteriori de μ.)

No original: *permutation*[45], *log-likelihood*[46], *estimation*[47], *independent and identically distributed*[48].

7.2.32 No contexto do Exemplo 7.2.1, prove que a distribuição preditiva a posteriori de uma observação futura adicional X_{n+1} da distribuição populacional tem a mesma distribuição que

$$\mu_x + \sqrt{\frac{2\beta_x\left(\left(n + 1/\tau_0^2\right)^{-1} + 1\right)}{(2\alpha_0 + n)}}\, T,$$

em que $T \sim t(2\alpha_0 + n)$. (Sugestão: note que podemos escrever $X_{n+1} = \mu + \sigma U$, em que $U \sim N(0, 1)$ é independente de $X_1, \ldots, X_n, \mu, \sigma$, e então raciocine como no Exemplo 7.2.1.)

7.2.33 No Exemplo 7.2.1, determine a forma de um intervalo de predição γ exato para uma observação futura adicional X_{n+1} da distribuição populacional, com base no conceito de HPD. (Sugestão: use o Problema 7.2.32.)

7.2.34 Suponha que Π_1 e Π_2 sejam distribuições de probabilidade discretas no espaço paramétrico $\boldsymbol{\Omega}$. Prove que, quando a distribuição a priori Π é uma mistura $\Pi = p\Pi_1 + (1 - p)\,\Pi_2$, a preditiva a priori para os dados s é dada por $m(s) = pm_1(s) + (1 - p)m_2(s)$, e a medida de probabilidade a posteriori é dada por (7.2.6).

7.2.35 (MV) Suponha que $\theta = (\theta_1, \theta_2) \in R^2$ e $h(\theta_1, \theta_2) = (\psi(\theta), \lambda(\theta)) \in R^2$. Suponha que h satisfaz as condições necessárias e mostre (7.2.1). (Sugestão: Teorema 2.9.2.)

Desafios

7.2.36 Outra maneira de avaliar a hipótese nula $H_0 : \psi(\theta) = \psi_0$ é calcular o valor-p

$$\Pi\left(\frac{\omega(\psi(\theta) \mid s)}{\omega(\psi(\theta))} \leq \frac{\omega(\psi_0 \mid s)}{\omega(\psi_0)} \,\middle|\, s\right) \tag{7.2.12}$$

em que ω é a densidade a priori marginal ou a função de probabilidade a priori marginal de ψ. Chamamos (7.2.12) de *surpresa relativa*[49] *observada* de H_0.

A quantidade $\omega(\psi_0 \mid s)/\omega(\psi_0)$ é uma medida de quanto os dados s mudaram nossa crença *a priori* de que ψ_0 é o valor verdadeiro de ψ. Quando (7.2.12) é pequeno, ψ_0 é um valor surpreendente para ψ, pois isso indica que os dados aumentaram mais nossa crença em outros valores de ψ.

(a) Prove que (7.2.12) é invariante sob transformações 1–1 continuamente diferenciáveis de ψ.

No original: *relative surprise*[49].

(b) Mostre que um valor ψ_0 que torna (7.2.12) o menor possível maximiza $\omega(\psi_0 \mid s)/\omega(\psi_0)$. Chamamos esse valor de *estimativa de menor surpresa relativa* de ψ.

(c) Indique como usar (7.2.12) para formar uma região de credibilidade[50] γ, conhecida como *região de surpresa relativa* γ, para ψ.

(d) Suponha que ψ assuma valores reais, com densidade a priori ω e densidade a posteriori $\omega(\cdot \mid s)$ ambas contínuas e positivas em ψ_0. Seja $A_\epsilon = (\psi_0 - \epsilon, \psi_0 + \epsilon)$. Mostre que $BF_{A_\epsilon} \to \omega(\psi_0 \mid s)/\omega(\psi_0)$ quando $\epsilon \downarrow 0$. Generalize isso para o caso em que ψ assume valores num subconjunto aberto de R^k. Isso mostra que podemos pensar na surpresa relativa observada como uma maneira de calibrar fatores de Bayes.

7.3 Cálculos Bayesianos

Em praticamente todos os exemplos deste capítulo até agora, conseguimos obter a forma exata das distribuições a posteriori e realizar com elas várias computações importantes. Acontece com frequência, porém, que não conseguimos obter nenhuma forma conveniente para a distribuição a posteriori. Além disso, mesmo quando *conseguimos* obter a distribuição a posteriori, podem surgir computações que não dá para realizar de forma exata — por exemplo, lembre a discussão do Exemplo 7.2.1 que levou à integral (7.2.2). Esses cálculos envolvem avaliar somas ou integrais complicadas. Por isso, quando aplicamos a inferência bayesiana a um exemplo prático, precisamos ter à disposição métodos para aproximar essas quantidades.

A aproximação de integrais é um assunto extenso, que não podemos tratar por completo aqui.* Vamos, no entanto, apresentar vários métodos de aproximação que surgem de modo muito natural em problemas de inferência bayesiana.

7.3.1 Normalidade Assintótica da Distribuição a Posteriori

Em muitas circunstâncias, a distribuição a posteriori de $\theta \in R^1$ acaba sendo aproximadamente normal. Podemos então usar isso para calcular regiões de

*Veja, por exemplo, *Approximating Integrals via Monte Carlo and Deterministic Methods*, de M. Evans e T. Swartz (Oxford University Press, Oxford, 2000).

No original: *credible region*[50].

credibilidade aproximadas para o verdadeiro valor de θ, fazer avaliação de hipóteses etc. Um resultado desse tipo diz que, sob condições que não vamos descrever aqui, quando $(x_1, \ldots, x_n)$ é uma amostra de f_θ, então

$$\Pi\left(\frac{\theta - \hat{\theta}(x_1, \ldots, x_n)}{\hat{\sigma}(x_1, \ldots, x_n)} \leq z \,\middle|\, x_1, \ldots, x_n\right) \to \Phi(z)$$

quando $n \to \infty$, em que $\hat{\theta}(x_1, \ldots, x_n)$ é a moda a posteriori e

$$\hat{\sigma}^2(x_1, \ldots, x_n) = \left(-\left.\frac{\partial^2 \ln(L(\theta \mid x_1, \ldots, x_n)\pi(\theta))}{\partial \theta^2}\right|_{\theta=\hat{\theta}}\right)^{-1}.$$

Note que esse resultado é parecido com o Teorema 6.5.3 para o EMV. Na verdade, podemos substituir $\hat{\theta}(x_1, \ldots, x_n)$ pelo EMV e $\hat{\sigma}^2(x_1, \ldots, x_n)$ pela informação observada (veja a Seção 6.5), e o resultado continua valendo. Quando θ é k-dimensional, há um resultado parecido, porém mais complicado.

7.3.2 Amostragem da Distribuição a Posteriori

Em geral, há muitas coisas que queremos calcular ao implementar uma análise bayesiana. Muitas delas podem ser escritas como esperanças em relação à distribuição a posteriori de θ. Por exemplo, podemos querer calcular a probabilidade a posteriori de um subconjunto $A \subset \mathbf{\Omega}$, a saber,

$$\Pi(A \mid s) = E(I_A(\theta) \mid s).$$

Mais em geral, queremos ser capazes de calcular a esperança a posteriori de uma função arbitrária $w(\theta)$, a saber,

$$E(w(\theta) \mid s). \tag{7.3.1}$$

Certamente seria conveniente se pudéssemos calcular todas essas quantidades de forma exata, mas muitas vezes não conseguimos. Na verdade, não é realmente necessário avaliar (7.3.1) de forma exata. Isso porque naturalmente esperamos que qualquer inferência que façamos sobre o verdadeiro valor do parâmetro esteja sujeita a erro amostral (conjuntos de dados diferentes, de mesmo tamanho, levam a inferências diferentes). Não é necessário realizar nossas computações com um grau de precisão muito maior do que aquele que o erro amostral permite. Por exemplo, se o erro amostral só nos permite conhecer o valor de um parâmetro com margem de ±0,1 unidade, então não faz sentido calcular uma estimativa com muito mais dígitos de precisão.

Diante disso, muitos dos problemas computacionais associados à implementação da inferência bayesiana ficam efetivamente resolvidos se conseguimos

gerar amostras da distribuição a posteriori de θ. Pois, quando isso é possível, simplesmente geramos uma sequência i.i.d. $\theta_1, \theta_2, \ldots, \theta_N$ da distribuição a posteriori de θ e estimamos (7.3.1) por

$$\bar{w} = \frac{1}{N}\sum_{i=1}^{N} w(\theta_i).$$

Sabemos então, pela lei forte dos grandes números[51] (veja o Teorema 4.3.2), que $\bar{w} \xrightarrow{\text{q.c.}} E(w(\theta) \mid x)$ quando $N \to \infty$.*

É claro que, para qualquer N dado, o valor de $\bar{w}$ só aproxima (7.3.1); gostaríamos de saber que escolhemos N grande o bastante para que a aproximação seja adequadamente precisa. Quando $E(w^2(\theta) \mid s) < \infty$, o teorema central do limite[52] (veja o Teorema 4.4.3) nos diz que

$$\frac{\bar{w} - E(w(\theta) \mid s)}{\sigma_w/\sqrt{N}} \xrightarrow{D} N(0,1)$$

quando $N \to \infty$, em que $\sigma_w^2 = \text{Var}(w(\theta) \mid s)$. Em geral, não conhecemos o valor de σ_w^2, mas podemos estimá-lo por

$$s_w^2 = \frac{1}{N-1}\sum_{i=1}^{N}(w(\theta_i) - \bar{w})^2$$

quando $w(\theta)$ é uma variável quantitativa, e por $s_w^2 = \bar{w}(1-\bar{w})$ quando $w = I_A$ para $A \subset \mathbf{\Omega}$. Como mostrado na Seção 4.4.2, em qualquer dos casos s_w^2 é uma estimativa consistente[53] de σ_w^2. Então, pelo Corolário 4.4.4, temos que

$$\frac{\bar{w} - E(w(\theta) \mid s)}{s_w/\sqrt{N}} \xrightarrow{D} N(0,1)$$

quando $N \to \infty$.

Por esse resultado, sabemos que

$$\bar{w} \pm 3\frac{s_w}{\sqrt{N}}$$

é um intervalo de confiança[54] aproximado de 100% para $E(w(\theta) \mid s)$, de modo que podemos olhar para $3s_w/\sqrt{N}$ para decidir se N é ou não grande o bastante para a precisão exigida.

*__Nota do tradutor.__ O original traz $E(w(\theta) \mid x)$; pelo resto da seção seria $E(w(\theta) \mid s)$.

No original: *strong law of large numbers*[51], *central limit theorem*[52], *consistent estimate*[53], *confidence interval*[54].

Um cuidado com essa maneira de avaliar o erro é que o próprio $3s_w/\sqrt{N}$ está sujeito a erro, já que s_w é uma estimativa de σ_w, e isso pode enganar. Uma recomendação comum, então, é acompanhar o valor de $3s_w/\sqrt{N}$ para valores sucessivamente maiores de N e interromper a amostragem só quando estiver claro que o valor de $3s_w/\sqrt{N}$ é pequeno o bastante para a precisão desejada e parece estar diminuindo como deveria. Mesmo essa abordagem, porém, não dá uma cota garantida para a precisão das computações, de modo que é preciso ter cautela.

Também é importante lembrar que a aplicação desses resultados exige que $\sigma_w^2 < \infty$. Para w limitada, isso sempre vale, pois toda variável aleatória[55] limitada tem variância finita. Para w ilimitada[56], porém, isso precisa ser verificado — e às vezes é muito difícil fazê-lo.

Consideramos um exemplo em que é possível gerar amostras exatas da distribuição a posteriori.

Exemplo 7.3.1 — Normal de Locação e Escala

Suponha que $(x_1, \dots, x_n)$ é uma amostra de uma distribuição $N(\mu, \sigma^2)$ em que $\mu \in R^1$ e $\sigma > 0$ são desconhecidos, e que usamos a a priori dada no Exemplo 7.1.4. A distribuição a posteriori de (μ, σ^2) obtida ali é

$$\mu \,|\, \sigma^2, x_1, \dots, x_n \sim N\left(\mu_x, (n + 1/\tau_0^2)^{-1}\sigma^2\right) \tag{7.3.2}$$

e

$$1/\sigma^2 \,|\, x_1, \dots, x_n \sim \text{Gama}(\alpha_0 + n/2, \beta_x), \tag{7.3.3}$$

em que μ_x é dado por (7.1.7) e β_x é dado por (7.1.8).

A maioria dos pacotes estatísticos tem geradores embutidos para distribuições gama e para a distribuição normal. Assim, é muito fácil gerar uma amostra $(\mu_1, \sigma_1^2), \dots, (\mu_N, \sigma_N^2)$ dessa distribuição a posteriori. Simplesmente geramos um valor de $1/\sigma_i^2$ da distribuição gama especificada; então, dado esse valor, geramos o valor de μ_i da distribuição normal especificada.

Suponha, então, que queremos obter a distribuição a posteriori do coeficiente de variação $\psi = \sigma/\mu$. Para isso, geramos N valores da distribuição a posteriori conjunta de (μ, σ^2), usando (7.3.2) e (7.3.3), e calculamos ψ para cada um deles. Sabemos então, de imediato, que $\psi_1, \dots, \psi_N$ é uma amostra da distribuição a posteriori de ψ.

No original: *random variable*[55], *unbounded*[56].

Como exemplo numérico específico, suponha que observamos a seguinte amostra $(x_1, \ldots, x_{15})$.

11,6714	1,8957	2,1228	2,1286	1,0751
8,1631	1,8236	4,0362	6,8513	7,6461
1,9020	7,4899	4,9233	8,3223	7,9486

Aqui, $\bar{x} = 5{,}2$ e $s = 3{,}3$. Suponha ainda que a a priori é especificada por $\mu_0 = 4$, $\tau_0^2 = 2$, $\alpha_0 = 2$ e $\beta_0 = 1$.

Por (7.1.7), temos

$$\mu_x = \left(15 + \frac{1}{2}\right)^{-1}\left(\frac{4}{2} + 15 \cdot 5{,}2\right) = 5{,}161,$$

e, por (7.1.8),

$$\begin{aligned}\beta_x &= 1 + \frac{15}{2}(5{,}2)^2 + \frac{4^2}{2 \cdot 2} + \frac{14}{2}(3{,}3)^2 - \frac{1}{2}\left(15 + \frac{1}{2}\right)^{-1}\left(\frac{4}{2} + 15 \cdot 5{,}2\right)^2 \\ &= 77{,}578.\end{aligned}$$

Portanto, geramos

$$1/\sigma^2 \mid x_1, \ldots, x_n \sim \text{Gama}(9{,}5;\ 77{,}578),$$

seguido de

$$\mu \mid \sigma^2, x_1, \ldots, x_n \sim N(5{,}161;\ (15{,}5)^{-1}\sigma^2).$$

Veja o Apêndice B para um código que pode ser usado para gerar valores dessa distribuição conjunta.

Na Figura 7.3.1, representamos uma amostra de $N = 200$ valores de (μ, σ^2) dessa distribuição a posteriori conjunta. Na Figura 7.3.2, representamos um histograma de densidade dos 200 valores de ψ que resultam dessa amostra.

Uma amostra de 200 não é muito grande, de modo que em seguida geramos uma amostra de $N = 10^3$ valores da distribuição a posteriori de ψ. Um histograma de densidade desses valores é dado na Figura 7.3.3. Na Figura 7.3.4, damos um histograma de densidade baseado numa amostra de $N = 10^4$ valores. Vemos por ele que, com $N = 10^3$, a forma básica da distribuição já foi obtida, embora a cauda direita não esteja sendo estimada com muita precisão. A cauda direita fica melhor com $N = 10^4$, mas note que ainda há alguns valores extremos bem desconectados da massa principal de valores. Como é típico da maioria das distribuições,

vamos precisar de valores muito grandes de N para estimar as caudas com precisão. De qualquer forma, aprendemos que essa distribuição é assimétrica à direita, com uma cauda direita longa.

Suponha que queremos estimar

$$\Pi(\psi \leq 0{,}5 \mid x_1, \ldots, x_n) = E(I_{(-\infty;\, 0{,}5)}(\psi) \mid x_1, \ldots, x_n).$$

Ora, $w = I_{(-\infty;\, 0{,}5)}$ é limitada, de modo que sua variância a posteriori existe. Na tabela a seguir, registramos as estimativas para cada N, junto com o erro padrão baseado em cada uma das amostras geradas. Incluímos no Apêndice B um código para calcular essas estimativas e seus erros padrão. Com base nos resultados para $N = 10^4$, parece que essa probabilidade a posteriori está no intervalo $0{,}289 \pm 3(0{,}0045) = [0{,}2755;\ 0{,}3025]$.

N	Estimativa de $\Pi(\psi \leq 0{,}5 \mid x_1, \ldots, x_n)$	Erro padrão
200	0,265	0,0312
10^3	0,271	0,0141
10^4	0,289	0,0045

Esse exemplo também mostra um ponto importante. Seria muito fácil calcular a média amostral dos valores de ψ gerados de sua distribuição a posteriori e considerá-la uma estimativa da média a posteriori de ψ. Mas o Problema 7.2.24 sugere (veja o Problema 7.3.15) que essa média não existe. Assim, uma estimativa de Monte Carlo dessa quantidade não faz nenhum sentido! Por isso, devemos sempre verificar primeiro se a esperança que queremos estimar existe, antes de seguir com algum procedimento de estimação. ■

Quando não conseguimos gerar amostras diretamente da distribuição a posteriori, precisamos dos métodos da seção seguinte.

7.3.3 Amostragem da Distribuição a Posteriori via Amostragem de Gibbs (Avançado)

A amostragem da distribuição a posteriori, como descrita na Seção 7.3.2, é muito eficaz quando pode ser implementada. Infelizmente, muitas vezes é difícil ou até impossível fazer isso diretamente, como fizemos no Exemplo 7.3.1. Há, porém, vários algoritmos que nos permitem gerar amostras aproximadas da

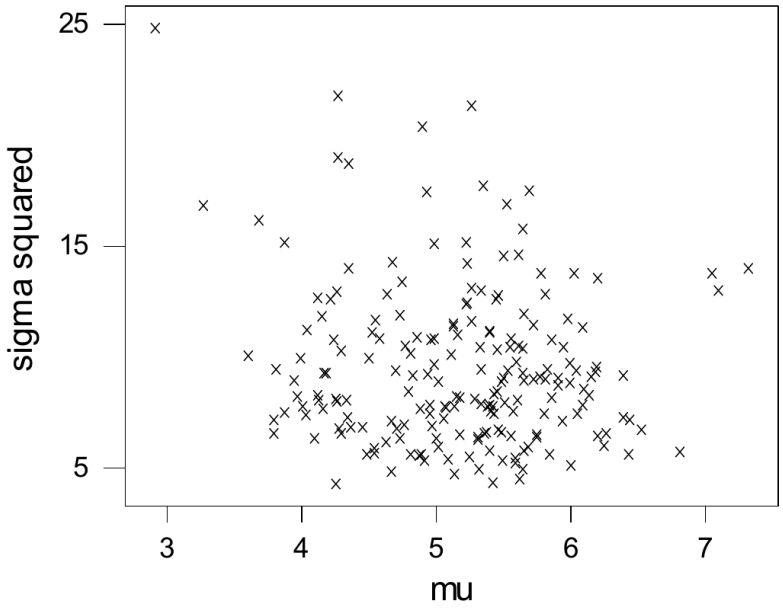


Figura 7.3.1: Uma amostra de 200 valores de (μ, σ^2) da distribuição a posteriori conjunta do Exemplo 7.3.1 quando $n = 15$, $\bar{x} = 5{,}2$, $s = 3{,}3$, $\mu_0 = 4$, $\tau_0^2 = 2$, $\alpha_0 = 2$ e $\beta_0 = 1$.

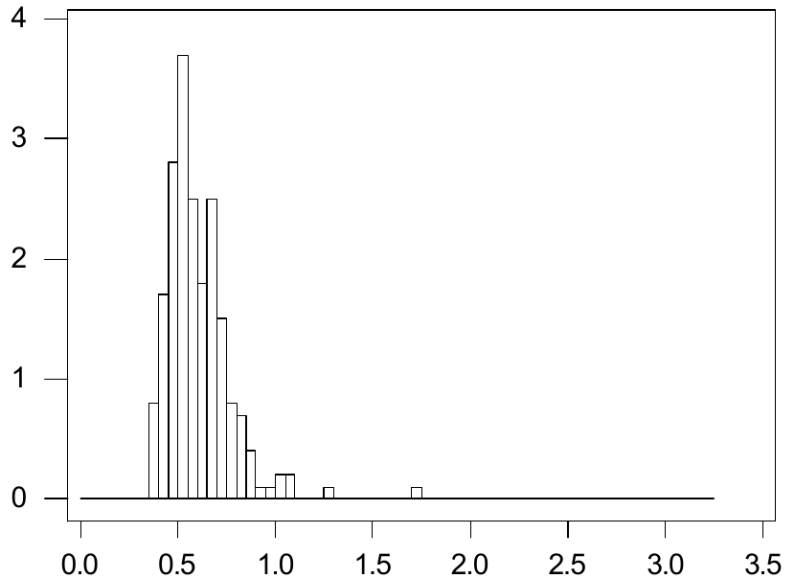


Figura 7.3.2: Histograma de densidade de 200 valores da distribuição a posteriori de ψ no Exemplo 7.3.1.

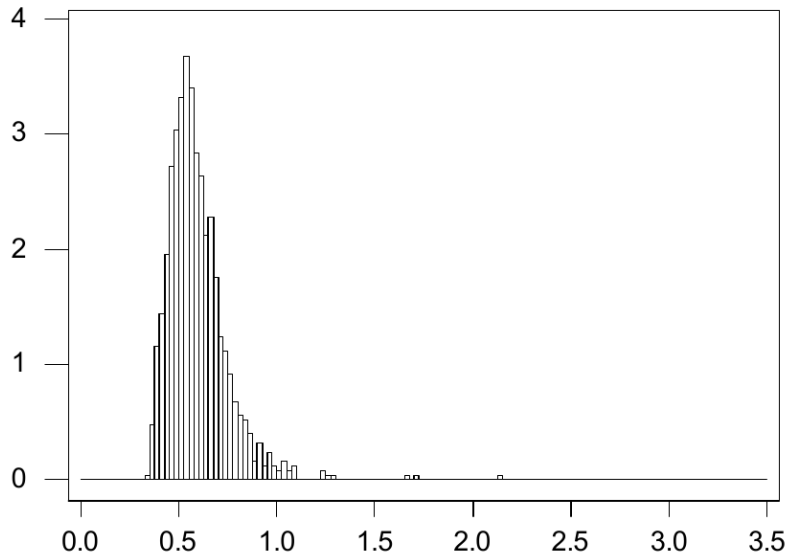


Figura 7.3.3: Histograma de densidade de 1000 valores da distribuição a posteriori de ψ no Exemplo 7.3.1.

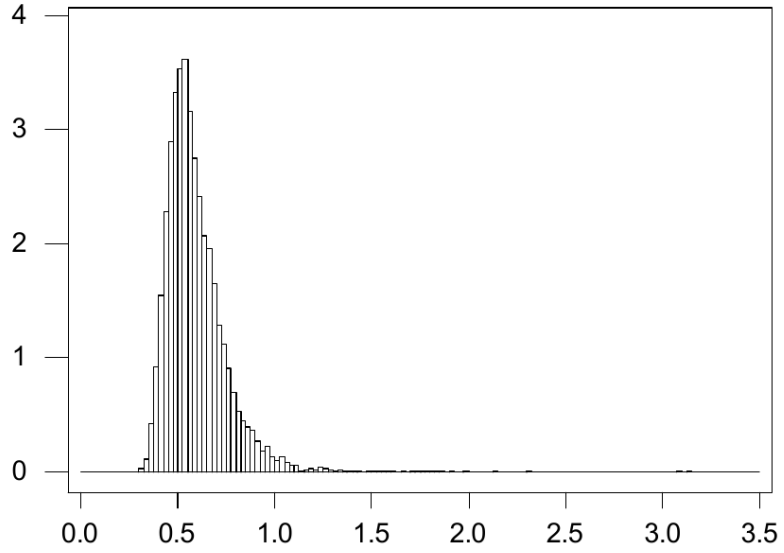


Figura 7.3.4: Histograma de densidade de $N = 10^4$ valores da distribuição a posteriori de ψ no Exemplo 7.3.1.

distribuição a posteriori. Um deles, conhecido como *amostragem de Gibbs*[57], é aplicável em muitos contextos estatísticos.

Para descrever esse algoritmo, suponha que queremos gerar amostras da distribuição conjunta de $(Y_1, \ldots, Y_k) \in R^k$. Suponha ainda que conseguimos gerar valores de cada uma das distribuições condicionais completas $Y_i \mid Y_{-i} = y_{-i}$, em que

$$Y_{-i} = (Y_1, \ldots, Y_{i-1}, Y_{i+1}, \ldots, Y_k),$$

isto é, conseguimos gerar valores da distribuição condicional de Y_i dados os valores de todas as outras coordenadas. O amostrador de Gibbs[58] procede então iterativamente, da seguinte maneira.

1. Especifique um valor inicial $(y_{1(0)}, \ldots, y_{k(0)})$ para $(Y_1, \ldots, Y_k)$.
2. Para $N > 0$, gere $Y_{i(N)}$ da sua distribuição condicional dados $(y_{1(N)}, \ldots, y_{i-1(N)}, y_{i+1(N-1)}, \ldots, y_{k(N-1)})$, para cada $i = 1, \ldots, k$.

Por exemplo, se $k = 3$, primeiro especificamos $(y_{1(0)}, y_{2(0)}, y_{3(0)})$. Então geramos

$$\begin{aligned} Y_{1(1)} \mid Y_{2(0)} = y_{2(0)}, Y_{3(0)} = y_{3(0)} \\ Y_{2(1)} \mid Y_{1(1)} = y_{1(1)}, Y_{3(0)} = y_{3(0)} \\ Y_{3(1)} \mid Y_{1(1)} = y_{1(1)}, Y_{2(1)} = y_{2(1)} \end{aligned}$$

para obter $(Y_{1(1)}, Y_{2(1)}, Y_{3(1)})$. Em seguida, geramos

$$\begin{aligned} Y_{1(2)} \mid Y_{2(1)} = y_{2(1)}, Y_{3(1)} = y_{3(1)} \\ Y_{2(2)} \mid Y_{1(2)} = y_{1(2)}, Y_{3(1)} = y_{3(1)} \\ Y_{3(2)} \mid Y_{1(2)} = y_{1(2)}, Y_{2(2)} = y_{2(2)} \end{aligned}$$

para obter $(Y_{1(2)}, Y_{2(2)}, Y_{3(2)})$ etc. Note que, na verdade, não precisávamos especificar $Y_{1(0)}$, já que ele nunca é usado.

Pode-se mostrar então (veja a Seção 11.3) que, em circunstâncias bastante gerais, $(Y_{1(N)}, \ldots, Y_{k(N)})$ converge em distribuição para a distribuição conjunta de $(Y_1, \ldots, Y_k)$ quando $N \to \infty$. Assim, para N grande, a distribuição de $(Y_{1(N)}, \ldots, Y_{k(N)})$ é aproximadamente igual à distribuição conjunta de $(Y_1, \ldots, Y_k)$ da qual queremos gerar amostras. Desse modo, a amostragem de Gibbs fornece um método aproximado para gerar amostras de uma distribuição de interesse.

No original: *Gibbs sampling*[57], *Gibbs sampler*[58].

Além disso, e este é o resultado mais relevante para simulações, pode-se mostrar que, sob certas condições,

$$\bar{w} = \frac{1}{N}\sum_{i=1}^{N} w(Y_{1(i)}, \ldots, Y_{k(i)}) \xrightarrow{\text{q.c.}} E(w(Y_1, \ldots, Y_k)).$$

A estimação da variância de $\bar{w}$ é diferente da do caso i.i.d., em que usamos a variância amostral, porque agora os termos $w(Y_{1(i)}, \ldots, Y_{k(i)})$ não são independentes.

Há várias abordagens para estimar a variância de $\bar{w}$, mas talvez a mais usada seja a técnica das *médias em lotes*[59]. Para isso, dividimos a sequência

$$w(Y_{1(0)}, \ldots, Y_{k(0)}), \ldots, w(Y_{1(N)}, \ldots, Y_{k(N)})$$

em N/m lotes sequenciais sem sobreposição, de tamanho m (supondo aqui que N é divisível por m), calculamos a média de cada lote, obtendo $\bar{w}_1, \ldots, \bar{w}_{N/m}$, e então estimamos a variância de $\bar{w}$ por

$$\frac{s_b^2}{N/m}, \tag{7.3.4}$$

em que s_b^2 é a variância amostral obtida das médias dos lotes, isto é,

$$s_b^2 = \frac{1}{N/m - 1}\sum_{i=1}^{N/m} (\bar{w}_i - \bar{w})^2.$$

Pode-se mostrar que $(Y_{1(i)}, \ldots, Y_{k(i)})$ e $(Y_{1(i+m)}, \ldots, Y_{k(i+m)})$ são aproximadamente independentes para m grande o bastante. Assim, escolhemos o tamanho de lote m grande o bastante para que as médias dos lotes sejam aproximadamente independentes, mas não tão grande a ponto de deixar pouquíssimos graus de liberdade[60] para a estimação da variância. Em condições ideais, $\bar{w}_1, \ldots, \bar{w}_{N/m}$ é uma sequência i.i.d. com média amostral

$$\bar{w} = \frac{1}{N/m}\sum_{i=1}^{N/m} \bar{w}_i,$$

e, como de costume, estimamos a variância de $\bar{w}$ por (7.3.4).

Às vezes, nem mesmo a amostragem de Gibbs pode ser implementada diretamente, porque não conseguimos obter algoritmos para gerar valores de todas as condicionais completas. Há diversas técnicas para lidar com isso,

No original: *batch means*[59], *degrees of freedom*[60].

mas em muitas aplicações estatísticas a técnica das *variáveis latentes* costuma funcionar. Para isso, procuramos algumas variáveis aleatórias, digamos $(V_1, \ldots, V_l)$, tais que cada Y_i seja função de $(V_1, \ldots, V_l)$ e que possamos aplicar a amostragem de Gibbs à distribuição conjunta de $(V_1, \ldots, V_l)$. Ilustramos a amostragem de Gibbs via variáveis latentes no exemplo a seguir.

Exemplo 7.3.2 — Student de Locação e Escala

Suponha agora que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição da forma $X = \mu + \sigma Z$, em que $Z \sim t(\lambda)$ (veja a Seção 4.6.2 e o Problema 4.6.14). Se $\lambda > 2$, então μ é a média e $\sigma(\lambda/(\lambda-2))^{1/2}$ é o desvio padrão da distribuição (veja o Problema 4.6.16). Note que $\lambda = \infty$ corresponde a variação normal, enquanto $\lambda = 1$ corresponde a variação de Cauchy.

Vamos fixar λ num valor especificado para refletir o fato de que estamos interessados em modelar situações em que a variável em consideração tem uma distribuição com caudas mais longas que as da distribuição normal. Em geral, isso se manifesta num histograma dos dados com forma aproximadamente simétrica, mas com alguns valores extremos nas caudas, de modo que uma distribuição $t(\lambda)$ pode ser apropriada.

Suponha que colocamos sobre (μ, σ^2) a a priori dada por $\mu \,|\, \sigma^2 \sim N(\mu_0, \tau_0^2\sigma^2)$ e $1/\sigma^2 \sim \text{Gama}(\alpha_0, \beta_0)$. A função de verossimilhança é dada por

$$\left(\frac{1}{\sigma^2}\right)^{n/2} \prod_{i=1}^{n} \left[1 + \frac{1}{\lambda}\left(\frac{x_i - \mu}{\sigma}\right)^2\right]^{-(\lambda+1)/2}, \tag{7.3.5}$$

logo a densidade a posteriori de $(\mu, 1/\sigma^2)$ é proporcional a

$$\left(\frac{1}{\sigma^2}\right)^{n/2} \prod_{i=1}^{n} \left[1 + \frac{1}{\lambda}\left(\frac{x_i - \mu}{\sigma}\right)^2\right]^{-(\lambda+1)/2} \times \left(\frac{1}{\sigma^2}\right)^{1/2} \exp\left(-\frac{1}{2\tau_0^2\sigma^2}(\mu - \mu_0)^2\right)\left(\frac{1}{\sigma^2}\right)^{\alpha_0 - 1} \exp\left(-\frac{\beta_0}{\sigma^2}\right).$$

Essa distribuição não é reconhecível de imediato, e não está nada claro como gerar valores dela.

É natural, então, ver se conseguimos implementar a amostragem de Gibbs. Para fazer isso diretamente, precisamos de um algoritmo para gerar valores da distribuição a posteriori de μ dado o valor de σ^2 e de um algoritmo para gerar valores da distribuição a posteriori de σ^2 dado μ. Infelizmente, nenhuma dessas distribuições condicionais se presta às técnicas discutidas na Seção 2.10, de modo que não podemos implementar a amostragem de Gibbs diretamente.

Lembre, porém, que, quando $V \sim \chi^2(\lambda) = \text{Gama}(\lambda/2, 1/2)$ (veja o Problema 4.6.13) é independente de $Y \sim N(\mu, \sigma^2)$, então (Problema 4.6.14)

$$Z = \frac{Y - \mu}{\sigma\sqrt{V/\lambda}} \sim t(\lambda).$$

Portanto, escrevendo

$$X = \mu + \sigma Z = \mu + \sigma\frac{Y - \mu}{\sigma\sqrt{V/\lambda}} = \mu + \frac{Y - \mu}{\sqrt{V/\lambda}},$$

temos que $X \mid V = v \sim N(\mu, \sigma^2\lambda/v)$.

Introduzimos agora as *n variáveis latentes*, ou *variáveis ocultas*, $(V_1, \ldots, V_n)$, que são i.i.d. $\chi^2(\lambda)$, e supomos que $X_i \mid V_i = v_i \sim N(\mu, \sigma^2\lambda/v_i)$. As V_i são consideradas latentes porque não fazem realmente parte da formulação do problema, mas foram acrescentadas aqui por conveniência (como veremos). Então, notando que há um fator $v_i^{1/2}$ associado à densidade de $X_i \mid V_i = v_i$, a densidade conjunta dos valores $(X_1, V_1), \ldots, (X_n, V_n)$ é proporcional a

$$\left(\frac{1}{\sigma^2}\right)^{n/2} \prod_{i=1}^{n} \exp\left(-\frac{v_i}{2\sigma^2\lambda}(x_i - \mu)^2\right) v_i^{(\lambda/2)-(1/2)} \exp\left(-\frac{v_i}{2}\right).$$

Pelo argumento acima, a densidade conjunta marginal de $(X_1, \ldots, X_n)$ (depois de integrar os v_i) é proporcional a (7.3.5), isto é, uma amostra de tamanho n da distribuição especificada por $X = \mu + \sigma Z$, em que $Z \sim t(\lambda)$. Com a mesma estrutura a priori de antes, temos que a densidade conjunta de

$$(X_1, V_1), \ldots, (X_n, V_n), \mu, 1/\sigma^2$$

é proporcional a

$$\left(\frac{1}{\sigma^2}\right)^{n/2} \prod_{i=1}^{n} \exp\left(-\frac{v_i}{2\sigma^2\lambda}(x_i - \mu)^2\right) v_i^{(\lambda/2)-(1/2)} \exp\left(-\frac{v_i}{2}\right) \times \left(\frac{1}{\sigma^2}\right)^{1/2} \exp\left(-\frac{1}{2\tau_0^2\sigma^2}(\mu - \mu_0)^2\right) \left(\frac{1}{\sigma^2}\right)^{\alpha_0 - 1} \exp\left(-\frac{\beta_0}{\sigma^2}\right). \quad (7.3.6)$$

Em (7.3.6), trate $x_1, \ldots, x_n$ como constantes (observamos esses valores) e considere as distribuições condicionais de cada uma das variáveis $V_1, \ldots, V_n, \mu, 1/\sigma^2$ dadas todas as outras variáveis. Por (7.3.6), a densidade condicional completa de μ é proporcional a

$$\exp\left\{-\frac{1}{2\sigma^2}\left(\sum_{i=1}^{n}\frac{v_i}{\lambda}(x_i - \mu)^2 + \frac{1}{\tau_0^2}(\mu - \mu_0)^2\right)\right\},$$

que é proporcional a

$$\exp\left\{-\frac{1}{2\sigma^2}\left[\left(\sum_{i=1}^{n}\frac{v_i}{\lambda}\right)+\frac{1}{\tau_0^2}\right]\mu^2+\frac{2}{2\sigma^2}\left[\left(\sum_{i=1}^{n}\frac{v_i}{\lambda}x_i\right)+\frac{\mu_0}{\tau_0^2}\right]\mu\right\}.$$

Disso deduzimos de imediato que

$$\mu \mid x_1,\ldots,x_n,v_1,\ldots,v_n,\sigma^2 \sim N\left(r(v_1,\ldots,v_n)\left[\left(\sum_{i=1}^{n}\frac{v_i}{\lambda}x_i\right)+\frac{\mu_0}{\tau_0^2}\right], r(v_1,\ldots,v_n)\sigma^2\right),$$

em que

$$r(v_1,\ldots,v_n)=\left[\left(\sum_{i=1}^{n}\frac{v_i}{\lambda}\right)+\frac{1}{\tau_0^2}\right]^{-1}.$$

Por (7.3.6), a densidade condicional de $1/\sigma^2$ é proporcional a

$$\left(\frac{1}{\sigma^2}\right)^{(n/2)+\alpha_0-(1/2)}\exp\left\{-\left(\begin{array}{c}\sum_{i=1}^{n}\frac{v_i}{\lambda}(x_i-\mu)^2\\+\frac{1}{\tau_0^2}(\mu-\mu_0)^2+2\beta_0\end{array}\right)\frac{1}{2\sigma^2}\right\},$$

e deduzimos de imediato que

$$\frac{1}{\sigma^2}\,\Big|\, x_1,\ldots,x_n,v_1,\ldots,v_n,\mu \sim \text{Gama}\left(\frac{n}{2}+\alpha_0+\frac{1}{2},\frac{1}{2}\left(\sum_{i=1}^{n}\frac{v_i}{\lambda}(x_i-\mu)^2+\frac{1}{\tau_0^2}(\mu-\mu_0)^2+2\beta_0\right)\right).$$

Por fim, a densidade condicional de V_i é proporcional a

$$v_i^{(\lambda/2)-(1/2)}\exp\left\{-\left[\frac{(x_i-\mu)^2}{2\sigma^2\lambda}+\frac{1}{2}\right]v_i\right\},$$

e é imediato que

$$V_i \mid x_1,\ldots,x_n,v_1,\ldots,v_{i-1},v_{i+1},\ldots,v_n,\mu,\sigma^2 \sim \text{Gama}\left(\frac{\lambda}{2}+\frac{1}{2},\frac{1}{2}\left(\frac{(x_i-\mu)^2}{\sigma^2\lambda}+1\right)\right).$$

Agora podemos gerar facilmente valores de todas essas distribuições e implementar um algoritmo de amostragem de Gibbs. Como não estamos interessados nos valores de $V_1,\ldots,V_n$, simplesmente os descartamos à medida que iteramos.

Consideremos agora uma computação específica usando os mesmos dados e a mesma a priori do Exemplo 7.3.1. A análise do Exemplo 7.3.1 supôs que os dados vinham de uma distribuição normal, mas agora vamos supor que os dados são uma amostra de uma distribuição $\mu + \sigma t(3)$, isto é, $\lambda = 3$. Consideramos de novo a aproximação da distribuição a posteriori do coeficiente de variação $\psi = \sigma/\mu$.

Fazemos a iteração da amostragem de Gibbs na ordem $v_1, \ldots, v_n, \mu, 1/\sigma^2$. Isso implica que precisamos de valores iniciais só para μ e σ^2 (as condicionais completas das v_i não dependem das outras v_j). Tomamos o valor inicial de μ como $\bar{x} = 5{,}2$ e o valor inicial de σ como $s = 3{,}3$. Para cada valor gerado de (μ, σ^2), calculamos ψ, obtendo a sequência $\psi_1, \psi_2, \ldots, \psi_N$.

Os valores $\psi_1, \psi_2, \ldots, \psi_N$ não são i.i.d. da distribuição a posteriori de ψ. O melhor que podemos dizer é que

$$\psi_m \xrightarrow{D} \psi \sim \omega(\cdot \mid x_1, \ldots, x_n)$$

quando $m \to \infty$, em que $\omega(\cdot \mid x_1, \ldots, x_n)$ é a densidade a posteriori de ψ. Além disso, valores suficientemente afastados na sequência se comportarão como valores i.i.d. de $\omega(\cdot \mid x_1, \ldots, x_n)$. Assim, uma abordagem é determinar um valor apropriado m e então extrair $\psi_m, \psi_{2m}, \psi_{3m}, \ldots$ como uma sequência aproximadamente i.i.d. da distribuição a posteriori. Muitas vezes, porém, é difícil determinar um valor apropriado para m.

De qualquer forma, sabe-se que, sob condições bastante fracas,

$$\bar{w} = \frac{1}{N} \sum_{i=1}^{N} w(\psi_i) \xrightarrow{\text{q.c.}} E(w(\psi) \mid x_1, \ldots, x_n)$$

quando $N \to \infty$. Assim, podemos usar a sequência inteira $\psi_1, \psi_2, \ldots, \psi_N$ e registrar um histograma de densidade de ψ, exatamente como fizemos no Exemplo 7.3.1. O valor do histograma de densidade entre dois pontos de corte convergirá quase certamente para o valor correto quando $N \to \infty$. No entanto, teremos de tomar N maior ao usar o algoritmo de amostragem de Gibbs do que com a amostragem i.i.d., para obter a mesma precisão. Em muitos exemplos, o efeito de a sequência não ser i.i.d. é muito pequeno, de modo que N não precisará ser muito maior. Precisamos sempre ter cautela, porém, e a recomendação geral é calcular estimativas para valores sucessivamente maiores de N, parando só quando os resultados parecerem ter se estabilizado.

Na Figura 7.3.5, representamos o histograma de densidade dos valores de ψ resultantes de 10^4 iterações do amostrador de Gibbs. Nesse caso,

representar o histograma de densidade de ψ com base em $N = 5 \times 10^4$ e $N = 8 \times 10^4$ resultou apenas em pequenos desvios em relação a esse gráfico. Note que essa densidade é muito parecida com a representada no Exemplo 7.3.1, mas não tem um pico tão acentuado e tem uma cauda direita mais curta.

Também podemos estimar $\Pi(\psi \leq 0{,}5 \,|\, x_1, \ldots, x_n)$, exatamente como fizemos no Exemplo 7.3.1, registrando a proporção de valores da sequência que são menores que 0,5, isto é, $w(\psi) = I_A(\psi)$, em que $A = \{\theta : \psi \leq 0{,}5\}$. Nesse caso, obtivemos a estimativa 0,5441, que é bem diferente do valor obtido no Exemplo 7.3.1. Assim, usar uma distribuição $t(3)$ para descrever a variação da resposta fez uma grande diferença nos resultados.

É claro que também precisamos quantificar quão precisa acreditamos ser nossa estimativa. Usando um tamanho de lote $m = 10$, obtivemos 0,00639 como erro padrão da estimativa 0,5441. Quando tomamos o tamanho de lote $m = 20$, o erro padrão da média é 0,00659; com um tamanho de lote $m = 40$, o erro padrão da média é 0,00668. Assim, sentimo-nos bastante confiantes de que estamos avaliando o erro da estimativa de modo apropriado. De novo, sob certas condições, temos que $\bar{w}$ é assintoticamente normal, de modo que nesse caso podemos afirmar que o intervalo $0{,}5441 \pm 3(0{,}0066) = [0{,}5243;\ 0{,}5639]$ contém o verdadeiro valor de $\Pi(\psi \leq 0{,}5 \,|\, x_1, \ldots, x_n)$ praticamente com certeza.

Veja o Apêndice B para um código que foi usado para implementar o algoritmo de amostragem de Gibbs descrito aqui. ■

É justo dizer que a introdução da amostragem de Gibbs provocou uma revolução nas aplicações estatísticas, por causa da grande variedade de problemas antes intratáveis que ela resolve com sucesso. Há várias modificações e algoritmos intimamente relacionados. Remetemos o leitor interessado ao Capítulo 11, onde se discute a teoria geral do que se chama Monte Carlo via cadeias de Markov (MCMC).

Resumo da Seção 7.3

- A implementação da inferência bayesiana muitas vezes exige a avaliação de integrais ou somas complicadas.
- Se, porém, conseguimos gerar amostras da distribuição a posteriori do parâmetro, isso muitas vezes leva a aproximações suficientemente precisas dessas integrais ou somas via Monte Carlo.
- Muitas vezes é difícil gerar amostras exatas de uma distribuição a

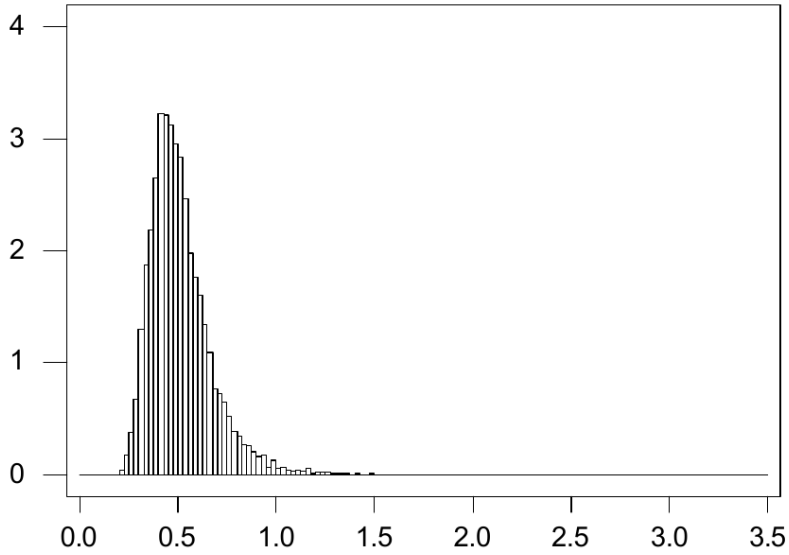


Figura 7.3.5: Histograma de densidade de $N = 10^4$ valores de ψ gerados sequencialmente via amostragem de Gibbs no Exemplo 7.3.2.

posteriori de interesse. Nessas circunstâncias, a amostragem de Gibbs pode se mostrar um método eficaz para gerar uma amostra aproximada dessa distribuição.

Exercícios

7.3.1 Suponha que temos a seguinte amostra de uma distribuição $N(\mu, 2)$, em que μ é desconhecido.

2,6	4,2	3,1	5,2	3,7	3,8	5,6	1,8	5,3	4,0
3,0	4,0	4,1	3,2	2,2	3,4	4,5	2,9	4,7	5,2

Se a a priori de μ é Uniforme$(2, 6)$, determine um intervalo de credibilidade 0,95 aproximado para μ com base nos resultados para grandes amostras descritos na Seção 7.3.1.

7.3.2 Determine a forma do intervalo de credibilidade 0,95 aproximado da Seção 7.3.1 para o modelo de Bernoulli com uma a priori Beta(α, β), discutido no Exemplo 7.2.2.

7.3.3 Determine a forma dos intervalos de credibilidade 0,95 aproximados da Seção 7.3.1 para o modelo normal de locação com uma a priori $N(\mu_0, \tau_0^2)$, discutido no Exemplo 7.2.3.

7.3.4 Suponha que $X \sim$ Uniforme$[0, 1/\theta]$ e $\theta \sim$ Exponencial(1). Obtenha um algoritmo de Monte Carlo simples, baseado na geração de valores de uma distribuição gama, para gerar um valor da distribuição condicional $\theta \,|\, X = x$. Generalize isso para uma amostra de tamanho n da distribuição Uniforme$[0, 1/\theta]$. Quando esse algoritmo será ineficiente, no sentido de precisarmos de muita computação para gerar um único valor?

7.3.5 Suponha que $X \sim N(\theta, 1)$ e $\theta \sim$ Uniforme$[0, 1]$. Obtenha um algoritmo de Monte Carlo simples, baseado na geração de valores de uma distribuição normal, para gerar valores da distribuição condicional $\theta \,|\, X = x$. Generalize isso para uma amostra de tamanho n da distribuição $N(\theta, 1)$. Quando esse algoritmo será ineficiente, no sentido de precisarmos de muita computação para gerar um único valor?

7.3.6 Suponha que $X \sim 0{,}5N(\theta, 1) + 0{,}5N(\theta, 2)$ e $\theta \sim$ Uniforme$[0, 1]$. Obtenha um algoritmo de Monte Carlo simples, baseado na geração de valores de uma mistura de distribuições normais, para gerar valores da distribuição condicional $\theta \,|\, X = x$. Generalize isso para uma amostra de tamanho $n = 2$ da distribuição $0{,}5N(\theta, 1) + 0{,}5N(\theta, 2)$.

Exercícios computacionais

7.3.7 No contexto do Exemplo 7.3.1, construa um histograma de densidade da distribuição a posteriori de $\psi = \mu + \sigma z_{0,25}$, isto é, o primeiro quartil da população, usando $N = 5 \times 10^3$ e $N = 10^4$, e compare os resultados. Estime a média a posteriori dessa distribuição e avalie o erro da sua aproximação. (Sugestão: modifique o programa do Apêndice B.)

7.3.8 Suponha que um fabricante retira uma amostra aleatória de itens fabricados e testa cada item para saber se é defeituoso ou não. Considera-se que as respostas são i.i.d. Bernoulli(θ), em que θ é a probabilidade de o item ser defeituoso. O fabricante coloca uma distribuição Beta$(0{,}5;\ 10)$ sobre θ. Se uma amostra de $n = 100$ itens é retirada e são observados 5 defeituosos, então, usando uma amostra de Monte Carlo com $N = 1000$, estime a probabilidade a posteriori de que $\theta < 0{,}1$ e avalie o erro da sua estimativa.

7.3.9 Suponha que se sabe que os tempos de vida (em anos) de um item fabricado seguem uma distribuição Exponencial(λ), em que $\lambda > 0$ é desconhecido, e que tomamos como a priori $\lambda \sim$ Gama$(10, 2)$. Suponha que foram observados os tempos de vida 4,3; 6,2; 8,4; 3,1; 6,0; 5,5 e 7,8.

(a) Usando uma amostra de Monte Carlo de tamanho $N = 10^3$, aproxime

a probabilidade a posteriori de que $\lambda \in [3, 6]$ e avalie o erro da sua estimativa.

(b) Usando uma amostra de Monte Carlo de tamanho $N = 10^3$, aproxime a função de probabilidade a posteriori de $\lfloor 1/\lambda \rfloor$ ($\lfloor x \rfloor$ é o maior inteiro menor ou igual a x).

(c) Usando uma amostra de Monte Carlo de tamanho $N = 10^3$, aproxime a esperança a posteriori de $\lfloor 1/\lambda \rfloor$ e avalie o erro da sua aproximação.

7.3.10 Gere uma amostra de tamanho $n = 10$ de uma distribuição Pareto(2). Agora finja que você sabe apenas que tem uma amostra de uma distribuição Pareto(α), em que $\alpha > 0$ é desconhecido, e coloque uma a priori Gama(2, 1) sobre α. Usando uma amostra de Monte Carlo de tamanho $N = 10^4$, aproxime a esperança a posteriori de $1/(\alpha + 1)$ com base na amostra observada e avalie a precisão da sua aproximação dando um intervalo que contenha o valor exato praticamente com certeza[61]. (Sugestão: Problema 2.10.15.)

Problemas

7.3.11 Suponha que $X_1, \ldots, X_n$ é uma amostra do modelo $\{f_\theta : \theta \in \boldsymbol{\Omega}\}$ e que todas as condições de regularidade da Seção 6.5 valem. Suponha que a a priori $\pi(\theta)$ é uma função contínua de θ e que a moda a posteriori $\hat{\theta}(X_1, \ldots, X_n) \xrightarrow{\text{q.c.}} \theta$ quando $X_1, \ldots, X_n$ é uma amostra de f_θ (esta última hipótese vale sob condições muito gerais).

(a) Usando o fato de que, se $Y_n \xrightarrow{\text{q.c.}} Y$ e g é uma função contínua, então $g(Y_n) \xrightarrow{\text{q.c.}} g(Y)$, prove que

$$-\frac{1}{n} \frac{\partial^2 \ln(L(\theta \mid x_1, \ldots, x_n)\pi(\theta))}{\partial \theta^2}\bigg|_{\theta=\hat{\theta}} \xrightarrow{\text{q.c.}} I(\theta)$$

quando $X_1, \ldots, X_n$ é uma amostra de f_θ.

(b) Explique até que ponto os métodos aproximados para grandes amostras da Seção 7.3.1 dependem da a priori, se valem as hipóteses que acabamos de descrever.

7.3.12 No Exercício 7.3.10, explique por que o intervalo que você construiu para conter a média a posteriori de $1/(\alpha + 1)$ praticamente com certeza pode conter ou não o verdadeiro valor de $1/(\alpha + 1)$.

No original: *with virtual certainty*[61].

7.3.13 Suponha que (X, Y) tem distribuição Normal Bivariada$(\mu_1, \mu_2, \sigma_1, \sigma_2, \rho)$. Determine um algoritmo de amostragem de Gibbs para gerar valores dessa distribuição. Suponha que você tem um algoritmo para gerar valores de distribuições normais univariadas. Essa é a melhor maneira de gerar amostras dessa distribuição? (Sugestão: Problema 2.8.27.)

7.3.14 Suponha que a densidade conjunta de (X, Y) é dada por $f_{X,Y}(x, y) = 8xy$ para $0 < x < y < 1$. Descreva por completo um algoritmo de amostragem de Gibbs para essa distribuição. Em particular, indique como você geraria todas as variáveis aleatórias. Você consegue projetar um algoritmo para gerar valores exatamente dessa distribuição?

7.3.15 No Exemplo 7.3.1, prove que a média a posteriori de $\psi = \sigma/\mu$ não existe. (Sugestão: use o Problema 7.2.24 e o teorema da esperança total para dividir a integral em duas partes, em que uma parte tem valor ∞ e a outra tem valor $-\infty$.)

7.3.16 (*Amostragem por importância*[62] *baseada na a priori*) Suponha que temos um algoritmo para gerar valores da a priori.

(a) Indique como você poderia usá-lo para aproximar uma esperança a posteriori usando amostragem por importância (veja o Problema 4.5.21).

(b) Qual você imagina ser a principal fraqueza dessa abordagem?

Problemas computacionais

7.3.17 No contexto do Exemplo 7.3.2, construa um histograma de densidade da distribuição a posteriori de $\psi = \mu + \sigma z_{0,25}$, isto é, o primeiro quartil da população, usando $N = 10^4$. Estime a média a posteriori dessa distribuição e avalie o erro da sua aproximação.*

*Nota do tradutor. No modelo do Exemplo 7.3.2 ($Z \sim t(3)$), o primeiro quartil da população seria $\mu + \sigma t_{0,25}(3)$; o original traz $z_{0,25}$, quantil da normal padrão.

No original: *importance sampling*[62].

7.4 Escolha de Distribuições a Priori

A questão de escolher uma priori para um problema é importante. Naturalmente, a ideia é escolher uma priori que reflita as nossas crenças *a priori* sobre o valor verdadeiro de θ. Como isso costuma variar de estatístico para estatístico, esse procedimento é muitas vezes criticado como subjetivo demais para estudos científicos. Convém lembrar, porém, que o modelo amostral $\{f_\theta : \theta \in \mathbf{\Omega}\}$ também é uma escolha subjetiva do estatístico. Essas escolhas são guiadas pelo julgamento do estatístico. O que justifica, então, escolher um modelo estatístico ou uma priori em vez de outro?

Na prática, quando os estatísticos escolhem uma priori e um modelo, estão prescrevendo uma distribuição conjunta para (θ, s). A única maneira de avaliar se foi feita ou não uma escolha adequada é verificar se o s observado é razoável diante dessa escolha. Se s for surpreendente quando comparado à distribuição prescrita pelo modelo e pela priori, então temos evidência contra as escolhas do estatístico. Os métodos criados para avaliar isso se chamam procedimentos de verificação de modelos[63] e são discutidos no Capítulo 9. Neste ponto, porém, devemos reconhecer a subjetividade que entra nas análises estatísticas, mas nos confortar com o fato de termos uma metodologia para verificar se as escolhas feitas pelo estatístico fazem sentido ou não.

Muitas vezes, o estatístico considera uma família particular $\{\pi_\lambda : \lambda \in \Lambda\}$ de prioris para um problema e tenta escolher uma priori adequada $\pi_{\lambda_0} \in \{\pi_\lambda : \lambda \in \Lambda\}$. Nesse contexto, o parâmetro λ é chamado de *hiperparâmetro*[64]. Note que essa família poderia ser o conjunto de todas as prioris possíveis, de modo que essa formulação não impõe nenhuma restrição. Discutimos agora algumas famílias $\{\pi_\lambda : \lambda \in \Lambda\}$ de uso comum e métodos para escolher $\lambda_0 \in \Lambda$.

7.4.1 Prioris Conjugadas

Dependendo do modelo amostral, a família pode ser conjugada.

No original: *model checking*[63], *hyperparameter*[64].

Definição 7.4.1

A família de prioris $\{\pi_\lambda : \lambda \in \Lambda\}$ para o parâmetro θ do modelo $\{f_\theta : \theta \in \mathbf{\Omega}\}$ é *conjugada* se, para todos os dados $s \in S$ e todo $\lambda \in \Lambda$, a posteriori $\pi_\lambda(\cdot \mid s) \in \{\pi_\lambda : \lambda \in \Lambda\}$.

A conjugação costuma ser muito conveniente, pois começamos com alguma escolha $\lambda_0 \in \Lambda$ para a priori e depois encontramos o $\lambda_s \in \Lambda$ correspondente para a posteriori, muitas vezes sem muito cálculo. Embora a conjugação possa ser criticada como mera conveniência matemática, é preciso reconhecer que muitas famílias conjugadas oferecem variedade suficiente para permitir a expressão de um amplo espectro de crenças a priori.

Exemplo 7.4.1 — Famílias Conjugadas

No Exemplo 7.1.1, mostramos, na prática, que a família de todas as distribuições Beta é conjugada para a amostragem do modelo de Bernoulli. No Exemplo 7.1.2, mostra-se que a família de prioris normais é conjugada para a amostragem do modelo normal de locação. No Exemplo 7.1.3, mostra-se que a família de distribuições Dirichlet é conjugada para modelos Multinomiais. No Exemplo 7.1.4, mostra-se que a família de prioris especificada ali é conjugada para a amostragem do modelo normal de locação e escala. ■

Naturalmente, usar uma família conjugada não nos diz como escolher λ_0. Talvez a abordagem mais justificável seja usar a *elicitação da priori*.

7.4.2 Elicitação

A elicitação consiste em usar explicitamente as crenças do estatístico sobre o valor verdadeiro de θ para escolher uma priori em $\{\pi_\lambda : \lambda \in \Lambda\}$ que reflita essas crenças. Em geral, isso envolve o estatístico fazer perguntas a si mesmo, ou a especialistas na área de aplicação, de tal modo que as respostas especifiquem uma priori da família.

Exemplo 7.4.2 — Normal de Locação

Suponha que estamos amostrando de uma distribuição $N(\mu, \sigma_0^2)$ com μ desconhecido e σ_0^2 conhecido, e que restringimos a atenção à família $\{N(\mu_0, \tau_0^2) : \mu_0 \in R^1, \tau_0^2 > 0\}$ de prioris para μ. Assim, aqui, $\lambda = (\mu_0, \tau_0^2)$ e há dois graus de liberdade nessa família. Portanto, especificar duas características independentes especifica uma priori.

Assim, poderíamos pedir a um especialista que especificasse dois quantis da sua distribuição a priori para μ (ver o Exercício 7.4.10), já que isso especifica uma priori da família. Por exemplo, poderíamos pedir a um especialista que especificasse um número μ_0 tal que o valor verdadeiro de μ tivesse a mesma chance de ser maior ou menor que μ_0, de modo que μ_0 é a mediana da priori. Poderíamos também pedir ao especialista que especificasse um valor υ_0 tal que houvesse 99% de certeza de que o valor verdadeiro de μ é menor que υ_0. Esse, naturalmente, é o quantil 0,99 da sua priori.

Alternativamente, poderíamos pedir ao especialista que especificasse o centro μ_0 da sua distribuição a priori e uma constante τ_0 tal que $\mu_0 \pm 3\tau_0$ contenha o valor verdadeiro de μ praticamente com certeza. Claramente, nesse caso, μ_0 é a média a priori e τ_0 é o desvio padrão a priori. ■

A elicitação é uma parte importante de qualquer análise estatística bayesiana. Se os especialistas consultados realmente conhecem bem a aplicação, parece intuitivamente claro que vamos melhorar a análise estatística ao incluir essa informação a priori.

O processo de elicitação, no entanto, pode ser um tanto trabalhoso em problemas complicados. Além disso, há várias considerações que precisam ser levadas em conta, envolvendo preconceitos e falhas na maneira como raciocinamos sobre probabilidade fora de uma formulação matemática. Ver Garthwaite, Kadane e O'Hagan (2005), "Statistical methods for eliciting probability distributions", *Journal of the American Statistical Association* (v. 100, n. 470, p. 680–700), para uma discussão mais profunda dessas questões.

7.4.3 Bayes Empírico

Quando a escolha de λ_0 se baseia nos dados s, esses métodos são chamados de *métodos bayesianos empíricos*. Logicamente, esses métodos pareceriam violar um princípio básico da inferência, a saber, o princípio da probabilidade condicional. Isso porque, quando calculamos a distribuição a posteriori de

θ usando uma priori baseada em s, em geral ela deixa de ser a distribuição condicional de θ dados os dados. Embora essa seja, sem dúvida, uma preocupação importante, em muitos problemas a aplicação de Bayes empírico leva a inferências com propriedades satisfatórias.

Por exemplo, um método bayesiano empírico consiste em calcular a preditiva a priori $m_\lambda(s)$ para os dados s e então basear a escolha de λ nesses valores. Note que a preditiva a priori é como uma função de verossimilhança[65] para λ (já que é a função densidade ou a função de probabilidade do s observado), e por isso os métodos do Capítulo 6 se aplicam à inferência sobre λ. Por exemplo, poderíamos escolher o valor λ_s de λ que maximiza $m_\lambda(s)$. Os cálculos necessários podem ser extensos, já que λ costuma ser multidimensional. Ilustramos com um exemplo simples.

Exemplo 7.4.3 — Bernoulli

Suponha que temos uma amostra $x_1, \ldots, x_n$ de uma distribuição Bernoulli(θ) e cogitamos pôr uma priori Beta(λ, λ) em θ para algum $\lambda > 0$. Assim, a priori é simétrica em torno de 1/2, e a dispersão dessa distribuição é controlada por λ. Como a média a priori é 1/2 e a variância a priori é $\lambda^2/[(2\lambda+1)(2\lambda)^2] = 1/4(2\lambda+1) \to 0$ quando $\lambda \to \infty$, vemos que escolher λ grande leva a uma priori muito precisa. Temos então que

$$\begin{aligned} m_\lambda(x_1, \ldots, x_n) &= \frac{\Gamma(2\lambda)}{\Gamma^2(\lambda)} \int_0^1 \theta^{n\bar{x}+\lambda-1}(1-\theta)^{n(1-\bar{x})+\lambda-1}\, d\theta \\ &= \frac{\Gamma(2\lambda)}{\Gamma^2(\lambda)} \frac{\Gamma(n\bar{x}+\lambda)\Gamma(n(1-\bar{x})+\lambda)}{\Gamma(n+2\lambda)}. \end{aligned}$$

É difícil encontrar o valor de λ que maximiza essa expressão, mas, para dados reais, podemos tabelar $m_\lambda(x_1, \ldots, x_n)$ e fazer o seu gráfico para obter esse valor. Métodos computacionais mais avançados também podem ser usados.

Por exemplo, suponha que $n = 20$ e que obtivemos $n\bar{x} = 5$ como o número de 1's observados. Na Figura 7.4.1, fizemos o gráfico de $m_\lambda(x_1, \ldots, x_n)$ como função de λ. Vemos por ele que o máximo ocorre perto de $\lambda = 2$. Mais precisamente, por uma tabulação, determinamos que $\lambda = 2{,}3$ está próximo do máximo. Assim, usamos a distribuição Beta$(5 + 2{,}3; 15 + 2{,}3)$ = Beta$(7{,}3; 17{,}3)$ para as inferências sobre θ. ■

Há muitas questões envolvendo os métodos de Bayes empírico. Esta é uma área

No original: *likelihood function*[65].

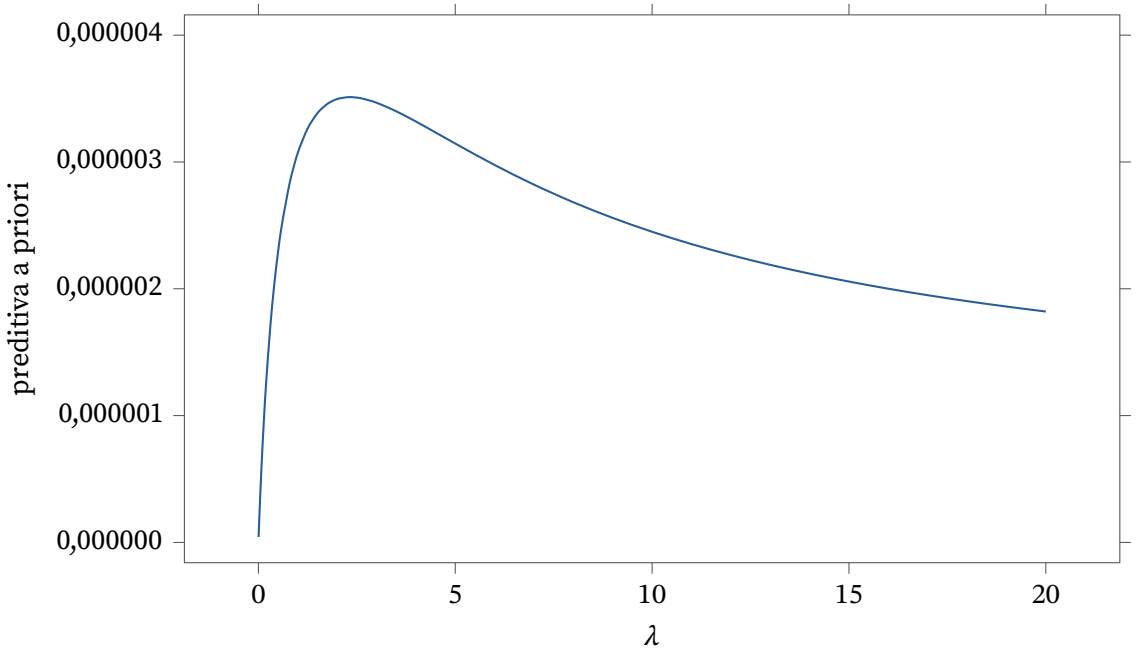


Figura 7.4.1: Gráfico de $m_\lambda(x_1, \ldots, x_n)$ no Exemplo 7.4.3.

ativa de pesquisa estatística.

7.4.4 Bayes Hierárquico

Uma alternativa à escolha de uma priori para θ em $\{\pi_\lambda : \lambda \in \Lambda\}$ consiste em pôr ainda outra distribuição a priori ω, chamada de *hiperpriori*, sobre λ. Essa abordagem costuma ser chamada de *Bayes hierárquico*. A priori para θ passa a ser, basicamente, $\pi(\theta) = \int_\Lambda \pi_\lambda(\theta)\omega(\lambda)\, d\lambda$, de modo que, na prática, eliminamos o hiperparâmetro por integração. O problema, então, é como escolher a priori ω. Em essência, simplesmente trocamos o problema de escolher a priori sobre θ pelo de escolher a hiperpriori sobre λ. Nas aplicações que usam Bayes hierárquico, é comum fazer escolhas padrão para ω, embora também pudéssemos recorrer a técnicas de elicitação. Discutiremos isso mais a fundo na Seção 7.4.5.

Assim, nessa situação, a densidade a posteriori de θ é igual a

$$\pi(\theta \mid s) = \frac{f_\theta(s) \int_\Lambda \pi_\lambda(\theta)\omega(\lambda)\, d\lambda}{m(s)} = \int_\Lambda \frac{f_\theta(s)\pi_\lambda(\theta)}{m_\lambda(s)} \frac{m_\lambda(s)\omega(\lambda)}{m(s)}\, d\lambda,$$

em que $m(s) = \int_\Lambda \int_\Omega f_\theta(s)\pi_\lambda(\theta)\omega(\lambda)\, d\theta\, d\lambda = \int_\Lambda m_\lambda(s)\omega(\lambda)\, d\lambda$ e, para λ fixo, $m_\lambda(s) = \int f_\theta(s)\pi_\lambda(\theta)\, d\theta$ (supondo λ contínuo, com densidade a priori dada por ω). Note que a densidade a posteriori de λ é $m_\lambda(s)\omega(\lambda)/m(s)$, enquanto $f_\theta(s)\pi_\lambda(\theta)/m_\lambda(s)$ é a densidade a posteriori de θ dado λ.

Portanto, podemos usar $\pi(\theta \mid s)$ para inferências sobre o parâmetro do modelo θ (por exemplo, estimação, regiões de credibilidade e avaliação de hipóteses) e $m_\lambda(s)\omega(\lambda)/m(s)$ para inferências sobre λ. Em geral, porém, não estamos interessados em λ e, na verdade, não faz muito sentido falar no valor "verdadeiro" de λ. O valor verdadeiro de θ corresponde à distribuição que de fato produziu os dados observados s, ao menos quando o modelo está correto, ao passo que não pensamos em λ como gerado a partir de ω. Isso implica também outra distinção entre θ e λ: θ faz parte da função de verossimilhança, baseada em como os dados foram gerados, enquanto λ não faz.

Exemplo 7.4.4 — Normal de Locação e Escala

Suponha que a situação seja a discutida no Exemplo 7.1.4. Nesse caso, tanto μ quanto σ^2 fazem parte da função de verossimilhança e, portanto, são parâmetros do modelo, enquanto μ_0, τ_0^2, α_0 e β_0 não fazem e, portanto, são hiperparâmetros. Para completar essa especificação como modelo hierárquico, precisamos especificar uma priori $\omega(\mu_0, \tau_0^2, \alpha_0, \beta_0)$, tarefa que deixamos para um curso mais avançado. ■

7.4.5 Prioris Impróprias e Não Informatividade

Uma abordagem para escolher uma priori, e para interromper a cadeia de prioris numa abordagem de Bayes hierárquico, é prescrever uma *priori não informativa*[66] baseada na ignorância. Essa priori também é chamada de *priori padrão* ou *priori de referência*. A motivação é especificar uma priori que ponha o mínimo possível de informação na análise e que, em certo sentido, caracterize a ignorância. Surpreendentemente, em muitos contextos, os estatísticos foram levados a escolher prioris não informativas que são *impróprias*, isto é, $\int_\Omega \pi(\theta)\, d\theta = \infty$, de modo que não correspondem a distribuições de probabilidade.

A ideia aqui é dar uma regra tal que, se um estatístico não tiver nenhuma crença a priori sobre o valor de um parâmetro ou hiperparâmetro, seja prescrita uma priori que reflita isso. Na abordagem de Bayes hierárquico, sobe-se pela cadeia até que o estatístico declare ignorância, e uma priori padrão completa a especificação.

Infelizmente, a maneira exata de exprimir a ignorância acaba sendo uma questão bastante sutil. Em muitos casos, as prioris padrão acabam

No original: *noninformative prior*[66].

sendo *impróprias*, isto é, a integral ou a soma da priori sobre todo o espaço paramétrico é igual a ∞, por exemplo, $\int_{\Omega} \pi(\theta)\, d\theta = \infty$, de modo que a priori não é uma distribuição de probabilidade. A interpretação de uma priori imprópria[67] não é nada clara, e o seu uso é um tanto controverso. Naturalmente, (s, θ) deixa de ter uma distribuição de probabilidade conjunta quando usamos prioris impróprias, e não podemos usar o princípio da probabilidade condicional para justificar que as nossas inferências se baseiem na posteriori.

Houve inúmeras dificuldades associadas ao uso de prioris impróprias, o que talvez não surpreenda. Em particular, é importante notar que, em geral, não há razão para que a posteriori de θ exista como uma distribuição de probabilidade própria quando π é imprópria. Se estivermos usando uma priori imprópria, devemos sempre verificar se a posteriori é própria, pois as inferências não farão sentido se estivermos usando uma posteriori imprópria.

Ao usar uma priori imprópria π, é totalmente equivalente usar, em vez dela, a priori $c\pi$ para qualquer $c > 0$, pois a posteriori sob π é própria se e somente se a posteriori sob $c\pi$ for própria; nesse caso, as posterioris são idênticas (ver o Exercício 7.4.6).

O exemplo a seguir ilustra o uso de uma priori imprópria.

Exemplo 7.4.5 — Modelo Normal de Locação com uma Priori Imprópria

Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição $N(\mu, \sigma_0^2)$, em que $\mu \in \boldsymbol{\Omega} = R^1$ é desconhecido e σ_0^2 é conhecido. Muitos argumentos em favor de prioris padrão nesse contexto levam à escolha $\pi(\mu) = 1$, que é claramente imprópria.

Procedendo como no Exemplo 7.1.2, isto é, fingindo que essa π é uma densidade de probabilidade própria, obtemos que a densidade a posteriori de μ é proporcional a

$$\exp\left(-\frac{n}{2\sigma_0^2}(\bar{x} - \mu)^2\right).$$

Isso implica imediatamente que a distribuição a posteriori de μ é $N(\bar{x}, \sigma_0^2/n)$. Note que essa é a mesma posteriori limite obtida no Exemplo 7.1.2 quando $\tau_0 \to \infty$, embora o ponto de vista seja bem diferente. ■

Um método muito usado para escolher uma priori padrão é usar, quando disponível, a priori dada por $I^{1/2}(\theta)$ quando $\theta \in R^1$ (e por $(\det I(\theta))^{1/2}$ no caso

No original: *improper prior*[67].

multidimensional), em que I é a informação de Fisher[68] do modelo estatístico, conforme definida na Seção 6.5. Ela é chamada de *priori de Jeffreys*[69]. Note que a priori de Jeffreys depende do modelo.

A priori de Jeffreys tem uma importante propriedade de invariância. Pelo Desafio 6.5.19, temos que, sob certas condições de regularidade, se fizermos uma transformação 1–1 do parâmetro real θ por meio de $\psi = \Psi(\theta)$, então a informação de Fisher de ψ é dada por

$$I\left(\Psi^{-1}(\psi)\right)\left(\left(\Psi^{-1}\right)'(\psi)\right)^2.$$

Portanto, a priori padrão de Jeffreys para ψ é

$$I^{1/2}\left(\Psi^{-1}(\psi)\right)\left|\left(\Psi^{-1}\right)'(\psi)\right|. \tag{7.4.1}$$

Vemos agora que, se tivéssemos começado com a priori padrão $I^{1/2}(\theta)$ para θ e feito a mudança de variável[70] para ψ, essa priori se transformaria em (7.4.1), pelos Teoremas 2.6.2 e 2.6.3. Um resultado semelhante pode ser obtido quando θ é multidimensional.

A priori de Jeffreys muitas vezes acaba sendo imprópria, como ilustra o próximo exemplo.

Exemplo 7.4.6 — Normal de Locação (continuação do Exemplo 7.4.5)

Nesse caso, a priori de Jeffreys é dada por $\pi(\theta) = \sqrt{n}/\sigma_0$, que dá a mesma posteriori que no Exemplo 7.4.5. Note que a priori de Jeffreys é, na prática, uma constante e, portanto, a priori do Exemplo 7.4.5 é equivalente à priori de Jeffreys. ■

A pesquisa sobre regras para determinar prioris não informativas e sobre as consequências de usar essas prioris é uma área ativa da estatística. Embora a impropriedade pareça contraintuitiva, o seu uso muitas vezes produz inferências com boas propriedades.

Resumo da Seção 7.4

- Para implementar a inferência bayesiana, o estatístico precisa escolher uma priori, além do modelo amostral para os dados.
- Essas escolhas precisam ser verificadas se se espera que as inferências obtidas tenham validade prática. Esse tema é discutido no Capítulo 9.

No original: *Fisher information*[68], *Jeffreys' prior*[69], *change of variable*[70].

- Foram criadas várias técnicas para permitir a escolha automática de uma priori. Entre elas estão os métodos de Bayes empírico, o Bayes hierárquico e o uso de prioris não informativas para exprimir ignorância.
- As prioris não informativas são muitas vezes impróprias. Devemos sempre verificar se uma priori imprópria leva a uma posteriori própria.

Exercícios

7.4.1 Prove que a família $\{\text{Gama}(\alpha, \beta) : \alpha > 0, \beta > 0\}$ é uma família conjugada de prioris com respeito à amostragem do modelo dado pelas distribuições Pareto(λ) com $\lambda > 0$.

7.4.2 Prove que a família $\{\pi_{\alpha,\beta}(\theta) : \alpha > 1, \beta > 0\}$ de prioris dada por

$$\pi_{\alpha,\beta}(\theta) = \frac{\theta^{-\alpha} I_{[\beta,\infty)}(\theta)}{(\alpha - 1)\beta^{\alpha-1}}$$

é uma família conjugada de prioris com respeito à amostragem do modelo dado pelas distribuições Uniforme$[0, \theta]$ com $\theta > 0$.

7.4.3 Suponha que o modelo estatístico é dado por

	$p_\theta(1)$	$p_\theta(2)$	$p_\theta(3)$	$p_\theta(4)$
$\theta = a$	1/3	1/6	1/3	1/6
$\theta = b$	1/2	1/4	1/8	1/8

e que consideramos a família de prioris dada por

	$\pi_\tau(a)$	$\pi_\tau(b)$
$\tau = 1$	1/2	1/2
$\tau = 2$	1/3	2/3

e que observamos a amostra $x_1 = 1$, $x_2 = 1$, $x_2 = 3$.*

(a) Se usarmos o valor máximo da preditiva a priori para os dados para determinar o valor de τ e, com ele, a priori, qual priori é escolhida aqui?

(b) Determine a posteriori de θ com base na priori escolhida.

7.4.4 Para a situação descrita no Exercício 7.4.3, ponha uma priori uniforme no hiperparâmetro τ e determine a posteriori de θ. (Sugestão: teorema da probabilidade total.)

*Nota do tradutor. O original traz x_2 duas vezes; pelo contexto, a terceira observação seria $x_3 = 3$.

7.4.5 Para o modelo de proporções descrito no Exemplo 7.1.1, determine a densidade preditiva a priori. Se $n = 10$ e $n\bar{x} = 7$, qual das prioris dadas por $(\alpha, \beta) = (1, 1)$ ou $(\alpha, \beta) = (5, 5)$ o critério da preditiva a priori escolheria para as inferências seguintes sobre θ?

7.4.6 Prove que, ao usar uma priori imprópria π, a posteriori sob π é própria se e somente se a posteriori sob $c\pi$ for própria para $c > 0$, e que, nesse caso, as posterioris são idênticas.

7.4.7 Determine a priori de Jeffreys para o modelo Bernoulli(θ) e determine a distribuição a posteriori de θ com base nessa priori.

7.4.8 Suponha que estamos amostrando de um modelo Uniforme$[0, \theta]$, $\theta > 0$, e queremos usar a priori imprópria $\pi(\theta) \equiv 1$.

(a) A posteriori existe nesse contexto?

(b) A priori de Jeffreys existe nesse contexto?

7.4.9 Suponha que um estudante quer pôr uma priori na nota média, de 0 a 100, que a sua turma vai obter na próxima prova de estatística. O estudante acha que uma priori normal centrada em 66 é adequada e que o intervalo $(40, 92)$ deve conter 99% das notas. Identifique a priori completamente.

7.4.10 Um laboratório fez, no passado, muitas medições em amostras de água de uma fonte específica para determinar a presença de um certo contaminante. Pelos seus registros, determinou-se que 50% das amostras tinham contaminação inferior a 5,3 partes por milhão, enquanto 95% tinham contaminação inferior a 7,3 partes por milhão. Se uma priori normal for usada numa análise futura, que priori esses dados determinam?

7.4.11 Suponha que um fabricante quer construir um intervalo de credibilidade 0,95 para o tempo de vida[71] médio θ de um item vendido pela empresa. Um engenheiro consultor tem 99% de certeza de que o tempo de vida médio é inferior a 50 meses. Se a priori de θ for uma Exponencial(λ), determine λ com base nessa informação.

7.4.12 Suponha que a priori de um parâmetro do modelo μ é tomada como $N(\mu_0, \sigma_0^2)$, em que μ_0 e σ_0^2 são hiperparâmetros. O estatístico consegue elicitar um valor para μ_0, mas sente-se incapaz de fazer isso para σ_0^2. Por isso, o estatístico põe em σ_0^2 uma hiperpriori dada por $1/\sigma_0^2 \sim \text{Gama}(\alpha_0, 1)$ para algum valor de α_0. Determine a priori de μ. (Sugestão: escreva $\mu = \mu_0 + \sigma_0 z$, em que $z \sim N(0, 1)$.)

No original: *lifelength*[71].

Exercícios computacionais

7.4.13 Considere a situação discutida no Exercício 7.4.5.

(a) Se observarmos $n = 10$, $n\bar{x} = 7$ e estivermos usando uma priori simétrica, isto é, $\alpha = \beta$, faça o gráfico da preditiva a priori como função de α no intervalo $(0, 20)$ (você vai precisar de um pacote estatístico que calcule valores da função gama[72] para isso). Esse gráfico escolhe claramente um valor para α?

(b) Se observarmos $n = 10$, $n\bar{x} = 9$, faça o gráfico da preditiva a priori como função de α no intervalo $(0, 20)$. Compare esse gráfico com o do item (a).

7.4.14 Reproduza o gráfico dado no Exemplo 7.4.3 e verifique que o máximo ocorre perto de $\lambda = 2{,}3$.

Problemas

7.4.15 Mostre que uma distribuição da família $\{N(\mu_0, \tau_0^2) : \mu_0 \in R^1, \tau_0^2 > 0\}$ fica completamente determinada quando especificamos dois quantis da distribuição.

7.4.16 (*Modelo normal de escala*) Considere a família de distribuições $N(\mu_0, \sigma^2)$, em que μ_0 é conhecido e $\sigma^2 > 0$ é desconhecido. Determine a priori de Jeffreys para esse modelo.

7.4.17 Suponha que, para o modelo normal de locação e escala[73] descrito no Exemplo 7.1.4, usamos a priori formada pela priori de Jeffreys para o modelo de locação (apenas uma constante) vezes a priori de Jeffreys para o modelo normal de escala. Determine a distribuição a posteriori de (μ, σ^2).

7.4.18 Considere o modelo normal de locação descrito no Exemplo 7.1.2.

(a) Determine a densidade preditiva a priori m. (Sugestão: escreva a densidade conjunta da amostra e de μ. Use (7.1.2) para eliminar μ por integração e não se preocupe em pôr m numa forma reconhecível.)

(b) Como você geraria um valor $(X_1, \ldots, X_n)$ dessa distribuição?

(c) $X_1, \ldots, X_n$ são mutuamente independentes? Justifique a sua resposta. (Sugestão: escreva $X_i = \mu + \sigma_0 Z_i$, $\mu = \mu_0 + \tau_0 Z$, em que $Z, Z_1, \ldots, Z_n$ são i.i.d. $N(0, 1)$.)

No original: *gamma function*[72], *location-scale normal model*[73].

7.4.19 Considere o Exemplo 7.3.2, mas desta vez use a priori $\pi(\mu, \sigma^2) = 1/\sigma^2$. Desenvolva o algoritmo do amostrador de Gibbs para essa situação. (Sugestão: basta ajustar adequadamente cada condicional completa[74] do Exemplo 7.3.2.)

Problemas computacionais

7.4.20 Use a formulação descrita no Problema 7.4.17 e os dados da tabela a seguir

2,6	4,2	3,1	5,2	3,7	3,8	5,6	1,8	5,3	4,0
3,0	4,0	4,1	3,2	2,2	3,4	4,5	2,9	4,7	5,2

para gerar uma amostra de tamanho $N = 10^4$ da posteriori. Faça o gráfico de uma estimativa da densidade a posteriori de $\psi = \sigma/\mu$ por histograma de densidade, com base nessa amostra.

Desafios

7.4.21 Quando $\theta = (\theta_1, \theta_2)$, a matriz de informação de Fisher $I(\theta_1, \theta_2)$ é definida no Problema 6.5.15. A priori de Jeffreys é então definida como $(\det I(\theta_1, \theta_2))^{1/2}$. Determine a priori de Jeffreys para o modelo normal de locação e escala e compare-a com a priori usada no Problema 7.4.17.

Tópicos para discussão

7.4.22 Usar métodos de Bayes empírico para determinar uma priori viola o princípio bayesiano de que a todas as incógnitas devem ser atribuídas distribuições de probabilidade. Comente isso. A abordagem bayesiana hierárquica é uma solução para esse problema?

No original: *full conditional*[74].

7.5 Demonstrações Adicionais (Avançado)

Dedução da Distribuição a Posteriori para o Modelo Normal de Locação e Escala

No Exemplo 7.1.4, a função de verossimilhança é dada por

$$L(\theta \mid x_1, \ldots, x_n) = (2\pi\sigma^2)^{-n/2} \exp\left(-\frac{n}{2\sigma^2}(\bar{x}-\mu)^2\right) \exp\left(-\frac{n-1}{2\sigma^2}s^2\right).$$

A priori de (μ, σ^2) é dada por $\mu \mid \sigma^2 \sim N(\mu_0, \tau_0^2\sigma^2)$ e $1/\sigma^2 \sim \text{Gama}(\alpha_0, \beta_0)$, em que μ_0, τ_0^2, α_0 e β_0 são fixos e conhecidos.

A densidade a posteriori de (μ, σ^{-2}) é então proporcional à verossimilhança vezes a priori conjunta. Portanto, mantendo apenas as partes da verossimilhança e da priori que dependem de μ e σ^2, a densidade a posteriori conjunta é proporcional a

$$\begin{aligned}
&\left\{\left(\frac{1}{\sigma^2}\right)^{n/2} \exp\left(-\frac{n}{2\sigma^2}(\bar{x}-\mu)^2\right) \exp\left(-\frac{n-1}{2\sigma^2}s^2\right)\right\} \times \\
&\left\{\left(\frac{1}{\sigma^2}\right)^{1/2} \exp\left(-\frac{1}{2\tau_0^2\sigma^2}(\mu-\mu_0)^2\right)\right\}\left\{\left(\frac{1}{\sigma^2}\right)^{\alpha_0-1} \exp\left(-\frac{\beta_0}{\sigma^2}\right)\right\} \\
= \; & \exp\left(-\frac{n}{2\sigma^2}(\bar{x}-\mu)^2 - \frac{1}{2\tau_0^2\sigma^2}(\mu-\mu_0)^2\right)\left(\frac{1}{\sigma^2}\right)^{\alpha_0+n/2-1/2} \times \\
& \exp\left(-\left[\beta_0 + \frac{n-1}{2}s^2\right]\frac{1}{\sigma^2}\right) \\
= \; & \exp\left(-\frac{1}{2\sigma^2}\left[\left(n+\frac{1}{\tau_0^2}\right)\mu^2 - 2\left(n\bar{x}+\frac{\mu_0}{\tau_0^2}\right)\mu\right]\right) \times \\
& \left(\frac{1}{\sigma^2}\right)^{\alpha_0+n/2-1/2} \exp\left(-\left[\beta_0 + \frac{n}{2}\bar{x}^2 + \frac{1}{2\tau_0^2}\mu_0^2 + \frac{n-1}{2}s^2\right]\frac{1}{\sigma^2}\right) \\
= \; & \left(\frac{1}{\sigma^2}\right)^{1/2} \exp\left(-\frac{1}{2\sigma^2}\left(n+\frac{1}{\tau_0^2}\right)\left[\mu - \left(n+\frac{1}{\tau_0^2}\right)^{-1}\left(\frac{\mu_0}{\tau_0^2}+n\bar{x}\right)\right]^2\right) \times \\
& \left(\frac{1}{\sigma^2}\right)^{\alpha_0+n/2-1} \exp\left(-\left[\begin{array}{c} \beta_0 + \frac{n}{2}\bar{x}^2 + \frac{1}{2\tau_0^2}\mu_0^2 + \frac{n-1}{2}s^2 \\ -\frac{1}{2}\left(n+\frac{1}{\tau_0^2}\right)^{-1}\left(\frac{\mu_0}{\tau_0^2}+n\bar{x}\right)^2 \end{array}\right]\frac{1}{\sigma^2}\right).
\end{aligned}$$

Daí deduzimos que a distribuição a posteriori de (μ, σ^2) é dada por

$$\mu \mid \sigma^2, x \sim N\left(\mu_x, \left(n+\frac{1}{\tau_0^2}\right)^{-1}\sigma^2\right)$$

e

$$\frac{1}{\sigma^2} \Big| x \sim \text{Gama}(\alpha_0 + n/2, \beta_x),$$

em que

$$\mu_x = \left(n + \frac{1}{\tau_0^2}\right)^{-1} \left(\frac{\mu_0}{\tau_0^2} + n\bar{x}\right)$$

e

$$\begin{aligned}\beta_x &= \beta_0 + \frac{n}{2}\bar{x}^2 + \frac{\mu_0^2}{2\tau_0^2} + \frac{n-1}{2}s^2 - \frac{1}{2}\left(n + \frac{1}{\tau_0^2}\right)^{-1}\left(\frac{\mu_0}{\tau_0^2} + n\bar{x}\right)^2 \\ &= \beta_0 + \frac{n-1}{2}s^2 + \frac{1}{2}\frac{n(\bar{x}-\mu_0)^2}{1+n\tau_0^2}.\end{aligned}$$

Dedução de $J(\theta(\psi_0, \lambda))$ para a Normal de Locação e Escala

Aqui temos que

$$\psi = \psi(\mu, \sigma^{-2}) = \frac{\sigma}{\mu} = \frac{1}{\mu}\left(\frac{1}{\sigma^2}\right)^{-1/2}$$

e

$$\lambda = \lambda(\mu, \sigma^{-2}) = \frac{1}{\sigma^2}.$$

Temos que

$$\begin{aligned}\left|\det\begin{pmatrix} \frac{\partial\psi}{\partial\mu} & \frac{\partial\psi}{\partial\left(\frac{1}{\sigma^2}\right)} \\ \frac{\partial\lambda}{\partial\mu} & \frac{\partial\lambda}{\partial\left(\frac{1}{\sigma^2}\right)} \end{pmatrix}\right| &= \left|\det\begin{pmatrix} -\mu^{-2}\left(\frac{1}{\sigma^2}\right)^{-1/2} & -\frac{1}{2}\mu^{-1}\left(\frac{1}{\sigma^2}\right)^{-3/2} \\ 0 & 1 \end{pmatrix}\right| \\ &= \left|\det\begin{pmatrix} -\psi^2\lambda^{1/2} & -\frac{1}{2}\psi\lambda^{-1} \\ 0 & 1 \end{pmatrix}\right| = \psi^2\lambda^{1/2},\end{aligned}$$

e assim

$$J(\theta(\psi_0, \lambda)) = (\psi^2\lambda^{1/2})^{-1}.$$

CAPÍTULO 8

Inferências Ótimas

ESBOÇO DO CAPÍTULO

Seção 1 Estimação Não Viesada Ótima
Seção 2 Testes de Hipóteses Ótimos
Seção 3 Inferências Bayesianas Ótimas
Seção 4 Teoria da Decisão (Avançado)
Seção 5 Demonstrações Adicionais (Avançado)

No Capítulo 5, apresentamos o ingrediente básico da inferência estatística: o modelo estatístico. No Capítulo 6, desenvolvemos métodos de inferência baseados apenas no modelo, por meio da função de verossimilhança[1]. No Capítulo 7, acrescentamos a distribuição a priori[2] para o parâmetro do modelo, o que levou à distribuição a posteriori[3] como base para obter métodos de inferência.

Tanto com a verossimilhança[4] quanto com a distribuição a posteriori[5], porém, as inferências foram obtidas, em grande parte, com base na intuição. Por exemplo, quando tínhamos uma característica de interesse $\psi(\theta)$, nada na teoria dos Capítulos 6 e 7 nos obrigava a escolher um estimador, um intervalo de confiança[6] ou de credibilidade ou um procedimento de teste em particular. Uma teoria completa da inferência estatística, porém, prescreveria totalmente nossas inferências.

Uma tentativa de resolver essa questão é introduzir uma medida de desempenho para as inferências e, então, escolher a inferência que se sai melhor com respeito a essa medida. Por exemplo, podemos escolher medir o desempenho dos estimadores pelo seu erro quadrático médio[7] (MSE) e, então, tentar obter um estimador com o menor MSE possível. Essa é a abordagem de otimalidade da inferência, e ela tem tido bastante sucesso em vários problemas. Neste capítulo, veremos vários sucessos da abordagem de otimalidade na obtenção de inferências.

Às vezes, a medida de desempenho que usamos pode ser considerada como baseada no que se chama de *função de perda*[8]. As funções de perda formam

No original: *likelihood function*[1], *prior*[2], *posterior*[3], *likelihood*[4], *posterior*[5], *confidence interval*[6], *mean-squared error*[7], *loss function*[8].

a base de mais uma abordagem da inferência estatística, chamada *teoria da decisão*[9]. Embora nem sempre uma medida de desempenho seja baseada numa função de perda, isso vale em alguns dos problemas mais importantes da inferência estatística. A teoria da decisão fornece um arcabouço geral para discutir esses problemas. Uma breve introdução à teoria da decisão é dada na Seção 8.4, como tópico avançado.

8.1 Estimação Não Viesada Ótima

Suponha que queremos estimar a característica real $\psi(\theta)$ do modelo estatístico $\{f_\theta : \theta \in \mathbf{\Omega}\}$. Se observamos os dados s, uma estimativa[10] é um valor $T(s)$ que o estatístico espera que esteja perto do verdadeiro valor de $\psi(\theta)$. Dizemos que T é um *estimador* de ψ. O erro da estimativa é dado por $|T(s) - \psi(\theta)|$. Por várias razões (a maioria ligada à matemática), é mais conveniente considerar o erro quadrático $(T(s) - \psi(\theta))^2$.

É claro que gostaríamos que esse erro quadrático fosse o menor possível. Como não conhecemos o verdadeiro valor de θ, isso nos leva a considerar as distribuições do erro quadrático quando s tem distribuição dada por f_θ, para cada $\theta \in \mathbf{\Omega}$. Gostaríamos, então, de escolher o estimador T de modo que essas distribuições fiquem o mais concentradas possível em torno de 0. Uma medida conveniente da concentração dessas distribuições em torno de 0 é dada por suas médias, isto é,

$$\mathrm{MSE}_\theta(T) = E_\theta((T - \psi(\theta))^2), \tag{8.1.1}$$

chamada de *erro quadrático médio* (lembre a Definição 6.3.1).

Um *estimador ótimo* de $\psi(\theta)$ é, então, um T que minimiza (8.1.1) para todo $\theta \in \mathbf{\Omega}$. Em outras palavras, T seria ótimo se, para qualquer outro estimador T^* definido em S, tivéssemos

$$\mathrm{MSE}_\theta(T) \leq \mathrm{MSE}_\theta(T^*)$$

para cada θ. Infelizmente, pode-se mostrar que, exceto em circunstâncias muito artificiais, não existe tal T; por isso, precisamos modificar nosso problema de otimização.

Essa modificação consiste em restringir os estimadores T que admitiremos como escolhas possíveis para a inferência. Considere um estimador T tal que $E_\theta(T)$ não existe ou é infinito. Pode-se mostrar, então, que (8.1.1) é infinito (veja

No original: *decision theory*[9], *estimate*[10].

o Desafio 8.1.26). Assim, primeiro restringiremos nossa busca aos T para os quais $E_\theta(T)$ é finito para todo θ.

Outras restrições aos tipos de estimadores que consideramos usam o resultado a seguir (lembre também o Teorema 6.3.1).

Teorema 8.1.1

Se T é tal que $E(T^2)$ é finito, então

$$E((T-c)^2) = \text{Var}(T) + (E(T)-c)^2,$$

Isso é minimizado tomando $c = E(T)$.

Demonstração. Temos que

$$\begin{aligned} E((T-c)^2) &= E((T-E(T)+E(T)-c)^2) \\ &= E((T-E(T))^2) + 2E(T-E(T))(E(T)-c) + (E(T)-c)^2 \\ &= \text{Var}(T) + (E(T)-c)^2, \end{aligned} \tag{8.1.2}$$

pois $E(T-E(T)) = E(T) - E(T) = 0$. Como $(E(T)-c)^2 \geq 0$ e $\text{Var}(T)$ não depende de c, o valor de (8.1.2) é minimizado tomando $c = E(T)$. ■

8.1.1 O Teorema de Rao–Blackwell e a Rao–Blackwellização

Vamos provar que, quando procuramos um T que minimize (8.1.1), podemos restringir ainda mais nossa atenção a estimadores T que dependem dos dados apenas por meio do valor de uma estatística suficiente[11]. Isso simplifica nossa busca, pois a suficiência muitas vezes resulta numa redução da dimensão dos dados (lembre a discussão e os exemplos da Seção 6.1.1). Antes, porém, precisamos da seguinte propriedade da suficiência.

Teorema 8.1.2

Uma estatística U é suficiente para um modelo se e somente se a distribuição condicional dos dados s dado $U = u$ é a mesma para todo $\theta \in \mathbf{\Omega}$.

No original: *sufficient statistic*[11].

Demonstração. Veja a Seção 8.5 para a demonstração deste resultado. ■

A consequência desse resultado é que a informação contida nos dados s além do valor $U(s) = u$ não pode nos dizer nada sobre o verdadeiro valor de θ, porque essa informação vem de uma distribuição que não depende do parâmetro. Observe que o Teorema 8.1.2 é uma caracterização da suficiência, alternativa à dada na Seção 6.1.1.

Considere um exemplo simples que ilustra o conteúdo do Teorema 8.1.2.

Exemplo 8.1.1

Suponha que $S = \{1, 2, 3, 4\}$, $\mathbf{\Omega} = \{a, b\}$, em que as duas distribuições de probabilidade são dadas pela tabela a seguir.

	$s = 1$	$s = 2$	$s = 3$	$s = 4$
$\theta = a$	1/2	1/6	1/6	1/6
$\theta = b$	1/4	1/4	1/4	1/4

Então $L(\cdot \mid 2) = L(\cdot \mid 3) = L(\cdot \mid 4)$ e, assim, $U : S \longrightarrow \{0, 1\}$, dada por $U(1) = 0$ e $U(2) = U(3) = U(4) = 1$, é uma estatística suficiente.

Como necessariamente $s = 1$ quando observamos $U(s) = 0$, a distribuição condicional da resposta s, dado $U(s) = 0$, é degenerada em 1 (isto é, toda a massa de probabilidade está no ponto 1) tanto para $\theta = a$ quanto para $\theta = b$. Quando $\theta = a$, a distribuição condicional da resposta s, dado $U(s) = 1$, põe 1/3 de sua massa em cada um dos pontos de $\{2, 3, 4\}$, e o mesmo acontece quando $\theta = b$. Assim, dado $U(s) = 1$, as distribuições condicionais são as da tabela a seguir.

	$s = 1$	$s = 2$	$s = 3$	$s = 4$
$\theta = a$	0	1/3	1/3	1/3
$\theta = b$	0	1/3	1/3	1/3

Vemos, portanto, que as distribuições condicionais de fato não dependem de θ. ■

Agora combinamos os Teoremas 8.1.1 e 8.1.2 para mostrar que podemos restringir nossa atenção a estimadores T que dependem dos dados apenas por meio do valor de uma estatística suficiente U. Pelo Teorema 8.1.2, podemos denotar a medida de probabilidade condicional[12] de s, dado $U(s) = u$, por

No original: *conditional probability*[12].

$P(\cdot \mid U = u)$, isto é, essa medida de probabilidade[13] não depende de θ, pois é a mesma para todo $\theta \in \mathbf{\Omega}$.

Para um estimador T de $\psi(\theta)$ tal que $E_\theta(T)$ é finito para todo θ, tome $T_U(s)$ igual à esperança condicional[14] de T dado o valor de $U(s)$, ou seja,

$$T_U(s) = E_{P(\cdot|U=U(s))}(T),$$

isto é, T_U é o valor médio[15] de T quando tomamos a média usando $P(\cdot \mid U = U(s))$. Observe que $T_U(s_1) = T_U(s_2)$ sempre que $U(s_1) = U(s_2)$ (isso porque $P(\cdot \mid U = U(s_1)) = P(\cdot \mid U = U(s_2))$) e, assim, T_U depende dos dados s apenas por meio do valor de $U(s)$.

Teorema 8.1.3 (Rao–Blackwell)

Suponha que U é uma estatística suficiente e que $E_\theta(T^2)$ é finito para todo θ. Então $\text{MSE}_\theta(T_U) \leq \text{MSE}_\theta(T)$ para todo $\theta \in \mathbf{\Omega}$.

Demonstração. Seja $P_{\theta,U}$ a medida de probabilidade marginal de U induzida por P_θ. Pelo teorema da esperança[16] total (veja o Teorema 3.5.2), temos que

$$\text{MSE}_\theta(T) = E_{P_{\theta,U}}\Big(E_{P(\cdot|U=u)}((T - \psi(\theta))^2)\Big),$$

em que $E_{P(\cdot|U=u)}((T - \psi(\theta))^2)$ denota o MSE condicional de T, dado $U = u$. Agora, pelo Teorema 8.1.1,

$$E_{P(\cdot|U=u)}((T - \psi(\theta))^2) = \text{Var}_{P(\cdot|U=u)}(T) + (E_{P(\cdot|U=u)}(T) - \psi(\theta))^2. \tag{8.1.3}$$

Como os dois termos em (8.1.3) são não negativos, e lembrando a definição de T_U, temos

$$\begin{aligned}\text{MSE}_\theta(T) &= E_{P_{\theta,U}}(\text{Var}_{P(\cdot|U=u)}(T)) + E_{P_{\theta,U}}((T_U(s) - \psi(\theta))^2) \\ &\geq E_{P_{\theta,U}}((T_U(s) - \psi(\theta))^2).\end{aligned}$$

Agora $(T_U(s) - \psi(\theta))^2 = E_{P(\cdot|U=u)}((T_U(s) - \psi(\theta))^2)$ (Teorema 3.5.4) e, assim, pelo teorema da esperança total,

$$\begin{aligned}E_{P_{\theta,U}}((T_U(s) - \psi(\theta))^2) &= E_{P_{\theta,U}}\Big(E_{P(\cdot|U=u)}((T_U(s) - \psi(\theta))^2)\Big) \\ &= E_{P_\theta}((T_U(s) - \psi(\theta))^2) = \text{MSE}_\theta(T_U)\end{aligned}$$

e o teorema está provado. ■

No original: *probability measure*[13], *conditional expectation*[14], *mean value*[15], *expectation*[16].

O Teorema 8.1.3 mostra que sempre podemos melhorar (ou, pelo menos, não piorar) qualquer estimador T que tenha segundo momento finito, substituindo $T(s)$ pela estimativa $T_U(s)$. Esse processo às vezes é chamado de *Rao–Blackwellização* de um estimador.

Observe que tomar $E = E_\theta$ e $c = \psi(\theta)$ no Teorema 8.1.1 implica

$$\text{MSE}_\theta(T) = \text{Var}_\theta(T) + (E_\theta(T) - \psi(\theta))^2. \tag{8.1.4}$$

Assim, o MSE de T pode ser decomposto como a soma da variância[17] de T com o quadrado do viés de T (isso também foi provado no Teorema 6.3.1).

O Teorema 8.1.1 tem outra consequência importante, pois (8.1.4) é minimizado tomando $\psi(\theta) = E_\theta(T)$. Isso indica que, em média, o estimador T fica mais perto (em termos de erro quadrático) de $E_\theta(T)$ do que de qualquer outro valor. Assim, se estamos amostrando da distribuição especificada por θ, $T(s)$ é uma estimativa natural de $E_\theta(T)$. Portanto, para uma característica geral $\psi(\theta)$, faz sentido restringir a atenção a estimadores com viés igual a 0. Isso leva à definição a seguir.

Definição 8.1.1

Um estimador T de $\psi(\theta)$ é *não viesado* se $E_\theta(T) = \psi(\theta)$ para todo $\theta \in \mathbf{\Omega}$.

Observe que, para estimadores não viesados com segundo momento finito, (8.1.4) se torna

$$\text{MSE}_\theta(T) = \text{Var}_\theta(T).$$

Portanto, nossa busca por um estimador ótimo se tornou a busca por um estimador não viesado[18] de menor variância. Se tal estimador existe, damos a ele um nome especial.

Definição 8.1.2

Um estimador não viesado de $\psi(\theta)$ com a menor variância para cada $\theta \in \mathbf{\Omega}$ é chamado de *estimador não viesado de variância uniformemente mínima (UMVU)*.

É importante notar que o teorema de Rao–Blackwell (Teorema 8.1.3) também se aplica a estimadores não viesados. Isso porque a Rao–Blackwellização de um estimador não viesado produz um estimador não viesado, como mostra o resultado a seguir.

No original: *variance*[17], *unbiased*[18].

Teorema 8.1.4 (Rao–Blackwell para estimadores não viesados)

Se T tem segundo momento finito, é não viesado para $\psi(\theta)$ e U é uma estatística suficiente, então $E_\theta(T_U) = \psi(\theta)$ para todo $\theta \in \mathbf{\Omega}$ (logo, T_U também é não viesado para $\psi(\theta)$) e $\mathrm{Var}_\theta(T_U) \leq \mathrm{Var}_\theta(T)$.

Demonstração. Usando o teorema da esperança total (Teorema 3.5.2), temos

$$E_\theta(T_U) = E_{P_{\theta,U}}(T_U) = E_{P_{\theta,U}}\big(E_{P(\cdot|U=u)}(T)\big) = E_\theta(T) = \psi(\theta).$$

Assim, T_U é não viesado para $\psi(\theta)$ e $\mathrm{MSE}_\theta(T) = \mathrm{Var}_\theta(T)$, $\mathrm{MSE}_\theta(T_U) = \mathrm{Var}_\theta(T_U)$. Aplicando o Teorema 8.1.3, obtemos $\mathrm{Var}_\theta(T_U) \leq \mathrm{Var}_\theta(T)$. ■

Há muitas situações em que a teoria da estimação[19] não viesada leva a bons estimadores. O exemplo a seguir, porém, mostra que em alguns problemas não existem estimadores não viesados e, portanto, a teoria tem algumas limitações.

No original: *estimation*[19].

Exemplo 8.1.2 — A Inexistência de um Estimador Não Viesado

Suponha que $(x_1, \ldots, x_n)$ é uma amostra da Bernoulli(θ) e que queremos encontrar um estimador UMVU de $\psi(\theta) = \theta/(1-\theta)$, a chance a favor da ocorrência de um sucesso. Pelo Teorema 8.1.4, podemos restringir nossa busca a estimadores não viesados T que sejam funções da estatística suficiente $n\bar{x}$.

Tal T satisfaz $E_\theta(T(n\bar{X})) = \theta/(1-\theta)$ para todo $\theta \in [0,1]$. Lembrando que $n\bar{X} \sim \text{Binomial}(n, \theta)$, isso implica

$$\frac{\theta}{1-\theta} = \sum_{k=0}^{n} T(k)\binom{n}{k}\theta^k(1-\theta)^{n-k}$$

para todo $\theta \in [0,1]$. Pelo teorema binomial, temos

$$(1-\theta)^{n-k} = \sum_{l=0}^{n-k}\binom{n-k}{l}(-1)^l\theta^l.$$

Substituindo isso na expressão anterior para $\theta/(1-\theta)$ e escrevendo-a em termos de potências de θ, chegamos à igualdade a seguir:*

$$\frac{\theta}{1-\theta} = \sum_{m=0}^{n}\left(\sum_{k=0}^{m} T(k)\binom{n}{k}(-1)^{m-k}\right)\theta^m. \tag{8.1.5}$$

Agora, o lado esquerdo de (8.1.5) vai para ∞ quando $\theta \to 1$, mas o lado direito é um polinômio em θ, que é limitado em $[0,1]$. Portanto, não pode existir um estimador não viesado de ψ. ■

Se uma característica $\psi(\theta)$ tem um estimador não viesado, diz-se que ela é *U-estimável*. Deve-se ter em mente, porém, que o fato de um parâmetro não ser U-estimável não significa que não podemos estimá-lo! Por exemplo, ψ no Exemplo 8.1.2 é uma função injetora[20] de θ; assim, o EMV de ψ é dado por $\bar{x}/(1-\bar{x})$ (veja o Teorema 6.2.1), e esse parece um estimador razoável, mesmo sendo viesado.

*Nota do tradutor. O original omite o fator $\binom{n-k}{m-k}$ na soma interna; pela conta, o coeficiente de θ^m seria $\sum_{k=0}^{m} T(k)\binom{n}{k}\binom{n-k}{m-k}(-1)^{m-k}$. O argumento não muda: o lado direito continua sendo um polinômio em θ.

No original: *one-to-one*[20].

8.1.2 Completude e o Teorema de Lehmann–Scheffé

Em certas circunstâncias, se existe um estimador não viesado que é função de uma estatística suficiente U, então só existe um estimador assim; logo, ele tem de ser UMVU. Precisamos do conceito de completude[21] para estabelecer isso.

Definição 8.1.3

Uma estatística U é *completa* se qualquer função h de U que satisfaça $E_\theta(h(U)) = 0$ para todo $\theta \in \mathbf{\Omega}$ também satisfaz $h(U(s)) = 0$ com probabilidade 1 para cada $\theta \in \mathbf{\Omega}$ (isto é, $P_\theta(\{s : h(U(s)) = 0\}) = 1$ para todo $\theta \in \mathbf{\Omega}$).

Em teoria das probabilidades, tratamos duas funções como equivalentes se elas diferem apenas num conjunto de probabilidade 0, pois a probabilidade de as funções assumirem valores diferentes num valor observado da resposta é 0. Assim, na Definição 8.1.3, não precisamos distinguir entre h e a constante 0. Portanto, uma estatística U é completa se o único estimador não viesado de 0 baseado em U é o próprio 0.

Podemos agora obter o resultado a seguir.

Teorema 8.1.5 (Lehmann–Scheffé)

Se U é uma estatística suficiente completa e se T depende dos dados apenas por meio do valor de U, tem segundo momento finito para todo θ e é não viesado para $\psi(\theta)$, então T é UMVU.

Demonstração. Suponha que T^* também é um estimador não viesado de $\psi(\theta)$. Pelo Teorema 8.1.4, podemos supor que T^* depende dos dados apenas por meio do valor de U. Então existem funções h e h^* tais que $T(s) = h(U(s))$ e $T^*(s) = h^*(U(s))$ e

$$0 = E_\theta(T) - E_\theta(T^*) = E_\theta(h(U)) - E_\theta(h^*(U)) = E_\theta(h(U) - h^*(U)).$$

Pela completude de U, temos $h(U) = h^*(U)$ com probabilidade 1 para cada $\theta \in \mathbf{\Omega}$, o que implica $T = T^*$ com probabilidade 1 para cada $\theta \in \mathbf{\Omega}$. Isso diz que existe, essencialmente, um único estimador não viesado de $\psi(\theta)$ baseado em U e, portanto, ele tem de ser UMVU. ■

No original: *completeness*[21].

O teorema de Rao–Blackwell para estimadores não viesados (Teorema 8.1.4), junto com o teorema de Lehmann–Scheffé, fornece um método para obter um estimador UMVU de $\psi(\theta)$. Suponha que conseguimos encontrar um estimador não viesado T com segundo momento finito. Se também temos uma estatística suficiente completa U, então, pelo Teorema 8.1.4, $T_U(s) = E_{P(\cdot|U=U(s))}(T)$ é não viesado para $\psi(\theta)$ e depende dos dados apenas por meio do valor de U, pois $T_U(s_1) = T_U(s_2)$ sempre que $U(s_1) = U(s_2)$. Portanto, pelo Teorema 8.1.5, T_U é UMVU para $\psi(\theta)$.

Não é necessário que, num dado problema, exista uma estatística suficiente completa. Na verdade, pode-se provar que a única candidata a isso é uma estatística suficiente minimal[22] (lembre a definição na Seção 6.1.1). Assim, num dado problema, precisamos obter uma estatística suficiente minimal e, então, determinar se ela é completa ou não. Ilustramos isso com um exemplo.

Exemplo 8.1.3 — Normal de Locação

Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição $N(\mu, \sigma_0^2)$, em que $\mu \in R^1$ é desconhecido e $\sigma_0^2 > 0$ é conhecido. No Exemplo 6.1.7, mostramos que $\bar{x}$ é uma estatística suficiente minimal para esse modelo.

Na verdade, $\bar{x}$ também é completa para esse modelo. A demonstração disso é um pouco trabalhosa e é apresentada na Seção 8.5.

Como $\bar{x}$ é uma estatística suficiente minimal completa, $T(\bar{x})$ é um estimador UMVU de sua média $E_\mu(T(\bar{X}))$ sempre que T tem segundo momento finito para todo $\mu \in R^1$. Em particular, $\bar{x}$ é o estimador UMVU de μ, pois $E_\mu(\bar{X}) = \mu$ e $E_\mu(\bar{X}^2) = (\sigma_0^2/n) + \mu^2 < \infty$. Além disso, $\bar{x} + \sigma_0 z_p$ é o estimador UMVU de $E_\mu(\bar{X} + \sigma_0 z_p) = \mu + \sigma_0 z_p$ (o p-ésimo quantil da verdadeira distribuição). ■

Os argumentos necessários para mostrar a completude de uma estatística suficiente minimal num problema costumam ser parecidos com o que foi exigido no Exemplo 8.1.3 (veja o Desafio 8.1.27). Em vez de entrar nesses detalhes técnicos aqui, citamos alguns exemplos importantes em que a estatística suficiente minimal é completa.

No original: *minimal sufficient statistic*[22].

Exemplo 8.1.4 — Normal de Locação e Escala

Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição $N(\mu, \sigma^2)$, em que $\mu \in R^1$ e $\sigma > 0$ são desconhecidos. O parâmetro desse modelo é bidimensional e é dado por $(\mu, \sigma^2) \in R^1 \times (0, \infty)$.

Mostramos, no Exemplo 6.1.8, que $(\bar{x}, s^2)$ é uma estatística suficiente minimal para esse modelo. Na verdade, pode-se mostrar que $(\bar{x}, s^2)$ é uma estatística suficiente minimal completa. Portanto, $T(\bar{x}, s^2)$ é um estimador UMVU de $E_\theta(T(\bar{X}, S^2))$ sempre que o segundo momento de $T(\bar{x}, s^2)$ é finito para todo (μ, σ^2). Em particular, $\bar{x}$ é o estimador UMVU de μ e s^2 é UMVU para σ^2. ■

Exemplo 8.1.5 — Modelos Livres de Distribuição

Suponha que $(x_1, \ldots, x_n)$ é uma amostra de alguma distribuição contínua em R^1. O modelo estatístico é formado por todas as distribuições contínuas em R^1.

Pode-se mostrar que as estatísticas de ordem $(x_{(1)}, \ldots, x_{(n)})$ formam uma estatística suficiente minimal completa para esse modelo. Portanto, $T(x_{(1)}, \ldots, x_{(n)})$ é UMVU para

$$E_\theta(T(X_{(1)}, \ldots, X_{(n)}))$$

sempre que

$$E_\theta(T^2(X_{(1)}, \ldots, X_{(n)})) < \infty \tag{8.1.6}$$

para toda distribuição contínua. Em particular, isso acontece se $T : R^n \to R^1$ é limitada. Por exemplo, se

$$T(x_{(1)}, \ldots, x_{(n)}) = \frac{1}{n} \sum_{i=1}^{n} I_A(x_{(i)}),$$

a frequência relativa do evento A na amostra, então $T(x_{(1)}, \ldots, x_{(n)})$ é UMVU para $E_\theta(T(X_{(1)}, \ldots, X_{(n)})) = P_\theta(A)$.

Agora mude a hipótese do modelo, de modo que $(x_1, \ldots, x_n)$ seja uma amostra de alguma distribuição contínua em R^1 que possui seus primeiros m momentos. Novamente, pode-se mostrar que as estatísticas de ordem formam uma estatística suficiente minimal completa. Portanto, $T(x_{(1)}, \ldots, x_{(n)})$ é UMVU para $E_\theta(T(X_{(1)}, \ldots, X_{(n)}))$ sempre que (8.1.6) vale para toda distribuição contínua que possui seus primeiros m momentos. Por exemplo, se $m = 2$, isso implica que $T(x_{(1)}, \ldots, x_{(n)}) = \bar{x}$ é UMVU para $E_\theta(\bar{X})$. Quando $m = 4$, temos que s^2 é UMVU para a variância populacional (veja o Exercício 8.1.2). ■

8.1.3 A Desigualdade de Cramer–Rao (Avançado)

Existe uma desigualdade fundamental que vale para a variância de um estimador T. Ela é dada pela *desigualdade de Cramer–Rao*[23] (às vezes chamada de *desigualdade da informação*). Ela é um corolário da desigualdade a seguir.

No original: *Cramer–Rao inequality*[23].

Teorema 8.1.6 (Desigualdade da covariância)

Suponha $T, U_\theta : S \to R^1$ e $E_\theta(T^2) < \infty$, $0 < E_\theta(U_\theta^2) < \infty$ para todo $\theta \in \mathbf{\Omega}$. Então

$$\mathrm{Var}_\theta(T) \geq \frac{(\mathrm{Cov}_\theta(T, U_\theta))^2}{\mathrm{Var}_\theta(U_\theta)}$$

para todo $\theta \in \mathbf{\Omega}$. Vale a igualdade se e somente se

$$T(s) = E_\theta(T) + \frac{\mathrm{Cov}_\theta(T, U_\theta)}{\mathrm{Var}_\theta(U_\theta)}(U_\theta(s) - E_\theta(U_\theta(s)))$$

com probabilidade 1 para todo $\theta \in \mathbf{\Omega}$ (isto é, se e somente se $T(s)$ e $U_\theta(s)$ são linearmente relacionados).

Demonstração. Esse resultado decorre imediatamente da desigualdade de Cauchy–Schwartz[24] (Teorema 3.6.3). ■

Agora suponha que $\mathbf{\Omega}$ é um subintervalo aberto de R^1 e tomamos

$$U_\theta(s) = S(\theta \mid s) = \frac{\partial \ln f_\theta(s)}{\partial \theta}, \tag{8.1.7}$$

isto é, U_θ é a função escore[25]. Suponha que valem as condições discutidas na Seção 6.5, de modo que $E_\theta(S(\theta \mid s)) = 0$ para todo θ e a informação de Fisher[26] $I(\theta) = \mathrm{Var}_\theta(S(\theta \mid s))$ é finita. Então, usando

$$\frac{\partial \ln f_\theta(s)}{\partial \theta} = \frac{\partial f_\theta(s)}{\partial \theta} \frac{1}{f_\theta(s)},$$

temos

$$\begin{aligned} &\mathrm{Cov}_\theta(T, U_\theta) \\ &\quad = E_\theta\left(T(s)\frac{\partial \ln f_\theta(s)}{\partial \theta}\right) = E_\theta\left(T(s)\frac{\partial f_\theta(s)}{\partial \theta}\frac{1}{f_\theta(s)}\right) \\ &\quad = \sum_s \left(T(s)\frac{\partial f_\theta(s)}{\partial \theta}\frac{1}{f_\theta(s)}\right) f_\theta(s) = \frac{\partial}{\partial \theta}\sum_s T(s) f_\theta(s) = \frac{\partial E_\theta(T)}{\partial \theta}, \end{aligned} \tag{8.1.8}$$

no caso discreto, em que supusemos condições como as discutidas na Seção 6.5, de modo que podemos passar a derivada parcial para dentro da soma. Um argumento semelhante dá a igualdade (8.1.8) também no caso contínuo.

A desigualdade da covariância[27], aplicada com U_θ especificada como em (8.1.7) e usando (8.1.8), dá o resultado a seguir.

No original: *Cauchy–Schwartz inequality*[24], *score function*[25], *Fisher information*[26], *covariance*[27].

Corolário 8.1.1 (Desigualdade de Cramer–Rao ou da informação)

Sob essas condições,

$$\mathrm{Var}_\theta(T) \geq \left(\frac{\partial E_\theta(T)}{\partial \theta}\right)^2 (I(\theta))^{-1}$$

para todo $\theta \in \mathbf{\Omega}$. Vale a igualdade se e somente se

$$T(s) = E_\theta(T) + \frac{\partial E_\theta(T)}{\partial \theta}(I(\theta))^{-1} S(\theta \mid s)$$

com probabilidade 1 para todo $\theta \in \mathbf{\Omega}$.

A desigualdade de Cramer–Rao fornece uma cota inferior[28] fundamental para a variância de um estimador T. Por (8.1.4), sabemos que a variância é uma medida relevante da precisão de um estimador apenas quando o estimador é não viesado; por isso, reenunciamos o Corolário 8.1.1 para esse caso.

Corolário 8.1.2

Sob as condições do Corolário 8.1.1, quando T é um estimador não viesado de $\psi(\theta)$,

$$\mathrm{Var}_\theta(T) \geq (\psi'(\theta))^2 (I(\theta))^{-1}$$

para todo $\theta \in \mathbf{\Omega}$. Vale a igualdade se e somente se

$$T(s) = \psi(\theta) + \psi'(\theta)(I(\theta))^{-1} S(\theta \mid s) \tag{8.1.9}$$

com probabilidade 1 para todo $\theta \in \mathbf{\Omega}$.

Observe que, quando $\psi(\theta) = \theta$, o Corolário 8.1.2 diz que a variância do estimador não viesado T é limitada inferiormente pelo inverso da informação de Fisher. De modo mais geral, quando ψ é uma transformação injetora e suave, temos (usando o Desafio 6.5.19) que a variância de um T não viesado é de novo limitada inferiormente pelo inverso da informação de Fisher, mas desta vez o modelo usa a parametrização em termos de $\psi(\theta)$.

O Corolário 8.1.2 tem várias consequências interessantes. Primeiro, se obtemos um estimador não viesado T cuja variância atinge a cota inferior, sabemos imediatamente que ele é UMVU. Segundo, sabemos que qualquer estimador não viesado que atinge a cota inferior tem a forma dada em (8.1.9). Observe que o lado direito de (8.1.9) precisa ser independente de θ para que isso seja

No original: *lower bound*[28].

um estimador. Se não for, então não há estimadores UMVU cuja variância atinja a cota inferior. O exemplo a seguir mostra que há casos em que existem estimadores UMVU, mas sua variância não atinge a cota inferior.

Exemplo 8.1.6 — Modelo Poisson(λ)

Suponha que $(x_1, \dots, x_n)$ é uma amostra da distribuição Poisson(λ), em que $\lambda > 0$ é desconhecido. A log-verossimilhança é dada por $l(\lambda \mid x_1, \dots, x_n) = n\bar{x} \ln \lambda - n\lambda$; assim, a função escore é dada por $S(\lambda \mid x_1, \dots, x_n) = n\bar{x}/\lambda - n$. Agora

$$\frac{\partial S(\lambda \mid x_1, \dots, x_n)}{\partial \lambda} = -\frac{n\bar{x}}{\lambda^2},$$

e, portanto,

$$I(\lambda) = E_\lambda\left(\frac{n\bar{x}}{\lambda^2}\right) = \frac{n}{\lambda}.$$

Suponha que estamos estimando λ. Então a cota inferior de Cramer–Rao é dada por $I^{-1}(\lambda) = \lambda/n$. Notando que $\bar{x}$ é não viesado para λ e que $\mathrm{Var}_\lambda(\bar{X}) = \lambda/n$, vemos imediatamente que $\bar{x}$ é UMVU e atinge a cota inferior.

Agora suponha que estamos estimando $\psi(\lambda) = e^{-\lambda} = P_\lambda(\{0\})$. A cota inferior de Cramer–Rao é igual a $\lambda e^{-2\lambda}/n$ e

$$\begin{aligned}\psi(\lambda) + \psi'(\lambda) I^{-1}(\lambda) S(\lambda \mid x_1, \dots, x_n) &= e^{-\lambda} - e^{-\lambda}\left(\frac{\lambda}{n}\right)\left(\frac{n\bar{x}}{\lambda} - n\right) \\ &= e^{-\lambda}(1 - \bar{x} + \lambda),\end{aligned}$$

que claramente não é independente de λ. Assim, não existe um estimador UMVU de ψ que atinja a cota inferior.

Existe um estimador UMVU de ψ? Observe que, quando $n = 1$, $I_{\{0\}}(x_1)$ é um estimador não viesado de ψ. Acontece que $\bar{x}$ é (para todo n) uma estatística suficiente minimal completa para esse modelo; assim, pelo teorema de Lehmann–Scheffé, $I_{\{0\}}(x_1)$ é UMVU para ψ. Além disso, $I_{\{0\}}(X_1)$ tem variância

$$P_\lambda(X_1 = 0)(1 - P_\lambda(X_1 = 0)) = e^{-\lambda}(1 - e^{-\lambda}),$$

pois $I_{\{0\}}(X_1) \sim \text{Bernoulli}(e^{-\lambda})$. Isso implica que $e^{-\lambda}(1 - e^{-\lambda}) > \lambda e^{-2\lambda}$.

Em geral, temos que

$$\frac{1}{n}\sum_{i=1}^{n} I_{\{0\}}(x_i)$$

é um estimador não viesado de ψ, mas não é uma função de $\bar{x}$. Assim, não podemos aplicar o teorema de Lehmann–Scheffé, mas podemos Rao–Blackwellizar esse estimador. Portanto, o estimador UMVU de ψ é dado por

$$\frac{1}{n}\sum_{i=1}^{n} E(I_{\{0\}}(X_i) \mid \bar{X} = \bar{x}).$$

Para determinar esse estimador em forma fechada, raciocinamos da seguinte maneira. A função de probabilidade condicional de $(X_1, \ldots, X_n)$ dado $\bar{X} = \bar{x}$, como $n\bar{X}$ tem distribuição Poisson$(n\lambda)$, é

$$\left\{\frac{\lambda^{x_1}}{x_1!}\cdots\frac{\lambda^{x_n}}{x_n!}e^{-n\lambda}\right\}\left\{\frac{(n\lambda)^{n\bar{x}}}{(n\bar{x})!}e^{-n\lambda}\right\}^{-1} = \binom{n\bar{x}}{x_1 \ \ldots \ x_n}\left(\frac{1}{n}\right)^{x_1}\cdots\left(\frac{1}{n}\right)^{x_n},$$

isto é, $(X_1, \ldots, X_n)$ dado $\bar{X} = \bar{x}$ tem distribuição Multinomial$(n\bar{x}, 1/n, \ldots, 1/n)$. Assim, o estimador UMVU é dado por

$$E(I_{\{0\}}(X_1) \mid \bar{X} = \bar{x}) = P(X_1 = 0 \mid \bar{X} = \bar{x}) = \left(1 - \frac{1}{n}\right)^{n\bar{x}}$$

pois $X_i \mid \bar{X} = \bar{x} \sim$ Binomial$(n\bar{x}, 1/n)$ para cada $i = 1, \ldots, n$.

Com certeza, não é nada óbvio, pela forma funcional, que esse estimador seja não viesado, muito menos UMVU. Assim, esse resultado pode ser visto como uma aplicação um tanto notável da teoria. ■

Lembre agora os Teoremas 6.5.2 e 6.5.3. As consequências desses resultados, com algumas condições adicionais, são que o EMV de θ é assintoticamente não viesado para θ e que a variância assintótica do EMV está na cota inferior da informação. Isso muitas vezes é interpretado como querendo dizer que, com amostras grandes, o EMV faz uso completo da informação sobre θ contida nos dados.

Resumo da Seção 8.1

- Em média, é da sua própria média que um estimador fica mais perto (usando a distância quadrática) (veja o Teorema 8.1.1); por isso, podemos restringir a atenção a estimadores não viesados das quantidades de interesse.
- O teorema de Rao–Blackwell diz que podemos restringir a atenção a funções de uma estatística suficiente ao procurar um estimador que minimize o MSE.

- Quando uma estatística suficiente é completa, qualquer função dessa estatística suficiente é UMVU para sua média.
- A cota inferior de Cramer–Rao dá uma cota inferior para a variância de um estimador não viesado e um método para obter um estimador cuja variância está nessa cota inferior, quando tal estimador existe.

Exercícios

8.1.1 Suponha que um modelo estatístico é dado pelas duas distribuições da tabela a seguir.

	$s=1$	$s=2$	$s=3$	$s=4$
$f_a(s)$	1/3	1/6	1/12	5/12
$f_b(s)$	1/2	1/4	1/6	1/12

Se $T : \{1,2,3,4\} \to \{1,2,3,4\}$ é definida por $T(1) = T(2) = 1$ e $T(s) = s$ nos demais casos, prove que T é uma estatística suficiente. Obtenha as distribuições condicionais de s dado $T(s)$ e mostre que elas não dependem de θ.

8.1.2 Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição com média μ e variância σ^2. Prove que $s^2 = (n-1)^{-1} \sum_{i=1}^{n} (x_i - \bar{x})^2$ é não viesado para σ^2.

8.1.3 Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição $N(\mu, \sigma_0^2)$, em que $\mu \in R^1$ é desconhecido e σ_0^2 é conhecido. Determine um estimador UMVU do segundo momento $\mu^2 + \sigma_0^2$.

8.1.4 Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição $N(\mu, \sigma_0^2)$, em que $\mu \in R^1$ é desconhecido e σ_0^2 é conhecido. Determine um estimador UMVU do primeiro quartil $\mu + \sigma_0 z_{0,25}$.

8.1.5 Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição $N(\mu, \sigma_0^2)$, em que $\mu \in R^1$ é desconhecido e σ_0^2 é conhecido. $2\bar{x} + 3$ é um estimador UMVU de alguma coisa? Se for, é UMVU para quê? Justifique sua resposta.

8.1.6 Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição Bernoulli(θ), em que $\theta \in [0,1]$ é desconhecido. Determine um estimador UMVU de θ (use o fato de que uma estatística suficiente minimal para esse modelo é completa).

8.1.7 Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição Gama(α_0, β), em que α_0 é conhecido e $\beta > 0$ é desconhecido. Usando o fato de

que $\bar{x}$ é uma estatística suficiente completa (veja o Desafio 8.1.27), determine um estimador UMVU de β^{-1}.

8.1.8 Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição $N(\mu_0, \sigma^2)$, em que μ_0 é conhecido e $\sigma^2 > 0$ é desconhecido. Mostre que $\sum_{i=1}^{n}(x_i - \mu_0)^2$ é uma estatística suficiente para esse problema. Usando o fato de que ela é completa, determine um estimador UMVU para σ^2.

8.1.9 Suponha que um modelo estatístico é formado por todas as distribuições contínuas em R^1. Com base numa amostra de tamanho n, determine um estimador UMVU de $P((-1, 1))$, em que P é a verdadeira medida de probabilidade. Justifique sua resposta.

8.1.10 Suponha que um modelo estatístico é formado por todas as distribuições contínuas em R^1 que têm segundo momento finito. Com base numa amostra de tamanho n, determine um estimador UMVU de μ^2, em que μ é a verdadeira média. Justifique sua resposta. (Sugestão: encontre um estimador não viesado para $n = 2$, Rao–Blackwellize esse estimador para uma amostra de tamanho n e, então, use o teorema de Lehmann–Scheffé.)

8.1.11 O estimador determinado no Exercício 8.1.10 também é não viesado para μ^2 quando o modelo estatístico é formado por todas as distribuições contínuas em R^1 que têm primeiro momento finito. Esse estimador continua sendo UMVU para μ^2?

Problemas

8.1.12 Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição Uniforme[29]$[0, \theta]$, em que $\theta > 0$ é desconhecido. Mostre que $x_{(n)}$ é uma estatística suficiente e determine sua distribuição. Usando o fato de que $x_{(n)}$ é completa, determine um estimador UMVU de θ.

8.1.13 Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição Bernoulli(θ), em que $\theta \in [0, 1]$ é desconhecido. Determine, então, a distribuição condicional[30] de $(x_1, \ldots, x_n)$ dado o valor da estatística suficiente $\bar{x}$.

8.1.14 Prove que $L(\theta, a) = (\theta - a)^2$ satisfaz

$$L(\theta, \alpha a_1 + (1 - \alpha)a_2) \leq \alpha L(\theta, a_1) + (1 - \alpha)L(\theta, a_2)$$

quando a varia num subintervalo de R^1. Use esse resultado junto com a desigualdade de Jensen[31] (Teorema 3.6.4) para provar o teorema de

No original: *uniform distribution*[29], *conditional distribution*[30], *Jensen's*[31].

Rao–Blackwell.

8.1.15 Prove que $L(\theta, a) = |\theta - a|$ satisfaz

$$L(\theta, \alpha a_1 + (1-\alpha)a_2) \leq \alpha L(\theta, a_1) + (1-\alpha)L(\theta, a_2)$$

quando a varia num subintervalo de R^1. Use esse resultado junto com a desigualdade de Jensen (Teorema 3.6.4) para provar o teorema de Rao–Blackwell para o erro absoluto. (Sugestão: primeiro mostre que $|x+y| \leq |x| + |y|$ para quaisquer x e y.)

8.1.16 Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição $N(\mu, \sigma^2)$, em que $(\mu, \sigma^2) \in R^1 \times (0, \infty)$ é desconhecido. Mostre que o estimador ótimo (no sentido de minimizar o MSE) da forma cs^2 para σ^2 é dado por $c = (n-1)/(n+1)$. Determine o viés desse estimador e mostre que ele vai para 0 quando $n \to \infty$.

8.1.17 Prove que, se uma estatística T é completa para um modelo e $U = h(T)$ para uma função injetora h, então U também é completa.

8.1.18 Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição $N(\mu, \sigma^2)$, em que $(\mu, \sigma^2) \in R^1 \times (0, \infty)$ é desconhecido. Obtenha um estimador UMVU do desvio padrão[32] σ. (Sugestão: calcule o valor esperado[33] do desvio padrão[34] amostral s.)

8.1.19 Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição $N(\mu, \sigma^2)$, em que $(\mu, \sigma^2) \in R^1 \times (0, \infty)$ é desconhecido. Obtenha um estimador UMVU do primeiro quartil $\mu + \sigma z_{0,25}$. (Sugestão: Problema 8.1.17.)*

8.1.20 Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição $N(\mu, \sigma_0^2)$, em que $\theta \in \mathbf{\Omega} = \{\mu_1, \mu_2\}$ é desconhecido e $\sigma_0^2 > 0$ é conhecido. Estabeleça que $\bar{x}$ é uma estatística suficiente minimal para esse modelo, mas que não é completa.

8.1.21 Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição $N(\mu, \sigma_0^2)$, em que $\mu \in R^1$ é desconhecido e σ_0^2 é conhecido. Determine a cota inferior da informação, para um estimador não viesado, quando consideramos a estimação do segundo momento $\mu^2 + \sigma_0^2$. O estimador UMVU do Exercício 8.1.3 atinge a cota inferior da informação?

8.1.22 Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição Gama(α_0, β), em que α_0 é conhecido e $\beta > 0$ é desconhecido. Determine a cota

*__Nota do tradutor.__ Pelo conteúdo, a sugestão parece remeter ao Problema 8.1.18 (estimador UMVU de σ); o original traz 8.1.17.

No original: *standard deviation*[32], *expected value*[33], *standard deviation*[34].

inferior da informação para a estimação de β^{-1} por estimadores não viesados e determine se o estimador UMVU obtido no Exercício 8.1.7 a atinge.

8.1.23 Suponha que $(x_1, \ldots, x_n)$ é uma amostra da distribuição com densidade $f_\theta(x) = \theta x^{\theta-1}$ para $x \in [0,1]$, em que $\theta > 0$ é desconhecido. Determine a cota inferior da informação para a estimação de θ por estimadores não viesados. Existe um estimador UMVU com variância na cota inferior para esse problema?

8.1.24 Suponha que uma estatística T é uma estatística completa[35] baseada em algum modelo estatístico. Um submodelo é um modelo estatístico formado apenas por algumas das distribuições do modelo original. Por que T não é necessariamente completa para um submodelo?

8.1.25 Suponha que uma estatística T é uma estatística completa baseada em algum modelo estatístico. Se construímos um modelo maior que contém todas as distribuições do modelo original e é tal que qualquer conjunto com probabilidade 0 para toda distribuição do modelo original também tem probabilidade 0 para toda distribuição do modelo maior, prove que T também é completa para o modelo maior.

Desafios

8.1.26 Se X é uma variável aleatória[36] tal que $E(X)$ não existe ou é infinito, mostre que $E((X-c)^2) = \infty$ para qualquer constante c.

8.1.27 Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição Gama(α_0, β), em que α_0 é conhecido e $\beta > 0$ é desconhecido. Mostre que $\bar{x}$ é uma estatística suficiente minimal completa.

8.2 Testes de Hipóteses Ótimos

Suponha que queiramos avaliar uma hipótese sobre a característica real $\psi(\theta)$ do modelo $\{f_\theta : \theta \in \mathbf{\Omega}\}$. Tipicamente, ela terá a forma $H_0 : \psi(\theta) = \psi_0$, em que especificamos um valor para ψ. Depois de observar os dados s, queremos avaliar se temos ou não evidência contra H_0.

Na Seção 6.3.3, discutimos métodos para avaliar uma hipótese desse tipo com base no EMV plug-in de $\psi(\theta)$. Eles envolviam calcular um valor-p como

No original: *complete statistic*[35], *random variable*[36].

medida de quão surpreendentes são os dados s quando se supõe que a hipótese nula[37] é verdadeira. Se s é surpreendente para cada uma das distribuições f_θ com $\psi(\theta) = \psi_0$, então temos evidência contra H_0. O desenvolvimento desses procedimentos se baseou em grande parte na justificativa intuitiva da função de verossimilhança.

8.2.1 A Função Poder de um Teste

Intimamente associado a um procedimento específico de cálculo de um valor-p está o conceito de *função poder*[38] $\beta(\theta)$, definido na Seção 6.3.6. Para isso, especificamos um *valor crítico* α tal que declaramos os resultados do teste estatisticamente significativos sempre que o valor-p for menor ou igual a α. O poder $\beta(\theta)$ é então a probabilidade de o valor-p ser menor ou igual a α quando amostramos de f_θ. Quanto maior o valor de $\beta(\theta)$, quando $\psi(\theta) \neq \psi_0$, melhor o procedimento detecta afastamentos de H_0. A função poder é, portanto, uma medida da sensibilidade do procedimento de teste para detectar afastamentos de H_0.

Lembre-se do seguinte exemplo fundamental.

Exemplo 8.2.1 — Modelo Normal de Locação

Suponha que temos uma amostra $(x_1, \dots, x_n)$ do modelo $N(\mu, \sigma_0^2)$, em que $\mu \in R^1$ é desconhecido e $\sigma_0^2 > 0$ é conhecido, e queremos avaliar a hipótese nula $H_0 : \mu = \mu_0$. No Exemplo 6.3.9, mostramos que um teste sensato para esse problema se baseia na estatística z

$$z = \frac{\bar{x} - \mu_0}{\sigma_0/\sqrt{n}},$$

com $Z \sim N(0,1)$ sob H_0. O valor-p é então dado por

$$P_{\mu_0}\left(|Z| \geq \left|\frac{\bar{x} - \mu_0}{\sigma_0/\sqrt{n}}\right|\right) = 2\left[1 - \Phi\left(\left|\frac{\bar{x} - \mu_0}{\sigma_0/\sqrt{n}}\right|\right)\right],$$

em que Φ denota a função de distribuição $N(0,1)$.

No Exemplo 6.3.18, mostramos que, para o valor crítico α, a função poder

No original: *null hypothesis*[37], *power function*[38].

do teste z é dada por

$$\begin{aligned}\beta(\mu) &= P_\mu\left(2\left[1-\Phi\left(\left|\frac{\bar{X}-\mu_0}{\sigma_0/\sqrt{n}}\right|\right)\right] < \alpha\right)\\ &= P_\mu\left(\Phi\left(\left|\frac{\bar{X}-\mu_0}{\sigma_0/\sqrt{n}}\right|\right) > 1-\frac{\alpha}{2}\right)\\ &= 1-\Phi\left(\frac{\mu_0-\mu}{\sigma_0/\sqrt{n}}+z_{1-(\alpha/2)}\right)+\Phi\left(\frac{\mu_0-\mu}{\sigma_0/\sqrt{n}}-z_{1-(\alpha/2)}\right)\end{aligned}$$

porque $\bar{X} \sim N(\mu, \sigma_0^2/n)$.

Vemos que especificar um valor para α especifica um conjunto de valores dos dados

$$R = \left\{(x_1, \ldots, x_n) : \Phi\left(\left|\frac{\bar{x}-\mu_0}{\sigma_0/\sqrt{n}}\right|\right) > 1-\frac{\alpha}{2}\right\}$$

tal que os resultados do teste são declarados estatisticamente significativos sempre que $(x_1, \ldots, x_n) \in R$. Usando o fato de que Φ é injetora e crescente, podemos também escrever R como

$$\begin{aligned}R &= \left\{(x_1, \ldots, x_n) : \left|\frac{\bar{x}-\mu_0}{\sigma_0/\sqrt{n}}\right| > \Phi^{-1}\left(1-\frac{\alpha}{2}\right)\right\}\\ &= \left\{(x_1, \ldots, x_n) : \left|\frac{\bar{x}-\mu_0}{\sigma_0/\sqrt{n}}\right| > z_{1-(\alpha/2)}\right\}.\end{aligned}$$

Além disso, a função poder é dada por $\beta(\mu) = P_\mu(R)$ e $\beta(\mu_0) = P_{\mu_0}(R) = \alpha$. ■

8.2.2 Erros Tipo I e Tipo II

Adotamos agora um ponto de vista diferente. Vamos procurar testes que sejam ótimos para testar a hipótese nula $H_0 : \psi(\theta) = \psi_0$. Primeiro, vamos supor que, tendo observado os dados s, decidiremos aceitar ou rejeitar H_0. Se rejeitarmos H_0, isso equivale a aceitar a alternativa $H_a : \psi(\theta) \neq \psi_0$. Nossa medida de desempenho para avaliar procedimentos de teste será então a probabilidade de o procedimento de teste cometer um erro.

Há dois tipos de erro. Podemos cometer um *erro tipo I*[39] — rejeitar H_0 quando ela é verdadeira — ou cometer um *erro tipo II*[40] — aceitar H_0 quando H_0 é falsa. Note que, se rejeitarmos H_0, isso implica que estamos aceitando a *hipótese alternativa* $H_a : \psi(\theta) \neq \psi_0$.

No original: *type I error*[39], *type II error*[40].

Acontece que, exceto em circunstâncias muito artificiais, não há procedimentos de teste que minimizem simultaneamente as probabilidades de cometer os dois tipos de erro. Por isso, vamos impor uma cota superior[41] α, chamada de *valor crítico*, à probabilidade de cometer um erro tipo I. Procuramos então, entre os testes cuja probabilidade de cometer um erro tipo I é menor ou igual a α, um procedimento de teste que minimize a probabilidade de cometer um erro tipo II.

Às vezes, os problemas de teste de hipóteses[42] para parâmetros reais são classificados como unilaterais ou bilaterais. Por exemplo, se θ é real, então $H_0 : \theta = \theta_0$ versus $H_a : \theta \neq \theta_0$ é um problema de teste bilateral[43], enquanto $H_0 : \theta \leq \theta_0$ versus $H_a : \theta > \theta_0$ ou $H_0 : \theta \geq \theta_0$ versus $H_a : \theta < \theta_0$ são exemplos de problemas unilaterais. Note, porém, que, se definirmos

$$\psi(\theta) = I_{(\theta_0,\infty)}(\theta),$$

então $H_0 : \theta \leq \theta_0$ versus $H_a : \theta > \theta_0$ é equivalente ao problema $H_0 : \psi(\theta) = 0$ versus $H_a : \psi(\theta) \neq 0$. Da mesma forma, se definirmos

$$\psi(\theta) = I_{(-\infty,\theta_0)}(\theta),$$

então $H_0 : \theta \geq \theta_0$ versus $H_a : \theta < \theta_0$ é equivalente ao problema $H_0 : \psi(\theta) = 0$ versus $H_a : \psi(\theta) \neq 0$. Assim, a formulação que adotamos para problemas de teste sobre um ψ geral inclui os problemas unilaterais como casos particulares.

8.2.3 Regiões de Rejeição e Funções de Teste

Uma maneira de especificar um procedimento de teste é escolher um subconjunto $R \subset S$ antes de observarmos s. Então *rejeitamos* H_0 sempre que $s \in R$ e aceitamos H_0 sempre que $s \notin R$. O conjunto R é chamado de *região de rejeição*[44]. Impor uma cota superior à probabilidade de rejeitar H_0 quando ela é verdadeira leva ao seguinte.

No original: *upper bound*[41], *hypothesis testing*[42], *two-sided*[43], *rejection region*[44].

Definição 8.2.1

Uma região de rejeição R que satisfaz

$$P_\theta(R) \leq \alpha \tag{8.2.1}$$

sempre que $\psi(\theta) = \psi_0$ é chamada de *região de rejeição de tamanho* α para H_0.

Assim, (8.2.1) expressa a cota para a probabilidade de cometer um erro tipo I.

Entre todas as regiões de rejeição R de tamanho α, queremos encontrar aquela (se existir) que minimiza a probabilidade de cometer um erro tipo II. Isso equivale a encontrar a região de rejeição R de tamanho α que maximiza a probabilidade de rejeitar a hipótese nula quando ela é falsa. Essa probabilidade pode ser expressa em termos da função poder de R e é dada por $\beta(\theta) = P_\theta(R)$ sempre que $\psi(\theta) \neq \psi_0$.

Para especificar por completo a abordagem de otimalidade para testes de hipóteses, precisamos de mais um ingrediente. Observe que nossa busca por uma região de rejeição R ótima de tamanho α equivale a encontrar a função indicadora[45] I_R que satisfaz $\beta(\theta) = E_\theta(I_R) = P_\theta(R) \leq \alpha$, quando $\psi(\theta) = \psi_0$, e maximiza $\beta(\theta) = E_\theta(I_R) = P_\theta(R)$, quando $\psi(\theta) \neq \psi_0$. Acontece que, em vários problemas, não existe tal região de rejeição.

Por outro lado, muitas vezes há solução para o problema mais geral de encontrar uma função $\varphi : S \to [0, 1]$ que satisfaça

$$\beta(\theta) = E_\theta(\varphi) \leq \alpha, \tag{8.2.2}$$

quando $\psi(\theta) = \psi_0$, e maximize

$$\beta(\theta) = E_\theta(\varphi),$$

quando $\psi(\theta) \neq \psi_0$. Temos a seguinte terminologia.

No original: *indicator function*[45].

Definição 8.2.2

Chamamos $\varphi : S \to [0,1]$ de *função de teste* e $\beta(\theta) = E_\theta(\varphi)$ de função poder associada à função de teste φ. Se φ satisfaz (8.2.2) quando $\psi(\theta) = \psi_0$, ela é chamada de *função de teste de tamanho* α. Se φ satisfaz $E_\theta(\varphi) = \alpha$ quando $\psi(\theta) = \psi_0$, ela é chamada de *função de teste de tamanho exato* α. Uma função de teste φ de tamanho α que maximiza $\beta(\theta) = E_\theta(\varphi)$ quando $\psi(\theta) \neq \psi_0$ é chamada de *função de teste uniformemente mais poderosa (UMP) de tamanho* α.

Note que $\varphi = I_R$ é uma função de teste[46] com função poder dada por $\beta(\theta) = E_\theta(I_R) = P_\theta(R)$.

Para dados observados s, interpretamos $\varphi(s) = 0$ como aceitar H_0 e $\varphi(s) = 1$ como rejeitar H_0. Em geral, interpretamos $\varphi(s)$ como a probabilidade condicional de rejeitarmos H_0 dados os dados s. Na prática, isso significa que, depois de observar s, geramos uma variável aleatória Bernoulli($\varphi(s)$). Se obtivermos 1, rejeitamos H_0; se obtivermos 0, aceitamos H_0. Portanto, pelo teorema da esperança total, $E_\theta(\varphi)$ é a probabilidade incondicional[47] de rejeitar H_0. A aleatorização que ocorre quando $0 < \varphi(s) < 1$ pode parecer um tanto contraintuitiva, mas ela nos é imposta pela busca por um teste UMP[48] de tamanho α, já que, em certos problemas, podemos aumentar o poder fazendo isso.

8.2.4 O Teorema de Neyman–Pearson

Para um problema de teste especificado por uma hipótese nula $H_0 : \psi(\theta) = \psi_0$ e um valor crítico α, queremos encontrar uma função de teste φ UMP de tamanho α. Note que uma função de teste φ_0 UMP de tamanho α para $H_0 : \psi(\theta) = \psi_0$ é caracterizada (denotando por β_φ a função poder de φ) por

$$\beta_{\varphi_0}(\theta) \leq \alpha,$$

quando $\psi(\theta) = \psi_0$, e por

$$\beta_{\varphi_0}(\theta) \geq \beta_\varphi(\theta),$$

quando $\psi(\theta) \neq \psi_0$, para qualquer outra função de teste φ de tamanho α.

Ainda assim, esse problema de otimização não tem solução em geral. Em certos problemas, porém, é possível encontrar uma solução ótima. O resultado a

No original: *test function*[46], *unconditional probability*[47], *UMP test*[48].

seguir dá um exemplo disso. Ele é fundamental para toda a teoria de testes de hipóteses ótimos.

Teorema 8.2.1 (Neyman–Pearson)

Suponha que $\mathbf{\Omega} = \{\theta_0, \theta_1\}$ e que queremos testar $H_0 : \theta = \theta_0$. Então existe uma função de teste φ_0 de tamanho exato α da forma

$$\varphi_0(s) = \begin{cases} 1 & f_{\theta_1}(s)/f_{\theta_0}(s) > c_0 \\ \gamma & f_{\theta_1}(s)/f_{\theta_0}(s) = c_0 \\ 0 & f_{\theta_1}(s)/f_{\theta_0}(s) < c_0 \end{cases} \tag{8.2.3}$$

para algum $\gamma \in [0, 1]$ e $c_0 \geq 0$. Esse teste é UMP de tamanho α.

Demonstração. Veja a Seção 8.5 para a demonstração deste resultado. ■

O resultado a seguir pode ser estabelecido por uma extensão simples da demonstração do teorema de Neyman–Pearson.

Corolário 8.2.1

Se φ é um teste UMP de tamanho α, então $\varphi(s) = \varphi_0(s)$ em toda parte, exceto possivelmente na *fronteira* $B = \{s : f_{\theta_1}(s)/f_{\theta_0}(s) = c_0\}$. Além disso, φ tem tamanho exato α, a menos que o poder de um teste UMP de tamanho α seja igual a 1.

Demonstração. Veja o Desafio 8.2.22.* ■

Note a natureza intuitiva do teste dado pelo teorema de Neyman–Pearson, pois (8.2.3) indica que rejeitamos categoricamente H_0 como verdadeira quando a razão de verossimilhança[49] de θ_1 contra θ_0 é maior que a constante c_0, e aceitamos H_0 quando ela é menor. Quando a razão de verossimilhança é igual a c_0, decidimos ao acaso rejeitar H_0 com probabilidade γ. Além disso, o Corolário 8.2.1 diz que um teste UMP de tamanho α é essencialmente único, embora possa haver diferentes estratégias de aleatorização na fronteira.

*Nota do tradutor. o original remete ao Desafio 8.2.22; o desafio que pede esta demonstração é o 8.2.23

No original: *likelihood ratio*[49].

A demonstração do teorema de Neyman–Pearson revela que c_0 é o menor número real tal que

$$P_{\theta_0}\left(\frac{f_{\theta_1}(s)}{f_{\theta_0}(s)} > c_0\right) \leq \alpha \tag{8.2.4}$$

e

$$\gamma = \begin{cases} \dfrac{\alpha - P_{\theta_0}\left(\frac{f_{\theta_1}(s)}{f_{\theta_0}(s)} > c_0\right)}{P_{\theta_0}\left(\frac{f_{\theta_1}(s)}{f_{\theta_0}(s)} = c_0\right)} & P_{\theta_0}\left(\frac{f_{\theta_1}(s)}{f_{\theta_0}(s)} = c_0\right) \neq 0 \\ 0 & \text{caso contrário.} \end{cases} \tag{8.2.5}$$

Usamos (8.2.4) e (8.2.5) para calcular c_0 e γ e, assim, determinar o teste UMP de tamanho α num problema particular.

Note que o teste é não aleatorizado sempre que $P_{\theta_0}(f_{\theta_1}(s)/f_{\theta_0}(s) > c_0) = \alpha$, pois então $\gamma = 0$, isto é, aceitamos ou rejeitamos H_0 categoricamente depois de ver os dados. Isso sempre ocorre quando a distribuição de $f_{\theta_1}(s)/f_{\theta_0}(s)$ é contínua quando $s \sim P_{\theta_0}$. Curiosamente, pode acontecer de a distribuição da razão não ser contínua mesmo quando a distribuição de s é contínua (ver Problema 8.2.17).

Antes de considerar algumas aplicações do teorema de Neyman–Pearson, estabelecemos o análogo do teorema de Rao–Blackwell para problemas de teste de hipóteses. Dado o valor da estatística suficiente $U(s) = u$, denotamos por $P(\cdot \mid U = u)$ a medida de probabilidade condicional da resposta s (pelo Teorema 8.1.2, essa medida de probabilidade não depende de θ). Para a função de teste φ, tomamos $\varphi_U(s)$ igual à esperança condicional de φ dado o valor de $U(s)$, isto é,

$$\varphi_U(s) = E_{P(\cdot|U=U(s))}(\varphi).$$

Teorema 8.2.2

Suponha que U é uma estatística suficiente e que φ é uma função de teste de tamanho α para $H_0 : \psi(\theta) = \psi_0$. Então φ_U é uma função de teste de tamanho α para $H_0 : \psi(\theta) = \psi_0$ que depende dos dados apenas por meio do valor de U. Além disso, φ e φ_U têm a mesma função poder.

Demonstração. É claro que $\varphi_U(s_1) = \varphi_U(s_2)$ sempre que $U(s_1) = U(s_2)$ e, assim, φ_U depende dos dados apenas por meio do valor de U. Seja agora $P_{\theta,U}$ a medida de probabilidade marginal de U induzida por P_θ. Então, pelo teorema da esperança total, temos $E_\theta(\varphi) = E_{P_{\theta,U}}(E_{P(\cdot|U=u)}(\varphi)) = E_{P_{\theta,U}}(\varphi_U) = E_\theta(\varphi_U)$. Ora, $E_\theta(\varphi) \leq \alpha$ quando $\psi(\theta) = \psi_0$, o que implica que $E_\theta(\varphi_U) \leq \alpha$ quando $\psi(\theta) = \psi_0$, e $\beta(\theta) = E_\theta(\varphi) = E_\theta(\varphi_U)$ quando $\psi(\theta) \neq \psi_0$. ■

Esse resultado nos permite restringir a busca por um teste UMP de tamanho α às funções de teste que dependem dos dados apenas por meio do valor de uma estatística suficiente.

Consideramos agora algumas aplicações do teorema de Neyman–Pearson. O exemplo a seguir mostra que esse resultado pode levar a soluções de problemas muito mais gerais do que o caso simples tratado.

Exemplo 8.2.2 — Testes de Hipóteses Ótimos no Modelo Normal de Locação

Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição $N(\mu, \sigma_0^2)$, em que $\mu \in \mathbf{\Omega} = \{\mu_0, \mu_1\}$ e $\sigma_0^2 > 0$ é conhecido, e queremos testar $H_0 : \mu = \mu_0$ versus $H_a : \mu = \mu_1$. A função de verossimilhança é dada por

$$L(\mu \mid x_1, \ldots, x_n) = \exp\left(-\frac{n}{2\sigma_0^2}(\bar{x} - \mu)^2\right),$$

e $\bar{x}$ é uma estatística suficiente para esse modelo restrito.

Pelo Teorema 8.2.2, podemos restringir nossa atenção às funções de teste que dependem dos dados por meio de $\bar{x}$. Ora, $\bar{X} \sim N(\mu, \sigma_0^2/n)$, de modo que

$$\begin{aligned}
\frac{f_{\mu_1}(\bar{x})}{f_{\mu_0}(\bar{x})} &= \frac{\exp\left(-\frac{n}{2\sigma_0^2}(\bar{x} - \mu_1)^2\right)}{\exp\left(-\frac{n}{2\sigma_0^2}(\bar{x} - \mu_0)^2\right)} \\
&= \exp\left(-\frac{n}{2\sigma_0^2}\left(\bar{x}^2 - 2\bar{x}\mu_1 + \mu_1^2 - \bar{x}^2 + 2\bar{x}\mu_0 - \mu_0^2\right)\right) \\
&= \exp\left(\frac{n}{\sigma_0^2}(\mu_1 - \mu_0)\bar{x}\right)\exp\left(-\frac{n}{2\sigma_0^2}\left(\mu_1^2 - \mu_0^2\right)\right).
\end{aligned}$$

Portanto,

$$\begin{aligned}
&P_{\mu_0}\left(\frac{f_{\mu_1}(\bar{X})}{f_{\mu_0}(\bar{X})} > c_0\right) \\
&= P_{\mu_0}\left(\exp\left(\frac{n}{\sigma_0^2}(\mu_1 - \mu_0)\bar{X}\right)\exp\left(-\frac{n}{2\sigma_0^2}\left(\mu_1^2 - \mu_0^2\right)\right) > c_0\right) \\
&= P_{\mu_0}\left(\exp\left(\frac{n}{\sigma_0^2}(\mu_1 - \mu_0)\bar{X}\right) > c_0 \exp\left(\frac{n}{2\sigma_0^2}\left(\mu_1^2 - \mu_0^2\right)\right)\right) \\
&= P_{\mu_0}\left((\mu_1 - \mu_0)\bar{X} > \frac{\sigma_0^2}{n}\ln\left\{c_0 \exp\left(\frac{n}{2\sigma_0^2}\left(\mu_1^2 - \mu_0^2\right)\right)\right\}\right) \\
&= \begin{cases} P_{\mu_0}\left(\dfrac{\bar{X} - \mu_0}{\sigma_0/\sqrt{n}} > c_0'\right) & \mu_1 > \mu_0 \\ P_{\mu_0}\left(\dfrac{\bar{X} - \mu_0}{\sigma_0/\sqrt{n}} < c_0'\right) & \mu_1 < \mu_0, \end{cases}
\end{aligned}$$

em que

$$c_0' = \frac{\sqrt{n}}{\sigma_0}\left\{\frac{\sigma_0^2}{n(\mu_1-\mu_0)}\ln\left\{c_0\exp\left(\frac{n}{2\sigma_0^2}(\mu_1^2-\mu_0^2)\right)\right\}-\mu_0\right\}.$$

Usando (8.2.4), quando $\mu_1 > \mu_0$, escolhemos c_0 de modo que $c_0' = z_{1-\alpha}$; quando $\mu_1 < \mu_0$, escolhemos c_0 de modo que $c_0' = z_\alpha$. Essas escolhas implicam que

$$P_{\mu_0}\left(\frac{f_{\mu_1}(\bar{X})}{f_{\mu_0}(\bar{X})} > c_0\right) = \alpha$$

e, por (8.2.5), $\gamma = 0$.

Assim, o teste UMP de tamanho α é não aleatorizado. Quando $\mu_1 > \mu_0$, o teste é dado por

$$\varphi_0(\bar{x}) = \begin{cases} 1 & \bar{x} \geq \mu_0 + \frac{\sigma_0}{\sqrt{n}}z_{1-\alpha} \\ 0 & \bar{x} < \mu_0 + \frac{\sigma_0}{\sqrt{n}}z_{1-\alpha}. \end{cases} \tag{8.2.6}$$

Quando $\mu_1 < \mu_0$, o teste é dado por

$$\varphi_0^*(\bar{x}) = \begin{cases} 1 & \bar{x} \leq \mu_0 + \frac{\sigma_0}{\sqrt{n}}z_{\alpha} \\ 0 & \bar{x} > \mu_0 + \frac{\sigma_0}{\sqrt{n}}z_{\alpha}. \end{cases} \tag{8.2.7}$$

Note que a função de teste em (8.2.6) não depende de μ_1 de modo algum. A consequência é que essa função de teste é UMP de tamanho α para $H_0 : \mu = \mu_0$ versus $H_a : \mu = \mu_1$ para qualquer $\mu_1 > \mu_0$. Isso implica que φ_0 é UMP de tamanho α para $H_0 : \mu = \mu_0$ versus a alternativa $H_a : \mu > \mu_0$.

Além disso, temos

$$\begin{aligned}\beta_{\varphi_0}(\mu) &= P_\mu\left(\bar{X} \geq \mu_0 + \frac{\sigma_0}{\sqrt{n}}z_{1-\alpha}\right) = P_\mu\left(\frac{\bar{X}-\mu}{\sigma_0/\sqrt{n}} \geq \frac{\mu_0-\mu}{\sigma_0/\sqrt{n}} + z_{1-\alpha}\right) \\ &= 1 - \Phi\left(\frac{\mu_0-\mu}{\sigma_0/\sqrt{n}} + z_{1-\alpha}\right).\end{aligned}$$

Note que essa função é crescente em μ, o que implica que φ_0 é uma função de teste de tamanho α para $H_0 : \mu \leq \mu_0$ versus $H_a : \mu > \mu_0$. Observe que, se φ é uma função de teste de tamanho α para $H_0 : \mu \leq \mu_0$ versus $H_a : \mu > \mu_0$, então ela também é um teste de tamanho α para $H_0 : \mu = \mu_0$ versus $H_a : \mu > \mu_0$. Disso concluímos que φ_0 é UMP de tamanho α para $H_0 : \mu \leq \mu_0$ versus $H_a : \mu > \mu_0$. Da mesma forma (ver Problema 8.2.12), pode-se mostrar que φ_0^* em (8.2.7) é UMP de tamanho α para $H_0 : \mu \geq \mu_0$ versus $H_a : \mu < \mu_0$.

Podemos nos perguntar se existe um teste UMP de tamanho α para o problema bilateral $H_0 : \mu = \mu_0$ versus $H_a : \mu \neq \mu_0$. Suponha que φ é um teste UMP de tamanho α para esse problema. Então φ também tem tamanho α para $H_0 : \mu = \mu_0$ versus $H_a : \mu = \mu_1$ quando $\mu_1 > \mu_0$. Usando o Corolário 8.2.1 e os desenvolvimentos anteriores (que também mostram que não existe um teste da forma (8.2.3) com poder igual a 1 para esse problema), isso implica que $\varphi = \varphi_0$ (a fronteira B tem probabilidade 0 aqui). Mas φ também é UMP de tamanho α para $H_0 : \mu = \mu_0$ versus $H_a : \mu = \mu_1$ quando $\mu_1 < \mu_0$; assim, pelo mesmo raciocínio, $\varphi = \varphi_0^*$. Mas claramente $\varphi_0 \neq \varphi_0^*$, de modo que não existe teste UMP de tamanho α para o problema bilateral.

Intuitivamente, esperaríamos que o teste de tamanho α dado por

$$\varphi(\bar{x}) = \begin{cases} 1 & \left|\dfrac{\bar{x} - \mu_0}{\sigma_0/\sqrt{n}}\right| \geq z_{1-\alpha/2} \\ 0 & \left|\dfrac{\bar{x} - \mu_0}{\sigma_0/\sqrt{n}}\right| < z_{1-\alpha/2} \end{cases} \tag{8.2.8}$$

fosse um bom teste a usar, mas ele não é UMP de tamanho α. Acontece, porém, que o teste em (8.2.8) é UMP de tamanho α entre todos os testes que satisfazem $\beta_\varphi(\mu_0) \leq \alpha$ e $\beta_\varphi(\mu) \geq \alpha$ quando $\mu \neq \mu_0$. ■

O Exemplo 8.2.2 ilustrou um problema de teste de hipóteses para o qual não existe teste UMP de tamanho α. Às vezes, porém, exigindo que o teste tenha outra propriedade muito natural, podemos obter um teste ótimo.

Definição 8.2.3

Um teste φ que satisfaz $\beta_\varphi(\theta) \leq \alpha$, quando $\psi(\theta) = \psi_0$, e $\beta_\varphi(\theta) \geq \alpha$, quando $\psi(\theta) \neq \psi_0$, é chamado de *teste não viesado de tamanho* α para o problema de teste de hipóteses $H_0 : \psi(\theta) = \psi_0$.

Assim, (8.2.8) é um teste UMP não viesado de tamanho α. Um teste não viesado tem a propriedade de que a probabilidade de rejeitar a hipótese nula, quando ela é falsa, é sempre maior que a probabilidade de rejeitá-la quando ela é verdadeira. Essa parece uma propriedade muito razoável. Em particular, pode-se provar que todo teste UMP de tamanho α é sempre um teste não viesado de tamanho α (Problema 8.2.14). Não aprofundamos a teoria dos testes não viesados neste texto.

Consideramos agora um exemplo que mostra que não podemos dispensar o uso

de testes aleatorizados.

Exemplo 8.2.3 — Testes de Hipóteses Ótimos no Modelo Bernoulli(θ)

Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição Bernoulli(θ), em que $\theta \in \mathbf{\Omega} = \{\theta_0, \theta_1\}$, e queremos testar $H_0 : \theta = \theta_0$ versus $H_a : \theta = \theta_1$, em que $\theta_1 > \theta_0$. Então $n\bar{x}$ é uma estatística suficiente minimal e, pelo Teorema 8.2.2, podemos restringir nossa atenção às funções de teste que dependem dos dados apenas por meio de $n\bar{x}$.

Ora, $n\bar{X} \sim$ Binomial(n, θ), de modo que

$$\frac{f_{\theta_1}(n\bar{x})}{f_{\theta_0}(n\bar{x})} = \frac{\theta_1^{n\bar{x}}(1-\theta_1)^{n-n\bar{x}}}{\theta_0^{n\bar{x}}(1-\theta_0)^{n-n\bar{x}}} = \left(\frac{\theta_1}{\theta_0}\right)^{n\bar{x}} \left(\frac{1-\theta_1}{1-\theta_0}\right)^{n-n\bar{x}}.$$

Portanto,

$$\begin{aligned}
&P_{\theta_0}\left(\frac{f_{\theta_1}(n\bar{X})}{f_{\theta_0}(n\bar{X})} > c_0\right) \\
&= P_{\theta_0}\left(\left(\frac{\theta_1}{\theta_0}\right)^{n\bar{X}} \left(\frac{1-\theta_1}{1-\theta_0}\right)^{n-n\bar{X}} > c_0\right) \\
&= P_{\theta_0}\left(\left(\frac{\theta_1}{1-\theta_1}\,\frac{1-\theta_0}{\theta_0}\right)^{n\bar{X}} > c_0\left(\frac{1-\theta_1}{1-\theta_0}\right)^{-n}\right) \\
&= P_{\theta_0}\left(n\bar{X}\left[\ln\left(\frac{\theta_1}{1-\theta_1}\,\frac{1-\theta_0}{\theta_0}\right)\right] > \ln c_0\left(\frac{1-\theta_1}{1-\theta_0}\right)^{-n}\right) \\
&= P_{\theta_0}\left(n\bar{X} > \frac{\ln c_0\left(\frac{1-\theta_1}{1-\theta_0}\right)^{-n}}{\ln\left(\frac{\theta_1}{1-\theta_1}\,\frac{1-\theta_0}{\theta_0}\right)}\right) = P_{\theta_0}(n\bar{X} > c_0')
\end{aligned}$$

porque

$$\ln\left(\frac{\theta_1}{1-\theta_1}\,\frac{1-\theta_0}{\theta_0}\right) > 0,$$

já que $\theta/(1-\theta)$ é crescente em θ, o que implica $\theta_1/(1-\theta_1) > \theta_0/(1-\theta_0)$.

Agora, usando (8.2.4), escolhemos c_0 de modo que c_0' seja um inteiro que satisfaça

$$P_{\theta_0}(n\bar{X} > c_0') \le \alpha \quad \text{e} \quad P_{\theta_0}(n\bar{X} > c_0' - 1) > \alpha.$$

Como $n\bar{X} \sim$ Binomial(n, θ_0) é uma distribuição discreta, vemos que, em geral, não conseguiremos obter $P_{\theta_0}(n\bar{X} > c_0') = \alpha$ exatamente. Assim, usando (8.2.5),

$$\gamma = \frac{\alpha - P_{\theta_0}(n\bar{X} > c_0')}{P_{\theta_0}(n\bar{X} = c_0')}$$

não será igual a 0. Então

$$\varphi_0(n\bar{x}) = \begin{cases} 1 & n\bar{x} > c_0' \\ \gamma & n\bar{x} = c_0' \\ 0 & n\bar{x} < c_0' \end{cases}$$

é UMP de tamanho α para $H_0 : \theta = \theta_0$ versus $H_a : \theta = \theta_1$. Note que podemos usar um software estatístico (ou a Tabela D.6) da distribuição binomial para obter c_0'.

Por exemplo, suponha que $n = 6$ e $\theta_0 = 0{,}25$. A tabela a seguir dá os valores da função de distribuição Binomial$(6; 0{,}25)$ com três casas decimais.

x	0	1	2	3	4	5	6
$F(x)$	0,178	0,534	0,831	0,962	0,995	1,000	1,000

Portanto, se $\alpha = 0{,}05$, temos $c_0' = 3$ porque $P_{0,25}(n\bar{X} > 3) = 1 - 0{,}962 = 0{,}038$ e $P_{0,25}(n\bar{X} > 2) = 1 - 0{,}831 = 0{,}169$. Isso implica que*

$$\gamma = \frac{0{,}05 - (1 - 0{,}962)}{0{,}962} = 0{,}012.$$

Assim, com esse teste, rejeitamos $H_0 : \theta = \theta_0$ categoricamente se o número de sucessos for maior que 3, aceitamos $H_0 : \theta = \theta_0$ categoricamente quando o número de sucessos for menor que 3 e, quando o número de 1s for igual a 3, rejeitamos $H_0 : \theta = \theta_0$ ao acaso com probabilidade 0,012 (por exemplo, gere $U \sim$ Uniforme$[0, 1]$ e rejeite sempre que $U \leq 0{,}012$).

Note que o teste φ_0 não envolve θ_1, de modo que, de fato, ele é UMP de tamanho α para $H_0 : \theta = \theta_0$ versus $H_a : \theta > \theta_0$. Além disso, usando o Problema 8.2.18, temos

$$\begin{aligned} P_\theta(n\bar{X} > c_0') &= \sum_{k=c_0'+1}^{n} \binom{n}{k} \theta^k (1-\theta)^{n-k} \\ &= 1 - \frac{\Gamma(n+1)}{\Gamma(c_0'+1)\,\Gamma(n-c_0')} \int_\theta^1 u^{c_0'} (1-u)^{n-c_0'-1}\, du. \end{aligned}$$

Como

$$\int_\theta^1 u^{c_0'} (1-u)^{n-c_0'-1}\, du$$

é decrescente em θ, devemos ter que $P_\theta(n\bar{X} > c_0')$ é crescente em θ. Argumentando como no Exemplo 8.2.2, concluímos que φ_0 é UMP de tamanho α para $H_0 : \theta \leq \theta_0$ versus $H_a : \theta > \theta_0$.

Da mesma forma, obtemos um teste UMP de tamanho α para $H_0 : \theta \leq \theta_0$ versus $H_a : \theta > \theta_0$.* Como no Exemplo 8.2.2, não existe teste UMP de tamanho α para $H_0 : \theta = \theta_0$ versus $H_a : \theta \neq \theta_0$, mas existe um teste UMP não viesado de tamanho α para esse problema. ■

8.2.5 Testes da Razão de Verossimilhança (Avançado)

Nos exemplos considerados até aqui, o teorema de Neyman–Pearson levou a soluções de problemas em que H_0 ou H_a não são apenas valores únicos do parâmetro, embora o teorema tenha sido enunciado só para o caso de valor único. Observamos também, porém, que isso não vale em geral (por exemplo, os problemas bilaterais discutidos nos Exemplos 8.2.2 e 8.2.3).

O método dos *testes da razão de verossimilhança generalizada* para $H_0 : \psi(\theta) = \psi_0$ foi desenvolvido para tratar o caso geral. Ele é motivado pelo teorema de Neyman–Pearson, pois observe que, em (8.2.3),

$$\frac{f_{\theta_1}(s)}{f_{\theta_0}(s)} = \frac{L(\theta_1 \mid s)}{L(\theta_0 \mid s)}.$$

Portanto, (8.2.3) pode ser visto como baseado na razão entre a verossimilhança em θ_1 e a verossimilhança em θ_0, e rejeitamos $H_0 : \theta = \theta_0$ quando a verossimilhança dá muito mais suporte a θ_1 do que a θ_0. A quantidade de suporte adicional exigida para a rejeição é determinada por c_0. Quanto maior c_0, maior a verossimilhança $L(\theta_1 \mid s)$ precisa ser em relação a $L(\theta_0 \mid s)$ para que rejeitemos $H_0 : \theta = \theta_0$.

Denote o EMV global de θ por $\hat{\theta}(s)$ e o EMV quando $\theta \in H_0$ por $\hat{\theta}_{H_0}(s)$. Assim, temos

$$L(\theta \mid s) \leq L(\hat{\theta}_{H_0}(s) \mid s)$$

para todo θ tal que $\psi(\theta) = \psi_0$. O teste da razão de verossimilhança generalizada rejeita então H_0 quando

$$\frac{L(\hat{\theta}(s) \mid s)}{L(\hat{\theta}_{H_0}(s) \mid s)} \tag{8.2.9}$$

é grande, pois isso indica evidência contra a veracidade de H_0.

*Nota do tradutor. pela fórmula (8.2.5), o denominador seria $P_{0,25}(n\bar{X} = 3) = 0{,}962 - 0{,}831 = 0{,}131$, o que daria $\gamma \approx 0{,}092$; o original divide por 0,962

*Nota do tradutor. o original repete aqui as hipóteses da frase anterior; pelo contexto seria $H_0 : \theta \geq \theta_0$ versus $H_a : \theta < \theta_0$

Como determinamos quando (8.2.9) é grande o bastante para rejeitar? Denotando por s_0 os dados observados, fazemos isso calculando os valores-p

$$P_\theta\left(\frac{L(\hat{\theta}(s) \mid s)}{L(\hat{\theta}_{H_0}(s) \mid s)} > \frac{L(\hat{\theta}(s_0) \mid s_0)}{L(\hat{\theta}_{H_0}(s_0) \mid s_0)}\right) \tag{8.2.10}$$

quando $\theta \in H_0$. Valores pequenos de (8.2.10) são evidência contra H_0. É claro que, quando $\psi(\theta) = \psi_0$ para mais de um valor de θ, não fica claro qual valor de (8.2.10) usar. Pode-se mostrar, porém, que, sob condições como as discutidas na Seção 6.5, se s corresponde a uma amostra de n valores de uma distribuição, então

$$2 \ln \frac{L(\hat{\theta}(s) \mid s)}{L(\hat{\theta}_{H_0}(s) \mid s)} \xrightarrow{D} \chi^2(\dim \boldsymbol{\Omega} - \dim H_0)$$

quando $n \to \infty$, sempre que o verdadeiro valor de θ está em H_0. Aqui, $\dim \boldsymbol{\Omega}$ e $\dim H_0$ são as dimensões desses conjuntos. Isso nos leva a um teste que rejeita H_0 sempre que

$$2 \ln \frac{L(\hat{\theta}(s) \mid s)}{L(\hat{\theta}_{H_0}(s) \mid s)} \tag{8.2.11}$$

é maior que um determinado quantil da distribuição $\chi^2(\dim \boldsymbol{\Omega} - \dim H_0)$.

Por exemplo, suponha que, num modelo normal de locação e escala[50], estamos testando $H_0 : \mu = \mu_0$. Então $\boldsymbol{\Omega} = R^1 \times [0, \infty)$, $H_0 = \{\mu_0\} \times [0, \infty)$, $\dim \boldsymbol{\Omega} = 2$, $\dim H_0 = 1$ e, para um teste de tamanho 0,05, rejeitamos sempre que (8.2.11) for maior que $\chi^2_{0,95}(1)$. Note que, a rigor, os testes da razão de verossimilhança não são derivados de considerações de otimalidade. Não discutiremos mais os testes da razão de verossimilhança neste texto.

Resumo da Seção 8.2

- Ao procurar um procedimento ótimo de teste de hipóteses, impomos uma cota superior à probabilidade de cometer um erro tipo I (rejeitar H_0 quando ela é verdadeira) e procuramos um teste que minimize a probabilidade de cometer um erro tipo II (aceitar H_0 quando ela é falsa).
- O teorema de Neyman–Pearson prescreve um teste ótimo de tamanho α quando H_0 e H_a especificam, cada uma, um único valor para o parâmetro completo θ.
- Às vezes, o teorema de Neyman–Pearson leva a soluções de problemas de teste de hipóteses quando a hipótese nula ou a alternativa admitem mais de um valor possível para θ, mas, em geral, precisamos recorrer aos testes da razão de verossimilhança para esses problemas.

No original: *location-scale normal model*[50].

Exercícios

8.2.1 Suponha que um modelo estatístico seja dado pelas duas distribuições da tabela a seguir.

	$s=1$	$s=2$	$s=3$	$s=4$
$f_a(s)$	1/3	1/6	1/12	5/12
$f_b(s)$	1/2	1/4	1/6	1/12

Determine o teste UMP de tamanho 0,10 para testar $H_0 : \theta = a$ versus $H_a : \theta = b$. Qual é o poder desse teste? Repita com o tamanho igual a 0,05.

8.2.2 Suponha que, para o problema de teste de hipóteses do Exercício 8.2.1, um estatístico decida gerar $U \sim$ Uniforme$[0,1]$ e rejeitar H_0 sempre que $U \leq 0{,}05$. Mostre que esse teste tem tamanho 0,05. Explique por que essa não é uma boa escolha de teste e por que o teste obtido no Exercício 8.2.1 é melhor. Dê evidência numérica disso.

8.2.3 Suponha que um pesquisador sabe que um processo industrial produz uma variável resposta[51] que segue uma distribuição $N(1,2)$. Foram feitas algumas mudanças no processo industrial, e o pesquisador acredita que elas possam ter mudado a média da resposta (não a variância), aumentando seu valor. O pesquisador quer que a probabilidade de ocorrer um erro tipo I seja menor que 1%. Determine um procedimento de teste adequado para esse problema com base numa amostra de tamanho 10.

8.2.4 Suponha que você tenha uma amostra de tamanho 20 de uma distribuição $N(\mu,1)$. Você constrói um intervalo de confiança 0,975 para μ e o usa para testar $H_0 : \mu = 0$, rejeitando H_0 sempre que 0 não está no intervalo de confiança.

(a) Qual é o tamanho desse teste?

(b) Determine a função poder desse teste.

8.2.5 Suponha que você tenha uma amostra de tamanho $n = 1$ de uma distribuição Uniforme$[0,\theta]$, em que $\theta > 0$ é desconhecido. Você testa $H_0 : \theta \leq 1$ rejeitando H_0 sempre que o valor amostrado for maior que 1.

(a) Qual é o tamanho desse teste?

(b) Determine a função poder desse teste.

No original: *response variable*[51].

8.2.6 Suponha que você esteja testando uma hipótese nula $H_0 : \theta = 0$, em que $\theta \in R^1$. Você usa um procedimento de teste de tamanho 0,05 e aceita H_0. Você acha que tem uma amostra razoavelmente grande, mas, ao calcular o poder em $\pm 0{,}2$, obtém o valor 0,10, em que 0,2 representa a menor diferença em relação a 0 que tem importância prática. Você acredita que faz sentido concluir que a hipótese nula é verdadeira? Justifique sua conclusão.

8.2.7 Suponha que você queira testar a hipótese nula $H_0 : \mu = 0$ com base numa amostra de tamanho n de uma distribuição $N(\mu, 1)$, em que $\mu \in \{0, 2\}$. Quão grande n precisa ser para que o poder em $\mu = 2$ do teste ótimo de tamanho 0,05 seja igual a 0,99?

8.2.8 Suponha que temos à disposição dois procedimentos de teste diferentes num problema e que eles têm a mesma função poder. Explique por que, do ponto de vista da teoria de testes de hipóteses ótimos, não deveria nos importar qual teste é usado.

8.2.9 Suponha que você tenha um teste φ UMP de tamanho α para testar a hipótese $H_0 : \psi(\theta) = \psi_0$, em que ψ é real. Explique como o gráfico da função poder de outro teste de tamanho α que não seja UMP difere do gráfico da função poder de φ.

Exercícios computacionais

8.2.10 Suponha que você tenha uma moeda e queira testar a hipótese de que ela é honesta, isto é, quer testar $H_0 : \theta = 1/2$, em que θ é a probabilidade de obter cara num único lançamento. Você decide rejeitar H_0 usando a região de rejeição $R = \{0, 1, 7, 8\}$ com base em $n = 10$ lançamentos. Tabele a função poder desse procedimento para $\theta \in \{0, 1/8, 2/8, \ldots, 7/8, 1\}$.

8.2.11 No mesmo gráfico, trace as funções poder do teste z bilateral de $H_0 : \mu = 0$ para amostras de tamanhos $n = 1$, 4, 10, 20 e 100, com base em $\alpha = 0{,}05$.

(a) O que você observa nesses gráficos?

(b) Explique como esses gráficos mostram que esse teste é não viesado.

Problemas

8.2.12 Prove que φ_0^* em (8.2.7) é UMP de tamanho α para $H_0 : \mu \geq \mu_0$ versus $H_a : \mu < \mu_0$.

8.2.13 Prove que a função de teste $\varphi(s) = \alpha$ para todo $s \in S$ é uma função de teste de tamanho exato α. Qual é a interpretação dessa função de teste?

8.2.14 Usando a função de teste do Problema 8.2.13, mostre que um teste UMP de tamanho α é também um teste UMP não viesado de tamanho α.

8.2.15 Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição Gama(α_0, β), em que α_0 é conhecido e $\beta > 0$ é desconhecido. Determine o teste UMP de tamanho α para testar $H_0 : \beta = \beta_0$ versus $H_a : \beta = \beta_1$, em que $\beta_1 > \beta_0$. Esse teste é UMP de tamanho α para $H_0 : \beta \leq \beta_0$ versus $H_a : \beta > \beta_0$?

8.2.16 Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição $N(\mu_0, \sigma^2)$, em que μ_0 é conhecido e $\sigma^2 > 0$ é desconhecido. Determine o teste UMP de tamanho α para testar $H_0 : \sigma^2 = \sigma_0^2$ versus $H_a : \sigma^2 = \sigma_1^2$, em que $\sigma_0^2 < \sigma_1^2$. Esse teste é UMP de tamanho α para $H_0 : \sigma^2 \leq \sigma_0^2$ versus $H_a : \sigma^2 > \sigma_0^2$?

8.2.17 Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição Uniforme$[0, \theta]$, em que $\theta > 0$ é desconhecido. Determine o teste UMP de tamanho α para testar $H_0 : \theta = \theta_0$ versus $H_a : \theta = \theta_1$, em que $\theta_0 < \theta_1$. Essa função de teste é UMP de tamanho α para $H_0 : \theta \leq \theta_0$ versus $H_a : \theta > \theta_0$?

8.2.18 Suponha que F é a função de distribuição da distribuição Binomial(n, θ). Prove então que

$$F(x) = \frac{\Gamma(n+1)}{\Gamma(x+1)\Gamma(n-x)} \int_\theta^1 y^x (1-y)^{n-x-1}\, dy$$

para $x = 0, 1, \ldots, n-1$. Isso estabelece uma relação entre a distribuição de probabilidade binomial e a função beta[52]. (Sugestão: integração por partes[53].)

8.2.19 Suponha que F é a função de distribuição da distribuição Poisson(λ). Prove então que

$$F(x) = \frac{1}{x!} \int_\lambda^\infty y^x e^{-y}\, dy$$

para $x = 0, 1, \ldots$. Isso estabelece uma relação entre a distribuição de probabilidade de Poisson e a função gama[54]. (Sugestão: integração por partes.)

No original: *beta function*[52], *integration by parts*[53], *gamma function*[54].

8.2.20 Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição Poisson(λ), em que $\lambda > 0$ é desconhecido. Determine o teste UMP de tamanho α para $H_0 : \lambda = \lambda_0$ versus $H_a : \lambda = \lambda_1$, em que $\lambda_0 < \lambda_1$. Essa função de teste é UMP de tamanho α para $H_0 : \lambda \leq \lambda_0$ versus $H_a : \lambda > \lambda_0$? (Sugestão: você vai precisar do resultado do Problema 8.2.19.)

8.2.21 Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição $N(\mu, \sigma^2)$, em que $(\mu, \sigma^2) \in R^1 \times (0, \infty)$ é desconhecido. Obtenha a forma do teste da razão de verossimilhança de tamanho exato α para testar $H_0 : \mu = \mu_0$ versus $H_0 : \mu \neq \mu_0$.*

8.2.22 (*Intervalos de confiança ótimos*) Suponha que, para o modelo $\{f_\theta : \theta \in \mathbf{\Omega}\}$, temos uma função de teste φ_{ψ_0} UMP de tamanho α para $H_0 : \psi(\theta) = \psi_0$, para cada valor possível de ψ_0. Suponha, além disso, que cada φ_{ψ_0} só assume valores em $\{0, 1\}$, isto é, cada φ_{ψ_0} é uma função de teste não aleatorizada de tamanho α.

(a) Prove que

$$C(s) = \{\psi_0 : \varphi_{\psi_0}(s) = 0\}$$

satisfaz

$$P_\theta(\psi(\theta) \in C(s)) \geq 1 - \alpha$$

para todo $\theta \in \mathbf{\Omega}$. Conclua que $C(s)$ é um conjunto de confiança $1 - \alpha$ para $\psi(\theta)$.

(b) Se C^* é um conjunto de confiança $1 - \alpha$ para $\psi(\theta)$, prove que a função de teste definida por

$$\varphi^*_{\psi_0}(s) = \begin{cases} 1 & \psi_0 \notin C(s) \\ 0 & \psi_0 \in C(s) \end{cases}$$

tem tamanho α para $H_0 : \psi(\theta) = \psi_0$.†

(c) Suponha que, para cada valor ψ_0, a função de teste φ_{ψ_0} é UMP de tamanho α para testar $H_0 : \psi(\theta) = \psi_0$ versus $H_0 : \psi(\theta) \neq \psi_0$.‡ Prove então que

$$P_\theta(\psi(\theta^*) \in C(s)) \tag{8.2.12}$$

é minimizada, quando $\psi(\theta) \neq \psi_0$, entre todos os conjuntos de confiança $1 - \alpha$ para $\psi(\theta)$. A probabilidade (8.2.12) é a probabilidade de C conter o

*Nota do tradutor. o original traz H_0 também na segunda hipótese; pelo contexto seria $H_a : \mu \neq \mu_0$

†Nota do tradutor. o original define $\varphi^*_{\psi_0}$ com $C(s)$; pelo contexto seria $C^*(s)$

‡Nota do tradutor. o original traz H_0 também na segunda hipótese; pelo contexto seria $H_a : \psi(\theta) \neq \psi_0$

valor falso $\psi(\theta^*)$, e uma região de confiança[55] $1-\alpha$ que minimiza essa probabilidade quando $\psi(\theta) \neq \psi_0$ é chamada de *região de confiança* $1-\alpha$ *uniformemente mais acurada (UMA)* para $\psi(\theta)$.

Desafios

8.2.23 Prove o Corolário 8.2.1 no caso discreto.

8.3 Inferências Bayesianas Ótimas

Acrescentamos agora a medida de probabilidade a priori[56] Π com densidade π. Como veremos, isso completa a especificação de um problema de otimalidade, pois agora sempre há uma solução. As soluções de problemas de otimização bayesianos são conhecidas como *regras de Bayes*.

Na Seção 8.1, o problema de otimização irrestrito era encontrar o estimador T de $\psi(\theta)$ que minimiza $\text{MSE}_\theta(T) = E_\theta((T-\psi(\theta))^2)$, para cada $\theta \in \mathbf{\Omega}$. A versão bayesiana desse problema é minimizar

$$E_\Pi(\text{MSE}_\theta(T)) = E_\Pi(E_\theta((T-\psi(\theta))^2)). \tag{8.3.1}$$

Pelo teorema da esperança total (Teorema 3.5.2), (8.3.1) é o valor esperado do erro quadrático $(T(s)-\psi(\theta))^2$ sob a distribuição conjunta[57] de (θ, s) induzida pela distribuição condicional de s dado θ (o modelo amostral[58]) e pela distribuição marginal[59] de θ (a distribuição a priori de θ). De novo pelo teorema da esperança total, podemos escrever isso como

$$E_\Pi(\text{MSE}_\theta(T)) = E_M(E_{\Pi(\cdot\,|\,s)}((T-\psi(\theta))^2)), \tag{8.3.2}$$

em que $\Pi(\cdot\,|\,s)$ denota a medida de probabilidade a posteriori de θ, dados os dados s (a distribuição condicional de θ dado s), e M denota a medida de probabilidade preditiva a priori[60] de s (a distribuição marginal de s).

Temos o seguinte resultado.

No original: *confidence region*[55], *prior*[56], *joint distribution*[57], *sampling model*[58], *marginal distribution*[59], *prior predictive*[60].

Teorema 8.3.1

Quando (8.3.1) é finito, uma regra de Bayes é dada por

$$T(s) = E_{\Pi(\cdot\,|\,s)}(\psi(\theta)),$$

isto é, a esperança a posteriori de $\psi(\theta)$.

Demonstração. Primeiro, considere o erro quadrático esperado a posteriori

$$E_{\Pi(\cdot\,|\,s)}\Big((T'(s) - \psi(\theta))^2\Big)$$

de uma estimativa $T'(s)$. Pelo Teorema 8.1.1, ele é minimizado tomando $T'(s)$ igual a $T(s) = E_{\Pi(\cdot\,|\,s)}(\psi(\theta))$ (note que a quantidade "aleatória" aqui é θ).

Agora suponha que T' é um estimador qualquer de $\psi(\theta)$. Acabamos de mostrar que

$$0 \leq E_{\Pi(\cdot\,|\,s)}\Big((T(s) - \psi(\theta))^2\Big) \leq E_{\Pi(\cdot\,|\,s)}\Big((T'(s) - \psi(\theta))^2\Big)$$

e, portanto,

$$\begin{aligned} E_\Pi(\mathrm{MSE}_\theta(T)) &= E_M\Big(E_{\Pi(\cdot\,|\,s)}((T(s) - \psi(\theta))^2)\Big) \\ &\leq E_M\Big(E_{\Pi(\cdot\,|\,s)}((T'(s) - \psi(\theta))^2)\Big) = E_\Pi(\mathrm{MSE}_\theta(T')). \end{aligned}$$

Portanto, T minimiza (8.3.1) e é uma regra de Bayes. ■

Vemos, então, que, sob condições brandas, o problema de estimação bayesiano ótimo sempre tem solução, e não há necessidade de nos restringirmos a estimadores não viesados etc.

Para o problema de teste de hipóteses $H_0 : \psi(\theta) = \psi_0$, queremos encontrar a função de teste φ que minimiza a probabilidade a priori de cometer um erro (tipo I ou tipo II). Uma tal φ é uma regra de Bayes. Temos o seguinte resultado.

Teorema 8.3.2

Uma regra de Bayes para o problema de teste de hipóteses $H_0 : \psi(\theta) = \psi_0$ é dada por

$$\varphi_0(s) = \begin{cases} 1 & \Pi(\{\psi(\theta) = \psi_0\}\,|\,s) \leq \Pi(\{\psi(\theta) \neq \psi_0\}\,|\,s) \\ 0 & \text{caso contrário.} \end{cases}$$

Demonstração. Considere a função de teste φ e seja $I_{\{\psi(\theta)=\psi_0\}}(\theta)$ a função indicadora do conjunto $\{\theta : \psi(\theta) = \psi_0\}$ (assim, $I_{\{\psi(\theta)=\psi_0\}}(\theta) = 1$ quando

$\psi(\theta) = \psi_0$ e é igual a 0 caso contrário). Observe que $\varphi(s)$ é a probabilidade de rejeitar H_0, tendo observado s, o que é um erro quando $I_{\{\psi(\theta)=\psi_0\}}(\theta) = 1$; $1 - \varphi(s)$ é a probabilidade de aceitar H_0, tendo observado s, o que é um erro quando $I_{\{\psi(\theta)=\psi_0\}}(\theta) = 0$. Portanto, dados s e θ, a probabilidade de cometer um erro é

$$e(\theta, s) = \varphi(s) I_{\{\psi(\theta)=\psi_0\}}(\theta) + (1 - \varphi(s))\,(1 - I_{\{\psi(\theta)=\psi_0\}}(\theta)).$$

Pelo teorema da esperança total, a probabilidade a priori de cometer um erro (tomando a esperança de $e(\theta, s)$ sob a distribuição conjunta de (θ, s)) é

$$E_M\big(E_{\Pi(\cdot\,|\,s)}(e(\theta, s))\big). \tag{8.3.3}$$

Como na demonstração do Teorema 8.3.1, se conseguirmos encontrar φ que minimiza $E_{\Pi(\cdot\,|\,s)}(e(\theta, s))$ para cada s, então φ também minimiza (8.3.3) e é uma regra de Bayes.

Usando o Teorema 3.5.4 para tirar $\varphi(s)$ da esperança condicional, e o fato de que $E_{\Pi(\cdot\,|\,s)}(I_A(\theta)) = \Pi(A \,|\, s)$ para qualquer evento A, temos

$$E_{\Pi(\cdot\,|\,s)}(e(\theta, s)) = \varphi(s)\Pi(\{\psi(\theta) = \psi_0\} \,|\, s) + (1 - \varphi(s))\,(1 - \Pi(\{\psi(\theta) = \psi_0\} \,|\, s)).$$

Como $\varphi(s) \in [0, 1]$, temos

$$\begin{aligned}&\min\{\Pi(\{\psi(\theta) = \psi_0\} \,|\, s), 1 - \Pi(\{\psi(\theta) = \psi_0\} \,|\, s)\}\\ &\quad \le \varphi(s)\Pi(\{\psi(\theta) = \psi_0\} \,|\, s) + (1 - \varphi(s))\,(1 - \Pi(\{\psi(\theta) = \psi_0\} \,|\, s)).\end{aligned}$$

Portanto, o valor mínimo de $E_{\Pi(\cdot\,|\,s)}(e(\theta, s))$ é atingido por $\varphi(s) = \varphi_0(s)$. ■

Observe que o Teorema 8.3.2 diz que a regra de Bayes rejeita H_0 sempre que a probabilidade a posteriori da hipótese nula é menor ou igual à probabilidade a posteriori da alternativa. Esse é um resultado intuitivamente satisfatório.

Surge, porém, o seguinte problema com essa abordagem. Temos

$$\begin{aligned}\Pi(\{\psi(\theta) = \psi_0\} \,|\, s) &= \frac{E_\Pi(I_{\{\theta:\psi(\theta)=\psi_0\}}(\theta) f_\theta(s))}{m(s)}\\ &\le \frac{\max_{\{\theta:\psi(\theta)=\psi_0\}} f_\theta(s)\,\Pi(\{\psi(\theta) = \psi_0\})}{m(s)}.\end{aligned} \tag{8.3.4}$$

Quando $\Pi(\{\psi(\theta) = \psi_0\}) = 0$, (8.3.4) implica que $\Pi(\{\psi(\theta) = \psi_0\} \,|\, s = 0)$ para todo s.* Portanto, usando a regra de Bayes, sempre rejeitaríamos H_0, quaisquer que fossem os dados s obtidos, o que não parece sensato. Como discutido na Seção 7.2.3, temos de tomar o cuidado de usar uma priori Π que atribua massa positiva a H_0 se formos usar a abordagem bayesiana ótima num problema de teste de hipóteses.

*Nota do tradutor. O original traz "$\Pi(\{\psi(\theta) = \psi_0\} \,|\, s = 0)$"; pelo sentido, seria $\Pi(\{\psi(\theta) = \psi_0\} \,|\, s) = 0$.

Resumo da Seção 8.3

- Os procedimentos bayesianos ótimos são obtidos minimizando a medida de desempenho esperada calculada com a distribuição a posteriori.
- Em problemas de estimação, quando se usa o erro quadrático como medida de desempenho, a média a posteriori é ótima.
- Em problemas de teste de hipóteses, quando a medida de desempenho a minimizar é a probabilidade de cometer um erro, é ótimo calcular a probabilidade a posteriori da hipótese nula e aceitar H_0 quando ela for maior que 1/2.

Exercícios

8.3.1 Suponha que $S = \{1, 2, 3\}$, $\mathbf{\Omega} = \{1, 2\}$, com as distribuições dos dados dadas pela tabela a seguir. Colocamos uma priori uniforme em θ e queremos estimar θ.

	$s = 1$	$s = 2$	$s = 3$
$f_1(s)$	1/6	1/6	2/3
$f_2(s)$	1/4	1/4	1/2

Usando uma regra de Bayes, teste a hipótese $H_0 : \theta = 2$ quando $s = 2$ é observado.

8.3.2 Para a situação descrita no Exercício 8.3.1, determine o estimador regra de Bayes de θ quando se usa o erro quadrático esperado como medida de desempenho dos estimadores.

8.3.3 Suponha que temos uma amostra $(x_1, \ldots, x_n)$ de uma distribuição $N(\mu, \sigma_0^2)$, em que μ é desconhecido e σ_0^2 é conhecido, e que queremos estimar μ usando o erro quadrático esperado como medida de desempenho dos estimadores. Se usarmos a distribuição a priori $\mu \sim N(\mu, \tau_0^2)$, determine a regra de Bayes para esse problema.* Determine a regra de Bayes limite quando $\tau_0 \to \infty$.

8.3.4 Suponha que observamos uma amostra $(x_1, \ldots, x_n)$ de uma distribuição Bernoulli(θ), em que θ é completamente desconhecido, e que queremos estimar θ usando o erro quadrático esperado como medida de desempenho dos

*Nota do tradutor. O original traz a priori $N(\mu, \tau_0^2)$; pela notação dos Exercícios 8.3.7 e 8.3.11, seria $N(\mu_0, \tau_0^2)$.

estimadores. Se usarmos a distribuição a priori $\theta \sim \text{Beta}(\alpha, \beta)$, determine uma regra de Bayes para esse problema.

8.3.5 Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição $\text{Gama}(\alpha_0, \beta)$, em que α_0 é conhecido, e que $\beta \sim \text{Gama}(\tau_0, \upsilon_0)$, em que τ_0 e υ_0 são conhecidos. Se queremos estimar β usando o erro quadrático esperado como medida de desempenho dos estimadores, determine a regra de Bayes. Use a lei fraca (ou forte) dos grandes números para determinar para onde esse estimador converge quando $n \to \infty$.

8.3.6 Para a situação descrita no Exercício 8.3.5, determine a regra de Bayes para estimar β^{-1} quando se usa o erro quadrático esperado como medida de desempenho dos estimadores.

8.3.7 Suponha que temos uma amostra $(x_1, \ldots, x_n)$ de uma distribuição $N(\mu, \sigma_0^2)$, em que μ é desconhecido e σ_0^2 é conhecido, e que queremos encontrar o teste de $H_0 : \mu = \mu_0$ que minimiza a probabilidade a priori de cometer um erro (tipo I ou tipo II). Se usarmos a distribuição a priori $\mu \sim p_0 I_{\{\mu_0\}} + (1 - p_0) N(\mu_0, \tau_0^2)$, em que $p_0 \in (0, 1)$ é conhecido (isto é, a priori é uma mistura de uma distribuição degenerada[61] em μ_0 e de uma distribuição $N(\mu_0, \tau_0^2)$), determine a regra de Bayes para esse problema. Determine a regra de Bayes limite quando $\tau_0 \to \infty$. (Sugestão: use as contas do Exemplo 7.2.13.)

8.3.8 Suponha que temos uma amostra $(x_1, \ldots, x_n)$ de uma distribuição Bernoulli(θ), em que θ é desconhecido, e que queremos encontrar o teste de $H_0 : \theta = \theta_0$ que minimiza a probabilidade a priori de cometer um erro (tipo I ou tipo II). Se usarmos a distribuição a priori $\theta \sim p_0 I_{\{\theta_0\}} + (1 - p_0)$ Uniforme$[0, 1]$, em que $p_0 \in (0, 1)$ é conhecido (isto é, a priori é uma mistura de uma distribuição degenerada em θ_0 e de uma distribuição uniforme), determine a regra de Bayes para esse problema.

Problemas

8.3.9 Suponha que $\mathbf{\Omega} = \{\theta_1, \theta_2\}$, que colocamos uma priori π em $\mathbf{\Omega}$ e que queremos estimar θ. Suponha que nossa medida de desempenho dos estimadores é a probabilidade de fazer uma escolha incorreta de θ. Se o modelo é denotado por $\{f_\theta : \theta \in \mathbf{\Omega}\}$, obtenha a forma da regra de Bayes quando os dados s são observados.

No original: *degenerate distribution*[61].

8.3.10 Para a situação descrita no Exercício 8.3.1, use a regra de Bayes obtida pelo método do Problema 8.3.9 para estimar θ quando $s = 2$. Que vantagem essa estimativa tem sobre a obtida no Exercício 8.3.2?

8.3.11 Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição $N(\mu, \sigma^2)$, em que $(\mu, \sigma^2) \in R^1 \times (0, \infty)$ é desconhecido, e que queremos estimar μ usando o erro quadrático esperado como medida de desempenho dos estimadores. Usando a distribuição a priori dada por

$$\mu \,|\, \sigma^2 \sim N(\mu_0, \tau_0^2 \sigma^2),$$

e usando

$$\frac{1}{\sigma^2} \sim \text{Gama}(\alpha_0, \beta_0),$$

em que μ_0, τ_0^2, α_0 e β_0 são fixos e conhecidos, determine a regra de Bayes para μ.

8.3.12 (*Seleção de modelos*) Generalize o Problema 8.3.9 para o caso $\mathbf{\Omega} = \{\theta_1, \ldots, \theta_k\}$.

Desafios

8.3.13 Na Seção 7.2.4, descrevemos o problema de predição[62] bayesiano. Usando a notação de lá, suponha que queremos predizer $t \in R^1$ usando um preditor[63] $\tilde{T}(s)$. Se avaliamos a precisão de um preditor por

$$E((\tilde{T}(s) - t)^2) = E_\Pi(E_{P_\theta}(E_{Q_\theta(\cdot\,|\,s)}((\tilde{T}(s) - t)^2))),$$

determine o preditor a priori que minimiza essa quantidade (suponha que todas as esperanças relevantes são finitas). Se observarmos s_0, determine o melhor preditor. (Sugestão: suponha que todas as medidas de probabilidade são discretas.)

8.4 Teoria da Decisão (Avançado)

Para determinar uma inferência ótima, escolhemos uma medida de desempenho e depois tentamos encontrar uma inferência, de um dado tipo, que tenha desempenho ótimo com relação a essa medida. Por exemplo,

No original: *prediction*[62], *predictor*[63].

ao considerar estimativas de uma característica de interesse $\psi(\theta)$ a valores reais, tomamos o MSE como medida de desempenho e depois procuramos o estimador que o minimiza para cada valor de θ.

A teoria da decisão está intimamente ligada à abordagem ótima para obter inferências, mas é um pouco mais especializada. No arcabouço da decisão, adotamos o ponto de vista de que, em qualquer problema estatístico, o estatístico se vê diante da tomada de uma decisão, por exemplo, decidir por um valor particular de $\psi(\theta)$. Além disso, associada a uma decisão está a noção de uma perda sofrida sempre que a decisão é incorreta. Uma regra de decisão é um procedimento, baseado nos dados observados s, que o estatístico usa para selecionar uma decisão. O problema de decisão consiste então em encontrar uma regra de decisão que minimize a perda média sofrida.

Há vários contextos do mundo real em que as perdas são uma parte evidente do problema, por exemplo, as perdas monetárias associadas aos diversos planos de seguro que uma seguradora pode considerar oferecer. Assim, a abordagem da teoria da decisão tem muitas aplicações. Fica claro em muitos problemas práticos, porém, que as perdas (assim como as medidas de desempenho) são componentes um tanto arbitrários de um problema estatístico, muitas vezes escolhidos simplesmente por conveniência. Nessas circunstâncias, as abordagens para obter inferências descritas nos Capítulos 6 e 7 são as preferidas de muitos estatísticos.

Assim, o *modelo da teoria da decisão* para a inferência acrescenta mais um ingrediente ao modelo amostral (ou ao modelo amostral e à priori) para obter inferências: a função de perda. Para formalizar isso, concebemos um conjunto de ações ou decisões possíveis que o estatístico poderia tomar depois de observar os dados s. Esse conjunto de ações possíveis é denotado por $\mathcal{A}$ e chamado de *espaço de ações*. Para ligar essas ações ao modelo estatístico, há uma *função de ação correta* $A : \mathbf{\Omega} \to \mathcal{A}$ tal que $A(\theta)$ é a ação correta a tomar quando θ é o verdadeiro valor do parâmetro. Naturalmente, como não conhecemos θ, não conhecemos a ação correta $A(\theta)$, de modo que há incerteza envolvida em nossa decisão. Considere um exemplo simples.

Exemplo 8.4.1

Suponha que lhe dizem que uma urna com 100 bolas tem ou 50 bolas brancas e 50 pretas, ou 60 brancas e 40 pretas. Cinco bolas são retiradas da urna sem reposição, e suas cores são observadas. A tarefa do estatístico é tomar uma decisão sobre a verdadeira proporção de bolas brancas na urna com base nesses dados.

O modelo estatístico consiste então em duas distribuições $\{P_1, P_2\}$, em que, usando o espaço paramétrico $\mathbf{\Omega} = \{1, 2\}$, P_1 é a distribuição Hipergeométrica$(100, 50, 5)$ (veja o Exemplo 2.3.7) e P_2 é a distribuição Hipergeométrica$(100, 60, 5)$. O espaço de ações é $\mathcal{A} = \{0{,}5; 0{,}6\}$, e $A : \mathbf{\Omega} \to \mathcal{A}$ é dada por $A(1) = 0{,}5$ e $A(2) = 0{,}6$. Os dados são as cores das cinco bolas retiradas. ■

Suponhamos agora que haja também uma perda ou penalidade $L(\theta, a)$ sofrida quando selecionamos a ação $a \in \mathcal{A}$ e θ é verdadeiro. Se selecionamos a ação correta, a perda é 0; caso contrário, ela é maior que 0.

Definição 8.4.1

Uma *função de perda* é uma função L definida em $\mathbf{\Omega} \times \mathcal{A}$ e que assume valores em $[0, \infty)$ tal que $L(\theta, a) = 0$ se e somente se $a = A(\theta)$.

Às vezes, a perda pode ser uma perda monetária real. Na verdade, a teoria da decisão é um pouco mais geral do que o que acabamos de descrever, pois podemos permitir perdas negativas (ganhos ou lucros), mas a restrição a perdas não negativas é adequada para aplicações puramente estatísticas.

Num problema específico, o estatístico escolhe uma função de perda que se acredita levar a procedimentos estatísticos razoáveis. Essa escolha depende da aplicação particular. Considere alguns exemplos.

Exemplo 8.4.2 — Continuação do Exemplo 8.4.1

Talvez uma escolha sensata neste problema seja

$$L(\theta, a) = \begin{cases} 1 & \theta = 1, a = 0{,}6 \\ 2 & \theta = 2, a = 0{,}5 \\ 0 & \text{caso contrário.} \end{cases}$$

Aqui decidimos que selecionar $a = 0{,}5$ quando isso não é correto é um erro mais grave do que selecionar $a = 0{,}6$ quando isso não é correto. Se quisermos tratar os erros de forma simétrica, podemos tomar

$$L(\theta, a) = I_{\{(1;0{,}6),(2;0{,}5)\}}(\theta, a),$$

isto é, as perdas são 1 ou 0. ■

Exemplo 8.4.3 — Estimação como Problema de Decisão

Suponha que temos um parâmetro marginal de interesse $\psi(\theta)$ e que queremos especificar uma estimativa $T(s)$ depois de observar $s \in S$. Aqui, o espaço de ações é $\mathcal{A} = \{\psi(\theta) : \theta \in \mathbf{\Omega}\}$ e $A(\theta) = \psi(\theta)$. Naturalmente, queremos $T(s) \in \mathcal{A}$.

Por exemplo, suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição $N(\mu, \sigma^2)$, em que $(\mu, \sigma^2) \in \mathbf{\Omega} = R^1 \times R^+$ é desconhecido, e que queremos estimar $\psi(\mu, \sigma^2) = \mu$. Nesse caso, $\mathcal{A} = R^1$, e um estimador possível é a média amostral $T(x_1, \ldots, x_n) = \bar{x}$.

Há muitas escolhas possíveis para a função de perda. Talvez uma escolha natural seja usar

$$L(\theta, a) = |\psi(\theta) - a|, \tag{8.4.1}$$

o desvio absoluto entre $\psi(\theta)$ e a. Como alternativa, é comum usar

$$L(\theta, a) = (\psi(\theta) - a)^2, \tag{8.4.2}$$

os desvios quadráticos entre $\psi(\theta)$ e a.

Chamamos (8.4.2) de *perda quadrática*. Note que (8.4.2) é simplesmente o quadrado da distância euclidiana entre $\psi(\theta)$ e a. Pode parecer mais natural usar de fato a distância (8.4.1) como função de perda. Acontece, porém, que há várias conveniências matemáticas que surgem do uso da distância ao quadrado. ■

Exemplo 8.4.4 — Teste de Hipóteses como Problema de Decisão

Neste problema, temos uma característica de interesse $\psi(\theta)$ e queremos avaliar quão plausível é o valor ψ_0 depois de ver os dados s. Num problema de teste de hipóteses, isso se escreve como $H_0 : \psi(\theta) = \psi_0$ versus $H_a : \psi(\theta) \neq \psi_0$. Como na Seção 8.2, chamamos H_0 de hipótese nula e H_a de hipótese alternativa.

O objetivo de um procedimento de teste de hipóteses é decidir qual das duas, H_0 ou H_a, é verdadeira com base nos dados observados s. Assim, neste problema, o espaço de ações é $\mathcal{A} = \{H_0, H_a\}$ e a função de ação correta é

$$A(\theta) = \begin{cases} H_0 & \psi(\theta) = \psi_0 \\ H_a & \psi(\theta) \neq \psi_0. \end{cases}$$

Uma maneira alternativa, e útil, de pensar nas duas hipóteses é como subconjuntos de $\mathbf{\Omega}$. Escrevemos $H_0 = \psi^{-1}\{\psi_0\}$ como o subconjunto de todos os valores de θ que tornam a hipótese nula verdadeira, e $H_a = H_0^c$ é o subconjunto de todos os valores de θ que tornam a hipótese nula falsa. Então, com base nos dados s, queremos decidir se o verdadeiro valor de θ está em H_0 ou se θ está em H_a. Se H_0 (ou H_a) é formada por um único ponto, ela é chamada de *hipótese simples* ou *hipótese pontual*; caso contrário, é chamada de *hipótese composta*.

Por exemplo, suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição $N(\mu, \sigma^2)$, em que $\theta = (\mu, \sigma^2) \in \mathbf{\Omega} = R^1 \times R^+$, $\psi(\theta) = \mu$, e que queremos testar a hipótese nula $H_0 : \mu = \mu_0$ versus a alternativa $H_a : \mu \neq \mu_0$. Então $H_0 = \{\mu_0\} \times R^+$ e $H_a = \{\mu_0\}^c \times R^+$. Para o mesmo modelo, seja

$$\psi(\theta) = I_{(-\infty, \mu_0] \times R^+}(\mu, \sigma^2),$$

isto é, ψ é a função indicadora do subconjunto $(-\infty, \mu_0] \times R^+$. Então testar $H_0 : \psi = 1$ versus a alternativa $H_a : \psi = 0$ equivale a testar que a média é menor ou igual a μ_0 versus a alternativa de que ela é maior que μ_0. Esse problema de teste de hipóteses unilateral costuma ser denotado por $H_0 : \mu \leq \mu_0$ versus $H_a : \mu > \mu_0$.

Há várias escolhas possíveis para a função de perda, mas a mais usada é da forma

$$L(\theta, a) = \begin{cases} 0 & \theta \in H_0, a = H_0 \text{ ou } \theta \in H_a, a = H_a \\ b & \theta \notin H_0, a = H_0 \\ c & \theta \notin H_a, a = H_a. \end{cases}$$

Se rejeitamos H_0 quando H_0 é verdadeira (um erro tipo I), sofremos uma perda de c; se aceitamos H_0 quando H_0 é falsa (um erro tipo II), sofremos uma perda de b. Quando $b = c$, podemos tomar $b = c = 1$ e obter a *função de perda 0–1*, de uso comum. ■

Um estatístico diante de um problema de decisão — isto é, um modelo, um espaço de ações, uma função de ação correta e uma função de perda — precisa agora escolher uma regra para selecionar um elemento do espaço de ações $\mathcal{A}$ quando os dados s são observados. Uma *função de decisão*[64] é um procedimento que especifica como uma ação deve ser selecionada no espaço de ações $\mathcal{A}$.

Definição 8.4.2

Uma *função de decisão não aleatorizada* d é uma função $d : S \to \mathcal{A}$.

Assim, depois de observar s, decidimos que a ação apropriada é $d(s)$.

Na verdade, vamos permitir que nossos procedimentos de decisão sejam um pouco mais gerais do que isso, pois admitimos uma escolha aleatória de uma ação depois de observar s.

Definição 8.4.3

Uma *função de decisão* δ é tal que $\delta(s, \cdot)$ é uma medida de probabilidade no espaço de ações $\mathcal{A}$ para cada $s \in S$ (assim, $\delta(s, A)$ é a probabilidade de que a ação tomada esteja em $A \subset \mathcal{A}$).

Operacionalmente, depois de observar s, um mecanismo aleatório com distribuição especificada por $\delta(s, \cdot)$ é usado para selecionar a ação no conjunto das ações possíveis. Note que, se $\delta(s, \cdot)$ é uma medida de probabilidade degenerada no ponto $d(s)$ (assim, $\delta(s, \{d(s)\}) = 1$) para cada s, então δ é equivalente à função de decisão não aleatorizada d, e reciprocamente (veja o Problema 8.4.8).

O uso de procedimentos de decisão aleatorizados pode parecer bastante pouco natural, mas, como veremos, às vezes eles são um ingrediente essencial da teoria da decisão. Em muitos problemas de estimação, o uso de procedimentos aleatorizados não traz vantagem alguma, mas não é esse o caso em problemas de teste de hipóteses. Denotamos por D o conjunto de todas as funções de decisão δ para o problema específico de interesse.

No original: *decision function*[64].

O problema de decisão consiste em escolher uma função de decisão $\delta \in D$. A δ selecionada será então usada para gerar decisões nas aplicações. Baseamos essa escolha no desempenho das diversas funções de decisão δ com relação à função de perda. Intuitivamente, queremos escolher δ de modo a tornar a perda a menor possível. Para uma δ particular, como $s \sim f_\theta$ e $a \sim \delta(s, \cdot)$, a perda $L(\theta, a)$ é uma quantidade aleatória. Portanto, em vez de minimizar perdas específicas, falamos em minimizar algum aspecto da distribuição das perdas para cada $\theta \in \mathbf{\Omega}$. Talvez uma escolha razoável seja minimizar a perda média. Assim, definimos a função de risco[65] associada a $\delta \in D$ como a perda média sofrida por δ. A função de risco tem papel central na determinação de uma função de decisão apropriada para um problema.

Definição 8.4.4

A *função de risco* associada à função de decisão δ é dada por

$$R_\delta(\theta) = E_\theta(E_{\delta(s,\cdot)}(L(\theta, a))). \tag{8.4.3}$$

Note que, para calcular a função de risco, primeiro calculamos a média de $L(\theta, a)$, com s fixo e $a \sim \delta(s, \cdot)$. Depois tomamos a média dessa média condicional com relação a $s \sim f$. Pelo teorema da esperança total, essa é a perda média. Quando $\delta(s, \cdot)$ é degenerada em $d(s)$ para cada s, (8.4.3) se simplifica (veja o Problema 8.4.8) para

$$R_\delta(\theta) = E_\theta(L(\theta, d(s))).$$

Considere os exemplos a seguir.

Exemplo 8.4.5

Suponha que $S = \{1, 2, 3\}$, $\mathbf{\Omega} = \{1, 2\}$ e que as distribuições são dadas pela tabela a seguir.

	$s = 1$	$s = 2$	$s = 3$
$f_1(s)$	1/3	1/3	1/3
$f_2(s)$	1/2	1/2	0

Suponha ainda que $\mathcal{A} = \mathbf{\Omega}$, $A(\theta) = \theta$, e que a função de perda é dada por $L(\theta, a) = 1$ quando $\theta \neq a$ e é 0 caso contrário.

Agora considere a função de decisão δ especificada pela tabela a seguir.

No original: *risk function*[65].

	$a=1$	$a=2$
$\delta(1,\{a\})$	1/4	3/4
$\delta(2,\{a\})$	1/4	3/4
$\delta(3,\{a\})$	1	0

Assim, quando observamos $s=1$, escolhemos aleatoriamente a ação $a=1$ com probabilidade 1/4 e a ação $a=2$ com probabilidade 3/4, e assim por diante. Note que essa função de decisão faz a coisa sensata e seleciona a decisão $a=1$ quando observamos $s=3$, já que nesse caso sabemos sem ambiguidade que $\theta=1$.

Temos

$$\begin{aligned}
E_{\delta(1,\cdot)}(L(\theta,a)) &= \frac{1}{4}L(\theta,1)+\frac{3}{4}L(\theta,2)\\
E_{\delta(2,\cdot)}(L(\theta,a)) &= \frac{1}{4}L(\theta,1)+\frac{3}{4}L(\theta,2)\\
E_{\delta(3,\cdot)}(L(\theta,a)) &= L(\theta,1),
\end{aligned}$$

de modo que a função de risco de δ é dada por

$$\begin{aligned}
R_\delta(1) &= E_1(E_{\delta(s,\cdot)}(L(1,a)))\\
&= \frac{1}{3}\Big(\frac{1}{4}L(1,1)+\frac{3}{4}L(1,2)\Big)+\frac{1}{3}\Big(\frac{1}{4}L(1,1)+\frac{3}{4}L(1,2)\Big)+\frac{1}{3}L(1,1)\\
&= \frac{3}{12}+\frac{3}{12}+0=\frac{1}{2}
\end{aligned}$$

e

$$\begin{aligned}
R_\delta(2) &= E_2(E_{\delta(s,\cdot)}(L(2,a)))\\
&= \frac{1}{2}\Big(\frac{1}{4}L(2,1)+\frac{3}{4}L(2,2)\Big)+\frac{1}{2}\Big(\frac{1}{4}L(2,1)+\frac{3}{4}L(2,2)\Big)+0L(2,1)\\
&= \frac{1}{8}+\frac{1}{8}+0=\frac{1}{4}.
\end{aligned}$$

■

Exemplo 8.4.6 — Estimação

Vamos restringir nossa atenção às funções de decisão não aleatorizadas e observar que elas também são chamadas de estimadores. A função de risco associada ao estimador T e à função de perda (8.4.1) é dada por

$$R_T(\theta) = E_\theta(|\psi(\theta) - T|)$$

e é chamada de *desvio absoluto médio* (MAD). A função de risco associada ao estimador T e à função de perda (8.4.2) é dada por

$$R_T(\theta) = E_\theta((\psi(\theta) - T)^2)$$

e é chamada de MSE.

Queremos escolher o estimador T que minimiza $R_T(\theta)$ para todo $\theta \in \mathbf{\Omega}$. Note que, quando se usa (8.4.2), esse problema de decisão é exatamente o mesmo problema de estimação ótima discutido na Seção 8.1. ■

Exemplo 8.4.7 — Teste de Hipóteses

Notamos que, para uma dada função de decisão δ para este problema e um valor s dos dados, a distribuição $\delta(s, \cdot)$ é caracterizada por $\varphi(s) = \delta(s, H_a)$, que é a probabilidade de rejeitar H_0 quando s foi observado. Isso porque a medida de probabilidade $\delta(s, \cdot)$ está concentrada em dois pontos, de modo que basta dar seu valor em um deles para especificá-la completamente. Chamamos φ de *função de teste* associada a δ e observamos que uma função de decisão para este problema também fica especificada por uma função de teste φ.

Temos imediatamente que

$$E_{\delta(s,\cdot)}(L(\theta, a)) = (1 - \varphi(s))\, L(\theta, H_0) + \varphi(s) L(\theta, H_a). \tag{8.4.4}$$

Portanto, quando se usa a função de perda 0–1,

$$\begin{aligned} R_\delta(\theta) &= E_\theta((1 - \varphi(s))\, L(\theta, H_0) + \varphi(s) L(\theta, H_a)) \\ &= L(\theta, H_0) + E_\theta(\varphi(s))\, (L(\theta, H_a) - L(\theta, H_0)) \\ &= \begin{cases} E_\theta(\varphi(s)) & \theta \in H_0 \\ 1 - E_\theta(\varphi(s)) & \theta \in H_a. \end{cases} \end{aligned}$$

Lembre que, na Seção 6.3.6, introduzimos a função poder associada a um procedimento de avaliação de hipóteses que rejeitava H_0 sempre que o

valor-p era menor que algum valor prescrito. A função poder, calculada em θ, é a probabilidade de que tal procedimento rejeite H_0 quando θ é o verdadeiro valor. Como $\varphi(s)$ é a probabilidade condicional, dado s, de que H_0 seja rejeitada, o teorema da esperança total implica que $E_\theta(\varphi(s))$ é igual à probabilidade incondicional de rejeitarmos H_0 quando θ é o verdadeiro valor. Assim, em geral, chamamos a função

$$\beta_\varphi(\theta) = E_\theta(\varphi(s))$$

de *função poder* do procedimento de decisão δ ou, de modo equivalente, de função poder da função de teste φ.

Portanto, minimizar a função de risco neste caso equivale a escolher φ de modo a minimizar $\beta_\varphi(\theta)$ para todo $\theta \in H_0$ e maximizar $\beta_\varphi(\theta)$ para todo $\theta \in H_a$. Desse modo, este problema de decisão é exatamente o mesmo problema de inferência ótima discutido na Seção 8.2. ■

Depois de escrevermos todos os ingredientes de um problema de decisão, fica claro que forma terá uma solução do problema. Em particular, qualquer função de decisão δ_0 que satisfaça

$$R_{\delta_0}(\theta) \leq R_\delta(\theta)$$

para todo $\theta \in \mathbf{\Omega}$ e $\delta \in D$ é uma *função de decisão ótima* e é uma solução. Se duas funções de decisão têm as mesmas funções de risco, então, do ponto de vista da teoria da decisão, elas são equivalentes. Assim, é concebível que haja mais de uma solução para um problema de decisão.

Na verdade, acontece que uma função de decisão ótima só existe em casos extremamente irrealistas, a saber, quando os dados sempre nos dizem categoricamente qual é a decisão correta (veja o Problema 8.4.9). Não precisamos realmente de inferência estatística em tais situações. Por exemplo, suponha que temos duas moedas: a moeda A tem duas caras e a moeda B tem duas coroas. Assim que observamos o resultado de um lançamento, sabemos exatamente qual moeda foi lançada, e não há necessidade de inferência estatística.

Ainda assim, podemos identificar algumas regras de decisão que não queremos usar. Por exemplo, se $\delta \in D$ é tal que existe $\delta_0 \in D$ satisfazendo $R_{\delta_0}(\theta) \leq R_\delta(\theta)$ para todo θ, e se há pelo menos um θ para o qual $R_{\delta_0}(\theta) < R_\delta(\theta)$, então naturalmente preferimos estritamente δ_0 a δ.

Definição 8.4.5

Uma função de decisão δ é dita *admissível* se não há δ_0 estritamente preferida a ela.

Uma consequência da teoria da decisão é que devemos usar somente funções de decisão admissíveis. Ainda assim, há muitas funções de decisão admissíveis e, tipicamente, nenhuma é ótima. Além disso, um procedimento que é apenas admissível[66] pode ser uma escolha muito ruim (veja o Desafio 8.4.11).

Há vários caminhos para sair desse impasse na teoria da decisão. Uma abordagem é usar *princípios de redução*. Com isso queremos dizer que procuramos uma função de decisão ótima em alguma subclasse $D_0 \subset D$ considerada apropriada. Procuramos então uma $\delta_0 \in D_0$ tal que $R_{\delta_0}(\theta) \leq R_\delta(\theta)$ para todo $\theta \in \mathbf{\Omega}$ e $\delta \in D_0$, isto é, procuramos uma função de decisão ótima em D_0. Considere o exemplo a seguir.

Exemplo 8.4.8 — Testes de Tamanho α para Teste de Hipóteses

Considere um problema de teste de hipóteses H_0 versus H_a. Lembre que, na Seção 8.2, restringimos a atenção às funções de teste φ que satisfazem $E_\theta(\varphi) \leq \alpha$ para todo $\theta \in H_0$. Uma tal φ é chamada de função de teste de tamanho α para este problema. Assim, neste caso, estamos nos restringindo à classe D_0 de todas as funções de decisão δ para este problema que correspondem a funções de teste de tamanho α.

Na Seção 8.2, mostramos que às vezes há uma $\delta \in D_0$ ótima. Por exemplo, quando H_0 e H_a são simples, o teorema de Neyman–Pearson (Teorema 8.2.1) fornece uma φ ótima; assim, δ, definida por $\delta(s, H_a) = \varphi(s)$, é ótima. Também mostramos na Seção 8.2, porém, que em geral não há função de teste φ de tamanho α ótima e, portanto, não há $\delta \in D_0$ ótima. Nesse caso, são necessários outros princípios de redução. ■

Outra abordagem para selecionar uma $\delta \in D$ se baseia em escolher uma característica particular, a valores reais, da função de risco de δ e ordenar as funções de decisão com base nela. Há várias possibilidades.

Uma delas é introduzir uma priori π no problema e então procurar o procedimento de decisão $\delta \in D$ que tem o menor risco a priori

$$r_\delta = E_\pi(R_\delta(\theta)).$$

No original: *admissible*[66].

Procuramos então uma regra cujo risco a priori seja igual a $\min_{\delta \in D} r_\delta$ (ou $\inf_{\delta \in D} r_\delta$). Essa abordagem é chamada de *teoria da decisão bayesiana*.

Definição 8.4.6

A quantidade r_δ é chamada de *risco a priori* de δ, $\min_{\delta \in D} r_\delta$ é chamado de *risco de Bayes*, e uma regra com risco a priori igual ao risco de Bayes é chamada de *regra de Bayes*.

Obtivemos regras de Bayes para vários problemas na Seção 8.3. Curiosamente, a teoria da decisão bayesiana sempre produz, na prática, uma resposta para um problema de decisão. Essa é uma propriedade muito desejável para qualquer teoria estatística.

Outra maneira de ordenar as funções de decisão usa o risco máximo (ou supremo). Assim, para uma função de decisão δ, calculamos

$$\max_{\theta \in \mathbf{\Omega}} R_\delta(\theta)$$

(ou $\sup_{\theta \in \mathbf{\Omega}} R_\delta(\theta)$) e então selecionamos uma $\delta \in D$ que minimiza essa quantidade. Uma tal δ tem o menor risco máximo, ou o menor pior comportamento.

Definição 8.4.7

Uma função de decisão δ_0 que satisfaz*

$$\max_{\theta \in \mathbf{\Omega}} R_{\delta_0}(\theta) = \min_{\delta \in D} \max_{\theta \in \mathbf{\Omega}} R_\delta(\theta) \tag{8.1}$$

é chamada de *função de decisão minimax*.

De novo, essa abordagem sempre produz, na prática, uma resposta para um problema de decisão (veja o Problema 8.4.10).

Há muito mais a dizer sobre a teoria da decisão do que esta breve introdução aos conceitos básicos. Muitos resultados gerais interessantes foram estabelecidos para a abordagem da teoria da decisão à inferência estatística.

*Nota do tradutor. A equação da Definição 8.4.7 é numerada (8.1) no original; pela sequência da seção, seria (8.4.5).

Resumo da Seção 8.4

- A abordagem da teoria da decisão à inferência estatística introduz um espaço de ações $\mathcal{A}$ e uma função de perda L.
- Uma função de decisão δ prescreve uma distribuição de probabilidade $\delta(s, \cdot)$ em $\mathcal{A}$. O estatístico gera uma decisão em $\mathcal{A}$ usando essa distribuição depois de observar s.
- O problema da teoria da decisão é selecionar δ; para isso, usa-se a função de risco $R_\delta(\theta)$. O valor $R_\delta(\theta)$ é a perda média sofrida ao usar a função de decisão δ, e o objetivo é minimizar o risco.
- Tipicamente, não existe função de decisão δ ótima. Assim, para selecionar uma δ, usam-se vários critérios de redução para reduzir a classe das funções de decisão possíveis, ou as funções de decisão são ordenadas por alguma característica a valores reais de suas funções de risco, por exemplo, o risco máximo ou o risco médio com relação a alguma priori.

Exercícios

8.4.1 Suponha que observamos uma amostra $(x_1, \dots, x_n)$ de uma distribuição Bernoulli(θ), em que θ é completamente desconhecido, e que queremos estimar θ usando perda quadrática. Escreva todos os ingredientes desse problema de decisão. Calcule a função de risco do estimador $T(x_1, \dots, x_n) = \bar{x}$. Faça o gráfico da função de risco quando $n = 10$.

8.4.2 Suponha que temos uma amostra $(x_1, \dots, x_n)$ de uma distribuição Poisson(λ), em que λ é completamente desconhecido, e que queremos estimar λ usando perda quadrática. Escreva todos os ingredientes desse problema de decisão. Considere o estimador $T(x_1, \dots, x_n) = \bar{x}$ e calcule sua função de risco. Faça o gráfico da função de risco quando $n = 25$.

8.4.3 Suponha que temos uma amostra $(x_1, \dots, x_n)$ de uma distribuição $N(\mu, \sigma_0^2)$, em que μ é desconhecido e σ_0^2 é conhecido, e que queremos estimar μ usando perda quadrática. Escreva todos os ingredientes desse problema de decisão. Considere o estimador $T(x_1, \dots, x_n) = \bar{x}$ e calcule sua função de risco. Faça o gráfico da função de risco quando $n = 25$, $\sigma_0^2 = 2$.

8.4.4 Suponha que observamos uma amostra $(x_1, \dots, x_n)$ de uma distribuição Bernoulli(θ), em que θ é completamente desconhecido, e que queremos testar a hipótese nula de que $\theta = 1/2$ versus a alternativa de que ele não é igual a essa

quantidade, e usamos perda 0–1. Escreva todos os ingredientes desse problema de decisão. Suponha que rejeitamos a hipótese nula sempre que observamos $n\bar{x} \in \{0, 1, n-1, n\}$. Determine a forma da função de teste e de sua função poder associada. Faça o gráfico da função poder quando $n = 10$.

8.4.5 Considere o problema de decisão com espaço amostral[67] $S = \{1, 2, 3, 4\}$, espaço paramétrico[68] $\mathbf{\Omega} = \{a, b\}$, com o parâmetro indexando as distribuições dadas na tabela a seguir.

	$s = 1$	$s = 2$	$s = 3$	$s = 4$
$f_a(s)$	1/4	1/4	0	1/2
$f_b(s)$	1/2	0	1/4	1/4

Suponha que o espaço de ações é $\mathcal{A} = \mathbf{\Omega}$, com $A(\theta) = \theta$, e que a função de perda é dada por $L(\theta, a) = 1$ quando $a \neq A(\theta)$ e é igual a 0 caso contrário.

(a) Calcule a função de risco da função de decisão determinística dada por $d(1) = d(2) = d(3) = a$ e $d(4) = b$.

(b) A d do item (a) é ótima?

Exercícios computacionais

8.4.6 Suponha que temos uma amostra $(x_1, \ldots, x_n)$ de uma distribuição Poisson(λ), em que λ é completamente desconhecido, e que queremos testar a hipótese de que $\lambda \leq \lambda_0$ versus a alternativa de que $\lambda > \lambda_0$, usando a função de perda 0–1. Escreva todos os ingredientes desse problema de decisão. Suponha que decidimos rejeitar a hipótese nula sempre que $n\bar{x} > \lfloor n\lambda_0 + 2\sqrt{n\lambda_0} \rfloor$ e rejeitar aleatoriamente a hipótese nula com probabilidade 1/2 quando $n\bar{x} = \lfloor n\lambda_0 + 2\sqrt{n\lambda_0} \rfloor$. Determine a forma da função de teste e de sua função poder associada. Faça o gráfico da função poder quando $\lambda_0 = 1$ e $n = 5$.

8.4.7 Suponha que temos uma amostra $(x_1, \ldots, x_n)$ de uma distribuição $N(\mu, \sigma_0^2)$, em que μ é desconhecido e σ_0^2 é conhecido, e que queremos testar a hipótese nula de que a resposta média é μ_0 versus a alternativa de que a resposta média não é igual a μ_0, usando a função de perda 0–1. Escreva todos os ingredientes desse problema de decisão. Suponha que decidimos rejeitar sempre que $\bar{x} \notin [\mu_0 - 2\sigma_0/\sqrt{n}, \mu_0 + 2\sigma_0/\sqrt{n}]$. Determine a forma da função de teste e de sua função poder associada. Faça o gráfico da função poder quando $\mu_0 = 0$, $\sigma_0 = 3$ e $n = 10$.

No original: *sample space*[67], *parameter space*[68].

Problemas

8.4.8 Prove que uma função de decisão δ que dá uma medida de probabilidade $\delta(s, \cdot)$ degenerada em $d(s)$ para cada $s \in S$ equivale a especificar uma função $d : S \to \mathcal{A}$, e reciprocamente. Para uma tal δ, prove que $R_\delta(\theta) = E_\theta(L(\theta, d(s)))$.

8.4.9 Suponha que temos um problema de decisão e que cada distribuição de probabilidade do modelo é discreta.

(a) Prove que δ é ótima em D se e somente se $\delta(s, \cdot)$ é degenerada em $A(\theta)$ para cada s para o qual $P_\theta(\{s\}) > 0$.

(b) Prove que, se existem $\theta_1, \theta_2 \in \mathbf{\Omega}$ tais que $A(\theta_1) \neq A(\theta_2)$, e P_{θ_1}, P_{θ_2} não estão concentradas em conjuntos disjuntos[69], então não há $\delta \in D$ ótima.

8.4.10 Se a função de decisão δ tem risco constante e é admissível, prove que δ é minimax.

Desafios

8.4.11 Suponha que temos um problema de decisão em que $\theta_0 \in \mathbf{\Omega}$ é tal que $P_{\theta_0}(C) = 0$ implica $P_\theta(C) = 0$ para todo $\theta \in \mathbf{\Omega}$. Suponha ainda que não há função de decisão ótima (veja o Problema 8.4.9). Prove então que a função de decisão não aleatorizada d dada por $d(s) \equiv A(\theta_0)$ é admissível. O que esse resultado lhe diz sobre o conceito de admissibilidade?

Tópicos para discussão

8.4.12 Comente a seguinte afirmação: uma exigência natural para qualquer teoria da inferência é que ela produza uma resposta para todo problema de inferência proposto. Discutimos até aqui alguma teoria que você acredite satisfazer isso?

8.4.13 A teoria da decisão produz uma decisão num problema dado. Ela nada diz sobre quão provável é que a decisão esteja errada. Alguns estatísticos argumentam que uma abordagem válida da inferência deve incluir alguma quantificação de nossa incerteza sobre qualquer afirmação que façamos sobre

No original: *disjoint*[69].

uma incógnita, pois só assim um destinatário pode julgar a confiabilidade da inferência. Comente isso.

8.5 Demonstrações Adicionais (Avançado)

Demonstração do Teorema 8.1.2

Queremos mostrar que uma estatística U é suficiente para um modelo se e somente se a distribuição condicional dos dados s dado $U = u$ é a mesma para todo $\theta \in \mathbf{\Omega}$.

Provamos isso no caso discreto, de modo que $f_\theta(s) = P_\theta(\{s\})$. O caso geral exige mais matemática, e o deixamos para um curso mais avançado.

Seja u tal que $P_\theta(U^{-1}\{u\}) > 0$, em que $U^{-1}\{u\} = \{s : U(s) = u\}$, de modo que $U^{-1}\{u\}$ é o conjunto dos valores de s tais que $U(s) = u$. Temos

$$P_\theta(s = s_1 \mid U = u) = \frac{P_\theta(s = s_1, U = u)}{P_\theta(U = u)}. \tag{8.5.1}$$

Sempre que $s_1 \notin U^{-1}\{u\}$,

$$P_\theta(s = s_1, U = u) = P_\theta(\{s_1\} \cap \{s : U(s) = u\}) = P_\theta(\varnothing) = 0,$$

independentemente de θ. Portanto, $P_\theta(s = s_1 \mid U = u) = 0$ independentemente de θ.

Suponhamos então que $s_1 \in U^{-1}\{u\}$. Então

$$P_\theta(s = s_1, U = u) = P_\theta(\{s_1\} \cap \{s : U(s) = u\}) = P_\theta(\{s_1\}) = f_\theta(s_1).$$

Se U é uma estatística suficiente, o teorema da fatoração[70] (Teorema 6.1.1) implica $f_\theta(s) = h(s)g_\theta(U(s))$ para alguma h e alguma g. Portanto, como

$$P_\theta(U = u) = \sum_{s \in U^{-1}\{u\}} f_\theta(s),$$

(8.5.1) é igual a

$$\frac{f_\theta(s_1)}{\sum_{s \in U^{-1}\{u\}} f_\theta(s)} = \frac{f_\theta(s_1)}{\sum_{s \in U^{-1}\{u\}} c(s, s_1) f_\theta(s_1)} = \frac{1}{\sum_{s \in U^{-1}\{u\}} c(s, s_1)},$$

No original: *factorization theorem*[70].

em que

$$\frac{f_\theta(s)}{f_\theta(s_1)} = \frac{h(s)}{h(s_1)} = c(s, s_1).$$

Concluímos que (8.5.1) não depende de θ.

Reciprocamente, se (8.5.1) não depende de θ, então, para $s_1, s_2 \in U^{-1}\{u\}$, temos

$$P_\theta(U = u) = \frac{P_\theta(s = s_2)}{P_\theta(s = s_2 \mid U = u)}.$$

Assim,

$$\begin{aligned} f_\theta(s_1) = P_\theta(s = s_1) &= P_\theta(s = s_1 \mid U = u) P_\theta(U = u) \\ &= P_\theta(s = s_1 \mid U = u) \frac{P_\theta(s = s_2)}{P_\theta(s = s_2 \mid U = u)} \\ &= \frac{P_\theta(s = s_1 \mid U = u)}{P_\theta(s = s_2 \mid U = u)} f_\theta(s_2) = c(s_1, s_2) f_\theta(s_2), \end{aligned}$$

em que

$$c(s_1, s_2) = \frac{P_\theta(s = s_1 \mid U = u)}{P_\theta(s = s_2 \mid U = u)}.$$

Pela definição de suficiência na Seção 6.1.1, isso estabelece a suficiência de U. ■

Estabelecendo a Completude de $\bar{x}$ no Exemplo 8.1.3

Suponha que $(x_1, \ldots, x_n)$ seja uma amostra de uma distribuição $N(\mu, \sigma_0^2)$, em que $\mu \in R^1$ é desconhecido e $\sigma_0^2 > 0$ é conhecido. No Exemplo 6.1.7, mostramos que $\bar{x}$ é uma estatística suficiente minimal.

Suponha que a função h seja tal que $E_\mu(h(\bar{x})) = 0$ para todo $\mu \in R^1$. Então, definindo

$$h^+(\bar{x}) = \max(0, h(\bar{x})) \quad \text{e} \quad h^-(\bar{x}) = \max(0, -h(\bar{x})),$$

temos $h(\bar{x}) = h^+(\bar{x}) - h^-(\bar{x})$. Portanto, tomando

$$c^+(\mu) = E_\mu(h^+(\bar{X})) \quad \text{e} \quad c^-(\mu) = E_\mu(h^-(\bar{X})),$$

devemos ter

$$E_\mu(h(\bar{X})) = E_\mu(h^+(\bar{X})) - E_\mu(h^-(\bar{X})) = c^+(\mu) - c^-(\mu) = 0,$$

e assim $c^+(\mu) = c^-(\mu)$. Como h^+ e h^- são funções não negativas, temos $c^+(\mu) \geq 0$ e $c^-(\mu) \geq 0$.

Se $c^+(\mu) = 0$, então $h^+(\bar{x}) = 0$ com probabilidade 1, pois uma função não negativa tem média 0 se e somente se é 0 com probabilidade 1 (ver Desafio

3.3.22). Então $h^-(\bar{x}) = 0$ com probabilidade 1 também, e concluímos que $h(\bar{x}) = 0$ com probabilidade 1.

Se $c^+(\mu_0) > 0$, então $h^+(\bar{x}) > 0$ para todo $\bar{x}$ num conjunto A com probabilidade positiva em relação à distribuição $N(\mu_0, \sigma_0^2/n)$ (caso contrário, $h^+(\bar{x}) = 0$ com probabilidade 1, o que implica, como acima, que $c^+(\mu_0) = 0$). Isso implica que $c^+(\mu) > 0$ para todo μ, porque toda distribuição $N(\mu, \sigma_0^2/n)$ também atribui probabilidade positiva a A (você pode pensar em A como um subintervalo de R^1).

Observe agora que

$$g^+(\bar{x}) = h^+(\bar{x}) \frac{1}{\sqrt{2\pi}\,\sigma_0} \exp(-n\bar{x}^2/2\sigma_0^2)$$

é não negativa e estritamente positiva em A.* Podemos escrever

$$\begin{aligned} c^+(\mu) = E_\mu(h^+(\bar{X})) &= \int_{-\infty}^{\infty} h^+(\bar{x}) \frac{1}{\sqrt{2\pi}\,\sigma_0} \exp\left(-n(\bar{x}-\mu)^2/2\sigma_0^2\right) d\bar{x} \\ &= \exp(-n\mu^2/2\sigma_0^2) \int_{-\infty}^{\infty} \exp(n\mu\bar{x}/\sigma_0^2) g^+(\bar{x})\, d\bar{x}. \end{aligned} \tag{8.5.2}$$

Tomar $\mu = 0$ estabelece que $0 < \int_{-\infty}^{\infty} g^+(\bar{x})\, d\bar{x} < \infty$, pois $0 < c^+(\mu) < \infty$ para todo μ. Portanto,

$$\frac{g^+(\bar{x})}{\int_{-\infty}^{\infty} g^+(\bar{x})\, d\bar{x}}$$

é uma densidade de probabilidade de uma distribuição concentrada em $A^+ = \{\bar{x} : h(\bar{x}) > 0\}$. Além disso, usando (8.5.2) e a definição de função geradora de momentos[71] da Seção 3.4,

$$\frac{c^+(\mu) \exp(n\mu^2/2\sigma_0^2)}{\int_{-\infty}^{\infty} g^+(\bar{x})\, d\bar{x}} \tag{8.5.3}$$

é a função geradora de momentos dessa distribuição avaliada em $n\mu/\sigma_0^2$.

Analogamente, definimos

$$g^-(\bar{x}) = h^-(\bar{x}) \frac{1}{\sqrt{2\pi}\,\sigma_0} \exp(-n\bar{x}^2/2\sigma_0^2),$$

*__Nota do tradutor.__ A densidade de $\bar{X} \sim N(\mu, \sigma_0^2/n)$ tem a constante $\sqrt{n}/(\sqrt{2\pi}\,\sigma_0)$; o original omite o fator $\sqrt{n}$ aqui e em g^+ e g^-. Uma constante positiva não altera o argumento.

No original: *moment-generating function*[71].

de modo que

$$\frac{g^-(\bar{x})}{\int_{-\infty}^{\infty} g^-(\bar{x})\,d\bar{x}}$$

é uma densidade de probabilidade de uma distribuição concentrada em $A^- = \{\bar{x} : h(\bar{x}) < 0\}$. Além disso,

$$\frac{c^-(\mu)\exp(n\mu^2/2\sigma_0^2)}{\int_{-\infty}^{\infty} g^-(\bar{x})\,d\bar{x}} \tag{8.5.4}$$

é a função geradora de momentos dessa distribuição avaliada em $n\mu/\sigma_0^2$.

Como $c^+(\mu) = c^-(\mu)$, temos (tomando $\mu = 0$)

$$\int_{-\infty}^{\infty} g^+(\bar{x})\,d\bar{x} = \int_{-\infty}^{\infty} g^-(\bar{x})\,d\bar{x}.$$

Isso implica que (8.5.3) é igual a (8.5.4) para todo μ, e assim as funções geradoras de momentos dessas duas distribuições são iguais em toda parte. Pelo Teorema 3.4.6, essas distribuições têm de ser iguais. Mas isso é impossível, já que a distribuição dada por g^+ está concentrada em A^+, enquanto a distribuição dada por g^- está concentrada em A^-, e $A^+ \cap A^- = \varnothing$. Assim, concluímos que não podemos ter $c^+(\mu) > 0$, e terminamos.

Demonstração do Teorema 8.2.1 (Teorema de Neyman–Pearson)

Queremos provar que, quando $\mathbf{\Omega} = \{\theta_0, \theta_1\}$ e queremos testar $H_0 : \theta = \theta_0$, existe uma função de teste φ_0 de tamanho exato α da forma

$$\varphi_0(s) = \begin{cases} 1 & f_{\theta_1}(s)/f_{\theta_0}(s) > c_0 \\ \gamma & f_{\theta_1}(s)/f_{\theta_0}(s) = c_0 \\ 0 & f_{\theta_1}(s)/f_{\theta_0}(s) < c_0 \end{cases} \tag{8.5.5}$$

para algum $\gamma \in [0, 1]$ e algum $c_0 \geq 0$, e que esse teste é UMP de tamanho α.

Desenvolvemos a demonstração deste resultado no caso discreto. A demonstração no contexto mais geral é semelhante.

Primeiro, observamos que $\{s : f_{\theta_0}(s) = f_{\theta_1}(s) = 0\}$ tem medida P_θ igual a 0 tanto para $\theta = \theta_0$ quanto para $\theta = \theta_1$. Assim, sem perda de generalidade, podemos retirar esse conjunto do espaço amostral e supor daqui em diante que $f_{\theta_0}(s)$ e $f_{\theta_1}(s)$ não podem ser 0 ao mesmo tempo. Portanto, a razão $f_{\theta_1}(s)/f_{\theta_0}(s)$ está sempre definida.

Suponha que $\alpha = 1$. Então, tomando $c = 0$ e $\gamma = 1$ em (8.5.5), vemos que $\varphi_0(s) \equiv 1$, e assim $E_{\theta_1}(\varphi_0) = 1$. Portanto, φ_0 é UMP de tamanho α, pois nenhum teste pode ter poder maior que 1.

Suponha que $\alpha = 0$. Tomando $c_0 = \infty$ e $\gamma = 1$ em (8.5.5), vemos que $\varphi_0(s) = 0$ se e somente se $f_{\theta_0}(s) > 0$ (se $f_{\theta_0}(s) = 0$, então $f_{\theta_1}(s)/f_{\theta_0}(s) = \infty$, e reciprocamente). Assim, φ_0 é a função indicadora do conjunto $A = \{s : f_{\theta_0}(s) = 0\}$ e, portanto, $E_{\theta_0}(\varphi_0) = 0$. Além disso, qualquer função de teste φ de tamanho 0 tem de ser 0 em A^c para ter $E_{\theta_0}(\varphi) = 0$. Em A, temos $0 \leq \varphi(s) \leq 1 = \varphi_0(s)$, e assim $E_{\theta_1}(\varphi) \leq E_{\theta_1}(\varphi_0)$. Portanto, φ_0 é UMP de tamanho α.

Suponha agora que $0 < \alpha < 1$. Considere a função de distribuição da razão de verossimilhança quando $\theta = \theta_0$, isto é,

$$1 - \alpha^*(c) = P_{\theta_0}(f_{\theta_1}(s)/f_{\theta_0}(s) \leq c).$$

Assim, $1 - \alpha^*(c)$ é uma função não decrescente de c, com $1 - \alpha^*(-\infty) = 0$ e $1 - \alpha^*(\infty) = 1$.

Seja c_0 o menor valor de c tal que $1 - \alpha \leq 1 - \alpha^*(c)$ (lembre que $1 - \alpha^*(c)$ é contínua à direita[72], por ser uma função de distribuição). Então temos $1 - \alpha^*(c_0 - 0) = 1 - \lim_{\varepsilon \searrow 0} \alpha^*(c_0 - \varepsilon) \leq 1 - \alpha \leq 1 - \alpha^*(c_0)$ e (usando o fato de que o salto de uma função de distribuição num ponto é igual à probabilidade do ponto)

$$\begin{aligned} P_{\theta_0}(f_{\theta_1}(s)/f_{\theta_0}(s) = c_0) &= (1 - \alpha^*(c_0)) - (1 - \alpha^*(c_0 - 0)) \\ &= \alpha^*(c_0 - 0) - \alpha^*(c_0). \end{aligned}$$

Usando esse valor de c_0 em (8.5.5), tome

$$\gamma = \begin{cases} \dfrac{\alpha - \alpha^*(c_0)}{\alpha^*(c_0 - 0) - \alpha^*(c_0)} & \alpha^*(c_0 - 0) \neq \alpha^*(c_0) \\ 0 & \text{caso contrário,} \end{cases}$$

e observe que $\gamma \in [0, 1]$. Então temos

$$\begin{aligned} E_{\theta_0}(\varphi_0) &= \gamma P_{\theta_0}(f_{\theta_1}(s)/f_{\theta_0}(s) = c_0) + P_{\theta_0}(f_{\theta_1}(s)/f_{\theta_0}(s) > c_0) \\ &= \alpha - \alpha^*(c_0) + \alpha^*(c_0) = \alpha, \end{aligned}$$

de modo que φ_0 tem tamanho exato α.

Suponha agora que φ seja outro teste de tamanho α e que $E_{\theta_1}(\varphi) \geq E_{\theta_1}(\varphi_0)$. Particionamos o espaço amostral como $S = S_0 \cup S_1 \cup S_2$, em que

$$\begin{aligned} S_0 &= \{s : \varphi_0(s) - \varphi(s) = 0\}, \\ S_1 &= \{s : \varphi_0(s) - \varphi(s) < 0\}, \\ S_2 &= \{s : \varphi_0(s) - \varphi(s) > 0\}. \end{aligned}$$

No original: *right continuous*[72].

Observe que

$$S_1 = \{s : \varphi_0(s) - \varphi(s) < 0, f_{\theta_1}(s)/f_{\theta_0}(s) \le c_0\}$$

porque $f_{\theta_1}(s)/f_{\theta_0}(s) > c_0$ implica $\varphi_0(s) = 1$, o que implica $\varphi_0(s) - \varphi(s) = 1 - \varphi(s) \ge 0$, já que $0 \le \varphi(s) \le 1$. Além disso,

$$S_2 = \{s : \varphi_0(s) - \varphi(s) > 0, f_{\theta_1}(s)/f_{\theta_0}(s) \ge c_0\}$$

porque $f_{\theta_1}(s)/f_{\theta_0}(s) < c_0$ implica $\varphi_0(s) = 0$, o que implica $\varphi_0(s) - \varphi(s) = -\varphi(s) \le 0$, já que $0 \le \varphi(s) \le 1$.

Portanto,

$$\begin{aligned} 0 &\ge E_{\theta_1}(\varphi_0) - E_{\theta_1}(\varphi) = E_{\theta_1}(\varphi_0 - \varphi) \\ &= E_{\theta_1}\big(I_{S_1}(s)(\varphi_0(s) - \varphi(s))\big) + E_{\theta_1}\big(I_{S_2}(s)(\varphi_0(s) - \varphi(s))\big). \end{aligned}$$

Observe agora que

$$\begin{aligned} E_{\theta_1}\big(I_{S_1}(s)(\varphi_0(s) - \varphi(s))\big) &= \sum_{s \in S_1} (\varphi_0(s) - \varphi(s)) f_{\theta_1}(s) \\ &\ge c_0 \sum_{s \in S_1} (\varphi_0(s) - \varphi(s)) f_{\theta_0}(s) = c_0 E_{\theta_0}\big(I_{S_1}(s)(\varphi_0(s) - \varphi(s))\big) \end{aligned}$$

porque $\varphi_0(s) - \varphi(s) < 0$ e $f_{\theta_1}(s)/f_{\theta_0}(s) \le c_0$ quando $s \in S_1$. Analogamente, temos

$$\begin{aligned} E_{\theta_1}\big(I_{S_2}(s)(\varphi_0(s) - \varphi(s))\big) &= \sum_{s \in S_2} (\varphi_0(s) - \varphi(s)) f_{\theta_1}(s) \\ &\ge c_0 \sum_{s \in S_2} (\varphi_0(s) - \varphi(s)) f_{\theta_0}(s) = c_0 E_{\theta_0}\big(I_{S_2}(s)(\varphi_0(s) - \varphi(s))\big) \end{aligned}$$

porque $\varphi_0(s) - \varphi(s) > 0$ e $f_{\theta_1}(s)/f_{\theta_0}(s) \ge c_0$ quando $s \in S_2$.

Combinando essas desigualdades, obtemos

$$\begin{aligned} 0 &\ge E_{\theta_1}(\varphi_0) - E_{\theta_1}(\varphi) \ge c_0 E_{\theta_0}(\varphi_0 - \varphi) \\ &= c_0\big(E_{\theta_0}(\varphi_0) - E_{\theta_0}(\varphi)\big) = c_0\big(\alpha - E_{\theta_0}(\varphi)\big) \ge 0 \end{aligned}$$

porque $E_{\theta_0}(\varphi) \le 0$.* Portanto, $E_{\theta_1}(\varphi_0) = E_{\theta_1}(\varphi)$, o que prova que φ_0 é UMP entre todos os testes de tamanho α. ■

*Nota do tradutor. O original traz $E_{\theta_0}(\varphi) \le 0$; como φ é um teste de tamanho α, seria $E_{\theta_0}(\varphi) \le \alpha$.

CAPÍTULO 9

Verificação de Modelos

ESBOÇO DO CAPÍTULO

Seção 1 Verificação do Modelo Amostral
Seção 2 Verificação de Conflito entre a Priori e Dados
Seção 3 O Problema das Verificações Múltiplas

Os métodos de inferência estatística desenvolvidos nos Capítulos 6 a 8 dependem todos de várias suposições. Por exemplo, no Capítulo 6 supusemos que os dados s foram gerados por uma distribuição do modelo estatístico $\{P_\theta : \theta \in \Omega\}$. No Capítulo 7, supusemos também que nossa incerteza sobre o verdadeiro valor do parâmetro θ do modelo podia ser descrita por uma distribuição de probabilidade a priori[1] Π. Assim, quaisquer inferências obtidas têm validade questionável se essas suposições não fizerem sentido numa aplicação particular.

De fato, toda metodologia estatística se baseia em suposições ou escolhas feitas pelo analista estatístico, e elas precisam ser verificadas se quisermos ter confiança de que nossas inferências são relevantes. Chamamos o processo de verificar essas suposições de *verificação de modelos*[2], o tema deste capítulo. Obviamente, isso tem enorme importância nas aplicações da estatística, e a boa prática estatística exige que se faça uma verificação de modelos eficaz. Os métodos vão desde métodos gráficos bastante informais até avaliações de hipóteses mais elaboradas, e discutiremos vários deles.

9.1 Verificação do Modelo Amostral

Os métodos de inferência baseados em frequência começam com um modelo estatístico $\{f_\theta : \theta \in \Omega\}$ para a verdadeira distribuição que gerou os dados s. Isso significa que estamos supondo que a verdadeira distribuição dos dados observados está nesse conjunto. Se essa suposição não for verdadeira, então

No original: *prior*[1], *model checking*[2].

parece razoável questionar a relevância de quaisquer inferências que façamos depois sobre θ.

Exceto em circunstâncias relativamente raras, nunca podemos saber de modo categórico que um modelo está correto. O máximo que podemos esperar é conseguir avaliar se os dados observados s poderiam plausivelmente ter surgido do modelo.

Se os dados observados forem surpreendentes para cada distribuição do modelo, então temos evidência de que o modelo está incorreto. Isso nos leva a pensar em calcular um valor-p para verificar se o modelo está correto. É claro que, nessa situação, a hipótese nula[3] é que o modelo está correto; a alternativa é que o modelo poderia ser qualquer um dos outros modelos possíveis para o tipo de dados com que estamos lidando.

Recordemos agora nossa discussão sobre valores-p no Capítulo 6, onde distinguimos entre significância prática e significância estatística. Observou-se que, embora um valor-p possa indicar que uma hipótese nula é falsa, em termos práticos o desvio em relação à hipótese nula pode ser tão pequeno que não tem importância para a aplicação. Quando o tamanho da amostra[4] fica grande, é inevitável que qualquer abordagem razoável por meio de valores-p detecte esse desvio e indique que a hipótese nula é falsa. Isso também vale quando fazemos a verificação de modelos usando valores-p. A solução é estimar, de alguma forma, o tamanho do desvio do modelo em relação ao modelo correto e, assim, determinar se o modelo será ou não adequado para a aplicação. Mesmo que no fim aceitemos usar o modelo, ainda assim é valioso saber que detectamos evidência de que o modelo está incorreto, quando for esse o caso.

Uma abordagem de verificação de modelos por valor-p consiste em especificar uma *estatística de discrepância*[5] $D : S \to R^1$ que mede os desvios em relação ao modelo em consideração. Tipicamente, valores grandes de D devem indicar que ocorreu um desvio. O valor efetivo $D(s)$, é claro, não é necessariamente uma indicação disso. A questão relevante é se o valor observado $D(s)$ é ou não surpreendente sob a suposição de que o modelo está correto. Portanto, precisamos avaliar se $D(s)$ está ou não numa região de baixa probabilidade para a distribuição dessa quantidade quando o modelo está correto. Por exemplo, considere a densidade de uma possível estatística D desenhada na Figura 9.1.1. Aqui, um valor $D(s)$ na cauda esquerda (perto de 0), na cauda direita (além de 15) ou entre as duas modas (no intervalo de cerca de 7 a 9) indicaria, em qualquer dos casos, que o modelo está incorreto, porque esses valores têm

No original: *null hypothesis*[3], *sample size*[4], *discrepancy statistic*[5].

baixa probabilidade de ocorrer quando o modelo está correto.

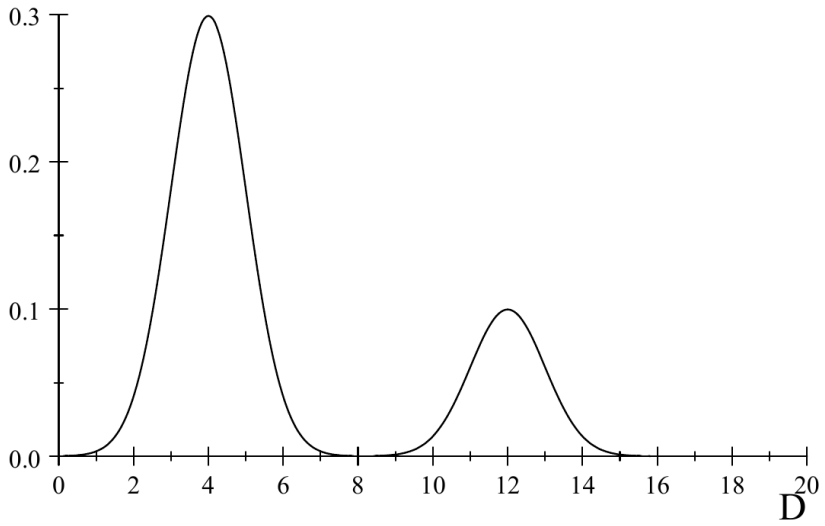


Figura 9.1.1: Gráfico de uma densidade de uma estatística de discrepância D.

A discussão acima impõe a restrição de que, quando o modelo está correto, D tenha uma única distribuição, isto é, a distribuição não pode depender de θ. Para muitas estatísticas de discrepância de uso comum, essa distribuição é unimodal. Um valor na cauda direita indica então uma falta de ajuste, ou *subajuste*[6], do modelo (as discrepâncias são anormalmente grandes); um valor na cauda esquerda indica então *sobreajuste*[7] do modelo (as discrepâncias são anormalmente pequenas).

Há dois métodos gerais disponíveis para obter uma única distribuição para o cálculo de valores-p. Um dos métodos exige que D seja ancilar.

Definição 9.1.1

Uma estatística D cuja distribuição sob o modelo não depende de θ é chamada *ancilar*, isto é, se $s \sim P_\theta$, então $D(s)$ tem a mesma distribuição para todo $\theta \in \Omega$.

Se D é ancilar, então ela tem uma única distribuição especificada pelo modelo. Se $D(s)$ é um valor surpreendente para essa distribuição, então temos evidência contra a veracidade do modelo.

Não é verdade que qualquer D ancilar sirva como estatística de discrepância útil. Por exemplo, se D é uma constante, então ela é ancilar, mas obviamente

No original: *underfitting*[6], *overfitting*[7].

não é útil para verificar o modelo. Portanto, precisamos ter cuidado ao escolher D.

Muitas vezes conseguimos encontrar estatísticas ancilares úteis para um modelo olhando para os *resíduos*. Em termos gerais, os resíduos se baseiam na informação dos dados que sobra depois de ajustarmos o modelo. Se usamos toda a informação relevante dos dados para o ajuste, então os resíduos não devem conter nenhuma informação útil para a inferência sobre o parâmetro θ. O Exemplo 9.1.1 vai ilustrar com mais clareza o que entendemos por resíduos. Os resíduos têm um papel importante na verificação de modelos.

O segundo método funciona com qualquer estatística de discrepância D. Para isso, usamos a distribuição condicional[8] de D dado o valor de uma estatística suficiente[9] T. Pelo Teorema 8.1.2, essa distribuição condicional é a mesma para todo valor de θ. Se $D(s)$ é um valor surpreendente para essa distribuição, então temos evidência contra a veracidade do modelo.

Às vezes as duas abordagens que acabamos de descrever concordam, mas nem sempre. Considere alguns exemplos.

Exemplo 9.1.1 — Normal de Locação

Vamos supor que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição $N(\mu, \sigma_0^2)$, em que $\mu \in R^1$ é desconhecido e σ_0^2 é conhecido. Sabemos que $\bar{x}$ é uma estatística suficiente minimal para esse problema (ver Exemplo 6.1.7). Além disso, $\bar{x}$ representa o ajuste do modelo aos dados, já que é a estimativa do valor desconhecido do parâmetro μ.

Agora considere

$$r = r(x_1, \ldots, x_n) = (r_1, \ldots, r_n) = (x_1 - \bar{x}, \ldots, x_n - \bar{x})$$

como uma definição possível do resíduo. Observe que podemos reconstruir os dados originais a partir dos valores de $\bar{x}$ e r.

Acontece que $R = (X_1 - \bar{X}, \ldots, X_n - \bar{X})$ tem uma distribuição que não depende de μ, com $E(R_i) = 0$ e $\text{Cov}(R_i, R_j) = \sigma_0^2(\delta_{ij} - 1/n)$ para todos i, j ($\delta_{ij} = 1$ quando $i = j$ e 0 caso contrário). Além disso, R é independente de $\bar{X}$ e $R_i \sim N(0, \sigma_0^2(1 - 1/n))$ (ver Problemas 9.1.19 e 9.1.20).

Assim, temos que r é ancilar, e também o é qualquer estatística de discrepância D que dependa dos dados apenas por meio de r. Além disso, a distribuição condicional de $D(R)$ dado $\bar{X} = \bar{x}$ é igual à distribuição

No original: *conditional distribution*[8], *sufficient statistic*[9].

marginal de $D(R)$, porque elas são independentes. Portanto, as duas abordagens para obter um valor-p concordam aqui, sempre que a estatística de discrepância depender dos dados apenas por meio de r.

Pelo Teorema 4.6.6, temos que

$$D(R) = \frac{1}{\sigma_0^2}\sum_{i=1}^{n} R_i^2 = \frac{1}{\sigma_0^2}\sum_{i=1}^{n}\left(X_i - \bar{X}\right)^2$$

tem distribuição $\chi^2(n-1)$; logo, essa é uma estatística de discrepância possível. Portanto, o valor-p

$$P(D > D(r)), \tag{9.1.1}$$

em que $D \sim \chi^2(n-1)$, fornece uma avaliação de se o modelo está ou não correto.

Observe que valores de (9.1.1) perto de 0 ou perto de 1 são ambos evidência contra o modelo, já que ambos indicam que $D(r)$ está numa região de baixa probabilidade quando se supõe que o modelo está correto. Um valor perto de 0 indica que $D(r)$ está na cauda direita, enquanto um valor perto de 1 indica que $D(r)$ está na cauda esquerda.

A necessidade de examinar a cauda esquerda da distribuição de $D(r)$, além da direita, se vê da seguinte forma. Considere a situação em que, na verdade, estamos amostrando de uma distribuição $N(\mu, \sigma^2)$ em que σ^2 é muito menor que σ_0^2. Nesse caso, esperamos que $D(r)$ seja um valor na cauda esquerda, porque $E(D(R)) = (n-1)\sigma^2/\sigma_0^2$.

Há obviamente muitas outras escolhas possíveis para a estatística D. Atualmente, não existe uma teoria que prescreva uma escolha em vez de outra. Uma ressalva deve ser feita, porém. A escolha de uma estatística D não pode se basear em olhar os dados primeiro. Fazer isso invalida o cálculo do valor-p descrito acima, pois teríamos então de condicionar à característica dos dados que nos levou a escolher aquela D em particular. ■

Exemplo 9.1.2 — Normal de Locação-Escala

Vamos supor que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição $N(\mu, \sigma^2)$, em que $(\mu, \sigma^2) \in R^1 \times (0, \infty)$ é desconhecido. Sabemos que $(\bar{x}, s^2)$ é uma estatística suficiente minimal para esse modelo (Exemplo 6.1.8). Considere

$$r = r(x_1, \ldots, x_n) = (r_1, \ldots, r_n) = \left(\frac{x_1 - \bar{x}}{s}, \ldots, \frac{x_n - \bar{x}}{s}\right)$$

como uma definição possível do resíduo. Observe que podemos reconstruir os dados a partir dos valores de $(\bar{x}, s^2)$ e r.

Acontece que R tem uma distribuição que não depende de (μ, σ^2) (e, portanto, é ancilar — ver Desafio 9.1.28), além de ser independente de $(\bar{X}, S^2)$. Assim, mais uma vez, as duas abordagens para obter um valor-p concordam aqui, desde que a estatística de discrepância dependa dos dados apenas por meio de r.

Uma estatística de discrepância possível é dada por

$$D(r) = -\frac{1}{n}\sum_{i=1}^{n} \ln\left(\frac{r_i^2}{n-1}\right).$$

Para usar essa estatística na verificação do modelo, precisamos obter sua distribuição quando o modelo está correto. Depois, comparamos o valor observado $D(r)$ com essa distribuição, para ver se ele é surpreendente.

Podemos fazer isso por simulação. Como a distribuição de $D(R)$ não depende de (μ, σ^2), podemos gerar N amostras de tamanho n da distribuição $N(0, 1)$ (ou de qualquer outra distribuição normal) e calcular $D(R)$ para cada amostra. Depois, olhamos para histogramas dos valores simulados para ver se $D(r)$, da amostra original, é um valor surpreendente, isto é, se está numa região de baixa probabilidade, como uma cauda esquerda ou direita.

Por exemplo, suponha que observamos a amostra

−2,08	−0,28	2,01	−1,37	40,08

obtendo o valor $D(r) = 4{,}93$. Então, simulando 10^4 valores da distribuição de D, sob a suposição de que o modelo está correto, obtivemos o histograma de densidade dado na Figura 9.1.2. Veja o Apêndice B para um código usado nessa simulação. O valor $D(r) = 4{,}93$ está bem na cauda direita e, portanto, indica que a amostra não vem de uma distribuição normal. De fato, apenas 0,0057 dos valores simulados são maiores, de modo que essa é uma evidência clara contra a veracidade do modelo.

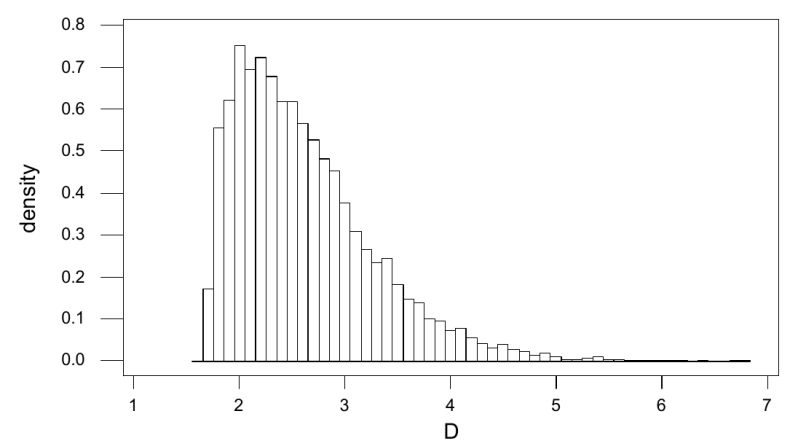


Figura 9.1.2: Um histograma de densidade de uma simulação de 10^4 valores de D no Exemplo 9.1.2.

Obviamente, há outras funções possíveis de r que poderíamos usar aqui para verificar o modelo. Em particular, $D_{\text{assim}}(r) = (n-1)^{-3/2} \sum_{i=1}^{n} r_i^3$, a *estatística de assimetria*, e $D_{\text{curtose}}(r) = (n-1)^{-2} \sum_{i=1}^{n} r_i^4$, a *estatística de curtose*, são de uso comum. A estatística de assimetria mede a simetria dos dados, enquanto a estatística de curtose mede o "grau de pico" dos dados. Como acabamos de descrever, podemos simular a distribuição dessas estatísticas sob a suposição de normalidade e depois comparar os valores observados com essas distribuições para ver se temos alguma evidência contra o modelo (ver Problema Computacional 9.1.27). ■

Os exemplos a seguir apresentam contextos em que as duas abordagens para calcular um valor-p na verificação de modelos não coincidem.

Exemplo 9.1.3 — Cauchy de Locação-Escala

Vamos supor que $(x_1, \ldots, x_n)$ é uma amostra da distribuição dada por $\mu + \sigma Z$, em que $Z \sim t(1)$ e $(\mu, \sigma^2) \in R^1 \times (0, \infty)$ é desconhecido. Desta vez, $(\bar{x}, s^2)$ não é uma estatística suficiente minimal, mas a estatística r definida no Exemplo 9.1.2 continua sendo ancilar (Desafio 9.1.28). Podemos novamente simular valores da distribuição de R (basta gerar amostras da distribuição $t(1)$ e calcular r para cada amostra) para estimar valores-p de qualquer estatística de discrepância, como as estatísticas $D(r)$ discutidas no Exemplo 9.1.2. ■

Exemplo 9.1.4 — Teste Exato de Fisher

Suponha que tomamos uma amostra de n indivíduos de uma população de estudantes e observamos os valores $(a_1, b_1), \ldots, (a_n, b_n)$, em que a_i é o sexo ($A = 1$ indica masculino, $A = 2$ indica feminino) e b_i é uma variável categórica para a situação de emprego em tempo parcial ($B = 1$ indica empregado, $B = 2$ indica desempregado). Assim, cada indivíduo é classificado em uma de quatro categorias, a saber,

$$\begin{aligned}&\text{Categoria 1, quando } A = 1, B = 1,\\ &\text{Categoria 2, quando } A = 1, B = 2,\\ &\text{Categoria 3, quando } A = 2, B = 1,\\ &\text{Categoria 4, quando } A = 2, B = 2.\end{aligned}$$

Suponha que nosso modelo para essa situação seja que A e B são independentes com $P(A = 1) = \alpha_1$, $P(B = 1) = \beta_1$, em que $\alpha_1 \in [0, 1]$ e $\beta_1 \in [0, 1]$ são completamente desconhecidos. Então, denotando por X_{ij} a contagem da categoria em que $A = i$, $B = j$, o Exemplo 2.8.5 dá que

$$(X_{11}, X_{12}, X_{21}, X_{22}) \sim \text{Multinomial}(n, \alpha_1\beta_1, \alpha_1\beta_2, \alpha_2\beta_1, \alpha_2\beta_2).$$

Como veremos no Capítulo 10, esse modelo equivale a dizer que não há relação entre sexo e situação de emprego.

Denotando as contagens observadas nas caselas por $(x_{11}, x_{12}, x_{21}, x_{22})$, a função de verossimilhança é dada por

$$\begin{aligned}&(\alpha_1\beta_1)^{x_{11}}(\alpha_1\beta_2)^{x_{12}}(\alpha_2\beta_1)^{x_{21}}(\alpha_2\beta_2)^{x_{22}}\\ &= \alpha_1^{x_{11}+x_{12}}(1-\alpha_1)^{n-x_{11}-x_{12}}\,\beta_1^{x_{11}+x_{21}}(1-\beta_1)^{n-x_{11}-x_{21}}\\ &= \alpha_1^{x_{1\cdot}}(1-\alpha_1)^{n-x_{1\cdot}}\,\beta_1^{x_{\cdot 1}}(1-\beta_1)^{n-x_{\cdot 1}},\end{aligned}$$

em que $(x_{1\cdot}, x_{\cdot 1}) = (x_{11} + x_{12}, x_{11} + x_{21})$. Portanto, o EMV (Problema 9.1.14) é dado por

$$(\hat{\alpha}_1, \hat{\beta}_1) = \left(\frac{x_{1\cdot}}{n}, \frac{x_{\cdot 1}}{n}\right).$$

Observe que $\hat{\alpha}_1$ é a proporção de homens na amostra e $\hat{\beta}_1$ é a proporção de todos os empregados na amostra. Como $(x_{1\cdot}, x_{\cdot 1})$ determina a função de verossimilhança e pode ser calculado a partir dela, temos que $(x_{1\cdot}, x_{\cdot 1})$ é uma estatística suficiente minimal.

Neste exemplo, uma definição natural de resíduo não parece evidente. Por isso, consideramos a distribuição condicional dos dados, dada a estatística suficiente minimal. A distribuição condicional da amostra

$(A_1, B_1), \ldots, (A_n, B_n)$, dados os valores $(x_{1\cdot}, x_{\cdot 1})$, é a distribuição uniforme no conjunto de todas as amostras em que as restrições

$$\begin{aligned} x_{11} + x_{12} &= x_{1\cdot}, \\ x_{11} + x_{21} &= x_{\cdot 1}, \\ x_{11} + x_{12} + x_{21} + x_{22} &= n \end{aligned} \tag{9.1.2}$$

são satisfeitas. Observe que, dados $(x_{1\cdot}, x_{\cdot 1})$, todos os outros valores em (9.1.2) ficam determinados quando especificamos um valor para x_{11}.

Pode-se mostrar que o número dessas amostras é igual a (ver Problema 9.1.21)

$$\binom{n}{x_{1\cdot}}\binom{n}{x_{\cdot 1}}.$$

Agora, o número de amostras com valores prescritos para $x_{1\cdot}$, $x_{\cdot 1}$ e $x_{11} = i$ é dado por

$$\binom{n}{x_{1\cdot}}\binom{x_{1\cdot}}{i}\binom{n - x_{1\cdot}}{x_{\cdot 1} - i}.$$

Portanto, a função de probabilidade condicional de x_{11}, dados $(x_{1\cdot}, x_{\cdot 1})$, é

$$P(x_{11} = i \mid x_{1\cdot}, x_{\cdot 1}) = \frac{\binom{n}{x_{1\cdot}}\binom{x_{1\cdot}}{i}\binom{n-x_{1\cdot}}{x_{\cdot 1}-i}}{\binom{n}{x_{1\cdot}}\binom{n}{x_{\cdot 1}}} = \frac{\binom{x_{1\cdot}}{i}\binom{n-x_{1\cdot}}{x_{\cdot 1}-i}}{\binom{n}{x_{\cdot 1}}}.$$

Essa é a função de probabilidade Hipergeométrica$(n, x_{\cdot 1}, x_{1\cdot})$.

Assim, temos evidência contra o modelo sempre que x_{11} estiver bem nas caudas dessa distribuição. Avaliar isso exige uma tabela dessa distribuição ou o uso de um pacote estatístico que tenha a função de distribuição hipergeométrica embutida.

Como exemplo numérico simples, suponha que tomamos uma amostra de $n = 20$ estudantes, obtendo $x_{\cdot 1} = 12$ desempregados, $x_{1\cdot} = 6$ homens e $x_{11} = 2$ homens empregados. Então, a função de probabilidade Hipergeométrica$(20, 12, 6)$ é dada pela tabela a seguir.

i	0	1	2	3	4	5	6
$p(i)$	0,001	0,017	0,119	0,318	0,358	0,163	0,024

A probabilidade de obter um valor tão longe nas caudas quanto $x_{11} = 2$, ou mais longe, é igual à probabilidade de observar um valor de x_{11} com probabilidade de ocorrência tão pequena quanto a de $x_{11} = 2$, ou menor. Esse valor-p é igual a

$$(0{,}119 + 0{,}017 + 0{,}001) + 0{,}024 = 0{,}161.$$

Portanto, não temos evidência contra o modelo de independência entre A e B. É claro que o tamanho da amostra aqui é bem pequeno.

Há outra abordagem para testar a independência de A e B aqui. Em particular, poderíamos supor apenas a independência da amostra inicial, sem classificação, e então sempre temos

$$(X_{11}, X_{12}, X_{21}, X_{22}) \sim \text{Multinomial}(n, \alpha_{11}, \alpha_{12}, \alpha_{21}, \alpha_{22}),$$

em que os α_{ij} formam uma distribuição de probabilidade desconhecida. Dado esse modelo, poderíamos então testar a independência de A e B. Discutiremos isso na Seção 10.2. ■

Outra abordagem para a verificação de modelos procede da seguinte forma. Ampliamos o modelo para incluir mais distribuições e então testamos a hipótese nula de que o verdadeiro modelo é o submodelo com que começamos. Se pudermos aplicar os métodos da Seção 8.2 para chegar a um teste uniformemente mais poderoso[10] (UMP) dessa hipótese nula, então teremos uma verificação de desvios em relação ao modelo de interesse — pelo menos dos desvios expressos pelas alternativas possíveis no modelo ampliado. Se o modelo passar nessa verificação, porém, ainda precisamos verificar a validade do modelo ampliado. Isso pode ser visto como uma técnica para gerar estatísticas de discrepância D relevantes.

9.1.1 Gráficos de Resíduos e de Probabilidade

Há outra abordagem, mais informal, para verificar se o modelo está correto, que é frequentemente usada quando temos resíduos disponíveis. Esses métodos envolvem vários gráficos dos resíduos, que devem exibir características específicas se o modelo estiver correto. Embora essa abordagem não tenha o rigor da abordagem por valor-p, ela é boa para mostrar desvios grosseiros das suposições do modelo. Ilustramos isso com alguns exemplos.

Exemplo 9.1.5 — Modelos Normais de Locação e de Locação-Escala

Usando os resíduos do modelo normal de locação discutido no Exemplo 9.1.1, temos que $E(R_i) = 0$ e $\text{Var}(R_i) = \sigma_0^2(1 - 1/n)$. Padronizamos esses valores para que eles também tenham variância 1 e assim obtemos os

No original: *uniformly most powerful test*[10].

resíduos padronizados $(r_1^*, \ldots, r_n^*)$ dados por

$$r_i^* = \sqrt{\frac{n}{\sigma_0^2(n-1)}}\,(x_i - \bar{x}). \tag{9.1.3}$$

Os resíduos padronizados têm distribuição $N(0,1)$ e, supondo que n seja razoavelmente grande, pode-se mostrar que eles são aproximadamente independentes. Assim, podemos pensar em $r_1^*, \ldots, r_n^*$ como uma amostra aproximada da distribuição $N(0,1)$.

Portanto, um gráfico dos pontos (i, r_i^*) não deve exibir nenhum padrão discernível. Além disso, todos os valores na direção y devem estar em $(-3, 3)$, a não ser, é claro, que n seja muito grande, caso em que podemos esperar alguns valores fora desse intervalo. Um padrão discernível, ou vários valores extremos, pode ser tomado como alguma evidência de que a suposição do modelo não está correta. Tenha sempre em mente, porém, que qualquer padrão observado poderia ter surgido simplesmente da variabilidade amostral quando o verdadeiro modelo está correto. Simular alguns desses gráficos de resíduos (basta gerar várias amostras de tamanho n da distribuição $N(0,1)$ e obter um gráfico de resíduos para cada amostra) nos dará uma ideia de se o padrão observado é ou não incomum.

A Figura 9.1.3 mostra um gráfico dos resíduos padronizados (9.1.3) para uma amostra de 100 da distribuição $N(0,1)$. A Figura 9.1.4 mostra um gráfico dos resíduos padronizados para uma amostra de 100 da distribuição dada por $3^{-1/2}Z$, em que $Z \sim t(3)$. Observe que uma distribuição $t(3)$ tem média 0 e variância igual a 3, de modo que $\text{Var}(3^{-1/2}Z) = 1$ (Problema 4.6.16). A Figura 9.1.5 mostra os resíduos padronizados para uma amostra de 100 de uma distribuição Exponencial(1).

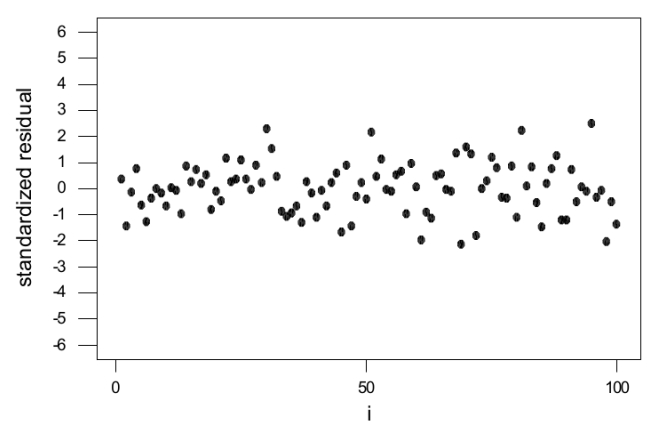


Figura 9.1.3: Um gráfico dos resíduos padronizados para uma amostra de 100 de uma distribuição $N(0,1)$.

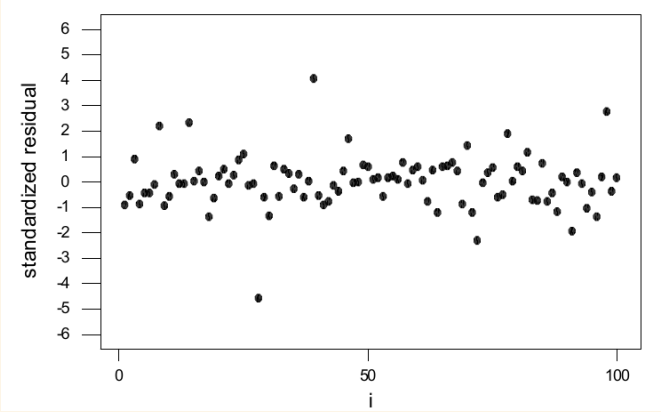


Figura 9.1.4: Um gráfico dos resíduos padronizados para uma amostra de 100 de $X = 3^{-1/2}Z$, em que $Z \sim t(3)$.

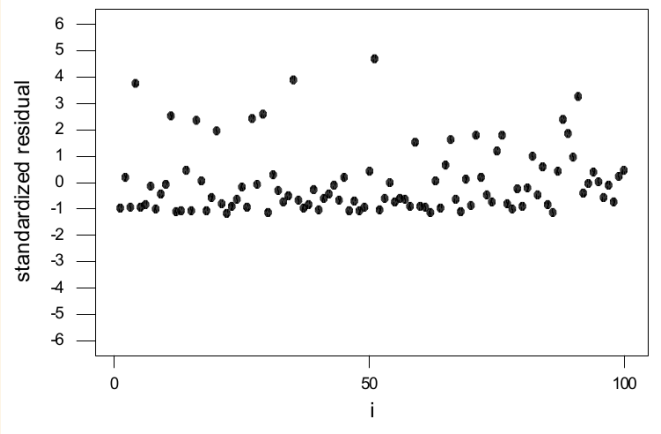


Figura 9.1.5: Um gráfico dos resíduos padronizados para uma amostra de 100 de uma distribuição Exponencial(1).

Observe que as distribuições dos resíduos padronizados de todas essas amostras têm média 0 e variância igual a 1. A diferença entre as Figuras 9.1.3 e 9.1.4 se deve ao fato de a distribuição t ter caudas muito mais longas. Isso se reflete no fato de alguns dos resíduos padronizados estarem fora de $(-3, 3)$ na Figura 9.1.4, mas não na Figura 9.1.3. Embora as duas distribuições sejam bastante diferentes — por exemplo, a distribuição $N(0, 1)$ tem todos os seus momentos, enquanto a distribuição $3^{-1/2}t(3)$ tem apenas dois momentos —, os gráficos dos resíduos padronizados são, fora isso, muito parecidos. A diferença entre as Figuras 9.1.3 e 9.1.5 se deve à assimetria da distribuição Exponencial(1), que é assimétrica à direita.

Usando os resíduos do modelo normal de locação-escala discutido no

Exemplo 9.1.2, definimos os resíduos padronizados $r_1^*, \ldots, r_n^*$ por

$$r_i^* = \sqrt{\frac{n}{s^2(n-1)}}\,(x_i - \bar{x}). \tag{9.1.4}$$

Aqui, a variância desconhecida é estimada por s^2. Novamente, pode-se mostrar que, quando n é grande, $(r_1^*, \ldots, r_n^*)$ é uma amostra aproximada da distribuição $N(0,1)$. Assim, fazemos o gráfico dos valores (i, r_i^*) e o interpretamos exatamente como descrevemos para o modelo normal de locação. ■

É muito comum, nas aplicações estatísticas, supor alguma forma básica para a distribuição dos dados; por exemplo, podemos supor que estamos amostrando de uma distribuição normal com alguma média e variância[11]. Para avaliar essa suposição, o uso de um *gráfico de probabilidade* tem se mostrado muito útil.

Para ilustrar, suponha que $(x_1, \ldots, x_n)$ seja uma amostra de uma distribuição $N(\mu, \sigma^2)$. Então pode-se mostrar que, quando n é grande, a esperança[12] da i-ésima estatística de ordem satisfaz

$$E(X_{(i)}) \approx \mu + \sigma\Phi^{-1}(i/(n+1)). \tag{9.1.5}$$

Se o valor x_j dos dados corresponde à estatística de ordem $x_{(i)}$ (isto é, $x_{(i)} = x_j$), então chamamos $\Phi^{-1}(i/(n+1))$ de *escore normal*[13] de x_j na amostra. Então (9.1.5) indica que, se fizermos o gráfico dos pontos $(x_{(i)}, \Phi^{-1}(i/(n+1)))$, eles devem ficar aproximadamente sobre uma reta com intercepto μ e inclinação σ. Chamamos esse gráfico de *gráfico de probabilidade normal*[14] ou *gráfico de quantis normais*. Gráficos semelhantes podem ser obtidos para outras distribuições.

No original: *variance*[11], *expectation*[12], *normal score*[13], *normal probability plot*[14].

Exemplo 9.1.6 — Normal de Locação-Escala

Suponha que queremos avaliar se o seguinte conjunto de dados pode ou não ser considerado uma amostra de tamanho $n = 10$ de alguma distribuição normal.

2,00	0,28	0,47	3,33	1,66	8,17	1,18	4,15	6,43	1,77

As estatísticas de ordem e os escores normais associados para essa amostra são dados na tabela a seguir.

i	1	2	3	4	5
$x_{(i)}$	0,28	0,47	1,18	1,66	1,77
$\Phi^{-1}(i/(n+1))$	−1,34	−0,91	−0,61	−0,35	−0,12
i	6	7	8	9	10
$x_{(i)}$	2,00	3,33	4,15	6,43	8,17
$\Phi^{-1}(i/(n+1))$	0,11	0,34	0,60	0,90	1,33

Os valores

$$(x_{(i)}, \Phi^{-1}(i/(n+1)))$$

são então representados na Figura 9.1.6. Há algum desvio claro em relação a uma reta aqui, mas observe que é difícil dizer se isso é inesperado numa amostra desse tamanho de uma distribuição normal. Novamente, recomenda-se simular algumas amostras do mesmo tamanho (digamos, de uma distribuição $N(0,1)$) e olhar seus gráficos de probabilidade normal. Neste caso, concluímos que o gráfico da Figura 9.1.6 parece razoável. ■

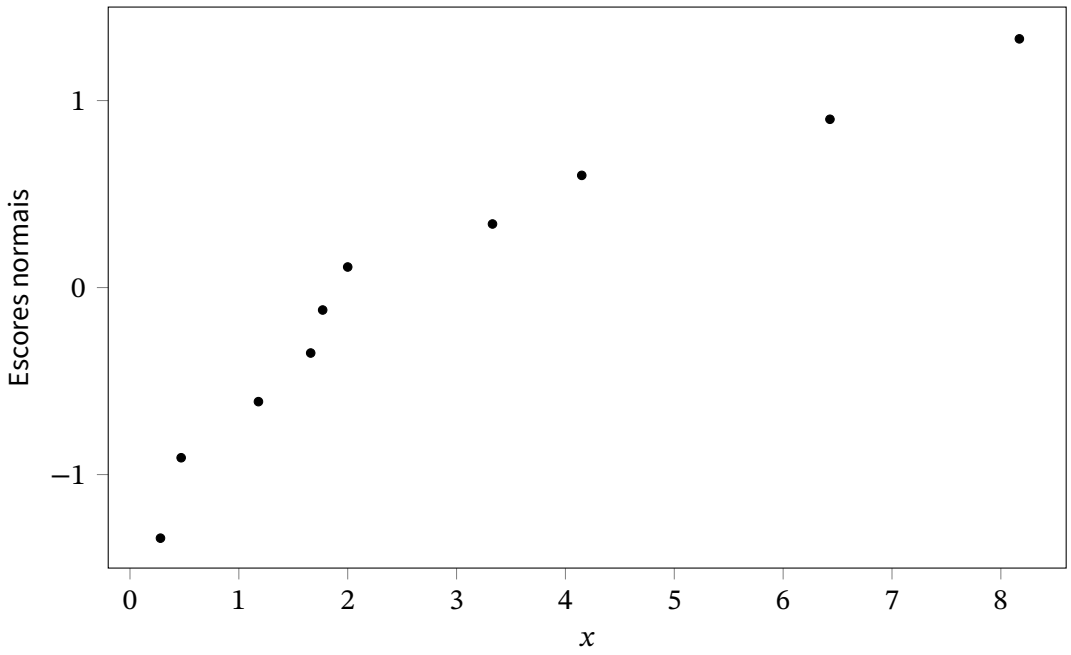


Figura 9.1.6: Gráfico de probabilidade normal dos dados do Exemplo 9.1.6.

Veremos no Capítulo 10 que o uso de gráficos de probabilidade normal de resíduos padronizados é uma parte importante da verificação de modelos mais complicados. Assim, embora eles não sejam realmente necessários aqui, consideramos algumas das características desses gráficos ao avaliar se uma amostra vem ou não de um modelo normal de locação[15] ou de locação-escala.

Suponha que n seja grande, de modo que possamos considerar os resíduos padronizados, dados por (9.1.3) ou (9.1.4), como uma amostra aproximada da distribuição $N(0,1)$. Então, um gráfico de probabilidade normal dos resíduos padronizados deve ser aproximadamente linear, com intercepto em y aproximadamente igual a 0 e inclinação aproximadamente igual a 1. Se obtivermos um desvio substancial disso, então temos evidência de que o modelo suposto está incorreto.

Na Figura 9.1.7, fizemos um gráfico de probabilidade normal dos resíduos padronizados de uma amostra de $n = 25$ de uma distribuição $N(0,1)$. Na Figura 9.1.8, fizemos um gráfico de probabilidade normal dos resíduos padronizados de uma amostra de $n = 25$ da distribuição dada por $X = 3^{-1/2}Z$, em que $Z \sim t(3)$. As duas distribuições têm média 0 e variância 1, de modo que a diferença entre os gráficos de probabilidade normal se deve a outras diferenças entre as distribuições.

No original: *location normal model*[15].

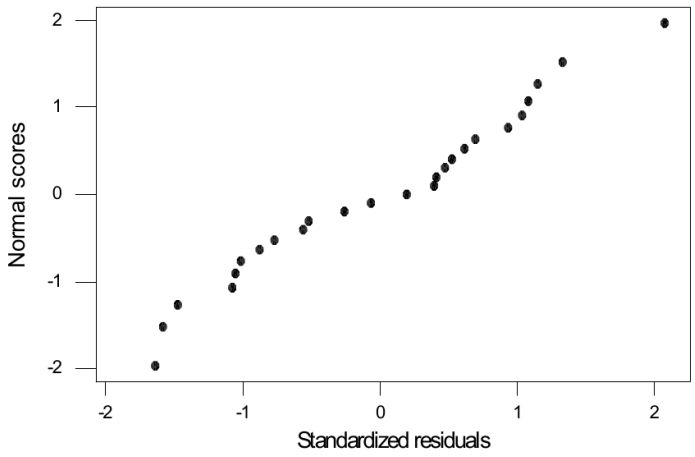


Figura 9.1.7: Gráfico de probabilidade normal dos resíduos padronizados de uma amostra de 25 de uma distribuição $N(0, 1)$.

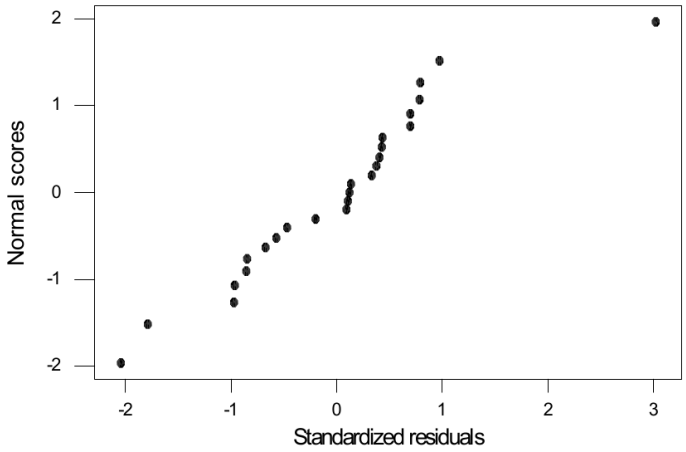


Figura 9.1.8: Gráfico de probabilidade normal dos resíduos padronizados de uma amostra de 25 de $X = 3^{-1/2}Z$, em que $Z \sim t(3)$.

9.1.2 O Teste Qui-quadrado de Aderência

O teste qui-quadrado de aderência[16] tem um lugar histórico importante em qualquer discussão sobre a avaliação da correção de modelos. Usamos esse teste para avaliar se uma variável aleatória[17] categórica W, que assume valores no espaço amostral[18] finito $\{1, 2, \dots, k\}$, tem ou não uma medida de probabilidade[19] especificada P, depois de observar uma amostra $(w_1, \dots, w_n)$. Quando temos uma variável aleatória discreta que assume infinitos valores,

No original: *chi-squared goodness of fit test*[16], *random variable*[17], *sample space*[18], *probability measure*[19].

dividimos os valores possíveis em k categorias e fazemos W simplesmente indicar qual categoria ocorreu. Se temos uma variável aleatória quantitativa, então dividimos R^1 em k subintervalos e fazemos W indicar em qual intervalo a resposta ocorreu. Na prática, queremos verificar se um modelo de probabilidade[20] específico, dado por P, está ou não correto para W, com base numa amostra observada.

Sejam $(X_1, \dots, X_k)$ as contagens, ou frequências, observadas de $1, \dots, k$, respectivamente. Se P está correta, então, pelo Exemplo 2.8.5,

$$(X_1, \dots, X_k) \sim \text{Multinomial}(n, p_1, \dots, p_k),$$

em que $p_i = P(\{i\})$. Isso implica que $E(X_i) = np_i$ e $\text{Var}(X_i) = np_i(1 - p_i)$ (lembre que $X_i \sim \text{Binomial}(n, p_i)$). Disso, deduzimos que

$$R_i = \frac{X_i - np_i}{\sqrt{np_i(1 - p_i)}} \xrightarrow{D} N(0, 1) \tag{9.1.6}$$

quando $n \to \infty$ (ver Exemplo 4.4.9).

Para n finito, a distribuição de R_i, quando o modelo está correto, depende de P, mas a distribuição limite[21] não depende. Assim, podemos pensar nos R_i como resíduos padronizados quando n é grande. Portanto, pareceria que uma estatística de discrepância razoável é dada pela soma dos quadrados dos resíduos padronizados, com $\sum_{i=1}^{k} R_i^2$ distribuída aproximadamente como $\chi^2(k)$. No entanto, vale a restrição $x_1 + \cdots + x_k = n$; logo, os R_i não são independentes, e a distribuição limite não é $\chi^2(k)$. Temos, porém, o seguinte resultado, que fornece uma estatística de discrepância semelhante.

Teorema 9.1.1

Se $(X_1, \dots, X_k) \sim \text{Multinomial}(n, p_1, \dots, p_k)$, então

$$X^2 = \sum_{i=1}^{k} (1 - p_i) R_i^2 = \sum_{i=1}^{k} \frac{(X_i - np_i)^2}{np_i} \xrightarrow{D} \chi^2(k - 1)$$

quando $n \to \infty$.

A demonstração desse resultado é um pouco complicada demais para este texto; veja, por exemplo, o Teorema 17.2 de *Asymptotic Statistics*, de A. W. van der Vaart (Cambridge University Press, Cambridge, 1998), que usaremos aqui.

Chamamos X^2 de *estatística qui-quadrado*. O processo de avaliar se o modelo está correto calculando o valor-p $P(X^2 \geq X_0^2)$, em que $X^2 \sim \chi^2(k - 1)$ e X_0^2 é o

No original: *probability model*[20], *limiting distribution*[21].

valor observado da estatística qui-quadrado, é chamado *teste qui-quadrado de aderência*. Valores-p pequenos, perto de 0, fornecem evidência de que o modelo de probabilidade está incorreto. Valores-p pequenos indicam que alguns dos resíduos são grandes demais.

Observe que o i-ésimo termo da estatística qui-quadrado pode ser escrito como

$$\frac{(X_i - np_i)^2}{np_i} = \frac{(\text{número na casela } i - \text{número esperado na casela } i)^2}{\text{número esperado na casela } i}.$$

Recomenda-se, por exemplo em *Statistical Methods*, de G. Snedecor e W. Cochran (Iowa State Press, 6.ª ed., Ames, 1967), que se use agrupamento (combinação de caselas) para garantir que $E(X_i) = np_i \geq 1$ para todo i, pois simulações mostraram que isso melhora a precisão da aproximação do valor-p.

Consideramos uma aplicação importante.

Exemplo 9.1.7 — Testando a Precisão de um Gerador de Números Aleatórios

Na prática, toda simulação de Monte Carlo pode ser vista como um conjunto de operações matemáticas aplicadas a uma sequência de números $U_1, U_2, \ldots$ em $[0,1]$ que deveriam ser i.i.d. Uniforme$[0,1]$. É claro que eles não podem satisfazer essa exigência exatamente, porque são gerados de acordo com alguma função determinística. Tipicamente, escolhe-se uma função $f : [0,1]^m \to [0,1]$, que é aplicada iterativamente para obter a sequência. Assim, selecionamos $U_1, \ldots, U_m$ como *valores-semente* iniciais e então $U_{m+1} = f(U_1, \ldots, U_m)$, $U_{m+2} = f(U_2, \ldots, U_{m+1})$ etc. Há muitas possibilidades para f, e muita pesquisa e estudo foram dedicados a selecionar funções que produzam sequências que imitem adequadamente as propriedades de uma sequência i.i.d. Uniforme$[0,1]$.

É claro que é sempre possível que a f usada num pacote estatístico ou outro programa em particular seja muito ruim. Nesse caso, os resultados das simulações podem estar grosseiramente errados. Como avaliamos se uma f em particular é ou não boa? Uma abordagem é aplicar uma bateria de testes estatísticos para ver se a sequência se comporta como sabemos que uma sequência ideal se comportaria.

Por exemplo, se a sequência $U_1, U_2, \ldots$ é i.i.d. Uniforme$[0,1]$, então

$$\lceil 10U_1 \rceil, \lceil 10U_2 \rceil, \ldots$$

é i.i.d. Uniforme$\{1, 2, \ldots, 10\}$ ($\lceil x \rceil$ denota o menor inteiro maior que x; por exemplo, $\lceil 3{,}2 \rceil = 4$).* Assim, podemos testar a adequação da função f subjacente gerando $U_1, \ldots, U_n$ para n grande, fazendo $x_i = \lceil 10U_i \rceil$ e então aplicando um teste qui-quadrado de aderência com as 10 categorias

$\{1, \dots, 10\}$, cada uma com probabilidade de casela igual a 1/10.

Fazer isso com um pacote estatístico popular (com $n = 10^4$) deu a seguinte tabela de contagens x_i e resíduos padronizados r_i, como especificados em (9.1.6).

i	x_i	r_i
1	993	−0,23333
2	1044	1,46667
3	1061	2,03333
4	1021	0,70000
5	1017	0,56667
6	973	−0,90000
7	975	−0,83333
8	965	−1,16667
9	996	−0,13333
10	955	−1,50000

Todos os resíduos padronizados parecem razoáveis como valores possíveis de uma distribuição $N(0, 1)$. Além disso,

$$X_0^2 = (1 - 0{,}1)\left\{\begin{array}{l}(-0{,}23333)^2 + (1{,}46667)^2 + (2{,}03333)^2 \\ + (0{,}70000)^2 + (0{,}56667)^2 + (-0{,}90000)^2 \\ + (-0{,}83333)^2 + (-1{,}16667)^2 + (-0{,}13333)^2 \\ + (-1{,}50000)^2\end{array}\right\}$$

$$= 11{,}0560$$

dá o valor-p $P(X^2 \geq 11{,}0560) = 0{,}27190$ quando $X^2 \sim \chi^2(9)$. Isso indica que não temos evidência de que o gerador de números aleatórios seja defeituoso.

É claro que a história não termina com um único teste como esse. Muitas outras características da sequência devem ser testadas. Por exemplo, poderíamos querer investigar as propriedades de independência da sequência e, assim, testar se cada combinação possível (i, j) ocorre com probabilidade 1/100 etc. ■

De modo mais geral, não teremos uma distribuição de probabilidade prescrita P para X, mas sim um modelo estatístico $\{P_\theta : \theta \in \Omega\}$, em que cada P_θ é uma medida de probabilidade no conjunto finito $\{1, 2, \dots, k\}$. Então, com base na

*Nota do tradutor. O original diz "menor inteiro maior que x"; a definição usual de $\lceil x \rceil$ é o menor inteiro maior ou igual a x (os dois só diferem quando x é inteiro).

amostra do modelo, temos que

$$(X_1, \dots, X_k) \sim \text{Multinomial}(n, p_1(\theta), \dots, p_k(\theta)),$$

em que $p_i(\theta) = P_\theta(\{i\})$.

Talvez uma maneira natural de avaliar se esse modelo se ajusta ou não aos dados seja encontrar o EMV $\hat{\theta}$ a partir da função de verossimilhança[22]

$$L(\theta \mid x_1, \dots, x_k) = (p_1(\theta))^{x_1} \cdots (p_k(\theta))^{x_k}$$

e então olhar para os resíduos padronizados

$$r_i(\hat{\theta}) = \frac{x_i - np_i(\hat{\theta})}{\sqrt{np_i(\hat{\theta})(1 - p_i(\hat{\theta}))}}.$$

Temos o seguinte resultado, que enunciamos sem demonstração.

Teorema 9.1.2

Sob certas condições (semelhantes às discutidas na Seção 6.5), temos que $R_i(\hat{\theta}) \xrightarrow{D} N(0,1)$ e

$$X^2 = \sum_{i=1}^{k} (1 - p_i(\hat{\theta}))R_i^2(\hat{\theta}) = \sum_{i=1}^{k} \frac{(X_i - np_i(\hat{\theta}))^2}{np_i(\hat{\theta})} \xrightarrow{D} \chi^2(k - 1 - \dim \Omega)$$

quando $n \to \infty$.

Por $\dim \Omega$ entendemos a dimensão do conjunto Ω. Em termos gerais, ela é o número mínimo de coordenadas necessárias para especificar um ponto do conjunto; por exemplo, uma reta exige uma coordenada (a distância positiva ou negativa a partir de um ponto fixo), uma circunferência exige uma coordenada, um plano em R^3 exige duas coordenadas etc. É claro que esse resultado implica que o número de caselas precisa satisfazer $k > 1 + \dim \Omega$.

Considere um exemplo.

Exemplo 9.1.8 — Testando a Exponencialidade

Suponha que uma amostra de tempos de vida de lâmpadas (medidos em milhares de horas) supostamente vem de uma distribuição Exponencial(θ), em que $\theta \in \Omega = (0, \infty)$ é desconhecido. Aqui, então,

No original: *likelihood function*[22].

$\dim \Omega = 1$, e precisamos de pelo menos duas caselas para o teste qui-quadrado. O fabricante espera que a maioria das lâmpadas dure pelo menos 1000 horas, que 50% durem menos de 2000 horas e que a maioria tenha queimado até 3000 horas. Assim, com base nisso, dividimos o espaço amostral como

$$(0, \infty) = (0, 1] \cup (1, 2] \cup (2, 3] \cup (3, \infty).$$

Suponha que foi tomada uma amostra de $n = 30$ lâmpadas e que se obtiveram as contagens $x_1 = 5$, $x_2 = 16$, $x_3 = 8$ e $x_4 = 1$ para os quatro intervalos, respectivamente. Então, a função de verossimilhança baseada nessas contagens é dada por

$$L(\theta \mid x_1, \ldots, x_4 0 = (1 - e^{-\theta})^5 (e^{-\theta} - e^{-2\theta})^{16} (e^{-2\theta} - e^{-3\theta})^8 (e^{-3\theta})^1,$$

*porque, por exemplo, a probabilidade de um valor cair em $(1, 2]$ é $e^{-\theta} - e^{-2\theta}$, e temos $x_2 = 16$ observações nesse intervalo. A Figura 9.1.9 é um gráfico da log-verossimilhança.

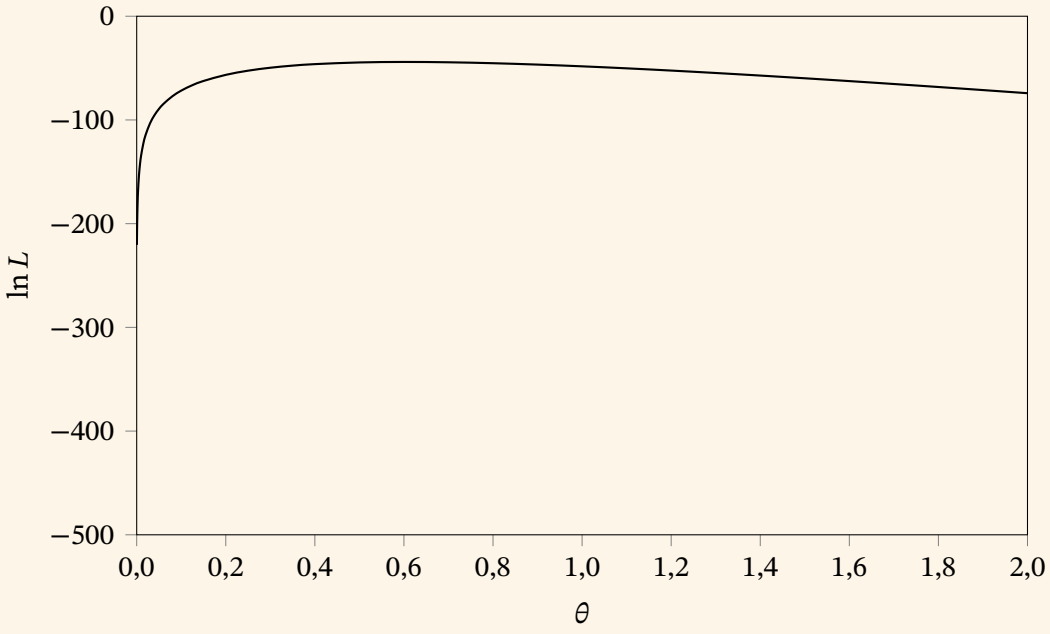


Figura 9.1.9: Gráfico da função de log-verossimilhança do Exemplo 9.1.8.

Fazendo sucessivamente o gráfico da verossimilhança em intervalos cada vez menores, determinou-se que o EMV é $\hat{\theta} = 0{,}603535$. Esse valor leva às

probabilidades

$$\begin{aligned} p_1(\hat{\theta}) &= 1 - e^{-0,603535} = 0,453125, \\ p_2(\hat{\theta}) &= e^{-0,603535} - e^{-2(0,603535)} = 0,247803, \\ p_3(\hat{\theta}) &= e^{-2(0,603535)} - e^{-3(0,603535)} = 0,135517, \\ p_4(\hat{\theta}) &= e^{-3(0,603535)} = 0,163555, \end{aligned}$$

aos valores ajustados

$$\begin{aligned} 30p_1(\hat{\theta}) &= 13,59375, \\ 30p_2(\hat{\theta}) &= 7,43409, \\ 30p_3(\hat{\theta}) &= 4,06551, \\ 30p_4(\hat{\theta}) &= 4,90665, \end{aligned}$$

e aos resíduos padronizados

$$\begin{aligned} r_1(\hat{\theta}) &= (5 - 13,59375)/\sqrt{30(0,453125)(1 - 0,453125)} = -3,151875, \\ r_2(\hat{\theta}) &= (16 - 7,43409)/\sqrt{30(0,247803)(1 - 0,247803)} = 3,622378, \\ r_3(\hat{\theta}) &= (8 - 4,06551)/\sqrt{30(0,135517)(1 - 0,135517)} = 2,098711, \\ r_4(\hat{\theta}) &= (1 - 4,90665)/\sqrt{30(0,163555)(1 - 0,163555)} = -1,928382. \end{aligned}$$

Observe que dois dos resíduos padronizados parecem grandes. Por fim, calculamos

$$\begin{aligned} X_0^2 &= (1 - 0,453125)(-3,151875)^2 + (1 - 0,247803)(3,622378)^2 \\ &\quad + (1 - 0,135517)(2,098711)^2 + (1 - 0,163555)(-1,928382)^2 \\ &= 22,221018 \end{aligned}$$

e

$$P(X^2 \geq 22,221018) = 0,0000$$

quando $X^2 \sim \chi^2(2)$. Portanto, temos forte evidência de que o modelo Exponencial(θ) não está correto para esses dados, e não usaríamos esse modelo para fazer inferência sobre θ.

Observe que usamos o EMV de θ baseado nos dados de contagem, e não na amostra original! Se, em vez disso, usássemos o EMV de θ baseado na amostra original (neste caso, igual a $\bar{x}$ e muito mais fácil de calcular), então o Teorema 9.1.2 deixaria de ser válido. ■

*__Nota do tradutor.__ O original traz "x_40 ="; pelo contexto, seria "x_4) =".

O teste qui-quadrado de aderência é apenas uma das muitas estatísticas de discrepância que foram propostas para a verificação de modelos na literatura estatística. A abordagem geral é selecionar uma estatística de discrepância D, como X^2, tal que a distribuição exata ou assintótica de D não dependa de θ e seja conhecida. Calculamos então um valor-p baseado em D. O *teste de Kolmogorov–Smirnov* e o *teste de Cramer–von Mises* são outros exemplos dessas estatísticas de discrepância, mas não os discutimos aqui.

9.1.3 Predição e Validação Cruzada

Talvez o teste mais rigoroso a que um modelo ou uma teoria científica pode ser submetido seja avaliar quão bem ele prediz dados novos depois de ter sido ajustado a um conjunto de dados independente. De fato, essa é uma etapa crucial na aceitação de qualquer teoria científica nova desenvolvida empiricamente — para ser aceita, ela precisa predizer resultados novos, além dos dados que levaram à sua formulação.

Se um modelo não faz um bom trabalho ao predizer dados novos, é razoável dizer que temos evidência contra a correção do modelo. Se o modelo for simples demais, o modelo ajustado vai subajustar os dados observados e também os dados futuros. Se o modelo for complicado demais, ele vai sobreajustar os dados originais, e isso será detectado quando considerarmos os dados novos à luz desse modelo ajustado.

Em aplicações estatísticas, em geral não podemos esperar até que dados novos sejam gerados para verificar o modelo. Por isso, os estatísticos usam uma técnica chamada *validação cruzada*[23]. Para isso, dividimos um conjunto de dados original $x_1, \ldots, x_n$ em duas partes: o *conjunto de treinamento*[24] T, formado por k dos valores dos dados e usado para ajustar o modelo; e o *conjunto de validação*[25] V, formado pelos $n - k$ valores restantes. Com base nos dados de treinamento, construímos preditores de vários aspectos dos dados de validação. Usando as discrepâncias entre os valores preditos e os reais, avaliamos então se o conjunto de validação V é ou não surpreendente como uma possível amostra futura do modelo.

É claro que existem

$$\binom{n}{k}$$

divisões possíveis desse tipo dos dados, e não gostaríamos de tomar uma decisão com base em apenas uma delas. Assim, uma análise de validação

No original: *cross-validation*[23], *training set*[24], *validation set*[25].

cruzada terá de levar isso em conta. Além disso, teremos de decidir como medir as discrepâncias entre T e V e escolher um valor para k. Não aprofundamos mais esse tema neste texto.

9.1.4 O Que Fazemos Quando um Modelo Falha?

Até aqui nos preocupamos em determinar se um modelo suposto é ou não apropriado, dados os dados observados. Suponha que o resultado da nossa verificação do modelo[26] seja que decidimos que um determinado modelo é *inapropriado*. O que fazemos agora?

Talvez a resposta óbvia seja dizer que temos de encontrar um modelo mais apropriado — um que passe na nossa verificação do modelo. Não é óbvio como devemos proceder, mas os estatísticos desenvolveram algumas técnicas.

Uma das técnicas mais simples é o *método das transformações*. Por exemplo, suponha que observamos uma amostra $y_1, \ldots, y_n$ da distribuição dada por $Y = \exp(X)$ com $X \sim N(\mu, \sigma^2)$. Um gráfico de probabilidade normal baseado nos y_i, como na Figura 9.1.10, vai detectar evidência de não normalidade da distribuição. Transformar esses valores y_i em $\ln y_i$, porém, vai produzir um gráfico de probabilidade normal de aparência razoável, como na Figura 9.1.11.

Assim, nesse caso, uma transformação simples da amostra produz um conjunto de dados que passa nessa verificação. Na verdade, isso é algo que os estatísticos fazem com frequência. Várias transformações da família das *transformações de potência*, dadas por Y^p para $p \neq 0$, ou a transformação logarítmica $\ln Y$, são testadas para ver se uma suposição sobre a distribuição pode ser satisfeita por uma amostra transformada. Veremos algumas aplicações disso no Capítulo 10. Surpreendentemente, essa técnica simples muitas vezes funciona, embora não haja garantia de que sempre funcionará.

Talvez a transformação mais aplicada seja a logarítmica, quando os valores dos dados são positivos (note que isso é uma necessidade para essa transformação). Outra transformação muito comum é a da raiz quadrada, isto é, $p = 1/2$, quando temos dados de contagem. É claro que não é correto testar muitas, muitas transformações até encontrar uma que faça os gráficos de probabilidade ou os gráficos de resíduos parecerem aceitáveis. Em vez disso, testamos algumas transformações simples.

No original: *model checking*[26].

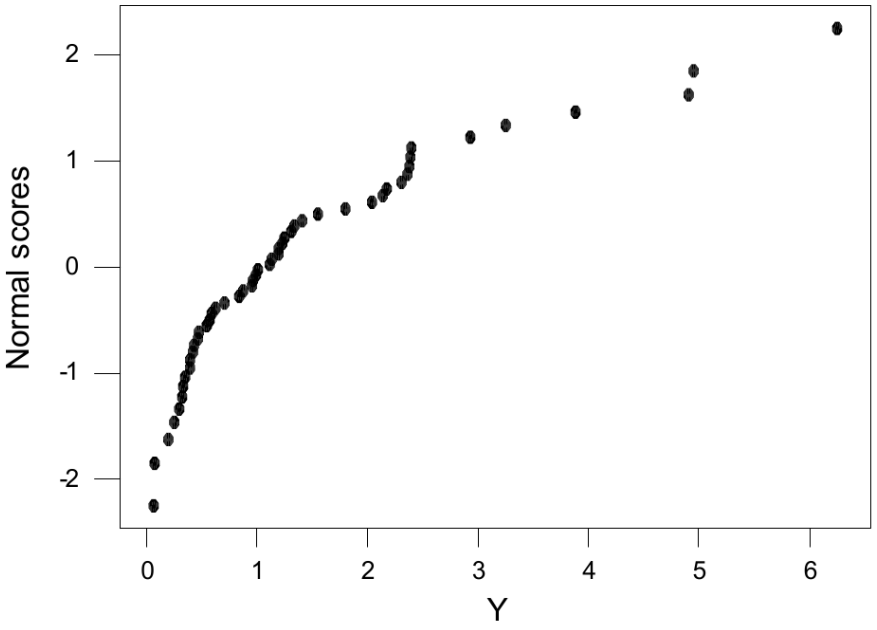


Figura 9.1.10: Gráfico de probabilidade normal de uma amostra de $n = 50$ da distribuição dada por $Y = \exp(X)$ com $X \sim N(0, 1)$.

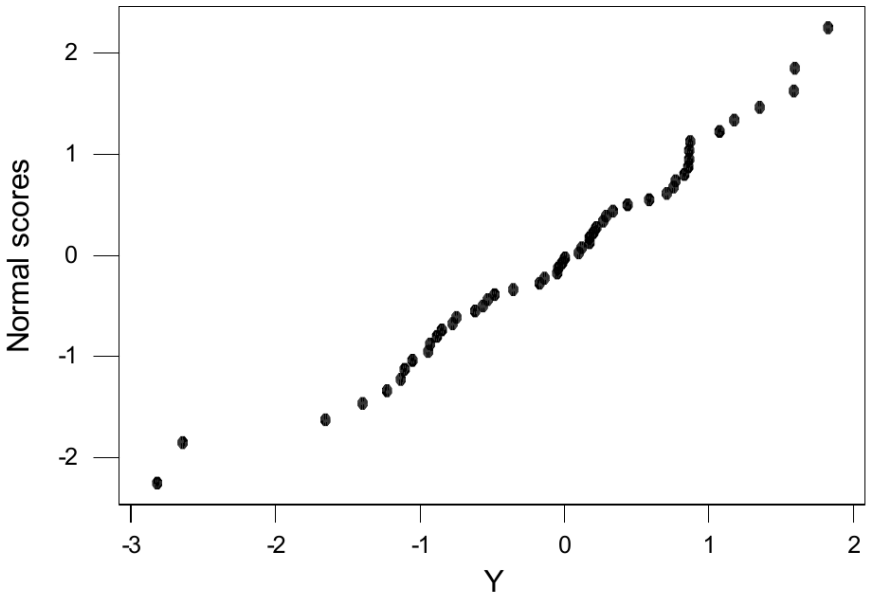


Figura 9.1.11: Gráfico de probabilidade normal de uma amostra de $n = 50$ da distribuição dada por $\ln Y$, em que $Y = \exp(X)$ e $X \sim N(0, 1)$.

Resumo da Seção 9.1

- A verificação do modelo é um componente fundamental da aplicação prática da estatística.
- Uma abordagem para a verificação do modelo consiste em escolher uma estatística de discrepância D e depois avaliar se o valor observado de D é ou não surpreendente, calculando um valor-p.
- O cálculo do valor-p exige que a distribuição de D seja conhecida sob a suposição de que o modelo é correto. Há duas abordagens para conseguir isso. Uma consiste em escolher D ancilar, e a outra consiste em calcular o valor-p usando a distribuição condicional dos dados dada a estatística suficiente minimal.
- A estatística qui-quadrado de aderência é uma estatística de discrepância muito usada. Para amostras grandes, com as contagens esperadas das caselas determinadas pelo EMV baseado na verossimilhança multinomial, a estatística qui-quadrado de aderência é aproximadamente ancilar.
- Há também muitos métodos informais de verificação do modelo baseados em diversos gráficos de resíduos.
- Se um modelo é rejeitado, há várias técnicas para modificá-lo. Em geral, elas envolvem transformações dos dados. Além disso, um modelo que falha num procedimento de verificação ainda pode ser útil, se o desvio em relação ao modelo correto for pequeno.

Exercícios

9.1.1 Suponha que se admite que a amostra a seguir vem de uma distribuição $N(\theta, 4)$, com $\theta \in R^1$ desconhecido.

1,8	2,1	−3,8	−1,7	−1,3	1,1	1,0	0,0	3,3	1,0
−0,4	−0,1	2,3	−1,6	1,1	−1,3	3,3	−4,9	−1,1	1,9

Verifique esse modelo usando a estatística de discrepância do Exemplo 9.1.1.

9.1.2 Suponha que se admite que a amostra a seguir vem de uma distribuição $N(\theta, 2)$, com θ desconhecido.

−0,4	1,9	−0,3	−0,2	0,0	0,0	−0,1	−1,1	2,0	0,4

(a) Faça o gráfico dos resíduos padronizados.

(b) Construa um gráfico de probabilidade normal dos resíduos padronizados.

(c) Que conclusões você tira com base nos resultados dos itens (a) e (b)?

9.1.3 Suponha que se admite que a amostra a seguir vem de uma distribuição $N(\mu, \sigma^2)$, em que $\mu \in R^1$ e $\sigma^2 > 0$ são desconhecidos.

14,0	9,4	12,1	13,4	6,3	8,5	7,1	12,4	13,3	9,1

(a) Faça o gráfico dos resíduos padronizados.

(b) Construa um gráfico de probabilidade normal dos resíduos padronizados.

(c) Que conclusões você tira com base nos resultados dos itens (a) e (b)?

9.1.4 Suponha que a tabela a seguir foi obtida classificando os membros de uma amostra de $n = 10$ de uma população de estudantes segundo as variáveis de classificação A e B, em que $A = 0, 1$ indica homem, mulher e $B = 0, 1$ indica conservador, liberal.

	$B = 0$	$B = 1$
$A = 0$	2	1
$A = 1$	3	4

Verifique o modelo que diz que gênero e orientação política são independentes, usando o teste exato de Fisher.

9.1.5 A amostra de $n = 20$ a seguir deveria vir de uma distribuição Uniforme[27]$[0, 1]$.

0,11	0,56	0,72	0,18	0,26	0,32	0,42	0,22	0,96	0,04
0,45	0,22	0,08	0,65	0,32	0,88	0,76	0,32	0,21	0,80

Depois de agrupar os dados, usando uma partição em cinco intervalos de mesmo comprimento, faça o teste qui-quadrado de aderência para avaliar se temos ou não evidência contra essa suposição. Registre os resíduos padronizados.

9.1.6 Suponha que um dado é lançado 1000 vezes e que se obtêm as seguintes frequências para o número de pontos na face de cima quando o dado para.

No original: *uniform distribution*[27].

x_1	x_2	x_3	x_4	x_5	x_6
163	178	142	150	183	184

Usando o teste qui-quadrado de aderência, avalie se temos evidência de que esse dado não é simétrico. Registre os resíduos padronizados.

9.1.7 Suponha que o espaço amostral de uma resposta é dado por $S = \{0, 1, 2, 3, \ldots\}$.

(a) Suponha que um estatístico acredita que, na verdade, a resposta vai estar no conjunto $S = \{10, 11, 12, 13, \ldots\}$ e, por isso, escolhe uma medida de probabilidade P que reflete isso. Quando os dados são coletados, porém, observa-se o valor $s = 3$. Qual é um valor-p apropriado para informar como medida de quão surpreendente esse valor é como valor possível de P?

(b) Suponha, em vez disso, que P seja uma distribuição Geométrica(0,1). Determine um valor-p apropriado para informar como medida de quão surpreendente $s = 3$ é como valor possível de P.

9.1.8 Suponha que observamos $s = 3$ caras em $n = 10$ lançamentos independentes de uma moeda supostamente honesta. Calcule um valor-p que avalie quão surpreendente esse valor é como valor possível da distribuição prescrita. Não use o teste qui-quadrado.

9.1.9 Suponha que você verifica um modelo calculando um valor-p baseado em alguma estatística de discrepância e conclui que não há evidência contra o modelo. Isso significa que o modelo é correto? Explique sua resposta.

9.1.10 Suponha que lhe dizem que as notas padronizadas numa prova têm distribuição $N(0, 1)$. A nota padronizada de um estudante é -4. Calcule um valor-p apropriado para avaliar se a afirmação é ou não correta.

9.1.11 Afirma-se que uma moeda está sendo lançada em lançamentos independentes. Você está um tanto cético quanto à independência dos lançamentos, porque sabe que algumas pessoas treinam o lançamento de moedas para aumentar a frequência de obter cara. Assim, você quer avaliar a independência de $(x_1, \ldots, x_n)$ de uma distribuição Bernoulli(θ).

(a) Mostre que a distribuição condicional de $(x_1, \ldots, x_n)$ dado $\bar{x}$ é uniforme no conjunto de todas as sequências de comprimento n com entradas em $\{0, 1\}$.

(b) Usando essa distribuição condicional, determine a distribuição do número de 1s observados nas primeiras $\lfloor n/2 \rfloor$ observações. (Sugestão: a distribuição hipergeométrica.)

(c) Suponha que você observa $(1, 1, 1, 1, 1, 0, 0, 0, 0, 1)$. Calcule um valor-p apropriado para avaliar a independência desses lançamentos usando (b).

Exercícios computacionais

9.1.12 Para os dados do Exercício 9.1.1, apresente um gráfico de probabilidade normal dos resíduos padronizados e comente-o.

9.1.13 Gere 25 amostras da distribuição $N(0, 1)$ com $n = 10$ e observe seus gráficos de probabilidade normal. Tire as conclusões gerais que puder.

9.1.14 Suponha que a tabela a seguir foi obtida classificando os membros de uma amostra de $n = 100$ de uma população de estudantes segundo as variáveis de classificação A e B, em que $A = 0, 1$ indica homem, mulher e $B = 0, 1$ indica conservador, liberal.

	$B = 0$	$B = 1$
$A = 0$	20	15
$A = 1$	36	29

Verifique o modelo de que gênero e orientação política são independentes usando o teste exato de Fisher.

9.1.15 Usando um software, gere uma amostra de $n = 1000$ da distribuição Binomial(10; 0,2). Depois, usando o teste qui-quadrado de aderência, verifique que essa amostra vem de fato dessa distribuição. Use agrupamento para garantir que $E(X_i) = np_i \geq 1$. O que você concluiria se obtivesse um valor-p próximo de 0?

9.1.16 Usando um pacote estatístico, gere uma amostra de $n = 1000$ da distribuição Poisson(5). Depois, usando o teste qui-quadrado de aderência baseado no agrupamento das observações em cinco caselas escolhidas para garantir que $E(X_i) = np_i \geq 1$, verifique que essa amostra vem de fato dessa distribuição. O que você concluiria se obtivesse um valor-p próximo de 0?

9.1.17 Usando um pacote estatístico, gere uma amostra de $n = 1000$ da distribuição $N(0, 1)$. Depois, usando o teste qui-quadrado de aderência baseado no agrupamento das observações em cinco caselas escolhidas para garantir que $E(X_i) = np_i \geq 1$, verifique que essa amostra vem de fato dessa distribuição. O que você concluiria se obtivesse um valor-p próximo de 0?

Problemas

9.1.18 (*Distribuição normal multivariada*[28]) Diz-se que um vetor aleatório $Y = (Y_1, \dots, Y_k)$ tem distribuição normal multivariada com vetor de médias $\mu \in R^k$ e matriz de variâncias $\Sigma = (\sigma_{ij}) \in R^{k\times k}$ se

$$a_1Y_1 + \cdots + a_kY_k \sim N\left(\sum_{i=1}^{k} a_i\mu_i, \sum_{i=1}^{k}\sum_{j=1}^{k} a_ia_j\sigma_{ij}\right)$$

para toda escolha de $a_1, \dots, a_k \in R^1$. Escrevemos $Y \sim N_k(\mu, \Sigma)$. Prove que $E(Y_i) = \mu_i$, $\text{Cov}(Y_i, Y_j) = \sigma_{ij}$ e que $Y_i \sim N(\mu_i, \sigma_{ii})$. (Sugestão: Teorema 3.3.4.)

9.1.19 No Exemplo 9.1.1, prove que o resíduo $R = (R_1, \dots, R_n)$ tem distribuição normal multivariada (veja o Problema 9.1.18) com vetor de médias $\mu = (0, \dots, 0)$ e matriz de variâncias $\Sigma = (\sigma_{ij}) \in R^{k\times k*}$, em que $\sigma_{ij} = -\sigma_0^2/n$ quando $i \neq j$ e $\sigma_{ii} = \sigma_0^2(1 - 1/n)$. (Sugestão: Teorema 4.6.1.)

9.1.20 Se $Y = (Y_1, \dots, Y_k)$ tem distribuição normal multivariada com vetor de médias $\mu \in R^k$ e matriz de variâncias $\Sigma = (\sigma_{ij}) \in R^{k\times k}$, e se $X = (X_1, \dots, X_l)$ tem distribuição normal multivariada com vetor de médias $\nu \in R^l$ e matriz de variâncias $\Upsilon = (\tau_{ij}) \in R^{l\times l}$, pode-se mostrar que Y e X são independentes sempre que $\sum_{i=1}^{k} a_iY_i$ e $\sum_{i=1}^{l} b_iX_i$ forem independentes para toda escolha de $(a_1, \dots, a_k)$ e $(b_1, \dots, b_l)$. Use esse fato para mostrar que, no Exemplo 9.1.1, $\bar{X}$ e R são independentes. (Sugestão: Teorema 4.6.2 e Problema 9.1.19.)

9.1.21 No Exemplo 9.1.4, prove que $(\hat{\alpha}_1, \hat{\beta}_1) = (x_{1\cdot}/n, x_{\cdot 1}/n)$ é o EMV.

9.1.22 No Exemplo 9.1.4, prove que o número de amostras que satisfazem as restrições (9.1.2) é igual a

$$\binom{n}{x_{1\cdot}}\binom{n}{x_{\cdot 1}}.$$

(Sugestão: usando i para a contagem x_{11}, mostre que o número dessas amostras é igual a

$$\binom{n}{x_{1\cdot}} \sum_{i=\max\{0,\, x_{1\cdot}+x_{\cdot 1}-n\}}^{\min\{x_{1\cdot},\, x_{\cdot 1}\}} \binom{x_{1\cdot}}{i}\binom{n-x_{1\cdot}}{x_{\cdot 1}-i}$$

e some isso usando o fato de que a soma das probabilidades da distribuição Hipergeométrica$(n, x_{\cdot 1}, x_{1\cdot})$ é igual a 1.)

*__Nota do tradutor.__ O original traz $R^{k\times k}$; pela dimensão de R seria $R^{n\times n}$

No original: *multivariate normal distribution*[28].

Problemas computacionais

9.1.23 Para os dados do Exercício 9.1.3, faça uma simulação para estimar o valor-p da estatística de discrepância do Exemplo 9.1.2. Faça um histograma de densidade dos valores simulados. (Sugestão: veja o Apêndice B para o código apropriado.)

9.1.24 Com $n = 10$, gere 10^4 valores da estatística de discrepância do Exemplo 9.1.2 quando temos uma amostra de uma distribuição $N(0,1)$. Faça um histograma de densidade com eles. Repita isso, mas agora gerando de uma distribuição de Cauchy[29]. Compare os histogramas (não se esqueça de garantir que os dois gráficos tenham as mesmas escalas).

9.1.25 Os dados a seguir deveriam vir de uma distribuição Exponencial(θ), em que $\theta > 0$ é desconhecido.

1,5	1,6	1,4	9,7	12,1	2,7	2,2	1,6	6,8	0,1
0,8	1,7	8,0	0,2	12,3	2,2	0,2	0,6	10,1	4,9

Verifique esse modelo usando um teste qui-quadrado de aderência baseado nos intervalos

$$(-\infty; 2{,}0], (2{,}0; 4{,}0], (4{,}0; 6{,}0], (6{,}0; 8{,}0], (8{,}0; 10{,}0], (10{,}0; \infty).$$

(Sugestão: calcule o EMV fazendo o gráfico da log-verossimilhança[30] em intervalos sucessivamente menores.)

9.1.26 A tabela a seguir, tirada de *Introduction to the Practice of Statistics*, de D. Moore e G. McCabe (W. H. Freeman, Nova York, 1999), dá as medidas, em miligramas, da ingestão diária de cálcio de 38 mulheres com idades entre 18 e 24 anos.

808	882	1062	970	909	802	374	416	784	997
651	716	438	1420	1425	948	1050	976	572	403
626	774	1253	549	1325	446	465	1269	671	696
1156	684	1933	748	1203	2433	1255	110		

(a) Suponha que o modelo especifica um modelo normal de locação para esses dados com $\sigma_0^2 = (500)^2$. Faça um teste qui-quadrado de aderência nesses dados usando os intervalos $(-\infty, 600]$, $(600, 1200]$,

No original: *Cauchy*[29], *log-likelihood*[30].

$(1200, 1800]$, $(1800, \infty)$. (Sugestão: faça o gráfico da log-verossimilhança em intervalos sucessivamente menores para determinar o EMV com cerca de uma casa decimal. Para determinar o intervalo inicial do gráfico, use do EMV global de μ menos três erros padrão até o EMV global mais três erros padrão.)

(b) Compare o EMV de μ obtido no item (a) com o EMV dos dados não agrupados.

(c) Seria mais realista supor que a variância σ^2 também é desconhecida. Registre a log-verossimilhança dos dados agrupados. (Métodos numéricos mais sofisticados são necessários para encontrar o EMV de (μ, σ^2) nesse caso.)

9.1.27 Gere 10^4 valores das estatísticas de discrepância D_{skew} e D_{kurtosis} do Exemplo 9.1.2 quando temos uma amostra de $n = 10$ de uma distribuição $N(0, 1)$. Faça histogramas de densidade com eles. Indique como você usaria esses histogramas para avaliar a suposição de normalidade quando tivéssemos uma amostra real de tamanho 10. Repita isso para $n = 20$ e compare as distribuições.

Desafios

9.1.28 (MV) Prove que, quando $(x_1, \ldots, x_n)$ é uma amostra da distribuição dada por $\mu + \sigma Z$, em que Z tem uma distribuição conhecida e $(\mu, \sigma^2) \in R^1 \times (0, \infty)$ é desconhecido, a estatística

$$r(x_1, \ldots, x_n) = \left(\frac{x_1 - \bar{x}}{s}, \ldots, \frac{x_n - \bar{x}}{s} \right)$$

é ancilar. (Sugestão: escreva um elemento da amostra como $x_i = \mu + \sigma z_i$ e depois mostre que $r(x_1, \ldots, x_n)$ pode ser escrita como função dos z_i.)

9.2 Verificação de Conflito entre a Priori e Dados

A metodologia bayesiana acrescenta a medida de probabilidade a priori[31] Π ao modelo estatístico $\{P_\theta : \theta \in \mathbf{\Omega}\}$, para a análise estatística subsequente. Os métodos da Seção 9.1 foram concebidos para verificar se os dados observados

No original: *prior*[31].

podem, de forma realista, ser considerados provenientes de uma distribuição em $\{P_\theta : \theta \in \mathbf{\Omega}\}$. Ao acrescentar a priori, estamos, na prática, dizendo que o nosso conhecimento sobre a distribuição verdadeira nos leva a atribuir a probabilidade preditiva a priori[32] M, dada por $M(A) = E_\Pi(P_\theta(A))$ para $A \subset \mathbf{\Omega}$, para descrever o processo que gera os dados. Pareceria, então, que uma abordagem bayesiana sensata de verificação do modelo seria comparar os dados observados s com a distribuição dada por M, para ver se eles são surpreendentes ou não.

Suponha que concluíssemos que o modelo bayesiano é incorreto depois de decidir que s é um valor surpreendente segundo M. Isso nos diz apenas, porém, que é improvável que a medida de probabilidade M tenha produzido os dados, e não que o modelo $\{P_\theta : \theta \in \mathbf{\Omega}\}$ estava errado. Considere o exemplo a seguir.

No original: *prior predictive*[32].

Exemplo 9.2.1 — Conflito entre a Priori e Dados

Suponha que obtemos uma amostra formada por $n = 20$ valores de $s = 1$ do modelo com $\boldsymbol{\Omega} = \{1, 2\}$ e funções de probabilidade da resposta básica dadas pela tabela a seguir.

	$s = 0$	$s = 1$
$f_1(s)$	0,9	0,1
$f_2(s)$	0,1	0,9

Então a probabilidade de obter essa amostra de f_2 é dada por $(0{,}9)^{20} = 0{,}12158$, que é um valor razoável; portanto, não temos evidência contra o modelo $\{f_1, f_2\}$.

Suponha que colocamos em $\boldsymbol{\Omega}$ uma priori dada por $\Pi(\{1\}) = 0{,}9999$, de modo que estamos praticamente certos de que $\theta = 1$. Então a probabilidade de obter esses dados da preditiva a priori M é

$$(0{,}9999)\,(0{,}1)^{20} + (0{,}0001)\,(0{,}9)^{20} = 1{,}2158 \times 10^{-5}.$$

A probabilidade a priori de observar uma amostra de 20 cuja probabilidade preditiva a priori não seja maior que $1{,}2158 \times 10^{-5}$ pode ser calculada (usando um software estatístico para tabelar a preditiva a priori) e é de aproximadamente 0,04. Isso nos diz que os dados observados estão "nas caudas" da preditiva a priori e, portanto, são surpreendentes, o que nos leva a concluir que temos evidência de que M é incorreta.

Assim, neste exemplo, verificar o modelo $\{f_\theta : \theta \in \boldsymbol{\Omega}\}$ nos leva a concluir que ele é plausível para os dados observados. Por outro lado, verificar o modelo dado por M nos leva à conclusão de que o modelo bayesiano é implausível. ■

A lição do Exemplo 9.2.1 é que o modelo pode falhar de duas maneiras no contexto bayesiano. Primeiro, os dados s podem ser surpreendentes à luz do modelo $\{f_\theta : \theta \in \boldsymbol{\Omega}\}$. Segundo, mesmo quando os dados provêm plausivelmente desse modelo, a priori e os dados podem estar em conflito. Esse conflito ocorre sempre que a priori atribui a maior parte da sua probabilidade a distribuições do modelo para as quais os dados são surpreendentes. Em qualquer das duas situações, as inferências tiradas do modelo bayesiano podem ser falhas.

Se, no entanto, a priori atribui probabilidade (ou densidade) positiva a todo valor possível de θ, então os resultados de consistência da inferência bayesiana mencionados no Capítulo 7 indicam que uma grande quantidade de

dados supera um conflito entre a priori e dados[33] (ver o Exemplo 9.2.4). Isso acontece porque o efeito da priori diminui à medida que a quantidade de dados aumenta. Assim, a existência de um conflito entre a priori e dados não significa necessariamente que as nossas inferências estejam erradas. Ainda assim, é útil saber se esse conflito existe ou não, pois muitas vezes é difícil detectar se temos ou não dados suficientes para evitar o problema.

Portanto, devemos primeiro usar as verificações discutidas na Seção 9.1 para garantir que os dados s provêm plausivelmente do modelo $\{f_\theta : \theta \in \mathbf{\Omega}\}$. Se aceitamos o modelo, procuramos então algum conflito entre a priori e dados. Vejamos agora como fazer isso.

A distribuição preditiva a priori de qualquer estatística ancilar é igual à sua distribuição sob o modelo amostral[34], isto é, a sua distribuição preditiva a priori não é afetada pela escolha da priori. Assim, o valor observado de uma estatística ancilar não pode nos dizer nada sobre a existência de um conflito entre a priori e dados. Concluímos daí que, se vamos usar alguma função dos dados para avaliar se há ou não conflito entre a priori e dados, então a distribuição marginal[35] dela tem de depender de θ.

Mostramos agora que a distribuição condicional preditiva a priori dos dados, dada uma estatística suficiente minimal[36] T, é independente da priori.

Teorema 9.2.1

Suponha que T é uma estatística suficiente para o modelo $\{f_\theta : \theta \in \mathbf{\Omega}\}$ para os dados s. Então a distribuição preditiva a priori condicional dos dados s dado T é independente da priori π.

Demonstração. Vamos demonstrar isso no caso em que cada distribuição amostral[37] f_θ e a priori π são discretas. Um argumento semelhante pode ser desenvolvido para o caso mais geral.

Pelo Teorema 6.1.1 (teorema da fatoração[38]), temos que

$$f_\theta(s) = h(s)\, g_\theta(T(s))$$

para certas funções g_θ e h. Portanto, a função de probabilidade[39] preditiva a priori de s é dada por

$$m(s) = h(s) \sum_{\theta \in \mathbf{\Omega}} g_\theta(T(s))\, \pi(\theta).$$

No original: *prior–data conflict*[33], *sampling model*[34], *marginal distribution*[35], *minimal sufficient statistic*[36], *sampling distribution*[37], *factorization theorem*[38], *probability function*[39].

A função de probabilidade preditiva a priori de T em t é dada por

$$m^*(t) = \sum_{\{s:T(s)=t\}} h(s) \sum_{\theta\in\Omega} g_\theta(t)\,\pi(\theta).$$

Portanto, a função de probabilidade preditiva a priori condicional dos dados s dado $T(s) = t$ é

$$m(s \mid T = t) = \frac{h(s)\sum_{\theta\in\Omega} g_\theta(t)\,\pi(\theta)}{\sum_{\{s':T(s')=t\}} h(s')\sum_{\theta\in\Omega} g_\theta(t)\,\pi(\theta)} = \frac{h(s)}{\sum_{\{s':t(s')=t\}} h(s')},$$

que é independente de π.* ■

Assim, pelo Teorema 9.2.1, concluímos que nenhum aspecto dos dados além do valor de uma estatística suficiente minimal pode nos dizer algo sobre a existência de um conflito entre a priori e dados. Portanto, se quisermos basear a nossa verificação de conflito entre a priori e dados na preditiva a priori, devemos usar a preditiva a priori de uma estatística suficiente minimal. Considere os exemplos a seguir.

Exemplo 9.2.2 — Verificação de uma Priori Beta para um Modelo de Bernoulli

Suponha que $(x_1, \ldots, x_n)$ é uma amostra de um modelo Bernoulli(θ), em que $\theta \in [0,1]$ é desconhecido, e que θ recebe uma distribuição a priori Beta(α, β). Temos então que a contagem amostral $y = \sum_{i=1}^n x_i$ é uma estatística suficiente minimal com distribuição Binomial(n, θ). Portanto, a função de probabilidade preditiva a priori de y é dada por

$$\begin{aligned} m(y) &= \binom{n}{y}\int_0^1 \theta^y(1-\theta)^{n-y}\frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\,\Gamma(\beta)}\theta^{\alpha-1}(1-\theta)^{\beta-1}\,d\theta \\ &= \frac{\Gamma(n+1)}{\Gamma(y+1)\,\Gamma(n-y+1)}\frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\,\Gamma(\beta)}\frac{\Gamma(y+\alpha)\,\Gamma(n-y+\beta)}{\Gamma(n+\alpha+\beta)} \\ &\propto \frac{\Gamma(y+\alpha)\,\Gamma(n-y+\beta)}{\Gamma(y+1)\,\Gamma(n-y+1)}. \end{aligned}$$

Observe agora que, quando $\alpha = \beta = 1$, temos $m(y) = 1/(n+1)$, isto é, a preditiva a priori de y é Uniforme$\{0, 1, \ldots, n\}$, e nenhum valor de y é surpreendente. Isso não é inesperado, pois, com a priori uniforme em θ, estamos implicitamente dizendo que qualquer contagem y é razoável.

Por outro lado, quando $\alpha = \beta = 2$, a priori põe mais peso em torno de $1/2$. A preditiva a priori é então proporcional a $(y+1)(n-y+1)$. Essa preditiva a priori está representada na Figura 9.2.1 para $n = 20$.

*Nota do tradutor. No último somatório, o original traz $t(s')$ minúsculo; pelo resto da conta seria $T(s')$.

Observe que contagens próximas de 0 ou de 20 levam a evidência de que há um conflito entre os dados e a priori. Por exemplo, se obtemos a contagem $y = 3$, podemos avaliar quão surpreendente é esse valor calculando a probabilidade de obter um valor com probabilidade de ocorrência menor. Usando a simetria da preditiva a priori, temos que essa probabilidade é igual a (usando um software estatístico para o cálculo) $m(0) + m(2) + m(19) + m(20) = 0{,}0688876$.* Portanto, a observação $y = 3$ não é surpreendente ao nível de 5%.

Suponha agora que $n = 50$ e $\alpha = 2$, $\beta = 4$. A média dessa priori é $2/(2 + 4) = 1/3$, e a priori é assimétrica à direita. A preditiva a priori está representada na Figura 9.2.2. Claramente, valores de y próximos de 50 dão evidência contra o modelo neste caso. Por exemplo, se observamos $y = 35$, a probabilidade de obter uma contagem com probabilidade de ocorrência menor é dada por (usando um software estatístico para o cálculo) $m(36) + \cdots + m(50) = 0{,}0500457$.† Somente valores mais extremos que esse dariam evidência contra o modelo ao nível de 5%. ■

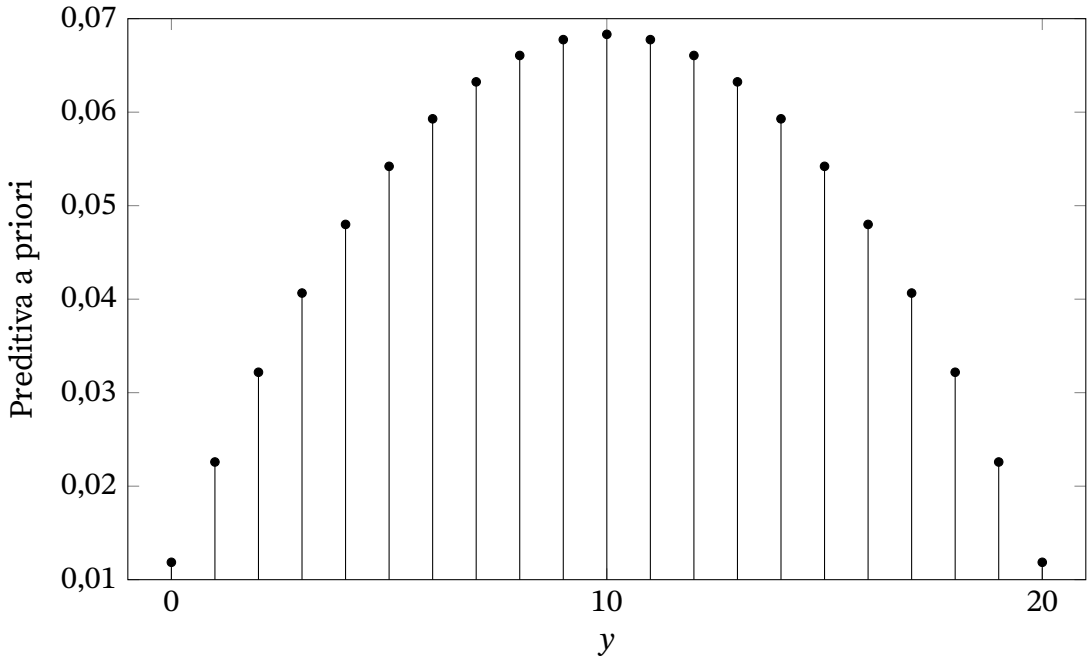


Figura 9.2.1: Gráfico da preditiva a priori da contagem amostral y no Exemplo 9.2.2 quando $\alpha = \beta = 2$ e $n = 20$.

*Nota do tradutor. O valor 0,0688876 é o de $m(0) + m(1) + m(19) + m(20)$; os valores com probabilidade menor que a de $y = 3$ dariam $m(0) + m(1) + m(2) + m(18) + m(19) + m(20) \approx 0{,}1011$.

†Nota do tradutor. Pela fórmula de $m(y)$ acima, $m(36) + \cdots + m(50) \approx 0{,}0350$; o valor 0,0500457 não confere.

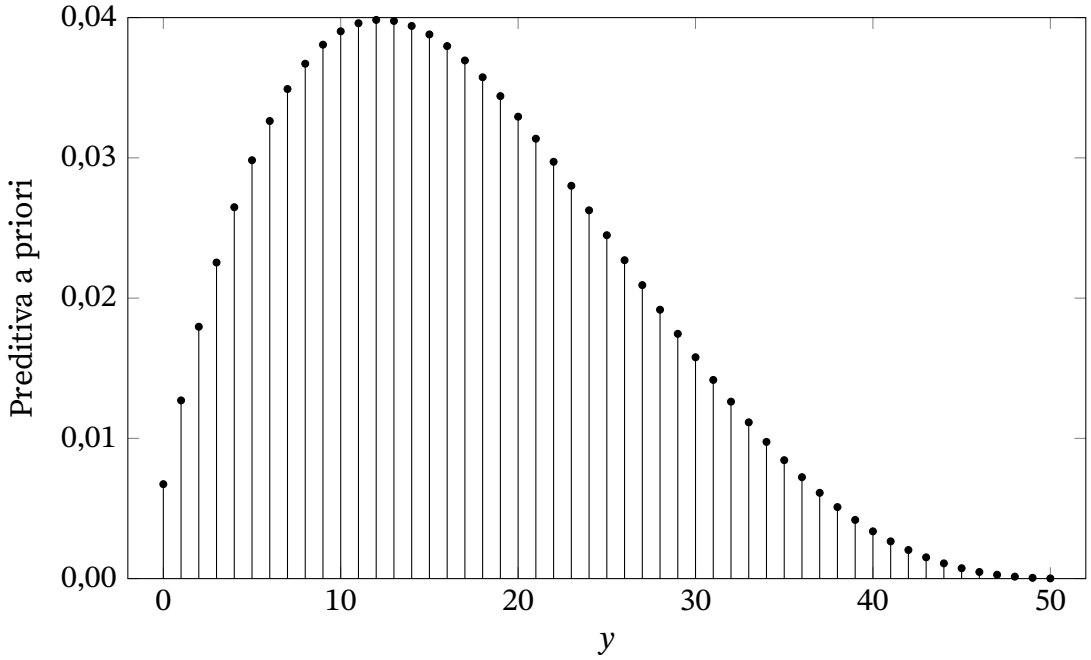


Figura 9.2.2: Gráfico da preditiva a priori da contagem amostral y no Exemplo 9.2.2 quando $\alpha = 2$, $\beta = 4$ e $n = 50$.

Exemplo 9.2.3 — Verificação de uma Priori Normal para um Modelo Normal de Locação

Suponha que $(x_1, \dots, x_n)$ é uma amostra de uma distribuição $N(\mu, \sigma_0^2)$, em que $\mu \in R^1$ é desconhecido e σ_0^2 é conhecido. Suponha que tomamos como distribuição a priori de μ uma $N(\mu_0, \tau_0^2)$, para alguma escolha especificada de μ_0 e τ_0^2. Note que $\bar{x}$ é uma estatística suficiente minimal para esse modelo; assim, precisamos comparar o valor observado dessa estatística com a sua distribuição preditiva a priori para avaliar se há ou não conflito entre a priori e dados.

Podemos escrever $\bar{x} = \mu + z$, em que $\mu \sim N(\mu_0, \tau_0^2)$ é independente de $z \sim N(0, \sigma_0^2/n)$. Daí deduzimos imediatamente (ver o Exercício 9.2.3) que a distribuição preditiva a priori de $\bar{x}$ é $N(\mu_0, \tau_0^2 + \sigma_0^2/n)$. Pela simetria da densidade preditiva a priori em torno de μ_0, vemos imediatamente que o valor-p apropriado é

$$M(|\bar{X} - \mu_0| \leq |\bar{x} - \mu_0|) = 2\big(1 - \Phi(|\bar{x} - \mu_0|/(\tau_0^2 + \sigma_0^2/n)^{1/2})\big). \tag{9.2.1}$$

Assim, um valor pequeno de (9.2.1)* é evidência de que há um conflito entre os dados observados e a priori, isto é, a priori está pondo a maior parte da sua massa em valores de μ para os quais os dados observados são surpreendentes. ■

Outra possibilidade de verificação do modelo nesse contexto é olhar para a distribuição preditiva a posteriori[40] dos dados. Considere, porém, o exemplo a seguir.

*Nota do tradutor. O original traz $\leq$ dentro de $M(\cdot)$ em (9.2.1); para o valor-p (e para bater com o lado direito) seria $|\bar{X} - \mu_0| \geq |\bar{x} - \mu_0|$.

No original: *posterior predictive*[40].

Exemplo 9.2.4 — Continuação do Exemplo 9.2.1

Lembre que, no Exemplo 9.2.1, concluímos que existia um conflito entre a priori e dados. Note, porém, que a probabilidade a posteriori de $\theta = 2$ é

$$\frac{(0{,}0001)\,(0{,}9)^{20}}{(0{,}9999)\,(0{,}1)^{20} + (0{,}0001)\,(0{,}9)^{20}} \approx 1.$$

Portanto, a probabilidade preditiva a posteriori da sequência observada de 20 valores de 1 é 0,12158, o que não indica nenhum conflito entre a priori e dados. Notamos, porém, que neste exemplo a quantidade de dados é suficiente para superar a priori; assim, somos levados a uma inferência sensata sobre θ. ■

O problema de usar a preditiva a posteriori para avaliar se existe ou não um conflito entre a priori e dados é que temos um caso do chamado *uso duplo dos dados*. Isso porque ajustamos o modelo, isto é, construímos a preditiva a posteriori, usando os dados observados, e depois tentamos usar essa preditiva a posteriori para avaliar se existe ou não um conflito entre a priori e dados. O uso duplo dos dados resulta em avaliações otimistas demais da validade do modelo bayesiano e muitas vezes não detecta discrepâncias. Não discutiremos mais a verificação do modelo a posteriori[41] neste texto.

Aqui apenas tocamos no básico da verificação de conflito entre a priori e dados. Com modelos mais complicados, existe a possibilidade de verificar componentes individuais de uma priori, por exemplo, os componentes da priori especificada no Exemplo 7.1.4 para o modelo normal de locação e escala[42], para determinar com mais precisão onde surge um conflito entre a priori e dados. Além disso, as estatísticas ancilares têm um papel na verificação de conflito entre a priori e dados, pois precisamos remover toda variação ancilar ao calcular o valor-p, já que essa variação não depende da priori. Além disso, quando a distribuição preditiva a priori de uma estatística suficiente minimal é contínua, é preciso tratar de questões sobre como exatamente os valores-p devem ser calculados. Todos esses são temas para um curso mais avançado de estatística.

No original: *posterior*[41], *location-scale normal model*[42].

Resumo da Seção 9.2

- Na inferência bayesiana, há duas fontes possíveis de incorreção do modelo. Primeiro, o modelo amostral dos dados pode estar incorreto. Segundo, mesmo que o modelo amostral esteja correto, a priori pode estar em conflito com os dados, no sentido de que a maior parte da probabilidade a priori é atribuída a distribuições do modelo para as quais os dados são surpreendentes.
- Primeiro verificamos se o modelo amostral está correto, usando os métodos da Seção 9.1. Se não encontramos evidência contra o modelo amostral, verificamos em seguida se há conflito entre a priori e dados, vendo se o valor observado de uma estatística suficiente minimal é surpreendente ou não em relação à distribuição preditiva a priori dessa quantidade.
- Mesmo que exista um conflito entre a priori e dados, as inferências a posteriori ainda podem ser válidas se tivermos dados suficientes.

Exercícios

9.2.1 Suponha que observamos o valor $s = 2$ do modelo dado pela tabela a seguir.

	$s = 1$	$s = 2$	$s = 3$
$f_1(s)$	1/3	1/3	1/3
$f_2(s)$	1/3	0	2/3

(a) Os dados observados nos levam a duvidar da validade do modelo? Explique por quê.

(b) Suponha que a priori dada por $\pi(1) = 0{,}3$ é colocada sobre o parâmetro $\theta \in \{1, 2\}$. Há alguma evidência de conflito entre a priori e dados? (Sugestão: calcule a preditiva a priori de cada conjunto de dados possível e avalie se o conjunto de dados observado é surpreendente ou não.)

(c) Repita o item (b) usando a priori dada por $\pi(1) = 0{,}01$.

9.2.2 Suponha que uma amostra de $n = 6$ é tirada de uma distribuição Bernoulli(θ), em que θ tem distribuição a priori Beta$(3, 3)$. Se for obtido o valor $n\bar{x} = 2$, determine se há algum conflito entre a priori e dados.

9.2.3 No Exemplo 9.2.3, mostre que a distribuição preditiva a priori de $\bar{x}$ é dada pela distribuição $N(\mu_0, \tau_0^2 + \sigma_0^2/n)$.

9.2.4 Suponha que temos uma amostra de $n = 5$ de uma distribuição $N(\mu, 2)$, em que μ é desconhecido, e que é observado o valor $\bar{x} = 7{,}3$. Uma priori $N(0, 1)$ é colocada sobre μ. Calcule o valor-p apropriado para verificar se há conflito entre a priori e dados.

9.2.5 Suponha que $x \sim \text{Uniforme}[0, \theta]$ e $\theta \sim \text{Uniforme}[0, 1]$. Se for observado o valor $x = 2{,}2$, determine um valor-p apropriado para verificar se há conflito entre a priori e dados.

Exercícios computacionais

9.2.6 Suponha que uma amostra de $n = 20$ é tirada de uma distribuição Bernoulli(θ), em que θ tem distribuição a priori Beta(3, 3). Se for obtido o valor $n\bar{x} = 6$, determine se há algum conflito entre a priori e dados.

Problemas

9.2.7 Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição $N(\mu, \sigma_0^2)$, em que $\mu \sim N(\mu_0, \tau_0^2)$. Determine a distribuição preditiva a priori de $\bar{x}$.

9.2.8 Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição Exponencial(θ), em que $\theta \sim \text{Gama}(\alpha_0, \beta_0)$. Determine a distribuição preditiva a priori de $\bar{x}$.

9.2.9 Suponha que $(s_1, \ldots, s_n)$ é uma amostra de uma distribuição Multinomial$(1, \theta_1, \ldots, \theta_k)$, em que $(\theta_1, \ldots, \theta_{k-1}) \sim \text{Dirichlet}(\alpha_1, \ldots, \alpha_k)$. Determine a distribuição preditiva a priori de $(x_1, \ldots, x_k)$, em que x_i é a contagem na i-ésima categoria.

9.2.10 Suponha que $(x_1, \ldots, x_n)$ é uma amostra de uma distribuição Uniforme$[0, \theta]$, em que θ tem densidade a priori dada por $\pi_{\alpha,\beta}(\theta) = \theta^{-\alpha} I_{[\beta,\infty)}(\theta)/(\alpha - 1)\beta^{\alpha-1}$, com $\alpha > 1$, $\beta > 0$.* Determine a distribuição preditiva a priori de $x_{(n)}$.

9.2.11 Suponha que estamos no contexto do Exemplo 9.2.3. Determine o valor-p limite para a verificação de conflito entre a priori e dados quando

*Nota do tradutor. Para que a densidade integre 1, o fator $(\alpha - 1)\beta^{\alpha-1}$ deveria multiplicar, e não dividir: $\pi_{\alpha,\beta}(\theta) = (\alpha - 1)\beta^{\alpha-1}\theta^{-\alpha} I_{[\beta,\infty)}(\theta)$.

$n \to \infty$. Interprete o significado desse valor-p em termos da priori e do valor verdadeiro de μ.

9.2.12 Suponha que $x \sim$ distribuição Geométrica(θ) e $\theta \sim$ Uniforme$[0, 1]$.

(a) Determine o valor-p apropriado para verificar se há conflito entre a priori e dados.

(b) Com base no valor-p determinado no item (a), descreva as circunstâncias em que haverá evidência de conflito entre a priori e dados.

(c) Se usamos uma priori contínua que é positiva num ponto, isso é uma afirmação de que o ponto é possível. À luz disso, discuta se faz sentido ou não uma priori contínua que seja positiva em $\theta = 0$ para a distribuição Geométrica(θ).

Desafios

9.2.13 Suponha que $X_1, \ldots, X_n$ é uma amostra de uma distribuição $N(\mu, \sigma^2)$, em que $\mu \mid \sigma^2 \sim N(\mu_0, \tau_0^2\sigma^2)$ e $1/\sigma^2 \sim$ Gama(α_0, β_0). Determine uma forma para a densidade preditiva a priori de $(\bar{X}, S^2)$ que você possa calcular sem integrar. (Sugestão: use as manipulações algébricas encontradas na Seção 7.5.)

9.3 O Problema das Verificações Múltiplas

Como mencionamos ao longo deste texto, a verificação do modelo faz parte da boa prática estatística. Em outras palavras, devemos sempre desconfiar do valor de um trabalho estatístico em que os pesquisadores não fizeram, e não relataram os resultados de, uma verificação do modelo razoavelmente rigorosa. Cabe de fato a quem relata resultados estatísticos nos convencer de que os seus modelos são razoáveis para os dados coletados, tendo em mente os efeitos tanto do subajuste quanto do sobreajuste.

Neste capítulo, apresentamos *algumas* das abordagens de verificação do modelo disponíveis. Concentramo-nos nas principais categorias de procedimentos e, talvez, nos métodos mais usados dentro delas. Há muitos outros. Neste ponto, não podemos dizer que alguma abordagem seja o melhor método possível. Talvez mais pesquisa sobre o tema traga uma compreensão maior nesse sentido, e então uma recomendação mais clara possa ser feita.

Uma recomendação que pode ser feita já, porém, é que não é razoável fazer a verificação do modelo aplicando todos os procedimentos de verificação do modelo possíveis. Um exemplo simples ilustra a insensatez de tal abordagem.

Exemplo 9.3.1

Suponha que $(x_1, \ldots, x_n)$ deveria ser uma amostra da distribuição $N(0,1)$. Suponha que decidimos verificar esse modelo calculando os valores-p

$$P_i = P(X_i^2 \geq x_i^2)$$

para $i = 1, \ldots, n$, em que $X_i^2 \sim \chi^2(1)$. Além disso, decidimos que o modelo é incorreto se o mínimo desses valores-p for menor que 0,05.

Considere agora o comportamento desse método em amostragens repetidas quando o modelo está correto. Temos que

$$\min\{P_1, \ldots, P_n\} < 0{,}05$$

se e somente se

$$\max\{x_1^2, \ldots, x_n^2\} \geq \chi^2_{0{,}95}(1),$$

e, portanto,

$$\begin{aligned} &P(\min\{P_1, \ldots, P_n\} < 0{,}05) \\ &\quad = P(\max\{X_1^2, \ldots, X_n^2\} \geq \chi^2_{0{,}95}(1)) = 1 - P(\max\{X_1^2, \ldots, X_n^2\} \leq \chi^2_{0{,}05}(1)) \\ &\quad = 1 - \prod_{i=1}^{n} P(X_i^2 \leq \chi^2_{0{,}95}(1)) = 1 - (0{,}95)^n \to 1 \end{aligned}$$

quando $n \to \infty$.* Isso nos diz que, se n for grande o bastante, rejeitaremos o modelo com certeza quase absoluta, mesmo ele estando correto! Note que n não precisa ser muito grande para que haja uma probabilidade apreciável de cometer um erro. Por exemplo, quando $n = 10$, a probabilidade de cometer um erro é 0,40; quando $n = 20$, a probabilidade de cometer um erro é 0,64; e, quando $n = 100$, a probabilidade de cometer um erro é 0,99. ■

Podemos aprender uma lição importante com o Exemplo 9.3.1: se realizamos procedimentos de verificação do modelo demais, é quase certo que encontraremos algo errado, mesmo que o modelo esteja correto. O remédio para isso é decidir, antes de observar os dados de fato (para que as nossas escolhas não sejam determinadas pelos dados efetivamente obtidos), uns

*Nota do tradutor. Na segunda linha, o original traz $\chi^2_{0{,}05}(1)$; pelo resto da conta seria $\chi^2_{0{,}95}(1)$.

poucos procedimentos relevantes de verificação do modelo a serem realizados, e aplicar somente esses.

O problema que estamos discutindo aqui às vezes é chamado de problema das *comparações múltiplas*[43], que surge também em outras situações; por exemplo, ver a Seção 10.4.1, em que várias médias são comparadas por meio de testes dois a dois para diferenças entre as médias. Uma abordagem para evitar o problema das comparações múltiplas é simplesmente baixar o ponto de corte do valor-p, de modo que a probabilidade de cometer um engano seja adequadamente pequena. Por exemplo, se decidíssemos, no Exemplo 9.3.1, que só há evidência contra o modelo quando um valor-p individual é menor que 0,0001, então a probabilidade de cometer um engano seria 0,01 quando $n = 100$. Uma dificuldade dessa abordagem, em geral, é que os nossos procedimentos de verificação do modelo não serão independentes, e nem sempre parece possível determinar um ponto de corte apropriado para os valores-p individuais. São necessários métodos mais avançados para lidar com esse problema.

Resumo da Seção 9.3

- Fazer verificações do modelo demais não é uma boa ideia, pois invariavelmente encontraremos algo que nos leve a concluir que o modelo é incorreto. Em vez de embarcar numa "expedição de pesca", em que simplesmente continuamos verificando o modelo, é melhor escolher uns poucos procedimentos antes de ver os dados e usar esses, e somente esses, na verificação do modelo.

No original: *multiple comparisons*[43].

CAPÍTULO 10

Relações entre Variáveis

ESBOÇO DO CAPÍTULO

Seção 1 Variáveis Relacionadas
Seção 2 Resposta e Preditores Categóricos
Seção 3 Resposta e Preditores Quantitativos
Seção 4 Resposta Quantitativa e Preditores Categóricos
Seção 5 Resposta Categórica e Preditores Quantitativos
Seção 6 Demonstrações Adicionais (Avançado)

Neste capítulo, tratamos daquela que talvez seja a aplicação mais importante da inferência estatística: o problema de analisar se existe ou não uma relação entre variáveis e que forma essa relação assume. Como exemplo particular disso, lembre o exemplo e a discussão da Seção 5.1.

Muitos dos problemas mais importantes da ciência e da sociedade dizem respeito a relações entre variáveis. Por exemplo, qual é a relação entre a quantidade de dióxido de carbono lançada na atmosfera e as temperaturas globais? Qual é a relação entre o tamanho da turma e o desempenho escolar dos alunos? Qual é a relação entre o peso e a ingestão de carboidratos em seres humanos? Qual é a relação entre o tempo de vida[1] e a dosagem de certo medicamento em pacientes com câncer? Todos esses são exemplos de perguntas cujas respostas envolvem relações entre variáveis. Veremos que a estatística tem um papel fundamental na resposta a perguntas como essas.

Na Seção 10.1, damos uma definição precisa do que significa dizer que variáveis estão relacionadas e distinguimos duas grandes categorias de relação, a saber, a associação e a relação de causa e efeito. Discutimos também algumas das ideias centrais envolvidas na coleta de dados quando queremos determinar se existe uma relação de causa e efeito. Nas seções restantes, examinamos as diversas metodologias estatísticas usadas para analisar dados quando estamos interessados em relações.

Neste capítulo, damos ênfase às metodologias frequentistas. Damos alguns exemplos da abordagem bayesiana, mas há certas complexidades nos

No original: *lifelength*[1].

problemas distribucionais associados aos métodos bayesianos que é melhor evitar nesta etapa. Já foram desenvolvidos algoritmos de amostragem para a abordagem bayesiana, nos moldes dos discutidos no Capítulo 7 (ver também o Capítulo 11), mas uma discussão completa deles nos levaria além do escopo deste texto. Vale notar, porém, que análises bayesianas com prioris difusas muitas vezes produzem resultados muito parecidos com os obtidos pela abordagem frequentista.

Como discutido no Capítulo 9, a verificação do modelo[2] é uma parte importante de qualquer análise estatística. Para os modelos usados neste capítulo, uma discussão completa da abordagem mais rigorosa da verificação do modelo, baseada em valores-p, exige mais desenvolvimento do que podemos fazer neste texto. Por isso, damos ênfase à abordagem informal da verificação do modelo, por meio de gráficos de resíduos e de probabilidade. Isso não deve ser interpretado como uma recomendação de que esses sejam os métodos preferidos para tais modelos.

10.1 Variáveis Relacionadas

Considere uma população Π com duas variáveis $X, Y : \Pi \to R^1$ definidas nela. O que significa dizer que as variáveis X e Y estão relacionadas? Talvez nossa primeira inclinação seja dizer que deve haver uma fórmula que relacione as duas variáveis, como $Y = a + bX^2$ para alguma escolha das constantes a e b, ou $Y = \exp(X)$ etc. Mas considere uma população Π de seres humanos e suponha que $X(\pi)$ seja o peso de π em quilogramas e $Y(\pi)$ seja a altura do indivíduo $\pi \in \Pi$ em centímetros. Por experiência, sabemos que pessoas mais altas tendem a ser mais pesadas, e por isso acreditamos que exista algum tipo de relação entre altura e peso. Sabemos também que não pode haver uma fórmula exata que descreva essa relação, porque pessoas com o mesmo peso muitas vezes têm alturas diferentes, e pessoas com a mesma altura muitas vezes têm pesos diferentes.

10.1.1 A Definição de Relação

Se pensarmos em todas as pessoas com um dado peso x, haverá uma distribuição de alturas para todos os indivíduos π que têm peso x. Chamamos essa distribuição de distribuição condicional[3] de Y, dado que $X = x$.

No original: *model checking*[2], *conditional distribution*[3].

Podemos agora exprimir o que queremos dizer com nossa ideia intuitiva de que X e Y estão relacionados, pois, à medida que mudamos o valor do peso em que condicionamos, esperamos que a distribuição condicional mude. Em particular, à medida que x aumenta, esperamos que a posição da distribuição condicional aumente, embora outras características da distribuição também possam mudar. Por exemplo, na Figura 10.1.1, apresentamos um gráfico possível de duas densidades aproximadas para as distribuições condicionais de Y dado $X = 70$ kg e a distribuição condicional de Y dado $X = 90$ kg.

Vemos que a distribuição condicional se deslocou para cima quando X passa de 70 para 90 kg, mas também que a forma da distribuição mudou um pouco. Assim, podemos dizer que existe com certeza uma relação entre X e Y, ao menos nessa população. Observe que, da forma como foram definidas até aqui, X e Y não são variáveis aleatórias, mas passam a ser quando selecionamos π aleatoriamente da população. Nesse caso, as distribuições condicionais mencionadas passam a ser as distribuições de probabilidade condicionais da variável aleatória[4] Y, dado que observamos $X = 70$ e $X = 90$, respectivamente.

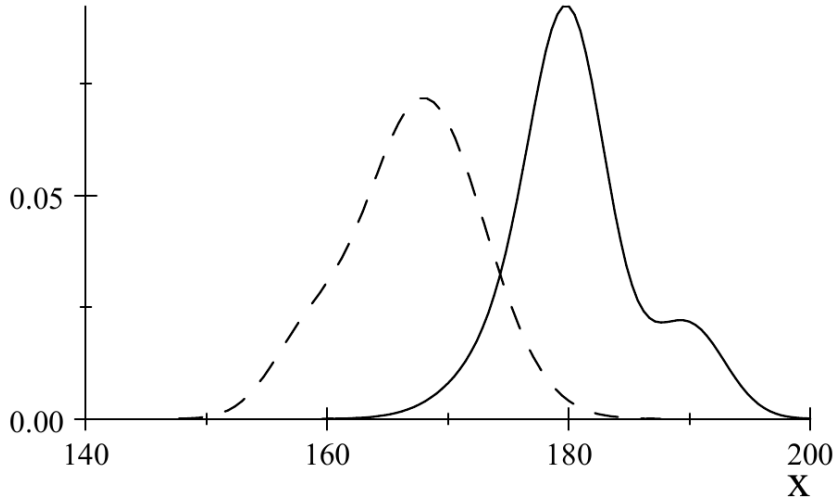


Figura 10.1.1: Gráfico de duas densidades aproximadas para a distribuição condicional de Y dado $X = 70$ kg (linha tracejada) e a distribuição condicional de Y dado $X = 90$ kg (linha contínua).

Adotaremos a definição a seguir para especificar com precisão o que queremos dizer quando afirmamos que variáveis estão relacionadas.

No original: *random variable*[4].

Definição 10.1.1

As variáveis X e Y são *variáveis relacionadas* se há alguma mudança na distribuição condicional de Y, dado $X = x$, à medida que x muda.

Poderíamos, em vez disso, definir o que significa variáveis serem *não relacionadas*. Dizemos que as variáveis X e Y são não relacionadas se forem independentes. Isso é equivalente à Definição 10.1.1, porque duas variáveis são independentes se e somente se a distribuição condicional de uma, dada a outra, não depende da condição (Exercício 10.1.1).

Há uma assimetria[5] aparente na Definição 10.1.1, porque a definição considera apenas a distribuição condicional de Y dado X, e não a distribuição condicional de X dado Y. Mas, se há uma mudança na distribuição condicional de Y dado $X = x$ quando mudamos x, então, pelo comentário acima, X e Y não são independentes; portanto, deve haver uma mudança na distribuição condicional de X dado $Y = y$ quando mudamos y (ver também o Problema 10.1.23).

Observe que a definição se aplica qualquer que seja o tipo de variável com que estamos lidando. Assim, ambas podem ser variáveis quantitativas, ou ambas variáveis categóricas, ou uma pode ser uma variável quantitativa e a outra uma variável categórica.

A Definição 10.1.1 diz que X e Y estão relacionadas se *qualquer* mudança for observada na distribuição condicional. Na realidade, isso significaria que praticamente sempre existe uma relação entre as variáveis X e Y. Parece provável que sempre detectaremos alguma diferença se fizermos um censo e calcularmos todas as distribuições condicionais relevantes. É aqui que a ideia da *força de uma relação entre variáveis* se torna relevante, pois, se virmos grandes mudanças nas distribuições condicionais, podemos dizer que existe uma relação forte. Se virmos apenas mudanças muito pequenas, podemos dizer que existe uma relação muito fraca, talvez sem importância prática.

O Papel dos Modelos Estatísticos

Se existe uma relação entre duas variáveis, então sua forma é completamente descrita pelo conjunto das distribuições condicionais de Y dado X. Às vezes, pode ser necessário descrever a relação usando todas essas distribuições condicionais. Em muitos problemas, porém, procuramos uma apresentação mais simples. De fato, muitas vezes supomos um modelo estatístico que

No original: *skewness*[5].

prescreve uma forma simples para o modo como as distribuições condicionais mudam quando mudamos X.

Considere o exemplo a seguir.

Exemplo 10.1.1 — Modelo de Regressão Linear Normal Simples

Na Seção 10.3.2, discutiremos o modelo de regressão linear normal simples, em que se supõe que a distribuição condicional da variável quantitativa Y, dada a variável quantitativa $X = x$, seja a distribuição

$$N(\beta_1 + \beta_2 x, \sigma^2),$$

em que β_1, β_2 e σ^2 são desconhecidos. Por exemplo, Y poderia ser a pressão arterial de um indivíduo e X a quantidade de sal que a pessoa consome por dia.

Nesse caso, as distribuições condicionais têm forma constante e mudam, à medida que x muda, apenas por meio da média condicional. A média se move ao longo da reta dada por $\beta_1 + \beta_2 x$ para algum intercepto β_1 e alguma inclinação β_2. Se esse modelo estiver correto, então as variáveis são não relacionadas se e somente se $\beta_2 = 0$, pois essa é a única situação em que as distribuições condicionais podem permanecer constantes quando mudamos x. ■

Modelos estatísticos como o descrito no Exemplo 10.1.1 podem estar errados. Nada exige que duas variáveis quantitativas *tenham de* estar relacionadas dessa maneira. Por exemplo, a variância condicional[6] de Y pode variar com x, e a própria forma da distribuição condicional também pode variar com x. O modelo do Exemplo 10.1.1 é um caso de hipótese simplificadora que é adequada em muitos contextos práticos. Contudo, métodos como os discutidos no Capítulo 9 precisam ser empregados para verificar as hipóteses do modelo antes de aceitar inferências estatísticas baseadas nesse modelo. Sempre consideraremos a verificação do modelo como parte de nossa discussão dos diversos modelos usados para examinar a relação entre variáveis.

Variáveis Resposta e Preditoras

Muitas vezes, pensamos em Y como uma variável dependente (que depende de X) e em X como uma variável independente (livre para variar). Nosso objetivo,

No original: *conditional variance*[6].

então, é predizer o valor de Y dado o valor de X. Nessa situação, chamamos Y de *variável resposta*[7] e X de *variável preditora*[8].

Às vezes, porém, não há realmente nada que distinga os papéis de X e Y. Por exemplo, suponha que X seja o peso de um indivíduo em quilogramas e Y seja a altura em centímetros. Poderíamos então pensar em predizer o peso a partir da altura ou o contrário. É indiferente, então, qual delas escolhemos para condicionar.

Em muitas aplicações, há mais de uma variável resposta[9] e mais de uma variável preditora X. Não consideraremos a situação em que temos mais de uma variável resposta, mas consideraremos o caso em que $X = (X_1, \ldots, X_k)$ é k-dimensional. Aqui, os vários preditores que compõem X podem ser todos categóricos, todos quantitativos ou alguma mistura de variáveis categóricas e quantitativas.

A definição de existência de uma relação entre a variável resposta Y e o conjunto de preditores $(X_1, \ldots, X_k)$ é exatamente como na Definição 10.1.1. Em particular, existe uma relação entre Y e $(X_1, \ldots, X_k)$ se há alguma mudança na distribuição condicional de Y dado $(X_1, \ldots, X_k) = (x_1, \ldots, x_k)$ quando $(x_1, \ldots, x_k)$ varia. Se essa relação existe, então a forma da relação é especificada pelo conjunto completo das distribuições condicionais. Novamente, muitas vezes se usam modelos estatísticos em que se fazem hipóteses simplificadoras sobre a forma da relação. Considere o exemplo a seguir.

No original: *response variable*[7], *predictor variable*[8], *response variable*[9].

Exemplo 10.1.2 — O Modelo Linear Normal com k Preditores

Na Seção 10.3.4, discutiremos o modelo de regressão linear múltipla normal. Nele, supõe-se que a distribuição condicional da variável quantitativa Y, dado que os preditores quantitativos são $(X_1, \dots, X_k) = (x_1, \dots, x_k)$, seja a distribuição

$$N(\beta_1 + \beta_2 x_1 + \cdots + \beta_{k+1} x_k, \sigma^2),$$

em que $\beta_1, \dots, \beta_{k+1}$ e σ^2 são desconhecidos. Por exemplo, Y poderia ser a pressão arterial, X_1 a quantidade diária de sal ingerida, X_2 a idade do indivíduo, X_3 o peso do indivíduo etc.

Nesse caso, as distribuições condicionais têm forma constante e mudam, à medida que os valores dos preditores $(x_1, \dots, x_k)$ mudam, apenas por meio da média condicional, que muda de acordo com a função $\beta_1 + \beta_2 x_1 + \cdots + \beta_{k+1} x_k$. Observe que, se esse modelo estiver correto, então as variáveis são não relacionadas se e somente se $\beta_2 = \cdots = \beta_{k+1} = 0$, pois essa é a única situação em que as distribuições condicionais podem permanecer constantes quando mudamos $(x_1, \dots, x_k)$. ■

Quando dividimos um conjunto de variáveis $Y, X_1, \dots, X_k$ em resposta Y e preditores $(X_1, \dots, X_k)$, estamos dizendo implicitamente que nos interessam diretamente apenas as distribuições condicionais de Y dado $(X_1, \dots, X_k)$. Pode haver relações entre os preditores $X_1, \dots, X_k$, porém, e elas podem ser de interesse.

Por exemplo, suponha que temos dois preditores X_1 e X_2, e que a distribuição condicional de X_1 dado X_2 seja praticamente degenerada num valor $a + cX_2$ para certas constantes a e c. Então não é uma boa ideia incluir X_1 e X_2 ao mesmo tempo num modelo como o discutido no Exemplo 10.1.2, pois isso pode tornar a análise muito sensível a pequenas mudanças nos dados. Esse é o chamado problema da *multicolinearidade*. O efeito da multicolinearidade, e como evitá-lo, não será mais discutido neste texto. Esse é, porém, um tema de considerável importância prática.

Modelos de Regressão

Suponha que a resposta Y seja quantitativa e que tenhamos k preditores $(X_1, \dots, X_k)$. Uma das hipóteses simplificadoras mais importantes usadas na prática é a *hipótese de regressão*, isto é, supomos que, à medida que mudamos $(X_1, \dots, X_k)$, a única coisa que pode mudar na distribuição condicional de Y

dado $(X_1, \ldots, X_k)$ é a média condicional $E(Y \mid X_1, \ldots, X_k)$. A importância dessa hipótese é que, para analisar a relação entre Y e $(X_1, \ldots, X_k)$, precisamos agora considerar apenas como $E(Y \mid X_1, \ldots, X_k)$ muda quando $(X_1, \ldots, X_k)$ muda. De fato, se $E(Y \mid X_1, \ldots, X_k)$ não muda quando $(X_1, \ldots, X_k)$ muda, então não há relação entre Y e os preditores. É claro que esse tipo de análise depende de a hipótese de regressão valer, e os métodos da Seção 9.1 precisam ser usados para verificar isso. Os *modelos de regressão* — isto é, modelos estatísticos em que fazemos a hipótese de regressão — estão entre os modelos estatísticos mais importantes usados na prática. As Seções 10.3 e 10.4 discutem vários casos de modelos de regressão.

Os modelos de regressão costumam ser apresentados na forma

$$Y = E(Y \mid X_1, \ldots, X_k) + Z, \tag{10.1.1}$$

em que $Z = Y - E(Y \mid X_1, \ldots, X_k)$ é chamado de *termo de erro*. Vemos imediatamente que, se a hipótese de regressão vale, então a distribuição condicional de Z dado $(X_1, \ldots, X_k)$ fica fixa quando mudamos $(X_1, \ldots, X_k)$ e, reciprocamente, se a distribuição condicional de Z dado $(X_1, \ldots, X_k)$ fica fixa quando mudamos $(X_1, \ldots, X_k)$, então a hipótese de regressão vale. Assim, quando a hipótese de regressão vale, (10.1.1) fornece uma decomposição de Y em duas partes: (1) uma parte que possivelmente depende de $(X_1, \ldots, X_k)$, a saber, $E(Y \mid X_1, \ldots, X_k)$, e (2) uma parte que é sempre independente de $(X_1, \ldots, X_k)$, a saber, o erro Z. Observe que os Exemplos 10.1.1 e 10.1.2 podem ser escritos na forma (10.1.1), com $Z \sim N(0, \sigma^2)$.

10.1.2 Relações de Causa e Efeito e Experimentos

Suponha agora que temos as variáveis X e Y definidas numa população Π e que concluímos que existe uma relação de acordo com a Definição 10.1.1. Isso pode se basear na realização de um censo completo de Π ou, o que é mais comum, teremos tirado uma amostra aleatória simples de Π e usado os métodos das seções restantes deste capítulo para concluir que essa relação existe. Se Y faz o papel da resposta e X é o preditor[10], então muitas vezes queremos poder afirmar que as mudanças em X estão *causando* as mudanças observadas nas distribuições condicionais de Y. É claro que, se não há mudanças nas distribuições condicionais, então não há relação entre X e Y e, portanto, também não há *relação de causa e efeito*.

Por exemplo, suponha que a quantidade de gás dióxido de carbono liberada na atmosfera esteja aumentando e que observemos que as temperaturas globais

No original: *predictor*[10].

médias estão subindo. Se temos razões para acreditar que a quantidade de dióxido de carbono liberada pode ter efeito sobre a temperatura, então talvez seja sensato acreditar que o aumento das emissões de dióxido de carbono está causando o aumento observado nas temperaturas globais médias. Como outro exemplo, há muitos anos se observa que os fumantes sofrem de doenças respiratórias com muito mais frequência do que os não fumantes. Parece razoável, então, concluir que fumar causa um aumento do risco de doença respiratória. Por outro lado, suponha que consideremos a relação entre peso e altura. Parece claro que existe uma relação, mas não faz nenhum sentido dizer que as mudanças numa das variáveis estão causando as mudanças nas distribuições condicionais da outra.

Variáveis de Confusão

Quando podemos dizer que uma relação observada entre X e Y é uma relação de causa e efeito? Se existe uma relação entre X e Y, então sabemos que há pelo menos dois valores x_1 e x_2 tais que $f_Y(\cdot \mid X = x_1) \neq f_Y(\cdot \mid X = x_2)$, isto é, essas duas distribuições condicionais não são iguais. Se quisermos dizer que essa diferença é causada pela mudança em X, então precisamos saber categoricamente que não há nenhuma outra variável Z definida em Π que se *confunda* com X. O exemplo a seguir ilustra a ideia de duas variáveis que se confundem.

Exemplo 10.1.3

Suponha que Π seja uma população de estudantes em que a maioria das mulheres tem um emprego de tempo parcial e a maioria dos homens não tem. Um pesquisador está interessado na distribuição das notas, medidas pela média geral das notas (GPA), e procura ver se há uma relação entre o GPA e o gênero. Com base nos dados coletados, o pesquisador observa uma diferença na distribuição condicional do GPA dado o gênero e conclui que existe uma relação entre essas variáveis. Parece claro, porém, que não se justifica afirmar que existe uma relação de causa e efeito entre o GPA e o gênero, pois a diferença nas distribuições condicionais também poderia ser atribuída à diferença na situação de trabalho em tempo parcial, e não ao gênero. Neste exemplo, a situação de trabalho em tempo parcial e o gênero estão confundidos. ■

Uma análise mais cuidadosa poderia salvar a situação descrita no Exemplo 10.1.3, pois, se X e Z denotam as variáveis que se confundem, então poderíamos coletar dados também sobre Z e examinar as distribuições

condicionais $f_Y(\cdot \mid X = x, Z = z)$. No Exemplo 10.1.3, essas serão as distribuições condicionais do GPA, dados o gênero e a situação de trabalho em tempo parcial. Se essas distribuições condicionais mudarem quando mudamos x, para algum valor fixo de z, então poderíamos afirmar que existe uma relação de causa e efeito entre X e Y, *desde que* não haja outras variáveis de confusão. É claro que provavelmente ainda há mais variáveis de confusão, e deveríamos, na verdade, condicionar em todas elas. Isso traz à tona o fato de que, em qualquer aplicação prática, quase certamente[11] nunca saberemos sequer quais são todas as possíveis variáveis de confusão.

Controle da Atribuição de Valores à Variável Preditora

Felizmente, às vezes há uma forma de contornar as dificuldades criadas pelas variáveis de confusão. Suponha que possamos *controlar* o valor da variável X para qualquer $\pi \in \Pi$, isto é, que possamos *atribuir* o valor x a π de modo que $X(\pi) = x$ para qualquer um dos valores possíveis de x. No Exemplo 10.1.3, isso significaria que poderíamos atribuir uma situação de trabalho em tempo parcial a qualquer estudante da população. Considere agora a seguinte situação idealizada. Imagine atribuir a todo elemento $\pi \in \Pi$ o valor $X(\pi) = x_1$ e então fazer um censo para obter a distribuição condicional $f_Y(\cdot \mid X = x_1)$. Imagine agora atribuir a todo $\pi \in \Pi$ o valor $X(\pi) = x_2$ e então fazer um censo para obter a distribuição condicional $f_Y(\cdot \mid X = x_2)$. Se há alguma diferença entre $f_Y(\cdot \mid X = x_1)$ e $f_Y(\cdot \mid X = x_2)$, então a única razão possível é que o valor de X difere. Portanto, se $f_Y(\cdot \mid X = x_1) \neq f_Y(\cdot \mid X = x_2)$, podemos afirmar que existe uma relação de causa e efeito.

Uma dificuldade do argumento acima é que, em geral, nunca conseguimos determinar exatamente $f_Y(\cdot \mid X = x_1)$ e $f_Y(\cdot \mid X = x_2)$. Mas, na verdade, talvez possamos tirar amostras delas; então os métodos de inferência estatística passam a estar disponíveis para inferirmos se há ou não alguma diferença. Suponha que tomemos uma amostra aleatória $\pi_1, \ldots, \pi_{n_1+n_2}$ de Π e atribuamos aleatoriamente a n_1 deles o valor $X = x_1$, com os π restantes recebendo o valor x_2. Obtemos os valores de Y, $y_{11}, \ldots, y_{1n_1}$, para os π que receberam o valor x_1 e os valores de Y, $y_{21}, \ldots, y_{2n_2}$, para os π que receberam o valor x_2. Fica então evidente que $y_{11}, \ldots, y_{1n_1}$ é uma amostra de $f_Y(\cdot \mid X = x_1)$ e $y_{21}, \ldots, y_{2n_2}$ é uma amostra de $f_Y(\cdot \mid X = x_2)$. De fato, desde que $n_1 + n_2$ seja pequeno em relação ao tamanho da população, podemos considerá-las amostras i.i.d. dessas distribuições condicionais.

Vemos, assim, que em certas circunstâncias é possível coletar dados de tal

No original: *almost surely*[11].

forma que podemos fazer inferências sobre a existência ou não de uma relação de causa e efeito. Especificamos agora as características da técnica de coleta de dados relevante.

Condições para Relações de Causa e Efeito

Primeiro, se nossas inferências devem se aplicar a uma população Π, então precisamos ter uma amostra aleatória dessa população. Essa é justamente a característica do que chamamos de estudo amostral na Seção 5.4, e precisamos fazer isso para evitar quaisquer efeitos de seleção. Assim, se o objetivo de um estudo é examinar a relação entre a duração das crises de enxaqueca e a dosagem de certo medicamento, o pesquisador precisa ter uma amostra aleatória da população das pessoas que sofrem de enxaqueca.

Segundo, precisamos ser capazes de *atribuir* qualquer valor possível da variável preditora X a qualquer π selecionado. Se não pudermos fazer isso, ou não o fizermos, então pode haver variáveis de confusão escondidas (às vezes chamadas de *variáveis ocultas*) influenciando as distribuições condicionais de Y. Assim, num estudo dos efeitos da dosagem de um medicamento sobre as enxaquecas, o pesquisador precisa ser capaz de impor a dosagem a cada participante do estudo.

Terceiro, depois de decidir quais valores de X usaremos no estudo, precisamos alocar aleatoriamente esses valores aos membros da amostra. Isso é feito para evitar a possibilidade de efeitos de seleção. Assim, depois de decidir quais dosagens usar no estudo dos efeitos da dosagem de um medicamento sobre as enxaquecas, e quantos participantes receberão cada dosagem, o pesquisador precisa selecionar aleatoriamente os indivíduos que receberão cada dosagem. Isso (espera-se) evitará efeitos de seleção, como apenas os indivíduos mais saudáveis receberem a menor dosagem etc.

Quando essas exigências são atendidas, chamamos o processo de coleta de dados de *experimento*. A inferência estatística baseada em dados coletados por meio de um experimento tem a capacidade de inferir que existem relações de causa e efeito, e por isso representa uma ferramenta científica importante e poderosa.

Uma Hierarquia de Estudos

Combinando esta discussão com a Seção 5.4, vemos uma hierarquia de métodos de coleta de dados. Os estudos observacionais ficam na base da hierarquia. As inferências tiradas de estudos observacionais devem ser tomadas com

certa cautela, pois efeitos de seleção podem fazer com que os resultados não se apliquem à população pretendida, e a existência de variáveis de confusão significa que não podemos fazer inferências sobre relações de causa e efeito. Nos estudos amostrais, sabemos que quaisquer inferências tiradas dizem respeito à população adequada; mas a existência de variáveis de confusão novamente causa dificuldades para quaisquer afirmações sobre a existência de relações de causa e efeito; por exemplo, apenas tomar amostras aleatórias de homens e mulheres da população II do Exemplo 10.1.3 não evitará as variáveis de confusão. No topo da hierarquia ficam os experimentos.

Provavelmente já está claro que muitas vezes é impossível realizar um experimento. No Exemplo 10.1.3, não podemos atribuir o valor do gênero, e assim nada se pode dizer sobre a existência de uma relação de causa e efeito entre o GPA e o gênero.

Há muitos exemplos notórios em que se fazem afirmações sobre a existência de relações de causa e efeito, mas para os quais nenhum experimento é possível. Por exemplo, foram realizados vários estudos em que se notaram diferenças entre as distribuições de QI de vários grupos raciais. É impossível, porém, controlar a variável origem racial, e por isso é impossível afirmar que as diferenças observadas nas distribuições condicionais do QI, dada a raça, são causadas por mudanças na raça.

Outro exemplo diz respeito ao fumo e ao câncer de pulmão em seres humanos. Já se observou que é impossível realizar um experimento, pois não podemos atribuir valores da variável preditora (talvez diferentes quantidades de fumo) a seres humanos ao nascer e depois observar a resposta, isto é, se a pessoa contrai ou não câncer de pulmão. Isso levanta uma questão importante. Não rejeitamos simplesmente os resultados de análises baseadas em estudos observacionais ou estudos amostrais porque os dados não vieram de um experimento. Em vez disso, tratamos esses resultados como evidência — evidência possivelmente falha, mas ainda assim evidência.

Pense no testemunho ocular, num tribunal, sugerindo que um crime foi cometido por determinado indivíduo. O testemunho ocular pode não ser confiável, mas, se duas ou três testemunhas oculares sem ligação entre si dão relatos semelhantes, então nossa confiança na credibilidade da evidência aumenta. Do mesmo modo, se muitos estudos observacionais e amostrais parecem indicar que fumar leva a um aumento do risco de contrair câncer de pulmão, então aumenta nossa confiança de que realmente existe uma relação de causa e efeito. Além disso, se conseguirmos identificar possíveis variáveis de confusão, então podem ser realizados estudos observacionais ou amostrais que as levem em conta, aumentando ainda mais nossa confiança. Em última

análise, talvez não sejamos capazes de resolver a questão de modo definitivo por meio de um experimento, mas ainda é possível construir evidências esmagadoras de que o fumo e o câncer de pulmão têm, de fato, uma relação de causa e efeito.

10.1.3 Planejamento de Experimentos

Suponha que temos uma resposta Y e um preditor X (às vezes chamado de *fator* em contextos experimentais) definidos numa população Π, e que queremos coletar dados para determinar se existe uma relação de causa e efeito entre eles. Seguindo a discussão da Seção 10.1.1, vamos realizar um experimento. Há agora uma série de decisões a tomar, e nossas escolhas constituem o que chamamos de *planejamento* do experimento.

Por exemplo, vamos atribuir valores de X aos elementos amostrados de Π, agora chamados de *unidades experimentais*, $\pi_1, \ldots, \pi_n$. Quais dos valores possíveis de X devemos usar? Quando X só pode assumir um número finito pequeno de valores, é natural usar esses valores. Por outro lado, quando o número de valores possíveis de X é muito grande ou até infinito, como acontece com preditores quantitativos, temos de escolher os valores de X que serão usados no experimento.

Suponha que escolhemos os valores $x_1, \ldots, x_k$ para X. Chamamos $x_1, \ldots, x_k$ de *níveis* de X; cada atribuição particular de um x_i a um π_j da amostra será chamada de *tratamento*[12]. Em geral, escolhemos os níveis de modo que cubram a faixa de valores possíveis de X de forma mais ou menos uniforme. Por exemplo, se X é a temperatura em graus Celsius e queremos examinar a relação entre Y e X para X no intervalo $[0, 100]$, então, usando $k = 5$ níveis, poderíamos tomar $x_1 = 0$, $x_2 = 25$, $x_3 = 50$, $x_4 = 75$ e $x_5 = 100$.

Escolhidos os níveis de X, temos então de escolher quantos tratamentos de cada nível vamos usar no experimento, isto é, decidir quantos valores da resposta n_i vamos observar no nível x_i, para $i = 1, \ldots, k$.

Em qualquer experimento, teremos à nossa disposição uma quantidade finita de recursos (dinheiro, tempo etc.), que determina o tamanho da amostra[13] n retirada de Π. A questão, então, é como escolher os n_i de modo que $n_1 + \cdots + n_k = n$. Se não sabemos nada sobre as distribuições condicionais $f_Y(\cdot \mid X = x_i)$, faz sentido usar *balanceamento*, isto é, escolher $n_1 = \cdots = n_k$.

No original: *treatment*[12], *sample size*[13].

Por outro lado, suponha que sabemos que algumas das $f_Y(\cdot \mid X = x_i)$ apresentarão variabilidade maior que outras. Por exemplo, poderíamos medir a variabilidade pela variância[14] de $f_Y(\cdot \mid X = x_i)$. Nesse caso, faz sentido alocar mais tratamentos aos níveis de X em que a resposta é mais variável. Isso porque serão necessárias mais observações para fazer inferências precisas sobre características de uma tal $f_Y(\cdot \mid X = x_i)$ do que para as distribuições condicionais menos variáveis.

Como discutido nas Seções 6.3.4 e 6.3.5, também queremos escolher os n_i de modo que as inferências que fizermos tenham a precisão desejada. Métodos para escolher os tamanhos de amostra n_i, parecidos com os discutidos no Capítulo 7, foram desenvolvidos para esses planejamentos mais complicados, mas não vamos discuti-los aqui.

Suponha, então, que determinamos $\{(x_1, n_1), \ldots, (x_k, n_k)\}$. Chamamos esse conjunto de pares ordenados de *planejamento experimental*[15].

Vejamos alguns exemplos.

No original: *variance*[14], *experimental design*[15].

Exemplo 10.1.4

Suponha que Π é uma população de estudantes de uma certa universidade. A administração quer determinar o valor de designar um orientador acadêmico para cada estudante. A variável resposta Y será uma nota, numa escala de 1 a 10 (completamente insatisfeito a completamente satisfeito com sua experiência na universidade), que o estudante dá ao fim de um certo semestre. Tratamos Y como uma variável quantitativa. Uma amostra aleatória de $n = 100$ estudantes é selecionada de Π, e 50 deles são escolhidos aleatoriamente para receber orientadores, enquanto aos 50 restantes não se designa orientador.

Aqui, o preditor X é uma variável categórica que indica se o estudante tem ou não um orientador. Há só $k = 2$ níveis, e os dois são usados no experimento. Se $x_1 = 0$ indica a ausência de orientador e $x_2 = 1$ indica que o estudante tem orientador, então $n_1 = n_2 = 50$ e temos um experimento balanceado. O planejamento experimental é dado por

$$\{(0, 50), (1, 50)\}.$$

Ao fim do experimento, queremos usar os dados para fazer inferências sobre as distribuições condicionais $f_Y(\cdot \mid X = 0)$ e $f_Y(\cdot \mid X = 1)$, para determinar se existe uma relação de causa e efeito. Os métodos da Seção 10.4 serão relevantes para isso. ■

Exemplo 10.1.5

Suponha que Π é uma população de vacas leiteiras. Uma empresa de ração está interessada na relação entre o ganho de peso, medido em quilogramas, ao longo de um período de tempo específico, e a quantidade de um suplemento, medida em gramas/litro, de um aditivo posto na ração das vacas. Aqui, a resposta Y é o ganho de peso — uma variável quantitativa. O preditor X é a concentração do aditivo. Suponha que X pode variar, de modo plausível, entre 0 e 2; então ele também é uma variável quantitativa.

O experimentador decide usar $k = 4$ níveis, com $x_1 = 0{,}00$, $x_2 = 0{,}66$, $x_3 = 1{,}32$ e $x_4 = 2{,}00$. Além disso, os tamanhos de amostra $n_1 = n_2 = n_3 = n_4 = 10$ foram considerados adequados. Assim, o planejamento experimental balanceado é dado por

$$\{(0{,}00; 10), (0{,}66; 10), (1{,}32; 10), (2{,}00; 10)\}.$$

Ao fim do experimento, queremos fazer inferências sobre as distribuições condicionais $f_Y(\cdot \mid X = 0{,}00)$, $f_Y(\cdot \mid X = 0{,}66)$, $f_Y(\cdot \mid X = 1{,}32)$ e $f_Y(\cdot \mid X = 2{,}00)$. Os métodos da Seção 10.3 são relevantes para isso. ■

Tratamento Controle, o Efeito Placebo e o Cegamento

Note que, no Exemplo 10.1.5, incluímos o nível $X = 0$, que corresponde a não aplicar o aditivo. Esse é chamado de *tratamento controle*, porque fornece uma base de comparação com a qual podemos avaliar o efeito do preditor. Em muitos experimentos, é importante incluir um tratamento controle.

Em experimentos médicos, costuma haver um *efeito placebo* — isto é, um portador de uma doença que recebe qualquer tratamento frequentemente registra uma melhora dos sintomas. Acredita-se que o efeito placebo se deva ao fato de que o doente começa a se sentir melhor simplesmente porque alguém está dando atenção à sua condição. Por isso, em qualquer experimento para determinar a eficácia de um medicamento no alívio dos sintomas de uma doença, é importante usar também um tratamento controle. Por exemplo, se queremos investigar se um certo medicamento alivia ou não as enxaquecas, então, entre as dosagens escolhidas para o experimento, devemos garantir que haja um comprimido sem nada do medicamento (a chamada *pílula de açúcar*); assim, podemos avaliar a extensão do efeito placebo. É claro que quem recebe o comprimido não deve saber se está recebendo a pílula de açúcar ou o medicamento. Isso se chama um experimento *cego*. Se também ocultamos a

identidade do tratamento dos experimentadores, para evitar qualquer viés da parte deles nos resultados, o experimento se chama *duplo-cego*.

No Exemplo 10.1.5, supusemos que é possível retirar uma amostra da população de todas as vacas leiteiras. A rigor, isso é necessário se queremos evitar efeitos de seleção e garantir que nossas inferências se apliquem à população de interesse. Na prática, porém, muitas vezes não é viável retirar uma amostra de unidades experimentais da população de interesse inteira. Por exemplo, muitos experimentos médicos são feitos em animais, e estes definitivamente não são amostras aleatórias da população do animal em questão, por exemplo, ratos.

Nesses casos, porém, simplesmente reconhecemos a possibilidade de que efeitos de seleção ou variáveis ocultas possam invalidar as conclusões tiradas dessas análises quando forem aplicadas à população de interesse. Mas ainda consideramos os resultados como evidência sobre o fenômeno em estudo. Cabe ao experimentador chegar o mais perto possível da situação idealizada especificada por um experimento válido; por exemplo, a aleatorização continua sendo empregada na atribuição dos tratamentos às unidades experimentais, para que os efeitos de seleção sejam evitados tanto quanto possível.

Interações

Nos experimentos discutidos até aqui, havia um único preditor. Em muitos contextos práticos, há mais de um preditor. Suponha, então, que há dois preditores X e W e que decidimos usar os níveis $x_1, \dots, x_k$ para X e os níveis $w_1, \dots, w_l$ para W. Uma possibilidade é olhar para as distribuições condicionais $f_Y(\cdot \mid X = x_i)$, para $i = 1, \dots, k$, e $f_Y(\cdot \mid W = w_j)$, para $j = 1, \dots, l$, para determinar se X e W têm, individualmente, relação com a resposta Y. Essa abordagem, porém, ignora o efeito dos dois preditores em conjunto. Em particular, a maneira como as distribuições condicionais $f_Y(\cdot \mid X = x, W = w)$ mudam quando mudamos x pode depender de w; quando isso acontece, dizemos que há uma *interação*[16] entre os preditores.

Para investigar a possibilidade de existir uma interação entre X e W, temos de amostrar de cada uma das kl distribuições $f_Y(\cdot \mid X = x_i, W = w_j)$, para $i = 1, \dots, k$ e $j = 1, \dots, l$. O planejamento experimental assume então a forma

$$\{(x_1, w_1, n_{11}), (x_2, w_1, n_{21}), \dots, (x_k, w_l, n_{kl})\},$$

em que n_{ij} é o número de aplicações do tratamento (x_i, w_j). Dizemos que os dois preditores X e W são *completamente cruzados* num planejamento desse

No original: *interaction*[16].

tipo, porque cada valor de X usado no experimento ocorre com cada valor de W usado no experimento. É claro que podemos estender esta discussão ao caso em que há mais de dois preditores. Na Seção 10.4.3, discutiremos como analisar os dados para determinar se há interações entre os preditores.

Exemplo 10.1.6

Suponha que temos uma população Π de estudantes de uma certa universidade e estamos investigando a relação entre a resposta Y, dada pela nota de um estudante em cálculo, e os preditores W e X. O preditor W é o número de horas de orientação acadêmica dadas por mês a um estudante; ele pode assumir os valores 0, 1 ou 2. O preditor X indica o tamanho da turma, em que $X = 0$ indica turma pequena e $X = 1$ indica turma grande. Temos, então, uma resposta quantitativa Y, um preditor quantitativo W que assume três valores e um preditor categórico X que assume dois valores. Os valores cruzados dos preditores (W, X) são dados pelo conjunto

$$\{(0,0),(1,0),(2,0),(0,1),(1,1),(2,1)\},$$

de modo que há seis tratamentos. Para realizar o experimento, a universidade toma então uma amostra aleatória de $6n$ estudantes e designa aleatoriamente n estudantes para cada tratamento. ■

Às vezes, incluímos preditores adicionais num planejamento experimental mesmo quando não estamos interessados principalmente nos efeitos deles sobre a resposta Y. Fazemos isso porque *sabemos* que essa variável tem relação com Y. Incluir esses preditores permite condicionar nos valores deles e, assim, investigar com mais precisão a relação de Y com os demais preditores. Chamamos uma variável desse tipo de *variável de bloqueio*[17].

No original: *blocking variable*[17].

Exemplo 10.1.7

Suponha que a variável resposta Y é a produtividade de trigo em bushels por acre e que a variável preditora X é uma variável indicadora de qual de três tipos de trigo está sendo plantado num estudo agrícola. Cada tipo de trigo será plantado numa parcela de terra, e todas as parcelas têm o mesmo tamanho, mas sabe-se que as parcelas usadas no experimento variam consideravelmente quanto à fertilidade. Note que esse experimento é outro exemplo de uma situação em que é impossível amostrar aleatoriamente as unidades experimentais (as parcelas) da população inteira de unidades experimentais.

Suponha que o experimentador consegue agrupar as unidades experimentais disponíveis em parcelas de baixa fertilidade e de alta fertilidade. Chamamos essas duas classes de terreno de *blocos*. Seja W o indicador do tipo de parcela. Então W é uma variável categórica que assume dois valores. Parece claro, então, que as distribuições condicionais $f_Y(\cdot \mid X = x, W = w)$ serão bem menos variáveis que as distribuições condicionais $f_Y(\cdot \mid X = x)$.

Nesse caso, W está servindo como variável de bloqueio. As unidades experimentais de um bloco específico, o de baixa fertilidade ou o de alta fertilidade, são mais homogêneas que o conjunto inteiro de parcelas; assim, a variabilidade será reduzida e as inferências serão mais precisas. ■

Resumo da Seção 10.1

- Dizemos que duas variáveis são relacionadas se a distribuição condicional de uma dada a outra muda de algum modo quando mudamos o valor da variável condicionante.
- Para concluir que uma relação entre duas variáveis é uma relação de causa e efeito, precisamos garantir que levamos em conta (por meio do condicionamento) todas as variáveis de confusão.
- A estatística oferece um modo prático de evitar os efeitos das variáveis de confusão: realizar um experimento. Para isso, precisamos ser capazes de atribuir os valores da variável preditora a unidades experimentais amostradas da população de interesse.
- O planejamento de experimentos trata de determinar métodos de coleta dos dados de modo que a análise deles leve a inferências precisas sobre as questões de interesse.

Exercícios

10.1.1 Prove que as variáveis aleatórias discretas X e Y são não relacionadas se e somente se X e Y são independentes.

10.1.2 Suponha que duas variáveis X e Y definidas numa população finita Π são funcionalmente relacionadas por $Y = g(X)$, para alguma função não constante desconhecida g. Explique como essa situação é coberta pela Definição 10.1.1, isto é, como a definição nos leva a concluir que X e Y são relacionadas. E a situação em que $g(x) = c$ para algum valor c, para todo x? (Sugestão: use as funções de frequência relativa[18] das variáveis.)

10.1.3 Suponha que um censo é realizado numa população e que a distribuição conjunta[19] de (X, Y) obtida é a da tabela a seguir.

	$Y = 1$	$Y = 2$	$Y = 3$
$X = 1$	0,15	0,18	0,40
$X = 2$	0,12	0,09	0,06

Determine se existe ou não uma relação entre Y e X.

10.1.4 Suponha que um censo é realizado numa população e que a distribuição conjunta de (X, Y) obtida é a da tabela a seguir.

	$Y = 1$	$Y = 2$	$Y = 3$
$X = 1$	1/6	1/6	1/3
$X = 2$	1/12	1/12	1/6

Determine se existe ou não uma relação entre Y e X.

10.1.5 Suponha que X é uma variável aleatória e que $Y = X^2$. Determine se X e Y são ou não relacionadas. O que acontece quando X tem uma distribuição degenerada[20]?

10.1.6 Suponha que um pesquisador quer investigar a relação entre o peso ao nascer e o desempenho num teste padronizado aplicado a crianças de dois anos de idade. Se uma relação for encontrada, pode-se afirmar que ela é uma relação de causa e efeito? Explique por quê.

10.1.7 Suponha que um grande estudo com todos os médicos do Canadá foi feito para determinar a relação entre diversas escolhas de estilo de vida e o

No original: *relative frequency*[18], *joint distribution*[19], *degenerate distribution*[20].

tempo de vida. Se a distribuição condicional do tempo de vida dados diversos hábitos de fumo muda, discuta o que pode ser concluído desse estudo.

10.1.8 Suponha que um professor quer determinar se uma prova com consulta ou sem consulta é o modo mais adequado de avaliar os alunos sobre um certo tópico. A variável resposta é a nota obtida na prova, de 0 a 100. Discuta como o professor poderia proceder para responder a essa questão.

10.1.9 Suponha que um pesquisador quer determinar se existe ou não uma relação de causa e efeito entre o tipo de propaganda política (negativa ou positiva) vista por um eleitor de uma certa população e o modo como esse eleitor vota. Discuta que conselho você daria ao pesquisador sobre a melhor maneira de conduzir o estudo.

10.1.10 Se duas variáveis aleatórias têm correlação[21] diferente de zero, elas são necessariamente relacionadas? Explique por quê.

10.1.11 Um experimentador quer determinar a relação entre a variação de peso Y ao longo de um período especificado e o uso de uma dieta especialmente elaborada. A variável preditora X é uma variável categórica que indica se uma pessoa está ou não na dieta. Um total de 200 voluntários se inscreveu no estudo; uma seleção aleatória de 100 deles recebeu a dieta, e os 100 restantes continuaram com sua dieta habitual.

(a) Registre o planejamento experimental.

(b) Se os resultados do estudo forem aplicados à população de todos os seres humanos, que preocupações você tem sobre o modo como o estudo foi conduzido?

(c) Acredita-se que a quantidade de peso perdida ou ganha também depende do peso inicial W do participante. Como você proporia alterar o experimento para levar isso em conta?

10.1.12 Um estudo será realizado, envolvendo a população de pessoas de 15 a 19 anos de um certo país, para determinar se existe uma relação entre a resposta Y (valor gasto, em dólares, numa semana com downloads de música) e os preditores W (gênero) e X (idade em anos).

(a) Se forem tomadas observações de cada distribuição condicional possível de Y dados os dois fatores, quantas distribuições condicionais desse tipo existem?

(b) Identifique o tipo de cada variável envolvida no estudo.

No original: *correlation*[21].

(c) Suponha que há recursos suficientes para acompanhar 2000 membros da população. Como você recomendaria alocar esses recursos entre as diversas combinações de fatores?

(d) Se uma relação for encontrada entre a resposta e os preditores, pode-se afirmar que ela é uma relação de causa e efeito? Explique por quê.

(e) Suponha que, além disso, se acredite que a renda familiar provavelmente tem efeito sobre Y e que as famílias podem ser classificadas em renda baixa e renda alta. Indique como você modificaria o estudo para levar isso em conta.

10.1.13 Uma amostra aleatória de 100 domicílios, do conjunto de todos os domicílios com dois ou mais moradores numa dada área geográfica, é selecionada, e seus hábitos de assistir à televisão são acompanhados durante seis meses. Uma seleção aleatória de 50 desses domicílios recebe, toda semana, um folheto que anuncia um certo programa. O objetivo do estudo é determinar se existe alguma relação entre a exposição ao folheto e o fato de esse programa ser assistido ou não.

(a) Identifique variáveis resposta e preditora adequadas.

(b) Se uma relação for encontrada, pode-se afirmar que ela é uma relação de causa e efeito? Explique por quê.

10.1.14 Suponha que temos uma variável resposta quantitativa Y e duas variáveis preditoras categóricas W e X, ambas assumindo valores em $\{0, 1\}$. Suponha que as distribuições condicionais de Y são dadas por

$$\begin{aligned} Y \mid W = 0, X = 0 &\sim N(3, 5) \\ Y \mid W = 1, X = 0 &\sim N(3, 5) \\ Y \mid W = 0, X = 1 &\sim N(4, 5) \\ Y \mid W = 1, X = 1 &\sim N(4, 5). \end{aligned}$$

W tem relação com Y? X tem relação com Y? Explique suas respostas.

10.1.15 Suponha que temos uma variável resposta quantitativa Y e duas variáveis preditoras categóricas W e X, ambas assumindo valores em $\{0, 1\}$. Suponha que as distribuições condicionais de Y são dadas por

$$\begin{aligned} Y \mid W = 0, X = 0 &\sim N(2, 5) \\ Y \mid W = 1, X = 0 &\sim N(3, 5) \\ Y \mid W = 0, X = 1 &\sim N(4, 5) \\ Y \mid W = 1, X = 1 &\sim N(4, 5). \end{aligned}$$

W tem relação com Y? X tem relação com Y? Explique suas respostas.

10.1.16 Os preditores interagem no Exercício 10.1.14? Os preditores interagem no Exercício 10.1.15? Explique suas respostas.

10.1.17 Suponha que temos variáveis X e Y definidas na população $\Pi = \{1, 2, \dots, 10\}$, em que $X(i) = 1$ quando i é ímpar e $X(i) = 0$ quando i é par, e $Y(i) = 1$ quando i é divisível por 3 e $Y(i) = 0$ caso contrário.

(a) Determine a função de frequência relativa de X.

(b) Determine a função de frequência relativa de Y.

(c) Determine a função de frequência relativa conjunta de (X, Y).

(d) Determine todas as distribuições condicionais de Y dado X.

(e) X e Y são relacionadas? Justifique sua resposta.

10.1.18 Uma abordagem matemática para examinar a relação entre as variáveis X e Y é ver se existe uma função g tal que $Y = g(X)$. Explique por que essa abordagem não funciona em muitas aplicações práticas em que examinamos a relação entre variáveis. Explique como a estatística trata esse problema.

10.1.19 Suponha que uma variável X assume os valores 1 e 2 numa população e que as distribuições condicionais de Y dado X são $N(0, 5)$ quando $X = 1$ e $N(0, 7)$ quando $X = 2$. Determine se X e Y são relacionadas e, se forem, descreva a relação entre elas.

10.1.20 Uma variável Y tem distribuição condicional dado X especificada por $N(1 + 2x, |x|)$ quando $X = x$. Determine se X e Y são relacionadas e, se forem, descreva qual é a relação entre elas.

10.1.21 Suponha que $X \sim \text{Uniforme}[-1, 1]$ e $Y = X^2$. Determine a correlação entre Y e X. X e Y são relacionadas?

Problemas

10.1.22 Se há mais de um preditor envolvido num experimento, você acha preferível que os preditores interajam ou não? Explique sua resposta. O experimentador pode controlar se os preditores interagem ou não?

10.1.23 Prove diretamente, usando a Definição 10.1.1, que, quando X e Y são variáveis relacionadas definidas numa população finita Π, então Y e X também são relacionadas.

10.1.24 Suponha que X, Y, Z são variáveis aleatórias $N(0,1)$ independentes e que $U = X + Z$, $V = Y + Z$. Determine se as variáveis U e V são ou não relacionadas. (Sugestão: calcule $\text{Cov}(U, V)$.)

10.1.25 Suponha que $(X, Y, Z) \sim \text{Multinomial}(n, 1/3, 1/3, 1/3)$. X e Y são relacionadas?

10.1.26 Suponha que $(X, Y) \sim$ Normal Bivariada$(\mu_1, \mu_2, \sigma_1, \sigma_2, \rho)$. Mostre que X e Y são não relacionadas se e somente se $\text{Corr}(X, Y) = 0$.

10.1.27 Suponha que (X, Y, Z) tem função de probabilidade[22] $p_{X,Y,Z}$. Se Y é relacionada a X, mas não a Z, prove que $p_{X,Y,Z}(x, y, z) = p_{Y|X}(y \mid x)\, p_{X|Z}(x \mid z)\, p_Z(z)$.

10.2 Resposta e Preditores Categóricos

Há duas situações possíveis quando temos uma única resposta categórica Y e um único preditor categórico X. O preditor categórico é aleatório ou determinístico, dependendo de como fazemos a amostragem. Examinamos essas duas situações separadamente.

10.2.1 Preditor Aleatório

Consideramos a situação em que X é categórica, assumindo valores em $\{1, \ldots, a\}$, e Y é categórica, assumindo valores em $\{1, \ldots, b\}$. Se tomamos uma amostra $\pi_1, \ldots, \pi_n$ da população, então os valores $X(\pi_i) = x_i$ são aleatórios, assim como os valores $Y(\pi_i) = y_j$.

Suponha que o tamanho da amostra n seja muito pequeno em relação ao tamanho da população (de modo que podemos supor que a amostragem i.i.d. é aplicável). Então, tomando $\theta_{ij} = P(X = i, Y = j)$, obtemos a função de verossimilhança[23] (veja o Problema 10.2.15)

$$L(\theta_{11}, \ldots, \theta_{ab} \mid (x_1, y_1), \ldots, (x_n, y_n)) = \prod_{i=1}^{a} \prod_{j=1}^{b} \theta_{ij}^{f_{ij}}, \tag{10.2.1}$$

em que f_{ij} é o número de valores amostrais com $(X, Y) = (i, j)$. Uma conta fácil (veja o Problema 10.2.16) mostra que o EMV de $(\theta_{11}, \ldots, \theta_{kl})$ é dado por

No original: *probability function*[22], *likelihood function*[23].

$\hat{\theta}_{ij} = f_{ij}/n$ e que o erro padrão[24] dessa estimativa[25] (porque a ocorrência de um membro da amostra cair na (i, j)-ésima casela tem distribuição Bernoulli(θ_{ij}), e usando o Exemplo 6.3.2) é dado por

$$\sqrt{\frac{\hat{\theta}_{ij}(1-\hat{\theta}_{ij})}{n}}.$$

Queremos saber se existe ou não uma relação entre X e Y. Para responder a isso, olhamos as distribuições condicionais de Y dado X. As distribuições condicionais de Y dado X, usando $\theta_{i\cdot} = \theta_{i1} + \cdots + \theta_{ib} = P(X = i)$, são dadas na tabela a seguir.

	$Y = 1$	$\cdots$	$Y = b$
$X = 1$	$\theta_{11}/\theta_{1\cdot}$	$\cdots$	$\theta_{1b}/\theta_{1\cdot}$
$\vdots$	$\vdots$		$\vdots$
$X = a$	$\theta_{a1}/\theta_{a\cdot}$	$\cdots$	$\theta_{ab}/\theta_{a\cdot}$

Então, estimando $\theta_{ij}/\theta_{i\cdot}$ por $\hat{\theta}_{ij}/\hat{\theta}_{i\cdot} = f_{ij}/f_{i\cdot}$, em que $f_{i\cdot} = f_{i1} + \cdots + f_{ib}$, as distribuições condicionais estimadas são as da tabela a seguir.

	$Y = 1$	$\cdots$	$Y = b$
$X = 1$	$f_{11}/f_{1\cdot}$	$\cdots$	$f_{1b}/f_{1\cdot}$
$\vdots$	$\vdots$		$\vdots$
$X = a$	$f_{a1}/f_{a\cdot}$	$\cdots$	$f_{ab}/f_{a\cdot}$

Se concluirmos que existe uma relação entre X e Y, então olhamos a tabela das distribuições condicionais estimadas para determinar a forma da relação, isto é, como as distribuições condicionais mudam à medida que mudamos o valor de X em que estamos condicionando.

Como, então, inferimos se existe ou não uma relação entre X e Y? Não existe relação entre Y e X se e somente se as distribuições condicionais de Y dado $X = x$ não mudam com x. Isso acontece se e somente se X e Y são independentes, e isso vale se e somente se

$$\theta_{ij} = P(X = i, Y = j) = P(X = i)P(Y = j) = \theta_{i\cdot}\theta_{\cdot j},$$

para todo i e j, em que $\theta_{\cdot j} = \theta_{1j} + \cdots + \theta_{aj} = P(Y = j)$. Portanto, avaliar se existe ou não uma relação entre X e Y equivale a avaliar a hipótese nula[26] $H_0 : \theta_{ij} = \theta_{i\cdot}\theta_{\cdot j}$ para todo i e j.

No original: *standard error*[24], *estimate*[25], *null hypothesis*[26].

Como devemos avaliar se os dados observados são ou não surpreendentes quando H_0 vale? Os métodos da Seção 9.1.2, e em particular o Teorema 9.1.2, podem ser aplicados aqui, pois temos que

$$(F_{11}, F_{12}, \dots, F_{ab}) \sim \text{Multinomial}(n, \theta_1.\theta_{.1}, \theta_1.\theta_{.2}, \dots, \theta_a.\theta_{.b})$$

quando H_0 vale, em que F_{ij} é a contagem na (i, j)-ésima casela.

Para aplicar o Teorema 9.1.2, precisamos do EMV dos parâmetros do modelo sob H_0. A verossimilhança[27], quando H_0 vale, é

$$L(\theta_1., \dots, \theta_a., \theta_{.1}, \dots, \theta_{.b} \mid (x_1, y_1), \dots, (x_n, y_n)) = \prod_{i=1}^{a} \prod_{j=1}^{b} (\theta_i.\theta_{.j})^{f_{ij}}. \quad (10.2.2)$$

Disso, deduzimos (veja o Problema 10.2.17) que os EMVs de $\theta_{i.}$ e $\theta_{.j}$ são dados por $\hat{\theta}_{i.} = f_{i.}/n$ e $\hat{\theta}_{.j} = f_{.j}/n$. Portanto, a estatística qui-quadrado relevante é

$$X^2 = \sum_{i=1}^{a} \sum_{j=1}^{b} \frac{(f_{ij} - n\hat{\theta}_{i.}\hat{\theta}_{.j})^2}{n\hat{\theta}_{i.}\hat{\theta}_{.j}}.$$

Sob H_0, o espaço paramétrico[28] tem dimensão $(a-1)+(b-1) = a+b-2$; assim, comparamos o valor observado de X^2 com a distribuição $\chi^2((a-1)(b-1))$, porque $ab - 1 - a - b + 2 = (a-1)(b-1)$.

Vejamos um exemplo.

Exemplo 10.2.1 — Dados de Anéis de Pistão

A tabela a seguir dá as contagens de falhas de anéis de pistão, em que a variável Y é o número do compressor e a variável X é a posição da perna, com base numa amostra de $n = 166$. Esses dados foram tirados de *Statistical Methods in Research and Production*, de O. L. Davies (Hafner Publishers, Nova York, 1961).

Aqui, Y assume quatro valores e X assume três valores (N = Norte, C = Central e S = Sul).

No original: *likelihood*[27], *parameter space*[28].

	$Y=1$	$Y=2$	$Y=3$	$Y=4$
$X=\text{N}$	17	11	11	14
$X=\text{C}$	17	9	8	7
$X=\text{S}$	12	13	19	28

A pergunta de interesse é se existe ou não alguma relação entre o compressor e a posição da perna. Como $f_{1\cdot}=53$, $f_{2\cdot}=41$ e $f_{3\cdot}=72$, as distribuições condicionais de Y dado X são estimadas como nas linhas da tabela a seguir.

	$Y=1$	$Y=2$	$Y=3$	$Y=4$
$X=\text{N}$	$17/53=0{,}321$	$11/53=0{,}208$	$11/53=0{,}208$	$14/53=0{,}264$
$X=\text{C}$	$17/41=0{,}415$	$9/41=0{,}222$	$8/41=0{,}195$	$7/41=0{,}171$
$X=\text{S}$	$12/72=0{,}167$	$13/72=0{,}181$	$19/72=0{,}264$	$28/72=0{,}389$

Comparando as linhas, certamente parece haver uma diferença nas distribuições condicionais, mas precisamos avaliar se as diferenças observadas podem ou não ser explicadas como devidas ao erro amostral. Para ver se as diferenças observadas são reais, fazemos o teste qui-quadrado.

Sob a hipótese nula de independência, os EMVs são dados por

$$\hat{\theta}_{\cdot 1}=\frac{46}{166},\quad \hat{\theta}_{\cdot 2}=\frac{33}{166},\quad \hat{\theta}_{\cdot 3}=\frac{38}{166},\quad \hat{\theta}_{\cdot 4}=\frac{49}{166}$$

para as probabilidades de Y, e por

$$\hat{\theta}_{1\cdot}=\frac{53}{166},\quad \hat{\theta}_{2\cdot}=\frac{41}{166},\quad \hat{\theta}_{3\cdot}=\frac{72}{166}$$

para as probabilidades de X. Então as contagens esperadas estimadas $n\hat{\theta}_{i\cdot}\hat{\theta}_{\cdot j}$ são dadas pela tabela a seguir.

	$Y=1$	$Y=2$	$Y=3$	$Y=4$
$X=\text{N}$	14,6867	10,5361	12,1325	15,6446
$X=\text{C}$	11,3614	8,1506	9,3855	12,1024
$X=\text{S}$	19,9518	14,3133	16,4819	21,2530

Os resíduos padronizados (usando (9.1.6))

$$\frac{f_{ij}-n\hat{\theta}_{i\cdot}\hat{\theta}_{\cdot j}}{\sqrt{n\hat{\theta}_{i\cdot}\hat{\theta}_{\cdot j}(1-\hat{\theta}_{i\cdot}\hat{\theta}_{\cdot j})}}$$

são os da tabela a seguir.

	$Y = 1$	$Y = 2$	$Y = 3$	$Y = 4$
$X = \text{N}$	0,6322	0,1477	−0,3377	−0,4369
$X = \text{C}$	1,7332	0,3051	−0,4656	−1,5233
$X = \text{S}$	−1,8979	−0,3631	0,6536	1,5673

Todos os resíduos padronizados parecem razoáveis, e temos $X^2 = 11{,}7223$, com $P(\chi^2(6) > 11{,}7223) = 0{,}0685$, que não é excessivamente pequeno.

Assim, embora possa haver algum indício de que a hipótese nula de ausência de relação seja falsa, essa evidência não é esmagadora. Consequentemente, neste caso, podemos supor que Y e X são independentes e usar as estimativas das probabilidades das caselas obtidas sob essa suposição. ■

Também precisamos nos preocupar com a verificação do modelo, isto é, o modelo que supusemos para os dados $(x_1, y_1), \ldots, (x_n, y_n)$ está correto? Se essas observações são i.i.d., então de fato o modelo está correto, pois isso é tudo o que está efetivamente sendo suposto. Então precisamos verificar se as observações formam uma amostra i.i.d. plausível. Como a estatística suficiente minimal[29] é dada por $(f_{11}, \ldots, f_{ab})$, um tal teste poderia se basear na distribuição condicional da amostra $(x_1, y_1), \ldots, (x_n, y_n)$ dado $(f_{11}, \ldots, f_{ab})$. A teoria de distribuições para esses testes é computacionalmente difícil de implementar, porém, e não seguimos com esse tema neste texto.

10.2.2 Preditor Determinístico

Considere novamente a situação em que X é categórica, assumindo valores em $\{1, \ldots, a\}$, e Y é categórica, assumindo valores em $\{1, \ldots, b\}$. Mas agora suponha que tomamos uma amostra $\pi_1, \ldots, \pi_n$ da população em que especificamos que n_i membros da amostra têm o valor $X = i$ etc. Isso poderia ser por atribuição, quando estamos tentando determinar se existe uma relação de causa e efeito; ou poderíamos ter a populações $\Pi_1, \ldots, \Pi_a$ e querer ver se há alguma diferença na distribuição de Y entre as populações. Note que $n_1 + \cdots + n_a = n$.

Nos dois casos, queremos de novo fazer inferências sobre as distribuições condicionais de Y dado X, representadas pela tabela a seguir.

No original: *minimal sufficient statistic*[29].

	$Y = 1$	$\cdots$	$Y = b$
$X = 1$	$\theta_{1\|X=1}$	$\cdots$	$\theta_{b\|X=1}$
$\vdots$	$\vdots$		$\vdots$
$X = a$	$\theta_{1\|X=a}$	$\cdots$	$\theta_{b\|X=a}$

Uma diferença nas distribuições condicionais significa que existe uma relação entre Y e X. Se denotamos por f_{ij} o número de observações na i-ésima amostra que têm $Y = j$, então, supondo que os tamanhos das amostras sejam pequenos em relação aos tamanhos das populações, a função de verossimilhança é dada por

$$L(\theta_{1|X=1}, \dots, \theta_{b|X=a} \mid (x_1, y_1), \dots, (x_n, y_n)) = \prod_{i=1}^{a} \prod_{j=1}^{b} (\theta_{j|X=i})^{f_{ij}}, \tag{10.2.3}$$

e o EMV é dado por $\hat{\theta}_{j|X=i} = f_{ij}/n_i$ (Problema 10.2.18).

Não existe relação entre Y e X se e somente se as distribuições condicionais não variam quando variamos X, ou seja, se e somente se

$$H_0 : \theta_{j|X=1} = \cdots = \theta_{j|X=a} = \theta_j$$

para todo $j = 1, \dots, b$, para alguma distribuição de probabilidade $\theta_1, \dots, \theta_b$. Sob H_0, a função de verossimilhança é dada por

$$L(\theta_1, \dots, \theta_b \mid (x_1, y_1), \dots, (x_n, y_n)) = \prod_{j=1}^{b} \theta_j^{f_{\cdot j}}, \tag{10.2.4}$$

e o EMV de θ_j é dado por $\hat{\theta}_j = f_{\cdot j}/n$ (veja o Problema 10.2.19). Então, aplicando o Teorema 9.1.2, temos que a estatística

$$X^2 = \sum_{i=1}^{a} \sum_{j=1}^{b} \frac{(f_{ij} - n_i \hat{\theta}_j)^2}{n_i \hat{\theta}_j}$$

tem distribuição aproximada $\chi^2((a-1)(b-1))$ sob H_0, porque há $a(b-1)$ parâmetros livres no modelo completo, $(b-1)$ parâmetros no modelo de independência e $a(b-1) - (b-1) = (a-1)(b-1)$.

Vejamos um exemplo.

Exemplo 10.2.2

Este exemplo foi tirado de um famoso livro de estatística aplicada, *Statistical Methods*, 6.ª ed., de G. Snedecor e W. Cochran (Iowa State University Press, Ames, 1967). Os indivíduos foram classificados segundo

seu tipo sanguíneo Y (O, A, B e AB, embora os indivíduos AB tenham sido eliminados, por serem poucos) e também segundo X, sua condição de doença (úlcera péptica = P, câncer gástrico = G ou controle = C). Assim, temos três populações, a saber: as pessoas que sofrem de úlcera péptica, as que sofrem de câncer gástrico e as que não sofrem de nenhum dos dois. Supomos ainda que os indivíduos envolvidos no estudo podem ser considerados amostras aleatórias das respectivas populações.

Os dados são dados na tabela a seguir.

	$Y = \text{O}$	$Y = \text{A}$	$Y = \text{B}$	Total
$X = \text{P}$	983	679	134	1796
$X = \text{G}$	383	416	84	883
$X = \text{C}$	2892	2625	570	6087

As distribuições condicionais estimadas de Y dado X são, então, as seguintes.

	$Y = \text{O}$	$Y = \text{A}$	$Y = \text{B}$
$X = \text{P}$	$983/1796 = 0{,}547$	$679/1796 = 0{,}378$	$134/1796 = 0{,}075$
$X = \text{G}$	$383/883 = 0{,}434$	$416/883 = 0{,}471$	$84/883 = 0{,}095$
$X = \text{C}$	$2892/6087 = 0{,}475$	$2625/6087 = 0{,}431$	$570/6087 = 0{,}093$

Agora queremos avaliar se há ou não alguma evidência para concluir que existe uma diferença entre essas distribuições condicionais. Sob a hipótese nula de que não existe diferença, os EMVs das probabilidades $\theta_1 = P(Y = \text{O})$, $\theta_2 = P(Y = \text{A})$ e $\theta_3 = P(Y = \text{B})$ são dados por

$$\hat{\theta}_1 = \frac{983 + 383 + 2892}{1796 + 883 + 6087} = 0{,}4857,$$
$$\hat{\theta}_2 = \frac{679 + 416 + 2625}{1796 + 883 + 6087} = 0{,}4244,$$
$$\hat{\theta}_3 = \frac{134 + 84 + 570}{1796 + 883 + 6087} = 0{,}0899.$$

Então as contagens esperadas estimadas $n_i\hat{\theta}_j$ são dadas pela tabela a seguir.

	$Y = \text{O}$	$Y = \text{A}$	$Y = \text{B}$
$X = \text{P}$	872,3172	762,2224	161,4604
$X = \text{G}$	428,8731	374,7452	79,3817
$X = \text{C}$	2956,4559	2583,3228	547,2213

Os resíduos padronizados (usando (9.1.6)) $(f_{ij} - n_i\hat{\theta}_j)/(n_i\hat{\theta}(1-\hat{\theta}_j))^{1/2}$ são dados pela tabela a seguir.*

	$Y = \text{O}$	$Y = \text{A}$	$Y = \text{B}$
$X = \text{P}$	5,2219	−3,9705	−2,2643
$X = \text{G}$	−3,0910	2,8111	0,5441
$X = \text{C}$	−1,6592	1,0861	1,0227

Temos $X^2 = 40{,}5434$ e $P(\chi^2(4) > 40{,}5434) = 0{,}0000$; assim, temos forte evidência contra a hipótese nula de que não existe relação entre Y e X. Observe os resíduos grandes quando $X = \text{P}$ e $Y = \text{O}$, $Y = \text{A}$.

Resta-nos examinar as distribuições condicionais para verificar que forma a relação entre Y e X assume. Uma ferramenta útil para isso é representar as distribuições condicionais em gráficos de barras, como fizemos na Figura 10.2.1. Por ela, vemos que a população com úlcera péptica tem uma proporção maior de tipo sanguíneo O do que as outras populações. ■

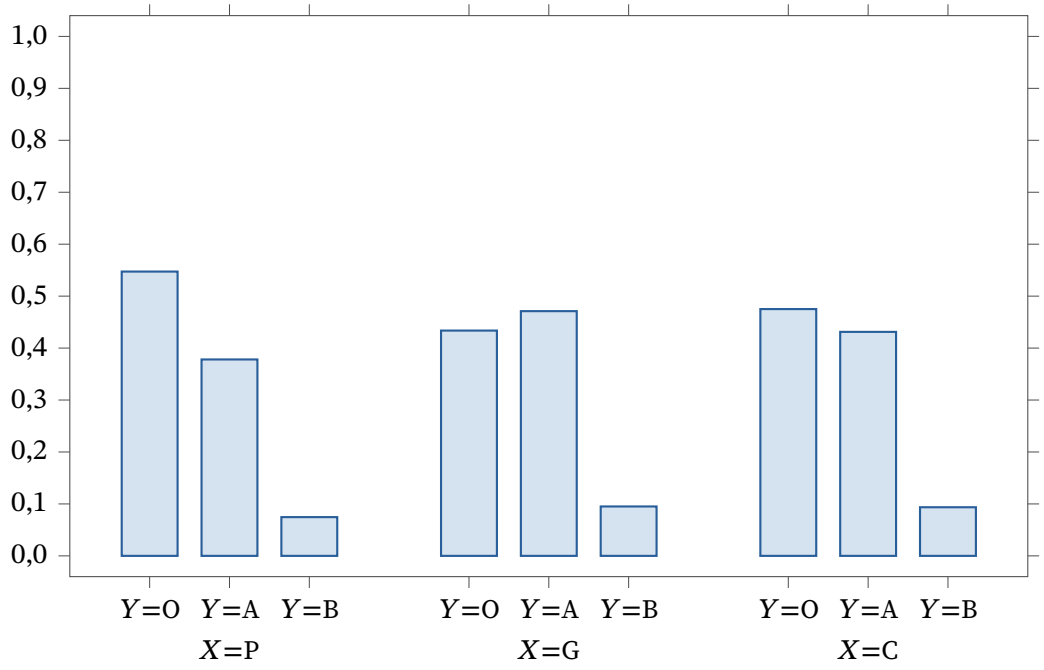


Figura 10.2.1: Gráfico das distribuições condicionais de Y, dado X, no Exemplo 10.2.2.

*Nota do tradutor. o original traz $\hat{\theta}$ sem índice no denominador; pelo contexto seria $n_i\hat{\theta}_j(1-\hat{\theta}_j)$.

10.2.3 Formulação Bayesiana

Agora acrescentamos uma densidade a priori[30] π para os valores desconhecidos dos parâmetros dos modelos discutidos nas Seções 10.2.1 e 10.2.2. Dependendo de como escolhemos π, e dependendo da conta específica que queremos fazer, poderíamos nos deparar com alguns problemas computacionais difíceis. É claro que temos à disposição, nessas circunstâncias, os métodos de Monte Carlo, que muitas vezes tornam uma conta bastante simples.

A escolha mais comum de priori nessas circunstâncias é uma priori conjugada[31]. Como as verossimilhanças discutidas nesta seção são como no Exemplo 7.1.3, vemos imediatamente que prioris Dirichlet serão conjugadas para o modelo completo da Seção 10.2.1 e que produtos de prioris Dirichlet independentes serão conjugados para o modelo completo da Seção 10.2.2.

Na Seção 10.2.1, a verossimilhança geral (isto é, sem restrições sobre os θ_{ij}) tem a forma

$$L(\theta_{11}, \dots, \theta_{ab} \mid (x_1, y_1), \dots, (x_n, y_n)) = \prod_{i=1}^{a} \prod_{j=1}^{b} \theta_{ij}^{f_{ij}}.$$

Se pusermos uma priori Dirichlet$(\alpha_{11}, \dots, \alpha_{ab})$ sobre o parâmetro, então a densidade a posteriori[32] é proporcional a

$$\prod_{i=1}^{a} \prod_{j=1}^{b} \theta_{ij}^{f_{ij}+\alpha_{ij}-1},$$

de modo que a posteriori[33] é uma distribuição Dirichlet[34]$(f_{11} + \alpha_{11}, \dots, f_{ab} + \alpha_{ab})$.

Na Seção 10.2.2, a verossimilhança geral tem a forma

$$L(\theta_{1|X=1}, \dots, \theta_{b|X=a} \mid (x_1, y_1), \dots, (x_n, y_n)) = \prod_{i=1}^{a} \prod_{j=1}^{b} (\theta_{j|X=i})^{f_{ij}}.$$

Como $\sum_{j=1}^{b} \theta_{j|X=i} = 1$ para cada $i = 1, \dots, a$, precisamos pôr uma priori sobre cada distribuição $(\theta_{1|X=i}, \dots, \theta_{b|X=i})$. Se escolhermos a priori[35] sobre a i-ésima distribuição como Dirichlet$(\alpha_{1|i}, \dots, \alpha_{a|i})$, então a densidade a posteriori é proporcional a*

$$\prod_{i=1}^{a} \prod_{j=1}^{b} \theta_{j|i}^{f_{ij}+\alpha_{j|i}-1}.$$

*Nota do tradutor. o original traz $\alpha_{a|i}$ como último parâmetro; como a distribuição tem b componentes, seria $\alpha_{b|i}$, como na posteriori logo abaixo.

No original: *prior*[30], *conjugate prior*[31], *posterior*[32], *posterior*[33], *Dirichlet distribution*[34], *prior*[35].

Reconhecemos isso como o produto de distribuições Dirichlet independentes, com a distribuição a posteriori de $(\theta_{1|X=i}, \ldots, \theta_{b|X=i})$ igual a uma distribuição

$$\text{Dirichlet}(f_{i1} + \alpha_{1|i}, \ldots, f_{ib} + \alpha_{b|i}).$$

Um caso especial e importante das prioris Dirichlet corresponde à situação em que sentimos não ter nenhuma informação sobre o parâmetro. Nessa situação, faz sentido escolher todos os parâmetros da Dirichlet iguais a 1, de modo que as prioris sejam todas uniformes.

Há muitas características de uma distribuição Dirichlet que podem ser calculadas em forma fechada, por exemplo, a esperança[36] de qualquer polinômio (veja o Problema 10.2.20). Mesmo assim, haverá muitas quantidades para as quais não haverá contas exatas disponíveis. Acontece que sempre podemos gerar facilmente amostras de distribuições Dirichlet, desde que tenhamos acesso a um gerador de distribuições beta. Isso está disponível na maioria dos pacotes estatísticos. Discutimos agora como fazer isso.

Exemplo 10.2.3 — Geração a Partir de uma Distribuição Dirichlet$(\alpha_1, \ldots, \alpha_k)$

A técnica que discutimos aqui é um método muito usado para gerar valores de distribuições multivariadas. Se queremos gerar um valor do vetor aleatório $(X_1, \ldots, X_k)$, podemos proceder da seguinte maneira. Primeiro, gere um valor x_1 da distribuição marginal de X_1. Em seguida, gere um valor x_2 da distribuição condicional de X_2 dado $X_1 = x_1$. Depois, gere um valor x_3 da distribuição condicional de X_3, dado que $X_1 = x_1$ e $X_2 = x_2$, etc.

Se a distribuição de X é discreta, então a probabilidade de um vetor de valores específico $(x_1, x_2, \ldots, x_k)$ surgir por esse esquema é

$$P(X_1 = x_1)P(X_2 = x_2 \mid X_1 = x_1) \cdots P(X_k = x_k \mid X_1 = x_1, \ldots, X_{k-1} = x_{k-1}).$$

Expandindo cada uma dessas probabilidades condicionais, obtemos

$$P(X_1 = x_1)\frac{P(X_1 = x_1, X_2 = x_2)}{P(X_1 = x_1)} \cdots \frac{P(X_1 = x_1, \ldots, X_{k-1} = x_{k-1}, X_k = x_k)}{P(X_1 = x_1, \ldots, X_{k-1} = x_{k-1})},$$

que é igual a $P(X_1 = x_1, \ldots, X_{k-1} = x_{k-1}, X_k = x_k)$; assim, $(x_1, x_2, \ldots, x_k)$ é um valor da distribuição conjunta de $(X_1, \ldots, X_k)$. Essa abordagem também funciona para distribuições absolutamente contínuas, e a demonstração é a mesma, mas usa funções densidade no lugar das probabilidades.

No original: *expectation*[36].

No caso de $(X_1, \ldots, X_{k-1}) \sim \text{Dirichlet}(\alpha_1, \ldots, \alpha_k)$, temos (veja o Desafio 10.2.23) que $X_1 \sim \text{Beta}(\alpha_1, \alpha_2 + \cdots + \alpha_k)$ e que X_i, dado $X_1 = x_1, \ldots, X_{i-1} = x_{i-1}$, tem a mesma distribuição que $(1 - x_1 - \cdots - x_{i-1})U_i$, em que

$$U_i \sim \text{Beta}(\alpha_i, \alpha_{i+1} + \cdots + \alpha_k)$$

e $U_2, \ldots, U_{k-1}$ são independentes. Note que $X_k = 1 - X_1 - \cdots - X_{k-1}$ para qualquer distribuição Dirichlet. Então geramos $X_1 \sim \text{Beta}(\alpha_1, \alpha_2 + \cdots + \alpha_k)$, geramos $U_2 \sim \text{Beta}(\alpha_2, \alpha_3 + \cdots + \alpha_k)$ e pomos $X_2 = (1 - X_1)U_2$, geramos $U_3 \sim \text{Beta}(\alpha_3, \alpha_4 + \cdots + \alpha_k)$ e pomos $X_3 = (1 - X_1 - X_2)U_3$ etc.

A seguir, apresentamos uma tabela com uma amostra de $n = 5$ valores de uma distribuição Dirichlet(2; 3; 1; 1,5).

	X_1	X_2	X_3	X_4
1	0,116159	0,585788	0,229019	0,069034
2	0,166639	0,566369	0,056627	0,210366
3	0,411488	0,183686	0,326451	0,078375
4	0,483124	0,316647	0,115544	0,084684
5	0,117876	0,147869	0,418013	0,316242

O Apêndice B contém o código usado para isso. Ele pode ser modificado para gerar valores de qualquer distribuição Dirichlet. ■

Resumo da Seção 10.2

- Nesta seção, consideramos a situação em que temos uma variável resposta categórica e uma variável preditora categórica.
- Distinguimos duas situações. A primeira surge quando o valor da variável preditora não é atribuído, e a segunda, quando é.
- Nos dois casos, o teste da hipótese nula de que não existe relação envolveu o teste qui-quadrado.

Exercícios

10.2.1 A tabela a seguir dá as contagens de acidentes em dois anos sucessivos numa determinada cidade.

	Junho	Julho	Agosto
Ano 1	60	100	80
Ano 2	80	100	60

Há alguma evidência de diferença na distribuição dos acidentes nesses meses entre os dois anos?

10.2.2 Os dados a seguir são de um estudo de Linus Pauling (1971) ("The significance of the evidence about ascorbic acid and the common cold", *Proceedings of the National Academy of Sciences*, Vol. 68, p. 2678), que examinou a relação entre tomar vitamina C e a incidência de resfriados. Dos 279 participantes do estudo, 140 receberam um placebo (pílula de açúcar) e 139 receberam vitamina C.

	Sem resfriado	Resfriado
Placebo	31	109
Vitamina C	17	122

Avalie a hipótese nula de que não existe relação entre tomar vitamina C e a incidência de resfriado comum.

10.2.3 Um experimento de simulação é feito para ver se existe alguma relação entre o primeiro e o segundo dígitos de uma variável aleatória gerada de uma distribuição Uniforme[37] $[0, 1]$. Foram geradas, no total, 1000 uniformes; se o primeiro e o segundo dígitos estavam em $\{0, 1, 2, 3, 4\}$, eram registrados como 0, e como 1 caso contrário. Os dados com a classificação cruzada são dados na tabela a seguir.

	Segundo dígito 0	Segundo dígito 1
Primeiro dígito 0	240	250
Primeiro dígito 1	255	255

Avalie a hipótese nula de que não existe relação entre os dígitos.

10.2.4 As notas numa disciplina de cálculo do primeiro ano foram obtidas para estudantes selecionados aleatoriamente em duas universidades e classificadas como aprovado ou reprovado. Foram obtidos os dados a seguir.

	Reprovado	Aprovado
Universidade 1	33	143
Universidade 2	22	263

No original: *uniform distribution*[37].

Há alguma evidência de relação entre as notas de cálculo e a universidade?

10.2.5 Os dados a seguir estão registrados em *Statistical Methods for Research Workers*, de R. A. Fisher (Hafner Press, Nova York, 1922), e mostram a classificação de 3883 crianças escocesas por sexo (X) e cor do cabelo (Y).

	$Y =$ loiro	$Y =$ ruivo	$Y =$ médio	$Y =$ escuro	$Y =$ preto-azeviche
$X =$ m	592	119	849	504	36
$X =$ f	544	97	677	451	14

(a) Há alguma evidência de relação entre a cor do cabelo e o sexo?

(b) Faça o(s) gráfico(s) de barras apropriado(s).

(c) Registre os resíduos e relacione-os com os resultados das partes (a) e (b). O que você conclui sobre o tamanho de qualquer desvio da independência?

10.2.6 Suponha que temos um preditor controlável X que assume quatro valores diferentes e que medimos uma resposta binária Y. Uma amostra aleatória de 100 foi tirada da população, e o valor de X foi atribuído aleatoriamente a cada indivíduo de tal maneira que há 25 membros da amostra assumindo cada um dos valores possíveis de X. Suponha que os dados a seguir foram obtidos.

	$X = 1$	$X = 2$	$X = 3$	$X = 4$
$Y = 0$	12	10	16	14
$Y = 1$	13	15	9	11

(a) Avalie se há ou não alguma evidência contra a existência de uma relação de causa e efeito entre X e Y.

(b) Explique por que é possível, neste exemplo, afirmar que qualquer evidência encontrada de que existe uma relação é evidência de que existe uma relação de causa e efeito.

10.2.7 Escreva em detalhes como você geraria um valor de uma distribuição Dirichlet$(1, 1, 1, 1)$.

10.2.8 Suponha que temos duas variáveis categóricas definidas numa população Π e que fazemos um censo. Como você decidiria se existe ou não uma relação entre X e Y? Se você decidisse que existe uma relação, como distinguiria entre uma relação forte e uma fraca?

10.2.9 Suponha que você lança dois dados simultaneamente n vezes e registra os resultados. Com base nesses valores, como você avaliaria a hipótese nula de que o resultado de cada dado é independente do resultado do outro?

10.2.10 Suponha que um professor queira avaliar se há ou não alguma diferença nas distribuições das notas finais (A, B, C, D e F) entre homens e mulheres numa determinada turma. Para avaliar a hipótese nula de que não há diferença entre essas distribuições, o professor faz um teste qui-quadrado.

(a) Discuta como o professor fez esse teste.

(b) Se o professor obteve evidência contra a hipótese nula, discuta que preocupações você tem quanto ao uso do teste qui-quadrado.

10.2.11 Suponha que um teste qui-quadrado seja feito, com base numa amostra aleatória de tamanho n de uma população, para avaliar se duas variáveis categóricas X e Y são ou não independentes. Suponha que o valor-p seja igual a 0,001 e que o pesquisador conclua que há evidência contra a independência. Discuta como você verificaria se o desvio da independência tem significância prática.

Problemas

10.2.12 No Exemplo 10.2.1, ponha uma priori uniforme sobre os parâmetros (uma distribuição Dirichlet com todos os parâmetros iguais a 1) e então determine a distribuição a posteriori dos parâmetros.

10.2.13 No Exemplo 10.2.2, ponha uma priori uniforme sobre os parâmetros de cada população (uma distribuição Dirichlet com todos os parâmetros iguais a 1), de modo que as três prioris sejam independentes. Então determine a distribuição a posteriori.

10.2.14 Numa tabela 2×2 com probabilidades θ_{ij}, prove que as variáveis de linha e de coluna são independentes se e somente se

$$\frac{\theta_{11}\theta_{22}}{\theta_{12}\theta_{21}} = 1,$$

ou seja, temos independência se e somente se a *razão cruzada* é igual a 1.

10.2.15 Estabeleça que a verossimilhança em (10.2.1) está correta quando o tamanho da população é infinito (ou quando fazemos amostragem com reposição[38] da população).

No original: *sampling with replacement*[38].

10.2.16 (MV) Prove que o EMV de $(\theta_{11}, \ldots, \theta_{ab})$ em (10.2.1) é dado por $\hat{\theta}_{ij} = f_{ij}/n$. Suponha que $f_{ij} > 0$ para todo i, j. (Sugestão: use os fatos de que uma função contínua neste espaço paramétrico $\mathbf{\Omega}$ precisa atingir seu máximo em algum ponto de $\mathbf{\Omega}$ e de que, se a função for continuamente diferenciável num tal ponto, então todas as suas derivadas parciais de primeira ordem são nulas ali. Isso permitirá concluir que a única solução das equações escore deve ser o ponto em que a log-verossimilhança[39] é maximizada. Tente primeiro o caso em que $a = 2$, $b = 2$.)

10.2.17 (MV) Prove que o EMV de $(\theta_{1\cdot}, \ldots, \theta_{a\cdot}, \theta_{\cdot 1}, \ldots, \theta_{\cdot b})$ em (10.2.2) é dado por $\hat{\theta}_{i\cdot} = f_{i\cdot}/n$ e $\hat{\theta}_{\cdot j} = f_{\cdot j}/n$. Suponha que $f_{i\cdot} > 0$, $f_{\cdot j} > 0$ para todo i, j. (Sugestão: use a sugestão do Problema 10.2.16.)

10.2.18 (MV) Prove que o EMV de $(\theta_{1|X=1}, \ldots, \theta_{b|X=a})$ em (10.2.3) é dado por $\hat{\theta}_{j|X=i} = f_{ij}/n_i$. Suponha que $f_{ij} > 0$ para todo i, j. (Sugestão: use a sugestão do Problema 10.2.16.)

10.2.19 (MV) Prove que o EMV de $(\theta_1, \ldots, \theta_b)$ em (10.2.4) é dado por $\hat{\theta}_j = f_{\cdot j}/n$. Suponha que $f_{\cdot j} > 0$ para todo i, j. (Sugestão: use a sugestão do Problema 10.2.16.)

10.2.20 Suponha que $X = (X_1, \ldots, X_{k-1}) \sim \text{Dirichlet}(\alpha_1, \ldots, \alpha_k)$. Determine $E(X_1^{l_1} \cdots X_k^{l_k})$ em termos da função gama[40], quando $l_i > 0$ para $i = 1, \ldots, k$.

Problemas computacionais

10.2.21 Suponha que $(\theta_1, \theta_2, \theta_3, \theta_4) \sim \text{Dirichlet}(1, 1, 1, 1)$, como no Exercício 10.2.7. Gere uma amostra de tamanho $N = 10^4$ dessa distribuição e use-a para estimar as esperanças dos θ_i. Compare essas estimativas com seus valores exatos. (Sugestão: há código relevante no Apêndice B para a geração; veja o Apêndice C para as fórmulas dos valores exatos dessas esperanças.)

10.2.22 Para o Problema 10.2.12, gere uma amostra de tamanho $N = 10^4$ da distribuição a posteriori dos parâmetros e use-a para estimar as esperanças a posteriori das probabilidades das caselas. Compare essas estimativas com seus valores exatos. (Sugestão: há código relevante no Apêndice B para a geração; veja o Apêndice C para as fórmulas dos valores exatos dessas esperanças.)

No original: *log-likelihood*[39], *gamma function*[40].

Desafios

10.2.23 (MV) Estabeleça a validade do método discutido no Exemplo 10.2.3 para gerar valores de uma distribuição Dirichlet$(\alpha_1, \ldots, \alpha_k)$.

10.3 Resposta e Preditores Quantitativos

Quando as variáveis resposta e preditoras são todas categóricas, pode ser difícil formular modelos simples que descrevam adequadamente a relação entre as variáveis. Resta-nos registrar as distribuições condicionais e representá-las em gráficos de barras. Quando a variável resposta é quantitativa, porém, foram formulados modelos úteis que dão uma expressão matemática precisa para a forma da relação que possa existir. Vamos estudar esses tipos de modelo nas próximas três seções. Esta seção se concentra na situação em que todas as variáveis são quantitativas.

10.3.1 O Método dos Mínimos Quadrados

O *método dos mínimos quadrados*[41] é um método geral para obter uma estimativa da média de uma distribuição. Ele não exige suposições específicas sobre a distribuição e, por isso, pode ser visto como um método livre de distribuição (ver Seção 6.4).

Suponha que temos uma variável aleatória Y e queremos estimar $E(Y)$ com base em uma amostra $(y_1, \ldots, y_n)$. O princípio a seguir é muito usado para gerar estimativas.

> O *princípio de mínimos quadrados* diz que escolhemos o ponto $t(y_1, \ldots, y_n)$, no conjunto de valores possíveis de $E(Y)$, que minimiza a soma dos desvios ao quadrado (daí o nome "mínimos quadrados") dada por $\sum_{i=1}^{n}(y_i - t(y_1, \ldots, y_n))^2$. Uma estimativa assim é chamada de *estimativa de mínimos quadrados*[42].

Observe que uma estimativa de mínimos quadrados está definida para qualquer tamanho da amostra, mesmo $n = 1$.

No original: *least squares*[41], *least-squares estimate*[42].

Para aplicar os mínimos quadrados, precisamos encontrar o ponto minimizador $t(y_1, \ldots, y_n)$. Um primeiro palpite para esse valor talvez seja a média amostral $\bar{y}$. Como $\sum_{i=1}^{n}(y_i - \bar{y})(\bar{y} - t(y_1, \ldots, y_n)) = (\bar{y} - t(y_1, \ldots, y_n))\left(\sum_{i=1}^{n} y_i - n\bar{y}\right) = 0$, temos

$$\begin{aligned}\sum_{i=1}^{n}(y_i - t(y_1, \ldots, y_n))^2 &= \sum_{i=1}^{n}(y_i - \bar{y} + \bar{y} - t(y_1, \ldots, y_n))^2 \\ &= \sum_{i=1}^{n}(y_i - \bar{y})^2 + 2\sum_{i=1}^{n}(y_i - \bar{y})(\bar{y} - t(y_1, \ldots, y_n)) + \sum_{i=1}^{n}(\bar{y} - t(y_1, \ldots, y_n))^2 \\ &= \sum_{i=1}^{n}(y_i - \bar{y})^2 + n(\bar{y} - t(y_1, \ldots, y_n))^2. \qquad (10.3.1)\end{aligned}$$

Portanto, o menor valor possível de (10.3.1) é $\sum_{i=1}^{n}(y_i - \bar{y}^2)$,* e ele é atingido tomando $t(y_1, \ldots, y_n) = \bar{y}$. Observe, porém, que $\bar{y}$ pode não ser um valor possível de $E(Y)$ e, nesse caso, não será a estimativa de mínimos quadrados. Em geral, (10.3.1) diz que a estimativa de mínimos quadrados é o valor $t(y_1, \ldots, y_n)$ que está mais próximo de $\bar{y}$ e é um valor possível de $E(Y)$.

Considere o exemplo a seguir.

Exemplo 10.3.1

Suponha que Y tenha uma das distribuições em $S = \{0, 1\}$ dadas na tabela a seguir.

	$y = 0$	$y = 1$
$p_1(y)$	1/2	1/2
$p_2(y)$	1/3	2/3

Então, a média de Y é dada por

$$E_1(Y) = 0\left(\frac{1}{2}\right) + 1\left(\frac{1}{2}\right) = \frac{1}{2} \quad \text{ou} \quad E_2(Y) = 0\left(\frac{1}{3}\right) + 1\left(\frac{2}{3}\right) = \frac{2}{3}.$$

Agora suponha que observamos a amostra $(0, 0, 1, 1, 1)$, de modo que $\bar{y} = 3/5$. Como os valores possíveis de $E(Y)$ estão em $\{1/2, 2/3\}$, vemos que $t(0, 0, 1, 1, 1) = 2/3$, pois $(3/5 - 2/3)^2 = 0{,}004$, enquanto $(3/5 - 1/2)^2 = 0{,}01$. ■

Sempre que o conjunto de valores possíveis de $E(Y)$ for um intervalo (a, b) e $P(Y \in (a, b)) = 1$, porém, teremos $\bar{y} \in (a, b)$. Isso implica que $\bar{y}$ é o estimador

*Nota do tradutor. O original traz $(y_i - \bar{y}^2)$; pela conta seria $(y_i - \bar{y})^2$.

de mínimos quadrados de $E(Y)$. Vemos, então, que em circunstâncias bastante gerais $\bar{y}$ é a estimativa de mínimos quadrados.

Há uma equivalência entre os mínimos quadrados e o método da máxima verossimilhança quando lidamos com distribuições normais.

Exemplo 10.3.2 — Mínimos Quadrados com Distribuições Normais

Suponha que $(y_1, \dots, y_n)$ seja uma amostra de uma distribuição $N(\mu, \sigma_0^2)$, em que μ é desconhecido. Então, o EMV de μ é obtido encontrando o valor de μ que maximiza

$$L(\mu \mid y_1, \dots, y_n) = \exp\left\{-\frac{n}{2\sigma_0^2}(\bar{y} - \mu)^2\right\}.$$

De modo equivalente, o EMV maximiza a log-verossimilhança

$$l(\mu \mid y_1, \dots, y_n) = -\frac{n}{2\sigma_0^2}(\bar{y} - \mu)^2.$$

Assim, precisamos encontrar o valor de μ que minimiza $(\bar{y} - \mu)^2$, exatamente como nos mínimos quadrados.

No caso do modelo normal de locação, vemos que a estimativa de mínimos quadrados e o EMV de θ coincidem.* Essa equivalência vale em geral para modelos normais (por exemplo, o modelo normal de locação e escala), pelo menos quando consideramos estimativas de parâmetros de locação. ■

Algumas das aplicações mais importantes dos mínimos quadrados surgem quando a resposta é um vetor aleatório $Y = (Y_1, \dots, Y_n)' \in R^n$ (a linha $'$ indica que consideramos Y como uma coluna) e observamos uma única observação $y = (y_1, \dots, y_n)' \in R^n$. O valor esperado[43] de $Y \in R^n$ é definido como o vetor das esperanças das variáveis aleatórias que são suas componentes, isto é,

$$E(Y) = \begin{pmatrix} E(Y_1) \\ \vdots \\ E(Y_n) \end{pmatrix} \in R^n.$$

O princípio de mínimos quadrados diz, então, que, com base na única

*Nota do tradutor. O original traz θ; pelo exemplo seria μ.

No original: *expected value*[43].

observação $y = (y_1, \ldots, y_n)$, precisamos encontrar*

$$t(y) = t(y_1, \ldots, y_n) = t_1(y_1, \ldots, y_n), \ldots, t_n(y_1, \ldots, y_n))',$$

no conjunto de valores possíveis de $E(Y)$ (um subconjunto de R^n), que minimiza

$$\sum_{i=1}^{n}(y_i - t_i(y_1, \ldots, y_n))^2. \tag{10.3.2}$$

Assim, $t(y)$ é o valor possível de $E(Y)$ que está mais próximo de y, já que o quadrado da distância entre dois pontos $x, y \in R^n$ é dado por $\sum_{i=1}^{n}(x_i - y_i)^2$.

Como é comum nas aplicações estatísticas, suponha que existam variáveis preditoras que possam estar relacionadas com Y e cujos valores são observados. Nesse caso, vamos substituir $E(Y)$ por sua média condicional, dados os valores observados dos preditores. A estimativa de mínimos quadrados da média condicional é, então, o valor $t(y_1, \ldots, y_n)$, no conjunto de valores possíveis da média condicional de Y, que minimiza (10.3.2). Usaremos essa definição nas seções seguintes.

Encontrar o valor minimizador de $t(y)$ em (10.3.2) pode ser um problema de otimização difícil quando o conjunto de valores possíveis da média é complicado. Vamos agora aplicar os mínimos quadrados a alguns problemas importantes em que a solução de mínimos quadrados pode ser encontrada em forma fechada.

10.3.2 O Modelo de Regressão Linear Simples

Suponha que temos uma única variável resposta quantitativa Y e um único preditor quantitativo X; por exemplo, Y poderia ser a pressão arterial medida em libras por polegada quadrada e X poderia ser a idade em anos. Para estudar a relação entre essas variáveis, examinamos as distribuições condicionais de Y, dado $X = x$, para ver como elas mudam quando mudamos x.

Podemos escolher examinar uma característica específica dessas distribuições para ver como ela varia com x. Talvez a característica mais usada seja a média condicional de Y dado $X = x$, ou $E(Y \mid X = x)$ (ver Seção 3.5).

No *modelo de regressão* (ver Seção 10.1), *supomos* que as distribuições condicionais têm forma constante e que elas mudam, quando mudamos x, no máximo por meio da média condicional. No *modelo de regressão linear simples*[44],

*Nota do tradutor. O original traz $t_1(\ldots), \ldots, t_n(\ldots))'$ sem o parêntese de abertura; seria $(t_1(\ldots), \ldots, t_n(\ldots))'$.

No original: *simple linear regression model*[44].

supomos que a única maneira de a média condicional mudar é por meio da relação

$$E(Y \mid X = x) = \beta_1 + \beta_2 x,$$

para alguns valores desconhecidos $\beta_1 \in R^1$ (o intercepto) e $\beta_2 \in R^1$ (o coeficiente angular). Também chamamos β_1 e β_2 de *coeficientes de regressão*.

Suponha que observamos os valores independentes $(x_1, y_1), \ldots, (x_n, y_n)$ de (X, Y). Então, usando o modelo de regressão linear simples, temos

$$E\left(\begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix} \middle| X_1 = x_1, \ldots, X_n = x_n\right) = \begin{pmatrix} \beta_1 + \beta_2 x_1 \\ \vdots \\ \beta_1 + \beta_2 x_n \end{pmatrix}. \tag{10.3.3}$$

A equação (10.3.3) nos diz que o valor esperado condicional da resposta $(Y_1, \ldots, Y_n)'$ está num subconjunto específico de R^n. Além disso, (10.3.2) se torna

$$\sum_{i=1}^{n} (y_i - t_i(y))^2 = \sum_{i=1}^{n} (y_i - \beta_1 - \beta_2 x_i)^2, \tag{10.3.4}$$

e precisamos encontrar os valores de β_1 e β_2 que minimizam (10.3.4). Esses valores são chamados de *estimativas de mínimos quadrados* de β_1 e β_2.

Antes de mostrar como fazer isso, considere um exemplo.

Exemplo 10.3.3

Suponha que obtivemos os seguintes $n = 10$ pontos de dados (x_i, y_i).

(3,9; 8,9)	(2,6; 7,1)	(2,4; 4,6)	(4,1; 10,7)	(−0,2; 1,0)
(5,4; 12,6)	(0,6; 3,3)	(−5,6; −10,4)	(−1,1; −2,3)	(−2,1; −1,6)

Na Figura 10.3.1, representamos esses pontos junto com a reta $y = 1 + x$.

Observe que, com $\beta_1 = 1$ e $\beta_2 = 1$,

$$(y_i - \beta_1 - \beta_2 x_i)^2 = (y_i - 1 - x_i)^2$$

é o quadrado da distância vertical entre o ponto (x_i, y_i) e o ponto da reta com o mesmo valor de x. Assim, (10.3.4) é a soma desses desvios ao quadrado e, neste caso, é igual a

$$(8{,}9 - 1 - 3{,}9)^2 + (7{,}1 - 1 - 2{,}6)^2 + \cdots + (-1{,}6 - 1 + 2{,}1)^2 = 141{,}15.$$

Se $\beta_1 = 1$ e $\beta_2 = 1$ fossem as estimativas de mínimos quadrados, então 141,15 seria igual ao menor valor possível de (10.3.4). Neste caso, ocorre (ver Exemplo 10.3.4) que as estimativas de mínimos quadrados são dadas pelos valores $\beta_1 = 1{,}33$, $\beta_2 = 2{,}06$, e o valor minimizado de (10.3.4) é 8,46, que é muito menor que 141,15.

Vemos, então, que, ao encontrar as estimativas de mínimos quadrados, estamos essencialmente encontrando a reta $\beta_1 + \beta_2 x$ que melhor se ajusta aos dados, no sentido de que a soma dos quadrados dos desvios verticais dos pontos observados em relação à reta é minimizada. ■

Diagramas de Dispersão

Como parte do Exemplo 10.3.3, representamos os pontos $(x_1, y_1), \ldots, (x_n, y_n)$ num gráfico. Ele é chamado de *diagrama de dispersão*[45] e é um primeiro passo recomendado em qualquer análise da relação entre variáveis quantitativas X e Y. Um diagrama de dispersão pode nos dar uma ideia bem geral de se existe ou não uma relação e de que forma ela pode ter.

É importante lembrar, porém, que a aparência de um gráfico assim depende muito das escalas que escolhemos para os eixos. Por exemplo, podemos fazer um diagrama de dispersão parecer praticamente plano (e, assim, indicar que

No original: *scatter plot*[45].

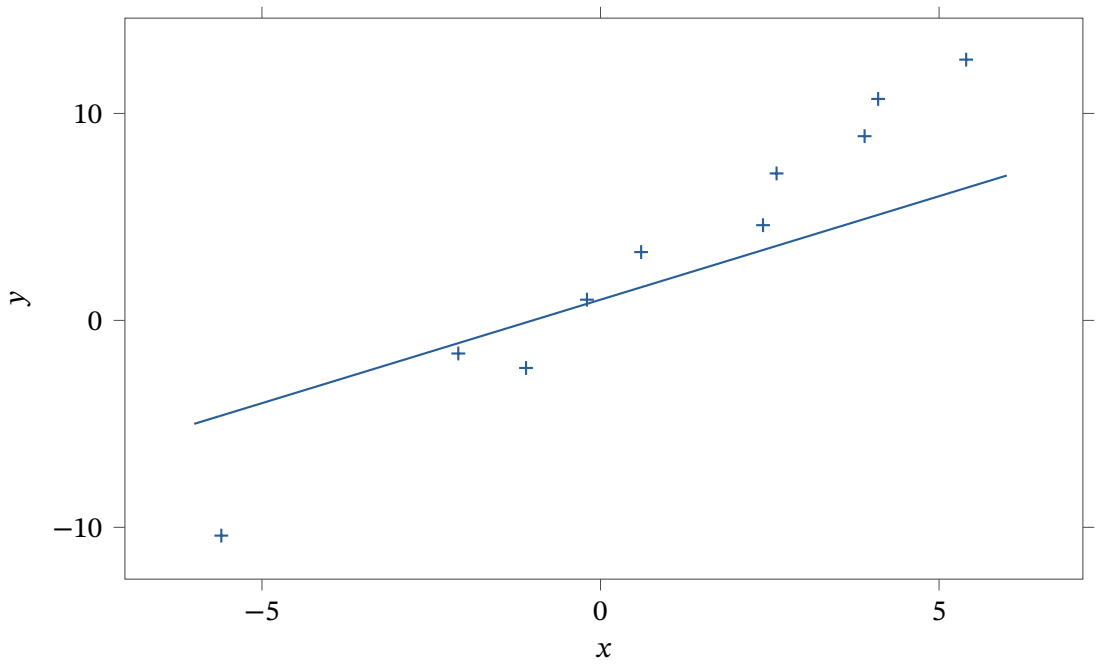


Figura 10.3.1: Gráfico dos pontos de dados (x_i, y_i) (+) e da reta $y = 1 + x$ no Exemplo 10.3.3.

não existe relação) escolhendo pôr marcas de escala ao longo de uma faixa larga demais no eixo y. Assim, devemos sempre complementar[46] um diagrama de dispersão com uma análise estatística baseada em números.

Estimativas de Mínimos Quadrados, Predições e Erros Padrão

Para o modelo de regressão linear simples, podemos obter fórmulas exatas para as estimativas de mínimos quadrados de β_1 e β_2.

Teorema 10.3.1

Suponha que $E(Y \mid X = x) = \beta_1 + \beta_2 x$ e que observamos os valores independentes $(x_1, y_1), \ldots, (x_n, y_n)$ de (X, Y). Então, as estimativas de mínimos quadrados de β_1 e β_2 são dadas por

$$b_1 = \bar{y} - b_2\bar{x} \quad \text{e} \quad b_2 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n}(x_i - \bar{x})^2},$$

respectivamente, sempre que $\sum_{i=1}^{n}(x_i - \bar{x})^2 \neq 0$.

No original: *complement*[46].

Demonstração. A demonstração deste resultado está na Seção 10.6. ■

Chamamos a reta $y = b_1 + b_2 x$ de *reta de mínimos quadrados*, ou *reta de melhor ajuste*, e $b_1 + b_2 x$ é a estimativa de mínimos quadrados de $E(Y \mid X = x)$. Observe que $\sum_{i=1}^{n}(x_i - \bar{x})^2 = 0$ se e somente se $x_1 = \cdots = x_n$. Nesse caso, não podemos usar mínimos quadrados para estimar β_1 e β_2, embora ainda possamos estimar $E(Y \mid X = x)$ (ver Problema 10.3.19).

Agora que temos as estimativas b_1, b_2 dos coeficientes de regressão, queremos usá-las para fazer inferências sobre β_1 e β_2. Essas estimativas têm a propriedade de serem não viesadas.

Teorema 10.3.2

Se $E(Y \mid X = x) = \beta_1 + \beta_2 x$ e observamos os valores independentes $(x_1, y_1), \ldots, (x_n, y_n)$ de (X, Y), então

(i) $E(B_1 \mid X_1 = x_1, \ldots, X_n = x_n) = \beta_1$,

(ii) $E(B_2 \mid X_1 = x_1, \ldots, X_n = x_n) = \beta_2$.

Demonstração. A demonstração deste resultado está na Seção 10.6. ■

Observe que o Teorema 10.3.2 e o teorema da esperança total implicam que $E(B_1) = \beta_1$ e $E(B_2) = \beta_2$ também incondicionalmente.

Acrescentando a suposição de que as variâncias condicionais existem, temos o teorema a seguir.

Teorema 10.3.3

Se $E(Y \mid X = x) = \beta_1 + \beta_2 x$, $\mathrm{Var}(Y \mid X = x) = \sigma^2$ para todo x, e observamos os valores independentes $(x_1, y_1), \ldots, (x_n, y_n)$ de (X, Y), então

(i) $\mathrm{Var}(B_1 \mid X_1 = x_1, \ldots, X_n = x_n) = \sigma^2 \left(1/n + \bar{x}^2 \Big/ \sum_{i=1}^{n}(x_i - \bar{x})^2\right)$,

(ii) $\mathrm{Var}(B_2 \mid X_1 = x_1, \ldots, X_n = x_n) = \sigma^2 \Big/ \sum_{i=1}^{n}(x_i - \bar{x})^2$,

(iii) $\mathrm{Cov}(B_1, B_2 \mid X_1 = x_1, \ldots, X_n = x_n) = -\sigma^2 \bar{x} \Big/ \sum_{i=1}^{n}(x_i - \bar{x})^2$.

Demonstração. Ver a Seção 10.6 para a demonstração deste resultado. ■

Para a estimativa de mínimos quadrados $b_1 + b_2 x$ da média $E(Y \mid X = x) = \beta_1 + \beta_2 x$, temos o resultado a seguir.

Corolário 10.3.1

$$\text{Var}(B_1 + B_2 x \mid X_1 = x_1, \ldots, X_n = x_n) = \sigma^2 \left(\frac{1}{n} + \frac{(x - \bar{x})^2}{\sum_{i=1}^{n} (x_i - \bar{x})^2} \right) \tag{10.3.5}$$

Demonstração. Ver a Seção 10.6 para a demonstração deste resultado. ■

Um preditor natural de um valor futuro de Y, quando $X = x$, é dado pela média condicional $E(Y \mid X = x) = \beta_1 + \beta_2 x$. Como não conhecemos os valores de β_1 e β_2, usamos a média estimada $b_1 + b_2 x$ como preditor.

Quando predizemos Y num valor de x que está dentro da faixa dos valores observados de X, dizemos que se trata de uma *interpolação*. Quando queremos predizer num valor de x que está fora dessa faixa, dizemos que se trata de uma *extrapolação*. Extrapolações são muito menos confiáveis que interpolações. Intuitivamente, quanto mais longe x estiver da faixa observada de valores de X, menos confiável nos parecerá essa predição[47]. Considerações assim devem estar sempre em mente. Por (10.3.5), vemos que a variância da predição no valor $X = x$ aumenta à medida que x se afasta de $\bar{x}$. Assim, até certo ponto, o erro padrão reflete esse aumento da incerteza, mas observe que sua forma se baseia na suposição de que o modelo de regressão linear simples está correto. Mesmo que aceitemos o modelo de regressão linear simples com base nos dados observados (vamos discutir a verificação do modelo mais adiante nesta seção), esse modelo pode deixar de valer para valores muito diferentes de x e, então, as predições estariam erradas.

Queremos usar os resultados do Teorema 10.3.3 e do Corolário 10.3.1 para calcular erros padrão das estimativas de mínimos quadrados. Como não conhecemos σ^2, porém, precisamos também de uma estimativa dessa quantidade. O resultado a seguir mostra que

$$s^2 = \frac{1}{n-2} \sum_{i=1}^{n} (y_i - b_1 - b_2 x_i)^2 \tag{10.3.6}$$

é uma estimativa não viesada de σ^2.

No original: *prediction*[47].

Teorema 10.3.4

Se $E(Y \mid X = x) = \beta_1 + \beta_2 x$, $\text{Var}(Y \mid X = x) = \sigma^2$ para todo x, e observamos os valores independentes $(x_1, y_1), \ldots, (x_n, y_n)$ de (X, Y), então

$$E(S^2 \mid X_1 = x_1, \ldots, X_n = x_n) = \sigma^2.$$

Demonstração. Ver a Seção 10.6 para a demonstração deste resultado. ■

Portanto, o erro padrão de b_1 é dado por

$$s\left(\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^{n}(x_i - \bar{x})^2}\right)^{1/2},$$

e o erro padrão de b_2 é dado por

$$s\left(\sum_{i=1}^{n}(x_i - \bar{x})^2\right)^{-1/2}.$$

Sob suposições adicionais, esses erros padrão podem ser interpretados exatamente como interpretamos os erros padrão das estimativas da média nos modelos normais de locação e de locação e escala.

Exemplo 10.3.4 — continuação do Exemplo 10.3.3

Usando os dados do Exemplo 10.3.3 e as fórmulas do Teorema 10.3.1, obtemos $b_1 = 1{,}33$, $b_2 = 2{,}06$ como as estimativas de mínimos quadrados do intercepto e do coeficiente angular, respectivamente. Assim, a reta de mínimos quadrados é dada por $1{,}33 + 2{,}06x$. Usando (10.3.6), obtemos $s^2 = 1{,}06$ como estimativa de σ^2.

Usando as fórmulas do Teorema 10.3.3, o erro padrão de b_1 é 0,3408, enquanto o erro padrão de b_2 é 0,1023.

A predição de Y em $X = 2{,}0$ é dada por $1{,}33 + 2{,}06(2) = 5{,}45$. Pelo Corolário 10.3.1, essa estimativa tem erro padrão 0,341. Essa predição é uma interpolação. ■

A Decomposição ANOVA e a Estatística F

O resultado a seguir dá uma decomposição da *soma de quadrados total* $\sum_{i=1}^{n}(y_i - \bar{y})^2$.

Lema 10.3.1

Se $(x_1, y_1), \ldots, (x_n, y_n)$ são tais que $\sum_{i=1}^n (x_i - \bar{x})^2 \neq 0$, então

$$\sum_{i=1}^n (y_i - \bar{y})^2 = b_2^2 \sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{i=1}^n (y_i - b_1 - b_2 x_i)^2.$$

Demonstração. A demonstração deste resultado está na Seção 10.6. ■

Chamamos

$$b_2^2 \sum_{i=1}^n (x_i - \bar{x})^2$$

de *soma de quadrados da regressão* (RSS) e chamamos

$$\sum_{i=1}^n (y_i - b_1 - b_2 x_i)^2$$

de *soma de quadrados dos erros* (ESS).

Se pensarmos na soma de quadrados total como uma medida da variação total observada nos valores da resposta y_i, então o Lema 10.3.1 dá uma decomposição dessa variação em RSS, que mede as mudanças na resposta devidas a mudanças no preditor, e ESS, que mede as mudanças na resposta devidas à contribuição do erro aleatório.

É comum escrever essa decomposição numa *tabela de análise de variância* (ANOVA).

Fonte	GL	Soma de Quadrados	Quadrado Médio
X	1	$b_2^2 \sum_{i=1}^n (x_i - \bar{x})^2$	$b_2^2 \sum_{i=1}^n (x_i - \bar{x})^2$
Erro	$n-2$	$\sum_{i=1}^n (y_i - b_1 - b_2 x_i)^2$	s^2
Total	$n-1$	$\sum_{i=1}^n (y_i - \bar{y})^2$	

Aqui, GL indica os graus de liberdade[48] (vamos discutir como as entradas de GL são calculadas na Seção 10.3.4). As entradas da coluna Quadrado Médio são calculadas dividindo a soma de quadrados correspondente pela entrada de GL.

Para ver o significado da tabela ANOVA, observe que, pelo Teorema 10.3.3,

$$E\left(B_2^2 \sum_{i=1}^n (x_i - \bar{x})^2 \,\middle|\, X_1 = x_1, \ldots, X_n = x_n\right) = \sigma^2 + \beta_2^2 \sum_{i=1}^n (x_i - \bar{x})^2, \tag{10.3.7}$$

No original: *degrees of freedom*[48].

que é igual a σ^2 se e somente se $\beta_2 = 0$ (estamos sempre supondo aqui que os x_i variam). Dado que o modelo de regressão linear simples está correto, temos $\beta_2 = 0$ se e somente se não há relação entre a resposta e o preditor. Portanto, $b_2^2 \sum_{i=1}^n (x_i - \bar{x})^2$ é um estimador não viesado[49] de σ^2 se e somente se $\beta_2 = 0$. Como s^2 é sempre uma estimativa não viesada de σ^2 (Teorema 10.3.4), uma estatística sensata para avaliar $H_0 : \beta_2 = 0$ é dada por

$$F = \frac{\text{RSS}}{\text{ESS}/(n-2)} = \frac{b_2^2 \sum_{i=1}^n (x_i - \bar{x})^2}{s^2}, \tag{10.3.8}$$

pois essa é a razão de dois estimadores não viesados de σ^2 quando H_0 é verdadeira. Concluímos, então, que temos evidência contra H_0 quando F é grande, já que (10.3.7) mostra também que o numerador tenderá a ser maior que σ^2 quando H_0 é falsa. Chamamos (10.3.8) de *estatística F*. Mais adiante, vamos discutir a distribuição amostral[50] de F para ver como determinar quando o valor de F é grande o bastante para ser evidência contra H_0.

Exemplo 10.3.5 — continuação do Exemplo 10.3.3

Usando os dados do Exemplo 10.3.3, obtemos

$$\sum_{i=1}^n (y_i - \bar{y})^2 = 437{,}01,$$

$$b_2^2 \sum_{i=1}^n (x_i - \bar{x})^2 = 428{,}55,$$

$$\sum_{i=1}^n (y_i - b_1 - b_2 x_i)^2 = 437{,}01 - 428{,}55 = 8{,}46,$$

e, assim,

$$F = \frac{b_2^2 \sum_{i=1}^n (x_i - \bar{x})^2}{s^2} = \frac{428{,}55}{1{,}06} = 404{,}29.$$

Observe que F é muito maior que 1, e isso parece indicar um efeito linear devido a X. ■

O Coeficiente de Determinação e a Correlação

O Lema 10.3.1 implica que

$$R^2 = \frac{b_2^2 \sum_{i=1}^n (x_i - \bar{x})^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

No original: *unbiased*[49], *sampling distribution*[50].

satisfaz $0 \leq R^2 \leq 1$. Portanto, quanto mais perto R^2 estiver de 1, maior a parte da variação total observada na resposta que é explicada por mudanças no preditor. De fato, interpretamos R^2, chamado de *coeficiente de determinação*[51], como a proporção da variação observada na resposta explicada por mudanças no preditor por meio da regressão linear simples.

O coeficiente de determinação é uma estatística descritiva importante, pois, mesmo que concluamos que existe uma relação, pode acontecer de a maior parte da variação observada se dever ao erro. Se quisermos usar o modelo para predizer novos valores da resposta, o coeficiente de determinação nos diz se podemos ou não esperar predições muito precisas. Um valor de R^2 perto de 1 significa predições muito precisas, enquanto um valor perto de 0 significa que as predições não serão muito precisas.

Exemplo 10.3.6 — continuação do Exemplo 10.3.3

Usando os dados do Exemplo 10.3.3, obtemos $R^2 = 0{,}981$. Portanto, 98,1% da variação observada em Y podem ser explicados pelas mudanças em X por meio da relação linear. Isso indica que podemos esperar predições bastante precisas ao usar esse modelo, pelo menos quando predizemos dentro da faixa dos valores observados de X. ■

Lembre que, na Seção 3.3, definimos o coeficiente de correlação entre as variáveis aleatórias X e Y como

$$\rho_{XY} = \text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\text{Sd}(X)\,\text{Sd}(Y)}.$$

No Corolário 3.6.1, provamos que $-1 \leq \rho_{XY} \leq 1$, com $\rho_{XY} = \pm 1$ se e somente se $Y = a \pm cX$ para algumas constantes $a \in R^1$ e $c > 0$. Assim, ρ_{XY} pode ser tomado como uma medida de quanto existe uma relação linear entre X e Y.

Se não conhecemos a distribuição conjunta de (X, Y), teremos de estimar ρ_{XY}. Com base nas observações $(x_1, y_1), \ldots, (x_n, y_n)$, a estimativa natural a usar é o *coeficiente de correlação amostral*[52]

$$r_{xy} = \frac{s_{xy}}{s_x s_y},$$

em que

$$s_{xy} = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y})$$

No original: *coefficient of determination*[51], *sample correlation coefficient*[52].

é a *covariância amostral*[53], que estima $\text{Cov}(X, Y)$, e s_x, s_y são os desvios padrão amostrais das variáveis X e Y, respectivamente. Então, $-1 \leq r_{xy} \leq 1$, com $r_{xy} = \pm 1$ se e somente se $y_i = a \pm cx_i$ para algumas constantes $a \in R^1$ e $c > 0$, para todo i (a demonstração é a mesma do Corolário 3.6.1, usando a distribuição conjunta que põe massa de probabilidade $1/n$ em cada ponto (x_i, y_i) — ver Problema 3.6.16).

O resultado a seguir mostra que o coeficiente de determinação é o quadrado da correlação entre os valores observados de X e Y.

Teorema 10.3.5

Se $(x_1, y_1), \ldots, (x_n, y_n)$ são tais que $\sum_{i=1}^n (x_i - \bar{x})^2 \neq 0$, $\sum_{i=1}^n (y_i - \bar{y})^2 \neq 0$, então $R^2 = r_{xy}^2$.

Demonstração. Temos

$$r_{xy}^2 = \frac{\left(\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})\right)^2}{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2} = b_2^2 \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = R^2,$$

em que usamos a fórmula de b_2 dada no Teorema 10.3.1. ■

Intervalos de Confiança e Testes de Hipóteses

Precisamos fazer mais algumas suposições para discutir as distribuições amostrais das diversas estatísticas que introduzimos. Temos os resultados a seguir.

Teorema 10.3.6

Se Y, dado $X = x$, tem distribuição $N(\beta_1 + \beta_2 x, \sigma^2)$ e observamos os valores independentes $(x_1, y_1), \ldots, (x_n, y_n)$ de (X, Y), então as distribuições condicionais de B_1, B_2 e S^2, dados $X_1 = x_1, \ldots, X_n = x_n$, são as seguintes.

(i) $B_1 \sim N\left(\beta_1, \sigma^2\left(1/n + \bar{x}^2 / \sum_{i=1}^n (x_i - \bar{x})^2\right)\right)$

(ii) $B_2 \sim N\left(\beta_2, \sigma^2 / \sum_{i=1}^n (x_i - \bar{x})^2\right)$

(iii) $B_1 + B_2 x \sim N\left(\beta_1 + \beta_2 x, \sigma^2\left(1/n + (x - \bar{x})^2 / \sum_{i=1}^n (x_i - \bar{x})^2\right)\right)$

(iv) $(n-2)S^2/\sigma^2 \sim \chi^2(n-2)$, independente de (B_1, B_2)

No original: *sample covariance*[53].

Demonstração. A demonstração deste resultado está na Seção 10.6. ■

Corolário 10.3.2

(i) $(B_1 - \beta_1) \Big/ \left(S \left(1/n + \bar{x}^2 \Big/ \sum_{i=1}^n (x_i - \bar{x})^2 \right)^{1/2} \right) \sim t(n-2)$

(ii) $(B_2 - \beta_2) \left(\sum_{i=1}^n (x_i - \bar{x})^2 \right)^{1/2} / S \sim t(n-2)$

(iii) *
$$\frac{B_1 + B_2 x - \beta_1 - \beta_2 x}{S \left((1/n + (x - \bar{x})^2) \Big/ \sum_{i=1}^n (x_i - \bar{x})^2 \right)^{1/2}} \sim t(n-2)$$

(iv) Se F é definida como em (10.3.8), então $H_0 : \beta_2 = 0$ é verdadeira se e somente se $F \sim F(1, n-2)$.

Demonstração. A demonstração deste resultado está na Seção 10.6. ■

Pelo Corolário 10.3.2(i), temos que

$$b_1 \pm s \left(1/n + \bar{x}^2 \Big/ \sum_{i=1}^n (x_i - \bar{x})^2 \right)^{1/2} t_{(1+\gamma)/2}(n-2)$$

é um intervalo de confiança[54] γ exato para β_1. Além disso, pelo Corolário 10.3.2(ii),

$$b_2 \pm s \left(\sum_{i=1}^n (x_i - \bar{x})^2 \right)^{-1/2} t_{(1+\gamma)/2}(n-2)$$

é um intervalo de confiança γ exato para β_2.

Pelo Corolário 10.3.2(iv), podemos testar $H_0 : \beta_2 = 0$ calculando o valor-p

$$P \left(F \geq \frac{b_2^2 \sum_{i=1}^n (x_i - \bar{x})^2}{s^2} \right), \tag{10.3.9}$$

em que $F \sim F(1, n-2)$, para ver se o valor observado (10.3.8) é ou não surpreendente. Isso às vezes é chamado de *teste ANOVA*. Observe que o

*Nota do tradutor. O original traz $(1/n + (x - \bar{x})^2)/\sum$ no denominador; pelo Teorema 10.3.6(iii) seria $1/n + (x - \bar{x})^2/\sum$.

No original: *confidence interval*[54].

Corolário 10.3.2(ii) implica que também podemos testar $H_0 : \beta_2 = 0$ calculando o valor-p

$$P\left(|T| \geq \frac{b_2\left(\sum_{i=1}^{n}(x_i - \bar{x})^2\right)^{1/2}}{s}\right), \tag{10.3.10}$$

em que $T \sim t(n-2)$. A demonstração do Corolário 10.3.2(iv) revela que (10.3.9) e (10.3.10) são iguais.

Exemplo 10.3.7 — continuação do Exemplo 10.3.3

Usando um software ou a Tabela D.4, obtemos $t_{0,975}(8) = 2{,}306$. Então, usando os dados do Exemplo 10.3.3, obtemos um intervalo de confiança 0,95 para β_1 dado por

$$b_1 \pm s\left(1/n + \bar{x}^2 \Big/ \sum_{i=1}^{n}(x_i - \bar{x})^2\right)^{1/2} t_{(1+\gamma)/2}(n-2)$$
$$= 1{,}33 \pm (0{,}3408)(2{,}306) = [0{,}544;\ 2{,}116]$$

e um intervalo de confiança 0,95 para β_2 dado por

$$b_2 \pm s\left(\sum_{i=1}^{n}(x_i - \bar{x})^2\right)^{-1/2} t_{(1+\gamma)/2}(n-2)$$
$$= 2{,}06 \pm (0{,}1023)(2{,}306) = [1{,}824;\ 2{,}296].$$

O intervalo de confiança 0,95 para β_2 não contém 0, de modo que temos evidência contra a hipótese nula $H_0 : \beta_2 = 0$ e concluímos que há evidência de uma relação entre X e Y. Isso é confirmado pelo teste F dessa hipótese nula, que dá o valor-p $P(F \geq 404{,}29) = 0{,}000$ quando $F \sim F(1, 8)$. ■

Análise de Resíduos

Numa aplicação do modelo de regressão simples, precisamos verificar se as suposições fazem sentido à luz dos dados que coletamos. A verificação do modelo se baseia nos resíduos $y_i - b_1 - b_2 x_i$ (depois de padronizados), como discutido na Seção 9.1. Observe que o i-ésimo resíduo é simplesmente a diferença entre o valor observado y_i em x_i e o valor predito $b_1 + b_2 x_i$ em x_i.

Da demonstração do Teorema 10.3.4, temos o resultado a seguir.

Corolário 10.3.3

(i) $E(Y_i - B_1 - B_2 x_i \mid X_1 = x_1, \ldots, X_n = x_n) = 0$

(ii) $\mathrm{Var}(Y_i - B_1 - B_2 x_i \mid X_1 = x_1, \ldots, X_n = x_n) = \sigma^2 \left(1 - \frac{1}{n} - \frac{(x_i - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2}\right)$

Isso leva à definição do i-ésimo *resíduo padronizado*[55] como

$$\frac{y_i - b_1 - b_2 x_i}{s\left(1 - \frac{1}{n} - (x_i - \bar{x})^2 / \sum_{j=1}^n (x_j - \bar{x})^2\right)^{1/2}}. \tag{10.3.11}$$

O Corolário 10.3.3 diz que (10.3.11), com σ no lugar de s, é um valor de uma distribuição com média condicional 0 e variância condicional 1. Além disso, quando a distribuição condicional da resposta dados os preditores é normal, a distribuição condicional dessa quantidade é $N(0, 1)$ (ver Problema 10.3.21). Esses resultados valem aproximadamente para (10.3.11) quando n é grande. Além disso, pode-se mostrar (ver Problema 10.3.20) que

$$\begin{aligned}&\mathrm{Cov}(Y_i - B_1 - B_2 x_i, Y_j - B_1 - B_2 x_j \mid X_1 = x_1, \ldots, X_n = x_n) \\ &\quad = -\sigma^2 \left(\frac{1}{n} + \frac{(x_i - \bar{x})(x_j - \bar{x})}{\sum_{k=1}^n (x_k - \bar{x})^2}\right).\end{aligned}$$

Portanto, sob a suposição de normalidade, os resíduos são aproximadamente independentes quando n é grande e

$$\frac{x_i - \bar{x}}{\sqrt{\sum_{k=1}^n (x_k - \bar{x})^2}} \to 0$$

quando $n \to \infty$. Esse será o caso sempre que $\mathrm{Var}(X)$ for finita (ver Desafio 10.3.27) ou, no contexto de planejamento, quando os valores do preditor forem escolhidos de forma adequada. Assim, uma abordagem para a verificação do modelo aqui é ver se os valores dados por (10.3.11) se parecem de algum modo com uma amostra da distribuição $N(0, 1)$. Para isso, podemos usar os gráficos discutidos no Capítulo 9.

No original: *standardized residual*[55].

Exemplo 10.3.8 — continuação do Exemplo 10.3.3

Usando os dados do Exemplo 10.3.3, obtemos os seguintes resíduos padronizados.

−0,49643	0,43212	−1,73371	1,00487	0,08358
0,17348	0,75281	−0,28430	−1,43570	1,51027

Eles estão representados contra o preditor x na Figura 10.3.2.

Recomenda-se representar os resíduos padronizados contra o preditor, pois isso pode revelar alguma relação subjacente que o modelo não captou. Este gráfico de resíduos parece razoável. Na Figura 10.3.3, temos um gráfico de probabilidade normal dos resíduos padronizados. Esses pontos ficam perto da reta que passa pela origem com coeficiente angular igual a 1, de modo que concluímos que não temos evidência contra o modelo aqui. ■

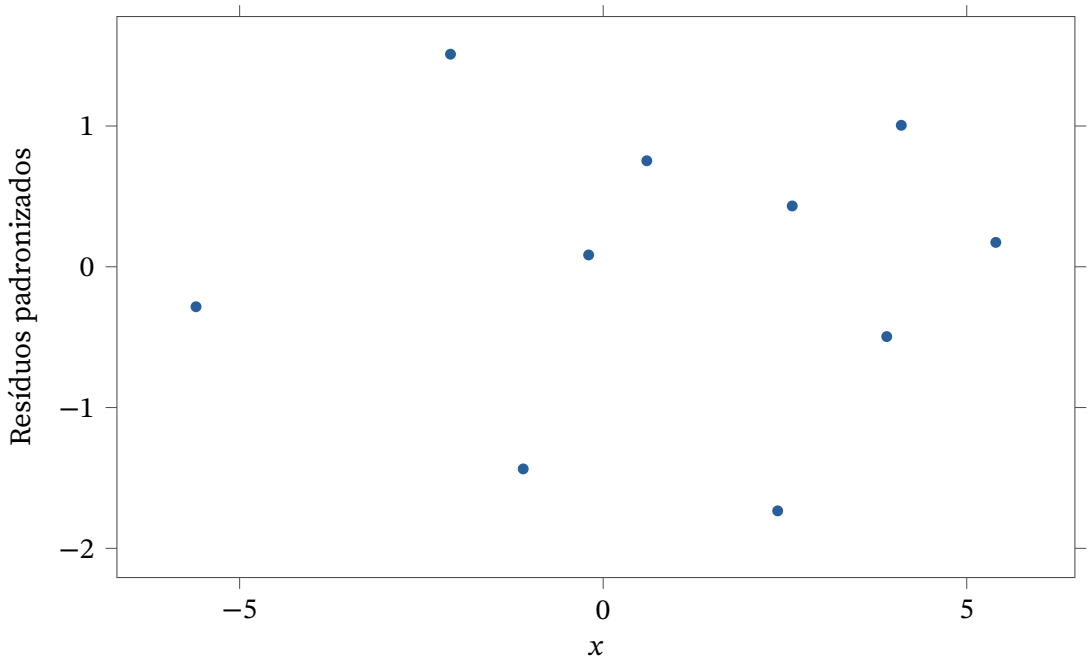


Figura 10.3.2: Gráfico dos resíduos padronizados do Exemplo 10.3.8.

O que fazemos se a verificação do modelo levar a uma falha do modelo? Como discutido no Capítulo 9, talvez a abordagem mais comum seja considerar várias transformações dos dados para ver se há uma modificação simples do modelo que passe na verificação. Podemos fazer transformações não só na variável resposta Y, mas também na variável preditora X.

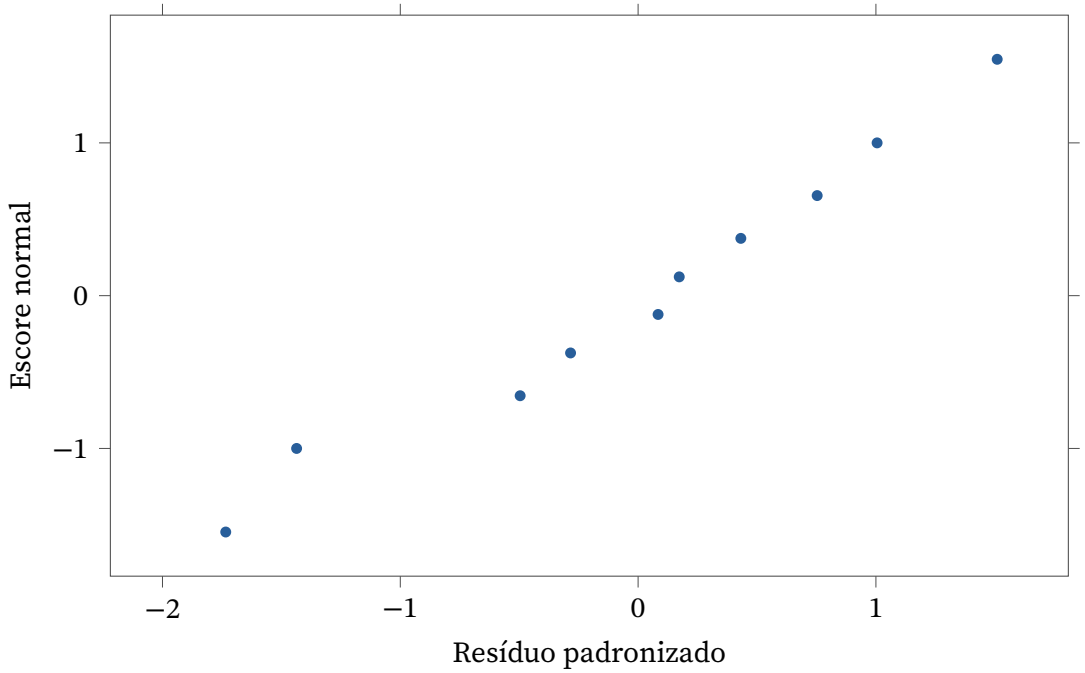


Figura 10.3.3: Gráfico de probabilidade normal dos resíduos padronizados do Exemplo 10.3.8.

Uma Aplicação da Análise de Regressão Linear Simples

O conjunto de dados a seguir foi extraído de *Statistical Methods*, 6ª ed., de G. Snedecor e W. Cochran (Iowa State University Press, Ames, 1967), e dá a velocidade recorde Y, em milhas por hora, nas corridas de automóveis do Memorial Day de Indianapolis nos anos de 1911 a 1941, exceto 1917 e 1918. Codificamos o ano X começando em 0 em 1911 e aumentando 1 a cada ano. Há $n = 29$ pontos de dados (x_i, y_i). O objetivo da análise é obter a reta de mínimos quadrados e, se for o caso, fazer inferências sobre os coeficientes de regressão. Tomamos o modelo de regressão linear simples normal como nosso modelo estatístico. Observe que este é um estudo observacional[56].

No original: *observational study*[56].

Ano	Velocidade	Ano	Velocidade	Ano	Velocidade
0	74,6	12	91,0	22	104,2
1	78,7	13	98,2	23	104,9
2	75,9	14	101,1	24	106,2
3	82,5	15	95,9	25	109,1
4	89,8	16	97,5	26	113,6
5	83,3	17	99,5	27	117,2
8	88,1	18	97,6	28	115,0
9	88,6	19	100,4	29	114,3
10	89,6	20	96,6	30	115,1
11	94,5	21	104,1		

Usando o Teorema 10.3.1, obtemos a reta de mínimos quadrados $y = 77{,}5681 + 1{,}27793x$. Essa reta, junto com um *diagrama de dispersão* dos valores (x_i, y_i), está representada na Figura 10.3.4. O ajuste parece bem bom, mas isso não garante que o modelo esteja correto, e precisamos fazer alguma forma de verificação do modelo.

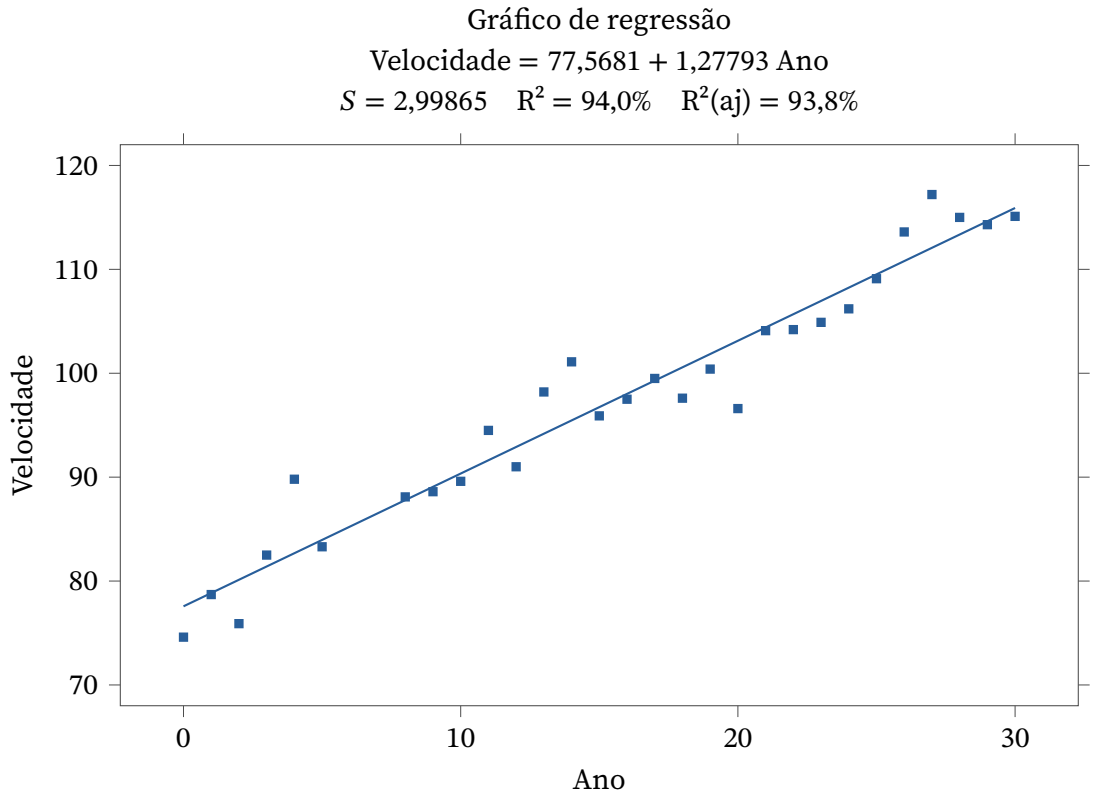


Figura 10.3.4: Diagrama de dispersão dos dados junto com o gráfico da reta de mínimos quadrados.

A Figura 10.3.5 é um gráfico dos resíduos padronizados contra o preditor. Esse gráfico parece razoável, sem nenhum padrão particularmente incomum

aparente. A Figura 10.3.6 é um gráfico de probabilidade normal[57] dos resíduos padronizados. A curvatura no centro pode levantar alguma dúvida sobre a suposição de normalidade. Geramos algumas amostras de tamanho $n = 29$ de uma distribuição $N(0, 1)$, porém, e olhar os seus gráficos de probabilidade normal (o que é sempre recomendado) revela que isso não é motivo de muita preocupação. É claro que também deveríamos aplicar procedimentos de verificação do modelo baseados nos resíduos padronizados e usando valores-p, mas não vamos avançar nesse tema aqui.

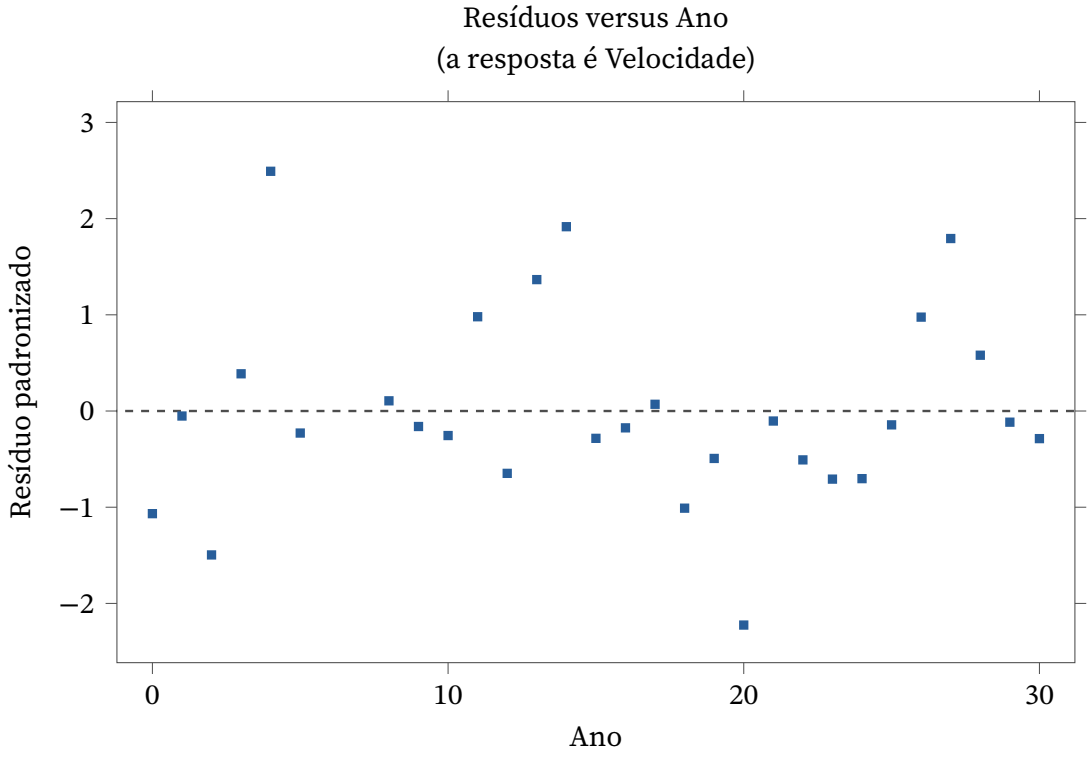


Figura 10.3.5: Gráfico dos resíduos padronizados contra o preditor.

Com base nos resultados da verificação do modelo, decidimos passar às inferências sobre os coeficientes de regressão. As estimativas e seus erros padrão estão na tabela a seguir, em que usamos a estimativa de σ^2 dada por $s^2 = (2{,}999)^2$ para calcular os erros padrão. Registramos também as estatísticas t adequadas para testar cada uma das hipóteses $H_0 : \beta_1 = 0$ e $H_0 : \beta_2 = 0$.

Coeficiente	Estimativa	Erro padrão	Estatística t
β_1	77,568	1,118	69,39
β_2	1,278	0,062	20,55

No original: *normal probability plot*[57].

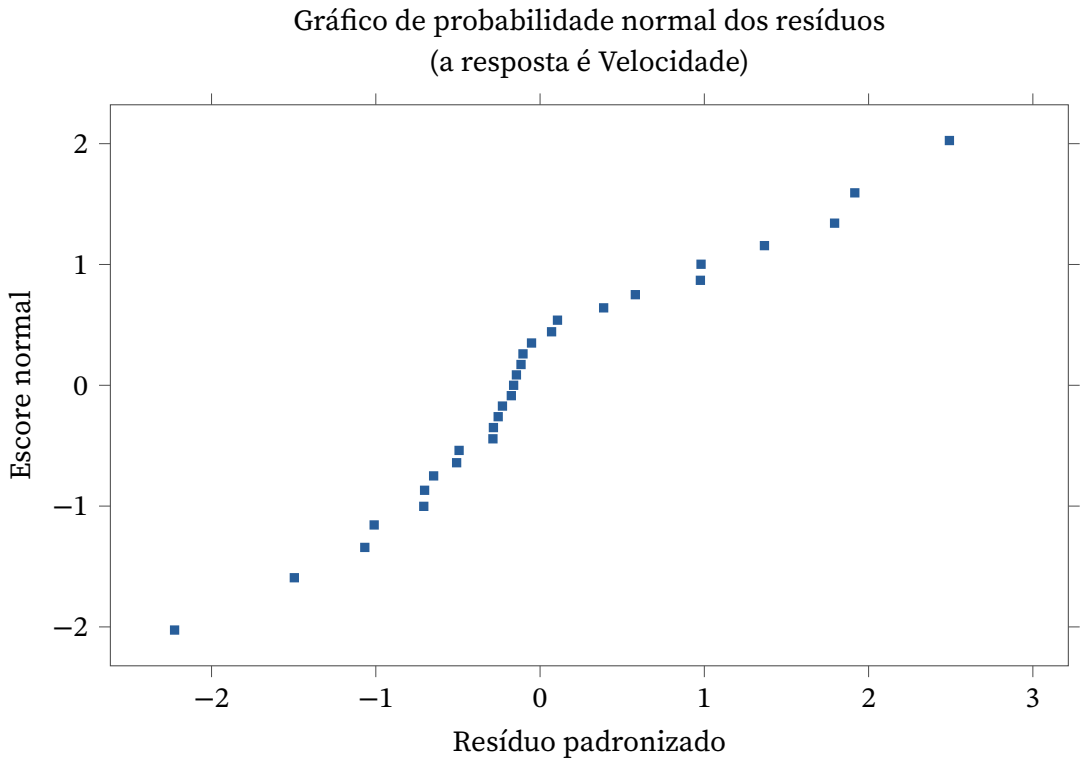


Figura 10.3.6: Gráfico de probabilidade normal dos resíduos padronizados.

Com isso, vemos que o valor-p para avaliar $H_0 : \beta_2 = 0$ é dado por

$$P(|T| \geq 20{,}55) = 0{,}000,$$

quando $T \sim t(27)$, de modo que temos forte evidência contra H_0. Parece claro que há uma forte relação positiva entre Y e X. Como o ponto 0,975 da distribuição $t(27)$ é igual a 2,0518, um intervalo de confiança 0,95 para β_2 é dado por

$$1{,}278 \pm (0{,}062)\, 2{,}0518 = [1{,}1508;\ 1{,}4052].$$

A decomposição ANOVA está na tabela a seguir.

Fonte	GL	Soma de Quadrados	Quadrado Médio
Regressão	1	3797,0	3797,0
Erro	27	242,8	9,0
Total	28	4039,8	

Assim, temos $F = 3797{,}0/9{,}0 = 421{,}888$ e, como $F \sim F(1, 27)$ quando $H_0 : \beta_2 = 0$ é verdadeira, $P(F > 421{,}888) = 0{,}000$, o que simplesmente confirma (como tinha de ser) o que obtivemos com o teste t anterior.

O coeficiente de determinação é dado por $R^2 = 3797{,}0/4039{,}8 = 0{,}94$. Portanto, 94% da variação observada na variável resposta podem ser explicados pelas

mudanças no preditor por meio da regressão linear simples. O valor de R^2 indica que o modelo ajustado será um excelente preditor de valores futuros, desde que o valor de X em que queremos predizer esteja na faixa (ou perto dela) dos valores de X usados para ajustar o modelo.

10.3.3 Modelo Linear Simples Bayesiano (Avançado)

Para a formulação bayesiana do modelo de regressão linear simples com erro normal, precisamos acrescentar uma distribuição a priori para os parâmetros desconhecidos do modelo, a saber, β_1, β_2 e σ^2. Há muitas escolhas possíveis para isso. A priori adequada depende da aplicação.

Para ajudar a simplificar os cálculos, reparametrizamos o modelo da seguinte forma. Sejam $\alpha_1 = \beta_1 + \beta_2\bar{x}$ e $\alpha_2 = \beta_2$. É então fácil mostrar (ver Problema 10.3.24) que

$$\begin{aligned}\sum_{i=1}^{n}(y_i - \beta_1 - \beta_2 x_i)^2 &= \sum_{i=1}^{n}(y_i - \alpha_1 - \alpha_2(x_i - \bar{x}))^2 \\ &= \sum_{i=1}^{n}((y_i - \bar{y}) - (\alpha_1 - \bar{y}) - \alpha_2(x_i - \bar{x}))^2 \\ &= \sum_{i=1}^{n}(y_i - \bar{y})^2 + n(\alpha_1 - \bar{y})^2 + \alpha_2^2\sum_{i=1}^{n}(x_i - \bar{x})^2 \\ &\quad - 2\alpha_2\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y}). \qquad (10.3.12)\end{aligned}$$

A função de verossimilhança, usando essa reparametrização, é então igual a

$$\left(2\pi\sigma^2\right)^{-n/2}\exp\left(-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(y_i - \alpha_1 - \alpha_2(x_i - \bar{x}))^2\right).$$

Por (10.3.12), e tomando

$$\begin{aligned}c_x^2 &= \sum_{i=1}^{n}(x_i - \bar{x})^2, \\ c_y^2 &= \sum_{i=1}^{n}(y_i - \bar{y})^2, \\ c_{xy} &= \sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y}),\end{aligned}$$

podemos escrevê-la como

$$\begin{aligned}
&\left(2\pi\sigma^2\right)^{-n/2}\exp\left(-\frac{c_y^2}{2\sigma^2}\right)\exp\left(-\frac{n}{2\sigma^2}(\alpha_1-\bar{y})^2\right)\\
&\quad\times\exp\left(-\frac{1}{2\sigma^2}\left\{\alpha_2^2c_x^2-2\alpha_2c_{xy}\right\}\right)\\
&=\left(2\pi\sigma^2\right)^{-n/2}\exp\left(-\frac{c_y^2-c_x^2a^2}{2\sigma^2}\right)\exp\left(-\frac{n}{2\sigma^2}(\alpha_1-\bar{y})^2\right)\\
&\quad\times\exp\left(-\frac{c_x^2}{2\sigma^2}(\alpha_2-a)^2\right),
\end{aligned}$$

em que a última igualdade decorre de $\alpha_2^2c_x^2-2\alpha_2c_{xy}=c_x^2(\alpha_2-a)^2-c_x^2a^2$, com $a=c_{xy}/c_x^2$.

Isso implica que, sempre que a distribuição a priori de (α_1,α_2) for tal que α_1 e α_2 sejam independentes dado σ^2, as distribuições a posteriori de α_1 e α_2 também serão independentes dado σ^2. Observe também que $\bar{y}$ e a são as estimativas de mínimos quadrados (e também os EMVs) de α_1 e α_2, respectivamente (ver Problema 10.3.24).

Suponha agora que tomemos como a priori

$$\begin{aligned}
\alpha_1\mid\alpha_2,\sigma^2&\sim N(\mu_1,\tau_1^2\sigma^2),\\
\alpha_2\mid\sigma^2&\sim N(\mu_2,\tau_2^2\sigma^2),\\
1/\sigma^2&\sim\text{Gama}(\kappa,\nu).
\end{aligned}$$

Observe que α_1 e α_2 são independentes dado σ^2.

Acontece que essa a priori é conjugada, de modo que podemos determinar facilmente uma forma exata para a distribuição a posteriori (ver Problema 10.3.25). A distribuição a posteriori conjunta de $(\alpha_1,\alpha_2,1/\sigma^2)$ é dada por

$$\begin{aligned}
\alpha_1\mid\alpha_2,\sigma^2&\sim N\left(\left(n+\frac{1}{\tau_1^2}\right)^{-1}\left(n\bar{y}+\frac{\mu_1}{\tau_1^2}\right),\left(n+\frac{1}{\tau_1^2}\right)^{-1}\sigma^2\right),\\
\alpha_2\mid\sigma^2&\sim N\left(\left(c_x^2+\frac{1}{\tau_2^2}\right)^{-1}\left(c_x^2a+\frac{\mu_2}{\tau_2^2}\right),\left(c_x^2+\frac{1}{\tau_2^2}\right)^{-1}\sigma^2\right),\\
\frac{1}{\sigma^2}&\sim\text{Gama}\left(\kappa+\frac{n}{2},\nu_{xy}\right),
\end{aligned}$$

em que

$$\nu_{xy}=\frac{1}{2}\left\{\begin{array}{l}c_y^2-c_x^2a^2+\left[n\bar{y}^2+\frac{\mu_1^2}{\tau_1^2}-\left(n+\frac{1}{\tau_1^2}\right)^{-1}\left(n\bar{y}+\frac{\mu_1}{\tau_1^2}\right)^2\right]\\ \quad+\left[c_x^2a^2+\frac{\mu_2^2}{\tau_2^2}-\left(c_x^2+\frac{1}{\tau_2^2}\right)^{-1}\left(c_x^2a+\frac{\mu_2}{\tau_2^2}\right)^2\right]\end{array}\right\}+\nu.$$

É claro que precisamos escolher os valores dos hiperparâmetros μ_1, τ_1, μ_2, τ_2, κ e ν para especificar completamente a a priori.

Observe agora que, para uma análise difusa, isto é, quando temos pouca ou nenhuma informação a priori sobre os parâmetros, fazemos $\tau_1 \to \infty$, $\tau_2 \to \infty$ e $\nu \to 0$, e a distribuição a posteriori converge para

$$\begin{aligned} \alpha_1 \mid \alpha_2, \sigma^2 &\sim N(\bar{y}, \sigma^2/n), \\ \alpha_2 \mid \sigma^2 &\sim N(a, \sigma^2/c_x^2), \\ 1/\sigma^2 &\sim \text{Gama}(\kappa + n/2, \nu_{xy}), \end{aligned}$$

em que $\nu_{xy} = (1/2)\{c_y^2 - c_x^2 a^2\}$. Mas isso ainda nos deixa com a necessidade de escolher o hiperparâmetro[58] κ. Veremos, porém, que essa escolha tem apenas um efeito pequeno sobre a análise quando n não é pequeno demais.

Podemos obter facilmente a distribuição a posteriori marginal dos α_i. Por exemplo, no caso difuso, a densidade a posteriori marginal de α_2 é proporcional a

$$\begin{aligned} &\int_0^\infty \left(\frac{1}{\sigma^2}\right)^{1/2} \exp\left\{-\frac{c_x^2}{2\sigma^2}(\alpha_2 - a)^2\right\} \left(\frac{1}{\sigma^2}\right)^{\kappa+(n/2)-1} \exp\left\{-\frac{\nu_{xy}}{\sigma^2}\right\} d\left(\frac{1}{\sigma^2}\right) \\ &= \int_0^\infty \left(\frac{1}{\sigma^2}\right)^{\kappa+(n/2)-(1/2)} \exp\left\{-\left(\nu_{xy} + \frac{c_x^2}{2}(\alpha_2 - a)^2\right)\frac{1}{\sigma^2}\right\} d\left(\frac{1}{\sigma^2}\right). \end{aligned}$$

Fazendo a mudança de variável[59] $1/\sigma^2 \to w$, em que

$$w = \left(\nu_{xy} + \frac{c_x^2}{2}(\alpha_2 - a)^2\right)\frac{1}{\sigma^2}$$

na integral anterior, vemos que a densidade a posteriori marginal de α_2 é proporcional a

$$\left(1 + \frac{c_x^2}{2\nu_{xy}}(\alpha_2 - a)^2\right)^{-(\kappa+(n+1)/2)} \int_0^\infty w^{\kappa+(n/2)-(1/2)} \exp\{-w\}\, dw,$$

que é proporcional a

$$\left(1 + \frac{c_x^2}{2\nu_{xy}}(\alpha_2 - a)^2\right)^{-(2\kappa+n+1)/2}.$$

Isso estabelece (ver Problema 4.6.17) que a distribuição a posteriori de α_2 é especificada por

$$\sqrt{2\kappa + n}\,\frac{\alpha_2 - a}{\sqrt{2\nu_{xy}/c_x^2}} \sim t(2\kappa + n).$$

No original: *hyperparameter*[58], *change of variable*[59].

Assim, um intervalo HPD γ (de maior densidade a posteriori[60]) para α_2 é dado por

$$a \pm \frac{1}{\sqrt{2\kappa + n}} \sqrt{\frac{2\nu_{xy}}{c_x^2}}\, t_{(1+\gamma)/2}(2\kappa + n).$$

Observe que esses intervalos não mudam muito quando mudamos κ, desde que n não seja pequeno demais.

Consideramos uma aplicação de uma análise bayesiana para esse modelo.

Exemplo 10.3.9 — Dados de Haavelmo sobre Renda e Investimento

Os dados deste exemplo foram tirados de *An Introduction to Bayesian Inference in Econometrics*, de A. Zellner (Wiley Classics, Nova York, 1996). A variável resposta Y é a renda per capita em dólares americanos (deflacionada), e a variável preditora X é o investimento per capita em dólares (deflacionado), para os Estados Unidos nos anos de 1922 a 1941. Os dados estão na tabela a seguir.

Ano	Renda	Investimento	Ano	Renda	Investimento
1922	433	39	1932	372	22
1923	483	60	1933	381	17
1924	479	42	1934	419	27
1925	486	52	1935	449	33
1926	494	47	1936	511	48
1927	498	51	1937	520	51
1928	511	45	1938	477	33
1929	534	60	1939	517	46
1930	478	39	1940	548	54
1931	440	41	1941	629	100

Na Figura 10.3.7, apresentamos um gráfico de probabilidade normal dos resíduos padronizados, obtidos por um ajuste de mínimos quadrados. Na Figura 10.3.8, apresentamos um gráfico dos resíduos padronizados contra o preditor. Os dois gráficos indicam que as suposições do modelo são razoáveis.

Suponha agora que analisemos esses dados usando a priori difusa limite com $\kappa = 2$. Aqui, temos $\bar{y} = 483$, $c_y^2 = 64.993$, $c_x^2 = 5.710{,}55$ e $c_{xy} = 17.408{,}3$, de modo que $a = 17.408{,}3/5.710{,}55 = 3{,}05$ e $\nu_{xy} = (64.993 - 17.408{,}3)/2 = 23.792{,}35$.* A distribuição a posteriori é então

No original: *highest posterior density*[60].

dada por

$$\begin{aligned}\alpha_1 \mid \alpha_2, \sigma^2 &\sim N(483, \sigma^2/20),\\ \alpha_2 \mid \sigma^2 &\sim N(3{,}05; \sigma^2/5.710{,}55),\\ 1/\sigma^2 &\sim \text{Gama}(12; 23.792{,}35).\end{aligned}$$

O interesse principal aqui está no multiplicador de investimento α_2. Pelos resultados acima, um intervalo HPD 0,95 para α_2, usando $t_{0,975}(24) = 2{,}0639$, é dado por*

$$\begin{aligned}&a \pm \frac{1}{\sqrt{2\kappa + n}}\sqrt{\frac{2\nu_{xy}}{r_x^2}}\, t_{(1+\gamma)/2}(2\kappa + n - 1)\\ &= 3{,}05 \pm \frac{1}{\sqrt{24}}\sqrt{\frac{2 \cdot 23.792{,}35}{5.710{,}55}}\, t_{0,975}(24) = 3{,}05 \pm (0{,}589)\, 2{,}0639\\ &= (1{,}834; 4{,}266).\end{aligned}$$

■

*Nota do tradutor. Pela fórmula $\nu_{xy} = (1/2)\{c_y^2 - c_x^2 a^2\}$ dada acima, seria $(c_y^2 - c_{xy}^2/c_x^2)/2 \approx 5.962$; o original subtrai c_{xy} em vez de $c_x^2 a^2$, e esse valor se propaga para a distribuição Gama e para o intervalo HPD abaixo.

*Nota do tradutor. O original traz r_x^2 e $2\kappa + n - 1$ na primeira linha; pela fórmula do intervalo HPD γ acima, seriam c_x^2 e $2\kappa + n$, que é o que a conta usa ($t_{0,975}(24)$, com $2\kappa + n = 24$).

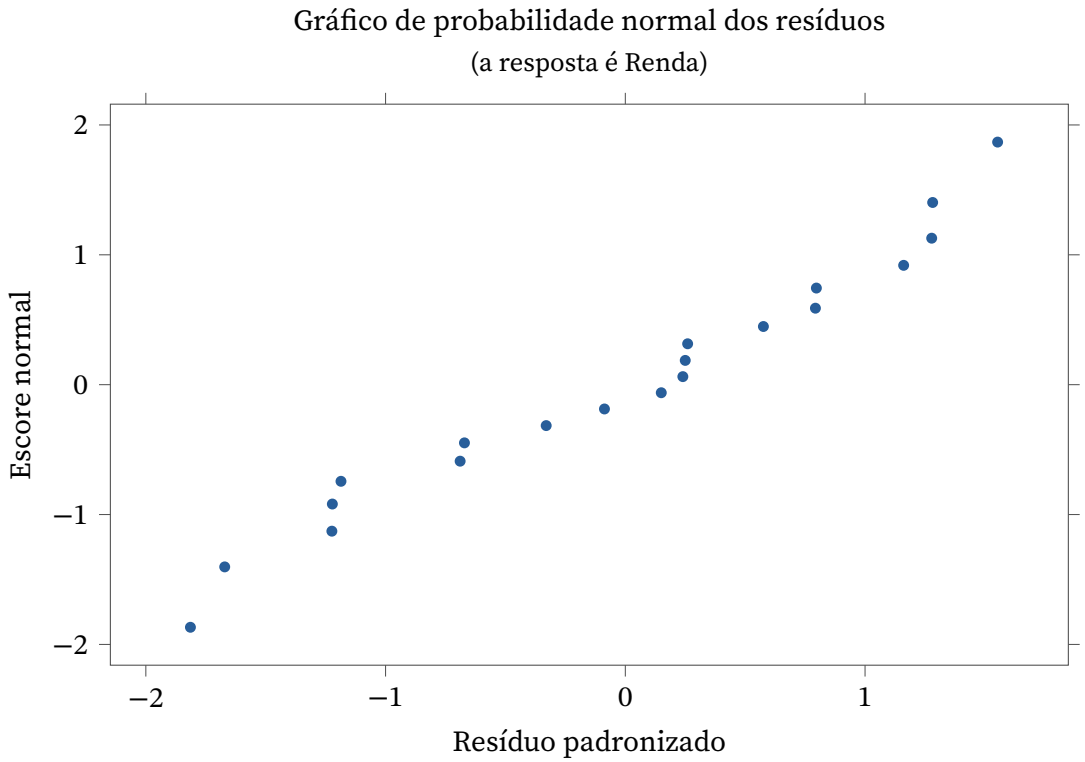


Figura 10.3.7: Gráfico de probabilidade normal dos resíduos padronizados do Exemplo 10.3.9.

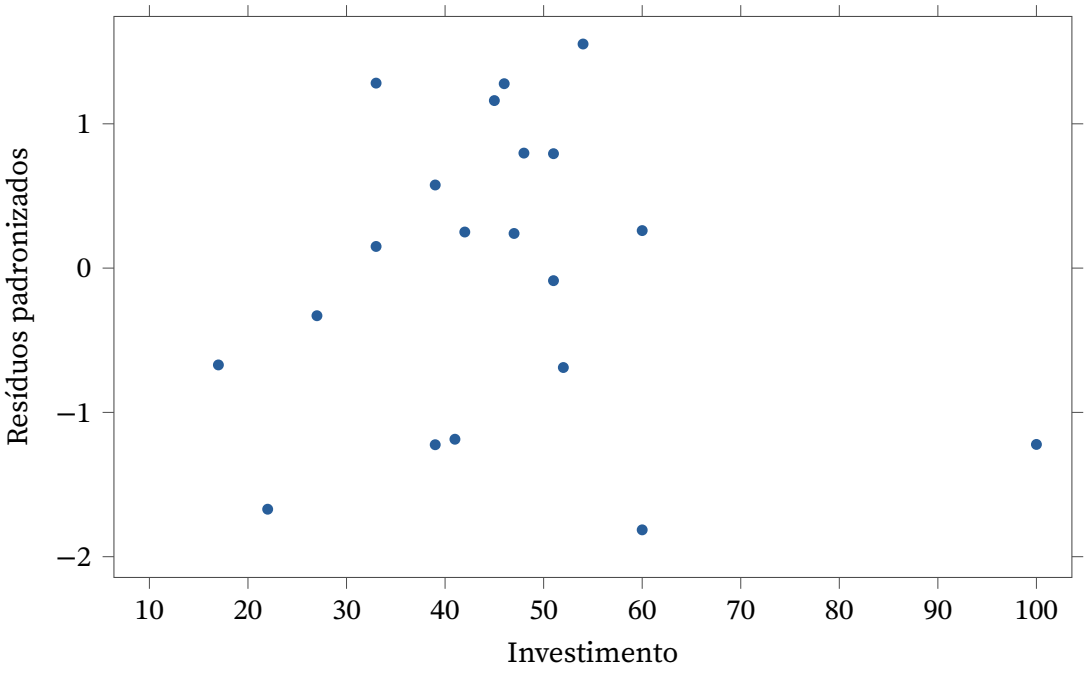


Figura 10.3.8: Gráfico dos resíduos padronizados contra o preditor no Exemplo 10.3.9.

10.3.4 O Modelo de Regressão Linear Múltipla (Avançado)

Consideramos agora a situação em que temos uma resposta quantitativa Y e preditores quantitativos $X_1, \ldots, X_k$. No modelo de regressão, supomos que as distribuições condicionais de Y, dados os preditores, têm forma constante e que mudam, à medida que os preditores mudam, no máximo por meio da média condicional $E(Y \mid X_1 = x_1, \ldots, X_k = x_k)$. No *modelo de regressão linear*, supomos que essa média condicional é da forma

$$E(Y \mid X_1 = x_1, \ldots, X_k = x_k) = \beta_1 x_1 + \cdots + \beta_k x_k. \tag{10.3.13}$$

Ela é linear nos $\beta_i \in R^1$ desconhecidos, para $i = 1, \ldots, k$.

Vamos desenvolver aqui apenas as linhas gerais da análise do modelo de regressão linear múltipla[61]. Todos os resultados serão enunciados sem demonstração. As demonstrações podem ser encontradas em textos mais avançados. É importante notar, porém, que todos esses resultados são apenas análogos dos resultados que desenvolvemos por métodos elementares na Seção 10.3.2 para o modelo de regressão linear simples.

Formulação Matricial do Problema de Mínimos Quadrados

Para a análise do modelo de regressão linear múltipla, precisamos de alguns conceitos de *matrizes*. Vamos discutir brevemente alguns deles aqui, mas veja também o Apêndice A.4.

Seja $A \in R^{m \times n}$ um arranjo retangular de números com m linhas e n colunas, e seja a_{ij} o elemento da i-ésima linha e da j-ésima coluna (chamado de elemento (i, j) de A). Por exemplo,

$$A = \begin{pmatrix} 1{,}2 & 1{,}0 & 0{,}0 \\ 3{,}2 & 0{,}2 & 6{,}3 \end{pmatrix} \in R^{2 \times 3}$$

denota uma matriz 2×3 e, por exemplo, $a_{22} = 0{,}2$.

Podemos somar duas matrizes de mesmas dimensões m e n simplesmente somando seus elementos posição a posição. Assim, se $A, B \in R^{m \times n}$ e $C = A + B$, então $c_{ij} = a_{ij} + b_{ij}$. Além disso, podemos multiplicar uma matriz por um número real c simplesmente multiplicando cada elemento da matriz por c. Assim, se $A \in R^{m \times n}$, então $B = cA \in R^{m \times n}$ e $b_{ij} = ca_{ij}$. Às vezes vamos escrever

No original: *multiple linear regression model*[61].

uma matriz $A \in R^{m\times n}$ em termos de suas colunas como $A = \begin{pmatrix} a_1 & \dots & a_n \end{pmatrix}$, de modo que aqui $a_i \in R^m$. Por fim, se $A \in R^{m\times n}$ e $b \in R^n$, definimos o produto de A por b como $Ab = b_1a_1 + \cdots + b_na_n \in R^m$.

Suponha agora que $Y \in R^n$ e que $E(Y)$ esteja restrito a um conjunto da forma

$$S = \{\beta_1\upsilon_1 + \cdots + \beta_k\upsilon_k : \beta_i \in R^1, i = 1, \dots, k\},$$

em que $\upsilon_1, \dots, \upsilon_k$ são vetores fixos de R^n. Um conjunto como S é chamado de *subespaço linear* de R^n. Quando $\{\upsilon_1, \dots, \upsilon_k\}$ tem a *propriedade de independência linear*, isto é,

$$\beta_1\upsilon_1 + \cdots + \beta_k\upsilon_k = 0$$

se e somente se $\beta_1 = \cdots = \beta_k = 0$, dizemos que S tem dimensão k e que $\{\upsilon_1, \dots, \upsilon_k\}$ é uma *base* de S.

Se fizermos

$$V = (\upsilon_1 \cdots \upsilon_k) = \begin{pmatrix} \upsilon_{11} & \upsilon_{12} & \cdots & \upsilon_{1k} \\ \upsilon_{21} & \upsilon_{22} & \cdots & \upsilon_{2k} \\ \vdots & \vdots & & \vdots \\ \upsilon_{n1} & \upsilon_{n2} & \cdots & \upsilon_{nk} \end{pmatrix} \in R^{n\times k},$$

então podemos escrever

$$E(Y) = \beta_1\upsilon_1 + \cdots + \beta_k\upsilon_k = \begin{pmatrix} \beta_1\upsilon_{11} + \beta_2\upsilon_{12} + \cdots + \beta_k\upsilon_{1k} \\ \beta_1\upsilon_{21} + \beta_2\upsilon_{22} + \cdots + \beta_k\upsilon_{2k} \\ \vdots \\ \beta_1\upsilon_{n1} + \beta_2\upsilon_{n2} + \cdots + \beta_k\upsilon_{nk} \end{pmatrix} = V\beta$$

para algum ponto desconhecido $\beta = (\beta_1, \beta_2, \dots, \beta_k)'$. Quando observamos $y \in R^n$, a estimativa de mínimos quadrados de $E(Y)$ é obtida encontrando o valor de β que minimiza

$$\sum_{i=1}^{n} (y_i - \beta_1\upsilon_{i1} - \beta_2\upsilon_{i2} - \cdots - \beta_k\upsilon_{ik})^2.$$

Pode-se provar que existe um único valor minimizador de $\beta \in R^k$ sempre que $\{\upsilon_1, \dots, \upsilon_k\}$ é uma base. O valor minimizador de β será denotado por b e é chamado de *estimativa de mínimos quadrados* de β. O ponto $b_1\upsilon_1 + \cdots + b_k\upsilon_k = Vb$ é a estimativa de mínimos quadrados de $E(Y)$ e às vezes é chamado de vetor de *valores ajustados*. O ponto $y - Vb$ é chamado de vetor de *resíduos*.

Vejamos agora como calcular b. Para isso, precisamos entender o que significa multiplicar a matriz $A \in R^{m\times k}$ à direita pela matriz $B \in R^{k\times n}$. O *produto de matrizes* AB é definido como a matriz $m \times n$ cujo elemento (i, j) é dado por

$$\sum_{l=1}^{k} a_{il}b_{lj}.$$

Note que o arranjo A precisa ter o mesmo número de colunas que o número de linhas de B para que esse produto esteja definido. A *transposta* de uma matriz $A \in R^{m\times k}$ é definida como

$$A' = \begin{pmatrix} a_{11} & \cdots & a_{m1} \\ \vdots & & \vdots \\ a_{1k} & \cdots & a_{mk} \end{pmatrix} \in R^{k\times m},$$

isto é, a i-ésima coluna de A se torna a i-ésima linha de A'. Para uma matriz $A \in R^{k\times k}$, a *matriz inversa* de A é definida como a matriz A^{-1} tal que

$$AA^{-1} = A^{-1}A = I,$$

em que $I \in R^{k\times k}$ tem 1 em toda a diagonal e 0 em todas as outras posições; ela é chamada de *matriz identidade* $k \times k$. Nem sempre $A \in R^{k\times k}$ tem inversa, mas, quando tem, pode-se mostrar que a inversa é única. Note que há muitos pacotes de software matemático e estatístico com recursos para calcular produtos, transpostas e inversas de matrizes.

Temos o seguinte resultado fundamental.

Teorema 10.3.7

Se $E(Y) \in S = \{\beta_1 v_1 + \cdots + \beta_k v_k : \beta_i \in R^1, i = 1, \ldots, k\}$ e as colunas de $V = (v_1 \cdots v_k)$ têm a propriedade de independência linear, então $(V'V)^{-1}$ existe, a estimativa de mínimos quadrados de β é única e é dada por

$$b = \begin{pmatrix} b_1 \\ \vdots \\ b_k \end{pmatrix} = (V'V)^{-1} V'y. \tag{10.3.14}$$

Estimativas de Mínimos Quadrados, Predições e Erros Padrão

Para o modelo de regressão linear (10.3.13), temos (escrevendo X_{ij} para o j-ésimo valor de X_i)

$$E\left(\begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix} \middle| X_{ij} = x_{ij} \text{ para todo } i, j\right) = \begin{pmatrix} \beta_1 x_{11} + \cdots + \beta_k x_{1k} \\ \vdots \\ \beta_1 x_{n1} + \cdots + \beta_k x_{nk} \end{pmatrix}$$
$$= \beta_1 v_1 + \cdots + \beta_k v_k = V\beta,$$

em que $\beta = (\beta_1, \ldots, \beta_k)'$ e

$$V = \begin{pmatrix} v_1 & v_2 & \ldots & v_k \end{pmatrix} = \begin{pmatrix} x_{11} & \cdots & x_{1k} \\ \vdots & & \vdots \\ x_{n1} & \cdots & x_{nk} \end{pmatrix} \in R^{n\times k}.$$

Vamos supor, daqui em diante, que as colunas $v_1, \ldots, v_k$ de V têm a propriedade de independência linear. Então (trocando a esperança pela esperança condicional[62]) segue imediatamente que a estimativa de mínimos quadrados de β é dada por (10.3.14).

Como no modelo de regressão linear simples, temos vários resultados sobre as estimativas de mínimos quadrados. Nós os enunciamos aqui sem demonstração.

Teorema 10.3.8

Se os $(x_{i1}, \ldots, x_{ik}, y_i)$ são observações independentes para $i = 1, \ldots, n$ e o modelo de regressão linear se aplica, então

$$E\left(B_i \mid X_{ij} = x_{ij} \text{ para todo } i, j\right) = \beta_i$$

para $i = 1, \ldots, k$.

Assim, o Teorema 10.3.8 afirma que as estimativas de mínimos quadrados são estimativas não viesadas dos coeficientes da regressão linear.

Se quisermos avaliar a precisão dessas estimativas, precisamos ser capazes de calcular seus erros padrão.

Teorema 10.3.9

Se os $(x_{i1}, \ldots, x_{ik}, y_i)$ são observações independentes para $i = 1, \ldots, n$, vindas do modelo de regressão linear, e se $\operatorname{Var}(Y \mid X_1 = x_1, \ldots, X_k = x_k) = \sigma^2$ para todos os $x_1, \ldots, x_k$, então

$$\operatorname{Cov}\left(B_i, B_j \mid X_{ij} = x_{ij} \text{ para todo } i, j\right) = \sigma^2 c_{ij}, \tag{10.3.15}$$

em que c_{ij} é o elemento (i, j) da matriz $(V'V)^{-1}$.

Temos o seguinte resultado sobre a estimação[63] da média*

$$E(Y \mid X_1 = x_1, \ldots, X_k) = x_k = \beta_1 x_1 + \cdots + \beta_k x_k$$

pela estimativa $b_1 x_1 + \cdots + b_k x_k$.

*Nota do tradutor. O original traz $X_k) = x_k$; pelo sentido seria $X_k = x_k$).

No original: *conditional expectation*[62], *estimation*[63].

Corolário 10.3.4

$$\begin{aligned}&\operatorname{Var}\left(B_1x_1+\cdots+B_kx_k \mid X_{ij}=x_{ij} \text{ para todo } i,j\right)\\&\quad=\sigma^2\Big(\sum_{i=1}^{k}x_i^2c_{ii}+2\sum_{i<j}x_ix_jc_{ij}\Big)=\sigma^2x'(V'V)^{-1}x,\end{aligned}\tag{10.3.16}$$

em que $x=(x_1,\ldots,x_k)$.

Também usamos $b_1x_1+\cdots+b_kx_k=b'x$ como predição de um novo valor da resposta quando $X_1=x_1,\ldots,X_k=x_k$.

Vemos, pelo Teorema 10.3.9 e pelo Corolário 10.3.4, que precisamos de uma estimativa de σ^2 para calcular os erros padrão. A estimativa é dada por*

$$s^2=\frac{1}{n-k}\sum_{i=1}^{n}(y_i-b_1x_{i1}-\cdots-b_kx_{ik})^2=\frac{1}{n-k}(y-Xb)'(y-Xb),\tag{10.3.17}$$

e temos o seguinte resultado.

Teorema 10.3.10

Se os $(x_{i1},\ldots,x_{ik},y_i)$ são observações independentes para $i=1,\ldots,n$, vindas do modelo de regressão linear, e se $\operatorname{Var}(Y \mid X_1=x_1,\ldots,X_k=x_k)=\sigma^2$, então

$$E\left(S^2 \mid X_{ij}=x_{ij} \text{ para todo } i,j\right)=\sigma^2.$$

Combinando (10.3.15) e (10.3.17), deduzimos que o erro padrão de b_i é $s\sqrt{c_{ii}}$. Combinando (10.3.16) e (10.3.17), deduzimos que o erro padrão de $b_1x_1+\cdots+b_kx_k$ é

$$s\Big(\sum_{i=1}^{k}x_i^2c_{ii}+2\sum_{i<j}x_ix_jc_{ij}\Big)^{1/2}=s\left(x'(V'V)^{-1}x\right)^{1/2}.$$

A Decomposição ANOVA e as Estatísticas F

Quando um dos preditores $X_1,\ldots,X_k$ é constante, dizemos que o modelo tem um *termo de intercepto*. Por convenção, vamos sempre tomá-lo como o primeiro preditor. Assim, quando queremos que o modelo tenha um termo de intercepto, tomamos $X_1\equiv 1$, e β_1 é o intercepto, como no modelo de regressão

*Nota do tradutor. O original traz $(y-Xb)'(y-Xb)$; com a notação da seção seria $(y-Vb)'(y-Vb)$.

linear simples. Note que é comum denotar o termo de intercepto por β_0, de modo que $X_0 \equiv 1$ e $X_1, \ldots, X_k$ denotam os preditores que de fato variam. Também vamos adotar essa convenção quando parecer apropriado.

Basicamente, a inclusão de um termo de intercepto é muito comum, pois ela diz que, quando os preditores que de fato variam não têm relação com a resposta Y, o intercepto é a média desconhecida da resposta. Quando não incluímos um intercepto, isso diz que *sabemos* que a resposta média é 0 quando não há relação entre Y e os preditores não constantes. A menos que haja evidência substantiva, baseada na aplicação, que apoie isso, em geral não vamos querer fazer essa suposição.

Denotando o termo de intercepto por β_1, de modo que $X_1 \equiv 1$, temos a seguinte decomposição ANOVA para esse modelo, que mostra como isolar a variação observada em Y que pode ser explicada por mudanças nos preditores não constantes.

Lema 10.3.2

Se, para $i = 1, \ldots, n$, os valores $(x_{i1}, \ldots, x_{ik}, y_i)$ são tais que a matriz V tem colunas linearmente independentes, com v_1 igual a uma coluna de uns, então $b_1 = \bar{y} - b_2\bar{x}_2 - \cdots - b_k\bar{x}_k$ e

$$\sum_{i=1}^{n}(y_i - \bar{y})^2 = \sum_{i=1}^{n}\left(b_2(x_{i2} - \bar{x}_2) + \cdots + b_k(x_{ik} - \bar{x}_k)\right)^2 + \sum_{i=1}^{n}\left(y_i - b_1x_{i1} - \cdots - b_kx_{ik}\right)^2.$$

Chamamos

$$\mathrm{RSS}(X_2, \ldots, X_k) = \sum_{i=1}^{n}\left(b_2(x_{i2} - \bar{x}_2) + \cdots + b_k(x_{ik} - \bar{x}_k)\right)^2$$

de *soma de quadrados da regressão* e

$$\mathrm{ESS} = \sum_{i=1}^{n}\left(y_i - b_1x_{i1} - \cdots - b_kx_{ik}\right)^2$$

de *soma de quadrados dos erros*. Isso leva à seguinte tabela ANOVA.

Fonte	GL	Soma de Quadrados	Quadrado Médio
$X_2, \ldots, X_k$	$k-1$	$\mathrm{RSS}(X_2, \ldots, X_k)$	$\mathrm{RSS}(X_2, \ldots, X_k)/(k-1)$
Erro	$n-k$	ESS	s^2
Total	$n-1$	$\sum_{i=1}^{n}(y_i - \bar{y})^2$	

Quando há um termo de intercepto, a hipótese nula de ausência de relação entre a resposta e os preditores equivale a $H_0 : \beta_2 = \cdots = \beta_k = 0$. Como no modelo de regressão linear simples, pode-se mostrar que o quadrado médio da regressão é um estimador não viesado de σ^2 se e somente se a hipótese nula é verdadeira. Portanto, uma estatística sensata para avaliar a hipótese nula é a estatística F

$$F = \frac{\text{RSS}(X_2, \ldots, X_k)/(k-1)}{s^2},$$

em que valores grandes são evidência contra a hipótese nula.

Muitas vezes, queremos avaliar a hipótese nula $H_0 : \beta_{l+1} = \cdots = \beta_k = 0$ ou, equivalentemente, a hipótese de que o modelo é dado por

$$E(Y \mid X_1 = x_1, \ldots, X_k = x_k) = \beta_1 x_1 + \cdots + \beta_l x_l,$$

em que $l < k$. Essa hipótese diz que os últimos $k - l$ preditores, $X_{l+1}, \ldots, X_k$, não têm relação com a resposta.

Se denotarmos por $b_1^*, \ldots, b_l^*$ as estimativas de mínimos quadrados de $\beta_1, \ldots, \beta_l$ obtidas ajustando o modelo menor, temos o seguinte resultado.

Lema 10.3.3

Se os $(x_{i1}, \ldots, x_{ik}, y_i)$, para $i = 1, \ldots, n$, são valores para os quais a matriz V tem colunas linearmente independentes, com v_1 igual a uma coluna de uns, então

$$\begin{aligned} \text{RSS}(X_2, \ldots, X_k) &= \sum_{i=1}^{n} \left(b_2(x_{i2} - \bar{x}_2) + \cdots + b_k(x_{ik} - \bar{x}_k)\right)^2 \\ &\geq \sum_{i=1}^{n} \left(b_2^*(x_{i2} - \bar{x}_2) + \cdots + b_l^*(x_{il} - \bar{x}_l)\right)^2 \\ &= \text{RSS}(X_2, \ldots, X_l). \end{aligned} \tag{10.3.18}$$

À direita da desigualdade em (10.3.18), temos a soma de quadrados da regressão obtida ajustando o modelo baseado nos primeiros l preditores. Portanto, podemos interpretar a diferença entre os lados esquerdo e direito de (10.3.18), isto é,

$$\text{RSS}(X_{l+1}, \ldots, X_k \mid X_2, \ldots, X_l) = \text{RSS}(X_2, \ldots, X_k) - \text{RSS}(X_2, \ldots, X_l),$$

como a contribuição dos preditores $X_{l+1}, \ldots, X_k$ para a soma de quadrados da regressão quando os preditores $X_1, \ldots, X_l$ estão no modelo. Obtemos a seguinte tabela ANOVA (na verdade, só as três primeiras colunas da tabela ANOVA) correspondente a essa decomposição da soma de quadrados total.

Fonte	GL	Soma de Quadrados
$X_2, \dots, X_l$	$l-1$	$\text{RSS}(X_2, \dots, X_l)$
$X_{l+1}, \dots, X_k \mid X_2, \dots, X_l$	$k-l$	$\text{RSS}(X_{l+1}, \dots, X_k \mid X_2, \dots, X_l)$
Erro	$n-k$	ESS
Total	$n-1$	$\sum_{i=1}^{n}(y_i - \bar{y})^2$

Pode-se mostrar que a hipótese nula $H_0 : \beta_{l+1} = \cdots = \beta_k = 0$ vale se e somente se

$$\text{RSS}(X_{l+1}, \dots, X_k \mid X_2, \dots, X_l)/(k-l)$$

é um estimador não viesado de σ^2. Portanto, uma estatística sensata para avaliar essa hipótese nula é a estatística F

$$F = \frac{\text{RSS}(X_{l+1}, \dots, X_k \mid X_2, \dots, X_l)/(k-l)}{s^2},$$

em que valores grandes são evidência contra a hipótese nula.

O Coeficiente de Determinação

O coeficiente de determinação desse modelo é dado por

$$R^2 = \frac{\text{RSS}(X_2, \dots, X_k)}{\sum_{i=1}^{n}(y_i - \bar{y})^2},$$

que, pelo Lema 10.3.2, está sempre entre 0 e 1. O valor de R^2 dá a proporção da variação observada em Y que é explicada pela inclusão dos preditores não constantes no modelo.

Pode-se mostrar que R^2 é o quadrado do *coeficiente de correlação múltipla* entre Y e $X_1, \dots, X_k$. No entanto, não discutimos o coeficiente de correlação múltipla neste texto.

Intervalos de Confiança e Testes de Hipóteses

Para a inferência, temos o seguinte resultado.

Teorema 10.3.11

Se a distribuição condicional de Y dado $(X_1, \ldots, X_k) = (x_1, \ldots, x_k)$ é $N(\beta_1 x_1 + \cdots + \beta_k x_k, \sigma^2)$ e se observamos os valores independentes $(x_{i1}, \ldots, x_{ik}, y_i)$ para $i = 1, \ldots, n$, então as distribuições condicionais dos B_i e de S^2, dados $X_{ij} = x_{ij}$ para todo i, j, são as seguintes.

(i) $B_i \sim N(\beta_i, \sigma^2 c_{ii})$

(ii) $B_1 x_1 + \cdots + B_k x_k$ tem distribuição

$$N\left(\beta_1 x_1 + \cdots + \beta_k x_k, \sigma^2\left(\sum_{i=1}^{k} x_i^2 c_{ii} + 2\sum_{i<j} x_i x_j c_{ij}\right)\right)$$

(iii) $(n-k)S^2/\sigma^2 \sim \chi^2(n-k)$, independente de $(B_1, \ldots, B_k)$

Corolário 10.3.5

(i) $(B_i - \beta_i)/sc_{ii}^{1/2} \sim t(n-k)$

(ii)

$$\frac{B_1 x_1 + \cdots + B_k x_k - \beta_1 x_1 - \cdots - \beta_k x_k}{S\left(\sum_{i=1}^{k} x_i^2 c_{ii} + 2\sum_{i<j} x_i x_j c_{ij}\right)^{1/2}} \sim t(n-k)$$

(iii) $H_0 : \beta_{l+1} = \cdots = \beta_k = 0$ é verdadeira se e somente se

$$F = \frac{(\mathrm{RSS}(X_2, \ldots, X_k) - \mathrm{RSS}(X_2, \ldots, X_l))/(k-l)}{S^2} \sim F(k-l, n-k)$$

Análise dos Resíduos

Numa aplicação do modelo de regressão múltipla, precisamos verificar se as suposições fazem sentido. A verificação do modelo se baseia nos resíduos $y_i - b_1 x_{i1} - \cdots - b_k x_{ik}$ (depois de padronizados), exatamente como discutido na Seção 9.1. Note que o i-ésimo resíduo é simplesmente a diferença entre o valor observado y_i em $(x_{i1}, \ldots, x_{ik})$ e o valor predito $b_1 x_{i1} + \cdots + b_k x_{ik}$ em $(x_{i1}, \ldots, x_{ik})$.

Temos também o seguinte resultado (que pode ser provado como corolário do Teorema 10.3.10).

Corolário 10.3.6

(i) $E(Y_i - B_1 x_{i1} - \cdots - B_k x_{ik} \mid V) = 0$

(ii) $\text{Cov}\left(Y_i - B_1 x_{i1} - \cdots - B_k x_{ik}, Y_j - B_1 x_{j1} - \cdots - B_k x_{jk} \mid V\right) = \sigma^2 d_{ij}$, em que d_{ij} é o elemento (i, j) da matriz $I - V(V'V)^{-1}V'$.

Portanto, os resíduos padronizados são dados por*

$$\frac{y_j - b_1 x_{j1} - \cdots - b_k x_{jk}}{s d_{ii}^{1/2}}. \tag{10.3.19}$$

Quando s é substituído por σ em (10.3.19), o Corolário 10.3.6 implica que essa quantidade tem média condicional 0 e variância condicional 1. Além disso, quando a distribuição condicional da resposta dados os preditores é normal, pode-se mostrar que a distribuição condicional dessa quantidade é $N(0, 1)$. Esses resultados também valem aproximadamente para (10.3.19) quando n é grande. Além disso, pode-se mostrar que as covariâncias entre os resíduos padronizados tendem a 0 quando $n \to \infty$, sob certas condições razoáveis sobre a distribuição das variáveis preditoras. Assim, uma abordagem para a verificação do modelo aqui é ver se os valores dados por (10.3.19) se parecem de algum modo com uma amostra da distribuição $N(0, 1)$.

O que fazemos se a verificação do modelo leva a uma falha do modelo? Como no Capítulo 9, podemos considerar fazer várias transformações dos dados para ver se há uma modificação simples do modelo que passe na verificação. Podemos fazer transformações não só na variável resposta Y, mas também nas variáveis preditoras $X_1, \ldots, X_k$.

Uma Aplicação da Análise de Regressão Linear Múltipla

Os cálculos necessários para realizar uma análise de regressão linear múltipla não podem ser feitos à mão. Eles são demorados demais e muito sujeitos a erros. Por isso, é importante que o estatístico tenha à disposição um computador com software adequado quando fizer uma análise de regressão linear múltipla.

Os dados da Tabela 10.1 foram tirados de *Statistical Theory and Methodology in Science and Engineering*, 2ª ed., de K. A. Brownlee (John Wiley & Sons, Nova York, 1965). A variável resposta Y é a perda na chaminé (Loss), que representa 10 vezes a porcentagem de amônia perdida como óxido nítrico não absorvido. As variáveis preditoras são X_1 = fluxo de ar (Air), X_2 = temperatura da água

*Nota do tradutor. O original traz d_{ii} no denominador; pelo índice do numerador seria d_{jj}.

de entrada (Temp) e X_3 = concentração de ácido nítrico (Acid). Também foi registrado o dia (Dia) em que a observação foi feita.

Dia	Air	Temp	Acid	Loss	Dia	Air	Temp	Acid	Loss
1	80	27	89	42	12	58	17	88	13
2	80	27	88	37	13	58	18	82	11
3	75	25	90	37	14	58	19	93	12
4	62	24	87	28	15	50	18	89	8
5	62	22	87	18	16	50	18	86	7
6	62	23	87	18	17	50	19	72	8
7	62	24	93	19	18	50	19	79	8
8	62	24	93	20	19	50	20	80	9
9	58	23	87	15	20	56	20	82	15
10	58	18	80	14	21	70	20	91	15
11	58	18	89	14					

Tabela 10.1: Dados para a aplicação da análise de regressão linear múltipla.

Consideramos o modelo $Y \mid x_1, x_2, x_3 \sim N(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3, \sigma^2)$. Note que incluímos um termo de intercepto. A Figura 10.3.9 é um gráfico de probabilidade normal dos resíduos padronizados. Ele parece razoável, exceto por um resíduo, $-2{,}63822$, que se afasta de modo bem nítido dos demais valores, que ficam perto da reta de 45 graus. Imprimindo os resíduos padronizados, vemos que esse resíduo está associado à observação do vigésimo primeiro dia. Talvez tenha havido algo de excepcional na operação desse dia, e por isso é razoável descartar esse dado e reajustar o modelo. A Figura 10.3.10 é um gráfico de probabilidade normal obtido ajustando o modelo às 20 primeiras observações. Ele parece um pouco melhor, mas ainda poderíamos nos preocupar com pelo menos um dos resíduos, que se afasta bastante da reta de 45 graus.

Seguindo a análise desses dados em *Fitting Equations to Data*, de C. Daniel e F. S. Wood (Wiley-Interscience, Nova York, 1971), consideramos em vez disso o modelo

$$\ln Y \mid x_1, x_2, x_3 \sim N(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3, \sigma^2), \tag{10.3.20}$$

isto é, transformamos a variável resposta tomando seu logaritmo e usamos todos os dados. Muitas vezes, quando os modelos não se ajustam, transformações simples como essa podem levar a grandes melhorias. Neste caso, vemos um gráfico de probabilidade normal muito melhor, como mostra a Figura 10.3.11.

Também examinamos gráficos dos resíduos padronizados contra os diversos preditores, e eles pareceram razoáveis. A Figura 10.3.12 é um gráfico dos resíduos padronizados contra os valores de Air.

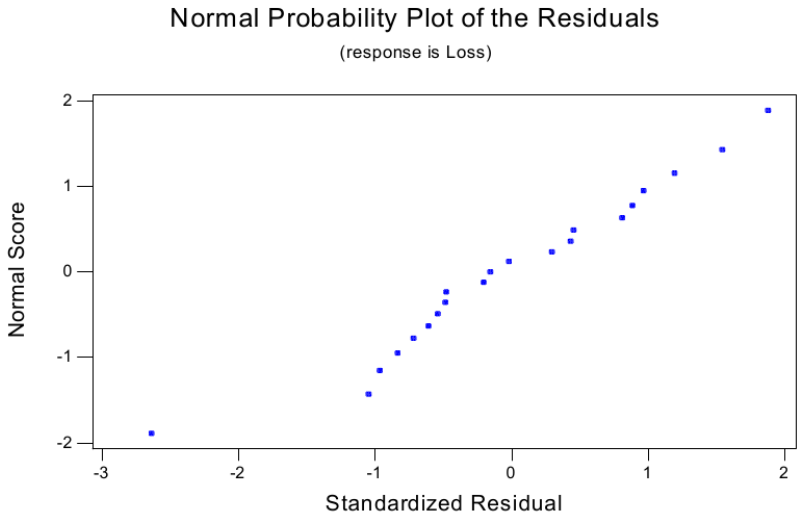


Figura 10.3.9: Gráfico de probabilidade normal dos resíduos padronizados com base em todos os dados.

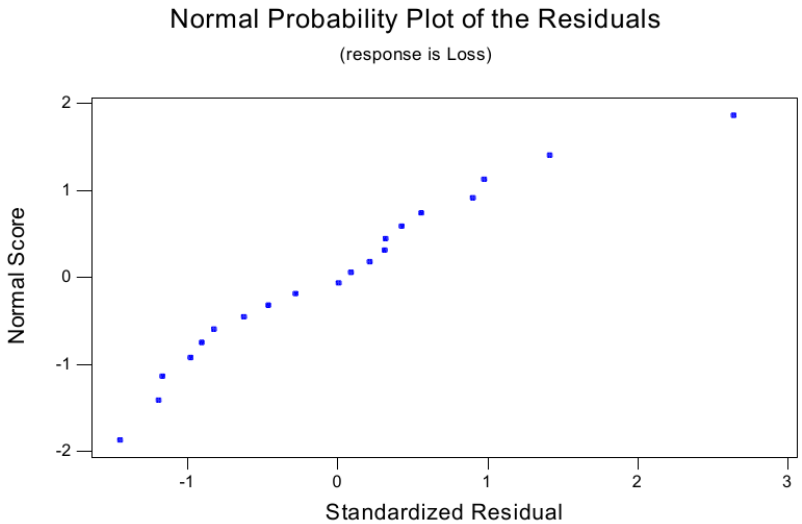


Figura 10.3.10: Gráfico de probabilidade normal dos resíduos padronizados com base nos 20 primeiros valores dos dados.

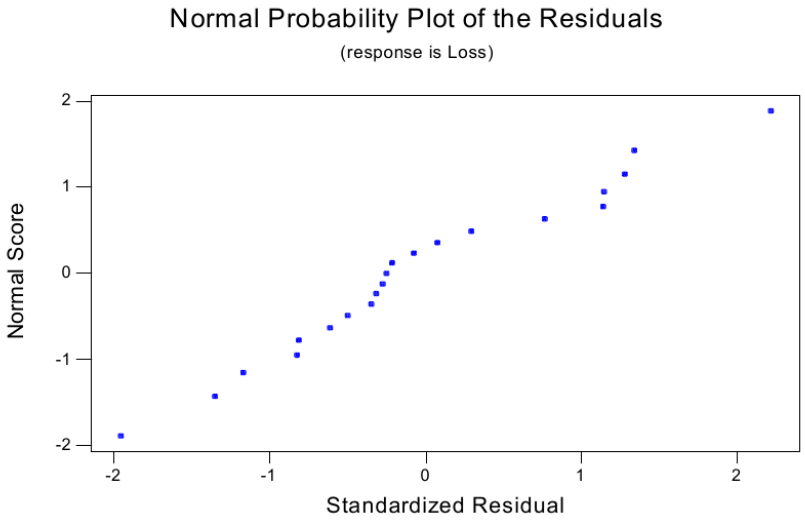


Figura 10.3.11: Gráfico de probabilidade normal dos resíduos padronizados para todos os dados, usando ln Y como resposta.

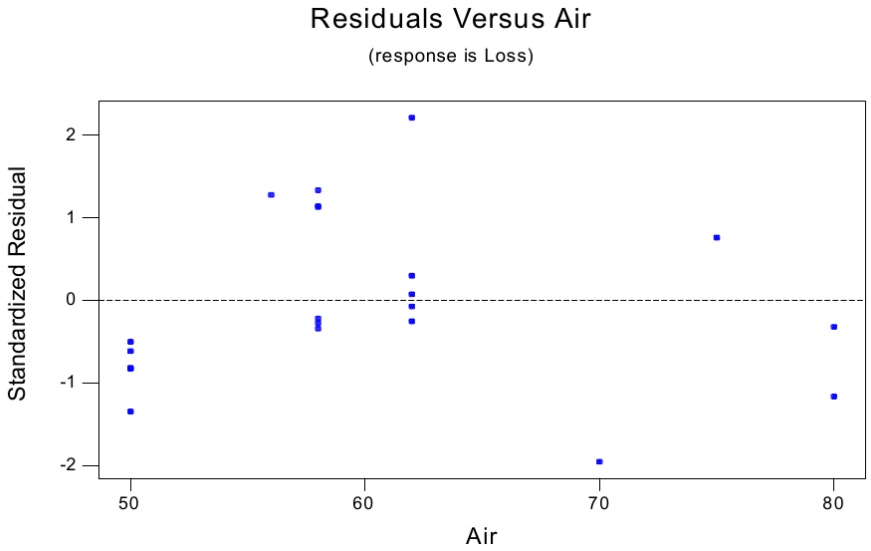


Figura 10.3.12: Gráfico dos resíduos padronizados para todos os dados, usando ln Y como resposta, contra os valores do preditor Air.

Agora que aceitamos o modelo (10.3.20), podemos passar às inferências sobre as incógnitas do modelo. As estimativas de mínimos quadrados dos β_i, seus erros padrão (Se), as estatísticas t correspondentes para testar $\beta_i = 0$ e os valores-p desses testes são dados na tabela a seguir.

Coeficiente	Estimativa	Se	Estatística t	Valor-p
β_0	−0,948700	0,647700	−1,46	0,161
β_1	0,034565	0,007343	4,71	0,000
β_2	0,063460	0,020040	3,17	0,006
β_3	0,002864	0,008510	0,34	0,742

A estimativa de σ^2 é dada por $s^2 = 0{,}0312$.

Para testar a hipótese nula de que não há relação entre a resposta e os preditores, ou, de modo equivalente, $H_0 : \beta_1 = \beta_2 = \beta_3 = 0$, temos a seguinte tabela ANOVA.

Fonte	GL	Soma de Quadrados	Quadrado Médio
X_1, X_2, X_3	3	4,9515	1,6505
Erro	17	0,5302	0,0312
Total	20	5,4817	

O valor da estatística F é dado por $1{,}6505/0{,}0312 = 52{,}900$ e, quando $F \sim F(3, 17)$, temos $P(F > 52{,}900) = 0{,}000$. Assim, há evidência substancial contra a hipótese nula. Para ver quão bem o modelo explica a variação da resposta, calculamos o valor $R^2 = 86{,}9\%$. Portanto, aproximadamente 87% da variação observada em Y pode ser explicada por mudanças nos preditores do modelo.

Embora tenhamos concluído que existe uma relação entre a resposta e os preditores, pode ser que alguns dos preditores não tenham relação com a resposta. Por exemplo, a tabela de estatísticas t acima parece indicar que talvez X_3 (ácido) não esteja afetando Y. Podemos avaliar isso por meio da seguinte tabela ANOVA, obtida ajustando o modelo $\ln Y \mid x_1, x_2, x_3 \sim N(\beta_0 + \beta_1 x_1 + \beta_2 x_2, \sigma^2)$.

Fonte	GL	Soma de Quadrados	Quadrado Médio
X_1, X_2	2	4,9480	2,4740
$X_3 \mid X_1, X_2$	1	0,0035	0,0035
Erro	17	0,5302	0,0312
Total	20	5,4817	

Note que $\text{RSS}(X_3 \mid X_1, X_2) = 4{,}9515 - 4{,}9480 = 0{,}0035$. O valor da estatística F para testar $H_0 : \beta_3 = 0$ é $0{,}0035/0{,}0312 = 0{,}112$ e, quando $F \sim F(1, 17)$, temos

$P(F > 0{,}112) = 0{,}742$. Assim, não temos evidência contra a hipótese nula e podemos retirar X_3 do modelo. Na verdade, esse é o mesmo valor-p obtido pelo teste t dessa hipótese nula, pois, em geral, o teste t de que um único coeficiente de regressão é 0 equivale ao teste F. Testes semelhantes sobre a necessidade de incluir X_1 e X_2 não nos levam a retirar essas variáveis do modelo.

Assim, com base nos resultados acima, decidimos retirar X_3 do modelo e usar a equação*

$$E(Y \mid X_1 = x_1, X_2 = x_2) = -0{,}7522 + 0{,}035402X_1 + 0{,}06346X_2 \qquad (10.3.21)$$

para descrever a relação entre Y e os preditores. Note que as estimativas de mínimos quadrados de β_0, β_1 e β_2 em (10.3.21) são obtidas reajustando o modelo sem X_3.

Resumo da Seção 10.3

- Nesta seção, examinamos a situação em que a variável resposta e as variáveis preditoras são quantitativas.
- Nessa situação, o modelo de regressão linear oferece uma descrição possível da forma de qualquer relação que possa existir entre a resposta e os preditores.
- Mínimos quadrados é um método padrão para ajustar modelos de regressão linear a dados.
- A ANOVA é uma decomposição da variação total observada na variável resposta numa parte atribuível a mudanças nas variáveis preditoras e numa parte atribuível ao erro aleatório.
- Se supomos um modelo de regressão linear normal, temos à disposição métodos de inferência como intervalos de confiança e testes de significância. Em particular, temos o teste F para avaliar se existe ou não uma relação entre a resposta e os preditores.
- Um modelo de regressão linear normal é verificado examinando os resíduos padronizados.

*Nota do tradutor. O original traz $E(Y \mid \ldots)$, embora o modelo ajustado (10.3.20) seja para $\ln Y$.

Exercícios

10.3.1 Suponha que $(x_1, \ldots, x_n)$ seja uma amostra de uma distribuição Bernoulli(θ), em que $\theta \in [0, 1]$ é desconhecido. Qual é a estimativa de mínimos quadrados da média dessa distribuição?

10.3.2 Suponha que $(x_1, \ldots, x_n)$ seja uma amostra da distribuição Uniforme$[0, \theta]$, em que $\theta > 0$ é desconhecido. Qual é a estimativa de mínimos quadrados da média dessa distribuição?

10.3.3 Suponha que $(x_1, \ldots, x_n)$ seja uma amostra da distribuição Exponencial(θ), em que $\theta > 0$ é desconhecido. Qual é a estimativa de mínimos quadrados da média dessa distribuição?

10.3.4 Considere os $n = 11$ valores de dados da tabela a seguir.

Observação	X	Y	Observação	X	Y
1	−5,00	−10,00	7	1,00	3,52
2	−4,00	−8,83	8	2,00	5,64
3	−3,00	−9,15	9	3,00	7,28
4	−2,00	−4,26	10	4,00	7,62
5	−1,00	−0,30	11	5,00	8,51
6	0,00	−0,04			

Suponha que consideremos a regressão linear normal simples para descrever a relação entre a resposta Y e o preditor X.

(a) Represente os dados num diagrama de dispersão.

(b) Calcule a reta de mínimos quadrados e trace-a no diagrama de dispersão do item (a).

(c) Faça o gráfico dos resíduos padronizados contra X.

(d) Produza um gráfico de probabilidade normal dos resíduos padronizados.

(e) Quais são suas conclusões com base nos gráficos produzidos nos itens (c) e (d)?

(f) Se for apropriado, calcule intervalos de confiança 0,95 para o intercepto e a inclinação.

(g) Construa a tabela ANOVA para testar se há ou não uma relação entre a resposta e os preditores. Qual é a sua conclusão?

(h) Se o modelo estiver correto, que proporção da variação observada na resposta é explicada por mudanças no preditor?

(i) Prediga um Y futuro em $X = 0{,}0$. Essa predição é uma extrapolação ou uma interpolação? Determine o erro padrão dessa predição.

(j) Prediga um Y futuro em $X = 6{,}0$. Essa predição é uma extrapolação ou uma interpolação? Determine o erro padrão dessa predição.

(k) Prediga um Y futuro em $X = 20{,}0$. Essa predição é uma extrapolação ou uma interpolação? Determine o erro padrão dessa predição. Compare-o com os erros padrão obtidos nos itens (i) e (j) e explique as diferenças.

10.3.5 Considere os $n = 11$ valores de dados da tabela a seguir.

Observação	X	Y	Observação	X	Y
1	−5,00	65,00	7	1,00	6,52
2	−4,00	39,17	8	2,00	17,64
3	−3,00	17,85	9	3,00	34,28
4	−2,00	7,74	10	4,00	55,62
5	−1,00	2,70	11	5,00	83,51
6	0,00	−0,04			

Suponha que consideremos a regressão linear normal simples para descrever a relação entre a resposta Y e o preditor X.

(a) Represente os dados num diagrama de dispersão.

(b) Calcule a reta de mínimos quadrados e trace-a no diagrama de dispersão do item (a).

(c) Faça o gráfico dos resíduos padronizados contra X.

(d) Produza um gráfico de probabilidade normal dos resíduos padronizados.

(e) Quais são suas conclusões com base nos gráficos produzidos nos itens (c) e (d)?

(f) Se for apropriado, calcule intervalos de confiança 0,95 para o intercepto e a inclinação.

(g) Os resultados da sua análise permitem concluir que há uma relação entre Y e X? Por quê?

(h) Se o modelo estiver correto, que proporção da variação observada na resposta é explicada por mudanças no preditor?

10.3.6 Suponha que os dados a seguir registrem as densidades de um organismo num recipiente de contenção durante 10 dias. Suponha que consideremos a regressão linear normal simples para descrever a relação entre a resposta Y (densidade) e o preditor X (dia).

Dia	Número/Litro	Dia	Número/Litro
1	1,6	6	1341,6
2	16,7	7	2042,9
3	65,2	8	7427,0
4	23,6	9	15571,8
5	345,3	10	33128,5

(a) Represente os dados num diagrama de dispersão.

(b) Calcule a reta de mínimos quadrados e trace-a no diagrama de dispersão do item (a).

(c) Faça o gráfico dos resíduos padronizados contra X.

(d) Produza um gráfico de probabilidade normal dos resíduos padronizados.

(e) Quais são suas conclusões com base nos gráficos produzidos nos itens (c) e (d)?

(f) Você consegue pensar numa transformação da resposta que possa resolver os problemas encontrados? Se sim, repita os itens de (a) a (e) depois de fazer essa transformação. (Sugestão: o diagrama de dispersão parece um crescimento exponencial. Que transformação é a inversa da exponenciação?)

(g) Calcule intervalos de confiança 0,95 para o intercepto e a inclinação apropriados.

(h) Construa a tabela ANOVA apropriada para testar se há ou não uma relação entre a resposta e os preditores. Qual é a sua conclusão?

(i) Os resultados da sua análise permitem concluir que há uma relação entre Y e X? Por quê?

(j) Calcule a proporção da variação explicada pelo preditor nos dois modelos que você considerou. Compare os resultados.

(k) Prediga um Y futuro em $X = 12$. Essa predição é uma extrapolação ou uma interpolação?

10.3.7 Um estudante faz testes semanais numa disciplina e recebe as seguintes notas ao longo de 12 semanas.

Semana	Nota	Semana	Nota
1	65	7	74
2	55	8	76
3	62	9	48
4	73	10	80
5	68	11	85
6	76	12	90

(a) Represente os dados num diagrama de dispersão com X = semana e Y = nota.

(b) Calcule a reta de mínimos quadrados e trace-a no diagrama de dispersão do item (a).

(c) Faça o gráfico dos resíduos padronizados contra X.

(d) Quais são suas conclusões com base no gráfico produzido em (c)?

(e) Calcule intervalos de confiança 0,95 para o intercepto e a inclinação.

(f) Construa a tabela ANOVA para testar se há ou não uma relação entre a resposta e os preditores. Qual é a sua conclusão?

(g) Que proporção da variação observada na resposta é explicada por mudanças no preditor?

10.3.8 Suponha que $Y = E(Y \mid X) + Z$, em que X, Y e Z são variáveis aleatórias.

(a) Mostre que $E(Z \mid X) = 0$.

(b) Mostre que $\text{Cov}(E(Y \mid X), Z) = 0$. (Sugestão: escreva $Z = Y - E(Y \mid X)$ e use os Teoremas 3.5.2 e 3.5.4.)

(c) Suponha que Z seja independente de X. Mostre que isso implica que a distribuição condicional de Y dado X depende de X apenas por meio de sua média condicional. (Sugestão: calcule a função de distribuição condicional de Y dado $X = x$.)

10.3.9 Suponha que X e Y sejam variáveis aleatórias tais que um modelo de regressão descreve a relação entre Y e X. Se $E(Y \mid X) = \exp\{\beta_1 + \beta_2 X\}$, discuta se esse é ou não um modelo de regressão linear simples (talvez envolvendo um preditor diferente de X).

10.3.10 Suponha que X e Y sejam variáveis aleatórias e que $\text{Corr}(X, Y) = 1$. Vale um modelo de regressão linear simples para descrever a relação entre Y e X? Se sim, qual é ele?

10.3.11 Suponha que X e Y sejam variáveis aleatórias tais que um modelo de regressão descreve a relação entre Y e X. Se $E(Y \mid X) = \beta_1 + \beta_2 X^2$, discuta se esse é ou não um modelo de regressão linear simples (talvez envolvendo um preditor diferente de X).

10.3.12 Suponha que $X \sim N(2, 3)$, independentemente de $Z \sim N(0, 1)$, e que $Y = X + Z$. Essa estrutura implica que a relação entre Y e X pode ser resumida por um modelo de regressão linear simples? Se sim, quais são β_1, β_2 e σ^2?

10.3.13 Suponha que um modelo linear simples seja ajustado a dados. Uma análise dos resíduos indica que não há razão para duvidar de que o modelo esteja correto; o teste ANOVA indica que há evidência substancial contra a hipótese nula de ausência de relação entre a resposta e o preditor. O valor de R^2 encontrado é 0,05. Qual é a interpretação desse número e quais são as consequências práticas?

Exercícios computacionais

10.3.14 Suponha que consideremos a regressão linear normal simples para descrever a relação entre a resposta Y (renda) e o preditor X (investimento) para os dados do Exemplo 10.3.9.

(a) Represente os dados num diagrama de dispersão.

(b) Calcule a reta de mínimos quadrados e trace-a no diagrama de dispersão do item (a).

(c) Faça o gráfico dos resíduos padronizados contra X.

(d) Produza um gráfico de probabilidade normal dos resíduos padronizados.

(e) Quais são suas conclusões com base nos gráficos produzidos nos itens (c) e (d)?

(f) Se for apropriado, calcule intervalos de confiança 0,95 para o intercepto e a inclinação.

(g) Os resultados da sua análise permitem concluir que há uma relação entre Y e X? Por quê?

(h) Se o modelo estiver correto, que proporção da variação observada na resposta é explicada por mudanças no preditor?

10.3.15 Os dados a seguir são medições da resistência à tração (100 lb/pol^2) e da dureza (Rockwell E) de 20 peças de alumínio fundido sob pressão.

Amostra	Resistência	Dureza	Amostra	Resistência	Dureza
1	293	53	11	298	60
2	349	70	12	292	51
3	340	78	13	380	95
4	340	55	14	345	88
5	340	64	15	257	51
6	354	71	16	265	54
7	322	82	17	246	52
8	334	67	18	286	64
9	247	56	19	324	83
10	348	86	20	282	56

Suponha que consideremos a regressão linear normal simples para descrever a relação entre a resposta Y (resistência) e o preditor X (dureza).

(a) Represente os dados num diagrama de dispersão.

(b) Calcule a reta de mínimos quadrados e trace-a no diagrama de dispersão do item (a).

(c) Faça o gráfico dos resíduos padronizados contra X.

(d) Produza um gráfico de probabilidade normal dos resíduos padronizados.

(e) Quais são suas conclusões com base nos gráficos produzidos nos itens (c) e (d)?

(f) Se for apropriado, calcule intervalos de confiança 0,95 para o intercepto e a inclinação.

(g) Os resultados da sua análise permitem concluir que há uma relação entre Y e X? Por quê?

(h) Se o modelo estiver correto, que proporção da variação observada na resposta é explicada por mudanças no preditor?

10.3.16 Foram feitos testes para determinar o efeito da temperatura de entrada do gás (graus Fahrenheit) e da velocidade do rotor (rpm) sobre o teor de alcatrão (grãos/pé cúbico) de um fluxo de gás, o que produziu os seguintes dados.

Observação	Alcatrão	Velocidade	Temperatura
1	60,0	2400	54,5
2	65,0	2450	58,5
3	63,5	2500	58,0
4	44,0	2700	62,5
5	54,5	2700	68,0
6	26,0	2775	45,5
7	54,0	2800	63,0
8	53,5	2900	64,5
9	33,5	3075	57,0
10	44,0	3150	64,0

Suponha que consideremos o modelo de regressão linear normal

$$Y \mid W = w, X = x \sim N(\beta_1 + \beta_2 w + \beta_3 x, \sigma^2)$$

para descrever a relação entre Y (teor de alcatrão) e os preditores W (velocidade do rotor) e X (temperatura).

(a) Faça diagramas de dispersão da resposta contra cada preditor.

(b) Calcule a equação de mínimos quadrados.

(c) Faça os gráficos dos resíduos padronizados contra W e X.

(d) Produza um gráfico de probabilidade normal dos resíduos padronizados.

(e) Quais são suas conclusões com base nos gráficos produzidos nos itens (c) e (d)?

(f) Se for apropriado, calcule intervalos de confiança 0,95 para os coeficientes da regressão.

(g) Construa a tabela ANOVA para testar se há ou não uma relação entre a resposta e os preditores. Qual é a sua conclusão?

(h) Se o modelo estiver correto, que proporção da variação observada na resposta é explicada por mudanças nos preditores?

(i) Numa tabela ANOVA, avalie a hipótese nula de que não há efeito devido a W, dado que X está no modelo.

(j) Estime a média de Y quando $W = 2750$ e $X = 50{,}0$. Se considerarmos esse valor como uma predição de um Y futuro nesses valores dos preditores, trata-se de uma extrapolação ou de uma interpolação?

10.3.17 Suponha que consideremos o modelo de regressão linear normal

$$Y \mid X = x \sim N(\beta_1 + \beta_2 x + \beta_3 x^2, \sigma^2)$$

para os dados do Exercício 10.3.5.

(a) Represente a resposta Y num diagrama de dispersão contra X.

(b) Calcule a equação de mínimos quadrados.

(c) Faça o gráfico dos resíduos padronizados contra X.

(d) Produza um gráfico de probabilidade normal dos resíduos padronizados.

(e) Quais são suas conclusões com base nos gráficos produzidos nos itens (c) e (d)?

(f) Se for apropriado, calcule intervalos de confiança 0,95 para os coeficientes da regressão.

(g) Construa a tabela ANOVA para testar se há ou não uma relação entre a resposta e o preditor. Qual é a sua conclusão?

(h) Se o modelo estiver correto, que proporção da variação observada na resposta é explicada por mudanças nos preditores?

(i) Numa tabela ANOVA, avalie a hipótese nula de que não há efeito devido a X^2, dado que X está no modelo.

(j) Compare as predições de Y em $X = 6$ obtidas com o modelo de regressão linear simples e com o modelo linear com um termo linear e um termo quadrático.

Problemas

10.3.18 Suponha que $(x_1, \ldots, x_n)$ seja uma amostra da distribuição de mistura

$$0{,}5\,\text{Uniforme}[0, 1] + 0{,}5\,\text{Uniforme}[2, \theta],$$

em que $\theta > 2$ é desconhecido. Qual é a estimativa de mínimos quadrados da média dessa distribuição?

10.3.19 Considere o modelo de regressão linear simples e suponha que, para os dados coletados, temos $\sum_{i=1}^{n}(x_i - \bar{x})^2 = 0$. Explique como, e para qual valor de x, você estimaria $E(Y \mid X = x)$.

10.3.20 No modelo de regressão linear simples, sob as hipóteses do Teorema 10.3.3, estabeleça que

$$\begin{aligned}&\operatorname{Cov}\left(Y_i - B_1 - B_2 x_i, Y_j - B_1 - B_2 x_j \mid X_1 = x_1, \ldots, X_n = x_n\right)\\ &\quad = \sigma^2 \delta_{ij} - \sigma^2 \left(\frac{1}{n} + \frac{(x_i - \bar{x})(x_j - \bar{x})}{\sum_{k=1}^{n} (x_k - \bar{x})^2}\right),\end{aligned}$$

em que $\delta_{ij} = 1$ quando $i = j$ e 0 caso contrário. (Sugestão: use os Teoremas 3.3.2 e 10.3.3.)

10.3.21 Estabeleça que (10.3.11) tem distribuição $N(0, 1)$ quando S é substituído por σ no denominador. (Sugestão: use o Teorema 4.6.1 e o Problema 10.3.20.)

10.3.22 (*Intervalos de predição*) Sob as hipóteses do Teorema 10.3.6, prove que o intervalo*

$$b_1 + b_2 x \pm s \left(1 + \frac{1}{n} + \frac{(x_i - \bar{x})^2}{\sum_{k=1}^{n} (x_k - \bar{x})^2}\right)^{1/2} t_{(1+\gamma)/2}(n-2),$$

baseado em $(x_1, y_1), \ldots, (x_n, y_n)$ independentes, contém Y com probabilidade igual a γ para um (X, Y) futuro independente com $X = x$. (Sugestão: Teoremas 4.6.1 e 3.3.2 e Corolário 10.3.1.)

10.3.23 Considere o modelo de regressão sem intercepto dado por $E(Y \mid X = x) = \beta x$, em que $\beta \in R^1$ é desconhecido. Suponha que observemos os valores independentes $(x_1, y_1), \ldots, (x_n, y_n)$.

(a) Determine a estimativa de mínimos quadrados de β.

(b) Prove que a estimativa de mínimos quadrados b de β é não viesada e, quando $\operatorname{Var}(Y \mid X = x) = \sigma^2$, prove que

$$\operatorname{Var}\left(B \mid X_1 = x_1, \ldots, X_n = x_n\right) = \frac{\sigma^2}{\sum_{i=1}^{n} x_i^2}.$$

(c) Sob as hipóteses dadas no item (b), prove que

$$s^2 = \frac{1}{n-1} \sum_{i=1}^{n} (y_i - b x_i)^2$$

é um estimador não viesado de σ^2.

*Nota do tradutor. O original traz $(x_i - \bar{x})^2$; para a predição em $X = x$ seria $(x - \bar{x})^2$.

(d) Escreva uma decomposição ANOVA apropriada para esse modelo e uma fórmula para R^2 que meça a proporção da variação observada em Y devida a mudanças em X.

(e) Quando $Y \mid X = x \sim N(\beta x, \sigma^2)$ e observamos os valores independentes $(x_1, y_1), \ldots, (x_n, y_n)$, prove que $b \sim N\big(\beta, \sigma^2 / \sum_{i=1}^n x_i^2\big)$.

(f) Sob as hipóteses do item (e), e supondo que $(n-1)S^2/\sigma^2 \sim \chi^2(n-1)$, independente de B (isso pode ser provado), indique como você testaria a hipótese nula de ausência de relação entre Y e X.

(g) Como você definiria resíduos padronizados para esse modelo e os usaria para verificar a validade do modelo?

10.3.24 Para dados $(x_1, y_1), \ldots, (x_n, y_n)$, prove que, se $\alpha_1 = \beta_1 + \beta_2 \bar{x}$ e $\alpha_2 = \beta_2$, então $\sum_{i=1}^n (y_i - \beta_1 - \beta_2 x_i)^2$ é igual a

$$\sum_{i=1}^n (y_i - \bar{y})^2 + n(\alpha_1 - \bar{y})^2 + \alpha_2^2 \sum_{i=1}^n (x_i - \bar{x})^2 - 2\alpha_2 \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}).$$

A partir disso, deduza que $\bar{y}$ e $a = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) / \sum_{i=1}^n (x_i - \bar{x})^2$ são as estimativas de mínimos quadrados de α_1 e α_2, respectivamente.

10.3.25 Para o modelo discutido na Seção 10.3.3, prove que a priori dada por $\alpha_1 \mid \alpha_2, \sigma^2 \sim N(\mu_1, \tau_1^2 \sigma^2)$, $\alpha_2 \mid \sigma^2 \sim N(\mu_2, \tau_2^2 \sigma^2)$ e $1/\sigma^2 \sim \text{Gama}(\kappa, \nu)$ leva à distribuição a posteriori enunciada ali. Conclua que essa priori é conjugada com a distribuição a posteriori, como especificado. (Sugestão: o desenvolvimento é semelhante ao do Exemplo 7.1.4, como detalhado na Seção 7.5.)

10.3.26 Para o modelo especificado na Seção 10.3.3, prove que, quando $\tau_1 \to \infty$, $\tau_2 \to \infty$ e $\nu \to 0$, a distribuição a posteriori de α_1 é dada pela distribuição de $\bar{y} + \big(2\nu_{xy}/n\,(2\kappa + n)\big)^{1/2} Z$, em que $Z \sim t(2\kappa + n)$ e $\nu_{xy} = (c_y^2 - a^2 c_x^2)/2$.

Desafios

10.3.27 Se $X_1, \ldots, X_n$ é uma amostra de uma distribuição com variância finita, prove que

$$\frac{X_i - \bar{X}}{\sqrt{\sum_{k=1}^n \left(X_k - \bar{X}\right)^2}} \xrightarrow{\text{q.c.}} 0.$$

10.4 Resposta Quantitativa e Preditores Categóricos

Nesta seção, consideramos a situação em que a resposta é quantitativa e os preditores são categóricos. Pode haver muitos preditores categóricos, mas restringimos a discussão a no máximo dois, porque isso já mostra as características mais importantes do caso geral. O caso geral fica para um curso mais avançado.

10.4.1 Um Preditor Categórico (ANOVA com Um Fator)

Suponha agora que a resposta Y é quantitativa e que o preditor X é categórico, assumindo a valores ou níveis, denotados por $1, \dots, a$. No modelo de regressão, supomos que o único aspecto da distribuição condicional de Y, dado $X = x$, que muda quando x muda é a média. Seja

$$\beta_i = E(Y \mid X = i)$$

a resposta média quando o preditor X está no nível i. Observe que isso já é, de imediato, um modelo de regressão linear.

Introduzimos as *variáveis indicadoras*

$$X_i = \begin{cases} 1 & X = i \\ 0 & X \neq i \end{cases}$$

para $i = 1, \dots, a$. Observe que, qualquer que seja o valor da resposta Y, apenas uma das variáveis indicadoras assume o valor 1, e as demais assumem o valor 0. Assim, podemos escrever*

$$E(Y \mid X_1 = x_1, \dots, X_a) = x_a = \beta_1 x_1 + \cdots + \beta_a x_a,$$

porque um e apenas um dos x_i é igual a 1, enquanto os demais são 0. Isso tem exatamente a mesma forma do modelo discutido na Seção 10.3.4, já que as X_i são quantitativas. Desse modo, todos os resultados da Seção 10.3.4 se aplicam imediatamente (vamos reapresentar aqui os resultados relevantes).

*Nota do tradutor. o original traz "$X_a) = x_a =$"; o pretendido parece ser $E(Y \mid X_1 = x_1, \dots, X_a = x_a) = \beta_1 x_1 + \cdots + \beta_a x_a$.

Inferências sobre Médias Individuais

Suponha agora que observamos n_i valores $(y_{i1}, \ldots, y_{in_i})$ quando $X = i$ e que todos os valores da resposta são independentes. Observe que temos a amostras independentes. As estimativas de mínimos quadrados dos β_i são obtidas minimizando

$$\sum_{i=1}^{a}\sum_{j=1}^{n_i}(y_{ij} - \beta_i)^2.$$

As estimativas de mínimos quadrados são então iguais a (ver o Problema 10.4.14)

$$b_i = \bar{y}_i = \frac{1}{n_i}\sum_{j=1}^{n_i} y_{ij}.$$

Pode-se mostrar que esses são estimadores não viesados dos β_i.

Supondo que as distribuições condicionais de Y, dado $X = x$, têm todas variância igual a σ^2, temos que a variância condicional de $\bar{Y}_i$ é dada por σ^2/n_i e que a covariância[64] condicional entre $\bar{Y}_i$ e $\bar{Y}_j$, quando $i \neq j$, é 0. Além disso, sob essas condições, um estimador não viesado de σ^2 é dado por

$$s^2 = \frac{1}{N-a}\sum_{i=1}^{a}\sum_{j=1}^{n_i}(y_{ij} - \bar{y}_i)^2,$$

em que $N = n_1 + \cdots + n_k$.*

Se, além disso, supusermos o modelo de regressão linear normal, isto é,

$$Y \mid X = i \sim N(\beta_i, \sigma^2),$$

então $\bar{Y}_i \sim N(\beta_i, \sigma^2/n_i)$, independente de $(N-a)S^2/\sigma^2 \sim \chi^2(N-a)$. Portanto, pela Definição 4.6.2,

$$T = \frac{\bar{Y}_i - \beta_i}{S/\sqrt{n_i}} \sim t(N-a),$$

o que leva a um intervalo de confiança γ da forma

$$\bar{y}_i \pm \frac{s}{\sqrt{n_i}}\, t_{(1+\gamma)/2}(N-a)$$

para β_i. Também podemos testar a hipótese nula $H_0 : \beta_i = \beta_{i0}$ calculando o valor-p

$$P\left(|T| \geq \left|\frac{\bar{y}_i - \beta_{i0}}{s/\sqrt{n_i}}\right|\right) = 2\left(1 - G\left(\left|\frac{\bar{y}_i - \beta_{i0}}{s/\sqrt{n_i}}\right|; N-a\right)\right),$$

*Nota do tradutor. o original traz n_k; pela notação da seção, seria n_a.

No original: *covariance*[64].

em que $G(\cdot\,; N-a)$ é a fda da distribuição $t(N-a)$. Observe que essas inferências são exatamente como as obtidas na Seção 6.3 para o modelo normal de locação e escala[65], exceto que agora usamos outro estimador de σ^2 (com mais graus de liberdade).

Inferências sobre Diferenças de Médias e Inferências com Duas Amostras

Muitas vezes queremos fazer inferências sobre uma diferença de médias $\beta_i - \beta_j$. Observe que $E(\bar{Y}_i - \bar{Y}_j) = \beta_i - \beta_j$ e

$$\operatorname{Var}(\bar{Y}_i - \bar{Y}_j) = \operatorname{Var}(\bar{Y}_i) + \operatorname{Var}(\bar{Y}_j) = \sigma^2(1/n_i + 1/n_j),$$

porque $\bar{Y}_i$ e $\bar{Y}_j$ são independentes. Pelo Teorema 4.6.1,

$$\bar{Y}_i - \bar{Y}_j \sim N(\beta_i - \beta_j, \sigma^2(1/n_i + 1/n_j)).$$

Além disso,

$$\frac{(\bar{Y}_i - \bar{Y}_j) - (\beta_i - \beta_j)}{\sigma(1/n_i + 1/n_j)^{1/2}} \sim N(0,1),$$

independente de $(N-a)\,S^2/\sigma^2 \sim \chi^2(N-a)$. Portanto, pela Definição 4.6.2,

$$\begin{aligned} T &= \left(\frac{(\bar{Y}_i - \bar{Y}_j) - (\beta_i - \beta_j)}{\sigma(1/n_i + 1/n_j)^{1/2}}\right) \Bigg/ \sqrt{\frac{(N-a)\,S^2}{(N-a)\,\sigma^2}} \\ &= \frac{(\bar{Y}_i - \bar{Y}_j) - (\beta_i - \beta_j)}{S(1/n_i + 1/n_j)^{1/2}} \sim t(N-a). \end{aligned} \tag{10.4.1}$$

Isso leva ao intervalo de confiança γ

$$\bar{y}_i - \bar{y}_j \pm s\sqrt{\frac{1}{n_i} + \frac{1}{n_j}}\; t_{(1+\gamma)/2}(N-a)$$

para a diferença de médias $\beta_i - \beta_j$. Podemos testar a hipótese nula $H_0 : \beta_i = \beta_j$, isto é, de que a diferença entre as médias é igual a 0, calculando o valor-p

$$P\left(|T| \geq \left|\frac{\bar{y}_i - \bar{y}_j}{s\sqrt{\frac{1}{n_i} + \frac{1}{n_j}}}\right|\right) = 2\left(1 - G\left(\left|\frac{\bar{y}_i - \bar{y}_j}{s\sqrt{\frac{1}{n_i} + \frac{1}{n_j}}}\right|; N-a\right)\right).$$

Quando $a = 2$, isto é, quando há apenas dois valores para X, chamamos (10.4.1) de *estatística t para duas amostras*, e os procedimentos de inferência

No original: *location-scale normal model*[65].

correspondentes são chamados de *intervalo de confiança t para duas amostras* e *teste t para duas amostras* para a diferença de médias. Nesse caso, se concluímos que $\beta_1 \neq \beta_2$, estamos dizendo que existe uma relação entre Y e X.

A ANOVA para Avaliar uma Relação com o Preditor

Suponha que, no caso geral em que $a \geq 2$, estamos interessados em avaliar se existe ou não uma relação entre a resposta e o preditor. Não há relação se e somente se todas as distribuições condicionais são iguais; sob as nossas suposições, isso acontece se e somente se $\beta_1 = \cdots = \beta_a$, isto é, se e somente se todas as médias são iguais. Assim, testar a hipótese nula de que não há relação entre a resposta e o preditor equivale a testar a hipótese nula $H_0 : \beta_1 = \cdots = \beta_a = \beta$ para algum β desconhecido.

Se a hipótese nula é verdadeira, a estimativa de mínimos quadrados de β é dada por $\bar{y}$, a média geral dos valores da resposta. Nesse caso, a variação total se decompõe como (ver o Problema 10.4.15)

$$\sum_{i=1}^{a}\sum_{j=1}^{n_i}(y_{ij}-\bar{y})^2 = \sum_{i=1}^{a} n_i\,(\bar{y}_i-\bar{y})^2 + \sum_{i=1}^{a}\sum_{j=1}^{n_i}(y_{ij}-\bar{y}_i)^2,$$

e, assim, a tabela ANOVA relevante para testar H_0 é a dada a seguir.*

Fonte	GL	Soma de Quadrados	Quadrado Médio
X	$a-1$	$\sum_{i=1}^{a} n_i\,(\bar{y}_i-\bar{y})^2$	$\sum_{i=1}^{a} n_i\,(\bar{y}_i-\bar{y})^2/(a-1)$
Erro	$N-a$	$\sum_{i=}^{a}\sum_{j=1}^{n_i}(y_{ij}-\bar{y}_i)^2$	s^2
Total	$N-1$	$\sum_{i=}^{a}\sum_{j=1}^{n_i}(y_{ij}-\bar{y})^2$	

Para avaliar H_0, usamos a estatística F

$$F = \frac{\sum_{i=1}^{a} n_i\,(\bar{y}_i-\bar{y})^2/(a-1)}{s^2},$$

porque, sob a hipótese nula, tanto o numerador quanto o denominador são estimadores não viesados de σ^2. Quando a hipótese nula é falsa, o numerador tende a ser maior que σ^2. Quando acrescentamos a suposição de normalidade, temos que $F \sim F(a-1, N-a)$, e então calculamos o valor-p

$$P\left(F > \frac{\sum_{i=1}^{a} n_i\,(\bar{y}_i-\bar{y})^2/(a-1)}{s^2}\right)$$

*Nota do tradutor. nas linhas Erro e Total da tabela, o original traz o índice do primeiro somatório incompleto, "$i =$"; pelo contexto, seria $i = 1$.

para avaliar se o valor observado de F é tão grande a ponto de ser surpreendente. Observe que, quando $a = 2$, esse valor-p é igual ao valor-p obtido pelo teste t para duas amostras.

Comparações Múltiplas

Se rejeitamos a hipótese nula de que não há diferenças entre as médias, então queremos ver onde estão as diferenças. Para isso, usamos métodos de inferência baseados em (10.4.1). Naturalmente, precisamos nos preocupar com o problema das *comparações múltiplas*[66], discutido na Seção 9.3. Lembre-se de que esse problema surge sempre que testamos muitas hipóteses nulas usando um valor crítico específico, como 5%, como ponto de corte para um valor-p, a fim de decidir se existe ou não uma diferença. O ponto de corte para um valor-p individual é chamado de *taxa de erro individual*. Na prática, mesmo que não exista nenhuma diferença, a probabilidade de concluir que existe pelo menos uma diferença, a *taxa de erro da família*, pode ser bastante alta.

Há vários procedimentos destinados a controlar a taxa de erro da família ao fazer comparações múltiplas. O mais simples é diminuir a taxa de erro individual, já que a taxa de erro da família é, em geral, uma função crescente dessa quantidade. É essa a abordagem que adotamos aqui, e contamos com um software estatístico para calcular e informar a taxa de erro da família. Chamamos esse procedimento de *teste de comparações múltiplas de Fisher*.

Verificação do Modelo

Para verificar o modelo, olhamos os resíduos padronizados (ver o Problema 10.4.17), dados por

$$\frac{y_{ij} - \bar{y}_i}{s\sqrt{1 - \frac{1}{n_i}}}. \tag{10.4.2}$$

Vamos nos restringir a vários gráficos dos resíduos padronizados para a verificação do modelo.

Consideramos agora um exemplo.

No original: *multiple comparisons*[66].

Exemplo 10.4.1

Foi feito um estudo para determinar se oito tipos diferentes de gordura são ou não absorvidos em quantidades diferentes durante a fritura de donuts. Os resultados foram obtidos fritando seis donuts diferentes e medindo depois a quantidade de gordura absorvida, em gramas. Tomamos a variável X como o tipo de gordura e usamos o modelo desta seção.

Os dados coletados são apresentados na tabela a seguir.

Gordura 1	164	177	168	156	172	195
Gordura 2	172	197	167	161	180	190
Gordura 3	177	184	187	169	179	197
Gordura 4	178	196	177	181	184	191
Gordura 5	163	177	144	165	166	178
Gordura 6	163	193	176	172	176	178
Gordura 7	150	179	146	141	169	183
Gordura 8	164	169	155	149	170	167

Um gráfico de probabilidade normal dos resíduos padronizados é apresentado na Figura 10.4.1. Um gráfico dos resíduos padronizados contra o tipo de gordura é apresentado na Figura 10.4.2. Nenhum dos dois gráficos dá motivos sérios de preocupação com a validade do modelo, embora haja algum indício de diferença na variabilidade da resposta conforme o tipo de gordura muda. Outro gráfico útil nesta situação são os boxplots lado a lado, porque mostram graficamente onde podem estar as possíveis diferenças. Esse gráfico é apresentado na Figura 10.4.3.

A tabela a seguir dá as quantidades médias absorvidas de cada gordura.

Gordura 1	Gordura 2	Gordura 3	Gordura 4
172,00	177,83	182,17	184,50
Gordura 5	Gordura 6	Gordura 7	Gordura 8
165,50	176,33	161,33	162,33

A resposta média geral é dada por 172,8.

Para avaliar a hipótese nula de que não há diferenças entre os tipos de gordura, calculamos a seguinte tabela ANOVA.

Fonte	GL	Soma de Quadrados	Quadrado Médio
X	7	3344	478
Erro	40	5799	145
Total	47	9143	

Usamos então a estatística F, dada por $F = 478/145 = 3{,}3$. Como $F \sim F(7, 40)$ sob H_0, obtemos o valor-p $P(F > 3{,}3) = 0{,}007$. Portanto, concluímos que há uma diferença entre os tipos de gordura ao nível de 0,05.

Para descobrir onde estão as diferenças, olhamos todas as diferenças duas a duas. Há $8 \cdot 7/2 = 28$ comparações desse tipo. Se usamos o nível de 0,05 para determinar se existe ou não uma diferença entre as médias, o software calcula a taxa de erro da família como 0,481, o que parece desconfortavelmente alto. Quando usamos o nível de 0,01, a taxa de erro da família cai para 0,151. Com a taxa de erro individual em 0,003, a taxa de erro da família é 0,0546. Usando a taxa de erro individual de 0,003, as únicas diferenças detectadas entre as médias são as entre a Gordura 4 e a Gordura 7 e entre a Gordura 4 e a Gordura 8. Observe que a Gordura 4 tem a maior absorção, enquanto as Gorduras 7 e 8 têm as menores.

No geral, os resultados são um tanto inconclusivos: vemos alguma evidência de que existem diferenças, mas também ficamos com algumas anomalias. Por exemplo, as Gorduras 4 e 5 não são diferentes, nem as Gorduras 7 e 5, mas as Gorduras 4 e 7 são consideradas diferentes. Resolver esses conflitos exige amostras maiores ou um experimento mais refinado, para que as comparações sejam mais precisas. ■

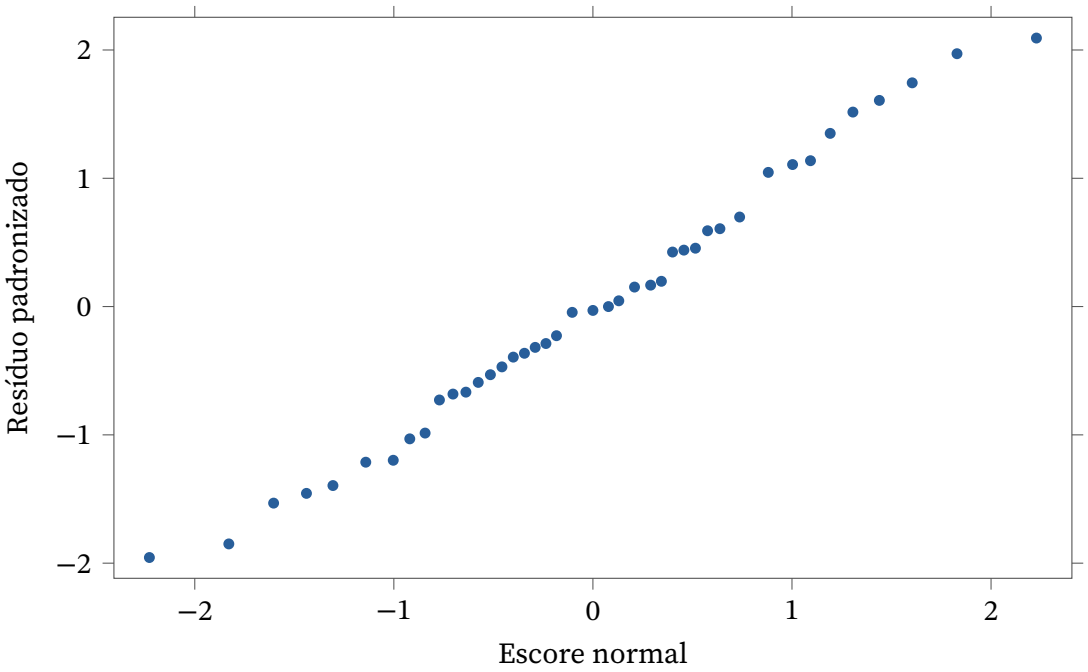


Figura 10.4.1: Gráfico de probabilidade normal dos resíduos padronizados no Exemplo 10.4.1.

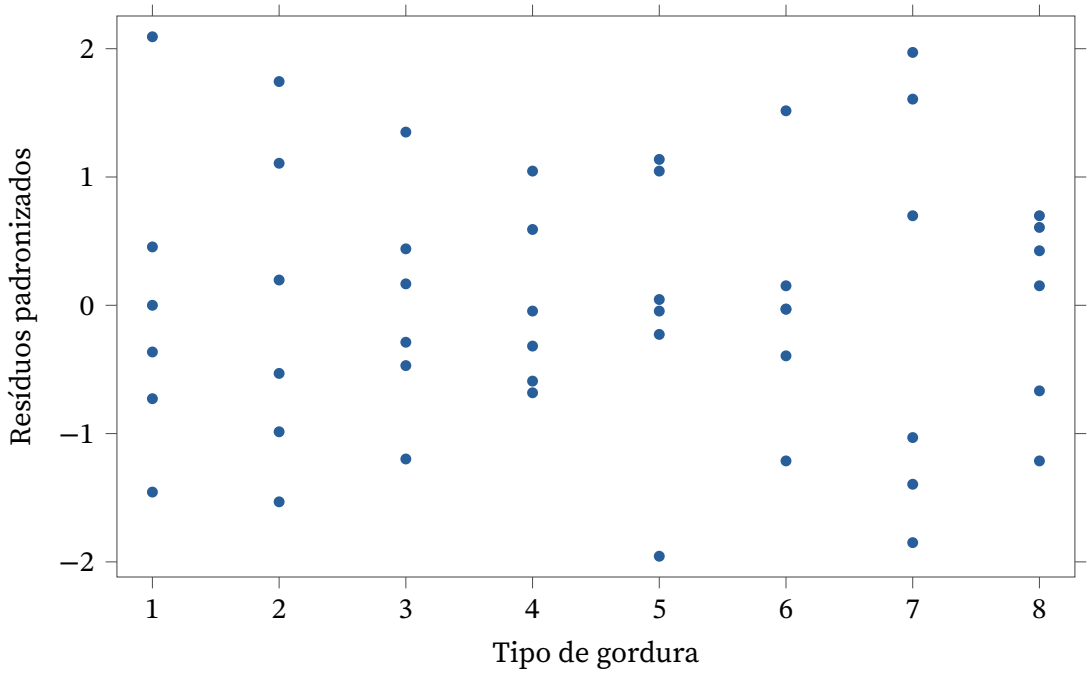


Figura 10.4.2: Resíduos padronizados versus tipo de gordura no Exemplo 10.4.1.

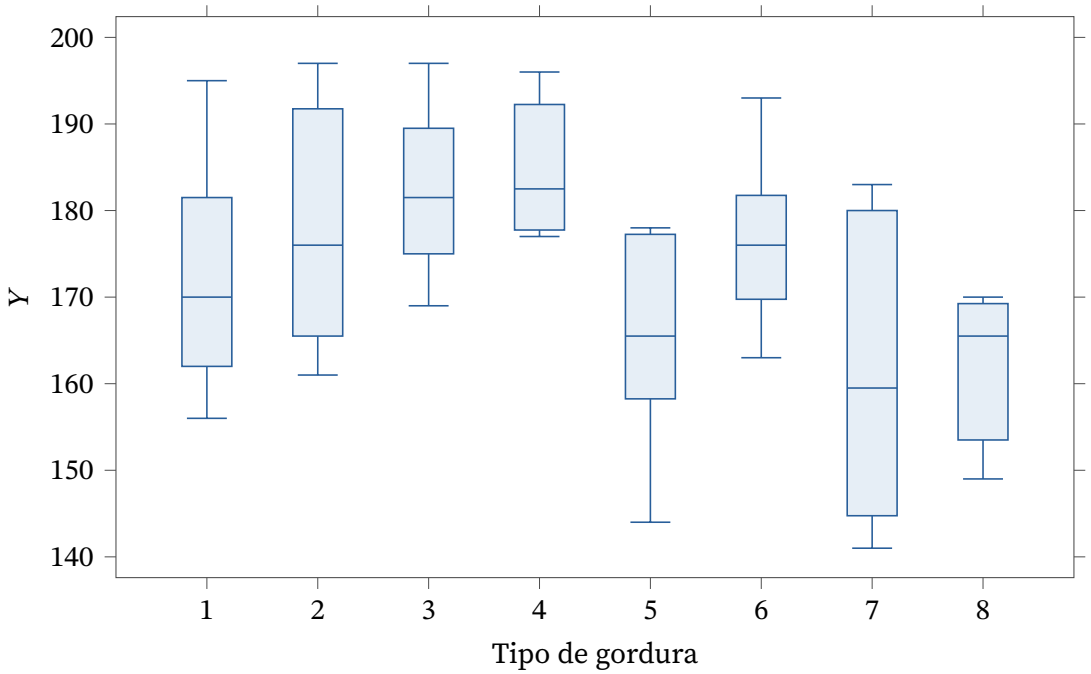


Figura 10.4.3: Boxplots lado a lado da resposta versus tipo de gordura no Exemplo 10.4.1.

10.4.2 Medidas Repetidas (Comparações Pareadas)

Considere k variáveis quantitativas $Y_1, \ldots, Y_k$ definidas numa população Π. Suponha que o nosso objetivo seja comparar as distribuições dessas variáveis. Em geral, serão variáveis semelhantes, todas medidas nas mesmas unidades.

Exemplo 10.4.2

Suponha que Π é um conjunto de estudantes matriculados num programa de primeiro ano que exige que os estudantes cursem tanto cálculo quanto física, e que queremos comparar as notas obtidas nessas disciplinas. Se Y_1 denota a nota de cálculo e Y_2 denota a nota de física, então queremos comparar as distribuições dessas variáveis. ■

Exemplo 10.4.3

Suponha que queremos comparar as distribuições da duração das dores de cabeça para dois tratamentos (A e B) numa população de pessoas que sofrem de enxaqueca. Seja Y_1 a duração de uma dor de cabeça depois da administração do tratamento A, e seja Y_2 a duração de uma dor de cabeça depois da administração do tratamento B. ■

A abordagem de *medidas repetidas* para o problema de comparar as distribuições de $Y_1, \ldots, Y_k$ consiste em tomar uma amostra aleatória $\pi_1, \ldots, \pi_n$ de Π e, para cada π_i, obter o valor k-dimensional $(Y_1(\pi_i), \ldots, Y_k(\pi_i)) = (y_{i1}, \ldots, y_{ik})$. Isso dá uma amostra de tamanho n de uma distribuição k-dimensional. Evidentemente, isso se chama medidas repetidas porque estamos tomando as medições $Y_1(\pi_i), \ldots, Y_k(\pi_i)$ no mesmo π_i.

Uma alternativa às medidas repetidas é tomar k amostras independentes de Π e, para cada uma delas, obter os valores de uma e apenas uma das variáveis Y_i. Há um motivo importante para preferir a abordagem de medidas repetidas: esperamos menos variação nos valores das diferenças, como $Y_i - Y_j$, na amostragem com medidas repetidas do que na amostragem independente, porque, nas medidas repetidas, os valores $Y_1(\pi), \ldots, Y_k(\pi)$ são tomados no *mesmo* membro da população.

Para ver isso com mais clareza, suponha que todas as variâncias e covariâncias existem para a distribuição conjunta de $Y_1, \ldots, Y_k$. Isso implica que

$$\operatorname{Var}(Y_i - Y_j) = \operatorname{Var}(Y_i) + \operatorname{Var}(Y_j) - 2\operatorname{Cov}(Y_i, Y_j). \tag{10.4.3}$$

Como Y_i e Y_j são variáveis semelhantes, medidas no mesmo indivíduo, esperamos que sejam positivamente correlacionadas. Já com amostragem

independente, temos que $\text{Var}(Y_i - Y_j) = \text{Var}(Y_i) + \text{Var}(Y_i)$, então as variâncias das diferenças devem ser menores com medidas repetidas do que com amostragem independente.*

Quando supomos que as distribuições das Y_i diferem no máximo em suas médias, faz sentido fazer inferências sobre as diferenças das médias populacionais $\mu_i - \mu_j$ usando as diferenças das médias amostrais $\bar{y}_i - \bar{y}_j$. No contexto de medidas repetidas, podemos escrever

$$\bar{y}_i - \bar{y}_j = \frac{1}{n}\sum_{l=1}^{n}(y_{li} - y_{lj}).$$

Como as parcelas individuais dessa soma são independentes, temos

$$\text{Var}(\bar{Y}_i - \bar{Y}_j) = \frac{\text{Var}(Y_i) + \text{Var}(Y_j) - 2\,\text{Cov}(Y_i, Y_j)}{n}.$$

Podemos considerar as diferenças $d_1 = y_{1i} - y_{1j}, \ldots, d_n = y_{ni} - y_{nj}$ como uma amostra de tamanho n de uma distribuição unidimensional com média $\mu_i - \mu_j$ e variância σ^2 dada por (10.4.3). Assim, estimamos $\mu_i - \mu_j$ por $\bar{d} = \bar{y}_i - \bar{y}_j$ e estimamos σ^2 por

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(d_i - \bar{d})^2. \tag{10.4.4}$$

Se supusermos que a distribuição conjunta de $Y_1, \ldots, Y_k$ é normal multivariada (isso significa que qualquer combinação linear dessas variáveis tem distribuição normal — ver o Problema 9.1.18), então a distribuição de $Y_i - Y_j$ é forçosamente $N(\mu_i - \mu_j, \sigma^2)$. Assim, temos à disposição todas as técnicas univariadas discutidas no Capítulo 6 para fazer inferências sobre $\mu_i - \mu_j$.

Até aqui, a discussão foi sobre se as distribuições das variáveis diferiam. Supondo que essas distribuições difiram no máximo em suas médias, isso leva a uma comparação das médias. Podemos, no entanto, registrar uma observação como (X, Y), em que X assume valores em $\{1, \ldots, k\}$ e $X = i$ significa que $Y = Y_i$. Então, a distribuição condicional de Y dado $X = i$ é igual à distribuição de Y_i. Portanto, se concluímos que as distribuições das Y_i são diferentes, podemos concluir que existe uma relação entre Y e X. No Exemplo 10.4.2, isso significa que existe uma relação entre a nota de um estudante e o fato de a nota ser de cálculo ou de física. No Exemplo 10.4.3, isso significa que existe uma relação entre a duração de uma dor de cabeça e o tratamento.

Quando podemos afirmar que tal relação é de fato uma relação de causa e efeito? Aplicando a discussão da Seção 10.1.2, sabemos que temos de ser

*Nota do tradutor. o original traz $\text{Var}(Y_i) + \text{Var}(Y_i)$; seria $\text{Var}(Y_i) + \text{Var}(Y_j)$.

capazes de atribuir o valor de X a um elemento da população selecionado ao acaso. No Exemplo 10.4.2, vemos que isso é impossível, e então não podemos afirmar que tal relação seja uma relação de causa e efeito. No Exemplo 10.4.3, porém, podemos de fato fazer isso: para um indivíduo selecionado ao acaso, atribuímos aleatoriamente um tratamento à primeira dor de cabeça que ele tiver durante o período do estudo e então aplicamos o outro tratamento à segunda dor de cabeça que ele tiver durante o período do estudo.

Uma discussão completa de medidas repetidas exige conceitos mais avançados de estatística. Restringimos agora a nossa atenção à apresentação de um exemplo com $k = 2$, situação que costuma ser chamada de *comparações pareadas*.

Exemplo 10.4.4 — Estudo da Pressão Arterial

A tabela a seguir vem de um estudo do efeito do medicamento captopril sobre a pressão arterial, relatado em *Applied Statistics, Principles and Examples*, de D. R. Cox e E. J. Snell (Chapman and Hall, Londres, 1981). Cada medição é a diferença entre a pressão arterial sistólica antes e depois da administração do medicamento.

−9	−4	−21	−3	−20
−31	−17	−26	−26	−10
−23	−33	−19	−19	−23

A Figura 10.4.4 é um gráfico de probabilidade normal desses dados e, como ele parece razoável, concluímos que os métodos de inferência baseados na suposição de normalidade são aceitáveis. Observe que aqui não padronizamos a variável antes; assim, estamos apenas verificando se o gráfico é razoavelmente reto.

A diferença média é dada por $\bar{d} = -18{,}93$, com desvio padrão $s = 9{,}03$. Assim, o erro padrão da estimativa da diferença das médias, usando (10.4.4), é dado por $s/\sqrt{15} = 2{,}33$. Um intervalo de confiança 0,95 para a diferença da pressão arterial sistólica média antes e depois da administração do captopril é então

$$\bar{d} \pm \frac{s}{\sqrt{n}} t_{0{,}975}(n-1) = -18{,}93 \pm 2{,}33\, t_{0{,}975}(14) = (-23{,}93; -13{,}93).$$

Como esse intervalo não contém 0, rejeitamos a hipótese nula de que não há diferença entre as médias ao nível de 0,05. O valor-p efetivo do teste bilateral é dado por

$$P(|T| > |-18{,}93/2{,}33|) = 0{,}000,$$

porque $T \sim t(14)$ sob a hipótese nula H_0 de que as médias são iguais. Portanto, temos forte evidência contra H_0. Parece que temos forte evidência de que o medicamento está levando a uma queda da pressão arterial. ■

10.4.3 Dois Preditores Categóricos (ANOVA com Dois Fatores)

Suponha agora que temos uma única resposta quantitativa Y e dois preditores

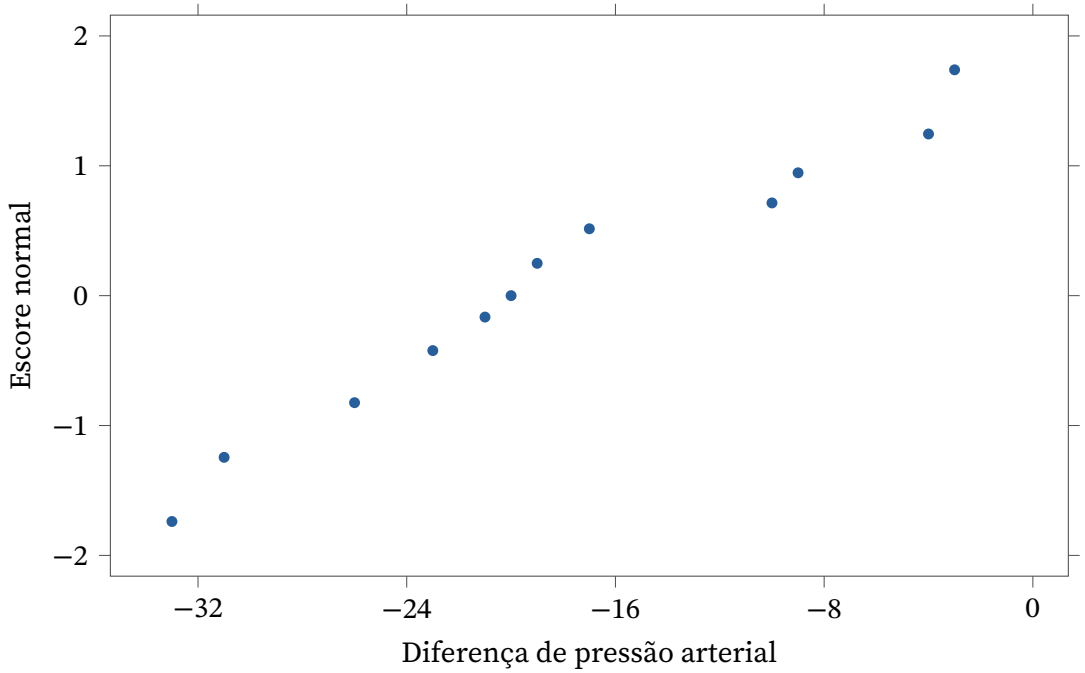


Figura 10.4.4: Gráfico de probabilidade normal dos dados do Exemplo 10.4.4.

categóricos A e B, em que A assume a níveis e B assume b níveis. Uma possibilidade é considerar fazer dois estudos com um fator. Um estudo examinará a relação entre Y e A, e o segundo examinará a relação entre Y e B. Há, no entanto, várias desvantagens nessa abordagem.

Primeiro, e talvez mais importante, fazer duas análises separadas não nos permitirá determinar a relação conjunta que A e B têm com Y. Isso se relaciona diretamente com o conceito de *interação* entre preditores. Logo definiremos esse conceito com mais precisão, mas, basicamente, se A e B interagem, então a relação condicional entre Y e A, dado $B = j$, muda de modo substancial à medida que mudamos j. Se os preditores A e B não interagem, então de fato poderemos examinar a relação entre a resposta e cada um dos preditores separadamente. Mas quase nunca sabemos de antemão que é esse o caso, e precisamos avaliar se existe ou não uma interação com base nos dados coletados.

Um segundo motivo para incluir os dois preditores na análise é que isso muitas vezes leva a uma redução da contribuição do erro aleatório para os resultados. Com isso, queremos dizer que poderemos explicar parte da variação observada em Y pela inclusão da segunda variável no modelo. Isso depende, porém, de a variável adicional ter uma relação com a resposta. Além disso, para que a inclusão de uma segunda variável valha a pena, essa relação precisa ser forte o bastante para justificar a perda de graus de liberdade disponíveis para a estimação da contribuição do erro aleatório para os resultados experimentais.

Como veremos, incluir a segunda variável na análise resulta numa redução dos graus de liberdade na linha do Erro da tabela ANOVA. Aqui, os graus de liberdade fazem o papel do tamanho da amostra. Quanto menos graus de liberdade houver na linha do Erro, menos precisa será nossa estimativa de σ^2.

Quando incluímos os dois preditores na análise e temos a oportunidade de determinar o processo de amostragem, é importante que *cruzemos* os preditores. Com isso, queremos dizer que observamos Y em cada combinação

$$(A, B) = (i, j) \in \{1, \dots, a\} \times \{1, \dots, b\}.$$

Suponha, então, que temos n_{ij} valores da resposta no nível $(A, B) = (i, j)$ dos preditores. Então, sendo

$$E(Y \mid (A, B) = (i, j)) = \beta_{ij}$$

a resposta média quando $A = i$ e $B = j$, e introduzindo as variáveis indicadoras

$$X_{ij} = \begin{cases} 1 & A = i, B = j \\ 0 & A \neq i \text{ ou } B \neq j, \end{cases}$$

podemos escrever

$$\begin{aligned} E(Y \mid X_{ij} = x_{ij} \text{ para todo } i, j) &= \beta_{11}x_{11} + \beta_{21}x_{21} + \cdots + \beta_{ab}x_{ab} \\ &= \sum_{i=1}^{a}\sum_{j=1}^{b} \beta_{ij}x_{ij}. \end{aligned}$$

A relação entre Y e os preditores está inteiramente contida nas mudanças dos β_{ij} à medida que i e j mudam. Daí vemos que um modelo de regressão para essa situação é imediatamente um modelo de regressão linear.

Inferências sobre Médias Individuais e Diferenças de Médias

Seja agora y_{ijk} o k-ésimo valor da resposta quando $X_{ij} = 1$. Então, como na Seção 10.4.1, a estimativa de mínimos quadrados de β_{ij} é dada por

$$b_{ij} = \bar{y}_{ij} = \frac{1}{n_{ij}} \sum_{k=1}^{n_{ij}} y_{ijk},$$

a média das observações quando $X_{ij} = 1$. Se, além disso, supusermos que as distribuições condicionais de Y, dados os preditores, têm todas variância igual a σ^2, então, com $N = n_{11} + n_{21} + \cdots + n_{ab}$, temos que

$$s^2 = \frac{1}{N - ab} \sum_{i=1}^{a}\sum_{j=1}^{b}\sum_{k=1}^{n_{ij}} \left(y_{ijk} - \bar{y}_{ij}\right)^2 \tag{10.4.5}$$

é um estimador não viesado de σ^2. Portanto, usando (10.4.5), o erro padrão de $\bar{y}_{ij}$ é dado por $s/\sqrt{n_{ij}}$.

Com a hipótese de normalidade, temos que $\bar{Y}_{ij} \sim N(\beta_{ij}, \sigma^2/n_{ij})$, independente de

$$\frac{(N-ab)\,S^2}{\sigma^2} \sim \chi^2(N-ab).$$

Isso leva aos intervalos de confiança γ

$$\bar{y}_{ij} \pm \frac{s}{\sqrt{n_{ij}}}\, t_{(1+\gamma)/2}(N-ab)$$

para β_{ij} e

$$\bar{y}_{ij} - \bar{y}_{kl} \pm s\sqrt{\frac{1}{n_{ij}} + \frac{1}{n_{kl}}}\, t_{(1+\gamma)/2}(N-ab)$$

para a diferença de médias $\beta_{ij} - \beta_{kl}$.

A ANOVA para Avaliar a Interação e as Relações com os Preditores

Queremos saber se existe ou não alguma relação entre Y e os preditores. Não há relação entre a resposta e os preditores se e somente se todos os β_{ij} são iguais. Antes de testar isso, porém, é costume testar a hipótese nula de que não há interação entre os preditores. A definição precisa de ausência de interação aqui é que

$$\beta_{ij} = \mu_i + \upsilon_j$$

para todo i e j, para certas constantes μ_i e υ_j, isto é, as médias podem ser expressas de forma aditiva. Note que, se fixamos $B = j$ e deixamos A variar, então essas *curvas de resposta* (uma curva de resposta é um gráfico das médias de uma variável mantendo fixo o valor da segunda variável) são todas paralelas. Essa é uma maneira equivalente de dizer que não há interação entre os preditores.

Na Figura 10.4.5, representamos curvas de resposta em que os fatores não interagem, e na Figura 10.4.6 representamos curvas de resposta em que eles interagem. Note que as linhas cheias, por exemplo a que liga β_{11} e β_{21}, estão lá só para facilitar a visualização do paralelismo (ou da falta dele) e não têm nenhum outro significado.

Para testar a hipótese nula de ausência de interação, precisamos primeiro ajustar o modelo em que $\beta_{ij} = \mu_i + \upsilon_j$, isto é, encontrar as estimativas de mínimos quadrados dos β_{ij} sob essas restrições. Não vamos desenvolver aqui a matemática para obter essas estimativas; vamos contar com o software para fazer isso por nós e para calcular a soma de quadrados relevante para testar

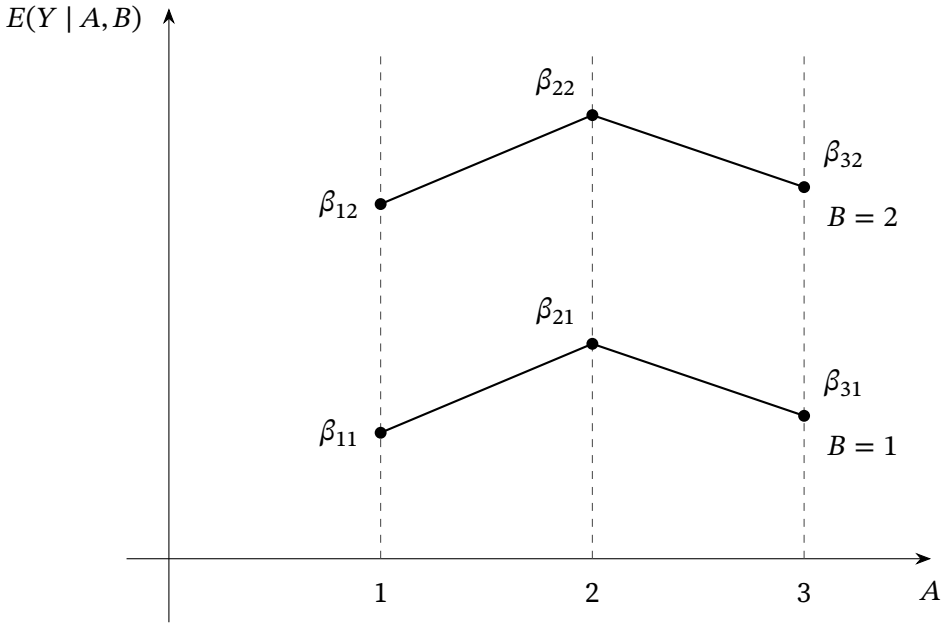


Figura 10.4.5: Curvas de resposta para a resposta esperada com dois preditores, com A assumindo três níveis e B assumindo dois níveis. Como elas são paralelas, os preditores não interagem.

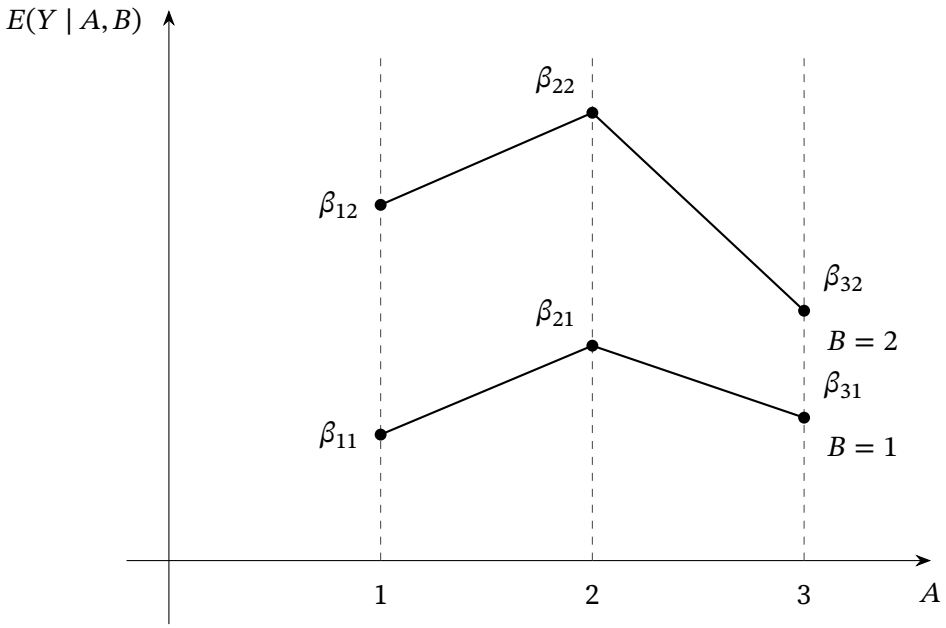


Figura 10.4.6: Curvas de resposta para a resposta esperada com dois preditores, com A assumindo três níveis e B assumindo dois níveis. Elas não são paralelas, então os preditores interagem.

a hipótese nula de ausência de interação (pelos resultados da Seção 10.3.4, sabemos que ela é obtida pela diferença entre a soma de quadrados da regressão obtida do modelo completo e a soma de quadrados da regressão obtida do modelo sem interação).

Se decidimos que existe uma interação, então é imediato que tanto A quanto B têm efeito sobre Y (se A não tem efeito, então A e B não podem interagir — veja o Problema 10.4.16); precisamos olhar as diferenças entre os $\bar{y}_{ij}$ para determinar a forma da relação. Se decidimos que não existe interação, então A tem efeito se e somente se os μ_i variam, e B tem efeito se e somente se os υ_j variam. Podemos testar a hipótese nula $H_0 : \mu_1 = \cdots = \mu_a$ de nenhum efeito devido a A e a hipótese nula $H_0 : \upsilon_1 = \cdots = \upsilon_b$ de nenhum efeito devido a V,* separadamente, depois de decidir que não existe interação.

Os detalhes da obtenção das somas de quadrados relevantes para todas essas hipóteses não são tratados aqui, mas muitos pacotes estatísticos produzem uma tabela ANOVA, como a dada abaixo.

Fonte	GL	Soma de Quadrados
A	$a-1$	$\text{RSS}(A)$
B	$b-1$	$\text{RSS}(B)$
$A \times B$	$(a-1)(b-1)$	$\text{RSS}(A \times B)$
Erro	$N-ab$	$\sum_{i=1}^{a}\sum_{j=1}^{b}\sum_{k=1}^{n_{ij}}\left(y_{ijk}-\bar{y}_{ij}\right)^2$
Total	$N-1$	$\sum_{i=1}^{a}\sum_{j=1}^{b}\sum_{k=1}^{n_{ij}}\left(y_{ijk}-\bar{y}\right)^2$

Note que, se tivéssemos incluído apenas A no modelo, então haveria $N-a$ graus de liberdade para a estimação de σ^2. Ao incluir B, perdemos $(N-a)-(N-ab) = a(b-1)$ graus de liberdade para a estimação de σ^2.

Usando essa tabela, primeiro avaliamos a hipótese nula H_0 : não há interação entre A e B, usando $F \sim F((a-1)(b-1), N-ab)$ sob H_0, por meio do valor-p

$$P\left(F > \frac{\text{RSS}(A \times B)/(a-1)(b-1)}{s^2}\right),$$

em que s^2 é dado por (10.4.5). Se decidimos que não existe interação, então avaliamos a hipótese nula H_0 : nenhum efeito devido a A, usando $F \sim F(a-1, N-ab)$ sob H_0, por meio do valor-p

$$P\left(F > \frac{\text{RSS}(A)/(a-1)}{s^2}\right),$$

e avaliamos H_0 : nenhum efeito devido a B, usando $F \sim F(b-1, N-ab)$ sob H_0, por meio do valor-p

$$P\left(F > \frac{\text{RSS}(B)/(b-1)}{s^2}\right).$$

*Nota do tradutor. o original traz V; pelo contexto seria B.

Verificação do Modelo

Para verificar o modelo, olhamos os resíduos padronizados, dados por (veja o Problema 10.4.18)

$$\frac{y_{ijk} - \bar{y}_{ij}}{s\sqrt{1 - 1/n_{ij}}}. \tag{10.4.6}$$

Vamos nos restringir a vários gráficos dos resíduos padronizados para a verificação do modelo.

Consideramos um exemplo de uma análise com dois fatores.

Exemplo 10.4.5

Os dados da tabela a seguir vêm de G. E. P. Box e D. R. Cox, "An analysis of transformations" (*Journal of the Royal Statistical Society*, 1964, Series B, p. 211) e representam tempos de sobrevivência, em horas, de animais expostos a um de três tipos diferentes de veneno e submetidos a quatro tipos diferentes de tratamento. Denotamos por A os tratamentos e por B o tipo de veneno, de modo que temos $3 \times 4 = 12$ combinações (A, B) diferentes. Cada combinação foi aplicada a quatro animais diferentes, isto é, $n_{ij} = 4$ para todo i e j.

	$A1$	$A2$	$A3$	$A4$
$B1$	3,1; 4,5; 4,6; 4,3	8,2; 11,0; 8,8; 7,2	4,3; 4,5; 6,3; 7,5	4,5; 7,1; 6,6; 6,2
$B2$	3,6; 2,9; 4,0; 2,3	9,2; 6,1; 4,9; 12,4	4,4; 3,5; 3,1; 4,0	5,6; 10,2; 7,1; 3,8
$B3$	2,2; 2,1; 1,8; 2,3	3,0; 3,7; 3,8; 2,9	2,3; 2,5; 2,4; 2,2	3,0; 3,6; 3,1; 3,3

Um gráfico de probabilidade normal desses dados, usando os resíduos padronizados depois de ajustar o modelo com dois fatores, revela um problema claro. Na referência acima, sugere-se uma transformação da resposta para a recíproca $1/Y$, com base numa análise mais sofisticada, e isso de fato leva a gráficos dos resíduos padronizados muito mais adequados. A Figura 10.4.7 é um gráfico de probabilidade normal dos resíduos padronizados com base na resposta recíproca. Esse gráfico de probabilidade normal parece razoável.

A Figura 10.4.8 é um gráfico dos resíduos padronizados contra as várias combinações (A, B), em que codificamos a combinação (i, j) como $b(i-1) + j$, com $b = 3$, $i = 1, 2, 3, 4$ e $j = 1, 2, 3$. Essa codificação atribui um inteiro único a cada combinação (i, j) e é conveniente para comparar diagramas de dispersão da resposta para cada tratamento. De novo, esse gráfico de resíduos parece razoável.

Abaixo damos as estimativas de mínimos quadrados dos β_{ij} para o modelo transformado.*

	$A1$	$A2$	$A3$	$A4$
$B1$	0,24869	0,11635	0,18627	0,16897
$B2$	0,32685	0,13934	0,27139	0,17015
$B3$	0,48027	0,30290	0,42650	0,30918

A tabela ANOVA dos dados, obtida de um pacote estatístico padrão, é dada abaixo.

Fonte	GL	Soma de Quadrados	Quadrado Médio
A	3	0,20414	0,06805
B	2	0,34877	0,17439
$A \times B$	6	0,01571	0,00262
Erro	36	0,08643	0,00240
Total	47	0,65505	

Disso, determinamos que $s = \sqrt{0{,}00240} = 4{,}89898 \times 10^{-2}$ e, portanto, os erros padrão das estimativas de mínimos quadrados são todos iguais a $s/2 = 0{,}0244949$.

Para testar a hipótese nula de ausência de interação entre A e B, temos, usando $F \sim F(6, 36)$ sob H_0, o valor-p

$$P\left(F > \frac{0{,}00262}{0{,}00240}\right) = P(F > 1{,}09) = 0{,}387.$$

Não temos evidência contra a hipótese nula.

Então podemos passar a testar a hipótese nula de nenhum efeito devido a A e temos, usando $F \sim F(2, 36)$ sob H_0, o valor-p[†]

$$P\left(F > \frac{0{,}06805}{0{,}00240}\right) = P(F > 28{,}35) = 0{,}000.$$

Rejeitamos essa hipótese nula.

Da mesma forma, testando a hipótese nula de nenhum efeito devido a B, temos, usando $F \sim F(2, 36)$ sob H_0, o valor-p

$$P\left(F > \frac{0{,}17439}{0{,}00240}\right) = P(F > 72{,}66) = 0{,}000.$$

Rejeitamos também essa hipótese nula.

Assim, decidimos que o modelo adequado é o *modelo aditivo*, dado por $E(1/Y \mid (A, B)) = (i, j) = \mu_i + \upsilon_j$ (ainda estamos usando a

resposta transformada $1/Y$). Também podemos escrever isso como $E(1/Y \mid (A,B)) = (i,j) = (\mu_i + \alpha) + (\upsilon_j - \alpha)$ para qualquer escolha de α. Portanto, não há uma estimativa única dos efeitos aditivos devidos a A ou a B. Ainda assim, temos estimativas de mínimos quadrados únicas das médias, que são obtidas (com software) ajustando o modelo com as restrições sobre os β_{ij} que correspondem à ausência de interação. Elas estão registradas na tabela a seguir.

	$A1$	$A2$	$A3$	$A4$
$B1$	0,26977	0,10403	0,21255	0,13393
$B2$	0,31663	0,15089	0,25942	0,18080
$B3$	0,46941	0,30367	0,41219	0,33357

Como decidimos que não há interação entre A e B, podemos avaliar os efeitos de um só fator examinando as médias da resposta para cada fator separadamente. Por exemplo, as médias para investigar o efeito de A são dadas na tabela a seguir.

$A1$	$A2$	$A3$	$A4$
0,352	0,186	0,295	0,216

Podemos comparar essas médias usando procedimentos baseados na distribuição t. Por exemplo, um intervalo de confiança 0,95 para a diferença entre as médias nos níveis $A1$ e $A2$ é dado por

$$\begin{aligned} \bar{y}_{1\cdot} - \bar{y}_{2\cdot} \pm \frac{s}{\sqrt{12}}\, t_{0,975}(36) &= (0{,}352 - 0{,}186) \pm \sqrt{\frac{0{,}00240}{12}}\, 2{,}0281 \\ &= (0{,}13732;\ 0{,}19468). \end{aligned} \tag{10.4.7}$$

Isso indica que rejeitaríamos a hipótese nula de nenhuma diferença entre essas médias ao nível 0,05.

Note que usamos a estimativa de σ^2 baseada no modelo completo em (10.4.7). Logicamente, pareceria fazer mais sentido usar a estimativa baseada no ajuste do modelo aditivo, já que decidimos que ele é adequado. Quando fazemos isso, falamos em *combinação* (*pooling*), pois pode-se mostrar que a nova estimativa do erro é calculada somando $\text{RSS}(A \times B)$ à ESS original e dividindo pela soma dos graus de liberdade de $A \times B$ e dos graus de liberdade do erro. Não combinar é considerado um procedimento um pouco mais conservador. ■

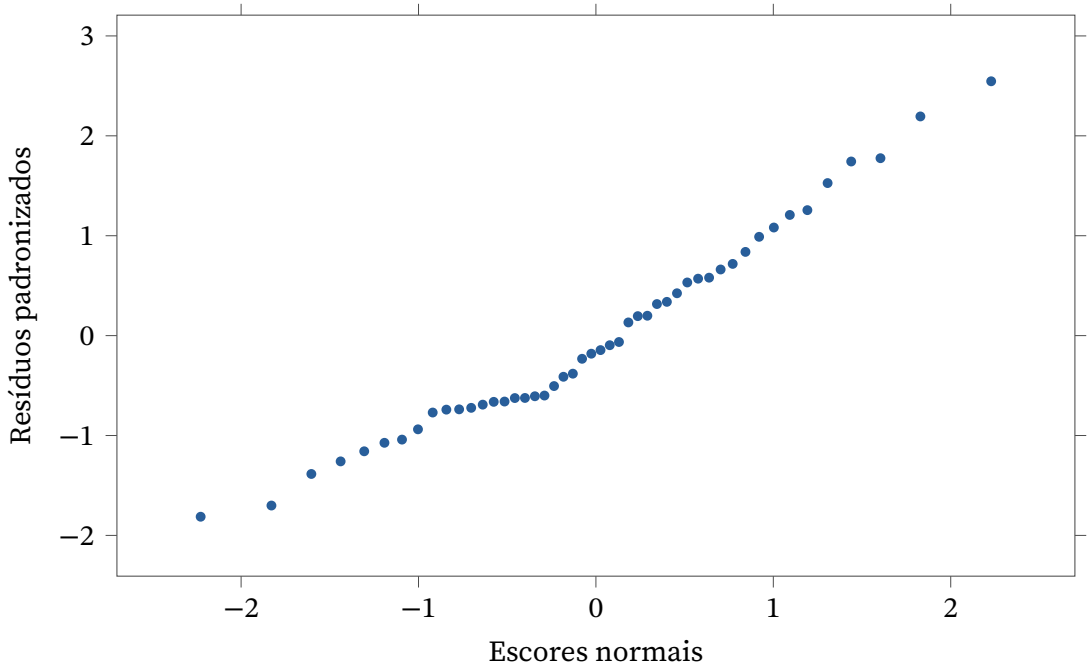


Figura 10.4.7: Gráfico de probabilidade normal dos resíduos padronizados no Exemplo 10.4.5, usando a recíproca da resposta.

10.4.4 Blocos Aleatorizados

Com modelos de dois fatores, em geral queremos investigar se cada um desses fatores tem ou não uma relação com a resposta Y. Suponha, porém, que sabemos que um fator B tem uma relação com Y e que queremos investigar se outro fator A tem ou não uma relação com Y. Devemos fazer um experimento com um fator usando o preditor A, ou um experimento com dois fatores incluindo o fator B?

A resposta é a que demos no início da Seção 10.4.2. Incluir o fator B nos permitirá, se B responder por boa parte da variação observada, fazer comparações mais precisas. Note, porém, que, se B não tem um efeito substancial sobre Y, então sua inclusão será um desperdício, pois sacrificamos $a(b-1)$ graus de liberdade que, de outro modo, iriam para a estimação de σ^2.

Por isso é importante que de fato *saibamos* que B tem um efeito substancial. Nesse caso, dizemos que B é uma *variável de bloqueio*. De novo, é importante que a variável de bloqueio B seja cruzada com A. Então podemos testar qualquer efeito devido a A testando primeiro se há interação entre A e B;

*Nota do tradutor. o original traz 0.18627 para $B1, A3$; com os dados da tabela acima a conta dá 0,18671; o valor impresso corresponde a 7,6 no lugar de 7,5.

†Nota do tradutor. o original traz $F(2, 36)$; como A tem 3 graus de liberdade na tabela ANOVA, seria $F(3, 36)$.

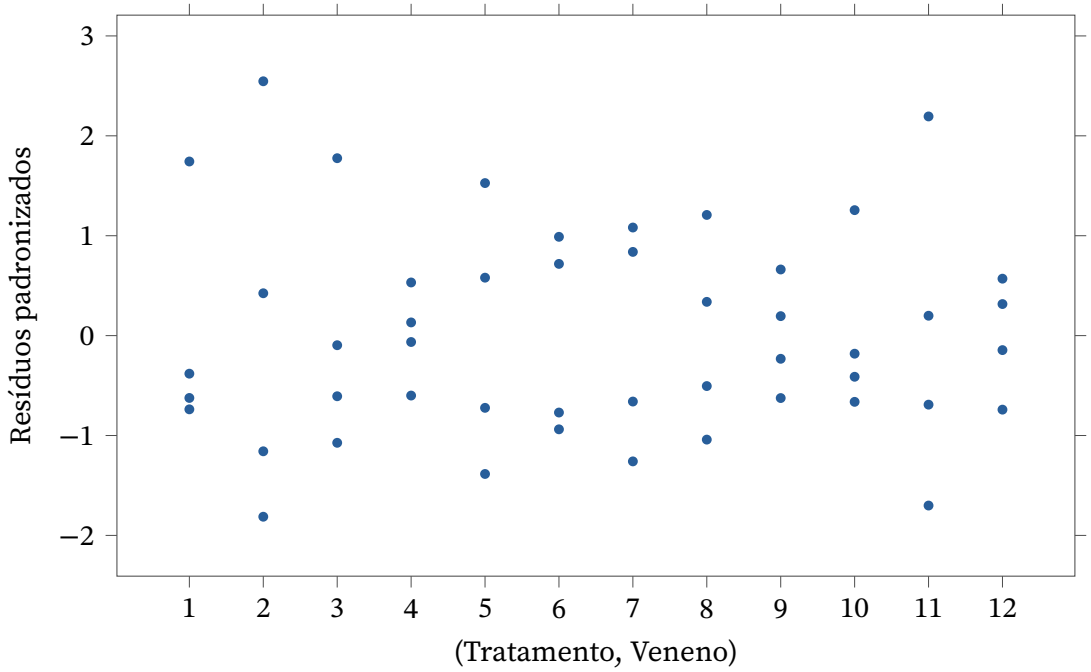


Figura 10.4.8: Gráfico de dispersão, para os dados do Exemplo 10.4.5, dos resíduos padronizados contra cada valor de (A, B), usando a recíproca da resposta.

se nenhuma interação for encontrada, testamos um efeito devido só a A, exatamente como discutimos na Seção 10.4.3.

Um caso especial do uso de uma variável de bloqueio ocorre quando temos $n_{ij} = 1$ para todo i e j. Nesse caso, $N = ab$, de modo que não há graus de liberdade disponíveis para a estimação do erro. Na verdade, temos que (veja o Problema 10.4.19) $s^2 = 0$. Ainda assim, esse delineamento tem valor prático, desde que estejamos dispostos a *supor* que não há interação entre A e B. Ele é chamado de *delineamento em blocos aleatorizados*[67].

Para um delineamento em blocos aleatorizados, temos que

$$s^2 = \frac{\text{RSS}(A \times B)}{(a-1)(b-1)} \tag{10.4.8}$$

é uma estimativa não viesada de σ^2, e assim temos $(a-1)(b-1)$ graus de liberdade para a estimação do erro. Claro, isso não estará correto se A e B interagirem, mas, quando não interagem, esse pode ser um delineamento altamente eficiente, pois removemos o efeito da variação devida a B e precisamos de apenas ab observações para isso. Quando o delineamento em blocos aleatorizados é adequado, testamos um efeito devido a A, usando

No original: *randomized block design*[67].

$F \sim F(a-1,(a-1)(b-1))$ sob H_0, por meio do valor-p

$$P\left(F > \frac{\text{RSS}(A)/(a-1)}{s^2}\right).$$

10.4.5 Um Preditor Categórico e Um Preditor Quantitativo

Também é possível que a resposta seja quantitativa enquanto alguns dos preditores são categóricos e outros são quantitativos. Consideramos agora a situação em que temos um preditor categórico A, que assume a valores, e um preditor quantitativo W. Supomos que o modelo de regressão se aplica. Além disso, restringimos nossa atenção à situação em que supomos que, dentro de cada nível de A, a resposta média varia como*

$$E(Y \mid (A,W)) = (i,w) = \beta_{i1} + \beta_{i2}w,$$

de modo que temos um modelo de regressão linear simples dentro de cada nível de A.

Se introduzirmos as variáveis indicadoras

$$X_{ij} = \begin{cases} W^{j-1} & A = i \\ 0 & A \neq i \end{cases}$$

para $i = 1,\ldots,a$ e $j = 1,2$, então podemos escrever o modelo de regressão linear como

$$E\big(Y \mid (X_{ij}) = (x_{ij})\big) = (\beta_{11}x_{11} + \beta_{12}x_{12}) + \cdots + (\beta_{a1}x_{a1} + \beta_{a2}x_{a2}).$$

Aqui, β_{i1} é o intercepto e β_{i2} é a inclinação que especifica a relação entre Y e W quando $A = i$. Os métodos da Seção 10.3.4 ficam então disponíveis para a inferência sobre esse modelo.

Também temos uma noção de interação nesse contexto, pois dizemos que os dois preditores interagem se as inclinações das retas variam entre os níveis de A. Assim, dizer que não existe interação é o mesmo que dizer que as curvas de resposta são paralelas quando representadas graficamente para cada nível de A. Se existe uma interação, então é certo que tanto A quanto W têm efeito sobre Y. Logo, a hipótese nula de que não existe interação é equivalente a $H_0 : \beta_{12} = \cdots = \beta_{a2}$.

*Nota do tradutor. o original imprime $E(Y \mid (A,W)) = (i,w)$, com o parêntese fechado antes do segundo sinal de igual; pelo sentido seria $E(Y \mid (A,W) = (i,w))$.

Se decidirmos que não existe interação, então podemos testar a ausência de efeito devido a W testando a hipótese nula de que a inclinação comum é igual a 0, ou podemos testar a hipótese nula de que não há efeito devido a A testando $H_0 : \beta_{11} = \cdots = \beta_{a1}$, isto é, que os termos de intercepto são os mesmos em todos os níveis de A.

Não aprofundamos aqui a análise desse modelo. Existem, porém, programas estatísticos que calculam a tabela ANOVA pertinente para avaliar as várias hipóteses nulas.

Análise de Covariância

Suponha que estamos conduzindo um experimento planejado e que, para cada unidade experimental, podemos medir, mas não controlar, uma variável quantitativa W que acreditamos ter efeito sobre a resposta Y. Se o efeito dessa variável for apreciável, então a boa prática estatística sugere que incluamos essa variável no modelo, pois assim reduziremos a contribuição do erro para os nossos resultados experimentais e, portanto, faremos comparações mais precisas. É claro que pagamos um preço ao fazer isso, pois perdemos graus de liberdade que, de outro modo, estariam disponíveis para a estimação do erro. Por isso, precisamos ter certeza de que W tem de fato um efeito significativo nesse caso. Além disso, não testamos se essa variável tem efeito, já que presumivelmente sabemos que ela tem. Essa técnica é chamada de *análise de covariância* e é, evidentemente, semelhante em natureza ao uso de variáveis de bloqueio.

Resumo da Seção 10.4

- Consideramos a situação que envolve uma resposta quantitativa e variáveis preditoras categóricas.
- Com a introdução de variáveis indicadoras para as variáveis preditoras, podemos tratar essa situação como uma aplicação particular do modelo de regressão múltipla da Seção 10.3.4.
- Se decidirmos que existe uma relação, então em geral tentamos explicar que forma essa relação assume comparando médias. Para evitar encontrar diferenças estatisticamente significativas demais, reduzimos a taxa de erro individual de modo a garantir uma taxa de erro da família razoável.
- Quando temos dois preditores, verificamos primeiro se os fatores interagem. Se os dois preditores interagem, então ambos têm efeito sobre

a resposta.

- Um caso especial de análise com dois fatores surge quando um dos preditores serve como variável de bloqueio. Em geral, é importante saber que a variável de bloqueio tem efeito sobre a resposta, para não desperdiçarmos graus de liberdade ao incluí-la.
- Às vezes podemos medir, nas unidades experimentais individuais, variáveis que sabemos ter efeito sobre a resposta. Nesse caso, incluímos essas variáveis no nosso modelo, pois elas reduzem a contribuição do erro aleatório para a análise e tornam nossas inferências mais precisas.

Exercícios

10.4.1 Os seguintes valores de uma resposta Y foram obtidos para três valores de um preditor categórico A.

$A = 1$	2,9976	0,3606	4,7716	1,5652
$A = 2$	0,7468	1,3308	2,2167	−0,3184
$A = 3$	2,1192	2,3739	0,3335	3,3015

Suponha que adotamos para esses dados o modelo de regressão normal com um preditor categórico.

(a) Produza boxplots lado a lado dos dados.

(b) Faça o gráfico dos resíduos padronizados contra A (se você estiver usando um computador para os cálculos, produza também um gráfico de probabilidade normal dos resíduos padronizados). Isso lhe dá motivos para suspeitar que as hipóteses do modelo estejam incorretas?

(c) Faça uma ANOVA com um fator para testar se há alguma diferença entre as médias condicionais de Y dado A.

(d) Se for o caso, construa intervalos de confiança 0,95 para as diferenças entre as médias e resuma suas conclusões.

10.4.2 Os seguintes valores de uma resposta Y foram obtidos para três valores de um preditor categórico A.

$A = 1$	0,090	0,800	33,070	−1,890
$A = 2$	5,120	1,580	1,760	1,740
$A = 3$	5,080	−3,510	4,420	1,190

Suponha que adotamos para esses dados o modelo de regressão normal com um preditor categórico.

(a) Produza boxplots lado a lado dos dados.

(b) Faça o gráfico dos resíduos padronizados contra A (se você estiver usando um computador para os cálculos, produza também um gráfico de probabilidade normal dos resíduos padronizados). Isso lhe dá motivos para suspeitar que as hipóteses do modelo estejam incorretas?

(c) Se surgirem dúvidas sobre a validade do modelo, você consegue "consertar" o problema?

(d) Se você conseguiu consertar os problemas encontrados no modelo, faça uma ANOVA com um fator para testar se há diferenças entre as médias condicionais de Y dado A.

(e) Se for o caso, construa intervalos de confiança 0,95 para as diferenças entre as médias e resuma suas conclusões.

10.4.3 A tabela a seguir dá o teor percentual de umidade de dois tipos diferentes de queijo, determinado por amostragem aleatória de lotes de queijo do processo de produção.

Queijo 1	39,02; 38,79; 35,74; 35,41; 37,02; 36,00
Queijo 2	38,96; 39,01; 35,58; 35,52; 35,70; 36,04

Suponha que adotamos para esses dados o modelo de regressão normal com um preditor categórico.

(a) Produza boxplots lado a lado dos dados.

(b) Faça o gráfico dos resíduos padronizados contra Queijo (se você estiver usando um computador para os cálculos, produza também um gráfico de probabilidade normal dos resíduos padronizados). Isso lhe dá motivos para suspeitar que as hipóteses do modelo estejam incorretas?

(c) Faça uma ANOVA com um fator para testar se há diferenças entre as médias condicionais de Y dado Queijo. Observe que isso é o mesmo que um teste t para a diferença entre as médias.

10.4.4 Num experimento, ratos foram alimentados com uma ração padrão durante 100 dias, com várias quantidades de gossipol adicionadas. Foram registrados os seguintes ganhos de peso, em gramas.

0,00% de gossipol	228, 229, 218, 216, 224, 208, 235, 229, 233, 219, 224, 220, 232, 200, 208, 232
0,04% de gossipol	186, 229, 220, 208, 228, 198, 222, 273, 216, 198, 213
0,07% de gossipol	179, 193, 183, 180, 143, 204, 114, 188, 178, 134, 208, 196
0,10% de gossipol	130, 87, 135, 116, 118, 165, 151, 59, 126, 64, 78, 94, 150, 160, 122, 110, 178
0,13% de gossipol	154, 130, 118, 118, 118, 104, 112, 134, 98, 100, 104

Suponha que adotamos para esses dados o modelo de regressão normal e tratamos o gossipol como um preditor categórico com cinco níveis.

(a) Crie um gráfico de boxplots lado a lado dos dados. Isso lhe dá algum motivo para se preocupar com as hipóteses subjacentes a uma análise baseada no modelo de regressão normal?

(b) Produza um gráfico dos resíduos padronizados contra o fator gossipol (se você estiver usando um computador para os cálculos, produza também um gráfico de probabilidade normal dos resíduos padronizados). Quais são suas conclusões?

(c) Faça uma ANOVA com um fator para testar se há diferenças entre as respostas médias para as diferentes quantidades de gossipol.

(d) Calcule intervalos de confiança 0,95 para todas as diferenças de médias duas a duas e resuma suas conclusões.

10.4.5 Numa investigação sobre o efeito da deficiência de oligoelementos numa variável Y medida em ovelhas, foram obtidos os dados da tabela a seguir.

Controle	13,2; 13,6; 11,9; 13,0; 14,5; 13,4
Cobalto	11,9; 12,2; 13,9; 12,8; 12,7; 12,9
Cobre	14,2; 14,0; 15,1; 14,9; 13,7; 15,8
Cobalto + Cobre	15,0; 15,6; 14,5; 15,8; 13,9; 14,4

Suponha que adotamos para esses dados o modelo de regressão normal com um preditor categórico.

(a) Produza boxplots lado a lado dos dados.

(b) Faça o gráfico dos resíduos padronizados contra o preditor (se você estiver usando um computador para os cálculos, produza também um

gráfico de probabilidade normal dos resíduos padronizados). Isso lhe dá motivos para suspeitar que as hipóteses do modelo estejam incorretas?

(c) Faça uma ANOVA com um fator para testar se há diferenças entre as médias condicionais de Y dado o preditor.

(d) Se for o caso, construa intervalos de confiança 0,95 para todas as diferenças entre as médias duas a duas e resuma suas conclusões.

10.4.6 Duas dietas foram dadas a amostras de porcos durante um período de tempo, e foram registrados os seguintes ganhos de peso (em libras).

Dieta A	8, 4, 14, 15, 11, 10, 6, 12, 13, 7
Dieta B	7, 13, 22, 15, 12, 14, 18, 8, 21, 23, 10, 17

Suponha que adotamos para esses dados o modelo de regressão normal.

(a) Produza boxplots lado a lado dos dados.

(b) Faça o gráfico dos resíduos padronizados contra Dieta. Produza também um gráfico de probabilidade normal dos resíduos padronizados. Isso lhe dá motivos para suspeitar que as hipóteses do modelo estejam incorretas?

(c) Faça uma ANOVA com um fator para testar se há diferença entre as médias condicionais de Y dado Dieta.

(d) Construa intervalos de confiança 0,95 para as diferenças entre as médias.

10.4.7 Dez alunos foram selecionados aleatoriamente entre os alunos de uma universidade que cursaram cálculo do primeiro ano e estatística do primeiro ano. Suas notas nessas disciplinas estão registradas na tabela a seguir.

Aluno	1	2	3	4	5	6	7	8	9	10
Cálculo	66	61	77	62	66	68	64	75	59	71
Estatística	66	63	79	63	67	70	71	80	63	74

Suponha que adotamos para esses dados o modelo de regressão normal.

(a) Produza boxplots lado a lado dos dados.

(b) Tratando as notas de cálculo e de estatística como amostras separadas, faça uma ANOVA com um fator para testar se há alguma diferença entre a nota média em cálculo e a nota média em estatística. Produza os gráficos apropriados para verificar as hipóteses do modelo.

(c) Agora leve em conta que cada aluno tem uma nota de cálculo e uma nota de estatística e teste se há alguma diferença entre a nota média em cálculo e a nota média em estatística. Produza os gráficos apropriados para verificar as hipóteses do modelo. Compare seus resultados com os obtidos na parte (b).

(d) Estime a correlação entre as notas de cálculo e de estatística.

10.4.8 Os dados a seguir foram registrados em *Statistical Methods*, 6.ª ed., de G. Snedecor e W. Cochran (Iowa State University Press, Ames, 1967), e representam o número médio de flósculos observados em plantas de sete parcelas. Cada planta foi cultivada a partir de cormos altos ou de cormos baixos (um tipo de caule subterrâneo).

	Parcela						
	1	2	3	4	5	6	7
Cormo Alto	11,2	13,3	12,8	13,7	12,2	11,9	12,1
Cormo Baixo	14,6	12,6	15,0	15,6	12,7	12,0	13,1

Suponha que adotamos para esses dados o modelo de regressão normal.

(a) Produza boxplots lado a lado dos dados.

(b) Tratando as medições de Cormo Alto e de Cormo Baixo como amostras separadas, faça uma ANOVA com um fator para testar se há alguma diferença entre as médias populacionais. Produza os gráficos apropriados para verificar as hipóteses do modelo.

(c) Agora leve em conta que cada parcela tem uma medição de Cormo Alto e uma de Cormo Baixo. Compare seus resultados com os obtidos na parte (b). Produza os gráficos apropriados para verificar as hipóteses do modelo.

(d) Estime a correlação entre as notas de cálculo e de estatística.*

10.4.9 Suponha que duas medições, Y_1 e Y_2, correspondentes a tratamentos diferentes, são feitas no mesmo indivíduo, amostrado aleatoriamente de uma população Π. Suponha que Y_1 e Y_2 têm a mesma variância e são negativamente correlacionadas. Nosso objetivo é comparar as médias dos tratamentos. Explique por que teria sido melhor amostrar aleatoriamente dois indivíduos de Π e aplicar os tratamentos a esses indivíduos separadamente. (Sugestão: considere $\text{Var}(Y_1 - Y_2)$ nessas duas situações de amostragem.)

*Nota do tradutor. o item repete o (d) do Exercício 10.4.7; aqui o sentido seria a correlação entre as medições de Cormo Alto e de Cormo Baixo.

10.4.10 Liste as hipóteses subjacentes à validade do teste ANOVA com um fator discutido na Seção 10.4.1.

10.4.11 Liste as hipóteses subjacentes à validade do teste de comparação pareada discutido na Seção 10.4.2.

10.4.12 Liste as hipóteses subjacentes à validade do teste ANOVA com dois fatores discutido na Seção 10.4.3.

10.4.13 Liste as hipóteses subjacentes à validade do teste usado com o delineamento em blocos aleatorizados, discutido na Seção 10.4.4, quando $n_{ij} = 1$ para todo i e j.

Problemas

10.4.14 Prove que $\sum_{i=1}^{a} \sum_{j=1}^{n_i} (y_{ij} - \beta_i)^2$ é minimizada, como função dos β_i, por $\beta_i = \bar{y}_i = (y_{i1} + \cdots + y_{in_i})/n_i$ para $i = 1, \ldots, a$.

10.4.15 Prove que

$$\sum_{i=1}^{a} \sum_{j=1}^{n_i} (y_{ij} - \bar{y})^2 = \sum_{i=1}^{a} n_i (\bar{y}_i - \bar{y})^2 + \sum_{i=1}^{a} \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_i)^2,$$

em que $\bar{y}_i = (y_{i1} + \cdots + y_{in_i})/n_i$ e $\bar{y}$ é a média geral.

10.4.16 Argumente que, se a relação entre uma resposta quantitativa Y e dois preditores categóricos A e B é dada por um modelo de regressão linear, então A e B têm ambos efeito sobre Y sempre que A e B interagem. (Sugestão: o que significa, em termos de curvas de resposta, existir uma interação, e existir um efeito devido a A?)

10.4.17 Mostre que (10.4.2) é a expressão adequada para o resíduo padronizado no modelo de regressão linear com um preditor categórico.

10.4.18 Mostre que (10.4.6) é a expressão adequada para o resíduo padronizado no modelo de regressão linear com dois preditores categóricos.

10.4.19 Mostre que $s^2 = 0$ no modelo de regressão linear com dois preditores categóricos quando $n_{ij} = 1$ para todo i e j.

10.4.20 Como você avaliaria, depois de coletar os dados, se o delineamento em blocos aleatorizados era ou não apropriado?

Problemas computacionais

10.4.21 Use um programa apropriado para fazer o teste de comparações múltiplas de Fisher com os dados do Exercício 10.4.5, de modo que a taxa de erro da família fique entre 0,04 e 0,05. Que taxa de erro individual é necessária?

10.4.22 Considere os dados do Exercício 10.4.3, mas suponha agora que também levamos em conta que os queijos foram feitos em lotes, cada um correspondendo a uma rodada de produção. Registrando os dados dessa maneira, obtemos a tabela a seguir.

	Lote 1	Lote 2	Lote 3
Queijo 1	39,02; 38,79	35,74; 35,41	37,02; 36,00
Queijo 2	38,96; 39,01	35,58; 35,52	35,70; 36,04

Suponha que adotamos para esses dados o modelo de regressão normal com dois preditores categóricos.

(a) Produza boxplots lado a lado dos dados para cada tratamento.

(b) Produza uma tabela das médias das caselas.

(c) Produza um gráfico de probabilidade normal dos resíduos padronizados e um gráfico dos resíduos padronizados contra cada combinação de tratamentos (codifique as combinações de tratamentos de modo que haja um único inteiro correspondente a cada uma). Comente a validade do modelo.

(d) Construa a tabela ANOVA testando primeiro a ausência de interação entre A e B e, se necessário, um efeito devido a A e um efeito devido a B.

(e) Com base nos resultados da parte (d), construa a tabela de médias apropriada, faça o gráfico da curva de resposta correspondente e faça todas as comparações duas a duas entre as médias.

(f) Compare seus resultados com os obtidos no Exercício 10.4.4 e comente as diferenças.*

10.4.23 Foi conduzido um experimento planejado com dois fatores, sendo A e B ambos variáveis categóricas com três valores. Cada tratamento foi aplicado quatro vezes, e foram obtidos os seguintes valores da resposta.

*__Nota do tradutor.__ os dados dos queijos são os do Exercício 10.4.3; o Exercício 10.4.4 trata dos ratos e do gossipol.

	$A = 1$		$A = 2$		$A = 3$	
$B = 1$	19,86	20,88	26,37	24,38	29,72	29,64
	20,15	25,44	24,87	30,93	30,06	35,49
$B = 2$	15,35	15,86	22,82	20,98	27,12	24,27
	21,86	26,92	29,38	34,13	34,78	40,72
$B = 3$	4,01	4,48	10,34	9,38	15,64	14,03
	21,66	25,93	30,59	40,04	36,80	42,55

Suponha que adotamos para esses dados o modelo de regressão normal com dois preditores categóricos.

(a) Produza boxplots lado a lado dos dados para cada tratamento.

(b) Produza uma tabela das médias das caselas.

(c) Produza um gráfico de probabilidade normal dos resíduos padronizados e um gráfico dos resíduos padronizados contra cada combinação de tratamentos (codifique as combinações de tratamentos de modo que haja um único inteiro correspondente a cada uma). Comente a validade do modelo.

(d) Construa a tabela ANOVA testando primeiro a ausência de interação entre A e B e, se necessário, um efeito devido a A e um efeito devido a B.

(e) Com base nos resultados da parte (d), construa a tabela de médias apropriada, faça o gráfico das curvas de resposta correspondentes e faça todas as comparações duas a duas entre as médias.

10.4.24 Uma pasta química é produzida em partidas e colocada em barris. Dez partidas entregues foram selecionadas aleatoriamente para teste; em seguida, três barris foram selecionados aleatoriamente de cada entrega, e a resistência da pasta foi medida duas vezes, com base em amostras retiradas de cada barril amostrado. A resposta foi expressa como porcentagem da resistência de enchimento.* Os dados coletados estão na tabela a seguir. Suponha que adotamos para esses dados o modelo de regressão normal com dois preditores categóricos.

*__Nota do tradutor.__ “fill strength” no original; pode ser erro por “full strength” (resistência plena).

	Partida 1	Partida 2	Partida 3	Partida 4	Partida 5
Barril 1	62,8; 62,6	60,0; 61,4	58,7; 57,5	57,1; 56,4	55,1; 55,1
Barril 2	60,1; 62,3	57,5; 56,9	63,9; 63,1	56,9; 58,6	54,7; 54,2
Barril 3	62,7; 63,1	61,1; 58,9	65,4; 63,7	64,7; 64,5	58,5; 57,5
	Partida 6	Partida 7	Partida 8	Partida 9	Partida 10
Barril 1	63,4; 64,9	62,5; 62,6	59,2; 59,4	54,8; 54,8	58,3; 59,3
Barril 2	59,3; 58,1	61,0; 58,7	65,2; 66,0	64,0; 64,0	59,2; 59,2
Barril 3	60,5; 60,0	56,9; 57,7	64,8; 64,1	57,7; 56,8	58,9; 56,8

(a) Produza boxplots lado a lado dos dados para cada tratamento.

(b) Produza uma tabela das médias das caselas.

(c) Produza um gráfico de probabilidade normal dos resíduos padronizados e um gráfico dos resíduos padronizados contra cada combinação de tratamentos (codifique as combinações de tratamentos de modo que haja um único inteiro correspondente a cada uma). Comente a validade do modelo.

(d) Construa a tabela ANOVA testando primeiro a ausência de interação entre Partida e Barril e, se necessário, a ausência de efeito devido a Partida e a ausência de efeito devido a Barril.

(e) Com base nos resultados da parte (d), construa a tabela de médias apropriada e faça o gráfico das curvas de resposta correspondentes.

10.4.25 Os dados a seguir vêm de um delineamento em blocos aleatorizados, em que o fator B é a variável de bloqueio e corresponde a parcelas de terra nas quais se planta algodão. Cada parcela foi dividida em cinco subparcelas, e diferentes concentrações de fertilizante foram aplicadas a cada uma, sendo a resposta uma medida da resistência do algodão colhido. Havia três blocos e cinco concentrações diferentes de fertilizante. Observe que há uma única observação para cada combinação de bloco e concentração. Mais discussão desses dados pode ser encontrada em *Experimental Design*, 2.ª ed., de W. G. Cochran e G. M. Cox (John Wiley & Sons, Nova York, 1957, pp. 107–108). Suponha que adotamos o modelo de regressão normal com dois preditores categóricos.

	$B = 1$	$B = 2$	$B = 3$
$A = 36$	7,62	8,00	7,93
$A = 54$	8,14	8,15	7,87
$A = 72$	7,70	7,73	7,74
$A = 108$	7,17	7,57	7,80
$A = 144$	7,46	7,68	7,21

(a) Construa a tabela ANOVA para testar a ausência de efeito devido ao fertilizante, que também remova a variação devida à variável de bloqueio.

(b) Além das hipóteses habituais com que nos preocupamos, que hipótese adicional é necessária para essa análise?

(c) Na verdade, o fator A é uma variável quantitativa. Se levássemos isso em conta ajustando um modelo com a mesma inclinação para cada bloco, mas com interceptos possivelmente diferentes, que benefício obteríamos?

(d) Faça a análise sugerida na parte (c) e avalie se esse modelo faz ou não sentido para esses dados.

10.5 Resposta Categórica e Preditores Quantitativos

Consideramos agora a situação em que a resposta é categórica, mas pelo menos alguns dos preditores são quantitativos. A dificuldade essencial nesse contexto está nos preditores quantitativos, de modo que vamos nos concentrar na situação em que todos os preditores são quantitativos. Quando também há alguns preditores categóricos, eles podem ser tratados da mesma maneira, pois podemos substituir cada preditor categórico por um conjunto de variáveis quantitativas indicadoras, como discutido na Seção 10.4.5.

Por simplicidade, vamos restringir nossa atenção à situação em que a variável resposta Y é binária, e tomaremos esses valores como 0 e 1. Suponha, então, que haja k preditores quantitativos $X_1, \ldots, X_k$. Como $Y \in \{0, 1\}$, temos

$$E(Y \mid X_1 = x_1, \ldots, X_k = x_k) = P(Y = 1 \mid X_1 = x_1, \ldots, X_k = x_k) \in [0, 1].$$

Portanto, não podemos escrever $E(Y \mid x_1, \ldots, x_k) = \beta_1 x_1 + \cdots + \beta_k x_k$ sem impor algumas restrições artificiais aos β_i para garantir que $\beta_1 x_1 + \cdots + \beta_k x_k \in [0, 1]$.

Talvez a maneira mais simples de contornar isso seja usar uma função injetora[68] $l : [0, 1] \to R^1$ e escrever

$$l(P(Y = 1 \mid X_1 = x_1, \ldots, X_k = x_k)) = \beta_1 x_1 + \cdots + \beta_k x_k,$$

de modo que

$$P(Y = 1 \mid X_1 = x_1, \ldots, X_k = x_k) = l^{-1}(\beta_1 x_1 + \cdots + \beta_k x_k).$$

No original: *one-to-one*[68].

Chamamos l de *função de ligação*[69]. Há muitas escolhas possíveis para l. Por exemplo, é imediato que podemos tomar como l qualquer fda inversa de uma distribuição contínua.

Se tomamos $l = \Phi^{-1}$, isto é, a fda inversa da distribuição $N(0,1)$, isso se chama *ligação probit*. Uma ligação mais usada, por causa de algumas simplicidades matemáticas que lhe são inerentes, é a *ligação logística*[70], dada por

$$l(p) = \ln\left(\frac{p}{1-p}\right). \tag{10.5.1}$$

O lado direito de (10.5.1) é chamado de *logito* ou *log da chance*. A ligação logística é a fda inversa da distribuição logística (ver Exercício 10.5.1). Daqui em diante, vamos restringir nossa discussão à ligação logística.

A ligação logística implica que (ver Exercício 10.5.2)

$$P(Y = 1 \mid X_1 = x_1, \ldots, X_k = x_k) = \frac{\exp\{\beta_1 x_1 + \cdots + \beta_k x_k\}}{1 + \exp\{\beta_1 x_1 + \cdots + \beta_k x_k\}}, \tag{10.5.2}$$

que é uma relação relativamente simples. Vemos imediatamente, no entanto, que*

$$\begin{aligned}&\operatorname{Var}(Y \mid X_1 = x_1, \ldots, X_k = x_k)\\ &\quad = P(Y = 1 \mid X_1 = x_1, \ldots, X_k) = x_k(1 - P(Y = 1 \mid X_1 = x_1, \ldots, X_k = x_k)),\end{aligned}$$

de modo que a variância da distribuição condicional de Y, dados os preditores, depende dos valores dos preditores. Portanto, esses modelos não são, a rigor, modelos de regressão como os definimos. Ainda assim, quando usamos a função de ligação dada por (10.5.1), chamamos isso de *modelo de regressão logística*[71].

Suponha agora que observemos n observações independentes $(x_{i1}, \ldots, x_{ik}, y_i)$ para $i = 1, \ldots, n$. Temos então que, dado $(x_{i1}, \ldots, x_{ik})$, a resposta y_i é uma observação da distribuição Bernoulli$(P(Y = 1 \mid X_1 = x_1, \ldots, X_k = x_k))$. Então (10.5.2) implica que a verossimilhança condicional, dados os valores dos preditores, é

$$\prod_{i=1}^{n} \left(\frac{\exp\{\beta_1 x_1 + \cdots + \beta_k x_k\}}{1 + \exp\{\beta_1 x_1 + \cdots + \beta_k x_k\}}\right)^{y_i} \left(\frac{1}{1 + \exp\{\beta_1 x_1 + \cdots + \beta_k x_k\}}\right)^{1-y_i}.$$

*__Nota do tradutor.__ O original traz "$P(Y = 1 \mid X_1 = x_1, \ldots, X_k) = x_k(1 - \ldots)$"; pela conta seria $P(Y = 1 \mid X_1 = x_1, \ldots, X_k = x_k)(1 - \ldots)$.

No original: *link function*[69], *logistic*[70], *logistic regression*[71].

A inferência sobre os β_i prossegue, então, pelos métodos de verossimilhança discutidos no Capítulo 6. Na verdade, precisamos usar um software para obter os EMVs e, como as distribuições amostrais exatas dessas quantidades não estão disponíveis, os métodos de grandes amostras discutidos na Seção 6.5 são usados para obter intervalos de confiança e valores-p aproximados. Observe que avaliar a hipótese nula $H_0 : \beta_i = 0$ equivale a avaliar a hipótese nula de que o preditor X_i não tem relação com a resposta.

Ilustramos o uso da regressão logística com um exemplo.

Exemplo 10.5.1

A tabela de dados a seguir representa o

(número de fracassos, número de sucessos)

de lingotes preparados para laminação sob diferentes ajustes das variáveis preditoras, U = duração do encharque e V = duração do aquecimento, conforme relatado em *Analysis of Binary Data*, de D. R. Cox (Methuen, Londres, 1970). Um fracasso indica que o lingote não está pronto para a laminação após o tratamento. Houve observações em 19 ajustes diferentes dessas variáveis.

	$V = 7$	$V = 14$	$V = 27$	$V = 51$
$U = 1{,}0$	$(0, 10)$	$(0, 31)$	$(1, 55)$	$(3, 10)$
$U = 1{,}7$	$(0, 17)$	$(0, 43)$	$(4, 40)$	$(0, 1)$
$U = 2{,}2$	$(0, 7)$	$(2, 31)$	$(0, 21)$	$(0, 1)$
$U = 2{,}8$	$(0, 12)$	$(0, 31)$	$(1, 21)$	$(0, 0)$
$U = 4{,}0$	$(0, 9)$	$(0, 19)$	$(1, 15)$	$(0, 1)$

Incluir um intercepto no modelo e termos lineares em U e V leva a três variáveis preditoras $X_1 \equiv 1, X_2 = U, X_3 = V$, e o modelo toma a forma

$$P(Y = 1 \mid X_2 = x_2, X_3 = x_3) = \frac{\exp\{\beta_1 + \beta_2 x_2 + \beta_3 x_3\}}{1 + \exp\{\beta_1 + \beta_2 x_2 + \beta_3 x_3\}}.$$

O ajuste do modelo pelo método da máxima verossimilhança leva às estimativas dadas na tabela a seguir. Nela, z é o valor da estimativa dividido pelo seu erro padrão. Como z tem distribuição aproximadamente $N(0, 1)$ quando o β_i correspondente é igual a 0, o valor-p para avaliar a hipótese nula de que $\beta_i = 0$ é $P(|Z| > |z|)$, com $Z \sim N(0, 1)$.

Coeficiente	Estimativa	Erro padrão	z	Valor-p
β_1	5,55900	1,12000	4,96	0,000
β_2	−0,05680	0,33120	−0,17	0,864
β_3	−0,08203	0,02373	−3,46	0,001

É claro que precisamos estar confiantes de que o modelo é apropriado antes de fazer inferências formais sobre os β_i. Neste caso, observamos que o número de sucessos $s(x_2, x_3)$ na casela da tabela correspondente ao ajuste $(X_2, X_3) = (x_2, x_3)$ é uma observação de uma distribuição

$$\text{Binomial}(m(x_2, x_3), P(Y = 1 \mid X_2 = x_2, X_3 = x_3)),$$

em que $m(x_2, x_3)$ é a soma do número de sucessos e de fracassos nessa casela. Assim, por exemplo, se $X_2 = U = 1{,}0$ e $X_3 = V = 7$, então $m(1{,}0; 7) = 10$ e $s(1{,}0; 7) = 10$. Denotando por $\hat{p}(x_2, x_3)$ a estimativa de $P(Y = 1 \mid X_2 = x_2, X_3 = x_3)$ obtida substituindo o EMV, temos que (ver Problema 10.5.8)

$$X^2 = \sum_{(x_2, x_3)} \frac{(s(x_2, x_3) - m(x_2, x_3)\hat{p}(x_2, x_3))^2}{m(x_2, x_3)\hat{p}(x_2, x_3)} \tag{10.5.3}$$

tem distribuição assintótica $\chi^2(19 - 3) = \chi^2(16)$ quando o modelo é correto. Determinamos os graus de liberdade contando o número de caselas em que houve observações (19 neste caso, já que não houve observações quando $U = 2{,}8$, $V = 51$) e subtraindo o número de parâmetros estimados. Para esses dados, $X^2 = 13{,}543$ e o valor-p é $P(\chi^2(16) > 13{,}543) = 0{,}633$. Portanto, não temos evidência de que o modelo seja incorreto e podemos prosseguir para fazer inferências sobre os β_i com base no modelo de regressão logística.

Pela tabela anterior, vemos que a hipótese nula $H_0 : \beta_2 = 0$ não é rejeitada. Assim, descartamos X_2 e ajustamos o modelo menor dado por

$$P(Y = 1 \mid X_3 = x_3) = \frac{\exp\{\beta_1 + \beta_3 x_3\}}{1 + \exp\{\beta_1 + \beta_3 x_3\}}.$$

Isso leva às estimativas $\hat{\beta}_1 = 5{,}4152$ e $\hat{\beta}_3 = -0{,}08070$. Observe que elas diferem só marginalmente das estimativas anteriores. Na Figura 10.5.1, apresentamos um gráfico da função ajustada na faixa em que observamos X_3. ■

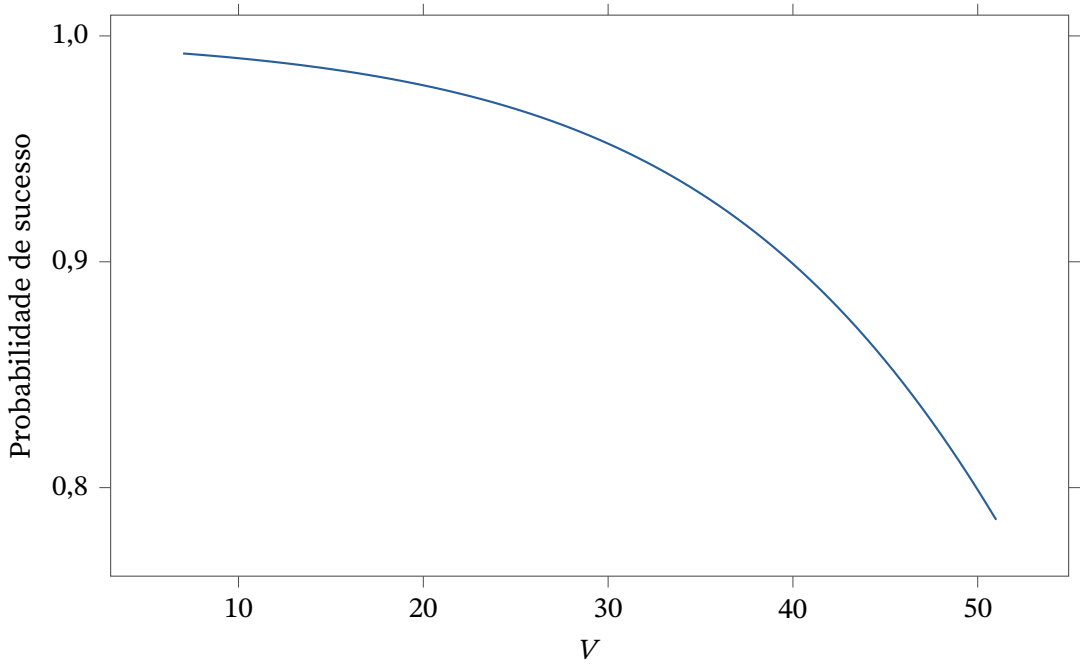


Figura 10.5.1: A probabilidade ajustada de obter um lingote pronto para ser laminado, como função da duração do aquecimento, no Exemplo 10.5.1.

Resumo da Seção 10.5

- Examinamos a situação em que temos uma única variável resposta binária e vários preditores quantitativos.
- Um método de expressar uma relação entre a resposta e os preditores é usar uma função de ligação.
- Se usarmos a função de ligação logística, então podemos fazer uma análise de regressão logística usando métodos de inferência baseados na verossimilhança.

Exercícios

10.5.1 Prove que a função $f : R^1 \to R^1$, definida por $f(x) = e^{-x}(1 + e^{-x})^{-2}$ para $x \in R^1$, é uma função densidade[72] com função de distribuição dada por $F(x) = (1 + e^{-x})^{-1}$ e fda inversa dada por $F^{-1}(p) = \ln p - \ln(1 - p)$ para $p \in [0, 1]$. Ela é chamada de *distribuição logística*.

10.5.2 Demonstre (10.5.2).

No original: *density function*[72].

10.5.3 Suponha que um modelo de regressão logística para uma resposta binária Y seja dado por

$$P(Y = 1 \mid x) = \frac{\exp\{\beta_1 + \beta_2 x\}}{1 + \exp\{\beta_1 + \beta_2 x\}}.$$

Prove que o log da chance em $X = x$ é dado por $\beta_1 + \beta_2 x$.

10.5.4 Suponha que, em vez da fda logística inversa como função de ligação, usemos a fda inversa de uma distribuição de Laplace[73] (ver Problema 2.4.22). Determine a forma de $P(Y = 1 \mid X_1 = x_1, \ldots, X_k = x_k)$.

10.5.5 Suponha que, em vez da fda logística inversa como função de ligação, usemos a fda inversa de uma distribuição de Cauchy[74] (ver Problema 2.4.21). Determine a forma de $P(Y = 1 \mid X_1 = x_1, \ldots, X_k = x_k)$.

Exercícios computacionais

10.5.6 Use um software para reproduzir os resultados do Exemplo 10.5.1.

10.5.7 Suponha que os dados a seguir tenham sido obtidos para o preditor quantitativo X e a variável resposta binária Y.

X	-5	-4	-3	-2	-1	0	1	2	3	4	5
Y	$0,0$	$0,0$	$0,0$	$0,0$	$1,0$	$0,0$	$1,0$	$0,1$	$1,1$	$1,1$	$1,1$

(a) Usando esses dados, ajuste o modelo de regressão logística dado por

$$P(Y = 1 \mid x) = \frac{\exp\{\beta_1 + \beta_2 x + \beta_3 x^2\}}{1 + \exp\{\beta_1 + \beta_2 x + \beta_3 x^2\}}.$$

(b) O modelo se ajusta aos dados?

(c) Teste a hipótese nula $H_0 : \beta_3 = 0$.

(d) Se você concluir que não há efeito quadrático, reajuste o modelo e teste se há algum efeito linear.

(e) Faça o gráfico de $P(Y = 1 \mid x)$ como função de x.

No original: *Laplace distribution*[73], *Cauchy*[74].

Problemas

10.5.8 Prove que (10.5.3) é a forma correta da estatística do teste qui-quadrado de aderência[75].

10.6 Demonstrações Adicionais (Avançado)

Demonstração do Teorema 10.3.1

Queremos provar que, quando $E(Y \mid X = x) = \beta_1 + \beta_2 x$ *e observamos os valores independentes* $(x_1, y_1), \ldots, (x_n, y_n)$ *de* (X, Y)*, então as estimativas de mínimos quadrados de* β_1 *e* β_2 *são dadas por* $b_1 = \bar{y} - b_2\bar{x}$ *e*

$$b_2 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n}(x_i - \bar{x})^2},$$

sempre que $\sum_{i=1}^{n}(x_i - \bar{x})^2 \neq 0$.

Precisamos de um resultado algébrico que vai simplificar nossos cálculos.

Lema 10.6.1

Se $(x_1, y_1), \ldots, (x_n, y_n)$ são tais que $\sum_{i=1}^{n}(x_i - \bar{x})^2 \neq 0$ e $q, r \in R^1$, então $\sum_{i=1}^{n}(y_i - b_1 - b_2 x_i)(q + r x_i) = 0$.

Demonstração. Temos

$$\sum_{i=1}^{n}(y_i - b_1 - b_2 x_i) = n\bar{y} - nb_1 - nb_2\bar{x} = n(\bar{y} - \bar{y} + b_2\bar{x} - b_2\bar{x}) = 0,$$

o que estabelece que $\sum_{i=1}^{n}(y_i - b_1 - b_2 x_i)q = 0$ para todo q. Agora, usando isso e

No original: *chi-squared goodness of fit test*[75].

as fórmulas do Teorema 10.3.1, obtemos

$$\begin{aligned}
&\sum_{i=1}^{n}(y_i - b_1 - b_2x_i)x_i \\
&= \sum_{i=1}^{n}(y_i - b_1 - b_2x_i)(x_i - \bar{x}) \\
&= \sum_{i=1}^{n}(y_i - \bar{y} - b_2(x_i - \bar{x}))(x_i - \bar{x}) \\
&= \sum_{i=1}^{n}(y_i - \bar{y})(x_i - \bar{x}) - \sum_{i=1}^{n}(y_i - \bar{y})(x_i - \bar{x}) = 0.
\end{aligned}$$

Isso estabelece o lema. ■

Voltando à demonstração do Teorema 10.3.1, temos*

$$\begin{aligned}
&\sum_{i=1}^{n}(y_i - \beta_1 - \beta_2x_i)^2 \\
&= \sum_{i=1}^{n}(y_i - b_1 - b_2x_i - (\beta_1 - b_1) - (\beta_2 - b_2)x_i)^2 \\
&= \sum_{i=1}^{n}(y_i - b_1 - b_2x_i)^2 - 2\sum_{i=1}^{n}(y_i - b_1 - b_2x_i)\{(\beta_1 - b_1) + (\beta_2 - b_2)x_i\} \\
&\quad + \sum_{i=1}^{n}((\beta_1 - b_1) + (\beta_2 - b_2)x_i)^2 \\
&= \sum_{i=1}^{n}(y_i - b_1 - b_2x_i)^2 + \sum_{i=1}^{n}((\beta_1 - b_1) + (\beta_2 - b_2x_i))^2,
\end{aligned}$$

já que o termo do meio é 0 pelo Lema 10.6.1. Portanto,

$$\sum_{i=1}^{n}(y_i - \beta_1 - \beta_2x_i)^2 \geq \sum_{i=1}^{n}(y_i - b_1 - b_2x_i)^2$$

e $\sum_{i=1}^{n}(y_i - \beta_1 - \beta_2x_i)^2$ atinge seu valor mínimo se e somente se

$$\sum_{i=1}^{n}((\beta_1 - b_1) + (\beta_2 - b_2)x_i)^2 = 0.$$

Isso ocorre se e somente se $(\beta_1 - b_1) + (\beta_2 - b_2)x_i = 0$ para todo i. Como os x_i não são todos iguais, isso vale se e somente se $\beta_1 = b_1$ e $\beta_2 = b_2$, o que completa a demonstração. ■

*Nota do tradutor. Na última linha, o original traz $(\beta_2 - b_2x_i)$; pela linha anterior seria $(\beta_2 - b_2)x_i$.

Demonstração do Teorema 10.3.2

Queremos provar que, se $E(Y \mid X = x) = \beta_1 + \beta_2 x$ *e observamos os valores independentes* $(x_1, y_1), \ldots, (x_n, y_n)$ *de* (X, Y)*, então*

(i) $E(B_1 \mid X_1 = x_1, \ldots, X_n = x_n) = \beta_1$,

(ii) $E(B_2 \mid X_1 = x_1, \ldots, X_n = x_n) = \beta_2$.

Pelo Teorema 10.3.1 e por $E(\bar{Y} \mid X_1 = x_1, \ldots, X_n = x_n) = \beta_1 + \beta_2 \bar{x}$, temos que

$$\begin{aligned} E(B_2 \mid X_1 = x_1, \ldots, X_n = x_n) &= \frac{\sum_{i=1}^{n}(x_i - \bar{x})(\beta_1 + \beta_2 x_i - \beta_1 - \beta_2 \bar{x})}{\sum_{i=1}^{n}(x_i - \bar{x})^2} \\ &= \beta_2 \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{\sum_{i=1}^{n}(x_i - \bar{x})^2} = \beta_2. \end{aligned}$$

Além disso, pelo Teorema 10.3.1 e pelo que acabamos de provar,

$$E(B_1 \mid X_1 = x_1, \ldots, X_n = x_n) = \beta_1 + \beta_2 \bar{x} - \beta_2 \bar{x} = \beta_1.$$

■

Demonstração do Teorema 10.3.3

Queremos provar que, se $E(Y \mid X = x) = \beta_1 + \beta_2 x$, $\mathrm{Var}(Y \mid X = x) = \sigma^2$ *para todo* x*, e observamos os valores independentes* $(x_1, y_1), \ldots, (x_n, y_n)$ *de* (X, Y)*, então*

(i) $\mathrm{Var}(B_1 \mid X_1 = x_1, \ldots, X_n = x_n) = \sigma^2(1/n + \bar{x}^2 / \sum_{i=1}^{n}(x_i - \bar{x})^2)$,

(ii) $\mathrm{Var}(B_2 \mid X_1 = x_1, \ldots, X_n = x_n) = \sigma^2 / \sum_{i=1}^{n}(x_i - \bar{x})^2$,

(iii) $\mathrm{Cov}(B_1, B_2 \mid X_1 = x_1, \ldots, X_n = x_n) = -\sigma^2 \bar{x} / \sum_{i=1}^{n}(x_i - \bar{x})^2$.

Primeiro provamos (ii). Observe que b_2 é uma combinação linear dos valores $y_i - \bar{y}$, de modo que podemos calcular a variância condicional depois de obter as variâncias e covariâncias condicionais dos valores $Y_i - \bar{Y}$. Temos que

$$Y_i - \bar{Y} = \left(1 - \frac{1}{n}\right) Y_i - \frac{1}{n} \sum_{j \neq i} Y_j,$$

de modo que a variância condicional de $Y_i - \bar{Y}$ é dada por

$$\sigma^2 \left(1 - \frac{1}{n}\right)^2 + \sigma^2 \frac{n-1}{n^2} = \sigma^2 \left(1 - \frac{1}{n}\right).$$

Quando $i \neq j$, podemos escrever

$$Y_i - \bar{Y} = \left(1 - \frac{1}{n}\right) Y_i - \frac{1}{n} Y_j - \frac{1}{n} \sum_{k \neq i,j} Y_k,$$

e a covariância condicional entre $Y_i - \bar{Y}$ e $Y_j - \bar{Y}$ é então dada por

$$-2\sigma^2\left(1-\frac{1}{n}\right)\frac{1}{n}+\sigma^2\frac{n-2}{n^2}=-\frac{\sigma^2}{n}$$

(observe que, para este cálculo, você pode supor que as médias das esperanças dos Y são 0). Portanto, a variância condicional de B_2 é dada por

$$\begin{aligned}
&\operatorname{Var}(B_2 \mid x_1,\ldots,x_n)\\
&=\sigma^2\left(1-\frac{1}{n}\right)\frac{\sum_{i=1}^n(x_i-\bar{x})^2}{\left(\sum_{i=1}^n(x_i-\bar{x})^2\right)^2}-\frac{\sigma^2}{n}\frac{\sum_{i\neq j}(x_i-\bar{x})(x_j-\bar{x})}{\left(\sum_{i=1}^n(x_i-\bar{x})^2\right)^2}\\
&=\frac{\sigma^2}{\sum_{i=1}^n(x_i-\bar{x})^2},
\end{aligned}$$

porque

$$\begin{aligned}
\sum_{i\neq j}(x_i-\bar{x})(x_j-\bar{x})&=\left(\sum_{i=1}^n(x_i-\bar{x})\right)^2-\sum_{i=1}^n(x_i-\bar{x})^2\\
&=-\sum_{i=1}^n(x_i-\bar{x})^2.
\end{aligned}$$

Para (iii), temos que

$$\begin{aligned}
&\operatorname{Cov}(B_1,B_2 \mid X_1=x_1,\ldots,X_n=x_n)\\
&=\operatorname{Cov}(\bar{Y}-B_2\bar{X},B_2 \mid X_1=x_1,\ldots,X_n=x_n)\\
&=\operatorname{Cov}(\bar{Y},B_2 \mid X_1=x_1,\ldots,X_n=x_n)-\bar{x}\operatorname{Var}(B_2 \mid X_1=x_1,\ldots,X_n=x_n)
\end{aligned}$$

e*

$$\begin{aligned}
&\operatorname{Cov}(\bar{Y},B_2 \mid X_1=x_1,\ldots,X_n=x_n)\\
&=\frac{\sum_{i=1}(x_i-\bar{x})\operatorname{Cov}((Y_i-\bar{Y}),\bar{Y} \mid X_1=x_1,\ldots,X_n=x_n)}{\sum_{i=1}^n(x_i-\bar{x})^2}\\
&=\sigma^2(1-1/n)\frac{\sum_{i=1}(x_i-\bar{x})}{\sum_{i=1}^n(x_i-\bar{x})^2}=0.
\end{aligned}$$

Portanto, $\operatorname{Cov}(B_1,B_2 \mid X_1=x_1,\ldots,X_n=x_n)=-\sigma^2\bar{x}/\sum_{i=1}^n(x_i-\bar{x})^2$.

Por fim, para (i), temos†

$$\begin{aligned}
&\operatorname{Var}(B_1 \mid X_1=x_1,\ldots,X_n=x_n)=\operatorname{Var}(\bar{Y}-B_2\bar{x} \mid X_1=x_1,\ldots,X_n=x_n)\\
&=\operatorname{Var}(\bar{Y} \mid X_1=x_1,\ldots,X_n=x_n)+\bar{x}^2\operatorname{Var}(B_2 \mid X_1=x_1,\ldots,X_n=x_n)\\
&\quad-2\operatorname{Cov}(\bar{Y},B_2 \mid X_1=x_1,\ldots,X_n=x_n),
\end{aligned}$$

*Nota do tradutor. O fator $\sigma^2(1-1/n)$ da última linha não confere: pela conta, $\operatorname{Cov}(Y_i-\bar{Y},\bar{Y} \mid \ldots)=\sigma^2/n-\sigma^2/n=0$. O resultado final, 0, não muda.

†Nota do tradutor. O original traz $-2\operatorname{Cov}(\bar{Y},B_2 \mid \ldots)$; pela conta seria $-2\bar{x}\operatorname{Cov}(\bar{Y},B_2 \mid \ldots)$. Como essa covariância é 0, o resultado não muda.

em que $\text{Var}(\bar{Y} \mid X_1 = x_1, \ldots, X_n = x_n) = \sigma^2/n$. Substituir os resultados de (ii) e (iii) completa a demonstração do teorema. ■

Demonstração do Corolário 10.3.1

Precisamos mostrar que

$$\text{Var}(B_1 + B_2 x \mid X_1 = x_1, \ldots, X_n = x_n) = \sigma^2 \left(\frac{1}{n} + \frac{(x - \bar{x})^2}{\sum_{i=1}^{n} (x_i - \bar{x})^2} \right).$$

Para isso, temos que

$$\begin{aligned}
&\text{Var}(B_1 + B_2 x \mid X_1 = x_1, \ldots, X_n = x_n) \\
&= \text{Var}(B_1 \mid X_1 = x_1, \ldots, X_n = x_n) + x^2 \,\text{Var}(B_2 \mid X_1 = x_1, \ldots, X_n = x_n) \\
&\quad + 2x \,\text{Cov}(B_1, B_2 \mid X_1 = x_1, \ldots, X_n = x_n) \\
&= \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2 + x^2 - 2x\bar{x}}{\sum_{i=1}^{n} (x_i - \bar{x})^2} \right) = \sigma^2 \left(\frac{1}{n} + \frac{(x - \bar{x})^2}{\sum_{i=1}^{n} (x_i - \bar{x})^2} \right).
\end{aligned}$$

■

Demonstração do Teorema 10.3.4

Queremos mostrar que, se $E(Y \mid X = x) = \beta_1 + \beta_2 x$, $\text{Var}(Y \mid X = x) = \sigma^2$ *para todo* x, *e observamos os valores independentes* $(x_1, y_1), \ldots, (x_n, y_n)$ *de* (X, Y), *então*

$$E(S^2 \mid X_1 = x_1, \ldots, X_n = x_n) = \sigma^2.$$

Temos que

$$\begin{aligned}
&E((n-2)S^2 \mid X_1 = x_1, \ldots, X_n = x_n) \\
&= E\left(\sum_{i=1}^{n} (Y_i - B_1 - B_2 x_i)^2 \,\middle|\, X_1 = x_1, \ldots, X_n = x_n \right) \\
&= \sum_{i=1}^{n} E((Y_i - \bar{Y} - B_2(x_i - \bar{x}))^2 \mid X_1 = x_1, \ldots, X_n = x_n) \\
&= \sum_{i=1}^{n} \text{Var}(Y_i - \bar{Y} - B_2(x_i - \bar{x}) \mid X_1 = x_1, \ldots, X_n = x_n)
\end{aligned}$$

porque

$$\begin{aligned}
&E(Y_i - \bar{Y} - B_2(x_i - \bar{x}) \mid X_1 = x_1, \ldots, X_n = x_n) \\
&= \beta_1 + \beta_2 x_i - \beta_1 - \beta_2 \bar{x} - \beta_2 (x_i - \bar{x}) = 0.
\end{aligned}$$

Agora,

$$\begin{aligned}&\operatorname{Var}(Y_i - \bar{Y} - B_2(x_i - \bar{x}) \mid X_1 = x_1, \ldots, X_n = x_n)\\ &= \operatorname{Var}(Y_i - \bar{Y} \mid X_1 = x_1, \ldots, X_n = x_n)\\ &\quad - 2(x_i - \bar{x}) \operatorname{Cov}((Y_i - \bar{Y}), B_2 \mid X_1 = x_1, \ldots, X_n = x_n)\\ &\quad + (x_i - \bar{x})^2 \operatorname{Var}(B_2 \mid X_1 = x_1, \ldots, X_n = x_n)\end{aligned}$$

e, usando os resultados estabelecidos sobre as covariâncias dos $Y_i - \bar{Y}$ na demonstração do Teorema 10.3.3, temos que

$$\operatorname{Var}(Y_i - \bar{Y} \mid X_1 = x_1, \ldots, X_n = x_n) = \sigma^2(1 - 1/n)$$

e

$$\begin{aligned}&\operatorname{Cov}(Y_i - \bar{Y}, B_2 \mid X_1 = x_1, \ldots, X_n = x_n)\\ &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{j=1}^n (x_j - \bar{x}) \operatorname{Cov}(Y_i - \bar{Y}, Y_j - \bar{Y} \mid X_1 = x_1, \ldots, X_n = x_n)\\ &= \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \left(\left(1 - \frac{1}{n}\right)(x_i - \bar{x}) - \frac{1}{n} \sum_{j \neq i} (x_j - \bar{x}) \right) = \frac{\sigma^2 (x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2},\end{aligned}$$

porque $\sum_{j \neq i} (x_j - \bar{x}) = -(x_i - \bar{x})$. Portanto,

$$\begin{aligned}&\operatorname{Var}(Y_i - \bar{Y} - B_2(x_i - \bar{x}) \mid X_1 = x_1, \ldots, X_n = x_n)\\ &= \sigma^2 \left(1 - \frac{1}{n}\right) - 2\frac{\sigma^2 (x_i - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2} + \frac{\sigma^2 (x_i - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2}\\ &= \sigma^2 \left(1 - \frac{1}{n} - \frac{(x_i - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2}\right)\end{aligned}$$

e

$$E(S^2 \mid X_1 = x_1, \ldots, X_n = x_n) = \frac{\sigma^2}{n-2} \sum_{i=1}^n \left(1 - \frac{1}{n} - \frac{(x_i - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2}\right) = \sigma^2,$$

como foi enunciado. ■

Demonstração do Lema 10.3.1

Precisamos mostrar que, se $(x_1, y_1), \ldots, (x_n, y_n)$ *são tais que* $\sum_{i=1}^n (x_i - \bar{x})^2 \neq 0$, *então*

$$\sum_{i=1}^n (y_i - \bar{y})^2 = b_2^2 \sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{i=1}^n (y_i - b_1 - b_2 x_i)^2.$$

Temos que

$$\begin{aligned}\sum_{i=1}^{n}(y_i-\bar{y})^2 &= \sum_{i=1}^{n} y_i^2 - n\bar{y}^2 \\ &= \sum_{i=1}^{n}(y_i - b_1 - b_2x_i + b_1 + b_2x_i)^2 - n\bar{y}^2 \\ &= \sum_{i=1}^{n}(y_i - b_1 - b_2x_i)^2 + \sum_{i=1}^{n}(b_1 + b_2x_i)^2 - n\bar{y}^2\end{aligned}$$

porque $\sum_{i=1}^{n}(y_i - b_1 - b_2x_i)(b_1 + b_2x_i) = 0$ pelo Lema 10.6.1. Então, usando o Teorema 10.3.1, temos

$$\sum_{i=1}^{n}(b_1 + b_2x_i)^2 - n\bar{y}^2 = \sum_{i=1}^{n}(\bar{y} + b_2(x_i - \bar{x}))^2 - n\bar{y}^2 = b_2^2\sum_{i=1}^{n}(x_i - \bar{x})^2,$$

e isso completa a demonstração. ■

Demonstração do Teorema 10.3.6

Queremos mostrar que, se Y, dado $X = x$, tem distribuição $N(\beta_1 + \beta_2 x, \sigma^2)$ e observamos os valores independentes $(x_1, y_1), \ldots, (x_n, y_n)$ de (X, Y), então as distribuições condicionais de B_1, B_2 e S^2, dados $X_1 = x_1, \ldots, X_n = x_n$, são as seguintes.

(i) $B_1 \sim N(\beta_1, \sigma^2(1/n + \bar{x}^2/\sum_{i=1}^{n}(x_i - \bar{x})^2))$

(ii) $B_2 \sim N(\beta_2, \sigma^2/\sum_{i=1}^{n}(x_i - \bar{x})^2)$

(iii)
$$B_1 + B_2x \sim N\left(\beta_1 + \beta_2 x, \sigma^2\left(\frac{1}{n} + \frac{(x-\bar{x})^2}{\sum_{i=1}^{n}(x_i - \bar{x})^2}\right)\right)$$

(iv) $(n-2)S^2/\sigma^2 \sim \chi^2(n-2)$ *independente de* (B_1, B_2)

Primeiro provamos (i). Como B_1 pode ser escrito como uma combinação linear dos Y_i, o Teorema 4.6.1 implica que a distribuição de B_1 tem de ser normal. O resultado segue, então, dos Teoremas 10.3.2 e 10.3.3. Uma demonstração semelhante estabelece (ii) e (iii). A demonstração de (iv) é semelhante à do Teorema 4.6.6, e a deixamos para um curso posterior de estatística. ■

Demonstração do Corolário 10.3.2

Queremos mostrar que

(i) $(B_1 - \beta_1)/S\left(1/n + \bar{x}^2/\sum_{i=1}^{n}(x_i - \bar{x})^2\right)^{1/2} \sim t(n-2)$

(ii) $(B_2 - \beta_2)\left(\sum_{i=1}^{n}(x_i - \bar{x})^2\right)^{1/2}/S \sim t(n-2)$

(iii) *
$$\frac{B_1 + B_2 x - \beta_1 - \beta_2 x}{S\left((1/n + (x-\bar{x})^2)/\sum_{i=1}^{n}(x_i - \bar{x})^2\right)^{1/2}} \sim t(n-2)$$

(iv) *Se F for definida como em (10.3.8), então $H_0 : \beta_2 = 0$ é verdadeira se e somente se $F \sim F(1, n-2)$.*

Primeiro provamos (i). Como B_1 e S^2 são independentes,

$$\frac{B_1 - \beta_1}{\sigma\left(1/n + \bar{x}^2/\sum_{i=1}^{n}(x_i - \bar{x})^2\right)^{1/2}} \sim N(0,1)$$

independente de $(n-2)S^2/\sigma^2 \sim \chi^2(n-2)$. Portanto, aplicando a Definição 4.6.2, temos

$$\frac{B_1 - \beta_1}{\sigma\left(1/n + \bar{x}^2/\sum_{i=1}^{n}(x_i - \bar{x})^2\right)^{1/2}\left((n-2)S^2/(n-2)\sigma^2\right)^{1/2}}$$
$$= \frac{B_1 - \beta_1}{S\left(1/n + \bar{x}^2/\sum_{i=1}^{n}(x_i - \bar{x})^2\right)^{1/2}} \sim t(n-2).$$

Para (ii), a demonstração prossegue exatamente como a de (i).

Para (iii), a demonstração prossegue exatamente como a de (i), usando também o Corolário 10.3.1.

Provamos agora (iv). Elevar ao quadrado a razão em (ii) e aplicar o Teorema 4.6.11 implica

$$G = \frac{(B_2 - \beta_2)^2}{S^2\left(\sum_{i=1}^{n}(x_i - \bar{x})^2\right)^{-1}} = \frac{(B_2 - \beta_2)^2 \sum_{i=1}^{n}(x_i - \bar{x})^2}{S^2} \sim F(1, n-2).$$

Observe agora que a F definida por (10.3.8) é igual a G quando $\beta_2 = 0$. A recíproca[76], de que $F \sim F(1, n-2)$ só se $\beta_2 = 0$, é um pouco mais difícil de provar, e a deixamos para um curso posterior. ■

*Nota do tradutor. O original agrupa $(1/n + (x-\bar{x})^2)/\sum_{i=1}^{n}(x_i - \bar{x})^2$; pelo Corolário 10.3.1 seria $1/n + (x-\bar{x})^2/\sum_{i=1}^{n}(x_i - \bar{x})^2$.

No original: *converse*[76].

CAPÍTULO 11

Tópico Avançado — Processos Estocásticos

ESBOÇO DO CAPÍTULO

Seção 1 Passeio Aleatório Simples
Seção 2 Cadeias de Markov
Seção 3 Monte Carlo via Cadeias de Markov
Seção 4 Martingais
Seção 5 Movimento Browniano
Seção 6 Processos de Poisson
Seção 7 Demonstrações Adicionais

Neste capítulo, consideramos *processos estocásticos*, que são processos que evoluem aleatoriamente no *tempo*. Isto é, em vez de considerar variáveis aleatórias fixas X, Y etc., ou mesmo sequências de variáveis aleatórias independentes e identicamente distribuídas[1] (i.i.d.), consideraremos sequências $X_0, X_1, X_2, \ldots$, em que X_n representa alguma quantidade aleatória *no instante* n. Em geral, o valor X_n no instante n pode depender da quantidade X_{n-1} no instante $n-1$, ou até dos valores X_m em outros instantes $m < n$. Os processos estocásticos têm um "sabor" diferente do das variáveis aleatórias comuns: como evoluem no tempo, parecem mais "vivos".

Começamos com um caso simples, mas muito interessante: o passeio aleatório simples[2].

11.1 Passeio Aleatório Simples

O passeio aleatório simples pode ser visto como um modelo para *jogos de azar* repetidos. Mais precisamente, suponha que você comece com US$ a e faça repetidamente apostas de US$ 1. Em cada aposta, você tem probabilidade p de

No original: *independent and identically distributed*[1], *simple random walk*[2].

ganhar US$ 1 e probabilidade q de perder US$ 1, em que $p + q = 1$. Se X_n é a quantia de dinheiro que você tem no instante n (daqui em diante, sua *fortuna* no instante n), então $X_0 = a$, enquanto X_1 pode ser $a + 1$ ou $a - 1$, conforme você ganhe ou perca a primeira aposta. Em seguida, X_2 pode ser $a + 2$ (se você ganhar as duas primeiras apostas), ou a (se ganhar uma vez e perder uma vez), ou $a - 2$ (se perder as duas primeiras apostas). Continuando assim, obtemos toda uma sequência $X_0, X_1, X_2, \ldots$ de valores aleatórios, que correspondem à sua fortuna nos instantes $0, 1, 2, \ldots$.

Chamaremos o processo estocástico[3] $\{X_n\}$ de *passeio aleatório simples*. Outra forma de definir esse modelo é partir de variáveis aleatórias $\{Z_i\}$ i.i.d. com $P(Z_i = 1) = p$ e $P(Z_i = -1) = 1 - p \equiv q$, em que $0 < p < 1$. (Aqui, $Z_i = 1$ se você ganha a i-ésima aposta, e $Z_i = -1$ se você perde a i-ésima aposta.) Tomamos então $X_0 = a$ e, para $n \geq 1$, definimos

$$X_n = a + Z_1 + Z_2 + \cdots + Z_n.$$

Vejamos um exemplo específico disso.

Exemplo 11.1.1

Considere o passeio aleatório simples com $a = 8$ e $p = 1/3$; assim, você começa com US$ 8 e tem probabilidade $1/3$ de ganhar cada aposta. Então a probabilidade de você ter US$ 9 depois de uma aposta é dada por

$$P(X_1 = 9) = P(8 + Z_1 = 9) = P(Z_1 = 1) = 1/3,$$

como deveria ser. Além disso, a probabilidade de você ter US$ 7 depois de uma aposta é dada por

$$P(X_1 = 7) = P(8 + Z_1 = 7) = P(Z_1 = -1) = 2/3.$$

Por outro lado, a probabilidade de você ter US$ 10 depois de duas apostas é dada por

$$P(X_2 = 10) = P(8 + Z_1 + Z_2 = 10) = P(Z_1 = Z_2 = 1) = (1/3)(1/3) = 1/9.$$

■

No original: *stochastic process*[3].

Exemplo 11.1.2

Considere novamente o passeio aleatório simples com $a = 8$ e $p = 1/3$. Então a probabilidade de você ter US$ 7 depois de três apostas é dada por

$$P(X_3 = 7) = P(8 + Z_1 + Z_2 + Z_3 = 7) = P(Z_1 + Z_2 + Z_3 = -1).$$

Ora, há três maneiras diferentes de termos $Z_1 + Z_2 + Z_3 = -1$, a saber:

(a) $Z_1 = 1$, enquanto $Z_2 = Z_3 = -1$;

(b) $Z_2 = 1$, enquanto $Z_1 = Z_3 = -1$; ou

(c) $Z_3 = 1$, enquanto $Z_1 = Z_2 = -1$.

Cada uma dessas três opções tem probabilidade $(1/3)(2/3)(2/3)$. Logo,

$$P(X_3 = 7) = (1/3)(2/3)(2/3) + (1/3)(2/3)(2/3) + (1/3)(2/3)(2/3) = 4/9.$$

Se o número de apostas for muito maior que três, fica cada vez menos cômodo calcular probabilidades da maneira acima. É preciso uma abordagem mais sistemática, que é o que veremos a seguir.

11.1.1 A Distribuição da Fortuna

Primeiro calculamos a distribuição de X_n, isto é, a probabilidade de sua fortuna X_n depois de n apostas assumir os vários valores possíveis.

Teorema 11.1.1

Seja $\{X_n\}$ o passeio aleatório simples como antes, e seja n um inteiro positivo. Se k é um inteiro tal que $-n \leq k \leq n$ e $n + k$ é par, então

$$P(X_n = a + k) = \binom{n}{\frac{n+k}{2}} p^{(n+k)/2} q^{(n-k)/2}.$$

Para todos os outros valores de k, temos $P(X_n = a + k) = 0$. Além disso, $E(X_n) = a + n(2p - 1)$.

Demonstração. Veja a Seção 11.7. ■

Esse teorema nos dá a distribuição inteira, e o valor esperado[4], da fortuna X_n no instante n.

Exemplo 11.1.3

Suponha que $p = 1/3$, $n = 8$ e $a = 1$. Então $P(X_n = 6) = 0$, porque $6 = 1 + 5$ e $n + 5 = 13$ não é par. Além disso, $P(X_n = 13) = 0$, porque $13 = 1 + 12$ e $12 > n$. Por outro lado,

$$P(X_n = 5) = P(X_n = 1 + 4) = \binom{n}{\frac{n+4}{2}} p^{(n+4)/2} q^{(n-4)/2} = \binom{8}{6} (1/3)^6 (2/3)$$
$$= \frac{8 \cdot 7}{2} (1/3)^6 (2/3)^1 = 0{,}0256.$$

Além disso, $E(X_n) = a + n(2p - 1) = 1 + 8(2/3 - 1) = -5/3$. ■

Quanto a $E(X_n)$, obtemos imediatamente o corolário a seguir.

Corolário 11.1.1

Se $p = 1/2$, então $E(X_n) = a$ para todo $n \geq 0$. Se $p < 1/2$, então $E(X_n) < a$ para todo $n \geq 1$. Se $p > 1/2$, então $E(X_n) > a$ para todo $n \geq 1$.

Esse corolário tem a seguinte interpretação. Se $p = 1/2$, então o jogo é *justo*, isto é, você e seu adversário têm a mesma chance de ganhar cada aposta. Assim, o corolário diz que, em jogos justos, sua fortuna esperada $E(X_n)$ nunca muda em relação ao valor inicial, a.

Por outro lado, se $p < 1/2$, então o jogo é *desfavorável*, isto é, as chances do seu adversário são melhores que as suas. Nesse caso, o corolário diz que sua fortuna esperada vai *diminuir*, isto é, ficar abaixo do valor inicial a. Da mesma forma, se $p > 1/2$, então o jogo é *favorável*, e o corolário diz que sua fortuna esperada vai *aumentar*, isto é, ficar acima do valor inicial a.

É claro que, num cassino de verdade, o jogo é sempre desfavorável (é assim que o cassino tem lucro). Logo, num cassino de verdade, a quantia média de dinheiro com que você sai será sempre menor que a quantia com que você entrou!

No original: *expected value*[4].

Exemplo 11.1.4

Suponha que $a = 10$ e $p = 1/4$. Então $E(X_n) = 10 + n(2p - 1) = 10 - 3n/4$. Logo, temos sempre $E(X_n) \leq 10$ e, de fato, $E(X_n) < 0$ se $n \geq 14$. Isto é, sua fortuna esperada nunca passa do valor inicial de US$ 10 e, na verdade, fica *negativa* a partir de 14 apostas. ■

Por fim, observamos de passagem que é possível alterar suas probabilidades mudando sua *estratégia* de jogo, como no exemplo a seguir. Portanto, a análise anterior vale apenas para a estratégia de apostar exatamente US$ 1 de cada vez.

Exemplo 11.1.5

Considere a estratégia de jogo "dobre até ganhar", definida da seguinte forma. Primeiro apostamos US$ 1. Cada vez que perdemos, *dobramos* a aposta na rodada seguinte. Assim que ganhamos uma vez, paramos de jogar (isto é, apostamos zero daí em diante).

É fácil ver que, com essa estratégia, estaremos US$ 1 à frente assim que ganharmos uma aposta (o que tem de acontecer em algum momento, já que $p > 0$). Logo, com probabilidade 1, ganharemos US$ 1 com essa estratégia para *qualquer* valor positivo de p.

Isso é bastante surpreendente, porque, se $0 < p < 1/2$, as chances nesse jogo estão contra nós. Parece, então, que "enganamos o destino", e de fato enganamos. Por outro lado, podemos precisar perder uma quantia de dinheiro arbitrariamente grande antes de ganhar nosso US$ 1; assim, é necessário "capital infinito" para seguir essa estratégia. Se houver apenas capital finito disponível, então é impossível enganar o destino dessa maneira. Para uma demonstração disso, veja livros de probabilidade mais avançados, por exemplo, a página 64 de *A First Look at Rigorous Probability Theory*, segunda edição, de J. S. Rosenthal (World Scientific Publishing, Singapura, 2006). ■

11.1.2 O Problema da Ruína do Jogador

A subseção anterior considerou a distribuição e o valor esperado da fortuna X_n num instante fixo n. Aqui consideramos o problema da *ruína do jogador*[5], que exige considerar muitos valores de n ao mesmo tempo, isto é, considera a *evolução temporal* do processo.

No original: *gambler's ruin*[5].

Seja $\{X_n\}$ o passeio aleatório simples como antes, para alguma fortuna inicial a e alguma probabilidade p de ganhar cada aposta. Suponha que a seja um inteiro positivo. Além disso, seja $c > a$ algum outro inteiro. A pergunta da ruína do jogador é: se você apostar US$ 1 repetidamente, qual é a probabilidade de alcançar uma fortuna de US$ c *antes* de perder todo o seu dinheiro, chegando a uma fortuna de US$ 0? Em outras palavras, o passeio aleatório[6] atingirá c antes de atingir 0? Informalmente, qual é a probabilidade de o jogador ficar rico (isto é, ter US$ c) antes de ir à falência?

Mais formalmente, sejam

$$\tau_0 = \min\{n \geq 0 : X_n = 0\},$$
$$\tau_c = \min\{n \geq 0 : X_n = c\}$$

os *tempos de primeira passagem* por 0 e por c, respectivamente. Isto é, τ_0 é o primeiro instante em que sua fortuna chega a 0, enquanto τ_c é o primeiro instante em que sua fortuna chega a c.

A pergunta da ruína do jogador é: qual é

$$P(\tau_c < \tau_0),$$

a probabilidade de atingir c antes de atingir 0? Essa pergunta não é tão fácil de responder, porque não há limite para quanto tempo pode levar até que c ou 0 seja atingido. Logo, não basta calcular as probabilidades depois de 10 apostas, ou de 20 apostas, ou de 100 apostas, ou mesmo de 1.000.000 de apostas. Felizmente, é possível responder a essa pergunta, como veremos a seguir.

Teorema 11.1.2

Seja $\{X_n\}$ o passeio aleatório simples, com alguma fortuna inicial a e probabilidade p de ganhar cada aposta. Suponha que $0 < a < c$. Então a probabilidade $P(\tau_c < \tau_0)$ de atingir c antes de 0 é dada por

$$P(\tau_c < \tau_0) = \begin{cases} a/c & p = 1/2 \\ \dfrac{1 - \left(\frac{q}{p}\right)^a}{1 - \left(\frac{q}{p}\right)^c} & p \neq 1/2. \end{cases}$$

Demonstração. Veja a Seção 11.7 para a demonstração. ■

Vejamos algumas aplicações desse resultado.

No original: *random walk*[6].

Exemplo 11.1.6

Suponha que você comece com US$ 5 (isto é, $a = 5$) e que seu objetivo seja chegar a US$ 10 antes de ir à falência (isto é, $c = 10$). Se $p = 0{,}500$, sua probabilidade de sucesso é $a/c = 0{,}500$. Se $p = 0{,}499$, sua probabilidade de sucesso é dada por

$$\left(1 - \left(\frac{0{,}501}{0{,}499}\right)^5\right)\left(1 - \left(\frac{0{,}501}{0{,}499}\right)^{10}\right)^{-1},$$

que é aproximadamente 0,495. Se $p = 0{,}501$, sua probabilidade de sucesso é dada por

$$\left(1 - \left(\frac{0{,}499}{0{,}501}\right)^5\right)\left(1 - \left(\frac{0{,}499}{0{,}501}\right)^{10}\right)^{-1},$$

que é aproximadamente 0,505. Vemos, assim, que neste caso pequenas mudanças em p levam a pequenas mudanças na probabilidade de vencer na ruína do jogador. ■

Exemplo 11.1.7

Suponha agora que você comece com US$ 5000 (isto é, $a = 5000$) e que seu objetivo seja chegar a US$ 10.000 antes de ir à falência (isto é, $c = 10.000$). Se $p = 0{,}500$, sua probabilidade de sucesso é $a/c = 0{,}500$, como antes. Por outro lado, se $p = 0{,}499$, sua probabilidade de sucesso é dada por

$$\left(1 - \left(\frac{0{,}501}{0{,}499}\right)^{5000}\right)\left(1 - \left(\frac{0{,}501}{0{,}499}\right)^{10.000}\right)^{-1},$$

que é aproximadamente 2×10^{-9}, isto é, duas partes em um bilhão! Por fim, se $p = 0{,}501$, sua probabilidade de sucesso é dada por

$$\left(1 - \left(\frac{0{,}499}{0{,}501}\right)^{5000}\right)\left(1 - \left(\frac{0{,}499}{0{,}501}\right)^{10.000}\right)^{-1},$$

que é extremamente próxima de 1. Vemos, assim, que neste caso pequenas mudanças em p levam a mudanças enormes na probabilidade de vencer na ruína do jogador. Por exemplo, mesmo uma desvantagem minúscula em cada aposta pode levar a uma desvantagem muito grande no longo prazo! A razão é que, para ir de 5000 a 10.000, é preciso fazer muitas apostas, de modo que pequenas mudanças em p têm um efeito enorme no total. ■

Por fim, observamos que também é possível usar o resultado da ruína do jogador para calcular $P(\tau_0 < \infty)$, a probabilidade de o passeio *algum dia* atingir 0 (ou, de forma equivalente, de você *algum dia* perder todo o seu dinheiro), como segue.

Teorema 11.1.3

Seja $\{X_n\}$ o passeio aleatório simples, com fortuna inicial $a > 0$ e probabilidade p de ganhar cada aposta. Então a probabilidade $P(\tau_0 < \infty)$ de o passeio *algum dia* atingir 0 é dada por

$$P(\tau_0 < \infty) = \begin{cases} 1 & p \leq 1/2 \\ (q/p)^a & p > 1/2. \end{cases}$$

Demonstração. Veja a Seção 11.7 para a demonstração. ■

Exemplo 11.1.8

Suponha que $a = 2$ e $p = 2/3$. Então a probabilidade de você *acabar* perdendo todo o seu dinheiro é dada por $(q/p)^a = ((1/3)/(2/3))^2 = 1/4$. Assim, começando com apenas US$ 2, vemos que em 3/4 das vezes você poderá apostar para sempre sem nunca perder todo o seu dinheiro.

Por outro lado, se $p \leq 1/2$, então, por maior que seja a, é certo que você acabará perdendo todo o seu dinheiro. ■

Resumo da Seção 11.1

- Um passeio aleatório simples é uma sequência $\{X_n\}$ de variáveis aleatórias, com $X_0 = 1$* e $P(X_{n+1} = X_n + 1) = p = 1 - P(X_{n+1} = X_n - 1)$.
- Segue-se que
$$P(X_n = a + k) = \binom{n}{\frac{n+k}{2}} p^{(n+k)/2} q^{(n-k)/2}$$
para $k = -n, -n+2, -n+4, \ldots, n$, e $E(X_n) = a + n(2p-1)$.
- Se $0 < a < c$, então a probabilidade da ruína do jogador de alcançar c antes de 0 é igual a a/c se $p = 1/2$ e, caso contrário, a
$$(1 - ((1-p)/p)^a)/(1 - ((1-p)/p)^c).$$

*Nota do tradutor. O original traz $X_0 = 1$; pelo texto da seção, seria $X_0 = a$.

Exercícios

11.1.1 Seja $\{X_n\}$ o passeio aleatório simples, com fortuna inicial $a = 12$ e probabilidade $p = 1/3$ de ganhar cada aposta. Calcule $P(X_n = x)$ para os seguintes valores de n e x.

(a) $n = 0, x = 13$

(b) $n = 1, x = 12$

(c) $n = 1, x = 13$

(d) $n = 1, x = 11$

(e) $n = 1, x = 14$

(f) $n = 2, x = 12$

(g) $n = 2, x = 13$

(h) $n = 2, x = 14$

(i) $n = 2, x = 15$

(j) $n = 20, x = 15$

(k) $n = 20, x = 16$

(l) $n = 20, x = -18$

(m) $n = 20, x = 10$

11.1.2 Seja $\{X_n\}$ o passeio aleatório simples, com fortuna inicial $a = 5$ e probabilidade $p = 2/5$ de ganhar cada aposta.

(a) Calcule $P(X_1 = 6, X_2 = 5)$.

(b) Calcule $P(X_1 = 4, X_2 = 5)$.

(c) Calcule $P(X_2 = 5)$.

(d) Qual é a relação entre as quantidades dos itens (a), (b) e (c)? Por que isso acontece?

11.1.3 Seja $\{X_n\}$ o passeio aleatório simples, com fortuna inicial $a = 7$ e probabilidade $p = 1/6$ de ganhar cada aposta.

(a) Calcule $P(X_1 = X_3 = 8)$.

(b) Calcule $P(X_1 = 6, X_3 = 8)$.

(c) Calcule $P(X_3 = 8)$.

(d) Qual é a relação entre as quantidades dos itens (a), (b) e (c)? Por que isso acontece?

11.1.4 Suponha que $a = 1000$ e $p = 0{,}49$.

(a) Calcule $E(X_n)$ para $n = 0, 1, 2, 10, 20, 100$ e 1000.

(b) Quão grande n precisa ser para que $E(X_n) < 0$?

11.1.5 Seja $\{X_n\}$ o passeio aleatório simples, com fortuna inicial a e probabilidade $p = 0{,}499$ de ganhar cada aposta. Calcule a probabilidade da ruína do jogador $P(\tau_c < \tau_0)$ para os seguintes valores de a e c. Interprete seus resultados em palavras.

(a) $a = 9$, $c = 10$

(b) $a = 90$, $c = 100$

(c) $a = 900$, $c = 1000$

(d) $a = 9000$, $c = 10.000$

(e) $a = 90.000$, $c = 100.000$

(f) $a = 900.000$, $c = 1.000.000$

11.1.6 Seja $\{X_n\}$ o passeio aleatório simples, com fortuna inicial $a = 10$ e probabilidade p de ganhar cada aposta. Calcule $P(\tau_0 < \infty)$ para $p = 0{,}4$ e também para $p = 0{,}6$. Interprete seus resultados em palavras.

11.1.7 Seja $\{X_n\}$ o passeio aleatório simples, com fortuna inicial $a = 5$ e probabilidade $p = 1/4$ de ganhar cada aposta.

(a) Calcule $P(X_1 = 6)$.

(b) Calcule $P(X_1 = 4)$.

(c) Calcule $P(X_2 = 7)$.

(d) Calcule $P(X_2 = 7 \mid X_1 = 6)$.

(e) Calcule $P(X_2 = 7 \mid X_1 = 4)$.

(f) Calcule $P(X_1 = 6 \mid X_2 = 7)$.

(g) Explique por que a resposta do item (f) é igual ao que é.

11.1.8 Seja $\{X_n\}$ o passeio aleatório simples, com fortuna inicial $a = 1000$ e probabilidade $p = 2/5$ de ganhar cada aposta.

(a) Calcule $E(X_1)$.

(b) Calcule $E(X_{10})$.

(c) Calcule $E(X_{100})$.

(d) Calcule $E(X_{1000})$.

(e) Encontre o menor valor de n tal que $E(X_n) \leq 0$.

11.1.9 Seja $\{X_n\}$ o passeio aleatório simples, com fortuna inicial $a = 100$ e probabilidade $p = 18/38$ de ganhar cada aposta (como ao apostar no vermelho na roleta).

(a) Calcule $P(X_1 \geq a)$.

(b) Calcule $P(X_2 \geq a)$.

(c) Calcule $P(X_3 \geq a)$.

(d) Tente adivinhar o valor de $\lim_{n\to\infty} P(X_n \geq a)$.

(e) Interprete o item (d) em linguagem simples.

Problemas

11.1.10 Suponha que você comece com US$ 10 e aposte repetidamente US$ 2 (em vez de US$ 1), com probabilidade p de ganhar a cada vez. Suponha que seu objetivo seja US$ 100, isto é, você continua apostando até perder todo o seu dinheiro ou chegar a US$ 100.

(a) Em função de p, qual é a probabilidade de você chegar a US$ 100 antes de perder todo o seu dinheiro? Não deixe de justificar sua solução. (Sugestão: talvez você se veja dividindo tanto 10 quanto 100 por 2.)

(b) Suponha que $p = 0{,}4$. Calcule um valor numérico para a solução do item (a).

(c) Compare as probabilidades do item (b) com as probabilidades correspondentes se você apostar apenas US$ 1 de cada vez. Qual é maior?

(d) Repita o item (b) para o caso em que você aposta US$ 10 de cada vez. A probabilidade de sucesso aumenta ou diminui?

Desafios

11.1.11 Prove que a fórmula da probabilidade da ruína do jogador $P(\tau_c < \tau_0)$ é uma função contínua de p, provando que ela é contínua em $p = 1/2$. Isto é,

prove que

$$\lim_{p\to 1/2} \frac{1-((1-p)/p)^a}{1-((1-p)/p)^c} = \frac{a}{c}.$$

Tópicos para discussão

11.1.12 Suponha que você jogue roleta repetidamente num cassino de verdade, apostando a mesma quantia a cada vez e continuando para sempre enquanto tiver dinheiro para apostar. É certo que você acabará perdendo todo o seu dinheiro? Por quê?

11.1.13 No Problema 11.1.10, itens (c) e (d), você consegue explicar intuitivamente por que as probabilidades mudam do jeito que mudam à medida que aumentamos a quantia apostada a cada vez?

11.1.14 Suponha que você comece em a e precise chegar a c, em que $c > a > 0$. Você precisa continuar jogando até chegar a c ou a 0. Suponha que você esteja jogando um jogo desfavorável[7] (isto é, $p < 1/2$), mas possa escolher quanto apostar a cada vez (isto é, pode apostar US$ 1, ou US$ 2, ou mais, embora, é claro, não possa apostar mais do que tem). Que valores de aposta você acha* que maximizarão sua probabilidade de sucesso, isto é, maximizarão $P(\tau_c < \tau_0)$? (Sugestão: os resultados do Problema 11.1.10 podem dar uma pista.)

11.2 Cadeias de Markov

Intuitivamente, uma *cadeia de Markov*[8] representa o movimento aleatório de algum objeto. Escreveremos X_n para a posição (ou valor) do objeto no instante n. Há então regras que dão as *probabilidades* de para onde o objeto vai saltar em seguida.

Uma cadeia de Markov requer um *espaço de estados*[9] S, que é o conjunto de todos os lugares aonde o objeto pode ir. (Por exemplo, talvez $S = \{1, 2, 3\}$, ou $S = \{\text{alto}, \text{baixo}\}$, ou S seja o conjunto de todos os inteiros positivos.)

*Para resultados mais avançados sobre isso, veja, por exemplo, o Teorema 7.3 de *Probability and Measure*, terceira edição, de P. Billingsley (John Wiley & Sons, Nova York, 1995).

No original: *subfair game*[7], *Markov chain*[8], *state space*[9].

Uma cadeia de Markov requer também *probabilidades de transição*[10], que dão as probabilidades de para onde o objeto vai saltar em seguida. Especificamente, para $i, j \in S$, o número p_{ij} é a probabilidade de que, se o objeto está em i, ele salte em seguida para j. Assim, a coleção $\{p_{ij} : i, j \in S\}$ de probabilidades de transição satisfaz $p_{ij} \geq 0$ para todos os $i, j \in S$, e

$$\sum_{j \in S} p_{ij} = 1$$

para cada $i \in S$.

Precisamos também considerar onde a cadeia de Markov *começa*. Muitas vezes, simplesmente tomaremos $X_0 = s$ para algum estado particular $s \in S$. Mais geralmente, poderíamos ter uma *distribuição inicial*[11] $\{\mu_i : i \in S\}$, em que $\mu_i = P(X_0 = i)$. Nesse caso, precisamos de $\mu_i \geq 0$ para cada $i \in S$, e

$$\sum_{i \in S} \mu_i = 1.$$

Resumindo, aqui S é o espaço de estados de todos os lugares aonde o objeto pode ir; μ_i representa a probabilidade de que o objeto comece no ponto i; e p_{ij} representa a probabilidade de que, *se* o objeto está no ponto i, ele salte então para o ponto j no passo seguinte. Em termos da sequência de valores aleatórios $X_0, X_1, X_2, \ldots$, temos então que

$$P(X_{n+1} = j \mid X_n = i) = p_{ij}$$

para todo inteiro positivo n e quaisquer $i, j \in S$. Observe que exigimos também que essa probabilidade de salto não dependa da história anterior da cadeia. Isto é, exigimos que

$$P(X_{n+1} = j \mid X_n = i, X_{n-1} = x_{n-1}, \ldots, X_0 = x_0) = p_{ij}$$

para todo n e todos os $i, j, x_0, \ldots, x_{n-1} \in S$.

11.2.1 Exemplos de Cadeias de Markov

Apresentamos aqui alguns exemplos de cadeias de Markov.

No original: *transition probabilities*[10], *initial distribution*[11].

Exemplo 11.2.1

Seja $S = \{1, 2, 3\}$, formado por apenas três elementos, e defina as probabilidades de transição por $p_{11} = 0$, $p_{12} = 1/2$, $p_{13} = 1/2$, $p_{21} = 1/3$, $p_{22} = 1/3$, $p_{23} = 1/3$, $p_{31} = 1/4$, $p_{32} = 1/4$ e $p_{33} = 1/2$. Isso significa que, por exemplo, se a cadeia está no estado 3, então ela tem probabilidade 1/4 de saltar para o estado 1 no próximo salto, probabilidade 1/4 de saltar para o estado 2 no próximo salto e probabilidade 1/2 de permanecer no estado 3 no próximo salto.

Essa cadeia de Markov salta pelos três pontos $\{1, 2, 3\}$ de um modo aleatório e interessante. Por exemplo, se ela começa no ponto 1, então pode saltar para 2 ou para 3 (com probabilidade 1/2 cada). Se ela salta para (digamos) 3, então no passo seguinte pode saltar para 1 ou 2 (probabilidade 1/4 cada) ou para 3 (probabilidade 1/2). Ela continua fazendo esses saltos aleatórios para sempre.

Observe que também podemos escrever as probabilidades de transição p_{ij} em forma de matriz, como

$$(p_{ij}) = \begin{pmatrix} 0 & 1/2 & 1/2 \\ 1/3 & 1/3 & 1/3 \\ 1/4 & 1/4 & 1/2 \end{pmatrix}$$

(de modo que $p_{31} = 1/4$ etc.). A matriz (p_{ij}) é então chamada de *matriz estocástica*. Essa representação matricial às vezes é conveniente. ■

Exemplo 11.2.2

De novo, seja $S = \{1, 2, 3\}$. Desta vez, defina as probabilidades de transição $\{p_{ij}\}$ em forma de matriz, como

$$(p_{ij}) = \begin{pmatrix} 1/4 & 1/4 & 1/2 \\ 1/3 & 1/3 & 1/3 \\ 0{,}01 & 0{,}01 & 0{,}98 \end{pmatrix}.$$

Isso também define uma cadeia de Markov em S. Por exemplo, a partir do estado 3, há probabilidade 0,01 de saltar para o estado 1, probabilidade 0,01 de saltar para o estado 2 e probabilidade 0,98 de ficar no estado 3. ■

Exemplo 11.2.3

Seja $S = \{\text{quarto, cozinha, sala}\}$. Defina as probabilidades de transição $\{p_{ij}\}$ em forma de matriz por

$$(p_{ij}) = \begin{pmatrix} 1/4 & 1/4 & 1/2 \\ 0 & 0 & 1 \\ 0{,}01 & 0{,}01 & 0{,}98 \end{pmatrix}.$$

Isso define uma cadeia de Markov em S. Por exemplo, a partir do quarto, a cadeia tem probabilidade $1/4$ de ficar no quarto, probabilidade $1/4$ de saltar para a cozinha e probabilidade $1/2$ de saltar para a sala. ■

Exemplo 11.2.4

Desta vez, seja $S = \{1, 2, 3, 4\}$, e defina as probabilidades de transição $\{p_{ij}\}$ em forma de matriz, como

$$(p_{ij}) = \begin{pmatrix} 0{,}2 & 0{,}4 & 0 & 0{,}4 \\ 0{,}4 & 0{,}2 & 0{,}4 & 0 \\ 0 & 0{,}4 & 0{,}2 & 0{,}4 \\ 0{,}4 & 0 & 0{,}4 & 0{,}2 \end{pmatrix}.$$

Isso define uma cadeia de Markov em S. Por exemplo, a partir do estado 4, ela tem probabilidade 0,4 de saltar para o estado 1, mas probabilidade 0 de saltar para o estado 2. ■

Exemplo 11.2.5

Desta vez, seja $S = \{1, 2, 3, 4, 5, 6, 7\}$, e defina as probabilidades de transição $\{p_{ij}\}$ em forma de matriz, como

$$(p_{ij}) = \begin{pmatrix} 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 1/2 & 0 & 1/2 & 0 & 0 & 0 & 0 \\ 0 & 1/5 & 4/5 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1/3 & 1/3 & 1/3 & 0 & 0 \\ 1/10 & 0 & 0 & 0 & 7/10 & 0 & 1/5 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 & 0 & 1 & 0 \end{pmatrix}.$$

Isso define uma cadeia de Markov (complicada!) em S. ■

Exemplo 11.2.6 — Passeio Aleatório no Círculo

Seja $S = \{0, 1, 2, \dots, d-1\}$, e defina as probabilidades de transição dizendo que $p_{ii} = 1/3$ para todo $i \in S$, e também $p_{ij} = 1/3$ sempre que i e j estiverem "um ao lado do outro" ao redor do círculo. Isto é, $p_{ij} = 1/3$ sempre que $j = i$, ou $j = i+1$, ou $j = i-1$. Além disso, $p_{0,d-1} = p_{d-1,0} = 1/3$. Caso contrário, $p_{ij} = 0$.

Se pensarmos nos d elementos de S dispostos num círculo, então nosso objeto, a cada passo, ou fica onde está, ou anda um passo no sentido horário, ou anda um passo no sentido anti-horário — cada um com probabilidade 1/3. (Observe, em particular, que ele pode dobrar a "esquina" saltando de $d-1$ para 0, ou de 0 para $d-1$, com probabilidade 1/3.) ■

Exemplo 11.2.7 — Urna de Ehrenfest

Considere duas urnas, a urna nº 1 e a urna nº 2, em que d bolas estão divididas entre as duas urnas. Suponha que, a cada passo, escolhemos uma bola uniformemente ao acaso dentre as d bolas e a passamos para a outra urna. Seja X_n o número de bolas na urna nº 1 no instante n. Assim, há $d - X_n$ bolas na urna nº 2 no instante n.

Aqui, o espaço de estados é $S = \{0, 1, 2, \dots, d\}$, porque esses são todos os números possíveis de bolas na urna nº 1 em qualquer instante n.

Além disso, se há i bolas na urna nº 1 em algum instante, então há probabilidade i/n^* de que escolhamos em seguida uma dessas i bolas, e nesse caso o número de bolas na urna nº 1 cai para $i-1$. Portanto,

$$p_{i,i-1} = i/d.$$

Da mesma forma,

$$p_{i,i+1} = (d-i)/d$$

porque há probabilidade $(d-i)/d$ de que, em vez disso, escolhamos uma das $d-i$ bolas da urna nº 2. Assim, essa cadeia de Markov se move aleatoriamente entre os números possíveis $\{0, 1, \dots, d\}$ de bolas na urna nº 1 a cada instante.

Seria de esperar que, se d é grande e a cadeia de Markov roda por muito tempo, o mais provável fosse haver aproximadamente $d/2$ bolas na urna nº 1. (Consideraremos questões desse tipo na Seção 11.2.4.) ■

Os exemplos acima devem convencer você de que cadeias de Markov em espaços de estados finitos aparecem em todas as formas e tamanhos. Cadeias de Markov em espaços de estados *infinitos* também são importantes. De fato, já vimos uma classe dessas cadeias de Markov.

Exemplo 11.2.8 — Passeio Aleatório Simples

Seja $S = \{\dots, -2, -1, 0, 1, 2, \dots\}$ o conjunto de todos os inteiros. Então S é infinito, de modo que não podemos escrever as probabilidades de transição $\{p_{ij}\}$ em forma de matriz.

Fixe $a \in S$ e tome $X_0 = a$. Fixe um número real p com $0 < p < 1$, e tome $p_{i,i+1} = p$ e $p_{i,i-1} = 1 - p$ para cada $i \in \mathbf{Z}$, com $p_{ij} = 0$ se $j \neq i \pm 1$. Assim, essa cadeia de Markov começa no ponto a (com probabilidade 1) e, a cada passo, ou aumenta de 1 (com probabilidade p) ou diminui de 1 (com probabilidade $1 - p$). É fácil ver que essa cadeia de Markov corresponde exatamente ao modelo de passeio aleatório (isto é, de apostas repetidas) da Seção 11.1.2. ■

Por fim, observamos que, em grupo, você pode criar sua própria cadeia de Markov, como segue (experimente — é divertido!).

Exemplo 11.2.9

Forme um grupo de 5 a 50 pessoas. Cada membro do grupo deve escolher em segredo duas outras pessoas do grupo, uma "pessoa A" e uma "pessoa B". Além disso, cada membro do grupo deve ter uma moeda.

Pegue um objeto qualquer, como uma bola, uma caneta ou um sapo de pelúcia. Entregue o objeto a um membro do grupo para começar. Essa pessoa deve então lançar imediatamente a moeda. Se a moeda der cara, o membro do grupo entrega (ou joga!) o objeto para a sua pessoa A. Se der coroa, o objeto vai para a sua pessoa B. A pessoa que recebe o objeto deve então lançar imediatamente a moeda e continuar o processo. (Dizer o próprio nome ao receber o objeto é uma ótima maneira de todos se conhecerem!)

Continue esse processo por um grande número de rodadas. Que padrões você observa? Todos acabam recebendo o objeto? Com que frequência? Quanto tempo o objeto leva para voltar a quem começou? Faça tantas observações interessantes quanto puder; algumas delas estarão relacionadas aos tópicos que vêm a seguir. ■

*Nota do tradutor. o original traz i/n; pela conta seria i/d, como na fórmula logo abaixo

11.2.2 Cálculos com Cadeias de Markov

Suponha que uma cadeia de Markov $\{X_n\}$ tenha probabilidades de transição $\{p_{ij}\}$ e distribuição inicial $\{\mu_i\}$. Então $P(X_0 = i) = \mu_i$ para todos os estados i. E quanto a $P(X_1 = i)$? Temos o resultado a seguir.

Teorema 11.2.1

Considere uma cadeia de Markov $\{X_n\}$ com espaço de estados S, probabilidades de transição $\{p_{ij}\}$ e distribuição inicial $\{\mu_i\}$. Então, para qualquer $i \in S$,

$$P(X_1 = i) = \sum_{k \in S} \mu_k p_{ki}.$$

Demonstração. Pela lei da probabilidade total[12],

$$P(X_1 = i) = \sum_{k \in S} P(X_0 = k, X_1 = i).$$

Mas $P(X_0 = k, X_1 = i) = P(X_0 = k)\,P(X_1 = i \mid X_0 = k) = \mu_k\, p_{ki}$ e o resultado segue. ■

Vejamos um exemplo disso.

Exemplo 11.2.10

De novo, seja $S = \{1, 2, 3\}$, e

$$(p_{ij}) = \begin{pmatrix} 1/4 & 1/4 & 1/2 \\ 1/3 & 1/3 & 1/3 \\ 0{,}01 & 0{,}01 & 0{,}98 \end{pmatrix}.$$

Suponha que $P(X_0 = 1) = 1/7$, $P(X_0 = 2) = 2/7$ e $P(X_0 = 3) = 4/7$. Então

$$P(X_1 = 3) = \sum_{k \in S} \mu_k p_{k3} = (1/7)(1/2) + (2/7)(1/3) + (4/7)(0{,}98) = 0{,}73.$$

Assim, em cerca de 73% das vezes, essa cadeia estará no estado 3 após um passo. ■

Para prosseguir, escrevamos

$$P_i(A) = P(A \mid X_0 = i)$$

No original: *law of total probability*[12].

para a probabilidade do evento A, *supondo* que a cadeia comece no estado i, isto é, supondo que $\mu_i = 1$ e $\mu_j = 0$ para $j \neq i$. Vemos então que $P_i(X_n = j)$ é a probabilidade de que, se a cadeia começa no estado i e roda por n passos, ela termine no estado j. Podemos calcular isso?

Para $n = 0$, devemos ter $X_0 = i$. Portanto, $P_i(X_0 = j) = 1$ se $i = j$, enquanto $P_i(X_0 = j) = 0$ se $i \neq j$.

Para $n = 1$, vemos que $P_i(X_1 = j) = p_{ij}$. Isto é, a probabilidade de estarmos no estado j após um passo é dada pela probabilidade de transição p_{ij}.

E para $n = 2$? Se começamos em i e terminamos em j após 2 passos, então temos de estar em *algum* estado após 1 passo. Seja k esse estado. Então vemos o seguinte.

Teorema 11.2.2

Temos $P_i(X_1 = k, X_2 = j) = p_{ik}p_{kj}$.

Demonstração. Se começamos em i, então a probabilidade de saltar primeiro para k é igual a p_{ik}. Dado que saltamos primeiro para k, a probabilidade de *então* saltar para j é dada por p_{kj}. Portanto,*

$$\begin{aligned} P_i(X_1 = k, X_2 = j) &= P(X_1 = k, X_2 = j \mid X_0 = i) \\ &= P(X_1 = k \mid X_0 = i)\, P(X_2 = k \mid X_1 = j, X_0 = i) \\ &= p_{ik}p_{kj}. \end{aligned}$$

■

Usando isso, obtemos o seguinte.

Teorema 11.2.3

Temos $P_i(X_2 = j) = \sum_{k \in S} p_{ik}p_{kj}$.

Demonstração. Pela lei da probabilidade total,

$$P_i(X_2 = j) = \sum_{k \in S} P_i(X_1 = k, X_2 = j),$$

de modo que o resultado segue do Teorema 11.2.2. ■

*Nota do tradutor. o original traz $P(X_2 = k \mid X_1 = j, X_0 = i)$ no segundo fator; pela definição seria $P(X_2 = j \mid X_1 = k, X_0 = i)$

Exemplo 11.2.11

Considere de novo a cadeia do Exemplo 11.2.1, com $S = \{1, 2, 3\}$ e

$$(p_{ij}) = \begin{pmatrix} 0 & 1/2 & 1/2 \\ 1/3 & 1/3 & 1/3 \\ 1/4 & 1/4 & 1/2 \end{pmatrix}.$$

Então

$$\begin{aligned} P_1(X_2 = 3) &= \sum_{k \in S} p_{1k} p_{k3} = p_{11}p_{13} + p_{12}p_{23} + p_{13}p_{33} \\ &= (0)(1/2) + (1/2)(1/3) + (1/2)(1/2) = 1/6 + 1/4 = 5/12. \end{aligned}$$

Por indução (ver o Problema 11.2.18), obtemos o seguinte.

Teorema 11.2.4

Temos

$$P_i(X_n = j) = \sum_{i_1, i_2, \ldots, i_{n-1} \in S} p_{ii_1} p_{i_1 i_2} p_{i_2 i_3} \cdots p_{i_{n-2} i_{n-1}} p_{i_{n-1} j}.$$

Demonstração. Ver o Problema 11.2.18. ■

Assim, o Teorema 11.2.4 dá uma fórmula completa para a probabilidade de que, começando num estado i no instante 0, a cadeia esteja em algum outro estado j no instante n. Vemos pelo Teorema 11.2.4 que, uma vez conhecidas as probabilidades de transição p_{ij} para todos os $i, j \in S$, podemos calcular os valores de $P_i(X_n = j)$ para todos os $i, j \in S$ e todos os inteiros positivos n. (Mas as contas ficam bem trabalhosas!) As quantidades $P_i(X_n = j)$ são às vezes chamadas de *probabilidades de transição de ordem superior*.

Vejamos uma aplicação disso.

Exemplo 11.2.12

Considere mais uma vez a cadeia com $S = \{1, 2, 3\}$ e

$$(p_{ij}) = \begin{pmatrix} 0 & 1/2 & 1/2 \\ 1/3 & 1/3 & 1/3 \\ 1/4 & 1/4 & 1/2 \end{pmatrix}.$$

Então*

$$\begin{aligned} P_1(X_3 = 3) &= \sum_{k\in S}\sum_{\ell\in S} p_{1k}p_{k\ell}p_{\ell 3} \\ &= p_{11}p_{11}p_{13} + p_{11}p_{12}p_{23} + p_{11}p_{13}p_{33} + p_{12}p_{21}p_{13} + p_{12}p_{22}p_{23} \\ &\quad + p_{12}p_{23}p_{33} + p_{13}p_{31}p_{13} + p_{13}p_{32}p_{23} + p_{13}p_{33}p_{33} \\ &= (0)(0)(1/2) + (0)(1/2)(1/3) + (0)(1/2)(1/2) + (1/2)(1/3)(1/2) \\ &\quad + (1/2)(1/3)(1/3) + (1/2)(1/4)(1/2) + (1/2)(1/4)(1/2) \\ &\quad + (1/2)(1/4)(1/3) + (1/2)(1/2)(1/2) \\ &= 31/72. \end{aligned}$$

■

Por fim, observamos que, se escrevemos A para a matriz (p_{ij}), v_0 para o vetor linha $(\mu_i) = (P(X_0 = i))$ e v_1 para o vetor linha $(P(X_1 = i))$, então o Teorema 11.2.1 pode ser escrito de forma sucinta, com multiplicação de matrizes, como $v_1 = v_0A$. Isto é, o vetor (linha) de probabilidades da cadeia após um passo, v_1, é igual ao vetor (linha) de probabilidades da cadeia após zero passos, v_0, *multiplicado* pela matriz A de probabilidades de transição. Na verdade, se escrevemos v_n para o vetor linha $(P(X_n = i))$, então, prosseguindo por indução, vemos que $v_{n+1} = v_nA$ para cada n. Portanto, $v_n = v_0A^n$, em que A^n é a n-ésima *potência* da matriz A. Nesse contexto, o Teorema 11.2.4 tem uma interpretação particularmente bonita. Ele diz que $P_i(X_n = j)$ é igual à entrada (i, j) da matriz A^n, isto é, a n-ésima potência da matriz A.

11.2.3 Distribuições Estacionárias

Suponha que temos probabilidades de transição $\{p_{ij}\}$ de uma cadeia de Markov num espaço de estados S. Seja $\{\pi_i : i \in S\}$ uma distribuição de probabilidade em S, de modo que $\pi_i \geq 0$ para todo i e $\sum_{i\in S} \pi_i = 1$. Temos a seguinte definição.

*Nota do tradutor. no sexto produto numérico, o original traz $(1/2)(1/4)(1/2)$ para $p_{12}p_{23}p_{33}$; pela matriz seria $(1/2)(1/3)(1/2)$, e o resultado seria $65/144$ (a entrada $(1, 3)$ de A^3), não $31/72$

Definição 11.2.1

A distribuição $\{\pi_i : i \in S\}$ é *estacionária* para uma cadeia de Markov com probabilidades de transição $\{p_{ij}\}$ num espaço de estados S se $\sum_{i \in S} \pi_i p_{ij} = \pi_j$ para todo $j \in S$.

O motivo do termo "estacionária" é que, se a cadeia começa com essas probabilidades, então ela terá *sempre* essas mesmas probabilidades, como mostram o teorema e o corolário a seguir.

Teorema 11.2.5

Suponha que $\{\pi_i : i \in S\}$ seja uma distribuição estacionária para uma cadeia de Markov com probabilidades de transição $\{p_{ij}\}$ num espaço de estados S. Suponha que, para algum inteiro n, tenhamos $P(X_n = i) = \pi_i$ para todo $i \in S$. Então também temos $P(X_{n+1} = i) = \pi_i$ para todo $i \in S$.

Demonstração. Se $\{\pi_i\}$ é estacionária, então calculamos que

$$\begin{aligned} P(X_{n+1} = j) &= \sum_{i \in S} P(X_n = i, X_{n+1} = j) \\ &= \sum_{i \in S} P(X_n = i)\, P(X_{n+1} = j \mid X_n = i) = \sum_{i \in S} \pi_i\, p_{ij} = \pi_j. \end{aligned}$$

■

Por indução, obtemos o corolário a seguir.

Corolário 11.2.1

Suponha que $\{\pi_i : i \in S\}$ seja uma distribuição estacionária para uma cadeia de Markov com probabilidades de transição $\{p_{ij}\}$ num espaço de estados S. Suponha que, para algum inteiro n, tenhamos $P(X_n = i) = \pi_i$ para todo $i \in S$. Então também temos $P(X_m = i) = \pi_i$ para todo $i \in S$ e todo inteiro $m > n$.

O teorema e o corolário acima dizem que, uma vez que a cadeia de Markov esteja na sua distribuição estacionária[13], ela permanecerá na sua distribuição estacionária para sempre.

No original: *stationary distribution*[13].

Exemplo 11.2.13

Considere a cadeia de Markov com $S = \{1, 2, 3\}$ e

$$(p_{ij}) = \begin{pmatrix} 1/2 & 1/4 & 1/4 \\ 1/2 & 1/4 & 1/4 \\ 1/2 & 1/4 & 1/4 \end{pmatrix}.$$

Não importa onde esteja, essa cadeia de Markov sempre salta com as mesmas probabilidades, isto é, para o estado 1 com probabilidade 1/2, para o estado 2 com probabilidade 1/4 ou para o estado 3 com probabilidade 1/4.

De fato, se tomarmos $\pi_1 = 1/2$, $\pi_2 = 1/4$ e $\pi_3 = 1/4$, vemos que $p_{ij} = \pi_j$ para todos $i, j \in S$. Logo,

$$\sum_{i \in S} \pi_i p_{ij} = \sum_{i \in S} \pi_i \pi_j = \pi_j \sum_{i \in S} \pi_i = \pi_j(1) = \pi_j.$$

Assim, $\{\pi_i\}$ é uma distribuição estacionária. Portanto, uma vez na distribuição $\{\pi_i\}$, a cadeia permanecerá na distribuição $\{\pi_i\}$ para sempre. ■

Exemplo 11.2.14

Considere uma cadeia de Markov com $S = \{0, 1\}$ e

$$(p_{ij}) = \begin{pmatrix} 0{,}1 & 0{,}9 \\ 0{,}6 & 0{,}4 \end{pmatrix}.$$

Se essa cadeia tivesse uma distribuição estacionária $\{\pi_i\}$, deveríamos ter

$$\pi_0(0{,}1) + \pi_1(0{,}6) = \pi_0,$$
$$\pi_0(0{,}9) + \pi_1(0{,}4) = \pi_1.$$

A primeira equação dá $\pi_1(0{,}6) = \pi_0(0{,}9)$, de modo que $\pi_1 = (3/2)(\pi_0)$. Isso também é compatível com a segunda equação. Além disso, exigimos que $\pi_0 + \pi_1 = 1$, isto é, que $\pi_0 + (3/2)\pi_0 = 1$, de modo que $\pi_0 = 2/5$. Então $\pi_1 = (3/2)(2/5) = 3/5$.

Verificamos então que os valores $\pi_0 = 2/5$ e $\pi_1 = 3/5$ satisfazem as equações acima. Logo, $\{\pi_i\}$ é de fato uma distribuição estacionária para essa cadeia de Markov. ■

Exemplo 11.2.15

Considere agora a cadeia de Markov com $S = \{1, 2, 3\}$ e

$$(p_{ij}) = \begin{pmatrix} 0 & 1/2 & 1/2 \\ 1/2 & 0 & 1/2 \\ 1/2 & 1/2 & 0 \end{pmatrix}.$$

Vemos que essa cadeia de Markov tem a propriedade de que, além de valer $\sum_{j \in S} p_{ij} = 1$ para todo i, vale também $\sum_{i \in S} p_{ij} = 1$ para todo j. Isto é, não só as *linhas* da matriz (p_{ij}) somam 1, mas também as *colunas*. (Uma matriz assim às vezes é chamada de *duplamente estocástica*.)

Seja $\pi_1 = \pi_2 = \pi_3 = 1/3$, de modo que $\{\pi_i\}$ é a distribuição uniforme em S. Então calculamos que

$$\sum_{i \in S} \pi_i p_{ij} = \sum_{i \in S} (1/3) p_{ij} = (1/3) \sum_{i \in S} p_{ij} = (1/3)(1) = \pi_j.$$

Como isso vale para todo j, vemos que $\{\pi_i\}$ é uma distribuição estacionária para essa cadeia de Markov. ■

Exemplo 11.2.16

Considere a cadeia de Markov com $S = \{1, 2, 3\}$ e

$$(p_{ij}) = \begin{pmatrix} 1/2 & 1/4 & 1/4 \\ 1/3 & 1/3 & 1/3 \\ 0 & 1/4 & 3/4 \end{pmatrix}.$$

Essa cadeia de Markov tem uma distribuição estacionária?

Bem, se ela tivesse uma distribuição estacionária $\{\pi_i\}$, as seguintes equações teriam de ser satisfeitas:

$$\begin{aligned} \pi_1 &= (1/2)\pi_1 + (1/3)\pi_2 + (0)\pi_3, \\ \pi_2 &= (1/4)\pi_1 + (1/3)\pi_2 + (1/4)\pi_3, \\ \pi_3 &= (1/4)\pi_1 + (1/3)\pi_2 + (3/4)\pi_3. \end{aligned}$$

A primeira equação dá $\pi_1 = (2/3)\pi_2$. A segunda equação dá então

$$\begin{aligned} (1/4)\pi_3 &= \pi_2 - (1/4)\pi_1 - (1/3)\pi_2 \\ &= \pi_2 - (1/4)(2/3)\pi_2 - (1/3)\pi_2 = (1/2)\pi_2, \end{aligned}$$

de modo que $\pi_3 = 2\pi_2$.

Mas também exigimos que $\pi_1 + \pi_2 + \pi_3 = 1$, isto é, $(2/3)\pi_2 + \pi_2 + 2\pi_2 = 1$, de modo que $\pi_2 = 3/11$. Então $\pi_1 = 2/11$ e $\pi_3 = 6/11$.

Verifica-se então facilmente que a distribuição dada por $\pi_1 = 2/11$, $\pi_2 = 3/11$ e $\pi_3 = 6/11$ satisfaz as equações anteriores; portanto, ela é de fato uma distribuição estacionária para essa cadeia de Markov. ■

Exemplo 11.2.17

Considere novamente o passeio aleatório no círculo, como no Exemplo 11.2.6. Observamos que, para qualquer estado j, há exatamente três estados i (a saber, o estado $i = j$, o estado uma posição no sentido horário a partir de j e o estado uma posição no sentido anti-horário a partir de j) com $p_{ij} = 1/3$. Logo, $\sum_{i \in S} p_{ij} = 1$. Isto é, a matriz de transição (p_{ij}) é de novo duplamente estocástica.

Segue então, exatamente como no Exemplo 11.2.15, que a distribuição uniforme, dada por $\pi_i = 1/d$ para $i = 0, 1, \ldots, d-1$, é uma distribuição estacionária para essa cadeia de Markov. ■

Exemplo 11.2.18

Para a urna de Ehrenfest (veja o Exemplo 11.2.7), não é óbvio qual poderia ser uma distribuição estacionária. No entanto, uma possível solução aparece quando pensamos em cada bola *individualmente*. De fato, uma bola qualquer em geral fica parada, mas de vez em quando é trocada de uma urna para a outra. Assim, parece razoável que, na estacionariedade, ela tenha a mesma chance de estar em qualquer das duas urnas, isto é, que tenha probabilidade $1/2$ de estar na urna nº 1.

Se for assim, então o número total de bolas na urna nº 1 teria a distribuição Binomial$(n, 1/2)$, já que haveria n bolas, cada uma com probabilidade $1/2$ de estar na urna nº 1.*

Para testar isso, tomamos $\pi_i = \binom{d}{i}/2^d$, para $i = 0, 1, \ldots, d$. Calculamos então que, se $1 \leq j \leq d-1$,

$$\begin{aligned}\sum_{i\in S} \pi_i p_{ij} &= \pi_{j-1} p_{j-1,j} + \pi_{j+1} p_{j+1,j} \\ &= \binom{d}{j-1}\frac{1}{2^d}\frac{d-(j-1)}{d} + \binom{d}{j+1}\frac{1}{2^d}\frac{j+1}{d} \\ &= \binom{d-1}{j-1}\frac{1}{2^d} + \binom{d-1}{j}\frac{1}{2^d}.\end{aligned}$$

Em seguida, usamos a identidade conhecida como *triângulo de Pascal*, que diz que

$$\binom{d-1}{j-1} + \binom{d-1}{j} = \binom{d}{j}.$$

Logo, concluímos que

$$\sum_{i\in S} \pi_i p_{ij} = \binom{d}{j}\frac{1}{2^d} = \pi_j.$$

Com pequenas modificações (veja o Problema 11.2.19), o argumento anterior vale também para $j = 0$ e $j = d$. Concluímos, portanto, que $\sum_{i\in S} \pi_i p_{ij} = \pi_j$ para todo $j \in S$. Logo, $\{\pi_i\}$ é uma distribuição estacionária. ■

Uma maneira fácil de verificar a estacionariedade é a seguinte.

*Nota do tradutor. O original traz n aqui e na frase anterior; pelo Exemplo 11.2.7 e pela conta a seguir, o número de bolas é d.

Definição 11.2.2

Diz-se que uma cadeia de Markov é *reversível* em relação a uma distribuição $\{\pi_i\}$ se, para todos $i, j \in S$, temos $\pi_i p_{ij} = \pi_j p_{ji}$.

Teorema 11.2.6

Se uma cadeia de Markov é reversível em relação a $\{\pi_i\}$, então $\{\pi_i\}$ é uma distribuição estacionária para a cadeia.

Demonstração. Calculamos, usando a reversibilidade, que, para qualquer $j \in S$,

$$\sum_{i \in S} \pi_i p_{ij} = \sum_{i \in S} \pi_j p_{ji} = \pi_j \sum_{i \in S} p_{ji} = \pi_j(1) = \pi_j.$$

Logo, $\{\pi_i\}$ é uma distribuição estacionária. ■

Exemplo 11.2.19

Suponha que $S = \{1, 2, 3, 4, 5\}$ e que as probabilidades de transição sejam dadas por

$$(p_{ij}) = \begin{pmatrix} 1/3 & 2/3 & 0 & 0 & 0 \\ 1/3 & 0 & 2/3 & 0 & 0 \\ 0 & 1/3 & 0 & 2/3 & 0 \\ 0 & 0 & 1/3 & 0 & 2/3 \\ 0 & 0 & 0 & 1/3 & 2/3 \end{pmatrix}.$$

Não é imediatamente claro que distribuição estacionária essa cadeia possa ter. Além disso, calcular diretamente, como no Exemplo 11.2.16, seria bem trabalhoso.

Por outro lado, observamos que, para $1 \leq i \leq 4$, sempre temos $p_{i,i+1} = 2\, p_{i+1,i}$. Logo, se tomarmos $\pi_i = C2^i$ para algum $C > 0$, teremos

$$\pi_i p_{i,i+1} = C2^i p_{i,i+1} = C2^i 2\, p_{i+1,i},$$

enquanto

$$\pi_{i+1} p_{i+1,i} = C2^{i+1} p_{i+1,i}.$$

Logo, $\pi_i p_{i,i+1} = \pi_{i+1} p_{i+1,i}$ para cada i.

Além disso, $p_{ij} = 0$ se i e j diferem por pelo menos 2. Segue que $\pi_i p_{ij} = \pi_j p_{ji}$ para cada $i, j \in S$. Logo, a cadeia é reversível em relação a $\{\pi_i\}$ e, portanto, $\{\pi_i\}$ é uma distribuição estacionária para a cadeia.

Por fim, determinamos C. Precisamos de $\sum_{i \in S} \pi_i = 1$. Logo, devemos ter* $C = 1 \big/ \sum_{i \in S} 2^i = 1 \big/ \sum_{i=1}^{5} 2^i = 1/63$. Assim, $\pi_i = 2^i/63$ para $i \in S$. ■

11.2.4 Teorema Limite para Cadeias de Markov

Suponha agora que $\{X_n\}$ seja uma cadeia de Markov que tem uma distribuição estacionária $\{\pi_i\}$. Já vimos que, se $P(X_n = i) = \pi_i$ para todo i, para algum n, então também $P(X_m = i) = \pi_i$ para todo i, para todo $m > n$.

Suponha agora que *não* valha $P(X_n = i) = \pi_i$ para todo i. Ainda assim, poderíamos esperar que, se a cadeia for executada por muito tempo (isto é, $n \to \infty$), a probabilidade de estar num estado particular $i \in S$ convirja para π_i,

*Nota do tradutor. O original traz 1/63; pela conta, $\sum_{i=1}^{5} 2^i = 62$, o que daria $C = 1/62$ e $\pi_i = 2^i/62$.

qualquer que seja o estado inicial escolhido. Isto é, poderíamos esperar que

$$\lim_{n\to\infty} P(X_n = i) = \pi_i, \tag{11.2.1}$$

para cada $i \in S$, qualquer que seja a distribuição inicial $\{\mu_i\}$.

Isso não é verdade em toda a generalidade, como mostram os dois exemplos a seguir. No entanto, veremos no Teorema 11.2.8 que isso de fato vale para a maioria das cadeias de Markov.

Exemplo 11.2.20

Suponha que $S = \{1, 2\}$ e que as probabilidades de transição sejam dadas por

$$(p_{ij}) = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}.$$

Isto é, essa cadeia de Markov nunca sai do lugar! Suponha também que $\mu_1 = 1$, isto é, que sempre temos $X_0 = 1$.

Nesse caso, *qualquer* distribuição é estacionária para essa cadeia. Em particular, podemos tomar $\pi_1 = \pi_2 = 1/2$ como distribuição estacionária. Por outro lado, claramente temos $P_1(X_n = 1) = 1$ para todo n. Como $\pi_1 = 1/2$ e $1 \neq 1/2$, *não* temos $\lim_{n\to\infty} P(X_n = i) = \pi_i$ nesse caso.

Veremos mais adiante que essa cadeia de Markov não é "irredutível", e é isso que impede a convergência. ■

Exemplo 11.2.21

Suponha de novo que $S = \{1, 2\}$, mas que desta vez as probabilidades de transição sejam dadas por

$$(p_{ij}) = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}.$$

Isto é, essa cadeia de Markov sempre passa de 1 para 2 e de 2 para 1. Suponha de novo que $\mu_1 = 1$, isto é, que sempre temos $X_0 = 1$.

Podemos de novo tomar $\pi_1 = \pi_2 = 1/2$ como distribuição estacionária (na verdade, desta vez a distribuição estacionária é única). Por outro lado, desta vez claramente temos $P_1(X_n = 1) = 1$ para n par e $P_1(X_n = 1) = 0$ para n ímpar. Logo, de novo *não* temos $\lim_{n\to\infty} P_1(X_n = 1) \to \pi_1 = 1/2$.

Veremos que aqui o que impede a convergência é que a cadeia de Markov é "periódica", com período 2. ■

À luz desses exemplos, fazemos algumas definições.

Definição 11.2.3

Uma cadeia de Markov é *irredutível* se for possível para a cadeia ir de qualquer estado para qualquer outro estado. De modo equivalente, a cadeia de Markov é irredutível se, para quaisquer $i, j \in S$, existe um inteiro positivo n com $P_i(X_n = j) > 0$.

Assim, a cadeia de Markov do Exemplo 11.2.20 não é irredutível[14], porque não é possível ir do estado 1 para o estado 2. De fato, nesse caso, $P_1(X_n = 2) = 0$ para todo n.

No original: *irreducible*[14].

Exemplo 11.2.22

Considere a cadeia de Markov com $S = \{1, 2, 3\}$ e

$$(p_{ij}) = \begin{pmatrix} 1/2 & 1/2 & 0 \\ 1/2 & 1/4 & 1/4 \\ 1/2 & 1/4 & 1/4 \end{pmatrix}.$$

Para essa cadeia, não é possível ir do estado 1 para o estado 3 em um passo. Por outro lado, é possível ir do estado 1 para o estado 2 e depois do estado 2 para o estado 3. Logo, essa cadeia ainda é irredutível. ■

Exemplo 11.2.23

Considere a cadeia de Markov com $S = \{1, 2, 3\}$ e

$$(p_{ij}) = \begin{pmatrix} 1/2 & 1/2 & 0 \\ 3/4 & 1/4 & 0 \\ 1/2 & 1/4 & 1/4 \end{pmatrix}.$$

Para essa cadeia, não é possível ir do estado 1 para o estado 3 em um passo. Além disso, também não é possível ir do estado 2 para o estado 3. Na verdade, não há como *jamais* ir do estado 1 para o estado 3, em qualquer número de passos. Logo, essa cadeia *não* é irredutível. ■

Claramente, se uma cadeia de Markov não é irredutível, então a convergência da cadeia de Markov (11.2.1) nem sempre valerá, porque será impossível chegar a certos estados da cadeia.

Precisamos também da definição a seguir.

Definição 11.2.4

Dadas transições $\{p_{ij}\}$ de uma cadeia de Markov num espaço de estados S e um estado $i \in S$, o *período* de i é o máximo divisor comum (m.d.c.) do conjunto $\{n \geq 1 : p_{ii}^{(n)} > 0\}$, em que $p_{ii}^{(n)} = P(X_n = i \mid X_0 = i)$.

Isto é, o período de i é o m.d.c. dos tempos em que é possível ir de i a i. Por exemplo, o período de i é 2 se só for possível ir de i a i num número par de passos. (Era o caso do Exemplo 11.2.21.) Por outro lado, se $p_{ii} > 0$, então claramente o período de i é 1.

Claramente, se o período de algum estado é maior que 1, então, de novo, (11.2.1) nem sempre valerá, porque a cadeia só conseguirá alcançar certos estados em

certos instantes. Isso motiva a definição a seguir.

Definição 11.2.5

Uma cadeia de Markov é *aperiódica* se o período de cada estado é igual a 1.

Exemplo 11.2.24

Considere a cadeia de Markov com $S = \{1, 2, 3\}$ e

$$(p_{ij}) = \begin{pmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{pmatrix}.$$

Para essa cadeia, a partir do estado 1 só é possível ir para o estado 2. E a partir do estado 2 só é possível ir para o estado 3. Depois, a partir do estado 3 só é possível ir para o estado 1. Logo, só é possível voltar ao estado 1 após um múltiplo inteiro de 3 passos. Logo, o estado 1 (e, na verdade, todos os três estados) tem período igual a 3, e a cadeia *não* é aperiódica. ■

Exemplo 11.2.25

Considere a cadeia de Markov com $S = \{1, 2, 3\}$ e

$$(p_{ij}) = \begin{pmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1/2 & 0 & 1/2 \end{pmatrix}.$$

Para essa cadeia, a partir do estado 1 só é possível ir para o estado 2. E a partir do estado 2 só é possível ir para o estado 3. No entanto, a partir do estado 3 é possível ir para o estado 1 ou para o estado 3. Logo, é possível voltar ao estado 1 após 3 ou 4 passos. Como o m.d.c. de 3 e 4 é 1, concluímos que o período do estado 1 (e, na verdade, de todos os três estados) é igual a 1, e a cadeia é de fato aperiódica. ■

Registramos o seguinte fato simples.

Teorema 11.2.7

Se uma cadeia de Markov tem $p_{ij} > 0$ para todos $i, j \in S$, então a cadeia é irredutível e aperiódica.

Demonstração. Se $p_{ij} > 0$ para todos $i, j \in S$, então $P_i(X_1 = j) > 0$ para todos $i, j \in S$. Logo, a cadeia de Markov tem de ser irredutível.

Além disso, se $p_{ij} > 0$ para todos $i, j \in S$, então o conjunto $\{n \geq 1 : p_{ii}^{(n)} > 0\}$ contém o valor $n = 1$ (e, na verdade, todos os inteiros positivos n). Logo, seu máximo divisor comum tem de ser 1. Portanto, cada estado i tem período 1, e a cadeia é aperiódica[15]. ■

Em termos das definições anteriores, temos o seguinte teorema, muito importante, sobre a convergência de cadeias de Markov.

Teorema 11.2.8

Suponha que uma cadeia de Markov seja irredutível e aperiódica e tenha uma distribuição estacionária $\{\pi_i\}$. Então, qualquer que seja a distribuição inicial $\{\mu_i\}$, temos $\lim_{n\to\infty} P(X_n = i) = \pi_i$ para todos os estados i.

Demonstração. Para uma demonstração, veja livros de probabilidade mais avançados, por exemplo, as páginas 92–93 de *A First Look at Rigorous Probability Theory*, 2ª ed., de J. S. Rosenthal (World Scientific Publishing, Singapura, 2006). ■

O Teorema 11.2.8 mostra que as distribuições estacionárias são ainda mais importantes. Não só uma cadeia de Markov permanece numa distribuição estacionária quando chega a ela, como também, para a maioria das cadeias (as irredutíveis e aperiódicas), as probabilidades *convergem* para a distribuição estacionária de qualquer modo. Logo, a distribuição estacionária fornece informação fundamental sobre o comportamento de longo prazo da cadeia de Markov.

No original: *aperiodic*[15].

Exemplo 11.2.26

Considere novamente a cadeia de Markov com $S = \{1, 2, 3\}$ e

$$(p_{ij}) = \begin{pmatrix} 1/2 & 1/4 & 1/4 \\ 1/2 & 1/4 & 1/4 \\ 1/2 & 1/4 & 1/4 \end{pmatrix}.$$

Já vimos que, se tomarmos $\pi_1 = 1/2$, $\pi_2 = 1/4$ e $\pi_3 = 1/4$, então $\{\pi_i\}$ é uma distribuição estacionária. Além disso, vemos que $p_{ij} > 0$ para todos $i, j \in S$; assim, pelo Teorema 11.2.7, a cadeia de Markov tem de ser irredutível e aperiódica.

Concluímos que $\lim_{n\to\infty} P(X_n = i) = \pi_i$ para todos os estados i. Por exemplo, $\lim_{n\to\infty} P(X_n = 1) = 1/2$. (Além disso, esse limite não depende da distribuição inicial; assim, por exemplo, também $\lim_{n\to\infty} P_1(X_n = 1) = 1/2$ e $\lim_{n\to\infty} P_2(X_n = 1) = 1/2$.)

Na verdade, neste exemplo teremos $P(X_n = i) = \pi_i$ para todo i desde que $n \geq 1$. ■

Exemplo 11.2.27

Considere novamente a cadeia de Markov do Exemplo 11.2.14, com $S = \{0, 1\}$ e

$$(p_{ij}) = \begin{pmatrix} 0{,}1 & 0{,}9 \\ 0{,}6 & 0{,}4 \end{pmatrix}.$$

Já vimos que essa cadeia de Markov tem uma distribuição estacionária, dada por $\pi_0 = 2/5$ e $\pi_1 = 3/5$.

Além disso, como $p_{ij} > 0$ para todos $i, j \in S$, essa cadeia de Markov é irredutível e aperiódica. Portanto, concluímos que $\lim_{n\to\infty} P(X_n = i) = \pi_i$. Assim, se (digamos) $n = 100$, teremos $P(X_{100} = 0) \approx 2/5$ e $P(X_{100} = 1) \approx 3/5$. Mais uma vez, essa conclusão não depende da distribuição inicial; assim, por exemplo, também $\lim_{n\to\infty} P_0(X_n = i) = \lim_{n\to\infty} P_1(X_n = i) = \pi_i$. ■

Exemplo 11.2.28

Considere novamente a cadeia de Markov do Exemplo 11.2.16, com $S = \{1, 2, 3\}$ e

$$(p_{ij}) = \begin{pmatrix} 1/2 & 1/4 & 1/4 \\ 1/3 & 1/3 & 1/3 \\ 0 & 1/4 & 3/4 \end{pmatrix}.$$

Já vimos que essa cadeia tem uma distribuição estacionária $\{\pi_i\}$ dada por $\pi_1 = 2/11$, $\pi_2 = 3/11$ e $\pi_3 = 6/11$.

Neste caso, não temos $p_{ij} > 0$ para todos $i, j \in S$, porque $p_{31} = 0$. Por outro lado, $p_{32} > 0$ e $p_{21} > 0$; assim, pelo Teorema 11.2.3, temos

$$P_3(X_2 = 1) = \sum_{k \in S} p_{3k} p_{k1} \geq p_{32} p_{21} > 0.$$

Logo, a cadeia ainda é irredutível.

Da mesma forma, temos $P_3(X_2 = 3) \geq p_{32} p_{23} > 0$ e $P_3(X_3 = 3) \geq p_{32} p_{21} p_{13} > 0$. Portanto, como o m.d.c. de 2 e 3 é 1, vemos que o m.d.c. do conjunto dos n com $P_3(X_n = 3) > 0$ também é 1. Logo, a cadeia ainda é aperiódica.

Como a cadeia é irredutível e aperiódica, segue do Teorema 11.2.8 que $\lim_{n\to\infty} P(X_n = i) = \pi_i$ para todos os estados i. Logo, $\lim_{n\to\infty} P(X_n = 1) = 2/11$, $\lim_{n\to\infty} P(X_n = 2) = 3/11$ e $\lim_{n\to\infty} P(X_n = 3) = 6/11$. Assim, se (digamos) $n = 500$, esperamos que $P(X_{500} = 1) \approx 2/11$, $P(X_{500} = 2) \approx 3/11$ e $P(X_{500} = 3) \approx 6/11$. ■

Resumo da Seção 11.2

- Uma cadeia de Markov é uma sequência $\{X_n\}$ de variáveis aleatórias, com probabilidades de transição $\{p_{ij}\}$ tais que $P(X_{n+1} = j \mid X_n = i) = p_{ij}$, e com uma distribuição inicial $\{\mu_i\}$ tal que $P(X_0 = i) = \mu_i$.
- Há muitos exemplos diferentes de cadeias de Markov.
- Todas as probabilidades de todos os X_n podem ser calculadas em termos de $\{\mu_i\}$ e $\{p_{ij}\}$.
- Uma distribuição $\{\pi_i\}$ é estacionária para a cadeia se $\sum_{i \in S} \pi_i p_{ij} = \pi_j$ para todo $j \in S$.
- Se a cadeia de Markov é irredutível e aperiódica e $\{\pi_i\}$ é estacionária, então $\lim_{n\to\infty} P(X_n = i) = \pi_i$ para todo $i \in S$.

Exercícios

11.2.1 Considere uma cadeia de Markov com $S = \{1, 2, 3\}$, $\mu_1 = 0{,}7$, $\mu_2 = 0{,}1$, $\mu_3 = 0{,}2$ e

$$(p_{ij}) = \begin{pmatrix} 1/4 & 1/4 & 1/2 \\ 1/6 & 1/2 & 1/3 \\ 1/8 & 3/8 & 1/2 \end{pmatrix}.$$

Calcule as quantidades a seguir.

(a) $P(X_0 = 1)$

(b) $P(X_0 = 2)$

(c) $P(X_0 = 3)$

(d) $P(X_1 = 2 \mid X_0 = 1)$

(e) $P(X_3 = 2 \mid X_2 = 1)$

(f) $P(X_1 = 2 \mid X_0 = 2)$

(g) $P(X_1 = 2)$.

11.2.2 Considere uma cadeia de Markov com $S = \{\text{alto}, \text{baixo}\}$, $\mu_{\text{alto}} = 1/3$, $\mu_{\text{baixo}} = 2/3$ e

$$(p_{ij}) = \begin{pmatrix} 1/4 & 3/4 \\ 1/6 & 5/6 \end{pmatrix}.$$

Calcule as quantidades a seguir.

(a) $P(X_0 = \text{alto})$

(b) $P(X_0 = \text{baixo})$

(c) $P(X_1 = \text{alto} \mid X_0 = \text{alto})$

(d) $P(X_3 = \text{alto} \mid X_2 = \text{baixo})$

(e) $P(X_1 = \text{alto})$

11.2.3 Considere uma cadeia de Markov com $S = \{0, 1\}$ e

$$(p_{ij}) = \begin{pmatrix} 0{,}2 & 0{,}8 \\ 0{,}3 & 0{,}7 \end{pmatrix}.$$

(a) Calcule $P_i(X_2 = j)$ para as quatro combinações de $i, j \in S$.

(b) Calcule $P_0(X_3 = 1)$.

11.2.4 Considere novamente a cadeia de Markov com $S = \{0, 1\}$ e

$$(p_{ij}) = \begin{pmatrix} 0{,}2 & 0{,}8 \\ 0{,}3 & 0{,}7 \end{pmatrix}.$$

(a) Calcule uma distribuição estacionária $\{\pi_i\}$ para essa cadeia.

(b) Calcule $\lim_{n\to\infty} P_0(X_n = 0)$.

(c) Calcule $\lim_{n\to\infty} P_1(X_n = 0)$.

11.2.5 Considere a cadeia de Markov do Exemplo 11.2.5, com $S = \{1, 2, 3, 4, 5, 6, 7\}$ e

$$(p_{ij}) = \begin{pmatrix} 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 1/2 & 0 & 1/2 & 0 & 0 & 0 & 0 \\ 0 & 1/5 & 4/5 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1/3 & 1/3 & 1/3 & 0 & 0 \\ 1/10 & 0 & 0 & 0 & 7/10 & 0 & 1/5 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 & 0 & 1 & 0 \end{pmatrix}.$$

Calcule as quantidades a seguir.

(a) $P_2(X_1 = 1)$

(b) $P_2(X_1 = 2)$

(c) $P_2(X_1 = 3)$

(d) $P_2(X_2 = 1)$

(e) $P_2(X_2 = 2)$

(f) $P_2(X_2 = 3)$

(g) $P_2(X_3 = 3)$

(h) $P_2(X_3 = 1)$

(i) $P_2(X_1 = 7)$

(j) $P_2(X_2 = 7)$

(k) $P_2(X_3 = 7)$

(l) $\max_n P_2(X_n = 7)$ (isto é, a maior probabilidade de ir do estado 2 para o estado 7 em n passos, para qualquer n)

(m) Essa cadeia de Markov é irredutível?

11.2.6 Para cada uma das matrizes de probabilidades de transição a seguir, determine (com explicação) se ela é irredutível e se é aperiódica.

(a)
$$(p_{ij}) = \begin{pmatrix} 0{,}2 & 0{,}8 \\ 0{,}3 & 0{,}7 \end{pmatrix}$$

(b)
$$(p_{ij}) = \begin{pmatrix} 1/4 & 1/4 & 1/2 \\ 1/6 & 1/2 & 1/3 \\ 1/8 & 3/8 & 1/2 \end{pmatrix}$$

(c)
$$(p_{ij}) = \begin{pmatrix} 0 & 1 \\ 0{,}3 & 0{,}7 \end{pmatrix}$$

(d)
$$(p_{ij}) = \begin{pmatrix} 0 & 1 & 0 \\ 1/3 & 1/3 & 1/3 \\ 0 & 1 & 0 \end{pmatrix}$$

(e)
$$(p_{ij}) = \begin{pmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{pmatrix}$$

(f)
$$(p_{ij}) = \begin{pmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1/2 & 0 & 1/2 \end{pmatrix}$$

11.2.7 Calcule uma distribuição estacionária para a cadeia de Markov do Exemplo 11.2.4. (Sugestão: não se esqueça do Exemplo 11.2.15.)

11.2.8 Mostre que o processo do passeio aleatório no círculo (veja o Exemplo 11.2.6) é

(a) irredutível.

(b) aperiódico.

(c) reversível[16] em relação à sua distribuição estacionária.

11.2.9 Mostre que o processo da urna de Ehrenfest (veja o Exemplo 11.2.7) é

No original: *reversible*[16].

(a) irredutível.

(b) *não* aperiódico.

(c) reversível em relação à sua distribuição estacionária.

11.2.10 Considere a cadeia de Markov com $S = \{1, 2, 3\}$ e

$$(p_{ij}) = \begin{pmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1/2 & 1/2 & 0 \end{pmatrix}.$$

(a) Determine (com explicação) se a cadeia é ou não irredutível.

(b) Determine (com explicação) se a cadeia é ou não aperiódica.

(c) Calcule uma distribuição estacionária para a cadeia.

(d) Calcule (com explicação) uma boa aproximação de $P_1(X_{500} = 2)$.

11.2.11 Repita as quatro partes do Exercício 11.2.10 se $S = \{1, 2, 3\}$ e

$$(p_{ij}) = \begin{pmatrix} 0 & 1/2 & 1/2 \\ 0 & 0 & 1 \\ 1/2 & 1/2 & 0 \end{pmatrix}.$$

11.2.12 Considere uma cadeia de Markov com $S = \{1, 2, 3\}$ e

$$(p_{ij}) = \begin{pmatrix} 0{,}3 & 0{,}3 & 0{,}4 \\ 0{,}2 & 0{,}2 & 0{,}6 \\ 0{,}1 & 0{,}2 & 0{,}7 \end{pmatrix}.$$

(a) Essa cadeia de Markov é irredutível e aperiódica? Explique. (Sugestão: não se esqueça do Teorema 11.2.7.)

(b) Calcule $P_1(X_1 = 3)$.

(c) Calcule $P_1(X_2 = 3)$.

(d) Calcule $P_1(X_3 = 3)$.

(e) Calcule $\lim_{n\to\infty} P_1(X_n = 3)$. (Sugestão: encontre uma distribuição estacionária para a cadeia.)

11.2.13 Para a cadeia de Markov do exercício anterior, calcule $P_1(X_1 + X_2 \geq 5)$.

11.2.14 Considere uma cadeia de Markov com $S = \{1, 2, 3\}$ e

$$(p_{ij}) = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{pmatrix}.$$

(a) Calcule o período de cada estado.

(b) Essa cadeia de Markov é aperiódica? Explique.

11.2.15 Considere uma cadeia de Markov com $S = \{1, 2, 3\}$ e

$$(p_{ij}) = \begin{pmatrix} 0 & 1 & 0 \\ 0{,}5 & 0 & 0{,}5 \\ 0 & 1 & 0 \end{pmatrix}.$$

(a) Essa cadeia de Markov é irredutível? Explique.

(b) Essa cadeia de Markov é aperiódica? Explique.

Problemas

11.2.16 Considere uma cadeia de Markov com $S = \{1, 2, 3, 4, 5\}$ e

$$(p_{ij}) = \begin{pmatrix} 1/5 & 4/5 & 0 & 0 & 0 \\ 1/5 & 0 & 4/5 & 0 & 0 \\ 0 & 1/5 & 0 & 4/5 & 0 \\ 0 & 0 & 1/5 & 0 & 4/5 \\ 0 & 0 & 0 & 1/5 & 4/5 \end{pmatrix}.$$

Calcule uma distribuição estacionária $\{\pi_i\}$ para essa cadeia. (Sugestão: use a reversibilidade, como no Exemplo 11.2.19.)

11.2.17 Suponha que 100 vitórias-régias estejam dispostas em círculo, numeradas $0, 1, \ldots, 99$ (com a vitória-régia 99 ao lado da vitória-régia 0). Suponha que um sapo comece na vitória-régia 0 e, a cada segundo, salte uma vitória-régia no sentido horário, salte uma vitória-régia no sentido anti-horário ou fique onde está — cada opção com probabilidade $1/3$. Depois de fazer isso por um mês, qual é a probabilidade aproximada de que o sapo esteja na vitória-régia 55? (Sugestão: o sapo está fazendo um passeio aleatório no círculo, como no Exemplo 11.2.6. Além disso, os resultados do Exemplo 11.2.17 e do Teorema 11.2.8 podem ajudar.)

11.2.18 Demonstre o Teorema 11.2.4. (Sugestão: proceda como na demonstração do Teorema 11.2.3 e use indução.)

11.2.19 No Exemplo 11.2.18, prove que $\sum_{i \in S} \pi_i p_{ij} = \pi_j$ quando $j = 0$ e quando $j = d$.

Tópicos para discussão

11.2.20 Com um grupo, monte a "cadeia de Markov humana" do Exemplo 11.2.9. Faça o maior número possível de observações sobre o comportamento de longo prazo da cadeia de Markov resultante.

11.3 Monte Carlo via Cadeias de Markov

Na Seção 4.5, vimos que é possível estimar diversas quantidades (como propriedades de objetos reais, por meio de experimentação, ou o valor de somas ou integrais complicadas) usando *técnicas de Monte Carlo*, isto é, gerando num computador variáveis aleatórias apropriadas. Além disso, vimos na Seção 2.10 que é bem fácil gerar variáveis aleatórias com certas distribuições especiais. O método de Monte Carlo foi usado várias vezes nos Capítulos 6, 7, 9 e 10 para auxiliar na implementação de diversos métodos estatísticos.

Contudo, para muitas (na verdade, para a maioria das!) distribuições de probabilidade, não há maneira simples e direta de simular (num computador) variáveis aleatórias com essa distribuição. Ilustramos isso com um exemplo.

Exemplo 11.3.1

Seja Z uma variável aleatória que assume valores no conjunto de todos os inteiros, com

$$P(Z = j) = C(j - 1/2)^4 e^{-3|j|} \cos^2(j) \tag{11.3.1}$$

para $j = \ldots, -2, -1, 0, 1, 2, 3, \ldots$, em que $C = 1 \Big/ \sum_{j=-\infty}^{\infty} (j-1/2)^4 e^{-3|j|} \cos^2(j)$. Suponha agora que queremos calcular a quantidade $A = E((Z - 20)^2)$.

Bem, *se* pudéssemos gerar variáveis aleatórias i.i.d. $Y_1, Y_2, \ldots, Y_M$ com a distribuição dada por (11.3.1), para M muito grande, então poderíamos estimar A por

$$A \approx \hat{A} = \frac{1}{M} \sum_{i=1}^{M} (Y_i - 20)^2.$$

Então $\hat{A}$ seria uma *estimativa de Monte Carlo* de A.

O problema, é claro, é que não é fácil gerar variáveis aleatórias Y_i com essa distribuição. Na verdade, não é fácil nem mesmo calcular o valor de C. ■

Surpreendentemente, as dificuldades descritas no Exemplo 11.3.1 às vezes

podem ser resolvidas com cadeias de Markov. Ilustramos essa ideia a seguir.

Exemplo 11.3.2

No contexto do Exemplo 11.3.1, suponha que pudéssemos encontrar uma cadeia de Markov no espaço de estados $S = \{\dots, -2, -1, 0, 1, 2, \dots\}$ de todos os inteiros que fosse irredutível e aperiódica e que tivesse distribuição estacionária dada por $\pi_j = C(j - 1/2)^4 e^{-3|j|} \cos^2(j)$ para $j \in S$.

Se fosse assim, poderíamos rodar a cadeia de Markov por um tempo longo N, obtendo valores aleatórios $X_0, X_1, X_2, \dots, X_N$. Para N suficientemente grande, pelo Teorema 11.2.8, teríamos

$$P(X_N = j) \approx \pi_j = C(j - 1/2)^4 e^{-3|j|} \cos^2(j).$$

Logo, se fizermos $Y_1 = X_N$, teremos $P(Y_1 = j)$ aproximadamente igual a (11.3.1), para todo inteiro j. Isto é, o valor de X_N seria *aproximadamente* tão bom quanto uma verdadeira variável aleatória Y_1 com essa distribuição.

Uma vez gerado o valor de Y_1, poderíamos repetir o processo rodando *novamente* a cadeia de Markov, dessa vez para gerar novos valores aleatórios

$$X_0^{[2]}, X_1^{[2]}, X_2^{[2]}, \dots, X_N^{[2]}$$

(digamos). Teríamos então

$$P(X_N^{[2]} = j) \approx \pi_j = C(j - 1/2)^4 e^{-3|j|} \cos^2(j).$$

Logo, se fizermos $Y_2 = X_N^{[2]}$, teremos $P(Y_2 = j)$ aproximadamente igual a (11.3.1), para todo inteiro j.

Continuando assim, poderíamos gerar valores $Y_1, Y_2, Y_3, \dots, Y_M$ que sejam aproximadamente i.i.d. com a distribuição dada por (11.3.1). Poderíamos então, como antes, estimar A por

$$A \approx \hat{A} = \frac{1}{M} \sum_{i=1}^{M} (Y_i - 20)^2.$$

Dessa vez, a aproximação tem duas fontes de erro. Primeiro, há o erro de Monte Carlo, pois M pode não ser grande o bastante. Segundo, há o erro da cadeia de Markov, pois N pode não ser grande o bastante. Contudo, se M e N forem ambos muito grandes, então $\hat{A}$ será uma boa aproximação de A. ■

Resumimos o método do exemplo anterior no teorema a seguir.

Teorema 11.3.1 (*O método de Monte Carlo via cadeias de Markov*)

Suponha que queremos estimar o valor esperado $A = E(h(Z))$, em que $P(Z = j) = \pi_j$ para $j \in S$, com $P(Z = j) = 0$ para $j \notin S$. Suponha que, para $i = 1, 2, \ldots, M$, possamos gerar valores $X_0^{[i]}, X_1^{[i]}, X_2^{[i]}, \ldots, X_N^{[i]}$ de alguma cadeia de Markov que seja irredutível, aperiódica e tenha $\{\pi_j\}$ como distribuição estacionária. Seja

$$\hat{A} = \frac{1}{M} \sum_{i=1}^{M} h(X_N^{[i]}).$$

Se M e N forem suficientemente grandes, então $A \approx \hat{A}$.

Rodar M cadeias de Markov diferentes é um tanto ineficiente. Em vez disso, quem aplica o método muitas vezes roda uma única cadeia de Markov e tira a média dos diferentes valores da cadeia. Para uma cadeia de Markov irredutível rodada por tempo suficiente, isso também converge para a resposta certa, como afirma o teorema a seguir.

Teorema 11.3.2 (*O método de Monte Carlo via cadeias de Markov com uma única cadeia*)

Suponha que queremos estimar o valor esperado $A = E(h(Z))$, em que $P(Z = j) = \pi_j$ para $j \in S$, com $P(Z = j) = 0$ para $j \notin S$. Suponha que possamos gerar valores $X_0, X_1, X_2, \ldots, X_N$ de alguma cadeia de Markov que seja irredutível, aperiódica e tenha $\{\pi_j\}$ como distribuição estacionária. Para algum inteiro $B \geq 0$, seja

$$\hat{A} = \frac{1}{N - B + 1} \sum_{i=B+1}^{N} h(X_i).$$

Se $N - B$ for suficientemente grande, então $A \approx \hat{A}$.

Aqui, B é o *tempo de aquecimento*[17], cuja finalidade é eliminar a influência do valor inicial X_0 da cadeia. A melhor escolha de B continua controversa entre os estatísticos. Contudo, se o valor inicial X_0 for "razoável", então não há problema em tomar $B = 0$, desde que N seja suficientemente grande. Foi o que se fez, por exemplo, no Exemplo 7.3.2.

Esses teoremas indicam que, se conseguirmos construir uma cadeia de Markov

No original: *burn-in*[17].

que tenha $\{\pi_i\}$ como distribuição estacionária, então poderemos usar essa cadeia de Markov para estimar quantidades associadas a $\{\pi_i\}$. Esse é um truque muito útil, e fez do método de Monte Carlo via cadeias de Markov uma das técnicas mais populares de toda a estatística computacional.

Contudo, para essa técnica ser útil, precisamos ser capazes de construir uma cadeia de Markov que tenha $\{\pi_i\}$ como distribuição estacionária. Isso parece um problema difícil! De fato, se $\{\pi_i\}$ fosse muito *simples*, nem precisaríamos usar Monte Carlo via cadeias de Markov. Mas, se $\{\pi_i\}$ é complicada, como é que vamos conseguir construir uma cadeia de Markov que tenha justamente essa distribuição estacionária?

Notavelmente, esse problema acaba sendo muito mais fácil de resolver do que se poderia esperar. Discutimos agora uma das melhores soluções, o algoritmo de Metropolis–Hastings.

11.3.1 O Algoritmo de Metropolis–Hastings

Suponha que temos uma distribuição de probabilidade $\{\pi_i\}$ num espaço de estados S. Como podemos construir uma cadeia de Markov em S que tenha $\{\pi_i\}$ como distribuição estacionária?

Uma resposta é dada pelo *algoritmo de Metropolis–Hastings*. Ele projeta uma cadeia de Markov que avança em duas etapas. Na primeira etapa, um novo ponto é *proposto* a partir de alguma *distribuição proposta*[18]. Na segunda etapa, o ponto proposto é *aceito* ou *rejeitado*. Se o ponto proposto for aceito, a cadeia de Markov se move para ele. Se for rejeitado, a cadeia de Markov fica onde está. Escolhendo a probabilidade de aceitação[19] na medida certa, acabamos criando uma cadeia de Markov que tem $\{\pi_i\}$ como distribuição estacionária.

Os detalhes do algoritmo são os seguintes. Começamos com um espaço de estados S e uma distribuição de probabilidade $\{\pi_i\}$ em S. Escolhemos então algumas probabilidades de transição (simples) de uma cadeia de Markov $\{q_{ij} : i, j \in S\}$, chamadas de *distribuição proposta*. Assim, exigimos que $q_{ij} \geq 0$ e que $\sum_{j \in S} q_{ij} = 1$ para cada $i \in S$. Contudo, *não* supomos que $\{\pi_i\}$ seja uma distribuição estacionária da cadeia $\{q_{ij}\}$; na verdade, a cadeia $\{q_{ij}\}$ pode nem mesmo *ter* uma distribuição estacionária.

Dado $X_n = i$, o algoritmo de Metropolis–Hastings calcula o valor X_{n+1} da seguinte forma.

No original: *proposal distribution*[18], *acceptance probability*[19].

1. Escolha $Y_{n+1} = j$ de acordo com a cadeia de Markov $\{q_{ij}\}$.
2. Faça $\alpha_{ij} = \min\left\{1, \frac{\pi_j q_{ji}}{\pi_i q_{ij}}\right\}$ (a *probabilidade de aceitação*).
3. Com probabilidade α_{ij}, faça $X_{n+1} = Y_{n+1} = j$ (isto é, *aceitando* a proposta Y_{n+1}). Caso contrário, com probabilidade $1 - \alpha_{ij}$, faça $X_{n+1} = X_n = i$ (isto é, *rejeitando* a proposta Y_{n+1}).

A razão para esse algoritmo incomum é dada pelo teorema a seguir.

Teorema 11.3.3

O algoritmo de Metropolis–Hastings acima resulta numa cadeia de Markov $X_0, X_1, X_2, \ldots$ que tem $\{\pi_i\}$ como distribuição estacionária.

Demonstração. Veja a Seção 11.7 para a demonstração. ■

Consideramos algumas aplicações desse algoritmo.

Exemplo 11.3.3

Como no Exemplo 11.3.1, suponha que $S = \{\dots, -2, -1, 0, 1, 2, \dots\}$ e

$$\pi_j = C(j - 1/2)^4 e^{-3|j|} \cos^2(j),$$

para $j \in S$. Vamos construir uma cadeia de Markov que tenha $\{\pi_i\}$ como distribuição estacionária.

Primeiro, precisamos escolher alguma cadeia de Markov simples $\{q_{ij}\}$. Tomamos $\{q_{ij}\}$ como o passeio aleatório simples com $p = 1/2$, de modo que $q_{ij} = 1/2$ se $j = i + 1$ ou $j = i - 1$, e $q_{ij} = 0$ caso contrário.

Calculamos então que, se $j = i + 1$ ou $j = i - 1$, temos*

$$\begin{aligned} \alpha_{ij} &= \min\left\{1, \frac{q_{ji}\pi_j}{q_{ij}\pi_i}\right\} = \min\left\{1, \frac{(1/2)C(j - 1/2)^4 e^{-3|j|}\cos^2(j)}{(1/2)C(i - 1/2)^4 e^{3i}\cos^2(i)}\right\} \\ &= \min\left\{1, \frac{(j - 1/2)^4 e^{-3|j|}\cos^2(j)}{(i - 1/2)^4 e^{3i}\cos^2(i)}\right\}. \end{aligned} \tag{11.3.2}$$

Note que C se cancelou, de modo que α_{ij} não depende de C. (Na verdade, isso sempre acontece.) Logo, vemos que α_{ij}, embora um tanto trabalhosa, ainda é muito fácil de calcular num computador.

Dado $X_n = i$, o algoritmo de Metropolis–Hastings calcula o valor X_{n+1} da seguinte forma.

1. Faça $Y_{n+1} = X_n + 1$ ou $Y_{n+1} = X_n - 1$, com probabilidade 1/2 cada.
2. Faça $j = Y_{n+1}$ e calcule α_{ij} como em (11.3.2).
3. Com probabilidade α_{ij}, faça $X_{n+1} = Y_{n+1} = j$. Caso contrário, com probabilidade $1 - \alpha_{ij}$, faça $X_{n+1} = X_n = i$.

Todos esses passos podem ser executados facilmente num computador. Se os repetirmos para $n = 0, 1, 2, \dots, N - 1$, com algum número grande N de iterações, obteremos uma variável aleatória X_N, em que $P(X_N = j) \approx \pi_j = C(j - 1/2)^4 e^{-3|j|}\cos^2(j)$, para todo $j \in S$. ■

*Nota do tradutor. O original traz e^{3i} no denominador; pela definição de π_i seria $e^{-3|i|}$.

Exemplo 11.3.4

Novamente, seja $S = \{\dots, -2, -1, 0, 1, 2, \dots\}$ e, dessa vez, seja $\pi_j = Ke^{-j^4}$, para $j \in S$. Considere a distribuição proposta $\{q_{ij}\}$ correspondente a um passeio aleatório simples com $p = 1/4$, de modo que $Y_{n+1} = X_n + 1$ com probabilidade $1/4$ e $Y_{n+1} = X_n - 1$ com probabilidade $3/4$.

Nesse caso, calculamos que, se $j = i + 1$, então*

$$\alpha_{ij} = \min\left\{1, \frac{q_{ji}\pi_j}{q_{ij}\pi_i}\right\} = \min\left\{1, \frac{(3/4)Ke^{-j^4}}{(1/4)Ke^{-i^4}}\right\} = \min\left\{1, 3e^{j^4 - i^4}\right\}. \tag{11.3.3}$$

Se, em vez disso, $j = i - 1$, então

$$\begin{aligned}\alpha_{ij} &= \min\left\{1, \frac{q_{ji}\pi_j}{q_{ij}\pi_i}\right\} = \min\left\{1, \frac{(1/4)Ke^{-j^4}}{(3/4)Ke^{-i^4}}\right\} \\ &= \min\left\{1, (1/3)e^{j^4 - i^4}\right\}. \end{aligned} \tag{11.3.4}$$

(Note que a constante K se cancelou novamente, como esperado.) Logo, mais uma vez, α_{ij} é muito fácil de calcular num computador.

Dado $X_n = i$, o algoritmo de Metropolis–Hastings calcula o valor X_{n+1} da seguinte forma.

1. Faça $Y_{n+1} = X_n + 1$ com probabilidade $1/4$, ou $Y_{n+1} = X_n - 1$ com probabilidade $3/4$.
2. Faça $j = Y_{n+1}$ e calcule α_{ij} usando (11.3.3) e (11.3.4).
3. Com probabilidade α_{ij}, faça $X_{n+1} = Y_{n+1} = j$. Caso contrário, com probabilidade $1 - \alpha_{ij}$, faça $X_{n+1} = X_n = i$.

Mais uma vez, todos esses passos podem ser executados facilmente num computador; se forem repetidos com algum número grande N de iterações, então $P(X_N = j) \approx \pi_j = Ke^{-j^4}$ para $j \in S$. ■

O algoritmo de Metropolis–Hastings também pode ser usado para variáveis aleatórias *contínuas*, usando *densidades*, como segue.

*Nota do tradutor. Em (11.3.3) e (11.3.4) o original traz o expoente $j^4 - i^4$; pela conta seria $i^4 - j^4$.

Exemplo 11.3.5

Suponha que queremos gerar uma amostra da distribuição com densidade proporcional a

$$f(y) = e^{-y^4}(1 + |y|)^3.$$

Então a densidade é $Cf(y)$, em que $C = 1\Big/ \int_{-\infty}^{\infty} f(y)\,dy$. Como podemos gerar uma variável aleatória Y tal que Y tenha aproximadamente essa distribuição, isto é, tenha densidade de probabilidade aproximadamente igual a $Cf(y)$?

Usemos uma distribuição proposta dada por uma distribuição $N(x, 1)$, isto é, uma distribuição normal com média x e variância 1. Ou seja, dado $X_n = x$, escolhemos Y_{n+1} por $Y_{n+1} \sim N(x, 1)$. Como a distribuição $N(x, 1)$ tem densidade $(2\pi)^{-1/2}e^{-(y-x)^2/2}$, isso corresponde a uma *densidade proposta* $q(x, y) = (2\pi)^{-1/2}e^{-(y-x)^2/2}$.

Quanto à probabilidade de aceitação $\alpha(x, y)$, usamos novamente densidades, de modo que

$$\begin{aligned}
\alpha(x, y) &= \min\left\{1, \frac{Cf(y)\,q(y, x)}{Cf(x)\,q(x, y)}\right\} \\
&= \min\left\{1, \left(\frac{1 + |y|}{1 + |x|}\right)^3 \frac{Ce^{-y^4}\,(2\pi)^{-1/2}\,e^{-(y-x)^2/2}}{Ce^{-x^4}\,(2\pi)^{-1/2}\,e^{-(x-y)^2/2}}\right\} \\
&= \min\left\{1, \left(\frac{1 + |y|}{1 + |x|}\right)^3 e^{-y^4+x^4}\right\}. \qquad (11.3.5)
\end{aligned}$$

Dado $X_n = x$, o algoritmo de Metropolis–Hastings calcula o valor X_{n+1} da seguinte forma.

1. Gere $Y_{n+1} \sim N(X_n, 1)$.
2. Faça $y = Y_{n+1}$ e calcule $\alpha(x, y)$, como antes.
3. Com probabilidade $\alpha(x, y)$, faça $X_{n+1} = Y_{n+1} = y$. Caso contrário, com probabilidade $1 - \alpha(x, y)$, faça $X_{n+1} = X_n = x$.

Mais uma vez, todos esses passos podem ser executados facilmente num computador; se forem repetidos com algum número grande N de iterações, então a variável aleatória X_N terá aproximadamente densidade dada por $Cf(y)$. ■

11.3.2 O Amostrador de Gibbs

Na Seção 7.3.3, discutimos o amostrador de Gibbs[20] e sua aplicação num problema de estatística bayesiana. Como mostraremos agora, o *amostrador de Gibbs* é uma versão especializada do algoritmo de Metropolis–Hastings, projetada para distribuições multivariadas. Ele escolhe as probabilidades propostas q_{ij} na medida certa para que sempre tenhamos $\alpha_{ij} = 1$, isto é, para que nunca haja rejeição.

Suponha que $S = \{\dots, -2, -1, 0, 1, 2, \dots\} \times \{\dots, -2, -1, 0, 1, 2, \dots\}$, isto é, S é o conjunto de todos os pares ordenados de inteiros $i = (i_1, i_2)$. (Assim, $(2, 3) \in S$, e $(-6, 14) \in S$ etc.) Suponha que alguma distribuição $\{\pi_i\}$ esteja definida em S. Defina uma distribuição proposta $\{q_{ij}^{(1)}\}$ da seguinte forma.

Seja $V(i) = \{j \in S : j_2 = i_2\}$. Isto é, $V(i)$ é o conjunto de todos os estados $j \in S$ tais que i e j coincidem na segunda coordenada. Assim, $V(i)$ é uma reta vertical em S que passa pelo ponto i.

Em termos dessa definição de $V(i)$, defina $q_{ij}^{(1)} = 0$ se $j \notin V(i)$, isto é, se i e j diferem na segunda coordenada. Se $j \in V(i)$, isto é, se i e j coincidem na segunda coordenada, defina

$$q_{ij}^{(1)} = \frac{\pi_j}{\sum_{k \in V(i)} \pi_k}.$$

Uma interpretação é que, se $X_n = i$ e $P(Y_{n+1} = j) = q_{ij}^{(1)}$ para $j \in S$, então a distribuição de Y_{n+1} é a distribuição *condicional* de $\{\pi_i\}$, *condicionada* a saber que a segunda coordenada tem de ser igual a i_2.

Com essa escolha de $q_{ij}^{(1)}$, quanto vale α_{ij}? Bem, se $j \in V(i)$, então $i \in V(j)$, e também $V(j) = V(i)$. Logo,

$$\begin{aligned}\alpha_{ij} &= \min\left\{1, \frac{\pi_j q_{ji}^{(1)}}{\pi_i q_{ij}^{(1)}}\right\} = \min\left\{1, \frac{\pi_j \left(\pi_i / \sum_{k \in V(j)} \pi_k\right)}{\pi_i \left(\pi_j / \sum_{l \in V(i)} \pi_l\right)}\right\} \\ &= \min\left\{1, \frac{\pi_j \pi_i}{\pi_i \pi_j}\right\} = \min\{1, 1\} = 1.\end{aligned}$$

Isto é, esse algoritmo aceita a proposta Y_{n+1} com probabilidade 1 e nunca rejeita!

Ora, esse algoritmo sozinho não é muito útil, porque propõe apenas estados em $V(i)$ e, portanto, nunca muda o valor da segunda coordenada. Contudo, podemos definir de modo análogo uma reta horizontal passando por i por

No original: *Gibbs sampler*[20].

$H(i) = \{j \in S : j_1 = i_1\}$, de modo que $H(i)$ é o conjunto de todos os estados j tais que i e j coincidem na primeira coordenada. Isto é, $H(i)$ é uma reta horizontal em S que passa pelo ponto i.

Podemos então definir $q_{ij}^{(2)} = 0$ se $j \notin H(i)$ (isto é, se i e j diferem na primeira coordenada), enquanto, se $j \in V(i)$ (isto é, se i e j coincidem na primeira coordenada), então*

$$q_{ij}^{(2)} = \frac{\pi_j}{\sum_{k \in H(i)} \pi_k}.$$

Como antes, calculamos que, para essa proposta, sempre teremos $\alpha_{ij} = 1$, isto é, o algoritmo de Metropolis–Hastings com essa proposta nunca rejeita.

O amostrador de Gibbs funciona *combinando* esses dois algoritmos de Metropolis–Hastings diferentes, alternando entre eles. Isto é, dado um valor $X_n = i$, ele produz um valor X_{n+1} da seguinte forma.

1. Proponha um valor $Y_{n+1} \in V(i)$, de acordo com a distribuição proposta $\{q_{ij}^{(1)}\}$.
2. Aceite sempre Y_{n+1} e faça $j = Y_{n+1}$, movendo-se assim na vertical.
3. Proponha um valor $Z_{n+1} \in H(j)$, de acordo com a distribuição proposta $\{q_{ij}^{(2)}\}$.
4. Aceite sempre Z_{n+1}, movendo-se assim na horizontal.
5. Faça $X_{n+1} = Z_{n+1}$.

Desse modo, o amostrador de Gibbs faz um "zigue-zague" pelo espaço de estados S, movendo-se alternadamente na direção vertical e na horizontal.

À luz do Teorema 11.3.2, obtemos imediatamente o seguinte.

Teorema 11.3.4

O algoritmo do amostrador de Gibbs acima resulta numa cadeia de Markov $X_0, X_1, X_2, \ldots$ que tem $\{\pi_i\}$ como distribuição estacionária.

O amostrador de Gibbs oferece, assim, uma maneira particular de implementar o algoritmo de Metropolis–Hastings em problemas multidimensionais, que nunca rejeita os valores propostos.

*Nota do tradutor. O original traz $j \in V(i)$; pelo contexto seria $j \in H(i)$.

Resumo da Seção 11.3

- Em casos complicados demais para as técnicas comuns de Monte Carlo, é possível usar, em vez delas, técnicas de Monte Carlo via cadeias de Markov, tirando a média de valores gerados por uma cadeia de Markov.
- O algoritmo de Metropolis–Hastings oferece uma maneira simples de criar uma cadeia de Markov com distribuição estacionária $\{\pi_i\}$. Dado X_n, ele gera uma proposta Y_{n+1} a partir de uma distribuição proposta $\{q_{ij}\}$ e então aceita essa proposta (fazendo $X_{n+1} = Y_{n+1}$) com probabilidade α_{ij}, ou a rejeita (fazendo $X_{n+1} = X_n$) com probabilidade $1 - \alpha_{ij}$.
- Alternativamente, o amostrador de Gibbs atualiza as coordenadas uma de cada vez a partir de sua distribuição condicional, de modo que sempre temos $\alpha_{ij} = 1$.

Exercícios

11.3.1 Suponha que $\pi_i = Ce^{-(i-13)^4}$ para $i \in S = \{\dots, -2, -1, 0, 1, 2, \dots\}$, em que $C = 1\Big/\sum_{i=-\infty}^{\infty} e^{-(i-13)^4}$. Descreva em detalhe um algoritmo de Metropolis–Hastings para $\{\pi_i\}$ que use o passeio aleatório simples com $p = 1/2$ para as propostas.

11.3.2 Suponha que $\pi_i = C(i + 6{,}5)^{-8}$ para $i \in S = \{\dots, -2, -1, 0, 1, 2, \dots\}$, em que $C = 1\Big/\sum_{i=-\infty}^{\infty}(i + 6{,}5)^{-8}$. Descreva em detalhe um algoritmo de Metropolis–Hastings para $\{\pi_i\}$ que use o passeio aleatório simples com $p = 5/8$ para as propostas.

11.3.3 Suponha que $\pi_i = Ke^{-i^4-i^6-i^8}$ para $i \in S = \{\dots, -2, -1, 0, 1, 2, \dots\}$, em que* $C = 1\Big/\sum_{i=-\infty}^{\infty} e^{-i^4-i^6-i^8}$. Descreva em detalhe um algoritmo de Metropolis–Hastings para $\{\pi_i\}$ que use o passeio aleatório simples com $p = 7/9$ para as propostas.

11.3.4 Suponha que $f(x) = e^{-x^4-x^6-x^8}$ para $x \in R^1$. Seja $K = 1\Big/\int_{-\infty}^{\infty} e^{-x^4-x^6-x^8}\,dx$. Descreva em detalhe um algoritmo de Metropolis–Hastings para a distribuição com densidade $Kf(x)$ que use a distribuição proposta $N(x, 1)$, isto é, uma distribuição normal com média x e variância[21] 1.

*Nota do tradutor. O original define a constante como C, mas π_i usa K.

No original: *variance*[21].

11.3.5 Seja $f(x) = e^{-x^4-x^6-x^8}$ para $x \in R^1$, e seja $K = 1 \Big/ \int_{-\infty}^{\infty} e^{-x^4-x^6-x^8}\, dx$. Descreva em detalhe um algoritmo de Metropolis–Hastings para a distribuição com densidade $Kf(x)$ que use a distribuição proposta $N(x, 10)$, isto é, uma distribuição normal com média x e variância 10.

Exercícios computacionais

11.3.6 Rode o algoritmo do Exercício 11.3.1. Discuta a saída.

11.3.7 Rode o algoritmo do Exercício 11.3.2. Discuta a saída.

Problemas

11.3.8 Suponha que $S = \{1, 2, 3, \ldots\} \times \{1, 2, 3, \ldots\}$, isto é, S é o conjunto de todos os *pares* de inteiros positivos. Para $i = (i_1, i_2) \in S$, suponha que $\pi_i = C/2^{i_1+i_2}$ para uma constante positiva C apropriada. Descreva em detalhe um algoritmo de amostrador de Gibbs para essa distribuição $\{\pi_i\}$.

Problemas computacionais

11.3.9 Rode o algoritmo do Exercício 11.3.4. Discuta a saída.

11.3.10 Rode o algoritmo do Exercício 11.3.5. Discuta a saída.

Tópicos para discussão

11.3.11 Por que você acha que os algoritmos de Monte Carlo via cadeias de Markov se tornaram tão populares em tantos ramos da ciência? (Liste tantas razões quanto conseguir.)

11.3.12 Suponha que você vai usar uma estimativa[22] de Monte Carlo via cadeias de Markov da forma

$$\hat{A} = \frac{1}{M} \sum_{i=1}^{M} h(X_N^{[i]}).$$

No original: *estimate*[22].

Suponha também que, por restrições de tempo, o número total de iterações não possa passar de um milhão. Isto é, é preciso ter $NM \leq 1.000.000$. Discuta as vantagens e desvantagens das seguintes escolhas de N e M.

(a) $N = 1.000.000$, $M = 1$

(b) $N = 1$, $M = 1.000.000$

(c) $N = 100$, $M = 10.000$

(d) $N = 10.000$, $M = 100$

(e) $N = 1000$, $M = 1000$

(f) Qual escolha você acha que seria a melhor, e em quais circunstâncias? Por quê?

11.4 Martingais

Nesta seção, estudamos uma classe especial de processos estocásticos chamados *martingais*. Veremos que esses processos se caracterizam por "permanecer os mesmos, em média".

Como motivação, considere novamente um passeio aleatório simples no caso de um jogo justo[23], isto é, com $p = 1/2$. Suponha, como no contexto da ruína do jogador, que você comece em a e continue até atingir c ou 0, em que $0 < a < c$. Seja Z o valor com que você termina, de modo que sempre temos $Z = c$ ou $Z = 0$. Sabemos, pelo Teorema 11.1.2, que de fato $P(Z = c) = a/c$, de modo que $P(Z = 0) = 1 - a/c$.

Consideremos agora o *valor esperado* de Z. Temos que

$$E(Z) = \sum_{z \in R^1} z\, P(Z = z) = cP(Z = c) + 0P(Z = 0) = c(a/c) = a.$$

Isto é, o valor médio[24] do ponto onde você termina é a. Mas a é também o valor em que você começou!

Isso não é coincidência. De fato, como $p = 1/2$ (isto é, o jogo era justo), isso significa que, "em média", você sempre permaneceu em a. Isto é, $\{X_n\}$ é um *martingal*[25].

No original: *fair game*[23], *mean value*[24], *martingale*[25].

11.4.1 Definição de Martingal

Começamos com a definição de martingal. Por simplicidade, supomos que o martingal é uma cadeia de Markov, embora isso não seja realmente necessário.

Definição 11.4.1

Seja $X_0, X_1, X_2, \ldots$ uma cadeia de Markov. A cadeia é um *martingal* se, para todo $n = 0, 1, 2, \ldots$, temos $E(X_{n+1} - X_n \mid X_n) = 0$. Isto é, em média, o valor da cadeia não muda, qualquer que seja o valor atual X_n.

Exemplo 11.4.1

Seja $\{X_n\}$ um passeio aleatório simples com $p = 1/2$. Então $X_{n+1} - X_n$ é igual a 1 ou a -1, com probabilidade $1/2$ cada. Logo,

$$E(X_{n+1} - X_n \mid X_n) = (1)(1/2) + (-1)(1/2) = 0,$$

de modo que $\{X_n\}$ permanece o mesmo em média e é um martingal. (Note que nunca teremos de fato $X_{n+1} - X_n = 0$. No entanto, *em média*, teremos $X_{n+1} - X_n = 0$.) ■

Exemplo 11.4.2

Seja $\{X_n\}$ um passeio aleatório simples com $p = 2/3$. Então $X_{n+1} - X_n$ é igual a 1 ou a -1, com probabilidades $2/3$ e $1/3$, respectivamente. Logo,

$$E(X_{n+1} - X_n \mid X_n) = (1)(2/3) + (-1)(1/3) = 1/3 \neq 0.$$

Assim, $\{X_n\}$ *não* é um martingal neste caso. ■

Exemplo 11.4.3

Suponha que começamos com o número 5 e depois fazemos repetidamente o seguinte: ou somamos 3 ao número (com probabilidade 1/4), ou subtraímos 1 do número (com probabilidade 3/4). Seja X_n o número obtido depois de repetir esse procedimento n vezes. Então, dado o valor de X_n, vemos que $X_{n+1} = X_n + 3$ com probabilidade 1/4, enquanto $X_{n+1} = X_n - 1$ com probabilidade 3/4. Logo,

$$E(X_{n+1} - X_n \mid X_n) = (3)(1/4) + (-1)(3/4) = 3/4 - 3/4 = 0$$

e $\{X_n\}$ é um martingal. ■

Às vezes, é possível criar martingais de maneiras sutis, como segue.

Exemplo 11.4.4

Seja $\{X_n\}$ novamente um passeio aleatório simples, mas desta vez para p geral. Então $X_{n+1} - X_n$ é igual a 1 com probabilidade p, e a -1 com probabilidade $q = 1 - p$. Logo,

$$E(X_{n+1} - X_n \mid X_n) = (1)(p) + (-1)(q) = p - q = 2p - 1.$$

Se $p \neq 1/2$, isso *não* é igual a 0. Logo, $\{X_n\}$ *não* permanece o mesmo em média, de modo que $\{X_n\}$ *não* é um martingal.

Por outro lado, seja

$$Z_n = \left(\frac{1-p}{p}\right)^{X_n},$$

isto é, Z_n é igual à constante $(1 - p)/p$ elevada à *potência* X_n. Então, aumentar X_n em 1 corresponde a *multiplicar* Z_n por $(1 - p)/p$, enquanto diminuir X_n em 1 corresponde a *dividir* Z_n por $(1 - p)/p$, isto é, multiplicar por $p/(1 - p)$. Mas $X_{n+1} = X_n + 1$ com probabilidade p, enquanto $X_{n+1} = X_n - 1$ com probabilidade $q = 1 - p$. Portanto, vemos que, dado o valor de Z_n, temos

$$\begin{aligned} E(Z_{n+1} - Z_n \mid Z_n) &= \left(\frac{1-p}{p}Z_n - Z_n\right)p + \left(\frac{p}{1-p}Z_n - Z_n\right)(1-p) \\ &= \big((1-p)Z_n - pZ_n\big) + \big(pZ_n - (1-p)Z_n\big) = 0. \end{aligned}$$

Consequentemente, $E(Z_{n+1} - Z_n \mid Z_n) = 0$, de modo que $\{Z_n\}$ permanece o mesmo em média, isto é, $\{Z_n\}$ é um martingal. ■

11.4.2 Valores Esperados

Como martingais permanecem os mesmos em média, temos imediatamente o seguinte.

Teorema 11.4.1

Seja $\{X_n\}$ um martingal com $X_0 = a$. Então $E(X_n) = a$ para todo n.

Às vezes, esse teorema fornece informações muito úteis, como mostram os exemplos a seguir.

Exemplo 11.4.5

Seja $\{X_n\}$ novamente um passeio aleatório simples com $p = 1/2$. Já vimos que $\{X_n\}$ é um martingal. Logo, se $X_0 = a$, teremos $E(X_n) = a$ para todo n. Isto é, num jogo justo (isto é, com $p = 1/2$), não importa por quanto tempo você esteja jogando, sua fortuna *média* será sempre igual à sua fortuna inicial a. ■

Exemplo 11.4.6

Suponha que começamos com o número 10 e depois fazemos repetidamente o seguinte: ou somamos 2 ao número (com probabilidade 1/3), ou subtraímos 1 do número (com probabilidade 2/3). Suponha que repetimos esse processo 25 vezes. Qual é o valor esperado do número com que terminamos?

Sem a teoria dos martingais, esse problema parece difícil e exige cálculos longos das várias possibilidades do que pode acontecer em cada um dos 25 passos. Com a teoria dos martingais, porém, ele é muito fácil.

De fato, seja X_n o número depois de n passos, de modo que $X_0 = 10$, $X_1 = 12$ (com probabilidade 1/3) ou $X_1 = 9$ (com probabilidade 2/3) etc. Então, como $X_{n+1} - X_n$ é igual a 2 (com probabilidade 1/3) ou a -1 (com probabilidade 2/3), temos

$$E(X_{n+1} - X_n \mid X_n) = 2(1/3) + (-1)(2/3) = 2/3 - 2/3 = 0.$$

Logo, $\{X_n\}$ é um martingal.

Segue então que $E(X_n) = X_0 = 10$, para qualquer n. Em particular, $E(X_{25}) = 10$. Isto é, depois de 25 passos, o número será, em média, igual a 10. ■

11.4.3 Tempos de Parada

Se $\{X_n\}$ é um martingal com $X_0 = a$, é muito útil saber que $E(X_n) = a$ para todo n. Às vezes, porém, é ainda mais útil saber que $E(X_T) = a$, em que T é um tempo *aleatório*. Bem, isso nem sempre é verdade; mas é verdade com frequência, como veremos. Começamos com outra definição.

Definição 11.4.2

Seja $\{X_n\}$ um processo estocástico, e seja T uma variável aleatória que assume valores em $\{0, 1, 2, \ldots\}$. Então T é um *tempo de parada* se, para todo $m = 0, 1, 2, \ldots$, o evento $\{T = m\}$ é independente dos valores $X_{m+1}, X_{m+2}, \ldots$. Isto é, ao decidir se $T = m$ ou não (isto é, se vamos "parar" no tempo m ou não), não podemos olhar os valores futuros $X_{m+1}, X_{m+2}, \ldots$.

Exemplo 11.4.7

Seja $\{X_n\}$ um passeio aleatório simples, seja b um inteiro qualquer e seja $\tau_b = \min\{n \geq 0 : X_n = b\}$ o primeiro tempo em que atingimos o valor b. Então τ_b é um tempo de parada, porque o evento $\tau_b = n$ depende só de $X_0, \ldots, X_n$, e não de $X_{n+1}, X_{n+2}, \ldots$.

Por outro lado, seja $T = \tau_b - 1$, de modo que T corresponde a parar logo *antes* de atingirmos b. Então T não é um tempo de parada, porque precisa olhar o valor futuro X_{m+1} para decidir se para ou não no tempo m. ■

Um resultado-chave sobre martingais e tempos de parada é o teorema da parada opcional[26], como segue.

No original: *optional stopping theorem*[26].

Teorema 11.4.2 (Teorema da parada opcional)

Suponha que $\{X_n\}$ seja um martingal com $X_0 = a$ e que T seja um tempo de parada. Suponha ainda que

(a) o martingal seja limitado até o tempo T, isto é, para algum $M > 0$, tenhamos $|X_n| \leq M$ para todo $n \leq T$; ou

(b) o tempo de parada seja limitado, isto é, para algum $M > 0$, tenhamos $T \leq M$.

Então $E(X_T) = a$, isto é, em média, o valor do processo no tempo aleatório T é igual ao valor inicial a.

Demonstração. Para uma demonstração e mais discussão, veja, por exemplo, a página 273 de *Probability: Theory and Examples*, 2.ª ed., de R. Durrett (Duxbury Press, Nova York, 1996). ■

Considere uma aplicação simples disso.

Exemplo 11.4.8

Seja $\{X_n\}$ um passeio aleatório simples com valor inicial a e com $p = 1/2$. Sejam $r > a > s$ inteiros. Seja $T = \min\{\tau_r, \tau_s\}$ o primeiro tempo em que o processo atinge r ou s. Então $r \geq X_n \geq s$ para $n \leq T$, de modo que a condição (a) do teorema da parada opcional se aplica. Concluímos que $E(X_T) = a$, isto é, que, no tempo T, o passeio será, em média, igual a a. ■

Veremos que o teorema da parada opcional é útil de muitas maneiras.

Exemplo 11.4.9

Podemos usar o teorema da parada opcional para encontrar a probabilidade de o passeio aleatório simples com $p = 1/2$ atingir r antes de atingir outro valor s.

De fato, seja novamente $\{X_n\}$ um passeio aleatório simples com valor inicial a e $p = 1/2$, com $r > a > s$ inteiros e $T = \min\{\tau_r, \tau_s\}$. Então, como antes, $E(X_T) = a$. Podemos usar isso para obter $P(X_T = r)$, isto é, a probabilidade de o passeio atingir r antes de atingir s.

Claramente, sempre temos $X_T = r$ ou $X_T = s$. Seja $h = P(X_T = r)$. Então $E(X_T) = hr + (1 - h)s$. Como $E(X_T) = a$, devemos ter $a = hr + (1 - h)s$. Resolvendo para h, vemos que

$$P(X_T = r) = \frac{a - s}{r - s}.$$

Concluímos que a probabilidade de o processo atingir r antes de atingir s é igual a $(a - s)/(r - s)$. Note que não foi preciso absolutamente nenhum cálculo difícil para obter esse resultado. ■

Um caso particular do exemplo anterior merece atenção especial.

Exemplo 11.4.10

No exemplo anterior, suponha que $r = c$ e $s = 0$. Então o valor $h = P(X_T = r)$ é exatamente a probabilidade de sucesso no problema da ruína do jogador. O exemplo anterior mostra que $h = (a - s)/(r - s) = a/c$. Isso dá a mesma resposta do Teorema 11.1.2, mas com muito menos esforço. ■

É impressionante que, no exemplo anterior, a teoria dos martingais consiga resolver tão facilmente o problema da ruína do jogador no caso $p = 1/2$. Nossa solução anterior, sem usar a teoria dos martingais, foi muito mais difícil (veja a Seção 11.7). Mais surpreendente ainda, a teoria dos martingais também resolve o problema da ruína do jogador quando $p \neq 1/2$, como segue.

Exemplo 11.4.11

Seja $\{X_n\}$ um passeio aleatório simples com valor inicial a e com $p \neq 1/2$. Sejam $0 < a < c$ inteiros. Seja $T = \min\{\tau_c, \tau_0\}$ o primeiro tempo em que o processo atinge c ou 0. Para resolver o problema da ruína do jogador neste

caso, estamos interessados em $g = P(X_T = c)$. Podemos usar o teorema da parada opcional para obter a probabilidade g da ruína do jogador, como segue.

Bem, $\{X_n\}$ não é um martingal, de modo que não podemos aplicar a ele a teoria dos martingais. No entanto, seja

$$Z_n = \left(\frac{1-p}{p}\right)^{X_n}.$$

Então $\{Z_n\}$ tem valor inicial $Z_0 = ((1-p)/p)^a$. Além disso, sabemos, pelo Exemplo 11.4.4, que $\{Z_n\}$ é um martingal. Mais ainda,

$$0 \le Z_n \le \max\left\{\left(\frac{1-p}{p}\right)^c, \left(\frac{1-p}{p}\right)^{-c}\right\}$$

para $n \le T$, de modo que a condição (a) do teorema da parada opcional se aplica. Concluímos que

$$E(Z_T) = Z_0 = \left(\frac{1-p}{p}\right)^a.$$

Bem, claramente, sempre temos $X_T = c$ (com probabilidade g) ou $X_T = 0$ (com probabilidade $1 - g$). No primeiro caso, $Z_T = ((1-p)/p)^c$, enquanto no segundo, $Z_T = 1$. Logo, $E(Z_T) = g((1-p)/p)^c + (1-g)(1)$. Como $E(Z_T) = ((1-p)/p)^a$, devemos ter

$$\left(\frac{1-p}{p}\right)^a = g\left(\frac{1-p}{p}\right)^c + (1-g)(1).$$

Resolvendo para g, vemos que

$$g = \frac{((1-p)/p)^a - 1}{((1-p)/p)^c - 1}.$$

Isso dá novamente a mesma resposta do Teorema 11.1.2, desta vez para $p \neq 1/2$, mas outra vez com muito menos esforço. ■

A teoria dos martingais também pode nos revelar outros fatos surpreendentes.

Exemplo 11.4.12

Seja $\{X_n\}$ um passeio aleatório simples com $p = 1/2$ e com valor inicial $a = 0$. O passeio atingirá o valor -1 em algum momento durante o primeiro milhão de passos? Provavelmente sim, mas não com certeza. Além disso, condicionado a *não* atingir -1, ele provavelmente será extremamente grande, como discutimos agora.

Seja $T = \min\{10^6, \tau_{-1}\}$. Isto é, T é o primeiro tempo em que o processo atinge -1, a menos que isso leve mais de um milhão de passos, caso em que $T = 10^6$.

Bem, $\{X_n\}$ é um martingal. Além disso, T é um tempo de parada (porque não olha para o futuro ao decidir se para ou não). Mais ainda, sempre temos $T \leq 10^6$, de modo que a condição (b) do teorema da parada opcional se aplica. Concluímos que $E(X_T) = a = 0$.

Por outro lado, pela lei da esperança total, temos

$$\begin{aligned} E(X_T) = {} & E(X_T \mid X_T = -1)\, P(X_T = -1) \\ & + E(X_T \mid X_T \neq -1)\, P(X_T \neq -1). \end{aligned}$$

Além disso, claramente, $E(X_T \mid X_T = -1) = -1$. Seja $u = P(X_T = -1)$, de modo que $P(X_T \neq -1) = 1 - u$. Então concluímos que $0 = (-1)u + E(X_T \mid X_T \neq -1)(1 - u)$, de modo que

$$E(X_T \mid X_T \neq -1) = \frac{u}{1-u}.$$

Bem, claramente, u estará muito perto de 1, isto é, é muito provável que, em 10^6 passos, o processo já tenha atingido -1. Logo, $E(X_T \mid X_T \neq -1)$ é extremamente grande.

Podemos resumir esta discussão da seguinte maneira. Quase sempre temos $X_T = -1$. No entanto, muito ocasionalmente, teremos $X_T \neq -1$. Além disso, o valor médio de X_T quando $X_T \neq -1$ é *tão* grande que, no total (isto é, contando tanto o caso $X_T = -1$ quanto o caso $X_T \neq -1$), o valor médio de X_T é 0 (como deve ser, já que $\{X_n\}$ é um martingal)! ■

Quem não toma cuidado pode ser enganado pela teoria dos martingais, como segue.

Exemplo 11.4.13

Suponha novamente que $\{X_n\}$ seja um passeio aleatório simples com $p = 1/2$ e com valor inicial $a = 0$. Seja $T = \tau_{-1}$, isto é, T é o primeiro tempo em que o processo atinge -1 (não importa quanto tempo isso leve).

Como o processo sempre esperará até atingir -1, sempre temos $X_T = -1$. Como isso vale com probabilidade 1, também temos $E(X_T) = -1$.

Por outro lado, novamente $\{X_n\}$ é um martingal, de modo que, de novo, parece que deveríamos ter $E(X_T) = 0$. O que está acontecendo?

A resposta, é claro, é que nem a condição (a) nem a condição (b) do teorema da parada opcional é satisfeita neste caso. Isto é, não há limite para quão grande T pode precisar ser, nem para quão grande X_n pode ficar para algum $n \leq T$. Logo, o teorema da parada opcional não se aplica neste caso, e não podemos concluir que $E(X_T) = 0$. Em vez disso, aqui $E(X_T) = -1$. ■

Resumo da Seção 11.4

- Uma cadeia de Markov $\{X_n\}$ é um martingal se permanece a mesma em média, isto é, se $E(X_{n+1} - X_n \mid X_n) = 0$ para todo n. Há muitos exemplos.
- Um tempo de parada T da cadeia é uma variável aleatória com valores inteiros não negativos que não olha para o futuro de $\{X_n\}$. Por exemplo, $T = \tau_b$ pode ser o primeiro tempo em que a cadeia atinge algum estado b.
- Se $\{X_n\}$ é um martingal com tempo de parada T, e se T ou $\{X_n\}_{n \leq T}$ é limitado, então $E(X_T) = X_0$. Isso pode ser usado para resolver muitos problemas, por exemplo, o da ruína do jogador.

Exercícios

11.4.1 Suponha que definimos um processo $\{X_n\}$ da seguinte maneira. Dado X_n, com probabilidade 3/8 fazemos $X_{n+1} = X_n - 4$, enquanto com probabilidade 5/8 fazemos $X_{n+1} = X_n + C$. Que valor de C faz de $\{X_n\}$ um martingal?

11.4.2 Suponha que definimos um processo $\{X_n\}$ da seguinte maneira. Dado X_n, com probabilidade p fazemos $X_{n+1} = X_n + 7$, enquanto com probabilidade $1 - p$ fazemos $X_{n+1} = X_n - 2$. Que valor de p faz de $\{X_n\}$ um martingal?

11.4.3 Suponha que definimos um processo $\{X_n\}$ da seguinte maneira. Dado

X_n, com probabilidade p fazemos $X_{n+1} = 2X_n$, enquanto com probabilidade $1 - p$ fazemos $X_{n+1} = X_n/2$. Que valor de p faz de $\{X_n\}$ um martingal?

11.4.4 Seja $\{X_n\}$ um martingal com valor inicial $X_0 = 14$. Suponha que, para algum n, saibamos que $P(X_n = 8) + P(X_n = 12) + P(X_n = 17) = 1$, isto é, X_n é sempre 8, 12 ou 17. Suponha ainda que $P(X_n = 8) = 0{,}1$. Calcule $P(X_n = 14)$.

11.4.5 Seja $\{X_n\}$ um martingal com valor inicial $X_0 = 5$. Suponha que saibamos que $P(X_8 = 3) + P(X_8 = 4) + P(X_8 = 6) = 1$, isto é, X_8 é sempre 3, 4 ou 6. Suponha ainda que $P(X_8 = 3) = 2\,P(X_8 = 6)$. Calcule $P(X_8 = 4)$.

11.4.6 Suponha que você comece com 175 moedas de 1 centavo. Você lança repetidamente uma moeda honesta. Cada vez que sai cara, você ganha uma moeda de 1 centavo; cada vez que sai coroa, você perde uma moeda de 1 centavo.

(a) Depois de repetir esse procedimento 20 vezes, quantas moedas de 1 centavo você terá, em média?

(b) Suponha que você continue até ter 100 ou 200 moedas de 1 centavo e, então, pare. Qual é a probabilidade de você ter 200 moedas de 1 centavo quando parar?

11.4.7 Defina um processo $\{X_n\}$ por $X_0 = 27$ e $X_{n+1} = 3X_n$ com probabilidade $1/4$, ou $X_{n+1} = X_n/3$ com probabilidade $3/4$. Seja $T = \min\{\tau_1, \tau_{81}\}$ o primeiro tempo em que o processo atinge 1 ou 81.

(a) Mostre que $\{X_n\}$ é um martingal.

(b) Mostre que T é um tempo de parada[27].

(c) Calcule $E(X_T)$.

(d) Calcule a probabilidade $P(X_T = 1)$ de o processo atingir 1 antes de atingir 81.

Problemas

11.4.8 Seja $\{X_n\}$ um processo estocástico, e seja T_1 um tempo de parada. Sejam $T_2 = T_1 + i$ e $T_3 = T_1 - i$, para algum inteiro positivo i. Qual de T_2 e T_3 é necessariamente um tempo de parada, e qual não é? (Explique seu raciocínio.)

11.4.9 Seja $\{X_n\}$ um processo estocástico, e sejam T_1 e T_2 dois tempos de parada diferentes. Sejam $T_3 = \min\{T_1, T_2\}$ e $T_4 = \max\{T_1, T_2\}$.

No original: *stopping time*[27].

(a) T_3 é necessariamente um tempo de parada? (Explique seu raciocínio.)

(b) T_4 é necessariamente um tempo de parada? (Explique seu raciocínio.)

11.5 Movimento Browniano

O modelo de passeio aleatório simples da Seção 11.1.2 (com $p = 1/2$) pode ser estendido a um modelo interessante de tempo contínuo, chamado *movimento browniano*[28], da seguinte maneira. Em linhas gerais, a ideia é acelerar o tempo cada vez mais por um fator M (para M muito grande) e, ao mesmo tempo, encolher o espaço cada vez mais por um fator $1/\sqrt{M}$. Os fatores M e $1/\sqrt{M}$ são escolhidos na medida certa para que, usando o teorema central do limite[29], possamos deduzir propriedades do movimento browniano. De fato, usando o teorema central do limite, veremos que várias distribuições relacionadas ao movimento browniano são, na verdade, distribuições *normais*.

Historicamente, o movimento browniano recebe o nome de Robert Brown, um botânico que, em 1828, observou ao microscópio os movimentos de partículas minúsculas em solução, à medida que eram bombardeadas, em direções aleatórias, por muitas moléculas invisíveis. O movimento browniano foi proposto como modelo para o movimento caótico e aleatório observado nessas partículas. Na verdade, o movimento browniano acaba *não* sendo um modelo muito bom para esse movimento (por exemplo, o movimento browniano tem derivada infinita, o que só faria sentido se as partículas se movessem infinitamente rápido!). Ainda assim, o movimento browniano tem muitas propriedades matemáticas úteis e é também muito importante na teoria de finanças, porque é usado com frequência como modelo para as flutuações dos preços de ações. Uma teoria matemática adequada do movimento browniano foi desenvolvida em 1923 por Norbert Wiener*; por isso, o movimento browniano às vezes também é chamado de *processo de Wiener*[30].

Construiremos o movimento browniano em duas etapas. Primeiro, construímos passeios aleatórios cada vez mais rápidos, que chamaremos de $\{Y_t^{(M)}\}$, com M grande. Depois, tomamos o limite quando $M \to \infty$ para obter o movimento browniano.

*Wiener era um professor tão distraído que certa vez se perdeu e não conseguia achar a própria casa. Em sua confusão, pediu informações a uma menina, sem reconhecer que a menina era sua filha!

No original: *Brownian motion*[28], *central limit theorem*[29], *Wiener process*[30].

11.5.1 Passeios Aleatórios Cada Vez Mais Rápidos

Para começar, sejam $Z_1, Z_2, \ldots$ i.i.d. com $P(Z_i = +1) = P(Z_i = -1) = 1/2$. Para cada $M \in \{1, 2, \ldots\}$, defina um processo aleatório de tempo discreto

$$\{Y_{i/M}^{(M)} : i = 0, 1, \ldots\},$$

por $Y_0^{(M)} = 0$ e

$$Y_{(i+1)/M}^{(M)} = Y_{\frac{i}{M}}^{(M)} + \frac{1}{\sqrt{M}} Z_{i+1},$$

para $i = 0, 1, 2, \ldots$, de modo que

$$Y_{i/M}^{(M)} = \frac{1}{\sqrt{M}}(Z_1 + Z_2 + \cdots + Z_i).$$

Intuitivamente, então, $\{Y_{i/M}^{(M)}\}$ é como um passeio aleatório comum (de tempo discreto) (com $p = 1/2$), exceto que o tempo foi acelerado por um fator M e o espaço foi encolhido por um fator $\sqrt{M}$ (cada passo do novo passeio percorre uma distância $1/\sqrt{M}$). Isto é, esse processo dá muitos e muitos passos muito pequenos.

Para transformar $\{Y_{i/M}^{(M)}\}$ num processo de tempo contínuo, podemos então "preencher" os valores que faltam tornando a função linear nos intervalos $[i/M, (i+1)/M]$. Dessa forma, obtemos um processo de tempo contínuo

$$\{Y_t^{*(M)} : t \geq 0\},$$

que coincide com $\{Y_{i/M}^{(M)}\}$ sempre que $t = 1/M$*. Na Figura 11.5.1, traçamos o gráfico de

$$\{Y_{i/10}^{(10)} : i = 0, 1, \ldots, 20\}$$

(os pontos) e dos valores correspondentes de

$$\{Y_t^{*(10)} : 0 \leq t \leq 20\}$$

(a linha contínua)†, que vêm da realização‡

$$(Z_1, \ldots, Z_{20}) = (1, -1, -1, -1, -1, 1, \ldots),$$

em que tomamos $1/\sqrt{10} = 0{,}316$.

*Nota do tradutor. o original traz $t = 1/M$; pela construção seria $t = i/M$.

†Nota do tradutor. o original traz $0 \leq t \leq 20$; pela figura e por $i = 0, 1, \ldots, 20$ com $t = i/10$, seria $0 \leq t \leq 2$.

‡Nota do tradutor. o original traz quatro -1 seguidos; pela Figura 11.5.1, a realização começa com $(1, -1, -1, -1, 1, 1, 1, \ldots)$.

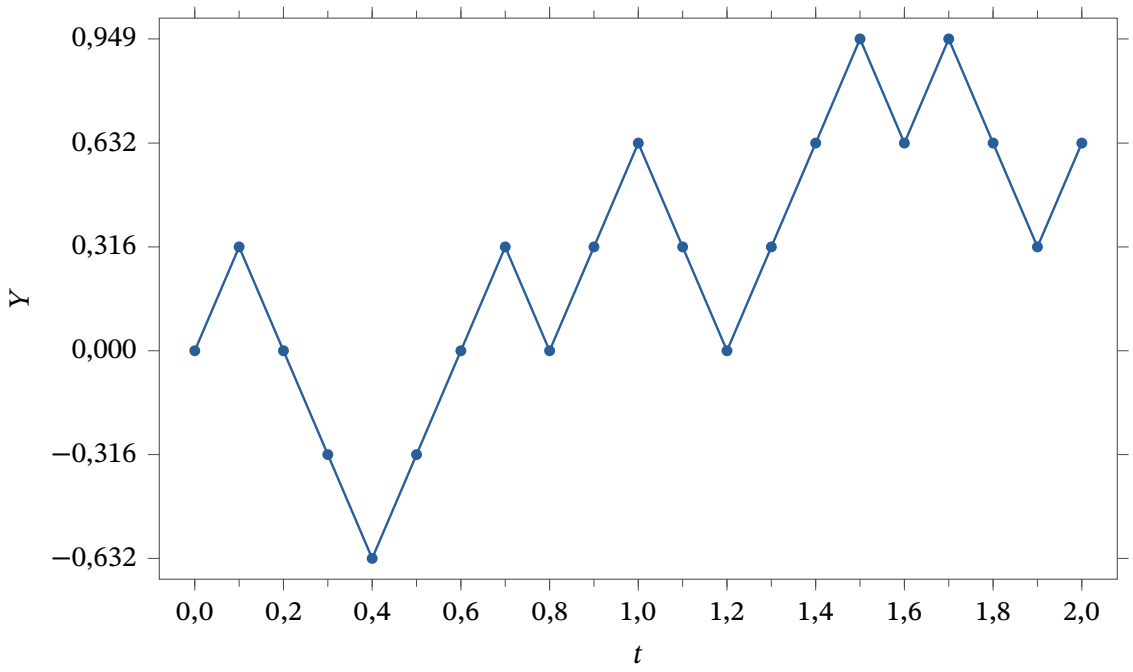


Figura 11.5.1: Gráfico de alguns valores de $Y_{i/10}^{(10)}$ e $Y_t^{*(10)}$.

A coleção de variáveis $\{Y_t^{*(M)} : t \geq 0\}$ é então um processo estocástico, mas agora indexado pelo parâmetro de tempo *contínuo* $t \geq 0$. Esse é um exemplo de *processo estocástico de tempo contínuo*[31].

Ora, os fatores M e $\sqrt{M}$ foram escolhidos com cuidado, como ilustra o teorema a seguir.

No original: *continuous-time stochastic process*[31].

Teorema 11.5.1

Seja $\{Y_t^{*(M)} : t \geq 0\}$ como definido anteriormente. Então, para M grande:

(a) Para $t \geq 0$, a distribuição de $Y_t^{*(M)}$ é aproximadamente $N(0, t)$, isto é, normal com média t.*

(b) Para $s, t \geq 0$, a covariância†

$$\text{Cov}\left(Y_t^{*(M)}, Y_t^{*(M)}\right)$$

é aproximadamente igual a $\min\{s, t\}$.

(c) Para $t \geq s \geq 0$, a distribuição do incremento $Y_t^{*(M)} - Y_s^{*(M)}$ é aproximadamente $N(0, t - s)$, isto é, normal com média 0 e variância $t - s$, e é aproximadamente independente de $Y_s^{*(M)}$.

(d) $Y_t^{*(M)}$ é uma função contínua de t.

Demonstração. Veja a Seção 11.7 para a demonstração deste resultado. ■

Usaremos esse teorema limite para construir o movimento browniano.

11.5.2 O Movimento Browniano como Limite

Já desenvolvemos os processos cada vez mais rápidos $\{Y_t^{*(M)} : t \geq 0\}$ e algumas de suas propriedades. O movimento browniano é então definido como o limite, quando $M \to \infty$, dos processos $\{Y_t^{*(M)} : t \geq 0\}$. Isto é, definimos o movimento browniano $\{B_t : t \geq 0\}$ dizendo que a distribuição de $\{B_t : t \geq 0\}$ é igual ao limite, quando $M \to \infty$, da distribuição de $\{Y_t^{*(M)} : t \geq 0\}$. Um gráfico de uma trajetória típica do movimento browniano está na Figura 11.5.2.

Dessa forma, todas as propriedades de $Y_t^{*(M)}$ para M grande, desenvolvidas no Teorema 11.5.1, valem para o movimento browniano, como segue.

*Nota do tradutor. o original traz "com média t"; por $N(0, t)$, seria média 0 e variância t.

†Nota do tradutor. o original traz as duas variáveis com índice t; pelo enunciado, seria $\text{Cov}(Y_s^{*(M)}, Y_t^{*(M)})$.

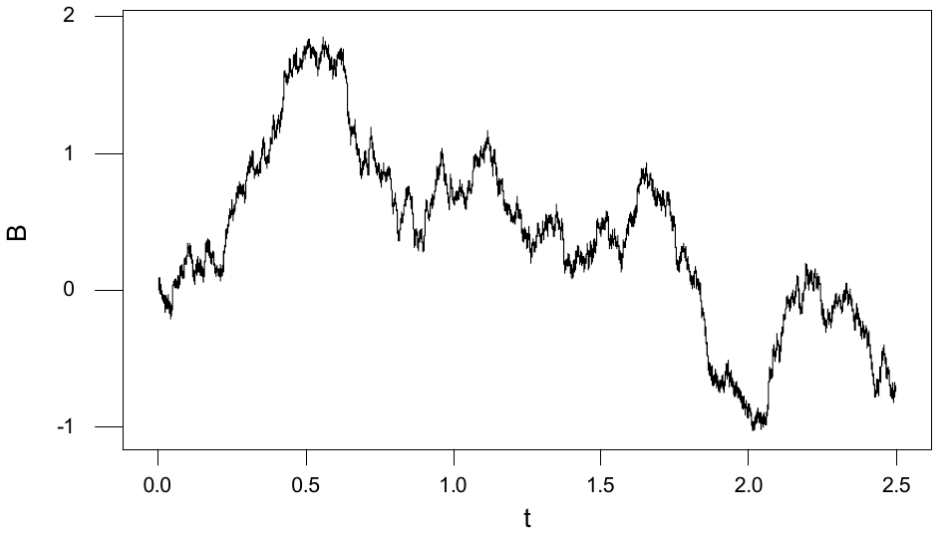


Figura 11.5.2: Um resultado típico do movimento browniano.

Teorema 11.5.2

Seja $\{B_t : t \geq 0\}$ o movimento browniano. Então

(a) B_t tem distribuição normal: $B_t \sim N(0, t)$ para todo $t \geq 0$;

(b) $\text{Cov}(B_s, B_t) = E(B_s B_t) = \min\{s, t\}$ para $s, t \geq 0$;

(c) se $0 < s < t$, então o incremento $B_t - B_s$ tem distribuição normal: $B_t - B_s \sim N(0, t - s)$; além disso, $B_t - B_s$ é independente de B_s;

(d) a função $\{B_t\}_{t \geq 0}$ é uma função contínua.

Esse teorema pode ser usado para calcular muitas coisas sobre o movimento browniano.

Exemplo 11.5.1

Seja $\{B_t\}$ o movimento browniano. Quanto vale $P(B_5 \leq 3)$?

Sabemos que $B_5 \sim N(0,5)$. Logo, $B_5/\sqrt{5} \sim N(0,1)$. Concluímos que

$$P(B_5 \leq 3) = P(B_5/\sqrt{5} \leq 3/\sqrt{5}) = \Phi(3/\sqrt{5}) = 0{,}910,$$

em que

$$\Phi(x) = \int_{-\infty}^{x} \frac{1}{\sqrt{2\pi}} e^{-s^2/2}\, ds$$

é a fda de uma distribuição normal padrão, e obtivemos o valor numérico na Tabela D.2. Assim, em cerca de 91% das vezes, o movimento browniano estará abaixo de 3 no instante 5. ■

Exemplo 11.5.2

Seja $\{B_t\}$ o movimento browniano. Quanto vale $P(B_7 \geq -4)$?

Sabemos que $B_7 \sim N(0,7)$. Logo, $B_7/\sqrt{7} \sim N(0,1)$. Concluímos que

$$\begin{aligned} P(B_7 \geq -4) &= 1 - P(B_7 \leq -4) = 1 - P(B_7/\sqrt{7} \leq -4/\sqrt{7}) \\ &= 1 - \Phi(-4/\sqrt{7}) = 1 - 0{,}065 = 0{,}935. \end{aligned}$$

Assim, em mais de 93% das vezes, o movimento browniano estará em pelo menos -4 no instante 7. ■

Exemplo 11.5.3

Seja $\{B_t\}$ o movimento browniano. Quanto vale $P(B_8 - B_6 \leq -1{,}5)$?

Sabemos que $B_8 - B_6 \sim N(0, 8-6) = N(0,2)$. Logo, $(B_8 - B_6)/\sqrt{2} \sim N(0,1)$. Concluímos que

$$P(B_8 - B_6 \leq -1{,}5) = P((B_8 - B_6)/\sqrt{2} \leq -1{,}5/\sqrt{2}) = \Phi(-1{,}5/\sqrt{2}) = 0{,}144.$$

Assim, em cerca de 14% das vezes, o movimento browniano diminuirá pelo menos 1,5 entre o instante 6 e o instante 8. ■

Exemplo 11.5.4

Seja $\{B_t\}$ o movimento browniano. Quanto vale $P(B_2 \leq -0{,}5, B_5 - B_2 \geq 1{,}5)$?

Pelo Teorema 11.5.2, vemos que $B_5 - B_2$ e B_2 são *independentes*. Logo,

$$P(B_2 \leq -0{,}5, B_5 - B_2 \geq 1{,}5) = P(B_2 \leq -0{,}5)\, P(B_5 - B_2 \geq 1{,}5).$$

Ora, sabemos que $B_2 \sim N(0, 2)$. Logo, $B_2/\sqrt{2} \sim N(0, 1)$, e

$$P(B_2 \leq -0{,}5) = P(B_2/\sqrt{2} \leq -0{,}5/\sqrt{2}) = \Phi(-0{,}5/\sqrt{2}).$$

Da mesma forma, $B_5 - B_2 \sim N(0, 3)$, de modo que $(B_5 - B_2)/\sqrt{3} \sim N(0, 1)$, e*

$$\begin{aligned} P(B_5 - B_2 \geq 1{,}5) &= P((B_5 - B_2)/\sqrt{3} \geq 1{,}5/\sqrt{3}) \\ &= 1 - P((B_5 - B_2)/\sqrt{3} < 1{,}5/\sqrt{3}) = \Phi(1{,}5/\sqrt{3}). \end{aligned}$$

Concluímos que

$$\begin{aligned} P(B_2 \leq -0{,}5, B_5 - B_2 \geq 1{,}5) &= P(B_2 \leq -0{,}5)\, P(B_5 - B_2 \geq 1{,}5) \\ &= \Phi(-0{,}5/\sqrt{2})\, \Phi(1{,}5/\sqrt{3}) = 0{,}292. \end{aligned}$$

Assim, em cerca de 29% das vezes, o movimento browniano não passará de $-1/2$ no instante 2 e depois aumentará pelo menos 1,5 entre o instante 2 e o instante 5. ■

Notamos também que, como o movimento browniano foi criado a partir de passeios aleatórios simples com $p = 1/2$, segue-se que o movimento browniano é um *martingal*. Isso implica que $E(B_t) = 0$ para todo t, mas é claro que já sabíamos disso, porque $B_t \sim N(0, t)$. Por outro lado, agora podemos usar o teorema da parada opcional (Teorema 11.4.2) para concluir que $E(B_T) = 0$, em que T é um tempo de parada (desde que, como de costume, T ou $\{B_t : t \leq T\}$ seja limitado). Isso nos permite calcular certas probabilidades, como segue.

*Nota do tradutor. o original traz $\Phi(1{,}5/\sqrt{3})$ no fim; pela conta, $1 - P(\cdots < 1{,}5/\sqrt{3}) = \Phi(-1{,}5/\sqrt{3})$, e o resultado final seria $\Phi(-0{,}5/\sqrt{2})\, \Phi(-1{,}5/\sqrt{3}) = 0{,}070$ (cerca de 7%), e não 0,292.

Exemplo 11.5.5

Seja $\{B_t\}$ o movimento browniano. Seja $c < 0 < b$. Qual é a probabilidade de o processo atingir c antes de atingir b?

Para resolver esse problema, seja τ_c o primeiro instante em que o processo atinge c, e τ_b o primeiro instante em que o processo atinge b. Seja então $T = \min\{\tau_c, \tau_b\}$ o primeiro instante em que o processo atinge c ou atinge b. A pergunta passa a ser: quanto vale $P(\tau_c < \tau_b)$? De modo equivalente, quanto vale $P(B_T = c)$?

Para resolver isso, notamos que devemos ter $E(B_T) = B_0 = 0$. Mas, se $h = P(B_T = c)$, então $B_T = c$ com probabilidade h, e $B_T = b$ com probabilidade $1 - h$. Logo, devemos ter $0 = E(B_T) = hc + (1 - h)b$, de modo que $h = b/(b - c)$. Concluímos que

$$P(B_T = c) = P(\tau_c < \tau_b) = \frac{b}{b - c}.$$

(Lembre que $c < 0$, de modo que aqui $b - c = |b| + |c|$.) ■

Por fim, notamos que, embora o movimento browniano seja uma função contínua, acontece que, com probabilidade um, o movimento browniano não é *diferenciável* em ponto nenhum! Essa é parte da razão pela qual o movimento browniano não é um bom modelo para o movimento de partículas reais. (Veja o Desafio 11.5.15 para um resultado relacionado a isso.) Ainda assim, o movimento browniano tem muitos outros usos, inclusive como modelo para preços de ações, que descrevemos agora.

11.5.3 Difusões e Preços de Ações

O movimento browniano é usado para construir vários processos de *difusão*, como segue.

Dado o movimento browniano $\{B_t\}$, podemos tomar

$$X_t = a + \delta t + \sigma B_t,$$

em que a e δ são números reais quaisquer e $\sigma \geq 0$. Então $\{X_t\}$ é uma difusão.

Aqui, a é o valor inicial, δ (chamado de *deriva*) é a taxa média de crescimento, e σ (chamado de *parâmetro de volatilidade*[32]) representa a quantidade de aleatoriedade da difusão.

No original: *volatility*[32].

Intuitivamente, X_t é aproximadamente igual à função linear $a + \delta t$, mas, por causa da aleatoriedade do movimento browniano, X_t assume valores *aleatórios* em torno dessa função linear.

A distribuição exata de X_t pode ser calculada, como segue.

Teorema 11.5.3

Seja $\{B_t\}$ o movimento browniano, e seja $X_t = a + \delta t + \sigma B_t$ uma difusão. Então

(a) $E(X_t) = a + \delta t$,

(b) $\text{Var}(X_t) = \sigma^2 t$,

(c) $X_t \sim N(a + \delta t, \sigma^2 t)$.

Demonstração. Sabemos que $B_t \sim N(0, 1)$, de modo que $E(B_t) = 0$ e $\text{Var}(B_t) = t$.* Além disso, $a + \delta t$ não é aleatório (isto é, é uma *constante* do ponto de vista das variáveis aleatórias). Logo,

$$E(X_t) = E(a + \delta t + \sigma B_t) = a + \delta t + \sigma E(B_t) = a + \delta t,$$

o que prova a parte (a).

Da mesma forma,

$$\text{Var}(X_t) = \text{Var}(a + \delta t + \sigma B_t) = \text{Var}(\sigma B_t) = \sigma^2 \text{Var}(B_t) = \sigma^2 t,$$

o que prova a parte (b).

Por fim, como X_t é uma função linear da variável aleatória[33] B_t, que tem distribuição normal, X_t tem de ter distribuição normal, pelo Teorema 4.6.1. Isso prova a parte (c). ■

Difusões são usadas com frequência como modelos para *preços de ações*. Isto é, supõe-se com frequência que o preço X_t de uma ação no instante t é dado por $X_t = a + \delta t + \sigma B_t$, para valores apropriados de a, δ e σ.

*Nota do tradutor. o original traz $N(0, 1)$; pelo Teorema 11.5.2(a) e por $\text{Var}(B_t) = t$, seria $N(0, t)$.

No original: *random variable*[33].

Exemplo 11.5.6

Suponha que uma ação tenha preço inicial de US$ 20, deriva de US$ 3 por ano e parâmetro de volatilidade 1,4. Qual é a probabilidade de o preço da ação estar acima de US$ 30 depois de dois anos e meio?

Aqui, o preço da ação depois de t anos é dado por $X_t = 20 + 3t + 1{,}4B_t$ e, portanto, é uma difusão.

Assim, depois de 2,5 anos, temos $X_{2,5} = 20 + 7{,}5 + 1{,}4B_{2,5} = 27{,}5 + 1{,}4B_{2,5}$. Logo,

$$\begin{aligned} P(X_{2,5} > 30) &= P(27{,}5 + 1{,}4B_{2,5} > 30) = P(B_{2,5} > (30 - 27{,}5)/1{,}4) \\ &= P(B_{2,5} > 1{,}79). \end{aligned}$$

Mas, como antes,

$$\begin{aligned} P(B_{2,5} > 1{,}79) &= 1 - P(B_{2,5} \leq 1{,}79) = 1 - P(B_{2,5}/\sqrt{2{,}5} \leq 1{,}79/\sqrt{2{,}5}) \\ &= 1 - \Phi(1{,}79/\sqrt{2{,}5}) = 0{,}129. \end{aligned}$$

Concluímos que $P(X_{2,5} > 30) = 0{,}129$.

Logo, a chance de a ação valer mais de US$ 30 depois de dois anos e meio é de pouco menos de 13%. ■

Exemplo 11.5.7

Suponha que uma ação tenha preço inicial de US$ 100, deriva de −US$ 2 por ano e parâmetro de volatilidade 5,5. Qual é a probabilidade de o preço da ação estar abaixo de US$ 90 depois de apenas meio ano?

Aqui, o preço da ação depois de t anos é dado por $X_t = 100 - 2t + 5{,}5B_t$ e, de novo, é uma difusão. Assim, depois de 0,5 ano, temos $X_{0,5} = 100 - 1{,}0 + 5{,}5B_{0,5} = 99 + 5{,}5B_{0,5}$. Logo,

$$\begin{aligned} P(X_{0,5} < 90) &= P(99 + 5{,}5B_{0,5} < 90) = P(B_{0,5} < (90 - 99)/5{,}5) \\ &= P(B_{0,5} < -1{,}64) = P(B_{0,5}/\sqrt{0{,}5} \leq -1{,}64/\sqrt{0{,}5}) \\ &= \Phi(-1{,}64/\sqrt{0{,}5}) = \Phi(-2{,}32) = 0{,}010. \end{aligned}$$

Portanto, a chance de a ação valer menos de US$ 90 depois de meio ano é de cerca de 1%. ■

De modo mais geral, a deriva δ e a volatilidade σ poderiam ser *funções* do valor

X_t, levando a difusões $\{X_t\}$ mais complicadas, que não estudaremos aqui.

Resumo da Seção 11.5

- O movimento browniano $\{B_t\}_{t\geq 0}$ é criado a partir do passeio aleatório simples com $p = 1/2$, acelerando o tempo por um fator grande M e encolhendo o espaço por um fator $1/\sqrt{M}$.
- Logo, $B_0 = 0$, $B_t \sim N(0,t)$, e $\{B_t\}$ tem incrementos normais independentes $B_t - B_s \sim N(0, t-s)$ para $0 \leq s < t$, e $\text{Cov}(B_s, B_t) = \min(s,t)$, e $\{B_t\}$ é uma função contínua.
- Difusões (usadas com frequência para modelar preços de ações) têm a forma $X_t = a + \delta t + \sigma B_t$.

Exercícios

11.5.1 Considere os processos acelerados $\{Y_{i/M}^{(M)}\}$ usados para construir o movimento browniano. Calcule as quantidades a seguir.

(a) $P(Y_1^{(1)} = 1)$

(b) $P(Y_1^{(2)} = 1)$

(c) $P(Y_1^{(2)} = \sqrt{2})$ (Sugestão: não se esqueça de que $\sqrt{2} = 2/\sqrt{2}$.)

(d) $P(Y_1^{(M)} \geq 1)$ para $M = 1$, $M = 2$, $M = 3$ e $M = 4$

11.5.2 Seja $\{B_t\}$ o movimento browniano. Calcule $P(B_1 \geq 1)$.

11.5.3 Seja $\{B_t\}$ o movimento browniano. Calcule cada uma das quantidades a seguir.

(a) $P(B_2 \geq 1)$

(b) $P(B_3 \leq -4)$

(c) $P(B_9 - B_5 \leq 2{,}4)$

(d) $P(B_{26} - B_{11} > 9{,}8)$

(e) $P(B_{26,3} \leq -6)$

(f) $P(B_{26,3} \leq 0)$

11.5.4 Seja $\{B_t\}$ o movimento browniano. Calcule cada uma das quantidades a seguir.

(a) $P(B_2 \geq 1, B_5 - B_2 \geq 2)$

(b) $P(B_5 < -2, B_{13} - B_5 \geq 4)$

(c) $P(B_{8,4} > 3{,}2, B_{18,6} - B_{8,4} \geq 0{,}9)$

11.5.5 Seja $\{B_t\}$ o movimento browniano. Calcule $E(B_{13}B_8)$. (Sugestão: não se esqueça da parte (b) do Teorema 11.5.2.)

11.5.6 Seja $\{B_t\}$ o movimento browniano. Calcule $E((B_{17} - B_{14})^2)$ de duas maneiras.

(a) Use o fato de que $B_{17} - B_{14} \sim N(0, 3)$.

(b) Desenvolva o quadrado e calcule $E(B_{17}^2) - 2\,E(B_{17}B_{14}) + E(B_{14}^2)$.

11.5.7 Seja $\{B_t\}$ o movimento browniano.

(a) Calcule a probabilidade de o processo atingir -5 antes de atingir 15.

(b) Calcule a probabilidade de o processo atingir -15 antes de atingir 5.

(c) Qual das respostas às partes (a) e (b) é maior? Por que isso acontece?

(d) Calcule a probabilidade de o processo atingir 15 antes de atingir -5.

(e) Quanto vale a soma das respostas às partes (a) e (d)? Por que isso acontece?

11.5.8 Seja $X_t = 5 + 3t + 2B_t$ uma difusão (de modo que $a = 5$, $\delta = 3$ e $\sigma = 2$). Calcule cada uma das quantidades a seguir.

(a) $E(X_7)$

(b) $\text{Var}(X_{8,1})$

(c) $P(X_{2,5} < 12)$

(d) $P(X_{17} > 50)$

11.5.9 Seja $X_t = 10 - 1{,}5t + 4B_t$. Calcule $E(X_3X_5)$.

11.5.10 Suponha que uma ação tenha preço inicial de US$ 400 e parâmetro de volatilidade igual a 9. Calcule a probabilidade de o preço da ação estar acima de US$ 500 depois de 8 anos, se a deriva por ano for igual a

(a) US$ 0.

(b) US$ 5.

(c) US$ 10.

(d) US$ 20.

11.5.11 Suponha que uma ação tenha preço inicial de US$ 200 e deriva de US$ 3 por ano. Calcule a probabilidade de o preço da ação estar acima de US$ 250 depois de 10 anos, se o parâmetro de volatilidade for igual a

(a) 1.

(b) 4.

(c) 10.

(d) 100.

Problemas

11.5.12 Seja $\{B_t\}$ o movimento browniano, e seja $X = 2B_3 - 7B_5$. Calcule a média e a variância de X.

11.5.13 Prove que $P(B_t < x) = P(B_t > -x)$ para todo $t \geq 0$ e todo $x \in R^1$.

Desafios

11.5.14 Calcule $P(B_s \leq x \mid B_t = y)$, em que $0 < s < t$ e $x, y \in R^1$. (Sugestão: você vai precisar usar densidades condicionais.)

11.5.15

(a) Seja $f : R^1 \to R^1$ uma *função de Lipschitz*, isto é, uma função para a qual existe $K < \infty$ tal que $|f(x) - f(y)| \leq K|x - y|$ para todos $x, y \in R^1$. Calcule

$$\lim_{h \searrow 0} \frac{(f(t+h) - f(t))^2}{h}$$

para qualquer $t \in R^1$.

(b) Seja $\{B_t\}$ o movimento browniano. Calcule

$$\lim_{h \searrow 0} E\left(\frac{(B_{t+h} - B_t)^2}{h}\right)$$

para qualquer $t > 0$.

(c) O que as partes (a) e (b) parecem implicar sobre o movimento browniano?

(d) É um fato conhecido que toda função continuamente diferenciável num intervalo fechado é de Lipschitz. À luz disso, o que a parte (c) parece implicar sobre o movimento browniano?

Tópicos para discussão

11.5.16 Difusões como as discutidas aqui (e versões mais complicadas, com coeficientes variáveis) são usadas com muita frequência por grandes investidores e operadores do mercado de ações para modelar preços de ações.

(a) Você acha que as difusões fornecem bons modelos para preços de ações?

(b) Mesmo que as difusões *não* fornecessem bons modelos para preços de ações, por que os investidores ainda poderiam precisar conhecê-las?

11.6 Processos de Poisson

Por fim, voltamos nossa atenção para os processos de Poisson. Esses processos são modelos para eventos que acontecem em instantes aleatórios T_n. Por exemplo, T_n pode ser o instante do n-ésimo incêndio numa cidade, ou da detecção da n-ésima partícula por um contador Geiger, ou da passagem do n-ésimo carro por um posto de controle numa estrada. Os processos de Poisson fornecem um modelo para as probabilidades de quando esses eventos podem ocorrer.

Mais formalmente, seja $a > 0$ e sejam $R_1, R_2, \ldots$ variáveis aleatórias i.i.d., cada uma com distribuição Exponencial(a). Seja $T_0 = 0$ e, para $n \geq 1$,

$$T_n = R_1 + R_2 + \cdots + R_n.$$

O valor T_n corresponde, assim, ao instante (aleatório) do n-ésimo evento.

Definimos também uma coleção de variáveis de contagem N_t, da seguinte forma. Para $t \geq 0$, seja

$$N_t = \max\{n : T_n \leq t\}.$$

Isto é, N_t conta o número de eventos que aconteceram até o instante t. (Em particular, $N_0 = 0$. Além disso, $N_t = 0$ para todo $t < T_1$, isto é, antes de ocorrer o primeiro evento.)

Podemos pensar na coleção de variáveis N_t, para $t \geq 0$, como um processo estocástico, indexado pelo parâmetro de tempo contínuo $t \geq 0$. O processo $\{N_t : t \geq 0\}$ é, assim, mais um exemplo, como o movimento browniano, de um *processo estocástico de tempo contínuo*.

Na verdade, $\{N_t : t \geq 0\}$ é chamado de *processo de Poisson*[34] (com *intensidade* a). Esse nome vem do resultado a seguir.

Teorema 11.6.1

Para qualquer $t > 0$, a distribuição de N_t é Poisson(at).

Demonstração. Veja a Seção 11.7 para a demonstração deste resultado. ■

Na verdade, vale ainda mais.

Teorema 11.6.2

Seja $0 = t_0 \leq t_1 < t_2 < t_3 < \cdots < t_d$. Então, para $i = 1, 2, \ldots, d$, a distribuição de $N_{t_i} - N_{t_{i-1}}$ é Poisson$(a(t_i - t_{i-1}))$. Além disso, as variáveis aleatórias $N_{t_i} - N_{t_{i-1}}$, para $i = 1, \ldots, d$, são independentes.

Demonstração. Veja a Seção 11.7 para a demonstração deste resultado. ■

Exemplo 11.6.1

Seja $\{N_t\}$ um processo de Poisson com intensidade $a = 5$. Quanto vale $P(N_3 = 12)$?

Aqui, $N_3 \sim \text{Poisson}(3a) = \text{Poisson}(15)$. Logo, pela definição da distribuição de Poisson, temos

$$P(N_3 = 12) = e^{-15}(15)^{12} / 12! = 0{,}083,$$

o que é um pouco mais de 8%. ■

No original: *Poisson process*[34].

Exemplo 11.6.2

Seja $\{N_t\}$ um processo de Poisson com intensidade $a = 2$. Quanto vale $P(N_6 = 11)$?

Aqui, $N_6 \sim \text{Poisson}(6a) = \text{Poisson}(12)$. Logo,

$$P(N_6 = 11) = e^{-12}(12)^{11}/11! = 0{,}114,$$

ou seja, pouco mais de 11%. ■

Exemplo 11.6.3

Seja $\{N_t\}$ um processo de Poisson com intensidade $a = 4$. Quanto vale $P(N_2 = 3, N_5 = 4)$? (Lembre que aqui a vírgula significa "e" em afirmações de probabilidade.)

Começamos escrevendo $P(N_2 = 3, N_5 = 4) = P(N_2 = 3, N_5 - N_2 = 1)$. Isso é apenas reescrever a pergunta. No entanto, coloca-a num contexto em que podemos usar o Teorema 11.6.2.

De fato, por esse teorema, N_2 e $N_5 - N_2$ são independentes, com $N_2 \sim \text{Poisson}(8)$ e $N_5 - N_2 \sim \text{Poisson}(12)$. Logo,

$$\begin{aligned} P(N_2 = 3, N_5 = 4) &= P(N_2 = 3, N_5 - N_2 = 1) \\ &= P(N_2 = 3)\, P(N_5 - N_2 = 1) \\ &= e^{-8}\frac{8^3}{3!}\, e^{-12}\frac{12^1}{1!} = 0{,}0000021. \end{aligned}$$

Vemos, assim, que o evento $\{N_2 = 3, N_5 = 4\}$ é muito improvável neste caso. ■

Resumo da Seção 11.6

- Os processos de Poisson são modelos de eventos que acontecem em instantes aleatórios T_n.
- Supõe-se que o tempo $R_n = T_n - T_{n-1}$ entre eventos consecutivos tem distribuição Exponencial(a) para algum $a > 0$. Então N_t representa o número total de eventos até o instante t.
- Segue que $N_t \sim \text{Poisson}(at)$ e, na verdade, o processo $\{N_t\}_{t\geq 0}$ tem incrementos independentes, com $N_t - N_s \sim \text{Poisson}(a(t-s))$ para $0 \leq s < t$.

Exercícios

11.6.1 Seja $\{N(t)\}_{t\geq 0}$ um processo de Poisson com intensidade $a = 7$. Calcule as probabilidades a seguir.

(a) $P(N_2 = 13)$

(b) $P(N_5 = 3)$

(c) $P(N_6 = 20)$.

(d) $P(N_{50} = 340)$

(e) $P(N_2 = 13, N_5 = 3)$.

(f) $P(N_2 = 13, N_6 = 20)$

(g) $P(N_2 = 13, N_5 = 3, N_6 = 20)$

11.6.2 Seja $\{N(t)\}_{t\geq 0}$ um processo de Poisson com intensidade $a = 3$. Calcule $P(N_{1/2} = 6)$ e $P(N_{0,3} = 5)$.

11.6.3 Seja $\{N(t)\}_{t\geq 0}$ um processo de Poisson com intensidade $a = 1/3$. Calcule $P(N_2 = 6)$ e $P(N_3 = 5)$.

11.6.4 Seja $\{N(t)\}_{t\geq 0}$ um processo de Poisson com intensidade $a = 3$. Calcule $P(N_2 = 6, N_3 = 5)$. Explique sua resposta.

11.6.5 Seja $\{N(t)\}_{t\geq 0}$ um processo de Poisson com intensidade $a > 0$. Calcule (com explicação) a probabilidade condicional[35] $P(N_{2,6} = 2 \mid N_{2,9} = 2)$.

11.6.6 Seja $\{N(t)\}_{t\geq 0}$ um processo de Poisson com intensidade $a = 1/3$. Calcule (com explicação) as probabilidades condicionais a seguir.

(a) $P(N_6 = 5 \mid N_9 = 5)$

(b) $P(N_6 = 5 \mid N_9 = 7)$

(c) $P(N_9 = 5 \mid N_6 = 7)$

(d) $P(N_9 = 7 \mid N_6 = 7)$

(e) $P(N_9 = 12 \mid N_6 = 7)$

No original: *conditional probability*[35].

Problemas

11.6.7 Seja $\{N_t : t \geq 0\}$ um processo de Poisson com intensidade $a > 0$. Seja $0 < s < t$ e seja j um inteiro positivo.

(a) Calcule (com explicação) a probabilidade condicional $P(N_s = j \mid N_t = j)$.

(b) A resposta do item (a) depende do valor da intensidade a? Intuitivamente, por quê?

11.6.8 Seja $\{N_t : t \geq 0\}$ um processo de Poisson com intensidade $a > 0$. Seja T_1 o instante do primeiro evento, como de costume. Seja $0 < s < t$.

(a) Calcule $P(N_s = 1 \mid N_t = 1)$. (Se quiser, pode usar o problema anterior, com $j = 1$.)

(b) Suponha que t esteja fixo, mas que s possa variar no intervalo $(0, t)$. O que a resposta do item (b)* diz sobre a "distribuição condicional[36]" de T_1, condicionada a saber que $N_t = 1$?

11.7 Demonstrações Adicionais

Demonstração do Teorema 11.1.1

Queremos provar que, quando $\{X_n\}$ é um passeio aleatório simples, n é um inteiro positivo e k é um inteiro tal que $-n \leq k \leq n$ e $n + k$ é par, então

$$P(X_n = a + k) = \binom{n}{\frac{n+k}{2}} p^{(n+k)/2} q^{(n-k)/2}.$$

Para todos os outros valores de k, temos $P(X_n = a + k) = 0$. Além disso,

$$E(X_n) = a + n(2p - 1).$$

Das primeiras n apostas, seja W_n o número de apostas ganhas e L_n o número de apostas perdidas. Então $n = W_n + L_n$. Além disso, $X_n = a + W_n - L_n$.

Somando essas duas equações, concluímos que $n + X_n = W_n + L_n + a + W_n - L_n = a + 2W_n$. Resolvendo para W_n, vemos que $W_n = (n + X_n - a)/2$. Como W_n

*Nota do tradutor. o original diz "part (b)" dentro do próprio item (b); pelo sentido seria o item (a)

No original: *conditional distribution*[36].

tem de ser inteiro, segue que $n + X_n - a$ tem de ser par. Concluímos que $P(X_n = a + k) = 0$, a menos que $n + k$ seja par.

Por outro lado, resolvendo para X_n, vemos que $X_n = a + 2W_n - n$, ou $X_n - a = 2W_n - n$. Como $0 \leq W_n \leq n$, segue que $-n \leq X_n - a \leq n$, isto é, que $P(X_n = a + k) = 0$ se $k < -n$ ou $k > n$.

Suponha agora que $k + n$ seja par e que $-n \leq k \leq n$. Então, pelo que vimos acima, $P(X_n = a + k) = P(W_n = (n + k)/2)$. Mas a distribuição de W_n é claramente Binomial(n, p). Concluímos que

$$P(X_n = a + k) = \binom{n}{\frac{n+k}{2}} p^{(n+k)/2} q^{(n-k)/2},$$

desde que $k + n$ seja par e $-n \leq k \leq n$.

Por fim, como $W_n \sim$ Binomial(n, p), temos $E(W_n) = np$. Logo, como $X_n = a + 2W_n - n$, temos $E(X_n) = a + 2E(W_n) - n = a + 2np - n = a + n(2p - 1)$, como afirmado. ■

Demonstração do Teorema 11.1.2

Queremos provar que, quando $\{X_n\}$ é um passeio aleatório simples, com alguma fortuna inicial a e probabilidade p de ganhar cada aposta, e $0 < a < c$, então a probabilidade $P(\tau_c < \tau_0)$ de atingir c antes de 0 é dada por

$$P(\tau_c < \tau_0) = \begin{cases} a/c & p = 1/2 \\ \dfrac{1 - \left(\frac{q}{p}\right)^a}{1 - \left(\frac{q}{p}\right)^c} & p \neq 1/2. \end{cases}$$

Para começar, escrevemos $s(b)$ para a probabilidade $P(\tau_c < \tau_0)$ quando se parte da fortuna inicial b, para qualquer $0 \leq b \leq c$. Estamos interessados em calcular $s(a)$. No entanto, acaba sendo mais fácil resolver para *todos* os valores $s(0), s(1), s(2), \ldots, s(c)$ simultaneamente, e esse é o truque que usamos.

Por definição, temos $s(0) = 0$ (isto é, se começamos com US$ 0, nunca podemos ganhar) e $s(c) = 1$ (isto é, se começamos com US$ c, já ganhamos). Esses dois casos, portanto, são fáceis. No entanto, os valores de $s(b)$ para $1 \leq b \leq c - 1$ não se obtêm com a mesma facilidade.

Nosso truque será desenvolver equações que relacionam os valores $s(b)$ para valores *diferentes* de b. De fato, suponha $1 \leq b \leq c - 1$. É difícil calcular $s(b)$ diretamente. No entanto, é fácil entender o que vai acontecer na *primeira*

aposta: ou perdemos US$ 1 com probabilidade p, ou ganhamos US$ 1 com probabilidade q*. Isso leva ao resultado a seguir.

Lema 11.7.1

Para $1 \leq b \leq c-1$, temos

$$s(b) = ps(b+1) + qs(b-1). \tag{11.7.1}$$

Demonstração. Suponha primeiro que ganhamos a primeira aposta, isto é, que $Z_1 = 1$. *Depois* dessa primeira aposta, teremos fortuna $b+1$. Podemos então "recomeçar" nossa busca por atingir c antes de atingir 0, só que agora partindo da fortuna $b+1$ em vez de b. Logo, depois de ganhar essa primeira aposta, nossa chance de atingir c antes de atingir 0 passa a ser $s(b+1)$. (Ainda não sabemos quanto vale $s(b+1)$, mas pelo menos estamos fazendo uma ligação entre $s(b)$ e $s(b+1)$.)

Suponha, ao contrário, que perdemos essa primeira aposta, isto é, que $Z_1 = -1$. Depois dessa primeira aposta, teremos fortuna $b-1$. Podemos então "recomeçar" com a fortuna $b-1$ em vez de b. Logo, depois dessa primeira aposta, nossa chance de atingir c antes de atingir 0 passa a ser $s(b-1)$.

Podemos combinar todas as informações anteriores da seguinte forma.

$$\begin{aligned} s(b) &= P(\tau_c < \tau_0) \\ &= P(Z_1 = 1, \tau_c < \tau_0) + P(Z_1 = -1, \tau_c < \tau_0) \\ &= ps(b+1) + qs(b-1) \end{aligned}$$

Isto é, $s(b) = p\,s(b+1) + q\,s(b-1)$, como afirmado. ■

E então, onde estamos? Tínhamos $c+1$ incógnitas, $s(0), s(1), \ldots, s(c)$. Agora conhecemos as duas equações $s(0) = 0$ e $s(c) = 1$, mais as $c-1$ equações da forma $s(b) = p\,s(b+1) + q\,s(b-1)$ para $b = 1, 2, \ldots, c-1$. Em outras palavras, temos $c+1$ equações em $c+1$ incógnitas, e agora podemos resolver nosso problema!

A solução ainda exige vários passos algébricos, como segue.

*Nota do tradutor. o original troca as probabilidades: pela definição de p e pela demonstração do Lema 11.7.1, ganhamos com probabilidade p e perdemos com probabilidade q

Lema 11.7.2

Para $1 \leq b \leq c-1$, temos

$$s(b+1) - s(b) = \frac{q}{p}\big(s(b) - s(b-1)\big).$$

Demonstração. Lembrando que $p + q = 1$, reorganizamos (11.7.1) da seguinte forma.

$$\begin{aligned} s(b) &= p\,s(b+1) + q\,s(b-1) \\ (p+q)s(b) &= p\,s(b+1) + q\,s(b-1) \\ q\big(s(b) - s(b-1)\big) &= p\big(s(b+1) - s(b)\big) \end{aligned}$$

E, por fim,

$$s(b+1) - s(b) = \frac{q}{p}\big(s(b) - s(b-1)\big),$$

o que dá o resultado. ■

Lema 11.7.3

Para $0 \leq b \leq c$, temos

$$s(b) = \sum_{i=0}^{b-1} \left(\frac{q}{p}\right)^i s(1). \tag{11.7.2}$$

Demonstração. Aplicando a equação do Lema 11.7.2 com $b = 1$, obtemos

$$s(2) - s(1) = \frac{q}{p}\big(s(1) - s(0)\big) = \frac{q}{p}s(1)$$

(pois $s(0) = 0$). Aplicando-a *de novo* com $b = 2$, obtemos

$$s(3) - s(2) = \frac{q}{p}\big(s(2) - s(1)\big) = \left(\frac{q}{p}\right)^2 \big(s(1) - s(0)\big) = \left(\frac{q}{p}\right)^2 s(1).$$

Por indução, vemos que

$$s(b+1) - s(b) = \left(\frac{q}{p}\right)^b s(1),$$

para $b = 0, 1, 2, \ldots, c-1$. Logo, calculamos que, para $b = 0, 1, 2, \ldots, c$,

$$\begin{aligned} s(b) &= \big(s(b) - s(b-1)\big) + \big(s(b-1) - s(b-2)\big) + \big(s(b-2) - s(b-3)\big) + \cdots \\ &\quad + \big(s(1) - s(0)\big) \\ &= \sum_{i=0}^{b-1} \big(s(i+1) - s(i)\big) = \sum_{i=0}^{b-1} \left(\frac{q}{p}\right)^i s(1). \end{aligned}$$

Isso dá o resultado. ■

Agora podemos terminar a demonstração do Teorema 11.1.2.

Se $p = 1/2$, então $q/p = 1$, de modo que (11.7.2) se torna $s(b) = bs(1)$. Mas $s(c) = 1$, então devemos ter $cs(1) = 1$, isto é, $s(1) = 1/c$. Então $s(b) = bs(1) = b/c$. Logo, $s(a) = a/c$ neste caso.

Se $p \neq 1/2$, então $q/p \neq 1$, de modo que (11.7.2) é uma série geométrica e se torna

$$s(b) = \frac{(q/p)^b - 1}{(q/p) - 1} s(1).$$

Como $s(c) = 1$, devemos ter

$$1 = \frac{(q/p)^c - 1}{(q/p) - 1} s(1),$$

então

$$s(1) = \frac{(q/p) - 1}{(q/p)^c - 1}.$$

Então

$$s(b) = \frac{(q/p)^b - 1}{(q/p) - 1} s(1) = \frac{(q/p)^b - 1}{(q/p) - 1} \frac{(q/p) - 1}{(q/p)^c - 1} = \frac{(q/p)^b - 1}{(q/p)^c - 1}.$$

Logo,

$$s(a) = \frac{(q/p)^a - 1}{(q/p)^c - 1}$$

neste caso. ■

Demonstração do Teorema 11.1.3

Queremos provar que, quando $\{X_n\}$ é um passeio aleatório simples, com fortuna inicial $a > 0$ e probabilidade p de ganhar cada aposta, então a probabilidade $P(\tau_0 < \infty)$ de o passeio algum dia atingir 0 é dada por

$$P(\tau_0 < \infty) = \begin{cases} 1 & p \leq 1/2 \\ (q/p)^a & p > 1/2. \end{cases}$$

Pela continuidade das probabilidades, vemos que

$$P(\tau_0 < \infty) = \lim_{c \to \infty} P(\tau_0 < \tau_c) = \lim_{c \to \infty} \big(1 - P(\tau_c < \tau_0)\big).$$

Logo, se $p = 1/2$, então $P(\tau_0 < \infty) = \lim_{c \to \infty}(1 - a/c) = 1$.

Agora, se $p \neq 1/2$, então

$$P(\tau_0 < \infty) = \lim_{c \to \infty} \left(1 - \frac{1 - (q/p)^a}{1 - (q/p)^c}\right).$$

Se $p < 1/2$, então $q/p > 1$, de modo que $\lim_{c\to\infty}(q/p)^c = \infty$ e $P(\tau_0 < \infty) = 1$. Se $p > 1/2$, então $q/p < 1$, de modo que $\lim_{c\to\infty}(q/p)^c = 0$ e $P(\tau_0 < \infty) = (q/p)^a$. ■

Demonstração do Teorema 11.3.3

Queremos provar que o algoritmo de Metropolis–Hastings resulta numa cadeia de Markov $X_0, X_1, X_2, \ldots$ que tem $\{\pi_i\}$ como distribuição estacionária.

Vamos provar que a cadeia de Markov resultante é *reversível* em relação a $\{\pi_i\}$, isto é, que

$$\pi_i P(X_{n+1} = j \mid X_n = i) = \pi_j P(X_{n+1} = i \mid X_n = j), \tag{11.7.3}$$

para $i, j \in S$. Segue então do Teorema 11.2.6 que $\{\pi_i\}$ é uma distribuição estacionária da cadeia.

Temos, assim, de provar (11.7.3). Ora, (11.7.3) é claramente verdadeira se $i = j$, de modo que podemos supor $i \neq j$.

Mas, se $i \neq j$ e $X_n = i$, então a única maneira de termos $X_{n+1} = j$ é se $Y_{n+1} = j$ (isto é, *propomos* o estado j, o que faremos com probabilidade p_{ij}*). Além disso, *aceitamos* essa proposta (o que faremos com probabilidade α_{ij}). Logo,

$$P(X_{n+1} = j \mid X_n = i) = q_{ij}\alpha_{ij} = q_{ij} \min\left\{1, \frac{\pi_j q_{ji}}{\pi_i q_{ij}}\right\} = \min\left\{q_{ij}, \frac{\pi_j q_{ji}}{\pi_i}\right\}.$$

Segue que $\pi_i P(X_{n+1} = j \mid X_n = i) = \min\{\pi_i q_{ij}, \pi_j q_{ji}\}$.

Da mesma forma, calculamos que $\pi_j P(X_{n+1} = i \mid X_n = j) = \min\{\pi_j q_{ji}, \pi_i q_{ij}\}$. Segue que (11.7.3) é verdadeira. ■

Demonstração do Teorema 11.5.1

Queremos provar que, quando $\{Y_t^{*(M)} : t \geq 0\}$ é como definido anteriormente, então, para M grande:

(a) Para $t \geq 0$, a distribuição de $Y_t^{*(M)}$ é aproximadamente $N(0, t)$, isto é, normal com média t†.

(b) Para $s, t \geq 0$, a covariância[37]

$$\mathrm{Cov}\left(Y_t^{*(M)}, Y_t^{*(M)}\right)$$

*Nota do tradutor. o original traz p_{ij}; pela fórmula logo abaixo, a probabilidade de propor j é q_{ij}

†Nota do tradutor. o original diz "mean t"; para $N(0, t)$, a média é 0 e a variância é t

No original: *covariance*[37].

é aproximadamente igual a $\min\{s,t\}$*.

(c) Para $t \geq s \geq 0$, a distribuição do incremento

$$Y_t^{*(M)} - Y_s^{*(M)}$$

é aproximadamente $N(0, t-s)$, isto é, normal com média 0 e variância $t-s$, e é aproximadamente independente de $Y_s^{*(M)}$.

(d) $Y_t^{*(M)}$ é uma função contínua de t.

Escreva $\lfloor r \rfloor$ para o maior inteiro que não excede r, de modo que, por exemplo, $\lfloor 7{,}6 \rfloor = 7$. Vemos então que, para M grande, t fica muito próximo de $\lfloor tM \rfloor / M$, de modo que $Y_t^{*(M)}$ fica muito próximo (formalmente, a menos de $O(1/M)$ em probabilidade) de

$$A = Y^{(M)}_{\lfloor tM \rfloor / M} = \frac{1}{\sqrt{M}}\big(Z_1 + Z_2 + \cdots + Z_{\lfloor tM \rfloor}\big).$$

Ora, A é igual a $1/\sqrt{M}$ vezes a soma de $\lfloor tM \rfloor$ variáveis aleatórias i.i.d. diferentes, cada uma com média 0 e variância 1. Segue do teorema central do limite que A converge em distribuição para a distribuição $N(0,t)$ quando $M \to \infty$. Isso prova o item (a).

Para o item (b), note que também $Y_s^{*(M)}$ fica muito próximo de

$$B = Y^{(M)}_{\lfloor sM \rfloor / M} = \frac{1}{\sqrt{M}}\big(Z_1 + Z_2 + \cdots + Z_{\lfloor sM \rfloor}\big).$$

Como $E(Z_i) = 0$, devemos ter $E(A) = E(B) = 0$, de modo que $\mathrm{Cov}(A,B) = E(AB)$.

Para simplificar, suponha $s \leq t$; o caso $s > t$ é análogo. Então temos

$$\begin{aligned}
\mathrm{Cov}(A,B) &= E(AB) \\
&= \frac{1}{M} E\Big(\big(Z_1 + Z_2 + \cdots + Z_{\lfloor sM \rfloor}\big)\big(Z_1 + Z_2 + \cdots + Z_{\lfloor tM \rfloor}\big)\Big) \\
&= \frac{1}{M} E\left(\sum_{i=1}^{\lfloor sM \rfloor} \sum_{j=1}^{\lfloor tM \rfloor} Z_i Z_j\right) = \frac{1}{M} \sum_{i=1}^{\lfloor sM \rfloor} \sum_{j=1}^{\lfloor tM \rfloor} E(Z_i Z_j).
\end{aligned}$$

Ora, temos $E(Z_i Z_j) = 0$, a menos que $i = j$, caso em que $E(Z_i Z_j) = 1$. Haverá exatamente $\lfloor sM \rfloor$ termos na soma em que $i = j$, a saber, um para cada valor de i (pois $t \geq s$). Logo,

$$\mathrm{Cov}(A,B) = \frac{\lfloor sM \rfloor}{M},$$

*Nota do tradutor. o original traz $Y_t^{*(M)}$ nos dois argumentos; pelo enunciado de $\min\{s,t\}$ e pela demonstração, seria $\mathrm{Cov}(Y_s^{*(M)}, Y_t^{*(M)})$

que converge para s quando $M \to \infty$. Isso prova o item (b).

O item (c) segue de modo muito parecido com o item (a). Por fim, o item (d) segue porque a função $Y_t^{(M)}$ foi construída de maneira contínua (como na Figura 11.5.1). ■

Demonstração do Teorema 11.6.1

Queremos provar que, para qualquer $t > 0$, a distribuição de N_t é Poisson(at).

Primeiro precisamos de um lema técnico.

Lema 11.7.4

Seja $g_n(t) = e^{-at}a^n t^{n-1}/(n-1)!$ a densidade da distribuição Gama(n, a). Então, para $n \geq 1$,

$$\int_0^t g_n(s)\,ds = \sum_{i=n}^{\infty} e^{-at}(at)^i/i!. \tag{11.7.4}$$

Demonstração. Se $t = 0$, os dois lados valem 0. Para os outros valores de t, derivando em relação a t, vemos (fazendo $j = i - 1$) que

$$\begin{aligned}
\frac{\partial}{\partial t}\sum_{i=n}^{\infty} e^{-at}(at)^i/i! &= \sum_{i=n}^{\infty}\left(-ae^{-at}(at)^i/i! + e^{-at}a^i t^{i-1}/(i-1)!\right) \\
&= \sum_{i=n}^{\infty}\left(-e^{-at}a^{i+1}t^i/i!\right) + \sum_{j=n-1}^{\infty} e^{-at}a^{j+1}t^j/j! \\
&= e^{-at}a^{(n-1)+1}t^{n-1}/(n-1)! = g_n(t) = \frac{\partial}{\partial t}\int_0^t g_n(s)\,ds.
\end{aligned}$$

Como isso vale para todo $t \geq 0$, vemos que (11.7.4) é satisfeita para qualquer $n \geq 0$*. ■

Lembre (veja o Exemplo 2.4.16) que a distribuição Exponencial(λ) é a mesma que a distribuição Gama$(1, \lambda)$. Além disso (veja o Problema 2.9.15), se $X \sim$ Gama(α_1, λ) e $Y \sim$ Gama(α_2, λ) são independentes, então $X + Y \sim$ Gama$(\alpha_1 + \alpha_2, \lambda)$.

Ora, no nosso caso, temos $T_n = R_1 + R_2 + \cdots + R_n$, em que $R_i \sim$ Exponencial$(a) =$ Gama$(1, a)$. Segue que $T_n \sim$ Gama(n, a). Logo, a densidade de T_n é $g_n(t) = e^{-at}a^n t^{n-1}/(n-1)!$.

*Nota do tradutor. o original diz $n \geq 0$, mas o lema é enunciado para $n \geq 1$ e g_0 não está definida

Ora, o evento $N_t \geq n$ (isto é, o número de eventos até o instante t é pelo menos n) é o mesmo que o evento $T_n \leq t$ (isto é, o n-ésimo evento ocorre antes do instante n*). Logo,

$$P(N_t \geq n) = P(T_n \leq t) = \int_0^t g_n(s)\, ds.$$

Então, pelo Lema 11.7.4,

$$P(N_t \geq n) = \sum_{i=n}^{\infty} e^{-at} \frac{(at)^i}{i!} \tag{11.7.5}$$

para qualquer $n \geq 1$. Se $n = 0$, os dois lados valem 1, de modo que, na verdade, (11.7.5) vale para qualquer $n \geq 0$.

Usando isso, vemos que

$$\begin{aligned} P(N_t = j) &= P(N_t \geq j) - P(N_t \geq j+1) \\ &= \left(\sum_{i=j}^{\infty} e^{-at}(at)^i/i! \right) - \left(\sum_{i=j+1}^{\infty} e^{-at}(at)^i/i! \right) = e^{-at}(at)^j/j!. \end{aligned}$$

Segue que $N_t \sim \text{Poisson}(at)$, como afirmado. ■

Demonstração do Teorema 11.6.2

Queremos provar que, quando $0 = t_0 \leq t_1 < t_2 < t_3 < \cdots < t_d$, então, para $i = 1, 2, \ldots, d$, a distribuição de $N_{t_i} - N_{t_{i-1}}$ é $\text{Poisson}(a(t_i - t_{i-1}))$. Além disso, as variáveis aleatórias $N_{t_i} - N_{t_{i-1}}$, para $i = 1, \ldots, d$, são independentes.

Pela propriedade de falta de memória[38] das distribuições exponenciais (veja o Problema 2.4.14), segue que, quaisquer que sejam os valores de N_s para $s \leq t_{i-1}$, eles não terão efeito sobre a distribuição dos incrementos $N_t - N_{t_{i-1}}$ para $t > t_{i-1}$. Isto é, o processo $\{N_t\}$ recomeça do zero a cada instante t_{i-1}, exceto por partir de um valor inicial diferente, $N_{t_{i-1}}$, em vez de $N_0 = 0$.

Logo, a distribuição de $N_{t_{i-1}+u} - N_{t_{i-1}}$ para $u \geq 0$ é idêntica à distribuição de $N_u - N_0 = N_u$ e é independente dos valores de N_s para $s \leq t_{i-1}$. Como já sabemos que $N_u \sim \text{Poisson}(au)$, segue que $N_{t_{i-1}+u} - N_{t_{i-1}} \sim \text{Poisson}(au)$ também. Em particular, $N_{t_i} - N_{t_{i-1}} \sim \text{Poisson}(a(t_i - t_{i-1}))$ também, com $N_{t_i} - N_{t_{i-1}}$ independente de $\{N_s : s \leq t_{i-1}\}$. O resultado segue. ■

*Nota do tradutor. o original diz "before time n"; pelo evento $T_n \leq t$, seria "até o instante t"

No original: *memoryless property*[38].

APÊNDICE A

Fundamentos Matemáticos

Para entender este livro, é necessário conhecer certos assuntos de matemática, listados a seguir. Como se supõe que o estudante já tenha feito um curso de cálculo, temas como derivadas, integrais e séries infinitas são tratados aqui de forma bem breve. As integrais múltiplas são tratadas com um pouco mais de detalhe.

A.1 Derivadas

Do cálculo, sabemos que a *derivada* de uma função f é a sua taxa de variação instantânea:

$$f'(x) = \frac{d}{dx}f(x) = \lim_{h\to 0}\frac{f(x+h)-f(x)}{h}.$$

Em particular, o leitor deve se lembrar, do cálculo, de que

$$\frac{d}{dx}5 = 0, \qquad \frac{d}{dx}x^3 = 3x^2, \qquad \frac{d}{dx}x^n = nx^{n-1},$$
$$\frac{d}{dx}e^x = e^x, \qquad \frac{d}{dx}\sin x = \cos x, \qquad \frac{d}{dx}\cos x = -\sin x,$$

etc. Assim, se $f(x) = x^3$, então $f'(x) = 3x^2$ e, por exemplo, $f'(7) = 3\ 7^2 = 147$.

As derivadas respeitam a soma e a multiplicação por escalar; assim, se f e g são funções e C é uma constante, então

$$\frac{d}{dx}\big(Cf(x) + g(x)\big) = Cf'(x) + g'(x).$$

Portanto,

$$\frac{d}{dx}(5x^3 - 3x^2 + 7x + 12) = 15x^2 - 6x + 7,$$

etc.

Por fim, as derivadas satisfazem uma *regra da cadeia*: se uma função pode ser escrita como uma *composição* de duas outras funções, como em $f(x) = g(h(x))$, então $f'(x) = g'(h(x))\,h'(x)$. Assim,

$$\frac{d}{dx}e^{5x} = 5e^{5x},$$
$$\frac{d}{dx}\sin(x^2) = 2x\cos(x^2),$$
$$\frac{d}{dx}(x^2 + x^3)^5 = 5(x^2 + x^3)^4(2x + 3x^2),$$

etc.

As derivadas de ordem superior são definidas por

$$f''(x) = \frac{d}{dx}f'(x), \quad f'''(x) = \frac{d}{dx}f''(x),$$

etc. Em geral, a derivada de ordem r, $f^{(r)}(x)$, pode ser definida por indução, com $f^{(0)}(x) = f(x)$ e

$$f^{(r)}(x) = \frac{d}{dx}f^{(r-1)}(x)$$

para $r \geq 1$. Assim, se $f(x) = x^4$, então $f'(x) = 4x^3$, $f''(x) = f^{(2)}(x) = 12x^2$, $f^{(3)}(x) = 24x$, $f^{(4)}(x) = 24$ etc.

As derivadas são usadas com frequência neste texto.

A.2 Integrais

Se f é uma função e $a < b$ são constantes, então a *integral* de f no intervalo $[a, b]$, escrita

$$\int_a^b f(x)\,dx,$$

representa a soma dos valores $f(x)$, multiplicados pelas larguras de pequenos intervalos em torno de x. Isto é, $\int_a^b f(x)\,dx \approx \sum_{i=1}^{d} f(x_i)(x_i - x_{i-1})$, em que $a = x_0 < x_1 < \ldots < x_d = b$ e em que $x_i - x_{i-1}$ é pequeno.

Mais formalmente, podemos tomar $x_i = a + (i/d)(b - a)$ e fazer $d \to \infty$, para obter uma definição formal de integral como

$$\int_a^b f(x)\,dx = \lim_{d\to\infty} \sum_{i=1}^{d} f\big(a + (i/d)(b-a)\big)\,(1/d).$$

Calcular $\int_a^b f(x)\,dx$ dessa maneira toda vez seria tedioso. Felizmente, o *teorema fundamental do cálculo* oferece um jeito muito mais fácil de calcular integrais. Ele diz que, se $F(x)$ é qualquer função com $F'(x) = f(x)$, então $\int_a^b f(x)\,dx = F(b) - F(a)$. Logo,

$$\int_a^b 3x^2\,dx = b^3 - a^3,$$
$$\int_a^b x^2\,dx = \tfrac{1}{3}(b^3 - a^3),$$
$$\int_a^b x^n\,dx = \tfrac{1}{n+1}(b^{n+1} - a^{n+1}),$$

e

$$\int_a^b \cos x\,dx = \sin b - \sin a,$$
$$\int_a^b \sin x\,dx = -(\cos b - \cos a),$$
$$\int_a^b e^{5x}\,dx = \tfrac{1}{5}(e^{5b} - e^{5a}).$$

A.3 Séries Infinitas

Se $a_1, a_2, a_3, \ldots$ é uma sequência infinita de números, podemos considerar a soma infinita (ou *série*)

$$\sum_{i=1}^{\infty} a_i = a_1 + a_2 + a_3 + \cdots.$$

Formalmente, $\sum_{i=1}^{\infty} a_i = \lim_{N\to\infty} \sum_{i=1}^{N} a_i$. Essa soma pode ser finita ou infinita. Por exemplo, é claro que $\sum_{i=1}^{\infty} 1 = 1 + 1 + 1 + 1 + \cdots = \infty$. Por outro lado, como

$$\frac{1}{2} + \frac{1}{4} + \frac{1}{8} + \frac{1}{16} + \cdots + \frac{1}{2^n} = \frac{2^n - 1}{2^n},$$

vemos que

$$\frac{1}{2} + \frac{1}{4} + \frac{1}{8} + \frac{1}{16} + \cdots = \sum_{i=1}^{\infty} \frac{1}{2^i} = \lim_{N\to\infty} \sum_{i=1}^{N} \frac{1}{2^i} = \lim_{N\to\infty} \frac{2^N - 1}{2^N} = 1.$$

De modo mais geral, calculamos que

$$\sum_{i=1}^{\infty} a^i = \frac{a}{1-a}$$

sempre que $|a| < 1$.

Um tipo de série infinita particularmente importante é a *série de Taylor*[1]. Se f é uma função, então a sua série de Taylor é dada por

$$f(0) + xf'(0) + \frac{1}{2!}x^2 f''(0) + \frac{1}{3!}x^3 f^{(3)}(0) + \cdots = \sum_{i=0}^{\infty} \frac{1}{i!} x^i f^{(i)}(0).$$

No original: *Taylor series*[1].

(Aqui, $i! = i(i-1)(i-2)\cdots(2)(1)$ indica *i fatorial*, com $0! = 1! = 1$, $2! = 2$, $3! = 6$, $4! = 24$ etc.) Em geral, $f(x)$ será exatamente igual à expansão em série de Taylor; assim,*

$$\begin{aligned}
\operatorname{sin} x &= x - x^3/3 + x^5/5 - x^7/7 + \cdots, \\
\operatorname{cos} x &= 1 - x^2/2 + x^4/4 - x^5/5 + \cdots, \\
e^x &= 1 + x + x^2/2! + x^3/3! + x^4/4! + \cdots, \\
e^{5x} &= 1 + 5x + (5x)^2/2! + (5x)^3/3! + (5x)^4/4! + \cdots,
\end{aligned}$$

etc. Se $f(x)$ é um polinômio (por exemplo, $f(x) = x^3 - 3x^2 + 2x - 6$), então a série de Taylor de $f(x)$ é exatamente a mesma função que $f(x)$.

A.4 Multiplicação de Matrizes

Uma *matriz* é qualquer coleção $r \times s$ de números, por exemplo,

$$A = \begin{pmatrix} 8 & 6 \\ 5 & 2 \end{pmatrix}, \quad B = \begin{pmatrix} 3 & 6 & 2 \\ -7 & 6 & 0 \end{pmatrix}, \quad C = \begin{pmatrix} 2 & -1 \\ 3/5 & 2/5 \\ -0{,}6 & -17{,}9 \end{pmatrix},$$

etc.

As matrizes podem ser *multiplicadas* da seguinte maneira. Se A é uma matriz $r \times s$ e B é uma matriz $s \times u$, então o produto AB é uma matriz $r \times u$ cuja entrada i, j é dada por $\sum_{k=1}^{s} A_{ik}B_{kj}$, uma soma de produtos. Por exemplo, com A e B como acima, se $M = AB$, então

$$\begin{aligned}
M &= \begin{pmatrix} 8 & 6 \\ 5 & 2 \end{pmatrix}\begin{pmatrix} 3 & 6 & 2 \\ -7 & 6 & 0 \end{pmatrix} \\
&= \begin{pmatrix} 8(3)+6(-7) & 8(6)+6(6) & 8(2)+6(0) \\ 5(3)+2(-7) & 5(6)+2(6) & 5(2)+2(0) \end{pmatrix} = \begin{pmatrix} -18 & 84 & 16 \\ 1 & 42 & 10 \end{pmatrix},
\end{aligned}$$

já que, por exemplo, a entrada $(2, 1)$ de M é igual a $5(3) + 2(-7) = 1$.

A multiplicação de matrizes acaba sendo surpreendentemente útil e é usada em vários pontos deste livro.

*Nota do tradutor. O original traz estas duas séries assim; pela fórmula de Taylor acima seriam $\operatorname{sin} x = x - x^3/3! + x^5/5! - x^7/7! + \cdots$ e $\operatorname{cos} x = 1 - x^2/2! + x^4/4! - x^6/6! + \cdots$.

A.5 Derivadas Parciais

Suponha que f seja uma função de *duas* variáveis, como em $f(x, y) = 3x^2y^3$. Então podemos tomar uma *derivada parcial* de f em relação a x, escrita

$$\frac{\partial}{\partial x} f(x, y),$$

variando x enquanto mantemos y fixo. Isto é,

$$\frac{\partial}{\partial x} f(x, y) = \lim_{h \to 0} \frac{f(x + h, y) - f(x, y)}{h}.$$

Ela pode ser calculada simplesmente tratando y como um valor constante. No exemplo acima,

$$\frac{\partial}{\partial x}(3x^2y^3) = 6xy^3.$$

Da mesma forma, tratando x como constante e variando y, vemos que

$$\frac{\partial}{\partial y}(3x^2y^3) = 9x^2y^2.$$

Outros exemplos são*

$$\frac{\partial}{\partial x}\left(18e^{xy} + x^6y^8 - \sin(y^3)\right) = 18ye^{xy} + 6x^5y^8,$$
$$\frac{\partial}{\partial y}\left(18e^{xy} + x^6y^8 - \sin(y^3)\right) = 18xe^{xy} + 8x^6y^7 - 3y^2\sin(y^3),$$

etc.

Se f é uma função de três ou mais variáveis, as derivadas parciais podem ser tomadas do mesmo modo. Assim,

$$\frac{\partial}{\partial x}(x^2y^4z^6) = 2xy^4z^6, \quad \frac{\partial}{\partial y}(x^2y^4z^6) = 4x^2y^3z^6, \quad \frac{\partial}{\partial z}(x^2y^4z^6) = 6x^2y^4z^5,$$

etc.

*Nota do tradutor. O original traz $-3y^2\sin(y^3)$ no fim da segunda linha; pela conta seria $-3y^2\cos(y^3)$.

A.6 Integrais Múltiplas

Se f é uma função de duas ou mais variáveis, ainda podemos calcular integrais de f. Porém, em vez de tomar integrais num intervalo $[a, b]$, precisamos tomar integrais em *regiões* de dimensão maior.

Por exemplo, seja $f(x, y) = x^2y^3$ e seja R a região retangular dada por $R = \{0 \leq x \leq 1, 5 \leq y \leq 7\} = [0, 1] \times [5, 7]$. Quanto vale

$$\int_R \int f(x, y)\, dx\, dy,$$

a integral de f na região R? Em termos geométricos, é o volume sob o gráfico de f (que é uma superfície) acima da região R. Mas como calculamos isso?

Bem, se y é constante, sabemos que

$$\int_0^1 f(x, y)\, dx = \int_0^1 x^2y^3\, dx = \frac{1}{3}y^3. \tag{A.6.1}$$

Isso corresponde a somar os valores de f ao longo de uma "faixa" da região R, na qual y é constante. Na Figura A.6.1, mostramos a região de integração $R = [0, 1] \times [5, 7]$. O valor de (A.6.1), quando $y = 6{,}2$, é $(6{,}2)^3/3 = 79{,}443$; essa é a área sob a curva $x^2(6{,}2)^3$ acima do segmento $[0, 1] \times \{6{,}2\}$.

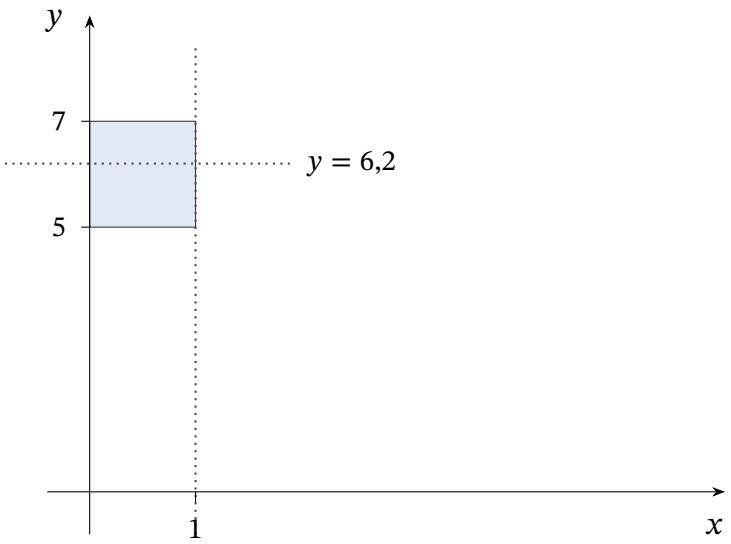


Figura A.6.1: Gráfico da região de integração (sombreada) $R = [0, 1] \times [5, 7]$, junto com a reta $y = 6{,}2$.

Se então somarmos os valores das áreas sobre essas faixas ao longo de todos os valores possíveis de y, obtemos a integral total, ou volume, da seguinte

maneira:

$$\int_R \int f(x,y)\,dx\,dy = \int_5^7 \Big(\int_0^1 f(x,y)\,dx\Big)\,dy = \int_5^7 \Big(\int_0^1 x^2y^3\,dx\Big)\,dy$$
$$= \int_5^7 \Big(\frac{1}{3}y^3\Big)\,dy = \frac{1}{3}\,\frac{1}{4}(7^4 - 5^4) = 148.$$

Assim, o volume sob o gráfico de f e acima da região R é igual a 148.

Observe que também podemos calcular essa integral integrando primeiro em y e depois em x, e obtemos a mesma resposta:

$$\int_R \int f(x,y)\,dx\,dy = \int_0^1 \Big(\int_5^7 f(x,y)\,dy\Big)\,dx = \int_0^1 \Big(\int_5^7 x^2y^3\,dy\Big)\,dx$$
$$= \int_0^1 \Big(\frac{1}{4}x^2(7^4 - 5^4)\Big)\,dx = \frac{1}{3}\,\frac{1}{4}(7^4 - 5^4) = 148.$$

Regiões Não Retangulares

Se a região R não é um retângulo, o cálculo é mais complicado. A ideia é que, para cada valor de x, integramos y apenas nos valores para os quais o ponto (x,y) está dentro de R.

Por exemplo, suponha que R seja o triângulo dado por $R = \{(x,y) : 0 \le 2y \le x \le 6\}$. Na Figura A.6.2, representamos essa região junto com os cortes em $x = 3$ e $y = 3/2$. Usamos os cortes em x para determinar os limites de y para x fixo quando integramos primeiro em y; usamos os cortes em y para determinar os limites de x para y fixo quando integramos primeiro em x.

Então x pode assumir qualquer valor entre 0 e 6. Porém, uma vez conhecido x, y só pode assumir valores entre 0 e $x/2$. Logo, se $f(x,y) = xy + x^6y^8$, então

$$\int_R \int f(x,y)\,dx\,dy$$
$$= \int_0^6 \Big(\int_0^{x/2} f(x,y)\,dy\Big)\,dx = \int_0^6 \Big(\int_0^{x/2} (xy + x^6y^8)\,dy\Big)\,dx$$
$$= \int_0^6 \Big(x\frac{1}{2}\big((x/2)^2 - 0^2\big) + \big(x^6\frac{1}{9}\big((x/2)^9 - 0^9\big)\big)\Big)\,dx$$
$$= \int_0^6 \Big(\frac{1}{8}x^3 + \frac{1}{4608}x^{15}\Big)\,dx$$
$$= \frac{1}{8}\,\frac{1}{4}(6^4 - 0^4) + \frac{1}{4608}\,\frac{1}{16}(6^{16} - 0^{16})$$
$$= 3{,}8264 \times 10^7.$$

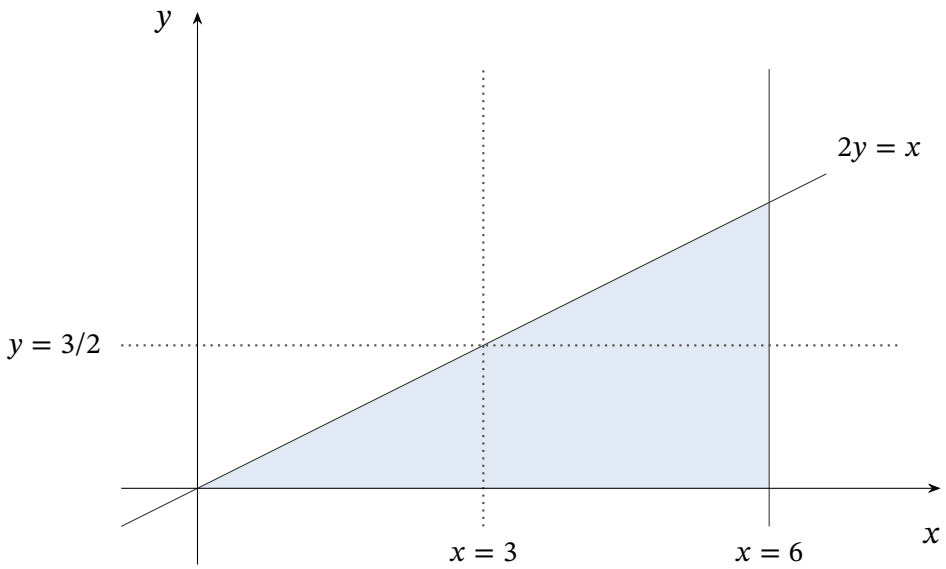


Figura A.6.2: A região de integração (sombreada) $R = \{(x, y) : 0 \le 2y \le x \le 6\}$, junto com os cortes em $x = 3$ e $y = 3/2$.

Mais uma vez, podemos calcular a mesma integral na ordem inversa, integrando primeiro em x e depois em y. Nesse caso, y pode assumir qualquer valor entre 0 e 3. Então, para um dado valor de y, vemos que x pode assumir valores entre 0 e $2y$. Logo,*

$$\int_R \int f(x,y)\,dx\,dy = \int_0^3 \left(\int_{2y}^6 f(x,y)\,dx \right) dy = \int_0^3 \left(\int_{2y}^6 (xy + x^6 y^8)\,dx \right) dy.$$

Deixamos como exercício para o leitor terminar esta integral e verificar que se obtém a mesma resposta de antes.

Funções de três ou mais variáveis também podem ser integradas em regiões da dimensão correspondente, três ou maior. Para simplificar, não damos ênfase a essas integrais de ordem superior neste livro.

*Nota do tradutor. O original traz "entre 0 e $2y$"; pela região e pelos limites da integral abaixo, seria entre $2y$ e 6.

APÊNDICE B

Cálculos

Descrevemos brevemente dois pacotes computacionais que podem ser usados para todos os cálculos feitos no texto. Recomendamos que os estudantes se familiarizem com pelo menos um deles. A descrição do R é bastante completa, ao menos para os cálculos baseados no material deste texto, ao passo que é necessária outra referência para aprender o Minitab.

B.1 Usando o R

O R é um pacote estatístico gratuito que pode ser baixado e instalado no seu computador (veja `http://cran.r-project.org/`). Um manual gratuito também está disponível nesse site.

Depois de instalar o R no seu sistema, você pode iniciá-lo clicando no ícone correspondente (ou, em sistemas Unix, simplesmente digitando "R"). Aparece então uma janela, chamada *R Console*, que contém algum texto e um prompt ">", depois do qual você digita os comandos. Os comandos são separados por novas linhas ou por ";". A saída dos comandos também é exibida nessa janela, a menos que seja propositalmente direcionada para outro lugar. Para sair do R, digite `q()` depois do prompt. Para saber mais sobre qualquer coisa no R, um recurso conveniente é usar o Help da barra de menus, no alto da janela do R. Outra opção é digitar `?name` depois do prompt (e pressionar Enter) para exibir informações sobre `name`; por exemplo, `?q` abre uma página com informações sobre o comando de encerramento `q`.

Operações e Funções Básicas

Um comando básico avalia uma expressão, como

```
> 2+3
[1] 5
```

que soma 2 e 3 e produz a resposta 5. Outra possibilidade é *atribuir* o valor da expressão a uma variável, como em

```
> a <- 2
```

em que <- (sinal de menor seguido de sinal de menos) atribui o valor 2 a uma variável chamada a. Também se pode usar = na atribuição, como em a = 2, mas usaremos <-. Podemos então verificar essa atribuição simplesmente digitando a e apertando Enter, o que faz o valor de a ser impresso.

```
> a
[1] 2
```

Observe que o R diferencia maiúsculas de minúsculas, de modo que A seria uma variável diferente de a. Há algumas restrições na escolha de nomes para variáveis e vetores, mas você não errará se sempre começar o nome com uma letra.

Podemos atribuir os valores de um vetor usando a função de concatenação c(), como em

```
> b <- c(1,1,1,3,4,5)
> b
[1] 1 1 1 3 4 5
```

o que cria um vetor chamado b com seis valores. Podemos acessar a *i*-ésima entrada de um vetor b referindo-nos a ela como b[i]. Por exemplo,

```
> b[3]
[1] 1
```

imprime a terceira entrada de b, isto é, 1. Outra possibilidade é usar o comando scan para a entrada de dados. Por exemplo,

```
> b <- scan()
1:  1 1 1 3 4 5
7:
Read 6 items
> b
[1] 1 1 1 3 4 5
```

faz a mesma atribuição. Observe que, com o comando scan, simplesmente digitamos os dados e encerramos a entrada com uma linha em branco. Também podemos usar scan para ler dados de um arquivo; para isso, remetemos o leitor a ?scan.

Às vezes queremos vetores cujas entradas seguem algum padrão. Muitas vezes podemos usar a função rep para isso. Por exemplo, x <- rep(1,20) cria um

vetor de 20 uns. Padrões mais complicados podem ser obtidos; para isso, remetemos o leitor a `?rep`.

A aritmética básica pode ser feita com variáveis e vetores usando + (adição), - (subtração), * (multiplicação), / (divisão) e ^ (exponenciação). Essas operações são feitas componente a componente. Por exemplo, poderíamos multiplicar cada componente de `b` por ele mesmo com

```
> b*b
[1] 1 1 1 9 16 25
```

ou multiplicar cada elemento de `b` por 2, como em

```
> 2*b
[1] 2 2 2 6 8 10
```

o que realiza essa operação.

Há várias funções disponíveis no R, como `abs(x)` (calcula o valor absoluto de `x`), `log(x)` (calcula o logaritmo natural de `x`), `exp(x)` (calcula *e* elevado à potência `x`), `sin(x)`, `cos(x)`, `tan(x)` (que calculam as funções trigonométricas), `sqrt(x)` (que calcula a raiz quadrada de `x`), `ceiling(x)` e `floor(x)` (que calculam o teto e o piso de `x`). Quando uma dessas funções é aplicada a um vetor `x`, ela devolve um vetor de mesmo comprimento, com a função aplicada a cada elemento do vetor original. Há inúmeras funções especiais disponíveis no R, mas duas importantes são `gamma(x)`, que devolve a função gama[1] aplicada a `x`, e `lgamma(x)`, que devolve o logaritmo natural da função gama.

Há também funções que devolvem um único valor quando aplicadas a um vetor. Por exemplo, `min(x)` e `max(x)` devolvem, respectivamente, o menor e o maior elemento de `x`; `length(x)` dá o número de elementos de `x`; e `sum(x)` dá a soma dos valores de `x`.

O R também opera com as quantidades lógicas `TRUE` (ou `T`, para verdadeiro) e `FALSE` (ou `F`, para falso). Valores lógicos são gerados por condições que são verdadeiras ou falsas. Por exemplo,

```
> a <- c(-3,4,2,-1,-5)
> b <- a>0
> b
[1] FALSE TRUE TRUE FALSE FALSE
```

No original: *gamma function*[1].

compara cada elemento do vetor `a` com 0, devolvendo `TRUE` quando ele é maior que 0 e `FALSE` caso contrário, e esses valores lógicos são guardados no vetor `b`. Podem ser usados os seguintes operadores lógicos: <, <=, >=, >, == (igualdade), != (desigualdade), além de & (conjunção), | (disjunção) e ! (negação). Por exemplo, se criarmos um vetor lógico `c` assim:

```
> c <- c(T,T,T,T,T)
> b&c
[1] FALSE TRUE TRUE FALSE FALSE
> b|c
[1] TRUE TRUE TRUE TRUE TRUE
```

então um elemento de `b&c` é `TRUE` quando os dois elementos correspondentes de `b` e `c` são TRUE, enquanto um elemento de `b|c` é `TRUE` quando pelo menos um dos elementos correspondentes de `b` e `c` é TRUE.

Às vezes podemos ter variáveis que assumem valores de caractere. Embora sempre seja possível codificar esses valores como números, não há necessidade disso, pois o R também lida com variáveis de valores de caractere. Por exemplo, os comandos

```
> A <- c('a','b')
> A
[1] "a" "b"
```

criam um vetor de caracteres `A`, contendo dois valores, `a` e `b`, e depois imprimem esse vetor. Observe que pusemos os valores de caractere entre aspas simples ao fazer a atribuição.

Às vezes faltam valores nos dados, e eles são então listados como `NA` (not available, não disponível). Operações com valores faltantes criam valores faltantes. Além disso, uma operação impossível, como 0/0, produz `NaN` (not a number, não é um número).

Vários objetos podem ser criados durante uma sessão do R. Para ver os que foram criados até o momento na sua sessão, use o comando `ls()`. Você pode remover qualquer objeto da sua área de trabalho usando o comando `rm`. Por exemplo, `rm(x)` remove o vetor `x`.

Funções de Probabilidade

O R tem várias funções embutidas para calcular a fda, a fda inversa, a função densidade[2] ou de probabilidade e para gerar amostras aleatórias das distribuições comuns que encontramos em probabilidade e estatística. Elas se distinguem por um prefixo e pelo nome da distribuição base. Alguns dos nomes de distribuições são dados na tabela a seguir.

Distribuição	Nome no R e argumentos
beta	`beta(·,a,b)`
binomial	`binom(·,n,p)`
qui-quadrado	`chisq(·,df)`
exponencial	`exp(·,lambda)`
F	`f(·,df1,df2)`
gama	`gamma(·,alpha,lambda)`
geométrica	`geom(·,p)`
hipergeométrica	`hyper(·,N,M,n)`
binomial negativa	`nbinom(·,k,p)`
normal	`norm(·,mu,sigma)`
Poisson	`pois(·,lambda)`
t	`t(·,df)`
uniforme	`unif(·,min,max)`

Como sempre, é preciso tomar cuidado com a distribuição gama. O caminho mais seguro é incluir outro argumento junto com a distribuição para indicar se `lambda` é um parâmetro de taxa (a densidade é $(\Gamma(\alpha))^{-1}\lambda^{\alpha}x^{\alpha-1}e^{-\lambda x}$) ou um parâmetro de escala (a densidade é $(\Gamma(\alpha))^{-1}\lambda^{-\alpha}x^{\alpha-1}e^{-x/\lambda}$). Assim, `gamma(·,alpha,rate=lambda)` indica que `lambda` é um parâmetro de taxa, e `gamma(·,alpha,scale=lambda)` indica que ele é um parâmetro de escala.

O argumento indicado por · é especificado de acordo com a finalidade do comando que usa o nome da distribuição. Para obter a fda de uma distribuição, ponha `p` antes do nome; então · é o valor em que se quer calcular a fda. Para obter a fda inversa de uma distribuição, ponha `q` antes do nome; então · é o valor em que se quer calcular a fda inversa. Para obter a função densidade ou de probabilidade, ponha `d` antes do nome; então · é o valor em que se quer calcular a densidade ou a função de probabilidade[3]. Para obter amostras aleatórias, ponha `r` antes do nome; então · é o tamanho da amostra[4] aleatória que se quer gerar.

Por exemplo,

No original: *density function*[2], *probability function*[3], *sample size*[4].

```
> x <- rnorm(4,1,2)
> x
[1] -0.2462307 2.7992913 4.7541085 3.3169241
```

gera uma amostra de tamanho 4 da distribuição $N(1, 2^2)$ e a atribui ao vetor `x`. O comando

```
> dnorm(3.2,2,.5)
[1] 0.04478906
```

calcula a densidade $N(2; 0{,}25)$ em 3,2, enquanto

```
> pnorm(3.2,2,.5)
[1] 0.9918025
```

calcula a fda $N(2; 0{,}25)$ em 3,2, e

```
> qnorm(.025,2,.5)
[1] 1.020018
```

dá o quantil 0,025 da distribuição $N(2; 0{,}25)$.

Se temos dados guardados num vetor `x`, podemos amostrar valores de `x`, com ou sem reposição, usando a função `sample`. Por exemplo, `sample(x,n,T)` gera uma amostra de tamanho `n` de `x` com reposição, enquanto `sample(x,n,F)` gera uma amostra de tamanho `n` de `x` sem reposição (observe que, neste último caso, `n` não pode ser maior que `length(x)`).

Às vezes é conveniente poder repetir uma simulação de modo que os mesmos valores aleatórios sejam gerados. Para isso, pode-se usar o comando `set.seed`. Por exemplo, `set.seed(12345)` fixa a semente em `12345`.

Tabulação de Dados

O comando `table` está disponível para tabular dados. Por exemplo, `table(x)` devolve uma tabela com a lista dos valores distintos encontrados em `x` e suas frequências de ocorrência em `x`. Essa tabela pode ser atribuída a uma variável com

```
y <- table(x)
```

para análise posterior (veja o trecho O Teste Qui-Quadrado, mais adiante).

Se `x` e `y` são vetores de mesmo comprimento, então `table(x,y)` produz uma tabulação cruzada, isto é, conta o número de vezes em que se obtém cada valor possível de (x, y), em que x pode ser qualquer um dos valores assumidos em `x` e y pode ser qualquer um dos valores assumidos em `y`.

Gráficos de Dados

O R tem vários comandos disponíveis para fazer gráficos de dados. Por exemplo, suponha que temos uma amostra de tamanho n guardada no vetor `x`.

O comando `hist(x)` fornece um histograma de frequências dos dados, com os pontos de corte escolhidos automaticamente pelo R. Podemos acrescentar argumentos opcionais a `hist`. Seguem alguns dos argumentos disponíveis.

> `breaks` — Um vetor que contém os pontos de corte.
>
> `freq` — Uma variável lógica; quando `freq=T` (o padrão), obtém-se um histograma de frequências e, quando `freq=F`, obtém-se um histograma de densidade.

Por exemplo, `hist(x,breaks=c(-10,-5,-2,0,2,5,10),freq=F)` faz o gráfico de um histograma de densidade com pontos de corte $-10, -5, -2, 0, 2, 5, 10$, em que tivemos o cuidado de garantir que `min(x)` > -10 e `max(x)` < 10.

Se `y` é outro vetor de mesmo comprimento que `x`, podemos produzir um diagrama de dispersão[5] de `y` contra `x` com o comando `plot(x,y)`. O comando `plot(x,y,type="l")` fornece um diagrama de dispersão de `y` contra `x`, mas agora com os pontos ligados por linhas. O comando `plot(x)` faz o gráfico dos valores de `x` contra seus índices. O comando `plot(ecdf(x))` faz o gráfico da fda empírica dos dados de `x`.

Um boxplot dos dados de `x` é obtido com o comando `boxplot(x)`. Boxplots lado a lado dos dados de `x`, `y`, `z` etc. podem ser obtidos com `boxplot(x,y,z)`.

Um gráfico de probabilidade normal[6] dos valores de `x` pode ser obtido com o comando `qqnorm(x)`.

Um gráfico de barras pode ser obtido com o comando `barplot`. Por exemplo,

```
> h <- c(1,2,3)
> barplot(h)
```

No original: *scatter plot*[5], *normal probability plot*[6].

produz um gráfico de barras com 3 barras de alturas 1, 2 e 3.

Há muitos outros aspectos dos gráficos no R que dão ao usuário um controle considerável sobre a aparência dos gráficos. Remetemos o leitor ao manual para uma discussão mais ampla sobre eles.

Inferência Estatística

O R tem uma abordagem poderosa para ajustar modelos e fazer inferência sobre eles. Os modelos são especificados pelo símbolo `~`. Não discutimos isso por completo aqui; apenas indicamos como usá-lo para tratar os modelos de regressão linear simples e múltipla (em que a resposta e os preditores são todos quantitativos), os modelos com um e com dois fatores (em que a resposta é quantitativa, mas os preditores são categóricos) e o modelo de regressão logística[7] (em que a resposta é categórica, mas os preditores são quantitativos). Suponha, então, que temos um vetor `y` com os valores da resposta.

Estatísticas Básicas

A função `mean(y)` devolve a média dos valores de `y`, `var(y)` devolve a variância[8] amostral dos valores de `y`, e `sd(y)` dá o desvio padrão[9] amostral. O comando `median(y)` devolve a mediana de `y`, enquanto `quantile(y,p)` devolve os quantis amostrais especificados no vetor de probabilidades `p`. Por exemplo, `quantile(y,c(.25,.5,.75))` devolve a mediana e o primeiro e o terceiro quartis. A função `sort(y)` devolve um vetor com os valores de `y` ordenados do menor para o maior, e `rank(y)` dá os postos dos valores de `y`.

O Teste *t*

Para os dados em `y`, podemos usar o comando

```
> t.test(y,mu=1,alternative="two.sided",conf.level=.95)
```

para fazer um teste t. Ele calcula o valor-p do teste de $H_0 : \mu = 1$ e forma um intervalo de confiança[10] 0,95 para μ.

No original: *logistic regression*[7], *variance*[8], *standard deviation*[9], *confidence interval*[10].

O Teste Qui-Quadrado

Suponha que `y` contenha um vetor de contagens para `k` caselas e que `prob` contenha as probabilidades hipotéticas dessas caselas. Então o comando

```
> chisq.test(y,p=prob)
```

faz o teste qui-quadrado para avaliar essa hipótese. Observe que `y` também poderia corresponder a uma tabela unidimensional.

Se `x` e `y` são dois vetores de mesmo comprimento, então `chisq.test(x,y)` faz um teste qui-quadrado de independência na tabela formada pela tabulação cruzada das entradas de `x` e `y`. Se primeiro criarmos essa tabulação cruzada na tabela `t` usando a função `table`, então `chisq.test(t)` faz esse teste.

Regressão Linear Simples

Suponha que temos um único preditor[11], com valores no vetor `x`. O modelo de regressão linear simples[12] $E(y \mid x) = \beta_1 + \beta_2 x$ é então especificado no R por `y~x`. Chamamos `y~x` de fórmula do modelo e a lemos como "`y` é modelado como um modelo linear envolvendo `x`". Para fazer o ajuste (o que fizemos aqui para um conjunto específico de dados), usamos o comando de ajuste de modelos lineares `lm`, como segue. O comando

```
> regexamp <- lm(y~x)
```

faz os cálculos de ajuste e de inferência sobre esse modelo e atribui o resultado a uma estrutura chamada `regexamp`. Qualquer outro nome válido poderia ter sido usado para essa estrutura. Podemos agora usar várias funções do R para extrair vários itens de interesse. Por exemplo,

```
> summary(regexamp)
Call:
lm(formula = y~x)
Residuals:
  Min      1Q    Median 3Q     Max
-4.2211 -2.1163 0.3248 1.7255 4.3323
Coefficients:
 Estimate          Std.  Error  t value Pr(>|t|)
```

No original: *predictor*[11], *simple linear regression model*[12].

```
(Intercept) 6.5228   1.2176     5.357   4.31e-05 ***
    x       1.7531   0.1016    17.248   1.22e-12 ***
--
Signif.  codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’
0.1 ‘ ’ 1
Residual standard error:  2.621 on 18 degrees of freedom
Multiple R-squared:  0.9429, Adjusted R-squared:  0.9398

F-statistic:  297.5 on 1 and 18 DF, p-value:  1.219e-12
```

usa a função `summary` para nos dar todas as informações de que precisamos. Por exemplo, a reta ajustada é dada por $6{,}5228 + 1{,}7531x$. O teste de $H_0 : \beta_2 = 0$ tem valor-p de $1{,}22 \times 10^{-12}$, de modo que temos forte evidência contra H_0. Além disso, o R^2 é dado por 94,29%. Itens individuais podem ser acessados por várias funções do R; para isso, remetemos o leitor a `?lm`.

Regressão Linear Múltipla

Se temos dois preditores quantitativos nos vetores `x1` e `x2`, podemos proceder exatamente como na regressão linear simples para ajustar o modelo de regressão linear $E(y \mid x_1, x_2) = \beta_1 + \beta_2 x_1 + \beta_2 x_2$.* Por exemplo, os comandos

```
> regex <- lm(y~x1+x2)
> summary(regex)
```

ajustam o modelo linear acima, atribuem os resultados à estrutura `regex`, e então a função `summary` imprime (omitido aqui) todas as quantidades relevantes. Lemos `y~x1+x2` como “y é modelado como um modelo linear envolvendo `x1` *e* `x2`”. Em particular, obtêm-se a estatística F e o valor-p associado a ela para o teste de $H_0 : \beta_2 = \beta_3 = 0$.

Isso se generaliza imediatamente para modelos de regressão linear com k preditores quantitativos $x_1, \ldots, x_k$. Além disso, suponha que queremos testar se o modelo envolve apenas $x_1, \ldots, x_l$, para $l < k$. Usamos `lm` para ajustar o modelo com todos os k preditores e atribuímos isso a `regex`, e também usamos `lm` para ajustar o modelo que envolve só l preditores e atribuímos isso a `regex1`. Então o comando `anova(regex,regex1)` fornece a estatística F e seu valor-p para o teste de $H_0 : \beta_{l+1} = \cdots = \beta_k = 0$.

*Nota do tradutor. O original traz $\beta_2 x_2$ no último termo; pelo teste de $H_0 : \beta_2 = \beta_3 = 0$ logo adiante, seria $\beta_3 x_2$.

ANOVA com Um e com Dois Fatores

Suponha agora que A denota um preditor categórico que assume dois níveis, a_1 e a_2. Observe que os valores de A podem ser de caractere em vez de numéricos; por exemplo, `x` é um vetor de caracteres contendo os valores `a1` e `a2`, usados para indicar em que nível o valor correspondente de `y` foi observado. Em qualquer caso, precisamos transformar isso num fator `A`, com o comando

```
> A <- factor(x)
```

para que `A` possa ser usado na análise. Então o comando

```
> aov(y~A)
```

produz a tabela de ANOVA com um fator. Naturalmente, `aov` também trata fatores com mais de dois níveis. Para obter as médias das caselas, use o comando `tapply(y,A,mean)`.

Suponha que exista um segundo fator B, com 5 níveis $b_1, \ldots, b_5$. Se esse é o fator `B` no R, então o comando

```
> aov(y~A+B+A:B)
```

produz a ANOVA com dois fatores para testar interações entre os fatores `A` e `B`. Para obter as médias das caselas, use o comando `tapply(y,list(A,B),mean)`. O comando `aov(y~A+B)` produz a tabela de ANOVA supondo que não há interações.

Regressão Logística

Suponha que temos dados binários guardados no vetor `y` e que `x` contém os valores correspondentes de um preditor quantitativo. Então podemos usar o comando de modelo linear generalizado `glm` para ajustar o modelo de regressão logística $P(Y = 1 \mid x) = \exp\{\beta_1 + \beta_2 x\}/(1 + \exp\{\beta_1 + \beta_2 x\})$. Os comandos

```
> logreg <- glm(y~x,family=binomial)
> summary(logreg)
```

ajustam o modelo de regressão logística, atribuem os resultados a `logreg`, e então o comando `summary` imprime esse material. Isso nos dá as estimativas dos β_i, seus erros padrão e os valores-p para testar que $\beta_i = 0$.

Comandos de Controle e Programas em R

Um comando de controle básico tem a forma `if (expr1) expr2 else expr3`, em que `expr1` assume um valor lógico, `expr2` é executado se `expr1` é `T`, e `expr3` é executado se `expr1` é `F`. Por exemplo, se `x` é uma variável que assume o valor -2, então

```
> if (x<0) {y <- -1} else {y <- 1}
```

faz com que seja atribuído a `y` o valor -1. Observe que a parte `else` do comando pode ser omitida.

O comando `for (name in expr) expr2` executa `expr2` para cada valor de `name` em `expr1`.* Por exemplo,

```
> for (i in 1:10) print(i)
```

imprime o valor da variável `i` à medida que são atribuídos a `i`, sucessivamente, os valores de $\{1, 2, \ldots, 10\}$. Observe que `m:n` é, no R, uma abreviação da sequência $(m, m+1, \ldots, n)$. Outro exemplo:

```
> for (i in 1:20) y[i] <- 2^i
```

cria um vetor `y` com 20 entradas, em que o i-ésimo elemento de `y` é igual a 2^i.

O `break` encerra um laço, possivelmente com base em alguma condição que se verifique, enquanto `next` interrompe o processamento da iteração atual e avança o índice do laço. Tanto `break` quanto `next` valem apenas para o mais interno de laços aninhados.

Comandos no R podem ser agrupados colocando-os entre chaves, `{expr1; expr2; ...}`. Os comandos dentro das chaves são executados como uma unidade. Por exemplo,

```
> for (i in 1:20) {print(i); y[i] <- 2^i}; print(y[i])}
```

faz com que `i` seja impresso, `y[i]` seja atribuído e `y[i]` seja impresso, tudo dentro de um laço `for`.†

*Nota do tradutor. O original escreve `expr` no comando e `expr1` logo depois; trata-se da mesma expressão.

†Nota do tradutor. O comando impresso no original tem uma chave a mais, depois de `2^i`; pela descrição, seria `{print(i); y[i] <- 2^i; print(y[i])}`.

Muitas vezes, quando um cálculo é complicado, como um que envolve laços, é melhor pôr todos os comandos do R num único arquivo e executar o arquivo em modo de lote. Por exemplo, suponha que você tem um arquivo `prog.R` contendo código R. Então o comando `source("pathname/prog.R")` faz com que todos os comandos do arquivo sejam executados.

Muitas vezes é conveniente pôr comentários nos programas em R para explicar o que as linhas de código fazem. Uma linha de comentário é precedida por # e, claro, não é executada.

Funções Definidas pelo Usuário

O R também permite funções definidas pelo usuário. A sintaxe da definição de uma função é a seguinte.

nome da função <- **function**(*argumentos*) {
    corpo da função;
    return(*valor de retorno*);
}

Por exemplo, a função a seguir calcula o coeficiente de variação amostral dos dados `x`.

```
coef_var <- function(x) {
    result <- sd(x)/mean(x);
    return(result);
}
```

Então, se depois quisermos calcular o coeficiente de variação dos dados `y`, basta digitar `coef_var(y)`.

Arranjos e Listas

Um vetor de comprimento m também pode ser visto como um arranjo unidimensional de comprimento m. O R pode lidar com *arranjos* multidimensionais, por exemplo, arranjos $m \times n$, $m \times n \times p$ etc. Se `a` é um arranjo tridimensional, então `a[i,j,k]` se refere à entrada na posição (i, j, k) do arranjo. Há várias operações que podem ser feitas com arranjos; para elas, remetemos o leitor ao manual. Mais adiante neste manual, discutiremos o caso especial dos arranjos bidimensionais, também conhecidos como matrizes. Por ora, pensamos nos arranjos apenas como objetos em que guardamos dados.

Uma estrutura de dados muito geral no R é dada por uma *lista*. Uma lista é parecida com um arranjo, com várias diferenças importantes.

1. Qualquer entrada de um arranjo é referida pelo seu índice. Já qualquer entrada de uma lista pode ser referida por um nome de caracteres. Por exemplo, os coeficientes da regressão ajustada são referidos por `regex$coefficients` depois do ajuste do modelo linear `regex <- lm(y ~ x1 + x2)`. O cifrão ($) é o operador de referência a entradas, isto é, `varname$entname` indica a entrada "entname" da lista "varname".
2. Enquanto um arranjo guarda dados de um só tipo, uma lista pode guardar quaisquer objetos do R. Por exemplo, a entrada `coefficients` de um objeto de regressão linear é um vetor numérico, e a entrada `model` é uma lista.
3. Os operadores de referência são diferentes: `arr[i]` se refere à i-ésima entrada do arranjo `arr`, e `lst[[i]]` se refere à i-ésima entrada da lista `lst`. Observe que i pode ser o nome da entrada, isto é, `lst$entname` e `lst[['entname']]` se referem aos mesmos dados.

Exemplos

Consideramos agora alguns exemplos relativos a seções ou exemplos específicos do texto principal. Para executar qualquer um destes códigos, é preciso primeiro definir as funções. Para isso, carregue o código com o comando `source`. Depois, é preciso especificar os argumentos das funções. Observe que as linhas das listagens podem estar quebradas de modo pouco natural e continuar na linha seguinte.

Exemplo B.1.1 — Bootstrap no Exemplo 6.4.2

O código R a seguir gera amostras bootstrap e calcula a mediana de cada uma delas. Para executar este código, digite `y <- bootstrap_median(m,x)`, em que `m` é o número de amostras bootstrap, `x` contém a amostra original e as medianas das reamostras são guardadas em `y`. A estatística a que se aplica o bootstrap pode ser trocada substituindo `median` no código. ■

```
#   Example B.1.1
#   function name: bootstrap_median
#   parameters:
```

```
#       m   resample size
#       x   original data
#   return value:
#       a vector of resampled medians
#   description: resamples and stores its median
  bootstrap_median <- function(m,x) {
      n <- length(x);
      result <- rep(0,m);
      for(i in 1:m) result[i] <- median(sample(x,n,T));
   return(result);
  }
```

Exemplo B.1.2 — Amostragem da Distribuição a Posteriori no Exemplo 7.3.1

O código R a seguir gera uma amostra de da distribuição a posteriori conjunta no Exemplo 7.3.1.* Para executar uma simulação, digite

```
post <- post_normal(m,x,alpha0,beta0,mu0,tau0square)
```

em que `m` é o tamanho da amostra de Monte Carlo e os demais argumentos são os hiperparâmetros da priori. O resultado é uma lista chamada (neste caso) `post`, em que `post$mu` e `post$sigmasq` contêm os valores gerados de μ e σ^2, respectivamente. Por exemplo,

```
> x <- c(11.6714, 1.8957, 2.1228, 2.1286, 1.0751, 8.1631,
1.8236, 4.0362, 6.8513, 7.6461, 1.9020, 7.4899, 4.9233,
8.3223, 7.9486);
> post <- post_normal(10**4,x,2,1,4,2)
> z <- sqrt(post$sigmasq)/post$mu
```

executa uma simulação como no Exemplo 7.3.1, com $N = 10^4$. ■

```
#   Example B.1.2
#   function name: post_normal
#   parameters:
#       m       sample size
#       x       data
#       alpha0  shape parameter for 1/sigma^2
#       beta0   rate parameter for 1/sigma^2
#       mu0     location parameter for mu
#       tau0square  variance ratio parameter for mu
```

*Nota do tradutor. Falta no original o que é amostrado ("a sample of from"); pelo Exemplo 7.3.1, são valores de (μ, σ^2).

```
#   returned values:
#       mu      sampled mu
#       sigmasq sampled sigmasquare
#   description: samples from the posterior distribution
#   in Example 7.3.1
#
post_normal<-function(m,x,alpha0,beta0,mu0,tau0square){
# set the length of the data
n <- length(x);
# the shape and rate parameters of the posterior dist.
# alpha_x = first parameter of the gamma dist.
#         = (alpha0 + n/2)
alpha_x <- alpha0 + n/2
# beta_x  = the rate parameter of the gamma dist.
beta_x  <- beta0 + (n-1)/2 * var(x) + n*(mean(x)-mu0)**2/
           2/(1+n*tau0square);
# mu_x    = the mean parameter of the normal dist.
mu_x    <- (mu0/tau0square+n*mean(x))/(n+1/tau0square);
# tausq_x = the variance ratio parameter of the normal
#           distribution
tausq_x <- 1/(n+1/tau0square);
# initialize the result
result  <- list();
result$sigmasq <- 1/rgamma(m,alpha_x,rate=beta_x);
result$mu      <- rnorm(m,mu_x,sqrt(tausq_x *
                        result$sigmasq));
return(result);
}
```

Exemplo B.1.3 — Cálculo das Estimativas e dos Erros Padrão no Exemplo 7.3.1

Uma vez que temos uma amostra de valores da distribuição a posteriori de ψ guardada em `psi`, podemos calcular o intervalo dado pelo valor médio de psi mais ou menos 3 desvios padrão como medida da precisão da estimação. ■

```
# Example B.1.3
# set the data
x <- c(11.6714, 1.8957, 2.1228, 2.1286, 1.0751, 8.1631,
  1.8236, 4.0362, 6.8513, 7.6461, 1.9020, 7.4899,
  4.9233, 8.3223, 7.9486);
```

```
post <- post_normal(10**4,x,2,1,4,2);
# compute the coefficient of variation
psi <- sqrt(post$sigmasq)/post$mu;
psi_hat <- mean(psi <= .5);
psi_se  <- sqrt(psi_hat * (1-psi_hat))/sqrt(length(psi));
# the interval
cq <- 3
cat("The three times s.e. interval is ",
  "[",psi_hat-cq*psi_se, ", ", psi_hat+cq*psi_se,"]\n");
```

Exemplo B.1.4 — Uso do Amostrador de Gibbs no Exemplo 7.3.2

Para executar esta função, digite

```
post<-gibbs_normal(m,x,alpha0,beta0,lambda,mu0,
                   tau0sq,burnin=0)
```

pois isso cria uma lista chamada `post`, em que `post$mu` e `post$sigmasq` contêm os valores gerados de μ e σ^2, respectivamente. Observe que o argumento `burnin` recebe um inteiro não negativo e indica que queremos descartar os primeiros `burnin` valores de μ e σ^2 e reter os últimos `m`. O valor padrão é `burnin=0`. ■

```
# Example B.1.4
#   function name: gibbs_normal
#   parameters
#     m         the size of posterior sample
#     x         data
#     alpha0    shape parameter for 1/sigma^2
#     beta0     rate parameter for 1/sigma^2
#     lambda    degree of freedom of Student's t-dist.
#     mu0       location parameter for mu
#     tau0sq    scale parameter for mu
#     burnin    size of burn in. the default value is 0.
#
#   returnrd values
#       mu       sampled mu's
#       sigmasq  sampled sigma^2's
#   description: samples from the posterior in Ex. 7.3.2
#
gibbs_normal <- function(m,x,alpha0,beta0,lambda,mu0,
                         tau0sq,burnin=0) {
```

```
  # initialize the result
  result <- list();
  result$sigmasq <- result$mu <- rep(0,m);
  # set the initial parameter
  mu      <- mean(x);
  sigmasq <- var(x);
  n       <- length(x);

  # set parameters
  alpha_x <- n/2 + alpha0 + 1/2;
  # loop
  for(i in (1-burnin):m) {
   # update v_i's
   v       <- rgamma(n,(lambda+1)/2,rate=((x-mu)**2/
                          sigmasq/lambda+1)/2);
   # update sigma-square
   beta_x <-(sum(v*(x-mu)**2)/lambda+(mu-mu0)**2/
                               tau0sq)/2+beta0;
   sigmasq<- 1/rgamma(1,alpha_x,rate=beta_x);
   # update mu
   r       <- 1/(sum(v)/lambda+1/tau0sq);
   mu      <- rnorm(1,r*(sum(v*x)/lambda+mu0/tau0sq),
                        sqrt(r*sigmasq));
   # burnin check
   if(i < 1) next;
   result$mu[i]      <- mu;
   result$sigmasq[i] <- sigmasq;
  }
  result$psi <- sqrt(result$sigmasq)/result$mu;
  return(result);
}
```

Exemplo B.1.5 — Formação de Lotes no Exemplo 7.3.2

O código R a seguir divide uma série de dados em lotes e calcula as médias dos lotes. Para executar o código, digite `y<-batching(k,x)` para pôr no vetor `y` as médias dos lotes consecutivos de tamanho `k` dos dados do vetor `x`. ■

```
#   Example B.1.5
#   function name: batching
```

```
#   parameters:
#       k   size of each batch
#       x   data
#   return value:
#       an array of the averages of each batch
#   description: this function separates the data x into
#   floor(length(x)/k) batches and returns the array of
#   the averages of each batch
batching <- function(k,x) {
    m <- floor(length(x)/k);
    result <- rep(0,m);
    for(i in 1:m) result[i] <- mean(x[(i-1)*k+(1:k)]);
    return(result);
}
```

Exemplo B.1.6 — Simulação de uma Amostra da Distribuição da Estatística de Discrepância no Exemplo 9.1.2

O código R a seguir gera uma amostra da estatística de discrepância especificada no Exemplo 9.1.2. Para gerar a amostra, digite `y<-discrepancy(m,n)` para pôr em `y` uma amostra de tamanho `m`, em que `n` é o tamanho do conjunto de dados original. Este código pode ser facilmente modificado para gerar amostras de outras estatísticas de discrepância. ■

```
#   Example B.1.6
#   function name: discrepancy
#   parameters:
#       m   resample size
#       n   size of data
#   return value:
#       an array of m discrepancies
#   description: this function generates m discrepancies
#   when the data size is n
discrepancy <- function(m,n) {
    result <- rep(0,m);
    for(i in 1:m) {
        x    <- rnorm(n);
        xbar <- mean(x);
        r    <- (x-xbar)/sqrt((sum((x-xbar)**2)));
        result[i] <- -sum(log(r**2));
```

```
    }
    return(result/n);
}
```

Exemplo B.1.7 — Geração a partir de uma Distribuição Dirichlet no Exemplo 10.2.3

O código R a seguir gera uma amostra de uma distribuição Dirichlet($\alpha_1, \alpha_2, \alpha_3, \alpha_4$). Para gerar dessa distribuição, primeiro atribua valores ao vetor `alpha` e depois digite `ddirichlet(n,alpha)`, em que `n` é o tamanho da amostra. ■

```
#   Example B.1.7
#   function name: ddirichlet
#   parameters:
#       n       sample size
#       alpha   vector(alpha1,...,alphak)
#   return value:
#       a (n x k) matrix. rows are i.i.d. samples
#   description: this function generates n random samples
#   from Dirichlet(alpha1,...,alphak) distribution
ddirichlet <- function(n,alpha) {
    k <- length(alpha);
    result <- matrix(0,n,k);
    for(i in 1:k) result[,i] <- rgamma(n,alpha[i]);
    for(i in 1:n) result[i,] <- result[i,] /
                                    sum(result[i,]);
    return(result);
}
```

Matrizes

Uma matriz pode ser vista como uma coleção de valores de dados com dois índices ou como um arranjo retangular de dados. Assim, se `a` é uma matriz, então `a[i,j]` é o elemento (i, j) de `a`. Observe que `a[i,]` se refere à i-ésima linha de `a` e `a[,j]` se refere à j-ésima coluna de `a`. Se uma matriz tem m linhas e n colunas, ela é uma matriz $m \times n$, e m e n são chamados de dimensões da matriz.

Talvez a maneira mais simples de criar matrizes seja com os comandos `cbind` e `rbind`. Por exemplo,

```
> x<-c(1,2,3)
> y<-c(4,5,6)
> a<-cbind(x,y)
> a
 x y
[1,] 1 4
[2,] 2 5
[3,] 3 6
```

cria os vetores `x` e `y`, e o comando `cbind` toma `x` como primeira coluna e `y` como segunda coluna da matriz 3×2 recém-criada `a`. Observe que, na impressão de `a`, as colunas continuam rotuladas `x` e `y`, embora ainda possamos nos referir a elas como `a[,1]` e `a[,2]`. Podemos remover esses nomes de colunas com o comando `colnames(a)<-NULL`. Do mesmo modo, o comando `rbind` trata os vetores dados como argumentos como as linhas de uma matriz. Para determinar o número de linhas e de colunas de uma matriz `a`, podemos usar os comandos `nrow(a)` e `ncol(a)`. Também podemos criar uma matriz diagonal usando o comando `diag`. Se `x` é um vetor n-dimensional, então `diag(x)` é uma matriz $n \times n$ com as entradas de `x` na diagonal e 0 nas demais posições. Se `a` é uma matriz $m \times n$, então `diag(a)` é o vetor com as entradas tiradas da diagonal principal de `a`. Para criar uma matriz identidade $n \times n$, use `diag(n)`.

Há várias operações que podem ser feitas com matrizes. Se as matrizes `a` e `b` são $m \times n$, então `a+b` é a matriz $m \times n$ formada pela soma das matrizes componente a componente. A transposta de `a` é a matriz $n \times m$ `t(a)`, cuja i-ésima linha é igual à i-ésima coluna de `a`. Se `c` é um número, então `c*a` é a matriz $m \times n$ formada pela multiplicação de cada elemento de `a` por `c`. Se `a` é $m \times n$ e `b` é $n \times p$, então `a%*%b` é a matriz $m \times p$ produto (Apêndice A.4) de `a` e `b`. Um vetor numérico é tratado como vetor coluna na multiplicação de matrizes. Observe que `a*b` também está definido quando `a` e `b` têm a mesma dimensão, mas esse é o produto componente a componente das duas matrizes, bem diferente do produto de matrizes.

Se `a` é uma matriz $m \times m$, a inversa de `a` é obtida como `solve(a)`. O comando `solve` devolve um erro se a matriz não tiver inversa. Se `a` é uma matriz quadrada, então `det(a)` calcula o determinante de `a`.

Consideramos agora uma aplicação importante.

Exemplo B.1.8 — Ajuste de Modelos de Regressão

Suponha que o vetor n-dimensional `y` corresponda ao vetor de respostas e que a matriz $n \times k$ `V` corresponda à matriz de planejamento quando ajustamos um modelo de regressão linear dado por $E(y \mid V) = V\beta$. A estimativa de mínimos quadrados de β é dada por `b`, calculada em

```
b<-solve(t(V)%*%V)%*%t(V)%*%y
```

com o vetor de valores preditos `p` e os resíduos `r` dados por

```
> p<-V%*%b
> r<-y-p
```

com comprimentos ao quadrado

```
> slp<-t(p)%*%p
> slr<-t(r)%*%r
```

em que `slp` é o comprimento ao quadrado de `p` e `slr` é o comprimento ao quadrado de `r`. Observe que a matriz `solve(t(V)%*%V)` é usada para formar intervalos de confiança e testes para os β_i individuais. Praticamente todos os cálculos envolvidos no ajuste e na inferência para o modelo de regressão linear podem ser feitos com cálculos matriciais no R como os que ilustramos.* ■

Pacotes

Há muitos pacotes escritos para estender a capacidade do R básico. É muito provável que, se você tiver uma necessidade de análise de dados que não possa ser atendida pelo R, encontre um pacote disponível gratuitamente para acrescentar. Remetemos o leitor a `?install.packages` e `?library` para saber mais sobre isso.

B.2 Usando o Minitab

Todos os cálculos encontrados neste texto foram feitos com o Minitab. Esse pacote de software estatístico é muito fácil de aprender e de usar. Outros pacotes, como o SAS ou o R (ver a Seção B.1), também poderiam ser usados com essa finalidade.

*Nota do tradutor. O original diz "linear regression matrix" (matriz de regressão linear); pelo contexto, trata-se do modelo de regressão linear.

A maior parte dos cálculos foi feita usando o Minitab como uma calculadora, isto é, os dados eram digitados e então se recorria a vários comandos do Minitab para obter as quantidades desejadas. Esses cálculos não exigem nenhuma programação.

Houve alguns cálculos, porém, que envolveram um pouco de programação. Em geral, tratava-se de um cálculo em que muitas operações tinham de ser feitas repetidas vezes, e por isso convinha usar um laço. Em cada um desses casos, registramos aqui o código do Minitab que usamos nesses cálculos. Como mostram os exemplos a seguir, esses programas nunca foram muito complicados.

Os estudantes podem usar esses programas como modelos para escrever os próprios programas no Minitab. Na verdade, a linguagem é tão simples que achamos que qualquer pessoa que programe em outra linguagem consegue ler esses programas e usá-los como modelos do mesmo jeito. Basta pensar nos símbolos `c1`, `c2` etc. como vetores (*arrays*), em que o *i*-ésimo elemento do vetor `c1` é acessado por `c1(i)`. Além disso, há as constantes `k1`, `k2` etc.

Um programa do Minitab se chama *macro* e precisa começar com a instrução `gmacro` e terminar com a instrução `endmacro`. A primeira instrução depois de `gmacro` dá um nome ao programa. Comentários num programa, postos ali para explicar o código, começam com `note`.

Se o arquivo que contém o programa se chama `prog.txt` e está gravado no diretório raiz de uma unidade de disco chamada `c`, então o comando do Minitab

```
MTB> %c:/prog.txt
```

executa o programa. Qualquer saída será impressa na janela Session (se você tiver usado um comando `print`) ou guardada na planilha (*worksheet*) do Minitab.

Mais detalhes sobre o Minitab podem ser encontrados no `Help` do programa. A seguir, damos alguns exemplos de macros do Minitab usadas no texto.

Exemplo B.2.1 — Bootstrap no Exemplo 6.4.2

O código do Minitab a seguir gera 1000 amostras bootstrap a partir dos dados em `c1`, calcula a mediana de cada uma dessas amostras e depois calcula a variância amostral dessas medianas. ■

```
gmacro
bootstrapping
```

```
base 34256734
note - original sample is stored in c1
note - bootstrap sample is placed in c2 with each one
note   overwritten
note - medians of bootstrap samples are stored in c3
note - k1 = size of data set (and bootstrap samples)
let k1=15
do k2=1:1000
sample 15 c1 c2;
replace.
let c3(k2)=median(c2)
enddo
note - k3 equals (6.4.5)
let k3=(stdev(c3))**2
print k3
endmacro
```

Exemplo B.2.2 — Amostragem da Distribuição a Posteriori no Exemplo 7.3.1

O código do Minitab a seguir gera uma amostra de tamanho 10^4 da distribuição a posteriori conjunta do Exemplo 7.3.1. Observe que, no software Minitab, a densidade Gama(α, β) tem a forma $(\beta^{-\alpha}/\Gamma(\alpha))x^{\alpha-1}e^{-x/\beta}$. Assim, para gerar de uma distribuição Gama(α, β), como definida neste livro, precisamos tomar no Minitab o segundo parâmetro de forma igual a $1/\beta$. ■

```
gmacro
normalpost
note - the base command sets the seed for the random
note   numbers
base 34256734
note - the parameters of the posterior
note - k1 = first parameter of the gamma distribution
note      = (alpha_0 + n/2)
let k1=9.5
note - k2 = 1/beta
let k2=1/77.578
note - k3 = posterior mean of mu
let k3=5.161
note - k4 = (n + 1/(tau_0 squared) )^(-1)
let k4=1/15.5
```

```
note - main loop
note - c3 contains generated value of sigma**2
note - c4 contains generated value of mu
note - c5 contains generated value of coefficient of
         variation
do k5=1:10000
random 1 c1;
gamma k1 k2.
let c3(k5)=1/c1(1)
let k6=sqrt(k4/c1(1))
random 1 c2;
normal k3 k6.
let c4(k5)=c2(1)
let c5(k5)=sqrt(c3(k5))/c4(k5)
enddo
endmacro
```

Exemplo B.2.3 — Cálculo das Estimativas e dos Erros Padrão no Exemplo 7.3.1

Temos uma amostra de 10^4 valores da distribuição a posteriori de ψ, guardada em C5. Os cálculos a seguir usam essa amostra para calcular uma estimativa da probabilidade a posteriori de que $\psi \leq 0{,}5$ (k1), e também o erro padrão dessa estimativa (k2), a estimativa menos três vezes o seu erro padrão (k3) e a estimativa mais três vezes o seu erro padrão (k4). ■

```
let c6=c5 le .5
let k1=mean(c6)
let k2=sqrt(k1*(1-k1))/sqrt(10000)
let k3=k1-3*k2
let k4=k1+3*k2
print k1 k2 k3 k4
```

Exemplo B.2.4 — Uso do Amostrador de Gibbs no Exemplo 7.3.2

O código do Minitab a seguir gera uma cadeia de 10^4 valores com o amostrador de Gibbs descrito no Exemplo 7.3.2. ■

```
gmacro
gibbs
```

```
base 34256734
note - data sample is stored in c1
note - starting value for mu.
let k1=mean(c1)
note - starting value for sigma**2
let k2=stdev(c1)
let k2=k2**2
note - lambda
let k3=3
note - sample size
let k4=15
note - n/2 + alpha_0 + 1/2
let k5=k4/2 +2+.5
note - mu_0
let k6=4
note - tau_0**2
let k7=2
note - beta_0
let k8=1
let k9=(k3/2+.5)
note - main loop
do k100=1:10000
note - generate the nu_i in c10
do k111=1:15
let k10=.5*(((c1(k111)-k1)**2)/(k2*k3) +1)
let k10=1/k10
random 1 c2;
gamma k9 k10.
let c10(k111)=c2(1)
enddo
note - generate sigma**2 in c20
let c11=c10*((c1-k1)**2)
let k11=.5*sum(c11)/k3+.5*((k1-k6)**2)/k7 +k8
let k11=1/k11
random 1 c2;
gamma k5 k11.
let c20(k100)=1/c2(1)
let k2=1/c2(1)
note - generate mu in c21
let k13=1/(sum(c10)/k3 +1/k7)
let c11=c1*c10/k3
```

```
let k14=sum(c11)+k6/k7
let k14=k13*k14
let k13=sqrt(k13*k2)
random 1 c2;
normal k14 k13.
let c21(k100)=c2(1)
let k1=c2(1)
enddo
endmacro
```

Exemplo B.2.5 — Divisão em Lotes no Exemplo 7.3.2

O código do Minitab a seguir divide em lotes a amostra gerada pelo código da amostragem de Gibbs do Exemplo 7.3.2 e calcula as médias dos lotes. ■

```
gmacro
batching
note - k2= batch size
let k2=40
note - k4 holds the batch sums
note - c1 contains the data to be batched (10000 data values)
note - c2 will contain the batch means (250 batch means)
do k10=1:10000/40
let k4=0
do k20=0:39
let k3=c1(k10+k20)
let k4=k4+k3
enddo
let k11=floor(k10/k2) +1
let c2(k11)=k4/k2
enddo
endmacro
```

Exemplo B.2.6 — Simulação de uma Amostra da Distribuição da Estatística de Discrepância no Exemplo 9.1.2

O código a seguir gera uma amostra da estatística de discrepância especificada no Exemplo 9.1.2. ■

```
gmacro
```

```
goodnessoffit
base 34256734
note - generated sample is stored in c1
note - residuals are placed in c2
note - value of D(r) are placed in c3
note - k1 = size of data set
let k1=5
do k2=1:10000
random k1 c1
let k3=mean(c1)
let k4=sqrt(k1-1)*stdev(c1)
let c2=((c1-k3)/k4)**2
let c2=loge(c2)
let k5=-sum(c2)/k1
let c3(k2)=k5
enddo
endmacro
```

Exemplo B.2.7 — Geração a Partir de uma Distribuição Dirichlet no Exemplo 10.2.3

O código a seguir gera uma amostra de uma distribuição Dirichlet$(\alpha_1, \alpha_2, \alpha_3, \alpha_4)$, em que $\alpha_1 = 2$, $\alpha_2 = 3$, $\alpha_3 = 1$, $\alpha_4 = 1{,}5$. ■

```
gmacro
dirichlet
note - the base command sets the seed for the random
note   number generator (so you can repeat a simulation).
base 34256734
note - here we provide the algorithm for generating from
note   a Dirichlet(k1,k2,k3,k4) distribution.
note - assign the values of the parameters.
let k1=2
let k2=3
let k3=1
let k4=1.5
let k5=K2+k3+k4
let k6=k3+k4
note - generate the sample with i-th sample in i-th row
note   of c2, c3, c4, c5, ....
do k10=1:5
```

```
random 1 c1;
beta k1 k5.
let c2(k10)=c1(1)
random 1 c1;
beta k2 k6.
let c3(k10)=(1-c2(k10))*c1(1)
random 1 c1;
beta k3 k4.
let c4(k10)=(1-c2(k10)-c3(k10))*c1(1)
let c5(k10)= 1-c2(k10)-c3(k10)-c4(k10)
enddo
endmacro
```

APÊNDICE C

Distribuições Comuns

Registramos aqui as distribuições mais usadas em probabilidade e estatística, bem como algumas de suas características básicas.

C.1 Distribuições Discretas

1. *Bernoulli*(θ), $\theta \in [0,1]$ (igual à Binomial$(1,\theta)$).

função de probabilidade[1]: $p(x) = \theta^x(1-\theta)^{1-x}$ para $x = 0, 1$.

média: θ.

variância[2]: $\theta(1-\theta)$.

função geradora de momentos[3]: $m(t) = (1 - \theta + \theta e^t)$ para $t \in R^1$.

2. *Binomial*(n,θ), $n > 0$ inteiro, $\theta \in [0,1]$.

função de probabilidade: $p(x) = \binom{n}{x}\theta^x(1-\theta)^{n-x}$ para $x = 0, 1, \ldots, n$.

média: $n\theta$.

variância: $n\theta(1-\theta)$.

função geradora de momentos: $m(t) = (1 - \theta + \theta e^t)^n$ para $t \in R^1$.

3. *Geométrica*(θ), $\theta \in (0,1]$ (igual à Binomial Negativa$(1,\theta)$).

função de probabilidade: $p(x) = (1-\theta)^x\theta$ para $x = 0, 1, 2, \ldots$.

média: $(1-\theta)/\theta$.

variância: $(1-\theta)/\theta^2$.

função geradora de momentos: $m(t) = \theta\big(1-(1-\theta)e^t\big)^{-1}$ para $t < -\ln(1-\theta)$.

4. *Hipergeométrica*(N,M,n), $M \leq N$, $n \leq N$, todos inteiros positivos.

No original: *probability function*[1], *variance*[2], *moment-generating function*[3].

função de probabilidade:

$$p(x) = \binom{M}{x}\binom{N-M}{n-x}\Big/\binom{N}{n} \quad \text{para } \max(0, n+M-N) \le x \le \min(n, M).$$

média: $n\frac{M}{N}$.

variância: $n\frac{M}{N}\left(1-\frac{M}{N}\right)\frac{N-n}{N-1}$.

5. *Multinomial*$(n, \theta_1, \ldots, \theta_k)$, $n > 0$ inteiro, cada $\theta_i \in [0,1]$, $\theta_1 + \cdots + \theta_k = 1$.

função de probabilidade:

$$p(x_1, \ldots, x_k) = \binom{n}{x_1 \ldots x_k}\theta_1^{x_1}\cdots\theta_k^{x_k} \quad \text{em que cada } x_i \in \{0, 1, \ldots, n\} \text{ e } x_1 + \cdots + x_k = n.$$

média: $E(X_i) = n\theta_i$.

variância: $\text{Var}(X_i) = n\theta_i(1-\theta_i)$.

covariância[4]: $\text{Cov}(X_i, X_j) = -n\theta_i\theta_j$ quando $i \neq j$.

6. *Binomial Negativa*(r, θ), $r > 0$ inteiro, $\theta \in (0, 1]$.

função de probabilidade: $p(x) = \binom{r-1+x}{x}\theta^r(1-\theta)^x$ para $x = 0, 1, 2, 3, \ldots$.

média: $r(1-\theta)/\theta$.

variância: $r(1-\theta)/\theta^2$.

função geradora de momentos: $m(t) = \theta^r\left(1-(1-\theta)e^t\right)^{-r}$ para $t < -\ln(1-\theta)$.

7. *Poisson*(λ), $\lambda > 0$.

função de probabilidade: $p(x) = \frac{\lambda^x}{x!}e^{-\lambda}$ para $x = 0, 1, 2, 3, \ldots$.

média: λ.

variância: λ.

função geradora de momentos: $m(t) = \exp\{\lambda(e^t - 1)\}$ para $t \in R^1$.

No original: *covariance*[4].

C.2 Distribuições Absolutamente Contínuas

1. *Beta*(a, b), $a > 0$, $b > 0$ (igual à Dirichlet(a, b)).

função densidade[5]: $f(x) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} x^{a-1}(1-x)^{b-1}$ para $x \in (0, 1)$.

média: $a/(a+b)$.

variância: $ab/(a+b+1)(a+b)^2$.

2. *Normal Bivariada*$(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ para $\mu_1, \mu_2 \in R^1$, $\sigma_1^2, \sigma_2^2 > 0$, $\rho \in [-1, 1]$.

função densidade:

$$f_{X_1,X_2}(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left\{-\frac{1}{2(1-\rho^2)}\left[\left(\frac{x_1-\mu_1}{\sigma_1}\right)^2 + \left(\frac{x_2-\mu_2}{\sigma_2}\right)^2 - 2\rho\left(\frac{x_1-\mu_1}{\sigma_1}\right)\left(\frac{x_2-\mu_2}{\sigma_2}\right)\right]\right\}$$

para $x_1 \in R^1, x_2 \in R^1$.

média: $E(X_i) = \mu_i$.

variância: $\mathrm{Var}(X_i) = \sigma_i^2$.

covariância: $\mathrm{Cov}(X_1, X_2) = \rho\sigma_1\sigma_2$.

3. *Qui-quadrado*(α) ou $\chi^2(\alpha)$, $\alpha > 0$ (igual à Gama$(\alpha/2, 1/2)$).

função densidade: $f(x) = 2^{-\alpha/2}\big(\Gamma(\alpha/2)\big)^{-1} x^{(\alpha/2)-1} e^{-x/2}$ para $x > 0$.

média: α.

variância: 2α.

função geradora de momentos: $m(t) = (1-2t)^{-\alpha/2}$ para $t < 1/2$.

4. *Dirichlet*$(\alpha_1, \ldots, \alpha_{k+1})$, $\alpha_i > 0$ para cada i.

função densidade:

$$f_{X_1,\ldots,X_k}(x_1, \ldots, x_k) = \frac{\Gamma(\alpha_1 + \cdots + \alpha_{k+1})}{\Gamma(\alpha_1)\cdots\Gamma(\alpha_{k+1})} x_1^{\alpha_1-1} \cdots x_k^{\alpha_k-1}(1 - x_1 - \cdots - x_k)^{\alpha_{k+1}-1}$$

para $x_i \geq 0$, $i = 1, \ldots, k$ e $0 \leq x_1 + \cdots + x_k \leq 1$.

No original: *density function*[5].

média:

$$E(X_i) = \frac{\alpha_i}{\alpha_1 + \cdots + \alpha_{k+1}}.$$

variância:

$$\mathrm{Var}(X_i) = \frac{\alpha_i(\alpha_1 + \cdots + \alpha_{k+1} - \alpha_i)}{(\alpha_1 + \cdots + \alpha_{k+1})^2(1 + \alpha_1 + \cdots + \alpha_{k+1})}.$$

covariância quando $i \neq j$:

$$\mathrm{Cov}(X_i, X_j) = \frac{-\alpha_i\alpha_j}{(\alpha_1 + \cdots + \alpha_{k+1})^2(1 + \alpha_1 + \cdots + \alpha_{k+1})}.$$

5. *Exponencial*(λ), $\lambda > 0$ (igual à Gama$(1, \lambda)$).

função densidade: $f(x) = \lambda e^{-\lambda x}$ para $x > 0$.

média: λ^{-1}.

variância: λ^{-2}.

função geradora de momentos: $m(t) = \lambda(\lambda - t)^{-1}$ para $t < \lambda$.

Observe que alguns livros e pacotes de software substituem λ por $1/\lambda$ na definição da distribuição Exponencial(λ) — sempre confira isso ao usar outro livro ou ao usar um software para gerar valores dessa distribuição.

6. $F(\alpha, \beta)$, $\alpha > 0$, $\beta > 0$.

função densidade:

$$f(x) = \frac{\Gamma\left(\frac{\alpha+\beta}{2}\right)}{\Gamma\left(\frac{\alpha}{2}\right)\Gamma\left(\frac{\beta}{2}\right)}\left(\frac{\alpha}{\beta}x\right)^{\alpha/2-1}\left(1 + \frac{\alpha}{\beta}x\right)^{-(\alpha+\beta)/2}\frac{\alpha}{\beta}$$
$$\text{para } x > 0.$$

média: $\beta/(\beta - 2)$ quando $\beta > 2$.

variância: $2\beta^2(\alpha + \beta - 2)/\alpha(\beta - 2)^2(\beta - 4)$ quando $\beta > 4$.

7. *Gama*(α, λ), $\alpha > 0$, $\lambda > 0$.

função densidade: $f(x) = \frac{\lambda^\alpha x^{\alpha-1}}{\Gamma(\alpha)}e^{-\lambda x}$ para $x > 0$.

média: α/λ.

variância: α/λ^2.

função geradora de momentos: $m(t) = \lambda^\alpha(\lambda - t)^{-\alpha}$ para $t < \lambda$.

Observe que alguns livros e pacotes de software substituem λ por $1/\lambda$ na definição da distribuição Gama(α, λ) — sempre confira isso ao usar outro livro ou ao usar um software para gerar valores dessa distribuição.

8. Log-normal ou log $N(\mu, \sigma^2)$, $\mu \in R^1$, $\sigma^2 > 0$.

função densidade: $f(x) = (2\pi\sigma^2)^{-1/2} x^{-1} \exp\left(-\frac{1}{2\sigma^2}(\ln x - \mu)^2\right)$ para $x > 0$.

média: $\exp(\mu + \sigma^2/2)$.

variância: $\exp(2\mu + \sigma^2)\big(\exp(\sigma^2) - 1\big)$.

9. $N(\mu, \sigma^2)$, $\mu \in R^1$, $\sigma^2 > 0$.

função densidade: $f(x) = (2\pi\sigma^2)^{-1/2} \exp\left(-\frac{1}{2\sigma^2}(x - \mu)^2\right)$ para $x \in R^1$.

média: μ.

variância: σ^2.

função geradora de momentos: $m(t) = \exp(\mu t + \sigma^2 t^2/2)$ para $t \in R^1$.

10. *Student*(α) ou $t(\alpha)$, $\alpha > 0$ ($\alpha = 1$ dá a distribuição de Cauchy[6]).

função densidade:

$$f(x) = \frac{\Gamma\left(\frac{\alpha+1}{2}\right)}{\Gamma\left(\frac{1}{2}\right)\Gamma\left(\frac{\alpha}{2}\right)} \left(1 + \frac{x^2}{\alpha}\right)^{-(\alpha+1)/2} \frac{1}{\sqrt{\alpha}}$$
$$\text{para } x \in R^1.$$

média: 0 quando $\alpha > 1$.

variância: $\alpha/(\alpha - 2)$ quando $\alpha > 2$.

11. *Uniforme*$[L, R]$, $R > L$.

função densidade: $f(x) = 1/(R - L)$ para $L < x < R$.

média: $(L + R)/2$.

variância: $(R - L)^2/12$.

função geradora de momentos: $m(t) = (e^{Rt} - e^{Lt})/t(R - L)$.

No original: *Cauchy*[6].

APÊNDICE D

Tabelas

As tabelas a seguir podem ser usadas em diversos cálculos. Recomenda-se, porém, que o leitor se familiarize com o uso de um pacote de software estatístico, em vez de depender das tabelas. Com o software, é possível fazer cálculos muito mais variados e precisos e, no fim das contas, isso é muito mais conveniente.

D.1 Números Aleatórios

Cada linha da Tabela D.1 é uma amostra de 40 dígitos aleatórios, isto é, 40 valores independentes e identicamente distribuídos (i.i.d.) da distribuição uniforme[1] no conjunto $\{0, 1, 2, 3, 4, 5, 6, 7, 8, 9\}$.

Suponha que queremos uma amostra de cinco valores i.i.d. da distribuição uniforme em $S = \{1, 2, \ldots, 25\}$, isto é, uma amostra aleatória de tamanho cinco, com reposição, de S. Para isso, escolha um ponto de partida na tabela e vá lendo números sucessivos de dois dígitos (sem sobreposição), tratando um par como 07 como 7 e descartando os pares que não estejam entre 1 e 25, até obter cinco valores. Por exemplo, se começarmos na linha 110, lemos os pares ($*$ indica um elemento da amostra) 38, 44, 84, 87, 89, 18*, 33, 82, 46, 97, 39, 36, 44, 20*, 06*, 76, 68, 80, 87, 08*, 81, 48, 66, 94, 87, 60, 51, 30, 92, 97, 00, 41, 27, 12*. Vemos, nesse ponto, que temos uma amostra de tamanho cinco dada por 18, 20, 6, 8, 12.

Se quisermos uma amostra aleatória de tamanho cinco, sem reposição, de S, procedemos como acima, mas agora ignoramos as repetições na amostra gerada até obter os cinco números. No caso anterior, não houve repetições; assim, esta também é uma amostra aleatória simples de tamanho cinco sem reposição.

No original: *uniform distribution*[1].

Tabela D.1: Números Aleatórios

Linha								
101	19223	95034	05756	28713	96409	12531	42544	82853
102	73676	47150	99400	01927	27754	42648	82425	36290
103	45467	71709	77558	00095	32863	29485	82226	90056
104	52711	38889	93074	60227	40011	85848	48767	52573
105	95592	94007	69971	91481	60779	53791	17297	59335
106	68417	35013	15529	72765	85089	57067	50211	47487
107	82739	57890	20807	47511	81676	55300	94383	14893
108	60940	72024	17868	24943	61790	90656	87964	18883
109	36009	19365	15412	39638	85453	46816	83485	41979
110	38448	48789	18338	24697	39364	42006	76688	08708
111	81486	69487	60513	09297	00412	71238	27649	39950
112	59636	88804	04634	71197	19352	73089	84898	45785
113	62568	70206	40325	03699	71080	22553	11486	11776
114	45149	32992	75730	66280	03819	56202	02938	70915
115	61041	77684	94322	24709	73698	14526	31893	32592
116	14459	26056	31424	80371	65103	62253	50490	61181
117	38167	98532	62183	70632	23417	26185	41448	75532
118	73190	32533	04470	29669	84407	90785	65956	86382
119	95857	07118	87664	92099	58806	66979	98624	84826
120	35476	55972	39421	65850	04266	35435	43742	11937
121	71487	09984	29077	14863	61683	47052	62224	51025
122	13873	81598	95052	90908	73592	75186	87136	95761
123	54580	81507	27102	56027	55892	33063	41842	81868
124	71035	09001	43367	49497	72719	96758	27611	91596
125	96746	12149	37823	71868	18442	35119	62103	39244
126	96927	19931	36809	74192	77567	88741	48409	41903
127	43909	99477	25330	64359	40085	16925	85117	36071
128	15689	14227	06565	14374	13352	49367	81982	87209
129	36759	58984	68288	22913	18638	54303	00795	08727
130	69051	64817	87174	09517	84534	06489	87201	97245
131	05007	16632	81194	14873	04197	85576	45195	96565
132	68732	55259	84292	08796	43165	93739	31685	97150
133	45740	41807	65561	33302	07051	93623	18132	09547

Tabela D.1: Números Aleatórios (continuação)

Linha								
134	27816	78416	18329	21337	35213	37741	04312	68508
135	66925	55658	39100	78458	11206	19876	87151	31260
136	08421	44753	77377	28744	75592	08563	79140	92454
137	53645	66812	61421	47836	12609	15373	98481	14592
138	66831	68908	40772	21558	47781	33586	79177	06928
139	55588	99404	70708	41098	43563	56934	48394	51719
140	12975	13258	13048	45144	72321	81940	00360	02428
141	96767	35964	23822	96012	94591	65194	50842	53372
142	72829	50232	97892	63408	77919	44575	24870	04178
143	88565	42628	17797	49376	61762	16953	88604	12724
144	62964	88145	83083	69453	46109	59505	69680	00900
145	19687	12633	57857	95806	09931	02150	43163	58636
146	37609	59057	66967	83401	60705	02384	90597	93600
147	54973	86278	88737	74351	47500	84552	19909	67181
148	00694	05977	19664	65441	20903	62371	22725	53340
149	71546	05233	53946	68743	72460	27601	45403	88692
150	07511	88915	41267	16853	84569	79367	32337	03316
151	03802	29341	29264	80198	12371	13121	54969	43912
152	77320	35030	77519	41109	98296	18984	60869	12349
153	07886	56866	39648	69290	03600	05376	58958	22720
154	87065	74133	21117	70595	22791	67306	28420	52067
155	42090	09628	54035	93879	98441	04606	27381	82637
156	55494	67690	88131	81800	11188	28552	25752	21953
157	16698	30406	96587	65985	07165	50148	16201	86792
158	16297	07626	68683	45335	34377	72941	41764	77038
159	22897	17467	17638	70043	36243	13008	83993	22869
160	98163	45944	34210	64158	76971	27689	82926	75957
161	43400	25831	06283	22138	16043	15706	73345	26238
162	97341	46254	88153	62336	21112	35574	99271	45297
163	64578	67197	28310	90341	37531	63890	52630	76315
164	11022	79124	49525	63078	17229	32165	01343	21394
165	81232	43939	23840	05995	84589	06788	76358	26622

D.2 Fda da Normal Padrão

Se $Z \sim N(0,1)$, então podemos usar a Tabela D.2 para calcular a função de distribuição acumulada[2] (fda) Φ de Z. Por exemplo, suponha que queremos calcular $\Phi(z) = P(Z < 1{,}03)$. A simetria da distribuição $N(0,1)$ em torno de 0 implica que $\Phi(z) = 1 - \Phi(-z)$; assim, usando a Tabela D.2, temos que $P(Z < 1{,}03) = P(Z < 1{,}03) = 1 - P(Z < -1{,}03) = 1 - 0{,}1515 = 0{,}8485$.*

*__Nota do tradutor.__ O original repete $P(Z < 1{,}03)$; o segundo termo provavelmente seria $P(Z > -1{,}03)$.

No original: *cumulative distribution function*[2].

Tabela D.2: Fda da Normal Padrão

z	,00	,01	,02	,03	,04	,05	,06	,07	,08	,09
−3,4	,0003	,0003	,0003	,0003	,0003	,0003	,0003	,0003	,0003	,0002
−3,3	,0005	,0005	,0005	,0004	,0004	,0004	,0004	,0004	,0004	,0003
−3,2	,0007	,0007	,0006	,0006	,0006	,0006	,0006	,0005	,0005	,0005
−3,1	,0010	,0009	,0009	,0009	,0008	,0008	,0008	,0008	,0007	,0007
−3,0	,0013	,0013	,0013	,0012	,0012	,0011	,0011	,0011	,0010	,0010
−2,9	,0019	,0018	,0018	,0017	,0016	,0016	,0015	,0015	,0014	,0014
−2,8	,0026	,0025	,0024	,0023	,0023	,0022	,0021	,0021	,0020	,0019
−2,7	,0035	,0034	,0033	,0032	,0031	,0030	,0029	,0028	,0027	,0026
−2,6	,0047	,0045	,0044	,0043	,0041	,0040	,0039	,0038	,0037	,0036
−2,5	,0062	,0060	,0059	,0057	,0055	,0054	,0052	,0051	,0049	,0048
−2,4	,0082	,0080	,0078	,0075	,0073	,0071	,0069	,0068	,0066	,0064
−2,3	,0107	,0104	,0102	,0099	,0096	,0094	,0091	,0089	,0087	,0084
−2,2	,0139	,0136	,0132	,0129	,0125	,0122	,0119	,0116	,0113	,0110
−2,1	,0179	,0174	,0170	,0166	,0162	,0158	,0154	,0150	,0146	,0143
−2,0	,0228	,0222	,0217	,0212	,0207	,0202	,0197	,0192	,0188	,0183
−1,9	,0287	,0281	,0274	,0268	,0262	,0256	,0250	,0244	,0239	,0233
−1,8	,0359	,0351	,0344	,0336	,0329	,0322	,0314	,0307	,0301	,0294
−1,7	,0446	,0436	,0427	,0418	,0409	,0401	,0392	,0384	,0375	,0367
−1,6	,0548	,0537	,0526	,0516	,0505	,0495	,0485	,0475	,0465	,0455
−1,5	,0668	,0655	,0643	,0630	,0618	,0606	,0594	,0582	,0571	,0559
−1,4	,0808	,0793	,0778	,0764	,0749	,0735	,0721	,0708	,0694	,0681
−1,3	,0968	,0951	,0934	,0918	,0901	,0885	,0869	,0853	,0838	,0823
−1,2	,1151	,1131	,1112	,1093	,1075	,1056	,1038	,1020	,1003	,0985
−1,1	,1357	,1335	,1314	,1292	,1271	,1251	,1230	,1210	,1190	,1170
−1,0	,1587	,1562	,1539	,1515	,1492	,1469	,1446	,1423	,1401	,1379
−0,9	,1841	,1814	,1788	,1762	,1736	,1711	,1685	,1660	,1635	,1611
−0,8	,2119	,2090	,2061	,2033	,2005	,1977	,1949	,1922	,1894	,1867
−0,7	,2420	,2389	,2358	,2327	,2296	,2266	,2236	,2206	,2177	,2148
−0,6	,2743	,2709	,2676	,2643	,2611	,2578	,2546	,2514	,2483	,2451
−0,5	,3085	,3050	,3015	,2981	,2946	,2912	,2877	,2843	,2810	,2776
−0,4	,3446	,3409	,3372	,3336	,3300	,3264	,3228	,3192	,3156	,3121
−0,3	,3821	,3783	,3745	,3707	,3669	,3632	,3594	,3557	,3520	,3483
−0,2	,4207	,4168	,4129	,4090	,4052	,4013	,3974	,3936	,3897	,3859
−0,1	,4602	,4562	,4522	,4483	,4443	,4404	,4364	,4325	,4286	,4247
−0,0	,5000	,4960	,4920	,4880	,4840	,4801	,4761	,4721	,4681	,4641

D.3 Quantis da Distribuição Qui-Quadrado

Se $X \sim \chi^2(df)$, então podemos usar a Tabela D.3 para obter alguns quantis dessa distribuição. Por exemplo, se $df = 10$ e $P = 0{,}98$, então $x_{0{,}98} = 21{,}16$ é o quantil 0,98 dessa distribuição.

Tabela D.3: Quantis da $\chi^2(df)$

	P									
df	0,75	0,85	0,90	0,95	0,975	0,98	0,99	0,995	0,9975	0,999
1	1,32	2,07	2,71	3,84	5,02	5,41	6,63	7,88	9,14	10,83
2	2,77	3,79	4,61	5,99	7,38	7,82	9,21	10,60	11,98	13,82
3	4,11	5,32	6,25	7,81	9,35	9,84	11,34	12,84	14,32	16,27
4	5,39	6,74	7,78	9,49	11,14	11,67	13,28	14,86	16,42	18,47
5	6,63	8,12	9,24	11,07	12,83	13,39	15,09	16,75	18,39	20,51
6	7,84	9,45	10,64	12,59	14,45	15,03	16,81	18,55	20,25	22,46
7	9,04	10,75	12,02	14,07	16,01	16,62	18,48	20,28	22,04	24,32
8	10,22	12,03	13,36	15,51	17,53	18,17	20,09	21,95	23,77	26,12
9	11,39	13,29	14,68	16,92	19,02	19,68	21,67	23,59	25,46	27,88
10	12,55	14,53	15,99	18,31	20,48	21,16	23,21	25,19	27,11	29,59
11	13,70	15,77	17,28	19,68	21,92	22,62	24,72	26,76	28,73	31,26
12	14,85	16,99	18,55	21,03	23,34	24,05	26,22	28,30	30,32	32,91
13	15,98	18,20	19,81	22,36	24,74	25,47	27,69	29,82	31,88	34,53
14	17,12	19,41	21,06	23,68	26,12	26,87	29,14	31,32	33,43	36,12
15	18,25	20,60	22,31	25,00	27,49	28,26	30,58	32,80	34,95	37,70
16	19,37	21,79	23,54	26,30	28,85	29,63	32,00	34,27	36,46	39,25
17	20,49	22,98	24,77	27,59	30,19	31,00	33,41	35,72	37,95	40,79
18	21,60	24,16	25,99	28,87	31,53	32,35	34,81	37,16	39,42	42,31
19	22,72	25,33	27,20	30,14	32,85	33,69	36,19	38,58	40,88	43,82
20	23,83	26,50	28,41	31,41	34,17	35,02	37,57	40,00	42,34	45,31
21	24,93	27,66	29,62	32,67	35,48	36,34	38,93	41,40	43,78	46,80
22	26,04	28,82	30,81	33,92	36,78	37,66	40,29	42,80	45,20	48,27
23	27,14	29,98	32,01	35,17	38,08	38,97	41,64	44,18	46,62	49,73
24	28,24	31,13	33,20	36,42	39,36	40,27	42,98	45,56	48,03	51,18
25	29,34	32,28	34,38	37,65	40,65	41,57	44,31	46,93	49,44	52,62
26	30,43	33,43	35,56	38,89	41,92	42,86	45,64	48,29	50,83	54,05
27	31,53	34,57	36,74	40,11	43,19	44,14	46,96	49,64	52,22	55,48
28	32,62	35,71	37,92	41,34	44,46	45,42	48,28	50,99	53,59	56,89
29	33,71	36,85	39,09	42,56	45,72	46,69	49,59	52,34	54,97	58,30
30	34,80	37,99	40,26	43,77	46,98	47,96	50,89	53,67	56,33	59,70
40	45,62	49,24	51,81	55,76	59,34	60,44	63,69	66,77	69,70	73,40
50	56,33	60,35	63,17	67,50	71,42	72,61	76,15	79,49	82,66	86,66
60	66,98	71,34	74,40	79,08	83,30	84,58	88,38	91,95	95,34	99,61
80	88,13	93,11	96,58	101,9	106,6	108,1	112,3	116,3	120,1	124,8
100	109,1	114,7	118,5	124,3	129,6	131,1	135,8	140,2	144,3	149,4

D.4 Quantis da Distribuição t

A Tabela D.4 contém alguns quantis das distribuições t, ou de Student. Por exemplo, se $X \sim t(df)$, com $df = 10$ e $P = 0{,}98$, então $x_{0{,}98} = 2{,}359$ é o quantil 0,98 da distribuição $t(10)$. Lembre que a distribuição $t(df)$ é simétrica em torno de 0; assim, por exemplo, $x_{0{,}25} = -x_{0{,}75}$.

Tabela D.4: Quantis da $t(df)$

	P									
df	0,75	0,85	0,90	0,95	0,975	0,98	0,99	0,995	0,9975	0,999
1	1,000	1,963	3,078	6,314	12,71	15,89	31,82	63,66	127,3	318,3
2	0,816	1,386	1,886	2,920	4,303	4,849	6,965	9,925	14,09	22,33
3	0,765	1,250	1,638	2,353	3,182	3,482	4,541	5,841	7,453	10,21
4	0,741	1,190	1,533	2,132	2,776	2,999	3,747	4,604	5,598	7,173
5	0,727	1,156	1,476	2,015	2,571	2,757	3,365	4,032	4,773	5,893
6	0,718	1,134	1,440	1,943	2,447	2,612	3,143	3,707	4,317	5,208
7	0,711	1,119	1,415	1,895	2,365	2,517	2,998	3,499	4,029	4,785
8	0,706	1,108	1,397	1,860	2,306	2,449	2,896	3,355	3,833	4,501
9	0,703	1,100	1,383	1,833	2,262	2,398	2,821	3,250	3,690	4,297
10	0,700	1,093	1,372	1,812	2,228	2,359	2,764	3,169	3,581	4,144
11	0,697	1,088	1,363	1,796	2,201	2,328	2,718	3,106	3,497	4,025
12	0,695	1,083	1,356	1,782	2,179	2,303	2,681	3,055	3,428	3,930
13	0,694	1,079	1,350	1,771	2,160	2,282	2,650	3,012	3,372	3,852
14	0,692	1,076	1,345	1,761	2,145	2,264	2,624	2,977	3,326	3,787
15	0,691	1,074	1,341	1,753	2,131	2,249	2,602	2,947	3,286	3,733
16	0,690	1,071	1,337	1,746	2,120	2,235	2,583	2,921	3,252	3,686
17	0,689	1,069	1,333	1,740	2,110	2,224	2,567	2,898	3,222	3,646
18	0,688	1,067	1,330	1,734	2,101	2,214	2,552	2,878	3,197	3,611
19	0,688	1,066	1,328	1,729	2,093	2,205	2,539	2,861	3,174	3,579
20	0,687	1,064	1,325	1,725	2,086	2,197	2,528	2,845	3,153	3,552
21	0,686	1,063	1,323	1,721	2,080	2,189	2,518	2,831	3,135	3,527
22	0,686	1,061	1,321	1,717	2,074	2,183	2,508	2,819	3,119	3,505
23	0,685	1,060	1,319	1,714	2,069	2,177	2,500	2,807	3,104	3,485
24	0,685	1,059	1,318	1,711	2,064	2,172	2,492	2,797	3,091	3,467
25	0,684	1,058	1,316	1,708	2,060	2,167	2,485	2,787	3,078	3,450
26	0,684	1,058	1,315	1,706	2,056	2,162	2,479	2,779	3,067	3,435
27	0,684	1,057	1,314	1,703	2,052	2,158	2,473	2,771	3,057	3,421
28	0,683	1,056	1,313	1,701	2,048	2,154	2,467	2,763	3,047	3,408
29	0,683	1,055	1,311	1,699	2,045	2,150	2,462	2,756	3,038	3,396
30	0,683	1,055	1,310	1,697	2,042	2,147	2,457	2,750	3,030	3,385
40	0,681	1,050	1,303	1,684	2,021	2,123	2,423	2,704	2,971	3,307
50	0,679	1,047	1,299	1,676	2,009	2,109	2,403	2,678	2,937	3,261
60	0,679	1,045	1,296	1,671	2,000	2,099	2,390	2,660	2,915	3,232
80	0,678	1,043	1,292	1,664	1,990	2,088	2,374	2,639	2,887	3,195
100	0,677	1,042	1,290	1,660	1,984	2,081	2,364	2,626	2,871	3,174
1000	0,675	1,037	1,282	1,646	1,962	2,056	2,330	2,581	2,813	3,098
∞	0,674	1,036	1,282	1,645	1,960	2,054	2,326	2,576	2,807	3,091
	50%	70%	80%	90%	95%	96%	98%	99%	99,5%	99,8%
	Nível de confiança									

D.5 Quantis da Distribuição F

Se $X \sim F(ndf, ddf)$, podemos usar a Tabela D.5 para obter alguns quantis dessa distribuição. Por exemplo, se $ndf = 3$, $ddf = 4$ e $P = 0{,}975$, então $x_{0{,}975} = 9{,}98$ é o quantil 0,975 da distribuição $F(3, 4)$. Observe que, se $X \sim F(ndf, ddf)$, então $Y = 1/X \sim F(ddf, ndf)$ e $P(X \leq x) = P(Y \geq 1/x)$.

Tabela D.5: Quantis da $F(ndf, ddf)$

		ndf					
ddf	P	1	2	3	4	5	6
1	0,900	39,86	49,50	53,59	55,83	57,24	58,20
	0,950	161,45	199,50	215,71	224,58	230,16	233,99
	0,975	647,79	799,50	864,16	899,58	921,85	937,11
	0,990	4052,18	4999,50	5403,35	5624,58	5763,65	5858,99
	0,999	405284,07	499999,50	540379,20	562499,58	576404,56	585937,11
2	0,900	8,53	9,00	9,16	9,24	9,29	9,33
	0,950	18,51	19,00	19,16	19,25	19,30	19,33
	0,975	38,51	39,00	39,17	39,25	39,30	39,33
	0,990	98,50	99,00	99,17	99,25	99,30	99,33
	0,999	998,50	999,00	999,17	999,25	999,30	999,33
3	0,900	5,54	5,46	5,39	5,34	5,31	5,28
	0,950	10,13	9,55	9,28	9,12	9,01	8,94
	0,975	17,44	16,04	15,44	15,10	14,88	14,73
	0,990	34,12	30,82	29,46	28,71	28,24	27,91
	0,999	167,03	148,50	141,11	137,10	134,58	132,85
4	0,900	4,54	4,32	4,19	4,11	4,05	4,01
	0,950	7,71	6,94	6,59	6,39	6,26	6,16
	0,975	12,22	10,65	9,98	9,60	9,36	9,20
	0,990	21,20	18,00	16,69	15,98	15,52	15,21
	0,999	74,14	61,25	56,18	53,44	51,71	50,53
5	0,900	4,06	3,78	3,62	3,52	3,45	3,40
	0,950	6,61	5,79	5,41	5,19	5,05	4,95
	0,975	10,01	8,43	7,76	7,39	7,15	6,98
	0,990	16,26	13,27	12,06	11,39	10,97	10,67
	0,999	47,18	37,12	33,20	31,09	29,75	28,83
6	0,900	3,78	3,46	3,29	3,18	3,11	3,05
	0,950	5,99	5,14	4,76	4,53	4,39	4,28
	0,975	8,81	7,26	6,60	6,23	5,99	5,82
	0,990	13,75	10,92	9,78	9,15	8,75	8,47
	0,999	35,51	27,00	23,70	21,92	20,80	20,03
7	0,900	3,59	3,26	3,07	2,96	2,88	2,83
	0,950	5,59	4,74	4,35	4,12	3,97	3,87
	0,975	8,07	6,54	5,89	5,52	5,29	5,12
	0,990	12,25	9,55	8,45	7,85	7,46	7,19
	0,999	29,25	21,69	18,77	17,20	16,21	15,52

Tabela D.5: Quantis da $F(ndf, ddf)$ (continuação)

		ndf					
ddf	P	7	8	9	10	11	12
1	0,900	58,91	59,44	59,86	60,19	60,47	60,71
	0,950	236,77	238,88	240,54	241,88	242,98	243,91
	0,975	948,22	956,66	963,28	968,63	973,03	976,71
	0,990	5928,36	5981,07	6022,47	6055,85	6083,32	6106,32
	0,999	592873,29	598144,16	602283,99	605620,97	608367,68	610667,82
2	0,900	9,35	9,37	9,38	9,39	9,40	9,41
	0,950	19,35	19,37	19,38	19,40	19,40	19,41
	0,975	39,36	39,37	39,39	39,40	39,41	39,41
	0,990	99,36	99,37	99,39	99,40	99,41	99,42
	0,999	999,36	999,37	999,39	999,40	999,41	999,42
3	0,900	5,27	5,25	5,24	5,23	5,22	5,22
	0,950	8,89	8,85	8,81	8,79	8,76	8,74
	0,975	14,62	14,54	14,47	14,42	14,37	14,34
	0,990	27,67	27,49	27,35	27,23	27,13	27,05
	0,999	131,58	130,62	129,86	129,25	128,74	128,32
4	0,900	3,98	3,95	3,94	3,92	3,91	3,90
	0,950	6,09	6,04	6,00	5,96	5,94	5,91
	0,975	9,07	8,98	8,90	8,84	8,79	8,75
	0,990	14,98	14,80	14,66	14,55	14,45	14,37
	0,999	49,66	49,00	48,47	48,05	47,70	47,41
5	0,900	3,37	3,34	3,32	3,30	3,28	3,27
	0,950	4,88	4,82	4,77	4,74	4,70	4,68
	0,975	6,85	6,76	6,68	6,62	6,57	6,52
	0,990	10,46	10,29	10,16	10,05	9,96	9,89
	0,999	28,16	27,65	27,24	26,92	26,65	26,42
6	0,900	3,01	2,98	2,96	2,94	2,92	2,90
	0,950	4,21	4,15	4,10	4,06	4,03	4,00
	0,975	5,70	5,60	5,52	5,46	5,41	5,37
	0,990	8,26	8,10	7,98	7,87	7,79	7,72
	0,999	19,46	19,03	18,69	18,41	18,18	17,99
7	0,900	2,78	2,75	2,72	2,70	2,68	2,67
	0,950	3,79	3,73	3,68	3,64	3,60	3,57
	0,975	4,99	4,90	4,82	4,76	4,71	4,67
	0,990	6,99	6,84	6,72	6,62	6,54	6,47
	0,999	15,02	14,63	14,33	14,08	13,88	13,71

Tabela D.5: Quantis da $F(ndf, ddf)$ (continuação)

		ndf					
ddf	P	15	20	30	60	120	10000
1	0,900	61,22	61,74	62,26	62,79	63,06	63,32
	0,950	245,95	248,01	250,10	252,20	253,25	254,30
	0,975	984,87	993,10	1001,41	1009,80	1014,02	1018,21
	0,990	6157,28	6208,73	6260,65	6313,03	6339,39	6365,55
	0,999	615763,66	620907,67	626098,96	631336,56	633972,40	636587,61
2	0,900	9,42	9,44	9,46	9,47	9,48	9,49
	0,950	19,43	19,45	19,46	19,48	19,49	19,50
	0,975	39,43	39,45	39,46	39,48	39,49	39,50
	0,990	99,43	99,45	99,47	99,48	99,49	99,50
	0,999	999,43	999,45	999,47	999,48	999,49	999,50
3	0,900	5,20	5,18	5,17	5,15	5,14	5,13
	0,950	8,70	8,66	8,62	8,57	8,55	8,53
	0,975	14,25	14,17	14,08	13,99	13,95	13,90
	0,990	26,87	26,69	26,50	26,32	26,22	26,13
	0,999	127,37	126,42	125,45	124,47	123,97	123,48
4	0,900	3,87	3,84	3,82	3,79	3,78	3,76
	0,950	5,86	5,80	5,75	5,69	5,66	5,63
	0,975	8,66	8,56	8,46	8,36	8,31	8,26
	0,990	14,20	14,02	13,84	13,65	13,56	13,46
	0,999	46,76	46,10	45,43	44,75	44,40	44,06
5	0,900	3,24	3,21	3,17	3,14	3,12	3,11
	0,950	4,62	4,56	4,50	4,43	4,40	4,37
	0,975	6,43	6,33	6,23	6,12	6,07	6,02
	0,990	9,72	9,55	9,38	9,20	9,11	9,02
	0,999	25,91	25,39	24,87	24,33	24,06	23,79
6	0,900	2,87	2,84	2,80	2,76	2,74	2,72
	0,950	3,94	3,87	3,81	3,74	3,70	3,67
	0,975	5,27	5,17	5,07	4,96	4,90	4,85
	0,990	7,56	7,40	7,23	7,06	6,97	6,88
	0,999	17,56	17,12	16,67	16,21	15,98	15,75
7	0,900	2,63	2,59	2,56	2,51	2,49	2,47
	0,950	3,51	3,44	3,38	3,30	3,27	3,23
	0,975	4,57	4,47	4,36	4,25	4,20	4,14
	0,990	6,31	6,16	5,99	5,82	5,74	5,65
	0,999	13,32	12,93	12,53	12,12	11,91	11,70

Tabela D.5: Quantis da $F(ndf, ddf)$ (continuação)

		ndf					
ddf	P	1	2	3	4	5	6
8	0,900	3,46	3,11	2,92	2,81	2,73	2,67
	0,950	5,32	4,46	4,07	3,84	3,69	3,58
	0,975	7,57	6,06	5,42	5,05	4,82	4,65
	0,990	11,26	8,65	7,59	7,01	6,63	6,37
	0,999	25,41	18,49	15,83	14,39	13,48	12,86
9	0,900	3,36	3,01	2,81	2,69	2,61	2,55
	0,950	5,12	4,26	3,86	3,63	3,48	3,37
	0,975	7,21	5,71	5,08	4,72	4,48	4,32
	0,990	10,56	8,02	6,99	6,42	6,06	5,80
	0,999	22,86	16,39	13,90	12,56	11,71	11,13
10	0,900	3,29	2,92	2,73	2,61	2,52	2,46
	0,950	4,96	4,10	3,71	3,48	3,33	3,22
	0,975	6,94	5,46	4,83	4,47	4,24	4,07
	0,990	10,04	7,56	6,55	5,99	5,64	5,39
	0,999	21,04	14,91	12,55	11,28	10,48	9,93
11	0,900	3,23	2,86	2,66	2,54	2,45	2,39
	0,950	4,84	3,98	3,59	3,36	3,20	3,09
	0,975	6,72	5,26	4,63	4,28	4,04	3,88
	0,990	9,65	7,21	6,22	5,67	5,32	5,07
	0,999	19,69	13,81	11,56	10,35	9,58	9,05
12	0,900	3,18	2,81	2,61	2,48	2,39	2,33
	0,950	4,75	3,89	3,49	3,26	3,11	3,00
	0,975	6,55	5,10	4,47	4,12	3,89	3,73
	0,990	9,33	6,93	5,95	5,41	5,06	4,82
	0,999	18,64	12,97	10,80	9,63	8,89	8,38
13	0,900	3,14	2,76	2,56	2,43	2,35	2,28
	0,950	4,67	3,81	3,41	3,18	3,03	2,92
	0,975	6,41	4,97	4,35	4,00	3,77	3,60
	0,990	9,07	6,70	5,74	5,21	4,86	4,62
	0,999	17,82	12,31	10,21	9,07	8,35	7,86
14	0,900	3,10	2,73	2,52	2,39	2,31	2,24
	0,950	4,60	3,74	3,34	3,11	2,96	2,85
	0,975	6,30	4,86	4,24	3,89	3,66	3,50
	0,990	8,86	6,51	5,56	5,04	4,69	4,46
	0,999	17,14	11,78	9,73	8,62	7,92	7,44

Tabela D.5: Quantis da $F(ndf, ddf)$ (continuação)

		ndf					
ddf	P	7	8	9	10	11	12
8	0,900	2,62	2,59	2,56	2,54	2,52	2,50
	0,950	3,50	3,44	3,39	3,35	3,31	3,28
	0,975	4,53	4,43	4,36	4,30	4,24	4,20
	0,990	6,18	6,03	5,91	5,81	5,73	5,67
	0,999	12,40	12,05	11,77	11,54	11,35	11,19
9	0,900	2,51	2,47	2,44	2,42	2,40	2,38
	0,950	3,29	3,23	3,18	3,14	3,10	3,07
	0,975	4,20	4,10	4,03	3,96	3,91	3,87
	0,990	5,61	5,47	5,35	5,26	5,18	5,11
	0,999	10,70	10,37	10,11	9,89	9,72	9,57
10	0,900	2,41	2,38	2,35	2,32	2,30	2,28
	0,950	3,14	3,07	3,02	2,98	2,94	2,91
	0,975	3,95	3,85	3,78	3,72	3,66	3,62
	0,990	5,20	5,06	4,94	4,85	4,77	4,71
	0,999	9,52	9,20	8,96	8,75	8,59	8,45
11	0,900	2,34	2,30	2,27	2,25	2,23	2,21
	0,950	3,01	2,95	2,90	2,85	2,82	2,79
	0,975	3,76	3,66	3,59	3,53	3,47	3,43
	0,990	4,89	4,74	4,63	4,54	4,46	4,40
	0,999	8,66	8,35	8,12	7,92	7,76	7,63
12	0,900	2,28	2,24	2,21	2,19	2,17	2,15
	0,950	2,91	2,85	2,80	2,75	2,72	2,69
	0,975	3,61	3,51	3,44	3,37	3,32	3,28
	0,990	4,64	4,50	4,39	4,30	4,22	4,16
	0,999	8,00	7,71	7,48	7,29	7,14	7,00
13	0,900	2,23	2,20	2,16	2,14	2,12	2,10
	0,950	2,83	2,77	2,71	2,67	2,63	2,60
	0,975	3,48	3,39	3,31	3,25	3,20	3,15
	0,990	4,44	4,30	4,19	4,10	4,02	3,96
	0,999	7,49	7,21	6,98	6,80	6,65	6,52
14	0,900	2,19	2,15	2,12	2,10	2,07	2,05
	0,950	2,76	2,70	2,65	2,60	2,57	2,53
	0,975	3,38	3,29	3,21	3,15	3,09	3,05
	0,990	4,28	4,14	4,03	3,94	3,86	3,80
	0,999	7,08	6,80	6,58	6,40	6,26	6,13

Tabela D.5: Quantis da $F(ndf, ddf)$ (continuação)

		ndf					
ddf	P	15	20	30	60	120	10000
8	0,900	2,46	2,42	2,38	2,34	2,32	2,29
	0,950	3,22	3,15	3,08	3,01	2,97	2,93
	0,975	4,10	4,00	3,89	3,78	3,73	3,67
	0,990	5,52	5,36	5,20	5,03	4,95	4,86
	0,999	10,84	10,48	10,11	9,73	9,53	9,34
9	0,900	2,34	2,30	2,25	2,21	2,18	2,16
	0,950	3,01	2,94	2,86	2,79	2,75	2,71
	0,975	3,77	3,67	3,56	3,45	3,39	3,33
	0,990	4,96	4,81	4,65	4,48	4,40	4,31
	0,999	9,24	8,90	8,55	8,19	8,00	7,82
10	0,900	2,24	2,20	2,16	2,11	2,08	2,06
	0,950	2,85	2,77	2,70	2,62	2,58	2,54
	0,975	3,52	3,42	3,31	3,20	3,14	3,08
	0,990	4,56	4,41	4,25	4,08	4,00	3,91
	0,999	8,13	7,80	7,47	7,12	6,94	6,76
11	0,900	2,17	2,12	2,08	2,03	2,00	1,97
	0,950	2,72	2,65	2,57	2,49	2,45	2,41
	0,975	3,33	3,23	3,12	3,00	2,94	2,88
	0,990	4,25	4,10	3,94	3,78	3,69	3,60
	0,999	7,32	7,01	6,68	6,35	6,18	6,00
12	0,900	2,10	2,06	2,01	1,96	1,93	1,90
	0,950	2,62	2,54	2,47	2,38	2,34	2,30
	0,975	3,18	3,07	2,96	2,85	2,79	2,73
	0,990	4,01	3,86	3,70	3,54	3,45	3,36
	0,999	6,71	6,40	6,09	5,76	5,59	5,42
13	0,900	2,05	2,01	1,96	1,90	1,88	1,85
	0,950	2,53	2,46	2,38	2,30	2,25	2,21
	0,975	3,05	2,95	2,84	2,72	2,66	2,60
	0,990	3,82	3,66	3,51	3,34	3,25	3,17
	0,999	6,23	5,93	5,63	5,30	5,14	4,97
14	0,900	2,01	1,96	1,91	1,86	1,83	1,80
	0,950	2,46	2,39	2,31	2,22	2,18	2,13
	0,975	2,95	2,84	2,73	2,61	2,55	2,49
	0,990	3,66	3,51	3,35	3,18	3,09	3,01
	0,999	5,85	5,56	5,25	4,94	4,77	4,61

Tabela D.5: Quantis da $F(ndf, ddf)$ (continuação)

		ndf					
ddf	P	1	2	3	4	5	6
15	0,900	3,07	2,70	2,49	2,36	2,27	2,21
	0,950	4,54	3,68	3,29	3,06	2,90	2,79
	0,975	6,20	4,77	4,15	3,80	3,58	3,41
	0,990	8,68	6,36	5,42	4,89	4,56	4,32
	0,999	16,59	11,34	9,34	8,25	7,57	7,09
20	0,900	2,97	2,59	2,38	2,25	2,16	2,09
	0,950	4,35	3,49	3,10	2,87	2,71	2,60
	0,975	5,87	4,46	3,86	3,51	3,29	3,13
	0,990	8,10	5,85	4,94	4,43	4,10	3,87
	0,999	14,82	9,95	8,10	7,10	6,46	6,02
30	0,900	2,88	2,49	2,28	2,14	2,05	1,98
	0,950	4,17	3,32	2,92	2,69	2,53	2,42
	0,975	5,57	4,18	3,59	3,25	3,03	2,87
	0,990	7,56	5,39	4,51	4,02	3,70	3,47
	0,999	13,29	8,77	7,05	6,12	5,53	5,12
60	0,900	2,79	2,39	2,18	2,04	1,95	1,87
	0,950	4,00	3,15	2,76	2,53	2,37	2,25
	0,975	5,29	3,93	3,34	3,01	2,79	2,63
	0,990	7,08	4,98	4,13	3,65	3,34	3,12
	0,999	11,97	7,77	6,17	5,31	4,76	4,37
120	0,900	2,75	2,35	2,13	1,99	1,90	1,82
	0,950	3,92	3,07	2,68	2,45	2,29	2,18
	0,975	5,15	3,80	3,23	2,89	2,67	2,52
	0,990	6,85	4,79	3,95	3,48	3,17	2,96
	0,999	11,38	7,32	5,78	4,95	4,42	4,04
10000	0,900	2,71	2,30	2,08	1,95	1,85	1,77
	0,950	3,84	3,00	2,61	2,37	2,21	2,10
	0,975	5,03	3,69	3,12	2,79	2,57	2,41
	0,990	6,64	4,61	3,78	3,32	3,02	2,80
	0,999	10,83	6,91	5,43	4,62	4,11	3,75

Tabela D.5: Quantis da $F(ndf, ddf)$ (continuação)

		ndf					
ddf	P	7	8	9	10	11	12
15	0,900	2,16	2,12	2,09	2,06	2,04	2,02
	0,950	2,71	2,64	2,59	2,54	2,51	2,48
	0,975	3,29	3,20	3,12	3,06	3,01	2,96
	0,990	4,14	4,00	3,89	3,80	3,73	3,67
	0,999	6,74	6,47	6,26	6,08	5,94	5,81
20	0,900	2,04	2,00	1,96	1,94	1,91	1,89
	0,950	2,51	2,45	2,39	2,35	2,31	2,28
	0,975	3,01	2,91	2,84	2,77	2,72	2,68
	0,990	3,70	3,56	3,46	3,37	3,29	3,23
	0,999	5,69	5,44	5,24	5,08	4,94	4,82
30	0,900	1,93	1,88	1,85	1,82	1,79	1,77
	0,950	2,33	2,27	2,21	2,16	2,13	2,09
	0,975	2,75	2,65	2,57	2,51	2,46	2,41
	0,990	3,30	3,17	3,07	2,98	2,91	2,84
	0,999	4,82	4,58	4,39	4,24	4,11	4,00
60	0,900	1,82	1,77	1,74	1,71	1,68	1,66
	0,950	2,17	2,10	2,04	1,99	1,95	1,92
	0,975	2,51	2,41	2,33	2,27	2,22	2,17
	0,990	2,95	2,82	2,72	2,63	2,56	2,50
	0,999	4,09	3,86	3,69	3,54	3,42	3,32
120	0,900	1,77	1,72	1,68	1,65	1,63	1,60
	0,950	2,09	2,02	1,96	1,91	1,87	1,83
	0,975	2,39	2,30	2,22	2,16	2,10	2,05
	0,990	2,79	2,66	2,56	2,47	2,40	2,34
	0,999	3,77	3,55	3,38	3,24	3,12	3,02
10000	0,900	1,72	1,67	1,63	1,60	1,57	1,55
	0,950	2,01	1,94	1,88	1,83	1,79	1,75
	0,975	2,29	2,19	2,11	2,05	1,99	1,95
	0,990	2,64	2,51	2,41	2,32	2,25	2,19
	0,999	3,48	3,27	3,10	2,96	2,85	2,75

Tabela D.5: Quantis da $F(ndf, ddf)$ (continuação)

		ndf					
ddf	P	15	20	30	60	120	10000
15	0,900	1,97	1,92	1,87	1,82	1,79	1,76
	0,950	2,40	2,33	2,25	2,16	2,11	2,07
	0,975	2,86	2,76	2,64	2,52	2,46	2,40
	0,990	3,52	3,37	3,21	3,05	2,96	2,87
	0,999	5,54	5,25	4,95	4,64	4,47	4,31
20	0,900	1,84	1,79	1,74	1,68	1,64	1,61
	0,950	2,20	2,12	2,04	1,95	1,90	1,84
	0,975	2,57	2,46	2,35	2,22	2,16	2,09
	0,990	3,09	2,94	2,78	2,61	2,52	2,42
	0,999	4,56	4,29	4,00	3,70	3,54	3,38
30	0,900	1,72	1,67	1,61	1,54	1,50	1,46
	0,950	2,01	1,93	1,84	1,74	1,68	1,62
	0,975	2,31	2,20	2,07	1,94	1,87	1,79
	0,990	2,70	2,55	2,39	2,21	2,11	2,01
	0,999	3,75	3,49	3,22	2,92	2,76	2,59
60	0,900	1,60	1,54	1,48	1,40	1,35	1,29
	0,950	1,84	1,75	1,65	1,53	1,47	1,39
	0,975	2,06	1,94	1,82	1,67	1,58	1,48
	0,990	2,35	2,20	2,03	1,84	1,73	1,60
	0,999	3,08	2,83	2,55	2,25	2,08	1,89
120	0,900	1,55	1,48	1,41	1,32	1,26	1,19
	0,950	1,75	1,66	1,55	1,43	1,35	1,26
	0,975	1,94	1,82	1,69	1,53	1,43	1,31
	0,990	2,19	2,03	1,86	1,66	1,53	1,38
	0,999	2,78	2,53	2,26	1,95	1,77	1,55
10000	0,900	1,49	1,42	1,34	1,24	1,17	1,03
	0,950	1,67	1,57	1,46	1,32	1,22	1,03
	0,975	1,83	1,71	1,57	1,39	1,27	1,04
	0,990	2,04	1,88	1,70	1,48	1,33	1,05
	0,999	2,52	2,27	1,99	1,66	1,45	1,06

D.6 Probabilidades da Distribuição Binomial

Se $X \sim \text{Binomial}(n, p)$, a Tabela D.6 traz os valores de

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$$

para vários valores de n, k e p.

Observe que, se $X \sim \text{Binomial}(n, p)$, então $P(X = k) = P(Y = n - k)$, em que $Y = n - X \sim \text{Binomial}(n, 1 - p)$.

Tabela D.6: Probabilidades binomiais

		p								
n	k	,01	,02	,03	,04	,05	,06	,07	,08	,09
2	0	,9801	,9604	,9409	,9216	,9025	,8836	,8649	,8464	,8281
	1	,0198	,0392	,0582	,0768	,0950	,1128	,1302	,1472	,1638
	2	,0001	,0004	,0009	,0016	,0025	,0036	,0049	,0064	,0081
3	0	,9703	,9412	,9127	,8847	,8574	,8306	,8044	,7787	,7536
	1	,0294	,0576	,0847	,1106	,1354	,1590	,1816	,2031	,2236
	2	,0003	,0012	,0026	,0046	,0071	,0102	,0137	,0177	,0221
	3				,0001	,0001	,0002	,0003	,0005	,0007
4	0	,9606	,9224	,8853	,8493	,8145	,7807	,7481	,7164	,6857
	1	,0388	,0753	,1095	,1416	,1715	,1993	,2252	,2492	,2713
	2	,0006	,0023	,0051	,0088	,0135	,0191	,0254	,0325	,0402
	3			,0001	,0002	,0005	,0008	,0013	,0019	,0027
	4									,0001
5	0	,9510	,9039	,8587	,8154	,7738	,7339	,6957	,6591	,6240
	1	,0480	,0922	,1328	,1699	,2036	,2342	,2618	,2866	,3086
	2	,0010	,0038	,0082	,0142	,0214	,0299	,0394	,0498	,0610
	3		,0001	,0003	,0006	,0011	,0019	,0030	,0043	,0060
	4						,0001	,0001	,0002	,0003
	5									

Tabela D.6: Probabilidades binomiais (continuação)

		p								
n	k	,01	,02	,03	,04	,05	,06	,07	,08	,09
6	0	,9415	,8858	,8330	,7828	,7351	,6899	,6470	,6064	,5679
	1	,0571	,1085	,1546	,1957	,2321	,2642	,2922	,3164	,3370
	2	,0014	,0055	,0120	,0204	,0305	,0422	,0550	,0688	,0833
	3		,0002	,0005	,0011	,0021	,0036	,0055	,0080	,0110
	4					,0001	,0002	,0003	,0005	,0008
	5									
	6									
7	0	,9321	,8681	,8080	,7514	,6983	,6485	,6017	,5578	,5168
	1	,0659	,1240	,1749	,2192	,2573	,2897	,3170	,3396	,3578
	2	,0020	,0076	,0162	,0274	,0406	,0555	,0716	,0886	,1061
	3		,0003	,0008	,0019	,0036	,0059	,0090	,0128	,0175
	4				,0001	,0002	,0004	,0007	,0011	,0017
	5								,0001	,0001
	6									
	7									
8	0	,9227	,8508	,7837	,7214	,6634	,6096	,5596	,5132	,4703
	1	,0746	,1389	,1939	,2405	,2793	,3113	,3370	,3570	,3721
	2	,0026	,0099	,0210	,0351	,0515	,0695	,0888	,1087	,1288
	3	,0001	,0004	,0013	,0029	,0054	,0089	,0134	,0189	,0255
	4			,0001	,0002	,0004	,0007	,0013	,0021	,0031
	5							,0001	,0001	,0002
	6									
	7									
	8									

Tabela D.6: Probabilidades binomiais (continuação)

		p								
n	k	,10	,15	,20	,25	,30	,35	,40	,45	,50
2	0	,8100	,7225	,6400	,5625	,4900	,4225	,3600	,3025	,2500
	1	,1800	,2550	,3200	,3750	,4200	,4550	,4800	,4950	,5000
	2	,0100	,0225	,0400	,0625	,0900	,1225	,1600	,2025	,2500
3	0	,7290	,6141	,5120	,4219	,3430	,2746	,2160	,1664	,1250
	1	,2430	,3251	,3840	,4219	,4410	,4436	,4320	,4084	,3750
	2	,0270	,0574	,0960	,1406	,1890	,2389	,2880	,3341	,3750
	3	,0010	,0034	,0080	,0156	,0270	,0429	,0640	,0911	,1250
4	0	,6561	,5220	,4096	,3164	,2401	,1785	,1296	,0915	,0625
	1	,2916	,3685	,4096	,4219	,4116	,3845	,3456	,2995	,2500
	2	,0486	,0975	,1536	,2109	,2646	,3105	,3456	,3675	,3750
	3	,0036	,0115	,0256	,0469	,0756	,1115	,1536	,2005	,2500
	4	,0001	,0005	,0016	,0039	,0081	,0150	,0256	,0410	,0625
5	0	,5905	,4437	,3277	,2373	,1681	,1160	,0778	,0503	,0313
	1	,3280	,3915	,4096	,3955	,3602	,3124	,2592	,2059	,1563
	2	,0729	,1382	,2048	,2637	,3087	,3364	,3456	,3369	,3125
	3	,0081	,0244	,0512	,0879	,1323	,1811	,2304	,2757	,3125
	4	,0004	,0022	,0064	,0146	,0284	,0488	,0768	,1128	,1562
	5		,0001	,0003	,0010	,0024	,0053	,0102	,0185	,0312

Tabela D.6: Probabilidades binomiais (continuação)

		p								
n	k	,10	,15	,20	,25	,30	,35	,40	,45	,50
6	0	,5314	,3771	,2621	,1780	,1176	,0754	,0467	,0277	,0156
	1	,3543	,3993	,3932	,3560	,3025	,2437	,1866	,1359	,0938
	2	,0984	,1762	,2458	,2966	,3241	,3280	,3110	,2780	,2344
	3	,0146	,0415	,0819	,1318	,1852	,2355	,2765	,3032	,3125
	4	,0012	,0055	,0154	,0330	,0595	,0951	,1382	,1861	,2344
	5	,0001	,0004	,0015	,0044	,0102	,0205	,0369	,0609	,0937
	6			,0001	,0002	,0007	,0018	,0041	,0083	,0156
7	0	,4783	,3206	,2097	,1335	,0824	,0490	,0280	,0152	,0078
	1	,3720	,3960	,3670	,3115	,2471	,1848	,1306	,0872	,0547
	2	,1240	,2097	,2753	,3115	,3177	,2985	,2613	,2140	,1641
	3	,0230	,0617	,1147	,1730	,2269	,2679	,2903	,2918	,2734
	4	,0026	,0109	,0287	,0577	,0972	,1442	,1935	,2388	,2734
	5	,0002	,0012	,0043	,0115	,0250	,0466	,0774	,1172	,1641
	6		,0001	,0004	,0013	,0036	,0084	,0172	,0320	,0547
	7				,0001	,0002	,0006	,0016	,0037	,0078
8	0	,4305	,2725	,1678	,1001	,0576	,0319	,0168	,0084	,0039
	1	,3826	,3847	,3355	,2670	,1977	,1373	,0896	,0548	,0313
	2	,1488	,2376	,2936	,3115	,2965	,2587	,2090	,1569	,1094
	3	,0331	,0839	,1468	,2076	,2541	,2786	,2787	,2568	,2188
	4	,0046	,0185	,0459	,0865	,1361	,1875	,2322	,2627	,2734
	5	,0004	,0026	,0092	,0231	,0467	,0808	,1239	,1719	,2188
	6		,0002	,0011	,0038	,0100	,0217	,0413	,0703	,1094
	7			,0001	,0004	,0012	,0033	,0079	,0164	,0312
	8					,0001	,0002	,0007	,0017	,0039

Tabela D.6: Probabilidades binomiais (continuação)

		p								
n	k	,01	,02	,03	,04	,05	,06	,07	,08	,09
9	0	,9135	,8337	,7602	,6925	,6302	,5730	,5204	,4722	,4279
	1	,0830	,1531	,2116	,2597	,2985	,3292	,3525	,3695	,3809
	2	,0034	,0125	,0262	,0433	,0629	,0840	,1061	,1285	,1507
	3	,0001	,0006	,0019	,0042	,0077	,0125	,0186	,0261	,0348
	4			,0001	,0003	,0006	,0012	,0021	,0034	,0052
	5						,0001	,0002	,0003	,0005
	6									
	7									
	8									
	9									
10	0	,9044	,8171	,7374	,6648	,5987	,5386	,4840	,4344	,3894
	1	,0914	,1667	,2281	,2770	,3151	,3438	,3643	,3777	,3851
	2	,0042	,0153	,0317	,0519	,0746	,0988	,1234	,1478	,1714
	3	,0001	,0008	,0026	,0058	,0105	,0168	,0248	,0343	,0452
	4			,0001	,0004	,0010	,0019	,0033	,0052	,0078
	5					,0001	,0001	,0003	,0005	,0009
	6									,0001
	7									
	8									
	9									
	10									

Tabela D.6: Probabilidades binomiais (continuação)

		p								
n	k	,01	,02	,03	,04	,05	,06	,07	,08	,09
12	0	,8864	,7847	,6938	,6127	,5404	,4759	,4186	,3677	,3225
	1	,1074	,1922	,2575	,3064	,3413	,3645	,3781	,3837	,3827
	2	,0060	,0216	,0438	,0702	,0988	,1280	,1565	,1835	,2082
	3	,0002	,0015	,0045	,0098	,0173	,0272	,0393	,0532	,0686
	4		,0001	,0003	,0009	,0021	,0039	,0067	,0104	,0153
	5				,0001	,0002	,0004	,0008	,0014	,0024
	6							,0001	,0001	,0003
	7									
	8									
	9									
	10									
	11									
	12									
15	0	,8601	,7386	,6333	,5421	,4633	,3953	,3367	,2863	,2430
	1	,1303	,2261	,2938	,3388	,3658	,3785	,3801	,3734	,3605
	2	,0092	,0323	,0636	,0988	,1348	,1691	,2003	,2273	,2496
	3	,0004	,0029	,0085	,0178	,0307	,0468	,0653	,0857	,1070
	4		,0002	,0008	,0022	,0049	,0090	,0148	,0223	,0317
	5			,0001	,0002	,0006	,0013	,0024	,0043	,0069
	6						,0001	,0003	,0006	,0011
	7								,0001	,0001
	8									
	9									
	10									
	11									
	12									
	13									
	14									
	15									

Tabela D.6: Probabilidades binomiais (continuação)

		p								
n	k	,10	,15	,20	,25	,30	,35	,40	,45	,50
9	0	,3874	,2316	,1342	,0751	,0404	,0207	,0101	,0046	,0020
	1	,3874	,3679	,3020	,2253	,1556	,1004	,0605	,0339	,0176
	2	,1722	,2597	,3020	,3003	,2668	,2162	,1612	,1110	,0703
	3	,0446	,1069	,1762	,2336	,2668	,2716	,2508	,2119	,1641
	4	,0074	,0283	,0661	,1168	,1715	,2194	,2508	,2600	,2461
	5	,0008	,0050	,0165	,0389	,0735	,1181	,1672	,2128	,2461
	6	,0001	,0006	,0028	,0087	,0210	,0424	,0743	,1160	,1641
	7			,0003	,0012	,0039	,0098	,0212	,0407	,0703
	8				,0001	,0004	,0013	,0035	,0083	,0176
	9						,0001	,0003	,0008	,0020
10	0	,3487	,1969	,1074	,0563	,0282	,0135	,0060	,0025	,0010
	1	,3874	,3474	,2684	,1877	,1211	,0725	,0403	,0207	,0098
	2	,1937	,2759	,3020	,2816	,2335	,1757	,1209	,0763	,0439
	3	,0574	,1298	,2013	,2503	,2668	,2522	,2150	,1665	,1172
	4	,0112	,0401	,0881	,1460	,2001	,2377	,2508	,2384	,2051
	5	,0015	,0085	,0264	,0584	,1029	,1536	,2007	,2340	,2461
	6	,0001	,0012	,0055	,0162	,0368	,0689	,1115	,1596	,2051
	7		,0001	,0008	,0031	,0090	,0212	,0425	,0746	,1172
	8			,0001	,0004	,0014	,0043	,0106	,0229	,0439
	9					,0001	,0005	,0016	,0042	,0098
	10							,0001	,0003	,0010

Tabela D.6: Probabilidades binomiais (continuação)

		p								
n	k	,10	,15	,20	,25	,30	,35	,40	,45	,50
12	0	,2824	,1422	,0687	,0317	,0138	,0057	,0022	,0008	,0002
	1	,3766	,3012	,2062	,1267	,0712	,0368	,0174	,0075	,0029
	2	,2301	,2924	,2835	,2323	,1678	,1088	,0639	,0339	,0161
	3	,0852	,1720	,2362	,2581	,2397	,1954	,1419	,0923	,0537
	4	,0213	,0683	,1329	,1936	,2311	,2367	,2128	,1700	,1208
	5	,0038	,0193	,0532	,1032	,1585	,2039	,2270	,2225	,1934
	6	,0005	,0040	,0155	,0401	,0792	,1281	,1766	,2124	,2256
	7		,0006	,0033	,0115	,0291	,0591	,1009	,1489	,1934
	8		,0001	,0005	,0024	,0078	,0199	,0420	,0762	,1208
	9			,0001	,0004	,0015	,0048	,0125	,0277	,0537
	10					,0002	,0008	,0025	,0068	,0161
	11						,0001	,0003	,0010	,0029
	12								,0001	,0002
15	0	,2059	,0874	,0352	,0134	,0047	,0016	,0005	,0001	
	1	,3432	,2312	,1319	,0668	,0305	,0126	,0047	,0016	,0005
	2	,2669	,2856	,2309	,1559	,0916	,0476	,0219	,0090	,0032
	3	,1285	,2184	,2501	,2252	,1700	,1110	,0634	,0318	,0139
	4	,0428	,1156	,1876	,2252	,2186	,1792	,1268	,0780	,0417
	5	,0105	,0449	,1032	,1651	,2061	,2123	,1859	,1404	,0916
	6	,0019	,0132	,0430	,0917	,1472	,1906	,2066	,1914	,1527
	7	,0003	,0030	,0138	,0393	,0811	,1319	,1771	,2013	,1964
	8		,0005	,0035	,0131	,0348	,0710	,1181	,1647	,1964
	9		,0001	,0007	,0034	,0116	,0298	,0612	,1048	,1527
	10			,0001	,0007	,0030	,0096	,0245	,0515	,0916
	11				,0001	,0006	,0024	,0074	,0191	,0417
	12					,0001	,0004	,0016	,0052	,0139
	13						,0001	,0003	,0010	,0032
	14								,0001	,0005
	15									

Tabela D.6: Probabilidades binomiais (continuação)

		p								
n	k	,01	,02	,03	,04	,05	,06	,07	,08	,09
20	0	,8179	,6676	,5438	,4420	,3585	,2901	,2342	,1887	,1516
	1	,1652	,2725	,3364	,3683	,3774	,3703	,3526	,3282	,3000
	2	,0159	,0528	,0988	,1458	,1887	,2246	,2521	,2711	,2818
	3	,0010	,0065	,0183	,0364	,0596	,0860	,1139	,1414	,1672
	4		,0006	,0024	,0065	,0133	,0233	,0364	,0523	,0703
	5			,0002	,0009	,0022	,0048	,0088	,0145	,0222
	6				,0001	,0003	,0008	,0017	,0032	,0055
	7						,0001	,0002	,0005	,0011
	8								,0001	,0002
	9									
	10									
	11									
	12									
	13									
	14									
	15									
	16									
	17									
	18									
	19									
	20									

Tabela D.6: Probabilidades binomiais (continuação)

		p								
n	k	,10	,15	,20	,25	,30	,35	,40	,45	,50
20	0	,1216	,0388	,0115	,0032	,0008	,0002			
	1	,2702	,1368	,0576	,0211	,0068	,0020	,0005	,0001	
	2	,2852	,2293	,1369	,0669	,0278	,0100	,0031	,0008	,0002
	3	,1901	,2428	,2054	,1339	,0716	,0323	,0123	,0040	,0011
	4	,0898	,1821	,2182	,1897	,1304	,0738	,0350	,0139	,0046
	5	,0319	,1028	,1746	,2023	,1789	,1272	,0746	,0365	,0148
	6	,0089	,0454	,1091	,1686	,1916	,1712	,1244	,0746	,0370
	7	,0020	,0160	,0545	,1124	,1643	,1844	,1659	,1221	,0739
	8	,0004	,0046	,0222	,0609	,1144	,1614	,1797	,1623	,1201
	9	,0001	,0011	,0074	,0271	,0654	,1158	,1597	,1771	,1602
	10		,0002	,0020	,0099	,0308	,0686	,1171	,1593	,1762
	11			,0005	,0030	,0120	,0336	,0710	,1185	,1602
	12			,0001	,0008	,0039	,0136	,0355	,0727	,1201
	13				,0002	,0010	,0045	,0146	,0366	,0739
	14					,0002	,0012	,0049	,0150	,0370
	15						,0003	,0013	,0049	,0148
	16							,0003	,0013	,0046
	17								,0002	,0011
	18									,0002
	19									
	20									

APÊNDICE E

Respostas dos Exercícios Ímpares

As respostas são dadas aqui para os exercícios ímpares que pedem uma conta. Os detalhes das contas não são apresentados. Se o exercício pedia que se demonstrasse algo, é dada uma sugestão significativa.

Capítulo 1

1.2.1

(a) $P(\{1,2\}) = 5/6$

(b) $P(\{1,2,3\}) = 1$

(c) $P(\{1\}) = P(\{2,3\}) = 1/2$

1.2.3 $P(\{2\}) = 1/6$

1.2.5 $P(\{s\}) = 0$ para todo $s \in [0,1]$

1.2.7 É o subconjunto $(A \cap B^c) \cup (A^c \cap B)$.

1.2.9 $P(\{1\}) = 1/12$, $P(\{2\}) = 1/12$, $P(\{3\}) = 1/6$, $P(\{4\}) = 2/3$

1.2.11 $P(\{2\}) = 5/24$, $P(\{1\}) = 3/8$, $P(\{3\}) = 5/12$

1.3.1

(a) $P(\{2,3,4,\ldots,100\}) = 0{,}9$

(b) 0,1

1.3.3 $P(\text{atrasado ou mais cedo ou ambos}) = 25\%$

1.3.5

(a) $1/32 = 0{,}03125$.

(b) 0,96875

1.3.7 10%

1.4.1

(a) $(1/6)^8 = 1/1.679.616$

(b) $(1/6)^7 = 1/279.936$

(c) $8\,(1/6)^8 = 1/209.952$

1.4.3 $1 - 5051/2^{100}$

1.4.5

(a) $\binom{4}{1}\binom{13}{13}\binom{39}{13\ 13\ 13}\Big/\binom{52}{13\ 13\ 13\ 13}$

(b) $\binom{4}{1}\binom{4}{4}\binom{48}{9}\binom{39}{13\ 13\ 13}\Big/\binom{52}{13\ 13\ 13\ 13}$

1.4.7 $\binom{48}{10}\Big/\binom{52}{10} = 246/595 = 0{,}4134$

1.4.9 $(5/6)^2(1/6) = 25/216$

1.4.11 $\left(\binom{5}{3}\Big/\binom{12}{3}\right)\left(\binom{6}{3}\Big/\binom{18}{3}\right) + \left(\binom{7}{3}\Big/\binom{12}{3}\right)\left(\binom{12}{3}\Big/\binom{18}{3}\right)$

1.4.13 $\binom{2}{1}\frac{1}{2^2}\cdot\binom{3}{2}\frac{1}{2^3}\cdot\binom{4}{2}\frac{1}{2^4} + \binom{2}{1}\frac{1}{2^2}\cdot\binom{3}{0}\frac{1}{2^3}\cdot\binom{4}{3}\frac{1}{2^4} = \frac{11}{128} = 0{,}0859$

1.5.1

(a) 3/4

(b) 16/21

1.5.3

(a) 1/8

(b) $(1/8)/(1/2) = 1/4$

(c) $0/(1/2) = 0$

1.5.5 1

1.5.7 0,074

1.5.9

(a) Não

(b) Sim

(c) Sim

(d) Sim

(e) Não

1.5.11

(a) 0,1667

(b) 0,3125

1.6.1 1/3

1.6.3 $\{A_n\} \nearrow A = \{1, 2, 3, \ldots\} = S$

1.6.5 1

1.6.7 Suponha que não exista n tal que $P([0, n]) > 0{,}9$ e então note que isso implica $1 = P([0, \infty)) = \lim_{n\to\infty} P([0, n]) \leq 0{,}9$.

1.6.9 Não

Capítulo 2

2.1.1

(a) 1

(b) Não existe

(c) Não existe

(d) 1

2.1.3

(a) $X(s) = s$ e $Y(s) = s^2$ para todo $s \in S$.

(b) Neste exemplo, $Z(1) = 2$, $Z(2) = 18$, $Z(3) = 84$, $Z(4) = 260$, $Z(5) = 630$.

2.1.5 Sim, para $A \cap B$.

2.1.7

(a) $W(1) = 2$

(b) $W(2) = 0$

(c) $W(3) = -1$

(d) $W \geq Z$ não é verdade.

2.1.9

(a) $Y(1) = 1$

(b) $Y(2) = 4$

(c) $Y(4) = 0$

2.2.1 $P(X = 0) = P(X = 2) = 1/4$, $P(X = 1) = 1/2$, $P(X = x) = 0$ para $x \neq 0, 1, 2$

2.2.3

(a) $P(Y = y) = 0$ para $y \neq 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12$, $P(Y = 2) = 1/36$, $P(Y = 3) = 2/36$, $P(Y = 4) = 3/36$, $P(Y = 5) = 4/36$, $P(Y = 6) = 5/36$, $P(Y = 7) = 6/36$, $P(Y = 8) = 5/36$, $P(Y = 9) = 4/36$, $P(Y = 10) = 3/36$, $P(Y = 11) = 2/36$, $P(Y = 12) = 1/36$

(b) $P(Y \in B) = (1/36)I_B(2) + (2/36)I_B(3) + (3/36)I_B(4) + (4/36)I_B(5) + (5/36)I_B(6) + (6/36)I_B(7) + (5/36)I_B(8) + (4/36)I_B(9) + (3/36)I_B(10) + (2/36)I_B(11) + (1/36)I_B(12)$

2.2.5

(a) $P(X = 1) = 0{,}3$, $P(X = 2) = 0{,}2$, $P(X = 3) = 0{,}5$ e $P(X = x) = 0$ para todo $x \notin \{1, 2, 3\}$

(b) $P(Y = 1) = 0{,}3$, $P(Y = 2) = 0{,}2$, $P(Y = 3) = 0{,}5$ e $P(Y = y) = 0$ para todo $y \notin \{1, 2, 3\}$

(c) $P(W = 2) = 0{,}09$, $P(W = 3) = 0{,}12$, $P(W = 4) = 0{,}34$, $P(W = 5) = 0{,}2$, $P(W = 6) = 0{,}25$ e $P(W = w) = 0$ para todas as outras escolhas de w.

2.2.7 $P(X = 25) = 0{,}45$, $P(X = 30) = 0{,}55$ e $P(X = x) = 0$ caso contrário

2.3.1 $p_Y(2) = 1/36$, $p_Y(3) = 2/36$, $p_Y(4) = 3/36$, $p_Y(5) = 4/36$, $p_Y(6) = 5/36$, $p_Y(7) = 6/36$, $p_Y(8) = 5/36$, $p_Y(9) = 4/36$, $p_Y(10) = 3/36$, $p_Y(11) = 2/36$, $p_Y(12) = 1/36$ e $p_Y(y) = 0$ caso contrário

2.3.3 $p_Z(1) = p_Z(5) = 1/4$, $p_Z(0) = 1/2$ e $p_Z(z) = 0$ caso contrário

2.3.5 $p_W(1) = 1/36$, $p_W(2) = 2/36$, $p_W(3) = 2/36$, $p_W(4) = 3/36$, $p_W(5) = 2/36$, $p_W(6) = 4/36$, $p_W(8) = 2/36$, $p_W(9) = 1/36$, $p_W(10) = 2/36$, $p_W(12) = 4/36$, $p_W(15) = 2/36$, $p_W(16) = 1/36$, $p_W(18) = 2/36$, $p_W(20) = 2/36$, $p_W(24) = 2/36$, $p_W(25) = 1/36$, $p_W(30) = 2/36$ e $p_W(36) = 1/36$, com $p_W(w) = 0$ caso contrário

2.3.7 $\theta = 11/12$

2.3.9 53/512

2.3.11 θ^{10}

2.3.15

(a) $\binom{10}{3}(0{,}35)^3(0{,}65)^7$

(b) $(0{,}35)(0{,}65)^9$

(c) $\binom{9}{1}(0{,}35)^2(0{,}65)^8$

2.3.17

(a) Hipergeométrica$(9, 4, 2)$

(b) Hipergeométrica$(9, 5, 2)$

2.3.19 $P(X = 5) \approx \left((100/1000)^5/5!\right) \exp\{-100/1000\}$

2.4.1

(a) 0

(b) 0

(c) 0

(d) 2/3

(e) 2/3

(f) 1

(g) $= 1$

2.4.3

(a) e^{-20}

(b) 1

(c) e^{-12}

(d) $e^{-4(25)^{1/4}}$

2.4.5 Não

2.4.7 $c = 3/M^3$

2.4.9 $\int_1^2 f(x)\,dx > \int_1^2 g(x)\,dx$

2.4.11 Sim

2.4.13 $P(Y < 3) = \int_{-\infty}^{3}(2\pi)^{-1/2}\exp(-(y-1)^2/2)\,dy = \int_{-\infty}^{2}(2\pi)^{-1/2}\exp(-u^2/2)\,du = P(X < 2)$

2.5.1 As propriedades (a) e (b) seguem por inspeção. As propriedades (c) e (d) seguem porque $F_X(x) = 0$ para $x < 1/6$ e $F_X(x) = 1$ para $x > 1$.

2.5.3

(a) Não

(b) Sim

(c) Sim

(d) Não

(e) Sim

(f) Sim

(g) Não

2.5.5 Logo:

(a) 0,933

(b) 0,00135

(c) $1{,}90 \times 10^{-8}$

2.5.7

(a) 1/9

(b) 3/16

(c) 12/25

(d) 0

(e) 1

(f) 0

(g) 1

(h) 0

2.5.9

(b) Não

2.5.11

(b) Sim

2.5.13

(b) A função F é não decrescente, $\lim_{x \to -\infty} F(x) = 0$ e $\lim_{x \to \infty} F(x) = 1$.

(c) $P(X > 4/5) = 0$, $P(-1 < X < 1/2) = 3/4$, $P(X = 2/5) = 5/12$, $P(X = 4/5) = 1/4$

2.5.15

(a) $P(Z > 4/5) = 2e^{-16/25}/3$

(b) $P(-1 < Z < 1/2) = 11/12 - 2e^{-1/2}/3$

(c) $P(Z = 2/5) = 5/36$

(d) $P(Z = 4/5) = 1/12$

(e) $P(Z = 0) = 1/9$

(f) $P(Z = 1/2) = 11/12 - 2e^{-1/2}/3$

2.6.1 $f_Y(y)$ é igual a $1/(R-L)c$ para $L \le (y-d)/c \le R$ e, caso contrário, é igual a 0.

2.6.3 $f_Y(y) = e^{-[y-d-c\mu]^2/2c^2\sigma^2}/c\sigma\sqrt{2\pi}$

2.6.5 $f_Y(y)$ é igual a $(\lambda/3)y^{-2/3}e^{-\lambda y^{1/3}}$ para $y > 0$ e, caso contrário, é igual a 0.

2.6.7 $f_Y(y) = 1/6y^{1/2}$ para $0 < y < 9$

2.6.9

(a) $f_Y(y) = y/8$

(b) $f_Z(z) = z^7/2$ para $0 < z < \sqrt{2}$

2.6.11 $f_Y(y) = y^{-1/2}\sin(y^{1/2})/4$ para $0 < y < \pi^2$ e 0 caso contrário

2.6.13 $f_Y(y) = (2\pi)^{-1/2}(3|y|^{2/3})^{-1}\exp(-|y|^{2/3}/2)$

2.7.1

$$F_{X,Y}(x,y) = \begin{cases} 0 & \min[x,\ (y+2)/4] < 0 \\ 1/3 & 0 \le \min[x,\ (y+2)/4] < 1 \\ 1 & \min[x,\ (y+2)/4] \ge 1 \end{cases}$$

2.7.3

(a) $p_X(2) = p_X(3) = p_X(-3) = p_X(-2) = p_X(17) = 1/5$, com $p_X(x) = 0$ caso contrário

(b) $p_Y(3) = p_Y(2) = p_Y(-2) = p_Y(-3) = p_Y(19) = 1/5$, com $p_Y(y) = 0$ caso contrário

(c) $P(Y > X) = 3/5$

(d) $P(Y = X) = 0$

(e) $P(XY < 0) = 0$

2.7.5 $\{X \le x,\ Y \le y\} \subseteq \{X \le x\}$ e $\{X \le x,\ Y \le y\} \subseteq \{Y \le y\}$

2.7.7

(a) $f_X(x) = c(1 - \cos(2x))/x$ para $0 < x < 1$ e 0 caso contrário

(b) $f_Y(y) = c(1 - \cos(y))/y$ para $0 < y < 2$ e 0 caso contrário

2.7.9

(a) $f_X(x) = (4 + 3x^2 - 2x^3)/8$ para $x \in (0, 2)$ e 0 caso contrário

(b) $f_Y(y) = (y^3 + 3y^2)/12$ para $y \in (0, 2)$ e 0 caso contrário

(c) $P(Y < 1) = 5/48$

2.8.1

(a) $p_X(-2) = 1/4$, $p_X(9) = 1/4$, $p_X(13) = 1/2$; caso contrário, $p_X(x) = 0$

(b) $p_Y(3) = 2/3$, $p_Y(5) = 1/3$; caso contrário, $p_Y(y) = 0$

(c) Sim

2.8.3

(a) $f_X(x) = (18x/49) + (40/49)$ para $0 \leq x \leq 1$ e $f_X(x) = 0$ caso contrário

(b) $f_Y(y) = (48y^2 + 6y + 30)/49$ para $0 \leq y \leq 1$ e $f_Y(y) = 0$ caso contrário

(c) Não

2.8.5

(a) $P(Y = 4 \mid X = 9) = 1/6$

(b) $P(Y = -2 \mid X = 9) = 1/2$

(c) $P(Y = 0 \mid X = -4) = 0$

(d) $P(Y = -2 \mid X = 5) = 1$

(e) $P(X = 5 \mid Y = -2) = 1/3$

2.8.7

(a) $f_X(x) = x^2 + 2/3$, $f_Y(y) = 4y^5 + 2y/3$ para $0 \leq x \leq 1$ e $0 \leq y \leq 1$, $f_{Y|X}(y \mid x) = (2x^2y + 4y^5)/(x^2 + 2/3)$ (caso contrário, $f_{Y|X}(y \mid x) = 0$); logo, X e Y não são independentes.

(b) $f_X(x) = C(x^5/6 + x/2)$, $f_Y(y) = C(y^5/6 + y/2)$ para $0 \leq x \leq 1$ e $0 \leq y \leq 1$, $f_{Y|X}(y \mid x) = (xy + x^5y^5)/(x^5/6 + x/2)$ (caso contrário, $f_{Y|X}(y \mid x) = 0$); X e Y não são independentes.

(c) $f_X(x) = C(500.000x^5/3 + 50x)$, $f_Y(y) = C(2048y^5/3 + 8y)$ para $0 \leq x \leq 4$ e $0 \leq y \leq 10$, $f_{Y|X}(y \mid x) = (xy + x^5y^5)/(500.000x^5/3 + 50x)$ (caso contrário, $f_{Y|X}(y \mid x) = 0$); logo, X e Y não são independentes.

(d) $f_X(x) = C(500.000x^5/3)$ e $f_Y(y) = C(2048y^5/3)$ para $0 \le x \le 4$ e $0 \le y \le 10$, $f_{Y|X}(y \mid x) = 3y^5/500.000$ (caso contrário, $f_{Y|X}(y \mid x) = 0$); X e Y são independentes.

2.8.9 $P(X = 1, Y = 1) = P(X = 1, Y = 2) = P(X = 2, Y = 1) = P(X = 3, Y = 3) = 1/4$

2.8.11 Se $X = C$ é constante, então $P(X \in B_1) = I_{B_1}(C)$ e $P(X \in B_1, Y \in B_2) = I_{B_1}(C)\,P(Y \in B_2)$.

2.8.13

(a)

$p_{Y\|X}(y \mid x)$	$y = 1$	$y = 2$	$y = 4$	$y = 7$	Outros
$x = 3$	1/4	1/4	1/4	1/4	0
$x = 5$	1/4	1/4	1/4	1/4	0

(b)

$p_{X\|Y}(x \mid y)$	$x = 3$	$x = 5$	Outros
$y = 1$	1/2	1/2	0
$y = 2$	1/2	1/2	0
$y = 4$	1/2	1/2	0
$y = 7$	1/2	1/2	0

(c) X e Y são independentes.

2.8.15 $f_{Y|X}(y \mid x) = 2(x^2 + y)/(4 + 3x^2 - 2x^3)$ para $x < y < 2$ e 0 caso contrário

(b) $f_{X|Y}(x \mid y) = 3(x^2 + y)/(y^3 + 3y^2)$ para $0 < x < y$ e 0 caso contrário

(c) Não são independentes

2.9.1 $\dfrac{\partial h_1}{\partial u_1} = -\cos(2\pi u_2)\big/u_1\sqrt{2\log(1/u_1)}$, $\dfrac{\partial h_1}{\partial u_2} = -2\pi \sin(2\pi u_2)\sqrt{2\log(1/u_1)}$, $\dfrac{\partial h_2}{\partial u_1} = -\sin(2\pi u_2)\big/u_1\sqrt{2\log(1/u_1)}$, $\dfrac{\partial h_2}{\partial u_2} = -2\pi \cos(2\pi u_2) \times \sqrt{2\log(1/u_1)}$.*

2.9.3

(b) $h(x, y) = (x^2 + y^2,\ x^2 - y^2)$

(c) $h^{-1}(z, w) = \left(\sqrt{(z + w)/2},\ \sqrt{(z - w)/2}\right)$, pelo menos para $z + w \ge 0$ e $z - w \ge 0$

*Nota do tradutor. o original traz $-2\pi \cos(2\pi u_2)$ na última derivada; pela conta, com $h_2 = \sqrt{2\log(1/u_1)}\,\sin(2\pi u_2)$ do Exemplo 2.9.3, seria $+2\pi \cos(2\pi u_2)\sqrt{2\log(1/u_1)}$, e só assim $J(u_1, u_2) = -2\pi/u_1$

(d) $f_{Z,W}(z,w) = e^{-\sqrt{(z+w)/2}}/2\sqrt{z^2-w^2}$ para $\sqrt{(z+w)/2} \geq 0$ e $1 \leq \sqrt{(z-w)/2} \leq 4$, isto é, para $z \geq 4$ e $\max(-z,\ z-64) \leq w \leq z-4$, e 0 caso contrário

2.9.5

(b) $h(x,y) = (y^4,\ x^4)$

(c) $h^{-1}(z,w) = (w^{1/4},\ z^{1/4})$

(d) $f_{Z,W}(z,w) = e^{-w^{1/4}}$ para $w^{1/4} \geq 0$ e $1 \leq z^{1/4} \leq 4$, isto é, para $w \geq 0$ e $1 \leq z \leq 256$, e 0 caso contrário

2.9.7 $p_Z(2) = 1/18$, $p_Z(4) = 1/12$, $p_Z(5) = 1/18$, $p_Z(7) = 1/24$, $p_Z(8) = 1/72$, $p_Z(9) = 1/4$, $p_Z(11) = 3/8$, $p_Z(12) = 1/8$, $p_Z(z) = 0$ caso contrário

2.9.9

(a)

(z,w)	$(-8,16)$	$(-7,19)$	$(-3,11)$	$(-2,14)$	$(0,6)$	outros
$P(Z=z, W=w)$	1/5	1/5	1/5	1/5	1/5	0

(b) $p_Z(z) = 1/5$ para $z = -8,-7,-3,-2,0$ e, caso contrário, $p_Z(z) = 0$

(c) $p_W(w) = 1/5$ para $w = 6,11,14,16,19$ e, caso contrário, $p_W(w) = 0$

2.10.1 $Z = -7$ se $U \leq 1/2$, $Z = -2$ se $1/2 < U \leq 5/6$ e $Z = 5$ se $U > 5/6$

2.10.3 $Y \sim$ Exponencial(3)

2.10.5 $c_1 = \pm 3\sqrt{2}$ e $c_2 = 5$

2.10.7

(a) Para $x < 1$, $F_X(x) = 0$; para $1 \leq x < 2$, $F_X(x) = 1/3$; para $2 \leq x < 4$, $F_X(x) = 1/2$; para $x \geq 4$, $F_X(x) = 1$.

(b) Os valores de t têm de ficar restritos a $(0,1]$ porque $F_X^{-1}(0) = -\infty$. $F_X^{-1}(t) = 1$ para $t \in (0,1/3]$, $F_X^{-1}(t) = 2$ para $t \in (1/3,1/2]$ e $F_X^{-1}(t) = 4$ para $t \in (1/2,1]$.

(c) Para $y < 1$, $F_Y(y) = 0$; para $1 \leq y < 2$, $F_Y(y) = 1/3$; para $2 \leq y < 4$, $F_Y(y) = 1/2$; para $y \geq 4$, $F_Y(y) = 1$.

2.10.9 $Y = F_Z^{-1}(U) = U^{1/4}$

Capítulo 3

3.1.1

(a) $E(X) = 8/7$

(b) $E(X) = 1$

(c) $E(X) = 8$

3.1.3

(a) $E(X) = -1$

(b) $E(Y) = 11$

(c) $E(X^2) = 19$

(d) $E(Y^2) = 370/3$

(e) $E(X^2 + Y^2) = 427/3$

(f) $E(XY - 4Y) = -113/2$

3.1.5 $E(8X - Y + 12) = 8((1 - p)/p) - \lambda + 12$

3.1.7 $E(XY) = 30$

3.1.9 $E(X) = 6$

3.1.11

(a) $E(Z) = 7$

(b) $E(W) = 49/4$

3.1.13 $E(Y) = 7/4$

3.2.1

(a) $C = 1/4, E(X) = 7$

(b) $C = 1/16, E(X) = 169/24$

(c) $C = 5/3093, E(X) = -8645/2062$

3.2.3

(a) $E(X) = 17/24$

(b) $E(Y) = 17/8$

(c) $E(X^2) = 11/20$

(d) $E(Y^2) = 99/20$

(e) $E(Y^4) = 216/7$

(f) $E(X^2Y^3) = 27/4$

3.2.5 $E(-5X - 6Y) = -77/3$

3.2.7 $E(Y + Z) = 17/72$

3.2.9 Seja $\mu_k = E(X^k)$; então $\mu_1 = 39/25$, $\mu_2 = 64/25$, $\mu_3 = 152/35$.

3.2.11 334

3.2.13 $E(Y) = 214{,}1$

3.2.15 Sim

3.3.1

(a) $\text{Cov}(X, Y) = 2/3$

(b) $\text{Var}(X) = 2$, $\text{Var}(Y) = 32/9$

(c) $\text{Corr}(X, Y) = 1/4$

3.3.3 $\text{Corr}(X, Y) = -0{,}18292$

3.3.5 $E(XY) = E(X)E(Y)$

3.3.7

(a) $\text{Cov}(X, Z) = 1/9$

(b) $\text{Corr}(X, Z) = 1/\sqrt{46}$

3.3.9 $E(X(X-1)) = E(X^2) - E(X)$; quando $X \sim \text{Binomial}(n, \theta)$, $E(X(X-1)) = n(n-1)\theta^2$

3.3.11 $E(X) = 7/2$, $E(Y) = 7$, $E(XY) = 329/12$, $\text{Cov}(X, Y) = 35/12$

3.3.13 $\text{Cov}(Z, W) = 0$, $\text{Corr}(Z, W) = 0$

3.3.15 $\text{Cov}(X, Y) = 35/24$

3.4.1

(a) $r_Z(t) = t/(2-t)$, $r_Z'(t) = 2/(2-t)^2$, $r_Z''(t) = -4/(t-2)^3$

(b) $E(Z) = 2$, $\text{Var}(Z) = 2$, $m_Z(t) = e^t/(2-e^t)$, $m_Z'(t) = 2e^t/(2-e^t)^2$, $m_Z''(t) = 2e^t(2+e^t)/(2-e^t)$.*

*Nota do tradutor. o original traz $(2 - e^t)$ no denominador de $m_Z''(t)$, sem expoente (a linha encosta na margem); pela conta seria $(2 - e^t)^3$

3.4.3 $m_Y(s) = e^{\lambda(e^s-1)}$, $m'_Y(s) = \lambda e^s e^{\lambda(e^s-1)}$, então $m'_Y(s) = \lambda$, $m''_Y(s) = (\lambda e^s + \lambda^2 e^{2s})e^{\lambda(e^s-1)}$, então $m''_Y(s) = \lambda + \lambda^2$, $\text{Var}(Y) = \lambda + \lambda^2 - (\lambda)^2 = \lambda$.*

3.4.5 $m_Y(s) = e^{4s} m_X(3s)$

3.4.7 $m'''_Y(s) = e^{\lambda(e^s-1)} e^s \lambda(1 + 3e^s\lambda + e^{2s}\lambda^2)$, $E(Y^3) = m'''_Y(0) = \lambda(1 + 3\lambda + \lambda^2)$

3.5.1

(a) $E(X \mid Y = 3) = 5/2$

(b) $E(Y \mid X = 3) = 22/3$

(c) $E(X \mid Y = 2) = 5/2$, $E(X \mid Y = 17) = 3$

(d) $E(Y \mid X = 2) = 5/2$, $E(Y \mid X = 3) = 22/3$

3.5.3

(a) $E(Y \mid X = 6) = 25/4$

(b) $E(Y \mid X = -4) = 36/7$

(c) $E(Y \mid X) = 25/4$ sempre que $X = 6$, e $E(Y \mid X) = 36/7$ sempre que $X = -4$.

3.5.7 $E(Z \mid W = 4) = 14/3$

(b) $E(W \mid Z = 4) = 10/3$

3.5.9

(a) $E(X \mid Y = 0) = 1$

(b) $E(X \mid Y = 1) = 2$

(c) $E(Y \mid X = 0) = 0$

(d) $E(Y \mid X = 1) = 1/3$

(e) $E(Y \mid X = 2) = 2/3$

(f) $E(Y \mid X = 3) = 1$

(g) $E(Y \mid X) = X/3$

3.5.11

(a) $E(X) = \frac{27}{19}$

(b) $E(Y) = \frac{52}{95}$

*Nota do tradutor. o original traz $m'_Y(s) = \lambda$ e $m''_Y(s) = \lambda + \lambda^2$; pela conta, são os valores em $s = 0$: $m'_Y(0)$ e $m''_Y(0)$

(c) $E(X \mid Y = y) = 3(2 + y^3)/(4 + 3y^3)$

(d) $E(Y \mid X = x) = (x^2/2 + 1/5)/(x^2 + 1/4)$

(e) $E[E(X \mid Y)] = \int_0^1 \frac{3(2+y^3)}{4+3y^3} \cdot \frac{4}{19}(4 + 3y^3)\, dy = \frac{27}{19}$

(f) $E[E(Y \mid X)] = \int_0^2 \frac{x^2/2+1/5}{x^2+1/4} \cdot \frac{6}{19}\left(x^2 + \frac{1}{4}\right) dx = \frac{52}{95}$.

3.6.1 3/7

3.6.3

(a) 1/9

(b) 1/2

(c) 2

(d) A cota superior[1] do item (b) é menor e, portanto, mais útil que a do item (c).

3.6.5 1/4

3.6.7

(a) 10.000

(b) 12.100

3.6.9

(a) 1

(b) 1/4

3.6.11

(a) $E(Z) = 8/5$

(b) 32/75

3.6.13 7/16

3.7.1 $E(X_1) = 3$, $E(X_2) = 0$, $E(Y) = 3/5$

3.7.3 $P(X < t) = 0$ para $t < 0$, enquanto $P(X > t) = 1$ para $0 < t < C$ e $P(X > t) = 0$ para $t > C$

3.7.5 $E(X) = 2$

No original: *upper bound*[1].

3.7.7 $E(W) = 1/5$

3.7.9 $E(W) = 21/2$

Capítulo 4

4.1.1 $P(Y_3 = 1) = 1/8$, $P(Y_3 = 2) = 1/64$, $P(Y_3 = 3) = 1/64$, $P(Y_3 = 2^{1/3}) = 3/16$, $P(Y_3 = 3^{1/3}) = 3/16$, $P(Y_3 = 4^{1/3}) = 3/32$, $P(Y_3 = 9^{1/3}) = 3/32$, $P(Y_3 = 12^{1/3}) = 3/64$, $P(Y_3 = 18^{1/3}) = 3/64$, $P(Y_3 = 6^{1/3}) = 3/16$

4.1.3 Se Z é a média amostral, então $P(Z = 0) = p^2$, $P(Z = 0{,}5) = 2p(1-p)$ e $P(Z = 1) = (1-p)^2$.

4.1.5 Para $1 \le j \le 6$, $P(\max = j) = (j/6)^{20} - ((j-1)/6)^{20}$.

4.1.7 Se $W = XY$, então

$$P(W = w) = \begin{cases} 1/36 & \text{se } w = 1, 9, 16, 25, 36, \\ 1/18 & \text{se } w = 2, 3, 5, 8, 10, 15, 18, 20, 24, 30, \\ 1/12 & \text{se } w = 4, \\ 1/9 & \text{se } w = 6, 12, \\ 0 & \text{caso contrário.} \end{cases}$$

4.1.9 $p_Y(y) = 1/2$ para $y = 1, 2$; caso contrário, $p_Y(y) = 0$

4.2.1 Note que $Z_n = Z$, a menos que $7 \le U < 7 + 1/n^2$. Logo, para todo $\epsilon > 0$, $P(|Z_n - Z| \ge \epsilon) \le P(7 \le U < 7 + 1/n^2) = 1/5n^2 \to 0$ quando $n \to \infty$.

4.2.3 $P(W_1 + \cdots + W_n < n/2) = 1 - P(W_1 + \cdots + W_n \ge n/2) \ge 1 - P\left(\left|\frac{1}{n}(W_1 + \cdots + W_n) - \frac{1}{3}\right| \ge 1/6\right)$

4.2.5 $P(X_1 + \cdots + X_n > 9n) \le P(|(X_1 + \cdots + X_n)/n - 8| \ge 1)$

4.2.7 Para todo $\epsilon > 0$ e $n > -2\ln\epsilon$, $P(|X_n - Y| \ge \epsilon) = P(e^{-H_n} \ge \epsilon) = P(H_n \le -\ln\epsilon) \le P(|H_n - n/2| \ge |n/2 + \ln\epsilon|)\ n \to \infty$.*

4.2.9 Por definição, $H_n - 1 \le F_n \le H_n$ e $P(|X_n - Y_n - Z| \ge \epsilon) = P(|H_n - F_n|/(H_n + 1) \ge \epsilon) \le P(1/(H_n + 1) \ge \epsilon) = P(H_n \le (1/\epsilon) - 1) = P(H_n - n/2 \le (1/\epsilon) - 1 - n/2) \le P(|H_n - n/2| \ge |1 + n/2 - 1/\epsilon|)$.

4.2.11 $r = 9/2$

*Nota do tradutor. o original termina assim, "… |) $n \to \infty$"; pelo sentido falta "→ 0 quando" antes de $n \to \infty$

4.3.1 Note que $Z_n = Z$, a menos que $7 \leq U < 7 + 1/n^2$. Além disso, se $U > 7$, então $Z_n = Z$ sempre que $1/n^2 < 7 - U$, isto é, $n > 1/\sqrt{7-U}$. Logo, $P(Z_n \to Z) \geq P(U \neq 7)$.

4.3.3 $\{(W_1 + \cdots + W_n)/n \to 1/3\} \subseteq \{\exists\, n;\ (W_1 + \cdots + W_n)/n < 1/2\} = \{\exists\, n;\ W_1 + \cdots + W_n < n/2\}$

4.3.5 $P(X_n \to X \text{ e } Y_n \to Y) = 1 - P(X_n \not\to X \text{ ou } Y_n \not\to Y) \geq 1 - P(X_n \not\to X) - P(Y_n \not\to Y)$

4.3.7 $m = 5$

4.3.9 $r = 9/2$

4.3.11

(a) Suponha que não exista tal m e, a partir disso, obtenha uma contradição com a lei forte dos grandes números[2].

(b) Não

4.4.1 $\lim_{n\to\infty} P(X_n = i) = 1/3 = P(X = i)$ para $i = 1, 2, 3$

4.4.3 Aqui, $P(Z_n \leq 1) = 1$; para $0 \leq z < 1$, $P(Z_n \leq z) = z^{n+1}$; e $P(Z \leq z) = 1$ para $z \geq 1$.

4.4.5 $P(S \leq 540) \approx \Phi(1/2) = 0{,}6915$

4.4.7 $P(S \geq 2450) \approx \Phi(-0{,}51) = 0{,}3050$

4.4.9

(a) Para $0 < y < 1$, $P(Z \leq y) = y^2$.

(b) Para $1 \leq m \leq n$, $P(X_n \leq m/n) = m(m+1)/[n(n+1)]$.

(c) Para $0 < y < 1$, seja $m = \lfloor ny \rfloor$, o maior inteiro não maior que ny. Como não há inteiro em (m, ny), $P(m/n < X_n < y) \leq P(m/n < X_n < (m+1)/n) = 0$. Assim, $P(X_n \leq y) = m(m+1)/[n(n+1)]$, em que $m = \lfloor ny \rfloor$.

(d) Para $0 < y < 1$, seja $m_n = \lfloor ny \rfloor$; mostre que $m_n/n \to y$ quando $n \to \infty$. Depois mostre que $P(X_n \leq y) \to y^2$ quando $n \to \infty$.

4.4.11 $\lambda = 3$

4.4.13 A produção anual, Y, tem distribuição aproximadamente normal com média 1300 e variância[3] 433. Assim, $P(Y < 1280) \approx 0{,}1685$.

No original: *strong law of large numbers*[2], *variance*[3].

4.5.1 A integral é igual a $\sqrt{2\pi}\,E(\cos^2(Z))$, em que $Z \sim N(0,1)$.

4.5.3 Esta integral é igual a $(1/5)E(e^{-14Z^2})$, em que $Z \sim$ Exponencial(5).

4.5.5 Esta soma é aproximadamente igual a $e^5 E(\sin(Z^2))$, em que $Z \sim$ Poisson(5).

4.5.7 $(-6{,}1404; -3{,}8596)$

4.5.9 $(0{,}354; 0{,}447)$

4.5.11

(a) $C = \left\{\int_0^1 \int_0^1 g(x,y)\,dx\,dy\right\}^{-1}$

(b) Gere os X_i a partir de $f_X(x) = 3x^2$ para $0 < x < 1$ e os Y_i a partir de $f_Y(y) = 4y^3$ para $0 < y < 1$. Tome $D_i = \sin(X_i Y_i)\cos(\sqrt{X_i Y_i}) \times \exp(X_i^2 + Y_i)/12$ e $N_i = X_i \cdot D_i$ para $i = 1, \ldots, n$. Estime $E(X)$ por $M_n = \overline{N}/\overline{D} = (N_1 + \cdots + N_n)/(D_1 + \cdots + D_n)$.*

4.5.13

(a) $J = \int_0^1 \int_0^\infty e^y\, h(x,y)\, I_{[0,\infty)}(y) e^{-y}\,dy\, I_{[0,1]}(x)\,dx$

(b) Gere X_i e Y_i de forma apropriada, tome $T_i = e^{Y_i} h(X_i, Y_i)$ e estime J por $M_n = (T_1 + \cdots + T_n)/n$.

(c) $J = \int_0^1 \int_0^\infty e^{5y}\, h(x,y)\, I_{[0,\infty)}(y) 5e^{-5y}\,dy\, I_{[0,1]}(x)\,dx$

(d) Como no item (b).

(e) O estimador de menor variância é melhor. Portanto, use as variâncias amostrais para escolher entre eles.

4.6.1

(a) $U \sim N(43,\ 629)$, $V \sim N(-18 - 8C,\ 144 + 25C^2)$

(b) $C = -24/125$

4.6.3 $C_1 = 1/5$, $C_2 = -3$, $C_3 = 1/2$, $C_4 = 7$, $C_5 = 2$

4.6.5 Sejam $Z_1, \ldots, Z_n, W_1, \ldots, W_m \sim N(0,1)$ i.i.d. e tome $X = (Z_1)^2 + \cdots + (Z_n)^2$ e $Y = (W_1)^2 + \cdots + (W_n)^2$.†

4.6.7 $C = \sqrt{n}$

*Nota do tradutor. o original traz, soltos, um "a" depois de "$0 < x < 1$" e um "5." antes de "Estime"; parecem restos de edição e foram omitidos

†Nota do tradutor. o original traz $(W_n)^2$ como último termo de Y; como $Y \sim \chi^2(m)$, seria $(W_m)^2$

4.6.9 $C_1 = 2/5$, $C_2 = -3$, $C_3 = 2$, $C_4 = 7$, $C_5 = 2$, $C_6 = 1$, $C_7 = 1$

4.6.11

(a) $m = 60$, $K = \sqrt{61}$

(b) $y = 1{,}671$

(c) $a = 61$, $b = 1$, $c = 60$

(d) $w = 4{,}00$

Capítulo 5

5.1.1 Os tempos médios de sobrevivência do grupo de controle e do grupo de tratamento[4] são 93,2 dias e 356,2 dias, respectivamente.

5.1.3 Para os que ainda estão vivos, os tempos de sobrevivência serão maiores que os valores registrados; portanto, esses dados são incompletos.

5.1.5 $\bar{x} = -0{,}1375$

5.1.7 Use a diferença $\bar{x} - \bar{y}$.

5.2.1 No Exemplo 5.2.1, a moda é 0. No Exemplo 5.2.2, a moda é 1.

5.2.3 A mistura tem densidade $(5/\sqrt{2\pi})\exp\{-(x+4)^2/2\} + (5/\sqrt{2\pi})\exp\{-(x-4)^2/2\}$ para $-\infty < x < \infty$.*

5.2.5 $x = 10$

5.2.7 A moda é 1/3.

5.2.9 A moda é $x = 0$.

5.3.1 O modelo estatístico para uma única resposta consiste em três funções de probabilidade {Bernoulli(1/2), Bernoulli(1/3), Bernoulli(2/3)}.

5.3.3 A amostra $(X_1, \ldots, X_n)$ é uma amostra de uma distribuição $N(\mu, \sigma^2)$, em que $\theta = (\mu, \sigma^2) \in \mathbf{\Omega} = \{(10, 2), (8, 3)\}$. Tanto a média quanto a variância populacionais identificam univocamente a distribuição populacional.

*Nota do tradutor. O original traz $5/\sqrt{2\pi}$; com probabilidade de mistura 0,5, seria $0{,}5/\sqrt{2\pi}$.

No original: *treatment*[4].

5.3.5 Uma única observação provém de uma distribuição Exponencial(θ), em que $\theta \in \mathbf{\Omega} = [0, \infty)$. Podemos parametrizar esse modelo pela média ou pela variância, mas não pelo coeficiente de variação.

5.3.7

(a) $\mathbf{\Omega} = \{A, B\}$

(b) O valor $X = 1$ só pode ser observado quando $\theta = A$.

(c) Tanto $\theta = A$ quanto $\theta = B$ são possíveis.

5.3.9 P_1

5.4.1

$$F_X(x) = \begin{cases} 0 & x < 1 \\ \frac{4}{10} & 1 \le x < 2 \\ \frac{7}{10} & 2 \le x < 3 \\ \frac{9}{10} & 3 \le x < 4 \\ 1 & 4 \le x \end{cases}, \qquad f_X(x) = \begin{cases} \frac{4}{10} & x = 1 \\ \frac{3}{10} & x = 2 \\ \frac{2}{10} & x = 3 \\ \frac{1}{10} & x = 4 \end{cases}$$

$$\mu_X = \sum_{x=1}^{4} x f_X(x) = 2, \qquad \sigma_X^2 = \left(\sum_{x=1}^{4} x^2 f_X(x)\right) - 2^2 = 1$$

5.4.3

(a) Sim.

(b) Use a Tabela D.1, escolhendo uma linha e lendo os três primeiros números de um só algarismo (trate o 0 da tabela como 10).

(c) Usando a linha 108 da Tabela D.1 (tratando o 0 como 10): primeira amostra — obtemos os números aleatórios 6, 0, 9 e, assim, calculamos $(X(\pi_6) + X(\pi_{10}) + X(\pi_9))/3 = 3{,}0$. Segunda amostra — obtemos os números aleatórios 4, 0, 7 e, assim, calculamos $(X(\pi_6) + X(\pi_{10}) + X(\pi_9))/3 = 2{,}6667$. Terceira amostra — obtemos os números aleatórios 2, 0, 2 (note que não pulamos o segundo 2) e, assim, calculamos $(X(\pi_6) + X(\pi_{10}) + X(\pi_9))/3 = 2{,}0$.*

5.4.5

(c) A forma de um histograma depende dos intervalos usados.

*__Nota do tradutor.__ Na segunda e na terceira amostras, o original repete π_6, π_{10}, π_9; pelos números sorteados seriam π_4, π_{10}, π_7 e π_2, π_{10}, π_2, que dão os valores impressos.

5.4.7 É uma variável categórica.

5.4.9

(a) Os alunos tendem mais a mentir quando já baixaram música ilegalmente; portanto, os resultados do estudo serão falhos.

(b) Com anonimato, os alunos tendem mais a dizer a verdade; portanto, haverá menos erro.

(c) A probabilidade de que um aluno diga a verdade é $p = 0{,}625$. Seja Y_i a resposta do aluno i. Então $(\bar{Y} - (1-p))/(2p-1)$ é registrado como estimativa[5] da proporção de alunos que já baixaram música ilegalmente.

5.5.1

(a) $\hat{f}_X(0) = 0{,}2667$, $\hat{f}_X(1) = 0{,}2$, $\hat{f}_X(2) = 0{,}2667$, $\hat{f}_X(3) = \hat{f}_X(4) = 0{,}1333$

(b) $\hat{F}_X(0) = 0{,}2667$, $\hat{F}_X(1) = 0{,}4667$, $\hat{F}_X(2) = 0{,}7333$, $\hat{F}_X(3) = 0{,}8667$, $\hat{F}_X(4) = 1{,}000$

(d) A média é $\bar{x} = 1{,}667$ e a variância é $s^2 = 1{,}952$.

(e) A mediana é 2 e $IQR = 3$. Pela regra de 1,5 IQR, não há valores atípicos.

5.5.3

(a) $\hat{f}_X(1) = 25/82$, $\hat{f}_X(2) = 35/82$, $\hat{f}_X(3) = 22/82$

(b) Não.

5.5.5 A mediana amostral[6] é 0, o primeiro quartil é $-1{,}150$, o terceiro quartil é 0,975 e $IQR = 2{,}125$. Estimamos $F_X(1)$ por $\hat{F}_X(1) = 17/20 = 0{,}85$.

5.5.7 $\psi(\mu) = \mu + \sigma_0 z_{0{,}25}$, em que $z_{0{,}25}$ satisfaz $\Phi(z_{0{,}25}) = 0{,}25$

5.5.9 $\psi(\mu) = \Phi((3-\mu)/\sigma_0)$

5.5.11 $\psi(\mu, \sigma^2) = \Phi((3-\mu)/\sigma)$

5.5.13 $\psi(\theta) = 2\theta(1-\theta)$

5.5.15 $\psi(\theta) = \alpha_0/\beta^2$

No original: *estimate*[5], *sample median*[6].

Capítulo 6

6.1.1 O modelo estatístico adequado é Binomial(n, θ), em que $\theta \in \mathbf{\Omega} = [0, 1]$ é a probabilidade de ter esse anticorpo no sangue. A função de verossimilhança[7] é $L(\theta \mid 3) = \binom{10}{3}\theta^3(1-\theta)^7$.

6.1.3 $L(\theta \mid x_1, \ldots, x_{20}) = \theta^{20}\exp(-(20\bar{x})\theta)$, e $\bar{x}$ é uma estatística suficiente[8].

6.1.5 $c = \binom{10}{4}/\binom{9}{3}$

6.1.7 $L(\theta \mid x_1, \ldots, x_n) = \prod_{i=1}^{n} \theta^{x_i}e^{-\theta}/x_i! = \theta^{n\bar{x}}e^{-n\theta}/\prod x_i!$, e $\bar{x}$ é uma estatística suficiente minimal[9].

6.1.9 $L(1 \mid 0)/L(2 \mid 0) = 4{,}4817$: a distribuição f_1 é 4,4817 vezes mais verossímil que f_2.

6.1.11 Não.

6.1.13 Não.

6.2.1 $\hat{\theta}(1) = a$, $\hat{\theta}(2) = b$, $\hat{\theta}(3) = b$, $\hat{\theta}(4) = a$

6.2.3 $\psi(\theta) = \theta^2$ é injetora[10] e, portanto, $\psi(\hat{\theta}(x_1, \ldots, x_n)) = \bar{x}^2$ é o EMV.

6.2.5 $\hat{\theta} = \alpha_0/\bar{x}$

6.2.7 $\hat{\alpha} = -n/\sum_{i=1}^{n} \ln x_i$

6.2.9 $\hat{\alpha} = n/\sum_{i=1}^{n} \ln(1 + x_i)$

6.2.11 $\hat{\mu}^3 = 32{,}768\ \text{cm}^3$ é o EMV.

6.2.13 Uma função de verossimilhança não pode assumir valores negativos.

6.2.15 Funções de log-verossimilhança[11] equivalentes diferem por uma constante aditiva.

6.3.1 Valor-p $= 0{,}592$, e o intervalo de confiança[12] 0,95 é $(4{,}442; 5{,}318)$.

6.3.3 Valor-p $= 0{,}000$, e o intervalo de confiança 0,95 é $(63{,}56; 67{,}94)$.

6.3.5 Valor-p $= 0{,}00034$, e o intervalo de confiança 0,95 é $[47{,}617; 56{,}383]$. O tamanho mínimo da amostra necessário é 2.

No original: *likelihood function*[7], *sufficient statistic*[8], *minimal sufficient statistic*[9], *one-to-one*[10], *log-likelihood*[11], *confidence interval*[12].

6.3.7 Valor-p = 0,1138; portanto, o resultado não é estatisticamente significativo[13], e a diferença observada de $1{,}05 - 1 = 0{,}05$ está bem dentro da faixa de significância prática.

6.3.9 Valor-p = 0,527

6.3.11 Valor-p = 0,014

6.3.13

(a) $\sum_{i=1}^{n}(x_i - \bar{x})^2 = \sum_{i=1}^{n} x_i^2 - n\bar{x}^2$

(b) O estimador plug-in é $\hat{\sigma}^2 = \bar{x}(1 - \bar{x})$; portanto, $\hat{\sigma}^2 = s^2(n-1)/n$.

(c) $\text{viés}(\hat{\sigma}^2) = -\sigma^2/n \to 0$ quando $n \to \infty$.

6.3.15

(a) Sim.

(b) Não.

6.3.17 O valor-p 0,22 não implica que a hipótese nula[14] seja correta. Pode ser que simplesmente não tenhamos tomado uma amostra grande o bastante para detectar uma diferença.

6.4.1 $m_3 \pm z_{(1+\gamma)/2}\, s_3/\sqrt{n} = (26{,}027; 151{,}373)$

6.4.3 O estimador pelo método dos momentos[15] é $\sqrt{m_2 - m_1^2}/m_1$. Se $Y = cX$, então $E(Y) = cE(X)$ e $\text{Var}(Y) = c^2 \text{Var}(X)$.

6.4.5 Pela função geradora de momentos[16], $m_X'''(0) = 3\sigma^2\mu + \mu^3$. O estimador plug-in é $\hat{\mu}_3 = 3(m_2 - m_1^2) \times m_1 + m_1^3$, enquanto o estimador pelo método dos momentos de μ_3 é $m_3 = \frac{1}{n}\sum x_i^3$.

6.4.7 A mediana amostral é estimada por −0,03, a estimativa do primeiro quartil é −1,28 e a do terceiro quartil é 0,98. Além disso, $\hat{F}(2) = \hat{F}(1{,}36) = 0{,}90$.

6.4.9 O procedimento bootstrap[17] consiste em amostrar de uma distribuição discreta e, pelo teorema central do limite[18], a distribuição da média bootstrap é aproximadamente normal quando n e m são grandes. O teorema delta[19] justifica, sob certas condições, a normalidade aproximada de funções da média bootstrap.

No original: *statistically significant*[13], *null hypothesis*[14], *method of moments*[15], *moment-generating function*[16], *bootstrapping*[17], *central limit theorem*[18], *delta theorem*[19].

6.4.11 O número máximo de valores possíveis é $1 + \binom{n}{2} = 1 + n(n-1)/2$. Aqui, o 0 é obtido quando $i = j$. A amplitude amostral bootstrap $y_{(n)} - y_{(1)}$ tem maior valor possível $x_{(n)} - x_{(1)}$ e menor valor possível 0. Se houver muitos valores x_i repetidos na amostra bootstrap[20], o valor 0 ocorrerá com alta probabilidade para $y_{(n)} - y_{(1)}$; assim, a distribuição bootstrap da amplitude amostral não será aproximadamente normal.

6.5.1 $n/2\sigma^4$

6.5.3 n/α^2

6.5.5 $2/\bar{x} \pm (2/\bar{x})\, z_{0,95}/\sqrt{2n} = (9{,}5413 \times 10^{-4}; 1{,}5045 \times 10^{-3})$

6.5.7 $\hat{\alpha} \pm (\hat{\alpha}/\sqrt{n})\, z_{(1+\gamma)/2} = (0{,}18123; 0{,}46403)$ é um intervalo de confiança 0,95, e ele não contém $\alpha = 1 + 1/25 = 1{,}04$.

6.5.9 $\left[0, \min\left((1+\bar{x})^{-1} + n^{-1/2}(1+\bar{x})^{-1}\sqrt{\bar{x}(1+\bar{x})^{-1}}\, z_\gamma, 1\right)\right]$

Capítulo 7

7.1.1 Com base em $m(1,1) = 1/20 + 2/45 + 18/80 = 23/72$, $m(1,2) = 1/20+4/45+6/80 = 77/360$, $m(2,1) = m(1,2)$, $m(2,2) = 1/20+8/45+2/80 = 91/360$, as distribuições de probabilidade a posteriori[21] para cada uma das quatro amostras possíveis são as seguintes.

amostra	$(1,1)$	$(1,2)$
$\theta = 1$	$(1/4)(1/5)/m(1,1) = 18/115$	$(1/4)(1/5)/m(1,2) = 18/77$
$\theta = 2$	$(1/9)(2/5)/m(1,1) = 16/115$	$(2/9)(2/5)/m(1,2) = 32/77$
$\theta = 3$	$(9/16)(2/5)/m(1,1) = 81/115$	$(3/16)(2/5)/m(1,2) = 27/77$
amostra	$(2,1)$	$(2,2)$
$\theta = 1$	$(1/4)(1/5)/m(2,1) = 18/77$	$(1/4)(1/5)/m(2,2) = 18/91$
$\theta = 2$	$(2/9)(2/5)/m(2,1) = 32/77$	$(4/9)(2/5)/m(2,2) = 64/91$
$\theta = 3$	$(3/16)(2/5)/m(2,1) = 27/77$	$(1/16)(2/5)/m(2,2) = 9/91$

7.1.3 A probabilidade a priori[22] de que θ seja positivo é 0,5, e a probabilidade a posteriori[23] é 0,9992.

7.1.5 $\theta^{\alpha-n-1}e^{-\beta\theta} I_{[x_{(n)},\infty)}(\theta) \Big/ \int_{x_{(n)}}^{\infty} \theta^{\alpha-n-1}e^{-\beta\theta}\, d\theta$

7.1.7 $\mu \mid \sigma^2, x_1, \ldots, x_n \sim N(5{,}5353; \frac{4}{81}\sigma^2)$, $1/\sigma^2 \mid x_1, \ldots, x_n \sim \text{Gama}(11; 41{,}737)$

No original: *bootstrap sample*[20], *posterior*[21], *prior*[22], *posterior*[23].

7.1.9

(a) $(n+1)\theta^n I_{[0,4;0,6]}(\theta)/(0{,}6^{n+1} - 0{,}4^{n+1})$

(b) Não.

(c) A priori[24] precisa ser maior que 0 em todos os valores do parâmetro que acreditamos serem possíveis.

7.1.11

(a) $\Pi(|\theta| = 0) = 1/6$, $\Pi(|\theta| = 1) = 1/3$, $\Pi(|\theta| = 2) = 1/3$, $\Pi(|\theta| = 3) = 1/6$; portanto, $|\theta|$ não tem distribuição uniforme[25] em $\{0, 1, 2, 3\}$.

(b) Não.

7.2.1 $$\frac{\Gamma(\alpha+\beta+n)\Gamma(n\bar{x}+\alpha+m)}{\Gamma(n\bar{x}+\alpha)\Gamma(\alpha+\beta+n+m)}$$

7.2.3 $E(1/\sigma^2 \mid x_1, \ldots, x_n) = (\alpha_0 + n/2)/\beta_x$, e a moda a posteriori é $1/\hat{\sigma}^2 = (\alpha_0 + n/2 - 1)/\beta_x$.

7.2.5 Como no Exemplo 7.2.4, a distribuição a posteriori de θ_1 é Beta$(f_1 + \alpha_1, f_2 + \cdots + f_k + \alpha_2 + \cdots + \alpha_k)$; portanto,

$$E(\theta_1 \mid x_1, \ldots, x_n) = \frac{\Gamma\left(n + \sum_{i=1}^k \alpha_i\right)\Gamma(f_1 + \alpha_1 + 1)}{\Gamma(f_1 + \alpha_1)\Gamma\left(n + \sum_{i=1}^k \alpha_i + 1\right)},$$

e, para a moda a posteriori, maximize $\ln\left((\theta_1)^{f_1+\alpha_1-1}(1-\theta_1)^{\sum_{i=2}^k (f_i+\alpha_i)-1}\right)$.

7.2.7 Lembre que a distribuição a posteriori de θ_1 no Exemplo 7.2.2 é Beta$(f_1 + \alpha_1, f_2 + \cdots + f_k + \alpha_2 + \cdots + \alpha_k)$. Determine o segundo momento e use $\text{Var}(\theta_1 \mid x_1, \ldots, x_n) = E(\theta_1^2 \mid x_1, \ldots, x_n) - (E(\theta_1 \mid x_1, \ldots, x_n))^2$. Agora, $0 \le f_1/n \le 1$; portanto*

$$\text{Var}(\theta_1 \mid x_1, \ldots, x_n) = \frac{(f_1/n + \alpha_1)\left(\sum_{i=2}^k (f_i/n + \alpha_i)\right)}{n\left(1 + \sum_{i=1}^k \alpha_i/n + 1/n\right)\left(1 + \sum_{i=1}^k \alpha_i/n\right)^2} \to 0$$

quando $n \to \infty$.

*__Nota do tradutor.__ O original remete ao Exemplo 7.2.2, mas o modelo é o do Exemplo 7.2.4, citado no enunciado; e, pela conta, o numerador traria α_1/n e α_i/n no lugar de α_1 e α_i (o limite 0 não muda).

No original: *prior*[24], *uniform distribution*[25].

7.2.9 A densidade preditiva a posteriori[26] de x_{n+1} é obtida tomando a média da densidade $N(\bar{x}, (1/\tau_0^2 + n/\sigma_0^2)^{-1}\sigma_0^2)$ em relação à densidade a posteriori de μ; portanto, essa também tem de ser a distribuição preditiva a posteriori.

7.2.11 A distribuição preditiva a posteriori de $t = x_{n+1}$ é $(n\bar{x} + \beta_0)$ Pareto$(n + \alpha_0)$. Assim, a moda a posteriori é $\hat{t} = 0$, a esperança[27] a posteriori é $(n\bar{x} + \beta_0)/(n + \alpha_0 - 1)$, e a variância a posteriori é $(n\bar{x} + \beta_0)^2(n + \alpha_0)/[(n + \alpha_0 - 1)^2(n + \alpha_0 - 2)]$.

7.2.13

(a) A distribuição a posteriori de σ^2 é Gama inversa $(n/2 + \alpha_0, \beta_x)$, em que $\beta_x = (n-1)s^2/2 + n(\bar{x} - \mu_0)^2/2 + \beta_0$.

(b) $E(\sigma^2 \mid x_1, \ldots, x_n) = \beta_x/(n/2 + \alpha_0 - 1)$.

(c) Para avaliar a hipótese $H_0 : \sigma^2 \leq \sigma_0^2$, calcule a probabilidade $\Pi(1/\sigma^2 \geq 1/\sigma_0^2 \mid x_1, \ldots, x_n) = 1 - G(2\beta_x/\sigma_0^2; 2\alpha_0 + n)$, em que $G(\cdot\,; 2\alpha_0 + n)$ é a fda da $\chi^2(2\alpha_0 + n)$.

7.2.15

(a) A chance a favor de $A = 1/$(chance a favor de A^c).

(b) $BF(A) = 1/BF(A^c)$

7.2.17 A probabilidade a posteriori de H_0 do estatístico I é 0,0099. A probabilidade a posteriori de H_0 do estatístico II é 0,0292. Portanto, o estatístico II tem o maior grau de crença a posteriori em H_0.

7.2.19 Um fator de Bayes[28] a favor de A assume valores em $[0, \infty)$. Se A tem probabilidade a posteriori igual a 0, o fator de Bayes será 0.

7.3.1 (3,2052; 4,4448)

7.3.3 A moda a posteriori é $\hat{\mu} = (nt/\upsilon_0^2 + \mu_0/\sigma_0^2)/(n/\upsilon_0^2 + 1/\sigma_0^2)$ e $\hat{\sigma}^2(x_1, \ldots, x_n) = (n/\upsilon_0^2 + 1/\sigma_0^2)^{-1}$. Portanto, o intervalo de credibilidade[29] γ assintótico é $(\hat{\mu} - z_{(1+\gamma)/2}\hat{\sigma}, \hat{\mu} + z_{(1+\gamma)/2}\hat{\sigma})$.*

7.3.5 Para uma amostra $(x_1, \ldots, x_n)$, a distribuição a posteriori é $N(\bar{x}, 1/n)$ restrita a $[0, 1]$. Um algoritmo de Monte Carlo simples para a distribuição a posteriori é: 1. gere η de $N(\bar{x}, 1/n)$; 2. aceite η se ele estiver em $[0, 1]$ e, caso

*__Nota do tradutor.__ A resposta usa t, υ_0^2 e σ_0^2 onde o enunciado (Exemplo 7.2.3) usa $\bar{x}$, σ_0^2 e τ_0^2.

No original: *posterior predictive*[26], *expectation*[27], *Bayes factor*[28], *credible interval*[29].

contrário, volte ao passo 1. Se o valor verdadeiro θ_* não estiver em $[0,1]$, a taxa de aceitação será muito pequena para n grande.

7.4.1 A densidade a posteriori é proporcional a $\lambda^{n+\alpha-1}\exp\{-\lambda(\ln(\prod(1+x_i))+\beta)\}$.

7.4.3

(a) O valor máximo da preditiva a priori[30] é obtido quando $\tau = 1$.

(b) A posteriori de θ dado $\tau = 1$ é

$$\pi_1(\theta \mid 1,1,3) = \begin{cases} \dfrac{(1/2)(1/3)^3}{59/1728} = \dfrac{32}{59} & \theta = a \\ \dfrac{(1/2)(1/2)^2(1/8)}{59/1728} = \dfrac{27}{59} & \theta = b. \end{cases}$$

7.4.5 A preditiva a priori é dada por

$$m_{\alpha,\beta}(x_1,\ldots,x_n) = \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)}\,\frac{\Gamma(\alpha+n\bar{x})\Gamma(\beta+n(1-\bar{x}))}{\Gamma(\alpha+\beta+n)}.$$

Com base na preditiva a priori, escolheríamos a priori dada por $\alpha = 1$, $\beta = 1$.

7.4.7 A priori de Jeffreys[31] é $\sqrt{n}\,\theta^{-1/2}(1-\theta)^{-1/2}$. A distribuição a posteriori de θ é Beta$(n\bar{x}+1/2, n(1-\bar{x})+1/2)$.

7.4.9 A distribuição a priori é $\theta \sim N(66,\sigma^2)$ com $\sigma^2 = 101{,}86$.

7.4.11 Tome a priori $\theta \sim$ Exponencial(λ) com $\lambda = 0{,}092103$.

Capítulo 8

8.1.1 $L(1 \mid \cdot) = (3/2)L(2 \mid \cdot)$; portanto, pela Seção 6.1.1, T é uma estatística suficiente. As distribuições condicionais de s são as seguintes.

	$s=1$	$s=2$	$s=3$	$s=4$
$f_a(s \mid T=1)$	$\frac{1/3}{1/3+1/6} = \frac{2}{3}$	$\frac{1/6}{1/3+1/6} = \frac{1}{3}$	0	0
$f_b(s \mid T=1)$	$\frac{1/2}{1/2+1/4} = \frac{2}{3}$	$\frac{1/4}{1/2+1/4} = \frac{1}{3}$	0	0

No original: *prior predictive*[30], *Jeffreys' prior*[31].

	$s=1$	$s=2$	$s=3$	$s=4$
$f_a(s \mid T=3)$	0	0	1	0
$f_b(s \mid T=3)$	0	0	1	0

	$s=1$	$s=2$	$s=3$	$s=4$
$f_a(s \mid T=4)$	0	0	0	1
$f_b(s \mid T=4)$	0	0	0	1

8.1.3 $\bar{x}^2 + (1-1/n)\sigma_0^2$

8.1.5 UMVU para $5+2\mu$

8.1.7 $\bar{x}/\alpha_0$

8.1.9 $n^{-1}\sum_{i=1}^{n} I_{(-1,1)}(X_i)$

8.1.11 Sim.

8.2.1 Quando $\alpha = 0{,}1$, $c_0 = 3/2$ e $\gamma = ((1/10)-(1/12))/(1/2) = 1/30$. O poder do teste é 23/120. Quando $\alpha = 0{,}05$, $c_0 = 2$ e $\gamma = ((1/20)-0)/(1/12) = 3/5$. O poder do teste é 1/10.

8.2.3 Por (8.2.6), o teste ótimo de tamanho 0,01 é da forma

$$\varphi_0(\bar{x}) = \begin{cases} 1 & \bar{x} \geq 1 + \dfrac{\sqrt{2}}{\sqrt{10}}\,2{,}3263 \\ 0 & \bar{x} < 1 + \dfrac{\sqrt{2}}{\sqrt{10}}\,2{,}3263 \end{cases} = \begin{cases} 1 & \bar{x} \geq 2{,}0404 \\ 0 & \bar{x} < 2{,}0404. \end{cases}$$

8.2.5

(a) 0

(b) Suponha $\theta > 1$. A função poder[32] é $\beta(\theta) = 1 - 1/\theta$.

8.2.7 $n \geq 4$

8.2.9 O gráfico da função poder da função de teste[33] UMP de tamanho α fica acima do gráfico da função poder de qualquer outra função de teste de tamanho α.

8.3.1 $\Pi(\theta = 1 \mid 2) = 2/5$, $\Pi(\theta = 2 \mid 2) = 3/5$; portanto, $\Pi(\theta = 2 \mid 2) > \Pi(\theta = 1 \mid 2)$ e aceitamos $H_0 : \theta = 2$.

No original: *power function*[32], *test function*[33].

8.3.3 A regra de Bayes é dada por $(1/\tau_0^2 + n/\sigma_0^2)^{-1}(\mu_0/\tau_0^2 + n\bar{x}/\sigma_0^2)$, que converge para $\bar{x}$ quando $\tau_0 \to \infty$.

8.3.5 A regra de Bayes é dada por $(n\alpha_0 + \tau_0)/(n\bar{x} + \upsilon_0)$ e, pela lei fraca dos grandes números[34], ela converge em probabilidade para β quando $n \to \infty$.

8.3.7 A regra de Bayes rejeita sempre que

$$BF_{H_0} = \frac{\exp\left(-\frac{n}{2\sigma_0^2}(\bar{x} - \mu_0)^2\right)}{\tau_0^{-1}\left(\frac{n}{\sigma_0^2} + \frac{1}{\tau_0^2}\right)^{-1/2} \exp\left(\frac{1}{2}\left(\frac{1}{\tau_0^2} + \frac{n}{\sigma_0^2}\right)^{-1}\left(\frac{\mu_0}{\tau_0^2} + \frac{n}{\sigma_0^2}\bar{x}\right)^2 - \frac{1}{2}\left(\frac{\mu_0^2}{\tau_0^2} + \frac{n\bar{x}^2}{\sigma_0^2}\right)\right)}$$

é menor que $(1 - p_0)/p_0$. Quando $\tau_0^2 \to \infty$, o denominador converge para 0; portanto, no limite, nunca rejeitamos H_0.

8.4.1 O modelo é dado pela coleção de funções de probabilidade $\{\theta^{n\bar{x}}(1 - \theta)^{n-n\bar{x}} : \theta \in [0, 1]\}$ no conjunto de todas as sequências $(x_1, \ldots, x_n)$ de 0s e 1s. O espaço de ações é $\mathcal{A} = [0, 1]$, a função de ação correta é $A(\theta) = \theta$ e a função de perda[35] é $L(\theta, a) = (\theta - a)^2$. A função de risco[36] de T é $R_T(\theta) = \text{Var}_\theta(\bar{x}) = \theta(1 - \theta)/n$.

8.4.3 O modelo é o conjunto de densidades $\{(2\pi\sigma_0^2)^{-1/2} \exp\{-\sum_{i=1}^n (x_i - \mu)^2/2\sigma_0^2\} : \mu \in R^1\}$ em R^n.* O espaço de ações é $\mathcal{A} = R^1$, a função de ação correta é $A(\mu) = \mu$ e a função de perda é $L(\mu, a) = (\mu - a)^2$. A função de risco de T é $R_T(\mu) = \text{Var}_\mu(\bar{x}) = \sigma_0^2/n$.

8.4.5

(a) $R_d(a) = 1/2$, $R_d(b) = 3/4$

(b) Não. Considere a função de risco da função de decisão[37] d^* dada por $d^*(1) = b$, $d^*(2) = a$, $d^*(3) = b$, $d^*(4) = a$.

Capítulo 9

9.1.1 A estatística de discrepância[38] observada é dada por $D(r) = 22{,}761$ e o valor-p é $P(D(R) > 22{,}761) = 0{,}248$, o que não sugere evidência contra o modelo.

9.1.3

*Nota do tradutor. O original traz o expoente $-1/2$; para a densidade da amostra de tamanho n, seria $(2\pi\sigma_0^2)^{-n/2}$.

No original: *weak law of large numbers*[34], *loss function*[35], *risk function*[36], *decision function*[37], *discrepancy statistic*[38].

(c) Os gráficos sugerem que a suposição de normalidade parece razoável.

9.1.5 As contagens observadas são dadas na tabela a seguir.

Intervalo	Contagem
(0,0; 0,2]	4
(0,2; 0,4]	7
(0,4; 0,6]	3
(0,6; 0,8]	4
(0,8; 1]	2

A estatística qui-quadrado é igual a 3,50 e o valor-p é dado por ($X^2 \sim \chi^2(4)$) $P(X^2 \geq 3{,}5) = 0{,}4779$. Portanto, não temos evidência contra a correção do modelo Uniforme.

9.1.7

(a) A probabilidade do evento $s = 3$ é 0 com base na medida de probabilidade[39] P que tem S como suporte. O valor-p mais apropriado é 0.

(b) 0,729

9.1.9 Não.

9.1.11

(a) A função de probabilidade condicional[40] de $(x_1, \ldots, x_n)$ é

$$\theta^{n\bar{x}}(1-\theta)^{n(1-\bar{x})} \Big/ \binom{n}{n\bar{x}} \theta^{n\bar{x}}(1-\theta)^{n(1-\bar{x})} = 1 \Big/ \binom{n}{n\bar{x}}.$$

(b) Hipergeométrica$(n, \lfloor n/2 \rfloor, n\bar{x}_0)$

(c) 0,0476

9.2.1

(a) Não.

(b) O valor-p é 1/10, então há pouca evidência de conflito entre a priori e dados[41].

(c) O valor-p é 1/300, então há alguma evidência de conflito entre a priori e dados.

No original: *probability measure*[39], *conditional probability function*[40], *prior–data conflict*[41].

9.2.3 Podemos escrever $\bar{x} = \mu + z$, em que $z \sim N(0, \sigma_0^2/n)$ é independente de $\mu \sim N(\mu_0, \tau_0^2)$.

9.2.5 O valor-p para verificar o conflito entre a priori e dados é 0. Logo, há com certeza um conflito entre a priori e dados.

Capítulo 10

10.1.1 Para quaisquer x_1, x_2 (que ocorram com probabilidade positiva) e y, temos $P(Y = y \mid X = x_1) = P(Y = y \mid X = x_2)$. Assim, $P(X = x_1, Y = y) = P(X = x_2, Y = y)P(X = x_1)/P(X = x_2)$, e somar isso em x_1 leva a $P(X = x_2, Y = y) = P(X = x_2)P(Y = y)$. Para a recíproca[42], mostre que $P(Y = y \mid X = x) = P(Y = y)$.

10.1.3 X e Y são relacionadas.

10.1.5 As distribuições condicionais $P(Y = y \mid X = x)$ mudam com x sempre que X não é degenerada.

10.1.7 Se a distribuição condicional[43] do tempo de vida[44] dados diversos hábitos de fumo muda, podemos concluir que essas duas variáveis são relacionadas, mas não podemos concluir que essa relação é uma relação de causa e efeito, por causa da possível existência de variáveis de confusão.

10.1.9 O pesquisador deve retirar uma amostra aleatória da população de eleitores e pedir que eles meçam sua atitude em relação a um determinado partido político numa escala que vai de favoravelmente disposto a desfavoravelmente disposto. Em seguida, o pesquisador deve selecionar aleatoriamente metade dessa amostra para ser exposta a uma propaganda negativa, enquanto a outra metade é exposta a uma propaganda positiva. Depois, todos devem ser solicitados a medir sua atitude em relação ao mesmo partido político na mesma escala. Em seguida, compare a distribuição condicional da variável resposta[45] Y (a mudança de atitude de antes de ver a propaganda para depois), dado o preditor[46] X (tipo de propaganda a que foi exposto), usando as amostras para fazer inferência sobre essas distribuições.

10.1.11

(a) $\{(0, 100), (1, 100)\}$

No original: *converse*[42], *conditional distribution*[43], *lifelength*[44], *response variable*[45], *predictor*[46].

(b) Não foi retirada uma amostra da população de interesse. Os indivíduos envolvidos no estudo se ofereceram como voluntários e, como grupo, podem ser muito diferentes da população toda.

(c) Devemos agrupar os indivíduos de acordo com seu peso inicial W em grupos homogêneos (blocos) e então aplicar aleatoriamente os tratamentos aos indivíduos de cada bloco.

10.1.13

(a) A variável resposta[47] poderia ser o número de vezes que um indivíduo assistiu ao programa. Uma variável preditora[48] adequada é se ele recebeu ou não o folheto.

(b) Sim, já que controlamos a atribuição da variável preditora.

10.1.15 W tem relação com Y e X tem relação com Y.

10.1.17

(a)

	$X=0$	$X=1$	Soma
Freq. rel.	0,5	0,5	1,0

(b)

	$Y=0$	$Y=1$	Soma
Freq. rel.	0,7	0,3	1,0

(c)

Freq. rel.	$X=0$	$X=1$	Soma
$Y=0$	0,3	0,4	0,7
$Y=1$	0,2	0,1	0,3
soma	0,5	0,5	1,0

(d)

$P(Y=y \mid X=x)$	$y=0$	$y=1$	Soma
$x=0$	0,6	0,4	1,0
$x=1$	0,8	0,2	1,0

No original: *response variable*[47], *predictor variable*[48].

(e) Sim.

10.1.19 X e Y são relacionadas. Vemos que só a variância da distribuição condicional muda quando mudamos X.

10.1.21 A correlação[49] é 0, mas X e Y são relacionadas.

10.2.1 A estatística qui-quadrado é igual a $X_0^2 = 5{,}7143$ e, com $X^2 \sim \chi^2(2)$, o valor-p é igual a $P(X^2 > 5{,}7143) = 0{,}05743$. Portanto, não temos evidência contra a hipótese nula de que não há diferença nas distribuições das tempestades entre os dois anos, pelo menos ao nível 0,05.*

10.2.3 A estatística qui-quadrado é igual a $X_0^2 = 0{,}10409$ e, com $X^2 \sim \chi^2(1)$, o valor-p é igual a $P(X^2 > 4{,}8105) = 0{,}74698$. Portanto, não temos evidência contra a hipótese nula de que não há relação entre os dois dígitos.†

10.2.5

(a) A estatística qui-quadrado é igual a $X_0^2 = 10{,}4674$ e, com $X^2 \sim \chi^2(4)$, o valor-p é igual a $P(X^2 > 10{,}4674) = 0{,}03325$. Portanto, temos alguma evidência contra a hipótese nula de que não há relação entre a cor do cabelo e o sexo.

(c) Os resíduos padronizados são dados na tabela a seguir. Todos parecem razoáveis, de modo que nada se destaca como explicação de por que o modelo de independência não se ajusta. No geral, parece que um tamanho da amostra[50] grande detectou uma diferença pequena.

	$Y =$ loiro	$Y =$ ruivo	$Y =$ médio	$Y =$ escuro	$Y =$ preto-azeviche
$X =$ m	−1,07303	0,20785	1,05934	−0,63250	1,73407
$X =$ f	1,16452	−0,22557	−1,14966	0,68642	−1,88191

10.2.7 Devemos primeiro gerar um valor de $X_1 \sim \text{Dirichlet}(1, 3)$. Em seguida, gere U_2 da distribuição Beta$(1, 2)$ e faça $X_2 = (1 - X_1)U_2$. Depois, gere U_3 da distribuição Beta$(1, 1)$ e faça $X_3 = (1 - X_1 - X_2)U_3$. Por fim, faça $X_4 = 1 - X_1 - X_2 - X_3$.

*__Nota do tradutor.__ O original fala em tempestades (“thunderstorms”), mas o enunciado do Exercício 10.2.1 dá contagens de acidentes.

†__Nota do tradutor.__ O original traz $P(X^2 > 4{,}8105)$; pela conta seria $P(X^2 > 0{,}10409)$, que dá o 0,74698 impresso.

No original: *correlation*[49], *sample size*[50].

10.2.9 Então há 36 pares possíveis (i, j), para $i, j = 1, \ldots, 6$. Seja f_{ij} a frequência de (i, j) e calcule a estatística qui-quadrado

$$X^2 = \sum_{i=1}^{6} \sum_{j=1}^{6} (f_{ij} - f_{i.} f_{.j}/n)^2 / (f_{i.} f_{.j}/n).$$

Calcule o valor-p $P(\chi^2(25) > X^2)$.

10.2.11 Olhamos as diferenças $|f_{ij} - f_{i.} f_{.j}/n|$ para ver quão grandes elas são.

10.3.1 $\bar{x}$

10.3.3 $\bar{x}$

10.3.5

(b) $y = 29{,}9991 + 2{,}10236x$

(e) O gráfico dos resíduos padronizados contra X indica muito claramente que há um problema com esse modelo.

(f) Com base no item (e), não é apropriado calcular intervalos de confiança para o intercepto e a inclinação.

(g) Nada pode ser concluído sobre a relação entre Y e X com base nesse modelo, já que determinamos que ele é inadequado.

(h) $R^2 = 486{,}193/7842{,}01 = 0{,}062$, que é muito baixo.

10.3.7

(b) $b_2 = 1{,}9860$ e $b_1 = 58{,}9090$

(d) O resíduo padronizado[51] da nona semana se afasta dos outros resíduos do item (c). Isso fornece alguma evidência de que o modelo não está correto.

(e) O intervalo de confiança para β_1 é $[44{,}0545; 72{,}1283]$ e o intervalo de confiança para β_2 é $[0{,}0787; 3{,}8933]$.

(f) A tabela ANOVA é a seguinte.

Fonte	GL	Soma de Quadrados	Quadrado Médio
X	1	564,0280	564,0280
Erro	10	1047,9720	104,7972
Total	11	1612,0000	

No original: *standardized residual*[51].

Então a estatística F é $F = 5{,}3821$ e $P(F(1,10) \geq 5{,}3821) < 0{,}05$, pela Tabela D.5. Logo, concluímos que há evidência contra a hipótese nula de que não há relação linear entre a resposta e o preditor.

(g) $R^2 = 0{,}3499$, então quase 35% da variação observada na resposta é explicada por mudanças no preditor.

10.3.9 Em geral, $E(Y \mid X) = \exp(\beta_1 + \beta_2 X)$ não é um modelo de regressão linear simples[52], já que não pode ser escrito na forma $E(Y \mid X) = \beta_1^* + \beta_2^* V$, em que V é uma variável observada e os β_i^* são valores de parâmetros não observados.

10.3.11 Podemos escrever $E(Y \mid X) = E(Y \mid X^2)$ nesse caso e $E(Y \mid X^2) = \beta_1 + \beta_2 X^2$; então esse é um modelo de regressão linear simples, mas o preditor é X^2, e não X.

10.3.13 $R^2 = 0{,}05$ indica que o modelo linear explica só 5% da variação na resposta, de modo que o modelo não terá muito poder preditivo.

10.4.1

(b) Os dois gráficos parecem razoáveis, sem indicar nenhuma preocupação séria com a correção das hipóteses do modelo.

(c) A tabela ANOVA para testar $H_0 : \beta_1 = \beta_2 = \beta_3$ é dada a seguir.

Fonte	GL	SQ	QM
A	2	4,37	2,18
Erro	9	18,85	2,09
Total	11	23,22	

A estatística F para testar H_0 é dada por $F = 2{,}18/2{,}09 = 1{,}0431$, com valor-p $P(F > 1{,}0431) = 0{,}39135$. Portanto, não temos evidência contra a hipótese nula de que não há diferença entre as médias condicionais de Y dado X.

(d) Como não encontramos nenhuma relação entre Y e X, não há necessidade de calcular esses intervalos de confiança.

10.4.3

(b) Os dois gráficos indicam um possível problema com as hipóteses do modelo.

(c) A tabela ANOVA para testar $H_0 : \beta_1 = \beta_2$ é dada a seguir.

No original: *simple linear regression model*[52].

Fonte	GL	SQ	QM
Queijo	1	0,114	0,114
Erro	10	26,865	2,686
Total	11	26,979	

A estatística F para testar H_0 é dada por $F = 0{,}114/2{,}686 = 0{,}04$ e, com o valor-p $P(F > 0{,}04) = 0{,}841$, não temos nenhuma evidência contra a hipótese nula de que não há diferença entre as médias condicionais de Y dado Queijo.

10.4.5

(b) Os dois gráficos parecem razoáveis, sem indicar nenhuma preocupação com a correção das hipóteses do modelo.

(c) A tabela ANOVA para testar $H_0 : \beta_1 = \beta_2 = \beta_3 = \beta_4$ é a seguinte.

Fonte	GL	SQ	QM
Tratamento	3	19,241	6,414
Erro	20	11,788	0,589
Total	23	31,030	

A estatística F para testar H_0 é dada por $F = 6{,}414/0{,}589 = 10{,}89$ e, com valor-p $P(F > 10{,}89) = 0{,}00019$, temos forte evidência contra a hipótese nula de que não há diferença entre as médias condicionais de Y, dado o preditor.

(d) Os intervalos de confiança 0,95 para a diferença (média do nível da coluna) − (média do nível da linha) entre as médias são dados na tabela a seguir.*

	1	**2**	**3**
2	(−3913; 1,4580)		
3	(−2,2746; −0,4254)	(−2,8080; −0,9587)	
4	(−2,5246; −0,6754)	(−3,0580; −1,2087)	(−1,1746; 0,6746)

10.4.7

(b) Tratando as notas como amostras separadas, a tabela ANOVA para testar qualquer diferença entre a nota média em cálculo e a nota média em estatística é a seguinte.

*Nota do tradutor. O original traz −3913 no primeiro intervalo; pelas médias dos dados (diferença 0,5333 no centro do intervalo), seria −0,3913.

Fonte	GL	SQ	QM
Disciplina	1	36,45	36,45
Erro	18	685,30	38,07
Total	19	721,75	

A estatística F para testar $H_0 : \beta_1 = \beta_2$ é dada por $F = 36{,}45/38{,}07 = 0{,}95745$, com o valor-p igual a $P(F > 0{,}95745) = 0{,}3408$. Portanto, não temos nenhuma evidência contra a hipótese nula de que não há diferença entre as médias condicionais de Y dada a Disciplina.

Os dois gráficos de resíduos parecem razoáveis, sem indicar nenhuma preocupação com a correção das hipóteses do modelo.

(c) Tratando esses dados como medidas repetidas, a diferença média entre a nota em cálculo e a nota em estatística é dada por $\bar{d} = -2{,}7$, com desvio padrão[53] $s = 2{,}00250$. O valor-p para testar $H_0 : \mu_1 = \mu_2$ é 0,0021, então temos forte evidência contra a hipótese nula. Logo, concluímos que há uma diferença entre a nota média em cálculo e a nota média em estatística. Um gráfico de probabilidade normal[54] dos dados não indica nenhum motivo para duvidar das hipóteses do modelo.

(d) $r_{xy} = 0{,}944155$

10.4.9 Quando Y_1 e Y_2 são medidos no mesmo indivíduo, temos que $\text{Var}(Y_1 - Y_2) = 2(\text{Var}(Y_1) - \text{Cov}(Y_1, Y_2)) > 2\,\text{Var}(Y_1)$, já que $\text{Cov}(Y_1, Y_2) < 0$. Se tivéssemos medido Y_1 e Y_2 em indivíduos selecionados aleatoriamente de forma independente, teríamos $\text{Var}(Y_1 - Y_2) = 2\,\text{Var}(Y_1)$.

10.4.11 A diferença entre as duas respostas Y_1 e Y_2 tem distribuição normal, isto é, $Y_1 - Y_2 \sim N(\mu, \sigma^2)$.

10.4.13 (1) A distribuição condicional de Y, dado (X_1, X_2), depende de (X_1, X_2) só por meio de $E(Y \mid X_1, X_2)$, e o erro $Z = Y - E(Y \mid X_1, X_2)$ é independente de (X_1, X_2). (2) O erro $Z = Y - E(Y \mid X_1, X_2)$ tem distribuição normal. (3) X_1 e X_2 não interagem.

10.5.1

$$F(x) = \int_{-\infty}^{x} e^{-t}\left(1 + e^{-t}\right)^{-2} dt = \left(1 + e^{-t}\right)^{-1}\Big|_{-\infty}^{x} = \left(1 + e^{-x}\right)^{-1} \to 1$$

quando $x \to \infty$, e $p = F(x)$ implica $x = \ln(p/(1-p))$.

No original: *standard deviation*[53], *normal probability plot*[54].

10.5.3 Seja $l = l(p) = \ln(p/(1-p))$ o log da chance, de modo que $e^l = p/(1-p) = 1/(1/p - 1)$. Logo, $e^l/(1+e^l) = p$; agora substitua $l = \beta_1 + \beta_2 x$.

10.5.5 $P(Y = 1 \mid X_1 = x_1, \ldots, X_k = x_k) = 1/2 + \arctan(\beta_1 x_1 + \cdots + \beta_k x_k)/\pi$

Capítulo 11

11.1.1

(a) 0

(b) 0

(c) 1/3

(d) 2/3

(e) 0

(f) 4/9

(g) 0

(h) 1/9

(i) 0

(j) 0

(k) 0,00925

(l) 0

(m) 0,0987

11.1.3

(a) 5/108

(b) 5/216

(c) 5/72

(d) Pela lei da probabilidade total[55], $P(X_3 = 8) = P(X_1 = 6, X_3 = 8) + P(X_1 = 8, X_3 = 8)$.

11.1.5

(a) Aqui, $P(\tau_c < \tau_0) = 0{,}89819$. Isto é, se você começa com US$ 9 e faz repetidamente apostas de US$ 1 com probabilidade 0,499 de ganhar cada

No original: *law of total probability*[55].

aposta, então a probabilidade de você chegar a US$ 10 antes de perder todo o seu dinheiro é igual a 0,89819.

(b) 0,881065

(c) 0,664169

(d) 0,0183155

(e) 4×10^{-18}

(f) 2×10^{-174}

11.1.7 Usamos o Teorema 11.1.1.

(a) 1/4

(b) 3/4

(c) 0,0625

(d) 1/4

(e) 0

(f) 1

(g) Sabemos que a fortuna inicial é 5; então, para chegar a 7 em dois passos, o passeio tem de ter estado em 6 depois do primeiro passo.

11.1.9

(a) 18/38

(b) 0,72299

(c) 0,46056

(d) 0

(e) No longo prazo, o jogador perde dinheiro.

11.2.1

(a) 0,7

(b) 0,1

(c) 0,2

(d) 1/4

(e) 1/4

(f) 1/2

(g) 0,3

11.2.3

(a) $P_0(X_2 = 0) = 0{,}28$, $P_0(X_2 = 1) = 0{,}72$, $P_1(X_2 = 0) = 0{,}27$, $P_1(X_2 = 1) = 0{,}73$

(b) $P_0(X_3 = 1) = 0{,}728$

11.2.5

(a) 1/2

(b) 0

(c) 1/2

(d) 1/2

(e) 1/10

(f) 2/5

(g) 37/100

(h) 11/20

(i) 0

(j) 0

(k) 0

(l) 0

(m) Não.

11.2.7 Essa cadeia é duplamente estocástica, isto é, tem $\sum_i p_{ij} = 1$ para todo j. Logo, a distribuição uniforme ($\pi_1 = \pi_2 = \pi_3 = \pi_4 = 1/4$) tem de ser uma distribuição estacionária[56].

11.2.9

(a) Aumentando ou diminuindo um passo de cada vez, vemos que, para todos i e j, temos $p_{ij}^{(n)} > 0$ para algum $n \leq d$.

(b) Cada estado tem período 2.

(c) Se i e j distam dois ou mais, então $p_{ij} = p_{ji} = 0$. Se $j = i + 1$, então $\pi_i p_{ij} = (1/2^d)((d-1)!/i!(d-i-1)!)$, enquanto $\pi_j p_{ji} = (1/2^d)((d-1)!/i!(d-i-1)!)$.

No original: *stationary distribution*[56].

11.2.11

(a) Essa cadeia é irredutível[57].

(b) A cadeia é aperiódica[58].

(c) $\pi_1 = 2/9$, $\pi_2 = 3/9$, $\pi_3 = 4/9$

(d) $\lim_{n\to\infty} P_i(X_n = 2) = \pi_2 = 3/9 = 1/3$; então $P_i(X_{500} = 2) \approx 1/3$.

11.2.13 $P_i(X_1 + X_2 \geq 5) = 0{,}54$

11.2.15

(a) A cadeia é irredutível.

(b) A cadeia não é aperiódica.

11.3.1 Primeiro, escolha qualquer valor inicial X_0. Então, dado $X_n = i$, seja $Y_{n+1} = i + 1$ ou $i - 1$, com probabilidade 1/2 cada. Seja $j = Y_{n+1}$ e seja $\alpha_{ij} = \min\left(1, e^{-(j-13)^4+(i-13)^4}\right)$. Então faça $X_{n+1} = j$ com probabilidade α_{ij}; caso contrário, faça $X_{n+1} = i$ com probabilidade $1 - \alpha_{ij}$.

11.3.3 Primeiro, escolha qualquer valor inicial X_0. Então, dado $X_n = i$, seja $Y_{n+1} = i + 1$ com probabilidade 7/9 ou $Y_{n+1} = i - 1$ com probabilidade 2/9. Seja $j = Y_{n+1}$ e, se $j = i + 1$, seja

$$\alpha_{ij} = \min\left(1, e^{-j^4-j^6-j^8}(2/9)\Big/e^{-i^4-i^6-i^8}(7/9)\right)$$

ou, se $j = i - 1$, seja

$$\alpha_{ij} = \min\left(1, e^{-j^4-j^6-j^8}(7/9)\Big/e^{-i^4-i^6-i^8}(2/9)\right).$$

Então faça $X_{n+1} = j$ com probabilidade α_{ij}; caso contrário, faça $X_{n+1} = i$ com probabilidade $1 - \alpha_{ij}$.

11.3.5 Sejam $\{Z_n\}$ i.i.d. $\sim N(0, 1)$. Primeiro, escolha qualquer valor inicial X_0. Então, dado $X_n = x$, seja $Y_{n+1} = X_n + \sqrt{10}\, Z_{n+1}$. Seja $y = Y_{n+1}$ e seja

$$\alpha_{xy} = \min\left(1,\ \exp\{-y^4 - y^6 - y^8 + x^4 + x^6 + x^8\}\right).$$

Então faça $X_{n+1} = y$ com probabilidade α_{xy}; caso contrário, faça $X_{n+1} = x$ com probabilidade $1 - \alpha_{xy}$.

11.4.1 $C = 12/5$

11.4.3 $p = 1/3$

No original: *irreducible*[57], *aperiodic*[58].

11.4.5 $P(X_n = 4) = 5/8$.*

11.4.7

(a) Aqui, $E(X_{n+1} \mid X_n) = (1/4)(3X_n) + (3/4)(X_n/3) = X_n$.

(b) T é não negativo[59], assume valores inteiros e não olha para o futuro; logo, é um tempo de parada[60].

(c) $E(X_T) = X_0 = 27$.

(d) $P(X_T = 1) = 27/40$

11.5.1

(a) 1/2

(b) 0

(c) 1/4

(d) Temos $P\left(Y_1^{(M)} \geq 1\right) = P\left(Y_{M/M}^{(M)} \geq \sqrt{M}/\sqrt{M}\right)$. Logo, $P\left(Y_1^{(1)} \geq 1\right) = 1/2$, $P\left(Y_1^{(2)} \geq 1\right) = 1/4$, $P\left(Y_1^{(3)} \geq 1\right) = 3/8$, $P\left(Y_1^{(4)} \geq 1\right) = 5/16$.

11.5.3

(a) $P(B_2 \geq 1) = \Phi(-1/\sqrt{2})$

(b) $P(B_3 \leq -4) = \Phi(-4/\sqrt{3})$

(c) $P(B_9 - B_5 \leq 2{,}4) = 1 - \Phi(-2{,}4/2)$

(d) $P(B_{26} - B_{11} > 9{,}8) = \Phi(-9{,}8/\sqrt{15})$

(e) $P(B_{26{,}3} \leq -6) = \Phi(-6/\sqrt{26{,}3})$

(f) $P(B_{26{,}3} \leq 0) = \Phi(0/\sqrt{26{,}3}) = 1/2$

11.5.5 $E(B_{13}B_8) = 8$

11.5.7

(a) 3/4

(b) 1/4

(c) A resposta do item (a) é maior porque -5 está mais perto de $B_0 = 0$ do que 15, enquanto -15 está mais longe do que 5.

*__Nota do tradutor.__ O original traz X_n; o enunciado do Exercício 11.4.5 pede $P(X_8 = 4)$.

No original: *nonnegative*[59], *stopping time*[60].

(d) $1/4$

(e) Temos $3/4 + 1/4 = 1$, como tem de ser, já que os eventos dos itens (a) e (d) são complementares.

11.5.9 $E(X_3X_5) = 61{,}75$

11.5.11

(a) $P(X_{10} > 250) = \Phi(-20/1\sqrt{10})$

(b) $P(X_{10} > 250) = \Phi(-20/4\sqrt{10})$

(c) $P(X_{10} > 250) = \Phi(-20/10\sqrt{10})$

(d) $P(X_{10} > 250) = \Phi(-20/100\sqrt{10})$

11.6.1

(a) $e^{-14}14^{13}/13!$

(b) $e^{-35}35^{3}/3!$

(c) $e^{-42}42^{20}/20!$

(d) $e^{-350}350^{340}/340!$

(e) 0

(f) $\left(e^{-14}14^{13}/13!\right)\left(e^{-21}21^{7}/7!\right)$

(g) 0

11.6.3 $P(N_2 = 6) = e^{-2/3}(2/3)^6/6!$, $P(N_3 = 5) = e^{-3/3}(3/3)^5/5!$

11.6.5 $P(N_{2,6} = 2 \mid N_{2,9} = 2) = (2{,}6/2{,}9)^2$